


Análisis exploratorio, limpieza y transformación de datos

Cátedra Ciencia de Datos
Ingeniería en Sistemas de Información
UTN – Facultad Regional Rosario

CRISP-DM: ¿Dónde nos encontramos?





Análisis exploratorio de datos

- Análisis descriptivo de las variables en estudio (*análisis univariante*):
 - ◆ Numérico: media, mediana, varianza, desvío
 - ◆ Gráfico: Box Plot, histogramas, gráficos de barras, gráfico de torta.

- Análisis de relaciones entre variables (*análisis multivariante*):
 - ◆ Numérico: Vector de medias, Matriz **S**, Matriz **R**
 - ◆ Gráfico: Gráfico de dispersión 2D y 3D, gráfico barras apiladas, box plot y dispersión estratificados.



Análisis exploratorio

¿Cuándo utilizar cada tipo de gráfico?

ANÁLISIS UNIVARIANTE

Variable numérica

Variable cualitativa



Histogram



Quartile



Bars



Pie



Análisis exploratorio

¿Cuándo utilizar cada tipo de gráfico?


ANÁLISIS MULTIVARIANTE

2 numericas



Scatter

2 cualitativas



Bars Stacked

1 numérica y 1 cualitativa



Histogram Color



Quartile Color

2 numéricas y 1 cualitativa



Scatter

Y mucho más!



Limpieza y transformación de datos

Limpieza de datos:

- Tratamiento de datos ausentes (NA, Not available)
- Tratamiento de valores atípicos (Outliers)

Tratamiento de datos ausentes (NA, Not available)

- Tratamiento de valores atípicos (Outliers)



Limpieza: Manejando datos faltantes

Bajo el supuesto de que los datos faltantes (NA, Not Available) se distribuyen aleatoriamente en la muestra, es posible utilizar métodos de supresión o imputación:

Existen 3 caminos posibles:

- **Suprimir** casos (filas) o variables (columnas)
- Estimar o **imputar** los valores faltantes, asumiendo los errores de imputación.
- Dejar los NA, seleccionando modelos que sean robustos a datos faltantes.



Limpieza: Manejando datos faltantes

Opciones para imputación de datos faltantes:

- Imputación por el promedio.
- Imputación por la mediana.
- Imputación por la moda (variables categóricas).
- Imputación por algoritmos de regresión, Machine Learning o Deep Learning.



Limpieza: Detección de outliers

Detección univariante de casos atípicos

- Gráfico de caja y bigotes
- Estadísticos robustos de la variable

Detección bivariante de casos atípicos

- Gráfico de caja y bigotes
- Gráficos de dispersión

Detección multivariante de casos atípicos

- Estadísticos basados en distancia
- Análisis de componentes principales



Transformación de datos

La transformación de datos es clave en el proceso de minería de datos, y se realiza en forma iterativa hasta encontrar un modelo que nos resulte útil para el problema en estudio. Aquí el ingeniero de datos utiliza su creatividad, para representar la información disponible de una forma diferente.

Algunos ejemplos de transformación de datos son:

- Estandarización de una variable numérica,
- Creación de una variable cualitativa a partir de una numérica,
- Agrupación de categorías en una variable cualitativa,
- Creación de variables calculadas
- y mucho más!