

Limpieza y transformación de datos

Cátedra Ciencia de Datos
Ingeniería en Sistemas de Información
UTN – Facultad Regional Rosario

Manejando datos faltantes

Existen 3 caminos posibles:

- Eliminar cada registro que contiene un valor nulo.
- Estimar o imputar los valores faltantes. Asumiendo los errores de imputación.
- Seleccionar modelos que sean robustos a datos faltantes.

Manejando datos faltantes

Imputación de datos faltantes:

- Imputación por la moda o por valores cero. Útil para variables categóricas (ser cuidadosos, puede introducir un sesgo).
- Imputación por el promedio.
- Imputación por la mediana.
- Métodos de Machine Learning.
- Métodos de Deep Learning.

Manejando datos incorrectos o inconsistentes

Existen 3 métodos para detectarlos:

- Suele suceder cuando los datos vienen de distintas fuentes. Por ejemplo para el campo nombre tener el nombre completo y en otros registros las iniciales.
- Conocimiento del dominio. Si analizo los datos y encuentro un valor que sabemos que es imposible. Por ejemplo si estamos utilizando datos de ciudadanos de Argentina, alguien que viva en la ciudad Nueva York.
- Detección de outliers mediante métodos numéricos.

Normalización y escalamiento

Muchas veces las distintas columnas contienen distintas escalas y no pueden compararse entre sí. Hay algunos métodos de clasificación o clustering basados en distancias que pueden ser dominados por las variables que tengan mayor magnitud. Para eso es común **estandarizar** los datos.

$$z_i^j = \frac{x_i^j - \mu_j}{\sigma_j}$$

Normalización y escalamiento

Otro camino posible es realizar un escalamiento min - max para mapear todos los atributos al rango [0,1].

$$y_i^j = \frac{x_i^j - \min_j}{\max_j - \min_j}$$

Este método no sirve cuando el máximo y el mínimo son valores extremos (outliers). Por eso la estandarización es más robusta.