

Análisis exploratorio, limpieza y transformación de datos

Cátedra Ciencia de Datos
Ingeniería en Sistemas de Información
UTN – Facultad Regional Rosario

Medidas de Posición UNIVARIANTE

◆ Media

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{x_1 + x_2 + \dots + x_n}{n}$$

◆ Mediana

$$\frac{xN + 1}{2}$$

◆ Quartiles Q1, Q2, Q3

Son los 3 valores de la variable que dividen a un conjunto de datos ordenado en 4 partes iguales.





Medidas de Dispersión UNIVARIANTE

◆ Varianza

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$$

◆ Desvío estándar

$$\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2}$$



Medidas de Posición MULTIVARIANTE



Vector de Medias

Vector formado por las medias de cada variable

$$\bar{\mathbf{X}} = \frac{1}{n} \mathbf{X}' \mathbf{1} = \begin{bmatrix} \bar{X}_1 \\ \bar{X}_2 \\ \vdots \\ \bar{X}_p \end{bmatrix}$$


Medidas de Dispersión MULTIVARIANTE

- ◆ **Covarianza:**
La covarianza mide la relación lineal entre dos variables.

$$Cov(X, Y) = \frac{\sum_1^n (x_i - \bar{x})(y_i - \bar{y})}{n}$$

- ◆ **Correlación**
La correlación mide tanto la fuerza como la dirección de la relación lineal entre dos variables.

$$\frac{Cov(X, Y)}{D(X) D(Y)}$$



Medidas de Dispersión MULTIVARIANTE

◆ Ejemplo covarianza y correlación.

Los valores de covarianza **no están estandarizados**. La covarianza puede ir desde infinito negativo hasta infinito positivo. Es difícil determinar la fuerza de la relación entre las variables. En cambio en la **correlación** si podemos cuantificar la intensidad de la relación lineal, ya que está estandarizada. Siempre su valor estará entre -1 y 1.

$$X = (x_1, x_2, x_3) = (0, 4, 8)$$

$$Y = (y_1, y_2, y_3) = (5, 5, 8)$$

$$\bar{x} = \frac{0 + 4 + 8}{3} = 4$$

$$\bar{y} = \frac{5 + 5 + 8}{3} = 6$$

$$Cov(X, Y) = (0 - 4)(5 - 6) + (4 - 4)(5 - 6) + (8 - 4)(8 - 6)$$

$$Cov(X, Y) = 4$$

$$Corr(X, Y) = \frac{Cov(X, Y)}{D(X)D(Y)} = \frac{4}{4 \times 1,73} = 0,58$$