




Ciencia de Datos

Evolución del concepto “Ciencia de Datos”

- **1750 – 1970:** Probabilidad y Estadística
- **1970 – 1990:** Análisis de Datos (Exploratory Data Analysis), SQL
- **1990 – 2000:** OLAP (Online Analytical Processing)
- **2000 – 2005:** Minería de Datos, Business Intelligence
- **2005 – 2011:** Modelos Predictivos, Analytics, Machine Learning
- **2011 – 2015:** Big Data, Big Data Analytics.
- **2015 – presente:** Ciencia de Datos o Ingeniería de Datos

<https://pcweb.info/historia-del-data-science-la-ciencia-de-datos/#2015>

UTN - FRRo - Ciencia de Datos

2

Ciencia de Datos

Preguntas:

- ¿Cuál es el valor de los clientes?
- ¿Cuáles son los clientes que tienen mayor probabilidad de desertar?
- ¿Qué clientes permanecerán fieles?
- ¿Qué clientes están a punto de abandonar?
- ¿Cuáles son los productos que se venden en forma conjunta?
- ¿Dónde debemos localizar la próxima sucursal?
- ¿Qué productos se deben promocionar a qué grupo?
-


Respuestas:

- Están en los datos del usuario
- Se necesitan herramientas especiales para encontrarlas

UTN - FRRo - Ciencia de Datos

3

D, I, C, I, W



Ciencia de Datos

La ciencia de datos es un conjunto de técnicas que se utilizan para extraer valor de los datos. Estas técnicas se basan en encontrar patrones, conexiones y relaciones útiles dentro de los datos. El objetivo final de la ciencia de datos es encontrar conclusiones potencialmente útiles que los usuarios de análisis puedan aplicar.

Objetivo: convertir DATOS en CONOCIMIENTO

Data Science Concepts and Practice

UTN - FRRo - Ciencia de Datos

5

Ciencia de Datos – Características claves

- Extracción de patrones significativos
- Construcción de modelos representativos
- Combinación de estadísticas, aprendizaje automático y computación
- Algoritmos de aprendizaje
- Campos asociados
 - Estadística descriptiva
 - Visualización exploratoria
 - Análisis OLAP
 - Prueba de hipótesis
 - Ingeniería de datos
 - Business Intelligence

Data Science Concepts and Practice

UTN - FRRo - Ciencia de Datos

6

Ciencia de Datos



La ciencia de datos también se conoce comúnmente como *descubrimiento de conocimiento (KDD)*, *aprendizaje automático*, *análisis predictivo* y *minería de datos*. Sin embargo, cada término tiene una connotación ligeramente diferente según el contexto.

Data Science Concepts and Practice

UTN - FRRo - Ciencia de Datos

7

Ciencia de Datos - KDD



- Descubrimiento de conocimiento en BD: proceso no trivial de identificar patrones válidos, novedosos, potencialmente útiles y comprensibles a partir de los datos.
- Proceso **automático o semiautomático** (asistido).

Clementine User Guide


UTN - FRRo - Ciencia de Datos

8

Ciencia de Datos - KDD



Ciencia de Datos: Descubrimiento de **conocimiento** en BD (knowledge discovery in databases)



UTN - FRRo - Ciencia de Datos

9

Minería de Datos



- Minería de datos: Variedad de técnicas para identificar información desde un conjunto de datos, y extraer esta de modo que pueda ser dispuesta para su uso en áreas tales como soporte de decisión, pronósticos y estimaciones.
- Los datos son frecuentemente voluminosos, en su forma actual no se puede hacer uso directo de ellos. **Es la información oculta en ellos la que es útil.**

Objetivo: convertir DATOS en INFORMACION

Clementine User Guide

UTN - FRRo - Ciencia de Datos

10

Aplicaciones



- Comercio / Marketing
 - Buscar asociaciones entre clientes y características demográficas
 - Predecir respuestas a campañas de marketing
 - Análisis de la canasta de compra (compras conjuntas, secuenciales, ventas cruzadas, etc.)
- Bancos
 - Detectar patrones de uso fraudulento de tarjetas
 - Identificar clientes leales
 - Análisis de riesgos en créditos

UTN - FRRo - Ciencia de Datos

11

Aplicaciones



- Medicina
 - Identificar terapias médicas satisfactorias para distintas enfermedades
 - Asociación de síntomas y patologías
 - Estudios epidemiológicos
 - Análisis de rendimientos de campañas de información
- Deportes
 - Descubrimiento de sinergias entre integrantes de equipos

UTN - FRRo - Ciencia de Datos

12

Aplicaciones



- Seguros y salud
 - Análisis de procedimientos médicos realizados en conjunto
 - Identificar patrones de comportamiento en clientes con riesgo
 - Detectar comportamiento fraudulento
- Transportes
 - Determinar logística de distribución
 - Analizar patrones de carga

Aplicaciones



- Procesos industriales
 - Predicción de fallos
 - Modelos de calidad (costos / beneficios)
- Telecomunicaciones
 - Modelos de carga en redes
 - Detección de fraudes
 - Determinar patrones en llamadas
- Educación
- Correo electrónico
 - Detección de spam


Minando Datos Complejos




- Datos Espaciales
- Datos Temporales
- Datos Secuenciales
- Datos Multimedia
- Word Wide Web
- Textos
- Redes Sociales




Minería Web




Relación con otras disciplinas



Ciencia de Datos





Ciencia de Datos

La ciencia de datos es la aplicación comercial del aprendizaje automático, la inteligencia artificial y otros campos cuantitativos como la estadística, la visualización y las matemáticas.



Es un campo interdisciplinario que extrae valor de los datos.

En el contexto de cómo se utiliza la ciencia de datos hoy en día, se basa en gran medida en el aprendizaje automático y, a veces, se la denomina minería de datos.

Algunos ejemplos de casos de uso de la ciencia de datos son: motores de recomendación que pueden recomendar películas para un usuario en particular, un modelo de alerta de fraude que detecta transacciones fraudulentas con tarjetas de crédito, encuentra clientes que probablemente se darán de baja el mes que viene o predice los ingresos para el próximo trimestre.

Data Science Concepts and Practice

UTN - FRRo - Ciencia de Datos 20



Científico de Datos

$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{x^2}{2\sigma^2}}$

Diseñar modelos y algoritmos

Simular escenarios futuros

Matemáticas y Estadísticas

- Machine learning
- Statistical Modeling
- Exploratory Analysis
- Clustering
- Regression Analysis

Conocimiento del Dominio y habilidades de Soft

- Inclination towards business operations
- Keep on working with data
- Problem solver
- Strategic, proactive and cooperative
- Interested in hacking

Comunicación y Visualización


- Storytelling skills
- Convert data-based insights into decisions
- Collaborative with Sr. Management
- Knowledge of tools like Tableau
- Visual art design

Programación


- Computer Science fundamentals
- Database Management System
- Data Visualization
- Python
- Big Data

Visualización

UTN - FRRo - Ciencia de Datos 23



Herramientas



25

¿Qué no se puede automatizar?

- La **elección de los problemas** de negocio candidatos para tareas de Data Mining
- La **identificación** y recolección de los **datos** que contienen la información buscada
- El **masajeo** y tratamiento de los datos que posibilita la búsqueda de patrones
- El **diseño** y cálculo de **variables derivadas**

UTN - FRRO - Ciencia de Datos

26


OLAP y Minería

- Las herramientas OLAP
 - Facilitan el “manejo” de los datos
 - **Producen datos informativos** (mas agregados, combinados)
 - Ayudan a analizar los datos porque producen diferentes vistas de los mismos
- Las herramientas de Minería:
 - Permiten extraer patrones, modelos, descubrir relaciones, regularidades, tendencias, etc
 - **Producen reglas o patrones (descubren).**

UTN - FRRO - Ciencia de Datos

27

Tipos de conocimientos



UTN - FRRO - Ciencia de Datos

28

Método Científico

La ciencia de datos es un proceso que invierte la dinámica del método científico en el siguiente sentido:


- En el método científico, primero se formula la hipótesis y luego se diseña el experimento para coleccionar los datos que confirmen o refuten la hipótesis.
- Si esto se hace con la formalidad adecuada (cuidando cuáles son las variables controladas y cuáles experimentales), se obtiene un nuevo conocimiento.
- En la ciencia de datos, se coleccionan los datos y se espera que de ellos emerjan hipótesis.

UTN - FRRO - Ciencia de Datos

29

Metodología CRISP-DM


CRISP-DM (**cross industry standard process for data mining**) fue desarrollada por las empresas DaimlerChrysler y SPSS, pioneras en la aplicación de técnicas data mining en los procesos de negocio.



UTN - FRRO - Ciencia de Datos

30

Metodología CRISP-DM




Fase I. Definición de necesidades del cliente (comprensión del negocio)
Fase II. Estudio y comprensión de los datos.
Fase III. Análisis de los datos y selección de características.
Fase IV. Modelado. Se aplican las técnicas de modelado que sean pertinentes al problema.
Fase V. Evaluación (Obtención de resultados)
Fase VI. Despliegue (Puesta en producción)

(Chapman et al., 2000).

Metodología CRISP-DM

datascience-pm.com Poll Results
 Which process do you most commonly use for data science projects?




<https://www.datascience-pm.com/crisp-dm-2/>

Encuesta año 2020

UTN - FRRO - Ciencia de Datos

32


Proceso de extracción de conocimiento - Fases



UTN - FRRO - Ciencia de Datos

33

Proceso de extracción de conocimiento - Fases



UTN - FRRO - Ciencia de Datos

34

KDD: 1 – Integración y recopilación Orígenes de datos

- Determinar las fuentes de información útiles
 - Transaccionales: ej. las operaciones realizadas con tarjeta de crédito
 - Relacionales: ej. la estructura de los productos que ofrece el Banco
 - Demográficos: ej. características del grupo familiar
 - Económicos: inflación, competencia, estudios mercado
- Diseñar y crear procesos ETL para cargar el DW

UTN - FRRO - Ciencia de Datos



35

KDD: 1 – Integración y recopilación Tipos de datos

- Espaciales
- Temporales
- Secuenciales
- Documentales
- Multimedia
- World Wide Web

UTN - FRRO - Ciencia de Datos

36



KDD: 2 – Selección, limpieza y transformación

- Por que las técnicas de aprendizaje automático y la estadística no son directamente aplicables?
- Características de los datos:
 - Gran volumen de datos
 - Distintos orígenes
 - Muy alta dimensionalidad
 - DATOS IMPERFECTOS (Garbage In – Garbage out)

UTN - FRRo - Ciencia de Datos 39

KDD: 2 – Selección, limpieza y transformación

- Los datos se organizan en una tabla plana compuesta por filas y columnas.
- Las Filas : unidad de análisis. Por ejemplo: una cuenta, un ticket
- Las columnas : los atributos de cada unidad de análisis. Por ejemplo: frecuencia de uso de la tarjeta de crédito

Vista Minable

UTN - FRRo - Ciencia de Datos 40

KDD: 2 – Selección, limpieza y transformación

- Cada fila debe corresponder a una instancia relevante al negocio
- Las Columnas sin variabilidad deben ser ignoradas
- Las Columnas con valores únicos para cada caso deben ser ignoradas (Num. de cuenta)

UTN - FRRo - Ciencia de Datos 41

Proceso de extracción de conocimiento - Fases

The diagram shows the six phases of the knowledge extraction process, with a detailed view of the Mined View table. The table has columns V₁, V₂, ..., V_p and rows O₁, O₂, ..., O_n. The phases are: 1. Integración y recopilación (Integration and collection), 2. Selección, limpieza y transformación (Selection, cleaning, and transformation), 3. Minería de datos (Data mining), 4. Evaluación e interpretación (Evaluation and interpretation), 5. Difusión y uso (Dissemination and use), and 6. Revisión (Review).

Vista Minable

	V ₁	V ₂	...	V _p
O ₁				
O ₂				
...				
O _n				

1 Integración y Recopilación. Procesamiento Informático


2 Selección, limpieza y transformación. Procesamiento Estadístico

UTN - FRRo - Ciencia de Datos 42


KDD: 2 – Selección, limpieza y transformación

- **Objetivo:** eliminar el mayor numero posible de datos:
 - Erróneos o inconsistentes (limpieza)
 - Irrelevantes (criba)
- **Métodos:** estadísticos fundamentalmente
 - Detección de datos anómalos
 - Detección de datos ausentes
 - Selección de datos (muestreo, vertical u horizontal)
 - Redefinición de atributos (agrupación o separación)
 - Análisis de supuestos
 - Reducción de dimensión
 - Aumento de dimensión

KDD: 2 – Selección, limpieza y transformación




Proceso de extracción de conocimiento Fases 1 y 2




Fuente: Mining your Own Business Data Using DB2 Intelligent Miner for Data

Proceso de extracción de conocimiento Fases 1 y 2



Fuente: Universidad Politécnica de Madrid

Proceso de extracción de conocimiento - Fases



KDD: 3 – Minería de datos

Patrones a descubrir:

- El explorador decide que tipo de patrón quiere descubrir
- La técnica de minería a utilizar depende del tipo de conocimiento que se desea extraer
- Según como sea la búsqueda de conocimiento se puede distinguir entre:
 - Directed data mining: se sabe claramente lo que se busca, generalmente predecir o definir clases
 - Undirected data mining: no se sabe lo que se busca, se trabaja con los datos (hasta que confiesen!!)

KDD: 3 – Minería de datos



Las técnicas de minería crean modelos: predictivos o descriptivos

- Un modelo predictivo responde preguntas sobre datos futuros:
 - cuales serán las ventas el año próximo?
 - Es esta transacción fraudulenta?
- Un modelo descriptivo proporciona información sobre las relaciones entre los datos y sus características:
 - Los clientes que compran pañales suelen comprar cerveza
 - El tabaco y el alcohol son los factores importantes en la enfermedad Y
 - Los clientes sin televisión y con bicicleta tienen características muy distintas del resto

KDD: 3 – Modelo Predictivo




Para determinar si jugar o no al tenis esta tarde contamos con datos de condiciones climatológicas adecuadas para jugar al tenis reunidas de eventos pasados

Obs	Clima	Temp	Humedad	Viento	Se jugó?
1	Soleado	Alta	Alta	Débil	NO
2	Soleado	Alta	Alta	Fuerte	NO
3	Nublado	Alta	Alta	Débil	SI
4	Lluvioso	Moderada	Alta	Débil	SI
5	Lluvioso	Baja	Normal	Débil	SI
6	Lluvioso	Baja	Normal	Fuerte	NO
7	Nublado	Baja	Normal	Fuerte	SI
8	Soleado	Moderada	Alta	Débil	NO
9	Soleado	Baja	Normal	Débil	SI
10	Lluvioso	Baja	Normal	Débil	SI
11	Soleado	Moderada	Normal	Fuerte	SI
12	Nublado	Moderada	Alta	Fuerte	SI
13	Nublado	Moderada	Normal	Débil	SI
14	Lluvioso	Alta	Alta	Fuerte	NO

KDD: 3 – Modelo Predictivo



Procesamos los datos con un algoritmo de aprendizaje de árboles de decisión, señalando el atributo "se jugó" como output. El resultado es el siguiente modelo:




KDD: 3 – Modelo Predictivo




Usamos ese modelo para predecir si esta tarde jugamos o no al tenis

Por ejemplo, si:

Clima = soleado, Temperatura = alta, Humedad = alta, Viento = fuerte




KDD: 3 – Modelo Predictivo



KDD: 3 – Modelo Descriptivo




Usuario	Cervezas	Pañales
1	11	8
2	0	10
3	0	14
4	9	12
5	14	0
6	11	0
7	0	12
8	13	0
9	10	0
10	10	9
11	13	11
12	0	13



Se decide promocionar tres nuevos productos:

- Una crema hidratante para bebés
- Una nueva revista de autos
- Una promoción de pizzas congeladas


Tipos de conocimientos



UTN - FRRO - Ciencia de Datos

55

Aplicaciones



UTN - FRRO - Ciencia de Datos

56

KDD: 3 – Tareas y técnicas

Modelos	Tareas	Predictivos (supervisados)		Descriptivos (no supervisados)		
		Clasificación	Predicción	agrupamiento	Asociación	Otros
Redes Neuronales		X	X	X		
Árboles de Decisión		X	X	X	X	
Kohonen				X		
Regresión paramétrica			X			
Regresión Logística		X			X	
k means / k medioides				X		
A priori					X	
Análisis factorial						X
Análisis Discriminante		X				
Algoritmos genéticos		X	X	X	X	X
Naive Bayes		X				
Vecinos mas próximos		X	X	X		

UTN - FRRO - Ciencia de Datos

57

KDD: 3 – Tareas y técnicas


Modelos	Tareas	Predictivos (supervisados)		Descriptivos (no supervisados)		
		Clasificación	Predicción	agrupamiento	Asociación	Otros
Redes Neuronales		X	X	X		
Árboles de Decisión		X	X	X	X	
Kohonen				X		
Regresión paramétrica			X			
Regresión Logística		X			X	
k means / k medioides				X		
A priori					X	
Análisis factorial						X
Análisis Discriminante		X				
Algoritmos genéticos		X	X	X	X	X
Naive Bayes		X				
Vecinos mas próximos		X	X	X		

UTN - FRRO - Ciencia de Datos

58

KDD: 3 – Tipos de conocimientos

- Clasificación:** es el descubrimiento de una dependencia. El atributo dependiente puede tomar un valor entre varias clases, previamente conocidas, dependiendo de los valores que presenta en otras variables de interés.



UTN - FRRO - Ciencia de Datos

59

KDD: 3 – Tareas y técnicas

Modelos	Tareas	Predictivos (supervisados)		Descriptivos (no supervisados)		
		Clasificación	Predicción	agrupamiento	Asociación	Otros
Redes Neuronales		X	X	X		
Árboles de Decisión		X	X	X	X	
Kohonen				X		
Regresión paramétrica			X			
Regresión Logística		X			X	
k means / k medioides				X		
A priori					X	
Análisis factorial						X
Análisis Discriminante		X				
Algoritmos genéticos		X	X	X	X	X
Naive Bayes		X				
Vecinos mas próximos		X	X	X		

UTN - FRRO - Ciencia de Datos


60

KDD: 3 – Modelo Predictivo



- **Tendencias y Regresión:** el objetivo es predecir los valores de una variable cuantitativa a partir de una o más variables

KDD: 3 – Modelo Predictivo



KDD: 3 – Modelo Predictivo



- **Clasificación:**
 - Clasificar un nuevo cliente - de acuerdo a su perfil sociodemográfico - como potencial cliente Heavy, Medium, Light.
- **Estimación:**
 - Estimar el consumo de un determinado rubro de artículos de un grupo de clientes en el próximo trimestre.
 - Estimar el LTV (Life Time Value) potencial de un nuevo cliente
- **Predecir el abandono de un cliente (churning, attrition)**
 - Para una compañía de telefonía celular
 - Para una AFJP
 - Para una tarjeta de crédito

KDD: 3 – Tareas y técnicas



Modelos		Predictivos (supervisados)		Descriptivos (no supervisados)		
Técnicas	Tareas	Clasificación	Predicción	agrupamiento	Asociación	Otros
Redes Neuronales		X	X	X		
Arboles de Decisión		X	X	X	X	
Kohonen				X		
Regresión paramétrica			X			
Regresión Logística		X			X	
k means / k medioides				X		
A priori					X	
Análisis factorial						X
Análisis Discriminante		X				
Algoritmos genéticos		X	X	X	X	X
Naive Bayes		X				
Vecinos mas próximos		X	X	X		

KDD: 3 – Modelo Descriptivo



Asociaciones: una asociación entre dos atributos ocurre cuando es relativamente alta la frecuencia con que se presentan juntos dos valores determinados, uno de cada atributo

- Un ejemplo tradicional de minería de datos es el relacionado con una búsqueda en un almacén de datos, de un negocio de cadena, de hechos comunes y relevantes.

KDD: 3 – Modelo Descriptivo



- Supongamos el siguiente ejemplo:
 - Análisis de las compras de 800.000 clientes de una cadena de supermercados




KDD: 3 – Modelo Descriptivo



Minería de datos

Reglas Novedosas y Útiles (difíciles de detectar)



Muy frecuentes (fáciles de detectar) Muy raras (no son un patrón)

800.000 clientes
40.000 compraron pañales (5%)
60.000 compraron cerveza (7,5%)
16.000 compraron pañales y cervezas (2%)

UTN - FRRo - Ciencia de Datos 67

KDD: 3 – Modelo Descriptivo



- Regla encontrada: Pañales -> Cervezas
- Soporte: porcentaje del total de transacciones que incluyen un determinado producto. El soporte para pañales es del 5%
- Confianza: la regla de asociación pañales -> cerveza tiene una confianza del 40%.
- Lift: los clientes que compran pañales son 5,33 veces más propensos a comprar cerveza (que quienes no los compran).

$$\frac{(\text{Compraron ambos } 16.000)}{(\text{Compraron Pañales } 40.000)} = 40\%$$

UTN - FRRo - Ciencia de Datos 68

KDD: 3 – Modelo Descriptivo

Se dispone de datos sobre las compras de los clientes:



Obs	Huevos	Aceite	Pañales	Vino	Leche	Manteca	Asado	Lechuga
1	X			X		X	X	X
2		X			X			X
3			X		X			
4		X	X		X			
5	X	X				X		X
6	X			X	X	X	X	
7								
8	X	X	X	X	X	X	X	
...	...	...	...	...	...	...	...	...

Minería de datos

Huevos -> Aceite Lift: 12

UTN - FRRo - Ciencia de Datos 69

KDD: 3 – Modelo Descriptivo

Un supermercado quiere información sobre los hábitos de compra de sus clientes para mejorar el servicio:


- Reubicar los productos que se suelen comprar juntos
- Localizar los productos nuevos en el mejor lugar
- Ofrecer promociones



UTN - FRRo - Ciencia de Datos 70

KDD: 3 – Modelo Descriptivo

- Asociación secuencial: usado para determinar patrones secuenciales en los datos



Banco

Activación Caja de ahorros Préstamos personales

15/01/2024 30/03/2024 tiempo

65% de los casos

On line

Contrata señal de Cable Contrata paquete de Fútbol Contrata paquete de Noticias

15/01/2024 27/03/2024 2/04/2024 tiempo

80% de los casos

UTN - FRRo - Ciencia de Datos 71

KDD: 3 – Tareas y técnicas

Técnicas	Modelos	Predictivos (supervisados)		Descriptivos (no supervisados)		
		Clasificación	Predicción	agrupamiento	Asociación	Otros
Redes Neuronales		X	X	X		
Árboles de Decisión		X	X	X	X	
Kohonen				X		
Regresión paramétrica			X			
Regresión Logística		X			X	
k means / k medioides				X		
A priori					X	
Análisis factorial						X
Análisis Discriminante		X				
Algoritmos genéticos		X	X	X	X	X
Naive Bayes		X				
Vecinos mas próximos		X	X	X		


UTN - FRRo - Ciencia de Datos 72

KDD: 3 – Tipos de conocimientos



Agrupamiento /Segmentación:
el agrupamiento es la detección de grupos de individuos homogéneos

Se diferencia de la clasificación en que no se conocen ni las clases ni su número, con lo que el objetivo es determinar grupos (cluster o aglomerados) diferenciados entre sí




KDD: 3 – Modelo Descriptivo



Agrupar a los clientes según sus indicadores Frecuencia, Monto, Edad, etc. en segmentos de comportamiento homogéneo.

KDD: 3 – Modelo Descriptivo



KDD: 3 – Modelo Descriptivo



Agrupar a los clientes según sus indicadores Frecuencia, Monto, Edad, etc. en segmentos de comportamiento homogéneo.

Resultado: Clientes Heavy, Medium, Light, etc
El 78% de la facturación se concentra en el cluster Heavy (27% de los clientes).
Los clientes Heavy son casados, con hijos, trabajadores autónomos con un ingreso superior a \$3800.

KDD: 3 – Modelo Descriptivo



Queremos categorizar nuestros empleados
Contamos con los siguientes datos:

Obs	Sueldo	Casado	Coche	Hijos	Alq / prop	Sind.	Aus. / año	Antigüedad	Sexo
1	1000	Si	No	0	Alquiler	No	7	15	H
2	2000	No	Si	1	Alquiler	Si	3	3	M
3	1500	Si	Si	2	Prop.	Si	5	10	H
4	3000	Si	Si	1	Alquiler	No	15	7	M
5	1000	Si	Si	0	Prop.	Si	1	6	H
6	4000	No	Si	0	Alquiler	Si	3	16	M
7	2500	No	No	0	Alquiler	Si	0	8	H
8	2000	No	Si	0	Prop.	Si	2	6	M
9	2000	Si	Si	3	Prop.	No	7	5	H
10	3000	Si	Si	2	Prop.	No	1	20	H
11	5000	No	No	0	Alquiler	No	2	12	M
12	800	Si	Si	2	Prop.	No	3	1	H
13	2000	No	No	0	Alquiler	No	27	5	M
14	1000	No	Si	0	Alquiler	Si	0	7	H
15	800	No	Si	0	Alquiler	No	3	2	H

KDD: 3 – Modelo Descriptivo





- Procesamos estos datos con un algoritmo de clustering
- Se crean 3 clusters con la siguiente descripción:

Cluster 1: 5 examples
Sueldo: 2360
Casado: No -> 0.8
Si -> 0.2
Coche: No -> 0.8
Si -> 0.2
Hijos: 0
Alq./Prop: Alq. -> 1.0
Sindic.: No -> 0.8
Si -> 0.2
Ausencias / año: 8
Antigüedad: 2
Sexo: M -> 0.6
F -> 0.4

Cluster 2: 4 examples
Sueldo: 2000
Casado: No -> 1
Si -> 0
Coche: No -> 0
Si -> 1
Hijos: 0
Alq./Prop: Alq. -> 0.75
Sindic.: No -> 0
Si -> 1
Ausencias / año: 2
Antigüedad: 8
Sexo: M -> 0.25
F -> 0.75

Cluster 3: 6 examples
Sueldo: 1500
Casado: No -> 0
Si -> 1
Coche: No -> 0
Si -> 1
Hijos: 2
Alq./Prop: Alq. -> 0.17
Sindic.: No -> 0.67
Si -> 0.33
Ausencias / año: 5
Antigüedad: 8
Sexo: M -> 0.83
F -> 0.17

Cluster 1: Sin hijos. Alquilan. Poco sindicalizados. Muchas ausencias. Poca antigüedad
Cluster 2: Sin hijos. Con coche. Muy sindicalizados. Pocas ausencias. Alquilan. Mujeres
Cluster 3: Con hijos. Casados y con coche. Propietarios. Poco sindicalizados. Hombres



KDD: 4 – Evaluación

- La etapa anterior produce una o mas hipótesis de modelos.
Para seleccionar y validar esos modelos es necesario el uso de criterios de evaluación de hipótesis:
- 1ª fase: comprobación de la precisión del modelo en un conjunto de ejemplos independiente del que se ha utilizado para que el modelo aprenda. Se elige el mejor modelo
- 2ª fase: se puede realizar una experiencia piloto con ese modelo. Por ej.: en el caso de un modelo para predecir la respuesta de los clientes a un nuevo producto, se puede enviar un mailing a un subconjunto de clientes y evaluar la fiabilidad del modelo.

UTN - FRRo - Ciencia de Datos

KDD: 4 – Evaluación


N	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	80K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes
11	No	Single	75K	Yes
12	Yes	Married	50K	No
13	No	Single	75K	Yes
14	Yes	Married	50K	No
15	Yes	Divorced	90K	No
16	No	Single	40K	No

UTN - FRRo - Ciencia de Datos

KDD: 4 – Interpretación

- El despliegue del modelo a veces es trivial pero otras requiere un proceso de interpretación:
- El modelo es descriptivo y requiere **interpretación**: por ej.: una caracterización de zonas geográficas según la distribución de los productos vendidos

UTN - FRRo - Ciencia de Datos



KDD: 5 – Difusión y uso



El despliegue del modelo a veces es trivial pero otras requiere un proceso de **implementación (puesta en producción / despliegue / productivización)**:

- Informe de resultados
- Dashboard
- Detección en tiempo real de tarjetas fraudulentas
- Modelo para pre aprobación de créditos bancarios

KDD: 5 – Difusión y uso




El modelo puede tener muchos usuarios y necesita **difusión**: es necesario expresar el modelo de una manera comprensible para los usuarios de la organización.

Ej.: las cervezas y las cervezas se compran frecuentemente juntos



➡ ponerlos en góndolas próximas.

Proceso de extracción de conocimiento - Fases



KDD: 6 – Revisión



Como los procesos no son estáticos, los modelos deben adaptarse a los cambios, requieren:

Monitoreo y Actualización

- Monitoreo: revalidar el modelo con cierta frecuencia sobre nuevos datos, para detectar si requiere actualización por cambio de contexto (económico, competencia, fuentes de datos, etc)
- Actualización: revisar el modelo

Proceso de extracción de conocimiento - Fases

