

KNN

Vecinos más próximos

Cátedra Ciencia de Datos
Ingeniería en Sistemas de Información
UTN – Facultad Regional Rosario




Definición

- Consiste en clasificar un nuevo caso, en función de su distancia con los casos vecinos.
- Se trabaja con un parámetro “k” que determina la cantidad de vecinos cercanos con los cuales se comparará la nueva observación.
- En su versión más simple $k=1$, clasificando al nuevo caso con la clase del caso más próximo.

Enfoques del algoritmo


◆ One Nearest Neighbour (1-NN)

Asigna la clase del ejemplo más próximo.



◆ K Nearest Neighbors (K-NN)

Se asigna la clase mayoritaria entre los K vecinos más próximos. **La selección del parámetro k es muy importante.**




El parámetro K

K=1
CLASIFICA ROJO



K=4
CLASIFICA AZUL



El valor del parámetro k se obtiene experimentalmente, seleccionando el que genera la **menor tasa de error** en el conjunto de datos de prueba.



Clasificación de modelos predictivos

- ❖ **Métodos retardados (o perezosos):**
No crean un modelo general. Para clasificar un nuevo caso, buscan entre los ejemplos anteriores almacenados el mas parecido y resuelven como en esa ocasión. Ej: KNN
- ❖ **Métodos no retardados (o anticipativos):** Construyen un modelo general a partir del conjunto de ejemplos. Reemplazan los datos por el modelo. *Ej: árboles de decisión.*



Distancias

❖ **Euclídea**

Longitud de la recta que une dos puntos en el espacio.

Inconveniente: **depende de las unidades de medida** de las variables

$$d_{ij} = \sqrt{\sum_{s=1}^p (x_{is} - x_{js})^2} = [(\mathbf{x}_i - \mathbf{x}_j)'(\mathbf{x}_i - \mathbf{x}_j)]^{1/2}$$

❖ **Euclídea Ponderada:**

M puede ser una matriz diagonal para estandarizar variables, que, por ejemplo, puede tener las desviaciones estándares en la diagonal principal.

$$d_{ij} = [(\mathbf{x}_i - \mathbf{x}_j)' \mathbf{M}(\mathbf{x}_i - \mathbf{x}_j)]^{1/2}$$

M=I es la distancia euclídea



Distancias

❖ Distancia de Mahalanobis

- ❖ Utiliza la matriz de covarianzas S
- ❖ Es recomendable para variables correlacionadas

$$d_{ij} = [(\mathbf{x}_i - \mathbf{x}_j)' \mathbf{S}^{-1} (\mathbf{x}_i - \mathbf{x}_j)]^{1/2}$$

❖ Distancia de Manhattan

Hace referencia a recorrer un camino “zigueando” y no en diagonal

$$B(x, y) = \sum_i |x_i - y_i|$$



Distancias

❖ Distancia de chebyshev

Calcula la discrepancia más grande en alguna de las dimensiones

$$C(x, y) = \text{Max}|x_i - y_i|$$



Distancias en variables Categóricas

La distancia euclídea entre dos elementos será:

- **0** si ambos elementos coinciden en el valor del atributo
- **1** en caso de que tengan distinto valor

if $x=y$ then $D=0$ else $D=1$

Observación	Sexo	Alquila	Educación
i	M	No	Terciaria
j	M	Si	Universitaria



$$d_{ij} = \sqrt{0^2 + 1^2 + 1^2} = 1.414$$