

DATA SCIENCE


DECISION

Arboles de Decisión

Select split condition that maximize gain of purity

If output is numeric
purity = variance
else if output is categorical
purity = entropy or gini

Ciencia de Datos



KDD: Tareas y técnicas

Modelos	Tareas	Predictivos (supervisados)		Descriptivos (no supervisados)		
		Clasificación	Predicción	agrupamiento	Asociación	Otros
Redes Neuronales		X	X	X		
Arboles de Decisión		X	X	X	X	
Kohonen				X		
Regresión paramétrica			X			
Regresión Logística		X			X	
k means / k medioides				X		
A priori					X	
Análisis factorial						X
Análisis Discriminante		X				
Algoritmos genéticos		X	X	X	X	X
Naive Bayes		X				
Vecinos mas próximos		X	X	X		

UTN - FRRO - Ciencia de Datos 3

Arboles de Decisión

Un árbol de decisión es una técnica de aprendizaje supervisado, que se utiliza tanto para tareas de **clasificación**. Tiene una estructura jerárquica que consta de un nodo raíz, ramas, nodos internos y nodos hoja.

UTN - FRRO - Ciencia de Datos 4

Arboles de Decisión - Ejemplo

- Queremos saber si se recomienda jugar o no esta tarde al tenis.
- Hemos recogido datos de experiencias anteriores:

Outlook	Temperature	Humidity	Windy	Play
sunny	hot	high	false	no
sunny	hot	high	true	no
overcast	hot	high	false	yes
rainy	mild	high	false	yes
rainy	cool	normal	false	yes
rainy	cool	normal	true	no
overcast	cool	normal	true	yes
sunny	mild	high	false	no
sunny	cool	normal	false	yes
rainy	mild	normal	false	yes
sunny	mild	normal	true	yes
overcast	mild	high	true	yes
overcast	hot	normal	false	yes
rainy	mild	high	true	no

UTN - FRRO - Ciencia de Datos 5

Arboles de Decisión - Ejemplo

- Pasamos estos ejemplos a un algoritmo de aprendizaje de árboles de decisión, señalando el atributo "Jugar" como la clase (salida).
- El resultado del algoritmo es el siguiente modelo:

Ahora podemos utilizar este modelo para predecir si están dadas las condiciones para jugar o no al tenis. Pej., la instancia:

Estado = soleado, Humedad = 80, Viento = true

Play = Si

UTN - FRRO - Ciencia de Datos 6

Medidas de la información e incertidumbre

S	Estados	1	2		
	P	0.5	0.5		
U	Estados	1	2	3	4
	P	0.25	0.25	0.25	0.25
Z	Estados	1	2	3	4
	P	0.1	0.1	0.7	0.1

Medidas de la información e incertidumbre

Media	U	Estados	1	2	...	100	$\bar{U} = 50,50$
		P	1/100	1/100	...	1/100	
	Z	Estados	50,50			$\bar{Z} = 50,50$	
		P	1				

Desvío	U	Estados	Excelente	Normal	Malo
		P	0.3	0.5	0.2

Medidas de la información e incertidumbre

X	Estados	100	0	$\bar{X} = 20$ $\sigma_X = 40$
	P	0.2	0.8	
W	Estados	200	100	$\bar{W} = 120$ $\sigma_W = 40$
	P	0.2	0.8	
Y	Estados	100	120	$\bar{Y} = 110$ $\sigma_Y = 10$
	P	0.5	0.5	
Z	Estados	120	150	$\bar{Z} = 135$ $\sigma_Z = 15$
	P	0.5	0.5	

Medidas de la información e incertidumbre

U	Estados	100	200	300	400
	P	0.25	0.25	0.25	0.25
V	Estados	100	200	300	400
	P	0.2	0.4	0.1	0.3
$\bar{U} = 250$ $\sigma_U = 111,80$		$\bar{V} = 250$ $\sigma_V = 111,80$			

Medidas de la información e incertidumbre

Características de una medida de la incertidumbre:

- Aumente al aumentar el n° de estados
- Disminuya con la mayor propensión a suceder de un estado determinado
- Sea insensible a la unidad de medida de la misma

Entropía

Entropía

- Una medida de la información y la incertidumbre
- Estándar de referencia para medición y comparación

Entropía

Dado un universo Z

$$Z = \left\{ \begin{matrix} E_1 & E_2 & \dots & E_n \\ P_1 & P_2 & \dots & P_n \end{matrix} \right.$$

Definimos:

P_i : probabilidad asociada al estado E_i

$E(Z)$: medida numérica de la incertidumbre asociada al universo Z


$$E(Z) = - \sum_{i=1}^n P_i \log_2 P_i$$

Entropía

P_1	0	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1
E	0	0.469	0.722	0.881	0.971	1	0.971	0.881	0.722	0.469	0

$$Z = \left\{ \begin{matrix} E_1 & E_2 \\ P_1 & P_2 \end{matrix} \right.$$

$$P_2 = 1 - P_1$$



Entropía

Limitaciones:

- Deben existir probabilidades definidas para poder calcularla
- El número de estados debe ser conocido

Construyendo un Arbol

Ejemplo de Modelo Predictivo:

- Queremos saber si se recomienda o no jugar esta tarde al tenis.
- Hemos recogido datos de experiencias anteriores:

The weather data

Outlook	Temperature	Humidity	Windy	Play
sunny	hot	high	false	no
sunny	hot	high	true	no
overcast	hot	high	false	yes
rainy	mild	high	false	yes
rainy	cool	normal	false	yes
rainy	cool	normal	true	no
overcast	cool	normal	true	yes
sunny	mild	high	false	no
sunny	cool	normal	false	yes
rainy	mild	normal	false	yes
sunny	mild	normal	true	yes
overcast	mild	high	true	yes
overcast	hot	normal	false	yes
rainy	mild	high	true	no

Construyendo un Arbol – Algoritmo

1. Seleccionar el atributo A_i que maximice la ganancia o razón de ganancia

Estado	$G(\text{Estado}) = 0.247$
Temp	$G(\text{Temp}) = 0.029$
Humedad	$G(\text{Humedad}) = 0.152$
Viento	$G(\text{Viento}) = 0.048$



Construyendo un Arbol – Algoritmo

2. Crear un nodo para ese atributo con tantos sucesores como valores tenga




Construyendo un Arbol – Algoritmo

Vista Minable:

Outlook	Temperature	Humidity	Windy	Play
sunny	hot	high	false	no
sunny	hot	high	true	no
overcast	hot	high	false	yes
rainy	mild	high	false	yes
rainy	cool	normal	false	yes
rainy	cool	normal	true	no
overcast	cool	normal	true	yes
sunny	mild	high	false	no
sunny	cool	normal	false	yes
rainy	mild	normal	false	yes
sunny	mild	normal	true	yes
overcast	mild	high	true	yes
overcast	hot	normal	false	yes
rainy	mild	high	true	no

Construyendo un Arbol – Algoritmo

- Introducir los ejemplos en los sucesores según el valor que tenga el atributo A_i



Construyendo un Arbol – Algoritmo

- Por cada sucesor:

- si solo hay ejemplos de una clase, C_k , entonces etiquetarlo con C_k



- sino, ir a 1 con una tabla formada por los ejemplos de ese nodo, eliminando la columna del atributo A_i .



Construyendo un Arbol – Algoritmo

- Seleccionar el atributo A_i que maximice la ganancia o razón de ganancia
- Crear un nodo para ese atributo con tantos sucesores como valores tenga
- Introducir los ejemplos en los sucesores según el valor que tenga el atributo A_i
- Por cada sucesor:
 - si solo hay ejemplos de una clase, C_k , entonces etiquetarlo con C_k
 - sino, ir a 1 con una tabla formada por los ejemplos de ese nodo, eliminando la columna del atributo A_i .

Medidas a usar

$$\text{Info}(S) = -\sum P_i \log P_i = E(S)$$

$$\text{Ganancia}(S, V) = \text{Info}(S) - \sum_{k \in V} \frac{\text{Cant } V_k}{\text{Cant } V} \text{Info}(V_k)$$

S = conjunto de datos


V = variable

K = estados posibles del atributo

$\text{Cant } V_k$ = cantidad de elementos del estado K de la variable V

$\text{Cant } V$ = cantidad de elementos del conjunto A

Construyendo un Arbol



$$\text{Info}([2,3]) = \text{entropía}(2/5, 3/5) = 0.971 \text{ bits}$$

$$\text{Info}([4,0]) = 0 \text{ bits}$$

$$\text{Info}([3,2]) = 0.971 \text{ bits}$$

$$\text{Info}(\text{Estado}) = 5/14 \times 0.971 + 4/14 \times 0 + 5/14 \times 0.971$$

$$\text{Info}(\text{Estado}) = 0.693 \text{ bits}$$

$$\text{Info}(\text{conjunto datos}) = \text{Info}([9,5]) = 0.940 \text{ bits}$$


$$\text{Ganancia}(\text{Estado}) = 0.940 - 0.693 = 0.247 \text{ bits}$$

Construyendo un Arbol


The weather data

Outlook	Temperature	Humidity	Windy	Play
sunny	hot	high	false	no
sunny	hot	high	true	no
overcast	hot	high	false	yes
rainy	mild	high	false	yes
rainy	cool	normal	false	yes
rainy	cool	normal	true	no
overcast	cool	normal	true	yes
sunny	mild	high	false	no
sunny	cool	normal	false	yes
rainy	mild	normal	false	yes
sunny	mild	normal	true	yes
overcast	mild	high	true	yes
overcast	hot	normal	false	yes
rainy	mild	high	true	no

Construyendo un Arbol



Construyendo un Arbol



$$\text{Info}([2,2]) = 0.286 \text{ bits}$$

$$\text{Info}([4,2]) = 0.394 \text{ bits}$$

$$\text{Info}([3,1]) = 0.232 \text{ bits}$$


$$\text{Info}(\text{Temp}) = 4/14 \times 0.286 + 6/14 \times 0.394 + 4/14 \times 0.232$$

$$\text{Info}(\text{Temp}) = 0.911 \text{ bits}$$

$$\text{Ganancia}(\text{Temp}) = 0.940 - 0.911 = 0.029 \text{ bits}$$

[2,2] [4,2] [3,1]

Construyendo un Arbol



$$\text{Info}([3,4]) = 0.493 \text{ bits}$$

$$\text{Info}([6,1]) = 0.296 \text{ bits}$$


$$\text{Info}(\text{Humedad}) = 7/14 \times 0.493 + 5/14 \times 0.296$$

$$\text{Info}(\text{Humedad}) = 0.788 \text{ bits}$$

$$\text{Ganancia}(\text{Humedad}) = 0.940 - 0.788 = 0.152 \text{ bits}$$

[3,4] [6,1]

Construyendo un Arbol



$$\text{Info}([3,3]) = 0.428 \text{ bits}$$

$$\text{Info}([6,2]) = 0.464 \text{ bits}$$

$$\text{Info}(\text{Viento}) = 6/14 \times 0.428 + 8/14 \times 0.464$$

$$\text{Info}(\text{Viento}) = 0.892 \text{ bits}$$

$$\text{Ganancia}(\text{Viento}) = 0.940 - 0.892 = 0.048 \text{ bits}$$

[3,3] [6,2]

Ganancia

	Estado	Temperatura	Humedad	Viento
Información	0.693	0.911	0.788	0.892
Ganancia	0.247	0.029	0.152	0.048



Arbol resultante




Construyendo un Arbol

Atributos con alto número de ramificaciones

Nunca usar ID code en un modelo

The weather data with identification codes.					
ID code	Outlook	Temperature	Humidity	Windy	Play
a	sunny	hot	high	false	no
b	sunny	hot	high	true	no
c	overcast	hot	high	false	yes
d	rainy	mild	high	false	yes
e	rainy	cool	normal	false	yes
f	overcast	cool	normal	true	yes
g	overcast	cool	normal	true	yes
h	sunny	mild	high	false	no
i	sunny	cool	normal	false	yes
j	rainy	mild	normal	false	yes
k	sunny	mild	normal	true	yes
l	overcast	mild	high	true	yes
m	overcast	hot	normal	false	yes
n	rainy	mild	high	true	no



Tree stump for the ID code attribute.

$$\text{Info}(\text{id_code}) = \text{Info}([0,1]) + \text{Info}([0,1]) + \dots + \text{Info}([1,0]) + \text{Info}([0,1]) = 0$$

$$\text{Ganancia} = \text{Info}(\text{Conjunto de datos}) - \text{info}(\text{id_code})$$

$$\text{Ganancia} = 0.940 - 0 = 0.940 \text{ (máxima)}$$

Razón de ganancia

Split Information:

$$SI(S,V) = - \sum_{i=1}^c \frac{\text{Cant } S_i}{\text{Cant } S} \log_2 \frac{\text{Cant } S_i}{\text{Cant } S}$$

c: cantidad de valores distintos de la variable V

Cant S_i : cantidad de elementos de S con el valor i de la variable V

Nunca usar ID code en un modelo

The weather data with identification codes.					
ID code	Outlook	Temperature	Humidity	Windy	Play
a	sunny	hot	high	false	no
b	sunny	hot	high	true	no
c	overcast	hot	high	false	yes
d	rainy	mild	high	false	yes
e	rainy	cool	normal	false	yes
f	rainy	cool	normal	true	yes
g	overcast	cool	normal	true	yes
h	sunny	mild	high	false	no
i	sunny	cool	normal	false	yes
j	rainy	mild	normal	false	yes
k	sunny	mild	normal	true	yes
l	overcast	mild	high	true	yes
m	overcast	hot	normal	false	yes
n	rainy	mild	high	true	no

$$SI(\text{Tennis}, \text{id_code}) = SI([1,1,1,\dots,1]) = \left(-\frac{1}{14} \log \frac{1}{14}\right) \times 14 = 3.807 \text{ bits}$$


$$GR(\text{id_code}) = \frac{G(\text{id_code})}{SI(\text{id_code})} = \frac{0.940}{3.807} = 0.247$$

Razón de ganancia

	Estado	Temperatura	Humedad	Viento
Información	0.693	0.911	0.788	0.892
Ganancia	0.247	0.029	0.152	0.048
Split info	1.577	1.557	1.000	0.985
Razón ganancia	0.157	0.019	0.152	0.049

$$SI(\text{Tennis}, \text{Estado}) = SI([5,4,5]) = \left(-\frac{5}{14} \log \frac{5}{14}\right) + \left(-\frac{4}{14} \log \frac{4}{14}\right) + \left(-\frac{5}{14} \log \frac{5}{14}\right) = 1.577 \text{ bits}$$

Arbol resultante



Atributos Numéricos

Ejemplos ordenados (Humedad)

Valores	64	65	68	69	70	71	72	72	75	75	80	81	83	85
Clase	S	N	S	S	S	N	N	S	S	S	N	S	S	N

64,5 66,5

$$\text{Info}([1,0]) = 0 \text{ bits}$$

$$\text{Info}([8,5]) = 0.961 \text{ bits}$$

$$\text{Info}(\text{Hum.}) = 0.893 \text{ bits}$$

$$\text{Gan}(\text{Hum.}) = 0.047 \text{ bits}$$

$$\text{Info}([1,1]) = \text{xxx bits}$$

$$\text{Info}([8,4]) = \text{xxx bits}$$

$$\text{Info}(\text{Hum.}) = \text{xxx bits}$$

Atributos Numéricos

Ejemplos ordenados (Humedad)

Valores	64	65	68	69	70	71	72	75	75	80	81	83	85
Clase	S	N	S	S	S	N	N	S	S	N	S	S	N

Corte	Info < (bits)	Info > (bits)	Info(Humedad)	Gan(Humedad)
64,5	Info(1,0) = 0	Info(8,5) = 0,961	0,893	0,047
67	Info(1,1) = 1	Info(8,4) = 0,918	0,930	0,010
68,5	Info(2,1) = 0,918	Info(7,4) = 0,946	0,940	0
69,5	Info(3,1) = 0,811	Info(6,4) = 0,971	0,925	0,015
70,5	Info(4,1) = 0,500	Info(5,4) = 0,991	0,840	0,100
71,5	Info(4,2) = 0,918	Info(5,3) = 0,954	0,939	0,001
73	Info(5,3) = 0,954	Info(4,2) = 0,918	0,939	0,001
77	Info(7,3) = 0,881	Info(2,2) = 1	0,915	0,025
80,5	Info(7,4) = 0,946	Info(2,1) = 0,918	0,940	0
82	Info(8,4) = 0,918	Info(1,1) = 1	0,930	0,010
84	Info(9,4) = 0,890	Info(0,1) = 0	0,827	0,113

Atributos Numéricos

Elección del atributo raíz

	Estado	Temperatura	Humedad	Viento
Información	0.693	0.911	0.827	0.892
Ganancia	0.247	0.029	0.113	0.048

Atributos Numéricos

Analizando rama Lluvioso:


Estado	Hum.	Viento	Jugar
Lluvioso	96	No	Si
Lluvioso	80	No	Si
Lluvioso	70	Si	No
Lluvioso	80	No	Si
Lluvioso	91	Si	No

Valores	70	80	80	91	96
Clase	N	S	S	N	S


Info(conjunto datos) = Info([3,2]) = 0.971 bits

Corte	Info < (bits)	Info > (bits)	Info(Humedad)	Gan(Humedad)
75	Info(0,1) = 0	Info(3,1) = 0,811	0,649	0,322
85	Info(2,1) = 0,918	Info(1,1) = 1	0,951	0,020
93	Info(2,2) = 1	Info(1,0) = 0	0,800	0,171

Atributos Numéricos



Sobreajuste



Sobreajuste

Cuando el árbol se sobreajusta a nuestros datos, existen métodos que sirven para poder acotar el árbol y que pueda generalizar mejor.

Arboles de Decisión – Sobreajuste

UTN - FRRO - Ciencia de Datos 43

Arboles de Decisión – Poda

Datos independientes → Poda → $e = \frac{f}{N}$

UTN - FRRO - Ciencia de Datos 44

Arboles de Decisión – Poda

UTN - FRRO - Ciencia de Datos 45

Datos Prueba

No.	Estado	Humedad	Viento	Jugar
1	Soleado	85.0	No	No
2	Soleado	90.0	Si	No
3	Soleado	86.0	Si	No
4	Lluvioso	96.0	No	No
5	Lluvioso	80.0	No	Si
6	Lluvioso	70.0	Si	No
7	Soleado	85.0	Si	Si
8	Soleado	95.0	Si	No
9	Nublado	70.0	No	Si
10	Lluvioso	80.0	No	Si
11	Soleado	70.0	No	Si
12	Nublado	90.0	Si	Si
13	Nublado	75.0	No	No
14	Lluvioso	91.0	Si	Si

UTN - FRRO - Ciencia de Datos 46

Arboles de Decisión – Poda


UTN - FRRO - Ciencia de Datos 47

Matriz de confusión

		Predicho		
		A	No A	
Real	A	TP Verdaderos Positivos. Son los que se clasificaron como A y que efectivamente son A	FN Falsos Negativos. Son los que se clasificaron como no A pero que son A	TP + FN
	No A	FP Falsos Positivos. Son los que se clasificaron como A pero NO son A	TN Verdaderos Negativos. Son los que se clasificaron como no A y efectivamente son no A	FP + TN
		TP + FP	FN + TN	Total

UTN - FRRO - Ciencia de Datos 48

Arboles de Decisión



UTN - FRRO - Ciencia de Datos

49

Matriz de Confusión

No.	Estado	Humedad	Viento	Jugar
1	Soleado	85.0	No	No
2	Soleado	90.0	Si	No
3	Soleado	86.0	Si	Si
4	Lluvioso	96.0	No	No
5	Lluvioso	80.0	No	Si
6	Lluvioso	70.0	Si	No
7	Nublado	65.0	Si	Si
8	Soleado	95.0	Si	No
9	Nublado	70.0	No	Si
10	Lluvioso	80.0	No	Si
11	Soleado	70.0	No	No
12	Nublado	90.0	Si	Si
13	Nublado	75.0	No	No
14	Lluvioso	91.0	Si	Si

		Predicha	
		Si	No
Real	Si	5, 7, 9, 10, 12, 14	3
	No	4, 6, 11, 13	1, 2, 8

UTN - FRRO - Ciencia de Datos

50

Calculando el costo

Matriz de costos

		Predicha	
		Si	No
Real	Si	0	0
	No	50	0

Matriz de confusión

		Predicha	
		Si	No
Real	Si	5, 7, 9, 10, 12, 14	3
	No	4, 6, 11, 13	1, 2, 8

$$\text{Costo total} = 1 \times 0 + 4 \times 50 = 200$$

UTN - FRRO - Ciencia de Datos

51

Bibliografía

- Data Mining with SPSS Modeler. Sección 8.8



UTN - FRRO - Ciencia de Datos

52