






KDD: Tareas y técnicas

Modelos		Predictivos (supervisados)		Descriptivos (no supervisados)		
Técnicas	Tareas	Clasificación	Predicción	agrupamiento	Asociación	Otros
Redes Neuronales		X	X	X		
Arboles de Decisión		X	X	X	X	
Kohonen				X		
Regresión paramétrica			X			
Regresión Logística		X			X	
k means / k medioides				X		
A priori					X	
Análisis factorial						X
Análisis Discriminante		X				
Algoritmos genéticos		X	X	X	X	X
Naive Bayes		X				
Vecinos mas próximos		X	X	X		


UTN - FRRo - Ciencia de Datos

- Objetivos
- Un fin predictivo consistente en proporcionar procedimientos sistemáticos de clasificación de nuevas observaciones de origen desconocido en algunos de los grupos considerados
 - Un fin descriptivo consistente en analizar si existen diferencias entre una serie de grupos en los que se divide una población, con respecto a un conjunto de variables y, en caso afirmativo, averiguar a qué se deben
- UTN - FRRo - Ciencia de Datos

- Pasos
- Plantear el problema a resolver
 - Analizar supuestos del modelo
 - Analizar si existen diferencias significativas entre los grupos
 - Establecer el número y composición de las dimensiones de discriminación entre los grupos analizados
 - Evaluar los resultados obtenidos desde un punto de vista predictivo analizando la significación estadística y práctica del proceso de discriminación
- UTN - FRRo - Ciencia de Datos




Fronteras de decisión



UTN - FRRo - Ciencia de Datos

7


Poblaciones normales



UTN - FRRo - Ciencia de Datos

8


Modelos normales de clases



UTN - FRRo - Ciencia de Datos

9

Fronteras de decisión



UTN - FRRo - Ciencia de Datos

10

Supuestos

- No multicolinealidad
- Distribución Normal de las Variables
- Matrices de Varianza Covarianzas Iguales

UTN - FRRo - Ciencia de Datos

11

Interpretación geométrica

Para clasificar x_0 :

Trabajando con 2 poblaciones







- Construir función discriminante:

$$d = Xu \Rightarrow d_i = u_1 X_{1i} + u_2 X_{2i} + \dots + u_p X_{pi}$$


- Calcular $d_0 = x_0 u$
- Calcular $m_1 = u^T \mu_1$ y $m_2 = u^T \mu_2$
- Clasificar en P_1 si: $|d_0 - m_1| < |d_0 - m_2|$

UTN - FRRo - Ciencia de Datos

12



Hay modelo?



UTN - FRRO - Ciencia de Datos

19

Hay modelo?. Medias distintas

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_g = \mu$$

$$H_1 : \text{no todas las } \mu_i \text{ son iguales}$$

$$VT = VE + VNE$$


$$\Lambda = \frac{\text{Suma de cuadrados intragrupos}}{\text{Suma de cuadrados total}} = \frac{|VNE|}{|VT|}$$

$$V = -\left\{N - 1 - \frac{(p + g)}{2}\right\} \ln \Lambda \sim \chi^2_{p, G-1}$$

UTN - FRRO - Ciencia de Datos

20

Considerando costos




- Clasificamos x_0 en P_1 si

$$\frac{\pi_1 f_1(x_0)}{c(1/2)} > \frac{\pi_2 f_2(x_0)}{c(2/1)}$$

UTN - FRRO - Ciencia de Datos

21

Interpretación geométrica



UTN - FRRO - Ciencia de Datos

22

Funciones lineales de Fisher

En ocasiones, en lugar de utilizar el criterio del punto de corte, suelen construirse funciones discriminantes para cada grupo (especialmente cuando $G > 2$).

$$F_I = a_{I,1} X_1 + a_{I,2} X_2 + \dots + a_{I,k} X_k - C_I$$

$$F_{II} = a_{II,1} X_1 + a_{II,2} X_2 + \dots + a_{II,k} X_k - C_{II}$$

...

Cuando se utilizan estas funciones se clasifica a un individuo en el grupo para el que la función F_j sea mayor.

UTN - FRRO - Ciencia de Datos

23

Probabilidades de error


$$d = u'x \sim N(m_i, D^2)$$

$$E(d / P_i) = u' \mu_i = m_i$$

$$Var(d) = u' Var(x) u = (\mu_2 - \mu_1)' V^{-1} (\mu_2 - \mu_1) = D^2$$

$$P(2/1) = P\left(d \geq \frac{m_1 + m_2}{2} \mid d \sim N(m_1, D)\right)$$

$$P(1/2) = P\left(d \leq \frac{m_1 + m_2}{2} \mid d \sim N(m_2, D)\right)$$



$$u = V^{-1} (\mu_2 - \mu_1)$$

UTN - FRRO - Ciencia de Datos

24

Clasificación entre 2 poblaciones



- Teorema de Bayes

$$P(i / x_0) = \frac{\pi_i P_i(x_0 / 1)}{\pi_1 P_1(x_0 / 1) + \pi_2 P_2(x_0 / 2)}$$

$$P(x_0 / 1) = f_1(x_0)$$

$$P(x_0 / 2) = f_2(x_0)$$

$$f(x) = \pi_1 f_1(x) + \pi_2 f_2(x)$$

Clasificación entre 2 poblaciones



- Clasificamos x_0 en P_1 si:

$$P(1 / x_0) > P(2 / x_0)$$

- Equivale a clasificar x_0 en P_1 si:

$$\pi_1 f_1(x_0) > \pi_2 f_2(x_0)$$

Poblaciones Normales: Función lineal discriminante



- f_1 y $f_2 \sim N$
- Distintos vectores de medias
- No Multicolinealidad
- Matrices de Covarianzas iguales

$$f_i(x) = \underbrace{\frac{1}{(2\pi)^{p/2} |V|^{1/2}}}_{\text{Constante}} e^{\left\{ -\frac{1}{2} (x - \mu_i)' V^{-1} (x - \mu_i) \right\}}$$

Clasificación entre 2 poblaciones



- P_1 y P_2 poblaciones
- x , p-variante. variable aleatoria vectorial continua
- f_1 y f_2 funciones de densidad
- x_0 nuevo elemento a clasificar
- π_1 y π_2 probabilidades a priori

$$f(x) = \pi_1 f_1(x) + \pi_2 f_2(x)$$

$$\pi_1 + \pi_2 = 1$$

Poblaciones Normales: Función lineal discriminante



- Clasificamos en P_1 si:

$$\frac{\pi_1 f_1(x_0)}{c(1/2)} > \frac{\pi_2 f_2(x_0)}{c(2/1)}$$

- Reemplazando, clasificamos en P_1 si:

$$-\frac{1}{2} (x - \mu_1)' V^{-1} (x - \mu_1) + \ln\left(\frac{\pi_1}{c(1/2)}\right) > -\frac{1}{2} (x - \mu_2)' V^{-1} (x - \mu_2) + \ln\left(\frac{\pi_2}{c(2/1)}\right)$$

Variabilidad y Distancia



- Distancia de Mahalanobis

$$D_{ij}^2 = (x_i - x_j)' V^{-1} (x_i - x_j)$$

Clasifico en P_1 si:

$$\frac{1}{2} D_1^2 - \ln\left(\frac{\pi_1}{c(1/2)}\right) < \frac{1}{2} D_2^2 - \ln\left(\frac{\pi_2}{c(2/1)}\right)$$