

Regresión Logística

Ciencia de Datos

KDD: Tareas y técnicas

Modelos	Predictivos (supervisados)		Descriptivos (no supervisados)				
	Técnicas	Tareas	Clasificación	Predicción	agrupamiento	Asociación	Otros
Redes Neuronales			X	X	X		
Árboles de Decisión			X	X	X	X	
Kohonen					X		
Regresión paramétrica				X			
Regresión Logística			X			X	
k means / k medioides					X		
A priori						X	
Análisis factorial							X
Análisis Discriminante			X				
Algoritmos genéticos			X	X	X	X	X
Naive Bayes			X				
Vecinos mas próximos			X	X	X		

UTN - FRRO - Ciencia de Datos
2

Probabilidad

$$p_{(x)} = \frac{\text{Éxitos}}{\text{Total de intentos}}$$

DEFINICIÓN Medida del grado de certidumbre de que un evento pueda ocurrir.

CÁLCULO Número de veces que se presenta el evento / Número total de intentos

ESCALA Número entre 0 y 1. Donde 0 es igual a un suceso imposible y 1 a un suceso seguro.

EJEMPLO

He jugado Starcraft 5 veces, en las cuales he ganado 3 veces y he perdido 2.

$$p_{(\text{ganar})} = \frac{\text{Número de éxitos}}{\text{Número total de intentos}} = \frac{3}{5} = 0.6$$

La probabilidad de ganar es 0.6.

UTN - FRRO - Ciencia de Datos 3

ODDS

$$\text{Odds}_{(x)} = \frac{p}{(1-p)}$$

DEFINICIÓN Medida de probabilidad relativa que tiene un evento de ocurrir frente a que no ocurra.

CÁLCULO Ratio entre probabilidad de que suceda el evento / Probabilidad de que no suceda

ESCALA Va de 0 a infinito.

EJEMPLO

He jugado Starcraft 5 veces, en las cuales he ganado 3 veces y he perdido 2.

$$\text{Odds}_{(\text{ganar})} = \frac{\text{Probabilidad de ganar}}{\text{Probabilidad de perder}} = \frac{0.6}{0.4} = 1.5$$

Ganar es 1.5 veces más probable que perder.

UTN - FRRO - Ciencia de Datos 4

ODDS Ratio

$$\text{Odds Ratio}_{(x)} = \frac{\text{Odds}_{(\text{grupo 1})}}{\text{Odds}_{(\text{grupo 2})}}$$

DEFINICIÓN Es la razón entre dos odds. Permite comparar los odds de un evento en dos grupos.

CÁLCULO La división entre el Odds del evento X en un grupo 1 y el Odds del evento X en el grupo 2.

ESCALA Va de 0 a infinito.

EJEMPLO

He jugado Starcraft 5 veces, en las cuales he ganado 3 veces y he perdido 2.

Otro día jugué Counter Strike, también 5 veces, gané 1 y perdí 4.

$$\text{Odds}_{(\text{ganar})} = \frac{\text{Odds}_{(\text{Starcraft})}}{\text{Odds}_{(\text{Counter Strike})}} = \frac{0.48}{0.08} = 6$$

Ganar en Starcraft es 6 veces más probable que el ganar en Counter Strike.

UTN - FRRO - Ciencia de Datos 5

Regresión Lineal

Y: ventas semanales de alimento para mascotas, en \$00

Unidad de observación: supermercado de una cadena

x: espacio destinado a la exhibición del producto, en dm

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_q x_q + \epsilon$$

$E(\text{Ventas} / \text{Espacio}) = \beta_0 + \beta_1 \text{Espacio}$

Venta de alimentos para mascotas

Nos interesa **predecir** el valor de la variable Dependiente del modelo a partir de una o mas variables Explicativas

La variable Predicha (Y) es:

- Numérica
- Continua
- No acotada

UTN - FRRO - Ciencia de Datos 6

Regresión Logística Binomial

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_q x_q + \epsilon$$

Nos interesa **predecir** el valor de la variable Dependiente del modelo a partir de una o mas variables Explicativas

$$Y = \begin{cases} 0 \rightarrow \text{No evento} \\ 1 \rightarrow \text{Evento} \end{cases}$$

La variable Predicha (Y) es:

- Dicotómica


Ejemplos:

- Aprueba o no un préstamo
- Votó o no votó
- Tiene o no una enfermedad X
- Compra o no un determinado producto

$$E(Y/X) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_q x_q$$

$$P(Y/X) = \beta_0 + \beta_1 x_1 + \beta_1 x_1 + \dots + \beta_q x_q$$

Problema



- La regresión lineal ayuda a predecir una variable numérica, continua, no acotada, pero no una variable dicotómica. En una RL la variable y nos puede salir menor que 0 y mayor que 1 y no aplicaría.
- Esto nos obliga a buscar una forma alternativa para PREDECIR el evento que sea NO LINEAL. Esta forma debe tener una variable Y que se encuentre entre 0 y 1.


Regresión Logística Binomial

$$P(Y=1/X) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_q x_q$$

Necesitamos entonces que:

- $P(Y=1/X)$ sea creciente para $\beta > 0$
- $P(Y=1/X)$ sea decreciente para $\beta < 0$
- $0 \leq P(Y=1/X) \leq 1$ para cualquier valor de X

Función Logit



Una función alternativa que nos permite calcular una variable que se encuentre entre los valores de 0 y 1 es la denominada función **logit**:

$$\ln\left(\frac{P}{1-P}\right) \quad \text{ODDs}$$

Modelo de regresión logística


$$P(Y/X) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_q x_q$$

$$\ln\left(\frac{P}{1-P}\right) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_q x_q$$


$$\frac{P}{1-P} = e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_q x_q}$$

$$P = \frac{e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_q x_q}}{1 + e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_q x_q}}$$

$$P = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_q x_q)}}$$



Ejemplo



$$P = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1)}}$$

Ejemplo: Contratación pack noticias

Archivo NewschanE.sav

Variables:

- Años educación
- Edad en años
- Horas de tv por día
- Orgs (número de bocas contratadas)

Prueba Conjunta

Las VI explican en forma conjunta a la VD?

$$H_0: \forall i \beta_i = 0$$

$$H_A: \exists i / \beta_i \neq 0$$

Modelo 1:

$$\frac{1}{1 + e^{-(b_0 + b_1x_1 + \dots + b_kx_k + a)}}$$

Modelo 2:

$$\frac{1}{1 + e^{-(b_0 + b_1x_1 + \dots + b_kx_k + a)}}$$

Omnibus Tests of Model Coefficients

Step	Step	Chi-square	df	Sig.
1	Step	56.903	4	.000
	Block	56.903	4	.000
	Model	56.903	4	.000

Las VI explican en forma conjunta a la VD ✓

Significancia de coeficientes

Hay alguna VI que no explique a la VD?

$$H_0: \beta_i = 0$$

$$H_A: \beta_i \neq 0$$

Variables in the Equation

	B	S.E.	Wald	df	Sig.	Exp(B)	95% C.I. for EXP(B)
							Lower Upper
Step 1 ^a							
Años de Educación	.119	.041	8.169	1	.004	1.126	1.038 1.221
Edad en años	.058	.009	45.978	1	.000	1.060	1.042 1.078
Horas de TV por Día	.058	.058	1.013	1	.314	1.060	.946 1.187
Número de Afiliaciones	-.001	.065	.000	1	.983	.999	.880 1.134
Constant	-4.107	.784	27.482	1	.000	.016	

a. Variable(s) entered on step 1: Años de Educación, Edad en años, Horas de TV por Día, Número de Afiliaciones.

Significancia de coeficientes

Hay alguna VI que no explique a la VD?

$$H_0: \beta_i = 0$$

$$H_A: \beta_i \neq 0$$

Variables in the Equation

	B	S.E.	Wald	df	Sig.	Exp(B)	95% C.I. for EXP(B)
							Lower Upper
Step 1 ^a							
Años de Educación	.120	.041	8.484	1	.004	1.127	1.040 1.222
Edad en años	.058	.009	46.411	1	.000	1.060	1.042 1.078
Horas de TV por Día	.057	.058	.976	1	.323	1.059	.945 1.185
Constant	-4.138	.782	27.991	1	.000	.016	

a. Variable(s) entered on step 1: Años de Educación, Edad en años, Horas de TV por Día.

Significancia de coeficientes

Hay alguna VI que no explique a la VD?

$$H_0: \beta_i = 0$$

$$H_A: \beta_i \neq 0$$

Variables in the Equation

	B	S.E.	Wald	df	Sig.	Exp(B)	95% C.I. for EXP(B)
							Lower Upper
Step 1 ^a							
Años de Educación	.108	.039	7.658	1	.006	1.114	1.032 1.202
Edad en años	.058	.008	47.037	1	.000	1.060	1.042 1.077
Constant	-3.820	.690	30.643	1	.000	.022	

a. Variable(s) entered on step 1: Años de Educación, Edad en años.

Cada una de las VI explican a la VD ✓

Modelo estimado

Omnibus Tests of Model Coefficients

Step	Step	Chi-square	df	Sig.
1	Step	58.015	2	.000
	Block	58.015	2	.000
	Model	58.015	2	.000

Variables in the Equation

	B	S.E.	Wald	df	Sig.	Exp(B)	95% C.I. for EXP(B)
							Lower Upper
Step 1 ^a							
Años de Educación	.108	.039	7.658	1	.006	1.114	1.032 1.202
Edad en años	.058	.008	47.037	1	.000	1.060	1.042 1.077
Constant	-3.820	.690	30.643	1	.000	.022	

a. Variable(s) entered on step 1: Años de Educación, Edad en años.

$$P = \frac{1}{1 + e^{-(3.82 + 0.108 \text{AñosEd} + .058 \text{Edad})}}$$

Hipótesis básicas

ϵ tiene


- promedio 0
- varianza constante σ_ϵ^2
- ϵ_i, ϵ_j independientes
- VI, ϵ_j independientes
- distribución normal
- No Multicolinealidad (más de 1 VI)

Centrado de errores

Supuestos: Media cero

$$H_0: \bar{\epsilon} = 0$$

$$H_A: \bar{\epsilon} \neq 0$$



One-Sample Test

	1	df	Sig. (2-tailed)	Mean Difference	95% Confidence Interval of the Difference	
Difference between observed and predicted probabilities	.000	440	1.000	.00000000	Lower	Upper
					-.0437484	.0437484

$\bar{\epsilon} = 0$ ✓

¿Varianza constante?

H_0 : Errores homocedásticos

H_A : Hay Heterocedasticidad

Test of Homogeneity of Variances

		Levene Statistic	df1	df2	Sig.
Difference between observed and predicted probabilities	Based on Mean	.469	2	438	.628
	Based on Median	.223	2	438	.800
	Based on Median and with adjusted df	.223	2	410.176	.800
	Based on trimmed mean	.465	2	438	.628

Errores homocedásticos ✓

¿Distribución Normal?

$H_0: \epsilon \sim Normal$

$H_A: \epsilon \not\sim Normal$

Tests of Normality

	Kolmogorov-Smirnov ^a			Shapiro-Wilk		
	Statistic	df	Sig.	Statistic	df	Sig.
Difference between observed and predicted probabilities	.169	441	.000	.910	441	.000

a. Lilliefors Significance Correction

$\epsilon \sim Normal$ ✗

No Multicolinealidad

Supuestos: Análisis de Multicolinealidad

H_0 : No hay Multicolinealidad

H_A : Hay Multicolinealidad

Collinearity Diagnostics^a

Model	Dimension	Eigenvalue	Condition Index	(Constant)	Años de Educación	Edad en años	Horas de TV por Día	Número de Afiliaciones
1	1	4.149	1.000	.00	.00	.01	.01	.02
	2	.501	2.877	.00	.00	.00	.12	.76
	3	.249	4.084	.00	.02	.06	.70	.20
	4	.088	6.851	.01	.13	.68	.00	.03
	5	.013	18.079	.98	.85	.25	.16	.00

a. Dependent Variable: Acepta el Ofrecimiento del Servicio de Noticias

IC > 30 => Hay Multicolinealidad IC = 18.079 => No Hay Multicolinealidad ✓

No autocorrelación

Supuestos: No autocorrelación de errores

$H_0: \epsilon$ no autocorrelados

$H_A: \epsilon$ autocorrelados

Autocorrelations

Series: Difference between observed and predicted probabilities

Lag	Autocorrelation	Std. Error ^a	Value	Box-Ljung Statistic	df	Sig. ^b
1	-.023	.047	.237	1	1	.627
2	.018	.047	.388	2	2	.824
3	.005	.047	.400	3	3	.940
4	-.005	.047	.411	4	4	.982
5	-.024	.047	.671	5	5	.985

a. The underlying process assumed is independence (white noise).
b. Based on the asymptotic chi-square approximation.

ϵ no autocorrelados ✓

Independencia VE y E

Supuestos: Independencia entre variables explicativas y error

$$H_0: \in ind de VE$$

$$H_A: \in no ind de VE$$

Correlations				
		Años de Educación	Edad en años	Difference between observed and predicted probabilities
Años de Educación	Pearson Correlation	1	-.182**	.000
	Sig. (2-tailed)		.000	1.000
	N	442	441	441
Edad en años	Pearson Correlation	-.182**	1	.000
	Sig. (2-tailed)	.000		1.000
	N	441	441	441
Difference between observed and predicted probabilities	Pearson Correlation	.000	.000	1
	Sig. (2-tailed)	1.000	1.000	
	N	441	441	441


** Correlation is significant at the 0.01 level (2-tailed).

$\in ind de Var. Exp.$

UTN - FRRo - Ciencia de Datos

25

Puntos de balanceo e influyentes



UTN - FRRo - Ciencia de Datos

26

Distancia de Cook

- Los puntos con grandes valores de D_i tienen influencia sobre la estimación de β . Se suelen considerar **puntos influyentes** si $D_i > 1$

No hay puntos influyentes

UTN - FRRo - Ciencia de Datos

27

Evaluando el modelo

Classification Table ^a				
		Predicted		Percentage Correct
		Accepta el Ofrecimiento del Servicio de Noticias	No	
Step 1	Observed	No	Si	
	Accepta el Ofrecimiento del Servicio de Noticias	163	64	71.8
	No	88	126	58.9
Overall Percentage				65.5

a. The cut value is .500

Acierto Global = 65.5 %


Acierto para contrata el pack SI = 58.9 %

Acierto para contrata el pack NO = 71.8 %

UTN - FRRo - Ciencia de Datos

28

Evaluando el modelo



UTN - FRRo - Ciencia de Datos

29

Evaluando el modelo

Coordinates of the Curve				
Positive if Greater Than or Equal To ^a	Sensitivity	1 - Specificity	Specificity	Sensitivity - Specificity
0.4617546	0.664	0.379	0.621	0.042
0.4627365	0.664	0.374	0.626	0.038
0.4656646	0.664	0.370	0.630	0.034
0.4699360	0.654	0.366	0.634	0.020
0.4728885	0.654	0.352	0.6476	0.0066
0.4748561	0.650	0.344	0.6564	-0.0069
0.4768265	0.631	0.335	0.665	-0.034
0.4781326	0.626	0.335	0.665	-0.039
0.4804233	0.626	0.330	0.670	-0.043
0.4833818	0.621	0.304	0.696	-0.075
0.4863417	0.621	0.300	0.700	-0.079

Punto de corte = 0.4729

Classification Table ^a				
		Predicted		Percentage Correct
		Accepta el Ofrecimiento del Servicio de Noticias	No	
Step 1	Observed	No	Si	
	Accepta el Ofrecimiento del Servicio de Noticias	147	80	64.8
	No	74	140	65.4
Overall Percentage				65.1

a. The cut value is .473

Acierto Global
65.1 %

UTN - FRRo - Ciencia de Datos

30

Variables in the Equation								
	B	S.E.	Wald	df	Sig.	Exp(B)	95% C.I. for EXP(B) Lower	Upper
Step 1 ^a								
Años de Educación	.108	.039	7.658	1	.006	1.114	1.032	1.202
Edad en años	.058	.008	47.037	1	.000	1.060	1.042	1.077
Constant	-3.820	.690	30.643	1	.000	.022		

a. Variable(s) entered on step 1: Años de Educación, Edad en años.

UTN - FRRo - Ciencia de Datos

	B	S.E.	Wald	df	Sig.	Exp(B)	95% C.I. for Exp(B)	
							Lower	Upper
Step 1 ^a								
Años de Educación	.108	.039	7.658	1	.006	1.114	1.032	1.202
Edad en años	.058	.008	47.037	1	.000	1.060	1.042	1.077
Constant	-3.820	.690	30.643	1	.000	.022		

a. Variable(s) entered on step 1: Años de Educación, Edad en años.

UTN - FRRo - Ciencia de Datos

$$\frac{e^{\beta_0 + \beta_1(X+1)}}{e^{\beta_0 + \beta_1 X}} = e^{\beta_0 + \beta_1(X+1) - (\beta_0 + \beta_1 X)} = e^{\beta_1}$$

- UTN - FRRo - Ciencia de Datos

UTN - FRRo - Ciencia de Datos

Aplico el modelo a
nuevos datos