



**Cátedra de Ciencia de Datos
Ingeniería en Sistemas de Información**

Análisis de componentes principales (ACP)

Introducción Práctica

Análisis de componentes principales

1. Los datos de EPF de la encuesta de presupuestos familiares en España (**archivo epf.dat**) presentan los gastos medios de las familias españolas para las 51 provincias (Ceuta y Melilla aparecen unidas como una provincia) en nueve variables:

X1 = alimentación,

X2 = vestido y calzado

X3 = vivienda

X4 = mobiliario doméstico

X5 = gastos sanitarios

X6 = transportes

X7 = enseñanza y cultura

X8 = turismo y ocio

X9 = otros gastos

	X1	X2	X3	X4	X5	X6	X7	X8	X9
Almeria	618957	295452	522128	167067	58288	280035	129219	307967	107334
Cadiz	683940	203619	426690	124162	60657	285888	127792	313238	83523
Cordoba	590770	265604	487143	113386	37131	237320	116764	247536	79924
Granada	547353	238822	458338	119540	40340	236694	103901	272308	72813
...									

Poseemos información de 51 observaciones (N) en 9 variables (P)

¿Cómo podemos representar estos datos en una dimensionalidad menor?

Análisis de componentes principales

- ✓ Es una técnica descriptiva
- ✓ Tiene como objetivo representar un conjunto de datos de N observaciones y P variables (generalmente un valor grande de P) en una dimensionalidad significativamente menor con mínima pérdida de información.
- ✓ Esta técnica suele utilizarse para representar datos multidimensionales en 2 o 3 dimensiones.
- ✓ Puede utilizarse en conjunto con otras técnicas como clustering.

Análisis de componentes principales

Obs	X1	X2	X3	..	..	..	..	Xp
1	656	466	466					667
2	..	776	55		657		..	668
..	..			954	..	..	..	421
N	...		..	..				..

Generamos nuevas variables, combinación lineal de las variables originales:

$$Z_1 = a_{11} X_1 + a_{12} X_2 + a_{13} X_3 + \dots + a_{1p} X_p$$

$$Z_2 = a_{21} X_1 + a_{22} X_2 + a_{23} X_3 + \dots + a_{2p} X_p$$

..

..

$$Z_p = a_{p1} X_1 + a_{p2} X_2 + a_{p3} X_3 + \dots + a_{pp} X_p$$

Total de componentes: p

Sin embargo buscamos **r** variables **Zi (r < p)** que conserven la misma información

Análisis de componentes principales

Cada componente principal o variable Z_i quedará definida:

$$Z_i = a_{i1} X_1 + a_{i2} X_2 + a_{i3} X_3 + \dots + a_{ip} X_p$$

$$\text{Ejemplo } Z_1 = 4 X_1 + 5 X_2 + 6 X_3 + \dots + 7 X_p$$

- Las nuevas variables Z_i tienen $E(Z_i) = 0$ y $S^2(Z_i) = \lambda_i$
- Eigenvector (a_i) es el vector que define la i -ésima componente
- Eigenvalor (λ_i) es la varianza de la componente Z_i
- Prop. Variabilidad explicada $Z_i = \lambda_i / \text{Varianza Total}$

$$\text{Donde } \textbf{Varianza total} = \sum S^2(X_i) = \sum \lambda_i$$

- **$\text{Corr}(Z_i, Z_j) = 0$** es decir, las nuevas variables están incorreladas

Análisis de componentes principales

¿Cuántas componentes elegimos (r)?


Depende el % de variabilidad que deseamos conservar

Componente	λ	% explicado	% acumulado
1	7,45	57,34%	57,34%
2	2,14	16,46%	73,80%
3	1,25	9,59%	83,39%
4	0,63	4,85%	88,24%
5	0,51	3,92%	92,16%
6	0,32	2,49%	94,65%
7	0,27	2,11%	96,77%

En este ejemplo, podemos ver cómo con 2 CP (cada uno de ellos combinación lineal de las variables originales) conservamos el 73% de variabilidad de los datos.

Ahora este dataset de 9 variables, podemos representarlo en 2D

	X1	X2	X3	X4	X5	X6	X7	X8	X9
Almeria	618957	295452	522128	167067	58288	280035	129219	307967	107334
Cadiz	683940	203619	426690	124162	60657	285888	127792	313238	83523
Cordoba	590770	265604	487143	113386	37131	237320	116764	247536	79924
Granada	547353	238822	458338	119540	40340	236694	103901	272308	72813
...									



Análisis de componentes principales

Para poder aplicar PCA necesito:

- Variables numéricas.
- Variables correladas. Si no, no voy a lograr reducir la dimensionalidad.

El **RESULTADO de ACP** es un dataset donde

- cada **COLUMNA** son mis componentes principales en vez de mis VARIABLES ORIGINALES
- cada **FILA** sigue siendo una observación.
- La diferencia es que los **valores** ya no son los originales si no los de los valores de cada componente.

Usos:

- Reducir dimensionalidad.
- Obtener variables incorreladas.
- Realizar un análisis descriptivo de mis datos.
- Detectar algún outlier.