






Análisis de Componentes Principales




Ciencia de Datos



Variables


Variable	X	$X_c (x - \mu)$	$X_e ([x - \mu] / \sigma)$
Media	μ	0	0
Desvío std.	σ	σ	1

UTN - FRRo - ISI - Ciencia de Datos



Análisis Bivariado

ANAL MINF
ANAL 1.0000000 0.6741286
MINF 0.6741286 1.0000000



UTN - FRRo - ISI - Ciencia de Datos


Componentes principales

- Objetivo: dada una matriz de datos de dimensiones $n \times p$ que representa los valores de p variables en n individuos, investigar si es posible representar los individuos mediante r variables ($r < p$) con poca (o, dentro de lo posible, ninguna) pérdida de información.

UTN - FRRo - ISI - Ciencia de Datos

Análisis Bivariado


ANAL MINF
ANAL 1.0000000 0.6741286
MINF 0.6741286 1.0000000



UTN - FRRo - ISI - Ciencia de Datos

Análisis Bivariado

ANAL MINF
ANAL 1.0000000 0.6741286
MINF 0.6741286 1.0000000



UTN - FRRo - ISI - Ciencia de Datos

Componentes principales

Buscamos variables Z , combinación lineal de las X originales, tales que:

- r de ellas contengan toda la información
- las restantes $p-r$ sean irrelevantes

Ventajas

- Transforma las variables originales, usualmente correladas en incorreladas
- Es el primer paso para descubrir **variables latentes**







UTN - FRRo - ISI - Ciencia de Datos

Componentes principales

- $X_{n \times p}$: matriz de datos **centrados**

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix} \quad \bar{\mathbf{X}} = \mathbf{0}$$

UTN - FRRo - ISI - Ciencia de Datos




Análisis con correlaciones

- Al maximizar la varianza de las proyecciones sobre la dirección a , si alguna de las variables, por ej. x_i , tiene varianza mucho mayor que las de las demás, entonces el modo de aumentar $V(z_i)$ es acompañando a x_i con un coeficiente muy grande. El primer componente tenderá a coincidir con esta variable.
- Si las unidades de medida de las variables son distintas, la maximización dependerá de la escala usada para cada variable.

Solución: Estandarizar

UTN - FRRo - ISI - Ciencia de Datos

Datos estandarizados




Matriz de correlación

	Comp.1	Comp.2
V_1	0.7071068	0.7071068
V_2	0.7071068	-0.7071068

component variances

	Comp.1	Comp.2
	1.8870867	0.1129133

$$p = \text{cant. Var} \sum_{i=1}^p \lambda_i = \text{Cant. de Variables (p)}$$



UTN - FRRo - ISI - Ciencia de Datos

Análisis con correlaciones

- Variables estandarizadas

Matriz de covarianzas = Matriz de correlaciones

- Los componentes principales normados se obtienen calculando los valores y vectores propios asociados a la matriz de correlación

Si las diferencias entre las varianzas de las variables son informativas y queremos tenerlas en cuenta
NO DEBEMOS ESTANDARIZAR

UTN - FRRo - ISI - Ciencia de Datos

Situación Social

Correlaciones

	ANAL	ESPV	HCAG	HDCL	HHAC	HSGR	MINF	MORT	RPRI	RSEC	TCAM	VDRU	VDUR
ANAL	1,00	-0,65	-0,72	-0,61	0,86	0,84	0,67	-0,22	0,83	0,12	-0,16	0,84	0,80
ESPV	-0,65	1,00	0,37	0,23	-0,79	-0,76	-0,58	0,56	-0,58	-0,49	0,03	-0,75	-0,83
HCAG	-0,72	0,37	1,00	0,66	-0,51	-0,68	-0,50	-0,02	-0,64	0,17	0,23	-0,54	-0,72
HDCL	-0,61	0,23	0,66	1,00	-0,51	-0,52	-0,56	0,14	-0,59	0,29	0,26	-0,67	-0,49
HHAC	0,86	-0,79	-0,51	-0,51	1,00	0,82	0,77	-0,37	0,68	0,23	-0,15	0,92	0,84
HSGR	0,84	-0,76	-0,68	-0,52	0,82	1,00	0,66	-0,26	0,80	0,04	0,02	0,84	0,90
MINF	0,67	-0,58	-0,50	-0,56	0,77	0,66	1,00	-0,06	0,52	-0,03	-0,08	0,75	0,75
MORT	-0,22	0,56	-0,02	0,14	-0,37	-0,26	-0,06	1,00	-0,31	-0,70	0,46	-0,44	-0,40
RPRI	0,83	-0,58	-0,64	-0,59	0,68	0,80	0,52	-0,31	1,00	0,08	-0,10	0,75	0,75
RSEC	0,12	-0,49	0,17	0,29	0,23	0,04	-0,03	-0,70	0,08	1,00	-0,23	0,12	0,21
TCAM	-0,16	0,03	0,23	0,26	-0,15	0,02	-0,08	0,46	-0,10	-0,23	1,00	-0,25	-0,20
VDRU	0,84	-0,75	-0,54	-0,67	0,92	0,84	0,75	-0,44	0,75	0,12	-0,25	1,00	0,85
VDUR	0,80	-0,83	-0,72	-0,49	0,84	0,90	0,75	-0,40	0,75	0,21	-0,20	0,85	1,00

UTN - FRRo - ISI - Ciencia de Datos

Situación Social

Vectores Propios

Comp.	1	2	3	4	5	6	7	8	9	...
Var	0,34	0,08	-0,01	0,15	0,06	0,54	0,02	-0,29	-0,13	...
ANAL	0,34	0,08	-0,01	0,15	0,06	0,54	0,02	-0,29	-0,13	...
ESPV	-0,29	0,26	0,31	0,03	-0,08	0,32	0,02	0,14	0,77	...
HCAG	-0,26	-0,27	-0,22	-0,41	-0,47	0,21	0,29	0,17	-0,11	...
HDCL	-0,24	-0,28	-0,39	0,08	0,48	0,10	0,52	0,18	0,12	...
HHAC	0,34	-0,05	-0,13	-0,27	-0,01	0,26	0,18	-0,35	0,25	...
HSGR	0,34	0,08	-0,19	0,19	0,00	-0,21	0,28	-0,06	...	...
MINF	0,28	0,14	-0,10	-0,62	0,18	0,06	-0,31	...	...	...
MORT	-0,15	0,55	-0,21	-0,08	0,39	0,32	...	...	...	...
RPRI	0,31	0,06	0,00	0,46	-0,28	...	...	...	...	...
RSEC	0,06	-0,62	-0,10	0,13	...	...	...	...	...	...
TCAM	-0,08	0,23	-0,76	0,17	...	...	...	...	...	...
VDRU	0,35	-0,02	0,04	-0,23	...	...	...	...	...	...
VDUR	0,35	-0,04	-0,07	0,03	...	...	...	...	...	...

UTN - FRRo - ISI - Ciencia de Datos

Situación Social


$\text{Var}(Z_i)$

Se quiere el 80% de variabilidad explicada

Componente	λ	% explicado	% acumulado
1	7,45	57,34%	57,34%
2	2,14	16,46%	73,80%
3	1,25	9,59%	83,39%
4	0,63	4,85%	88,24%
5	0,51	3,92%	92,16%
6	0,32	2,49%	94,65%
7	0,27	2,11%	96,77%
8	0,19	1,48%	98,24%
9	0,08	0,62%	98,86%
10	0,06	0,46%	99,32%
11	0,04	0,32%	99,64%
12	0,04	0,27%	99,91%
13	0,01	0,09%	100,00%

UTN - FRRo - ISI - Ciencia de Datos

Situación Social



UTN - FRRO - ISI - Ciencia de Datos

Situación Social

Vectores Propios

Comp.	1	2	...
ANAL	0,34	0,08	
ESPV	-0,29	0,26	
HCAG	-0,26	-0,27	
HDCL	-0,24	-0,28	
HHAC	0,34	-0,05	
HSGR	0,34	0,08	
MINF	0,28	0,14	
MORT	-0,15	0,55	
RPRI	0,31	0,06	
RSEC	0,06	-0,62	
TCAM	-0,08	0,23	
VDRU	0,35	-0,02	
VDUR	0,35	-0,04	

$$Z_1 = 0,34 \text{ anal} - 0,29 \text{ espv} - 0,26 \text{ hcag} - 0,24 \text{ hdcl} + 0,34 \text{ hhac} + 0,34 \text{ hsg} + 0,28 \text{ minf} - 0,15 \text{ mort} + 0,31 \text{ rpri} + 0,06 \text{ rsec} - 0,08 \text{ tcam} + 0,35 \text{ vdr} + 0,35 \text{ vdur}$$

Distingue a las provincias según el nivel de la pobreza estructural:

Educación básica (analfabetismo y repitencia primaria)


Situación habitacional (viviendas deficitarias urb. y rurales)

Disponib. de infraest. de servicios (agua potable y desagües cloacales)

Expectativas de vida (esperanza de vida)

UTN - FRRO - ISI - Ciencia de Datos

Situación Social




UTN - FRRO - ISI - Ciencia de Datos

Ordenamiento según componentes

	PC1	PC2
Capital Federal	-6,48	-4,67
La Pampa	-2,62	-2,07
Tierra del Fuego	-2,61	-1,89
Cordoba	-2,35	-1,30
Santa Cruz	-2,26	-1,29
Buenos Aires	-2,23	-1,18
Mendoza	-2,07	-0,90
Santa Fe	-2,03	-0,02
Entre Rios	-0,93	0,09
Chubut	-0,92	0,14
Neuquen	-0,78	0,29
San Juan	-0,47	0,34
San Luis	-0,23	0,35
Rio Negro	-0,10	0,46
La Rioja	0,13	0,53
Tucuman	0,27	0,64
Catamarca	0,83	0,67
Salta	2,16	0,70
Jujuy	2,40	1,35
Corrientes	3,02	1,42
Sgo. del Estero	3,24	1,42
Misiones	4,54	1,54
Chaco	4,60	1,55
Formosa	4,91	1,82
Tierra del Fuego		-4,67
Neuquen		-2,07
Rio Negro		-1,89
Salta		-1,30
Jujuy		-1,29
Chubut		-1,18
Santa Cruz		-0,90
Mendoza		-0,02
San Luis		0,09
Formosa		0,14
Tucuman		0,29
La Rioja		0,34
Chaco		0,35
Catamarca		0,46
Misiones		0,53
La Pampa		0,64
San Juan		0,67
Corrientes		0,70
Entre Rios		1,35
Buenos Aires		1,42
Santa Fe		1,42
Capital Federal		1,54
Sgo. del Estero		1,55
Cordoba		1,82

UTN - FRRO - ISI - Ciencia de Datos

Situación Social. PC1 vs PC2



UTN - FRRO - ISI - Ciencia de Datos

Situación Social

Matriz S

	ANAL	ESPV	HCAG	HDCL	HHAC	HSGR	MINF	MORT	RPRI	RSEC	TCAM	VDRU	VDUR
ANAL	6,27	-1,96	-27,31	-29,34	8,92	28,29	7,77	-0,91	6,58	1,04	-0,53	49,62	22,79
ESPV	-1,96	1,43	6,65	5,26	-3,91	-12,23	-3,20	1,10	-2,19	-2,01	0,05	-20,97	-11,40
HCAG	-27,31	6,65	229,91	191,38	-32,08	-139,19	-35,02	-0,38	8,70	4,59	-193,74	-124,50	
HDCL	-29,34	5,26	191,38	364,42	-40,03	-134,31	-48,98	4,36	-35,65	19,26	6,41	-299,08	-107,43
HHAC	8,92	-3,91	-32,08	-40,03	17,22	45,79	14,77	-2,50	8,99	3,22	-0,80	89,63	39,82
HSGR	28,29	-12,23	-139,19	-134,31	45,79	179,62	40,87	-5,64	34,18	1,95	0,30	265,21	137,88
MINF	7,77	-3,20	-35,02	-48,98	14,77	40,87	21,20	-0,47	7,56	-0,44	-0,48	81,55	39,46
MORT	-0,91	1,10	-0,38	4,36	-2,50	-5,64	-0,47	2,71	-1,62	-3,99	0,99	-17,19	-7,61
RPRI	6,58	-2,19	-30,75	-35,65	8,99	34,18	7,56	-1,62	10,05	0,90	-0,40	55,77	27,05
RSEC	1,04	-2,01	8,70	19,26	3,22	1,95	-0,44	-3,99	0,90	11,86	-1,02	9,54	8,46
TCAM	-0,53	0,05	4,59	6,41	-0,80	0,30	-0,48	0,99	-0,40	-1,02	1,66	-7,72	-3,01
VDRU	49,62	-20,97	-193,74	-299,08	89,63	265,21	81,55	-17,19	55,77	9,54	-7,72	552,78	229,53
VDUR	22,79	-11,40	-124,50	-107,43	39,82	137,88	39,46	-7,61	27,05	8,46	-3,01	229,53	131,01

UTN - FRRO - ISI - Ciencia de Datos

Test de esfericidad de Barlett

$H_0: |R| = 1$

$H_A: |R| \neq 1$

R: Matriz de correlaciones

Determinante máximo = 1

KMO y prueba de Bartlett

Medida de adecuación muestral de Kaiser-Meyer-Olkin.		,734
Prueba de esfericidad de Bartlett	Chi-cuadrado aproximado	330,830
	gl	78
	Sig.	,000

UTN - FRRo - ISI - Ciencia de Datos

Situación Social

Componente	λ_i (Var(Z _i))	V(x _i)
1	1145,12	6,27
2	198,36	1,43
3	128,00	229,91
4	24,43	364,42
5	12,18	17,22
6	11,39	179,62
7	5,05	21,2
8	2,82	2,71
9	1,25	10,05
10	0,81	11,86
11	0,37	1,66
12	0,23	552,78
13	0,14	131,01
Total	1530,14	1530,14

Traza de la matriz S

UTN - FRRo - ISI - Ciencia de Datos

Ejemplo: Notas materias

Valores Propios

Componente	λ_i
1	3,7104
2	2,8608
3	0,9535
4	0,2156
5	0,1513
6	0,0628
7	0,0317
8	0,0139

Vectores Propios

Comp.	1	2	3	4	5	6	7	8
Lengua	0,500	0,085	-0,028	-0,235	0,434	...	...	...
Matemática	-0,113	0,555	0,133	-0,254	-0,245	...	...	...
Física	-0,052	0,575	0,076	0,059	0,386	...	...	...
Inglés	0,499	0,037	-0,005	-0,550	0,102	...	...	...
Filosofía	0,480	0,12	-0,303	0,702	0,145	...	...	...
Historia	0,483	0,064	-0,011	0,027	-0,736	...	...	...
Química	-0,073	0,574	-0,021	0,135	-0,163	...	...	...
Gimnasia	0,187	-0,069	0,940	0,250	0,052	...	...	...

UTN - FRRo - ISI - Ciencia de Datos