



MINERIA DE DATOS

PRACTICA: COMPONENTES PRINCIPALES

1. Los datos de EPF de la encuesta de presupuestos familiares en España (**archivo epf.dat**) presentan los gastos medios de las familias españolas para las 51 provincias (Ceuta y Melilla aparecen unidas como una provincia) en nueve variables:

- X1 = alimentación,
- X2 = vestido y calzado
- X3 = vivienda
- X4 = mobiliario doméstico
- X5 = gastos sanitarios
- X6 = transportes
- X7 = enseñanza y cultura
- X8 = turismo y ocio
- X9 = otros gastos


	X1	X2	X3	X4	X5	X6	X7	X8	X9
Almeria	618957	295452	522128	167067	58288	280035	129219	307967	107334
Cadiz	683940	203619	426690	124162	60657	285888	127792	313238	83523
Cordoba	590770	265604	487143	113386	37131	237320	116764	247536	79924
Granada	547353	238822	458338	119540	40340	236694	103901	272308	72813
...									

La matriz de covarianzas resume la variabilidad de estas 9 variables en los 51 elementos observados.

Realizar un análisis de componentes principales.

Fuente: ANALISIS DE DATOS MULTIVARIANTES, 1 Ed.
Por Daniel Peña
ISBN: 8448136101

2. Supongamos 6 observaciones $x_1, \dots, x_6$ en dos dimensiones, cada observación corresponde a un rectángulo y las variables son longitud de la base y altura del rectángulo. Gráficamente las observaciones son:



que corresponden a la matriz de datos:

Longitud base	Altura
2	2
1.5	0.5
0.7	0.5
0.5	1.5
0.5	0.7
0.7	0.7

Fuente: ANALISIS DE DATOS MULTIVARIANTES, 1 Ed.

Por Daniel Peña

ISBN: 8448136101

3. "acciones.dat"

Este conjunto de datos presenta 34 observaciones y 3 variables.

Las observaciones corresponden a distintas acciones que cotizan en el mercado continuo español y las variables a tres medidas de rentabilidad de estas acciones durante un periodo de tiempo.

Las variables son:

- X1 es la rentabilidad efectiva por dividendos
- X2 es la proporción de beneficios que va a dividendos y
- X3 el ratio entre precio por acción y beneficios

	X1	X2	X3
1	3,40	89,70	30,20
2	5,10	55,70	9,90
3	4,50	52,30	11,50
4	3,50	47,00	11,20
5	5,90	42,70	7,00
6	5,10	30,60	6,90
7	4,60	64,40	11,80
8	5,00	51,00	9,60
9	3,20	54,40	14,70
10	3,40	45,70	13,20
		.	
		.	
		.	
		.	
32	6,90	53,60	6,60
33	14,40	87,80	5,20
34	14,90	34,50	4,69

Fuente: ANALISIS DE DATOS MULTIVARIANTES, 1 Ed.

Por Daniel Peña

ISBN: 8448136101

4. "Invest".

Este conjunto de datos presenta 21 observaciones de 8 variables.

Las observaciones corresponden a los países de la OCDE y las variables son el número de publicaciones científicas recogidas en el trienio 1982-84 en ocho bases de datos de producción científica.

Las variables se han llamado según la orientación de la base de datos:

- InterA (por interdisciplinaria),
- InterF (por interdisciplinaria),
- Agric. (Agricultura),
- Biolo. (Biología),
- Medic. (Medicina),
- Quimic. (Química),
- Inge. (Ingeniería) y
- Física

	INTER.A	INTER.F	AGRIC.	BIOLO.	MEDIC.	QUIMI.	INGEN.	FISICA
EE.UU	815319	379851	88663	58104	255864	440134	111015	162288
UK	162103	90332	35158	29802	59630	92725	6409	34349
JP	105856	78811	13978	16758	55634	308926	32039	40538
F	118935	76186	13818	11253	49938	120065	9984	35792
G	91099	85037	11740	20337	41233	66087	11304	22093
C	72722	49459	14041	16722	23139	101900	12034	14645
I	42905	29734	7904	13444	31078	36322	5833	11351
A	36121	22236	12419	9863	12186	19641	4898	6299
H	29912	18036	6563	7548	13721	23029	3798	6775
S	28568	16190	3985	9502	14852	18341	2387	3549
CH	26495	14518	3378	3636	11096	19304	2556	5784
E	16425	11818	3089	3981	7196	15493	1258	2692
B	17311	11791	3240	4011	8098	11964	1772	3417
D	14677	555	2635	5667	8368	14266	1197	1999
AU	10957	13154	1433	2372	5928	6713	1318	2278
FI	11012	6457	2028	4756	5731	6647	1001	1669
N	9075	5432	1803	3299	4801	5326	912	853
Y	4686	2957	2031	1194	1806	7046	801	1861
GR	3720	2749	692	1293	1518	2415	896	1366
IR	6786	214	432	1119	1355	98	522	941
P	1221	1929	388	386	564	12	493	413

Fuente: ANALISIS DE DATOS MULTIVARIANTES, 1 Ed.

Por Daniel Peña

ISBN: 8448136101

5. "Gas". Datos de autos de importación y nacionales.

Este conjunto de datos contiene 30 observaciones y 7 variables que se detallan a continuación:

Variable	Tipo	Descripción añadida
Desplazamiento	numérico	en pulgadas cúbicas
Potencia	numérico	en pies-libras
Par motor	numérico	en pies-libras
Longitud del coche	numérico	en pulgadas
Anchura del coche	numérico	en pulgadas
Peso del coche	numérico	en libras
Recorrido gasolina	numérico	en millas por galón de gasolina

La siguiente tabla muestra el conjunto de datos:

74gas							
	desplazamiento	potencia	par	longitud	anchura	peso	recorrido
1	318.0	140	255	215.3	76.3	4370	19.7
2	440.0	215	330	184.5	69.0	4215	11.2
3	351.0	143	255	199.9	74.0	3890	18.3
4	360.0	180	290	214.2	76.3	4250	21.5
5	140.0	83	109	168.8	69.4	2700	20.3
6	85.3	80	83	160.6	62.2	2009	36.5
7	350.0	165	260	200.3	69.9	3910	18.9
8	96.9	75	83	162.5	65.0	2320	30.4
9	351.0	148	243	215.5	78.5	4540	13.9
10	440.0	215	330	231.0	79.7	5185	14.9
11	171.0	109	146	170.4	66.9	2655	21.5
12	302.0	129	220	199.9	74.0	3890	17.8
13	350.0	155	250	196.7	72.2	3910	17.8
14	318.0	145	255	197.6	71.0	3666	16.4
15	231.0	110	175	179.3	65.4	3050	23.5
16	96.9	75	83	165.2	61.8	2275	31.9
17	500.0	190	360	224.1	79.8	5290	14.4
18	231.0	110	175	179.3	65.4	3020	22.1
19	350.0	170	275	199.6	72.9	3860	17.0
20	250.0	105	185	196.7	72.2	3510	20.0
21	225.0	95	170	194.0	71.8	3365	20.1
22	89.7	70	81	155.7	64.0	1905	34.7
23	350.0	155	250	195.4	74.4	3885	16.5
24	258.0	110	195	171.5	77.0	3375	19.7
25	460.0	223	366	228.0	79.8	5430	13.3
26	360.0	195	295	209.3	77.4	4215	13.8
27	262.0	110	200	179.3	65.4	3180	21.5
28	350.0	165	255	185.2	69.0	3660	16.5
29	351.0	148	243	216.1	78.5	4715	13.3
30	133.6	96	120	171.5	63.4	2535	23.9

Se pide realizar un Análisis de Componentes Principales

Fuente: "Prediction Using Regression Models with Multicollinear Predictor Variables" IIE Transactions (Mayo, 1993) vol. 25 nº 3, 73-85, Montgomery D.C. & Peck E.A., Introduction to Linear Regression Analysis, 2ª edición, J. Wiley and Sons, N.Y. (1992)

Por Douglas Montgomery and David Friedman

6. "Medifis".

Este conjunto de datos contiene 28 observaciones de 8 variables.

Las observaciones corresponden a estudiantes españoles y las variables a sus características físicas.

Las variables son:

- genero(0 mujer, 1 hombre),
- estatura (en cm),
- peso (en kg),
- longitud de pie (en cm),
- longitud de brazo (en cm),
- anchura de espalda (en cm),
- diámetro del cráneo (en cm),
- longitud entre rodilla y tobillo (en cm).

	sexo	talla	peso	pie	longbr	aes	diamcraneo	longrodtob
1	0	159	49	36	68	42	57	40
2	1	164	62	39	73	44	55	44
3	0	172	65	38	75	48	58	44
4	0	167	52	37	73	41,50	58	44
...								
24	1	189	87	45	82	53	61	52
25	0	170	70	38	73	45	56	43
26	1	170	67	40	77	46,50	58	44,50
27	0	168	56	37,50	70,50	48	60	40

Fuente: ANALISIS DE DATOS MULTIVARIANTES, 1 Ed.

Por Daniel Peña

ISBN: 8448136101

7. Situación social en la Argentina: sus características y desigualdades.

Los datos disponibles para la República Argentina en los años '90, la presentan con niveles socioeconómicos aceptables en el contexto de América Latina. Así, con un nivel de crecimiento poblacional bajo, su ingreso per cápita y su nivel educativo promedio la colocan junto a Uruguay entre los países más desarrollados del subcontinente. Paralelamente, presenta niveles de desocupación próximos al 17%, casi un 20% de población con Necesidades Básicas Insatisfechas y un ingreso cada vez más concentrado.

Estos niveles reflejan un déficit en las condiciones sociales de amplios sectores de la población que requieren su atención y la implementación de políticas dirigidas a su pronta reducción. A su vez, es sabido que la distribución de los problemas económico-sociales en el ámbito nacional responde a cuestiones geográficas, productivas, ambientales, históricas, etc., que determinan una gran heterogeneidad y obligan consecuentemente a implementar políticas diferenciadas por regiones y provincias.

En este sentido, interesa captar la variabilidad de condiciones socioeconómicas entre las diferentes zonas, marcando entonces aquellas desigualdades que orienten las acciones sobre aspectos que se entienden prioritarios en materia de políticas sociales.

En consecuencia, la pregunta general que nos formulamos es:

¿Cuál es la situación social de las provincias argentinas?

Variables en el archivo **Situacion Social.txt**

Etiqueta	Nombre de la variable	Definición
REG	Región	1 .Metropolitana - 2.Pampeana - 3. Cuyo - 4.Nordeste - 5. Noroeste - 6.Patagonia
NURB	Nivel de Urbanización	1.Baja - 2.Media - 3.Alta
CREC	Tasa media anual de crecimiento	Es el ritmo de crecimiento medio anual en % de la población total.
ESPV	Esperanza de vida	Es el número medio de años que se espera vivan los habitantes de la provincia.
NATA	Tasa bruta de natalidad	Indica la frecuencia con que ocurren los nacimientos de una población (‰).
MORT	Tasa bruta de mortalidad	Indica la frecuencia con que ocurren las defunciones en una población dada (‰)-
MINF	Tasa de Mortalidad infantil	Expresa la intensidad de la mortalidad en el primer año de vida (‰).
HNBI	Hogares NBI (%)	Expresa la incidencia de Necesidades Básicas Insatisfechas en el total de hogares de una población (%).
ANAL	Analfabetismo (10 y +) (%)	Indica, en porcentajes, la incidencia del analfabetismo entre las personas 10 años y más.
RPRI	Repitencia primario (%)	Es la proporción de alumnos que, en el nivel primario, no logran superar el nivel que cursan.
RSEC	Repitencia Secundario (%)	Es la proporción de alumnos que, en el nivel secundario, no logran superar el nivel que cursan.
TCAM	Camas disponibles en Establecimientos Asistenciales (‰)	Cantidad de camas disponibles por cada 1.000 habitantes, en establecimientos asistenciales.
VDUR	Viviendas deficitarias urbanas (%)	Proporción de viviendas ubicadas en zonas urbanas que presentan algún tipo de déficit de infraestructura o servicios.
VDRU	Viviendas deficitarias rurales (%)	Proporción de viviendas ubicadas en zonas rurales que presentan algún tipo de déficit de infraestructura o servicios.
HHAC	Hogares con hacinamiento crítico (%)	Proporción de hogares en los que habitan tres o más personas por cuarto.
HSGR	Hogares sin gas de red o envasado (%)	Proporción de hogares que no cuentan con provisión de gas.
HCAG	Hogares con servicio de agua potable (%)	Proporción de hogares que cuentan con provisión de agua potable.
HDCL	Hogares con desagüe cloacal (%)	Proporción de hogares que disponen de servicios de desagües cloacales.

PTIP	Distribución de Puestos de Trabajo Industriales (%)	Es la parte de puestos de trabajo industriales de la nación, generados en cada provincia.
PTCP	Distribución de Puestos Trabajo Comercio (%)	Es la parte de puestos de trabajo en el comercio de la nación, generados en cada provincia.
DiRE	Distribución de la Transferencia de Recursos Nacionales (%)	Es la parte de recursos nacionales asignados a cada provincia.

Se pide realizar

- Análisis univariado con mortalidad infantil.
- Análisis bivariado con mortalidad infantil y analfabetismo.
- Análisis multivariado

Fuente: EL ANALISIS DE DATOS DESDE UNA PERSPECTIVA INTEGRADORA.
 Por María Fernanda Niño
 ISBN: 950-579-035-X

8. Postulantes a oferta de empleo.

48 individuos que habían presentado solicitud de trabajo a una gran empresa fueron entrevistados y clasificados en relación con 15 criterios.

Los aspirantes se clasificaron según

- la forma de su letra en la solicitud (FL),
- su aspecto (APP),
- su capacidad académica (AA),
- su amabilidad (LA),
- su autoconfianza (SC),
- su lucidez (LC),
- su honestidad (HON),
- su arte de vender (SMS),
- su experiencia (EXP),
- su empuje (DRV),
- su ambición (AMB),
- su capacidad para captar conceptos (GSP),
- su potencial (POT),
- su entusiasmo para trabajar en grupo (KJ),
- su conveniencia (SUIT).

Cada criterio se evaluó en una escala que va de 1 a 10, con 0 como una calificación muy insatisfactoria y con 10 como una calificación muy alta.

Supongamos que la empresa desea ofrecer empleo a los 6 mejores solicitantes, ¿Cómo seleccionaría?

Fuente: METODOS MULTIVARIADOS APLICADOS AL ANALISIS DE DATOS
 Por Dallas E. Johnson
 ISBN: 968-7529-90-3