




Ciencia de datos
Ingeniería en Sistemas de Información

Análisis de Conglomerados (Cluster)

Introducción práctica

Agrupamiento o cluster



- El objetivo es agrupar elementos en grupos homogéneos en función de las similitudes o similaridades entre ellos.
- Los objetos ubicados dentro del mismo grupo se consideran “similares” o “parecidos”.
- Construye **modelos descriptivos**.

Clusters

Los métodos de agrupamiento podemos clasificarlos en:

➤ **Métodos no jerárquicos**

- K-medias (variables numéricas)
- PAM (variables mixtas)
- Otros

➤ **Métodos jerárquicos**

- Hierarchical Clustering (variables mixtas)


Clusters

Métodos no jerárquicos: K-Medias

Objetivo: Dividir los elementos de la muestra en un número k (prefijado) de grupos

I. Seleccionar k puntos como centros de los grupos iniciales:

- Con información a priori
- Aleatoriamente
- Seleccionando los k puntos más alejados





(cont. K-means)

2. Calcular distancias euclídeas de cada elemento a cada centro y asignar el elemento al centro más próximo.

3. Recalcular las coordenadas del centro.


4. Iterar: reasignando los individuos al centro más próximo y recalculando las coordenadas del centro. Detener al cumplir un criterio de optimalidad.



Clusters

Métodos jerárquicos (Hierarchical Clustering)

Parten de una *matriz de distancias o similitudes* entre los elementos de la muestra para agrupar los mismos en forma jerárquica.



Clusters

Agrupamiento jerárquico (Hierarchical Clustering)

Estructura

1. Comienza con tantas clases como elementos
2. Selecciona el par de elementos más próximos en la matriz y forma una clase
3. Sustituye los 2 elementos por un elemento representante de la clase, calcular su distancia al resto de los elementos utilizando algún criterio de distancia entre grupos.
4. Vuelve al paso 2 e itera hasta tener una sola clase



Clusters - Normalización

Provincia	Precipitación promedio (mm)	Temperatura mínima promedio (°C)
Santa Fe	20	7
Jujuy	2	0
Salta	5	2
San Juan	1	1
Tucumán	20	6
Catamarca	3	2
Buenos Aires	40	4
Entre Ríos	50	10
La Pampa	20	2

Cuando las variables tienen diferente unidad de medida y/o diferencia significativa de varianza, algunas de ellas adquieren más protagonismo en el cálculo de la distancia.

Solución: estandarizar

Sin embargo, el investigador puede querer conservar estas diferencias y no estandarizar.



Clusters - Normalización

