

Índice

Fundamentos.....	4
¿Qué es la ciencia de datos?.....	4
Dato o Información.....	4
¿Qué es un dataset?.....	4
Vista minable.....	4
Tipos de variables.....	4
¿Qué es un modelo?.....	5
Covarianza y Correlación.....	5
Proceso de Descubrimiento de de conocimiento KDD - Fases.....	7
Fases.....	7
Ciclo de Vida CRISP-DM.....	12
Fase 2 Comprensión de los datos: Análisis Exploratorio de Datos (EDA).....	13
Fase 3 Preparación de los datos.....	16
Fase 4 Modelado.....	17
Fase 5 Evaluación.....	19
Fase 6 Despliegue.....	20
Conceptos Previos al Modelado.....	21
Aprendizaje.....	21
Tarea.....	21
Aprendizaje basado en instancias vs. basado en modelo.....	22
Algoritmo vs. Modelo.....	22
Parámetros vs. Hiperparámetros.....	22
Los sets de entrenamiento, validación y prueba.....	23
Técnicas de aprendizaje supervisado para tareas de clasificación.....	24
KNN.....	24
Árboles de decisión.....	27
Análisis Discriminante.....	36
Regresión Logística.....	51
Técnicas de aprendizaje no supervisado para tareas de Agrupamiento.....	73
Agrupación en clusters.....	73
Etapas previas a realizar Clustering.....	73
Cluster Jerárquico y Bietápico.....	74
Clustering No Jerárquico.....	77
Análisis de componentes principales.....	79
¿En qué consiste?.....	79
Beneficios del análisis de componentes principales.....	81
Desventajas del análisis de componentes principales.....	81
Formas de evaluar un algoritmo/modelo.....	82
Matriz de Confusión (tarea de clasificación).....	82
Matriz de Costos.....	85
Gráfico de Ganancias Acumuladas.....	86

Información útil y recomendaciones dadas en clase.....	90
Qué Hacer Cuando el Modelo No Es Bueno.....	90
Desbalance de la Variable Predicha.....	90
Buenas Prácticas al Documentar el Análisis.....	90

Fundamentos

¿Qué es la ciencia de datos?

La ciencia de datos es un área interdisciplinar que usa diferentes técnicas, herramientas, algoritmos y sistemas para extraer conocimiento profundo (insights) a partir de los datos y así usarlo para la solución de problemas o para la toma de decisiones.

Dato o Información

Llamamos "Dato" al valor mínimo, un átomo de conocimiento (ej: "35", "demorado"). Por sí solo no dice nada, mientras que llamamos "Información" al **dato procesado y puesto en contexto**.

"35" es un dato. "35 grados de temperatura en la CPU del ESP32" es información.

En ciencia de datos, nuestro trabajo es transformar datos masivos en información importante para el negocio.

¿Qué es un dataset?

Es nuestra materia prima, organizada en una tabla con:

- **Filas (Observaciones/Instancias):** Cada fila es un ente individual. Si analizamos vuelos, cada fila es un vuelo específico que ya ocurrió.
- **Columnas (Variables/Atributos):** Son las características que medimos de ese ente.
- **Dimensiones:** Se dice que un dataset tiene dimensiones $n \times m$, donde n es la cantidad de filas y m la cantidad de columnas.

Vista minable

La vista minable es la tabla (filas y columnas) sobre la cual se aplican todos los modelos predictivos y descriptivos.

Especificar la vista minable significa describir: qué variables/columnas se utilizan, qué tipo son (numéricas, categóricas), y que rango de valores toman.

Las variables que no aportan información (como nombre, apellido, email) se descartan y no forman parte de la vista minable.

Sin importar la fuente de datos original (BD Relacional, data warehouse, NoSQL), todos los modelos se aplican sobre una tabla plana (la vista minable).

Tipos de variables

A. Cualitativas (Categóricas)

Materia: Ciencia de datos

Representan cualidades o etiquetas. No podemos hacer cuentas matemáticas con ellas (no tiene sentido "promediar" ciudades).

- **Nominales:** No tienen un orden intrínseco. Ej: Ciudad (Rosario, Córdoba), Género, Color de auto.
- **Ordinales:** Tienen un orden o jerarquía lógica, Ej: Nivel de inglés (Bajo, Medio, Alto), Clase de vuelo (Turista, Business, Primera).

B. Cuantitativas (Numéricas)

Representan cantidades. Acá si aplicamos el promedio y la varianza.

- **Discretas:** Valores enteros, surgen de contar. Ej: Cantidad de hijos, cantidad de millas acumuladas, número de pasajeros.
- **Continuas:** Pueden tomar cualquier valor dentro de un rango, surgen de medir. Ej: Peso de la valija, temperatura, tiempo de demora del vuelo.

¿Variable con pocos valores: numérica o categórica?

Cuando una variable tiene pocos valores posibles (1 a 5, 1 a 6) y existe ordinalidad, surge la discusión:

1- **Como categórica:** permite gráficos de barras comparativos más enriquecedores. Es lo más habitual en la práctica.

2- **Cómo numérica:** permite calcular promedio y usar histogramas/boxplots.

Conclusión del profesor: en general se prefiere tomarla como categórica ordinal. Si el modelo no da buenos resultados, se puede volver a intentar como numérica.

¿Qué es un modelo?

Según IBM *"Un modelo es un conjunto de reglas, una fórmula o una ecuación que se puede utilizar para predecir un resultado basándose en un conjunto de campos de entrada. La capacidad para predecir un resultado es el objetivo central de los análisis predictivos."* (Modelos, 2021)

Covarianza y Correlación

Ambas miden la **relación lineal**, pero tienen una interpretación distinta:

Covarianza: Indica la dirección. Depende de la escala y las unidades (no mide intensidad). Si cambias las unidades (de metros a kilómetros), el valor de la covarianza cambia, aunque la relación sea la misma. Por eso no sirve para medir "intensidad".

Correlación: Estandarizada entre -1 y 1. Es "inmune" a los cambios de escala.

Fórmula:

$$r = \frac{cov(X,Y)}{s_x s_y}$$

Valor de r	Interpretación
$r \approx 1$	Relación lineal positiva fuerte (a mayor X, mayor Y). Los puntos forman una recta ascendente.
$r \approx -1$	Relación lineal negativa fuerte (a mayor X, menor Y). Los puntos forman una recta descendente.
$r \approx 0$	No hay relación lineal entre las variables. Los puntos forman una nube dispersa.
r intermedio	Relación lineal débil o moderada. Cuanto más cerca de ± 1 , más fuerte la relación.

Cuidado: La correlación mide exclusivamente la relación LINEAL entre dos variables. El hecho de que $r = 0$ no significa que las variables sean independientes: puede haber otro tipo de relación no lineal.

Cuidado: Correlación NO implica causalidad. La correlación indica que dos variables «se mueven juntas», pero no que una cause el cambio en la otra. Eso se analiza con regresión lineal.

Umbral de correlación importantes

- A partir de 0.4 podemos considerar que se empieza a notar una tendencia que vale la pena investigar.
- Mayor a 0.5 podemos afirmar con más seguridad que existe una relación entre las variables.

Consideraciones


- 1. El signo no importa para la fuerza:** Un valor de -0.55 es tan fuerte como uno de 0.55. La única diferencia es que la relación es inversa (si una sube, la otra baja).
- 2. No es una regla absoluta:** la profe aclaró que después de ver el número, hay que graficar. A veces podemos tener un valor de 0.4 que parece una nube de puntos (débil) y otras veces un 0.4 que muestra un patrón claro pero con algunos outliers que están "tirando abajo" el promedio de correlación.
- 3. Independencia:** Si el valor está muy cerca de 0 (por ejemplo, 0.1 o -0.05), las variables se consideran independientes y probablemente no te sirvan para hacer predicciones.

Proceso de Descubrimiento de de conocimiento KDD

KDD significa Knowledge Discovery in Databases, o descubrimiento de conocimiento en bases de datos. Es un proceso semiautomático, porque aunque usen herramientas automáticas, requiere intervención humana en varias etapas.

Hay operaciones que no se puede automatizar como:

- Elección de problemas de negocio para llevarlos a tareas de Minería de Datos.
- Identificación y recolección de los datos que contienen la información buscada.
- Tratamiento de datos para la búsqueda de patrones.
- Diseño y cálculo de variables derivadas.




El objetivo del proceso KDD es convertir **DATOS** en **CONOCIMIENTO**.

Es un proceso iterativo e interactivo:

- Es **interactivo** porque hay una comunicación constante con la gente de negocios, ya que es fundamental entender que quieren y esperan del modelo, y porque ayudan al análisis de los resultados que este brinda.
- Es **iterativo** porque ante cualquier situación, podemos volver hacia cualquiera de las etapas anteriores. Ejemplo: Supongamos que estamos en la vista minable, creamos un modelo, analizamos los resultados y vemos que dicho modelo no es útil. Quizás tengamos que reveer que está pasando en la vista minable e incluso analizar si deberíamos obtener nuevos datos.

Fases



1. Integración y Recopilación de Datos

Proceso informático.

Detectar dónde voy a buscar los datos, y llevarlos al Data Warehouse. Llevar los datos CORRECTOS al DW.

- **Determinar fuentes de información útiles:** Transaccionales (operaciones realizadas con tarjeta de crédito), Relacionales (estructura de los productos que ofrece el banco), Demográficas (características del grupo familiar), Económicas (inflación, competencia, estudios de mercado).
- **Diseñar y crear procesos ETL** (extracción, transformación, carga) para cargar el DW.


Ejemplo: Se combinan datos de tarjetas de crédito, encuestas y mercado.

2. Selección, Limpieza y Transformación

Procesamiento estadístico.

Una vez que tenemos el Data Warehouse completo, pasamos por un proceso de **selección, limpieza y transformación** con el fin de obtener un conjunto de datos sin errores, inconsistencias o irrelevancia, que nos permitan resolver nuestro problema específico de minería. Con dichos datos, generamos la **vista minable**.

Aclaración: Aunque un Data Warehouse es una gran ventaja porque centraliza los datos en un solo lugar, puedes hacer minería de datos sin necesidad de tener uno. En caso de tenerlo, no realizamos el paso 1 y pasamos directamente al paso 2, y en caso de no tenerlo deberíamos realizar ambos pasos.



3. Minería de datos

El objetivo es convertir **DATOS** en **INFORMACIÓN**.

Se elige el tipo de patrón que se quiere descubrir y se aplican modelos (clasificación, asociación, agrupamiento, etc).

Definimos **Minería** como un conjunto de técnicas que nos permite identificar y extraer información desde un conjunto de datos, de modo que pueda ser dispuesta para su uso en áreas tales como soporte de decisión, pronósticos y estimaciones.

Dependiendo del conocimiento que quiera obtener, va a depender la técnica que voy a utilizar. Podemos distinguir entre:

- Directed data mining (Minería de datos directa): se sabe claramente lo que se busca, generalmente predecir o definir clases.
- Undirected data mining (Minería de datos indirecta): no se sabe lo que se busca, se trabaja con los datos. Quiero descubrir algo, no sé qué.

Las técnicas de minería crean modelos supervisados, de asociación o segmentación:

Modelos predictivos (supervisados)

Los **modelos supervisados** utilizan los valores de uno o varios campos de entrada para predecir el valor de uno o varios resultados o campos de destino. Algunos ejemplos de estas técnicas son: **árboles de decisiones** (árbol C&R, QUEST, CHAID y algoritmos C5.0), **regresión** (lineal, logística, lineal generalizada y algoritmos de regresión de Cox), **redes neuronales**, **máquinas de vectores de soporte y redes bayesianas**.

Los modelos supervisados ayudan a las organizaciones a **predecir un resultado conocido**, por ejemplo si un cliente comprará o se irá o si una transacción se ajusta a un patrón conocido de fraude. Las técnicas de modelado incluyen aprendizaje automático de las máquinas, inducción de reglas, identificación de subgrupos, métodos estadísticos y generación de varios modelos. (*Tipos De Modelos*, 2021)

Modelos descriptivos (no supervisados)

Los **modelos descriptivos** encuentran **patrones** en los datos en los que una o más entidades (como eventos, compras o atributos) se asocian con una o más entidades. Los modelos construyen conjuntos de reglas que definen estas relaciones.

Los modelos **descriptivos** son los más útiles si se desean **predecir varios resultados**; por ejemplo, los clientes que adquirieron el producto X también adquirieron Y y Z. Los modelos descriptivos relacionan una conclusión específica (como la decisión de adquirir un producto) con un conjunto de condiciones. La ventaja de los algoritmos de reglas de asociación sobre

Materia: Ciencia de datos

los algoritmos más estándar de árboles de decisión (C5.0 y Árbol C&R) es que las asociaciones pueden existir entre cualquiera de los atributos. Un algoritmo de árbol de decisión generará reglas con una única conclusión, mientras que los algoritmos de asociación tratan de buscar muchas reglas, cada una de las cuales puede tener una conclusión diferente.

Dentro de los modelos descriptivos tenemos los **modelos de segmentación** los cuales dividen los datos en segmentos o clústeres de registros que tienen **patrones similares de campos de entrada**. Como sólo se interesan por los campos de entrada, **los modelos de segmentación no contemplan el concepto de campos de salida o destino**. Ejemplos de modelos de segmentación son las redes Kohonen, la agrupación en clústeres de K-medias, la agrupación en clústeres en dos pasos y la detección de anomalías.

Los modelos de segmentación (también conocidos como "modelos de agrupación en clústeres") **son útiles en aquellos casos en los que se desconoce el resultado específico** (por ejemplo a la hora de detectar nuevos patrones de fraude o de identificar grupos de interés en la base de clientes). Los modelos de agrupación en clústeres se centran en la identificación de grupos de registros similares y en el etiquetado de registros según el grupo al que pertenecen. Esto se lleva a cabo sin la ventaja que ofrece el conocimiento previo sobre los grupos y sus características, y diferencia a los modelos de clústeres de otras técnicas de modelado en que no hay campos de salida u objetivo predefinidos para el modelo que se va a predecir. No hay respuestas correctas o incorrectas para estos modelos. Su valor viene determinado por su capacidad de capturar agrupaciones interesantes en los datos y proporcionar descripciones útiles de dichas agrupaciones. Los modelos de clúster se usan a menudo para crear clústeres o segmentos que se usan posteriormente como entradas en análisis posteriores, (por ejemplo mediante la segmentación de clientes potenciales en subgrupos homogéneos). (Tipos De Modelos, 2021)

Tareas Técnicas	Predictivos (supervisados)		Descriptivos (no supervisados)		
	Clasificación	Predicción	agrupamiento	Asociación	Otros
Redes Neuronales	X	X	X		
Arboles de Decisión	X	X	X	X	
Kohonen			X		
Regresión paramétrica		X			
Regresión Logística	X			X	
k means / k medioides			X		
A priori				X	
Análisis factorial					X
Análisis Discriminante	X				
Algoritmos genéticos	X	X	X	X	X
Naive Bayes	X				
Vecinos mas próximos	X	X	X		

4. Evaluación e Interpretación

Se analiza si el modelo es bueno y se prueba con datos nuevos (test).

La etapa anterior produce una o más hipótesis de modelos. Para seleccionar y validar estos modelos es necesario el uso de criterios de evaluación de hipótesis:

- 1º fase:** comprobación de la precisión del modelo en un conjunto de ejemplos independiente del que se ha utilizado para que el modelo aprenda. Se elige el mejor modelo.
- 2º fase:** se puede realizar una experiencia piloto con ese modelo. Por ej.: en el caso de un modelo para predecir la respuesta de los clientes a un nuevo producto, se puede enviar un mailing a un subconjunto de clientes y evaluar la fiabilidad del modelo.

5. Difusión y Uso


Una vez que generamos el conocimiento, se le da **difusión** para poder **utilizarlo** y aplicar ese conocimiento en la toma de decisiones, es decir, **se implementan los modelos que construimos**.

6. Revisión

Por último está la etapa de **revisión**. El negocio tiene una dinámica y nos tenemos que adaptar a ella. Periódicamente debemos revisar el modelo implementado, ya que puede comenzar a tener errores que no aceptamos y, para que siga siendo válido en un futuro, tenemos que ajustarlo.

Ciclo de Vida CRISP-DM

Antes de procesar cualquier dato, un proyecto de Ciencia de Datos debe seguir una metodología estructurada llamada CRISP-DM (Cross-Industry Standard Process for Data Mining). No es un camino lineal, sino un proceso circular e iterativo donde los resultados de una etapa a menudo te obligan a volver a la anterior.



Fase I. Definición de necesidades del cliente (comprensión del negocio)

Fase II. Estudio y comprensión de los datos.

Fase III. Análisis de los datos y selección de características.

Fase IV. Modelado. Se aplican las técnicas de modelado que sean pertinentes al problema.

Fase V. Evaluación (Obtención de resultados)

Fase VI. Despliegue (Puesta en producción)

Las 6 Fases del Proyecto:

- 1. Comprensión del Negocio:** Definir qué problema queremos resolver y qué objetivos busca la empresa (por ejemplo, predecir demoras en DS Airlines).
- 2. Comprensión de los Datos:** Aquí es donde recolectamos la información y realizamos el **Análisis Exploratorio (EDA)** para conocer nuestra "materia prima".
- 3. Preparación de los Datos:** En esta fase se limpian los nulos, se tratan los outliers y se transforman las variables para crear la vista minable.
- 4. Modelado:** Seleccionar y aplicar los algoritmos de Machine Learning (como árboles de decisión o regresiones).
- 5. Evaluación:** Determinar si el modelo es lo suficientemente bueno y si realmente responde a los objetivos de negocio planteados al principio.
- 6. Implementación:** Poner el modelo en producción para que el cliente o la empresa pueda usarlo (por ejemplo, el agente de IA que notifica pasajeros).

Fase 2 Comprensión de los datos: Análisis Exploratorio de Datos (EDA)

Consiste en el análisis descriptivo para conocer la "salud" de los datos.

Análisis UNIVARIANTE

La diferencia radica en cuántas "columnas" del dataset estamos mirando al mismo tiempo.

Las **medidas univariantes** se centran en una sola variable de forma aislada. El objetivo es describir las características de esa variable específica (su centro, su dispersión y su forma) sin importar qué está pasando con las demás.

- **¿Qué miramos?** La distribución. ¿Los datos están amontonados en el medio? ¿Hay valores atípicos en las puntas?
- **Para variables categóricas:** Simplemente contamos cuántas veces aparece cada etiqueta (Frecuencia).
 - **Gráfico de Barras:** En el eje X van las categorías (ej: "Premium", "Estándar") y en el eje Y va el conteo o frecuencia. Las barras están separadas.
 - **Gráfico de Torta:** Útil para ver proporciones o porcentajes del total.
- **Para variables numéricas:** Usamos el **Promedio** (se usa cuando los datos son simétricos y no hay valores raros "outliers") o la **Mediana** (se usa cuando tenemos datos sesgados o con valores muy extremos) para ver dónde está el "centro", y el Desvío Estándar para ver qué tan dispersos están.
 - **Histograma:** a diferencia del de barras, las barras están juntas. El eje X representa intervalos numéricos. Sirve para ver la "forma" de los datos (si es una campana de Gauss o tiene "cola").
 - **Boxplot (Caja y Bigotes):** Es el gráfico estrella para ver la dispersión y detectar outliers. Son útiles para entender la concentración, si Q_1 está muy pegado a la Mediana, significa que hay muchísimos datos amontonados en los valores bajos. El *rango intercuartílico* ($RIC = Q_3 - Q_1$) es el ancho de la "caja", cuanto más grande es, más dispersos están los datos del centro (**mediana o Q_2**)


Ejemplo: Si analizamos solamente la velocidad de los autos para ver cuál es el promedio de la flota, estamos haciendo un análisis univariante.

Análisis MULTIVARIANTE

Las **medidas multivariantes** se centran en dos o más variables simultáneamente. Aquí lo que buscamos no es describir una columna, sino entender cómo se relacionan entre sí. En ciencia de datos esto es vital para encontrar **patrones predictores**.


- **¿Para qué sirven?** Para ver si una variable "explica" a la otra. Por ejemplo, ¿si aumenta la cilindrada, aumenta el consumo?
- **Bivariante (2 variables):** Es el caso más común. Por ejemplo, ¿a mayor **Distancia** del vuelo, hay más probabilidad de **Demora**?
- **Multivariante (+2 variables):** Cuando cruzás tres o más. Por ejemplo: **Clima + Tipo de Avión vs. Consumo**.

- **Para dos variables numéricas:** Usamos el gráfico **Scatter Plot (Dispersión)**, si los puntos forman una línea, hay correlación. Si es una nube sin forma, son independientes. Podemos pintar los puntos de colores según una variable categórica para ver si el comportamiento cambia (ej: Consumo vs Velocidad, pintando por tipo de auto), a esto la profesora le llama "Diagrama de dispersión estratificado".



Cuidado: Siempre se debe **complementar el análisis visual** del scatter con el **coeficiente de correlación numérico**, para no depender de la subjetividad visual.

- **Para dos variables categóricas:** Usamos el gráfico de **Barras apiladas**. Por ejemplo, ver la cantidad de vuelos demorados (Sí/No) dividido por Aeropuerto.



Cuidado: Para extraer conclusiones correctas sobre la relación entre dos variables cualitativas, siempre se debe usar el stack porcentual (al 100%). El stack absoluto (muestra la cantidad real de observaciones en cada categoría) puede llevar a conclusiones erróneas si los grupos tienen tamaños muy diferentes.


Ejemplo: analizado en clase (autos ecológicos vs. tipo de vehículo):

- Los autos premium en general no son ecológicos → Correcto.
- Los autos ecológicos en general son de tipo estándar → Correcto.

- Los autos no ecológicos en general son premium → INCORRECTO. La inversa de una afirmación puede no ser válida.

Hay que tener **mucho cuidado** al formular **conclusiones a partir de gráficos**. Invertir una afirmación puede llevar a conclusiones falsas.

- **Para una variable categórica y una numérica:** Usamos el gráfico de **Boxplots Múltiples** el eje X representan los grupos que queremos contrarrestar (ej: "Categoría", "Ciudad") y el eje Y representa la magnitud que queremos comparar (ej: "Consumo", "Tiempo de demora"). Ejemplo, si queremos ver si el tiempo de vuelo varía según la categoría de avión, podemos hacer un boxplot del tiempo por cada categoría.



Ejemplo: Si cruzamos velocidad y aceleración para ver si los autos más rápidos tardan menos en arrancar, estamos haciendo un análisis multivariante.

Cuidado: La profesora mencionó que **"no nos tenemos que quedar solo con el análisis univariante"**. Para detectar outliers complejos, a veces necesitamos el análisis multivariante. Por ejemplo: un sueldo de \$5.000 USD es normal (univariante), pero para un pasante de 18 años es un outlier (multivariante: edad + sueldo).

Análisis estratificado

El análisis estratificado consiste en **realizar el análisis estadístico de cada variable numérica segmentado por una variable de clase** (variable cualitativa).

¿Para qué sirve?

- Permite **descubrir** que un **estadístico calculado** sobre toda la muestra puede ser **engañoso** cuando existen grupos claramente diferenciados.
- Ejemplo de clase: el promedio de velocidad final de todos los autos era 190 km/h. Al estratificar por tipo de vehículo (**estándar vs. premium**), se vio que la mediana era 168 km/h para estándar y 214 km/h para premium. El promedio global era poco informativo.

Cuidado: Siempre que se disponga de una variable de clase relevante (como tipo de vehículo, segmento de cliente, región, etc.), se recomienda realizar el análisis estratificado. Los promedios globales sin segmentación pueden llevar a conclusiones incorrectas.

Gráficos usados en el análisis estratificado:

- **Boxplot estratificado:** diagrama de cajas y bigotes donde cada caja corresponde a una categoría de la variable de clase.

- **Histograma estratificado:** histograma con diferentes colores para cada categoría.
- **Scatter plot coloreado por clase:** identifica visualmente los grupos dentro de la nube de puntos.

Fase 3 Preparación de los datos

Limpieza

La limpieza de datos es una etapa fundamental que se realiza en **paralelo** al análisis exploratorio. Su objetivo es garantizar la calidad del dataset antes de aplicar modelos.

Cuidado: Si no se realiza un proceso de limpieza adecuado y se trabaja con datos incorrectos, todos los modelos que se generen también serán incorrectos y no representarán la realidad.

Tratamiento de Datos ausentes (NA)

Los datos ausentes son registros donde no se dispone del valor de alguna variable (identificados como NA, NULL, vacíos, etc.).

Existen 3 opciones de tratamiento:

1. **Supresión:** Eliminar filas o columnas con demasiados valores nulos si no son recuperables o relevantes.
2. **Imputación:** Estimar y rellenar los valores faltantes utilizando la media, mediana, moda (para categóricas) o incluso por algoritmos de regresión, Machine Learning o Deep Learning.
3. **Dejar nulos:** Algunos modelos de Machine Learning (ej: basados en árboles) pueden manejar valores nulos directamente.

Los modelos de minería muchas veces requieren que no haya datos ausentes. Por eso la imputación es necesaria antes del modelado.

Cuidado: Los datos ausentes deben estar distribuidos de forma aleatoria en la muestra. Si una columna tiene casi todos los valores ausentes, hay que eliminarla directamente.

Tratamiento de Outliers (Atípicos)

Identificación y manejo de datos anómalos que pueden sesgar los modelos. Se pueden detectar mediante:

- **Univariante:** Uso de Box Plots y estadísticos robustos.
- **Bivariante:** Scatter Plots y Box Plots múltiples.
- **Multivariante:** Análisis de Componentes Principales (PCA) y distancias estadísticas.

Además debe tenerse en cuenta que ante un dato atípico es recomendable consultar con el cliente o fuente de datos sobre la validez del dato y documentar las decisiones tomadas y su justificación.

Identificación de Variables Irrelevantes

Se eliminan variables que **no aportan valor** al proceso de modelado (por ejemplo, IDs o nombres) y se **analizan posibles correlaciones** entre variables predictoras. Esto es especialmente importante para técnicas como LDA y Regresión Logística, que requieren bajos niveles de multicolinealidad para garantizar estimaciones estables y modelos de mejor calidad.

Transformación

La transformación de datos consiste en crear nuevas variables o modificar las existentes para que resulten más útiles o interpretables para el problema de estudio.

Ejemplo de transformación de datos;

- **Estandarización/Normalización:** Escalar variables numéricas a un rango estándar para que no haya una variable que domine a otra debido a su magnitud.
- **Codificación de Variables Categóricas:** Convertir categorías textuales en formatos numéricos que los modelos puedan procesar.
- **Creación de Nuevas Variables (Feature Engineering):** Generar atributos nuevos a partir de los existentes que puedan enriquecer el poder predictivo del modelo.
- **Consistencia:** Cualquier transformación aplicada al conjunto de entrenamiento debe ser replicada en los datos nuevos para predicción.

Ejemplo práctico de la clase: a partir de la variable numérica 'consumo' (litros/100 km) se creó una nueva variable cualitativa llamada 'es_ecológico':

- Si consumo < 7 → Es ecológico.
- Si consumo ≥ 7 → No es ecológico.

Fase 4 Modelado

La fase de modelado representa el momento en el que los datos preparados son utilizados para construir modelos capaces de generar conocimiento útil y resolver los objetivos definidos durante la comprensión del negocio. En esta etapa se seleccionan y aplican diferentes técnicas de minería de datos, aprovechando la información obtenida durante las fases previas del proyecto. El propósito principal es encontrar modelos que permitan describir patrones, realizar predicciones o segmentar información de manera efectiva, según las necesidades del problema abordado.

Podemos dividir esta fase en las siguientes actividades:

1. **Selección de técnicas de modelado:** Se determinan las técnicas de minería de datos que serán utilizadas para resolver el problema planteado. La selección depende de los

objetivos del proyecto, las características de los datos disponibles y los requisitos específicos de cada técnica.

En términos generales, las técnicas pueden clasificarse en:

Técnicas predictivas: orientadas a estimar el valor de una variable objetivo a partir de variables predictoras.

En todo modelo predictivo existen dos tipos de variables:

- **Variables Predictoras** (también llamadas explicativas o independientes): todas las variables que se utilizan como entrada para la estimación.
- **Variable Predicha** (también llamada variable objetivo, explicada o dependiente): el atributo que se quiere estimar. Puede asumir diferentes valores.

Técnicas descriptivas: su propósito es descubrir patrones, agrupamientos o estructuras presentes en los datos.

Ejemplo: conformación de clusters (agrupamientos) o técnicas de reducción de dimensionalidad

En la cátedra se estudiarán cuatro técnicas predictivas: Árboles de Decisión, KNN, Análisis Discriminante (LDA) y Regresión Logística y **tres técnicas descriptivas:** Cluster k-medias, Cluster Jerárquico y Bietápico y Análisis de Componente Principales (ACP)

2. **Generación de un diseño de comprobación:** Antes de construir los modelos, se define cómo serán evaluados. Para ello se establecen los criterios de "bondad" del modelo y los datos que se utilizarán para su validación. Habitualmente se recurre a **particiones de entrenamiento y prueba**, así como a **métricas** que permitan **comparar objetivamente** el desempeño de las distintas alternativas de modelado. Estas métricas serán utilizadas posteriormente tanto para el ajuste de hiperparámetros durante la fase de modelado **como para la comparación de los modelos obtenidos**.
3. **Generación y ajuste de modelos:** El modelado es un proceso iterativo en el que se construyen **múltiples modelos** utilizando diferentes algoritmos y configuraciones de parámetros. A partir de los resultados obtenidos sobre los conjuntos de validación, se analizan métricas de rendimiento tales como Accuracy, Sensibilidad, Especificidad, Precisión, Curva ROC-AUC o Gráficos de Ganancia Acumulada, entre otras. Estas medidas permiten ajustar hiperparámetros, comparar configuraciones y seleccionar las alternativas más prometedoras. Asimismo, puede ser necesario regresar a la fase de preparación de datos para realizar nuevas transformaciones o incorporar atributos que mejoren el desempeño de los modelos.
4. **Descripción y evaluación inicial de los modelos:** Una vez generados los modelos, se **documentan** los parámetros utilizados, los resultados obtenidos y cualquier problema detectado durante su construcción. Posteriormente, los modelos son analizados y

clasificados utilizando criterios objetivos, como la precisión o el rendimiento, y criterios subjetivos, como la facilidad de interpretación, despliegue o utilidad para la organización. Como resultado de esta etapa se obtiene un conjunto de modelos candidatos que serán evaluados con mayor profundidad en la siguiente fase de CRISP-DM.

En un capítulo posterior estudiaremos técnicas de comprobación/evaluación como pueden ser Matriz de Confusión, Curva ROC-AUC, gráfico de ganancia acumulada y sus métricas asociadas como lo son la sensibilidad, precisión, especificidad, accuracy, etc.

Fase 5 Evaluación

La fase de evaluación tiene como finalidad analizar los modelos obtenidos para determinar si realmente resuelven el problema planteado desde la perspectiva del negocio. Aunque un modelo pueda presentar buenos resultados técnicos, todavía es necesario verificar que sus conclusiones sean relevantes, comprensibles y útiles para la organización. Por este motivo, la evaluación constituye el puente entre el desarrollo analítico y la futura implementación de la solución.

Se resume en 4 grandes actividades:

1. **Evaluación de los resultados:** Se evalúan los modelos obtenidos y los descubrimientos generados durante el proceso de minería de datos para determinar en qué medida cumplen los **criterios de rendimiento comercial definidos al inicio del proyecto**. El objetivo es verificar que los resultados puedan aplicarse efectivamente a los objetivos del negocio.
2. **Selección de los mejores modelos:** Los modelos construidos son comparados y clasificados utilizando **criterios objetivos** y **subjetivos**. Entre los criterios objetivos se encuentran las métricas de rendimiento obtenidas durante la fase de modelado, tales como Accuracy, Sensibilidad, Especificidad, Precisión, Curva ROC-AUC o Ganancia Acumulada. Sin embargo, **la decisión final no depende exclusivamente de estas medidas**, sino también de **criterios subjetivos vinculados al negocio**, como la facilidad de interpretación, despliegue, mantenimiento e impacto de los errores de clasificación sobre la organización.
3. **Revisión del proceso:** Se realiza una revisión de las actividades y decisiones tomadas a lo largo de todas las fases del proyecto, identificando aciertos, errores, limitaciones y oportunidades de mejora. Esta revisión permite extraer aprendizajes que pueden aprovecharse en futuros proyectos de minería de datos.

4. **Determinación de los pasos siguientes:** A partir de la evaluación realizada, se decide si los resultados son lo suficientemente precisos y relevantes para avanzar hacia la fase de despliegue o si es necesario volver a etapas anteriores para refinar los modelos o explorar nuevas alternativas de modelado.

Fase 6 Despliegue

La fase de despliegue tiene como objetivo transformar los modelos y conocimientos obtenidos durante el proyecto en acciones concretas para la organización, planificando su implementación, controlando su funcionamiento, comunicando los resultados y documentando las lecciones aprendidas para futuros proyectos.

También podemos dividir esta fase en 4 actividades:

1. **Planificación del despliegue:** Consiste en definir cómo se utilizarán los resultados obtenidos durante el proyecto de minería de datos. Para ello se identifican los modelos y descubrimientos que serán implementados, se establecen los pasos necesarios para su integración en los sistemas de la organización y se planifica la comunicación de los resultados a las personas involucradas. Además, se contemplan posibles problemas de implementación y planes de contingencia.
2. **Planificación del control y mantenimiento:** Una vez desplegados los modelos, es necesario **supervisar su funcionamiento** para asegurar que continúen siendo válidos y precisos a lo largo del tiempo. En esta actividad se definen los mecanismos de seguimiento, los criterios para determinar cuándo un modelo ha perdido vigencia y los procedimientos para actualizarlo, reconstruirlo o reemplazarlo cuando sea necesario.
3. **Elaboración del informe y presentación final:** Se documenta todo el proyecto realizado, incluyendo el problema abordado, la metodología utilizada, los modelos seleccionados, los descubrimientos obtenidos y el plan de despliegue propuesto. Dependiendo del público destinatario, la información puede presentarse con distintos niveles de detalle técnico o de negocio, con el objetivo de facilitar la comunicación de los resultados y apoyar la toma de decisiones.
4. **Revisión final del proyecto:** Se realiza una evaluación global del proyecto mediante la recopilación de opiniones de los participantes y de las personas impactadas por los resultados. El objetivo es identificar los conocimientos adquiridos, analizar las dificultades encontradas, evaluar el éxito de la implementación y registrar oportunidades de mejora para futuros proyectos de minería de datos.

Conceptos Previos al Modelado

Aprendizaje

Proceso mediante el cual el algoritmo aprovecha los datos para progresivamente y de forma automática lograr mejorar su desempeño en una tarea específica.

Tipos de aprendizaje

Supervisado: se alimenta el modelo con las características de cada dato (**variables independientes**) y con sus etiquetas correspondientes **variable dependiente**).

Métodos representativos:

- Regresión lineal
- Regresión logística
- Árboles de decisión

No supervisado: se alimenta el modelo **ÚNICAMENTE** con las características de cada dato (datos de los clientes; datos de los visitantes). La idea es que el modelo por si solo **encuentre agrupaciones en los datos**. No indicamos la meta a la que tiene que llegar.

Métodos representativos:

- Algoritmos de agrupamiento o clustering: k-means.
- Algoritmos de reducción de dimensionalidad: análisis de componentes principales, t-SNE.

Por refuerzo: un agente observa e interactúa con un entorno y debe aprender a ejecutar acciones para obtener la máxima recompensa posible.

Tarea

La tarea se define como **lo que el sistema** de Machine Learning **debe hacer con los datos de entrada**.

Tipos de tarea

- **Clasificación:** el sistema toma el dato de entrada y determina la categoría a la que pertenece. **Predice el valor de una categórica.**
Ejemplo: determinar si un correo electrónico es spam o no spam.
- **Regresión:** el sistema toma el dato de entrada y predice un valor **numérico continuo**. **Predecir el valor de una variable numérica.**
- **Agrupamiento (clustering):** el sistema genera agrupaciones de datos con base en alguna medida de similitud.

- **Reducción de dimensionalidad:** el sistema encuentra una representación compacta del dato de entrada. Ejemplo: buscar las características más relevantes que definen el precio de un vehículo.
- **Transcripción:** el sistema toma un dato no estructurado (no viene en formato tabular, como imágenes) a la entrada y genera una salida no estructurado pero en formato texto.
- **Detección de anomalías:** el sistema detecta datos atípicos o comportamientos inusuales en los datos. Ejemplo: transacciones fraudulentas.

Aprendizaje basado en instancias vs. basado en modelo

Basado en instancias

- No encuentra patrones. El algoritmo toma el dato a procesar, lo compara con datos conocidos y genera la predicción.

Basado en modelos

- El algoritmo permite encontrar un patrón en los datos y **generar un modelo** a cargo de la predicción.

Método Anticipativo (basado en modelos)	Método Perezoso (Lazy - basado en instancias)
Ejemplo: Árboles de Decisión	Ejemplo: KNN
Construye un modelo a partir del entrenamiento. Los datos de entrenamiento ya no son necesarios una vez construido el árbol.	NO construye un modelo. Siempre necesita los datos de entrenamiento para predecir (proyecta cada nueva observación sobre ellos).

Algoritmo vs. Modelo

En aprendizaje basado en instancias hablamos de algoritmos. Un **algoritmo** es un conjunto de reglas que definen cómo serán procesados los datos para ejecutar la **tarea**. No tenemos modelos porque no estamos buscando patrones.

En aprendizaje basado en modelos hablamos de que el algoritmo son las reglas que definen cómo serán procesados los datos para crear el modelo y el **modelo** es el encargado de ejecutar la **tarea**.

Parámetros vs. Hiperparámetros

Los **parámetros** son las **variables internas propias del algoritmo** (en el aprendizaje basado en instancias) o del algoritmo y del modelo (en el aprendizaje basado en modelos). Elementos que nosotros **no podemos controlar**.

Ejemplo: un parámetro que no podemos cambiar es la votación mayoritaria o la orientación de la frontera de decisión.

Los **hiperparámetros** son aquellas **variables** del algoritmo (en el aprendizaje basado en instancias) o del algoritmo y del modelo (en el aprendizaje basado en modelos) que **podemos controlar externamente**.

Ejemplo: número de vecinos que vamos a tener en cuenta para dicho voto o la forma de la frontera de decisión (recta o curva).

Los sets de entrenamiento, validación y prueba

Para comparar múltiples modelos necesitamos otras herramientas que nos permitan determinar cuál es el modelo más adecuado para el set de datos.

Los sets de validación y de prueba son un conjunto de datos independientes del set de entrenamiento.

Cada modelo puede tener sus propios hiperparámetros.

¿Cual de estos tres modelos va a ser mejor?

Para comparar cual de los tres modelos es mejor, podemos hacerlo solamente analizando cual maximiza una métrica en particular, pero no podemos usar el mismo set de entrenamiento ya que no es totalmente imparcial ya que lo hemos usado para construir los parámetros de cada modelo. Para hacerlo de manera imparcial lo hacemos con el set de validación, este lo usamos para ajustar los hiperparámetros del modelo y seleccionar el mejor modelo.

Generalización: la capacidad del modelo de generar buenas predicciones con datos totalmente nuevos, que nunca antes ha procesado.

Set de prueba, es usado para medir la capacidad de generalización del modelo seleccionado.

Técnicas de aprendizaje supervisado para tareas de clasificación

KNN

KNN es un método predictivo que clasifica una nueva observación en función de los casos vecinos a esa observación.

K es la **cantidad de vecinos más cercanos** que se toman para determinar la clase de la nueva observación. La clase asignada es la más frecuente entre los K vecinos más cercanos (votación por mayoría).

Si $K = 1$ el enfoque se conoce como One Nearest Neighbour (1-NN), para cualquier otro valor de K en enfoque se llama K Nearest Neighbors (KNN).

Es un método PEREZOSO (lazy): no construye un modelo, siempre necesita los datos de entrenamiento para predecir.

Funcionamiento básico

Para clasificar una nueva observación, KNN la proyecta en el espacio de los datos de entrenamiento y busca los K vecinos más cercanos. La clase que aparezca con mayor frecuencia entre esos K vecinos es la clase asignada.



Ejemplo sencillo en 2D

- Con $K = 1$: se toma el vecino más próximo y se le asigna su clase.
- Con $K = 4$: se toman los 4 vecinos más próximos y se asigna la clase mayoritaria.
- El mismo caso puede clasificarse distinto según el valor de K elegido, por eso es necesario buscar el K óptimo.

Selección del Valor Óptimo de K

Se prueban distintos valores de K y se calcula para cada uno de ellos la tasa de error sobre los datos de prueba (test).

Materia: Ciencia de datos

Se elige el K con la **menor tasa de error** y con una **buena distribución en la matriz de confusión**.

Cuidado: Tomar valores de K muy grandes implica incluir observaciones que no son realmente vecinas, lo que deteriora el modelo.

Distancias en KNN

El concepto de distancia es fundamental en KNN. El tema de distancias es en sí mismo una disciplina muy extensa. Las principales distancias mencionadas en clase son:

1. Distancia Euclídea

Longitud de la línea recta que une dos puntos en el espacio.

Se calcula restando cada variable entre los dos individuos, elevando al cuadrado (para evitar el efecto del signo), sumando todo y calculando la raíz cuadrada.

$$d_{ij} = \sqrt{\sum_{s=1}^p (x_{is} - x_{js})^2} = [(X_i - X_j)'(X_i - X_j)]^{1/2}$$

Es la distancia por defecto en la mayoría de los algoritmos.

Inconveniente: **depende de las unidades de medida de las variables**

2. Distancia Euclídea Ponderada

M puede ser una matriz diagonal para estandarizar variables, que, por ejemplo, puede tener las desviaciones estándares en la diagonal principal.

$$d_{ij} = [(X_i - X_j)'M^1(X_i - X_j)]^{1/2}$$

3. Distancia de Mahalanobis

Utiliza la matriz de covarianzas S. Es recomendable para variables correlacionadas.

$$d_{ij} = [(X_i - X_j)'S^{-1}(X_i - X_j)]^{1/2}$$

4. Distancia de Manhattan

Análoga moverse por las calles de una ciudad en cuadrícula. En lugar de una línea recta, se suman las distancias horizontales y verticales entre los dos puntos. Se utiliza mucho en técnicas de georreferencia y GPS, donde la línea recta no es el camino real.

$$B(x, y) = \sum_i |x_i - y_i|$$

5. Distancia de chebyshev

Calcula la discrepancia más grande en alguna de las dimensiones.

$$C(x, y) = \text{Max} |x_i - y_i|$$

Distancias en variables Categóricas

La distancia euclídea entre dos elementos será:

Materia: Ciencia de datos

- 0 si ambos elementos coinciden en el valor del atributo.
- 1 en caso de que tengan distinto valor

Ejemplo:

Observación	Sexo	Alquila	Educación
i	M	No	Terciaria
j	M	Si	Universitaria

$$d_{ij} = \sqrt{0^2 + 1^2 + 1^2} = 1.414$$

Distancias Mixtas (Variables Numéricas y Cualitativas)

Cuando el dataset tiene variables de ambos tipos, surgen problemas para calcular la distancia:

- Las variables numéricas suelen dominar la métrica por tener rangos de valores mucho mayores.
- Las variables cualitativas (0 o 1) tienden a tener poco peso.

Posibles soluciones: estandarizar las variables numéricas, usar una métrica de distancia diferente, analizar numéricas y cualitativas por separado, o usar la distancia mixta directamente y asumir sus limitaciones.

Ponderación de distancias

Podemos ponderar a los vecinos más cercanos de un punto de consulta haciendo que tengan una mayor influencia que los vecinos más alejados.

En python: el parámetro "weights" permite realizar esta ponderación, **KNeighborsClassifier(k, weights= "distance")**

Estandarización de Variables para KNN

Cuando las variables tienen diferentes unidades de medida o diferente escala, la distancia euclidiana queda dominada por la variable de mayor magnitud.

Estandarización (Z-score)

Estandarizar cada variable restando su media y dividiendo por su desvío estándar.

Resultado: todas las variables quedan con media 0 y desvío estándar 1, en la misma escala. Obteniendo una distribución normal.

Fórmula: $valorEstandarizado = \frac{(valor - media)}{desvío\ estándar}$

Normalización (Min-Max)

Estandarizar cada variable restando el mínimo valor y dividiendo por la diferencia entre el máximo valor y el mínimo valor.

Resultado: todas las variables quedan en un rango de [0, 1].

Fórmula: $valorEstandarizado = \frac{(valor - min_j)}{max_j - min_j}$

Se estandariza **SOLO** en las **variables numéricas**, las cualitativas (0/1) no se estandarizan de la misma manera.

Árboles de decisión

Un árbol de decisión es un conjunto de reglas dispuestas de forma jerárquica, de modo que cada camino posible conduce a una decisión.

Estos se pueden utilizar tanto para tareas de clasificación como para tareas de regresión. En un **Árbol de clasificación** la **variable** predicha es **cualitativa (categórica)** mientras que en un **Árbol de regresión** la variable predicha es **numérica**, la evaluación se realiza con métricas distintas.

Ventaja: Es el modelo predictivo de mayor comprensibilidad para el usuario final.

Variantes y algoritmos

Existen muchas variantes del árbol de decisión. Las más conocidas son:

- C5.0
- CHAID
- CART
- Random Forest (un conjunto de árboles)

Todos trabajan sobre la misma base conceptual y difieren en aspectos menores de implementación.

Fundamentos teóricos

Para construir un árbol de decisión es necesario determinar cuál es el mejor atributo para dividir los datos en cada nodo del árbol.

La idea fundamental consiste en generar grupos cada vez más homogéneos respecto de la variable objetivo. Cuanto más homogéneo sea un grupo, más fácil será clasificar nuevas observaciones y menor será la incertidumbre sobre el resultado esperado.

El problema principal durante la construcción de un árbol consiste en responder:

“¿Cómo medimos objetivamente la incertidumbre presente en un conjunto de datos?”

Para responder esta pregunta necesitamos una medida que permita cuantificar cuánta información contiene un conjunto y cuán mezcladas se encuentran sus clases.

Medidas tradicionales para medir la incertidumbre

Podríamos pensar en utilizar medidas conocidas como la media o el desvío estándar para medir la incertidumbre. Sin embargo, como veremos, no son adecuadas para este objetivo.

Utilizando la media

U	Estados	1	2		100	$\bar{U} = 50,50$
	P	1/100	1/100		1/100	

Z	Estados	50,50	$\bar{Z} = 50,50$
	P	1	

Entre el universo U y el Z hay menor incertidumbre en el Z, ya que tiene un solo estado, mientras que en el U tenemos 100 estados posibles. **En ambos la media es 50/50, por lo tanto no podemos utilizar a la media como medida de incertidumbre.**

Utilizando el desvío

Desvío	U	Estados	Excelente	Normal	Malo
		P	0.3	0.5	0.2

No podemos calcular el desvío de variables cualitativas.

Otros casos

X	Estados	100	0	$\bar{X} = 20$ $\sigma_X = 40$
	P	0.2	0.8	

W	Estados	200	100	$\bar{W} = 120$ $\sigma_W = 40$
	P	0.2	0.8	

Al tener la misma cantidad de estados con las mismas probabilidades de ocurrencia las incertidumbres son iguales, ocurre lo mismo con los desvíos, pero las medias son distintas.

Y	Estados	100	120	$\bar{Y} = 110$ $\sigma_Y = 10$
	P	0.5	0.5	

Z	Estados	120	150	$\bar{Z} = 135$ $\sigma_Z = 15$
	P	0.5	0.5	

Al tener la misma cantidad de estados con las mismas probabilidades de ocurrencia las incertidumbres son iguales, pero los desvíos y las medias son distintas.

U	Estados	100	200	300	400
	P	0.25	0.25	0.25	0.25

V	Estados	100	200	300	400
	P	0.2	0.4	0.1	0.3

$$\begin{aligned}\bar{U} &= 250 \\ \sigma_U &= 111,80\end{aligned}$$

$$\begin{aligned}\bar{V} &= 250 \\ \sigma_V &= 111,80\end{aligned}$$

Tienen la misma cantidad de estados, pero las mismas probabilidades de ocurrencia son distintas por lo que las incertidumbres difieren. Sin embargo los desvios y las medias son iguales.

Características de una buena medida de la incertidumbre

- Debe aumentar al incrementar el número de estados.
- Debe disminuir si un estado tiene mayor probabilidad de ocurrencia que el resto.
- Debe ser insensible a la unidad de medida de la misma.

Entropía

Es una medida de la información y la incertidumbre. Estándar de referencia para medición y comparación.

Limitaciones de la entropía:

- Deben existir probabilidades definidas para poder calcularla.
- El número de estados debe ser conocido.

Dado un universo Z

$$Z = \left\{ \begin{array}{cc} E_1 & E_2 \\ P_1 & P_2 \end{array} \right. \quad \dots \quad \begin{array}{c} E_n \\ P_n \end{array}$$

Definimos

P_i : probabilidad asociada al estado E_i

$E(Z)$: medida numérica de la incertidumbre asociada al universo Z.

Entonces


$$E(Z) = - \sum_{i=1}^n P_i \log_2 P_i$$

Ejemplo:

P_1	0	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1
E	0	0.469	0.722	0.881	0.971	1	0.971	0.881	0.722	0.469	0

$$Z = \left\{ \begin{matrix} E_1 & E_2 \\ P_1 & P_2 \end{matrix} \right\}$$

$$P_2 = 1 - P_1$$



El sistema Z tiene dos estados (E_1 y E_2). La regla fundamental es que sus probabilidades deben sumar 1 (es decir, $P_1 + P_2 = 1$).

- Incertidumbre cero ($E = 0$): En los extremos de la tabla, cuando $P_1 = 0$ y $P_1 = 1$, la entropía es 0. Ejemplo: Una moneda que tiene cara de ambos lados. No hay "información" nueva al lanzarla porque ya sabes qué va a salir.
- Incertidumbre máxima ($E = 1$): El punto más alto de la curva ocurre cuando $P_1 = 0.5$ y por ende $P_2 = 0.5$. Ejemplo: La moneda es **perfectamente justa** (50% cara, 50% cruz).
- Incertidumbres intermedias: pueden ocurrir en casos donde hay "truco" o tenes mayor certeza de que puede ocurrir un evento, por ejemplo si trucas la moneda para que salga "Cara" el 90% de las veces o si la trucas para que salga "Cruz" el 80% de las veces.

Ganancia y Criterio de División (Gain Ratio)

La razón de ganancia o **Gain Ratio** es básicamente un "puntaje" que le damos a una clasificación para saber qué tan buena es organizando datos.

Su función es medir **cuánto logramos reducir la entropía** tras hacer la clasificación, **si** después de dividir los datos **la incertidumbre baja mucho** (porque la probabilidad de ocurrencia de un evento es muy alta), entonces **la ganancia es alta**. Es el indicador que usan los árboles para decidir qué atributo divide mejor los datos.

Fórmula:

$$Ganancia(S, V) = info(S) - \sum_{k \in V} \frac{CantV_k}{CantV} \cdot Info(V_k)$$

donde:


- $info(S) = E(S) \Rightarrow$ entropía en el conjunto de datos S
- $info(V_k) = E(V_k) \Rightarrow$ entropía en el subconjunto de datos V_k
- $S \Rightarrow$ conjunto de datos original
- $V \Rightarrow$ variables o atributo por el cual se divide el conjunto de datos
- $K \Rightarrow$ estados posibles del atributo
- $\frac{CantV_k}{CantV} \Rightarrow$ proporción de datos que cae en el subconjunto k .

Básicamente la ganancia es la resta entre la entropía del conjunto original y la suma de las entropías de los nuevos grupos, pero pesadas según su tamaño.

Estructura del árbol

Un árbol de decisión se compone de las siguientes partes:

- **Raíz (nodo raíz):** el atributo que mejor divide los datos se coloca en la parte superior. Técnicamente, es el atributo con mayor **razón de ganancia (gain ratio)**.
- **Nodos internos:** cada nodo representa una variable (atributo) sobre la cual se realiza una pregunta o división.
- **Ramas:** representan los posibles valores (o rangos) que puede tomar el atributo del nodo.
- **Hojas:** son los nodos finales del árbol. Representan la decisión o clase a asignar.



Hojas puras e impuras

- **Hoja pura:** todas las observaciones que llegan a esa hoja son de la misma clase. El modelo no comete error en esa rama.
- **Hoja impura:** hay observaciones de más de una clase. Se etiqueta con la clase mayoritaria. Las observaciones de la clase minoritaria constituyen el error del modelo.

Cuidado: si un modelo tiene todas las hojas puras, se llega a un fenómeno llamado **sobreajuste** (overfitting), lo que significa que el modelo se ajustó demasiado a los datos de entrenamiento y no generalizará bien a datos nuevos. Existen métodos que sirven para poder acotar el árbol y que pueda generalizar llamados "poda" los cuales veremos más adelante

Algoritmo para construir un árbol

1. Seleccionar el atributo A_i que maximice la razón de ganancia. Va a ser el atributo raíz, de la cual se desprenderan las ramas del árbol. Calculamos la ganancia para cada atributo y seleccionamos aquel que tenga la mayor.

Estado	$G(\text{Estado}) = 0.247$	
Temp	$G(\text{Temp}) = 0.029$	
Humedad	$G(\text{Humedad}) = 0.152$	
Viento	$G(\text{Viento}) = 0.048$	

2. Crear un nodo para ese atributo con tantos sucesores (ramas) como valores tenga. Desde el nodo raíz, clasificamos el conjunto de datos en tantas ramas como valores tenga. En este caso se divide en 3 conjuntos filtrando por el valor de estado.



3. Introducir los ejemplos (valores que asume la variable objetivo) en los sucesores según el valor que tenga el atributo A_i



4. Por cada suceso:

a) Si solo hay ejemplos de una clase C_k , entonces etiquetalos con C_k .

En este ejemplo vemos que nublado solo tiene valores Y (siempre que estuvo nublado, la variable objetivo es Y). Se convierte en una hoja.



b) sino, ir al paso 1 con una tabla formada por los ejemplos de ese nodo, eliminando la columna del atributo A_i .

Tenemos que seguir, porque todavía tenemos incertidumbre dentro de ese conjunto de datos.



Buscamos la nueva variable para que clasifique, dentro de las restantes (temperatura, humedad, viento), según la ganancia.

Habíamos dicho que el atributo a clasificar debía maximizar la ganancia. Significa que a medida que la ganancia es mayor, más se reduce la incertidumbre del conjunto de datos.

Poda (Pruning) - Simplificación del Árbol

La poda es la operación de simplificación de un árbol de decisión. Consiste en reemplazar un subárbol (un conjunto de nodos y ramas) por una hoja, generalmente etiquetada con la clase mayoritaria.

Objetivo: simplificar el árbol para que sea más comprensible y evitar el sobreajuste.

Trade-off: al simplificar, el modelo pierde algo de precisión.

Tipos de poda

- **Post-poda (Pruning):** se realiza una vez que el árbol está completamente construido. Se reemplaza un subárbol por una hoja. Es el tipo utilizado en la cátedra.
- **Pre-poda (pre-pruning):** el algoritmo va podando el árbol a medida que lo construye. Tiende a generar árboles más pequeños que la post-poda. Mayor tasa de error pero árbol más compacto.


Criterio de poda — Ratio de error

Se usa la fórmula de error: casos que falló sobre el número total de observaciones del subconjunto.

Se analiza la relación entre el número de hojas y el ratio de error:

- A mayor número de hojas → menor error en entrenamiento.
- Con un conjunto de validación → a más hojas, el error va aumentando.

Objetivo: encontrar el número de hojas que minimiza el ratio de error sobre los datos de validación, no los de entrenamiento.



Nunca podar con los datos de entrenamiento. Siempre con un conjunto de datos independiente (validación/prueba).

Procedimiento de poda

Se recorre el árbol construido y, para cada rama, se evalúa si conviene mantenerla o reemplazarla por una hoja.


Paso a paso:

1. Se toman los datos de prueba (independientes) y se los hace pasar por el árbol.
2. Para cada nodo/rama, se cuenta cuántas veces el árbol acertó y falló con esas instancias.
3. Se calcula el error con la rama (error combinado de los subconjuntos).

4. Se calcula el error sin la rama (reemplazando el subárbol por una hoja, etiquetada con la clase mayoritaria de ese subconjunto).
5. Decisión:
 - Si el error con la rama es menor → se mantiene la rama.
 - Si el error sin la rama es igual o menor → se poda esa rama y se reemplaza por la hoja.
6. Se repite este proceso hasta que ya no se pueda podar más.

Ejemplo:

No.	Estado	Humedad	Viento	Jugar
1	Soleado	85.0	No	No
2	Soleado	90.0	Si	No
3	Soleado	86.0	Si	No
4	Lluvioso	96.0	No	No
5	Lluvioso	80.0	No	Si
6	Lluvioso	70.0	Si	No
7	Soleado	85.0	Si	Si
8	Soleado	95.0	Si	No
9	Nublado	70.0	No	Si
10	Lluvioso	80.0	No	Si
11	Soleado	70.0	No	Si
12	Nublado	90.0	Si	Si
13	Nublado	75.0	No	No
14	Lluvioso	91.0	Si	Si



Rama Soleado → subnodo Humedad

Subrama	Instancias	Error
Humedad < 80	1 sí, 0 no	$Error = 0$
Humedad > 80	4 sí, 1 no	$Error = 1/5 = 0.20$
Error combinado (sobre 6)	-	$0 \cdot (1/6) + 0.20 \cdot (5/6) \approx 0.17$

Si se reemplaza todo el subárbol de Humedad por una hoja "No" (clase mayoritaria: 4 No y 2 Si), el error sería de $2/6 = 0.33$

Como $0.17 < 0.33 \Rightarrow$ el error combinado es menor que el de la hoja, entonces **NO SE PODA**, se mantiene la rama Humedad.

Rama Nublado

Cae directamente en una hoja "Sí". Los registros de prueba que pasan por acá son los nros. 9, 12, 13 $\Rightarrow$ 2 Sí, 1 No

$Error\ de\ la\ hoja = 1/3 = 0.33$

No hay subárbol para evaluar. Se registra el error, pero no hay decisión de poda aquí.

Rama Lluvioso → subnodo Viento

Subrama	Instancias	Error
Viento $\Rightarrow$ Sí	1 sí, 1 no	$Error = 1/2 = 0.5$
Viento $\Rightarrow$ No	2 sí, 1 no	$Error = 1/3 = 0.33$
Error combinado (sobre 6)	-	$0.5 \cdot (2/5) + 0.33 \cdot (3/5) \approx 0.4$

Si se reemplaza todo el subárbol de Viento por una hoja "Sí" (clase mayoritaria: 3 Sí y 2 No), el error sería de $2/5 = 0.4$.

Como $0.4 = 0.4 \Rightarrow$ el error combinado es igual al de la hoja y **SE PODA**. No tiene sentido mantener la complejidad del subárbol si da lo mismo que una hoja "Sí".


Análisis Discriminante

El análisis discriminante es una técnica de minería de datos que pertenece a la etapa de Modelado dentro del proceso CRISP-DM. Se ubica dentro de los **modelos predictivos (supervisados)** para **tareas de clasificación**, junto con árboles de decisión y regresión logística.

Modelos Técnicas	Tareas	Predictivos (supervisados)		Descriptivos (no supervisados)		
		Clasificación	Predicción	agrupamiento	Asociación	Otros
Redes Neuronales		X	X	X		
Arboles de Decisión		X	X	X	X	
Kohonen				X		
Regresión paramétrica			X			
Regresión Logística		X			X	
k means / k medioides				X		
A priori					X	
Análisis factorial						X
Análisis Discriminante		X				
Algoritmos genéticos		X	X	X	X	X
Naive Bayes		X				
Vecinos mas próximos		X	X	X		


Esta técnica es capaz de decirnos **qué variables** permiten **diferenciar a los grupos** y **cuántas de estas variables** son necesarias para alcanzar **la mejor clasificación posible**.

Ejemplo con tres poblaciones (roja, negra y azul) y dos variables:



- Vemos que la función naranja discrimina mal al conjunto de datos.
- La función verde mejora para discriminar a los negros de los azules pero sigue siendo mala.
- La marrón discrimina mejor a rojo y negro pero no azul.
- Mientras que las amarillas, por sí solas discriminan muy bien a rojo/negro y negro/azul, pero mal al conjunto entero individualmente. Por lo tanto la combinación de estas dos funciones discriminan bien al conjunto de datos completo.⁶

Una vez construida la función discriminante, se definen puntos de corte que dividen el espacio en regiones. Todo punto que cae en la región de un grupo se clasifica como perteneciente a ese grupo.



Fundamentos teóricos

Variable dependiente y variables independientes

La pertenencia a los grupos, conocida de antemano (vuelo demorado / no demorado), se utiliza como variable **dependiente** (una variable categórica con tantos valores discretos como grupos). Las variables en las que suponemos que se diferencian los grupos se utilizan como variables **independientes** o variables de **clasificación** (también llamadas variables **discriminantes**). Según veremos, **deben ser variables cuantitativas continuas** o, al menos, **admitir un tratamiento numérico con significado**.

Cantidad de funciones discriminantes

La cantidad de funciones discriminantes que se pueden construir está determinada por el mínimo entre:

$$r = \min(G - 1, p)$$

Donde:

- G = cantidad de poblaciones sobre las cuales clasificar.
- p = cantidad de variables independientes

Ejemplo: Si tenemos que clasificar si una observación acepta o no el ofrecimiento, y tenemos 4 variables predictoras, entonces:

$$G = 2 \Rightarrow G - 1 = 1 ; p = 4$$

$$r = \min(1, 4) \Rightarrow \text{tenemos 1 función discriminante}$$

Si tenemos más de una función discriminante, Statistics otorga las mismas según el orden de mayor poder discriminante. La primera función será la que mejor clasifique y así sucesivamente.

Pasos para construir el modelo

1. Plantear el problema a resolver

Definir qué se quiere clasificar o analizar. Determinar la variable dependiente y las variables independientes

2. Analizar supuestos del modelo

Se deben verificar estos **supuestos** antes de aplicar el modelo para garantizar capacidad discriminante

- Distribución normal de las variables (multivariante)
- No multicolinealidad
- Matrices de Varianza Covarianzas Iguales (las campanas deben ser iguales). **El profesor aclaró que en la realidad es complicado que se cumpla**

3. Analizar si existen diferencias significativas entre los grupos (si los centroides están separados)

Comparar si las variables predictoras permiten distinguir entre los grupos. Si no hay diferencias reales entre los grupos, el análisis discriminante no podrá clasificarlos bien. Para esto se utiliza el lambda de Wilks.

4. Establecer el número y composición de las dimensiones de discriminación entre los grupos analizados

LDA genera funciones discriminantes (combinaciones lineales de las variables) que maximizan la separación entre los grupos. Se seleccionan las funciones más significativas y se analiza qué variables las componen.

5. Evaluar los resultados obtenidos desde un punto de vista predictivo analizando la significación estadística y práctica del proceso de discriminación

Se mide qué tan bien clasifica el modelo los casos conocidos. Se usan las métricas desprendidas de la matriz de confusión como la precisión o la tasa de error. Se analiza tanto la significación estadística (¿Las diferencias son reales?) como la significación práctica (¿Sirve para tomar decisiones?).

Supuestos del análisis discriminante

Antes de construir el modelo, se deben verificar tres supuestos fundamentales. Si no se cumplen, los resultados pueden ser poco confiables.

Supuesto 1: Distribución normal de las variables (Normalidad multivariante)

Lo que se quiere probar es la distribución normal multivariante. Como los software no permiten calcular la normal multivariante, vamos a probar la normalidad variable por variable. Sin embargo, hay que tener en cuenta que:

Si la población tiene distribución normal multivariante



Cada una de las variables tiene distribución normal

Si todas las variables tienen distribución normal



La población tiene distribución normal multivariante

No se da la inversa, sin embargo si todas las variables tienen distribución normal es más probable que la población tenga distribución normal multivariante.

Interpretación del test de normalidad

H_0 : La variable tiene distribución normal.

Para que el supuesto se **CUMPLA**, el p-value debe ser **MAYOR** que α (0.05). Si p-value < 0.05, se rechaza H_0 y el supuesto no se cumple.

Como validarlo en SPSS Statistics (Test Kolmogorov-Smirnov):

- Ir a Analizar → Estadísticos descriptivos → Explorar
- Pasar las variables cuantitativas a lista de dependientes
- En Gráficos, activar 'Gráficos de normalidad con pruebas'
- El sistema genera dos tests: Shapiro-Wilk (para $n \leq 50$) y Kolmogorov-Smirnov (para $n \geq 50$)

Cuidado: Para las pruebas de normalidad, cuando tenemos un test con más de **50 observaciones**, utilizamos el test de **Kolmogorov-Smirnov** mientras que si tenemos **menos** de 50 observaciones, utilizamos el test de **Shapiro-Wilk**.

Ejemplo de la tabla obtenida:

Pruebas de normalidad			
	Kolmogorov-Smirnov ^a		
	Estadístico	gl	Sig.
IngresoAnual	,129	6367	,000
TotalHijos	,169	6367	,000
CantAutomoviles	,181	6367	,000
Edad	,078	6367	,000

Donde vemos que las significancias correspondientes a las variables son todas **menores a 0.05** por lo tanto **ninguna se distribuye de forma normal**, por lo cual **no se cumple el supuesto de la distribución normal de las variables**.

Supuesto 2: No multicolinealidad

Las **variables predictoras** deben ser **independientes entre sí**. Si dos o más variables están fuertemente correladas, el fenómeno se llama **multicolinealidad** y **distorsiona la función discriminante**.

Como validarlo en SPSS Statistics (Test de colinealidad):

- Ir a Analizar → Regresión → Lineales
- Pasar las variables predictoras como independientes
- Poner cualquier variable como dependiente (sólo nos interesa el diagnóstico)
- En Estadísticos, activar 'Diagnósticos de colinealidad'
- Mirar la columna 'Índice de condición' en la última fila de la tabla

En la última fila observamos

- *Índice de condición* $< 20 \Rightarrow$ No hay multicolinealidad
- $20 \leq$ *Índice de condición* $\leq 30 \Rightarrow$ Multicolinealidad moderada
- *Índice de condición* $> 30 \Rightarrow$ Multicolinealidad significativa

Ejemplo de la tabla obtenida:

Diagnósticos de colinealidad^a

Modelo	Dimensión	Autovalor	Índice de condición	Proporciones de varianza				
				(Constante)	IngresoAnual	TotalHijos	CantAutomoviles	Edad
1	1	4,278	1,000	,00	,01	,01	,01	,00
	2	,318	3,670	,00	,06	,71	,11	,00
	3	,248	4,157	,04	,00	,08	,54	,03
	4	,137	5,583	,02	,92	,02	,33	,02
	5	,020	14,688	,93	,01	,18	,00	,96

a. Variable dependiente: D

Como el índice de condición en la última fila es de 14,688 entonces no hay multicolinealidad entre las variables. Se rechaza la hipótesis nula.

Supuesto 3: Matrices de varianza-covarianza iguales (Homocedasticidad)

Las matrices de varianza-covarianza de cada grupo deben ser iguales.

Geométricamente, esto significa que las 'campanas' de distribución de cada población sobre la función discriminante deben tener la misma forma y dispersión.

Como validarlo en SPSS Statistics (Test M de Box):

- Ir a Analizar → Clasificar → Discriminante
- En Estadísticos, activar 'M de Box'

Esta prueba genera un $p - value$ que se interpreta de la siguiente forma

H_0 : las matrices de varianza-covarianza son iguales (supuesto se cumple)

- Si $p - value > 0.05 \Rightarrow$ No se rechaza $H_0 \Rightarrow$ Supuesto cumplido
- Si $p - value < 0.05 \Rightarrow$ Se rechaza $H_0 \Rightarrow$ Supuesto **NO** cumplido

El profesor indicó que en la práctica es frecuente que este supuesto no se cumpla.

Ejemplo de la tabla obtenida:

Resultados de prueba

M de Box		209,152
F	Aprox.	20,894
	gl1	10
	gl2	62829289,20
	Sig.	,000

Prueba la hipótesis nula de las matrices de covarianzas de población iguales.

En este caso como el $p - value$ es menor a 0.05, no se cumple el supuesto. Por lo tanto las poblaciones no tienen varianza-covarianza iguales.

Test de hipótesis: diferencia significativa entre medias ¿Hay modelo o no?

Antes de confiar en el modelo discriminante, se realiza un test de hipótesis para verificar si existe realmente separación entre los grupos.

- H_0 (nula): las medias de todos los grupos son iguales $\Rightarrow$ no se puede discriminar.
- H_1 (alternativa): al menos dos medias difieren $\Rightarrow$ sí hay diferencias entre grupos.

Se rechaza H_0 si el p - value es menor que el nivel de significación α (generalmente 0.05).

Rechazar H_0 es deseable, significa que el modelo tiene poder discriminador

Tabla 23.4. Lambda de Wilks.

Contraste de las funciones	Lambda de Wilks	Chi-cuadrado	gl	Sig.
1	.773	83.202	2	.000

En nuestro ejemplo, **el valor de lambda es moderadamente alto (0,773)**, lo cual significa que existe **bastante solapamiento entre los grupos**. Sin embargo, el valor transformado de lambda (Chi-cuadrado = 83,202) tiene asociado, con 2 grados de libertad, **un nivel crítico (Sig.) de 0,000**, por lo que **podemos rechazar la hipótesis nula de que los grupos comparados tienen promedios iguales en las dos variables discriminantes**.

Interpretación de resultados (Salidas de SPSS Statistics)

Coeficientes de la función discriminante

Nos proporciona la función discriminante, que nos sirve para clasificar. Es la función de la recta. Se compone de las distintas variables multiplicadas por sus correspondientes coeficientes.

Los coeficientes muestran la **contribución neta** de cada variable independiente a la función discriminante (de manera similar a como lo hacen los coeficientes beta de un análisis de regresión).

	Función
	1
Peso total (kg)	.004
Aceleración 0 a 100 km/h	-.065
(Constante)	-2.967

En este caso la función discriminante queda determinada como:

$$d = b_0 + b_1x_1 + b_2x_2 = -2.967 + 0.004 \cdot \text{Peso} - 0.065 \cdot \text{Aceleración}$$

Puede comprobarse que a partir de **las medias** de cada grupo en las variables discriminantes y este conjunto de coeficientes se obtienen los centroides en la función discriminante:

País de origen		Media	Desv. típ.	N válido (según lista)	
				No ponderados	Ponderados
EE.UU.	Peso total (kg)	1122.11	262.87	253	253.000
	Aceleración 0 a 100 km/h	14.93	2.80	253	253.000
Europa	Peso total (kg)	810.12	163.62	73	73.000
	Aceleración 0 a 100 km/h	16.82	3.01	73	73.000
Total	Peso total (kg)	1052.25	276.55	326	326.000
	Aceleración 0 a 100 km/h	15.35	2.95	326	326.000

$$\bar{d}_1 = b_0 + b_1\bar{x}_1^{(1)} + b_2\bar{x}_2^{(1)} = -2.967 + 0.004 \cdot 1122.11 - 0.065 \cdot 14.93 = 0.290$$

$$\bar{d}_1 = b_0 + b_1\bar{x}_1^{(2)} + b_2\bar{x}_2^{(2)} = -2.967 + 0.004 \cdot 810.12 - 0.065 \cdot 16.82 = -1.006$$

Tabla de coeficientes estandarizados

Contiene una versión estandarizada de los coeficientes de la función discriminante. Estos coeficientes estandarizados son independientes de la métrica original de las variables discriminantes y, por lo tanto, son preferibles a los coeficientes brutos cuando las variables poseen una métrica distinta.

Atendiendo al valor de los coeficientes estandarizados podemos concluir que **la variable peso tiene mayor importancia que la variable aceleración** a la hora de predecir el grupo de pertenencia de los vehículos.

Tabla de coeficientes estandarizados de las funciones discriminantes canónicas

	Función
	1
Peso total (kg)	.919
Aceleración 0 a 100 km/h	-.184

Para interpretar los signos de las ponderaciones resulta útil inspeccionar primero la ubicación de los centroides de cada grupo.

Valores de los centroides en la función discriminante.

País de origen	Función
	1
EE.UU.	.290
Europa	-1.006

Podemos comprobar que el grupo de **coches estadounidenses tiende a obtener puntuaciones positivas** en la función discriminante, mientras que el grupo de **vehículos europeos tiende a obtener puntuaciones negativas**. Sabido esto, la función discriminante nos indica que un **incremento en el peso** (por encima de la media) hará más probable que el vehículo obtenga una **puntuación positiva** y, con ello, que se ajuste al patrón de los **vehículos estadounidenses**. Por el contrario, un **peso por debajo de la media será característico de un vehículo europeo**. En cuanto a la variable **aceleración**, un **valor por encima de la media** (mayor número de segundos en alcanzar los 100 km/h) hará **disminuir la puntuación discriminante** (dado que el signo es negativo) y será más característico de los **vehículos europeos**, y viceversa, una puntuación en aceleración por **debajo de la media** aumentará las posibilidades de que el vehículo sea clasificado como **estadounidense**. Basándonos en estos resultados, podemos afirmar que los vehículos estadounidenses tienen mayor peso y tardan menos en alcanzar los 100 km/h.

Matriz de estructuras

Contiene las **correlaciones entre las variables discriminantes y la función discriminante estandarizada**. Mientras que los coeficientes estandarizados muestran la contribución neta de cada variable independiente a la función discriminante, las correlaciones muestran la **relación bruta** entre cada variable y la función discriminante.

Cuando existe colinealidad entre las variables independientes puede ocurrir que alguna de ellas quede fuera del análisis por no aportar información nueva. Sin embargo, no por ello carece de interés conocer cómo se relaciona cada variable independiente con la función discriminante. Conocer estas relaciones puede ayudar a interpretar mejor la función discriminante.

En la tabla podemos apreciar que la **aceleración correlaciona alto con la función discriminante**, aunque sea una **variable poco importante en la función**. Posiblemente, la poca importancia de esta variable en la función se deba a su relación con la variable peso, la cual ha capitalizado la información que comparte con la aceleración y la aporta de manera individual a la función discriminante.

Matriz de estructuras

	Función
	1
Peso total (kg)	.985
Aceleración 0 a 100 km/h	-.513

Funciones en centroides de grupo

Nos indica qué valores toman los centroides (medias de las poblaciones) proyectados. Son los valores m .

Esta tabla es de gran utilidad para interpretar la función discriminante. Podemos observar que el grupo de vehículos estadounidenses se encuentra localizado, en promedio, en las puntuaciones positivas de la función, mientras que los vehículos europeos se encuentran ubicados en las puntuaciones negativas.

Si desconocemos la procedencia de un vehículo pero tenemos información sobre su peso y aceleración, podemos calcular su puntuación discriminante y, a partir de ella, asignarlo al grupo de cuyo centroide se encuentre más próximo.

Valores de los centroides en la función discriminante.

	Función
País de origen	1
EE.UU.	.290
Europa	-1.006

Variabilidad explicada y no explicada

Para evaluar si el modelo tiene poder discriminador, se trabaja con los conceptos de variabilidad total, explicada y no explicada:

- **Variabilidad total:** calculada como la varianza general de todos los datos.
- **Variabilidad no explicada (intragrupo):** variabilidad dentro de cada grupo, que **NO aporta información para discriminar**.
- **Variabilidad explicada (intergrupo):** variabilidad entre grupos, que **Sí sirve para discriminar**.

Autovalor y Lambda de Wilks

La tabla de autovalores cobra mayor significado en el caso de más de dos grupos. Cuando se trabaja con más de dos grupos se obtiene más de una función discriminante: en estas tablas es posible **comparar de manera global la capacidad discriminativa de cada función**. En la tabla aparece una fila numerada por cada función discriminante. En nuestro ejemplo, como solo hay una función, sólo se muestra una fila.

Tabla 23.3. Autovalores.

Función	Autovalor	% de varianza	% acumulado	Correlación canónica
1	.294 ^a	100.0	100.0	.477

a. Se han empleado las 1 primeras funciones discriminantes canónicas en el análisis.

El **autovalor** es el cociente entre la variación debida a las diferencias entre grupos (medida mediante la suma de cuadrados inter-grupos) y la variación que se da dentro de cada grupo combinada en una única cantidad (medida mediante la suma de cuadrados intra-grupos).

Su interés radica en que permite comparar cómo se distribuye la dispersión inter-grupos cuando existe más de una función. Aunque un autovalor tiene un mínimo de cero, no tiene un máximo, lo cual lo hace difícilmente interpretable por sí solo.

Por esa razón se acostumbra a utilizar el estadístico lambda de Wilks, que se encuentra estrechamente relacionado con los autovalores.

El estadístico lambda de Wilks expresa la proporción de variabilidad total no debida a las diferencias entre los grupos: permite contrastar la hipótesis nula de las medias multivariantes de los grupos (los centroides) son iguales.

$$\Lambda = \frac{\text{Suma de cuadrados intragrupos}}{\text{Suma de cuadrados total}} = \frac{|S|}{|T|}$$

Donde:

- $S \Rightarrow$ es la matriz de varianzas-covarianzas combinada, calculada a partir de las matrices de varianzas-covarianzas de cada grupo.
- $T \Rightarrow$ es la matriz de varianzas-covarianzas total, calculada sobre todos los casos como si pertenecieran a un único grupo.

Cuando los grupos se encuentren **superpuestos en el espacio multidimensional**, los valores del numerador y del denominador serán **aproximadamente** iguales y **su cociente valdrá 1**.

A medida que los grupos se vayan separando mas, la variabilidad inter-grupos irá aumentando y la variabilidad intra-grupos se irá haciendo comparativamente menor respecto a la variabilidad total, disminuyendo así el valor del cociente. **Por tanto, valores próximos a 1 indicarán un gran parecido entre los grupos, mientras que valores próximos a 0 indicarán una gran diferencia entre ellos.**

Tabla 23.4. Lambda de Wilks.

Contraste de las funciones	Lambda de Wilks	Chi-cuadrado	gl	Sig.
1	.773	83.202	2	.000

Es más frecuente utilizar una transformación de Λ que posee distribución aproximada conocida. Bartlett ha demostrado que el estadístico

$$V = \left| N - 1 - \frac{(p+g)}{2} \right| \ln \Lambda$$

se aproxima a la distribución chi-cuadrado con $(p - k)(g - k - 1)$ grados de libertad, donde:

- $p \Rightarrow$ es el número de variables independientes
- $g \Rightarrow$ es el número de grupos
- $k \Rightarrow$ es el número de funciones discriminantes obtenidas con anterioridad al contraste (cuando sólo existe una función, porque solo hay dos grupos, $k=0$)

La **gran ventaja** diagnóstica del estadístico lambda es que, puesto que se basa en las matrices de varianzas-covarianzas, **puede calcularse antes de obtener las funciones discriminantes.**

Clasificación de nuevos casos

Para clasificar una nueva observación X_0 , suponiendo que tenemos 2 poblaciones:

1. Construimos la función discriminante

$$d = Xu \Rightarrow d_i = u_1 X_{1i} + u_2 X_{2i} + \dots + u_p X_{pi}$$

Donde:

- $i \Rightarrow$ fila de la vista minable
- $p \Rightarrow$ cantidad de variables
- $d \Rightarrow$ función discriminante.
- $X \Rightarrow$ matriz de datos (vista minable)
- $u \Rightarrow$ vector de constantes de la combinación lineal (coeficientes de la función discriminante o coeficientes discriminante canónicos)
- $d_i \Rightarrow$ valor de la función discriminante para la fila i
- $u_p \Rightarrow$ coeficiente asociado a la variable p
- $X_{pi} \Rightarrow$ valores de la variable en la p en la fila i

2. Calculamos el valor de la función discriminante en la observación X_0

$$d_0 = u \cdot X_0$$

Esto equivale a proyectar el punto en la función discriminante.

3. Calcular las proyecciones de los centroides de los grupos a la función discriminante

$$m_1 = u' \cdot \mu_1 \text{ y } m_2 = u' \cdot \mu_2$$


Donde:

- $m_1 \Rightarrow$ proyección del centroide del grupo 1 a la función discriminante
- $m_2 \Rightarrow$ proyección del centroide del grupo 2 a la función discriminante
- $\mu_1 \Rightarrow$ centroide del grupo 1
- $\mu_2 \Rightarrow$ centroide del grupo 2

Los centroides son las medias de las variables filtradas por cada clase (población). Tenemos tantos centroides como poblaciones de datos.


Lo que hacemos es calcular (evaluar) los centroides en la función discriminante.

4. Clasificar en P_1 si: $|d_o - m_1| < |d_o - m_2|$



Entonces, para clasificar, tenemos la función discriminante sobre la cual proyectamos el punto X_0 que queremos clasificar. Luego proyectamos los centroides sobre la función. Finalmente calculamos la distancia euclídea entre el punto proyectado y los centroides proyectados, y nos quedamos con la población que minimice esa distancia.

Otra forma de clasificar consiste en calcular el punto medio entre los centroides proyectados (m_1 y m_2) y a partir de ese punto comparamos el la proyección del punto X_0 con dicho punto medio. Si cae dentro del "área" de m_1 y (c) entonces se clasifica como población 1 y si cae dentro del "área" de m_2 y (c) entonces se clasifica como población 2. Es por eso que decimos que (c) sería el punto de corte, que nos divide el área correspondiente a la población 1 y el área correspondiente a la población 2.



Funciones de Fisher (otra forma de clasificar)

Una forma alternativa para clasificar es, en lugar de utilizar el criterio del punto de corte, construir funciones discriminantes para cada grupo. Esta técnica es especialmente útil cuando tenemos más de dos poblaciones.

Fisher realiza **una función de clasificación para cada población posible**. En nuestro caso tenemos dos poblaciones posibles, por lo tanto tenemos dos funciones de fisher.

Tabla 23.15. Funciones de clasificación de Fisher.

	País de origen	
	EE.UU.	Europa
Peso total (kg)	.030	.025
Aceleración 0 a 100 km/h	2.769	2.853
(Constante)	-38.385	-35.003

Funciones discriminantes lineales de Fisher

$$1. d_{EE.UU} = -38.385 + 0.030 \cdot \text{Peso total} + 2.769 \cdot \text{Aceleración}$$

$$2. d_{Europa} = -35.003 + 0.025 \cdot \text{Peso total} + 2.853 \cdot \text{Aceleración}$$


Para clasificar una nueva observación, se evalúa **en todas las funciones discriminantes que tengamos** y luego se clasifica en el grupo para el que la función de clasificación de Fisher sea mayor.

Osea que si $d_{EE.UU} > d_{Europa}$ para una nueva observación, entonces **se clasificará como EE.UU.**

El problema de clasificación en datasets desbalanceados


La **clasificación** de casos es algo muy distinto a la **estimación** de la función discriminante. De hecho, una función perfectamente estimada puede no pasar de una pobre capacidad clasificatoria.

Una manera de clasificar los casos, como ya vimos, consiste en calcular la distancia existente entre los centroides de ambos grupos y situar un punto de corte d_c equidistante de ambos centroides. A partir de ese momento, los casos cuyas puntuaciones discriminantes sean mayores que el punto de corte d_c serán asignado al grupo superior y los casos cuyas puntuaciones discriminantes sean menores que el punto de corte d_c serán asignados al grupo inferior.



Esta regla de clasificación tiene un serio inconveniente: sólo permite distinguir entre dos grupos y es difícilmente aplicable al caso de más de dos grupos. Además, no tiene en cuenta que los grupos pueden tener distinto tamaño.

Si los tamaños muestrales son muy desiguales, la situación real será más parecida a la siguiente figura:



Podemos observar que si utilizamos el punto de corte d_c como punto de clasificación, la proporción de casos mal clasificados en el grupo de menor tamaño (zona rayada

Materia: Ciencia de datos

horizontalmente) será mucho menor que en el grupo de mayor tamaño (zona rayada verticalmente).

Por lo tanto, con tamaños desiguales es preferible utilizar una regla de clasificación que desplace el punto de corte hacia el centroide del grupo de menor tamaño buscando igualar los errores de clasificación.

Para calcular este punto de corte podemos utilizar una distancia ponderada:

$$\overline{d}_c = \frac{n_1 \overline{d}_1 + n_2 \overline{d}_2}{n_1 + n_2}$$

Donde:

- $n_1, n_2 \Rightarrow$ cantidad de casos en cada grupo.
- $\overline{d}_1, \overline{d}_2 \Rightarrow$ centroides proyectados de cada grupo sobre la función discriminante.

Si los grupos son iguales en tamaño, la fórmula da exactamente el punto medio entre los dos centroides, igual que el corte equidistante simple.

Costos de clasificar mal


Todo lo anterior, sigue asumiendo algo que no siempre es válido: que equivocarse en un grupo cuesta lo mismo que equivocarse en otro.

Pero en la práctica eso casi nunca es cierto. En medicina, clasificar a un enfermo como sano (falso negativo) es mucho más grave que clasificar a un sano como enfermo (falso positivo). En crédito bancario, aprobar un préstamo a alguien que no va a pagar cuesta más que rechazarle el crédito a alguien que sí pagaría.


Cuando los costes de error son distintos entre grupos, determinar el punto de corte óptimo deja de ser un problema estadístico puro y se convierte en un problema de Teoría de la Toma de Decisiones, donde hay que incorporar explícitamente cuánto pesa cada tipo de error para encontrar el umbral que minimiza el coste total esperado, no simplemente el porcentaje de clasificaciones incorrectas.

¿Qué ocurre si los costos son distintos? Como resultado nos quedaría un área más grande que la otra.

En esta gráfica podemos ver que es más costoso clasificar mal un valor de la población 2. Preferimos clasificar de la 1 como 2, pero no viceversa



Es esta gráfica podemos ver que es más costoso clasificar mal un valor de la población 1. Preferimos clasificar de la 2 como 1, pero no viceversa.



Comparación con regresión logística

En comparación con la regresión logística, la LDA realiza suposiciones más estrictas sobre los datos, pero si se cumplen, generalmente ofrece mejores resultados, especialmente en precisión y estabilidad. Por ejemplo, si las clases están bien separadas, la regresión logística puede tener una estimación de parámetros sorprendentemente inestable y, por lo tanto, un

Materia: Ciencia de datos

rendimiento particularmente bajo. Por otro lado, la regresión logística es más flexible y, por lo tanto, sigue siendo la preferida en la mayoría de los casos. Por ejemplo, el análisis discriminante lineal requiere variables de entrada numéricas continuas, ya que debe calcularse la covarianza y, por lo tanto, la distancia entre los puntos de datos. Esta es una desventaja en comparación con la regresión logística, que también puede procesar datos de tipo categóricos.

Regresión Logística

Introducción

La regresión logística es una técnica estadística de aprendizaje supervisado utilizada para resolver **problemas de clasificación**. Su objetivo es estimar la probabilidad de ocurrencia de un evento a partir de una o más variables predictoras.

A diferencia de la regresión lineal, que se utiliza para predecir variables numéricas continuas, la regresión logística se emplea cuando la **variable objetivo es categórica**. En su forma más común, denominada **regresión logística binomial**, la variable dependiente es **dicotómica**, es decir, puede tomar únicamente dos valores posibles:

- $1 \Rightarrow$ ocurre el evento de interés
- $0 \Rightarrow$ no ocurre el evento de interés

Por esta razón, la regresión logística se utiliza en problemas donde se busca clasificar observaciones en una de dos categorías posibles.

Aunque su nombre contiene la palabra "regresión", su finalidad principal no es predecir valores numéricos sino **clasificar observaciones mediante la estimación de probabilidades**.

El modelo **calcula la probabilidad** de que **ocurra** el **evento de interés** y, a partir de ella, **asigna** la observación **a una determinada categoría**.

De forma general, la regresión logística busca estimar:

$$P(Y = 1|X)$$

donde:

- $Y \Rightarrow$ es la variable objetivo (**dicotómica**)
- $Y = 1 \Rightarrow$ representa la ocurrencia del evento
- $X \Rightarrow$ representa el conjunto de variables predictoras. Pueden ser **numéricas** o **categóricas**.

Esta expresión se interpreta como:


"La probabilidad de que ocurra el evento dado un conjunto de variables predictoras"

Por ejemplo:

$$P(\text{Demora} = 1|X)$$

Representa la probabilidad de que un vuelo se demore dadas sus características.

¿Por qué no sirve la Regresión Lineal?



La regresión lineal es una técnica utilizada para predecir el valor de una variable numérica continua a partir de una o más variables independientes.

Cada observación se representa como

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \varepsilon$$

donde:

- $Y \Rightarrow$ variable que queremos explicar
- $X_1, X_2, \dots, X_n \Rightarrow$ variables explicativas
- $\beta_0 \Rightarrow$ intercepto (valor predicho de Y cuando $X = 0$), en regresión lineal simple es la ordenada al origen.
- $\beta_1, \beta_2, \dots, \beta_n \Rightarrow$ coeficientes
- $\varepsilon \Rightarrow$ error (todo lo que el modelo no puede explicar)

El modelo se expresa como

$$\hat{Y} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n$$

o también

$$E(Y|X) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n$$

Aquí ya no aparece ε porque estamos representando el valor promedio esperado de Y para cada valor de X .

Por ejemplo, podría utilizarse para predecir:

Materia: Ciencia de datos

- Ventas de una empresa
- Precio de una vivienda
- Consumo de energía.
- Temperatura

En todos estos casos **la variable objetivo es numérica, continua y no posee restricciones particulares sobre los valores que puede tomar**. Sin embargo ya vimos que **en problemas de clasificación, la variable objetivo es dicotómica (solo puede asumir valores de 0 o 1)**.

Si intentamos utilizar una regresión lineal para modelar esta variable, podríamos obtener valores de predicción como -0.3 o 1.4, resultados que no pueden interpretarse como probabilidades, ya que una probabilidad está siempre en un rango entre 0 y 1.

Por lo tanto, aunque **la regresión lineal** permite modelar relaciones mediante una combinación lineal de variables predictoras, **no es adecuada cuando queremos estimar la probabilidad de ocurrencia de un evento**.

Necesitamos entonces un **modelo** que conserve la idea de **utilizar una combinación lineal de variables independientes**, pero que **garantice** que el resultado obtenido siempre sea una **probabilidad válida**. Es precisamente este problema el que da origen a la regresión logística.

Ejemplo con regresión lineal simple (una única variable independiente)

Imaginemos que tenemos estos datos:

Espacio (dm^2)	Ventas (\$)
1	100
2	150
3	200
4	250

Observamos que cuanto más espacio le damos a un producto, más lo vendemos.

Entonces queremos una fórmula que describa esa relación

Por ejemplo

$$Ventas = 50 + 50 \cdot Espacio$$

Este es el modelo de regresión lineal simple. Este intenta modelar el valor promedio esperado de Y para un determinado valor de X .

Suponiendo las siguientes observaciones:

Espacio (dm^2)	Ventas (\$)
5	290
5	310
5	300

Para un espacio de $5 dm^2$ las ventas no son siempre iguales. A veces \$290, otras \$310 y otras \$300. Pero el promedio es: \$300

Entonces la regresión lineal no intenta adivinar cada observación, sino modelar

“¿Cuál es el valor promedio de Y cuando X vale cierto valor?”

Ahí es donde aparece la esperanza la cual es el promedio teórico esperado.

$$E(Y|X)$$

Se lee: Valor esperado de Y dado X o Promedio esperado de Y cuando conozco X

Si para $X = 5$ las ventas observadas fueron \$290, \$310, \$300 entonces:

$$E(\text{Ventas}|\text{Espacio} = 5) = 300$$

Es por eso que no aparece el error ε ya que la realidad puede no coincidir con la predicción:

El modelo predice que la ventas para $X = 5$ será de \$300, pero la venta real fue de, por ejemplo para la primera observación, \$290 por lo que el error es de

$$\text{error} = 290 - 300 = -10$$

Por eso una observación real se expresa como

$$Y = \beta_0 + \beta_1 X_1 + \varepsilon$$

Odds y Función Logit

Como vimos, la regresión lineal no es adecuada para estimar probabilidades, ya que puede generar valores menores que 0 y mayores que 1.

Por lo tanto, necesitamos una forma de representar la probabilidad que nos permita trabajar con una combinación lineal de variables predictoras sin perder la interpretación probabilística del resultado.

Para ello, la regresión logística utiliza dos conceptos fundamentales: los **Odds** y la **Función Logit**.

Probabilidad

La probabilidad mide la posibilidad de ocurrencia de un evento.

Se calcula como:

$$P(X) = \frac{\text{Número de éxitos}}{\text{Número total de intentos}}$$

Sus valores siempre se encuentra entre 0 y 1.

Por ejemplo, si un jugador gana 3 de 5 partidas:

$$P(\text{ganar}) = \frac{3}{5} = 0.6$$

La interpretación es: La probabilidad de ganar es del 60%

Sin embargo, la probabilidad presenta una limitación importante para el modelado, y es que siempre está acotada entre 0 y 1.

Odds

Los odds representan cuántas veces es más probable que ocurra un evento respecto de que no ocurra.

Se calcula mediante

$$\text{Odds} = \frac{P}{1-P}$$

Materia: Ciencia de datos

Por ejemplo, si la probabilidad de ganar es $P = 0.6$, entonces $Odds = \frac{0.6}{0.4} = 1.5$.

La interpretación es: Ganar es 1.5 veces más probable que perder.

A diferencia de la probabilidad, los Odds no están limitados al intervalo entre 0 y 1.

Por ejemplo:

Probabilidad	Odds
0.5	1
0.75	3
0.9	9
0.99	99

Puede observarse que, a medida que la probabilidad se acerca a 1, los Odds crecen sin límite. Sin embargo, los Odds siguen teniendo una restricción, nunca pueden tomar valores negativos.

Función Logit

Para eliminar esta última restricción se aplica una transformación adicional conocida como

Función Logit.


La función Logit se define como:

$$Logit(P) = \ln\left(\frac{P}{1-P}\right)$$

Observando la fórmula puede verse que

$$\frac{P}{1-P}$$

corresponde precisamente a los Odds. Por lo tanto el Logit es el logaritmo natural de los Odds.



La principal ventaja de esta transformación es que convierte una probabilidad comprendida entre 0 y 1 en una variable que puede tomar cualquier valor real.

Probabilidad	Odds	Logit
0.01	0.01	-4.60
0.10	0.11	-2.20
0.5	1	0
0.90	9	2.20
0.99	99	4.60

Puede observarse que:

- Si la probabilidad es baja, el Logit toma valores negativos.
- Si la probabilidad es 0.5, el Logit vale 0.
- Si la probabilidad es alta, el Logit toma valores positivos.

Esto permite modelar la probabilidad de ocurrencia de un evento mediante una combinación lineal de variables predictoras, del mismo modo que se hace en la regresión lineal.

Modelo de Regresión Logística

En la sección anterior vimos que la función Logit transforma una probabilidad en una variable que puede tomar cualquier valor real.

Esta transformación permite plantear una hipótesis similar a la utilizada en regresión lineal: asumir que existe una relación lineal entre las variables predictoras y la variable que se desea modelar.

Sin embargo, en lugar de modelar directamente la probabilidad, la regresión logística modela el **Logit de la probabilidad**.

La ecuación fundamental del modelo es:

$$\text{Logit}(P) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_q X_q$$

o

$$\ln\left(\frac{P(Y=1|X)}{1-P(Y=1|X)}\right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_q X_q$$

donde:

- $P(Y = 1|X) \Rightarrow$ es la probabilidad de ocurrencia del evento.
- $\beta_0 \Rightarrow$ es el intercepto del modelo.
- $\beta_1, \beta_2, \dots, \beta_q \Rightarrow$ son los coeficientes asociados a cada variable independiente.

- $X_1, X_2, \dots, X_q \Rightarrow$ son las variables independientes.

Esta ecuación establece que el el Logit de la probabilidad puede representarse mediante una combinación lineal de las variables predictoras.

¿Qué está modelando realmente el modelo?

- Es importante entender que la regresión logística no modela directamente la probabilidad. Tampoco modela directamente la clase/clasificación de la variable a predecir (0 o 1).

Lo que realmente modela es:

$$\ln\left(\frac{P}{1-P}\right)$$

Es decir, el Logit de la probabilidad .

Una vez estimados los coeficientes del modelo $(\beta_1, \beta_2, \dots, \beta_q)$, es posible calcular dicho Logit para cualquier observación nueva.

Obtención de la probabilidad

Aunque el modelo calcula el Logit de la probabilidad, lo que interesa al usuario final es la probabilidad de ocurrencia del evento.

Por ello, se despeja P de la ecuación anterior obteniendo:



$$P(Y = 1|X) = \frac{e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_q x_q}}{1 + e^{\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_q x_q}}$$

o

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_q X_q)}}$$

Esta expresión recibe el nombre de **función logística** o **función sigmoidea**.

Su característica más importante es que siempre produce valores comprendidos entre 0 y 1, independientemente de los valores que tome la combinación lineal de las variables predictoras.



Gracias a esta propiedad, el resultado puede interpretarse directamente como una probabilidad.

Ejemplo: Supongamos que se desea estimar la **probabilidad de compra** de un cliente utilizando dos variables:

- X_1 : *Edad*
- X_2 : *Tiempo de permanencia en el sitio web*

Luego del entrenamiento, el modelo obtiene:

$$\ln\left(\frac{P}{1-P}\right) = -2 + 0.03X_1 + 0.15X_2$$

Para un cliente de 30 años que permaneció 20 minutos en el sitio:

$$\text{Logit}(P) = -2 + 0.03(30) + 0.15(20)$$

Aplicando la **función logística**:

$$P = \frac{1}{1 + e^{-1.9}}$$

$$P = 0.87$$

Por lo tanto, la probabilidad estimada de compra es del 87%

Clasificación final

Una vez obtenida la probabilidad, es necesario decidir a qué clase asignar la observación.

Habitualmente se utiliza un **umbral de clasificación**.

Por ejemplo:

- Si $P \geq 0.5 \Rightarrow \text{Clase 1}$

- Si $P < 0.5 \Rightarrow \text{Clase 2}$

Sin embargo, **el valor del umbral** puede **modificarse** según las **necesidades del problema** y los **criterios de evaluación seleccionados**.

Test de hipótesis: prueba de ómnibus de coeficientes ¿Hay modelo o no?

Antes de confiar en el modelo de regresión logística, se realiza un test de hipótesis para verificar si las variables independientes en conjunto explican o no a la variable dependiente.

- $H_0(\text{nula}): \beta_i = 0, \forall i \Rightarrow$ las variables independientes no explican a la variable dependiente.
- $H_1(\text{alternativa}):$ Hay algún i tal que $\beta_i \neq 0$

Se rechaza H_0 si el $p - \text{value}$ es menor que el nivel de significación α (generalmente 0.05).

Rechazar H_0 es deseable, significa que las variables independientes del modelo explican la variable dependiente.

Como validarlo en SPSS Statistics (Test de ómnibus de coeficientes):

- Ir a Analizar $\rightarrow$ Regresión $\rightarrow$ Logística Binaria
- Pasar las variables independientes y dependiente
- El sistema genera el tests automáticamente

Pruebas ómnibus de coeficientes de modelo

		Chi-cuadrado	gl	Sig.
Paso 1	Paso	56,903	4	,000
	Bloque	56,903	4	,000
	Modelo	56,903	4	,000

En la fila correspondiente al **modelo** tenemos que la significancia (p-value) es menor a 0.05.

Por lo tanto, **podemos rechazar la hipótesis nula** y concluir que las variables independientes explican a la variable dependiente.

Análisis de significancia de cada variable independiente

Luego de realizar este **test del conjunto**, debemos hacer el **análisis de cada una de las variables**. Ya que podría darse el caso de tener 10 variables y que solo 1 de ellas tenga significancia sobre la dependiente. En ese caso, el conjunto explica a la dependiente, pero hay 9 variables que no lo hacen.

Dicha análisis lo hacemos con la tabla de **"Variables de la ecuación"**, que por cada variable, muestra el test de hipótesis:

Variables en la ecuación

		B	Error estándar	Wald	gl	Sig.	Exp(B)
Paso 1 ^a	Años de Educación	,119	,041	8,169	1	,004	1,126
	Edad en años	,058	,009	45,978	1	,000	1,060
	Horas de TV por Día	,058	,058	1,013	1	,314	1,060
	Número de Afiliaciones	-,001	,065	,000	1	,983	,999
	Constante	-4,107	,784	27,482	1	,000	,016

a. Variables especificadas en el paso 1: Años de Educación, Edad en años, Horas de TV por Día, Número de Afiliaciones.

Vemos que las variables **Años de educación** y **Edad** explican a la variable ya que $Sig. < 0.05$, mientras que las variables **Horas de TV por Día** y **Número de Afiliaciones** no explican a la variable ya que $Sig. > 0.05$.

Por ende eliminamos las **Horas de TV por Día** y **Número de Afiliaciones** **de a una a la vez**. Es importante hacerlo de a una, ya que quizás una variable pasa a explicar la dependiente porque al cambiar el modelo.

En este caso eliminaremos primero la variable **Número de Afiliaciones**.

Omnibus Tests of Model Coefficients				
		Chi-square	df	Sig.
Step 1	Step	57.592	3	.000
	Block	57.592	3	.000
	Model	57.592	3	.000

Tras realizar de nuevo el modelo vemos que el conjunto de variables independientes sigue explicando la variable dependiente.

Variables in the Equation

		B	S.E.	Wald	df	Sig.	Exp(B)	95% C.I. for EXP(B)	
								Lower	Upper
Step 1 ^a	Años de Educación	.120	.041	8.484	1	.004	1.127	1.040	1.222
	Edad en años	.058	.009	46.411	1	.000	1.060	1.042	1.078
	Horas de TV por Día	.057	.058	.976	1	.323	1.059	.945	1.185
	Constant	-4.138	.782	27.991	1	.000	.016		

a. Variable(s) entered on step 1: Años de Educación, Edad en años, Horas de TV por Día.

Podemos observar que el p-value ($Sig. > 0.05$) de la variable **Horas de TV por Día** sigue siendo mayor que 0.05, por lo que concluimos que sigue sin explicar la variable dependiente, y debemos **eliminarla del modelo**.

Omnibus Tests of Model Coefficients				
		Chi-square	df	Sig.
Step 1	Step	58.015	2	.000
	Block	58.015	2	.000
	Model	58.015	2	.000

Variables in the Equation								
		B	S.E.	Wald	df	Sig.	Exp(B)	95% C.I. for Exp(B) Lower Upper
Step 1 ^a	Años de Educación	.108	.039	7.658	1	.006	1.114	1.032 1.202
	Edad en años	.058	.008	47.037	1	.000	1.060	1.042 1.077
	Constant	-3.820	.690	30.643	1	.000	.022	

a. Variable(s) entered on step 1: Años de Educación, Edad en años.

Llegamos así, a un modelo en el que las dos variables (**Años de educación y Edad**) explican a la dependiente.

Obteniendo como fórmula del modelo:

$$P = \frac{1}{1 + e^{-(3.820 + 0.108Años + 0.058Edad)}}$$

Los valores β_i se observan en la primera columna de la tabla de variables.

¿Por qué realizamos las dos pruebas? (El test del conjunto y luego el test por cada variable.)

La razón es que las pruebas individuales son sensibles a la multicolinealidad. Un supuesto que se tiene que cumplir es el de **NO colinealidad** de las variables.

La multicolinealidad implica que las variables independientes en realidad no sean independientes, es decir que estén correladas entre sí.

Que los test sean sensibles a la multicolinealidad, significa que si hay multicolinealidad, muchas veces sucede que los test indican que las variables no sirven (no explican a la dependiente) por lo que habría que descartarlas, pero en realidad algunas sí sirven. Por ello, **en primer lugar se realiza el test en conjunto ya que éste es insensible y podemos determinar si el conjunto explica a la dependiente.**

Test en conjunto (ómibus) $\Rightarrow$ insensible a la multicolinealidad

Test en individuales $\Rightarrow$ sensibles a la multicolinealidad

Supuestos del Modelo

Supuestos que se tienen que cumplir para que el modelo sea bueno (supuestos basados en el error ϵ)

1. Promedio del error igual a 0 o $E(\epsilon) = 0$
2. Varianza constante del error $Var(\epsilon) = cte$
3. Distribución normal del error (porque vamos a hacer test de hipótesis con intervalos de confianza por lo que se exige normalidad)
4. No multicolinealidad de las variables. Si hay más de una variable independiente, no debe existir multicolinealidad
5. Errores independientes ϵ_i, ϵ_j independientes
6. Errores independientes de las variables explicativas VI, ϵ_j independientes

Como no conocemos el error real, vamos a trabajar con lo que se llaman **Residuos**.

Cómo observarlos en SPSS Statistics:

- Ir a Analizar → Regresión → Logística Binaria
- Pasar las variables independientes y dependiente
- En "Guardar" clickeamos "Valores pronosticados: Probabilidades" y "Residuos: No estandarizados".

Esto genera dos columnas nuevas en el dataset, una con probabilidad (PRE1) y la otra con el residuo (RES1). Siendo:

PRE1: probabilidad predicha, la que nos da el modelo.

RES1: diferencia entre el valor que tomó la variable y la probabilidad predicha por el modelo. Es el error que está cometiendo el modelo en términos de probabilidad.

(El valor que toma la variable es 0 o 1. Por lo que se pueden considerar como la probabilidad de que suceda el evento. En este caso si newchan asume valor 1, significa que acepta el ofrecimiento. Por lo tanto es la probabilidad de aceptar o no el ofrecimiento).

	edad	horas	orgs	hijos	ing	newschan	PRE_1	RES_1
1	35	1	0	1	4	1	,58923	,41077
2	25	5	0	0	1	0	,25346	-,25346
3	64	2	1	2	5	1	,80087	,19913

Ahora que tenemos los residuos, se procede a analizar los supuestos:

1. Supuesto de promedio del error igual a 0 $E(\epsilon) = 0$

$$H_0: \bar{\epsilon} = 0$$


$$H_A: \bar{\epsilon} \neq 0$$

Haciéndolo mediante gráficos

Materia: Ciencia de datos

- Creamos una variable nueva Aux asignándole todos unos (1s). (para que el gráfico arme un intervalo de confianza en un solo grupo)
- Gráficos → Generador de gráficos → Barras de error simples y colocamos en el eje y a la variable del residuo y en el eje x a la variable Aux que creamos.

Se obtiene:



Donde vemos que se obtiene media igual a 0, ya que el punto corresponde a la media y vemos que está posicionado sobre el valor de 0.

Otra forma de comprobarlo es haciendo el Test de Hipótesis, donde en la hipótesis nula decimos que la media es igual a 0 y en la hipótesis alternativa la media es distinta de 0.

Como validarlo en SPSS Statistics:

- Analizar → Comparación de medias → Prueba T para una muestra
- Variable de prueba: Residuo

Se obtiene:

Prueba para una muestra						
Valor de prueba = 0						
	t	gl	Sig. (bilateral)	Diferencia de medias	95% de intervalo de confianza de la diferencia	
					Inferior	Superior
Diferencia entre las probabilidades pronosticadas y observadas	,000	440	1,000	,00000000	-,0437484	,0437484

Donde vemos que el p-value es 1, como es mayor que 0.05 **no se rechaza la hipótesis nula.**

Recordatorio: Para la **significancia del modelo** quiero un **p-value menor** mientras que para los **supuestos** un **p-value mayor**. Esto es porque en los **supuestos** me quiero quedar con la **hipótesis nula**, mientras que en la significancia del modelo la queremos rechazar.

2. Supuesto de varianza del error constante $Var(e) = cte$

H_0 : Errores homocedásticos

H_A : Hay Heterocedasticidad

Qué la varianza (como se dispersan los datos) sea constante, implica que las campanas de Gauss del error en cualquier partición del conjunto de datos sean iguales. Si las campanas son distintas, los errores se distribuyen de forma diferente.

Para hacer ello, creamos 3 grupos en la variable Aux. Dividimos el conjunto de datos en 3, y asignamos al primer grupo el número 1, al segundo grupo el número 2, y al 3er grupo el número 3.

Hacemos el Test de Hipótesis.

Como validarlo en SPSS Statistics:

- Analizar → Comparación de medias → ANOVA de un factor
- Lista de dependientes: Residuo
- Factor: Aux
- En "Opciones...": Prueba de homogeneidad de varianzas

Se obtiene:

Prueba de homogeneidad de varianzas					
		Estadístico de Levene	gl1	gl2	Sig.
Diferencia entre las probabilidades pronosticadas y observadas	Se basa en la media	,220	2	438	,803
	Se basa en la mediana	,109	2	438	,897
	Se basa en la mediana y con gl ajustado	,109	2	361,402	,897
	Se basa en la media recortada	,218	2	438	,804


Donde, viendo el test basado en la media, vemos que el **p-value** es mayor que α (0.05) y por lo tanto se cumple el supuesto de varianza constante (las varianzas son homogéneas, constantes).

3. Supuesto de Distribución normal del error

$H_0: \epsilon \sim Normal$

$H_A: \epsilon \not\sim Normal$

Mediante el generador de gráficos, hacemos un Histograma Simple. En el eje X ponemos la variable Residuo, y mostrando la Curva Normal obtenemos:



Donde vemos que los datos **no se ajustan** a la distribución normal.

Como los gráficos son subjetivos y depende de quién los mire, vamos a hacer el Test de Hipótesis.

Como validarlo en SPSS Statistics:

- Analizar → Estadísticos Descriptivos → Explorar
- Lista de dependientes: Residuo
- En "Gráficos": Boxplots y Gráficos de normalidad con pruebas.

Se obtiene:




Gráfico de normalidad. Para que sea normal, **los puntos deberían estar todos sobre la recta.**

Por lo tanto vemos que no se cumple la normalidad. Éste gráfico nos sirve para ver qué

transformación podemos hacerle a los datos para obtener una distribución normal. Si los datos presentan una curva que se asemeja a una cuadrática, haciendo la raíz de los datos obtendríamos la distribución normal.

Pruebas de normalidad						
	Kolmogorov-Smirnov ^a			Shapiro-Wilk		
	Estadístico	gl	Sig.	Estadístico	gl	Sig.
Diferencia entre las probabilidades pronosticadas y observadas	,169	441	,000	,910	441	,000

a. Corrección de significación de Lilliefors

Tenemos dos pruebas de normalidad. En este caso miramos la de Kolmogorov-Smirnov, y vemos que el **p-value** es 0 (menor a 0.05), por lo tanto también vemos que **no se cumple el supuesto de normalidad**.

Cuidado: Para las pruebas de normalidad, cuando tenemos un test con más de **50 observaciones**, utilizamos el test de **Kolmogorov-Smirnov** mientras que si tenemos **menos** de 50 observaciones, utilizamos el test de **Shapiro-Wilk**.

4. Supuesto de no multicolinealidad (igual que en LDA)

H_0 : No hay Multicolinealidad

H_A : Hay Multicolinealidad

No queremos que haya multicolinealidad, queremos que las variables predictoras sean independientes.

Como validarlo en SPSS Statistics (Test de colinealidad):

- Ir a Analizar → Regresión → Lineales
- Pasar las variables predictoras como independientes
- Poner cualquier variable como dependiente (sólo nos interesa el diagnóstico)
- En Estadísticos. activar 'Diagnósticos de colinealidad'
- Mirar la columna 'Índice de condición' en la última fila de la tabla

En la última fila observamos

- *Índice de condición* < 20 ⇒ No hay multicolinealidad
- $20 \leq \text{Índice de condición} \leq 30$ ⇒ Multicolinealidad moderada
- *Índice de condición* > 30 ⇒ Multicolinealidad significativa

Se obtiene:

Diagnósticos de colinealidad^a

Modelo	Dimensión	Autovalor	Índice de condición	Proporciones de varianza		
				(Constante)	Edad en años	Años de Educación
1	1	2,894	1,000	,00	,01	,00
	2	,090	5,660	,01	,71	,13
	3	,015	13,827	,98	,28	,86

a. Variable dependiente: Horas de TV por Día

Miramos en la última fila, la columna de Índice de condición. En este caso es un valor menor a 20 por lo tanto decimos que no hay multicolinealidad y se cumple el supuesto.

5. Supuesto de Errores independientes


H_0 : ϵ no autocorrelados

H_A : ϵ autocorrelados

Como validarlo en SPSS Statistics:

- Ir a Analizar → Predicciones → Autocorrelaciones
- Variable: Residuo
- En Opciones. colocar 'Número de retardos = 5'

Se obtiene:



Materia: Ciencia de datos

Las líneas azules son los coeficientes de correlación. **El supuesto se cumple si dichas barras están dentro de los intervalos.** Si alguna está fuera del intervalo, no se cumple.

Autocorrelaciones

Serie: Diferencia entre las probabilidades pronosticadas y observadas

Retardo	Autocorrelación	Desv. Error ^a	Estadístico de Box-Ljung		
			Valor	gl	Sig. ^b
1	-,023	,047	,237	1	,627
2	,018	,047	,388	2	,824
3	,005	,047	,400	3	,940
4	-,005	,047	,411	4	,982
5	-,024	,047	,671	5	,985

Igualmente lo podemos comprobar con la tabla de autocorrelaciones, donde en este caso vemos que los p-value son todos mayores a 0.05 por lo tanto **se cumple el supuesto.**

6. Supuesto de Independencia entre variables explicativas y el error

H_0 : ϵ independiente de VE

H_A : ϵ no independiente de VE

Correlations

		Años de Educación	Edad en años	Difference between observed and predicted probabilities
Años de Educación	Pearson Correlation	1	-,182**	,000
	Sig. (2-tailed)		,000	1.000
	N	442	441	441
Edad en años	Pearson Correlation	-,182**	1	,000
	Sig. (2-tailed)	,000		1.000
	N	441	441	441
Difference between observed and predicted probabilities	Pearson Correlation	,000	,000	1
	Sig. (2-tailed)	1.000	1.000	
	N	441	441	441

** . Correlation is significant at the 0.01 level (2-tailed).

Donde vemos de la misma forma que para el supuesto anterior, que **los p-value son todos mayores que 0.05 por lo tanto se cumple el supuesto de independencia entre el error y las variables explicativas del modelo.**



Outliers

Otra cuestión que se debe analizar son los outliers (valores anómalos). Estos outliers, dependiendo del tipo que sean, pueden o no afectar al modelo.

Se diferencian como:

- **Puntos de balanceo:** aquellos que no modifican la predicción del modelo,
- **Puntos influyentes:** aquellos que varían la pendiente de la recta y afectan el modelo.

No podemos trabajar con ellos.



Para ver si el outlier es influyente o no, utilizamos la Distancia de Cook. Si dicha distancia es mayor a 1, consideramos al punto como influyente.

Como validarlo en SPSS Statistics:

- Ir a Analizar → Regresión → Logística Binaria
- En Guardar: marcar "De cook"

Vemos en la vista minable, una nueva variable COOK_1 donde se especifica la distancia de cook correspondiente a cada observación. **Si no hay ninguno mayor a 1, quiere decir que no hay puntos influyentes.**

Interpretación Coeficientes de Regresión Logística

- **Beta - β**

Si el β asociado a una variable X es positivo significa que al aumentar X , la probabilidad $P\left(\frac{Y=1}{X}\right)$ se incrementa, eso significa que **X favorece la aparición del evento de interés.**

En cambio, si el β asociado a una variable X es negativo, significa que al aumentar X , la probabilidad $P\left(\frac{Y=1}{X}\right)$ se decrementa, eso significa que **X perjudica la aparición del evento de interés.**

Por ejemplo:

Variables in the Equation								
		B	S.E.	Wald	df	Sig.	Exp(B)	95% C.I. for EXP(B) Lower Upper
Step 1 ^a	Años de Educación	.108	.039	7.658	1	.006	1.114	1.032 1.202
	Edad en años	.058	.008	47.037	1	.000	1.060	1.042 1.077
	Constant	-3.820	.690	30.643	1	.000	.022	

a. Variable(s) entered on step 1: Años de Educación, Edad en años.

β (Años de educación) = 0.108 $\Rightarrow$ al aumentar los años de educación, aumenta la probabilidad de contratación del pack de noticias.

- $Exp(\beta)$

Representa la razón de cambio en las probabilidades del evento de interés para un cambio de una unidad en el predictor. $Exp(\beta) = 1.114$ significa que **las probabilidades de contratar el pack aumentan un 1.114 veces para una persona que tiene 1 año más de educación, manteniendo el resto de las demás variables constantes.**

En el caso de que β sea negativo (< 0), para interpretar calculamos $\frac{1}{Exp(\beta)}$. En el ejemplo anterior, si para Edad en Años tendríamos $\beta = -0.058$ y $Exp(\beta) = 0.8$, entonces interpretamos: **por cada año más de edad, las probabilidades de contratar el pack es 1.25 veces menor, manteniendo el resto de variable constantes.**

Evaluación del modelo

Matriz de confusión

			Pronosticado		Porcentaje correcto
			Acepta el Ofrecimiento del Servicio de Noticias		
	Observado		No	Si	
Paso 1	Acepta el Ofrecimiento del Servicio de Noticias	No	160	63	71,7
		Si	87	126	59,2
		Porcentaje global			

Métricas:

$Accuracy = 65.5\%$

$Acierto\ para\ contrata\ el\ pack\ SI = 58.9\%$

$Acierto\ para\ contrata\ el\ pack\ NO = 71.8\%$

Analizando la matriz de confusión del modelo, vemos que el mismo **no es bueno ya que los porcentajes de la diagonal no son parejos.**


Curva ROC

Otra forma de analizar si el modelo es bueno o no, es realizando el análisis de la curva ROC del modelo.

Como validarlo en SPSS Statistics:

- Ir a Clasificar → Curva COR
- Variable de Prueba → Probabilidad pronosticada (PRE1)
- Variable de estado → Variable objetivo
- Marcar "Con línea diagonal de referencia" y "Puntos de coordenadas de la curva COR"

Se obtiene el gráfico, el área bajo la curva (AUC), y la tabla con las coordenadas de todos los puntos que conforman la curva.



En este caso el modelo es mayor a 0,7 por lo que el modelo puede ser útil. Como este es un modelo de iniciación, a pesar de que la matriz de confusión no sea tan buena, el modelo sirve.

Cuando analizamos el AUC, se determina que:

- Si es menor a 0.7 → El modelo es malo
- Si es mayor a 0.7 → El modelo puede ser útil
- Si es mayor a 0.8 → El modelo es bueno

Para que el modelo sea bueno, buscamos que la diagonal sea pareja, es decir, que la sensibilidad y la especificidad sean lo más cercanos/parecidos posible.

Buscamos el punto de corte donde los valores sean lo más cercanos posible. Para ello exportamos las coordenadas a un excel para poder agregar la columna de la especificidad que será 1-FPR y agregamos otra columna con la diferencia de ambas. Nos quedaremos con la coordenada que minimice dicha diferencia.

1	Coordenadas de la curva				
2	Variables de resultado de prueba: Probabilidad pronosticada				
3	Positivo si es mayor o igual que a	Sensibilidad	1 - Especificidad	Especificidad	Sensib. - Especif.
110	0,458	0,706	0,383	0,617	0,089
111	0,460	0,687	0,383	0,617	0,070
112	0,462	0,664	0,379	0,621	0,043
113	0,463	0,664	0,374	0,626	0,038
114	0,466	0,664	0,370	0,630	0,034
115	0,470	0,654	0,366	0,634	0,020
116	0,473	0,654	0,352	0,648	0,006
117	0,475	0,650	0,344	0,656	-0,006
118	0,477	0,631	0,335	0,665	-0,034
119	0,478	0,626	0,335	0,665	-0,039

Se obtiene en el ejemplo, que el umbral de 0.473 es el que tiene más parejos los valores de la diagonal, por lo tanto es el punto de corte a partir del cual me dice “está enfermo o no la persona”.

El punto de corte que usamos en árboles era 0,5 (por la pseudo-probabilidad) que era la probabilidad de que la predicción obtenida sea correcta.

Por lo tanto, **el análisis ROC en regresión logística nos permite cambiar el punto de corte, que nos va a generar una mejor predicción.**

En statistics, cuando armamos el modelo de Regresión Logística Binomial, en “Opciones.” podemos configurar el “Punto de corte para la clasificación”. Allí en nuestro caso, colocaremos 0.473, obteniendo ahora:

Observado			Pronosticado		Porcentaje correcto
			Acepta el Ofrecimiento del Servicio de Noticias		
			No	Si	
Paso 1	Acepta el Ofrecimiento del Servicio de Noticias	No	147	80	64,8
		Si	74	140	65,4
	Porcentaje global				65,1

a. El valor de corte es ,473

donde vemos que los porcentajes de acierto, o bien los valores de la diagonal, son mucho más similares que antes.

En este caso sí podemos mirar el acierto global porque la diagonal es pareja. Como es mayor al 60% y es un modelo de iniciación, podemos decir que el modelo es bueno.

Técnicas de aprendizaje no supervisado para tareas de Agrupamiento

Agrupación en clusters

Es un proceso situado en la etapa de **Minería de datos** de KDD. Y consiste en la construcción de modelos **descriptivos**, más precisamente, **de agrupamiento**.

Tareas \ Técnicas	Predictivos (supervisados)		Descriptivos (no supervisados)		
	Clasificación	Predicción	agrupamiento	Asociación	Otros
Redes Neuronales	X	X	X		
Arboles de Decisión	X	X	X	X	
Kohonen			X		
Regresión paramétrica		X			
Regresión Logística	X			X	
k means / k medioides / Jerárquicos			X		
A priori				X	
Análisis factorial					X
Análisis Discriminante	X				
Algoritmos genéticos	X	X	X	X	X
Naive Bayes	X				
Vecinos mas próximos	X	X	x		

El objetivo principal es, partiendo de la vista minable, lograr hallar grupos de objetos de manera que los objetos en un grupo sean **similares** a otros situados en el **mismo grupo** y **diferentes** a los objetos situados en **otros grupos**. Otra forma de verlo es que se buscan **patrones** o **estructuras** comunes a manera de agrupar datos.

En los datos de por sí no existe pertenencia a ninguna clase, por lo que se lo considera un método de exploración de los datos. Al igual que pertenece a los métodos de aprendizaje no supervisado.


Etapas previas a realizar Clustering

Algo que no es tenido en cuenta por muchas fuentes es la estandarización de valores. Al disponer de los valores y calcular **la distancia**, puede que valores como la “distancia de vuelo (en metros)” en un vuelo dominen por sobre “el tiempo del vuelo(en hs)”. Para solucionar esto y poder realizar un clustering apropiadamente, es necesario **estandarizar valores** con los métodos ya explicados (z-score o normalización min-max).

Cluster Jerárquico y Bietápico

Un conjunto de clusters anidados organizados como un árbol jerárquico con un clúster único arriba, agrupando todos los datos, y clusters con un solo elemento abajo.

Este método suele venir acompañado de un gráfico llamado **dendrograma**.



A partir de este gráfico se determina el punto de corte para determinar los diferentes grupos convenientes para el analista.

¿Cómo funciona el método?

- 1- En principio, **cada punto pertenece a un grupo separado**.
- 2- Se conforma una matriz **cuadrada** de distancias entre puntos. En cada celda se disponen las distancias:

Caso	Matriz de distancias						
	distancia euclídea						
	1	2	3	4	5	6	7
1	,000	,361	,500	,922	1,342	1,838	1,726
2	,361	,000	,424	,707	1,044	1,552	1,500
3	,500	,424	,000	,447	,922	1,389	1,237
4	,922	,707	,447	,000	,500	,943	,806
5	1,342	1,044	,922	,500	,000	,510	,583
6	1,838	1,552	1,389	,943	,510	,000	,400
7	1,726	1,500	1,237	,806	,583	,400	,000


- 3- Se busca el menor valor de la matriz y se procede a **unir los grupos** de los respectivos puntos. Por lo general se suprime de la matriz al punto de mayor índice y se considera que "se lo incorporó al grupo del punto de menor índice".
- 4- Se calcula el valor del centroide de este nuevo grupo conformado.
- 5- Si todos los puntos están en un mismo grupo, el método termina. Sino, se vuelve a conformar la matriz del paso 2 pero se utiliza la distancia al centroide del nuevo grupo, en vez de la distancia entre puntos.

Matriz de distancias

Caso	distancia euclídea					
	1	3	4	5	6	7
1	,000	,500	,922	1,342	1,838	1,726
3	,500	,000	,447	,922	1,389	1,237
4	,922	,447	,000	,500	,943	,806
5	1,342	,922	,500	,000	,510	,583
6	1,838	1,389	,943	,510	,000	,400
7	1,726	1,237	,806	,583	,400	,000

Dendrograma

El **dendrograma** es un gráfico propio de la clusterización jerárquica. Muestra la **evolución del proceso de clusterización** y los **instantes de comparación de distancias** en los que se unen los diferentes grupos.



En este gráfico en particular podemos ver que la primera "unión de grupos" se realiza entre el grupo que contiene inicialmente a la observación 1 y el grupo que contiene inicialmente a la observación 2, además evidencia que estas dos observaciones tenían una cercanía de ≈ 2 .

Criterios de aglomeración

Si bien luego veremos los tipos de distancia que pueden utilizarse para obtener diferentes resultados aplicando el método, también pueden verse los criterios de aglomeración que definen **"desde que" punto del grupo se mide la distancia**.


- **Encadenamiento simple:** La distancia entre grupos se define como la del par de individuos que están más cercanos.




- **Encadenamiento completo:** La distancia entre grupos se define como la mayor distancia entre pares de individuos, uno de cada grupo.




- **Encadenamiento promedio:** La distancia entre dos grupos se define como la distancia media entre todos los pares de individuos de cada grupo.



- **Método del centroide:** Los grupos se representan por los vectores de medias y las distancias entre los grupos se definen en términos de las distancias entre vectores de medias.



- **Método de Ward:** Se determinan los centros de los clusters y las distancias entre los individuos y el centro de cada cluster. Si se fusionan los grupos, la distancia desde las observaciones hasta el nuevo centro del grupo aumenta. El algoritmo identifica los dos grupos donde el incremento de distancias es menor.



Para el caso de las variables binarias se utiliza el coeficiente de Tanimoto, utilizando la tabla de contingencia. En base a ella, se comparan los dos objetos y se determinan la cantidad de comparaciones que dan como resultado a , b , c y d para luego aplicar la siguiente fórmula:

$$S_{ij} = \frac{a}{a+b+c}$$

Tabla de Contingencia

		Object 2	
		1	0
Object 1	1	a	b
	0	c	d

Medidas de proximidad

Determina el **cómo** se mide la distancia habiendo definido los puntos.


- **Distancia Euclídea:** $D_{ij} = \sqrt{\sum_{k=1}^p (X_{ik} - X_{jk})^2}$
 - No soporta cambios de escala
- **Distancia euclídea estandarizada:** $D_{ij}^2 = \frac{\sum_{k=1}^p (X_{ik} - X_{jk})^2}{S_k}$ siendo s_k la desviación típica de la variable k-ésima
 - Invariante al cambio de escala
- **Distancia de Mahalanobis:** $D_{ij} = \sqrt{(X_i - X_j)' \cdot S^{-1} \cdot (X_i - X_j)}$ siendo S la matriz de covarianzas dentro del grupo.
 - Invariante al cambio de escala
 - **Funciona mejor para observaciones distribuidas de manera normal**

Clustering No Jerárquico

El método consiste en, habiendo predefinido un número k de clusters, buscar los centroides que mejor representan a los datos separados en esos k grupos.

Quizás la diferencia más notoria con el clustering jerárquico es la necesidad de predefinir un número discreto k que representa la cantidad de clusters.

Algoritmo K-medias



Se procede a explicar el esquema, de entrada es necesario entender que previo a comenzar el algoritmo, se fija el número de grupos con el que se trabajará, denotado por la letra k .

En base a esto se determinan k puntos aleatorios, los cuales representan a los "puntos iniciales de los centroides". Acto seguido, se mide la distancia de cada observación a cada centroide y se asigna el grupo del centroide con el que la observación tenga menor distancia. Luego de terminar de clasificar todos los puntos, se recalculan los centroides teniendo en cuenta los puntos que ahora forman parte de cada grupo.

Se repite el proceso de medición y asignación de puntos basadas en centroides para ver si alguno de estos cambia de grupo. De no haber cambios de grupo, se finaliza el proceso.

Método del Codo (Elbow Method): No existe una forma cuantitativa de determinar el mejor valor de k . Sin embargo, podemos utilizar este método como una herramienta orientativa para estimar el número óptimo de clusters (k) en K-Means. Consiste en graficar la **Suma de Cuadrados Dentro del Cluster** (WCSS) contra diferentes valores de k ; el "codo" de la curva indica un punto de inflexión donde añadir más clusters no reduce significativamente la WCSS.




Gráfico de análisis de silueta (evaluar la calidad del cluster)

El gráfico de silueta es una herramienta visual que permite evaluar la calidad de una solución de clustering y determinar el número óptimo de grupos. Muestra una medida de la proximidad de cada punto de un cluster a los puntos de los clusters vecinos, con un rango de valores entre -1 y 1.


Para cada observación, el valor de silueta se interpreta de la siguiente manera:

- Cercano a +1 → la observación está bien clasificada, lejos de los clusters vecinos.
- Igual a 0 → la observación está en la frontera de decisión entre dos clusters vecinos.
- Negativo → la observación podría haber sido asignada al cluster equivocado.



El coeficiente de silueta global es el promedio de todos los valores individuales. Las observaciones de cada cluster se ordenan de mayor a menor según su valor, generando la forma descendente característica del gráfico. El grosor de cada franja representa el tamaño del cluster — franjas muy delgadas indican pocos casos, señal de que K podría ser demasiado grande.

Para elegir el número óptimo de clusters se corre el análisis con distintos valores de K y se compara el coeficiente promedio. Una mala elección de K se identifica por la presencia de clusters con puntuaciones inferiores al promedio general y por amplias fluctuaciones en el tamaño de las franjas.



Silhouette analysis for KMeans clustering on sample data with $n_clusters = 2$





Silhouette analysis for KMeans clustering on sample data with $n_clusters = 3$



Silhouette analysis for KMeans clustering on sample data with $n_clusters = 4$





K=3, K=5 y K=6 son malas elecciones porque presentan clusters con puntuaciones por debajo del promedio y franjas de tamaño muy desigual. El análisis resulta ambivalente entre K=2 y K=4: K=2 tiene el coeficiente más alto pero agrupa subconglomerados naturales en uno solo, generando una franja muy gruesa y desbalanceada. K=4 tiene un coeficiente algo menor pero todas las franjas son de grosor similar, indicando clusters más equilibrados en tamaño. En este caso la solución de K=4 sería la más razonable porque combina un buen coeficiente con clusters bien balanceados.

Análisis de componentes principales

Es un proceso realizado en la fase de **selección, limpieza y transformación de los datos** de KDD, si bien puede parecer un modelo no se lo considera dentro de la fase de Modelado. Además se la considera una **técnica descriptiva**.

El objetivo es *dada una matriz de datos de dimensiones $n \times p$ que representa los valores de p variables en n individuos, investigar si es posible representar los individuos mediante r variables ($r < p$) con poca (o en lo posible, ninguna) pérdida de información. Es decir, **reducir la dimensión de los datos**.*

El análisis de componentes principales permite reducir la dimensionalidad a través de la correlación de variables, por lo que será necesario contar con:

- Variables numéricas
- Variables correladas

Como resultado, ACP da un dataset donde:

- Cada **columna** es un componente principal en vez de una variable original
- Cada **fila** sigue siendo una observación
- La diferencia es que los valores ya no son los originales si no los de los valores de cada componente

¿En qué consiste?

El método consiste en generar nuevas variables que resulta como **combinación lineal de las variables originales**, de esta manera:

$$\begin{aligned}z_1 &= a_{11}X_1 + a_{12}X_2 + a_{13}X_3 + \dots + a_{1p}X_p \\z_2 &= a_{21}X_1 + a_{22}X_2 + a_{23}X_3 + \dots + a_{2p}X_p \\&\dots \\z_p &= a_{p1}X_1 + a_{p2}X_2 + a_{p3}X_3 + \dots + a_{pp}X_p\end{aligned}$$

Si bien se codifican p variables nuevas, la idea es buscar r variables del estilo Z_i que conserven la misma o la mayoría de la información (siendo $r < p$).

Las nuevas variables tienen



$$E(Z_i) = 0 \text{ y } S^2(Z_i) = \lambda_i$$

Podemos destacar que estas nuevas variables entonces:

- Conservan la variabilidad inicial

- La proporción de variabilidad explicada por un componente es el cociente entre su valor propio y la suma de los valores propios de la matriz
- Están incorreladas

Hay una lógica geométrica detrás del proceso en donde a partir de las correlaciones entre variables, se buscan nuevos ejes obtenidos mediante una rotación del sistema de coordenadas original. El primer eje se orienta en la dirección de máxima variabilidad de los datos; los siguientes son perpendiculares al anterior y explican la mayor variabilidad restante.



Paso a paso

1. Se analizan las variables originales y, si están en distintas escalas, se las estandariza para que todas tengan media 0 y desvío estándar 1.
2. Se calcula la matriz de correlaciones (o covarianzas) para estudiar cómo se relacionan las variables entre sí.
3. A partir de esa matriz se obtienen los componentes principales, que pueden interpretarse como nuevos ejes generados por combinaciones lineales de las variables originales. Estos ejes se orientan en las direcciones donde los datos presentan mayor variabilidad.
4. Los componentes se ordenan según la cantidad de variabilidad explicada. Generalmente se conservan los primeros componentes, ya que concentran la mayor

parte de la información, permitiendo reducir la dimensionalidad con una pérdida mínima de información.

¿Cuántas componentes (r) deberíamos elegir?

Depende del % de variabilidad que deseamos conservar. Cabe notar que en el caso de haber trabajado el método de componentes principales con variables que originalmente no presentaban una correlación notable, terminaremos eligiendo un $r \simeq p$ pues las componentes no tendrán correlación de la que valerse para simplificar las variables.

Cada componente principal tiene asociado un autovalor λ , que representa la cantidad de variabilidad explicada por dicho componente. El valor λ se obtiene a través de resolver la ecuación: $|R - \lambda \cdot I| = 0$, siendo R la matriz de correlaciones

Componente	λ	% explicado	% acumulado
1	7,45	57,34%	57,34%
2	2,14	16,46%	73,80%
3	1,25	9,59%	83,39%
4	0,63	4,85%	88,24%
5	0,51	3,92%	92,16%
6	0,32	2,49%	94,65%
7	0,27	2,11%	96,77%

En el gráfico podemos ver que con tan solo 2 componentes principales podemos conservar el 73% de la variabilidad de los datos. El % explicado se obtiene haciendo el valor de $\frac{\lambda_i}{\sum_{i=1}^n \lambda_i}$.

Beneficios del análisis de componentes principales

- Reducir dimensionalidad.
- Obtener variables **incorreladas**. Visto de otra forma, transforma las variables originales, usualmente correlación en incorreladas.
- Realizar un análisis descriptivo de los datos.
- Detectar algún outlier.

Desventajas del análisis de componentes principales

- Se pierde el análisis directo sobre las variables. Al transformar a componentes, yo no sé lo que representa cada "componente"

Formas de evaluar un algoritmo/modelo

Matriz de Confusión (tarea de clasificación)

LA MATRIZ DE CONFUSIÓN NO EXISTE EN TAREAS DE REGRESIÓN.

CUANDO LA VARIABLE A PREDECIR ES NUMÉRICA, NO EXISTE MATRIZ DE CONFUSIÓN

La Matriz de Confusión es fundamental para entender la calidad real de un **modelo predictivo**. La tasa de acierto global puede ser engañosa, la matriz de confusión revela **dónde** está acertando y dónde está fallando el modelo.

Estructura de la matriz (filas = valores reales, columnas = valores predichos):

La diagonal principal = aciertos del modelo

Fuera de la diagonal = errores del modelo.

		PREDICCIÓN			
		POSITIVO	NEGATIVO		
REAL	POSITIVO	TP TRUE POSITIVES	FN FALSE NEGATIVES	Sensitivity $\frac{TP}{(TP + FN)}$	Sensibilidad (Recall) + FNR = 1 $\frac{TP}{TP + FN} + \frac{FN}{TP + FN} = 1$
				FNR $\frac{FN}{(TP + FN)}$	
	NEGATIVO	FP FALSE POSITIVES	TN TRUE NEGATIVES	Specificity $\frac{TN}{(TN + FP)}$	Especificidad + FPR = 1 $\frac{TN}{TN + FP} + \frac{FP}{TN + FP} = 1$
				FPR $\frac{FP}{(TN + FP)}$	
		Precision $\frac{TP}{(TP + FP)}$	FDR $\frac{FP}{(TP + FP)}$	NPV $\frac{TN}{(TN + FN)}$	
		Precision + FDR = 1			

- **TP - Verdaderos Positivos.** Son los que se clasificaron como POSITIVO y que efectivamente son POSITIVO.
- **FN - Falsos Negativos.** Son los que se clasificaron como NEGATIVO pero que son POSITIVO.
- **FP - Falsos Positivos.** Son los que se clasificaron como POSITIVO pero son NEGATIVO.
- **TN - Verdaderos Negativos.** Son los que se clasificaron como NEGATIVO y efectivamente son NEGATIVO.

Métricas derivadas

1. Exactitud (Accuracy)

¿Qué mide? De cada 100 predicciones que hizo el modelo, ¿cuántas acertó en total?

¿Cuándo usarla? CASI NUNCA. Solo sirve cuando tus clases están balanceadas (50% sí, 50% no). Si tenés 95 sanos y 5 enfermos, un modelo que siempre diga "sano" tiene 95% de accuracy pero NO SIRVE para nada.

$$Accuracy = \frac{TP+TN}{TP+FN+FP+TN}$$

¿Qué tasa de acierto es buena?

Depende del dominio de aplicación

- Ciencias sociales: se considera aceptable una tasa > 60-65%. Un 72% es relativamente bueno.
- Ciencias exactas / aeroespacial / bioquímica: se requiere > 85-90% o más.

2. Precisión (Precision)

¿Qué mide? De todas las veces que el modelo dijo "Sí" (positivo), ¿cuántas fueron realmente "sí"?

Pregunta clave: "Cuando el modelo dice que algo es positivo, ¿le puedo creer?"

¿Cuándo usarla? Cuando un falso positivo (se clasifica como POSITIVO un NEGATIVO) es muy caro.

$$Precisión = \frac{TP}{TP+FP}$$

3. Sensibilidad (Recall)

¿Qué mide? De todas las personas que realmente eran "sí" (positivos reales), ¿cuántas detectó el modelo?

Pregunta clave: "El modelo, ¿se está perdiendo a muchos que realmente son positivos?"

¿Cuándo usarla? Cuando un falso negativo es muy peligroso.

$$Recall = \frac{TP}{TP+FN}$$

4. Especificidad (Specificity)

¿Qué mide? De todas las personas que realmente eran "no" (negativos reales), ¿cuántas identificó correctamente?

Pregunta clave: "El modelo, ¿sabe reconocer bien a los que NO tienen la condición?"

¿Cuándo usarla? Cuando es crítico no molestar a los que están bien.

$$Specificity = \frac{TN}{TN+FP}$$

F1-Score

¿Qué hace? Junta Precisión y Recall en un solo número. Le pega fuerte a los modelos que son muy buenos en una métrica pero pésimos en la otra.

Regla de oro: Si no sabés cuál métrica usar, usá F1-score. Te cubre las espaldas cuando las clases están desbalanceadas.

$$\text{F1-Score} = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Es especialmente útil cuando hay desequilibrio entre clases.

Los 4 escenarios posibles

Escenario	Precisión	Recall	¿Qué significa?	¿Sirve?
1	ALTA	ALTA	Detecto casi todas las demoras y casi nunca gasto plata al pedo. Pasajeros contentos, presupuesto controlado.	IDEAL
2	ALTA	BAJA	Los pocos vuelos clasificados como demorados verdaderamente lo son (no gasto plata de más), pero muchos vuelos demorados se quedan sin compensación. Presupuesto bajo pero pasajeros enojados, reputación dañada.	Sirve cuando las consecuencias de no detectar demorados son bajas o los demorados son pocos
3	BAJA	ALTA	Atiendo a casi todos los demorados... pero estoy regalando vouchers y salas VIP incluso en vuelos en hora. Presupuesto por las nubes, pero reputación buena.	Sirve si perder un cliente es más caro que el voucher o la sala vip
4	BAJA	BAJA	Gasto plata y encima los pasajeros demorados se quedan sin compensación. Lo peor de ambos mundos.	Inservible

Interpretación conjunta de precisión y recall

- Usá accuracy solo con dataset balanceados
- Usá F1-Score cuando hay desbalance
- Prioriza recall si no podés permitirte falsos negativos
- Prioriza precision si los falsos positivos son costosos
- Usa especificidad cuando identificar correctamente los negativos sea crítico

Lectura de la matriz de confusión

La forma correcta de leer la matriz es clase por clase, verificando que para cada valor real, la mayoría de las observaciones caigan en la celda predicha correcta.

Ejemplo:

- Para los que realmente son FIELES: ¿la mayoría fueron predichos como fieles? Si sí, el modelo es bueno prediciendo esta clase.
- Para los que realmente son INFIELES: ¿la mayoría fueron predichos como infieles? Si no, el modelo falla en esta clase, aunque la tasa de acierto global sea alta.

Ejemplo del profesor: un modelo con 70% de acierto puede ser malísimo si predice correctamente los fieles pero clasifica a casi todos los infieles como fieles. La tasa de acierto no detecta esto, pero la matriz de confusión sí.

		Predicho				
R e a l		Bueno		Malo		Total
	Bueno	3168		43		3211
	Malo	573		333		906
	Total	3741		376		4117

El porcentaje de aciertos global:

$(3168+333)/4117= 85,04\%$.

Este modelo no es bueno, ya que la mayoría de los que eran malos, los predijo como buenos.

Relación entre Desbalance de Clases y Matriz de Confusión

Cuando la variable predicha está desbalanceada (ej. muchos más fieles que infieles), el modelo tiende a predecir mejor la clase mayoritaria y a cometer más errores en la clase minoritaria. Esto es una causa habitual de matrices de confusión 'asimétricas'.

Matriz de Costos

Se usa **cuando los errores** del modelo **no tienen el mismo impacto**, equivocarse en una dirección puede ser mucho más grave que en la otra.

La matriz de costos se construye con información del dominio del problema (proporcionada por el cliente o investigador). Sin información del dominio, no se puede construir una matriz de costos

La evaluación por costos es complementaria a las métricas derivadas de la matriz de confusión que seleccionemos para evaluar el modelo. Si se puede hacer, aportará interpretabilidad a los resultados predictivos del modelo.

Cómo se Calcula el Costo Total

La evaluación por costos implica:

- 1. Primero:** definir la matriz de costos, asignando mayor peso (costo) a los errores más graves según el dominio del problema.
- 2. Segundo:** multiplicar la matriz de confusión por la matriz de costos elemento a elemento (no es multiplicación matricial, es multiplicación uno a uno).
- 3. Tercero:** sumar todos los productos para obtener el costo total del modelo.

El resultado es una evaluación basada en costo en lugar de (o complementaria a) la tasa de acierto.

Ejemplo:

Matriz de costos

		Predicha	
		Si	No
Real	Si	0	0
	No	50	0

Matriz de confusión

		Predicha	
		Si	No
Real	Si	5, 7, 9, 10, 12, 14	3
	No	4, 6, 11, 13	1, 2, 8

$$\text{Costo total} = 1 \cdot 0 + 4 \cdot 50 = 200$$

Receiver Operating Characteristic (ROC) y Area Under the Curve (AUC)

<https://codificandobits.com/tutorial/clasificacion-curva-roc-auc/>

Hemos visto cómo usar la matriz de confusión o las métricas precision, recall y F-score para caracterizar el desempeño de un clasificador.

Sin embargo, en ocasiones el clasificador hace uso de un **umbral** (es decir una cantidad numérica) que **permite asignar una u otra categoría a un dato**. Y el desempeño de dicho clasificador dependerá precisamente del umbral seleccionado.


Lo que sucede en estos casos es que tanto la matriz de confusión, como sus métricas asociadas: precision, recall o F-score, dependerán de dicho umbral. Así que no resulta práctico calcular múltiples valores de estas métricas para determinar cuál es el umbral adecuado.

Entonces veremos qué son y cómo interpretar la curva ROC (Receiver Operating Characteristic) y el AUC (Area Under the Curve) que permiten evaluar el desempeño de clasificadores binarios cuando el umbral de decisión puede variar.

Motivación

En ocasiones, al realizar tareas de clasificación binaria, el modelo implementado requiere la definición de un umbral que en últimas se usa para determinar si un dato pertenece a una u otra categoría.

Para entender esto hagamos uso de un set de datos muy simple que contiene 50 datos pertenecientes a la categoría 0 y 50 datos pertenecientes a la categoría 1. Cada dato contiene sólo una característica.



El dataset con datos de dos categorías (puntos azules y puntos rojos). El umbral ideal de $x=0.5$ permite clasificar adecuadamente las dos agrupaciones.

Como vemos en este gráfico, el umbral de $x=0.5$ permite:


- Clasificar como datos azules (categoría 0) los puntos que estén a la izquierda de dicho umbral
- Clasificar como datos rojos (categoría 1) los puntos que estén a la derecha de dicho umbral

Sin embargo, vemos que la separación entre las dos agrupaciones no es perfecta pues en esta ubicación algunos puntos rojos quedarán a la izquierda del umbral mientras que otros puntos azules quedarán a la derecha. A pesar de esto podemos decir que este umbral es ideal pues es el mejor compromiso entre la cantidad de puntos de cada categoría que quedarán de uno u otro lado del umbral.

Pero, **¿qué ocurriría si movemos este umbral ligeramente a la izquierda o a la derecha de este valor ideal?**

Analicemos cada situación en detalle:

- Supongamos que movemos el umbral a la izquierda del valor ideal, digamos a $x = 0.4$. En este caso podemos ver que prácticamente ningún punto de color rojo queda a la izquierda de este umbral. Sin embargo, no todos los puntos azules quedarán dentro de esta región.




Umbral: 0.4

TPR: 100.0%

FPR: 30.0%

- Ahora supongamos que el umbral se mueve a la derecha del valor ideal, digamos a $x=0.6$. En este caso tenemos una situación similar al caso anterior: prácticamente ningún punto azul quedará a la derecha del umbral, pero no lograremos clasificar correctamente la totalidad de los puntos rojos.



Umbral: 0.6

TPR: 66.0%

FPR: 0.0%

Entonces **¿cómo escogemos el umbral más adecuado para nuestro clasificador?**

Acá es donde entran en juego estos tres elementos: el TPR, el FPR y el umbral.

La idea es ver cómo cambia este compromiso entre la TPR y la FPR a medida que cambia el umbral. Y acá es donde aparece el concepto de la curva ROC.

La curva ROC (Receiver Operating Characteristic)


La curva ROC es una gráfica que nos permite ver **cómo cambia la TPR con respecto a la FPR a medida que cambiamos el umbral** de nuestro clasificador.

Materia: Ciencia de datos

Para construir esta gráfica simplemente repetimos el procedimiento anterior de cálculo de la TPR y la FPR para varios umbrales, tabulamos los datos y luego representamos cada par de puntos de forma gráfica: en el **eje vertical** pondremos los diferentes valores de **TPR (también conocido como sensibilidad o recall)** y en el eje horizontal los **FPR (también se puede calcular como 1-Especificidad)** correspondientes.

Y esto nos permite determinar de forma gráfica qué tan bien o mal lo hace el clasificador en términos de las tasas de verdaderos y falsos positivos.

Tras construir esta gráfica podemos tener varios tipos de comportamientos que podemos ver en la siguiente figura:



Analicemos cada una de estas posibles situaciones en detalle:

1. **Clasificador ideal (esquina superior izquierda):** un clasificador ideal tendría una TPR del 100% y una FPR del 0%. Es decir: detecta correctamente todos los positivos y no detecta incorrectamente ningún negativo. En este caso la curva ROC no sería una curva sino simplemente un punto.
2. **Clasificador aleatorio (esquina superior derecha):** un clasificador aleatorio es aquel que no es capaz de diferenciar entre categorías positivas y negativas y, por tanto, predice positivo o negativo al azar. Por tanto, TPR y FPR serán iguales





independientemente del umbral, lo cual se traduce en una gráfica ROC con una línea diagonal que va desde el punto ($FPR = 0, TPR = 0$) hasta el punto ($FPR = 1, TPR = 1$)

3. **Un buen clasificador (esquina inferior izquierda):** un buen clasificador debería tener una ROC cercana a la del **clasificador ideal**. Es decir que debería tener un sesgo hacia el punto ($FPR = 0, TPR = 1$) (pues en este caso se tendría una TPR cercana al 100% y una FPR cercana al 0%)
4. **Un mal clasificador (esquina inferior derecha):** un mal clasificador sería lo opuesto a un buen clasificador. Es decir que tendría un sesgo hacia el punto ($FPR = 1, TPR = 0$) (pues en este caso prácticamente tendría una TPR cercana al 0% y una FPR cercana al 100%, lo cual no es ideal).

AUC: área bajo la curva ROC (Area Under the ROC Curve)

La AUC es una manera equivalente de ver el desempeño del clasificador para diferentes umbrales.

En esencia esta AUC es simplemente un número que corresponde, como su nombre lo indica, al área bajo la curva de la ROC y al igual que ocurría con la ROC, en el caso de la AUC podemos tener cuatro situaciones:



Veamos en detalle cada una de estas situaciones:

- **Clasificador ideal (esquina superior izquierda):** un clasificador ideal tendrá una AUC exactamente igual a 1. Esto nos indica que la TPR será precisamente igual a 1 mientras que la FPR será exactamente igual a 0
- **Clasificador aleatorio (esquina superior derecha):** en este caso la AUC es igual a 0.5 lo cual nos indica que el modelo no tiene la capacidad de diferenciar entre categorías positivas y negativas y, por tanto, predice positivo o negativo al azar (de allí el valor de 0.5)
- **Un buen clasificador (esquina inferior izquierda):** un buen clasificador debería tener una AUC cercana al valor ideal de 1 (correspondiente con el sesgo de la ROC hacia el punto ideal $FPR = 0, TPR = 1$)
- **Un mal clasificador (esquina inferior derecha):** un mal clasificador tendrá una AUC cercana a 0 (e inferior a 0.5) lo cual indica que su desempeño es peor que el de un clasificador aleatorio.

Es importante resaltar un aspecto importante sobre la ROC y la AUC:

La ROC se construye usando diferentes umbrales, lo cual quiere decir que cada punto de la ROC es un nivel de desempeño (TPR vs. FPR) obtenido para un umbral en particular. Sin embargo, la AUC es una medida general del desempeño del modelo pues es calculada con base en la ROC que a su vez se construye considerando todos los posibles umbrales.

Elección del mejor umbral

Muy bien, en este punto ya tenemos claro qué son la ROC y la AUC y cómo estas dos herramientas nos permiten medir el desempeño general de nuestro clasificador (a través de la AUC) y para diferentes umbrales (a través de la ROC).

Así que sólo nos queda por responder una pregunta: **¿y entonces cómo elegimos el mejor umbral para un problema en particular?**

Pues la respuesta inicial es: depende. Depende del uso final que queramos darle al clasificador y si queremos priorizar los **positivos** o los **negativos** (o ambos).

Sin embargo, en el contexto de lo que hemos visto hasta este punto, una manera de elegir este mejor umbral es eligiendo **aquel umbral que nos arroje el punto más cercano a (0, 1) en la curva ROC.**

¿Por qué? Recordemos que un clasificador ideal tendrá una ROC que realmente es un punto ubicado en ($FPR = 0, TPR = 1$). Y si usamos como criterio la curva ROC ese sería precisamente el punto ideal.

La forma de hacer esto es sencilla:

1. Definimos un rango de umbrales a considerar dependiendo de las características de nuestro clasificador.
2. Por cada umbral:
 - a. Clasificamos los datos en una u otra categoría.
 - b. Almacenamos el valor del umbral y las tasas FPR y TPR correspondientes.
 - c. Calculamos la distancia de cada par de puntos (FPR, TPR) al punto ideal (0, 1):


$$distancia = \sqrt{(1 - TPR)^2 + (0 - FPR)^2}$$

3. Y luego simplemente calculamos la distancia mínima y extraemos los FPR y TPR correspondientes

Gráfico de Ganancias Acumuladas

La Curva ROC es para un usuario más técnico mientras que para un usuario más comercial usamos el **gráfico de ganancia**. La **gráfica de ganancias acumuladas** (Cumulative Gain Chart) es una herramienta de evaluación para modelos de clasificación que nos permite ver cuantas respuestas positivas o **cuántos casos positivos (éxitos, demoras, respuestas, etc.) se capturan al intervenir solo sobre un porcentaje de la población ordenada por probabilidad de ser positivos**, de mayor a menor.

El eje **X** representa el porcentaje de la población total contactada (ordenada de mayor a menor riesgo según el modelo). El eje Y representa el porcentaje acumulado de casos positivos (demoras, en este caso) que se logran detectar con esa intervención parcial.




Se comparan tres líneas:

- **Línea base (diagonal):** Representa un modelo aleatorio. Si se contacta al 30% de los registros, se captura el 30% de los casos positivos.
- **Curva del modelo real:** Muestra el rendimiento del modelo generado. Cuanto más se aleje de la diagonal hacia arriba, mejor es el modelo.
- **Línea ideal (mejor caso):** Representa un modelo perfecto que separa completamente los positivos de los negativos.

Pasos para construir el modelo de ganancia

1. Generar el modelo
2. Calcular las probabilidades de acierto (de los valores de la variable objetivo)
3. Ordenar los datos según la probabilidad de forma descendente (de mayor a menor) ya que nos enfocamos en los "clientes" de mayor probabilidad.
4. Calculamos la cantidad de aciertos (ganancia) en la muestra (cuantil) sobre la cantidad de aciertos total.
5. Graficamos el punto

Ejemplo:



1. Creamos el modelo (árbol Quest)

2. Calculamos las probabilidades (creamos la variable Probabilidad y le damos el valor segun corresponda)

Derivar campo:
Probabilidad

Derivar como: Condicional

Tipo de campo: Continuo


Si:
1 '\$R-newschan' = 'Si'


Entonces:
1 '\$RC-newschan'

En caso contrario:
1 1 - '\$RC-newschan'

3. Ordenamos de forma descendente (mayor a menor) según el campo Probabilidad.
4. Extraemos la muestra hasta dónde queremos acumular. En este caso calculamos el 30% inicial de los datos. Inicialmente tenemos 442 datos (215 "si" - 227 "no"), de los cuales extraemos los primeros 133 registros.
5. Contamos la cantidad de aciertos. (Primero ordenamos por el valor predicho por el modelo, y ahora vemos la variable original cuantos son "Si" sobre el total). De los 133 obtenidos, tenemos 90 "Si" y 43 "No", por lo tanto a partir de $90/215$ tenemos el porcentaje de "Si" dentro del primer 30% de registros, obteniendo un 41.8%.

En resumen, en el eje x tenemos los datos ordenados según la predicción del modelo (de mayor a menor probabilidad), y en el eje y la ganancia correspondiente a cada cuantil.





El mejor modelo (el modelo ideal), en este caso, nos debería dar un porcentaje de ganancia de 133 (todos "Si") dividido los 215 del total. Por lo que el modelo ideal tendría una ganancia de un 61.8 %. En la línea celeste (mejor modelo) podemos observar el par percentil-ganancia. En el caso ideal, en el 48% de los datos tendríamos el 100% de ganancia, que es cuando obtenemos todos los "Si" (215 / 442). Es decir la cantidad de "Si" sobre el total de datos. En nuestro modelo (línea roja), en ese punto (cuando tenemos el 48% de los datos), tenemos el 66% de las respuestas correctas. Y el 100% de ganancia se produce al observar el 100% de los datos.

Conclusiones del gráfico

¿Para qué me sirve este gráfico? ¿Para qué le sirve a la gente de Marketing este gráfico? Sirve para ver hasta donde dedicarle esfuerzo a la publicidad, ósea permite **transformar una predicción probabilística en una decisión operativa concreta y cuantificable**.

Llega un punto en el que se necesita publicitar a muchos clientes para poder conseguir que acepten el ofrecimiento, porque cada vez el porcentaje de "No" es mayor. Si la curva **se mantiene empinada hasta cierto punto y luego se aplana**, eso señala un rendimiento marginal decreciente, es decir, que **a partir de ese umbral agregar más casos a la intervención aporta cada vez menos valor adicional**.

En el caso de 100% de ganancia, a partir de ese punto ya nadie dice que "Si", ya tenemos todas las respuestas correctas y de nada sirve seguir haciendo publicidad. Por lo que el gráfico permite decidir hasta dónde invertir para conseguir más clientes que acepten el ofrecimiento.

Materia: Ciencia de datos

En nuestro caso, vemos que solo con el 30% de los clientes conseguimos obtener al 41.8% de los que iban a responder que aceptaban el ofrecimiento.

El gráfico de ganancia lo podemos usar cuando tenemos alguna forma de obtener las **probabilidades de ocurrencia del evento de interés en el modelo**, y cuando el evento de interés sea del **tipo categórico**, ya que si es del tipo numérico no podemos realizar el gráfico.

Información útil y recomendaciones dadas en clase

Qué Hacer Cuando el Modelo No Es Bueno

Antes de 'tirar la toalla', existen múltiples recursos que el analista puede aplicar. El Data Science es un proceso artesanal que requiere creatividad y perseverancia.

1. Cambiar los parámetros del árbol de decisión (profundidad, poda, confidence factor).
2. Probar otra técnica predictiva (KNN, análisis discriminante, etc.).
3. Volver a la fase de preprocesamiento y transformar los datos:
 - a. Crear nuevas variables (ej. dividir edad en grupos etarios).
 - b. Recodificar variables (ej. convertir escala 1-5 en binaria: poco feliz / muy feliz).
 - c. Probar combinaciones de variables como nuevos atributos.
4. Buscar más datos: más observaciones o más variables.

Si luego de agotar todos los recursos el modelo no mejora, se entrega el mejor modelo obtenido, aclarando su tasa de acierto y las limitaciones encontradas.

Desbalance de la Variable Predicha

Cuando la variable predicha tiene clases muy desbalanceadas (ej. 75% fieles vs. 25% infieles), suele ser mas difícil predecir la clase minoritaria (infieles). El modelo 'conoce' menos ejemplos de la clase minoritaria y por eso la predice peor.

- Esto es normal en muchos dominios: detección de fraudes, diagnósticos médicos raros, etc.
- Existen técnicas específicas para trabajar el balanceo de clases.

Buenas Prácticas al Documentar el Análisis

Siempre combinar Gráficos con Datos Numéricos

Cada gráfico debe estar acompañado de los estadísticos que lo avalan:

- Si se presenta un histograma → incluir la media, la mediana y el desvío estándar.
- Si se presenta un diagrama de dispersión → incluir el coeficiente de correlación entre las variables.
- Si se presenta un boxplot → indicar los valores de los cuartiles.

Cuidado: Nunca presentar un gráfico sin el respaldo numérico, ni un estadístico sin el gráfico que lo ilustre. Ambos se complementan y se validan mutuamente.

Cuidado con las Afirmaciones


Al extraer conclusiones de los gráficos:

- Verificar que la afirmación se aplique solo en la dirección en que se observa (la inversa puede no ser válida).
- Considerar siempre si hay variables de clase no tenidas en cuenta que puedan influir en el resultado.
- Documentar todas las decisiones tomadas (sobre outliers, datos ausentes, transformaciones) junto con su justificación.
- Indicar los estadísticos exactos que sostienen cada conclusión.

Cómo usar un modelo para nuevos datos en SPSS STATISTICS?

Para aplicar un modelo de regresión logística hecho en Statistics a un nuevo conjunto de datos para poder hacer las predicciones, es decir, para implementar el modelo en producción debemos hacer:

- Al crear el modelo, exportamos el XML.
 - Guardar → Exportar información del modelo a un archivo XML.



- Luego una vez abierto el nuevo conjunto de datos en Statistics
 - Utilidades → **Asistente de puntuación**
 - Cargar el modelo XML → Verificar que los campos coincidan → en la función "Probabilidad de categoría seleccionada" poner cualquier valor (0 o 1) → finalizar
- Finalmente tendremos una nueva fila "**PredictedValue**" con las predicciones del nuevo conjunto de datos

 Asistente de puntuación ✕

Nombre de modelo: LDA_TP

Tipo de modelo: DA

Seleccione funciones de puntuación:

Cada función seleccionada creará un campo nuevo en el conjunto de datos.

	Función	Nombres de campo	Valor
☒	Valor pronosticado	PredictedValue	
☒	Probabilidad de la categorías pron...	PredictedProbability	
☒	Probabilidad de categoría seleccion...	SelectedProbability	0 1

< Anterior

Siguiente >

Finalizar

Cancelar

Ayuda

En este paso seleccionar cualquier valor.