


UNIVERSIDAD TECNOLÓGICA NACIONAL REGIONAL ROSARIO



Trabajo Práctico Integrador: Gestión proactiva de demoras aéreas

INTEGRANTES:

- 51018 - Ivanisky, Macarena
- 48095 - Conti, Luca
- 51606 - Jeandrevin, Kimey
- 51922 - Mondino, Juan Cruz
- 46934 - Trucco, Rafael
- 46132 - Arce, Elias

COMISIÓN: 501 - Turno mañana

Profesores:

- Di Carlo, Martina
- Bigatti, Cristian

ASIGNATURA: Ciencia de Datos

FECHA: 26/06/26

Abstract	5
Objetivos	5
Análisis y desarrollo	6
Fase de entendimiento de negocio	6
Definición del problema:	6
Objetivos de Negocio:	6
Objetivos de minería de datos:	6
Criterios de rendimiento de minería de datos	7
Elaboración de un plan para el proyecto	7
Fase de entendimiento de los datos	7
Descripción de los datos:	7
Preparación de los datos	10
Análisis exploratorio de los datos (Vuelos)	10
Condiciones climáticas	11
Congestión aérea	11
Tipo avión	12
Demora	12
Hora salida programada	13
Minuto salida programada	13
Aeropuerto de origen	14
Aeropuerto de destino	15
Puerta embarque	16
Temporada alta	16
Dia de semana	17
Análisis Univariado	17
Histogramas y boxplot	17
Histograma de la distancia de vuelo	17
Boxplot de la distancia de vuelo	18
Histograma de la visibilidad	18
Boxplot de la visibilidad	19
Histograma del tiempo estimado de vuelo	19
Boxplot del tiempo estimado de vuelo	20
Histograma de la ocupación	20
Boxplot de la ocupación	21
Histograma de las horas de salida	21
Boxplot de las horas de salida	22
Boxplot de los minutos de salida	22
Gráfico de barras	23
Cantidad de vuelos según condición climática	23
Cantidad de vuelos según congestión aérea	23
Cantidad de vuelos según tipo de avión	24
Cantidad de vuelos demorados y no demorados	24
Cantidad de vuelos según el país de origen	25
Cantidad de vuelos según el país de destino	25
Cantidad de vuelos según temporada alta	26
Cantidad de vuelos por puerta de embarque	26
Cantidad de vuelos por día de semana	27
Matriz de covarianzas	27

Matriz de correlaciones	28
Scatterplot	28
Distancia vuelo vs Tiempo estimado vuelo	28
Boxplots Estratificados	29
Visibilidad según condición climática	29
Visibilidad según si hubo o no demora	30
Distancia de vuelo según tipo de avión	30
Ocupación del vuelo según país de origen	31
Ocupación del vuelo según si hubo o no demora	32
Distancia del vuelo según si hubo o no demora	32
Tiempo estimado del vuelo según si hubo o no demora	33
Ocupación del vuelo según día de semana	33
Ocupación del vuelo según si hay temporada alta	34
Gráficos de barras estratificados	35
Cantidad de demoras según condición climática	35
Cantidad de demoras según día de semana	35
Cantidad de demoras según congestión aérea	36
Cantidad de congestiones según temporada alta	36
Cantidad de demoras según el tipo de avión	37
Cantidad de demoras según país de origen	37
Cantidad de demoras según país de destino	38
Fase de Preparación	38
Vista Minable	38
Fase de Modelado	39
Árboles de Decisión	39
Python	39
Modeler	41
KNN	43
Python	43
Análisis de Discriminante	44
Comprobación de supuestos para los datos de train	44
Ausencia de multicolinealidad	44
Análisis de la distribución normal en las variables	45
Análisis de homogeneidad de matrices de covarianza	46
Diferencia significativa entre medias	47
Suma de minutos	48
Ejecución de clasificación por discriminante	49
Validación del modelo con los datos de test	50
Regresión Logística	51
Comprobación de supuestos	51
Identificación de outliers	55
Ejecuciones de la Regresión Logística	55
Conclusión sobre el modelo predictivo	56
Etapas de agrupamiento	57
Análisis exploratorio de los datos (Clientes)	57
Sexo	58
Provincia	59

Ocupación	60
Clase preferida	60
Programa Millas	61
Canal de compra	61
Análisis Univariado	62
Histogramas y boxplot	62
Histograma de la edad del cliente	62
Boxplot de la edad del cliente	62
Histograma de la cantidad de vuelos del cliente	63
Boxplot de la cantidad de vuelos del cliente	63
Histograma del gasto acumulado del cliente	64
Boxplot del gasto acumulado del cliente	65
Histograma del gasto acumulado extra del cliente	65
Boxplot del gasto acumulado extra del cliente	66
Histograma de la cantidad de millas del cliente	66
Boxplot de la cantidad de millas del cliente	67
Histograma del ingreso mensual del cliente	67
Boxplot del ingreso mensual del cliente	68
Histograma de días anticipación promedio de compra de los clientes	68
Boxplot de días anticipación promedio de compra de los clientes	69
Gráficos de barras	69
Cantidad de pasajeros según sexo	69
Cantidad de pasajeros por provincia	70
Cantidad de pasajeros según ocupación	71
Cantidad de pasajeros según clase preferida	71
Cantidad de pasajeros afiliados y no afiliados al programa millas	72
Cantidad de pasajeros según el canal de compra	72
Análisis Multivariado	73
Matriz de covarianzas	73
Matriz de correlaciones	73
Scatterplots	74
Scatterplot de Cantidad de vuelos vs Gasto acumulado	74
Scatterplot de Cantidad de vuelos vs Gasto acumulado extra	74
Scatterplot de Cantidad de vuelos vs Cantidad de millas	75
Fase de Preparación	76
Vista Minable	76
Análisis de Componentes Principales	77
Fase de Modelado	80
Clustering Jerárquico	80
Clustering Bietápico	81
Clustering No Jerárquico	83
Conclusión	84
Decisión de negocio	85

Abstract

Este trabajo aborda un caso de estudio de la aerolínea DS Airlines, la cual enfrenta una problemática en cuanto a la insatisfacción del cliente, causada por las demoras imprevistas en los vuelos. El análisis de la misma está fundamentado por la aplicación de técnicas de minería de datos y estadística multivariante sobre una base de datos histórica de vuelos y clientes.

Se evaluaron y compararon diversos algoritmos de clasificación: árboles de decisión (CHAID, C5.0 y QUEST), KNN, análisis discriminante y regresión logística. Con el propósito de alinearse de forma estricta con el mandato institucional de minimizar costos operativos, se estableció la Precisión como la métrica principal de evaluación. De este modo, se prioriza la reducción de los falsos positivos para evitar el impacto financiero derivado de otorgar compensaciones innecesarias, utilizando el Recall como métrica secundaria y complementaria.

Tras múltiples iteraciones y ajustes, el modelo de regresión logística con punto de corte en 0,5 demostró ser el más adecuado gracias a un equilibrio entre métricas que garantiza una distribución equitativa del costo de los errores, evitando tanto el subregistro de demoras reales como el exceso de compensaciones innecesarias, alineándose con el mandato de la empresa de minimizar costos operativos.

Luego, se evaluaron métodos jerárquicos y no jerárquicos para el agrupamiento de clientes con características similares que serán afectados por demoras previstas por nuestro modelo para asignarles la compensación apropiada para cada uno.

Finalmente, se optó por el cluster bietápico, ya que es el que mejor diferencia los datos y el que presenta mejor interpretabilidad sobre los grupos.

Objetivos

El objetivo principal del trabajo es desarrollar un modelo predictivo que le permita a la aerolínea anticipar las demoras de los vuelos y clasificar pasajeros en dos categorías, VIP o estándar, para automatizar la asignación de los beneficios compensatorios según le corresponda a cada tipo de cliente, buscando minimizar los costos que conlleva asignar estos beneficios.

Además, se busca comparar la eficacia de los modelos de minería de datos utilizados y las técnicas de análisis multivariante, para poder determinar qué metodología ofrece una mayor precisión al momento de detectar los vuelos demorados y minimizar los falsos positivos, reduciendo los costos operativos que generan los mismos.

Análisis y desarrollo

Fase de entendimiento de negocio

Definición del problema:

La aerolínea DS Airlines está experimentando una baja en la satisfacción y fidelidad de los clientes debido a las demoras imprevistas de los vuelos y la falta de respuestas oportunas ante las mismas.

La propuesta de la aerolínea es ofrecer una compensación a los pasajeros afectados por las demoras mediante un voucher de comida en un restaurante del aeropuerto o bien el acceso gratuito a la sala VIP, dependiendo del tipo de pasajero.

Objetivos de Negocio:

Para esto se ha encargado un estudio con los siguientes objetivos:

- Identificar aquellos vuelos con alta probabilidad de demora
- Compensar a los clientes afectados para fomentar su lealtad y mejorar su satisfacción
- Mejorar el posicionamiento de la aerolínea en un mercado altamente competitivo
- Reducir el impacto operativo

Provisionalmente la empresa ha comentado que dado el impacto económico de los beneficios ofrecidos el modelo debe orientarse a minimizar costos.

Objetivos de minería de datos:

El problema de minería de datos es de tipo predicción, debido a que se debe predecir si un vuelo tendrá demora o no, y de tipo clasificación ya que se deberá determinar si un cliente es VIP o no.

Los objetivos del estudio que se deben cumplir son:

- Utilizar datos históricos acerca de vuelos anteriores para generar un modelo predictivo que logre anticipar si un vuelo será demorado o no.
- Utilizar datos históricos acerca de los pasajeros para generar un modelo que logre clasificar a cada pasajero como VIP o no.
- Utilizar el modelo predictivo para asignar a cada pasajero afectado por un vuelo demorado el beneficio correspondiente a su perfil.

Criterios de rendimiento de minería de datos

Para la evaluación y selección definitiva de los modelos, se definió una estructura jerárquica de métricas. Se estableció una métrica rectora alineada estrictamente con el mandato del negocio de DS Airlines que busca minimizar costos operativos, complementada por métricas secundarias que actúan como límites de control.

- **Precisión:** La utilizaremos como métrica de rendimiento principal ya que los falsos positivos significan un alto costo operativo para la empresa, al tener que asignar compensaciones a clientes los cuales su vuelo no se haya demorado realmente. Consideramos que es fundamental poder tener un modelo que tenga una alta capacidad de medir positivos que verdaderamente lo fueron.
- **Recall:** La tomamos como una medida de apoyo a la precisión, ya que representa la capacidad del modelo de detectar los vuelos que realmente tienen demora. Un valor bajo en esta medida haría que no se realicen las compensaciones correspondientes, representando un costo intangible pero significativo para la organización (pérdida de satisfacción, fidelidad y reputación de la marca).
- **Accuracy:** Resulta útil como una medida general del modelo. Permite evaluar si el costo total de los errores, tanto falsos positivos como falsos negativos, se mantiene en niveles aceptables.

Elaboración de un plan para el proyecto

El proyecto se estructura bajo la metodología CRISP-DM, un marco que aporta una planificación tanto flexible como alineada a los objetivos estratégicos del negocio. Bajo este enfoque, respetar la secuencialidad de las fases resulta crucial; sólo así se garantiza un entendimiento integral del negocio y de los datos de manera previa al desarrollo del modelo predictivo.

Fase de entendimiento de los datos

Contamos con 3 archivos formato Excel de donde obtendremos los datos que usaremos para el modelado del agente inteligente:

- **Clientes.xlsx:** cuenta con 14 columnas y 50000 registros.
- **Vuelos.xlsx:** cuenta con 15 columnas y 15000 registros.
- **CasosNuevos.xlsx:** cuenta con 14 columnas y 5000 registros en la primera hoja, mientras que en la segunda hoja hay 2 columnas y 356416 registros.

Descripción de los datos:

Para los vuelos se cuenta con los siguientes datos:

- **id_vuelo:** Identificador del vuelo - Tipo numérica
 - Valores posibles: 10002,10003,10004,...

- **aeropuerto_origen:** Identifica el aeropuerto de salida del vuelo - Tipo categórica
 - Valores posibles: MEX, SJO, BSB, GUA, CDG,...
- **aeropuerto_destino:** Identifica el aeropuerto de llegada del vuelo - Tipo categórica
 - Valores posibles: MEX, SJO, BSB, GUA, CDG,...
- **hora_salida_programada*:** Indica el horario de salida previsto del vuelo - Tipo numérica
 - Valores posibles: 10:15, 15:00, 18:30, 19:45...
- **dia_semana:** Dia de la semana que sale el vuelo - Tipo Categórica
 - Valores posibles: Lunes, Martes, Miércoles, Jueves, Viernes, Sábado, Domingo
- **distancia_vuelo*:** Indica la distancia en km del vuelo - Tipo numérica
 - Valores posibles: 7680, 7300, 9350, 135, 265, 650...
- **condiciones_climaticas*:** Indica el estado del clima el dia del vuelo - Tipo categórica
 - Valores posibles: Despejado, Niebla, Lluvia, Tormenta, Nublado
- **congestion_aerea*:** Nivel de tráfico - Tipo Categórica
 - Valores posibles: Baja, Media, Alta
- **tipo_avion*:** Modelo de la aeronave - Tipo Categórica
 - Valores posibles: Boeing 737 MAX, Boeing 787, Airbus A330, Airbus A320, Boeing 757, Airbus A350, Embraer E190, Boeing 777, Airbus A320neo, Embraer E195, Boeing 737, ATR 72
- **ocupacion_vuelo:** Indica el porcentaje de asientos ocupados en el vuelo - Tipo numérica.
 - Valores posibles: 9.2, 10.9, 11.6, 12.4, 13.1...
- **temporada_alta:** Indica si el vuelo se realizó en temporada alta o no - Tipo booleano
 - Valores posibles: False, True
- **puerta_embarque:** Indica el número de puerta de embarque del vuelo - Tipo numérica
 - Valores posibles: 1-49
- **visibilidad*:** Visibilidad medida en km - Tipo Numérica
 - Valores posibles: 0.5, 1.6, 5.0, ...

- **tiempo_estimado_vuelo***: Tiempo estimado del vuelo en minutos - Tipo numérica
 - Valores posibles: 60,65,110, ...
- **demora***: Indica si el vuelo está demorado o no - Tipo categórica
 - Valores posibles: 0 = No demorado, 1 = Demorado

Para los clientes se cuentan con los siguientes datos:

- **id_cliente**: identificador del cliente - Tipo Numérica
 - Valores posibles: 1, 2, 3, ...
- **sexo**: sexo del cliente - Tipo Categórica
 - Valores posibles: M, F, No binario
- **provincia**: provincia de residencia del cliente - Tipo Categórica
 - Valores posibles: Río de Janeiro, Buenos Aires, Tolima, ...
- **edad**: edad del cliente - Tipo Numérica
 - Valores posibles: 18, 30, 45, ...
- **ocupacion**: ocupación/trabajo de cliente - Tipo Categórica
 - Valores posibles: Médico, Abogado, Deportista, ...
- **cant_vuelos***: cantidad de vuelos acumulados - Tipo Numérica
 - Valores posibles: 1, 2, 3, 4, ..
- **clase_preferida**: clase tarifaria más frecuente del cliente - Tipo Categórica
 - Valores posibles: Primera clase, Económica, Ejecutiva.
- **gasto_acumulado**: consumo historico acumulado en pasajes (USD) - Tipo Numérica
 - Valores posibles: 2200.05, 1504.05, ...
- **gasto_acumulado_extra**:. consumo histórico acumulado en servicios extra (USD) - Tipo Numérica
 - Valores posibles: 257.03, 356.09, ...
- **programaMillas***: indica si el cliente está afiliado al programa de millas - Tipo Categórica
 - Valores posibles: Si, No

- **cantidad_millas:** en caso de estar afiliado, indica las millas acumuladas del cliente - Tipo Numérica
 - Valores posibles: 32782, 65575, 98352, ...
- **ingreso_mensual:** sueldo mensual del cliente, en dólares - Tipo Numérica
 - Valores posibles:
- **anticipacion_compra_promedio:**
 - Valores posibles: 0, 1, 2, ...
- **canal_compra:**
 - Valores posibles: Agencia, Aeropuerto, App, Web

Preparación de los datos

Tanto en lo trabajado en el Modeler como en el Statistics, lo primero que realizamos fue separar la variable `hora_salida_programada` en dos columnas, una que contenga las horas y otra que contenga los minutos, `horas_sp` y `minutos_sp` respectivamente.

Luego, en Statistics si realizamos dos transformaciones más:

- `congestion_aerea`: tenía valores en formato de cadena de caracteres, lo que no nos permitía usarla como variable predictora en la regresión logística, ni incluirla en el análisis de algunos supuestos. Resolvimos crear una columna análoga donde en vez de “Baja”, “Media” o “Alta”, sea 0, 1 y 2 respectivamente.
- `temporada_alta`: por la misma razón que la variable anterior, a esta columna también le creamos una análoga que en vez de decir “VERDADERO” o “FALSO”, indica 1 y 0 respectivamente.

Análisis exploratorio de los datos (Vuelos)

Antes de comenzar a trabajar con los datos se tomó la decisión de dividir la variable “`hora_salida_programada`” en “`hora_salida_prog`” y “`minuto_salida_prog`”.

#	Column	Non-Null Count	Dtype
0	aeropuerto_origen	15000 non-null	object
1	aeropuerto_destino	15000 non-null	object
2	día_semana	15000 non-null	object
3	distancia_vuelo	15000 non-null	int64
4	condiciones_climaticas	15000 non-null	object
5	congestion_aerea	15000 non-null	object
6	tipo_avion	15000 non-null	object
7	ocupacion_vuelo	15000 non-null	float64
8	temporada_alta	15000 non-null	category
9	puerta_embarque	15000 non-null	category
10	visibilidad	15000 non-null	float64
11	tiempo_estimado_vuelo	15000 non-null	int64
12	demora	15000 non-null	category
13	hora_salida_prog	15000 non-null	int64
14	minuto_salida_prog	15000 non-null	int64
dtypes: category(3), float64(2), int64(4), object(6)			
memory usage: 1.4+ MB			

Podemos observar que el dataset no cuenta con datos nulos en ninguno de sus registros, por lo que no es necesario aplicar técnicas de tratamiento de valores faltantes.

	aeropuerto_origen	aeropuerto_destino	dia_semana	distancia_vuelo	condiciones_climaticas	congestion_aerea	tipo_avion	ocupacion_vuelo	temporada_alta	puerta_embarque	visibilidad	tiempo_estimado_vuelo	demora	hora_salida_programada	minuto_salida_programada
count	15000	15000	15000	150000000000	15000	15000	15000	150000000000	15000	15000.0	150000000000	150000000000	15000.0	150000000000	150000000000
unique	40	40	7	NaN	5	3	12	NaN	2	49.0	NaN	NaN	2.0	NaN	NaN
top	EZE	EZE	Viernes	NaN	Despejado	Baja	ATR 72	NaN	False	29.0	NaN	NaN	0.0	NaN	NaN
freq	2132	2196	2385	NaN	6761	6029	1760	NaN	9643	343.0	NaN	NaN	10222.0	NaN	NaN
mean	NaN	NaN	NaN	1.811.709.667	NaN	NaN	NaN	71.383.327	NaN	NaN	15.371.927	169.874.467	NaN	10.974.933	22.358.000
std	NaN	NaN	NaN	2.276.650.883	NaN	NaN	NaN	15.964.749	NaN	NaN	8.633.404	171.010.583	NaN	4.942.543	16.804.424
min	NaN	NaN	NaN	35.000.000	NaN	NaN	NaN	9.200.000	NaN	NaN	0.200000	22.000.000	NaN	0.000000	0.000000
25%	NaN	NaN	NaN	300.000.000	NaN	NaN	NaN	61.100.000	NaN	NaN	8.100.000	58.000.000	NaN	7.000.000	0.000000
50%	NaN	NaN	NaN	960.000.000	NaN	NaN	NaN	73.400.000	NaN	NaN	15.600.000	103.000.000	NaN	11.000.000	15.000.000
75%	NaN	NaN	NaN	2.620.000.000	NaN	NaN	NaN	83.800.000	NaN	NaN	22.900.000	220.000.000	NaN	15.000.000	30.000.000
max	NaN	NaN	NaN	100500000000	NaN	NaN	NaN	99.800.000	NaN	NaN	30.000.000	802.000.000	NaN	22.000.000	45.000.000

Condiciones climáticas

condiciones_climaticas		count
Despejado		6761
Nublado		3737
Lluvia		2267
Tormenta		1175
Niebla		1060

condiciones_climaticas		count
Despejado		45.073333
Nublado		24.913333
Lluvia		15.113333
Tormenta		7.833333
Niebla		7.066667

Para la variable condiciones_climaticas podemos observar en la primera captura la cantidad de eventos Despejado, Nublado, Lluvia, Tormenta y Niebla; siendo la condición “Despejado” la que presenta la mayor cantidad de eventos. En la segunda captura podemos observar la distribución porcentual de los vuelos según el clima, nuevamente siendo liderado por la condición “Despejado” con un 45%.

Congestión aérea

congestion_aerea		count
Baja		6029
Media		5978
Alta		2993

congestion_aerea		count
Baja		40.193333
Media		39.853333
Alta		19.953333

Para la congestión aérea podemos ver que los valores posibles son Alta, Media y Baja. Aproximadamente, en el 40% de los datos se tuvieron vuelos donde la congestión aérea fue Baja, al igual que los vuelos donde hubo congestión Media, demostrando que los vuelos donde hay congestión Alta son la minoría.

Tipo avión

...	count		count
tipo_avion		tipo_avion	
ATR 72	1760	ATR 72	11.733333
Boeing 737	1710	Boeing 737	11.400000
Embraer E190	1708	Embraer E190	11.386667
Airbus A320	1664	Airbus A320	11.093333
Boeing 757	1352	Boeing 757	9.013333
Airbus A320neo	1352	Airbus A320neo	9.013333
Embraer E195	1323	Embraer E195	8.820000
Boeing 737 MAX	1294	Boeing 737 MAX	8.626667
Boeing 777	775	Boeing 777	5.166667
Airbus A330	712	Airbus A330	4.746667
Airbus A350	704	Airbus A350	4.693333
Boeing 787	646	Boeing 787	4.306667

En cuanto a la variable tipo_avion podemos observar que el el tipo de avión que aparece con la mayor frecuencia de 1760 es el ATR 32, con frecuencia 1710 le sigue el Boeing 737 y Embraer E190 con 1708. Estos tres son los que se observan con frecuencias similares, los demás tipos de aviones se presentan con frecuencias más bajas. Analizando los mismos tres tipos de aviones aparecen liderando en cuanto a porcentajes: ATR 11,7%, Boeing 737 11,4% y Embraer E190 11,38%.

Demora

	count		count
demora		demora	
0	10222	0	68.146667
1	4778	1	31.853333

Se observa que la mayoría de los registros corresponden a vuelos sin retrasos (68.15% del total de los datos), mientras que el resto de los datos indican que hubo vuelos con demoras. Esto muestra que la aerolínea tiende a no tener muchos retrasos en sus vuelos.

Hora salida programada

hora_salida_prog		hora_salida_prog	
7	1505	7	10.033333
8	1500	8	10.000000
15	1241	15	8.273333
14	1189	14	7.926667
9	1079	9	7.193333
6	1011	6	6.740000
13	963	13	6.420000
16	941	16	6.273333
17	718	17	4.786667
10	646	10	4.306667
12	644	12	4.293333
5	585	5	3.900000
11	517	11	3.446667
18	392	18	2.613333
4	305	4	2.033333
19	299	19	1.993333
20	224	20	1.493333
22	218	22	1.453333
0	218	0	1.453333
3	216	3	1.440000
2	200	2	1.333333
1	199	1	1.326667
21	190	21	1.266667

Podemos observar un pico durante la mañana entre las 7 y las 8 de la mañana (representan el 20% de los datos). También se puede observar un pico de salidas entre las 14 y las 15 (16% de los registros). Como era de esperarse, la noche y la madrugada son rangos horarios donde la cantidad de salidas de vuelos es baja. Esto demuestra que los horarios de salida no siguen una distribución uniforme.

Minuto salida programada

count		count	
minuto_salida_prog		minuto_salida_prog	
0	3819	0	25.460000
30	3739	30	24.926667
15	3723	15	24.820000
45	3719	45	24.793333

Esta variable sólo toma 4 posibles valores: 0, 15, 30 y 45. Esto significa que no se programan vuelos en horarios aleatorios (ej: 19:43) sino que las salidas de los vuelos están organizadas en intervalos de 15 minutos. A diferencia de la hora de salida, los minutos se distribuyen de forma casi uniforme, es decir, que no hay preferencia por algún intervalo.

Aeropuerto de origen

aeropuerto_origen		aeropuerto_origen	
EZE	2132	EZE	14.213333
BOG	1937	BOG	12.913333
MDE	1565	MDE	10.433333
GRU	1447	GRU	9.646667
PTY	1333	PTY	8.886667
LIM	411	LIM	2.740000
UIO	380	UIO	2.533333
PEI	368	PEI	2.453333
MIA	349	MIA	2.326667
BAQ	339	BAQ	2.260000
CTG	339	CTG	2.260000
CLO	297	CLO	1.980000
CCS	290	CCS	1.933333
AEP	283	AEP	1.886667
JFK	280	JFK	1.866667
BGA	276	BGA	1.840000
MVD	240	MVD	1.600000
MEX	213	MEX	1.420000
GIG	210	GIG	1.400000
SCL	194	SCL	1.293333
ROS	156	ROS	1.040000
MAD	153	MAD	1.020000
CWB	131	CWB	0.873333
POA	129	POA	0.860000
COR	129	COR	0.860000
FLN	127	FLN	0.846667
SJO	121	SJO	0.806667
NQN	116	NQN	0.773333
ASU	112	ASU	0.746667
MDZ	107	MDZ	0.713333
IGR	106	IGR	0.706667
BSB	105	BSB	0.700000
BRC	97	BRC	0.646667
GUA	96	GUA	0.640000
TUC	94	TUC	0.626667
IAH	83	IAH	0.553333
CLT	80	CLT	0.533333
SSA	71	SSA	0.473333
AMS	53	AMS	0.353333
CDG	51	CDG	0.340000

Hay un claro desbalance en los aeropuertos de origen ya que hay una alta concentración en EZE (el más frecuente), BOG, MDE, GRU y PTY, estos concentran más del 56% de los registros. A partir de la mitad de la tabla, se tienen muchos aeropuertos (como CWB, POA, COR, ROS, MDZ) que representan menos del 1% de los datos cada uno.

Aeropuerto de destino

aeropuerto_destino		aeropuerto_destino	
EZE	2196	EZE	14.840000
BOG	1827	BOG	12.180000
GRU	1511	GRU	10.073333
MDE	1410	MDE	9.400000
PTY	1259	PTY	8.393333
UIO	429	UIO	2.880000
LIM	405	LIM	2.700000
MIA	363	MIA	2.420000
CTG	355	CTG	2.388887
PEI	349	PEI	2.328887
BGA	341	BGA	2.273333
BAQ	334	BAQ	2.228887
JFK	331	JFK	2.208887
CLO	327	CLO	2.180000
CCS	282	CCS	1.880000
AEP	279	AEP	1.860000
MVD	271	MVD	1.808887
MEX	205	MEX	1.388887
GIG	204	GIG	1.380000
SCL	188	SCL	1.253333
MAD	169	MAD	1.128887
ROS	146	ROS	0.973333
GUA	143	GUA	0.953333
SJO	133	SJO	0.888887
FLN	122	FLN	0.813333
CWB	122	CWB	0.813333
COR	116	COR	0.773333
BRC	114	BRC	0.760000
IGR	113	IGR	0.753333
MDZ	108	MDZ	0.720000
BSB	104	BSB	0.693333
TUC	102	TUC	0.680000
ASU	101	ASU	0.673333
POA	99	POA	0.660000
NQN	91	NQN	0.608887
CLT	85	CLT	0.568887
SSA	79	SSA	0.528887
IAH	79	IAH	0.528887
AMS	57	AMS	0.380000
CDG	51	CDG	0.340000

Los cinco aeropuertos que dominaban las salidas (EZE, BOG, GRU, MDE y PTY) son exactamente los mismos cinco que dominan las llegadas, manteniendo casi el mismo orden de importancia y porcentajes muy similares. Además, se observa, nuevamente, una lista de destinos minoritarios (aquellos con menos del 1% de participación).

Puerta embarque

puerta_embarque			
29	343	27	304
23	334	15	302
40	332	3	302
36	332	19	301
42	329	28	299
7	328	31	297
11	325	37	296
38	322	35	296
13	322	30	296
44	321	21	289
1	319	43	289
17	319	20	289
33	318	46	285
32	317	4	283
12	316	48	283
18	316	14	283
45	316	26	282
34	316	6	281
2	315	39	279
5	312	16	275
49	311	10	270
9	310		
25	310		
47	309		
41	308		
22	307		
24	306		
8	306		

Para la variable puerta de embarque podemos ver que la cantidad de vuelos asignados a cada uno se encuentra bastante balanceada.

Temporada alta

temporada_alta		count
False	9643	
True	5357	

temporada_alta		count
False	64.286667	
True	35.713333	

Para la variable temporada_alta podemos ver que la mayoría de vuelos en este caso los 9643 se realizaron fuera de temporada alta, y 5347 se realizaron en temporada alta, mientras que en la tabla de porcentajes vemos que el 64% de los vuelos se realizaron en temporada baja y el 35% en temporada alta.

Día de semana

Viernes	15.900000	Viernes	2385
Domingo	15.086667	Domingo	2263
Sábado	14.953333	Sábado	2243
Miércoles	14.326667	Miércoles	2149
Jueves	13.573333	Jueves	2036
Lunes	13.186667	Lunes	1978
Martes	12.973333	Martes	1946

Se observa los días viernes y domingo como días de mayor demanda de vuelos mientras que lunes y martes los de menor.

Análisis Univariado


Histogramas y boxplot

Histograma de la distancia de vuelo




El histograma de Distancia de Vuelo muestra una gran concentración de vuelos en el rango de 0 a 2000km, indicando que DS Airlines se centra en vuelos de corta/media distancia. Hay una fuerte asimetría positiva, dando a entender que a medida que las distancias de los vuelos aumentan, la frecuencia de los mismos disminuye de forma drástica.

Boxplot de la distancia de vuelo




En lo que respecta al BoxPlot, podemos identificar que los vuelos de una distancia mayor a 6000 km (aproximadamente) ya se consideran valores atípicos. También podemos ver que el 50% de los vuelos tienen distancias que varían entre los 300 km y los 2600 km (aproximadamente).

Histograma de la visibilidad




El histograma de Visibilidad muestra una distribución aproximadamente uniforme, indicando que los vuelos de DS Airlines operan con regularidad en un rango amplio de condiciones, teniendo visibilidad reducida (< 5 km) hasta visibilidad óptima (30km).

Boxplot de la visibilidad




En el BoxPlot podemos ver que el 50% central de los vuelos opera con un rango de visibilidad que varía entre los 8km y los 23 km (aproximadamente), confirmando la alta variabilidad climática con la que se opera regularmente. No se identifican outliers, indicando que no se han registrado casos atípicos extremos.

Histograma del tiempo estimado de vuelo



El histograma muestra una distribución claramente asimétrica hacia la derecha, la gran mayoría de los vuelos tienen una duración estimada de entre 50 y 200 minutos, con el pico máximo alrededor de los 75-100 minutos. A partir de ahí la frecuencia cae progresivamente, aunque se observa un segundo grupo de vuelos concentrado entre los 600 y 800 minutos, lo que sugiere la presencia de vuelos de larga distancia dentro del dataset.


Boxplot del tiempo estimado de vuelo



El boxplot confirma la asimetría hacia la derecha mencionada anteriormente: la mediana se ubica aproximadamente en los 150 minutos, con el 50% central de los datos entre los 75 y 250 minutos aproximadamente. También se observan valores atípicos (outliers), que representan precisamente esos vuelos de larga duración mencionados.


En conjunto, ambos gráficos indican que el dataset está dominado por vuelos cortos o medios, con una minoría de vuelos largos que generan la cola derecha de la distribución.

Histograma de la ocupación



La mayoría de los vuelos van casi llenos, el histograma de la ocupación muestra que la mayor parte de los vuelos tiene entre un 70% y 85% de sus asientos ocupados, formando una especie de campana bastante simétrica, lo cual es bastante típico estadísticamente.


Boxplot de la ocupación



El boxplot confirma que no hay mucha variación entre vuelos, la mitad central de los datos se concentra en un rango relativamente acotado.


Lo más destacable son algunos outliers a la izquierda, que representan vuelos con ocupación muy baja, es decir, vuelos casi vacíos que son casos raros dentro del dataset.

Histograma de las horas de salida




El histograma muestra que los vuelos no se distribuyen de forma pareja a lo largo del día. Se destacan dos picos principales, uno a la mañana entre las 7 y 9 hs y otro a la tarde entre las 14 y 16hs. Esto tiene mucho sentido, ya que las aerolíneas suelen concentrar sus frecuencias en esos horarios de mayor demanda. Las horas de madrugada tienen muy pocos vuelos.

Boxplot de las horas de salida



El boxplot confirma que la mitad central de los vuelos salen entre aproximadamente las 7 y las 15hs, con una mediana alrededor de las 10-11hs. No se observan outliers llamativos, lo que indica que no hay horarios extremadamente raros.


Boxplot de los minutos de salida



En el boxplot podemos ver que el 50% central de los vuelos tiene su minuto de salida programado en el rango que varía entre el minuto 0 y el minuto 30, lo cual es coherente con la distribución observada en bloques


Gráfico de barras

Cantidad de vuelos según condición climática



El gráfico de barras muestra la frecuencia o cantidad de vuelos registrados para las distintas condiciones climáticas (despejado, niebla, lluvia, tormenta y nublado). La categoría 'despejado' es la que tiene mayor frecuencia, lo que la posiciona como la moda de los datos. La categoría 'niebla' es la de menor frecuencia, indicando que en esta condición climática se registra menor actividad aérea.


Cantidad de vuelos según congestión aérea



El gráfico de barras muestra la distribución de los vuelos según el nivel de congestión aérea para las distintas categorías (baja, alta, media). Se puede observar que la categoría 'Baja' y


'Media' tienen una frecuencia muy similar y predominante, en cambio la categoría 'Alta' es aproximadamente la mitad de las ocurrencias anteriores, lo cual indica que los vuelos operando bajo esta congestión son los menos frecuentes en la muestra analizada.

Cantidad de vuelos según tipo de avión




El gráfico de barras muestra la distribución de los vuelos según el modelo de avión que se utilizó. Se puede observar que los modelos ATR 72, Boeing 737 y Embraer E190 tienen las frecuencias más altas. En cambio, el Boeing 787 es el que menos registros tiene, lo que indica que se realizaron pocos vuelos con este modelo en particular.

Cantidad de vuelos demorados y no demorados




Este gráfico de barras indica cuántas veces estuvo o no demorado un avión, siendo 0 que no hubo demoras, y 1 que el vuelo fue demorado. Podemos observar que la mayoría de los vuelos no sufrieron demoras, mientras que los vuelos demorados representan un poco menos de la mitad de los datos.

Cantidad de vuelos según el país de origen




Esta gráfica muestra el volumen total de vuelos que despegan desde diferentes países. Colombia registra la mayor cantidad de salidas con más de 5000 vuelos. Le sigue Argentina con un poco más de 3200 vuelos, y luego Brasil con aproximadamente 2200. Países como Panamá y Estados Unidos tienen una actividad moderada, mientras que el resto de los países origen presentan un flujo de salidas bajo, quedando por debajo de los 500 vuelos cada uno.

Cantidad de vuelos según el país de destino



Esta gráfica representa el volumen total de vuelos que llegan a cada país. Colombia vuelve a ser el destino principal, rozando los 5,000 vuelos recibidos. Seguido por Argentina, que ocupa el segundo puesto con aproximadamente 3200 arribos, seguido por Brasil con aproximadamente 2200. Panamá se mantiene como un destino intermedio importante, mientras que gran parte del resto de países muestran barras muy bajas, lo que significa que reciben una cantidad reducida de vuelos.


Cantidad de vuelos según temporada alta



Podemos observar que, aproximadamente, el 60% de los vuelos en este dataset se realizaron fuera de la temporada alta. Esto podría indicar que la aerolínea no está siendo solicitada en periodos de alta temporada o que los datos no estén sesgados solamente en periodos vacacionales.

Históricamente, la temporada alta está asociada a una mayor saturación de las puertas de embarque, mayor volumen de equipaje y una congestión aérea persistente. Es altamente probable que el modelo encuentre una correlación positiva entre `temporada_alta = True` y la probabilidad de demorado = 1.


Cantidad de vuelos por puerta de embarque



El gráfico de barras muestra que la frecuencia de vuelos está repartida de manera casi idéntica entre las 49 puertas de embarque disponibles, indicando una asignación aleatoria o rotativa por parte de la administración aeroportuaria en el dataset. Cada puerta registra un volumen de vuelos muy similar, lo que sugiere que ninguna puerta por sí sola parece representar un cuello de botella evidente.

Al ser una distribución tan uniforme, es probable que la variable puerta_embarque por sí sola no sea un predictor fuerte de demora.

Cantidad de vuelos por día de semana



El gráfico de barras muestra una distribución uniforme entre todos los días de la semana, ya que no se observan días de extrema actividad ni tampoco se ven días de inactividad. Por una poca diferencia, se podría decir que se destacan los días viernes, sábado y domingo, lo cual es lógico debido al comportamiento de la industria aérea, donde la frecuencia aérea aumenta en estos días debido a posibles viajes de ocio o de negocio. Aun así, en el resto de los días no hay una diferencia extrema de actividad, lo cual indica que la aerolínea mantiene una operación constante durante todo el ciclo semanal.

Análisis Multivariado

Matriz de covarianzas

	distancia_vuelo	ocupacion_vuelo	visibilidad	tiempo_estimado_vuelo	hora_salida_prog	minuto_salida_prog
distancia_vuelo	5.183139e+06	332.304359	168.522998	388838.717868	96.299609	-401.566498
ocupacion_vuelo	3.323044e+02	254.873196	1.882840	25.555537	-0.229187	-0.266935
visibilidad	1.685230e+02	1.882840	74.535666	12.630705	0.428558	-0.542773
tiempo_estimado_vuelo	3.888387e+05	25.555537	12.630705	29244.619549	6.954650	-29.127268
hora_salida_prog	9.629961e+01	-0.229187	0.428558	6.954650	24.428734	1.713555
minuto_salida_prog	-4.015665e+02	-0.266935	-0.542773	-29.127268	1.713555	282.388662

Debido a que la matriz de covarianzas no está estandarizada por lo cual resulta sensible a las unidades de medida de cada variables. Por estas razones es mejor utilizar la matriz de correlaciones la cual si estandariza los valores entre -1 y 1.

Matriz de correlaciones


	distancia_vuelo	ocupacion_vuelo	visibilidad	tiempo_estimado_vuelo	hora_salida_prog	minuto_salida_prog
distancia_vuelo	1.000000	0.009143	0.008574	0.998735	0.008558	-0.010496
ocupacion_vuelo	0.009143	1.000000	0.013661	0.009361	-0.002905	-0.000995
visibilidad	0.008574	0.013661	1.000000	0.008555	0.010043	-0.003741
tiempo_estimado_vuelo	0.998735	0.009361	0.008555	1.000000	0.008228	-0.010136
hora_salida_prog	0.008558	-0.002905	0.010043	0.008228	1.000000	0.020631
minuto_salida_prog	-0.010496	-0.000995	-0.003741	-0.010136	0.020631	1.000000

En la matriz de correlaciones se puede ver una correlación positiva de 0.998 entre tiempo_estimado_vuelo y distancia_vuelo indicando que a medida que aumenta la distancia de vuelo aumenta a su vez el tiempo estimado de vuelo.

En el resto de las variables se presentan coeficientes muy cercanos a 0 indicando que las variables son linealmente independientes.

Scatterplot


Distancia vuelo vs Tiempo estimado vuelo



En este gráfico se detecta una relación ascendente entre la distancia y la duración estimada del vuelo, ya que a mayor distancia, obviamente se va a tardar más en realizar el recorrido.

Boxplots Estratificados

Visibilidad según condición climática



Grupo 1: Climas de alta visibilidad

Las cajas son casi idénticas y la mediana de todas está alrededor de los 17-18km.


La visibilidad varía mucho, tomando valores desde los 5 km hasta los 30 km. Debido a esto podemos concluir que la visibilidad no se ve afectada por lluvia o nubes con respecto a la que habría un día soleado.

Grupo 2: Climas de baja visibilidad (niebla, tormenta)

Las cajas están completamente aplastadas hacia la izquierda.

Cuando el clima es neblinoso la mediana de la visibilidad está en menos de 2.5 km y el rango total de los bigotes está entre 0 y 4 km. En cambio cuando hay tormenta la mediana de la visibilidad aumenta a 3km y el rango de los bigotes entre 1 y 5 km aproximadamente. Debido a esto podemos concluir que cuando el pronóstico indica niebla o tormenta la visibilidad es muy baja.


Visibilidad según si hubo o no demora



En la gráfica de la sin demora (caja superior) podemos observar como la visibilidad se concentra entre los 9 km y 24 km aproximadamente. En los vuelos demorados (caja inferior) se concentra entre los 5 km y 22 km.

Aunque existe una ligerísima tendencia a que los vuelos demorados tengan menor visibilidad promedio (la caja se estira hacia la izquierda), la variable por sí sola no tiene la fuerza suficiente para clasificar y separar claramente los vuelos que cumplen el itinerario de aquellos que sufren demoras.

Distancia de vuelo según tipo de avión



En el BoxPlot de distancia por tipo de avión podemos ver una clara segmentación:


- Modelos de corto alcance: ATR 72 y los modelos Embraer (E190 y E195) trabajan en rangos de baja distancia (por debajo de los 1000km).

- Modelos de medio alcance: Airbus A320, A320neo y Boeing 737 / 737, sus distancias varían entre los 1000km y los 3000km.
- Modelos de largo alcance: Airbus A330, A350 y los Boeing 777, 787, son los que más distancia realizan.

Los modelos Boeing 757 y Airbus A330 son aviones versátiles que la empresa utiliza tanto para vuelos de media distancia como para vuelos más largos (esto lo vemos ya que tienen mayor Rango Intercuartílico).

Se identifica presencia de outliers en los modelos Boeing 737 y Airbus A320, lo cual indica que en algunas ocasiones se usan aviones de corta distancia para viajes de mayor recorrido al que están acostumbrados.


Ocupación del vuelo según país de origen



En el boxplot de la ocupación del vuelo según aeropuerto de origen se puede apreciar una notable homogeneidad ya que en la mayoría de cajas el 50% central de los vuelos opera entre valores de ocupación muy similares, generalmente entre el 60% y 85%. Esto indica que el punto de partida del vuelo no altera drásticamente el comportamiento habitual de la demanda.

También se pueden apreciar outliers en el extremo izquierdo de la mayoría de las cajas indicando así que los vuelos semi-vacíos son un problema general de la aerolínea y no algo puntual de una terminal en particular.


Ocupación del vuelo según si hubo o no demora



El boxplot de la ocupación del vuelo según si hubo o no demora muestra una distribución prácticamente idéntica para ambos casos ya que al observar las cajas podemos ver que el 50% central de los vuelos se concentran entre los valores 60 y 85 de ocupación. Esto indica claramente que el nivel de ocupación del vuelo no tiene un impacto directo ni relación con la probabilidad de que el vuelo sufra una demora.

Además, también se ven la existencia de outliers en el extremo izquierdo de ambas categorías lo cual implica que la existencia de vuelos semi-vacíos ocurre tanto en aquellos que logran llegar a horario como en los que registran demora.

Distancia del vuelo según si hubo o no demora




El boxplot de la distancia del vuelo según si hubo o no demora muestra una distribución prácticamente idéntica para ambos casos ya que al observar las cajas podemos ver que el 50% central de los vuelos se concentran entre los valores 300 y 2500 km aproximadamente.

Aunque la caja correspondiente a los vuelos demorados posee una leve extensión hacia distancias mayores en su tercer cuartil es posible afirmar que la distancia del vuelo no tiene un impacto directo ni relación con la probabilidad de que el vuelo sufra una demora.

Además, también se ven la existencia de outliers en el extremo derechos de ambas categorías lo cual implica que la existencia de vuelos muy larga distancia ocurre tanto en aquellos que logran llegar a horario como en los que registran demora.


Tiempo estimado del vuelo según si hubo o no demora



El boxplot del tiempo estimado de vuelo según si hubo demora o no muestra distribuciones prácticamente idénticas en ambos escenarios ya que al observar las cajas podemos ver que el 50% central de los vuelos en ambos grupos abarca un rango similar entre los 60 y 230 minutos aproximadamente, además, ambas medias se encuentran cercanas a 100. Esto indica claramente que la duración prevista de un vuelo no es un factor determinante que influya en la probabilidad de que un vuelo se retrase.

En ambas categorías se observa la existencia de outliers en el extremo derecho de las cajas lo cual indica que la existencia de vuelo de muy alta duración prevista ocurren esporádicamente tanto en aquellos que logran llegar a horario como en los que sufren demora.


Ocupación del vuelo según día de semana



El boxplot de la ocupación del vuelo según el día de semana revela uniformidad a lo largo de toda la semana ya que al observar las cajas podemos ver que el 50% central de los vuelos ocupa un rango de ocupaciones prácticamente idéntico sin importar el día de la semana. Esto indica que el día de la semana no es un factor determinante que altere el buen nivel de demanda habitual de las operaciones.

También se puede identificar la presencia de outliers en el extremo izquierdo de todas las cajas concluyendo así que la existencia de vuelos semi-vacíos es un fenómeno transversal a toda la semana.

Ocupación del vuelo según si hay temporada alta




El boxplot de la ocupación del vuelo según si hay temporada alta o no muestra que las distribuciones de ambos grupos son prácticamente idénticas ya que al observar las cajas se puede ver que el 50% central de los vuelos tanto en temporada alta como en temporada normal opera con rangos de ocupaciones similares, concentrándose entre valores de 60% y 85%. Esto indica, contra intuitivamente, que la temporada alta no afecta significativamente los niveles de ocupación de los vuelos.

En ambas categorías se aprecia la existencia de outliers en el extremo izquierdo de las cajas lo cual confirma que la existencia esporádica de vuelos semi-vacíos ocurre tanto en temporada alta como en temporada normal.


Gráficos de barras estratificados

Cantidad de demoras según condición climática




La gráfica muestra una disparidad significativa en la incidencia de demoras según el estado del tiempo. Mientras que la variable "Despejado" presenta el mayor volumen de operaciones, la categoría de "Tormenta" es la única donde la frecuencia de vuelos demorados supera a los vuelos a tiempo, estableciendo al clima severo como un factor crítico de riesgo operativo con una alta probabilidad de retraso.

Cantidad de demoras según día de semana




Se observa una distribución de frecuencias prácticamente uniforme a lo largo de la semana, lo que sugiere que el factor temporal por día no influye en la probabilidad de demora.

Cantidad de demoras según congestión aérea




El gráfico de barras Cantidad de demoras por congestión permite analizar la incidencia de la variable Demorado según el nivel de Congestión Aérea. En la categoría Baja, se observa la mayor eficiencia operativa con una baja tasa de demoras a pesar del alto volumen de vuelos. Sin embargo, en la congestión Alta, las clases se equilibran casi totalmente, indicando que el tráfico intenso es un predictor crítico que eleva la probabilidad de demora a niveles de incertidumbre. Finalmente, en la categoría Media, se mantiene una mayoría de vuelos puntuales, aunque con un volumen de demoras superior al escenario de alta congestión.

Cantidad de congestiones según temporada alta



La mayoría de los vuelos operan bajo niveles de congestión aérea baja y media cuando la temporada no es alta. Son bastantes proporcionales entre los distintos niveles de tráfico.


Cantidad de demoras según el tipo de avión



El gráfico de barras Cantidad de demoras por tipo de avión permite analizar la relación entre el Tipo de avión y la variable Demorado para las distintas aeronaves. A nivel general, se observa que en todos los modelos la cantidad de vuelos a tiempo supera a los demorados, manteniendo una distribución proporcionalmente similar independientemente de si son aviones de corto o largo alcance.

Modelos con alta frecuencia operativa, como el Boeing 737, el ATR 72 y el Embraer E190, concentran el mayor número absoluto de demoras, aunque conservan una tasa de puntualidad saludable. Por el contrario, aeronaves como el Airbus A330, A350 y el Boeing 787 presentan un volumen de registros menor, reflejando su uso en rutas específicas de mayor distancia. En conclusión, el tipo de avión no parece ser un factor discriminante crítico por sí solo para predecir demoras.


Cantidad de demoras según país de origen



La gráfica muestra la cantidad de vuelos por aeropuerto de origen, dejando claro que las terminales EZE, BOG y MDE son los centros con más actividad y, por lo tanto, donde se concentran más demoras. Aunque estos aeropuertos tienen muchísimos más vuelos que el

resto, la proporción de retrasos se mantiene parecida en casi todos, lo que indica que el tráfico está muy centralizado en unos pocos puntos clave.

Cantidad de demoras según país de destino



Esta gráfica muestra la cantidad de vuelos según su aeropuerto de destino, resaltando que la gran mayoría de los aterrizajes y sus demoras se concentran en unos pocos puntos principales como GRU, EZE y BOG. Se puede notar que los destinos con más tráfico tienen la mayor parte de los retrasos.

Fase de Preparación

Se decidió utilizar el 70% de los registros para el entrenamiento del modelo y el 30% restante para la prueba del mismo. Además, para todo el muestreo se utilizó una semilla fija para poder garantizar la reproducibilidad.

Al considerar que la cantidad de vuelos con demora es mucho más baja que la cantidad de vuelos sin demora se decidió realizar un muestreo estratificado, ya que de otra forma podría haber un desbalance en la proporción de vuelos demorados/no demorados al comparar el dataset de entrenamiento con el de prueba.

Para las variables categóricas se decidió realizar un One Hot Encoding con el objetivo de convertirlas a numéricas debido a que los modelos utilizados necesitan valores numéricos para poder realizar cálculos matemáticos.

Vista Minable

Variable	Tipo	Descripción
aeropuerto_origen	Dummies	Aeropuerto del que sale el avión 40 valores - 39 columnas
aeropuerto_destino	Dummies	Aeropuerto al que llega el avión

		40 valores - 39 columnas
hora_salida_prog	Numérica	Hora a la que el vuelo debería salir
minuto_salida_prog	Numérica	Minuto en el que el vuelo debería salir
dia_semana	Dummies	7 días - 6 columnas
distancia_vuelo	Numérica	Distancia del vuelo en km
condiciones_climaticas	Dummies	Despejado, Nublado, Tormenta, Lluvia, Niebla (4 columnas)
congestion_aerea	Dummies	Nivel de tráfico aéreo
tipo_avion	Dummies	12 modelos - 11 columnas
ocupacion_vuelo	Numérica	Porcentaje de asientos ocupados en el vuelo
temporada_alta	Booleana	Indica si el vuelo se realizó en temporada alta
puerta_embarque	Dummies	Número de puerta de embarque del vuelo 49 valores - 48 columnas
visibilidad	Numérica	Visibilidad medida en km
tiempo_estimado_vuelo	Numérica	Tiempo estimado del vuelo en minutos
demora	Booleana	Variable a predecir

Fase de Modelado

Árboles de Decisión

Python

Comenzamos probando con una profundidad máxima de 10 y todas las variables de la vista minable aplicando One-Hot Encoding a las variables categóricas para permitir el correcto procesamiento matemático del algoritmo. Esto nos arrojó una Precisión de 78%, un Recall del 40% y un Accuracy del 77% con los datos de entrenamiento, pero que luego disminuyó

a una Precisión de 48%, un Recall de 27% y una Accuracy del 67% al utilizar los datos de prueba lo cual indica que el modelo está sobreajustado y el mismo no es óptimo.


Luego de esto probamos sacando las variables `dia_semana`, `aeropuerto_origen`, `aeropuerto_destino`, `tipo_avion`, `puerta_embarque`, `ocupacion_vuelo` debido a lo observado en el análisis exploratorio. Lo cual arrojó unos valores de Precisión de 72%, un Recall de 40% y una Accuracy de 76% con los datos de entrenamiento, pero que nuevamente disminuyeron al utilizar los datos de prueba a una Precisión de 49%, un Recall de 28% y una Accuracy del 49%.


Lo próximo que se realizó fue disminuir la profundidad máxima a 5 y balancear el peso de las clases lo cual hizo que los valores se vean disminuidos a una Precisión de 45%, un Recall de 63% y una Accuracy del 64% con los datos de entrenamiento, aunque luego los valores obtenidos con los datos de prueba se mantuvieron mucho más cercanos al ser Precisión de 43%, un Recall de 61% y una Accuracy de 62%. Lo cual indica que el modelo ya no está sobreajustado.

Luego de esto se mantuvo la profundidad máxima en 5 y se aplicaron pesos personalizados a las clases (dándole una importancia 3 veces mayor a la clase de interés), lo cual hizo que los valores resultaran en una Precisión del 40%, un Recall del 76% y una Accuracy del 57% con los datos de entrenamiento, aunque luego los valores obtenidos con los datos de prueba se mantuvieron sumamente cercanos al ser Precisión del 40%, un Recall del 74% y una Accuracy del 56% lo cual indica que el modelo no está sobreajustado.

Por último, decidimos disminuir la profundidad máxima a 2 y se balancea nuevamente el peso de las clases, lo cual hizo que los valores resultaran en una Precisión del 41%, un Recall del 76% y una Accuracy del 57% con los datos de entrenamiento, y unos valores con los datos de prueba iguales a Precisión del 40%, Recall del 75% y una Accuracy del 56%.

Finalmente decidimos quedarnos con la tercera corrida debido a que presenta un buen balance entre Precisión y Recall aunque en líneas generales no termina de ser un buen modelo predictor.





Modeler

Un paso que tuvimos en cuenta antes de entrenar los algoritmos fue aplicar un factor de balanceo sobre los datos, ya que, al tener originalmente una cantidad mucho mayor de vuelos a tiempo que demorados, el balanceo fue fundamental para evitar que el algoritmo se sesgara hacia la clase mayoritaria.

Una vez equilibrado el dataset, procedimos a evaluar tres modelos distintos de árboles de decisión dentro de SPSS Modeler: **CHAID**, **QUEST** y **C5.0**.

Realizamos una corrida inicial que incluye todas las variables de la vista minable y se obtuvieron los siguientes resultados:

QUEST

Recall: 56.7% - Accuracy: 67% - Precision: 45,84%

CHAID

Recall: 66.1% - Accuracy 62.1% - *Precisión: 45,01%*

C5.0

Recall 52.8% - Accuracy 59% - *Precisión: 45,66%*

Luego de esto, basado en los hallazgos del análisis exploratorio, decidimos descartar las variables **dia_semana**, **aeropuerto_origen**, **aeropuerto_destino**, **tipo_avion**, **puerta_embarque**, **ocupacion_vuelo** y **distancia_vuelo**, ya que concluimos que no presentaban una influencia significativa para determinar la probabilidad de demora de un vuelo. Esta limpieza nos permitió trabajar con los datos más limpios y asegurar que las comparativas entre herramientas fueran justas.

A continuación, expondremos las matrices de confusión de cada modelo evaluado para ilustrar estas diferencias y detallaremos la conclusión final sobre nuestra elección del algoritmo.

CHAID

Demora	0	1
0	1761	1279
1	425	1047

Posee un Recall de 71.1%, una Precisión del 45,01% y un Accuracy de 62.2%. Esto nos indica que más de la mitad de las alertas de demora 54,99% son falsas alarmas. Lo que implicaría un gasto logístico inútil y compensaciones innecesarias.

C5.0

Demora	0	1
0	1963	1077
1	567	905

Presenta un Recall de 61.48%, una Precisión de 45,66% y una Accuracy de 63.56%. Lo que significa que se malgasta el tiempo operativo destinado a contingencias en alertas incorrectas para vuelos que operarán a tiempo .

QUEST

Demora	0	1
0	1959	1081
1	556	915

Este modelo presenta un Recall de 62.2%, una Precisión del 45,84% y una Accuracy de 63.71%. Los resultados de este modelo resultaron ser la opción más equilibrada. Si bien mantiene un margen de falsos positivos que impacta en el costo operativo, logra optimizar el compromiso entre sensibilidad y especificidad.

Al contrastar los tres algoritmos en IBM SPSS Modeler, concluimos que QUEST es la alternativa óptima para la estrategia del negocio. Mientras que CHAID y C5.0 presentan ineficiencias ya que destinan más del 54% de sus alertas a falsos positivos. Por otro lado QUEST aunque mantiene un margen de error, mitiga más el impacto operativo de falsas alarmas sin perder la capacidad de detectar demoras reales, razón por la cual decidimos tomarlo como el mejor. Por estos motivos, es que decidimos que el modelo QUEST se consolida como el mejor árbol de decisión.

KNN

Python


Inicialmente se debieron estandarizar las variables, se utilizó StandardScaler, que estandariza eliminando la media y escalando la varianza unitaria, sobre las variables: visibilidad, tiempo_estimado_vuelo, hora_salida_prog, minuto_salida_prog, ocupacion_vuelo y distancia_vuelo. Luego, aplicamos OneHotEncoder a las variables temporada_alta, condiciones_climaticas, congestion_aerea, aeropuerto_origen, aeropuerto_destino, tipo_avion, y puerta_embarque.

Comenzamos probando todos los K desde 1 hasta 50 junto con todas las variables. Los resultados fueron malos en líneas generales, siendo el mejor valor posible K=3 ya que daba como resultado un Recall de 30.6%, un Specifity de 81.2%, un Accuracy de 65% y al ser un número impar de puntos nunca se va a dar un caso de empate. Sin embargo este modelo claramente no es bueno para predecir si un vuelo va a tener demora.

Lo siguiente que hicimos fue repetir la prueba pero esta vez sin las variables dia_semana, aeropuerto_origen, aeropuerto_destino, tipo_avion, puerta_embarque y ocupacion_vuelo debido a que KNN es un algoritmo basado en distancias, por lo cual se decidió eliminar las variables categóricas.

Esto hizo que el valor óptimo pase a ser K=9 ya que posee un Recall de 31.3%, uno de los valores más altos entre todos los posibles K, una Specifity de 84% y un Accuracy de 67%. Además, 9 es un valor robusto ya que al tomar en consideración más puntos no se deja influenciar fácilmente por outliers y al ser impar anula por completo la posibilidad de que suceda un empate. Pero aunque sean los mejores resultados que pudimos conseguir, estos siguen sin ser suficientes como para que el modelo sea bueno a la hora de predecir demoras.

La causa de por qué este modelo no puede poseer un Recall más alto es que el conjunto de datos de vuelos está desbalanceado, se tienen más vuelos no demorados que demorados. Como KNN es un algoritmo que clasifica las clases según la clase mayoritaria entre los K vecinos más cercanos, el tener un conjunto de datos desbalanceado termina haciendo que la clase “no demorado” domine la toma decisiones. De esta forma, un vuelo demorado que esté rodeado de vuelos no demorados, sea clasificado incorrectamente.



Análisis de Discriminante

Para este análisis solo se usan variables predictoras del tipo escalares, no categóricas, por lo que el estudio se basará únicamente en las siguientes: ocupación de vuelo, visibilidad, tiempo estimado de vuelo y suma de minutos (esta variable representa la hora de salida programada como la suma de minutos desde las 00Hs).

Comprobación de supuestos para los datos de train

Para aplicar un análisis de discriminante, primeramente hay que corroborar los siguientes supuestos:

- Ausencia de multicolinealidad.
- Distribución normal en las variables.
- Homogeneidad de matrices de covarianza (homocedasticidad).
- Diferencia significativa entre medias.

Ausencia de multicolinealidad

El primer paso consistió en garantizar que las variables predictoras no estuvieran altamente correlacionadas entre sí, ya que la multicolinealidad distorsiona la estimación del modelo. Para ello, se generó la tabla de "Correlaciones":

Correlaciones				
		distancia_vuelo	ocupacion_vuelo	visibilidad
distancia_vuelo	Correlación de Pearson	1	,009	,009
	Sig. (bilateral)		,263	,294
	N	15000	15000	15000
ocupacion_vuelo	Correlación de Pearson	,009	1	,014
	Sig. (bilateral)	,263		,094
	N	15000	15000	15000
visibilidad	Correlación de Pearson	,009	,014	1
	Sig. (bilateral)	,294	,094	
	N	15000	15000	15000
tiempo_estimado_vuelo	Correlación de Pearson	,999**	,009	,009
	Sig. (bilateral)	,000	,252	,295
	N	15000	15000	15000
MInutos_suma	Correlación de Pearson	,008	-,003	,010
	Sig. (bilateral)	,331	,718	,230
	N	15000	15000	15000

Correlaciones			
		tiempo_estimado_vuelo	MInutos_suma
distancia_vuelo	Correlación de Pearson	,999**	,008
	Sig. (bilateral)	,000	,331
	N	15000	15000
ocupacion_vuelo	Correlación de Pearson	,009	-,003
	Sig. (bilateral)	,252	,718
	N	15000	15000
visibilidad	Correlación de Pearson	,009	,010
	Sig. (bilateral)	,295	,230
	N	15000	15000
tiempo_estimado_vuelo	Correlación de Pearson	1	,008
	Sig. (bilateral)		,350
	N	15000	15000
MInutos_suma	Correlación de Pearson	,008	1
	Sig. (bilateral)	,350	
	N	15000	15000

** . La correlación es significativa en el nivel 0,01 (bilateral).

Se observa que las variables, en general, presentan correlaciones nulas o muy bajas entre sí. A excepción de la distancia de vuelo y el tiempo estimado de vuelo, que son métricas equivalentes (altamente correlacionadas o "gemelos estadísticos"), gracias a que su correlación es muy cercana a 1 (0,999).

Como conclusión, para cumplir con el supuesto de independencia y evitar la multicolinealidad, se determinó que es necesario limpiar o descartar una de las dos variables redundantes antes de introducirlas al modelo predictivo definitivo.

Nos quedaremos con tiempo estimado de vuelo.

Análisis de la distribución normal en las variables

El análisis discriminante asume teóricamente una normalidad multivariante, pero se comenzó evaluando la normalidad univariante. Para ello, se revisó la tabla "Pruebas de normalidad".

Pruebas de normalidad

	demora	Kolmogorov-Smirnov ^a			Shapiro-Wilk	
		Estadístico	gl	Sig.	Estadístico	gl
ocupacion_vuelo	0	,057	10222	,000		
	1	,059	4778	,000	,967	4778
visibilidad	0	,060	10222	,000		
	1	,088	4778	,000	,935	4778
tiempo_estimado_vuelo	0	,218	10222	,000		
	1	,211	4778	,000	,743	4778
MInutos_suma	0	,085	10222	,000		
	1	,084	4778	,000	,982	4778

Pruebas de normalidad

	demora	Shapiro-...
		Sig.
ocupacion_vuelo	0	
	1	,000
visibilidad	0	
	1	,000
tiempo_estimado_vuelo	0	
	1	,000
MInutos_suma	0	
	1	,000

a. Corrección de significación de Lilliefors

Utilizando el estadístico de Kolmogorov-Smirnov, las variables continuas como visibilidad y tiempo estimado de vuelo obtuvieron un nivel de significancia de 0,000. Al ser menor que 0,05, se rechaza la hipótesis nula de normalidad.

Análisis de homogeneidad de matrices de covarianza

Para que la función discriminante lineal sea óptima, las varianzas y covarianzas deben ser similares en ambos grupos (demorados y no demorados). Para evaluar esto, se utilizó la sección de "Prueba de Box de la igualdad de matrices de covarianzas", observando específicamente la tabla "Resultados de prueba".

Resultados de prueba

M de Box		82,029
F	Aprox.	8,200
	gl1	10
	gl2	428314925,2
	Sig.	,000

Prueba la hipótesis nula de las matrices de covarianzas de población iguales.

El estadístico M de Box arrojó un valor de significancia de 0,000 a lo largo de las distintas iteraciones del modelo. Debido a que este valor es decididamente menor al umbral de 0,05, se rechaza la hipótesis nula de homocedasticidad, dando a entender que las nubes de datos de los grupos son diferentes entre sí.

El valor de significancia de 0,000 obtenido en la prueba M de Box tiene varias implicancias importantes para el modelo. En primer lugar, indica que existe una diferencia significativa en las matrices de covarianza de los grupos analizados, lo que puede generar sesgos en la clasificación. Por ejemplo, si los vuelos no demorados presentan una menor dispersión de los datos y los vuelos demorados una mayor variabilidad, el modelo puede inclinarse a clasificar nuevas observaciones en el grupo con mayor peso estadístico, sin considerar adecuadamente las características particulares de cada caso.


Además, esta situación afecta la precisión predictiva del análisis. Al no cumplirse el supuesto de igualdad de covarianzas, la función discriminante lineal utilizada deja de ser la más adecuada para separar los grupos, lo que puede traducirse en una mayor cantidad de errores de clasificación. Esto se refleja especialmente en las dificultades del modelo para identificar correctamente los vuelos que efectivamente presentan demoras.

En conclusión, el supuesto de igualdad de matrices de covarianza es rechazado empíricamente. Las varianzas entre los grupos de vuelos (con y sin demora) difieren significativamente, lo cual es una limitación para el modelo lineal.

Diferencia significativa entre medias

Para determinar la capacidad discriminatoria de las variables predictoras continuas, se procedió a analizar si existía una diferencia significativa entre sus medias al segmentar la muestra en los dos grupos de interés: vuelos sin demora (Demora = 0) y vuelos con demora (Demora = 1). Este supuesto es fundamental, puesto que si las medias de una variable son estadísticamente iguales en ambos grupos, dicha variable carece de utilidad para clasificar nuevas observaciones.

Suma de minutos



Si observamos los boxplots realizados en la etapa de análisis exploratorio (visibilidad, ocupación y tiempo estimado de vuelo, todos según si hubo o no demora) y el boxplot de la nueva variable “suma de minutos” según la demora, podemos verificar de manera visual que hay mucha superposición entre las distribuciones de los datos de ambos grupos. Esto hace que sea difícil poder separar los datos y por ende no se podría encontrar una recta discriminante eficiente.

Para una corroboración no tan empírica, se crearon las tablas de "Prueba de igualdad de medias de grupos", a través de las cuales se aplicó un proceso iterativo para descartar aquellos predictores que no alcanzaban el nivel de significancia requerido ($\text{Sig.} < 0,05$):

En las primeras iteraciones, tiempo estimado de vuelo fue la variable que obtuvo el valor de significancia más alto (0,334), por lo cual fue la primera que se decidió eliminar del modelo. Luego, se identificó que la variable suma de minutos arrojó una significancia de 0,109, indicando que sus medias no difieren entre grupos, por lo que fue eliminada del modelo. Posteriormente, se observó el mismo comportamiento en la variable ocupación del vuelo, la cual obtuvo una significancia de 0,068 y también fue removida. Tras este proceso de depuración, la única variable que demostró poseer diferencias significativas entre los grupos fue la visibilidad.

Al examinar la tabla de "Estadísticas de grupo", esta discrepancia se hace evidente en los valores absolutos: el grupo de vuelos sin demora (Demora = 0) registró una visibilidad media de 16,122, mientras que el grupo de vuelos efectivamente demorados (Demora = 1) presentó una media inferior, de 13,768.

Estadísticas de grupo

				N válido (por lista)	
demora		Media	Desv. Desviación	No ponderados	Ponderados
0	ocupacion_vuelo	71,2207	15,81489	10222	10222,000
	visibilidad	16,1216	8,26965	10222	10222,000
	tiempo_estimado_vuelo	168,9526	171,62819	10222	10222,000
	MInutos_suma	678,1916	298,02203	10222	10222,000
1	ocupacion_vuelo	71,7314	16,27694	4778	4778,000
	visibilidad	13,7680	9,16139	4778	4778,000
	tiempo_estimado_vuelo	171,8468	169,68279	4778	4778,000
	MInutos_suma	686,5498	295,93437	4778	4778,000
Total	ocupacion_vuelo	71,3833	15,96475	15000	15000,000
	visibilidad	15,3719	8,63340	15000	15000,000
	tiempo_estimado_vuelo	169,8745	171,01058	15000	15000,000
	MInutos_suma	680,8540	297,37427	15000	15000,000

Esta separación se corroboró en la tabla final de la "Prueba de igualdad de medias de grupos", donde la visibilidad alcanzó una significancia (Sig.) de 0,000. No obstante, al evaluar la magnitud real de esta diferencia mediante la Lambda de Wilks, el valor obtenido fue de 0,984.

Lambda de Wilks

Prueba de funciones	Lambda de Wilks	Chi-cuadrado	gl	Sig.
1	,983	252,457	4	,000

El valor 0,983 al ser un valor tan cercano a 1 indica que no se puede distinguir de forma clara los vuelos que tienen demora contra los que no tuvieron demora. Por lo tanto, aunque la diferencia de medias cumple con el requisito matemático, el poder discriminatorio real de la variable "visibilidad" resulta insuficiente para sostener un modelo predictivo robusto por sí sola.

Ejecución de clasificación por discriminante

Luego de realizar la clasificación por discriminante obtuvimos un Recall de 51.5%, un Specificity de 56.3% y una Accuracy de 54.8%. Si bien es un modelo balanceado en cuanto a Recall y Specificity, el bajo valor del Recall hace que no sea un buen modelo a la hora de predecir vuelos que serán demorados.

Observado\Pronosticado	0	1
0	1756	1364
1	674	716

Validación del modelo con los datos de test

Con el objetivo de analizar la capacidad de generalización del modelo discriminante, se aplicó la función obtenida sobre los datos de test, que, en este caso, es el 30% del total de las observaciones que no fueron utilizadas en el train. Se repitieron las tres corridas, variando el conjunto de variables predictoras en cada una.

La **primer corrida** se realizó con todas las variables y se obtuvieron los siguientes resultados:

Observado/Pronosticado	0	1
0	1764	1356
1	699	721

Se obtuvieron las siguientes métricas: Accuracy: 55,1%, Recall: 51,9% y Precisión: 34,7%, lo cual nos indica que menos de la mitad de los vuelos pronosticados como demorados, realmente están demorados. Esto generaría una gran cantidad de falsos positivos y por lo tanto, un costo innecesario incurrido por la empresa.

La segunda corrida se realizó sin la variable distancia_vuelo, ya que presentaba una correlación alta con tiempo_estimado_vuelo. Se obtuvo:

Observado/Pronosticado	0	1
0	1760	1360
1	671	719

Eliminando la variable mencionada, las métricas se mantuvieron casi igual: Accuracy del 55%, Recall de 51,7% y una Precisión del 34,6%. Esto quiere decir, que eliminar la variable distancia_vuelo no genera una mejora y sigue clasificando de forma precaria a los vuelos que realmente están demorados.

Para la **tercera corrida**, solo se utilizó la variable visibilidad ya que es la única variable con poder discriminatorio significativo. Los resultados fueron:

Observado/Pronosticado	0	1
0	1756	1364
1	674	716

Con esto, se obtuvo un Accuracy del 54,8%, Recall del 51,5% y una Precisión del 34,4%, que es la más baja de las 3 corridas, por lo que este modelo tampoco es adecuado para el objetivo de negocio.

Esto es representativo ya que al analizar los supuestos necesarios para realizar el análisis de Discriminante, comprobamos que no todos ellos nos daban de la forma correcta como para aplicar este modelo predictivo de clasificación. Recordando, los supuestos que no se cumplieron son: distribución normal de variables, la homogeneidad de covarianzas y diferencias significativas entre medias.

Regresión Logística

Su objetivo es predecir la probabilidad de demora utilizando una variable binaria.

Comprobación de supuestos

Corrida inicial

La Regresión Logística necesita que los datos cumplan ciertos supuestos para poder ser aplicada, estos son:

- Error con promedio igual a cero.
- Errores de cada variable independiente.
- Distribución normal en las variables.
- No multicolinealidad entre variables.

Para comprobar algunos de estos supuestos hicimos una corrida inicial con el fin de generar las probabilidades de demora de cada vuelo y almacenarlas en la nueva variable PRE_1.

A partir de la misma se calcula el error como Demora - PRE_1.

Error con promedio igual a cero

Prueba para una muestra

Valor de prueba = 0						
					95% de intervalo de confianza de la diferencia	
	t	gl	Sig. (bilateral)	Diferencia de medias	Inferior	Superior
Error	-,940	14999	,347	-,00339	-,0105	,0037

Como la significancia es mayor a 0,05 se acepta la hipótesis nula: se tiene la media del error en 0. Este supuesto es importante porque demuestra que la distribución de los errores no está sesgada y que, por ende, no hay sesgos en las predicciones.

Errores de cada variable independiente.

El supuesto de homocedasticidad establece que la varianza de los errores (o residuos) es constante a lo largo de todas las observaciones y niveles de las variables independientes en un modelo estadístico.

Prueba de homogeneidad de varianzas

		Estadístico de Levene	gl1	gl2	Sig.
Error	Se basa en la media	383,505	1	14998	,000
	Se basa en la mediana	348,607	1	14998	,000
	Se basa en la mediana y con gl ajustado	348,607	1	14820,226	,000
	Se basa en la media recortada	384,114	1	14998	,000

La independencia de los errores es importante porque la presencia de correlación entre ellos puede provocar estimaciones ineficientes y errores estándar incorrectos. Si las observaciones no son independientes, los coeficientes pueden seguir siendo estimados, pero las pruebas de significancia y los intervalos de confianza pueden resultar engañosos.

La significancia es menor a 0,05, por ende rechazo la H_0 , hay heterocedasticidad.

Distribución normal en las variables

Pruebas de normalidad

Kolmogorov-Smirnov ^a			
	Estadístico	gl	Sig.
Error	,268	15000	,000

a. Corrección de significación de Lilliefors

Como la significancia es menor a 0,05, el error no tiene distribución normal.

No multicolinealidad entre variables

Este es uno de los supuestos más importantes. Cuando dos o más variables independientes están altamente correlacionadas, resulta difícil distinguir el efecto individual de cada una sobre la variable dependiente. Como consecuencia, los coeficientes pueden volverse inestables, aumentar sus errores estándar e incluso cambiar de signo ante pequeñas modificaciones de los datos.

Diagnósticos de colinealidad^a

Modelo	Dimensión	Autovalor	Índice de condición	Proporciones de varianza		
				(Constante)	distancia_vuelo	congestion_aerea_num
1	1	7,074	1,000	,00	,00	,01
	2	,989	2,674	,00	,00	,01
	3	,616	3,390	,00	,00	,03
	4	,439	4,012	,00	,00	,87
	5	,330	4,633	,00	,00	,03
	6	,240	5,433	,00	,00	,00
	7	,193	6,061	,00	,00	,01
	8	,100	8,431	,03	,00	,02
	9	,020	18,893	,66	,00	,01
	10	,001	101,152	,31	1,00	,00

Como la última fila del índice de condición da un valor mayor a 30, hay multicolinealidad. Puede que esté dado por las variables redundantes.

Supuesto de independencia entre variables explicativas y el error

Correlaciones		Error
distancia_vuelo	Correlación de Pearson	-,001
	Sig. (bilateral)	,919
	N	15000
congestion_aerea_num	Correlación de Pearson	-,006
	Sig. (bilateral)	,453
	N	15000
ocupacion_vuelo	Correlación de Pearson	,001
	Sig. (bilateral)	,905
	N	15000
temporada_alta_bin	Correlación de Pearson	-,003
	Sig. (bilateral)	,683
	N	15000
puerta_embarque	Correlación de Pearson	,001
	Sig. (bilateral)	,918
	N	15000
visibilidad	Correlación de Pearson	,004
	Sig. (bilateral)	,660
	N	15000
tiempo_estimado_vuelo	Correlación de Pearson	-,001
	Sig. (bilateral)	,931
	N	15000
horas_sp	Correlación de Pearson	-,006
	Sig. (bilateral)	,454
	N	15000
minutos_sp	Correlación de Pearson	,000
	Sig. (bilateral)	,967
	N	15000

Como todas las filas tienen significancia mayor a 0,05 se acepta la H0 de que el error es independiente de dicha variable para cada una de ellas.

Correlaciones		tiempo_estimado_vuelo
distancia_vuelo	Correlación de Pearson	,999**
	Sig. (bilateral)	,000
	N	15000

Otra cosa que podemos observar es que la correlación distancia_vuelo y tiempo_estimado_vuelo es prácticamente 1, lo cual implica que ambas variables ofrecen la misma información (son redundantes).

Identificación de outliers

Estadísticos descriptivos

	N	Mínimo	Máximo	Media
Equivalente a los estadísticos de influencia de Cook	15000	,00033	,19655	,0098160
N válido (por lista)	15000			

No se observan puntos influyentes, ya que el valor máximo es menor que uno.

Supuesto de no autocorrelación

Autocorrelaciones

Serie: Error

Retardo	Autocorrelación	Desv. Error ^a	Estadístico de Box-Ljung		
			Valor	gl	Sig. ^b
1	,895	,008	12013,026	1	,000
2	,896	,008	24055,451	2	,000
3	,894	,008	36040,525	3	,000
4	,894	,008	48040,544	4	,000
5	,893	,008	60006,519	5	,000
6	,894	,008	72005,602	6	,000
7	,892	,008	83951,840	7	,000
8	,895	,008	95962,007	8	,000
9	,893	,008	107942,236	9	,000
10	,893	,008	119900,614	10	,000
11	,893	,008	131861,313	11	,000
12	,893	,008	143829,120	12	,000
13	,893	,008	155800,613	13	,000
14	,893	,008	167765,271	14	,000
15	,891	,008	179676,917	15	,000
16	,892	,008	191620,434	16	,000

a. El proceso subyacente asumido es independencia (ruido blanco).

b. Se basa en la aproximación de chi-cuadrado asintótica.

Como todas las significancias son menores a 0,05 se rechaza la H0 y se acepta la H1 de que todos los errores están autocorrelados.

Ejecuciones de la Regresión Logística

Cuando uno corre el modelo de predicción, el mismo software trabaja las variables categóricas dividiéndolas en un conjunto de columnas donde cada categoría posible para dicha variable se transforma en una columna, en estas se coloca un 1 en cada fila que tenía dicha categoría y un 0 para el resto.

Luego, se realiza la regresión lineal binaria con el bloque 0. Este bloque es el "modelo nulo", es decir, un modelo que intenta predecir la demora solo usando la constante, sin ninguna de las variables predictoras. El mismo nos arrojó una Precisión de 0% y un Recall de 0% debido a que los vuelos no demorados son mayoría.

El **Bloque 1** es el modelo real una vez que el algoritmo introduce las variables predictoras que seleccionamos. En este caso obtuvimos una Precisión de 60.27%, un Recall de 25% y un Accuracy de 70.4% con los datos de entrenamiento y una Precisión de 56%, un Recall

de 23.2% y un Accuracy de 70.8% con los datos de prueba, lo cual si bien representa una gran mejora con respecto al bloque 0 e indica que el modelo no está sobreajustado, no llega a ser suficiente para catalogarlo como un buen modelo predictor de vuelos demorados.

En la **segunda corrida** sacamos las variables tiempo_estimado_vuelo por la redundancia observada y luego, por lo observado en el EDA, se sacaron puerta_embarque, dia_semana, aeropuerto_origen, aeropuerto_destino, tipo_avion y ocupacion_vuelo. Este cambio produjo que la Precisión aumente a 63%, el Recall disminuya a 19.5% y la Accuracy se mantenga en 70.4% con los datos de entrenamiento y que la Precisión aumente a 62%, el Recall disminuya a 18.7% y la Accuracy aumente a 71.4% con los datos de prueba lo cual implicaría que a primera vista el modelo empeora al sacar las variables. Sin embargo, al analizar la curva ROC, se encontró el punto de corte 0.3276655 que mejora con respecto al punto de corte por default.

Al realizarse una **tercera corrida** con este nuevo punto de corte obtuvimos una Precisión de 43.5%, Recall de 63.2% y un Accuracy de 63.4% para el set de datos de entrenamiento, y una Precisión, Accuracy y Recall de 44,53%, 63,42% y 62,83% respectivamente para los datos de testeo. Evidentemente, el modelo empeora en gran medida.

En la **cuarta corrida** se sacaron las variables condiciones_climáticas, temporada_alta y congestion_aerea debido a que tenían una significancia muy baja en el modelo. Esto hizo que tanto la Precisión como el Recall disminuyan a 35% y 50,1% respectivamente así como el Accuracy a 56% en el set de datos de entrenamiento; y para el set de prueba se obtuvieron valores de 37,71% y 53,48% para la Precisión y el Recall respectivamente. Antes de realizar la próxima corrida decidimos volver a analizar la curva ROC del nuevo modelo y encontramos el punto de corte 0,3277164.

Se realizó la **quinta** y última corrida con las mismas variables que en la anterior, pero con el punto de corte mencionado anteriormente. Obtuvimos una Precisión del 35%, Recall de 50,1% y Accuracy de 56,1% para el dataset de entrenamiento, y Precisión del 37,69% y Recall del 53,45% para el dataset de prueba.

Luego de esto se llegó a la conclusión de que el mejor modelo fue el resultante de la segunda corrida, ya que es el que tiene una precisión más alta, lo cual se alinea al objetivo de negocio.

Observado\Pronosticado	0	1
0	2961	159
1	1130	260

Conclusión sobre el modelo predictivo

En base a los objetivos definidos, los modelos realizados y los resultados obtenidos, decidimos que el modelo que mejor puede predecir si un vuelo está demorado o no, es el de Regresión Logística. Este modelo es la opción más equilibrada, maximiza la detección de

demoras reales sin comprometer la credibilidad del sistema de alertas ni generar un volumen de compensaciones innecesaria que afecte la economía de la organización.

Si observamos su matriz de confusión, el modelo no está sesgado hacia ninguna clase, lo que en contexto de negocio significa que el costo de los errores está distribuido, no concentrado en un solo tipo de falla.

Sin embargo consideramos la posibilidad de elegir el árbol de decisión debido a ser el que mayor tasa de detección de vuelos que serán demorados a cambio de una alta tasa falsos positivos. Al final concluimos que el valor generado al detectar más vuelos que estaban demorados, no supera a la pérdida por aquellos vuelos que salían a tiempo pero que resultaban catalogados como demorados.

Luego de elegir el mejor modelo a nuestro criterio. Realizamos una corrida de predicciones con los casos nuevos, casos que el modelo no vió nunca, ni al entrenar, ni al validar.

Los resultados obtenidos son los siguientes:

- Vuelos demorados: 461
- Vuelos no demorados: 4538

Se puede observar que en el 90.76% de los vuelos se predice que no hay demora, mientras que en el resto de los casos probablemente haya demora.

Etapas de agrupamiento

Análisis exploratorio de los datos (Clientes)

De la misma manera que se realizó para el dataset de Vuelos, revisamos que los datos no contengan datos nulos.

#	Column	Non-Null Count	Dtype
0	sexo	50000 non-null	object
1	provincia	50000 non-null	object
2	edad	50000 non-null	int64
3	ocupacion	50000 non-null	object
4	cant_vuelos	50000 non-null	int64
5	clase_preferida	50000 non-null	object
6	gasto_acumulado	50000 non-null	float64
7	gasto_acumulado_extra	50000 non-null	float64
8	programaMillas	50000 non-null	object
9	cantidad_millas	50000 non-null	int64
10	ingreso_mensual	50000 non-null	int64
11	anticipacion_compra_promedio	50000 non-null	int64
12	canal_compra	50000 non-null	object

Observamos que los registros no contienen datos nulos, lo cual hace que no sea necesario realizar técnicas de tratamiento de valores faltantes.

	sexo	provincia	edad	ocupacion	cant_vuelos	clase_preferida	gasto_acumulado	gasto_acumulado_extra	programaMillas	cantidad_millas	ingreso_mensual	anticipacion_compra_promedio	canal_compra
count	50000	50000	50000	50000	50000	50000	50000	50000	50000	50000	50000	50000	50000
unique	3	31	NaN	15	NaN	3	NaN	NaN	2	NaN	NaN	NaN	4
top	M	Entre Ríos	NaN	Empleado	NaN	Económica	NaN	NaN	No	NaN	NaN	NaN	Web
freq	24973	2417	NaN	11430	NaN	37093	NaN	NaN	38052	NaN	NaN	NaN	19743
mean	NaN	NaN	37.8274	NaN	17.07186	NaN	6587.557023	953.732059	NaN	6759.36198	3062.88216	19.91066	NaN
std	NaN	NaN	11.478895	NaN	15.758184	NaN	18186.87888	1687.615883	NaN	28526.6124	8788.288844	84.48158	NaN

Sexo

count	
sexo	
M	24973
F	24515
No binario	512

count	
sexo	
M	49.946
F	49.030
No binario	1.024

En la variable sexo, podemos observar que está bastante equilibrado entre clientes masculinos y femeninos (ambos representan aproximadamente el 49% de los datos). El genero no binario representa una minoria en los datos.

Provincia

provincia		provincia	
Entre Ríos	2417	Entre Ríos	4.834
Buenos Aires	2390	Buenos Aires	4.780
Chaco	2388	Chaco	4.776
Salta	2370	Salta	4.740
Córdoba	2349	Córdoba	4.698
Mendoza	2338	Mendoza	4.676
Santa Fe	2331	Santa Fe	4.662
Misiones	2322	Misiones	4.644
CABA	2315	CABA	4.630
Tucumán	2289	Tucumán	4.578
Bolívar	1627	Bolívar	3.254
Antioquia	1596	Antioquia	3.192
Valle del Cauca	1570	Valle del Cauca	3.140
Atlántico	1563	Atlántico	3.126
Santander	1561	Santander	3.122
Nariño	1547	Nariño	3.094
Tolima	1544	Tolima	3.088
Cundinamarca	1519	Cundinamarca	3.038
Paraná	1196	Paraná	2.392
Rio de Janeiro	1192	Rio de Janeiro	2.384
São Paulo	1189	São Paulo	2.378
Pernambuco	1175	Pernambuco	2.350
Minas Gerais	1149	Minas Gerais	2.298
Rio Grande do Sul	1147	Rio Grande do Sul	2.294
Bahia	1143	Bahia	2.286
Los Santos	978	Los Santos	1.956
Chiriquí	972	Chiriquí	1.944
Panamá	964	Panamá	1.928
Colón	963	Colón	1.926
Veraguas	955	Veraguas	1.910
Herrera	941	Herrera	1.882

Podemos observar que se registraron provincias pertenecientes a 4 países diferentes Argentina, Colombia, Brasil y Panamá. Para cada país, se tiene que cada provincias tienen

una distribución uniforme (por ejemplo las provincias argentinas rondan entre el 4.6% y 4.8%). Se puede ver una predominancia de clientes argentinos ya que representan aproximadamente el 50% de los datos.

Ocupación

ocupacion		ocupacion	
Empleado	11430	Empleado	22.860
Profesional independiente	4378	Profesional independiente	8.756
Docente	4378	Docente	8.756
Estudiante	3615	Estudiante	7.230
Ejecutivo	3535	Ejecutivo	7.070
Comerciante	3446	Comerciante	6.892
Ingeniero	3053	Ingeniero	6.106
Empresario	2979	Empresario	5.958
Otro	2973	Otro	5.946
Médico	2582	Médico	5.164
Abogado	2115	Abogado	4.230
Contador	2063	Contador	4.126
Arquitecto	1673	Arquitecto	3.346
Deportista	1268	Deportista	2.536
Jubilado	512	Jubilado	1.024

Podemos observar que mayoritariamente los clientes son empleados (22.86%). Luego se puede ver que docentes, profesionales independientes, estudiantes, ejecutivos, comerciantes e ingenieros, cada uno representa una porción similar de los datos. Por otro lado, hay una concentración muy baja para los jubilados, que por poco supera el 1%, siendo los que menos vuelan en esta aerolínea.

Clase preferida

count	
clase_preferida	
Económica	37093
Ejecutiva	10937
Primera clase	1970

count	
clase_preferida	
Económica	74.186
Ejecutiva	21.874
Primera clase	3.940

Hay un dominio absoluto por parte de la clase Económica (representa el 74.18% de los datos). La distribución sigue coherentemente la lógica de precios.

Programa Millas

count	
programaMillas	
No	38052
Sí	11948

count	
programaMillas	
No	76.104
Sí	23.896

La gran mayoría de clientes no está inscrito en el programa de millas. Podemos observar que el porcentaje de clientes que sí están inscritos en el programa de millas es similar al porcentaje de clientes que prefieren clase ejecutiva, lo cual indica una probable correlación entre variables.

Canal de compra

canal_compra	
Web	19743
App	18514
Agencia	7300
Aeropuerto	4443

canal_compra	
Web	39.486
App	37.028
Agencia	14.600
Aeropuerto	8.886

Se puede ver una clara predominancia de los canales de autogestión online ya que si sumamos las compras por la Web (39.48%) y por la App (37.02%), vemos que más del 76.5% de los clientes eligen vías digitales para adquirir sus pasajes. Las compras presenciales representan una minoría debido a que este tipo de situaciones quedan reservadas, generalmente, a situaciones de emergencias o cambios de último momento.


En conclusión, tras observar las variables sexo, ocupación y canal de compra no poseen el poder de segmentación necesario para el modelo. Debido a cómo se distribuyen sus datos,

ya sea por falta de varianza o por alta concentración en una sola respuesta, no aportan información relevante que permita agrupar a los clientes de manera estratégica.

Análisis Univariado


Histogramas y boxplot

Histograma de la edad del cliente




En este histograma se puede observar que la variable sigue una distribución bastante normal, ligeramente sesgada hacia la derecha. El grueso de los clientes de la aerolínea se concentra fuertemente en la franja que va de los 30 a los 50 años, cerca de los 35-40 años. A partir de los 50 años, la frecuencia comienza a descender de manera escalonada y, luego, entre los 65-70 años ya no es algo frecuente. Algo a destacar es que hay un pico en los 18 años, no sabemos a ciencia cierta la causa de esto (una causa podría ser que sea la edad mínima permitida por el sistema para comprar).

Boxplot de la edad del cliente




Este boxplot confirma lo visto en el histograma anterior, donde la mitad de los clientes están muy concentrados en adultos jóvenes/medios (entre los 29 y los 47 años). Lo que agrega este boxplot es la detección de valores atípicos más allá de los 71 años lo cual indica que rara vez viaja gente muy mayor.

Histograma de la cantidad de vuelos del cliente



Podemos observar una clara división en dos bloques. El primer bloque va entre 1 y 24/25 (aproximadamente) vuelos, el cual tiene una alta densidad, y, luego, el bloque siguiente sufre una caída abrupta de densidad, que llega hasta los 100 vuelos. Este segundo bloque representa el segmento de viajeros que son muy frecuentes en la aerolínea (que son pocos en cantidad pero acumulan muchos viajes).


Boxplot de la cantidad de vuelos del cliente



El 50% central de los datos está concentrado altamente en la parte baja, aproximadamente entre los 5 y los 21 vuelos (similar a lo observado en el histograma). Podemos ver que la mediana se ubica entre los 13 y 14 vuelos, lo que significa que la mitad de los clientes del dataset tiene esa cantidad de vuelos o menos.

Es importante destacar la alta densidad de valores atípicos, que aparecen a partir de aproximadamente los 43/45 vuelos y que al ser tantos casos así se forma una línea negra gruesa y continua hasta llegar al 100. Esto hace que no deban ser eliminados mediante técnicas estándar de limpieza de rango intercuartílico, ya que conlleva a una pérdida de información valiosa porque representa un segmento de alto valor comercial.


Histograma del gasto acumulado del cliente



El histograma muestra una clara asimetría positiva, donde el pico más alto está pegado al cero, lo cual indica que el grueso de los clientes se compone mayoritariamente por clientes ocasionales o que han gastado montes muy bajos.


Luego, el gráfico cae en picada hacia la derecha, generando una larga cola que representa los clientes VIPs o corporativos (que son pocos pero que acumulan muchos gastos).

Boxplot del gasto acumulado del cliente



El gráfico identifica una cantidad masiva y continua de valores atípicos en el extremo superior. Dado que estos registros atípicos representan el sector más rentable del negocio y no errores de captura, no deben ser removidos. Esto confirma estadísticamente que el gasto del cliente promedio es bajo comparado con los máximos del sistema.


Histograma del gasto acumulado extra del cliente



Este histograma, al igual que en el de gasto acumulado, vemos que los clientes tienen un gasto extra acumulado de 0 (o cercano), es decir, los clientes viajan con lo que pagaron el

pasaje y no gastan en otro tipo de servicio adicional. Luego, hay una caída en picada muy pronunciada que indica que los que sí tienen un gasto extra son en montos muy pequeños. La cola va hasta los U\$D 40000/50000 en gasto extra aproximadamente, lo cual indica que hay muy pocos usuarios que tienen un gasto extra acumulado alto.

Boxplot del gasto acumulado extra del cliente



La caja está tan comprimida contra el margen izquierdo que apenas se ve. La mediana (el cliente típico) claramente está en cero o en un valor ínfimo. El 50% central de los datos prácticamente no tiene variación significativa en gasto extra. A partir de valores bajos (probablemente apenas superando los U\$D 2000 o 3000), el boxplot ya empieza a indicar valores atípicos. Nuevamente, se tiene una línea sólida de outliers, estadísticos que, en el contexto del negocio, representan ventas cruzadas exitosas.


Histograma de la cantidad de millas del cliente



En el histograma, se destaca un pico de concentración masiva en el primer intervalo (cercano a cero), el cual es totalmente congruente con el hecho de que más del 76% de los usuarios no posee el programa activo.


La mayoría de los inscriptos tiene pocas millas (las canjean rápido o viajan poco), mientras que un grupo minúsculo de viajeros corporativos acumula saldos gigantescos (más de 500.000 millas).

Boxplot de la cantidad de millas del cliente



La caja y la mediana están literalmente colapsadas en el cero o en un valor ínfimo, directamente no se ve la caja. Esto hace que prácticamente cualquier usuario que tenga millas acumuladas es considerado un valor atípico. Esa línea negra densa y continua son los clientes que realmente participan activamente del programa. Por lo tanto, estos registros extremos no deben ser descartados bajo ninguna circunstancia, ya que representan al núcleo de clientes fidelizados de la aerolínea.


Histograma del ingreso mensual del cliente



El histograma muestra que el grueso de los clientes de la aerolínea tiene ingresos mensuales que rondan los valores más bajos y medios de la escala. Luego, la caída en


picada de la curva indica que la cantidad de personas disminuye drásticamente a medida que sube el nivel de ingresos (son pocas personas con alto nivel adquisitivo).

Boxplot del ingreso mensual del cliente




La caja se encuentra fuertemente comprimida, con una mediana muy cercana al límite inferior. A nivel estadístico, esto provoca que cualquier ingreso de nivel medio-alto o alto sea catalogado como un valor atípico (outlier). Destaca, además, la presencia de registros extremos fuertemente aislados (superiores a 200.000 y 350.000).

Histograma de días anticipacion promedio de compra de los clientes



El pico máximo de la distribución está pegado al cero, lo cual indica que el volumen más grande de los usuarios compra sus pasajes con muy poca anticipación. Se destaca la presencia de picos periódicos en la distribución (visibles en intervalos aproximados de 7, 14, 30 y 60 días), lo que refleja que los clientes tienden a realizar transacciones en fechas redondas (por ejemplo, exactamente una semana o un mes antes del vuelo).


Boxplot de días anticipación promedio de compra de los clientes



La caja está comprimida hacia la izquierda, donde la mediana se ubica entre los 10 y los 15 días previos al vuelo. La gráfica detecta valores atípicos en aquellas compras con más de 60 días de antelación. Esta línea sólida de registros atípicos, que se extiende hasta los 180 días (6 meses), representa al segmento de usuarios con perfiles de alta planificación (muchísimos clientes con ese perfil).

Gráficos de barras

Cantidad de pasajeros según sexo




La distribución de pasajeros según el sexo muestra una composición equilibrada entre hombres y mujeres, con aproximadamente 25.000 clientes masculinos y 24.000 femeninos. La categoría "No binario" presenta una cantidad muy reducida de registros, esto indica que la base de clientes esta conformada principalmente por generos binarios.

La distribución es aproximadamente un 50% de observaciones en cada categoría. Dado que no existe una concentración significativa de clientes en ninguna categoría y la distribución

es homogénea, la variable sexo no parece aportar información relevante para diferenciar o segmentar grupos de clientes, ya que no evidencia patrones distintivos dentro de la población analizada.


Cantidad de pasajeros por provincia



La distribución de pasajeros por provincia presenta diferencias moderadas entre jurisdicciones. Algunas provincias, como Salta, Córdoba, Misiones, Tucumán, Santa Fe, CABA, Chaco, Mendoza y Entre Ríos, registran una mayor cantidad de pasajeros, con valores cercanos a los 2.300-2.400 clientes. Sin embargo, el resto de las provincias también poseen una participación significativa, generalmente superior a los 1.000 pasajeros. No se observan concentraciones extremas ni grupos claramente diferenciados que permitan definir segmentos geográficos naturales. Por ello, la variable provincia no parece aportar un elevado poder discriminante para la segmentación de clientes.


La distribución de pasajeros por provincia presenta una dispersión homogénea entre las distintas jurisdicciones. Si bien provincias como Salta, Córdoba, Misiones, Tucumán, Santa Fe, CABA, Chaco, Mendoza y Entre Ríos registran un volumen levemente superior (valores cercanos a los 2.300-2.400 clientes), el resto de las jurisdicciones mantiene una participación constante y significativa, superando los 1.000 pasajeros. Al no observarse concentraciones extremas, asimetrías severas ni brechas significativas entre regiones, se concluye que la variable provincia no posee poder discriminante para la segmentación. Por lo tanto, descartamos incluirla en el modelo de agrupamiento, ya que no aporta variabilidad útil para diferenciar el comportamiento de los clientes.

Cantidad de pasajeros según ocupación




La distribución de pasajeros según ocupación muestra una concentración muy marcada en la categoría Empleado, que agrupa aproximadamente 11.500 clientes, representando más del doble que cualquier otra ocupación.

Cantidad de pasajeros según clase preferida




La mayoría de los pasajeros (aproximadamente 37.000) prefiere viajar en clase económica, mientras que la clase ejecutiva concentra alrededor de 11.000 clientes. La primera clase representa únicamente cerca de 2.000 pasajeros, equivalente a aproximadamente el 4% de la cartera total. Esta baja participación evidencia la existencia de un grupo reducido y exclusivo de clientes con preferencias de viaje diferenciadas, por lo que la categoría Primera Clase constituye un segmento VIP natural que merece ser analizado de manera particular dentro de la estrategia de segmentación.

Cantidad de pasajeros afiliados y no afiliados al programa millas



Se puede observar que la mayoría de los pasajeros no está afiliado al programa de millas unos 37.000 pasajeros aproximadamente, mientras que la minoría mantiene una afiliación activa 12.000 clientes aproximadamente.

Cantidad de pasajeros según el canal de compra



Los canales digitales dominan las compras de pasajes, con web cercano a 20.000 pasajeros y app un aproximado a 18.500 pasajeros. Los canales tradicionales tienen presencia minoritaria: agencia con 7.500 clientes y Aeropuerto con 4.500, demostrando la preferencia de los pasajeros por plataformas online.

Si bien existen diferencias en la frecuencia de utilización de cada canal, estas reflejan una preferencia generalizada por los medios digitales más que la existencia de grupos de clientes claramente diferenciados. Por lo tanto, el canal de compra no parece constituir una variable con alto poder discriminante para la segmentación.

El análisis del canal_compra evidencia una marcada preferencia de los pasajeros por las plataformas digitales, donde los canales Web y App concentran el mayor volumen de operaciones (alcanzando aproximadamente 20.000 y 18.500 registros respectivamente), superando ampliamente a las compras presenciales en Agencia y Aeropuerto.

A pesar de esta notable concentración en el ecosistema digital, la tendencia se repite casi por igual en todo tipo de clientes. Como la mayoría prefiere comprar por internet sin importar sus ingresos o su perfil, la variable no ayuda a diferenciar un grupo de otro. Por este motivo, se decidió no incluirla en el modelo de agrupamiento, ya que no aporta información útil para separar a los clientes en segmentos distintos.

Análisis Multivariado

Matriz de covarianzas

	edad	cant_vuelos	gasto_acumulado	gasto_acumulado_extra	cantidad_millas	ingreso_mensual	anticipacion_compra_promedio
edad	131.776285	19.949582	8.959960e+03	1.242403e+03	1.022505e+04	3.729699e+03	-19.628833
cant_vuelos	19.949582	248.075858	1.203627e+05	1.738962e+04	1.841592e+05	1.901951e+04	-38.076482
gasto_acumulado	8959.959649	120362.707455	1.547506e+08	2.239549e+07	1.625663e+08	1.856816e+07	-19671.211744
gasto_acumulado_extra	1242.402641	17389.616596	2.239549e+07	3.950614e+06	2.345719e+07	2.711224e+06	-2771.858091
cantidad_millas	10225.046659	184159.221893	1.625663e+08	2.345719e+07	5.536441e+08	2.343386e+07	-29262.358128
ingreso_mensual	3729.699355	19019.513698	1.856816e+07	2.711224e+06	2.343386e+07	1.429128e+07	-4327.631060
anticipacion_compra_promedio	-19.628833	-38.076482	-1.967121e+04	-2.771858e+03	-2.926236e+04	-4.327631e+03	458.027639

Al observar la matriz de covarianzas de la tabla de clientes, notamos que no está estandarizada y resulta muy sensible a las unidades de medida (por ejemplo, la varianza de los ingresos o gastos muestra valores altísimos frente a los de la edad). Sin embargo, nos permite identificar direcciones en los datos: métricas de actividad como cantidad de vuelos, ingreso mensual y gasto acumulado varían en la misma dirección (covarianzas positivas), mientras que la anticipación de compra se mueve en sentido inverso a casi todas las demás (covarianza negativa). Por estas razones, es mejor utilizar la matriz de correlaciones, la cual sí estandariza los valores entre -1 y 1.

Matriz de correlaciones

	edad	cant_vuelos	gasto_acumulado	gasto_acumulado_extra	cantidad_millas	ingreso_mensual	anticipacion_compra_promedio
edad	1.000000	0.110337	0.062744	0.054452	0.037856	0.085945	-0.079897
cant_vuelos	0.110337	1.000000	0.614304	0.555476	0.496919	0.319427	-0.112958
gasto_acumulado	0.062744	0.614304	1.000000	0.905758	0.555391	0.394836	-0.073887
gasto_acumulado_extra	0.054452	0.555476	0.905758	1.000000	0.501566	0.360826	-0.065162
cantidad_millas	0.037856	0.496919	0.555391	0.501566	1.000000	0.263447	-0.058110
ingreso_mensual	0.085945	0.319427	0.394836	0.360826	0.263447	1.000000	-0.053490
anticipacion_compra_promedio	-0.079897	-0.112958	-0.073887	-0.065162	-0.058110	-0.053490	1.000000

En la matriz de correlaciones se puede ver una fuerte correlación positiva de 0.905 entre **gasto_acumulado** y **gasto_acumulado_extra**, indicando que a medida que aumenta el gasto general del cliente, aumenta a su vez proporcionalmente su gasto en servicios adicionales.


Adicionalmente, se observan correlaciones positivas moderadas (entre 0.49 y 0.61) entre el bloque de variables de actividad (**cant_vuelos**, **gasto_acumulado** y **cantidad_millas**), lo

que refleja que a mayor frecuencia de vuelos crecen conjuntamente los gastos y millas obtenidas.

En el resto de las interacciones (especialmente con **anticipacion_compra_promedio** y **edad**) se presentan coeficientes muy bajos o cercanos a 0, indicando que estas variables son linealmente casi independientes del nivel de actividad o gasto del cliente.


Scatterplots

Scatterplot de Cantidad de vuelos vs Gasto acumulado




Podemos visualizar una tendencia lógica donde a mayor cantidad de vuelos, el techo de gasto acumulado sube. En cuanto a la dispersión no podemos asegurar que un cliente que tenga muchos vuelos si o si gaste mucho dinero ya que puede haber muchos vuelos de clase económica por ejemplo.

Scatterplot de Cantidad de vuelos vs Gasto acumulado extra



En este gráfico, también tiende a que donde mayor cantidad de vuelos hay mayor gasto acumulado extra. Pero mientras el gasto acumulado llega a \$250,000 el gasto en extras llega a \$45,000. El comportamiento es proporcional. El que gasta mucho en pasajes también gasta mucho en servicios extras.

Scatterplot de Cantidad de vuelos vs Cantidad de millas




A medida que aumentan los vuelos también aumentan la cantidad de millas.

La dispersión no es una línea recta, sino que se va abriendo. Refleja que no todos los vuelos valen lo mismo. Un pasajero con 60 vuelos puede tener 100,000 millas (si voló siempre económica y tramos cortos) o puede tener 300.000 millas (si viajó ejecutiva a destinos internacionales).

El gráfico es necesario para poder entender cómo podemos clasificar cada pasajero como VIP o no, ya que nos demuestra que la "frecuencia" no es igual a "valor". Por ejemplo no vamos a hacer estrictamente VIP a todos los que tengan más de 60 vuelos, podemos ver que hay muchos clientes con pocas millas y otros con muchas.

Scatterplot de Cantidad de vuelos vs Ingreso Mensual



Podemos ver que hay mucha falta de correlación, el 95% de los puntos están aplastados en la parte inferior del gráfico desde 0 a 100, esto significa que no hay relación directa entre cuánto gana una persona y cuantas veces vuela. Hay gente que gana 20.000 y vuela 5 veces y gente que gana 20.000 y vuela 90 veces.

El gráfico sirve para evitar asumir que sueldo alto = cliente leal.

Fase de Preparación

Se utilizaron aquellos clientes que estuvieron presentes en los vuelos que fueron detectados como demorados, dentro del dataset de NuevosCasos.xlsx.

Además, se realizó una transformación sobre las variables `programaMillas` y `clase_preferida`. Para `programaMillas` lo que se hizo fue pasar de variable categórica a variable booleana, donde 0 significa que no están afiliados al programa y 1 significa que si lo están. Mientras que para `clase_preferida` lo que se hizo fue aprovechar que es una variable categórica ordinal para convertir los valores posibles a números, donde `Economica=0`, `Ejecutiva=1`, `Primera clase=2`.

Para una mejor visualización de los datos, utilizamos Análisis de Componentes Principales.

Vista Minable

Variable	Tipo	Descripción
sexo	Categórica	Genero del cliente (M, F)

provincia	Categórica	Provincia donde vive
edad	Numérica	Edad del cliente
ocupacion	Categórica	Ocupación del cliente
cant_vuelos	Numérica	Cantidad de vuelos realizados
clase_preferida	Categorica Ordinal	Clase tarifaria más frecuente (0, 1, 2)
gasto_acumulado	Numérica	Consumo histórico acumulado en pasajes
gasto_acumulado_extra	Numérica	Consumo histórico acumulado en servicios extra
programaMillas	Booleana	Indica si está afiliado al programa de millas
cantidad_millas	Numérica	Si está afiliado al programa de millas indica la cantidad acumulada de millas
ingreso_mensual	Numérica	Sueldo mensual
anticipacion_compra_promedio	Numérica	Cantidad promedio de días de anticipación con que el pasajero compra sus pasajes respecto a la fecha de salida del vuelo
canal_compra	Categórica	Medio preferido para la compra de pasajes (app, web, agencia, aeropuerto)

Análisis de Componentes Principales


Se realizó un análisis de componentes principales utilizando las variables edad, cant_vuelos, clase_preferida, gasto_acumulado, gasto_acumulado_extra, programaMillas, cantidad_millas, ingreso_mensual, anticipacion_compra_promedio.

Previamente se llevó a cabo una transformación con el StandardScaler, que estandariza eliminando la media y escalando la varianza unitaria.

	PC1	PC2	PC3	PC4	PC5	PC6	PC7
X1	0.076	0.713	0.658	-0.203	-0.025	-0.095	0.0004
X2	0.442	0.045	-0.019	-0.016	0.193	0.857	-0.058
X3	0.522	-0.101	-0.013	-0.088	-0.369	-0.147	0.741
X4	0.503	-0.113	-0.014	-0.096	-0.487	-0.207	-0.666
X5	0.409	-0.097	-0.057	-0.265	0.749	-0.430	-0.047
X6	0.311	0.068	0.175	0.916	0.160	-0.026	-0.022
X7	-0.080	-0.671	0.729	-0.065	0.031	0.074	0.0008

Componente	% Varianza explicada
1	0.440503
2	0.152783
3	0.131918
4	0.110795
5	0.082927
6	0.068151
7	0.012923

El gráfico de sedimentación evidencia un codo marcado a partir de la PC1, que por sí sola explica el 44% de la varianza total, siendo ampliamente la componente más informativa. A partir de la PC2 la curva desciende de manera más gradual. Se optó por retener las primeras 4 componentes principales, las cuales explican en conjunto el 83.6% de la varianza, considerando este valor suficiente para una representación fiel de los datos sin incurrir en pérdida de información significativa.



Se pueden caracterizar las componentes retenidas:

- **PC1** recibe cargas positivas altas de cant_vuelos (0,443), gasto_acumulado (0,503), gasto_acumulado_extra (0,410) y cantidad_millas (0,523). Este componente captura el nivel de actividad y valor económico general del cliente: a mayor valor en PC1, mayor es la frecuencia de vuelos, el gasto y las millas acumuladas.
- **PC2** está dominada por cargas altas en X1 (edad, 0,714) y una carga negativa fuerte en X7 (anticipacion_compra_promedio, -0,672). Representa una dimensión que contrapone la edad del cliente con su comportamiento de compra anticipada.
- **PC3** está dominada por una carga alta negativa de X1 (edad, -0,658 aproximado en el espacio transformado) y una positiva de X7 (anticipacion_compra_promedio, 0,729). Complementa a PC2 capturando varianza residual de estas mismas variables.
- **PC4** está principalmente asociada a X6 (ingreso_mensual, 0,917), siendo casi exclusivamente un indicador del nivel de ingresos del cliente.

El ACP confirma que las variables del dataset pueden resumirse en pocas dimensiones interpretables. Sin embargo, dado que el número de variables originales no es excesivo y cada una tiene un significado de negocio claro, la etapa de clustering la vamos a realizar directamente sobre las variables originales para preservar la interpretabilidad de los segmentos resultantes.

Fase de Modelado

Clustering Jerárquico

Se realizó un modelo de clustering jerárquico utilizando Python con el cual se ejecutaron diferentes pruebas con distintos criterios de aglomeración, tales como enlace simple, enlace completo, enlace promedio, método del centroide y método de Ward.

Con el *método del centroide* llegamos a que el corte óptimo sería de alrededor de 6 grupos, realizando un corte a una distancia aproximada de 17. Esto se debe a que a partir de ese nivel se observa un incremento significativo en las distancias de fusión, indicando que las uniones posteriores agrupan grupos cada vez más diferentes entre sí. Por lo tanto, mantener 6 grupos permite conservar una adecuada homogeneidad interna y una buena separación entre los mismos.

Con el *método de Ward* llegamos a la conclusión de que el corte óptimo sería de alrededor de 5 grupos, realizando un corte a una distancia aproximada de 200. Se observa un incremento considerable en las distancias de fusión a partir de ese nivel, por lo que las uniones posteriores implicaría combinar grupos cada vez más heterogéneos. Además, este método genera grupos relativamente compactos y bien separados, favoreciendo una baja variabilidad interna dentro de cada grupo.


Con el *enlace simple* todos los cortes resultaron ser poco adecuados. Se observa el efecto de encadenamiento, donde las observaciones se van incorporando progresivamente formando grupos muy desbalanceados. La mayoría de las primeras fusiones ocurren a distancias bajas (entre 4 y 8 aproximadamente), mientras que las últimas uniones presentan saltos importantes, lo que dificulta identificar una cantidad de grupos bien definida y con una separación clara entre ellos.

Con el *encadenamiento completo* concluimos que el corte óptimo es de 6 grupos, realizando un corte a una distancia aproximada de 25. Se observa un incremento en las distancias de fusión a partir de ese nivel, por lo que las uniones posteriores comenzaron a formar grupos cada vez más diferentes entre sí. Además, los grupos obtenidos presentan una separación relativamente clara y una mayor homogeneidad interna que la obtenida con el encadenamiento simple.

Con el *encadenamiento promedio* llegamos a que el corte óptimo es de 5 grupos, realizando un corte a una distancia aproximada de 18. Si bien el dendrograma permite identificar cinco grupos razonablemente diferenciados, las fusiones se producen de manera gradual y no se observan cambios muy marcados en las distancias de unión. Además, los grupos obtenidos no presentan una estructura tan homogénea ni tan equilibrada como la obtenida con el método de Ward, por lo que la separación entre ellos resulta menos clara.

Decidimos, finalmente, quedarnos con el clustering jerárquico utilizando el *método de Ward* debido a que muestra la menor distancia final intra-grupos con una cantidad relativamente

baja de los mismos y además brinda una buena separación entre estos.




Clustering Bietápico


Se realizaron varios modelos de clustering Bietápico, utilizando el software SPSS Modeler, con diferentes entradas para evaluar la cantidad de clusters y su calidad. Se concluye que la mejor agrupación se realizaba si no se tenían en cuenta las variables *edad* y *anticipacion_compra_promedio*, obteniendo así 4 clústeres y un promedio de silueta de 0.7.

Resumen del modelo

Algoritmo	Bietápico
Entradas	7
Clústeres	4

Calidad de clúster






En esta imagen podemos observar cómo se distribuyen las variables respecto a los grupos.

En *clase_preferida* y *programaMillas*, se puede notar que los grupos están bien separados y no se superponen con los demás, gracias a esto, podemos diferenciar fácilmente a qué segmento pertenece cada cliente.

En cuanto a *cant_vuelos*, *cantidad_millas*, *gasto_acumulado* y *gasto_acumulado_extra*, se ve notablemente que el cluster verde tiene una tendencia hacia la derecha, lo cual indicaría un comportamiento diferente al cliente promedio.


Sobre *ingreso_mensual*, si bien en la imagen los promedios de los grupos aparentan ser similares, la realidad es que son diferentes entre sí. Esto indica una separación clara entre grupos.




En este gráfico de torta podemos observar qué cantidad de datos absorbe cada cluster.

Clustering No Jerárquico

Primero se realiza el método del codo para tener una guía sobre dónde pueden rondar los mejores valores de K para el método de K-Medias y así obtener una segmentación eficiente.



Una vez que obtuvimos este gráfico, se realizaron pruebas con distintos valores de K variando entre 5 y 15. Finalmente, se concluye que el K óptimo es 6.



Sin embargo, el análisis profundo del gráfico de Siluetas revela que esta segmentación no es robusta ni útil debido a que, por un lado, el cluster 1 concentra una cantidad desproporcionada de observaciones, mientras que grupos como el cluster 2 son prácticamente inexistentes lo cual indicaría que el modelo no está logrando identificar patrones subyacentes. Además, una porción significativa de las observaciones en el cluster 5 presentan valores de $S_i < 0$ lo cual es una indicación de solapamiento y mala clasificación ya que significa que dichos puntos están más cerca de un cluster vecino que del cluster al que fueron asignados.

Conclusión

En esta segunda etapa evaluamos diferentes enfoques de aprendizaje no supervisado, para lograr una segmentación de los pasajeros DS Airlines. Tras evaluar los resultados de las técnicas de clustering jerárquico, no jerárquico (k-medias) y bietápico.

El modelo jerárquico, si bien con el método Ward llegamos a tener 5 grupos bien separados, se descarta debido a su necesidad de almacenar en memoria todas las distancias entre pasajeros; mientras que el análisis de K-Medias, para un valor de $k=6$, reveló fallas críticas de solapamiento (observaciones mal clasificadas) y un desbalance extremo que dejaba grupos prácticamente vacíos.

En contraposición, al excluir variables con poca capacidad de diferenciarse entre los grupos, como la edad y la anticipación de compra, el algoritmo bietápico determinó de manera automática y consistente una estructura de 4 clusters altamente definidos, alcanzando un

buen promedio de silueta de 0.7 consiguiendo así un modelo que logra combinar la escalabilidad que le falta al jerárquico con la precisión que le falta al K-Medias.

El clustering bietápico nos permitió observar 4 grupos, cada uno con sus propias características:

- Cluster 1: se caracteriza por tener a los clientes con menores ingresos mensuales, menores gastos acumulados, tienen como clase preferida absoluta la clase económica, no poseen el programa de millas, no tienen millas acumuladas y poseen pocos viajes realizados.
- Cluster 2: este grupo está caracterizado por clientes con un nivel de ingresos, gastos acumulados y de viajes realizados mayor a los del cluster 1 pero no con una diferencia muy grande, predomina mayoritariamente la clase económica como clase preferida, tienen el programa de millas y, a su vez, tienen una gran cantidad de millas acumuladas.
- Cluster 3: podemos observar un grupo dominado por clientes con un alto nivel de ingresos mensuales, grandes gastos acumulados, una mayoritaria preferencia por la Primera Clase, no muchas poseen millas acumuladas en comparación al cluster 2 y poco más de la mitad no poseen el programa de millas.
- Cluster 4: este grupo es el más pequeño de la muestra. Está conformado por clientes con ingresos, cantidad de vuelos y millas acumuladas bajos, pero poco más altos que el cluster 1 y el 2. Sin embargo, predomina la clase ejecutiva como la preferida y además están adheridos al programa de millas.

Decisión de negocio

Basándonos en las descripciones de las agrupaciones en clusters que se realizó más arriba, se decidió tomar las siguientes decisiones de negocio frente a las demoras predichas por nuestros modelos:

- El **cluster 1** está compuesto por los clientes que viajan poco y tienen pocos ingresos, por más de que hayan sufrido el inconveniente no es recomendable otorgar el beneficio de un pase a la sala VIP del free shop debido a que esta tiene una capacidad límite y este tipo de cliente es uno que no es fácil de captar porque no es que no viaja con la empresa por falta de confianza, sino que no viaja por falta de ingresos seguramente, es una variable externa a nosotros, por lo que no tenemos influencia.
- El **cluster 2** también es un conjunto de clientes que viaja en clase económica, pero es uno con más cantidad de vuelos, es un cliente que la empresa no quiere perder su recurrencia. Es por ello, que ofrecer un beneficio en forma de disculpa sirve como fidelización de dicho cliente. Los beneficios pueden ser otorgar pases al VIP del free shop o aumentar la clase en la que viaja.
- El **cluster 3** engloba clientes que no viajan mucho pero con ingresos altos y su elección, generalmente, es de viajar en primera clase. A estos también conviene

ofrecer alguno de los beneficios nombrados anteriormente con el fin de fomentar a que viajen, y si lo hacen regularmente, que lo hagan con nuestra compañía.

- Por último, en el **cuarto cluster** se encuentran los clientes con mayor ingreso económico y que viajan seguido. Estos pueden costearse, y lo hacen, clases altas para viajar y se deduce que recurren frecuentemente al sector VIP. Es por esto que la empresa no tiene muchos más beneficios que otorgarle a este tipo de cliente que genere una verdadera ganancia o evite costos en imagen de la misma. Mientras la concurrencia con la que suceden las demoras en los vuelos no sea muy alta, a estos clientes no creemos que les afecte en gran medida que les toque un vuelo demorado frente a los demás que hayan tomado.