

Introducción a la Inteligencia Artificial

Ing. Laura Aquili

Temas

1.1. Introducción	3
1.2. ¿Qué es la Inteligencia Artificial?	4
Ejemplos cotidianos de Inteligencia Artificial.....	6
Importancia de estudiar Inteligencia Artificial	7
1.3. Aproximaciones de la Inteligencia Artificial	8
1.3.1. Aproximaciones Simbólicas	9
1.3.2. Aproximaciones subsimbólicas.....	10
1.4. Historia de la Inteligencia Artificial.....	10
Épocas de auge y declive: Inviernos de la IA	13
1.5. Inteligencia artificial fuerte y débil.....	15
1.6. Sistemas que resuelven problemas de IA.....	17
Los problemas de la Inteligencia Artificial	17
1.7. Acciones que debe llevar a cabo un sistema de IA.....	23
1.7.1. Búsqueda en espacio de estados	24
1.7.2. Búsqueda en espacio de solución.....	28
1.7.3. Sistemas de producción.....	28
1.7.4. Análisis del problema	29

1.1. Introducción

La Inteligencia Artificial (IA) es una de las ramas de las ciencias de la computación que más interés ha despertado en la actualidad, debido a su enorme campo de aplicación.

La búsqueda de mecanismos que nos ayuden a comprender la inteligencia y realizar modelos y simulaciones de estos, es algo que ha motivado a muchos científicos a elegir esta área de investigación.

El origen inmediato del concepto y de los criterios de desarrollo de la “IA” se remonta a la intuición del genio matemático inglés Alan Turing y el apelativo “Inteligencia Artificial” se debe a McCarthy quien organizó una conferencia en el Dartmouth College (Estados Unidos) para discutir la posibilidad de construir máquinas “inteligentes”. A esta reunión asistieron científicos investigadores de conocida reputación en el área de las ciencias computacionales como: Marvin Minsky, Nathaniel Rochester, Claude Shannon, Herbert Simon y Allen Newell. Como resultado de esta reunión, se establecieron los primeros lineamientos de la hoy conocida como Inteligencia Artificial, aunque anteriormente ya existían algunos trabajos relacionados.

Desde su origen, la IA tuvo que lidiar con el conflicto de que no existía una definición clara y única de inteligencia, así es que no es de sorprender que aún en la actualidad, no exista una definición única de ella.

Las distintas definiciones de la inteligencia artificial hacen énfasis en diferentes aspectos, aunque existen similitudes entre ellas. A continuación, se presentan algunas de las definiciones iniciales de esta área.

- Estudio de la computación que observa que una máquina sea capaz de percibir, razonar y actuar (Winston, 1992).
- Ciencia de la obtención de máquinas que logren hacer cosas que requerirían inteligencia si las hiciesen los humanos (Minsky, 1968).
- Nuevo esfuerzo excitante que logre que la computadora piense, máquinas con mentes, en el sentido completo y literal (Haugeland, 1985).
- Rama de la ciencia computacional preocupada por la automatización de la conducta inteligente (Luger and Stubblefield, 1993).
- Máquina Inteligente es la que realiza el proceso de analizar, organizar, y convertir los datos en conocimiento, donde el conocimiento del sistema es información estructurada adquirida y aplicada para reducir la ignorancia o la incertidumbre sobre una tarea específica a realizar por esta (Pajares y Santos, 2006).

Originalmente la Inteligencia Artificial se construyó en base a conocimientos y teorías existentes en otras áreas del conocimiento. Algunas de las principales fuentes de inspiración y conocimientos que nutrieron a esta área son las ciencias de la computación, la filosofía, la lingüística, las matemáticas y la psicología. Cada una de estas ciencias contribuyó no solamente con los conocimientos desarrollados en ellas, sino con sus herramientas y experiencias también, contribuyendo así a la gestación y desarrollo de esta nueva área del conocimiento.

Los filósofos como Sócrates, Platón, Aristóteles, Leibniz desde el año 400 AC, sentaron las bases para la inteligencia artificial al concebir a la mente como una máquina que funciona a partir del conocimiento codificado en un lenguaje interno y al considerar que el pensamiento servía para determinar cuál era la acción correcta que había que emprender. Por ejemplo, Aristóteles quien es considerado como el primero (300 AC) en describir de forma estructurada la forma como el ser humano produce conclusiones racionales a partir de un grupo de premisas; contribuyó con un conjunto de reglas conocidas como silogismos que actualmente son la base de uno de los enfoques de la Inteligencia Artificial.

1.2. ¿Qué es la Inteligencia Artificial?

¿Es posible construir máquinas inteligentes? ¿Es el cerebro una máquina? Estas son dos preguntas que han obsesionado a grandes pensadores durante siglos.

La Inteligencia Artificial (IA), en una definición amplia y un tanto circular, tiene por objeto el estudio del comportamiento inteligente en las máquinas. A su vez, el comportamiento inteligente supone percibir, razonar, aprender, comunicarse y actuar en entornos complejos.

Consiste en el desarrollo de programas informáticos que emulan el pensamiento humano y ejecutan tareas complejas. Genera resultados como contenido, previsiones, recomendaciones o decisiones para un conjunto determinado de objetivos definidos por el ser humano.

La IA puede ser **débil** (cuando está diseñada para realizar tareas específicas, como un asistente virtual) o **fuerte** (cuando tiene la capacidad de realizar cualquier tarea cognitiva humana, aunque este tipo aún es teórico).

Una de las metas a largo plazo de la IA es el desarrollo de máquinas que puedan hacer todas estas cosas igual, o quizá incluso mejor, que los humanos.

Otra meta de la IA es llegar a comprender este tipo de comportamiento, sea en las máquinas, en los humanos o en otros animales.

La IA ha estado siempre rodeada de controversia. La cuestión básica de la IA ¿pueden pensar las máquinas? ha interesado tanto a filósofos como a científicos e ingenieros. En un famoso artículo, Alan Turing, uno de los fundadores de la informática, expresó esta misma cuestión, pero formulada en términos más adecuados para su comprobación empírica. Es lo que se ha dado en llamar el Test de Turing (Turing, 1950). Describiremos este test un poco más adelante, en esta misma sección, pero primero es importante destacar lo que ya observara Turing: que la respuesta a la pregunta ¿Pueden pensar las máquinas? depende de cómo definamos las palabras máquinas y pensar. Turing podría haber añadido que la respuesta depende también de cómo se defina la palabra pueden.

Pueden

Consideremos primero la palabra pueden, ¿Queremos decir que las máquinas pueden pensar ya ahora, o que algún día podrán pensar? ¿Queremos decir que las máquinas podrían ser capaces de pensar, en principio (incluso aunque nunca lleguemos a construir ninguna que lo haga), o lo que perseguimos es una implementación real de una máquina pensante? Estas cuestiones son realmente importantes puesto que todavía no disponemos de ninguna máquina que posea amplias habilidades pensantes.

Algunas personas creen que las máquinas pensantes tendrían que ser tan complejas, y disponer de una experiencia tan compleja (por ejemplo, interaccionando con el entorno o con otras máquinas pensantes), que nunca seremos capaces de diseñarlas o construirlas.

De forma similar, la inteligencia de nivel humano, a escala real, podría ser demasiado compleja, o al menos demasiado dependiente de la fisiología humana, para existir fuera de su encarnación en seres humanos inmersos en su entorno. La cuestión de si alguna vez seremos capaces, o no, de construir máquinas pensantes de nivel humano no admite aún una respuesta definitiva. El progreso de la IA hacia esta meta ha sido constante, aunque más lento de lo que algunos pioneros del tema habían predicho.

Máquinas

Consideremos ahora la palabra máquina. Para mucha gente, una máquina es todavía un artefacto más bien estúpido. La palabra evoca imágenes de engranajes rechinando, de chorros de vapor siseando y de piezas de acero martilleando. ¿Cómo podría llegar a pensar una cosa como esa? Sin embargo, hoy en día, los ordenadores han ampliado en gran medida nuestra noción de lo que una

máquina puede ser, y nuestra creciente comprensión de los mecanismos biológicos está expandiéndose incluso más aún.

Consideremos, por ejemplo, un virus simple, como el denominado Bacteriófago E6, mostrado esquemáticamente en la Figura 1.1. Su cabeza contiene ADN vírico. Este virus es capaz de adherirse a la pared celular de una bacteria mediante las fibras de su cola, pinchar la pared e inyectar su ADN en ella. Este ADN hace que la bacteria fabrique millares de copias de cada una de las piezas del virus. Después, las piezas se ensamblan automáticamente ellas mismas, formando nuevos virus que salen de la bacteria para repetir el proceso. El ensamblaje completo se parece mucho al de una máquina, por lo que podríamos, con toda propiedad, decir que se trata de una máquina, una máquina hecha de proteínas.




Figura 1.1

Sin embargo, aunque estuviésemos de acuerdo acerca de lo que es una máquina, este último argumento es rebatible. Aunque una máquina hecha de proteínas puede pensar, quizá una hecha de silicio no sería capaz de hacerlo. Un conocido filósofo, John Searle, cree que la materia de la que estamos hechos es fundamental para la inteligencia. Para él, el pensamiento solo puede ocurrir en máquinas muy especiales - las máquinas vivientes hechas de proteínas.

La hipótesis del sistema físico de símbolos de Newell y Simon (Newell y Simon, 1976) está en oposición directa a las creencias de Searle. Esta hipótesis establece que un sistema físico de símbolos dispone de los medios necesarios y suficientes para desarrollar una actividad general inteligente. De acuerdo con Newell y Simon, un sistema físico de símbolos es una máquina, tal como un ordenador digital, que es capaz de manipular datos simbólicos, sumar números, reordenar listas de símbolos (por ejemplo, ordenar alfabéticamente una lista de nombres), reemplazar algunos símbolos por otros, etc. Un aspecto importante de esta hipótesis es que no importa de qué esté hecho el sistema físico de símbolos. Decimos que la hipótesis de Newell y Simon es "neutral respecto al sustrato".

Una entidad inteligente podría estar hecha de proteínas, de relés mecánicos, de transistores, o de cualquier otra cosa, con tal de que sea capaz de procesar símbolos.

Otros pensadores creen que no es realmente importante que las máquinas estén hechas de silicio o de proteínas; piensan que el comportamiento inteligente es, en su mayor parte, el resultado de lo que ellos llaman procesamiento subsimbólico, es decir, procesamiento de señales, no de símbolos. Consideremos, por ejemplo, el reconocimiento de rostros familiares. Los humanos hacemos esto sin esfuerzo alguno, y aunque no se sabe exactamente cómo lo hacemos, se sospecha que la mejor explicación para el proceso es la que se basa en el tratamiento de imágenes, o de partes de ellas, como señales multidimensionales, no como símbolos.

Pensar

Finalmente, llegamos a la palabra más difícil, pensar. En lugar de intentar definir esta palabra, **Turing** propuso un test, el llamado **Test de Turing**, mediante el cual pudiera decidirse si una máquina particular es o no inteligente. El test fue descrito originalmente como un juego. Citemos del artículo de Turing (Turing, 1950):

En el juego participan tres personas, un hombre (A), una mujer (B) y un interrogador (C), que puede ser de cualquier sexo. El interrogador permanece en una sala, separado de los otros dos, pero pudiendo comunicarse con ellos mediante un teletipo. El objetivo del juego para el interrogador es determinar cuál de los otros dos es el hombre y cuál es la mujer. El interrogador los designa mediante las etiquetas X e Y, y al final del juego debe decir "X es A e Y es B" o "X es B e Y es A". Para ello, el interrogador puede plantear preguntas a A y a B, tales como: C: ¿Podría decirme X cual es la longitud de su pelo?

Supongamos que X es realmente A; entonces es A quien debe responder. El objetivo de A en el juego es intentar que C haga una identificación errónea.

El objetivo del juego para el tercer participante (B) es ayudar al interrogador.

Ahora podemos plantearnos la siguiente cuestión: "¿Qué sucedería si una máquina interpretase el papel de A en el juego?" ¿El interrogador hará tantas identificaciones erróneas como cuando el juego es interpretado por un hombre y una mujer? Estas cuestiones reemplazan a nuestra cuestión original: "¿pueden pensar las máquinas?"

A menudo, el Test de Turing se simplifica, planteándolo como un juego en el que una máquina intenta convencer a un interrogador humano de que ella es también humana. Esta versión simplificada del Test de Turing no se considera usualmente como un test de inteligencia muy útil, debido a que es posible, incluso para programas muy simples, engañar al interrogador humano durante un buen rato. Por ejemplo, el programa ELIZA de Joseph Weizenbaum (Prog. DOCTOR.PRO) usa algunos trucos muy simples para ello, pero es capaz de desarrollar un diálogo que resulta aparentemente realista para el interrogador poco avezado, aunque es un diálogo completamente vano (Weizenbaum, 1965). El programa JULIA de Mauldin es también un programa de diálogo de este tipo (Mauldin, 1994).

Aparte del Test de Turing, una cuestión que merece la pena intentar responder es la de cuáles deben ser las habilidades requeridas en una máquina para que podamos calificarla como inteligente.

Actualmente, existen muchos programas de ordenador capaces de realizar cosas realmente prodigiosas, incluyendo la planificación óptima de rutas aéreas para economizar combustible, la simulación global de condiciones meteorológicas, la planificación del uso de recursos en una fábrica, etc. ¿son inteligentes estos programas? ¿Deben ser considerados como objeto de estudio de la IA? Habíamos comenzado este capítulo describiendo máquinas que difícilmente podrían ser etiquetadas como inteligentes. ¿Son gradualmente más y más inteligentes conforme se incrementa su complejidad? Personalmente, lo creo así, pero existen indudablemente opiniones para todos los gustos.

Ejemplos cotidianos de Inteligencia Artificial

1. Asistentes Virtuales (como Siri, Alexa y Google Assistant): Los asistentes virtuales utilizan IA para entender comandos de voz y ofrecer respuestas o realizar tareas, como poner alarmas, responder preguntas o reproducir música.
2. Recomendaciones en plataformas de streaming (como Netflix, Spotify o YouTube): Estos servicios usan IA para analizar tu historial de visualización o escucha y sugerir contenido que podría interesarte, basándose en patrones y preferencias anteriores.

3. **Sistemas de navegación (como Google Maps o Waze):** La IA en estas aplicaciones procesa grandes cantidades de datos en tiempo real, como el tráfico, el clima y las rutas alternativas, para sugerir la mejor ruta hacia tu destino.
4. **Corrección automática de texto (como en los Smartphone o aplicaciones de correo electrónico):** La IA ayuda a corregir errores ortográficos y gramaticales, sugiriendo correcciones basadas en el contexto del texto.
5. **Automóviles autónomos:** Los vehículos autónomos utilizan IA para percibir su entorno (por ejemplo, a través de cámaras y sensores) y tomar decisiones de conducción, como frenar o cambiar de carril.
6. **Filtros de spam en correos electrónicos:** Los sistemas de correo electrónico utilizan IA para detectar y filtrar mensajes no deseados, analizando patrones en los correos entrantes.
7. **Reconocimiento facial:** La IA se usa para identificar personas mediante sus características faciales, y se encuentra en aplicaciones como el desbloqueo de teléfonos, la seguridad de cámaras y el etiquetado en redes sociales.
8. **Chatbots y atención al cliente automatizado:** Muchas empresas utilizan IA en sus chatbots para interactuar con los clientes, responder preguntas frecuentes y resolver problemas sin intervención humana.

Estos son solo algunos ejemplos de cómo la IA está integrada en nuestra vida diaria, mejorando la eficiencia, la personalización y la automatización de diversos procesos.

Importancia de estudiar Inteligencia Artificial

La importancia de estudiar Inteligencia Artificial (IA) radica en su creciente impacto en casi todos los aspectos de la vida moderna y su potencial para transformar el futuro. A continuación, se detallan algunas de las razones clave por las que estudiar IA es crucial, así como su impacto en diversos sectores y la sociedad en general.

1. Revolución tecnológica y oportunidades profesionales

La IA es una de las tecnologías más disruptivas de la actualidad, y está cambiando cómo interactuamos con el mundo. Estudiarla abre una variedad de oportunidades profesionales en áreas como la ciencia de datos, ingeniería de software, robótica, automóviles autónomos, y más. Esto se traduce en una alta demanda de profesionales capacitados en IA, lo que la convierte en una disciplina crucial para el futuro laboral.

2. Mejora de la eficiencia y productividad

La IA tiene el potencial de automatizar tareas repetitivas, optimizar procesos y aumentar la eficiencia en diversos campos. Por ejemplo, en la industria manufacturera, la IA puede mejorar las líneas de producción, predecir fallos en equipos y minimizar desperdicios. En la agricultura, puede optimizar el riego y el uso de pesticidas, aumentando el rendimiento y reduciendo el impacto ambiental.

3. Impacto en la salud y la medicina

La IA está revolucionando la medicina al permitir diagnósticos más rápidos y precisos, el desarrollo de tratamientos personalizados y la mejora de la investigación médica. Herramientas basadas en IA, como los sistemas de análisis de imágenes médicas o los asistentes de diagnóstico, pueden ayudar a identificar enfermedades, como el cáncer, en etapas tempranas, lo que mejora las tasas de éxito de los tratamientos.

4. Transformación en el sector financiero

En el sector financiero, la IA tiene aplicaciones en la gestión de riesgos, la detección de fraudes y la toma de decisiones de inversión. Los algoritmos de IA también se utilizan para mejorar la experiencia del cliente en bancos y aseguradoras, ofreciendo servicios más rápidos y personalizados, como los chatbots y los asesores virtuales.

5. Avances en el transporte y la movilidad

La inteligencia artificial es esencial para el desarrollo de vehículos autónomos. Estos vehículos tienen el potencial de reducir accidentes de tráfico, disminuir la congestión y mejorar la eficiencia del transporte. Además, la IA puede optimizar la gestión del tráfico urbano, lo que ayuda a reducir los tiempos de desplazamiento y la huella de carbono.

6. Educación personalizada

En el ámbito educativo, la IA está ayudando a crear entornos de aprendizaje personalizados. Herramientas como tutores virtuales y plataformas educativas basadas en IA pueden adaptarse a las necesidades de cada estudiante, ofreciendo recursos y materiales de acuerdo con su ritmo y estilo de aprendizaje.

7. Desafíos éticos y sociales

Aunque la IA tiene un gran potencial para mejorar la vida humana, también presenta desafíos éticos y sociales. La privacidad de los datos, el uso de la IA en decisiones críticas (como los procesos judiciales o las contrataciones laborales), y el riesgo de desempleo masivo por la automatización son problemas que deben ser abordados. Estudiar IA es fundamental para comprender estos desafíos y desarrollar soluciones responsables que minimicen los riesgos y maximicen los beneficios para la sociedad.

8. Impacto en la investigación científica

La IA está acelerando el progreso en diversas ramas de la ciencia, desde la física hasta la biología, ayudando a los científicos a analizar grandes volúmenes de datos y hacer descubrimientos más rápidamente. Esto puede llevar a avances importantes en la comprensión del universo, la creación de nuevos materiales o la mejora de la salud humana.

9. Contribución a la sostenibilidad y el medio ambiente

La IA también tiene el potencial de jugar un papel crucial en la lucha contra el cambio climático y la protección del medio ambiente. Puede predecir patrones climáticos, mejorar el monitoreo de la biodiversidad y optimizar el uso de los recursos naturales, ayudando a crear soluciones más sostenibles en sectores como la energía, la agricultura y la gestión de residuos.

10. Impacto cultural y social

La IA también tiene un impacto en la forma en que interactuamos socialmente. El uso de redes sociales inteligentes y sistemas de recomendación, por ejemplo, influye en las opiniones públicas y en las decisiones de consumo. Comprender cómo funciona la IA en este contexto es esencial para garantizar que su uso sea ético y no manipule a las personas de forma perjudicial.

En conclusión, estudiar Inteligencia Artificial es crucial porque está modelando el futuro de nuestra sociedad, de la economía global, de la política y de la cultura. Al comprender cómo funciona la IA, podemos aprovechar sus beneficios mientras gestionamos sus riesgos de manera efectiva. Además, preparar a las futuras generaciones para trabajar con IA les permitirá enfrentar desafíos nuevos y emocionantes, transformando la manera en que vivimos y trabajamos.

1.3. Aproximaciones de la Inteligencia Artificial


Aun aceptando que la IA ya ha sido capaz de producir algunos sistemas prácticos muy útiles, la creencia general es que el objetivo último de alcanzar una inteligencia de nivel humano está aún

muy distante. Siendo esto así, todavía hay un gran debate sobre cuáles son las mejores aproximaciones hacia la IA, mejores en el sentido de sentar los fundamentos centrales para conseguir las metas planteadas a largo plazo, así como mejores en el sentido de producir resultados prácticos a corto plazo.

Los principales paradigmas pueden ser clasificados en dos grupos:

La escuela clásica dentro de la IA, utiliza representaciones simbólicas basadas en un número finito de primitivas y de reglas para la manipulación de símbolos (por ejemplo, redes semánticas, lógica de predicados, etc.), los cuales fueron y siguen siendo parte central de dichos sistemas.

El enfoque sub-simbólico de la IA se caracteriza por crear sistemas con capacidad de aprendizaje. Éste se puede obtener a nivel de individuo, imitando el cerebro (Redes Neuronales), o a nivel de especie, imitando la evolución.



1.3.1. Aproximaciones Simbólicas

El primer grupo incluye lo que llamaríamos las aproximaciones basadas en el procesamiento de símbolos. Se sustentan sobre la hipótesis del sistema físico de símbolos de Newell y Simon, y aunque esta hipótesis no puede considerarse como universalmente aceptada, en ella se basa mucho de lo que podríamos llamar IA "clásica" (lo que el filósofo John Haugeland llama "IA al viejo estilo"). Un miembro destacado de esta familia de aproximaciones es el que se basa en la aplicación de operaciones lógicas sobre bases de conocimiento declarativo. Inspirado originalmente en los informes de John McCarthy sobre su "sistema consejero" (McCarthy, 1958), este estilo de IA representa el "conocimiento" sobre un problema del dominio mediante sentencias declarativas, a menudo basadas en sentencias de la lógica de predicados o sustancialmente equivalentes a ellas. Para deducir consecuencias a partir de este conocimiento se aplican técnicas de inferencia lógica. Este método admite numerosas variantes, incluyendo aquellas cuyo énfasis está en la axiomatización formal del dominio en un lenguaje lógico. Cuando se aplica a problemas "reales", este método requiere la representación de una cantidad sustancial de conocimiento del dominio, por lo que se suele hablar de aproximaciones basadas en el conocimiento. Se han construido muchos sistemas basados en estos métodos y nos referiremos a algunos de ellos más adelante.

En muchas de las aproximaciones basadas en procesamiento de símbolos, el análisis de los comportamientos deseados, o la síntesis de máquinas para conseguirlos, se extienden a través de varios niveles.

- El nivel superior corresponde al nivel del conocimiento (Newell, 1982), en el cual se especifica el conocimiento necesario para que la máquina alcance sus objetivos.
- A continuación viene el nivel simbólico, donde se representa este conocimiento mediante estructuras simbólicas, como, por ejemplo, listas escritas en el lenguaje de programación LISP, y se especifican operaciones sobre estas estructuras..

- Después están los niveles inferiores, en los cuales, realmente se implementan las operaciones de procesamiento de símbolos. Muchas aproximaciones basadas en procesamiento de símbolos utilizan una metodología de diseño "descendente"; se comienza en el nivel de conocimiento y se procede hacia abajo a través de los niveles simbólico y de implementación.

1.3.2. Aproximaciones subsimbólicas

El segundo grupo de aproximaciones hacia la IA incluye lo que se denominan aproximaciones subsimbólicas. Estas siguen usualmente un estilo de diseño "ascendente", comenzando en el nivel más bajo y procediendo hacia los niveles superiores.

En los niveles más bajos, el concepto de símbolo no es tan apropiado como el concepto de señal. Entre las aproximaciones subsimbólicas, una aproximación muy prominente es la que algunos han llamado "vida artificial". Los defensores de este estilo (Wilson, 1991 y Brooks, 1990) señalan que la inteligencia humana se desarrolló solo después de más de mil millones de años de vida sobre la tierra. Según ellos, para conseguir máquinas inteligentes tendremos que seguir muchos de estos pasos evolutivos. Primero, debemos concentrarnos en la duplicación de las capacidades de procesamiento de señal y control de las que disponen los animales más simples - los insectos, por ejemplo - y subir por la escalera evolutiva en pasos sucesivos. Esta estrategia no solo conducirá a la obtención a corto plazo de máquinas útiles, sino que desarrollará el substrato sobre el cual deben construirse necesariamente los niveles superiores de inteligencia.

Este segundo grupo de aproximaciones también pone énfasis en los fundamentos simbólicos. Brooks introdujo la hipótesis de los fundamentos físicos, en contraste con la hipótesis de los sistemas físicos de símbolos (Brooks, 1990). Según su hipótesis, se puede obtener un comportamiento complejo sin usar modelos centralizados; para ello, bastaría con dejar que los diversos módulos de comportamiento de un agente interactúen independientemente con el entorno. Sin embargo, Brooks acepta que para conseguir IA de nivel humano puede ser necesaria la integración de las dos aproximaciones.

La interacción entre una máquina y su entorno conduce a lo que se denomina comportamiento emergente. En palabras de una investigadora (Maes, 1990):

La funcionalidad de un agente debe verse como una propiedad emergente de la interacción intensiva del sistema con su entorno dinámico. La especificación del comportamiento del agente aislado no explica la funcionalidad que exhibe cuando el agente está operando. Por el contrario, su funcionalidad se basa en gran medida en las propiedades del entorno. No solo hay que tener en cuenta las características dinámicas del entorno, sino que éstas deben ser explotadas para servir al funcionamiento del sistema.

Las redes neuronales son un ejemplo bien conocido de máquinas que provienen de la escuela subsimbólica. Estos sistemas, inspirados en modelos biológicos, son interesantes, principalmente por su capacidad de aprendizaje.

También se han conseguido resultados interesantes mediante procesos que simulan ciertos aspectos de la evolución biológica: cruzamiento, mutación y reproducción de los organismos mejor adaptados..

1.4. Historia de la Inteligencia Artificial

La Inteligencia Artificial (IA) ha sido una disciplina de gran interés desde mediados del siglo XX y ha pasado por varias fases de desarrollo que han marcado su historia, evolución y fundamentos. A continuación, se presenta un recorrido por la historia de la IA, sus principios fundamentales y cómo ha evolucionado a lo largo del tiempo.

Cuando empezaron a desarrollarse los primeros ordenadores durante las décadas de los años 40 y 50, algunos investigadores escribieron programas que podían realizar tareas elementales de

razonamiento. Entre los resultados más prominentes de esta época podemos citar los primeros programas de ordenador capaces de jugar al ajedrez (Shannon, 1950; Newell, Shaw y Simon, 1958), los programas capaces de jugar a las damas (Samuel, 1959; Samuel, 1967) y los programas para demostrar teoremas de geometría plana (Gelernter, 1959). En 1956, John McCarthy y Claud Shannon coeditaron un volumen titulado *Automata Studies* (Shannon y McCarthy, 1956). La mayoría de los artículos del volumen trataban sobre los fundamentos matemáticos de la teoría de autómatas, por lo que **McCarthy**, decepcionado, **decidió acuñar el término Inteligencia Artificial** y usarlo como título de una conferencia celebrada en Darmouth en 1956. En esta conferencia se presentaron algunos trabajos muy relevantes, incluyendo uno de Allen Newell, Cliff Shaw y Herbert Simon sobre un programa llamado Teorizador Lógico (Newell, Shaw y Simon, 1957), que podía demostrar teoremas en lógica proposicional. Aunque se propusieron muchos otros términos para el campo, tales como procesamiento de información compleja, inteligencia de máquinas, programación heurística o cognología, solo el nombre de Inteligencia Artificial ha perdurado, sin duda a causa de la creciente progresión de libros de texto, cursos, congresos y revistas que usaban este término.

El primer paso hacia la inteligencia artificial fue dado mucho tiempo atrás por Aristóteles (384-322 a. C.), cuando comenzó a explicar y a codificar ciertos estilos de razonamiento deductivo que él llamó silogismos. Algunos de los esfuerzos tempranos para automatizar la inteligencia nos parecerían quijotescos hoy en día. Ramón LLull (1235-1316), un místico y poeta catalán, construyó una máquina de engranajes, llamada *Ars Magna*, que supuestamente era capaz de responder a todas las preguntas. Pero hubo también científicos y matemáticos que perseguían la automatización del razonamiento. Martin Gardner (Gardner, 1982) atribuye a Gottfried Leibniz (1646-1716) el sueño de un "álgebra universal mediante la cual todo el conocimiento, incluyendo las verdades morales y metafísicas, pueda ser algún día representado en un único sistema deductivo". Leibniz llamó a su sistema cálculo filosófico o raciocinador, fue, claro está, un sueño que no pudo ser realizado con el aparataje tecnológico de la época. No comenzó a haber un progreso sustancial hasta que George Boole (Boole, 1854) desarrolló los fundamentos de la lógica proposicional. El propósito de Boole, entre otras cosas, era "recoger algunos fundamentos probables relativos a la naturaleza y a la constitución de la mente humana". Hacia el final del siglo XIX, Gottlieb Frege propuso un sistema de notación para el razonamiento mecánico, con lo que inventó mucho de lo que hoy conocemos con el nombre de cálculo de predicados (Frege, 1879). Llamó a su lenguaje *Begriffsschrift*, lo que puede ser traducido como "escritura de conceptos".

En 1958, John McCarthy propuso la utilización del cálculo de predicados como un lenguaje para representar y usar conocimiento en un sistema al que llamó "sistema consejero" (McCarthy, 1958). A este sistema, en lugar de programarlo, había que decirle lo que necesitaba saber para resolver un problema. Una modesta, pero influyente, implementación de estas ideas fue abordada por Cordell Green en su sistema QA3 (Greenr 1969). Como resultado de muchas controversias entre los investigadores de la IA, el cálculo de predicados y sus variantes han sobrevivido como el fundamento básico para la representación del conocimiento.

Los lógicos del siglo XX, incluyendo a Kart Gödel, Stephen Kleene, Emil Post, Alonzo Church y Alan Turing, formalizaron y clarificaron lo que puede ser hecho y lo que no puede ser hecho mediante sistemas lógicos y computacionales. Posteriormente, informáticos como Stephen Cook y Richard Kart identificaron las clases de cómputos que, siendo posibles en principio, requerirían cantidades de tiempo y de memoria completamente impracticables.

Muchos de estos resultados de la lógica y de la informática se referían a "verdades que no pueden ser deducidas" y a "cálculos que no pueden ser realizados". Seguramente animados por estos hallazgos negativos, algunos filósofos y científicos (Lucas, 1961; Penrose; 1989) los interpretaron como confirmaciones de que la inteligencia humana no podría ser nunca mecanizada. Estos pensadores creían que los humanos son, de alguna forma, inmunes a las limitaciones computacionales inherentes a las máquinas. Sin embargo, la mayoría de los lógicos y de los

informáticos creen que estos resultados negativos de ningún modo implican que las máquinas tengan límites que no sean aplicables también a los humanos.

El primer artículo moderno que trataba sobre la posibilidad de mecanizar la inteligencia al estilo humano fue el de Alan Turing que ya hemos citado anteriormente (Turing, 1950). Durante el mismo período, Warren McCulloch y Walter Pitts teorizaban sobre las relaciones entre elementos computacionales simples y neuronas biológicas (McCulloch y Pitts, 1943).

Demostraron que es posible calcular cualquier función computable mediante redes de puertas lógicas. Otro trabajo, de Frank Rosenblatt (Rosenblatt, 1962), exploraba el uso de redes de tipo neuronal, denominadas perceptrones, para el aprendizaje y el reconocimiento de patrones. Algunas otras corrientes de trabajo, entre ellas la cibernética (Wiener, 1948), la psicología cognitiva, la lingüística computacional (Chomsky, 1965) y la teoría del control adaptativo (Widrow y Of., 1960), han contribuido también a esta matriz intelectual dentro de la cual se ha desarrollado la IA.

Una gran parte del trabajo inicial en la IA (durante la década de los años 60 y la primera parte de la década de los 70) se dedicaba a explorar diversas representaciones de problemas, técnicas de búsqueda y heurísticas generales que se aplicaban en programas de ordenador capaces de resolver puzzles sencillos, de jugar contra el usuario o de recuperar información. Uno de los programas más influyentes fue el Solucionador General de Problemas (GPS, o General Problem Solver) de Allen Newell, Cliff Shaw y Herbert Simon. Entre los problemas de muestra resuelto por estos sistemas pioneros se incluían la integración simbólica (Slagle, 1963), los problemas de álgebra (Bobrow, 1968), los puzzles analógicos (Evans, 1968) y el control de robots móviles (Nilsson, 1984). Muchos de estos sistemas constituyen el tema central de los artículos reunidos en el histórico volumen *Computer and Thought* (Feigenbaum y Feldman, 1963).

Los intentos de "escalar" estos programas y sus técnicas para enfrentarlos a aplicaciones de importancia práctica revelaron que solo valían para resolver "problemas de juguete". La construcción de sistemas más potentes requería la inclusión de mucho más conocimiento sobre el dominio de aplicación. Los últimos años de la década de los 70 y los primeros de la década de los 80 vieron el desarrollo de programas más realistas, que contenían el conocimiento necesario para mimetizar el comportamiento de los expertos humanos en tareas tales como el diagnóstico, el diseño y el análisis. Fueron explorados y desarrollados varios métodos para la representación de conocimiento específico del problema. El programa al que se atribuye el mérito de ser el primero que demostró la importancia de recoger grandes cantidades de conocimiento específico del dominio fue DENDRAL, un sistema para predecir la estructura de moléculas orgánicas a partir de su fórmula química y de su espectrograma de masas. (Feigenbaum, Buchanan y Lederberg, 1971) (Lindsay, 1980). Después se desarrollaron otros "sistemas expertos", incluyendo sistemas para diagnóstico médico (Shortliffe, 1976 y Millar, Pople y Myers, 1982), sistemas para configurar ordenadores (McDermott, 1982) y sistemas para valorar posibles yacimientos de minerales (Campbell, 1982 y Duda, Gaschnig y Hartf 1979). Un buen resumen de la historia de la IA a lo largo de este período fue escrito por (McCorduck, 1979).

Una de las áreas en la que se han realizado progresos sustanciales al escalar el tamaño del problema es el área de los juegos. El 11 de mayo de 1997, un programa de ordenador de IBM, denominado DEEP BLUE, consiguió vencer al entonces campeón del mundo de ajedrez, Garry Kasparov, por 3.5 a 2.5 en un encuentro a seis partidas. Este alto nivel de juego se ha conseguido gracias a la sinergia de sofisticados algoritmos de búsqueda, ordenadores de alta velocidad y hardware específico para el juego del ajedrez.

La inteligencia humana abarca muchas habilidades, incluyendo la habilidad para percibir y analizar escenas visuales y la habilidad para entender o generar el lenguaje. Estos son temas específicos que han recibido mucha atención. Larry Roberts desarrolló uno de los primeros programas de análisis de escenas (Roberts, 1963). Este trabajo preliminar fue seguido de una extensa cantidad de investigación en visión artificial (Nalga, 1993) es un buen libro de texto general, guiada mediante estudios científicos de los sistemas de visión animal (Letvin, 1959; Hubel, 1988 y Marr, 1982).

Uno de los sistemas pioneros en comprensión del lenguaje natural fue el desarrollado por Ferry Winograd (Winograd, 1972). Durante la década de los años 70 se llevó a cabo un proyecto coordinado multicentro que desarrolló prototipos de sistemas para la comprensión fluida del habla; el sistema LUNAR (Woods, 1973), desarrollado por William Woods, era capaz de responder a preguntas orales en inglés sobre las muestras de rocas recogidas por las misiones lunares de la NASA.

Aunque actualmente existen diversos sistemas de comprensión del lenguaje natural, su competencia se restringe a áreas temáticas específicas y a vocabularios especializados. El desarrollo de sistemas con un alcance más amplio requerirá de nuevos avances en la representación de grandes cantidades de conocimiento general de sentido común. El proyecto CYC (Guha y Lenat, 1990; Guha y Lenat, 1995) tiene como uno de sus objetivos la recogida y representación de conocimiento de este tipo.

Aunque el interés en las redes neuronales decayó un poco tras el trabajo pionero realizado en los últimos años de la década de los 50 por Frank Rosenblatt, resurgió con energía en los años 80. Las redes de elementos no lineales con interconexiones de pesos variables se consideran actualmente como una clase muy importante de herramientas para el modelado no lineal. Hoy en día existen diversas aplicaciones importantes de las redes neuronales. El trabajo sobre redes neuronales, junto con el trabajo en temas de vida artificial, ha ayudado a focalizar la investigación actual en IA sobre los problemas relacionados con la conexión entre procesos simbólicos y los sensores y efectores de los robots inmersos en un entorno físico.

Si proyectamos las tendencias actuales hacia el futuro, es razonable esperar un nuevo énfasis en el desarrollo de sistemas autónomos integrados, robots y "softbots". Los softbots (Etzioni y Weld, 1994) son agentes software que recorren Internet buscando la información que ellos creen que puede ser de interés para sus usuarios. La constante presión ejercida para mejorar las capacidades de los robots y de los agentes software motivará y guiará la investigación en inteligencia artificial durante muchos años.

Épocas de auge y declive: Inviernos de la IA

Los "inviernos de la IA" se refieren a períodos en los que el progreso en la investigación y desarrollo de la Inteligencia Artificial (IA) experimentó un estancamiento significativo o una desaceleración, debido a diversas razones, como expectativas excesivas, limitaciones tecnológicas o falta de financiación. A lo largo de la historia de la IA, han ocurrido varios ciclos de auge y declive, y los inviernos de la IA son un fenómeno clave que ha influido en su evolución. Estos "inviernos" se caracterizan por una falta de avances visibles, desilusión en la comunidad científica y una disminución en la inversión en el campo.

1. Primer Invierno de la IA (1970-1980).

Causas:

- Exceso de expectativas: En las décadas de 1950 y 1960, hubo un gran entusiasmo por la IA, con expectativas poco realistas sobre lo que las máquinas podían lograr. Los investigadores pensaban que la creación de una IA general (una máquina que pudiera realizar cualquier tarea cognitiva humana) estaba a la vuelta de la esquina.
- Limitaciones tecnológicas: Las máquinas de la época eran demasiado lentas y carecían de la capacidad de procesamiento y almacenamiento necesarias para manejar los complejos problemas de la IA. Los avances en sistemas de razonamiento lógico, aunque prometedores, no lograron cumplir con las expectativas.
- Falta de avances significativos: La IA experimentó dificultades en la resolución de problemas complejos y en la creación de sistemas de aprendizaje autónomos efectivos. Programas como

Shakey el robot (un robot diseñado para navegar en entornos simples) mostraron que, aunque se lograban avances, estos no eran lo suficientemente impresionantes para justificar el entusiasmo inicial.

Efectos del primer invierno:

- Disminución del interés y la inversión en IA.
- Reducción de los fondos gubernamentales y privados para investigaciones en IA.
- Los investigadores se sintieron frustrados por la falta de resultados tangibles.

2. Segundo Invierno de la IA (1987-1993)

Causas:

- Colapso de la industria de los sistemas expertos: En los años 80, los sistemas expertos (programas que usaban un conjunto de reglas para tomar decisiones en áreas específicas, como la medicina o la ingeniería) estuvieron en auge. Empresas como XCON (de Digital Equipment Corporation) y DENDRAL se utilizaban con éxito, pero sus limitaciones se hicieron evidentes.
- Falta de escalabilidad: Aunque los sistemas expertos funcionaban en ámbitos específicos, no podían generalizar sus conocimientos ni adaptarse a contextos nuevos. Este déficit en la flexibilidad provocó la caída de la demanda en esta tecnología.
- Inestabilidad económica y caída de la burbuja tecnológica: La recesión de finales de los años 80 y principios de los 90, junto con una desaceleración en la industria tecnológica, afectó a la financiación de proyectos de IA.

Efectos del segundo invierno:

- Nuevamente, se redujo significativamente la inversión pública y privada en IA.
- Se produjo una disminución del número de proyectos de investigación en IA y un mayor escepticismo hacia el campo.
- Los académicos y expertos en IA comenzaron a centrarse más en los avances en redes neuronales y algoritmos probabilísticos como una forma de superar las limitaciones de los enfoques anteriores.

3. Auge de la IA (1990-2000)

A pesar de los inviernos, la IA experimentó una recuperación a finales de los años 90, impulsada por avances en áreas clave como el aprendizaje automático, el procesamiento de lenguaje natural y el reconocimiento de patrones. El Deep Blue de IBM venció al campeón mundial de ajedrez Garry Kasparov en 1997, lo que fue un hito importante para la IA, ya que demostró la capacidad de las máquinas para realizar tareas cognitivas complejas.

4. Tercer Invierno de la IA (2004-2009)

Causas:

- Limitaciones en la potencia de cálculo y el almacenamiento: Aunque la computación había avanzado, la falta de algoritmos más eficientes y la limitada capacidad de los equipos de computación aún representaban un obstáculo para lograr avances significativos en IA.
- Nuevas expectativas poco realistas: Al igual que en los inviernos anteriores, la IA no cumplió con las expectativas sobre lo que podría lograr en áreas como la creación de una IA general (o AGI,

por sus siglas en inglés). Los grandes anuncios de avances se quedaron en meras promesas, y el entusiasmo de la comunidad se redujo nuevamente.

Efectos del tercer invierno:

- Las inversiones en IA se redujeron nuevamente.
- Hubo un retroceso en el desarrollo de robots inteligentes y otros campos emergentes de la IA.

5. El Renacimiento de la IA (2010 en adelante)

Desde alrededor de 2010, la IA ha experimentado un renacimiento masivo gracias a varios factores:

- Avances en aprendizaje profundo (deep learning): La invención de redes neuronales profundas y la mejora en los algoritmos, junto con una mayor capacidad de procesamiento (gracias a los procesadores gráficos o GPU), ha permitido entrenar modelos mucho más potentes y eficaces.
- Big Data: El acceso a enormes cantidades de datos, junto con la mejora en la infraestructura de almacenamiento y procesamiento, ha impulsado significativamente el desarrollo de la IA.
- Hardware avanzado: La mejora de la infraestructura de hardware, como las GPUs de NVIDIA, ha acelerado enormemente el entrenamiento de modelos de IA.
- Aplicaciones prácticas: El auge de aplicaciones como reconocimiento de voz, sistemas de recomendación, vehículos autónomos, asistentes virtuales y robots inteligentes ha demostrado el valor tangible de la IA, llevando a un fuerte aumento en las inversiones.

En conclusión, los inviernos de la IA han sido periodos cruciales que enseñaron a los investigadores y a la industria a ser más realistas sobre las expectativas y a centrarse en soluciones prácticas y alcanzables. Estos períodos también han ayudado a la comunidad a replantearse enfoques y buscar avances graduales más sólidos. Actualmente, la IA está viviendo un auge sin precedentes, pero las lecciones del pasado siguen siendo útiles para evitar caer nuevamente en el exceso de optimismo y las expectativas desmesuradas.

Así, el camino de la IA ha sido una serie de altibajos, con avances importantes seguidos por desaceleraciones, pero el progreso continuo en áreas como el aprendizaje profundo, el Big Data y el procesamiento en la nube sugieren que la IA seguirá evolucionando y desempeñando un papel aún más crucial en el futuro.

1.5. Inteligencia artificial fuerte y débil

La distinción entre inteligencia artificial fuerte y débil es fundamental para entender el alcance y las limitaciones de la IA actual y futura.

Inteligencia Artificial Débil (IA Débil):

- Enfoque en tareas específicas: La IA débil está diseñada para realizar tareas concretas y bien definidas.
- No posee conciencia: No tiene conciencia de sí misma ni capacidad para comprender el mundo de la misma manera que un humano.
- Ejemplos: Los asistentes virtuales como Siri o Alexa, los motores de búsqueda, los sistemas de recomendación de productos y los vehículos autónomos son ejemplos de IA débil.
- Objetivo: Simular la inteligencia humana en tareas específicas, pero sin alcanzar una comprensión profunda o general.

Inteligencia Artificial Fuerte (IA Fuerte):

- **Inteligencia general:** La IA fuerte, también conocida como inteligencia artificial general (AGI), tendría la capacidad de comprender, aprender y aplicar la inteligencia de manera similar a un ser humano.
- **Conciencia y autoconciencia:** Podría tener conciencia de sí misma, de su entorno y de sus propios procesos mentales.
- **Capacidad de aprendizaje continuo:** Sería capaz de aprender cualquier tarea intelectual que un ser humano pueda realizar y de mejorar sus habilidades con la experiencia.
- **Objetivo:** Crear máquinas con una inteligencia comparable a la humana en todos los aspectos.

¿Por qué es importante esta distinción?

- **Desarrollo tecnológico:** La mayoría de los avances actuales en IA se centran en la IA débil, que ya ofrece aplicaciones prácticas en muchos campos.
- **Implicaciones éticas:** La IA fuerte plantea cuestiones éticas más profundas, como la conciencia artificial, los derechos de los robots y el impacto en la sociedad.
- **Futuro de la IA:** La creación de una IA fuerte es un objetivo a largo plazo y aún no se sabe si es posible.

En conclusión, la IA débil es una realidad hoy en día, mientras que la IA fuerte sigue siendo un concepto teórico. La diferencia entre ambas radica en la capacidad de comprender y aprender de forma general, así como en la posibilidad de desarrollar conciencia.

1.6. Sistemas que resuelven problemas de IA

La Inteligencia Artificial (IA) estudia cómo lograr que las máquinas realicen tareas que, por el momento, son realizadas mejor por los seres humanos. Esta definición es, por supuesto, bastante efímera ya que hace referencia al estado actual de la informática. Además, falla al no incluir algunas áreas que potencialmente tienen un gran impacto, tales como aquellos problemas que no pueden ser resueltos adecuadamente ni por las máquinas ni por los hombres.

Los problemas de la Inteligencia Artificial

¿Cuáles son entonces los problemas de los que se ocupa la IA?

La mayoría de los primeros trabajos en este campo hicieron gran hincapié en las tareas formales, como juegos y demostración de teoremas. Samuel escribió un programa de juego de damas que no solo jugaba partidas contra un oponente, sino que además utilizaba la experiencia adquirida en las partidas para mejorar su rendimiento. El ajedrez también suscitó un gran interés. La lógica teórica fue el primer intento de demostrar los teoremas matemáticos; con ella se pudo demostrar algunos teoremas que aparecen en el primer capítulo de los Principia Mathematica de Whitehead y Russell. El demostrador de teoremas de Gelernter exploró otra área de las matemáticas: la geometría. Los juegos y la demostración de teoremas comparten la propiedad de que son tareas en las que se considera que es necesaria la inteligencia para desarrollarlas.

Otra primera incursión dentro de la IA se centró en la clase de problemas que aparecen a diario como cuando decidimos cómo llegar al trabajo por la mañana con frecuencia denominados de sentido común. Estos problemas incluyen el razonamiento sobre objetos físicos y sus relaciones (por ejemplo, un objeto solo puede estar en un lugar a la vez), como también razonamiento sobre acciones y sus consecuencias (por ejemplo, si se deja caer algo, chocará contra el suelo y posiblemente se romperá). Para estudiar este tipo de razonamientos, Newell, Shaw y Simon construyeron el Resolutor General de Problemas, el cual se aplicó tanto a variadas tareas de sentido común como al problema de realizar manipulaciones simbólicas en expresiones lógicas.

Conforme las investigaciones en IA progresaron y fueron desarrollándose técnicas de manipulación de grandes cantidades de conocimiento sobre el mundo, se realizaron algunos avances en las tareas descriptas y aparecieron nuevas áreas de investigación. Estas áreas incluyen la percepción (visión y habla), comprensión del lenguaje natural y resolución de problemas en campos especializados como diagnósticos médicos y análisis químico.

Las tareas de percepción son difíciles ya que incluyen señales analógicas (previas a las digitales); estas señales suelen contener bastante ruido, aunque normalmente se percibe a la vez una gran cantidad de objetos (algunos de los cuales pueden estar parcialmente tapados por otros).


La habilidad de utilizar un lenguaje para comunicar gran variedad de ideas es quizá el aspecto más importante que separa a los humanos del resto de los animales. La comprensión del lenguaje hablado es un problema de percepción difícil de resolver por las razones ya explicadas. Es posible, sin embargo, restringir el problema al lenguaje escrito. Este problema, normalmente denominado comprensión del lenguaje natural, es aun extremadamente difícil. Para poder comprender frases sobre un cierto tema, es necesario no solo poseer un conocimiento amplio sobre el propio lenguaje (vocabulario y gramática), sino también manejar el suficiente conocimiento sobre dicho tema para reconocer las suposiciones no expresadas en el texto.

Además de estas tareas de la vida diaria, mucha gente puede también realizar tareas más especializadas en las cuales es necesaria una cuidada adquisición de experiencia. Ejemplos de lo anterior son tareas como el diseño en ingeniería, los descubrimientos científicos, los diagnósticos médicos y la planificación financiera. Los programas que pueden resolver problemas sobre estos dominios también están bajo la tutela de la inteligencia artificial.

Si bien las habilidades de un experto necesitan un conocimiento que la mayoría no poseemos, con frecuencia es mucho menor que el conocimiento necesario en las tareas más comunes, y con frecuencia más fácil de representar y tratar en los programas.

Como consecuencia, las áreas donde la IA está prosperando como una disciplina práctica (en oposición a una puramente de investigación) es precisamente en los dominios donde es necesario únicamente un conocimiento experto sin la ayuda de sentido común. Existen en la actualidad miles de programas llamados sistemas expertos utilizados diariamente en cualquier área de la industria y la administración. Cada uno de estos sistemas intenta resolver parte, o quizás todos los problemas de cierta entidad que antes necesitaban gran cantidad de conocimiento técnico humano.

Algunas aplicaciones de la Inteligencia Artificial



¿Cuáles son nuestras suposiciones fundamentales sobre la inteligencia?

¿Qué tipo de técnicas son las más adecuadas para resolver los problemas de IA?

¿A qué nivel de detalle, si es que no es por completo, se puede intentar modelar la inteligencia humana?

¿cómo se puede saber cuándo se ha tenido éxito en la construcción de un programa inteligente?

Las suposiciones subyacentes

En el centro de las investigaciones sobre inteligencia artificial aparece lo que Newell y Simon (1976) llaman la hipótesis del sistema de símbolos físicos. Ellos definen un sistema de símbolos físicos como sigue:

Un sistema de símbolos físicos consiste en un conjunto de entidades, llamadas símbolos, que son patrones físicos que pueden funcionar como componentes de otro tipo de entidad llamada expresión (o estructura de símbolos). De esta forma, una estructura de símbolos está compuesta por un número de instancias (señales o tokens) de símbolos relacionados de alguna forma física (como que una señal debe seguir a otra). En algún instante, el sistema contendrá una colección de estas estructuras de símbolos. Además de estas estructuras, el sistema contiene también una colección de procesos que operan sobre expresiones para producir otras expresiones: procesos de creación, modificación, reproducción y destrucción. Un sistema de símbolos físicos es una máquina que produce a lo largo del tiempo una colección evolutiva de estructuras de símbolos. Este sistema existe en un mundo de objetos tan extenso como sus propias expresiones simbólicas.

Ellos entonces enunciaron la hipótesis así:

La hipótesis del sistema de símbolos físicos. Un sistema de símbolos físicos posee los medios necesarios y suficientes para realizar una acción inteligente genérica.

Esta hipótesis es solo una hipótesis. Esto significa que no hay manera de probarla o refutarla hablando en términos lógicos. De esta forma, debe estar sujeta a una validación empírica. Puede encontrarse que es falsa. Puede encontrarse que el peso de la evidencia dice que es cierta. Pero el único camino para determinar su certeza es mediante la experimentación.

Las computadoras proporcionan el medio perfecto para esta experimentación ya que pueden ser programadas para simular cualquier sistema de símbolos físicos.

Como la facilidad de construcción de máquinas para computar se ha ido incrementando, también se ha incrementado la posibilidad de dirigir las investigaciones empíricas hacia la hipótesis del sistema de símbolos físicos. En cada investigación, se selecciona una tarea concreta en la que pueda considerarse que es necesario el uso de la inteligencia. Se propone un programa que realice esa tarea y a continuación se comprueba.

Sin embargo, modelos subsimbólicos (como, por ejemplo, las redes neuronales) están comenzando a cuestionar los simbólicos como tareas de bajo nivel. Aún hoy se debaten ciertos conflictos entre modelos simbólicos y la hipótesis del sistema de símbolos físicos. Y es importante hacer notar que el éxito de los sistemas subsimbólicos no es necesariamente una evidencia en contra de la hipótesis. Con frecuencia es posible llevar a cabo una tarea de más de una forma.

La importancia de la hipótesis del sistema de símbolos físicos es doble. Es una teoría significativa de la naturaleza de la inteligencia humana y también es de gran interés para los psicólogos. Esto también forma la base de la creencia de que es posible construir programas que lleven a cabo las tareas inteligentes que son ahora realizadas por la gente.

¿Qué es una técnica de IA?

Los problemas abordados por la inteligencia artificial configuran un amplio espectro. Tienen muy poco en común excepto que todos ellos son complicados. ¿Existen entonces técnicas apropiadas para solucionar algunos de estos problemas? La respuesta es afirmativa, los hay. ¿Qué puede decirse de estas técnicas, si es que se puede, aparte del hecho de que manipulan símbolos?

Uno de los más rápidos y sólidos resultados que surgieron en las primeras tres décadas de las investigaciones en IA fue que la inteligencia necesita conocimiento. Para compensar este

arrollador logro, imprescindible, el conocimiento posee algunas propiedades poco deseables, tales como:

- Es voluminoso.
- Es difícil caracterizarlo con exactitud.
- Cambia constantemente.
- Se distingue de los datos en que se organiza de tal forma que se corresponde con la forma en que va a ser usado.

Entonces, ¿en qué punto nos quedamos en la definición de una técnica de IA?

Concluimos en que una técnica de IA es un método que utiliza conocimiento representado de tal forma que:

- El conocimiento representa las generalizaciones. En otras palabras, no es necesario representar de forma separada cada situación individual. En lugar de esto, se agrupan las situaciones que comparten propiedades importantes. Si el conocimiento no posee esta propiedad, puede necesitarse demasiada memoria. Si no se cumple esta propiedad es mejor hablar de "datos" que de conocimiento.
- Debe ser comprendido por las personas que lo proporcionan. Aunque en muchos programas, los datos pueden adquirirse automáticamente (por ejemplo, mediante lectura de instrumentos), en muchos dominios de la IA, la mayor parte del conocimiento que se suministra a los programas lo proporcionan personas, haciéndolo siempre en términos que ellos comprenden.
- Puede modificarse fácilmente para corregir errores y reflejar los cambios en el mundo y en nuestra visión del mundo.
- Puede usarse en gran cantidad de situaciones aun cuando no sea totalmente preciso o completo.
- Puede usarse para ayudar a superar su propio volumen, ayudando a acotar el rango de posibilidades que normalmente deben ser consideradas.

Como conclusión se ponen de manifiesto tres importantes técnicas de IA:

- Búsqueda: proporciona una forma de resolver los problemas en los que no se dispone de un método más directo tan bueno como una estructura en la que empotrar algunas técnicas directas existentes.
- Uso del conocimiento: proporciona una forma de resolver problemas complejos explotando las estructuras de los objetos involucrados.
- Abstracción: proporciona una forma de separar aspectos y variaciones importantes de aquellos otros sin importancia y que en caso contrario podrían colapsar un proceso.

Para solucionar problemas complicados los programas que utilizan estas técnicas presentan numerosas ventajas frente a los que no lo hacen. Los primeros son mucho menos frágiles, no se despistarán totalmente debido a una pequeña perturbación en la entrada. El conocimiento del programa es comprendido fácilmente por la gente. Y estas técnicas pueden trabajar con facilidad en grandes problemas en donde los métodos directos fallan.

El nivel del modelo

Antes de ponerse a trabajar, es una buena idea decidir qué es exactamente lo que se intenta lograr. Podemos preguntarnos ¿Qué pretendemos al construir programas que realicen las tareas inteligentes que los humanos hacen? ¿Estamos intentando construir programas que realicen las tareas de la misma forma en que lo hace el hombre? O ¿Estamos intentando construir programas que simplemente realicen las tareas de la forma que parezca más sencilla? Han existido proyectos de IA centrados en cada uno de estos objetivos.

Los esfuerzos dedicados a construir programas que lleven a cabo tareas de la misma forma que el hombre, se dividen en dos clases.

- Los programas de la primera clase se encargan de problemas que no se adecuan mucho con nuestra definición de tarea perteneciente a la IA; son aquellos problemas que una computadora puede resolver fácilmente, pero cuya resolución implica el uso de mecanismos de los que no dispone el hombre. Un ejemplo clásico de esta clase de programas lo constituye el Observador y Memorizador Elemental (EPAM) (Elementary Perceiver and Memorizar) (Feigenbaum, 1963), el cual memoriza parejas asociadas de sílabas sin sentido. Memorizar parejas de sílabas sin sentido es fácil para una computadora: simplemente se almacenan. Para recuperar una sílaba correspondiente dado su estímulo, la computadora examina la sílaba estimulada y responde con la que está almacenada a continuación.
- La segunda clase de programas que intentan modelar lo humano, son aquellas que realizan tareas que se adecuan claramente con nuestra definición de tareas de IA. Hacen cosas que no son triviales para una computadora.

Hay varias razones para querer modelar la forma de trabajar humana para llevar a cabo estas tareas:

- Verificar las teorías psicológicas de la actuación humana. PARRY (Colby, 1975) es un ejemplo de programa escrito por esta razón; utiliza un modelo de comportamiento paranoico humano para simular el comportamiento conversacional de una persona paranoica. El programa resultó lo suficientemente bueno como para que algunos psicólogos que tuvieron la oportunidad de conversar con el programa mediante un terminal, diagnosticaran que su comportamiento era paranoico.
- Capacitar a las computadoras para comprender el razonamiento humano. Por ejemplo, que una computadora pudiera leer un artículo en el periódico y al responder a preguntas tales como ¿por qué los terroristas mataron a los rehenes? El programa pueda simular los procesos de razonamiento de los seres humanos.
- Capacitar a la gente para comprender a las computadoras. En muchas circunstancias, la gente no está dispuesta a fiarse del resultado de una computadora a no ser que entienda como ha llegado la máquina a esa conclusión. Si el proceso de razonamiento de una computadora es similar al humano, producir una explicación adecuada resultaría mucho más fácil.
- Explotar el conocimiento que se puede buscar en el hombre. Debido a que el hombre es el sistema del que mejor se conoce cómo lleva a cabo las tareas con las que estamos familiarizados, tiene sentido fijarse en él para buscar pistas de cómo actuar.

Esta última motivación es probablemente la más penetrante de las cuatro. Motivó desde el principio la aparición de sistemas que intentaban obtener un comportamiento inteligente imitando al hombre a nivel de las neuronas individuales. Ejemplos de esto son los primeros trabajos teóricos de McCulloch y Pitts (1943), el trabajo sobre perceptrones, desarrollado en principio por Frank Rosenblatt, pero descrito mejor en Perceptrons (Minsky y papera, 1969) y Design for a Brain (Sabih, 1952). Se demostró, sin embargo, que era imposible producir un comportamiento mínimamente inteligente con estos sencillos dispositivos. Una de las razones era que había severas limitaciones teóricas en la arquitectura de la red neuronal que se estaba utilizando. Más recientemente han surgido nuevas arquitecturas de redes neuronales. Estas nuevas estructuras no se hallan sujetas a las mismas limitaciones teóricas que los perceptrones. Estas nuevas arquitecturas se denominan imprecisamente "conexionadas" (conexionist), y se usan como base para programas de resolución de problemas y aprendizaje.

Criterios de determinación del éxito

Una de las preguntas más importantes a responder en toda investigación científica o de ingeniería es ¿Cómo sabremos si hemos tenido éxito?. La Inteligencia Artificial no es una excepción. ¿Cómo podemos saber si hemos construido una máquina inteligente?

En 1950, Alan Turing propuso el siguiente método para determinar si una máquina es capaz de pensar. Este método es conocido como el test de Turing. Para realizarlo se necesitan dos personas y la máquina que se desea evaluar. Una de las personas actúa de entrevistador y se encuentra en una habitación, separado de la computadora y de la otra persona. El entrevistador hace preguntas tanto a la persona como a la computadora mecanografiando las cuestiones y recibe las respuestas de igual forma. El entrevistador solo los conoce por A y B, y debe intentar determinar quién es la persona y quien la máquina. El objetivo de la máquina es hacer creer al entrevistador que es una persona, si lo consigue, se concluye que la máquina piensa. Se permite que ésta haga cualquier cosa para engañar al entrevistador. Así, por ejemplo, si la pregunta es ¿cuánto es 123324 por 73981? La máquina podría esperar unos minutos y responder erróneamente (Turing, 1963).

El aspecto más serio, sin embargo, es la cantidad de conocimiento que necesitaría la máquina para pasar el test de Turing.

Aún tendrá que pasar mucho tiempo para que una máquina supere el test de Turing. Algunos piensan que nunca lo harán. Pero supongamos que estamos dispuestos a aceptar menos que una imitación completa de la persona. ¿Podemos calibrar el éxito de la IA en dominios más restringidos?

Con frecuencia la respuesta es afirmativa. Algunas veces se puede dar una medida bastante buena del logro obtenido por un programa. Por ejemplo, un programa puede jugar al ajedrez al mismo nivel que los jugadores humanos; su nivel vendrá dado por el de los jugadores a los que pueda derrotar. Actualmente, los programas logran clasificaciones más altas que la inmensa mayoría de los jugadores de ajedrez. Para otros dominios, es posible dar una medida menos precisa del éxito de un programa. Por ejemplo, DENDRAL, es un programa que analiza componentes orgánicos para determinar su estructura. Es cruel dar una medida precisa del nivel de éxito de DENDRAL, comparándolo con el de los químicos; sin embargo, se han logrado análisis que han sido publicados como resultados de investigación original. Desde luego es al menos una ayuda competente.

En otros dominios técnicos, es posible hacer una comparación del tiempo que tarda un programa en llevar a cabo una determinada tarea con el que tarda una persona en hacer lo mismo. Por ejemplo, existen bastantes programas usados por empresas de informática para configurar sistemas particulares a las necesidades del cliente (en donde el programa RI es pionero). Estos programas normalmente necesitan minutos para realizar tareas que antes requerían horas para un habilidoso ingeniero. Estos programas se evalúan normalmente atendiendo a si se ahorra o se gana dinero.

Si lo que se quiere es escribir programas que simulen el comportamiento humano ante una tarea, la forma de medir el éxito está en que el comportamiento del programa se corresponda con el humano, así como mediante distintas clases de experimentos y análisis de protocolos. En este sentido no se busca un programa que simplemente sea tan bueno como sea posible, se busca un programa que falle donde la gente lo hace.

1.7. Acciones que debe llevar a cabo un sistema de IA

Para construir un sistema que resuelva un problema específico, es necesario realizar estas cuatro acciones:

- Definir el problema con precisión. La definición debe incluir especificaciones precisas tanto sobre la o las situaciones iniciales como sobre las situaciones finales que se aceptarían como soluciones al problema.
- Analizar el problema. Algunas características de gran importancia pueden tener un gran efecto sobre la conveniencia o no de utilizar las diversas técnicas que resuelven el problema.
- Aislar y representar el conocimiento necesario para resolver el problema.
- Elegir la mejor técnica que resuelva el problema y aplicarla al problema particular.

Como plantear un problema

El planteamiento del problema inicia con la descripción del mismo en lenguaje natural, donde se establece la meta (solución que se quiere obtener), se delimita el problema y los elementos que intervienen como las variables, restricciones, función objetivo o a optimizar, punto de partida, todo esto de manera un tanto informal. Aquí es donde se identifica el nivel de conocimiento que se tiene del problema. Luego de obtener la descripción en lenguaje natural, se sigue un proceso de definición formal y estructurada que se representará en algún lenguaje, lo cual nos lleva a otro nivel de abstracción o síntesis. En este nivel es necesario definir las entidades que van a interactuar y eliminar ciertos detalles que se consideren no relevantes. Aquí es donde se puede determinar que parte de la descripción del problema puede ser validada y representada simbólicamente. Parte del proceso requiere que se determinen las entradas, las salidas y el proceso (cálculos y acciones) que realizará cada entidad de cada nivel y la forma en cómo se comunicaran entre ellas.

También se debe determinar el espacio de soluciones, de las cuales se van a considerar sólo las soluciones factibles, es decir las soluciones que cumplan con las restricciones previamente establecidas, de las cuales una o más pueden ser la solución óptima que resuelve el problema. Además de lo anterior, se requiere la información o datos con los que se trabajará, que representarán la instancia del problema a resolver. Una vez determinado esto, se podrá elegir la estrategia a seguir para obtener la solución del problema.




Figura 1.2

Cada problema que se pueda plantear es diferente, sin embargo, todos tienen ciertas características comunes que nos permiten en primera instancia clasificarlos y estructurarlos.

En segunda instancia esta estructuración, la cual se debe llevar a cabo de una manera formal, nos puede permitir resolverlos de manera automática, utilizando la representación adecuada. Dicha representación por necesidad de uniformidad y estandarización deberá utilizar un lenguaje común para ser utilizado por los entes inteligentes.

Si abstraemos los elementos que describen un problema podemos identificar los siguientes:

- Un punto de partida, los elementos que definen las características del problema.
- Un objetivo a alcanzar, qué queremos obtener con la resolución.
- Acciones a nuestra disposición para resolver el problema, o sea, de qué herramientas disponemos para manipular los elementos del problema.
- Restricciones sobre el objetivo, qué características debe tener la solución.
- Elementos que son relevantes en el problema definidos por el dominio concreto, es decir, que conocimiento tenemos que nos puede ayudar a resolver el problema de una manera eficiente.

La búsqueda en espacio de estados y la búsqueda en espacio de solución son dos enfoques fundamentales dentro de la inteligencia artificial para resolver problemas de toma de decisiones y planificación. Ambos conceptos están estrechamente relacionados, pero se diferencian en su representación y enfoque de los problemas.

1.7.1. Búsqueda en espacio de estados

La búsqueda en espacio de estados se refiere a la exploración de un conjunto de configuraciones posibles (estados) para resolver un problema. Un espacio de estados es el conjunto de todos los estados posibles que pueden ser alcanzados desde el estado inicial, siguiendo ciertas acciones o transiciones.

En este enfoque, el problema se representa como una secuencia de transiciones entre estados. La búsqueda en este espacio involucra la generación y exploración de estos estados hasta encontrar una solución (un estado objetivo).

En el espacio de estados, el objetivo es explorar el conjunto completo de configuraciones posibles. El espacio de estados representa una estructura más detallada, incluyendo todos los estados intermedios.

Los algoritmos de búsqueda en espacio de estados, como BFS (Búsqueda primero en anchura) y DFS (Búsqueda primero en profundidad) son ejemplos de estrategias para navegar este espacio, es decir, que buscan transitar por los estados hasta encontrar la solución.

Definición del problema mediante una búsqueda en espacio de estados

El problema de jugar al ajedrez

Suponga que comenzamos por el problema de "Jugar al ajedrez". A pesar de que es previsible que la mayoría de la gente únicamente con esta sentencia actúe correctamente, la definición del problema tal y como está, es incompleta. Para construir un programa que "juegue al ajedrez", primero se debe especificar la posición inicial del tablero, las reglas que definen los movimientos legales y las posiciones del tablero que representan una victoria tanto para un lado como para el otro. Además, se debe explicitar previamente el objetivo implícito de no solo realizar un movimiento legal de ajedrez, sino también ganar la partida, si es posible.

Para el problema de "jugar al ajedrez" es bastante fácil dar una descripción formal y completa del problema. La posición inicial se puede describir como un array de 8 por 8 posiciones donde cada una contiene un símbolo, de acuerdo con las piezas situadas en posición de comienzo de una partida oficial de ajedrez. El objetivo se define como cualquier posición del tablero en la que el contrario no pueda realizar ningún movimiento legal y su rey esté amenazado.

Los movimientos legales representan la forma de llegar a algún estado objetivo partiendo del estado inicial. Se pueden describir fácilmente como un conjunto de reglas compuestas por dos partes: una parte izquierda que se usa a modo de patrón para ser contrastado con la situación actual del tablero, y una parte derecha que describe el cambio que debe producirse en el tablero para que refleje el movimiento.

Existen diferentes formas de expresar estas reglas, una de ellas es la que se muestra en la siguiente figura:




Figura 1.3

Sin embargo, si se utilizan reglas como la anterior, es necesario escribir un número muy grande de ellas, ya que existiría una regla para cada una de las 10^{120} posibles posiciones del tablero. Al usar tal cantidad de reglas aparecen dos serias dificultades prácticas:

- Nadie puede suministrar un conjunto completo de tales reglas. Serían demasiadas y no se podría evitar la aparición de errores.
- Ningún programa puede manipular todas estas reglas. Podría usarse un sistema de hashing para poder encontrar más rápidamente las reglas más relevantes, pero, aun así, almacenar tantas reglas crea muchas dificultades.

Con el fin de minimizar estos problemas, se debe buscar la forma de escribir las reglas que describen los movimientos legales de la forma más general posible. Para lograrlo, es adecuado introducir una notación conveniente para describir los patrones y las sustituciones. Por ejemplo, la regla descrita en la Figura 1.3, al igual que muchas como ella, puede escribirse como se muestra en la Figura 1.4. En general, cuanto más concisamente se describan las reglas, menos trabajo se empleará para introducirlas y el programa las usará con más eficiencia.




Figura 1.4

Se ha definido el problema de jugar al ajedrez como un problema de movimientos a través de un espacio de estados, donde cada estado se corresponde con una posición legal del tablero. Se puede entonces jugar al ajedrez, comenzando a partir de un estado inicial, mediante el uso de un conjunto de reglas de movimientos que trasladan de un estado a otro para intentar finalizar en alguno de los estados finales.

El espacio de estados serían todas las configuraciones posibles del tablero y la búsqueda consistiría en explorar esos estados para encontrar una secuencia de jugadas que conduzca a la victoria.

La representación como espacio de estados surge de forma natural en el ajedrez, ya que el conjunto de estados, que se corresponde con el conjunto de posiciones del tablero, es artificial y bien estructurado.

El mismo tipo de representación es también adecuada para problemas menos estructurados, aunque sea necesario utilizar estructuras más complejas que una matriz para describir un estado individual. La representación como espacio de estados forma la base de la mayoría de los métodos de IA que se discuten aquí. Su estructura se corresponde con la estructura de la resolución de problemas por dos importantes razones:

- Permite definir formalmente el problema, mediante la necesidad de convertir alguna situación dada en la situación deseada usando un conjunto de operaciones permitidas.
- Permite definir el proceso de resolución de un problema como una combinación de técnicas conocidas (representadas por una regla que define un movimiento en el espacio) y búsqueda, la técnica general de exploración en el espacio intenta encontrar alguna ruta desde el estado actual hasta un estado objetivo. La búsqueda es un proceso de gran importancia en la resolución de problemas difíciles para los que no se dispone de técnicas más directas.

Con el fin de percibir la generalidad de la representación en espacio de estados, se muestra su uso para describir un problema muy diferente al de jugar al ajedrez.

El problema de las jarras de agua

Se tienen dos jarras, una de cuatro litros de capacidad y otra de tres. Ninguna de ellas tiene marcas de medición. Se tiene una bomba que permite llenar las jarras de agua. ¿Cómo se puede lograr tener exactamente dos litros de agua en la jarra de cuatro litros de capacidad?

Para este problema el espacio de estados se puede representar como un conjunto de pares ordenados de enteros (x,y) , de forma que $x = 0, 1, 2, 3, 4$ e $y = 0, 1, 2, 3$; x representa el número de litros de agua que almacena la jarra de cuatro litros, e y representa la cantidad de agua de la jarra de tres. El estado inicial es $(0,0)$. El estado objetivo es $(2,n)$ siendo n cualquier valor (el problema no especifica cuantos litros debe haber en la jarra de tres litros).

Los operadores usados para resolver el problema se describen en la Figura 1,5. Al igual que en el problema del ajedrez, están representados en forma de reglas en las que la parte izquierda se compara con el estado actual, y en las que la parte derecha describe el nuevo estado al que se llega mediante la aplicación de la regla.

1	(x,y) si $x < 4$	$\rightarrow (4,y)$	Llenar la jarra de 4 litros
2	(x,y) si $y < 3$	$\rightarrow (x,3)$	Llenar la jarra de 3 litros
3	(x,y) si $x > 0$	$\rightarrow (x-d,y)$	Vaciar un poco la jarra de 4 litros
4	(x,y) si $y > 0$	$\rightarrow (x,y-d)$	Vaciar un poco la jarra de 3 litros
5	(x,y) si $x > 0$	$\rightarrow (0,y)$	Vaciar la jarra de 4 litros en el suelo
6	(x,y) si $y > 0$	$\rightarrow (x,0)$	Vaciar la jarra de 3 litros en el suelo
7	(x,y) si $x+y \geq 4$ e $y > 0$	$\rightarrow (4,y-(4-x))$	Verter agua desde la jarra de 3 litros a la jarra de 4 litros hasta que la jarra de 4 litros esté llena
8	(x,y) si $x+y \geq 3$ y $x > 0$	$\rightarrow (x-(3-y),3)$	Verter agua desde la jarra de 4 litros a la jarra de 3 litros hasta que la jarra de 3 litros esté llena
9	(x,y) si $x+y \leq 4$ e $y > 0$	$\rightarrow (x+y,0)$	Verter todo el agua de la jarra de 3 litros en la jarra de 4 litros
10	(x,y) si $x+y \leq 3$ y $x > 0$	$\rightarrow (0,x+y)$	Verter todo el agua de la jarra de 4 litros en la jarra de 3 litros
11	(0,2)	$\rightarrow (2,0)$	Verter 2 litros de la jarra de 3 litros en la jarra de 4 litros
12	(x,2)	$\rightarrow (0,2)$	Vaciar la jarra de 4 litros en el suelo

Figura 1.5

Litros en la Jarra de 4 litros	Litros en la jarra de 3 litros	Regla aplicada
0	0	2
0	3	9
3	0	2
3	3	7
4	2	5 o 12
0	2	9 u 11
2	0	

Una solución al problema de las jarras de agua

Resumiendo lo dicho anteriormente, para poder producir una descripción formal de un problema debe hacerse lo siguiente:

- Definir un espacio de estados que contenga todas las configuraciones posibles de los objetos más relevantes (y quizá algunos imposibles). Es, por supuesto, posible definir este espacio sin tener que hacer una enumeración de todos y cada uno de los estados que contienen.
- Identificar uno o más estados que describan situaciones en las que comience el proceso de resolución del problema. Estos se denominan estados iniciales.
- Especificar uno o más estados que pudieran ser soluciones aceptables del problema. Estos estados se denominan estados objetivo.
- Especificar un conjunto de reglas que describan las acciones (operadores) disponibles.

De esta forma, el problema puede resolverse con el uso de las reglas en combinación con una estrategia apropiada de control para trasladarse a través del espacio problema hasta encontrar una ruta desde un estado inicial hasta un estado objetivo.

1.7.2. Búsqueda en espacio de solución

La búsqueda en espacio de solución es un enfoque más abstracto, donde el objetivo es encontrar una solución o conjunto de soluciones a un problema, es decir, está centrado solo en las soluciones que cumplen los criterios del problema.

En este enfoque, el problema se define en términos de objetivos que deben cumplirse, en lugar de una serie de estados intermedios.

Espacio de Solución se refiere al conjunto de todas las posibles soluciones del problema, que pueden no requerir recorrer todos los estados posibles, sino solo aquellos que conducen directamente a una solución.

En el espacio de solución, el objetivo es encontrar una solución sin explorar todos los estados posibles.

A diferencia de la búsqueda en espacio de estados, que se enfoca en explorar la estructura completa del problema, la búsqueda en espacio de solución se centra en encontrar caminos o combinaciones que lleven a la resolución del problema, sin tener que generar necesariamente todos los estados intermedios.

En el espacio de solución, la búsqueda podría ser más directa, centrada en encontrar soluciones específicas sin explorar todos los posibles estados intermedios. Por ejemplo, en un problema de optimización de rutas, el espacio de solución podría consistir en todas las posibles rutas de entrega y el algoritmo buscaría la que tenga el costo mínimo sin explorar necesariamente todas las combinaciones de paradas.

En síntesis, la búsqueda en espacio de estados se enfoca en explorar los estados posibles de un problema, mientras que la búsqueda en espacio de solución se centra en encontrar directamente soluciones al problema. Ambos son enfoques complementarios que dependen de cómo se modela y define el problema a resolver.

1.7.3. Sistemas de producción

Debido a que la búsqueda es el núcleo de muchos procesos inteligentes, es adecuado estructurar los programas de IA de forma que se facilite describir y desarrollar el proceso de búsqueda. Los sistemas de producción proporcionan tales estructuras. Más abajo se introduce una definición de sistema de producción. Conviene no confundirse con otros usos de la palabra producción, tales como lo que se produce en una fábrica.

Un sistema de producción consiste en:

- Un conjunto de reglas compuestas por una parte izquierda (un patrón) que determina la aplicabilidad de la regla y una parte derecha, que describe la operación que se lleva a cabo si se aplica la regla.
- Una o más bases de datos/conocimiento que contengan cualquier tipo de información apropiada para la tarea en particular. Partes de la base de datos pueden ser permanentes, mientras que otras pueden hacer referencia solo a la solución del problema actual. La información almacenada en estas bases de datos debe estructurarse de forma adecuada.
- Una estrategia de control que especifique el orden en el que las reglas se comparan con la base de datos, y la forma de resolver los conflictos que surjan cuando varias reglas puedan ser aplicadas a la vez.
- Un aplicador de reglas.

Hasta aquí, la definición de un sistema de producción es muy general. Abarca una gran cantidad de sistemas, incluyendo nuestras descripciones del jugador de ajedrez y de la solución al problema de las jarras de agua. También abarca una familia de intérpretes generales de sistemas de producción que incluye:

- Lenguajes básicos de sistemas de producción, tales como OPS5 (Brownston, 1985) y ACT* (Anderson, 1983).
- Sistemas más complejos, con frecuencia híbridos, denominados armazones de sistemas expertos (expert systems shell), los cuales poseen entornos completos (hablando relativamente) para la construcción de sistemas expertos basados en conocimiento.
- Arquitecturas generales de resolución de problemas tales como SOAR (Laird, 1987), sistema basado en un conjunto específico de hipótesis motivadas cognoscitivamente por la naturaleza del problema a resolver.

Todos estos sistemas mantienen la arquitectura de un sistema de producción en su totalidad y permiten que el programador escriba reglas para definir los problemas particulares que tienen que resolverse.

1.7.4. Análisis del problema

La búsqueda heurística es un método muy general que se puede aplicar a una gran clase de problemas. Incluye gran variedad de técnicas específicas, cada una de las cuales es particularmente efectiva para una pequeña clase de problemas. A fin de poder elegir el método más apropiado (o una combinación de métodos) para un problema en particular, es necesario analizarlo con arreglo a varias dimensiones clave:

- ¿Puede el problema descomponerse en un conjunto de subproblemas independientes (o casi) más pequeños o sencillos?
- ¿Pueden ignorarse pasos dados o al menos deshacerse si se comprueba que no eran adecuados?
- ¿Es predecible el universo del problema?
- ¿Una solución es buena de manera evidente, sin necesidad de compararla con todas las demás posibles soluciones?
- La solución deseada, ¿es un estado del mundo o una ruta hacia algún estado?
- ¿Es necesaria una gran cantidad de conocimiento para resolver el problema o solo es necesario para restringir la búsqueda?

- La computadora a la que simplemente se le da el problema ¿Puede emitir una solución, o es necesario que ésta interactúe con una persona?

1.7.4.1. ¿Puede descomponerse el problema?

Suponga que se desea resolver el problema de calcular la expresión:

$$\int (x^2 + 3x + \sin^2 x - \cos^2 x) dx$$

Se puede resolver este problema descomponiéndolo en tres problemas más pequeños, cada uno de los cuales puede resolverse usando una pequeña colección de reglas específicas. La Figura 1.6 muestra el árbol del problema que se genera mediante el proceso de descomposición. El árbol puede generarse con un sencillo programa recursivo de integración de esta forma: en cada paso, se verifica si el problema en el que se trabaja se puede resolver directamente. Si lo es, se devuelve inmediatamente la respuesta. Si el problema no se puede resolver fácilmente, el integrador verifica si puede descomponer el problema en otros más simples. Si puede, crea estos problemas y se llama recursivamente a sí mismo con ellos. Mediante el uso de esta técnica de descomposición del problema, se pueden resolver fácilmente problemas muy grandes.




Figura 1.6

Considere ahora el problema ilustrado en la Figura 1.7. Este problema está extraído de un dominio que con frecuencia está referenciado en la literatura de IA como el mundo de los bloques. Se permiten los siguientes operadores:

DESPEJADO (x) [el bloque x no tiene nada sobre él] → SOBRE (X, Mesa) [tome x y ponlo sobre la mesa]

DESPEJADO (x) y DESPEJADO (y) → SOBRE (X, y) [poner x sobre y]




Figura 1.7

La aplicación de la técnica de descomposición del problema a este sencillo ejemplo de mundo de bloques se lleva al árbol solución mostrado en la Figura 1.8. En la figura, los objetivos están subrayados; los estados alcanzados no lo están. La idea de esta solución es la de reducir el problema de conseguir B sobre C y A sobre B a dos problemas separados. El primero de estos nuevos problemas, conseguir B sobre C, es sencillo, dado el estado inicial. Simplemente se coloca B sobre C. El segundo subobjetivo no es tan sencillo, puesto que los únicos operadores permitidos toman un solo bloque a la vez, se tiene que eliminar A quitando C antes de coger A y situarlo sobre B. Esto puede hacerse fácilmente. Sin embargo, al intentar combinar las dos subsoluciones en una sola, se falla. Independientemente de cual se haga primero, no se podrá realizar el segundo tal y como se ha planeado. En este problema los dos subproblemas no son independientes. Interactúan, y tales interacciones deben ser consideradas a fin de llegar a una solución para la totalidad del problema.




Figura 1.8

Estos dos ejemplos, el de la integración simbólica y el del mundo de los bloques, ilustran la diferencia entre problemas que se pueden descomponer y los que no se pueden descomponer.

1.7.4.2. ¿Pueden deshacerse o ignorarse pasos hacia una solución?

Suponga que se intenta probar un teorema matemático. En primer lugar, se prueba un lema que se piensa que será útil. En cierto instante, se comprueba que el lema no supone una ayuda para nada. ¿se está en un apuro?

No, todo lo que se necesita saber para probar el teorema es todavía cierto y está memorizado. Algunas reglas que pudieron aplicarse al principio aún pueden hacerlo. Basta con continuar como si se comenzara de nuevo. Todo el esfuerzo realizado se ha perdido en explorar un callejón sin salida.

El problema del 8 puzzle

El 8-puzzle es un cajón cuadrado en el que hay situados ocho bloques cuadrados. El cuadrado restante está sin rellenar. Cada bloque tiene un número. Un bloque adyacente al hueco puede deslizarse hacia él. El juego consiste en partir de una posición de salida para llegar a una posición especificada como objetivo. El objetivo es transformar la posición inicial en la posición objetivo mediante el deslizamiento de los bloques.

En la Figura 1.9 se ve un juego de muestra con el 8-puzzle. Al intentar resolver el 8-puzzle, se pueden realizar movimientos estúpidos. Por ejemplo, en el juego que se muestra arriba, se podría empezar deslizando el bloque 5 al espacio vacío. Al hacer esto, no se podrá deslizar el bloque 6 al hueco porque éste se ha movido, pero podemos volver atrás y deshacer el primer movimiento, deslizando el bloque 5 adonde estaba. Entonces ya podemos mover el bloque 6. Los errores pueden recuperarse también, pero no de una forma tan sencilla como en el problema de la demostración del teorema. Se debe realizar un paso adicional para deshacer cada movimiento incorrecto, mientras que no se necesita realizar ninguna acción para "deshacer" un lema inútil. Además, el mecanismo de control de resolución de un 8-puzzle no debe perder de vista el orden en que se realizan las operaciones para que éstas puedan deshacerse si es necesario. La estructura de control del demostrador de teoremas no necesita almacenar toda esta información.




Figura 1.9

Considere otra vez el problema del juego del ajedrez. Suponga que un programa que juegue al ajedrez realiza un movimiento estúpido y cae en la cuenta un par de movimientos después; el programa no puede jugar como si nunca hubiera hecho el movimiento estúpido ni puede volver atrás y empezar el juego desde ese punto. Todo lo que puede hacer es intentar hacerlo mejor en la situación actual y partir desde ésta.

Estos tres problemas - la demostración de teoremas, el 8 puzzle y el ajedrez – ilustran las diferencias existentes entre tres importantes clases de problemas:

- Ignorables (por ej. la demostración de Teoremas) en la que pueden ignorarse pasos dados.
- Recuperables (por ej. El 8 puzzle), en el que pueden deshacerse pasos dados.
- No recuperables (por ej. el ajedrez), en el que no pueden deshacerse pasos dados.

Estas tres definiciones hacen referencia a los pasos de la solución de un problema y, por lo tanto, pueden surgir para caracterizar sistemas de producción específicos para resolver problemas más que el problema en sí mismo. Quizá una formulación diferente de un mismo problema haría que el

problema fuera caracterizado de forma diferente. Estrictamente hablando, esto es cierto. Sin embargo, debido a muchos grandes problemas, existe solo una formulación (o un pequeño número de ellas esencialmente equivalentes) que de forma natural describe el problema. Esto es así para cada uno de los problemas expuestos anteriormente. Cuando éste sea el caso, tiene sentido considerar la recuperabilidad de un» problema de forma equivalente a la recuperabilidad de una formulación natural para él.

La recuperabilidad de un problema juega un papel importante en la determinación de la complejidad de la estructura de control necesaria para resolver el problema. Los problemas ignorables se resuelven utilizando una sencilla estructura de control que nunca vuelve hacia atrás. Estas estructuras de control son fáciles de implementar. Los problemas recuperables se resuelven con estrategias un poco más complicadas que a veces cometen errores. Para recuperarse de tales errores será necesaria una vuelta atrás, de forma que la estructura de control debe implementarse con una pila "push-down", en la que las decisiones se conservan en caso de que necesiten ser deshechas más tarde. Los problemas no recuperables, por otro lado, se resuelven mediante un sistema que debe aplicar muchísimo esfuerzo en la toma de decisiones ya que éstas son irrevocables. Algunos problemas irre recuperables se resuelven con métodos de estilo recuperable usando un proceso de planificación, en el que se analiza por adelantado una secuencia entera de pasos para descubrir adonde conducirá antes de dar el primer paso. Más adelante se explican las clases de problemas en los que es posible hacer esto.

1.7.4.3. ¿Es predecible el universo?

Suponga nuevamente que estamos jugando al 8-puzzle. Cada vez que se hace un movimiento, se sabe exactamente qué ocurrirá. Esto significa que es posible planificar una secuencia entera de movimientos y estar seguros de que se conoce cuál será el resultado. Es posible utilizar una planificación para evitar tener que deshacer movimientos, si bien todavía se deben hacer comprobaciones de movimientos en tiempo de planificación. De esta forma, es necesaria una estructura de control que permita la comprobación.

Sin embargo, en otros juegos diferentes al 8-puzzle, no es posible un proceso de planificación. Suponga que queremos jugar al bridge. Una de las decisiones que hay que tomar es qué carta jugar en la primera baza. Sería deseable planificar la mano completa antes de realizar esta primera jugada. Pero ahora no es posible hacer tal planificación con certeza debido a que no se sabe con exactitud dónde están las cartas y qué harán los otros jugadores en sus turnos. Lo mejor que se puede hacer es investigar distintos planes y utilizar las probabilidades de las consecuencias que se derivan de su elección para resaltar el que tenga la más alta probabilidad estimada de llegar a una buena puntuación en el juego.

Estos dos juegos ilustran la diferencia entre problemas de consecuencia cierta y de consecuencia incierta. Una forma de describir una planificación es que es un problema resuelto sin realimentación del entorno. Para resolver los problemas de consecuencia cierta un sistema en lazo abierto es adecuado ya que el resultado de una acción se puede predecir perfectamente. Así, la planificación puede utilizarse para generar una secuencia de operadores que garantizan llegar a una solución. Para los problemas de consecuencia incierta, sin embargo, la planificación puede al menos generar una secuencia de operadores que tiene una buena probabilidad de conducir a una solución. Para resolver estos problemas, es necesario tener en cuenta que un proceso de revisión de planes se lleva a cabo cuando el plan se realice y proporcione la necesaria realimentación. Además de no garantizar una solución, la planificación aplicada a los problemas de consecuencia incierta tiene el inconveniente de que suele ser muy cara ya que el número de rutas de solución que necesita explorar crece exponencialmente con el número de puntos en los cuales la consecuencia no puede predecirse.

Las dos últimas características explicadas, ignorable versus recuperable y consecuencia-cierta versus consecuencia-incierta, interactúan de una forma interesante. Tal y como se ha mencionado siempre, una forma de resolver los problemas irrecuperables es planificando una solución completa antes de embarcarse en la implementación del plan. Sin embargo, este proceso de planificación solo es útil en los problemas de consecuencia-cierta. Así, uno de los tipos de problemas más difíciles de resolver son los irrecuperables de consecuencia-incierta.

Ejemplos de tales problemas son los siguientes:

Bridge: Sin embargo, puede mejorarse un poco ya que existen estimaciones exactas de las probabilidades de cada una de las posibles consecuencias.

Control de un brazo de robot: La consecuencia es incierta debido a varias razones. Alguien podría poner algo en la ruta del brazo; los mecanismos del brazo podrían atascarse; un leve error podría causar que el brazo choque con una pila de objetos.

Ayudar a un abogado a decidir cómo defender a su cliente contra un cargo de asesinato. En este caso no se puede dar probablemente una lista de posibles consecuencias, y mucho menos dar sus probabilidades.

1.7.4.4. Una solución adecuada ¿es absoluta o relativa?

Considere el problema de responder a preguntas basadas en una base de datos de hechos simples, tal como ésta:

1. Marco fue un hombre.
2. Marco era pompeyano.
3. Marco nació en el año 40 d.c.
4. Todos los hombres son mortales.
5. Todos los pompeyanos murieron con la erupción del volcán en el año 79 d.c.
6. Ningún mortal vive más de 150 años.
7. Estamos en el año 1994 d.c.

Suponga que se hace la siguiente pregunta "¿Está Marco vivo?". Al representar cada uno de estos hechos en un lenguaje formal, tal como la lógica de predicados, y al utilizar métodos formales de inferencia, puede derivarse fácilmente una respuesta a la pregunta. De hecho, cualquiera de las dos formas de razonamiento conducirá a la respuesta, tal y como se muestra en la Figura 1.10. Nuestro interés se centra en responder a esta pregunta sin importar qué camino se ha seguido para hacerlo. Si se sigue un camino que lleva a la respuesta con éxito, no hay razón para volver atrás y ver si existen otros caminos que también lleguen a la solución.

	Justificación
1. Marco fue un hombre.	axioma 1
4. Todos los hombres son mortales.	axioma 4
8. Marco es mortal.	1,4
3. Marco nació en el 40 d.c.	axioma 3
7. Estamos en el año 1994 d.c.	axioma 7
9. Marco tiene 1954 años.	3,7
6. Ningún mortal vive más de 150 años.	axioma 6
10. Marco está muerto.	8,6,9
o	
7. Estamos en el año 1994 d.c.	axioma 7
5. Todos los pompeyanos murieron con la erupción del volcán en el año 79 d.c.	axioma 5
11. Todos los pompeyanos están muertos.	7,5
2. Marco era pompeyano.	axioma 2
12. Marco está muerto.	11,2

Figura 1.10

Pero ahora considere de nuevo el problema del viajante de comercio. El objetivo es encontrar la ruta más corta que lleve a cada ciudad exactamente una vez. Suponga que las ciudades a visitar y las distancias entre ellas son las que aparecen en la Figura 1.11.

	Boston	Nueva York	Miami	Dallas	San Francisco
Boston		250	1450	1700	3000
Nueva York	250		1200	1500	2900
Miami	1450	1200		1600	3300
Dallas	1700	1500	1600		1700
San Francisco	3000	2900	3300	1700	

Figura 1.11

El vendedor podría comenzar desde Boston. En ese caso, una ruta que podría seguir es la que tiene 8850 millas de longitud. Pero, ¿es ésta la solución al problema? La respuesta es que no se puede asegurar hasta que no se intenten todas las demás rutas y se esté seguro de que ninguna de ellas es más corta. En este caso, como se ve en la Figura 1.12, la primera ruta no es definitivamente la solución al problema del viajante.




Figura 1.12

Estos dos ejemplos ilustran la diferencia que existe entre los problemas de algún-camino y los problemas de el-mejor-camino. Los problemas de el-mejor-camino son, por lo general, más complicados de computar que los problemas de algún-camino. Los problemas de algún-camino se resuelven frecuentemente en un tiempo razonable mediante heurísticas que sugieren rutas adecuadas para explorar. Si las heurísticas no son perfectas, la búsqueda de una solución puede no ser tan directa como sea posible, pero esto no tiene importancia. Para ciertos problemas de el-mejor-camino, sin embargo, no pueden usarse heurísticas que puedan omitir la mejor solución. Se requiere una búsqueda mucho más exhaustiva.

1.7.4.5. ¿La solución es un estado o una ruta?

Considere el problema de encontrar una interpretación consistente a la frase:

El presidente del banco comió un plato de ensalada de pasta con el tenedor.

Existen varios componentes de esta frase que, si se aíslan, pueden tener más de una interpretación. Sin embargo, los componentes tienen que formar un todo, y de esta forma se restringen las otras posibles interpretaciones. Algunas causas de ambigüedad en la frase son las siguientes:

La palabra "banco" puede referirse a una institución financiera o a un objeto para sentarse. Sin embargo, solo uno de ellos puede tener un presidente.

La palabra "plato" es el objeto directo del verbo "comer". Es posible comerse un plato, pero es más usual comerse la ensalada de pasta que el plato.

Una ensalada de pasta es una ensalada que contiene pasta. Sin embargo, existen otras formas semánticas de agrupar dos nombres. Por ejemplo, la comida de perros normalmente no contiene perros.

La frase "con el tenedor" puede modificar distintas partes de la oración. En este caso, modifica al verbo "comer". Pero, si la frase hubiera sido "con vegetales", la estructura de la modificación sería diferente. Y si la frase hubiera sido "con sus amigos", la estructura sería también diferente.

Debido a las interacciones existentes entre los distintos constituyentes de esta oración, puede ser necesaria una búsqueda para encontrar una interpretación completa de la misma. Sin embargo, para resolver el problema de encontrar esta interpretación se necesita generar solo la interpretación misma. No es necesario ningún registro del proceso seguido para encontrar la interpretación.

Compare esto con el problema de las jarras de agua. En este caso no basta con indicar que se ha resuelto el problema y que la solución es (2,0). Para este tipo de problemas, lo que realmente se pide no es el estado final, sino el camino que se ha seguido para encontrar ese estado. Así, la solución a este problema debe ser una secuencia de operaciones (a veces denominada "plan") que produce el estado final.

Estos dos ejemplos, comprensión del lenguaje natural y el problema de las jarras de agua, ilustran la diferencia que existe entre problemas en los que la solución es un estado y problemas en los que la solución es una ruta hacia un estado. A este nivel, esta diferencia se puede ignorar para formular todos los problemas de IA de forma que la solución sea un estado. Si se intenta esto para problemas como el de las jarras de agua, se deben volver a describir los estados para que cada uno de ellos represente un camino parcial hacia la solución en lugar de un simple estado del mundo. Así, esta cuestión no es formalmente relevante. Sin embargo, debido al dilema ignorabilidad versus recuperabilidad, existe con frecuencia una formulación natural (y económica) del problema en donde los estados se corresponden con situaciones del mundo, y no secuencias de operaciones. En este caso, la respuesta a esta cuestión nos indica si va a ser necesario almacenar el camino del proceso de resolución del problema.

1.7.4.6. ¿Cuál es el papel del conocimiento?

Considere de nuevo el problema del ajedrez. Suponga que se dispone de una potencia de computación ilimitada. ¿Cuánto conocimiento sería necesario para realizar un programa perfecto? La respuesta es muy poco, únicamente las reglas que determinen los movimientos legales y algún sencillo mecanismo de control que implemente el procedimiento de búsqueda apropiado. Algún conocimiento adicional sobre cosas tales como buenas estrategias y tácticas ayudaría, por supuesto, considerablemente a restringir la búsqueda para aumentar la velocidad de ejecución del programa.

Considere ahora, sin embargo, el problema de leer los periódicos del día para decidir cuáles de ellos apoyan a los republicanos y cuales a los demócratas en unas elecciones. Asuma de nuevo una potencia de computación ilimitada, ¿cuánto conocimiento sería necesario para que la computadora intente resolver este problema? Esta vez la respuesta es que se necesita una gran cantidad.

Sería necesario conocer cosas como éstas:

El nombre de los candidatos de cada partido.

El hecho de que, si la mayor exigencia que se tiene es bajar los impuestos, probablemente se está apoyando a los republicanos.

El hecho de que, si la mayor exigencia que se tiene es que mejore la educación, probablemente se está apoyando a los demócratas.

El hecho de que, si uno se opone a un gran aparato del Estado, probablemente se está apoyando a los Republicanos.

Y muchos más...

Estos dos problemas, el ajedrez y la comprensión de artículos periodísticos, ilustran la diferencia existente entre aquellos problemas en los que mucho conocimiento solo es necesario para acotar la búsqueda y aquellos en los que el conocimiento se emplea para poder reconocer una solución.

1.7.4.7. ¿Necesita la tarea interactuar con una persona?

Algunas veces resulta provechoso programar las computadoras para resolver problemas de una manera que la mayoría de la gente no sería capaz de entender. Esto es así si el nivel de interacción entre el hombre y la computadora es del tipo. Entrada-problema Salida-solución. Sin embargo, se están desarrollando cada vez más programas que necesitan interacción intermedia con el hombre,

tanto para proporcionar información adicional de entrada al programa como para proporcionar noticias adicionales al usuario.

Considérese, por ejemplo, el problema de la demostración de teoremas matemáticos. Si todo lo que se quiere saber es si existe una demostración y si el programa es capaz de hallar la demostración por sí mismo, entonces no importa la estrategia que use el programa para hallar la demostración. Puede utilizar, por ejemplo, el procedimiento de resolución, el cual puede ser muy eficiente, aunque no sea muy natural para el hombre. Pero si alguna de estas condiciones no se cumple, la forma de hallar la demostración tiene mucha importancia. Suponga que se intenta probar algún nuevo y difícil teorema. Se puede pedir una demostración que siguiera los patrones tradicionales de forma que un matemático esté seguro de que la demostración es correcta solo con leerla. Por otra parte, dar con una prueba del teorema puede llegar a ser tan complejo que el programa no sepa por dónde empezar. Hasta ahora, las personas son superiores al realizar las estrategias de alto nivel que se necesitan para demostrar un teorema, de forma que una computadora necesita pedir ciertos consejos. Por ejemplo, normalmente en geometría resulta más fácil encontrar una prueba si alguien indica como representarla gráficamente. Para poder utilizar estos consejos, el razonamiento seguido por una computadora debe ser análogo al realizado por el consejero humano, al menos en ciertos aspectos. Debido a que las computadoras trabajan en áreas muy significativas de nuestras vidas tales como diagnósticos médicos, la gente no podrá aceptar el veredicto que genere un programa si no puede comprender el razonamiento que ha seguido para darlo.

Así, se puede hacer una distinción entre dos tipos de problemas:

- Solitarios, en los que a la computadora se le da una descripción del problema y ésta proporciona una respuesta sin ningún tipo de comunicación ni necesidad de explicaciones del proceso de razonamiento.
- Conversacionales, en los que existe una comunicación intermedia entre el hombre y la computadora, bien para proporcionar una ayuda adicional a la máquina o para que la computadora proporcione información al usuario.

Por supuesto, esta distinción no es totalmente estricta al describir los dominios particulares del problema. Tal y como se ha dicho, la demostración de teoremas matemáticos podría ser tanto de un tipo como de otro. Sin embargo, para una aplicación en particular, se necesitan sistemas de uno u otro tipo, y esta decisión tiene gran importancia a la hora de elegir el método de resolución del problema.