IA - Unidad 3

Aprendizaje automático - Introducción

El aprendizaje automático representa el cruce entre la ciencia de datos y la ingeniería de software. Su objetivo es usar datos para crear un modelo predictivo que después se pueda integrar en una app o servicio.

Se refiere a la capacidad de un sistema para aprender de los datos sin programarlo explícitamente.

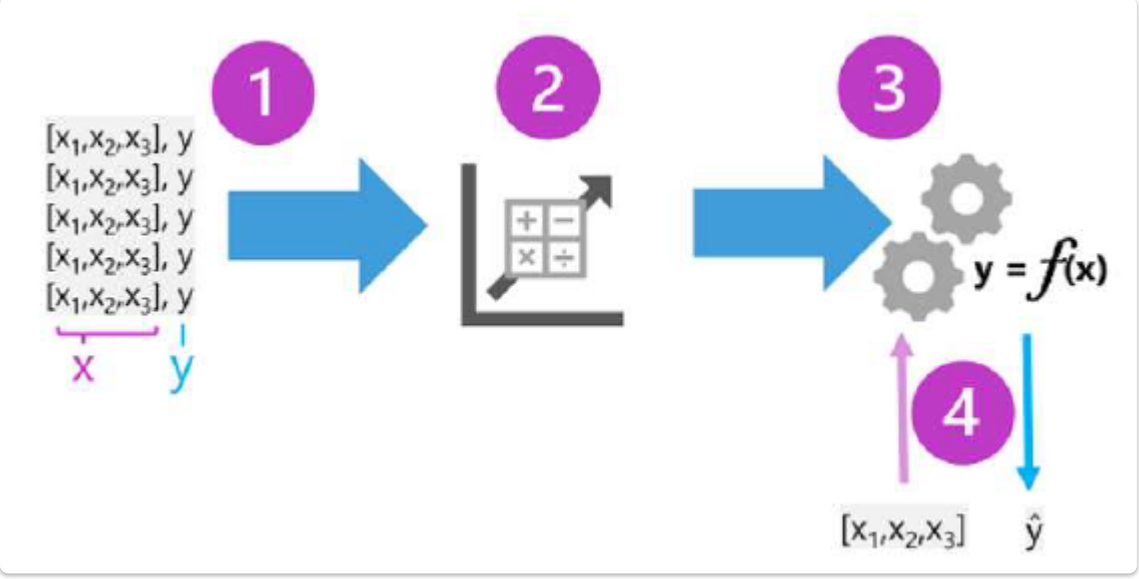
Como siempre, el punto de partida son los datos, en grandes cantidades, para identificar patrones, que luego se pueden usar para predecir y tomar decisiones.

¿Qué es?

La idea fundamental es usar datos pasados para predecir resultados desconocidos. Es una subárea de la inteligencia artificial. Tiene aplicaciones muy amplias en casi cualquier cosa en donde haya datos para explotar: salud, finanzas, marketing, transporte, etc.

Visto como función

Un modelo de AA encapsula una función que calcula un valor de salida basado en distintos valores de entrada. El proceso de definición de dicha función es el entrenamiento. Una vez definida, se usa para predecir nuevos valores mediante la inferencia.



- Los datos de entrenamiento son obs. pasadas. Incluyen atributos y el valor conocido de la cosa que se quiere predecir (la etiqueta). Una observación se compone de múltiples características x, más la etiqueta y.
- Luego se aplica un algoritmo para determinar la relación entre características y etiqueta, y generalizar eso como un cálculo. Se ajusta una función a los datos.

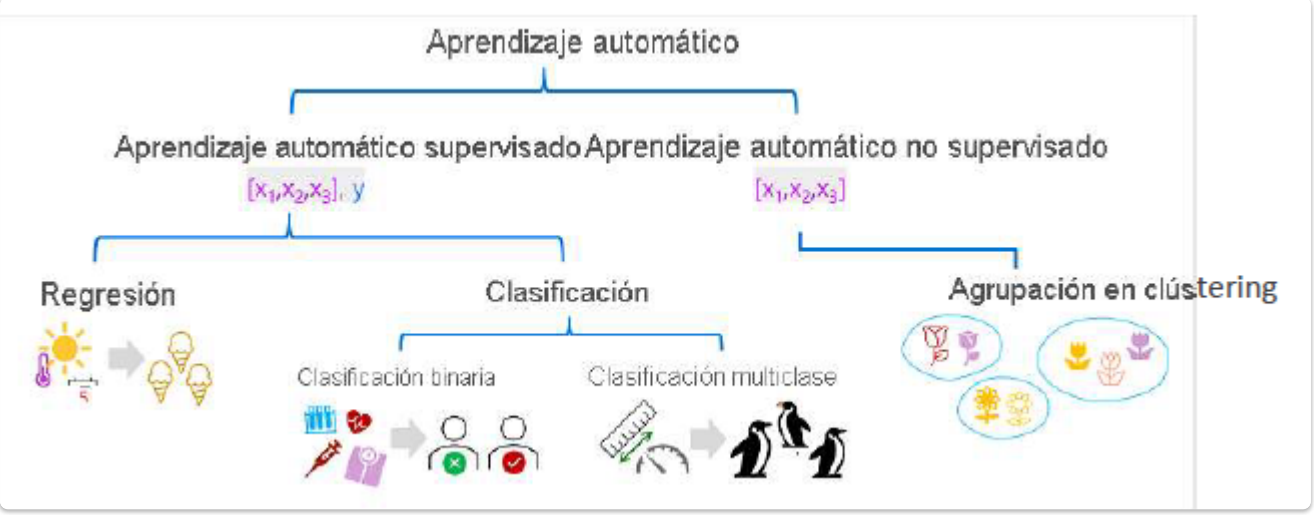
- El resultado del algoritmo es un modelo que encapsula el cálculo como una función f. y=f(x).
- Una vez completado el entrenamiento se puede usar para inferencia, logrando predecir el valor de la etiqueta en observaciones no etiquetadas.

Funcionamiento

Se pueden resumir los pasos de esta manera:

- Recopilacion de datos: Datos relevantes de distintas fuentes
- Preparación de los datos: Preprocesamiento para garantizar su utilidad
- Selección del algoritmo: Se elige según el tipo de problema
- Entrenamiento
- Evaluación: Verifica si satisface los criterios necesarios
- Implementación y supervisión

Tipos



AA Supervisado

En estos modelos las observaciones contienen una etiqueta.

- Regresión: La etiqueta inferida por el modelo es un valor numérico. Por ejemplo el valor de venta de una propiedad.
- Clasificación: La etiqueta representa una categoría o clase. Por ejemplo un vuelo demorado o no demorado, un resultado positivo de diabetes o no.
  - Clasificación binaria: La etiqueta consiste en dos resultados mutuamente excluyentes. Suele predecir positivo/negativo, verdadero/falso.
  - Multiclase: Más de dos clases.

AA no supervisado

Las observaciones no tienen etiqueta, solo características.

- Clustering: Agrupa observaciones en clusters, que se definen por alguna medida de similitud, por ejemplo distancia euclídea. Se puede usar por ejemplo para clasificar clientes en grupos discretos. Esas clases luego se pueden usar en un modelo de AA supervisado.

Deep learning

Intenta emular el cerebro humano, aprendiendo de una manera similar. Se crea una red neuronal artificial mediante el uso de funciones matemáticas.

Las redes neuronales se componen de varias capas de neuronas. Se ajustan los datos de entrenamiento a una función que predice la etiqueta en función de sus características. La función f(x) es la capa externa de una función anidada, en donde cada capa encapsula funciones que operan sobre x, y, y valores de peso w asociados. El modelo final tiene los valores de peso finales que dan como resultado las mejores predicciones.

Modelos conexionistas

Son las redes neuronales artificiales, el enfoque subsimbólico. Hay dos ideas fundamentales:

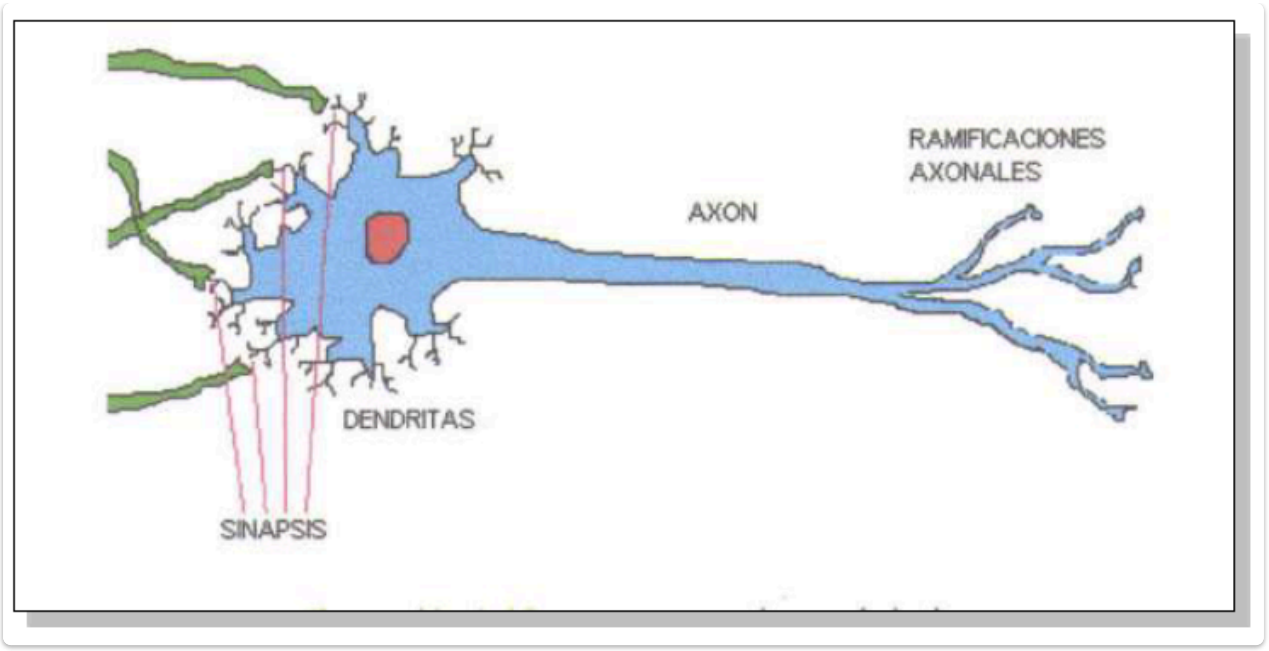
- Un concepto se representa en el cerebro como un conjunto de neuronas activas simultáneamente
- La memoria se localiza en las conexiones entre neuronas

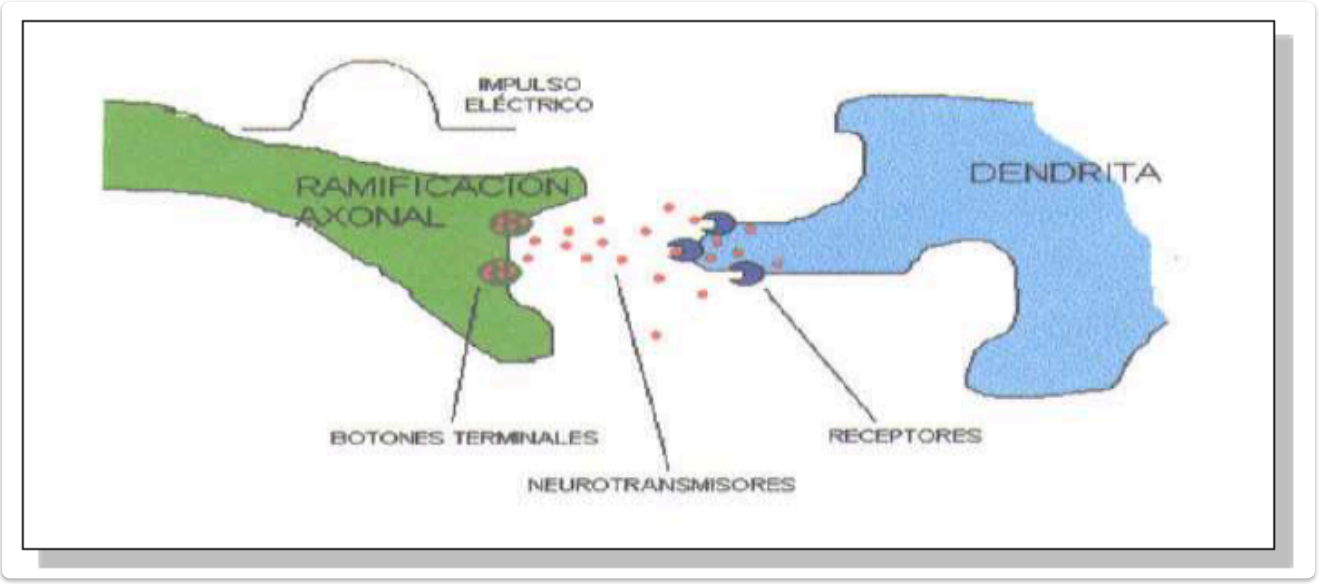
También está la regla de aprendizaje de Hebb (un psicólogo): Las conexiones entre dos neuronas se refuerzan si ambas son activadas.

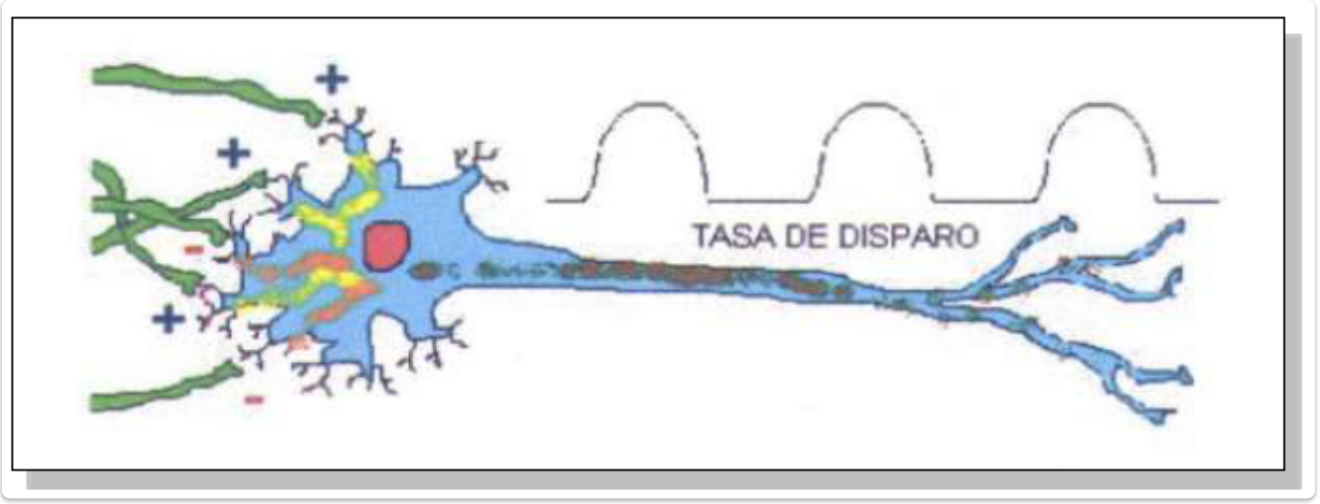
Redes neuronales biológicas

En resumen:

- La neurona recoge señales de otras neuronas a través de las dendritas.
- Emite impulsos eléctricos a lo largo del axón, que se divide en ramificaciones.
- Estas llegan a las dendritas de otras neuronas y establecen conexiones llamadas sinapsis, en donde se transforma el impulso eléctrico en un mensaje electroquímico mediante la liberación de neurotransmisores.
- Estos pueden tener un efecto excitatorio o inhibitorio.
- En función de la estimulación total, la neurona toma un cierto nivel de activación, y genera impulsos nerviosos con una frecuencia determinada.







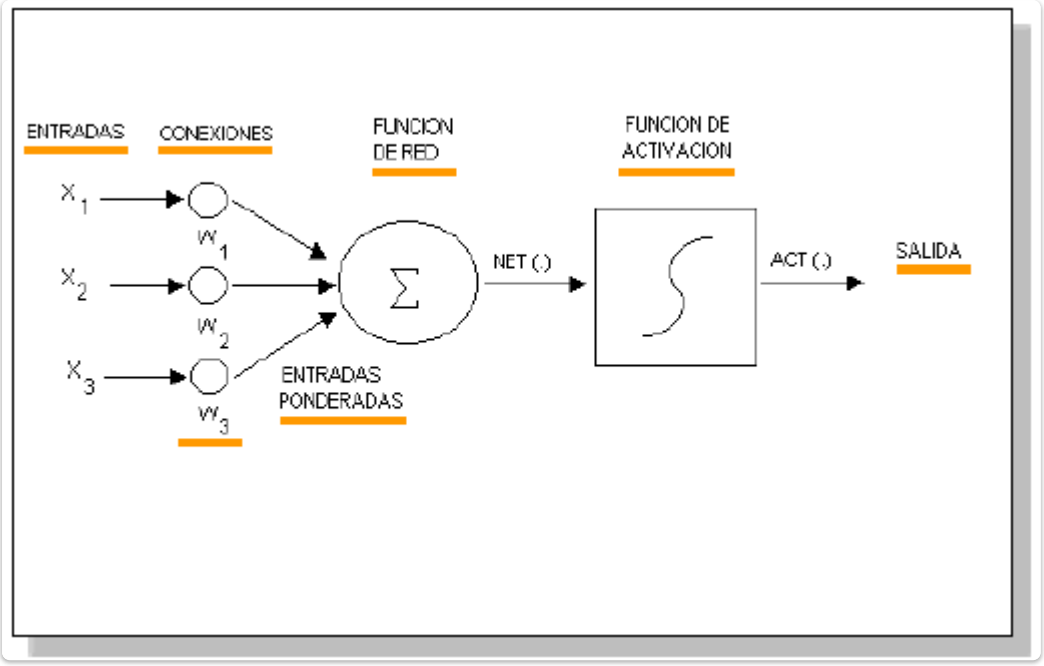
Redes neuronales artificiales

Se compone de muchos elementos simples que operan en paralelo, su función se determina por la estructura de la red y el peso de las conexiones.

Estructura

Tenemos unidades de proceso. Se componen de:

- Una función de entrada
- Una función de red, de propagación
- Un núcleo central de proceso
- La salida, donde se transmite el valor de activación a otras unidades



Peso sináptico (w): equivale a la fuerza de la sinapsis. Determina que tanto influye una unidad sobre otra. El valor de los pesos define el tipo e intensidad de la influencia.

Función de red: calcula el valor de entrada a la unidad, por ejemplo mediante una suma ponderada.

Función de activación: Calcula el nivel o estado de activación de la neurona en función de la entrada.

Salida: Calcula la salida en función de la activación.

Función de red

Existen distintos tipos:

- Función lineal de base (FLB): suma ponderada de las entradas, es una función de primer orden.

$$net_j(X, W_j) = \sum_{i=1}^{n} x_i w_{ij}$$

- Función radial de base (FRB): de segundo orden, no lineal, representa la distancia a un determinado patrón de referencia

$$net_j(X, W_j) = \sqrt{\sum_{i=1}^{n} (x_i - w_{ij})^2}$$

Función de activación

De vuelta, hay distintos tipos

- Funciones lineales: la salida es proporcional a la entrada.
- Funciones de umbral: la salida es un valor discreto (ej. 0 o 1), que depende de si la estimulación total supera cierto valor umbral.
- Funciones no lineales: No son proporcionales a la entrada
  - Sigmoidal o logística: transforma un valor real en un valor entre 0 y 1. Tiene una desventaja conocida como desvanecimiento de gradiente, para valores extremos, la derivada es casi cero y dificulta el entrenamiento
  - Función ReLU: posiblemente la más usada, rectifica los valores negativos a cero y deja pasar los positivos de manera lineal. Evita el desvanecimiento de gradiente.

Comparaciones entre red biológica y red artificial

Redes Neuronales Biológicas	Redes Neuronales Artificiales
Neuronas	Unidades de proceso
Conexiones sinápticas	Conexiones ponderadas
Efectividad de las sinapsis	Peso de las conexiones
Efecto excitatorio o inhibitorio de una conexión	Signo del peso de una conexión
Efecto combinado de las sinapsis	Función de propagación o de red
Activación → tasa de disparo	Función de activación → salida

Formas de interconexión

Lo más común es tener capas:

- Capa de entrada: Almacena la información bruta o hace un preprocesamiento pequeño.
- Capas ocultas: Son las intermedias, que se encargan de extraer, procesar y memorizar la información.
- Capa de salida: Almacena la respuesta de la red

En base a la cantidad de capas y como se interconectan se pueden clasificar:

- Redes en cascada: La información fluye en una dirección de una capa a la otra. No hay conexiones intra-capa.
- Redes recurrentes: La información puede volver a lugares por los que había pasado, admite conexiones intra-capa.

Las conexiones entre capas pueden ser totales, donde cada unidad se conecta con todas las unidades, o parciales. Podemos tener conexiones con o sin retardo.

Características

- Aprendizaje inductivo: No se indican las reglas, sino que crea sus propias
- Generalización: Se pueden presentar otros datos distintos a los del aprendizaje
- Abstracción: Es tolerante al ruido, extrae las características esenciales de las entradas
- Procesamiento paralelo: Lo cual las hace ideales para su uso en multiprocesadores
- Memoria distribuida: Como que el conocimiento está disperso en toda la red, es resistente a fallas

Ventajas y desventajas

Lo bueno:

- Adaptativas
- Se organizan automáticamente
- Tolerantes a fallas
- Pueden operar en tiempo real
- Es fácil aplicarlas gracias a la tecnología existente
- Escalables y eficientes

Lo malo:

- Hay que definir muchos parámetros
- La preparación de datos es crítica y puede ser compleja
- Se necesitan grandes cantidades de datos
- Costo computacional alto
- No son interpretables (caja negra)
- Overfitting
- Dependen del diseño del modelo
- El tiempo de entrenamiento es largo
- Sensibles a la calidad de los datos

Mecanismos de aprendizaje

Durante el proceso de aprendizaje, los pesos de las conexiones de la red sufren modificaciones. El proceso termina cuando los pesos se estabilizan.

Aprendizaje supervisado

El entrenamiento se realiza mediante un agente externo, que determina la respuesta que debería generar la red a partir de cierta entrada. Se puede hacer de tres formas:

- Por corrección de error: Se ajustan los pesos en función del error cometido en la salida.
- Por refuerzo: El supervisor indica una señal de refuerzo si la salida obtenida es la deseada. Por ejemplo +1 para el éxito, -1 para el fracaso.
- Estocástico: Se hacen cambios aleatorios en los pesos y se evalúa el efecto.

Aprendizaje no supervisado

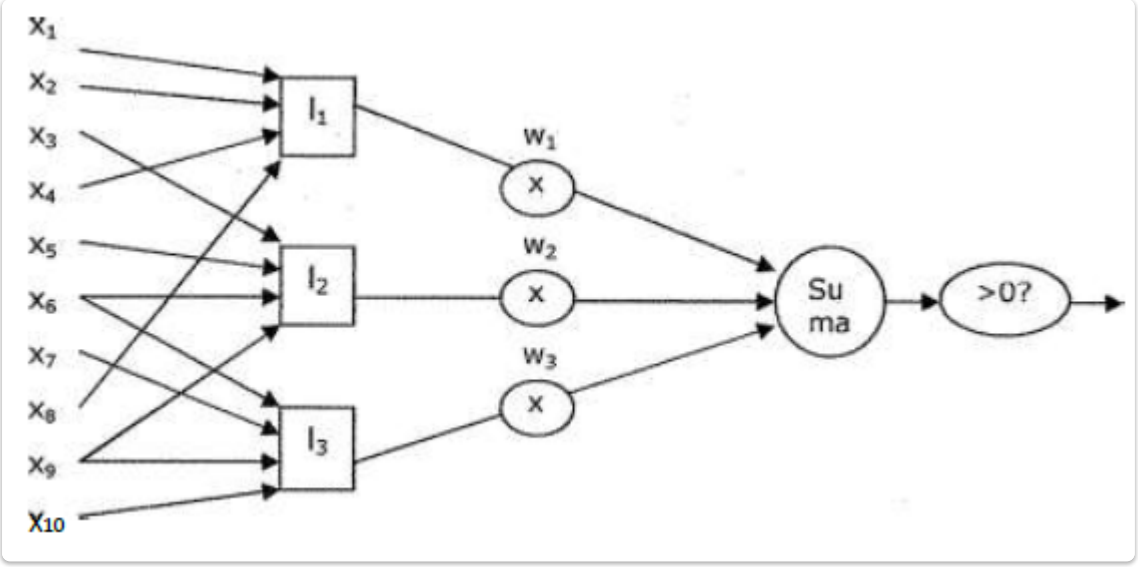
No requieren de influencia externa para ajustar los pesos. Las redes deben encontrar las características, correlaciones, categorías, etc., en los datos de entrada. En general hay dos tipos:

- Hebbiano: Un proceso de aprendizaje que tiene lugar a lo largo del tiempo modifica de alguna forma la red para incluir la nueva información.
- Competitivo: Las unidades de salida luchan por el control sobre porciones del espacio de entrada. La unidad con la mayor activación en sus entradas tendrá más fuerza que otras, esto hace que el resto se debilite lo cual se va reforzando hasta que las unidades más fuertes dejen al resto inactivas.

Perceptron

Es uno de los primeros modelos de redes neuronales (1962). Contiene pesos entrenables multiplicativos, un sumador y una función umbral. Es una red neuronal en donde:

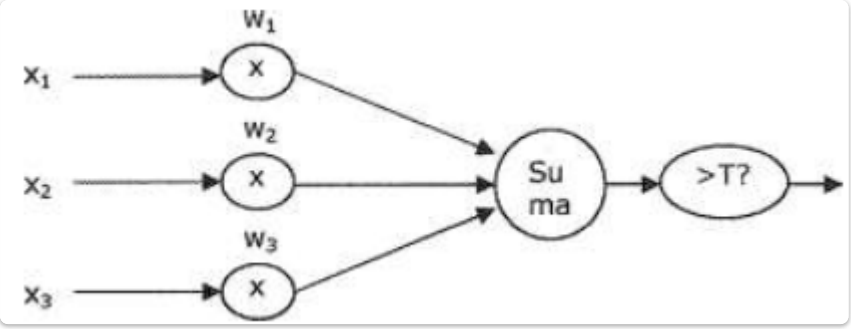
- Solo se tiene una neurona
- Las entradas son binarias (0 o 1)
- Las cajas lógicas se pueden interponer entre las entradas y los pesos
- La salida es 0 o 1 (función umbral)



Hay que notar que las cajas lógicas atienden una porción de las entradas cada una.

En un perceptron de orden n, cada caja lógica atiende n o menos entradas.

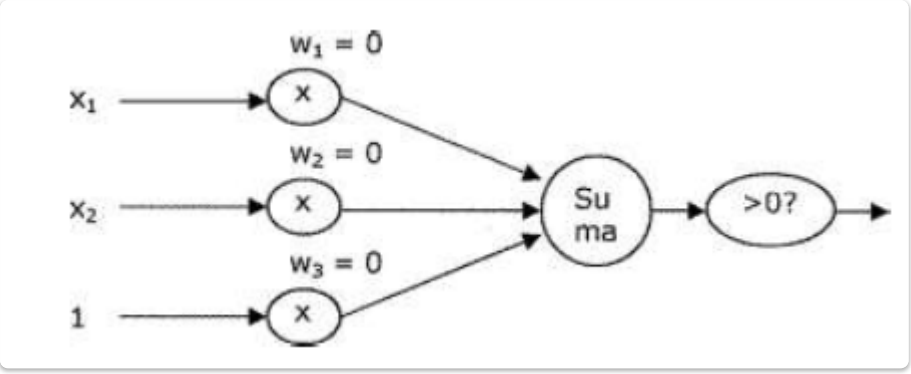
En un perceptron directo, cada caja lógica tiene una entrada, y la salida es siempre la misma que la entrada, es decir que puede verse como un perceptron sin cajas lógicas.



Aprendizaje del perceptron

- Arranca con los pesos en cero.
- Se intenta el perceptron con todas las muestras de a una. Cuando comete un error, se cambian los pesos de modo que el error se haga menos probable.
  - Si produce 0 cuando es 1, se puede aumentar la probabilidad de que produzca 1 si se incrementan los pesos asignados a las cajas que producen 1 en el momento que aparece el error
  - Y viceversa, si dice 1 cuando es 0, se disminuyen
  - No se alteran los pesos de las cajas que producen 0
- Para conseguir un efecto umbral, se agrega una entrada virtual extra que siempre vale 1.

Ejemplo: Se quiere aprender el OR lógico:

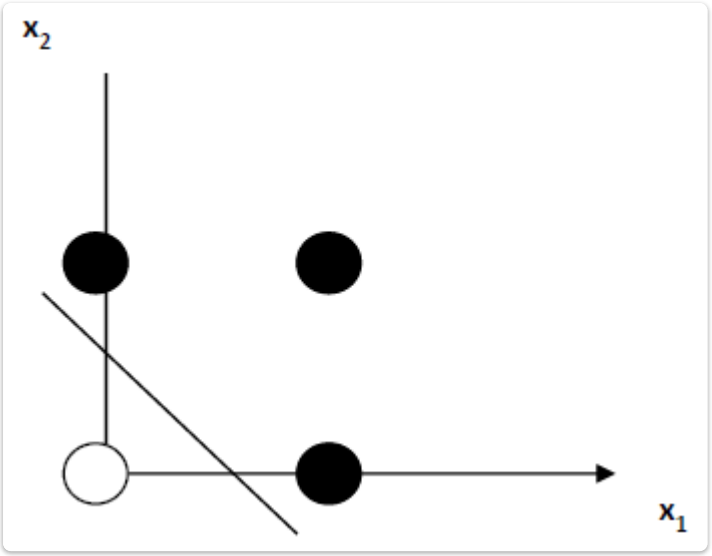


Muestra	$x_1 = (I_1)$	$X_2 = (I_2)$	$X_3 = (I_3)=1$	Salida deseada
1	0	0	1	0
2	0	1	1	1
3	1	0	1	1
4	1	1	1	1

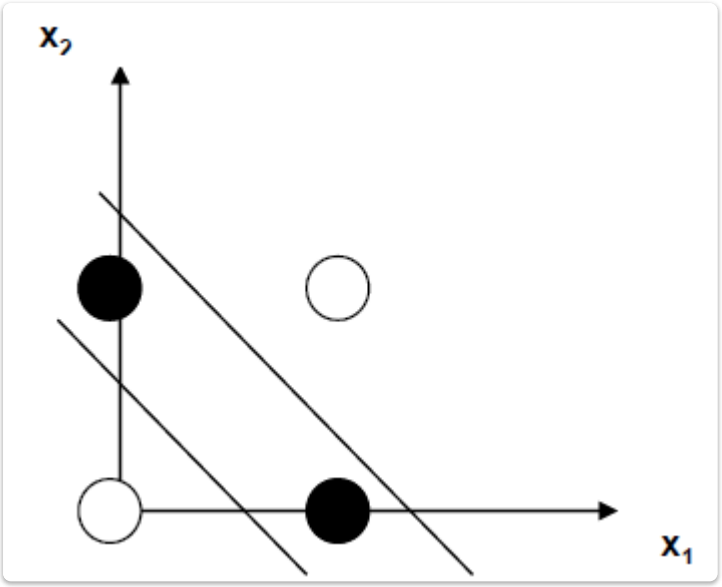
A medida que ocurren errores, el vector peso se ajusta, hasta llegar a la salida deseada.

Problemas del perceptron

El teorema de convergencia del perceptron garantiza que encontrara un estado solución, con tal de que las entradas sean linealmente separables, cosa que no suele ocurrir en la mayoría de los problemas.



Esta figura representa un espacio de entradas que como se ve se puede separar con una sola línea. El perceptron puede encontrar la solución.



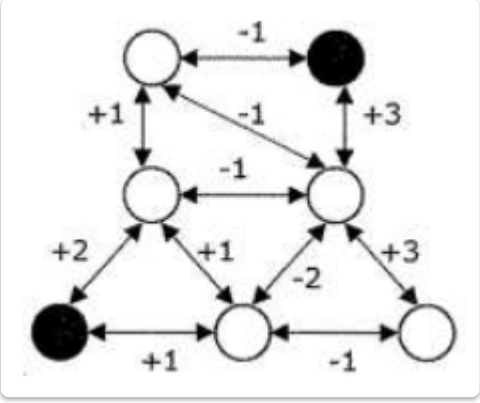
El perceptron no es capaz de resolver este problema. Esto es un XOR. No existe una única recta que pueda separar las salidas 1 de las salidas 0.

Redes de Hopfield

Se introduce la memoria como concepto. Las redes de Hopfield tienen estas características:

- Representan la memoria como un patrón de activación a través de un conjunto de elementos de proceso
- Cada elemento de proceso decide en base a su situación local
- Se pueden almacenar un número de patrones, para recuperar un patrón se necesita una parte específica de el
- Es tolerante a fallos

Lo siguiente es una red de Hopfield



Las unidades de proceso pueden estar activas (negro) o inactivas (blanco). Se conectan por conexiones simétricas que tienen un peso determinado. Un peso positivo indica que ambas unidades tienden a activarse la una a la otra. Un peso negativo permite que una unidad desactive a la otra.

Funcionamiento:

- Se elige una unidad random. Si una vecina está activada, la unidad calcula la suma de los pesos en las conexiones de esas unidades. Si la suma es positiva, se activa, de lo contrario se desactiva.
- Se elige otra unidad random, y se repite el proceso hasta que se obtenga un estado estable, conocido como relajación paralela.

El algoritmo de relajación paralela en algún momento llevará a la red a un estado estable, no puede existir divergencia u oscilación.

Esta red se puede usar como una memoria direccionable haciendo que las actividades de las unidades se correspondan con un patrón parcial. La red se asentará en un estado que mejor corresponda con el patrón parcial.

Máquinas de Boltzmann

Es una variante de la red de Hopfield. El principal problema de ellas es que convergen hacia mínimos locales.

Se introduce la técnica de enfriamiento simulado, que sirve para encontrar soluciones globalmente óptimas en problemas combinatorios.

Las unidades de las máquinas de Boltzmann actualizan sus estados binarios con una regla estocástica en vez de determinística. Esto permite introducir un factor de temperatura. Con temperaturas altas, el comportamiento es aleatorio, con temperaturas bajas se va volviendo

determinístico. El enfriamiento es el proceso de ir de temps. altas a bajas. **Esta aleatoriedad permite escapar de mínimos locales**.