


Patrones de datos en las series de tiempo y Medición del error de pronóstico


Patrones de datos en las series de tiempo



Patrones de datos en las series de tiempo

Los datos de **corte transversal** son observaciones recopiladas en un solo punto del tiempo.

Una **serie de tiempo** consiste en datos que se recopilan, registran u observan durante incrementos sucesivos de tiempo.




Patrones de datos en las series de tiempo


Uno de los pasos más importantes en la selección de un método para pronosticar adecuado con datos de una serie de tiempo es considerar los diferentes tipos de patrones de datos.

- **Horizontal.** Cuando los datos recopilados en el transcurso del tiempo fluctúan alrededor de un nivel o una media constantes. **Estacionario** en su media.
- **Tendencia.** Cuando los datos crecen o descienden en varios periodos.
- **Cíclico.** Cuando las observaciones indican aumentos y caídas que no tienen un periodo fijo. Es la fluctuación con forma de onda alrededor de la tendencia.
- **Estacional.** Cuando las observaciones se ven influidas por factores temporales. Se refiere a un patrón de cambio que se repite año tras año

Patrones de datos en las series de tiempo



TENDENCIA



ESTACIONALIDAD



AZAR

Patrones de datos en las series de tiempo

Método	Patrón de datos	Horizonte de tiempo	Tipo del modelo	Datos mínimos requeridos	
				No estacionales	Estacionales
Simple	ST, T, S	S	TS	1	
Promedios simples	ST	S	TS	30	
Promedios móviles	ST	S	TS	4-20	
Suavizamiento exponencial	ST	S	TS	2	
Suavizamiento exponencial lineal	T	S	TS	3	
Suavizamiento exponencial cuadrático	T	S	TS	4	
Suavizamiento exponencial estacional	S	S	TS		$2 \times s$
Filtración adaptativa	S	S	TS		
Regresión simple	T	I	C	10	
Regresión múltiple	C, S	I	C	$10 \times V$	
Descomposición clásica	S	S	TS		$5 \times s$
Modelos de tendencia exponencial	T	I, L	TS	10	
Ajuste de la curva S	T	I, L	TS	10	
Modelos de Gompertz	T	I, L	TS	10	
Curvas de crecimiento	T	I, L	TS	10	
Census X-12	S	S	TS		$6 \times s$
Box-Jenkins	ST, T, C, S	S	TS	24	$3 \times s$
Indicadores principales	C	S	C	24	
Modelos econométricos	C	S	C	30	
Regresión múltiple de series de tiempo	T, S	I, L	C		$6 \times s$

Patrón de datos:

- ST estacionario
- T tendencia
- S estacional
- C cíclico

Horizonte de tiempo:

- S corto plazo
- I mediano plazo
- L largo

Tipo de modelo:

- TS serie de tiempo
- C causal

Estacional


- S lon. estacionalidad

Variable:

- V número de variables

Patrones de datos en las series de tiempo


El gráfico muestra el crecimiento (tendencia) a largo plazo de una serie de tiempo (costos de viviendas) con datos anuales. Para ilustrar el crecimiento se dibuja una recta de tendencia lineal. Si bien la variable costo de la vivienda no se ha incrementado cada año, el cambio de la variable ha sido generalmente hacia arriba entre los periodos 1 a 20.



La **tendencia** es el componente de largo plazo que representa el crecimiento o el descenso en la serie de tiempo, durante un periodo extenso.

Patrones de datos en las series de tiempo

El gráfico también muestra una serie de tiempo con un componente cíclico. El pico cíclico en el periodo 9 ilustra una **expansión económica**; y el valle cíclico en el periodo 12, una **contracción económica**.




El componente **cíclico** es la oscilación alrededor de la tendencia.

Patrones de datos en las series de tiempo

Para las series mensuales, el componente estacional mide la variabilidad de la serie cada enero, cada febrero, y así sucesivamente. Para una serie trimestral, hay cuatro elementos estacionales, uno por cada trimestre.

El gráfico indica que el consumo de electricidad de clientes residenciales de la compañía Washington Water Power es mayor en el **primer trimestre** (los meses de invierno) de cada año.



El componente **estacional** es un patrón de cambio que se repite año tras año.

Análisis de autocorrelación

Cuando se mide una variable a lo largo del tiempo, las observaciones en diferentes periodos a menudo están relacionadas o correlacionadas. Esta correlación se mide usando el coeficiente de autocorrelación.

Autocorrelación es la correlación que existe entre una variable retrasada uno o más periodos consigo misma.

$$r_k = \frac{\sum_{t=k+1}^n (Y_t - \bar{Y})(Y_{t-k} - \bar{Y})}{\sum_{t=1}^n (Y_t - \bar{Y})^2}$$

$k = 0, 1, 2, \dots$


r_k = coeficiente de autocorrelación para un retraso de k periodos

$\bar{Y}$ = media de los valores de la serie


Y_t = observación en el periodo t

Y_{t-k} = observación k periodos anteriores o durante un periodo $t - k$

Tiempo t	Mes	Datos originales Y_t	Y atrasada un periodo Y_{t-1}	Y atrasada dos periodos Y_{t-2}
1	Enero	123		
2	Febrero	130		
3	Marzo	125		
4	Abril	138		
5	Mayo	145		
6	Junio	142		
7	Julio	141		
8	Agosto	146		
9	Septiembre	147		
10	Octubree	157		
11	Noviembre	150		
12	Diciembre	160		



Análisis de autocorrelación



Tiempo t	Y_t	Y_{t-1}	$(Y_t - \bar{Y})$	$(Y_{t-1} - \bar{Y})$	$(Y - \bar{Y})^2$	$(Y_t - \bar{Y})(Y_{t-1} - \bar{Y})$
1	123	—	-19	—	361	—
2	130	123	-12	-19	144	228
3	125	130	-17	-12	289	204
4	138	125	-4	-17	16	68
5	145	138	3	-4	9	-12
6	142	145	0	3	0	0
7	141	142	-1	0	1	0
8	146	141	4	-1	16	-4
9	147	146	5	4	25	20
10	157	147	15	5	225	75
11	150	157	8	15	64	120
12	160	150	18	8	324	144
Total	1,704		0		1,474	843

$$\bar{Y} = \frac{1,704}{12} = 142$$

$$r_1 = \frac{843}{1,474} = .572$$

Parece que existe una autocorrelación moderada, para dos periodos de retraso. r_2 es .463 y es menor que r_1 (.572). Generalmente, aumenta el número de retrasos (k), disminuyen los coeficientes de autocorrelación.

$$r_2 = \frac{\sum_{t=2+1}^n (Y_t - \bar{Y})(Y_{t-2} - \bar{Y})}{\sum_{t=1}^n (Y_t - \bar{Y})^2} = \frac{682}{1,474} = .463$$

Análisis de autocorrelación

Un *correlograma* o *función de autocorrelación* es una gráfica de las autocorrelaciones para varios retrasos de una serie de tiempo.

Con esta gráfica, se pueden estudiar los patrones de los datos incluyendo la tendencia y la estacionalidad.

Los coeficientes de autocorrelación para diferentes retrasos pueden usarse para contestar las siguientes preguntas acerca de una serie de tiempo:

1. ¿Los datos son aleatorios?
2. ¿Los datos muestran una tendencia (son no estacionarios)?
3. ¿Los datos son estacionarios?
4. ¿Los datos son estacionales?


Autocorrelation Function: VCR

Lag	ACF	T	LBQ
1	0.571913	1.98	5.00
2	0.462687	1.25	8.59
3	0.110583	0.27	8.82

TAB3-1.MTW ***			
	C1	C2	C3
	VCR		
1	123		
2	130		
3	125		
4	138		
5	145		

Minitab Instructions:

Stat>Time Series>Autocorrelation



Análisis de autocorrelación

Aleatoria, las autocorrelaciones entre Y_t y Y_{t-k} para cualquier retraso de tiempo k son cercanas a cero. Los valores sucesivos de una serie de tiempo no están relacionados entre sí.

Tendencia, las observaciones sucesivas están altamente correlacionadas y es típico que los coeficientes de correlación sean significativamente diferentes de cero, para los primeros retrasos de tiempo, y de forma gradual tienden a cero cuando se incrementan los retrasos. El coeficiente de autocorrelación para un r_1 y r_2 a menudo será muy grande (cercano a 1). Sin embargo, no será tan grande como para el retraso de tiempo 1.

Estacional, se presentará un coeficiente de autocorrelación significativo en el retraso de tiempo estacional o en los múltiplos del retraso estacional. El retraso estacional se considera de 4 para datos trimestrales y 12 para datos mensuales

¿Los datos son aleatorios?

$$SE(r_k) = \sqrt{\frac{1 + 2 \sum_{i=1}^{k-1} r_i^2}{n}}$$

Una forma alternativa para verificar la autocorrelación significativa es construir. Se desarrolla una prueba de hipótesis para determinar si un coeficiente de autocorrelación específico es significativamente diferente de cero.

$SE(r_k)$ = error estándar (desviación estándar estimada)

r_i = la autocorrelación en el retraso i

k = retraso de tiempo

n = el número de observaciones en la serie de tiempo

$$H_0: \rho_1 = 0$$

$$H_1: \rho_1 \neq 0$$

$$t = \frac{r_1 - \rho_1}{SE(r_1)} = \frac{r_1 - 0}{SE(r_1)} = \frac{r_1}{SE(r_1)}$$

tiene una distribución t con $df = n - 1$. Donde, $n - 1 = 12 - 1 = 11$, entonces, para un nivel de significancia de 5%, la regla de decisión es como sigue:

Si $t < -2.2$, o bien, $t > 2.2$ rechace H_0 y concluya que la autocorrelación del retraso 1 es significativamente diferente de 0.

Los valores críticos ± 2.2 son los puntos .025 superior e inferior, de una distribución t con 11 grados de libertad. El error estándar de r_1 es $SE(r_1) = \sqrt{1/12} = \sqrt{.083} = .289$, y el valor del estadístico de prueba se convierte en

$$t = \frac{r_1}{SE(r_1)} = \frac{.572}{.289} = 1.98$$

No puede rechazarse H_0 ya que
 $-2.2 < 1.98 < 2.2$


$$\text{retraso 1: } 0 \pm t_{.025} \times SE(r_1) \quad \text{o bien} \quad 0 \pm 2.2(.289) \rightarrow (-.636, .636)$$

$$\text{retraso 2: } 0 \pm t_{.025} \times SE(r_2) \quad \text{o bien} \quad 0 \pm 2.2(.371) \rightarrow (-.816, .816)$$

¿Los datos son aleatorios?

TABLA 3-3 Serie de tiempo de 40 números aleatorios para el ejemplo 3.3

t	Y_t	t	Y_t	t	Y_t	t	Y_t
1	343	11	946	21	704	31	555
2	574	12	142	22	291	32	476
3	879	13	477	23	43	33	612
4	728	14	452	24	118	34	574
5	37	15	727	25	682	35	518
6	227	16	147	26	577	36	296
7	613	17	199	27	834	37	970
8	157	18	744	28	981	38	204
9	571	19	627	29	263	39	616
10	72	20	122	30	424	40	97




Cada muestra producirá autocorrelaciones diferentes. La mayoría de estas muestras producirán coeficientes de autocorrelación muestrales que estén cercanos a cero. No obstante, es posible que una muestra produzca un coeficiente de autocorrelación que sea significativamente diferente de cero, tan sólo por casualidad.

¿Los datos son aleatorios?

Función de autocorrelación: Yt

Retraso	ACF	T	LBQ
1	-0.191171	-1.21	1.57
2	-0.006293	-0.04	1.58
3	-0.145224	-0.89	2.53
4	0.104475	0.63	3.04
5	-0.253756	-1.50	6.13
6	0.028640	0.16	6.17
7	0.169071	0.95	7.63
8	-0.027390	-0.15	7.67
9	-0.032551	-0.18	7.73
10	0.021546	0.12	7.75



¿Los datos muestran una tendencia?

Si una serie muestra una **tendencia**, hay una relación significativa entre los valores sucesivos de la serie de tiempo. Los coeficientes de autocorrelación son usualmente grandes para varios de los primeros retrasos de tiempo y luego, conforme se incrementa el número de retrasos, caen gradualmente hacia cero.



Los coeficientes de autocorrelación de una **serie estacionaria** decrecen hacia cero bastante rápidamente, por lo común después del segundo o tercer retraso de tiempo. Por otro lado, las autocorrelaciones muestrales de **serie no estacionaria** se permanecen muy grandes durante varios periodos.

Con frecuencia se utiliza un método llamado **diferencias** para eliminar la tendencia de una serie no estacionaria.

¿Los datos muestran una tendencia?

TABLA 3-4 Ingresos operativos anuales de Sears, 1955 a 2004, para el ejemplo 3.4

Año	Y_t	Año	Y_t	Año	Y_t	Año	Y_t	Año	Y_t
1955	3,307	1967	7,296	1979	17,514	1991	57,242	2003	23,253
1956	3,556	1968	8,178	1980	25,195	1992	52,345	2004	19,701
1957	3,601	1969	8,844	1981	27,357	1993	50,838		
1958	3,721	1970	9,251	1982	30,020	1994	54,559		
1959	4,036	1971	10,006	1983	35,883	1995	34,925		
1960	4,134	1972	10,991	1984	38,828	1996	38,236		
1961	4,268	1973	12,306	1985	40,715	1997	41,296		
1962	4,578	1974	13,101	1986	44,282	1998	41,322		
1963	5,093	1975	13,639	1987	48,440	1999	41,071		
1964	5,716	1976	14,950	1988	50,251	2000	40,937		
1965	6,357	1977	17,224	1989	53,794	2001	36,151		
1966	6,769	1978	17,946	1990	55,972	2002	30,762		





Función de autocorrelación: Ingresos

Retraso	ACF	T	LBQ
1	0.961601	6.80	49.06
2	0.919842	3.85	94.90
3	0.872940	2.90	137.05
4	0.812378	2.33	174.35
5	0.750592	1.95	206.90
6	0.689363	1.67	234.98
7	0.623393	1.43	258.48
8	0.549571	1.21	277.18
9	0.468019	1.00	291.07
10	0.382058	0.80	300.56


¿Los datos muestran una tendencia?

Con frecuencia se utiliza un método llamado **diferencias** para eliminar la tendencia de una serie no estacionaria.




Yt	Yt-1	Differences
123		
130	123	7
125	130	-5
138	125	13
145	138	7
142	145	-3
141	142	-1
146	141	5
147	146	1
157	147	10
150	157	-7
160	150	10

¿Los datos muestran una tendencia?



Función de autocorrelación: Ingreso diferenciado

Retraso	ACF	T	LBQ
1	0.093467	0.65	0.45
2	0.148351	1.03	1.62
3	0.316708	2.15	7.07
4	0.049511	0.31	7.21
5	-0.025610	-0.16	7.25
6	0.089635	0.56	7.71
7	0.159533	0.99	9.23
8	0.144327	0.87	10.50
9	0.076160	0.45	10.86
10	0.044129	0.26	10.99



¿Los datos son estacionales?

Si una serie es **estacional**, un patrón relacionado con el calendario se repite a sí mismo durante un intervalo de tiempo específico (generalmente un año). Las observaciones de la misma posición, en diferentes periodos estacionales, tienden a estar relacionadas.


Si se analizan datos trimestrales que tienen un patrón estacional, los primeros trimestres tienden a parecerse, los segundos trimestres tienden a parecerse, y así sucesivamente, y habrá un coeficiente de autocorrelación significativo en el retraso de tiempo 4.

TABLA 3-5 Ventas trimestrales de Coastal Marine, 1994-2006, para el ejemplo 3-5

<i>Año fiscal</i>	<i>Diciembre 31</i>	<i>Marzo 31</i>	<i>Junio 30</i>	<i>Septiembre 30</i>
1994	147.6	251.8	273.1	249.1
1995	139.3	221.2	260.2	259.5
1996	140.5	245.5	298.8	287.0
1997	168.8	322.6	393.5	404.3
1998	259.7	401.1	464.6	479.7
1999	264.4	402.6	411.3	385.9
2000	232.7	309.2	310.7	293.0
2001	205.1	234.4	285.4	258.7
2002	193.2	263.7	292.5	315.2
2003	178.3	274.5	295.4	286.4
2004	190.8	263.5	318.8	305.5
2005	242.6	318.8	329.6	338.2
2006	232.1	285.6	291.0	281.4


¿Los datos son estacionales?

Ventas trimestrales de Coastal Marine: 1994 a 2006



Función de autocorrelación: Ventas

Retraso	ACF	T	LBQ
1	0.392861	2.83	8.50
2	0.153945	0.97	9.83
3	0.293782	1.82	14.77
4	0.743520	4.34	47.11
5	0.150655	0.67	48.47
6	-0.153008	-0.67	49.90
7	-0.046978	-0.21	50.04
8	0.346975	1.51	57.72
9	-0.182601	-0.76	59.90
10	-0.434729	-1.80	72.53
11	-0.315031	-1.23	79.33
12	0.091203	0.35	79.91
13	-0.353274	-1.34	88.90



Medición del error de pronóstico

Hay varios métodos cuya finalidad es resumir los errores generados por una técnica específica de pronósticos. La mayoría de estas medidas son el promedio de alguna función de la diferencia entre su valor real y su valor pronosticado. Estas diferencias se conocen como **residuos**.

donde

$$e_t = Y_t - \hat{Y}_t$$

e_t = error de pronóstico en el periodo t

Y_t = valor real en el periodo t

$\hat{Y}_t$ = valor del pronóstico en el periodo t

Las medidas de precisión de un pronóstico a continuación son usadas para:

- *Comparar la exactitud de dos (o más) técnicas diferentes.*
- *Medir la utilidad o confiabilidad de una técnica en particular.*
- *Ayudar en la búsqueda de una técnica óptima.*

Medición del error de pronóstico

Desviación media absoluta (MAD), mide la exactitud del pronóstico, promediando las magnitudes de los errores del pronóstico.

$$MAD = \frac{1}{n} \sum_{t=1}^n |Y_t - \hat{Y}_t|$$

Error cuadrático medio (MSE), este enfoque sanciona errores grandes en la elaboración de pronósticos, los elevados al cuadrado.

$$MSE = \frac{1}{n} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2$$

Raíz cuadrada del MSE (RMSE) tienen las mismas unidades de la serie, de modo que su magnitud se interpreta con mayor facilidad

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2}$$

Error porcentual medio (MAPE) se expresa como un %, sirve para comparar la exactitud de la misma técnica o de otras técnicas en dos series completamente diferentes.

$$MAPE = \frac{1}{n} \sum_{t=1}^n \frac{|Y_t - \hat{Y}_t|}{|Y_t|}$$

Error cuadrático medio (MPE) se expresa como un %.

Cercano a cero, el enfoque del pronóstico no tiene sesgo.

Negativo grande, el método está sobreestimando consistentemente.

Positivo grande, el método está subestimando consistentemente.

$$MPE = \frac{1}{n} \sum_{t=1}^n \frac{(Y_t - \hat{Y}_t)}{Y_t}$$

Medición del error de pronóstico

Ejemplo. Cantidad diaria de clientes que solicitan reparaciones y el pronóstico de tales datos

<i>Tiempo t</i>	<i>Clientes Y_t</i>	<i>Pronóstico</i> $\hat{Y}_t$	<i>Error e_t</i>	$ e_t $	e_t^2	$ e_t /Y_t$	e_t/Y_t
1	58	—	—	—	—	—	—
2	54	58	-4	4	16	.074	-.074
3	60	54	6	6	36	.100	.100
4	55	60	-5	5	25	.091	-.091
5	62	55	7	7	49	.113	.113
6	62	62	0	0	0	.000	.000
7	65	62	3	3	9	.046	.046
8	63	65	-2	2	4	.032	-.032
9	70	63	7	7	49	.100	.100
Totales			12	34	188	.556	.162

$$MAD = \frac{1}{n} \sum_{t=1}^n |Y_t - \hat{Y}_t| = \frac{34}{8} = 4.3$$

$$MSE = \frac{1}{n} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2 = \frac{188}{8} = 23.5$$

$$RMSE = \sqrt{MSE} = \sqrt{23.5} = 4.8$$

$$MAPE = \frac{1}{n} \sum_{t=1}^n \frac{|Y_t - \hat{Y}_t|}{Y_t} = \frac{.556}{8} = .0695 \text{ (6.95\%)}$$

$$MPE = \frac{1}{n} \sum_{t=1}^n \frac{(Y_t - \hat{Y}_t)}{Y_t} = \frac{.162}{8} = .0203 \text{ (2.03\%)}$$