

EXPLORACIÓN DE PATRONES DE DATOS E INTRODUCCIÓN A LAS TÉCNICAS DE PRONÓSTICOS

Una de las partes más difícil y que más tiempo consume en la elaboración de pronósticos es la recopilación de datos válidos y confiables. El personal de procesamiento de datos usa comúnmente la expresión “basura entra, basura sale”. Esta expresión también se aplica a la elaboración de pronósticos. Un pronóstico no puede ser tan preciso como los datos en que se basa. El modelo de pronóstico más elaborado fallará si se aplica a datos poco confiables.

El poder y la capacidad de las computadoras modernas han traído consigo la acumulación de una cantidad increíble de datos en casi todas las disciplinas. La difícil tarea a la que se enfrenta la mayoría de los pronosticadores es cómo obtener los datos adecuados que les ayuden a resolver sus problemas propios de toma de decisiones.

Para determinar qué datos serán útiles, se aplican cuatro criterios:

1. Los datos deben ser fidedignos y precisos. Se debe tener mucho cuidado en que los datos se obtengan de una fuente confiable, poniendo especial atención en la exactitud.
2. Los datos deberían ser relevantes. Los datos tienen que ser representativos de las circunstancias para las cuales se están usando.
3. Los datos tienen que ser consistentes. Cuando cambian las definiciones relacionadas con la recopilación de datos, se tienen que hacer los ajustes necesarios para conservar la consistencia en los patrones históricos. Esto quizá sea un problema, por ejemplo, cuando las dependencias gubernamentales cambian la miscelánea o la “canasta básica”, que se emplea al determinar el índice del costo de la vida. Hace varios años, las computadoras personales no formaban parte de la combinación de productos que compraban los consumidores; ahora sí lo son.
4. Los datos deberían ser oportunos. Los datos recopilados, resumidos y publicados oportunamente tendrán el mayor valor para el pronosticador. Puede haber muy pocos datos (una historia insuficiente sobre la cual apoyar resultados futuros) o demasiados datos (datos de periodos históricos irrelevantes lejanos en el pasado).

Generalmente, son dos los tipos de datos de interés para el pronosticador. El primer tipo son los datos recopilados en un periodo único, ya sea una hora, un día, una semana, un mes, o un trimestre. El segundo tipo son las observaciones de datos realizadas a través del tiempo. Cuando todas las observaciones se hacen durante el mismo periodo, las llamamos datos de corte *transversal*. El propósito es examinar esos datos y luego extrapolar o extender las relaciones identificadas a una población en general. Por ejemplo, la extracción de una muestra aleatoria de archivos del personal, para conocer la situación de los empleados de una compañía. La recopilación de datos sobre la antigüedad y el costo del mantenimiento de nueve autobuses de Spokane Transit Authority es otro. Un diagrama de dispersión, como el de la figura 3-1, nos ayuda a visualizar las relaciones y sugiere que la antigüedad podría ayudar en la elaboración del pronóstico del presupuesto anual de mantenimiento.




FIGURA 3-1 Diagrama de dispersión de la antigüedad y el costo de mantenimiento para nueve autobuses de Spokane Transit Authority

Los datos *de corte transversal* son observaciones recopiladas en un solo punto del tiempo.

Cualquier variable integrada con datos recopilados, registrados u observados durante incrementos de tiempo sucesivos se llama *serie de tiempo*. La producción mensual de cerveza en Estados Unidos es un ejemplo de una serie de tiempo.

Una *serie de tiempo* consiste en datos que se recopilan, registran u observan durante incrementos sucesivos de tiempo.

ESTUDIO DE PATRONES DE DATOS EN LAS SERIES DE TIEMPO

Uno de los pasos más importantes en la selección de un método para pronosticar adecuado con datos de una serie de tiempo es considerar los diferentes tipos de patrones de datos. Existen cuatro tipos generales: horizontal, tendencias, estacionales y cíclicos.

Cuando los datos recopilados en el transcurso del tiempo fluctúan alrededor de un nivel o una media constantes, hay un patrón *horizontal*. Se dice que este tipo de series es *estacionario* en su media. Se considera que las ventas mensuales de un producto alimenticio que no se incrementan, ni disminuyen, consistentemente durante un largo periodo tienen un patrón horizontal.

Cuando los datos crecen o descienden en varios periodos, existe un patrón *de tendencia*. La figura 3-2 muestra el crecimiento (tendencia) a largo plazo de una serie de tiempo (costos de viviendas) con datos anuales. Para ilustrar el crecimiento se dibuja una recta de tendencia lineal. Si bien la variable costo de la vivienda no se ha incrementado cada año, el cambio de la variable ha sido generalmente hacia arriba entre los periodos 1 a 20. Algunos ejemplos de las fuerzas básicas que afectan y ayudan a explicar la tendencia de una serie son el crecimiento de la población, la inflación de los precios, el avance tecnológico, las preferencias del consumidor y los incrementos en la productividad.




FIGURA 3-2 Tendencia y componentes cíclicos de una serie de tiempo anual, como el costo de la vivienda

Muchas variables macroeconómicas, como el producto interno bruto (PIB), el empleo y la producción industrial de un país presentan un comportamiento con tendencia. La figura 3-10 (véase p. 74) contiene otro ejemplo de una serie de tiempo con una tendencia preponderante. Esta figura muestra el crecimiento de ingresos operativos para Sears, de 1995 a 2004.

La *tendencia* es el componente de largo plazo que representa el crecimiento o el descenso en la serie de tiempo, durante un periodo extenso.

Cuando las observaciones indican aumentos y caídas que no tienen un periodo fijo, existe un patrón cíclico. El *componente cíclico* es la fluctuación con forma de onda alrededor de la tendencia y, por lo común, se ve afectada por las condiciones económicas generales. Un componente cíclico, si existe, típicamente presenta un ciclo durante varios años. Las fluctuaciones cíclicas a menudo están influidas por cambios en las expansiones y contracciones económicas, mejor conocidas como el ciclo de negocios. La figura 3-2 también muestra una serie de tiempo con un componente cíclico. El pico cíclico en el periodo 9 ilustra una expansión económica; y el valle cíclico en el periodo 12, una contracción económica.

El *componente cíclico* es la oscilación alrededor de la tendencia.

Cuando las observaciones se ven influidas por factores temporales, existe un patrón estacional. El *componente estacional* se refiere a un patrón de cambio que se repite año tras año. Para las series mensuales, el componente estacional mide la variabilidad de la serie cada enero, cada febrero, y así sucesivamente. Para una serie trimestral, hay cuatro elementos estacionales, uno por cada trimestre. La figura 3-3 indica que el consumo de electricidad de clientes residenciales de la compañía Washington Water Power es mayor en el primer trimestre (los




FIGURA 3-3 Consumo eléctrico para la compañía Washington Water Power, 1980-1991

meses de invierno) de cada año. La figura 3-14 (véase p. 77) indica que las ventas trimestrales de Coastal Marine son usualmente bajas en el primer trimestre de cada año. La variación estacional puede representar condiciones climáticas, horarios de escuela, días feriados o duración de los meses calendario.

El componente estacional es un patrón de cambio que se repite año tras año.

EXPLORACIÓN DE PATRONES DE DATOS CON ANÁLISIS DE AUTOCORRELACIÓN

Cuando se mide una variable a lo largo del tiempo, las observaciones en diferentes periodos a menudo están relacionadas o correlacionadas. Esta correlación se mide usando el coeficiente de autocorrelación.

Autocorrelación es la correlación que existe entre una variable retrasada uno o más periodos consigo misma.

Los patrones de datos que incluyen componentes como tendencia y estacionalidad pueden estudiarse usando autocorrelaciones. Los patrones se identifican examinando los coeficientes de autocorrelación de una variable en diferentes retrasos de tiempo.

El concepto de autocorrelación se ilustra con los datos presentados en la tabla 3-1. Observe que los valores de las variables Y_{t-1} y Y_{t-2} son valores reales de Y , que se han retrasado uno y dos periodos, respectivamente. Los valores para marzo, los cuales se muestran en el renglón para el periodo 3, son ventas de marzo, $Y_t = 125$; ventas de febrero, $Y_{t-1} = 130$; y ventas de enero, $Y_{t-2} = 123$.

TABLA 3-1 Datos de la VCR para el ejemplo 3.1

Tiempo t	Mes	Datos originales Y_t	Y atrasada un periodo Y_{t-1}	Y atrasada dos periodos Y_{t-2}
1	Enero	123		
2	Febrero	130	123	
3	Marzo	125	130	123
4	Abril	138	125	130
5	Mayo	145	138	125
6	Junio	142	145	138
7	Julio	141	142	145
8	Agosto	146	141	142
9	Septiembre	147	146	141
10	Octubree	157	147	146
11	Noviembre	150	157	147
12	Diciembre	160	150	157

La ecuación 3.1 es la fórmula para calcular k el coeficiente de autocorrelación (r_k) entre las observaciones Y_t y Y_{t-k} , que se encuentran a k periodos de distancia.

$$r_k = \frac{\sum_{t=k+1}^n (Y_t - \bar{Y})(Y_{t-k} - \bar{Y})}{\sum_{t=1}^n (Y_t - \bar{Y})^2} \quad k = 0, 1, 2, \dots \quad (3.1)$$

donde

r_k = coeficiente de autocorrelación para un retraso de k periodos

$\bar{Y}$ = media de los valores de la serie

Y_t = observación en el periodo t

Y_{t-k} = observación k periodos anteriores o durante un periodo $t - k$

Ejemplo 3.1

Harry Vernon, ha recopilado datos del número de VCR vendidos el año pasado por Vernon's Music Store. Los datos se presentan en la tabla 3-1. La tabla 3-2 muestra las operaciones que llevan al cálculo del coeficiente de autocorrelación para un retraso de 1. La figura 3-4 contiene un diagrama de dispersión de los pares de observaciones (Y_t , Y_{t-1}). Al revisar el diagrama de dispersión, queda claro que la correlación de retraso 1 será positiva.

El coeficiente de autocorrelación de retraso 1 (r_1), es decir, la autocorrelación entre Y_t y Y_{t-1} , se calcula usando los totales de la tabla 3.2 y la ecuación 3.1. De modo que:

$$r_1 = \frac{\sum_{t=1+1}^n (Y_{t-1} - \bar{Y})(Y_t - \bar{Y})}{\sum_{t=1}^n (Y_t - \bar{Y})^2} = \frac{843}{1,474} = .572$$

Como se sugiere en el diagrama de la figura 3-4, en esta serie de tiempo hay una autocorrelación positiva para el retraso 1. La correlación entre Y_t y Y_{t-1} o la autocorrelación para el retraso de 1 es .572. Esto significa que las ventas mensuales sucesivas de VCR están correlacionadas de algún modo unas con otras. Esta información daría a Harry perspectivas valiosas sobre su serie de tiempo, que le ayudaría a prepararse para usar un método avanzado para la elaboración del pronóstico y quizás advertirle acerca del uso de un análisis de regresión con tales datos. Todas estas ideas se analizarán en capítulos posteriores.

TABLA 3-2 Cálculo del coeficiente de autocorrelación del retraso 1, para los datos de la tabla 3-1

Tiempo t	Y_t	Y_{t-1}	$(Y_t - \bar{Y})$	$(Y_{t-1} - \bar{Y})$	$(Y_t - \bar{Y})^2$	$(Y_t - \bar{Y})(Y_{t-1} - \bar{Y})$
1	123	—	-19	—	361	—
2	130	123	-12	-19	144	228
3	125	130	-17	-12	289	204
4	138	125	-4	-17	16	68
5	145	138	3	-4	9	-12
6	142	145	0	3	0	0
7	141	142	-1	0	1	0
8	146	141	4	-1	16	-4
9	147	146	5	4	25	20
10	157	147	15	5	225	75
11	150	157	8	15	64	120
12	160	150	18	8	324	144
Total	1,704		0		1,474	843

$$\bar{Y} = \frac{1,704}{12} = 142$$

$$r_1 = \frac{843}{1,474} = .572$$

El coeficiente de autocorrelación de segundo orden (r_2), o la correlación entre Y_t y Y_{t-2} , para los datos de Harry, también se calcula con la ecuación 3.1.

$$r_2 = \frac{\sum_{t=2+1}^n (Y_t - \bar{Y})(Y_{t-2} - \bar{Y})}{\sum_{t=1}^n (Y_t - \bar{Y})^2} = \frac{682}{1,474} = .463$$




FIGURA 3-4 Diagrama de dispersión de los datos de Vernon's Music Store para el ejemplo 3-1

Parece que existe una autocorrelación moderada en esta serie de tiempo, para dos periodos de retraso. La correlación entre Y_t y Y_{t-2} , o la autocorrelación para un retraso 2, es de .463. Observe que el coeficiente de autocorrelación para el retraso de 2 (.463) es menor que el coeficiente de autocorrelación para el retraso de 1 (.572). Generalmente, conforme aumenta el número de retrasos (k), disminuyen las magnitudes de los coeficientes de autocorrelación.

La figura 3-5 ilustra una gráfica de autocorrelaciones con retrasos de tiempo, para los datos de Harry Vernon usados en el ejemplo 3-1. La escala horizontal en la parte inferior de la gráfica presenta cada retraso de tiempo de interés: 1, 2, 3, etc. La escala vertical de la izquierda indica el posible rango del coeficiente de autocorrelación, de -1 a 1 . La línea horizontal a la mitad de la gráfica representa autocorrelaciones de cero. La línea vertical que se extiende por arriba de un retraso de tiempo 1 muestra un coeficiente de autocorrelación de .57, o $r_1 = .57$. La línea vertical que se extiende hacia arriba de un retraso de tiempo 2 muestra un coeficiente de autocorrelación .46, o $r_2 = .46$. Los estadísticos de las líneas punteadas, los estadísticos T y LBQ (Ljung-Box Q) desplegados en la ventana de sesión de Minitab se examinarán en los ejemplos 3.2 y 3.3. Los patrones en un correlograma se usan para analizar las características clave de los datos, un concepto que se estudia en la siguiente sección. El software Minitab (para instrucciones específicas, véase la sección de aplicaciones de Minitab al final del capítulo) puede usarse para calcular autocorrelaciones y desarrollar correlogramas.

Un *correlograma* o *función de autocorrelación* es una gráfica de las autocorrelaciones para varios retrasos de una serie de tiempo.




FIGURA 3-5 Correlograma o función de autocorrelación de los datos usados para el ejemplo 3.1

Con una pantalla como la de la figura 3-5, se estudian los patrones de datos incluyendo la tendencia y la estacionalidad. Los coeficientes de autocorrelación para diferentes retrasos de tiempo de una variable pueden usarse para contestar las siguientes preguntas acerca de una serie de tiempo:

1. ¿Los datos son aleatorios?
2. ¿Los datos muestran una tendencia (son no estacionarios)?
3. ¿Los datos son estacionarios?
4. ¿Los datos son estacionales?

Si una serie es aleatoria, las autocorrelaciones entre Y_t y Y_{t-k} para cualquier retraso de tiempo k son cercanas a cero. Los valores sucesivos de una serie de tiempo no están relacionados entre sí.

Si una serie muestra una tendencia, las observaciones sucesivas están altamente correlacionadas y es típico que los coeficientes de correlación sean significativamente diferentes de cero, para los primeros retrasos de tiempo, y de forma gradual tienden a cero conforme se incrementa el número de retrasos. El coeficiente de autocorrelación para un retraso de tiempo 1 a menudo será muy grande (cercano a 1). También el coeficiente de autocorrelación para el retraso de tiempo 2 será grande. Sin embargo, no será tan grande como para el retraso de tiempo 1.

Si una serie tiene un patrón estacional, se presentará un coeficiente de autocorrelación significativo en el retraso de tiempo estacional o en los múltiplos del retraso estacional. El retraso estacional se considera de 4 para datos trimestrales y 12 para datos mensuales.

¿Cómo determina un analista si un coeficiente de autocorrelación es significativamente diferente de cero para los datos de la tabla 3-1? Quenouille (1949) y otros han demostrado que los coeficientes de autocorrelación de datos aleatorios tienen una distribución muestral que puede aproximarse mediante una curva normal, con una media de cero y una desviación estándar aproximada de $1/\sqrt{n}$. Sabiendo esto, el analista compara los coeficientes de autocorrelación de la muestra, con esta distribución teórica de la muestra y determinar si, para retrasos de tiempo dados, provienen de una población cuya media sea cero.

En realidad, algunos paquetes de software usan una fórmula ligeramente diferente, como se indica en la ecuación 3.2, para calcular las desviaciones estándar (o errores estándar) de los coeficientes de autocorrelación. Esta fórmula supone que cualquier autocorrelación antes del retraso de tiempo k es diferente de cero, y que cualquier autocorrelación anterior al retraso k es cero. Para una autocorrelación en el retraso 1, se utiliza el error estándar $1/\sqrt{n}$.

$$SE(r_k) = \sqrt{\frac{1 + 2 \sum_{i=1}^{k-1} r_i^2}{n}} \quad (3.2)$$

donde

$SE(r_k)$ = error estándar (desviación estándar estimada) de la autocorrelación en retraso k

r_i = la autocorrelación en el retraso i

k = retraso de tiempo

n = el número de observaciones en la serie de tiempo

Este cálculo se demostrará en el ejemplo 3.2. Si la serie es verdaderamente aleatoria, casi todos los coeficientes de autocorrelación de la muestra deberían estar dentro de un rango especificado por cero, más o menos cierto número de errores estándar. En un nivel de confianza específico, una serie puede considerarse aleatoria, si cada uno de los coeficientes de autocorrelación calculados se encuentra dentro del intervalo alrededor de 0, definido por $0 \pm t \times SE(r_k)$, donde el multiplicador t es un punto porcentual adecuado de una distribución t .

Si bien es útil cada prueba de r_k para saber si, en lo individual, es significativamente diferente de 0, también es recomendable examinar un conjunto de r_k consecutivos, como un grupo. Podemos usar una prueba de conjunto para ver si, por ejemplo, de los primeros 10 valores de r_k son significativamente diferentes de un conjunto donde los 10 valores son cero.

Una prueba de baúl común es el estadístico modificado Q de Ljung-Box (ecuación 3.3). Esta prueba se aplica usualmente a los residuos de un modelo de pronóstico. Si las autocorrelaciones se calculan mediante un proceso aleatorio (o de ruido blanco), el estadístico Q tiene una distribución chi cuadrada con m grados de libertad (el número de retrasos de tiempo por probar). Sin embargo, para los residuos de un modelo de pronóstico, el estadístico Q tiene una distribución chi cuadrada, con m grados de libertad menos el número de parámetros estimados en el modelo. El valor del estadístico Q puede compararse con la tabla de chi cuadrada (tabla B-4), para determinar si es mayor de lo que esperaríamos que fuera, con la hipótesis nula de que todas las autocorrelaciones en el conjunto son cero. Alternativamente, el valor p generado por el estadístico de prueba Q puede ser calculado e interpretado. El estadístico Q está dado por la ecuación 3.3 y se demuestra en el ejemplo 3.3.

$$Q = n(n + 2) \sum_{k=1}^m \frac{r_k^2}{n - k} \quad (3.3)$$

donde

n = número de observaciones en la serie de tiempo

k = retraso de tiempo

m = número de retrasos de tiempo que se van a probar

r_k = la función de autocorrelación muestral de los residuos atrasados k periodos

¿Los datos son aleatorios?

Un modelo aleatorio simple, a menudo llamado *modelo de ruido blanco*, está representado por la ecuación 3.4. La observación Y_t se compone de dos partes: c , el nivel general; y ε_t , el componente de error aleatorio. Es importante advertir que se supone que el componente ε_t no está correlacionado de un periodo a otro.

$$Y_t = c + \varepsilon_t \quad (3.4)$$

¿Los datos de la tabla 3-1 son consistentes con este modelo? Este punto se explorará en los ejemplos 3.2 y 3.3.

Ejemplo 3.2

Se desarrolla una prueba de hipótesis para determinar si un coeficiente de autocorrelación específico es significativamente diferente de cero, para el correlograma de la figura 3-5. Las hipótesis nula y alternativa para la prueba de significancia del coeficiente de autocorrelación de la población del retraso 1 son:

$$H_0: \rho_1 = 0$$

$$H_1: \rho_1 \neq 0$$

Si la hipótesis nula es verdadera, el estadístico de prueba

$$t = \frac{r_1 - \rho_1}{SE(r_1)} = \frac{r_1 - 0}{SE(r_1)} = \frac{r_1}{SE(r_1)} \quad (3.5)$$

tiene una distribución t con $df = n - 1$. Donde, $n - 1 = 12 - 1 = 11$, entonces, para un nivel de significancia de 5%, la regla de decisión es como sigue:

Si $t < -2.2$, o bien, $t > 2.2$ rechace H_0 y concluya que la autocorrelación del retraso 1 es significativamente diferente de 0.

Los valores críticos ± 2.2 son los puntos .025 superior e inferior, de una distribución t con 11 grados de libertad. El error estándar de r_1 es $SE(r_1) = \sqrt{1/12} = \sqrt{.083} = .289$, y el valor del estadístico de prueba se convierte en

$$t = \frac{r_1}{SE(r_1)} = \frac{.572}{.289} = 1.98$$

Con la anterior regla de decisión, no puede rechazarse $H_0: \rho_1 = 0$ ya que $-2.2 < 1.98 < 2.2$. Observe que el valor de nuestro estadístico de prueba, $t = 1.98$, es el mismo que la cantidad del renglón de retraso 1, debajo de la T en el resultado de Minitab en la figura 3-5. Los valores T en la figura de Minitab son simplemente los valores del estadístico de prueba al realizar la prueba para la autocorrelación igual a 0 en los diferentes retrasos.

Para la prueba de autocorrelación cero en el retraso de tiempo 2, consideramos

$$\begin{aligned} H_0: \rho_2 &= 0 \\ H_1: \rho_2 &\neq 0 \end{aligned}$$

Y el estadístico de prueba

$$t = \frac{r_2 - \rho_2}{SE(r_2)} = \frac{r_2 - 0}{SE(r_2)} = \frac{r_2}{SE(r_2)}$$

Usando la ecuación 3.2,

$$SE(r_2) = \sqrt{\frac{1 + 2 \sum_{i=1}^{k-1} r_i^2}{n}} = \sqrt{\frac{1 + 2 \sum_{i=1}^{2-1} r_i^2}{n}} = \sqrt{\frac{1 + 2(.572)^2}{12}} = \sqrt{\frac{1.6544}{12}} = \sqrt{.138} = .371$$

y

$$t = \frac{.463}{.371} = 1.25$$

Este resultado coincide con el valor T para el retraso 2 en el resultado de Minitab de la figura 3-5.

Usando la anterior regla de decisión, $H_0: \rho_1 = 0$ no puede rechazarse con un nivel de 0.05, ya que $-2.2 < 1.25 < 2.2$. Una forma alternativa para verificar la autocorrelación significativa es construir, digamos, límites de confianza de 95% centrados en cero. Estos límites para los retrasos de tiempo 1 y 2 son como sigue:

$$\begin{aligned} \text{retraso 1: } 0 \pm t_{.025} \times SE(r_1) & \quad o \text{ bien} \quad 0 \pm 2.2(.289) \rightarrow (-.636, .636) \\ \text{retraso 2: } 0 \pm t_{.025} \times SE(r_2) & \quad o \text{ bien} \quad 0 \pm 2.2(.371) \rightarrow (-.816, .816) \end{aligned}$$

Está indicada una autocorrelación significativamente diferente de 0, siempre que un valor de r_k caiga fuera de los límites de confianza correspondientes. En la figura 3-5 se presentan los límites de confianza de 95%, representados con líneas punteadas, en la gráfica de la función de autocorrelación.

Ejemplo 3.3

Se usó Minitab para generar la serie de tiempo de 40 números de tres dígitos pseudoaleatorios presentados en la tabla 3-3. La figura 3-6 muestra una gráfica de la serie de tiempo con estos datos. Puesto que tales datos son aleatorios (independientes entre sí y todos de la misma población), las autocorrelaciones para todos los retrasos de tiempo, teóricamente, deberían ser iguales a cero. Por supuesto, los

TABLA 3-3 Serie de tiempo de 40 números aleatorios para el ejemplo 3.3

t	Y_t	t	Y_t	t	Y_t	t	Y_t
1	343	11	946	21	704	31	555
2	574	12	142	22	291	32	476
3	879	13	477	23	43	33	612
4	728	14	452	24	118	34	574
5	37	15	727	25	682	35	518
6	227	16	147	26	577	36	296
7	613	17	199	27	834	37	970
8	157	18	744	28	981	38	204
9	571	19	627	29	263	39	616
10	72	20	122	30	424	40	97

40 valores de la tabla 3-3 son sólo un conjunto, de 40 elementos, de un gran número de muestras posibles de tamaño 40. Cada muestra producirá autocorrelaciones diferentes. La mayoría de estas muestras producirán coeficientes de autocorrelación muestrales que estén cercanos a cero. No obstante, es posible que una muestra produzca un coeficiente de autocorrelación que sea significativamente diferente de cero, tan sólo por casualidad.

En seguida, usando Minitab, se construye la función de autocorrelación representada en la figura 3-7. Observe que las dos líneas punteadas indican los límites de confianza de 95%. Se examinan diez retrasos de tiempo y todos los coeficientes de autocorrelación individuales están dentro de estos límites. No hay razón para dudar de que cada una de las autocorrelaciones para los primeros 10 retrasos sea cero. Sin embargo, aun cuando las autocorrelaciones muestrales individuales no sean significativamente diferentes de cero, ¿las magnitudes de los primeros $10r_k$, consideradas como grupo, son mayores de lo que uno esperaría con la hipótesis de que no hay autocorrelación en ningún retraso? Esta pregunta la contesta el estadístico Q de Ljung-Box (LBQ en Minitab).

Si no hay autocorrelación en cualquiera de los retrasos, el estadístico Q tiene una distribución chi cuadrada con, en este caso, con $df = 10$. Como resultado, un valor grande para Q (un extremo de la distribución chi cuadrada) es evidencia contra la hipótesis nula. A partir la figura 3-7 vemos que el valor de Q (LBQ) para 10 retrasos de tiempo es 7.75. En la tabla B-4 observamos que el punto .05 más alto de una distribución chi cuadrada con 10 grados de libertad es 18.31. Puesto que $7.75 < 18.31$, no se puede rechazar la hipótesis nula con el nivel de significancia de 5%. Estos datos no están correlacionados en ningún retraso de tiempo, lo cual es consistente con el modelo de la ecuación 3.4.





FIGURA 3-6 Gráfica de serie de tiempo de 40 números aleatorios usados para el ejemplo 3.3

Función de autocorrelación: Yt

Retraso	ACF	T	LBQ
1	-0.191171	-1.21	1.57
2	-0.006293	-0.04	1.58
3	-0.145224	-0.89	2.53
4	0.104475	0.63	3.04
5	-0.253756	-1.50	6.13
6	0.028640	0.16	6.17
7	0.169071	0.95	7.63
8	-0.027390	-0.15	7.67
9	-0.032551	-0.18	7.73
10	0.021546	0.12	7.75

**FIGURA 3-7** Función de autocorrelación para los datos usados en el ejemplo 3.3

¿Los datos muestran una tendencia?

Si una serie muestra una tendencia, hay una relación significativa entre los valores sucesivos de la serie de tiempo. Los coeficientes de autocorrelación son usualmente grandes para varios de los primeros retrasos de tiempo y luego, conforme se incrementa el número de retrasos, caen gradualmente hacia cero.

Una serie de tiempo *estacionaria* es aquella cuyas propiedades estadísticas básicas, como la media y la varianza, permanecen constantes en el tiempo. Por lo tanto, se dice que una serie que varía alrededor de un nivel fijo (sin crecimiento ni decrecimiento) con el paso del tiempo es estacionaria. Se dice también que una serie que contiene una tendencia es *no estacionaria*. Los coeficientes de autocorrelación de una serie estacionaria decrecen hacia cero bastante rápidamente, por lo común después del segundo o tercer retraso de tiempo. Por otro lado, las autocorrelaciones muestrales de serie no estacionaria se permanecen muy grandes durante varios periodos. A menudo, para analizar la serie no estacionaria, se elimina la tendencia antes de aplicar cualquier modelo. Los procedimientos que se estudian en el capítulo 9 utilizan dicho enfoque.

Con frecuencia se utiliza un método llamado *diferencias* para eliminar la tendencia de una serie no estacionaria. Los datos de las VCR incluidos originalmente en la tabla 3-1 se presentan otra vez en la columna A de la figura 3-8. Los valores de Y_t , retrasados un periodo Y_{t-1} , se presentan en la columna B. Las diferencias de $Y_t - Y_{t-1}$ (columna A - columna B) se presentan en la columna C. Por ejemplo, el primer valor de las diferencias es $Y_2 - Y_1 = 130 - 123 = 7$. Observe el crecimiento o la tendencia de los datos de las VCR presentados en la gráfica A de la figura 3-9. Ahora observe el patrón estacionario de los datos diferenciados en la gráfica B de la figura 3-9. La diferencia de los datos elimina la tendencia.

Ejemplo 3.4

A Maggie Trymane, una analista de Sears, se le asignó la tarea de pronosticar los ingresos operativos para 2005. Ella reúne los datos de los años 1955 a 2004, que se muestran en la tabla 3-4. Los datos se grafican como una serie de tiempo en la figura 3-10. Observe que, si bien los ingresos operativos de Sears estuvieron decreciendo durante el periodo 2000 a 2004, la tendencia general durante el periodo completo 1955 a 2004 fue hacia arriba. Primero, Maggie calcula un intervalo de confianza de 95% para los coeficientes de autocorrelación para un retraso de tiempo 1, usando $0 \pm Z_{.025}(1/\sqrt{n})$ donde, para muestras grandes, la distribución normal estándar correspondiente a .025 se ha sustituido a la distribución *t* correspondiente:

$$0 \pm 1.96(\sqrt{1/50})$$

$$0 \pm .277$$

Después, Maggie corre los datos en Minitab y obtiene la función de autocorrelación que se presenta en la figura 3-11. Durante la revisión, se observa que las autocorrelaciones para los primeros cua-

Microsoft Excel - Book1

File Edit View Insert Format Tools Data Window Help

Arial 10 B I U

C3 =A3-B3

	A	B	C	D	E	F	G	H	I	J
1	Yt	Yt-1	Differences							
2	123									
3	130	123	7							
4	125	130	-5							
5	138	125	13							
6	145	138	7							
7	142	145	-3							
8	141	142	-1							
9	146	141	5							
10	147	146	1							
11	157	147	10							
12	150	157	-7							
13	160	150	10							
14										
15										
16										
17										
18										
19										
20										

FIGURA 3-8 Resultados de Excel de la diferenciación de los datos de las VCR para el ejemplo 3.1




FIGURA 3-9 Gráficas de series de tiempo de los datos de las VCR y los datos diferenciados de las VCR para el ejemplo 3.1

TABLA 3-4 Ingresos operativos anuales de Sears, 1955 a 2004, para el ejemplo 3.4

Año	Y_t	Año	Y_t	Año	Y_t	Año	Y_t	Año	Y_t
1955	3,307	1967	7,296	1979	17,514	1991	57,242	2003	23,253
1956	3,556	1968	8,178	1980	25,195	1992	52,345	2004	19,701
1957	3,601	1969	8,844	1981	27,357	1993	50,838		
1958	3,721	1970	9,251	1982	30,020	1994	54,559		
1959	4,036	1971	10,006	1983	35,883	1995	34,925		
1960	4,134	1972	10,991	1984	38,828	1996	38,236		
1961	4,268	1973	12,306	1985	40,715	1997	41,296		
1962	4,578	1974	13,101	1986	44,282	1998	41,322		
1963	5,093	1975	13,639	1987	48,440	1999	41,071		
1964	5,716	1976	14,950	1988	50,251	2000	40,937		
1965	6,357	1977	17,224	1989	53,794	2001	36,151		
1966	6,769	1978	17,946	1990	55,972	2002	30,762		

Fuente: Industry Surveys, varios años.

**FIGURA 3-10 Gráficas de series de tiempo de los ingresos operativos de Sears para el ejemplo 3.4**

tro retrasos de tiempo son significativamente diferentes de cero (.96, .92, .87 y .81) y que luego los valores tienden gradualmente hacia cero. Finalmente, Maggie mira el estadístico Q para 10 retrasos de tiempo. El LBQ es 300.56, el cual es mayor que el valor 18.3 de chi cuadrada (el punto .05 superior de una distribución chi cuadrada con 10 grados de libertad). Este resultado indica que las autocorrelaciones para los primeros 10 retrasos como grupo son significativamente diferentes de cero. Ella decide que los datos están altamente autocorrelacionados y que muestran una tendencia en su comportamiento.

Maggie sospecha que las series pueden diferenciarse para eliminar la tendencia y crear una serie estacionaria. Luego diferencia los datos (véase la sección de aplicaciones de Minitab al final del capítulo), y los resultados se presentan en la figura 3-12. Las series diferenciadas no presentan evidencia de alguna tendencia, en tanto que la función de autocorrelación de la figura 3-13 parece apoyar esta conclusión. Examinando la figura 3-13, Maggie observa que el coeficiente de autocorrelación en el retraso de tiempo 3, .32, es significativamente diferente de cero (probado al nivel de significancia .05). Las autocorrelaciones de los retrasos diferentes del retraso 3 son pequeñas, mientras que la del estadístico LBQ para un retraso 10 también es relativamente pequeña, de manera que hay una pequeña evidencia que sugiere que los datos diferenciados están autocorrelacionados. Todavía Maggie se pregunta si existe algún patrón en estos datos, que pueda modelarse con una de las técnicas más avanzadas como las que se estudian en el capítulo 9.




FIGURA 3-11 Función de autocorrelación de ingresos operativos de Sears para el ejemplo 3.4




FIGURA 3-12 Gráfica de serie de tiempo de las primeras diferencias de los ingresos operativos de Sears para el ejemplo 3.4




FIGURA 3-13 Función de autocorrelación para las primeras diferencias de los ingresos operativos de Sears para el ejemplo 3.4

TABLA 3-5 Ventas trimestrales de Coastal Marine, 1994-2006, para el ejemplo 3-5

<i>Año fiscal</i>	<i>Diciembre 31</i>	<i>Marzo 31</i>	<i>Junio 30</i>	<i>Septiembre 30</i>
1994	147.6	251.8	273.1	249.1
1995	139.3	221.2	260.2	259.5
1996	140.5	245.5	298.8	287.0
1997	168.8	322.6	393.5	404.3
1998	259.7	401.1	464.6	479.7
1999	264.4	402.6	411.3	385.9
2000	232.7	309.2	310.7	293.0
2001	205.1	234.4	285.4	258.7
2002	193.2	263.7	292.5	315.2
2003	178.3	274.5	295.4	286.4
2004	190.8	263.5	318.8	305.5
2005	242.6	318.8	329.6	338.2
2006	232.1	285.6	291.0	281.4

¿Los datos son estacionales?

Si una serie es estacional, un patrón relacionado con el calendario se repite a sí mismo durante un intervalo de tiempo específico (generalmente un año). Las observaciones de la misma posición, en diferentes periodos estacionales, tienden a estar relacionadas. Si se analizan datos trimestrales que tienen un patrón estacional, los primeros trimestres tienden a parecerse, los segundos trimestres tienden a parecerse, y así sucesivamente, y habrá un coeficiente de autocorrelación significativo en el retraso de tiempo 4. Si se analizan datos mensuales, aparecerá un coeficiente de autocorrelación significativo en el retraso de tiempo 12. Es decir, enero se correlacionará con otros eneros, febrero se correlacionará con otros febreros y así sucesivamente. En el ejemplo 3.5 se analiza una serie que es estacional.

Ejemplo 3.5

Perkin Kendell es un analista de Coastal Marine Corporation. Él siempre ha creído que las ventas son estacionales. Perkin reúne los datos presentados en la tabla 3-5 de las ventas trimestrales de Coastal Marine Corporation, de 1994 a 2006, y los grafica como una serie de tiempo como la presentada en la figura 3-14. Después, calcula un intervalo de confianza de 95% para una muestra grande con el coeficiente de autocorrelación en el retraso de tiempo 1:

$$0 \pm 1.96\sqrt{1/52}$$

$$0 \pm .272$$

Luego, Perkin calcula los coeficientes de autocorrelación presentados en la figura 3-15. Él nota que los coeficientes de autocorrelación en los retrasos de tiempo 1 y 4 son significativamente diferentes de cero ($r_1 = .39 > .272$ y $r_4 = .74 > .333$). Concluye que las ventas de Coastal Marine son estacionales, sobre una base trimestral.

SELECCIÓN DE UNA TÉCNICA DE PRONÓSTICOS

En su mayor parte, este libro está dedicado a la explicación de varias técnicas de elaboración de pronósticos y a la demostración de su utilidad. Primero se examina el valioso trabajo de seleccionar, entre varias, una técnica de elaboración de pronósticos.

Veamos algunas de las preguntas que deben considerarse, antes de decidir sobre la técnica más adecuada para la elaboración del pronóstico de un problema específico:

- ¿Por qué es necesario un pronóstico?
- ¿Quién usará el pronóstico?




FIGURA 3-14 Gráfica de serie de tiempo de las ventas trimestrales de Coastal Marine para el ejemplo 3.5

Función de autocorrelación: Ventas

Retraso	ACF	T	LBQ
1	0.392861	2.83	8.50
2	0.153945	0.97	9.83
3	0.293782	1.82	14.77
4	0.743520	4.34	47.11
5	0.150655	0.67	48.47
6	-0.153008	-0.67	49.90
7	-0.046978	-0.21	50.04
8	0.346975	1.51	57.72
9	-0.182601	-0.76	59.90
10	-0.434729	-1.80	72.53
11	-0.315031	-1.23	79.33
12	0.091203	0.35	79.91
13	-0.353274	-1.34	88.90




FIGURA 3-15 Función de autocorrelación de las ventas trimestrales de Coastal Marine para el ejemplo 3.5

- ¿Cuáles son las características de los datos disponibles?
- ¿Qué periodo se va pronosticar?
- ¿Cuáles son los requerimientos mínimos de datos?
- ¿Qué precisión se desea?
- ¿Cuánto costará el pronóstico?

Para elegir acertadamente la técnica de pronóstico, el pronosticador debe hacer lo siguiente:

- Definir la naturaleza del problema que se va a pronosticar.
- Explicar la naturaleza de los datos en investigación.
- Describir las capacidades y limitaciones de las técnicas de elaboración de pronósticos potencialmente útiles.
- Desarrollar algún criterio predeterminado, con el cual se pueda tomar la decisión.

Un factor importante que influye en la selección de la técnica de elaboración del pronóstico es la identificación y comprensión de patrones históricos en los datos. Si se pueden recono-

cer patrones de tendencia, cíclicos o estacionales, entonces se deben seleccionar las técnicas que sean capaces de extrapolar efectivamente tales patrones.

Técnicas de pronósticos para datos estacionarios

Se definió antes una serie *estacionaria* como aquella cuyo valor medio no cambia con el paso del tiempo. Tales situaciones surgen cuando los patrones de demanda que influyen en las series son relativamente estables. Es importante reconocer que los datos estacionarios no necesariamente varían de manera aleatoria alrededor de un nivel medio. Las series estacionarias pueden estar autocorrelacionadas; sin embargo, la naturaleza de la asociación es tal que los datos no se alejan de la media para cualquier periodo ampliado. En su forma más simple, el pronóstico de una serie estacionaria implica el uso de la historia disponible de la serie para estimar su valor medio, el cual se convierte así en el pronóstico de futuros periodos. Las técnicas más avanzadas implican actualizar la historia disponible de la serie para estimar su valor medio, lo que a su vez se convierte en el pronóstico de periodos futuros. Los pronósticos pueden actualizarse conforme se dispone de nueva información. La actualización es útil cuando las estimaciones iniciales no son confiables, o cuando se cuestiona la estabilidad del promedio. En este último caso, la actualización brinda algún grado de sensibilidad a los cambios potenciales en la estructura subyacente de la serie.

Las técnicas de pronósticos estacionarias se usan en las siguientes circunstancias:

- *Los factores que generan una serie se han estabilizado, y el ambiente en el cual existe la serie permanece relativamente sin cambios.* Algunos ejemplos son el número de interrupciones semanales de una línea de ensamble que tiene una tasa de producción uniforme, las unidades vendidas de un producto o servicio en la etapa de maduración de su ciclo de vida y el número de ventas resultantes de un nivel de esfuerzo constante.
- *Se necesita un modelo muy simple debido a la falta de datos para la explicación o implementación.* Un ejemplo se presenta cuando un negocio u organización es nuevo, y hay muy poca información histórica disponible.
- *La estabilidad puede obtenerse haciendo correcciones sencillas de factores tales como crecimiento demográfico o la inflación.* Algunos ejemplos son el cambio del ingreso por el ingreso per capita, y el cambio de ventas en dólares por cantidades constantes en dólares.
- *La serie puede convertirse en una serie estable.* Algunos ejemplos son la transformación de una serie mediante el uso de logaritmos, raíces cuadradas o diferencias.
- *La serie es un grupo de errores de pronóstico de una técnica de elaboración del pronóstico que se considera adecuada.* (Véase el ejemplo 3.7 de la p. 85).

Las técnicas que deben considerarse en la elaboración de pronósticos de serie estacionaria incluyen métodos informales, métodos de promedio simple, promedio móvil y modelos autorregresivos de promedio móvil (ARMA) así como los modelos de Box-Jenkins.

Técnicas de pronósticos para datos con una tendencia

En palabras sencillas, en una serie de tiempo una *tendencia* es un crecimiento o decrecimiento persistente de larga duración. Para una serie de tiempo con tendencia, el nivel de la serie no es constante. Es común que las series de tiempo de economía muestren una tendencia.

Las técnicas de pronóstico para datos con tendencia se usan en las siguientes circunstancias:

- *Un incremento en la productividad y nueva tecnología traen consigo cambios en el estilo de vida.* Algunos ejemplos son las demandas de componentes electrónicos, las cuales aumentaron con la llegada de las computadoras, y el uso del ferrocarril, el cual disminuyó con la aparición del avión.
- *Un incremento de la población causa aumentos en la demanda de bienes y servicios.* Ejemplos de esto son los ingresos por ventas de bienes de consumo, demanda de consumo de energía y uso de materias primas.
- *El poder de compra de la moneda afecta las variables económicas debido a la inflación.* Son ejemplos los salarios, los costos de producción y los precios.
- *Incremento de aceptación en el mercado.* Un ejemplo es el periodo de crecimiento en el ciclo de vida de un producto nuevo.

Las técnicas que deberían considerarse en el pronóstico de series con tendencia incluyen modelos de promedios móviles, de suavizamiento exponencial lineal de Holt, de regresión simple, de curvas de crecimiento, los modelos exponenciales y los modelos autorregresivos integrados de promedio móvil (ARIMA)(métodos de Box-Jenkins).

Técnicas de pronósticos para datos estacionales

Con anterioridad se definió una serie *estacional* como una serie de tiempo con un patrón de cambio que se repite a sí mismo año tras año. Una forma de desarrollar pronósticos estacionales es estimar índices estacionales de la historia de la serie. Por ejemplo, en datos mensuales, hay un índice para enero, un índice para febrero, y así sucesivamente. Estos índices se utilizan después para incluir la estacionalidad en los pronósticos o para eliminar tales efectos de los valores observados. El proceso que sigue se conoce como un ajuste de la estacionalidad de los datos y se analiza junto con los métodos de descomposición de la serie de tiempo en el capítulo 5.

Las técnicas para la elaboración de pronósticos con datos estacionales se usan en las siguientes circunstancias:

- *El clima influye en la variable de interés.* Ejemplos son el consumo eléctrico, las actividades de verano e invierno (por ejemplo, deportes como el esquí), el vestido y buenas temporadas en la agricultura.
- *El calendario anual influye en la variable de interés.* Son ejemplos las ventas al menudeo influidas por las vacaciones, fines de semana de tres días y calendarios académicos.

Las técnicas que deberían considerarse cuando se elaboren pronósticos con series estacionales incluyen modelos de descomposición clásica, Census *X*-12, suavizamiento exponencial de Winter, regresión múltiple y ARIMA (métodos de Box-Jenkins).

Técnicas de pronósticos para series cíclicas

El efecto cíclico se definió antes como la fluctuación con forma de onda alrededor de una tendencia. Los patrones cíclicos son difíciles de modelar porque sus patrones generalmente son inestables. Las fluctuaciones ondulatorias hacia arriba y hacia abajo de la tendencia rara vez se repiten en intervalos de tiempo fijos, en tanto que la magnitud de las variaciones también tiende a cambiar. Los métodos de descomposición (capítulo 5) pueden ampliarse para analizar los datos cíclicos. Sin embargo, debido al comportamiento irregular de los ciclos, el análisis del componente cíclico de una serie, si existe, a menudo requiere de la obtención de indicadores de coincidencia o indicadores económicos importantes.

Las técnicas para la elaboración de pronósticos con datos cíclicos se usan en las siguientes circunstancias:

- *El ciclo de negocios influye en la variable de interés.* Son ejemplos los factores económicos, de mercado y competitivos.
- *Ocurren cambios en el gusto popular.* Son ejemplos la moda, la música y la comida.
- *Sucedan cambios en la población.* Son ejemplos las guerras, las hambrunas, las epidemias y los desastres naturales.
- *Ocurren cambios en el ciclo de vida del producto.* Son ejemplos el lanzamiento, el crecimiento, la maduración, la saturación del mercado, y su declive.

Las técnicas que deberían considerarse cuando se elaboren pronósticos con series cíclicas incluyen la descomposición clásica, los indicadores de la economía, los modelos econométricos, la regresión múltiple y modelos ARIMA (métodos de Box-Jenkins).

Otros factores a considerar en la selección de una técnica de pronóstico

El horizonte de tiempo de un pronóstico tiene una relación directa con la selección de la técnica para pronosticar. En pronósticos de corto y mediano plazos, se puede aplicar una gama de técnicas cuantitativas. Sin embargo, conforme aumenta el horizonte del pronóstico, varias de estas técnicas se vuelven menos adecuadas. Por ejemplo, los modelos de promedios móviles, suavizamiento exponencial y ARIMA son pronosticadores deficientes de los cambios económicos drásticos;

mientras que los modelos econométricos resultan más útiles. Los modelos de regresión son apropiados para el corto, el mediano y el largo plazos. Las medias, los promedios móviles, la descomposición clásica y las proyecciones de la tendencia son técnicas cuantitativas adecuadas para horizontes de tiempo de corto y mediano plazos. Las técnicas más complejas de Box-Jenkins y econométricas también son recomendables para pronósticos de corto y mediano plazos. Los métodos cualitativos se usan a menudo para los horizontes de tiempo más largos (véase el capítulo 10).

La aplicabilidad de las técnicas de elaboración del pronóstico es algo que generalmente el pronosticador determina con base en la experiencia. Los gerentes frecuentemente necesitan pronósticos para un tiempo relativamente corto. Los métodos de suavizamiento exponencial, proyección de tendencia, modelos de regresión y descomposición clásica tienen una ventaja en esta situación (véase la tabla 3-6).

Los costos asociados con el uso de la computadora ya no son parte importante en la selección de una técnica. Las computadoras de escritorio (microprocesadores) y los paquetes de software para elaboración de pronósticos se han convertido en un lugar común en muchas organizaciones. Gracias a estos desarrollos, probablemente otros criterios minimizarán las consideraciones del costo informático.

A final de cuentas, el pronóstico se presentará a la gerencia para su aprobación y uso en el proceso de planeación. Por lo tanto, una fácil comprensión e interpretación de los resultados es una consideración importante. Los modelos de regresión, la proyección de tendencias, la descomposición clásica y las técnicas de suavizamiento exponencial, todas obtienen una calificación alta en dicho criterio.

Es importante señalar que la información presentada en la tabla 3-6 debería usarse como una guía para la selección de una técnica de elaboración de pronósticos. Es buena práctica

TABLA 3-6 Selección de una técnica de pronósticos

<i>Método</i>	<i>Patrón de datos</i>	<i>Horizonte de tiempo</i>	<i>Tipo del modelo</i>	<i>Datos mínimos requeridos</i>	
				<i>No estacionales</i>	<i>Estacionales</i>
Simple	ST, T, S	S	TS	1	
Promedios simples	ST	S	TS	30	
Promedios móviles	ST	S	TS	4–20	
Suavizamiento exponencial	ST	S	TS	2	
Suavizamiento exponencial lineal	T	S	TS	3	
Suavizamiento exponencial cuadrático	T	S	TS	4	
Suavizamiento exponencial estacional	S	S	TS		2 × s
Filtración adaptativa	S	S	TS		
Regresión simple	T	I	C	10	
Regresión múltiple	C, S	I	C	10 × V	
Descomposición clásica	S	S	TS		5 × s
Modelos de tendencia exponencial	T	I, L	TS	10	
Ajuste de la curva S	T	I, L	TS	10	
Modelos de Gompertz	T	I, L	TS	10	
Curvas de crecimiento	T	I, L	TS	10	
Census X-12	S	S	TS		6 × s
Box-Jenkins	ST, T, C, S	S	TS	24	3 × s
Indicadores principales	C	S	C	24	
Modelos econométricos	C	S	C	30	
Regresión múltiple de series de tiempo	T, S	I, L	C		6 × s

Patrón de datos: ST, estacionario; T, de tendencia; S, estacional; C, cíclico

Horizonte de tiempo: S, corto plazo (menos de tres meses); I, mediano plazo; L, largo plazo

Tipo de modelo: TS, serie de tiempo; C, causal

Estacional: S, longitud de la estacionalidad

Variable: V, número de variables

intentar más de un método para la elaboración del pronóstico de un problema específico, dejando fuera algunos datos recientes y luego calcular los pronósticos de estas observaciones excluidas, usando métodos diferentes. La efectividad de los métodos para estos casos de prueba excluidos puede determinarse usando una o más de las medidas de precisión definidas en las ecuaciones 3-7 a 3-11, que se estudian más adelante. Suponiendo un ajuste de los datos adecuado, el método más exacto (aquel con el menor error de pronóstico) es una selección razonable para “mejor” método. Aunque quizá no sea el mejor método en la siguiente situación.

Evaluación empírica de métodos para pronosticar

La investigación empírica ha encontrado que la exactitud en el pronóstico de los métodos sencillos a menudo es tan buena como la de las técnicas avanzadas o estadísticamente complejas (véase Fildes y otros, 1997; Makridakis y otros, 1993; y Makridakis y Hibon, 2000). Los resultados de M3-IJF Competition, donde diferentes expertos usaron su metodología favorita para pronosticar y obtuvieron cada uno pronósticos para 3,003 series de tiempo diferentes, tendieron a apoyar este hallazgo (Makridakis y Hibon, 2000). Parecería que cuanto más compleja es una técnica estadística, mejor debería predecir patrones de series de tiempo. Por desgracia, los patrones establecidos en las series de tiempo pueden cambiar en el futuro. De modo que tener el modelo que mejor represente los datos históricos (algo que los métodos complejos hacen bien) no necesariamente garantiza mayor exactitud en las predicciones del futuro. Por supuesto, la habilidad del pronosticador también desempeña un papel importante en el desarrollo de un buen pronóstico.

La M3-IJF Competition se realizó en 1997. Los pronósticos obtenidos con diferentes técnicas se compararon en toda la muestra de 3,003 series de tiempo, evaluando la exactitud con diversas medidas de error. La finalidad del estudio de 1997 fue verificar las cuatro conclusiones principales de la M-Competition original, sobre un conjunto de datos más grande (véase Makridakis y otros, 1982). Makridakis y Hibon (2000) resumieron la última competencia como sigue:

1. Al igual que en un estudio previo, los métodos avanzados o estadísticamente complejos no necesariamente dan como resultado pronósticos más precisos, que los métodos más simples.
2. Diferentes medidas de precisión producen resultados consistentes cuando se usan para evaluar diferentes métodos de elaboración de pronósticos.
3. La combinación de tres métodos de suavizamiento exponencial supera, en promedio, los métodos individuales que se combinan y funcionan bien en comparación con otros métodos.
4. La efectividad de los diferentes métodos de elaboración de pronósticos depende de la longitud del horizonte del pronóstico y la clase de datos (anuales, trimestrales, mensuales) que se analizan. Algunos métodos funcionan con más exactitud para horizontes cortos, en tanto que otros son más adecuados para los horizontes más grandes. Algunos métodos funcionan mejor con datos anuales y otros son más apropiados para datos trimestrales y mensuales.

Como parte de la selección final, cada técnica debe evaluarse en términos de su confiabilidad y aplicabilidad al problema que tenemos, de su eficiencia de costos y exactitud comparadas con técnicas similares, así como de su aceptación por parte de la gerencia. La tabla 3-6 resume las técnicas de elaboración de pronósticos adecuadas para patrones de datos específicos. Como señalamos, esta tabla representa un punto de inicio, es decir, métodos a tomar en cuenta —para datos con ciertas características. Finalmente, cualquier método seleccionado debería supervisarse continuamente para asegurarse de que hace adecuadamente el trabajo para el cual se aplica.

MEDICIÓN DEL ERROR DE PRONÓSTICO

Debido a que las técnicas cuantitativas de elaboración de pronósticos a menudo incluyen datos de series de tiempo, se desarrolló una notación matemática para referirse a cada periodo específico. La letra Y se usa para representar una variable de serie de tiempo, a menos que haya

más de una variable. El periodo asociado con una observación se identifica como un subíndice. De modo que Y_t se refiere al valor de la serie de tiempo en el periodo t . Los datos trimestrales para Coastal Marine Corporation presentados en el ejemplo 3.5 (véase la p. 76) se escribirían como $Y_1 = 147.6$, $Y_2 = 251.8$, $Y_3 = 273.1$, ..., $Y_{52} = 281.4$.

También debe desarrollarse notación matemática para distinguir entre un valor real de la serie de tiempo y el valor del pronóstico. Un símbolo $\hat{}$ (sombrero) se coloca arriba de un valor para indicar que se trata del pronóstico. El valor del pronóstico para Y_t es $\hat{Y}_t$. La exactitud de una técnica para la elaboración de un pronóstico a menudo se juzga por la comparación entre las series originales $Y_1, Y_2, \dots$, y los valores pronosticados de las series, $\hat{Y}_1, \hat{Y}_2, \dots$.

La notación básica para pronósticos se resume de la siguiente manera:

Y_t = valor de una serie de tiempo en el periodo t

$\hat{Y}_t$ = valor pronosticado de Y_t

$e_t = Y_t - \hat{Y}_t$ = residuo o error de pronóstico

Hay varios métodos cuya finalidad es resumir los errores generados por una técnica específica de pronósticos. La mayoría de estas medidas son el promedio de alguna función de la diferencia entre su valor real y su valor pronosticado. Estas diferencias se conocen como residuos.

Un *residuo* es la diferencia entre un valor real observado y su valor de pronóstico.

La ecuación 3.6 se usa para calcular el error o residuo de cada periodo pronosticado.

$$e_t = Y_t - \hat{Y}_t \quad (3.6)$$

donde

e_t = error de pronóstico en el periodo t

Y_t = valor real en el periodo t

$\hat{Y}_t$ = valor del pronóstico en el periodo t

Un método para evaluar una técnica de pronósticos usa la suma de los errores absolutos. La desviación media absoluta (*MAD*) mide la exactitud del pronóstico, promediando las magnitudes de los errores del pronóstico (los valores absolutos de los errores). *MAD* está en las mismas unidades que la serie original, y proporciona un tamaño promedio de los “errores” sin importar la dirección. La ecuación 3.7 muestra cómo se calcula la *MAD*.

$$MAD = \frac{1}{n} \sum_{t=1}^n |Y_t - \hat{Y}_t| \quad (3.7)$$

El error cuadrático medio (*MSE*) es otro método para evaluar una técnica de elaboración de pronósticos. Cada error o residuo se eleva al cuadrado; luego éstos se suman y se dividen entre el número de observaciones. Este enfoque sanciona errores grandes en la elaboración de pronósticos, ya que los errores están elevados al cuadrado, lo cual es importante porque una técnica que produce errores moderados quizá sea preferible a una que usualmente tenga pequeños errores, pero ocasionalmente produce errores extremadamente grandes. El *MSE* está dado por la ecuación 3.8.

$$MSE = \frac{1}{n} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2 \quad (3.8)$$

La raíz cuadrada del *MSE*, o la raíz cuadrada del error cuadrado medio (*RMSE*), también se usa para evaluar los métodos de elaboración de pronósticos. Tanto la *RMSE* como la *MSE* sancio-

nan los errores grandes pero tienen las mismas unidades de la serie que se está pronosticando, de modo que su magnitud se interpreta con mayor facilidad. La *RMSE* se presenta a continuación.

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2} \quad (3.9)$$

A veces es más útil calcular los errores del pronóstico en términos de porcentajes en vez de cantidades. El error porcentual absoluto medio (*MAPE*) se calcula obteniendo el error absoluto de cada periodo, dividiendo éste entre el valor real observado en ese periodo y promediando estos errores porcentuales absolutos. El resultado final se multiplica después por 100 y se expresa como porcentaje. Este enfoque es útil cuando el error relativo al tamaño respectivo del valor de la serie de tiempo es importante, para la evaluación de la exactitud del pronóstico. El *MAPE* es especialmente útil cuando los valores Y_t son grandes. El *MAPE* no tiene unidades de medición (es un porcentaje) y sirve para comparar la exactitud de la misma técnica o de otras técnicas en dos series completamente diferentes. La ecuación 3.10 muestra cómo se calcula el *MAPE*.

$$MAPE = \frac{1}{n} \sum_{t=1}^n \frac{|Y_t - \hat{Y}_t|}{|Y_t|} \quad (3.10)$$

Note que el *MAPE* no puede calcularse si cualquiera de las Y_t es cero.

Algunas veces es necesario determinar si el método para pronosticar está sesgado (con pronósticos consistentemente altos o bajos). En estos casos, se usa el error porcentual medio (*MPE*), el cual se calcula obteniendo el error en cada periodo, dividiendo éste entre el valor real de ese periodo y luego promediando estos errores porcentuales. El resultado usualmente se multiplica por 100 y se expresa como un porcentaje. Si el enfoque del pronóstico no tiene sesgo, el *MPE* producirá un resultado que esté cercano a cero. Si el resultado es un porcentaje negativo grande, el método de elaboración del pronóstico está sobreestimando consistentemente. Si el resultado es un porcentaje positivo grande, el método de elaboración del pronóstico está subestimando consistentemente. El *MPE* está dado por:

$$MPE = \frac{1}{n} \sum_{t=1}^n \frac{(Y_t - \hat{Y}_t)}{Y_t} \quad (3.11)$$

La decisión para usar una técnica de elaboración de pronósticos específica se basa, en parte, en la determinación de si la técnica producirá errores en el pronóstico que se consideren lo suficientemente pequeños. En efecto, es realista esperar que una buena técnica de elaboración de pronósticos produzca errores relativamente pequeños de manera consistente.

Las cinco medidas de precisión de un pronóstico recientemente descritas son usadas para:

- Comparar la exactitud de dos (o más) técnicas diferentes.
- Medir la utilidad o confiabilidad de una técnica en particular.
- Ayudar en la búsqueda de una técnica óptima.

El ejemplo 3.6 ilustrará cómo se calcula cada una de estas mediciones del error.

Ejemplo 3.6

La tabla 3.7 presenta los datos del número diario de clientes que solicitan reparaciones, Y_t , y un pronóstico de tales datos, $\hat{Y}_t$, para la estación de servicio Chevron de Gary. La técnica de elaboración del pronóstico utilizó el número de clientes atendidos en el periodo anterior como el pronóstico para el periodo actual. Esta sencilla técnica se estudiará en el capítulo 4. Se emplearon los siguientes cálculos para evaluar este modelo usando *MAD*, *MSE*, *RMSE*, *MAPE* y *MPE*.

$$MAD = \frac{1}{n} \sum_{t=1}^n |Y_t - \hat{Y}_t| = \frac{34}{8} = 4.3$$

$$MSE = \frac{1}{n} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2 = \frac{188}{8} = 23.5$$

$$RMSE = \sqrt{MSE} = \sqrt{23.5} = 4.8$$

$$MAPE = \frac{1}{n} \sum_{t=1}^n \frac{|Y_t - \hat{Y}_t|}{Y_t} = \frac{.556}{8} = .0695 \text{ (6.95\%)}$$

$$MPE = \frac{1}{n} \sum_{t=1}^n \frac{(Y_t - \hat{Y}_t)}{Y_t} = \frac{.162}{8} = .0203 \text{ (2.03\%)}$$

TABLA 3-7 Datos usados en los cálculos para medir el error en el pronóstico del ejemplo 3.6

Tiempo t	Clientes Y_t	Pronóstico					
		$\hat{Y}_t$	Error e_t	$ e_t $	e_t^2	$ e_t /Y_t$	e_t/Y_t
1	58	—	—	—	—	—	—
2	54	58	-4	4	16	.074	-.074
3	60	54	6	6	36	.100	.100
4	55	60	-5	5	25	.091	-.091
5	62	55	7	7	49	.113	.113
6	62	62	0	0	0	.000	.000
7	65	62	3	3	9	.046	.046
8	63	65	-2	2	4	.032	-.032
9	70	63	7	7	49	.100	.100
Totales			12	34	188	.556	.162

La *MAD* indica que cada pronóstico está desviado un promedio de 4.3 clientes. El *MSE* de 23.5 (o la *RMSE* de 4.8) y el *MAPE* de 6.95% se compararían con el *MSE* (*RMSE*) y el *MAPE* de cualquier otro método usado para pronosticar esos datos. Finalmente, el pequeño *MPE* de 2.03% indica que la técnica no tiene sesgo: Puesto que el valor está cercano a cero, la técnica no sobreestima ni subestima consistentemente el número de clientes atendidos diariamente.

DETERMINACIÓN DE UNA TÉCNICA ADECUADA DE PRONÓSTICO

Antes de elaborar el pronóstico con una técnica particular, se debería evaluar lo adecuado de la elección. El pronosticador debe contestar las siguientes preguntas:

- ¿Los coeficientes de autocorrelación de los residuos son indicadores de una serie aleatoria? Esta pregunta puede contestarse examinando la función de autocorrelación para los residuos, tal como se presentó en el ejemplo 3.7.
- ¿La distribución de los residuos es aproximadamente normal? Esta pregunta puede contestarse analizando un histograma de los residuos o una gráfica de probabilidad normal.
- ¿Son significativas las estadísticas t para los valores estimados de los parámetros? La distribución t se revisó en el capítulo 2, y se presentan aplicaciones de las estadísticas t en el ejemplo 3.2 y en los capítulos 6 a 9.
- ¿Quiénes toman decisiones entienden la técnica y la emplean con facilidad?

El requisito básico de que el patrón residual sea aleatorio se verifica examinando los coeficientes de autocorrelación de los residuos. No debería haber coeficientes de autocorrelación significativos. El ejemplo 3.2 ilustra cómo los coeficientes de autocorrelación pueden usarse para determinar si una serie es aleatoria. El estadístico Q de Ljung-Box también se usa para

probar que las autocorrelaciones para todos los retrasos hasta el retraso K dado sean iguales a cero. El ejemplo 3.7 ilustra este procedimiento con los residuos de dos modelos ajustados.

Ejemplo 3.7

A Maggie Trimane, la analista de Sears, se le ha pedido el pronóstico de ventas para 2005. Los datos de 1995 a 2004 se presentan en la tabla 3-4. Primero, Maggie trata de pronosticar los datos usando un promedio móvil de cinco meses (véase el capítulo 4 para la descripción de esta técnica). Los residuos, las diferencias entre los valores reales y los valores pronosticados, se calculan y se guardan. Los coeficientes de autocorrelación para tales residuos se muestran en la figura 3-16. Un examen de estos coeficientes de autocorrelación indica que dos son significativamente diferentes de cero, $r_1 = .77$ y $r_2 = .58$. Los coeficientes de autocorrelación significativos indican alguna asociación o patrón en los residuos. Además, la función de autocorrelación misma tiene un patrón de coeficientes que declinan suavemente. Examinando las primeras 10 autocorrelaciones como un grupo, vemos que el estadístico Q para 10 retrasos es 73.90, mucho mayor que el valor 0.05 superior de una variable chi cuadrada, con 10 grados de libertad, 18.3. La hipótesis de que las primeras 10 autocorrelaciones son consistentes con aquéllas de una serie aleatoria se rechaza claramente para el nivel de 5%. Puesto que uno de los requisitos básicos de una buena técnica de pronósticos es que brinde un residuo o una serie de error que sea esencialmente aleatorio, Maggie juzga que la técnica del promedio móvil de cinco meses es inadecuada.

Ahora Maggie prueba con el suavizamiento exponencial lineal de Holt (véase el capítulo 4 para su descripción). La función de autocorrelación para la serie de residuos generada con esta técnica se presenta en la figura 3-17. Un examen de estos coeficientes de autocorrelación indica que ninguno es

Función de autocorrelación: Residuos MA

Retraso	ACF	T	LBQ
1	0.767355	5.15	28.30
2	0.577829	2.63	44.73
3	0.452556	1.80	55.04
4	0.302645	1.13	59.77
5	0.242298	0.88	62.87
6	0.260305	0.93	66.54
7	0.263140	0.92	70.40
8	0.213366	0.73	73.00
9	0.092468	0.31	73.50
10	-0.080688	-0.27	73.90




FIGURA 3-16 Función de autocorrelación para residuos con un patrón del ejemplo 3.7

Función de autocorrelación: Residuos Holt

Retraso	ACF	T	LBQ
1	-0.010799	-0.08	0.01
2	-0.045018	-0.32	0.12
3	0.180281	1.27	1.91
4	-0.104552	-0.71	2.53
5	-0.214739	-1.45	5.20
6	-0.031463	-0.20	5.25
7	0.113653	0.74	6.04
8	0.091499	0.59	6.55
9	0.003889	0.02	6.55
10	0.114144	0.73	7.40




FIGURA 3-17 Función de autocorrelación para residuos que son esencialmente aleatorios del ejemplo 3.7

significativamente diferente de cero (al nivel de 5%). También se examina el estadístico Q para 10 retrasos de tiempo. El valor LBQ de 7.40 en el resultado Minitab es menor que el valor .05 superior de una variable chi cuadrada, con ocho grados de libertad, 15.5. (En este caso, los grados de libertad son iguales al número de retrasos que se prueban, menos el número de parámetros en el modelo de suavización exponencial lineal que se ha ajustado a los datos). Como grupo, las primeras 10 autocorrelaciones residuales no son diferentes de aquellas de una serie completamente aleatoria. Maggie decide considerar la técnica de suavizamiento exponencial lineal de Holt, como un posible modelo para elaborar el pronóstico de los ingresos operativos para Sears en 2005.

APLICACIÓN EN LA ADMINISTRACIÓN

Los conceptos en este capítulo brindan una base para la selección de una técnica de elaboración de pronósticos adecuada en una situación dada. Muchas de las técnicas más importantes para pronosticar se analizan y aplican en las situaciones de pronósticos en los siguientes capítulos. Es importante observar que en muchas situaciones prácticas, más de un método o modelo para pronosticar puede dar como pronósticos aceptables y casi sin diferencias. De hecho, se recomienda intentar varias técnicas razonables para pronosticar. A menudo se debe usar un criterio con base en la facilidad de uso, el costo, las condiciones ambientales externas, etcétera, para elegir un conjunto de pronósticos específico de entre, digamos, dos conjuntos de valores casi sin diferencias.

Los siguientes son unos cuantos ejemplos de situaciones que se presentan constantemente en el mundo de los negocios, donde una buena técnica para elaboración de pronósticos ayudaría en el proceso de toma de decisiones:

- Una compañía de bebidas gaseosas quiere proyectar la demanda mensual de su principal producto durante los próximos dos años.
- Una compañía de telecomunicaciones líder quiere pronosticar los pagos de dividendos trimestrales de su principal competidor por los próximos tres años.
- Una universidad necesita pronosticar las horas-crédito trimestrales de los estudiantes por los siguientes cuatro años, para desarrollar proyecciones del presupuesto para la legislatura estatal.
- Una empresa de contabilidad pública necesita pronósticos mensuales de ingresos por facturación, de modo que pueda planear las vacantes contables e iniciar el reclutamiento.
- El gerente de control de calidad de una fábrica que produce perfiles de aluminio necesita un pronóstico semanal de los defectos de producción para la alta gerencia de la compañía.
- Un banquero quiere ver las proyecciones mensuales de ingresos de un pequeño fabricante de bicicletas, quien está solicitando un crédito grande para triplicar su capacidad de producción.
- Una institución del gobierno federal necesita proyecciones anuales del promedio de millas por galón de los automóviles hechos en Estados Unidos durante los próximos 10 años, para efectuar recomendaciones regulatorias.
- Un gerente de recursos humanos necesita un pronóstico mensual de días de ausentismo en la fuerza laboral de la compañía para planear los gastos por horas extras.
- Un negocio de préstamos y ahorro requiere un pronóstico de préstamos incobrables por los siguientes dos años, en un intento por evitar la bancarrota.
- Una compañía que fabrica chips para computadora necesita un pronóstico de la industria sobre el número de computadoras personales vendidas para los próximos 5 años, con la finalidad de planear su presupuesto de investigación y desarrollo.
- Una compañía de Internet necesita pronosticar las solicitudes de servicio por los siguientes seis meses, para elaborar planes de reclutamiento de personal para sus *call centers*.

Glosario

Autocorrelación. Es la correlación entre una variable atrasada uno o más periodos consigo misma.

Correlograma o función de autocorrelación. Es una gráfica de las autocorrelaciones para varios retrasos en una serie de tiempo.

Corte transversal. Son observaciones recopiladas en un único periodo de tiempo.

Componente cíclico. Es la fluctuación ondulatoria alrededor de la tendencia.

Residuo. Es la diferencia entre un valor real y su valor pronosticado.

Componente estacional. Es un patrón de cambio que se repite año tras año.

Serie estacionaria. Es aquella cuyas propiedades estadísticas básicas, como la media y la varianza, permanecen constantes a través del tiempo.

Serie de tiempo. Una serie de tiempo consiste en datos que se recolectan, se registran o se observan durante incrementos de tiempo sucesivos.

Tendencia. Es el componente de largo plazo que representa el crecimiento o el decrecimiento en la serie de tiempo durante un periodo largo.

Fórmulas clave

Coefficiente de autocorrelación de k -ésimo orden

$$r_k = \frac{\sum_{t=k+1}^n (Y_t - \bar{Y})(Y_{t-k} - \bar{Y})}{\sum_{t=1}^n (Y_t - \bar{Y})^2} \quad (3.1)$$

Error estándar del coeficiente de autocorrelación

$$SE(r_k) = \sqrt{\frac{1 + 2 \sum_{i=1}^{k-1} r_i^2}{n}} \quad (3.2)$$

Estadístico Q de Ljung-Box

$$Q = n(n+2) \sum_{k=1}^m \frac{r_k^2}{n-k} \quad (3.3)$$

Modelo aleatorio

$$Y_t = c + \varepsilon_t \quad (3.4)$$

Estadístico t para probar la significancia de la autocorrelación del retraso 1

$$t = \frac{r_1}{SE(r_1)} \quad (3.5)$$

Error de pronóstico o residuo

$$e_t = Y_t - \hat{Y}_t \quad (3.6)$$

Desviación media absoluta

$$MAD = \frac{1}{n} \sum_{t=1}^n |Y_t - \hat{Y}_t| \quad (3.7)$$

Error cuadrático medio

$$MSE = \frac{1}{n} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2 \quad (3.8)$$

Raíz cuadrada del error cuadrático medio

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2} \quad (3.9)$$

Error porcentual absoluto medio

$$MAPE = \frac{1}{n} \sum_{t=1}^n \frac{|Y_t - \hat{Y}_t|}{|Y_t|} \quad (3.10)$$

Error porcentual medio

$$MPE = \frac{1}{n} \sum_{t=1}^n \frac{(Y_t - \hat{Y}_t)}{Y_t} \quad (3.11)$$

Problemas

1. Explique las diferencias entre las técnicas de pronósticos cualitativas y cuantitativas.
2. ¿Qué es una serie de tiempo?
3. Describa cada uno de los componentes de una serie de tiempo.
4. ¿Qué es la autocorrelación?
5. ¿Qué mide un coeficiente de autocorrelación?
6. Explique cómo se usan los correlogramas para analizar las autocorrelaciones de varios retrasos de una serie de tiempo.
7. Indique si cada uno de los siguientes enunciados describe una serie estacionaria o una serie no estacionaria.
 - a) Una serie que muestra una tendencia
 - b) Una serie cuya media y varianza permanecen constantes en el tiempo
 - c) Una serie cuyo valor de la media cambia con el tiempo
 - d) Una serie que no tiene crecimiento ni decrecimiento
8. En seguida se presentan descripciones de varios tipos de series: aleatoria, estacionaria, de tendencia y estacional. Identifique el tipo de serie que describe cada inciso.
 - a) La serie tiene propiedades estadísticas básicas, como media y varianza, que permanecen constantes en el tiempo.
 - b) Los valores sucesivos de una serie de tiempo no están relacionados entre sí.
 - c) Existe una relación significativa entre cada valor sucesivo de una serie.

- d) Un coeficiente de autocorrelación significativo aparece en el retraso de tiempo 4 para datos trimestrales.
 - e) La serie no tiene crecimiento ni decrecimiento
 - f) En general, los coeficientes de autocorrelación son significativamente diferentes de cero, para varios de los primeros retrasos de tiempo y luego disminuyen gradualmente hacia cero, conforme se incrementa el número de retrasos.
9. Liste algunas de las técnicas de pronósticos que deban considerarse cuando se está pronosticando una serie estacionaria. Dé ejemplos de situaciones en que dichas técnicas serían aplicables.
 10. Liste algunas de las técnicas de pronósticos que deban considerarse cuando se está pronosticando una serie de tendencia. Mencione ejemplos de situaciones en que dichas técnicas serían aplicables.
 11. Liste algunas de las técnicas de pronósticos que deban considerarse cuando se está pronosticando una serie estacional. Mencione ejemplos de situaciones en que dichas técnicas serían aplicables.
 12. Liste algunas de las técnicas de pronósticos que deban considerarse cuando se está pronosticando una serie cíclica. Mencione ejemplos de situaciones en que dichas técnicas serían aplicables.
 13. En la tabla P-13, se presenta el número de matrimonios en Estados Unidos. Calcule las primeras diferencias para tales datos. Grafique los datos originales y los datos de diferencia como una serie de tiempo. ¿Hay tendencia en cualquiera de estas series? Explique su respuesta.
 14. Calcule un intervalo de confianza de 95% para el coeficiente de autocorrelación para el retraso de tiempo 1 para una serie que contiene 80 elementos.
 15. ¿Qué medida de precisión del pronóstico debería usarse en cada una de las siguientes situaciones?
 - a) El analista necesita determinar si el método de elaboración del pronóstico tiene un sesgo.
 - b) El analista cree que el tamaño o la magnitud de la variable del pronóstico es importante en la evaluación de la exactitud de éste.
 - c) El analista necesita sancionar errores grandes del pronóstico.

TABLA P-13

<i>Año</i>	<i>Matrimonios (miles)</i>	<i>Año</i>	<i>Matrimonios (miles)</i>
1985	2,413	1995	2,336
1986	2,407	1996	2,344
1987	2,403	1997	2,384
1988	2,396	1998	2,244
1989	2,403	1999	2,358
1990	2,443	2000	2,329
1991	2,371	2001	2,345
1992	2,362	2002	2,254
1993	2,334	2003	2,245
1994	2,362	2004	2,279

Fuente: Basada en *Statistical Abstract of the United States*, varios años.

16. ¿Cuál de los siguientes enunciados es verdadero en relación con las medidas de precisión usadas para evaluar pronósticos?
- El *MAPE* toma en consideración la magnitud de los valores que se pronostican.
 - El *MSE* y la *RMSE* sancionan errores grandes.
 - El *MPE* se usa para determinar si, sistemáticamente, un modelo está prediciendo muy alto o muy bajo.
 - La ventaja del método de la *MAD* es que relaciona el tamaño del error con la observación real.
17. A Allie White, la jefa de la oficina de préstamos del Dominion Bank, le gustaría analizar el portafolios de préstamos del banco para los años 2001 a 2006. Los datos se presentan en la tabla P-17.
- Calcule las autocorrelaciones para los retrasos de tiempo 1 y 2. Haga una prueba para determinar si estos coeficientes de autocorrelación son significativamente diferentes de cero, para el nivel de significancia de .05.
 - Use un programa de computadora para graficar los datos y calcule las autocorrelaciones para los primeros seis retrasos de tiempo. ¿Esta serie de tiempo es estacionaria?

TABLA P-17 Préstamos por trimestre (\$ millones) del Dominion Bank, 2001 a 2006				
<i>Calendario</i>	<i>Mar. 31</i>	<i>Jun. 30</i>	<i>Sep. 30</i>	<i>Dic. 31</i>
2001	2,313	2,495	2,609	2,792
2002	2,860	3,099	3,202	3,161
2003	3,399	3,471	3,545	3,851
2004	4,458	4,850	5,093	5,318
2005	5,756	6,013	6,158	6,289
2006	6,369	6,568	6,646	6,861

Fuente: Basado en los registros del Dominion Bank.

18. Para el problema anterior. Calcule las primeras diferencias de los datos de préstamos trimestrales del Dominion Bank.
- Calcule el coeficiente de autocorrelación para el retraso de tiempo 1, usando los datos diferenciados.
 - Use un programa de cómputo para graficar los datos diferenciados y para calcular sus autocorrelaciones de los primeros seis retrasos de tiempo. ¿Esta serie es estacionaria?
19. Analice los coeficientes de autocorrelación para las series presentadas en las figuras 3-18 a 3-21. Describa brevemente cada serie.
20. A un analista le gustaría determinar si existe un patrón de ganancias por acción para la Price Company, la cual opera un negocio de autoservicio de venta al mayoreo/menudeo en varios estados con el nombre de Price Club. Los datos se presentan en la tabla P-20. Describa cualquiera de los patrones que existan en estos datos.
- Encuentre el pronóstico de las ganancias trimestrales por acción de Price Club para cada trimestre, usando el enfoque sencillo (p. ej., el pronóstico del primer trimestre de 1987 es el valor del cuarto trimestre de 1986, es decir, .32).
 - Evalúe el pronóstico sencillo usando la *MAD*.

- c) Evalúe el pronóstico sencillo usando el *MSE* y la *RMSE*.
- d) Evalúe el pronóstico sencillo usando el *MAPE*.
- e) Evalúe el pronóstico sencillo usando el *MPE*.
- f) Escriba un reporte que resuma sus hallazgos.




FIGURA 3-18 Función de autocorrelación para el problema 19




FIGURA 3-19 Función de autocorrelación para el problema 19




FIGURA 3-20 Función de autocorrelación para el problema 19




FIGURA 3-21 Función de autocorrelación para el problema 19

TABLA P-20 Ganancias trimestrales por acción de Price Club: trimestres de 1986 a 1993				
Año	1o	2o	3o	4o
1986	.40	.29	.24	.32
1987	.47	.34	.30	.39
1988	.63	.43	.38	.49
1989	.76	.51	.42	.61
1990	.86	.51	.47	.63
1991	.94	.56	.50	.65
1992	.95	.42	.57	.60
1993	.93	.38	.37	.57

Fuente: *The Value Line Investment Survey* (Nueva York: Value Line, 1994), p. 1646.

TABLA P-21 Ventas semanales de un artículo alimenticio							
(Lea transversalmente)							
2649.9	2898.7	2897.8	3054.3	3888.1	3963.6	3258.9	3199.6
3504.3	2445.9	1833.9	2185.4	3367.4	1374.1	497.5	1699.0
1425.4	1946.2	1809.9	2339.9	1717.9	2420.3	1396.5	1612.1
1367.9	2176.8	2725.0	3723.7	2016.0	862.2	1234.6	1166.5
1759.5	1039.4	2404.8	2047.8	4072.6	4600.5	2370.1	3542.3
2273.0	3596.6	2615.8	2253.3	1779.4	3917.9	3329.3	1864.4
3318.9	3342.6	2131.9	3003.2				

21. La tabla p-21 contiene las ventas semanales de un artículo alimenticio para 52 semanas consecutivas.
- a) Grafique los datos de ventas como una serie de tiempo.
 - b) ¿Cree que esta serie sea estacionaria o no estacionaria?
 - c) Usando Minitab o un programa similar, calcule las autocorrelaciones de la serie de ventas para los 10 primeros retrasos de tiempo. ¿El comportamiento de las autocorrelaciones es consistente con su respuesta al inciso b)? Explique por qué.

22. Esta pregunta se refiere al problema 21.
- Ajuste el modelo aleatorio dado por la ecuación 3.4 a los datos de la tabla P-21, estimando c con la media muestral $\bar{Y}$ de modo que $\hat{Y}_t = \bar{Y}$. Calcule los residuos usando $e_t = Y_t - \hat{Y}_t = Y_t - \bar{Y}$.
 - Usando Minitab o un programa similar, calcule las autocorrelaciones de los residuos de la parte c para los primeros 10 retrasos de tiempo. ¿El modelo aleatorio es adecuado para los datos de ventas? Explique su respuesta.
23. La tabla P-23 presenta los ingresos trimestrales de Southwest Airlines, antes de partidas extraordinarias (millones de \$) para los años de 1988 a 1999.
- Grafique los datos de ingresos como una serie de tiempo y describa cualquier patrón existente.
 - ¿La serie es estacionaria o no estacionaria? Explique su respuesta.
 - Usando Minitab o un programa similar, calcule las autocorrelaciones de la serie de ingresos para los primeros 10 retrasos de tiempo. ¿El comportamiento de las autocorrelaciones es congruente con su elección realizada en el inciso b)? Explique su respuesta.
24. Esta pregunta se refiere al problema 23.
- Use Minitab o Excel para calcular las diferencias *cuartas* de los datos de ingresos en la tabla P-23. Las diferencias cuartas se calculan diferenciando las observaciones separadas por cuatro periodos. Con datos trimestrales, este procedimiento algunas veces es útil en la creación de una serie estacionaria, a partir de una serie no estacionaria (véase el capítulo 9). Por lo tanto, los datos diferenciados cuartos serán $Y_5 - Y_1 = 19.64 - 0.17 = 19.47$, $Y_6 - Y_2 = 19.24 - 15.13 = 4.11$, ..., y así sucesivamente.
 - Grafique las series de tiempo de las diferencias cuartas. ¿Estas series de tiempo parecen ser estacionarias o no estacionarias? Explique su respuesta.
25. Este problema se remite al problema 23.
- Considere un método de pronósticos sencillo, donde los ingresos del primer trimestre se usen para pronosticar los ingresos del primer trimestre del siguiente año, los ingresos del segundo trimestre se usen para pronosticar los ingresos del segundo trimestre del siguiente año, etcétera. Por ejemplo, un pronóstico de los ingresos del primer trimestre de 1998 lo proporcionan los ingresos del primer trimestre de 1997: 50.87 (véase la tabla P-23). Use este

TABLA P-23 Ingresos trimestrales de Southwest Airlines (millones de \$)				
Año	1o	2o	3o	4o
1988	0.17	15.13	26.59	16.07
1989	19.64	19.24	24.57	8.11
1990	5.09	23.53	23.04	-4.58
1991	-8.21	10.57	15.72	8.84
1992	13.48	23.48	26.89	27.17
1993	24.93	42.15	48.83	38.37
1994	41.85	58.52	58.62	20.34
1995	11.83	59.72	67.72	43.36
1996	33.00	85.32	60.86	28.16
1997	50.87	93.83	92.51	80.55
1998	70.01	133.39	129.64	100.38
1999	95.85	157.76	126.98	93.80

Fuente: Basada en *Compustat Industrial Quarterly Data Base*.

método sencillo para calcular los pronósticos de los ingresos trimestrales para los años 1998 a 1999.

b) Usando los pronósticos del inciso a), calcule *MAD*, *RMSE* y *MAPE*.

c) Dados los resultados en el inciso b) y la naturaleza de los patrones en la serie de ingresos, ¿cree usted que sea viable el método del pronóstico sencillo?
¿Pensaría en otro método sencillo que fuera mejor?

CASOS

CASO 3-1A MURPHY BROTHERS FURNITURE

En 1958 los hermanos Murphy abrieron una tienda de muebles en el centro de Dallas. Tuvieron mucho éxito durante varios años y ampliaron su cobertura de menudeo al oeste y al medio oeste. Para 1996 la cadena de sus mueblerías tenía presencia en 36 estados.

Julie Murphy, la hija de uno de los fundadores, se incorporó recientemente a la empresa. Su papá y su tío tenían buenos conocimientos en muchas áreas, aunque no en el área de las habilidades cuantitativas. En particular, ambos creían que no serían capaces de pronosticar con exactitud las futuras ventas de Murphy Brothers usando las técnicas computacionales modernas. Por tal razón, pidieron a Julie que los ayudara como parte de su nuevo empleo.

Julie pensó primero en usar las ventas en dólares de Murphy como su variable; pero se encontró con que faltaban varios años de información. Consultó a su padre, Glen, acerca de esto y él le dijo que por ese entonces él “creía que no era importante”. Julie explicó a Glen la importancia de los datos históricos y le pidió que guardara los datos en el futuro.

Julie pensó que las ventas de Murphy probablemente estaban muy relacionadas con las cifras de ventas nacionales y decidió buscar una variable adecuada en una de las diversas publicaciones federales. Después

de buscar en un número reciente de *Survey and Current Business*, encontró la historia de ventas mensuales de todas las tiendas minoristas en Estados Unidos, y decidió usar esta variable como sustituto de la variable que le interesaba: las ventas en dólares de Murphy Brothers. Ella creía que si era capaz de obtener pronósticos exactos de las ventas nacionales, podría relacionar tales pronósticos con las ventas propias de Murphy y conseguir los pronósticos que requería.

La tabla 3-8 presenta los datos que recopiló Julie, y la figura 3-22 ilustra una gráfica con los datos obtenidos con el programa de cómputo de Julie. Ella inició su análisis usando la computadora para desarrollar una gráfica de los coeficientes de autocorrelación.

Después de revisar la función de autocorrelación de la figura 3-23, era evidente para Julie que sus datos mostraban una tendencia. Los primeros coeficientes de autocorrelación eran muy grandes, y tendían hacia cero muy lentamente en el tiempo. Para hacer estacionaria la serie, de modo que pudiera considerar varios métodos de elaboración de pronósticos, Julie decidió diferenciar primero sus datos, para saber si la tendencia se podría eliminar. La función de autocorrelación para estos datos diferenciados se presenta en la figura 3-24.

PREGUNTAS

1. ¿Qué debería concluir Julie acerca de la serie de ventas al menudeo?
2. ¿Ha avanzado mucho Julie para encontrar una técnica de elaboración de pronósticos?
3. ¿Ha avanzado mucho Julie para encontrar una técnica de elaboración de pronósticos?
4. ¿Cómo sabrá Julie cuál técnica funcionará mejor?