

REGRESIÓN LINEAL
SIMPLE

En el capítulo 2 se analizó la asociación lineal (correlación) entre dos variables numéricas. La asociación lineal implica una relación en línea recta, y vimos cómo ajustar una línea recta a pares de observaciones de las dos variables usando el método de los mínimos cuadrados. En este capítulo se estudian con detalle los modelos de regresión lineal simple (línea recta). Una vez que se establece una relación lineal, el conocimiento de la variable independiente servirá para pronosticar la variable dependiente.

Con la finalidad de revisar el análisis de la relación entre dos variables, presentado en el capítulo 2, considere el siguiente ejemplo.

Ejemplo 6.1

Suponga que el señor Bump observa el precio y volumen de los galones de leche vendidos durante 10 semanas seleccionadas al azar. Los datos que recolectó se presentan en la tabla 6-1.

Primero, elabora un diagrama de dispersión de los datos, que se muestra en la figura 6-1. En este diagrama parece que existe una relación lineal negativa entre Y , el número de galones de leche vendidos, y X , el precio por galón. Al parecer, conforme el precio sube, el volumen baja.

Ahora, Bump desea medir el grado de esta relación aparente calculando el coeficiente de correlación de la muestra, r . Con base en la ecuación 2.10 y los cálculos de la tabla 6-2, él obtiene

$$\begin{aligned}
 r &= \frac{n\sum XY - (\sum X)(\sum Y)}{\sqrt{n\sum X^2 - (\sum X)^2}\sqrt{n\sum Y^2 - (\sum Y)^2}} \\
 &= \frac{10(149.3) - (14.4)(112)}{\sqrt{10(21.56) - (14.4)^2}\sqrt{10(1,488) - (112)^2}} \\
 &= \frac{-119.8}{138.7} = -.86
 \end{aligned}$$

TABLA 6-1 Datos de los galones de leche para el ejemplo 6.1

<i>Semana</i>	<i>Nivel de ventas semanal, Y (miles de galones)</i>	<i>Precio de venta X (\$)</i>
1	10	1.30
2	6	2.00
3	5	1.70
4	12	1.50
5	10	1.60
6	15	1.20
7	5	1.60
8	12	1.40
9	17	1.00
10	20	1.10




FIGURA 6-1 Diagrama de dispersión para el ejemplo 6.1

TABLA 6-2 Cálculos necesarios para el ejemplo 6.1

	<i>Y</i>	<i>X</i>	<i>XY</i>	<i>X</i> ²	<i>Y</i> ²
<i>n</i> = 10	10	1.30	13.0	1.69	100
	6	2.00	12.0	4.00	36
	5	1.70	8.5	2.89	25
	12	1.50	18.0	2.25	144
	10	1.60	16.0	2.56	100
	15	1.20	18.0	1.44	225
	5	1.60	8.0	2.56	25
	12	1.40	16.8	1.96	144
	17	1.00	17.0	1.00	289
	20	1.10	22.0	1.21	400
Totales	112	14.40	149.3	21.56	1,488

El coeficiente de correlación de la muestra de $-.86$ indica una relación negativa bastante fuerte entre *Y* y *X*: conforme el precio del galón de leche aumenta, el número de galones vendidos disminuye.

La pregunta que se puede hacer ahora es: ¿En qué medida desciende el volumen conforme el precio se eleva? Esta pregunta sugiere la graficación de una línea recta por los puntos de datos representados en el diagrama de dispersión. Después de que se ha dibujado la línea, la pendiente de ésta indicará la disminución promedio del volumen *Y* por cada dólar de incremento en el precio *X*.

LÍNEA DE REGRESIÓN

El señor Bump podría dibujar una línea recta por los puntos de datos, intentando ajustar la línea a los puntos tanto como sea posible. Sin embargo, alguien más podría dibujar una línea diferente. Un procedimiento más adecuado es obtener la mejor línea recta usando un criterio que, para un conjunto determinado de datos, produzca siempre la misma línea recta sin impor-

tar quién esté haciendo el ajuste. Como apuntamos en el capítulo 2, un procedimiento muy conocido para determinar la mejor línea recta ajustada es el criterio de los mínimos cuadrados.

La línea que mejor se ajusta a una colección de puntos de datos X - Y es la línea que minimiza la suma de los cuadrados de las distancias entre los puntos y la línea, medidas verticalmente, es decir, en la dirección Y . Esta línea se conoce como la *línea de los mínimos cuadrados* o *línea de regresión ajustada* y su ecuación se llama *ecuación de regresión ajustada*.

La línea recta ajustada es de la forma $\hat{Y} = b_0 + b_1X$. El primer término del segundo miembro, b_0 , es la *intersección con Y* , y el segundo término, b_1 , es la *pendiente*. Recuerde que la pendiente representa la cantidad de cambio de Y cuando se incrementa X en una unidad. El objetivo inmediato es determinar los valores de b_0 y b_1 .

Recuerde del capítulo 2 (véase la ecuación 2.11) que el *método de los mínimos cuadrados* selecciona los valores de b_0 y b_1 que minimizan los errores de la suma de los cuadrados (distancias).

$$SSE = \sum (Y - \hat{Y})^2 = \sum (Y - b_0 - b_1X)^2 \quad (6.1)$$

Usando un poco de cálculo, es posible obtener expresiones algebraicas específicas para los valores de los mínimos cuadrados. En particular,

$$b_1 = \frac{n \sum XY - \sum X \sum Y}{n \sum X^2 - (\sum X)^2} = \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\sum (X - \bar{X})^2} \quad (6.2)$$

$$b_0 = \frac{\sum Y}{n} - \frac{b_1 \sum X}{n} = \bar{Y} - b_1 \bar{X} \quad (6.3)$$

Como usted podrá adivinar, el coeficiente de la pendiente de los mínimos cuadrados está relacionado con el coeficiente de correlación de la muestra. Específicamente,

$$b_1 = \frac{\sqrt{\sum (Y - \bar{Y})^2}}{\sqrt{\sum (X - \bar{X})^2}} r \quad (6.4)$$

De manera que b_1 y r son proporcionales entre sí y tienen el mismo signo.

Las diferencias entre los valores Y realmente observados y los correspondientes valores Y ajustados, las $\hat{Y}$'s, se llaman *residuos*. Los residuos son las distancias verticales (positivas o negativas) entre los puntos de datos y la línea de mínimos cuadrados.

Tenemos la identidad

$$\text{Observación} = \text{Ajuste} + \text{Residuo}$$

o, en símbolos,

$$Y = \hat{Y} + (Y - \hat{Y}) \quad (6.5)$$

En este contexto, el ajuste representa el patrón general en los datos, y los residuos representan las desviaciones de ese patrón. La separación en ajustes más residuos se aplica también a otros patrones diferentes a los de una línea recta y los utilizaremos repetidamente en capítulos posteriores.

Ejemplo 6.2

Los coeficientes de mínimos cuadrados para ajustar una línea recta a los datos del señor Bump (véase la figura 6-1) se calculan fácilmente mediante las ecuaciones 6.2 y 6.3 y la información de la tabla 6-2. Así, tenemos

$$b_1 = \frac{10(149.3) - (14.4)(112)}{10(21.56) - (14.4)^2} = \frac{-119.8}{8.24} = -14.54$$

$$b_0 = \frac{112}{10} - (-14.54)\frac{14.4}{10} = 11.2 + 14.54(1.44) = 32.14$$

La línea de mínimos cuadrados ajustada tiene la ecuación

$$\hat{Y} = b_0 + b_1X$$

$$\hat{Y} = 32.14 - 14.54X \quad (6.6)$$

Esta ecuación se llama la *ecuación de regresión ajustada*.

Ahora, el señor Bump desea interpretar los valores en esta ecuación. La intersección con Y , b_0 , es el valor de Y cuando X es igual a cero. Una interpretación estricta sugeriría que el número promedio de galones vendidos cuando $X = 0$ (es decir, cuando el precio del galón de leche es cero) es de 32,140 galones. Esta interpretación no concuerda con el sentido común, puesto que uno esperaría que se “vendiera” más leche si ésta fuera gratis. El problema ilustrado aquí implica la predicción de un valor de Y con base en un valor de X acerca del cual no se ha recolectado evidencia muestral. Es decir, ninguno de los puntos de la muestra tiene un valor X en cero o cerca de cero. En este caso, como en muchos casos de análisis de regresión, no es posible tener una interpretación útil de la intersección con Y .

En términos más generales, con frecuencia no conviene predecir valores de Y para cualquier X más allá del rango de las X recopiladas en los datos muestrales. Una función de regresión debería interpretarse como una aproximación útil al comportamiento en el mundo real *de la región en la cual existen datos*. La extrapolación más allá de los datos requiere una desmedida suposición de que la naturaleza de la relación entre X y Y no cambia.¹

El coeficiente de la pendiente, b_1 , se puede interpretar como el cambio promedio de Y que ocurre cuando X se incrementa en una unidad. En este ejemplo, Y disminuye un promedio de 14.54 (esto es, se venden 14,540 galones menos) cuando X se incrementa en 1 (es decir, cuando el costo de un galón de leche se incrementa en \$1). Cada dólar de incremento en el precio de un galón de leche reduce la cantidad comprada en un promedio de 14,540 galones. Para expresar este enunciado en unidades más significativas, la evidencia muestral indica que cada incremento de 1 centavo en el precio de un galón de leche reduce la cantidad comprada en un promedio de 145.4 galones.

La relación X - Y se puede ilustrar dibujando la línea recta que mejor se ajusta a los puntos de datos en un diagrama de dispersión. El resultado se presenta en la figura 6-2.

Observe que las distancias verticales de los puntos a la línea se representan como líneas punteadas. Si estas distancias se elevan al cuadrado y se suman, el resultado sería menor que el calculado para cualquier otra línea que pudiera dibujarse a través de los puntos.² Así, de acuerdo con el procedimiento de los mínimos cuadrados, esta línea representa el mejor ajuste posible para los puntos de los 10 datos muestrales.

Cuando los puntos en el diagrama de dispersión no se ubican exactamente sobre la línea, como en la figura 6-2, es necesario recurrir a ideas estadísticas para el estudio de la relación entre dos variables. Pensamos en los datos de un diagrama de dispersión como una muestra de observaciones sobre una relación subyacente que se mantiene en la población de valores X - Y . El modelo estadístico de la regresión lineal simple supone que para todos los valores de X , los valores observados de la variable dependiente, Y , están normalmente distribuidos

¹En el capítulo 5 encontramos una situación similar cuando analizamos la utilidad de la extrapolación de curvas de tendencia para pronosticar valores futuros de una serie de tiempo.

²Para los datos de Bump, la suma más pequeña de las distancias elevadas al cuadrado es $SSE = 59.14$.




FIGURA 6-2 Línea de regresión ajustada de los datos del señor Bump para el ejemplo 6.2




FIGURA 6-3 Modelo estadístico de la regresión lineal simple

alrededor de la media, $\mu_Y = \beta_0 + \beta_1 X$, la cual depende linealmente de X . Es decir, conforme X cambia, las medias de la distribución de los valores posibles de Y permanecen a lo largo de la línea recta. Esta línea se conoce como la *línea de regresión de población*. Las Y observadas variarán alrededor de estas medias por la influencia de factores no medidos. El modelo supone que esta variación, medida por la desviación estándar, σ , es la misma para todos los valores de X . Finalmente, la desviación (distancia) entre un valor de Y y su media se conoce como *error* y se representa mediante la letra griega épsilon.

En el modelo de regresión lineal simple, la variable de respuesta o dependiente Y es la suma de esta media y la desviación aleatoria (ϵ) en relación con la media. Las desviaciones (ϵ) representan la variación de Y que se debe a otros factores no observados, los cuales impiden a los valores X - Y ubicarse exactamente sobre una línea recta en el diagrama de dispersión.

El modelo estadístico de regresión lineal simple se ilustra en la figura 6-3.

Modelo estadístico de regresión lineal

La variable de respuesta o dependiente, Y , está relacionada con la variable controlada o independiente, X , mediante

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Aquí, $\beta_0 + \beta_1 X$ es la respuesta promedio para una X dada. Se supone que las desviaciones (ε) son independientes y están normalmente distribuidas, con una media igual a 0 y una desviación estándar σ . Las constantes desconocidas son β_0 , β_1 y σ .

La línea de regresión ajustada (de la muestra), $\hat{Y} = b_0 + b_1 X$, puede considerarse como una estimación de la línea de regresión de la población, $m_y = \beta_0 + \beta_1 X$, en tanto que los residuos $e = Y - \hat{Y}$, pueden considerarse como estimaciones de los componentes del error, ε . Esto implica la siguiente correspondencia:

$$\text{Población: } Y = \beta_0 + \beta_1 X + \varepsilon$$

$$\text{Muestra: } Y = b_0 + b_1 X + e$$

La mayoría de los paquetes de software de computadora ejecutan los análisis de correlación y regresión. Las instrucciones para usar Excel en los ejemplos 6.1 y 6.2 se presentan en la sección de aplicaciones de Excel al final de este capítulo.

ERROR ESTÁNDAR DE LA ESTIMACIÓN

Una vez que se ha calculado la línea recta ajustada, el señor Bump podría estar interesado en medir el grado en el que los puntos de datos muestrales se dispersan alrededor de la función de regresión ajustada. Es posible desarrollar una medida de dispersión análoga a la desviación estándar de la muestra. Esta medida, llamada *error estándar de la estimación*, mide la dispersión de los puntos de datos en la dirección Y alrededor de la línea ajustada. El error estándar de la estimación se denota por $s_{y \cdot x}$ y está dado por

$$s_{y \cdot x} = \sqrt{\frac{\sum (Y - \hat{Y})^2}{n - 2}} \quad (6.7)$$

El *error estándar de la estimación* mide la cantidad por la cual los valores reales de Y difieren de los valores estimados o $\hat{Y}$. Para muestras relativamente grandes, esperaríamos que alrededor del 67% de las diferencias $Y - \hat{Y}$ estuvieran a una distancia inferior de $s_{y \cdot x}$ del 0, y que alrededor del 95% de estas diferencias estuvieran dentro de $2s_{y \cdot x}$ del 0.

El error estándar de la estimación es similar a la desviación estándar de la muestra presentada en el capítulo 2. Puede utilizarse para calcular la desviación estándar de la población. De hecho, $s_{y \cdot x}$ estima la desviación estándar, σ , del término de error, ε , en el modelo estadístico de regresión lineal simple. De manera equivalente, $s_{y \cdot x}$ estima la desviación estándar común, σ , de la distribución normal de los valores Y alrededor de la línea de regresión de la población, $\mu_y = \beta_0 + \beta_1 X$, para cada X (véase la figura 6-3).

Un análisis de regresión con un error estándar pequeño de la estimación significa que todos los puntos de datos se ubican muy cerca de la línea de regresión ajustada.³ Si el error estándar de la estimación es grande, los puntos de datos están considerablemente dispersos alrededor de la línea ajustada.

Para efectos de cálculo, la ecuación 6.7 se convierte en

$$s_{y \cdot x} = \sqrt{\frac{\sum Y^2 - b_0 \sum Y - b_1 \sum XY}{n - 2}} \quad (6.8)$$

Para el ejemplo de Bump, el error estándar de la estimación es

$$\begin{aligned} s_{y \cdot x} &= \sqrt{\frac{1,488 - (32.14)(112) - (-14.54)(149.3)}{10 - 2}} \\ &= \sqrt{\frac{59.14}{8}} = \sqrt{7.39} = 2.72 \end{aligned}$$

Con los valores de $\hat{Y}$ en el rango 3-18 (véase la figura 6-2), $s_{y \cdot x}$ es moderadamente grande e indica que una cantidad apreciable de la variación en Y (galones vendidos) no se explica por X (precio). Investigaremos más adelante esta afirmación, en la sección sobre el coeficiente de determinación.

PRONÓSTICO DE Y

Luego, la línea de regresión ajustada puede usarse para estimar el valor de Y para un valor dado de X . Si queremos obtener un *pronóstico puntual* o un pronóstico para un valor dado de X , simplemente evaluamos la función de regresión estimada para X .

Ejemplo 6.3

Suponga que el señor Bump desea pronosticar la cantidad de leche vendida si el precio se fijara en \$1.63. De acuerdo con la ecuación 6.6, el pronóstico es

$$\begin{aligned} \hat{Y} &= 32.14 - 14.54X \\ \hat{Y} &= 32.14 - 14.54(1.63) = 8.440 \end{aligned}$$

o 8,440 galones. Observe que este pronóstico es un valor de $\hat{Y}$; es decir, el pronóstico es la coordenada Y del punto sobre la línea de regresión ajustada donde $X = 1.63$.

Por supuesto, el señor Bump se da cuenta de que es improbable que los valores reales de Y correspondientes a las posiciones de las X se ubiquen exactamente sobre la línea de regresión. De hecho, estarán distribuidos a uno y otro lado de la línea conforme a la medición $s_{y \cdot x}$. Más aún, la línea de regresión (ajustada) de la muestra es una estimación de la línea de regresión de la población basada en una muestra de 10 puntos de datos. Otras muestras aleatorias de 10 producirían diferentes líneas de regresión ajustada, en forma similar al caso en el que muchas muestras extraídas de la misma población tienen diferentes medias muestrales.

Entonces, existen dos fuentes de incertidumbre asociadas con un pronóstico puntual generado por una ecuación de regresión ajustada:

1. La incertidumbre que se debe a la dispersión de los puntos de datos alrededor de la línea de regresión de la muestra.
2. La incertidumbre que se debe a la dispersión de la línea de la regresión de la muestra alrededor de la línea de regresión de la población.

³Si todos los puntos de datos se localizan exactamente sobre la línea ajustada, $Y = \hat{Y}$ para toda X y $s_{y \cdot x} = 0$.

Es posible construir un *intervalo de predicción* de Y que tome en cuenta estas dos fuentes de incertidumbre.

El *error estándar del pronóstico*, s_f , mide la variabilidad de la Y pronosticada en relación con el valor real de Y para un valor dado de X .

El error estándar del pronóstico es

$$s_f = \sqrt{s_{y \cdot x}^2 + s_{y \cdot x}^2 \left(\frac{1}{n} + \frac{(X - \bar{X})^2}{\sum (X - \bar{X})^2} \right)}$$

$$s_f = s_{y \cdot x} \sqrt{1 + \frac{1}{n} + \frac{(X - \bar{X})^2}{\sum (X - \bar{X})^2}} \quad (6.9)$$

El primer término debajo del primer radical en la ecuación 6.9, $s_{y \cdot x}^2$, mide la dispersión de los puntos de datos alrededor de la línea de regresión de la muestra (primera fuente de incertidumbre). El segundo término debajo del radical mide la dispersión de la línea de regresión de la muestra alrededor de la línea de regresión de la población (segunda fuente de incertidumbre). Advierta que el error estándar del pronóstico depende de X , el valor de X para el cual se desea un pronóstico de Y . También, observe que s_f es el más pequeño cuando $X = \bar{X}$, puesto que el numerador del tercer término debajo del radical en la ecuación 6.9 (abajo) será $(\bar{X} - \bar{X})^2 = 0$.⁴ Si todo permanece igual, cuanto más lejos está X de $\bar{X}$, más grande es el error estándar del pronóstico.

Si el modelo estadístico de regresión lineal simple es el adecuado, un intervalo de predicción de Y está dado por

$$\hat{Y} \pm ts_f \quad (6.10)$$

donde t es un punto porcentual de la distribución t de Student con $df = n - 2$. Si el tamaño de la muestra es grande ($n \geq 30$), el punto porcentual t puede sustituirse por el correspondiente punto porcentual Z de la distribución normal estándar. Por ejemplo, en esencia, un intervalo de predicción del 95% para una muestra grande para Y es

$$\hat{Y} \pm 2s_f \quad (6.11)$$

Ejemplo 6.4

Gráficamente, en el caso que analiza el señor Bump, el intervalo de predicción del 95% para Y con varios valores de X se vería como el de la figura 6-4.

Al usar los resultados de la tabla 6-3 y la ecuación 6.9 con $\bar{X} = 1.44$, el error estándar del pronóstico para $X = 1.63$ es

$$s_f = 2.72 \sqrt{1 + \frac{1}{10} + \frac{(1.63 - 1.44)^2}{.824}} = 2.72(1.069) = 2.91$$

A partir del ejemplo 6.3, $\hat{Y} = 8.440$ cuando $X = 1.63$, y usando la ecuación 6.10, un intervalo de predicción del 95% para Y es

$$\hat{Y} \pm ts_f = 8.44 \pm 2.306(2.91) = 8.44 \pm 6.71$$

⁴Para la opción $X = \bar{X}$, el pronóstico de Y es $\hat{Y} = \bar{Y}$.




FIGURA 6-4 Intervalo de predicción de los datos del señor Bump para el ejemplo 6.4

TABLA 6-3 Cálculo de $\Sigma(X - \bar{X})^2$ para el ejemplo 6.4

X	$(X - \bar{X})^2$
1.30	.0196
2.00	.3136
1.70	.0676
1.50	.0036
1.60	.0256
1.20	.0576
1.60	.0256
1.40	.0016
1.00	.1936
1.10	.1156
$\Sigma(X - \bar{X})^2 = .8240$	

o (1.73, 15.15); es decir, de 1,730 a 15,150 galones. Aquí, $2.306 = t_{0.025}$ es el punto que deja un área de 2.5% a la derecha de la distribución t con 8 grados de libertad $df = 8$.

El intervalo de predicción es muy extenso —tanto, que prácticamente carece de valor para pronosticar Y — a causa del reducido tamaño de la muestra y del valor relativamente grande de s_f . La cantidad de incertidumbre reflejada por el intervalo de predicción tan grande no es evidente en el pronóstico puntual calculado a partir de la función de regresión ajustada. La ventaja principal de la estimación del intervalo es que da cuenta explícitamente de la incertidumbre asociada con el pronóstico.

En general, es peligroso utilizar la función de regresión ajustada para predecir los valores de Y más allá del rango de los datos disponibles. El señor Bump tiene justificación al tratar de pronosticar Y cuando $X = 1.63$ porque algunos de los valores originales de X están cercanos a 1.63. Por otro lado, tal vez no sería conveniente pronosticar Y cuando $X = 3.00$. No se han recopilado valores de X tan grandes y, por esa razón, cualquier pronóstico que implique valores de X como éstos sería muy sospechoso.⁵ Para calcular la cantidad de leche vendida cuando el precio por galón es de \$3.00, el señor Bump tiene que suponer que el modelo lineal sigue siendo válido. Tal vez tenga una buena razón para hacer esta suposición, pero no tiene evidencia directa para apoyarla.

⁵Más aún, el error estándar del pronóstico sería grande, puesto que la cifra $(X - \bar{X})^2$ sería relativamente grande.

Resulta útil terminar esta sección revisando los supuestos subyacentes del modelo estadístico de regresión lineal.

1. *Para un valor dado de X , la población de los valores de Y está normalmente distribuida alrededor de la línea de regresión de la población.* Esta condición se evidencia en la figura 6-3. En la práctica, se obtienen resultados razonablemente exactos siempre que los valores de Y estén distribuidos aproximadamente de manera normal.
2. *La dispersión de los puntos de datos de la población alrededor de la línea de regresión de la población permanece constante a lo largo de la línea.* Es decir, la varianza de la población no se hace más grande o más pequeña conforme los valores de los puntos de datos de X se incrementan. Una violación de este supuesto se llama *heteroscedasticidad*; un ejemplo de esta condición y su solución se encuentra en el capítulo 8.
3. *Los términos de error (ϵ) son independientes uno del otro.* Esta suposición implica una muestra aleatoria de datos X - Y . Cuando los puntos de datos X - Y se registran en el tiempo, este supuesto se viola a menudo. En vez de ser independientes, las observaciones consecutivas están *serialmente correlacionadas*. Los métodos para manejar el problema de la correlación serial se estudiarán en el capítulo 8.
4. *Existe una relación lineal entre X y Y en la población.* Existen extensiones de regresiones lineales simples para manejar las relaciones X - Y que no son lineales; algunas de ellas se estudiarán más adelante en este capítulo.


DESCOMPOSICIÓN DE LA VARIANZA

De acuerdo con la ecuación 6.5

$$Y = \hat{Y} + (Y - \hat{Y})$$

o

$$Y = b_0 + b_1X + (Y - b_0 - b_1X)$$



En una situación ideal, en la cual todos los puntos se ubican exactamente sobre la línea ajustada, todos los residuos son cero y los valores de Y están totalmente explicados por la relación lineal con X .

Al restar $\bar{Y}$ de ambos lados de la expresión anterior,

$$(Y - \bar{Y}) = (\hat{Y} - \bar{Y}) + (Y - \hat{Y})$$

Con un poco de álgebra es posible demostrar que la suma de los cuadrados da por resultado:

$$\Sigma(Y - \bar{Y})^2 = \Sigma(\hat{Y} - \bar{Y})^2 + \Sigma(Y - \hat{Y})^2 \quad (6.12)$$

o

$$SST = SSR + SSE$$

donde

$$SST = \Sigma(Y - \bar{Y})^2$$

$$SSR = \Sigma(\hat{Y} - \bar{Y})^2$$

$$SSE = \Sigma(Y - \hat{Y})^2$$

Aquí, SS significa *suma de cuadrados* (del inglés, *sum of squares*) y T , R y E significan *total*, *regresión* y *error*, respectivamente. Estas sumas de cuadrados tienen grados de libertad asociados:

$$df(SST) = n - 1$$

$$df(SSR) = 1$$

$$df(SSE) = n - 2$$

En correspondencia con las sumas de los cuadrados, los grados de libertad están relacionados por

$$n - 1 = 1 + (n - 2) \quad (6.13)$$

Si no existe una relación lineal, Y no depende de X , y la variación de Y queda descrita por la varianza de la muestra:

$$s_y^2 = \frac{1}{n - 1} \sum (Y - \bar{Y})^2$$

Si, por otro lado, Y está relacionada con X , algunas de las diferencias en los valores de Y se deben a esta relación.

La regresión de la suma de los cuadrados, SSR , mide la parte de la variación de Y que se explica por la relación lineal. La suma de los errores al cuadrado, SSE , es la variación restante de Y , o la variación de Y que no se explica por la relación lineal.

Descomposición de la variabilidad

$$\begin{array}{ccccc} SST & = & SSR & + & SSE \\ \text{Variabilidad} & & \text{Variabilidad} & & \text{Residuo o} \\ \text{total de } Y & & \text{explicada por} & & \text{variabilidad} \\ & & \text{la relación lineal} & & \text{no explicada} \end{array}$$

La sumas de los cuadrados asociadas con la descomposición de la variabilidad de Y y sus correspondientes grados de libertad se pueden arreglar como se muestra en la tabla 6-4, que constituye un ejemplo de una *tabla ANOVA* (*analysis of variance*, análisis de varianza).

La columna final de la tabla ANOVA es la columna del cuadrado medio. El *cuadrado medio* de la regresión, MSR , es la suma de los cuadrados de la regresión dividida entre su número de grados de libertad. De forma similar, el error cuadrático medio, MSE , es la suma de los cuadrados de los errores dividida entre su número de grados de libertad.

TABLA 6-4 Tabla ANOVA para la regresión de línea recta

<i>Fuente</i>	<i>Suma de cuadrados</i>	<i>df</i>	<i>Cuadrado medio</i>
Regresión	SSR	1	$MSR = SSR/1$
Error	SSE	$n-2$	$MSE = SSE/(n-2)$
Total	SST	$n-1$	

TABLA 6-5 Residuos de los datos del señor Bump con el factor de predicción $\bar{Y}$ para el ejemplo 6.5

<i>Y real</i>	<i>Y pronosticada ($\bar{Y}$)</i>	<i>Residuo ($Y - \bar{Y}$)</i>	$(Y - \bar{Y})^2$
10	11.2	-1.2	1.44
6	11.2	-5.2	27.04
5	11.2	-6.2	38.44
12	11.2	.8	.64
10	11.2	-1.2	1.44
15	11.2	3.8	14.44
5	11.2	-6.2	38.44
12	11.2	.8	.64
17	11.2	5.8	33.64
20	11.2	8.8	77.44
		Totales	233.60
			0.0

Observe que en la ecuación 6.7 el error cuadrático medio es

$$MSE = \frac{SSE}{n - 2} = \frac{\sum (Y - \hat{Y})^2}{n - 2} = s_{y \cdot x}^2$$

el cuadrado del error estándar de la estimación. Las razones de los cuadrados medios se utilizarán más adelante con otra finalidad en este capítulo.

Ejemplo 6.5

El análisis del señor Bump se inició con el conocimiento tan sólo de 10 cantidades del volumen de ventas semanales (la variable Y). Si no hubiera más información disponible, el señor Bump podría utilizar el promedio muestral, $\bar{Y} = 11.2$, como un factor de predicción de los galones de leche vendidos cada semana. Los errores, o residuos, asociados con este pronóstico son $Y - \bar{Y}$, y la suma de los errores cuadráticos es $\sum (Y - \bar{Y})^2$. Observe que esta última cantidad, $\sum (Y - \bar{Y})^2$, es exactamente SST , la suma total de cuadrados que se introdujo en la ecuación 6.12. Por lo tanto, SST mide la variabilidad de Y alrededor de un factor de predicción que usa sólo los valores Y en sus cálculos.⁶ Los pronósticos ($\bar{Y}$), los residuos ($Y - \bar{Y}$), y la suma total de cuadrados ($SST = \sum (Y - \bar{Y})^2$) se muestran en la tabla 6-5.⁷

El señor Bump también tiene información acerca de una variable X , el precio por galón de leche, que está relacionada con Y , el volumen semanal de leche vendida. (Recuerde el ejemplo 6.1, donde $r = -.86$). Con esta variable adicional, él espera explicar parte de la variación (diferencias) de los valores de Y más allá de lo que explica el factor de predicción, $\bar{Y}$.

En el ejemplo 6.2, la línea ajustada a la gráfica de dispersión de las observaciones X - Y tiene la ecuación $\hat{Y} = 32.14 - 14.54X$. Se puede construir una tabla similar a la tabla 6-5, si se usa $\hat{Y}$ para predecir Y . El resultado es la tabla 6-6.⁸

Una comparación de las tablas 6-5 y 6-6 indica que el uso de $\hat{Y}$ como factor de predicción de Y tiene como resultado residuos generalmente más pequeños (en valor absoluto) y una suma de cuadrados residual (error) considerablemente menor que cuando se usa $\bar{Y}$ como factor de predicción. El uso de la variable relacionada X reduce los errores de predicción o pronóstico. Es decir, el conocimiento de X ayuda a explicar aún más las diferencias en las Y . ¿Qué tanto ayuda X ? La descomposición de la variabilidad ofrece una respuesta a esta pregunta.

⁶Si el análisis se detuviera en este punto, la variabilidad de Y se mediría por la varianza muestral, $s_y^2 = \sum (Y - \bar{Y})^2 / (n - 1)$, en vez de $SST = \sum (Y - \bar{Y})^2$. La varianza muestral es la medida habitual de variabilidad para mediciones de una variable individual.

⁷Los residuos, $Y - \bar{Y}$, siempre suman cero porque el promedio $\bar{Y}$ es el centro matemático de los valores de Y .

⁸Si se incluye un término de intersección en la ecuación de regresión, la suma de los residuos $\sum (Y - \hat{Y})$ siempre es cero.

TABLA 6-6 Residuos de los datos del señor Bump con el factor de predicción $\hat{Y}$ para el ejemplo 6.5

X	Y	$Y(\hat{Y})$ pronosticada usando $\hat{Y} = 32.14 - 14.54X$	Residual ($Y - \hat{Y}$)	($Y - \hat{Y}$) ²
1.30	10	13.238	-3.238	10.48
2.00	6	3.060	2.940	8.64
1.70	5	7.422	-2.422	5.87
1.50	12	10.330	1.670	2.79
1.60	10	8.876	1.124	1.26
1.20	15	14.692	.308	.09
1.60	5	8.876	-3.876	15.02
1.40	12	11.784	.216	.05
1.00	17	17.600	-.600	.36
1.10	20	16.146	3.854	14.85
			Totales 0.000	59.41

De acuerdo con las tablas 6-5 y 6-6 y la ecuación 6-12,

$$SST = \Sigma(Y - \bar{Y})^2 = 233.60$$

$$SSE = \Sigma(Y - \hat{Y})^2 = 59.41$$

y, en consecuencia,

$$SSR = \Sigma(\hat{Y} - \bar{Y})^2 = 233.60 - 59.41 = 174.19$$

La descomposición de la variabilidad es

SST	=	SSR	+	SSE
233.60	=	174.19	+	59.41
Variación total		Variación explicada		Variación no explicada

De la variabilidad restante después del pronóstico de Y con $\bar{Y}$, el señor Bump ve que una proporción

$$\frac{SSR}{SST} = \frac{174.19}{233.60} = .75$$

de ella ha sido explicada por la relación de Y con X . Una proporción, $1 - .75 = .25$, de la variación de Y con respecto a $\bar{Y}$ permanece sin explicación. Desde esta perspectiva, el conocimiento de la variable relacionada X da como resultado mejores predicciones de Y de las que pueden obtenerse a partir de $\bar{Y}$, una cantidad que no depende de X .

La descomposición de la variabilidad de los datos del señor Bump puede obtenerse a partir del análisis de una tabla de varianza, como se demuestra en el siguiente ejemplo.

Ejemplo 6.6

El señor Bump construye una tabla ANOVA para sus datos usando el formato de la tabla 6-4 y los cálculos de las sumas de los cuadrados del ejemplo 6.5, como se indica en la tabla 6-7.

La descomposición de la variabilidad se presenta claramente en la columna de la suma de cuadrados. Observe que, dentro del redondeo del error, $MSE = 7.43 = (2.72)^2 = s_{y \cdot x}^2$.

TABLA 6-7 Tabla ANOVA de los datos del señor Bump para el ejemplo 6.6

<i>Fuente</i>	<i>Suma de cuadrados</i>	<i>df</i>	<i>Cuadrado medio</i>
Regresión	174.19	1	174.19
Error	59.41	8	7.43
Total	233.60	9	

COEFICIENTE DE DETERMINACIÓN

La identidad

$$(Y - \bar{Y}) = (\hat{Y} - \bar{Y}) + (Y - \hat{Y})$$

conduce a la descomposición de la varianza dada por la ecuación 6.12 y se muestra gráficamente para la línea de regresión ajustada del señor Bump y un punto de datos hipotético en la figura 6-5.

Si Y no dependiera de X , el señor Bump esperaría que Y estuviera cerca de $\bar{Y}$ y que la desviación $Y - \bar{Y}$ sencillamente reflejara la variación aleatoria. Sin embargo, Y depende de X de una manera sugerida por la función de regresión ajustada. En la figura, el valor observado X es mayor que $\bar{X}$, y se sabe que X y Y tienen una correlación negativa bastante fuerte ($r = -.86$). De la distancia vertical total $Y - \bar{Y}$, la cantidad $\hat{Y} - \bar{Y}$ es “explicada”, por lo tanto, por la variación de X , mientras que la distancia vertical restante, $Y - \hat{Y}$, “no se explica” por el movimiento de X .

Como se indicó en la sección anterior, SST mide la variación total alrededor de $\bar{Y}$, y la parte del total que se explica por la variación de X es SSR . La variación restante o no explicada es el SSE . La razón entre la variación explicada y la variación total se llama *coeficiente de determinación* de la muestra y se representa por r^2 .




FIGURA 6-5 Variación explicada y variación no explicada en los datos del señor Bump

$$\begin{aligned}
 r^2 &= \frac{\text{Variación explicada}}{\text{Variación total}} = \frac{SSR}{SST} = \frac{\sum(\hat{Y} - \bar{Y})^2}{\sum(Y - \bar{Y})^2} \\
 &= 1 - \frac{\text{Variación no explicada}}{\text{Variación total}} = 1 - \frac{SSE}{SST} = 1 - \frac{\sum(Y - \hat{Y})^2}{\sum(Y - \bar{Y})^2} \quad (6.14)
 \end{aligned}$$

El *coeficiente de determinación* mide el porcentaje de variabilidad de Y que se puede explicar a través del conocimiento de la variabilidad (diferencias) de la variable independiente X .

Ejemplo 6.7

El coeficiente de determinación, r^2 , para los datos del señor Bump se calculó en el ejemplo 6.5, aunque no se le llamó así. El coeficiente de determinación también se encuentra fácilmente disponible en la tabla ANOVA, es decir, la tabla 6-7, del ejemplo 6.6. Recuerde que

$$SST = \sum(Y - \bar{Y})^2 = 233.60$$

$$SSR = \sum(\hat{Y} - \bar{Y})^2 = 174.19$$

$$SSE = \sum(Y - \hat{Y})^2 = 59.41$$

y

$$r^2 = \frac{174.19}{233.60} = .746$$

De forma alternativa, r^2 puede calcularse como

$$r^2 = 1 - \frac{59.41}{233.60} = 1 - .254 = .746$$

Alrededor del 75% de la variabilidad en galones de leche vendida (Y) puede explicarse por las diferencias en el precio por galón (X). Alrededor del 25% de la variabilidad en la cantidad de leche vendida *no puede* explicarse por el precio. Esta porción de la variabilidad debe explicarse por factores que no se consideraron en este análisis de regresión (por ejemplo, la cantidad de publicidad, la disponibilidad de productos sustitutos o la calidad de la leche).

Para la regresión lineal, r^2 es el cuadrado de r , el coeficiente de correlación.

$$\text{Coeficiente de determinación} = (\text{Coeficiente de correlación})^2$$

$$r^2 = (r)^2$$


De manera que, para los datos del señor Bump e ignorando el redondeo del error,

$$.746 = (-.863)^2$$

¿Por qué es necesario identificar específicamente tanto r como r^2 en un análisis de regresión? La respuesta es que expresan información diferente.

El coeficiente de correlación revela la fortaleza y dirección de la relación lineal. En el caso de los datos que recopiló el señor Bump, existe una relación negativa ($r = -.86$). En otros casos, el valor de r podría estar indicando una relación positiva. Como veremos en el siguiente capítulo, es útil identificar la naturaleza de las relaciones que existen entre ciertos pares de variables cuando se está manejando un gran conjunto de variables. Observe que, cuando el coeficiente de correlación está elevado al cuadrado, el valor siempre es positivo, de manera que la naturaleza de la relación se pierde.

El coeficiente de determinación, r^2 , mide la fuerza de la relación entre Y y X de un modo diferente a como lo hace r . El valor de r^2 mide el *porcentaje* de variabilidad de Y que se explica

FIGURA 6-6 Valores extremos de r^2

por las diferencias de X . Esta útil interpretación se puede generalizar a las relaciones entre Y y más de una X .

La figura 6-6 ilustra los dos casos extremos para r^2 , $r^2 = 0$ y $r^2 = 1$. En el primer caso, *nada* de variabilidad de Y se explica por X : el diagrama de dispersión sugiere que no existe una relación lineal entre X y Y . Cuando $r^2 = 1$, *toda* la variabilidad de Y se explica cuando se conoce X : todos los puntos de datos muestrales se ubican sobre la línea de regresión ajustada.

PRUEBA DE HIPÓTESIS

La línea de regresión ajustada se genera por los valores X - Y de la *muestra*. El modelo estadístico de regresión lineal simple sugiere que la relación lineal entre Y y X se mantiene para *todas* las opciones de pares X - Y . Es decir, existe una relación verdadera entre X y Y de la forma $\mu_y = \beta_0 + \beta_1 X$. Dada la evidencia muestral, ¿podemos concluir que la relación verdadera se mantiene para todas las X y Y ?

Considere la hipótesis

$$H_0: \beta_1 = 0$$

donde β_1 es la pendiente de la línea de regresión de la población. Advierta que, si esta hipótesis es verdadera, no existe relación entre Y y X en la población. Por otro lado, si no se rechaza H_0 , significa que a pesar del hecho de que la muestra ha producido una línea ajustada con un valor diferente de cero para b_1 , debemos concluir que no hay suficiente evidencia para indicar que Y esté relacionada con X . Es decir, no podemos excluir la posibilidad de que la línea de regresión de la población sea plana (horizontal).⁹

¿Cómo es posible que β_1 sea cero mientras b_1 es diferente de cero? Considere la figura 6-7 donde se presenta una población de puntos de datos de los cuales se selecciona una muestra de cinco datos (los puntos de datos muestrales se indican mediante $\times$). Como lo sugiere el diagrama de dispersión, si se seleccionan suficientes puntos de datos muestrales, se hará obvio que la población de puntos de datos tiene una línea de regresión con pendiente cero. Sin embargo, los cinco puntos de datos seleccionados de manera aleatoria se ubican bastante cerca de una línea de regresión con tendencia ascendente. A partir de esta evidencia se podría concluir erróneamente que X y Y están relacionadas linealmente de manera positiva. Sin embargo, si se prueba la hipótesis $\beta_1 = 0$ con los datos muestrales, quizás no pueda rechazarla el encargado de efectuar el pronóstico.

⁹Una línea de regresión plana de la población (esto es, $\beta_1 = 0$) también es equivalente al enunciado $H_0: \rho = 0$, donde ρ es el coeficiente de correlación de la población.




FIGURA 6-7 Población y puntos de datos muestrales

Si $H_0: \beta_1 = 0$ es verdadera, el estadístico de prueba t con valor de $t = \frac{b_1}{s_{b_1}}$ tiene una distribución t con $df = n - 2$, donde S_{b_1} es la desviación estándar estimada (o error estándar) de b_1 , dado por $s_{b_1} = s_{y \cdot x} / \sqrt{\sum (X - \bar{X})^2}$.

Este resultado ofrece un modo de probar $H_0: \beta_1 = 0$, como se ilustra en el siguiente ejemplo.

Ejemplo 6.8

Al señor Bump le gustaría probar

$$H_0: \beta_1 = 0 \text{ (no hay relación lineal)}$$

contra

$$H_1: \beta_1 \neq 0 \text{ (una relación lineal con pendiente diferente de cero)}$$

Él calcula¹⁰

$$s_{b_1} = s_{y \cdot x} / \sqrt{\sum (X - \bar{X})^2} = 2.72 / \sqrt{.824} = 3.00$$

y formula la razón (estadístico de prueba)

$$t = \frac{b_1}{s_{b_1}} = \frac{-14.54}{3.00} = -4.8$$

¿El valor $t = -4.8$ es un resultado inusual si H_0 es verdadera? El señor Bump verifica t en la tabla para $n - 2 = 8$ grados de libertad y obtiene

$$t_{.005} = 3.355$$

$$t_{.025} = 2.306$$

Puesto que $|t| = 4.8 > 3.355$, el señor Bump rechaza H_0 para el nivel de significancia del 1%. Concluye que su regresión es significativa, puesto que $t = -4.8$ es sumamente improbable si H_0 es verdadera. Un valor t de esta magnitud se presentará menos de una vez en 100 si no existiera una relación lineal entre Y y X .

¹⁰Los valores usados en los siguientes cálculos se obtuvieron con anterioridad en este capítulo.

Para tamaños muestrales muy grandes, es posible rechazar H_0 y concluir que existe una relación lineal entre X y Y aun cuando r^2 sea pequeña, digamos, del 10%. De forma similar, para muestras pequeñas y una r^2 muy grande —digamos, del 95%— es posible concluir que la regresión es significativa. Una r^2 pequeña significa que es improbable que la ecuación de regresión ajustada tenga mucho poder de predicción. Por otro lado, una r^2 grande con un tamaño muestral muy pequeño podría dejar incómodo al analista y requerir mayor evidencia muestral antes de que la función ajustada se use para pronosticar. Puede haber una diferencia entre la significancia estadística y la significancia práctica. A veces, es necesario un buen juicio aparejado con conocimiento del tema para determinar si una función de regresión ajustada es una herramienta útil para pronosticar.

Una prueba alternativa de $H_0: \beta_1 = 0$ está disponible en la tabla ANOVA.

Si los supuestos del modelo estadístico de la regresión lineal son adecuados y si la hipótesis nula $H_0: \beta_1 = 0$ es verdadera, la razón

$$F = \frac{\text{Cuadrado medio de la regresión}}{\text{Error cuadrático medio}} = \frac{MSR}{MSE} \quad (6.15)$$

tiene una distribución F con $df = 1, n - 2$. Cuando H_0 es verdadera, tanto el MSR como el MSE son estimadores de σ^2 , la varianza del término de error (ε) en el modelo estadístico de regresión de línea recta. Por otro lado, si $H_0: \beta_1 \neq 0$ es verdadera, el numerador F en la razón tiende a ser mayor que el denominador. De esta forma, razones grandes de F son congruentes con la hipótesis alternativa.

En el modelo de regresión de línea recta, la prueba de la hipótesis $H_0: \beta_1 = 0$ contra $H_0: \beta_1 \neq 0$ puede apoyarse en la razón $F = \frac{MSR}{MSE}$ con $df = 1, n - 2$. En el nivel α , la región de rechazo es $F > F_\alpha$.

Como se discutirá en el próximo capítulo, la prueba F se puede extender para verificar la significancia de los modelos de regresión con más de una variable independiente.

Ejemplo 6.9

La tabla 6-7 es la tabla ANOVA para los datos del señor Bump. En esta tabla,

$$F = \frac{MSR}{MSE} = \frac{174.19}{7.43} = 23.4$$

y con $\delta_1 = 1$ y $\delta_2 = 8$ grados de libertad

$$F_{.05} = 5.32$$

$$F_{.01} = 11.26$$

Puesto que $F = 23.4 > 11.26$, $H_0: \beta_1 = 0$ se rechaza con un nivel del 1%. La regresión es significativa.

No es accidental que los resultados de la prueba F sean congruentes con los resultados de la prueba t del ejemplo 6.8. De hecho, dentro del error de redondeo,

$$F = 23.4 = (-4.8)^2 = t^2$$

Más aún,

$$F_{.01} = 11.26 = (3.355)^2 = (t_{.005})^2$$

Así, para un nivel de significancia dado, la prueba t rechaza $H_0: \beta_1 = 0$ siempre que la prueba F la rechace y viceversa. Esta relación entre las pruebas t y F se cumple sólo para el modelo de regresión de línea recta.

El estadístico F también puede expresarse en términos del coeficiente de determinación, r^2 .

$$F = \frac{r^2(n - 2)}{1 - r^2} \quad (6.16)$$

Si todo lo demás permanece igual, el valor de F se incrementa conforme r^2 aumenta. Cuanta mayor sea la cantidad de variación de Y que tenga explicación mediante la función de regresión ajustada, más probabilidad hay de que la prueba F considere a la regresión como significativa.

ANÁLISIS DE RESIDUOS

El ajuste de un modelo por los mínimos cuadrados, la construcción de intervalos de predicción y la prueba de hipótesis no completan un estudio de regresión. Estos pasos son sólo la mitad de la historia: las inferencias que pueden hacerse *cuando el modelo supuesto es adecuado*. En la mayoría de los estudios no resulta obvio cuál es el modelo correcto.

Las inferencias suelen ser muy engañosas si los supuestos realizados en la formulación del modelo son extremadamente incompatibles con los datos. Es esencial verificar con cuidado los datos para obtener indicios de cualquier violación de los supuestos. Recuerde que los supuestos del modelo de regresión de línea recta son los siguientes:

1. La relación entre las variables es lineal.
2. Los errores son independientes.
3. Los errores tienen una varianza constante.
4. Los errores están distribuidos normalmente.

La información sobre la variación que no puede explicarse mediante la función de regresión ajustada está contenida en los residuos, $e = Y - \hat{Y}$. Para calificar los méritos de un modelo tentativo, podemos examinar los residuos graficándolos de varias maneras.

1. Grafique un histograma de los residuos.
2. Grafique los residuos contra los valores ajustados.
3. Grafique los residuos contra la variable explicativa.
4. Grafique los residuos en el tiempo si los datos son cronológicos.

Un histograma de los residuos permite verificar el supuesto de normalidad. Comúnmente, las desviaciones moderadas de una curva en forma de campana no afectan las conclusiones de las pruebas o los intervalos de predicción basados en la distribución t , particularmente si el conjunto de datos es grande. Por lo regular, una violación del supuesto de normalidad no es tan seria como una violación de cualquier otro de los supuestos.

Si una gráfica de los residuos contra los valores ajustados indica que la naturaleza general de la relación entre Y y X forma una curva en vez de una línea recta, una transformación conveniente de los datos puede reducir una relación no lineal a una que sea aproximadamente lineal. Examinaremos las transformaciones de las variables en una sección posterior de este capítulo.

Una transformación también ayuda a estabilizar la varianza. La figura 6-8 presenta una gráfica residual que indica que la dispersión de los residuos se incrementa conforme la magnitud de los valores ajustados aumenta. Es decir, la variabilidad de los puntos de datos alrededor de la línea de los mínimos cuadrados es más grande para valores ajustados de Y grandes que para valores pequeños. Esto implica que tal vez no se cumpla el supuesto de la varianza constante. En esta situación, relacionar el logaritmo de Y con X puede generar una relación residual que sea más congruente con una varianza constante.

El supuesto de independencia es el más importante. La falta de independencia podría distorsionar en forma drástica las conclusiones obtenidas de las pruebas t . El supuesto de independencia es particularmente riesgoso en los datos de las series de tiempo, que son frecuentes en problemas de pronósticos económicos y de negocios.




FIGURA 6-8 Una gráfica residual con dispersión creciente

Para los residuos de las series de tiempo —es decir, para los residuos que se producen al usar métodos de regresión con datos ordenados en el tiempo— la independencia puede verificarse con una gráfica de los residuos en el tiempo. No debe haber patrones sistemáticos, tales como una sucesión de valores altos seguida de una sucesión de valores bajos. Además, las autocorrelaciones muestrales de los residuos

$$r_k(e) = \frac{\sum_{t=k+1}^n e_t e_{t-k}}{\sum_{t=1}^n e_t^2} \quad k = 1, 2, \dots, K \quad (6.17)$$

donde n es el número de residuos y K comúnmente es $n/4$, deberían ser todas pequeñas. En particular, la independencia existe si los coeficientes de autocorrelación residual se encuentran todos en el intervalo $0 \pm 2/\sqrt{n}$ para todos los retrasos de tiempo k .

Ejemplo 6.10

Usando los valores ajustados y los residuos presentados en la tabla 6-6, el señor Bump construyó un histograma de los residuos y una gráfica de los residuos contra los valores ajustados. Éstos y otros resultados se presentan en la figura 6-9.

El histograma está centrado en cero y, si bien es simétrico, no parece tener forma de campana. Sin embargo, con sólo 10 observaciones, un histograma como el ilustrado en la figura 6-9 no es raro para datos con distribución normal. El supuesto de normalidad parece razonable.

Los puntos en la gráfica de probabilidad normal de la figura 6-9 se ubican muy cerca de la línea recta. Como señalamos en el capítulo 2, este comportamiento como línea recta sugiere un buen ajuste entre los datos (en este caso, los residuos) y una distribución normal. La gráfica de probabilidad normal sugiere que no hay razón para dudar del supuesto de normalidad.

La segunda gráfica de la primera fila en la figura 6-9 también se ve bien. Cuando se grafican los residuos contra los valores ajustados, la dispersión alrededor del cero en la dirección vertical debe ser aproximadamente igual para todos los valores a lo largo del eje horizontal. Es decir, las magnitudes de los residuos para valores ajustados pequeños deben ser aproximadamente iguales que las magnitudes de los residuos para valores ajustados intermedios y aproximadamente iguales que las magnitudes de los residuos para valores ajustados grandes. Este comportamiento ideal sugiere dos cosas: **1.** La relación subyacente entre Y y X es lineal, y **2.** la variabilidad del error es constante (las Y para diferentes valores de X tienen la misma dispersión alrededor de la línea de regresión).

El señor Bump está contento de que la gráfica de los residuos contra los valores ajustados no esté “arqueada” —por ejemplo, con una sucesión de residuos positivos seguida de una sucesión de residuos negativos, seguida, a la vez, de una sucesión de residuos positivos. Este comportamiento




FIGURA 6-9 Gráficas residuales de los datos del señor Bump para el ejemplo 6.10

sugeriría una relación no lineal entre Y y X . Él también está complacido porque su gráfica no tiene la forma cónica como la de la gráfica de la figura 6-8, lo cual indica variabilidad inconstante (creciente).

Si bien las Y representan ventas semanales de leche, las semanas fueron seleccionadas al azar y no estaban ordenadas en el tiempo. Por consiguiente, la graficación de los residuos en el tiempo o el cálculo de las autocorrelaciones residuales no eran apropiados.

El señor Bump está satisfecho con su análisis residual. Considera que su modelo de regresión de línea recta describe adecuadamente la relación entre el volumen de las ventas semanales y el precio.

RESULTADO DE COMPUTADORA

El problema del análisis de regresión del señor Bump (con los datos de la tabla 6-1) se corre en Minitab (para instrucciones específicas, véase la sección de aplicaciones de Minitab al final del capítulo), y la salida se presenta en la tabla 6-8.

Para explicar la terminología usada en el resultado de la computadora, se presentan las definiciones y los cálculos en la siguiente lista. Estas definiciones y cálculos se teclearon para obtener la tabla 6-8.

1. Correlación = $-.86$. El coeficiente de correlación (r) de la muestra indica la relación entre X y Y , es decir, precio y ventas, respectivamente.
2. El coeficiente de regresión (Coef) = -14.54 . Este valor (b_1) es el cambio de Y (las ventas) cuando X (el precio) se incrementa en una unidad. Cuando el precio aumenta \$1, las ventas estimadas disminuyen en 14,539 unidades.

TABLA 6-8 Resultado de Minitab para los datos del señor Bump

Correlations: Sales, Price

Pearson correlation of Sales (Y) and Price (X) = - 0.863 (1)

Regression Analysis: Sales versus Price

The regression equation is

Sales (Y) = 32.1 - 14.5 Price (X) (5) and (2)

Predictor	Coef	SE Coef	T	P
Constant	32.136 (5)	4.409	7.29	0.000
Price (X)	-14.539 (2)	3.002 (3)	-4.84 (4)	0.001 (7)

S = 2.72545 (6) R-Sq = 74.6% (8) R-Sq(adj) = 71.4% (9)

Analysis of Variance

Source	DF	SS	MS	F	P
Regression	1	174.18	174.18	23.45 (12)	0.001
Residual Error	8	59.42 (10)	7.43 (6)		
Total	9	233.60 (11)			

3. El error estándar del coeficiente de regresión (SE Coef) = 3.0. Este valor es la estimación de la desviación estándar del valor del coeficiente de regresión (b_1).

$$s_{b_1} = s_{y \cdot x} / \sqrt{\sum (X - \bar{X})^2} = 2.725 / \sqrt{.824} = 2.725 / .908 = 3.002$$

4. Se calcula el valor de $t = -4.84$. El valor de t calculado se utiliza para probar si el coeficiente de regresión de la población (β_1) es significativamente diferente de cero.

$$t = \frac{b_1}{s_{b_1}} = \frac{-14.54}{3.002} = -4.84$$

5. La constante = 32.14. Este valor es la intersección con Y (b_0). Por lo tanto, la ecuación completa de regresión es

$$\hat{Y} = 32.14 - 14.54X$$

6. El error estándar de la estimación = 2.725. El error estándar de la estimación indica que los valores de Y caen generalmente a una distancia de unas 2.725 unidades de la línea de regresión.

$$s_{y \cdot x} = \sqrt{\frac{\sum (Y - \hat{Y})^2}{n - 2}} = \sqrt{\frac{SSE}{n - 2}} = \sqrt{MSE} = \sqrt{7.43} = 2.725$$

7. El valor p , .001, es la probabilidad de obtener un valor t tan grande como $|t| = |-4.84| = 4.84$ por azar si $H_0: \beta_1 = 0$ es verdadera. Puesto que el valor p es extremadamente pequeño, se concluye que el coeficiente de la pendiente de la regresión es significativamente diferente de 0.

8. $r^2 = (R - Sq) = .746$. La línea de regresión ajustada explica el 74.6% de la varianza en el volumen de las ventas.

$$r^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} = 1 - \frac{59.42}{233.60} = 1 - .254 = .746$$

9. La r^2 ajustada ($R-Sq(adj)$) = .714. Se ajusta la r^2 para los grados de libertad adecuados.

$$\begin{aligned}\bar{r}^2 &= 1 - \frac{\Sigma(Y - \hat{Y})^2/(n - 2)}{\Sigma(Y - \bar{Y})^2/(n - 1)} = 1 - \frac{SSE/(n - 2)}{SST/(n - 1)} = 1 - \frac{59.42/8}{233.60/9} \\ &= 1 - \frac{7.428}{25.956} = 1 - .286 = .714\end{aligned}$$

10. La suma residual de cuadrados (Error residual) = 59.42. La suma de residuos al cuadrado es la suma de las diferencias al cuadrado entre las Y reales y las Y pronosticadas ($\hat{Y}$'s).

$$SSE = \Sigma(Y - \hat{Y})^2 = 59.42$$

11. Suma total de cuadrados = 233.60. Este valor es la suma de las desviaciones al cuadrado de las Y con respecto a su media.

$$SST = \Sigma(Y - \bar{Y})^2 = 233.60$$

12. El análisis de la varianza y la razón F : La razón F ($23.45 = 174.18/7.43$) en esta tabla ANOVA prueba la hipótesis nula de que la regresión no es significativa; es decir, $H_0: \beta_1 = 0$. Un valor F grande permitirá el rechazo de esta hipótesis, sugiriendo una regresión *significativa*. El valor F (23.45) aumenta conforme una porción más grande de la suma total de las desviaciones al cuadrado (SST) se explica por la regresión. En este caso, el valor tabulado de F ($df = 1, 8; \alpha = .01$) es 11.26. La hipótesis de regresión no significativa con un nivel de significancia del 1% se rechaza, puesto que $F = 23.45 > 11.26$. (Véase el ejemplo 6.9).

TRANSFORMACIONES DE VARIABLES

Si bien el modelo de regresión lineal simple supone una relación lineal entre X y Y , en general, un modelo de regresión lineal se refiere a un modelo que es lineal en la incógnita β . Siempre que la función de regresión sea lineal en las β (por ejemplo, no está presente), las variables de predicción (las X) pueden adoptar varias formas y entonces la metodología de regresión estándar sigue siendo adecuada. Es posible utilizar los modelos de regresión para modelar relaciones complejas entre Y y X (o varias X), o bien, para modelar una relación lineal entre Y y alguna función (transformación) de X .

Cuando un diagrama de dispersión indica que existe una relación no lineal entre Y y X , existen dos métodos básicos para tratar este caso. El primero consiste en ajustar los datos a una función de regresión que se grafique como una curva y utilizar la función ajustada para elaborar el pronóstico. El segundo método implica la transformación de la variable X a otra forma, de manera que la relación resultante con Y sea lineal.

Cuatro de las transformaciones más comunes (funciones) que se emplean para generar nuevas variables de predicción son el recíproco, el logaritmo, la raíz cuadrada y el cuadrado.

$$\frac{1}{X}, \log X, \sqrt{X}, X^2$$

Cuando cada una de estas variables se grafica contra Y , se espera que la relación no lineal entre Y y X se convierta en una relación lineal entre Y y una de las X transformadas. Si es así, Y y esta nueva variable pueden tratarse con el modelo lineal explicado en este capítulo, incluyendo el cálculo del coeficiente de correlación y la ecuación de regresión ajustada.

En el siguiente ejemplo se usa Minitab (véase la sección de aplicaciones de Minitab al final del capítulo) para graficar una relación simple entre X y Y que parece ser no lineal. Entonces se dan instrucciones al programa para que calcule las cuatro transformaciones descritas anteriormente. Luego, estas variables se grafican contra Y para generar los puntos de datos que se indican.

Ejemplo 6.11



Gilbert García posee una cadena de ferreterías en Chicago, Illinois. Él está interesado en predecir sus ventas mensuales usando el conocimiento que tiene acerca de los gastos de publicidad mensual correspondientes. Gil sospecha que las ventas se incrementarán conforme la cantidad gastada en publicidad se incremente. Sin embargo, también cree que después de cierto punto, las ventas empezarán a incrementarse a un ritmo más lento. Gil siente que, después de gastar cierta cantidad en publicidad, alcanzará un punto donde se obtendrán pocas ventas a partir de gastos ulteriores en publicidad.

A partir de los registros de la compañía, Gil seleccionó una muestra aleatoria de datos de 14 meses. Los datos aparecen en la figura 6-10, mientras que el diagrama de dispersión de los datos se presenta en la figura 6-11. Gil advierte que las ventas parecen nivelarse después de que se gasta cierta cantidad en publicidad. Ajusta la ecuación de regresión lineal presentada en la figura 6-12 y se percata de que la ecuación explica el 77.7% de la variabilidad en las ventas.

En la figura 6-13 se observa una gráfica de los residuos contra los valores ajustados de la línea recta ajustada. Esta gráfica indica que una línea recta no describe adecuadamente la relación entre las ventas y los gastos de publicidad. Todos los residuos son negativos para pequeños valores pronosticados, todos son positivos para los valores pronosticados de nivel medio, y todos son negativos otra

	C1	C2	C3	C4	C5	C6	C7	C8	C9	C10
	Sales	Expenditures	LOGX	SQRTX	X*X	1/X				
1	1.1	3.9	1.36098	1.97484	15.21	0.256410				
2	1.7	4.9	1.58924	2.21359	24.01	0.204082				
3	2.6	7.6	2.02815	2.75681	57.76	0.131579				
4	2.4	6.8	1.91692	2.60768	46.24	0.147059				
5	2.3	5.9	1.77495	2.42899	34.81	0.169492				
6	2.9	9.1	2.20827	3.01662	82.81	0.109890				
7	0.4	3.4	1.22378	1.84391	11.56	0.294118				
8	3.2	11.6	2.45101	3.40588	134.56	0.086207				
9	3.3	14.1	2.64617	3.75500	198.81	0.070922				
10	3.1	14.9	2.70136	3.86005	222.01	0.067114				
11	3.2	10.5	2.35138	3.24037	110.25	0.095238				
12	3.0	9.9	2.29253	3.14643	98.01	0.101010				
13	3.7	17.1	2.83908	4.13521	292.41	0.058480				
14	3.3	12.4	2.51770	3.52136	153.76	0.080645				
15										

FIGURA 6-10 Datos para el ejemplo 6.11

**FIGURA 6-11** Diagrama de dispersión para el ejemplo 6.11**FIGURA 6-12** Línea de regresión ajustada para el ejemplo 6.11

vez para valores pronosticados grandes. Los residuos no están distribuidos de manera uniforme alrededor de la línea de regresión estimada. Se ve claramente que una línea recta no refleja la curvatura de los datos.

Luego, Gil considera varias transformaciones de X (véase la figura 6-10). Construye un diagrama de dispersión múltiple con gráficas de las ventas (Y) contra los logaritmos de los gastos en publicidad ($\log X$), ventas (Y) contra las raíces cuadradas de los gastos en publicidad ($\sqrt{X}$), ventas




FIGURA 6-13 Gráfica de residuos contra valores ajustados para la línea recta ajustada del ejemplo 6.11

(Y) contra los gastos en publicidad elevados al cuadrado (X^2) y, finalmente, ventas (Y) contra los recíprocos de los gastos en publicidad ($1/X$). El resultado se presenta en la figura 6-14.

Después de examinar el diagrama de dispersión múltiple, Gil concluye que las relaciones entre las ventas y los logaritmos de gastos en publicidad, las ventas y las raíces cuadradas de gastos en publicidad, y las ventas y los gastos en publicidad elevados al cuadrado muestran todos algún grado de curvatura. Estas relaciones no son lineales. Sin embargo, la relación entre las ventas y los recíprocos de los gastos en publicidad parece ser lineal con una pendiente negativa. Usando Minitab, Gil ajusta un modelo de regresión lineal simple a los datos de las ventas y los recíprocos de los gastos en publicidad. Así, determina la ecuación ajustada $\hat{Y} = 4.29 - 12.7(1/X)$, como se presenta en la tabla 6-9, y ve que r^2 es igual al 98.1%. Un análisis residual indica que este modelo lineal es apropiado.

CURVAS DE CRECIMIENTO

Las curvas de crecimiento se presentaron en el capítulo 5 (véase la figura 5-7) en nuestro estudio para modelar la tendencia en la descomposición de una serie de tiempo. A menudo, la tendencia (cambio a largo plazo) es de interés por sí misma. Un analista, por ejemplo, tal vez esté interesado en la proyección de los costos del uso de la computadora hasta bien entrado el futuro sin considerar la tecnología que podría traer cambios en el costo. Como otro ejemplo, un analista de seguros de vida quizás esté interesado en proyecciones a largo plazo de la expectativa de vida de la población de Estados Unidos sin considerar las condiciones económicas y ambientales que podrían ser responsables de cambios en la expectativa de vida.

Las curvas de crecimiento son relaciones curvilíneas entre la variable de interés y el tiempo. Las curvas de crecimiento se ajustan comúnmente a los datos anuales, puesto que en estos casos se requieren pronósticos a largo plazo.

Aun cuando los pronósticos son probablemente imprecisos cuando los ajustes de las curvas de crecimiento a los datos históricos son extrapolados para predecir el futuro, este método de pronóstico puede ser de gran ayuda para los administradores, puesto que concentra su atención en aspectos a largo plazo de los negocios. Más aún, las curvas de crecimiento indican la tasa anual de crecimiento que debe mantenerse con la finalidad de alcanzar los niveles proyectados




FIGURA 6-14 Diagrama de dispersión de ventas (Y) contra $a)$ $\log X$, $b)$ raíz cuadrada de X , $c)$ X al cuadrado y $d)$ recíproco de X

TABLA 6-9 Resultado de Minitab para el ejemplo 6-11

Regression Analysis: Sales versus 1/X

The regression equation is

$$\text{Sales} = 4.29 - 12.7 \, 1/X$$

Predictor	Coef	SE Coef	T	P
Constant	4.28587	0.07695	55.69	0.000
1/X	-12.7132	0.5092	-24.97	0.000

S = 0.134159 R-Sq = 98.1% R-Sq(adj) = 98.0%

Analysis of Variance

Source	DF	SS	MS	F	P
Regression	1	11.221	11.221	623.44	0.000
Residual Error	12	0.216	0.018		
Total	13	11.437			

para el futuro. Esta tasa de crecimiento anual puede o no ser razonable y tal vez sea motivo de debate en una reunión de ejecutivos o en un “comité de expertos”.

Si una variable medida en el tiempo se incrementa en el mismo *porcentaje* cada periodo, se dice que presenta un *crecimiento exponencial*. Si una variable se incrementa en la misma *cantidad* cada periodo, se dice que registra un *crecimiento lineal*. Algunas veces una transformación simple convierte una variable con crecimiento exponencial en una variable con crecimiento lineal. Si éste es el caso, los métodos de regresión presentados en este capítulo servirán para modelar el crecimiento exponencial.

Por ejemplo, suponga que una variable Y , medida anualmente, sigue la curva de tendencia exponencial (véase la ecuación 5.6).

$$Y = b_0 b_1^t$$

Aquí, $100(b_1 - 1)\%$ es el incremento porcentual anual de Y . Tomando los logaritmos de ambos lados de la ecuación de la tendencia exponencial, tenemos

$$\log Y = \log(b_0 b_1^t) = \log b_0 + t \log b_1 = \tilde{b}_0 + \tilde{b}_1 t$$

Así, $\log Y$ contra el tiempo (t) grafica una línea recta con pendiente $\tilde{b}_1 = \log b_1$ e intersección $\tilde{b}_0 = \log b_0$. $\log Y$ se incrementa una cantidad constante, $\tilde{b}_1$, de un año a otro. Como se ilustra en el siguiente ejemplo, es posible obtener los pronósticos de Y y una estimación de la tasa de crecimiento, b_1 , a partir de la ecuación de la línea recta que relaciona $\log Y$ con t .

Ejemplo 6.12

Jill Johnson, la asistente administrativa de una universidad importante, está contenta con la aprobación de un sistema de inscripciones por Internet para los cursos. Ella recolectó los datos de la tabla 6-10 y ve que el uso del sistema ha crecido de forma increíble. Si la tasa actual de crecimiento continúa, todo el campus estará registrándose por Internet para los cursos dentro de un año y el sistema anterior de inscripciones por teléfono se eliminará por completo.

Los datos de la tabla 6-10 indican los números de estudiantes que usan el sistema de inscripciones por Internet para el periodo de 2002 a 2006. La última columna de la tabla contiene los logaritmos de base 10 de los números de usuarios.


Jill ha tenido alguna experiencia con la regresión lineal simple y se pregunta si este método servirá para pronosticar el número de usuarios en 2007 y para hacer una estimación de la tasa de crecimiento anual. Una gráfica del número de usuarios contra el año (véase la figura 6-15a) rápidamente le sugiere a Jill que un modelo de regresión lineal simple no es adecuado para sus datos. El crecimiento del uso parece ser exponencial, con un incremento porcentual anual de alrededor del 70%. Sin embargo, el aumento en el número de usuarios cada año es completamente diferente. Los incrementos varían en magnitud desde una modesta cifra de 2,500 durante el periodo de 2002 a 2003 a una cifra considerable de 10,000 durante el periodo de 2005 a 2006.

Jill siempre ha sido buena manejando logaritmos y recuerda que un cambio porcentual constante en una variable durante cierto periodo es equivalente a un incremento constante en la magnitud del logaritmo de la variable durante el mismo periodo de tiempo. Con esto en mente, Jill transforma los números de las inscripciones por Internet de los usuarios a los cursos tomando sus logaritmos; luego, grafica los logaritmos (usuarios) contra el año (véase la figura 6-15b).


Como ella sospechaba, cuando los números de los usuarios se transforman usando sus logaritmos, el crecimiento exponencial se convierte en un crecimiento lineal. La curva que representa el crecimiento exponencial en la figura 6-15a se convierte en una línea en la figura 6-15b) gracias a la transformación logarítmica. En la figura 6-15b), el incremento en la magnitud de los logaritmos (usuarios) cada año es aproximadamente el mismo, alrededor de .23 por año. Jill ajusta una línea recta a los datos de la figura 6-15b) con los logaritmos (usuarios) como la variable dependiente Y y el tiempo (t) como la variable independiente. Los resultados se presentan en la figura 6-16.

TABLA 6-10 Datos para el ejemplo 6.12

<i>Año</i>	<i>Tiempo</i>	<i>Usuarios</i>	<i>Log (Usuarios)</i>
2002	1	3,000	3.477
2003	2	5,500	3.740
2004	3	9,000	3.954
2005	4	16,500	4.217
2006	5	26,500	4.423



a)



b)

FIGURA 6-15 Diagramas de dispersión de los datos de Jill Johnson para el ejemplo 6.12

Jill calcula el pronóstico para el año de 2007 usando la ecuación ajustada $\log \hat{Y} = 3.252 + .2369t$ con $t = 6$:

$$\log \hat{Y}_{2007} = 3.252 + .2369(6) = 4.673$$

$$\hat{Y}_{2007} = 10^{4.673} = 47,100$$

Jill pronostica que 47,100 estudiantes usarán el sistema de inscripción por Internet en 2007. Puesto que la universidad espera una matrícula total de 45,000 estudiantes, Jill concluye que probablemente todos los estudiantes van a usar el nuevo sistema de inscripciones a los cursos y que el sistema telefónico anterior puede descontinuarse.

Finalmente, Jill calcula que la tasa de crecimiento anual de los usuarios del sistema de inscripciones por Internet es

$$100(\text{antilog}(.2369) - 1)\% = 100(10^{.2369} - 1)\% = 100(1.725 - 1)\% = 72.5\%$$

Jill admite que con la capacidad de inscripción de la universidad, no tiene sentido extrapolar el aumento del número de usuarios del sistema de inscripción por Internet más allá de 2007.

En algunas situaciones, una curva de crecimiento lineal puede ajustarse directamente a los datos originales.




FIGURA 6-16 Línea ajustada de regresión para el ejemplo 6.12

Ejemplo 6.13

Suponga que en 1999 una compañía relacionada con la prestación de servicios de salud para personas mayores está interesada en una proyección a largo plazo de la expectativa de vida en el momento del nacimiento en Estados Unidos, de manera que pueda formular una estrategia corporativa de largo plazo. La compañía obtiene proyecciones de esta variable desde 1970 a 1997 del *Statistical Abstract of the United States*. Estos datos se presentan en la tabla 6-11. Después de codificar los años como 1 = 1970, 2 = 1971, ..., 28 = 1997 y teclear los datos en Minitab, la rutina Regresión-Gráfica de línea ajustada produce la gráfica de la figura 6-17.

La compañía no está interesada en examinar las razones de un incremento obvio en la longevidad durante varios años pasados, sino en una proyección lejana en el futuro de la línea de regresión ajustada. Tampoco está interesada en especular acerca de si la tendencia ascendente continuará, o por qué medios se podría alcanzar un incremento como éste. Sólo quiere completar el siguiente enunciado: “Si las tendencias actuales continúan, la expectativa de vida en el momento del nacimiento será de Y en un futuro de X años”. Se selecciona el año de 2050 ($X = 53$ años más allá de 1997) como el año objetivo en el futuro. Al usar $28 + 53 = 81$ como el valor para el tiempo en la ecuación de regresión que se presenta en la figura 6-17 y al despejar Y, la compañía obtiene una expectativa de vida de 86.6 años. Esta edad obviamente representa un aumento sustancial en la longevidad para las próximas décadas y la compañía empieza a trabajar sobre planes estratégicos para tomar ventaja de este incremento esperado en el tiempo de vida.

APLICACIÓN A LA ADMINISTRACIÓN

El análisis de regresión es la herramienta estadística que se utiliza más ampliamente en la dirección de una empresa cuando existe la necesidad de evaluar el efecto de una sola variable independiente sobre una variable dependiente. El análisis de regresión —junto con el análisis de correlación— ayuda al responsable de hacer el pronóstico a conocer las relaciones entre variables. El analista puede determinar tanto la importancia como la dirección de la relación entre variables.

La mayoría de los problemas que requieren el análisis de regresión implican la versión más compleja, llamada *análisis de regresión múltiple* (que estudiaremos en el siguiente capítulo), porque la mayoría de las relaciones ameritan el estudio de la relación entre una variable

TABLA 6-11 Expectativa de vida al nacer de la población total de Estados Unidos, ejemplo 6.13			
1970	70.8	1984	74.7
1971	71.2*	1985	74.7
1972	71.5*	1986	74.7
1973	71.9*	1987	74.9
1974	72.4*	1988	74.9
1975	72.6	1989	75.1
1976	72.8*	1990	75.4
1977	73.0*	1991	75.5
1978	73.3*	1992	75.8
1979	73.5*	1993	75.5
1980	73.7	1994	75.7
1981	74.1*	1995	75.8
1982	74.5	1996	76.1
1983	74.6	1997	76.5

Fuente: *Statiscal Abstract of the United States*, 119a. ed., 1999.

*Interpoladas.




FIGURA 6-17 Línea de regresión ajustada para el ejemplo 6.13

dependiente y más de una variable independiente. Sin embargo, la regresión simple y el análisis de correlación simple se utilizan con frecuencia. Los siguientes son unos cuantos ejemplos de situaciones que implican la regresión múltiple:

- *Consumo de productos.* Un fabricante desea pronosticar cuánta cerveza bebe una persona a la semana considerando variables como ingreso, edad, educación y clase demográfica.
- *Ventas.* Un minorista quiere pronosticar las ventas de un producto de una tienda contra las ventas de otra sobre la base de diferencias de precio, el ingreso relativo de la comunidad circundante, la simpatía relativa del personal de la tienda, y el número y fortaleza de los competidores en cada mercado.
- *Precios de las acciones.* Un analista bursátil de una firma regional de corretaje desea pronosticar el precio de una nueva emisión de acciones de una empresa local sobre la base de la economía regional, el ingreso, la población y el prestigio de la compañía.
- *Deudas incobrables.* Un contador necesita pronosticar las deudas incobrables que una empresa podría enfrentar el siguiente año fiscal sobre la base del número de personas desempleadas, créditos pendientes, tasas de interés y ventas esperadas.
- *Necesidades de empleo.* El director de personal de una gran empresa manufacturera desea pronosticar los requerimientos de personal para el año venidero tomando como base la edad promedio de sus empleados, su escala de salarios comparada con los de la localidad, la expectativa de nuevos contratos de ventas y la disponibilidad de puestos de trabajo competitivos.
- *Demanda en centros comerciales.* El gerente de un nuevo centro comercial quiere anticipar la demanda analizando el ingreso de la localidad, el tamaño de la población, así como la proximidad y el tamaño de centros comerciales competidores.

Una vez que se determina la relación entre las variables independiente y dependiente, la administración puede, en algunos casos, tratar de controlar la variable dependiente con base en este conocimiento. Por ejemplo, suponga que un gerente de marketing determina que existe una relación positiva significativa entre los gastos de publicidad y las ventas. La ecuación de regresión podría ser

$$\text{Ventas} = \$43,000 + .3(\text{Gastos de publicidad})$$

A partir de esta ecuación, el gerente de marketing puede tratar de controlar las ventas aumentando o disminuyendo los gastos de publicidad en una cantidad que maximice las utilidades. Siempre que el gerente tenga control sobre la variable independiente y exista la relación causa-efecto implicada por la ecuación de regresión, es posible controlar parcialmente la variable dependiente. La ecuación de regresión y el coeficiente de determinación ayudan a la administración de una compañía a determinar si tal control vale la pena.

Glosario

Coefficiente de determinación. Mide el porcentaje de variabilidad de Y que puede explicarse a través del conocimiento de la variabilidad (diferencias) de la variable independiente X .

Línea de regresión ajustada. Es la línea que mejor se ajusta a la colección de puntos de datos $X-Y$. Minimiza la suma de las distancias elevadas al cuadrado desde los puntos hasta la línea medidas verticalmente, es decir, en la dirección Y .

Error estándar de la estimación. Mide la cantidad por la que los valores reales de Y difieren de los valores estimados. Es una estimación de la desviación estándar del término de error, ε , en el modelo de regresión lineal simple.

Error estándar del pronóstico (s_f). Mide la variabilidad de la Y pronosticada en relación con la Y real para un valor dado de X .

Fórmulas clave

Suma de errores al cuadrado

$$SSE = \sum (Y - \hat{Y})^2 = \sum (Y - b_0 - b_1X)^2 \quad (6.1)$$

Método de los mínimos cuadrados: fórmula de la pendiente

$$b_1 = \frac{n \sum XY - \sum X \sum Y}{n \sum X^2 - (\sum X)^2} = \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\sum (X - \bar{X})^2} \quad (6.2)$$

Método de los mínimos cuadrados: fórmula de la intersección con Y

$$b_0 = \frac{\sum Y}{n} - \frac{b_1 \sum X}{n} = \bar{Y} - b_1 \bar{X} \quad (6.3)$$

Relación entre el coeficiente de la pendiente y el coeficiente de correlación

$$b_1 = \frac{\sqrt{\sum (Y - \bar{Y})^2}}{\sqrt{\sum (X - \bar{X})^2}} r \quad (6.4)$$

Observación = Ajuste + residuo

$$Y = \hat{Y} + (Y - \hat{Y}) \quad (6.5)$$

Ecuación de regresión ajustada

$$\hat{Y} = b_0 + b_1X \quad (6.6)$$

Error estándar de la estimación: fórmula de definición

$$s_{y \cdot x} = \sqrt{\frac{\sum (Y - \hat{Y})^2}{n - 2}} \quad (6.7)$$

Error estándar de la estimación: fórmula de cálculo

$$s_{y \cdot x} = \sqrt{\frac{\sum Y^2 - b_0 \sum Y - b_1 \sum XY}{n - 2}} \quad (6.8)$$

Error estándar del pronóstico

$$s_f = s_{y \cdot x} \sqrt{1 + \frac{1}{n} + \frac{(X - \bar{X})^2}{\sum (X - \bar{X})^2}} \quad (6.9)$$

Intervalo de predicción

$$\hat{Y} \pm t s_f \quad (6.10)$$

Intervalo de predicción del 95% para una muestra grande

$$\hat{Y} \pm 2s_f \quad (6.11)$$

Descomposición de la suma de los cuadrados y grados de libertad

$$\begin{aligned} SST &= SSR + SSE \\ \sum (Y - \bar{Y})^2 &= \sum (\hat{Y} - \bar{Y})^2 + \sum (Y - \hat{Y})^2 \end{aligned} \quad (6.12)$$

$$df: n - 1 = 1 + (n - 2) \quad (6.13)$$

Coefficiente de determinación

$$r^2 = \frac{\sum(\hat{Y} - \bar{Y})^2}{\sum(Y - \bar{Y})^2} = 1 - \frac{\sum(Y - \hat{Y})^2}{\sum(Y - \bar{Y})^2} \quad (6.14)$$

Estadístico t para probar $H_0: \beta_1 = 0$

$$t = \frac{b_1}{s_{b_1}} \quad (\text{véase el recuadro sombreado en la p. 237})$$

Error estándar del coeficiente de regresión

$$s_{b_1} = s_{y \cdot x} / \sqrt{\sum(X - \bar{X})^2} \quad (\text{véase el recuadro sombreado en la p. 237})$$

Estadístico F

$$F = \frac{\text{Cuadrado medio de regresión}}{\text{Error cuadrático medio}} = \frac{MSR}{MSE} \quad (6.15)$$

Relación del estadístico F con el coeficiente de determinación

$$F = \frac{r^2(n-2)}{1-r^2} \quad (6.16)$$

Coefficiente de autocorrelación residual

$$r_k(e) = \frac{\sum_{t=k+1}^n e_t e_{t-k}}{\sum_{t=1}^n e_t^2} \quad k = 1, 2, \dots, K \quad (6.17)$$

Problemas

Nota: La mayoría de los problemas siguientes contienen datos que van a ser manipulados usando procedimientos de análisis de regresión. Si bien es posible, incluso útil, trabajar uno o dos de estos análisis a mano, es importante que usted aprenda cómo usar el software de computadora para resolver problemas como éstos. En el siguiente capítulo usted aprenderá cómo se efectúa un análisis de regresión múltiple, en el cual no es posible resolver los problemas a mano. Por eso, usted debe familiarizarse con el software de análisis de regresión cuando resuelva los siguientes problemas. Si usted tiene acceso a Minitab o Excel, vea las instrucciones de uso en la sección final de este capítulo.

- ¿Cuál de las siguientes situaciones es incongruente?
 - $\hat{Y} = 499 + .21X$ y $r = .75$
 - $\hat{Y} = 100 + .9X$ y $r = -.70$
 - $\hat{Y} = -20 + 1X$ y $r = .40$
 - $\hat{Y} = -7 - 4X$ y $r = -.90$
- Las ganancias en miles de millones de dólares de American Telegraph and Telephone (AT&T) se estiman usando el producto interno bruto (PIB). La ecuación de regresión es $\hat{Y} = .078 + .06X$, donde el PIB se mide en miles de millones de dólares.
 - Interprete la pendiente.
 - Interprete la intersección con Y .

TABLA P-3

<i>Y</i> (\$)	<i>X</i> (\$)	<i>Y</i> (\$)	<i>X</i> (\$)
1,250	41	1,300	46
1,380	54	1,400	62
1,425	63	1,510	61
1,425	54	1,575	64
1,450	48	1,650	71

3. Considere los datos de la tabla P-3 donde X = gastos semanales de publicidad y Y = ventas semanales.
 - a) ¿Existe una relación significativa entre los gastos de publicidad y las ventas?
 - b) Defina la ecuación de predicción.
 - c) Pronostique las ventas para un gasto de publicidad de \$50.
 - d) ¿Qué porcentaje de variación de las ventas puede explicarse con la ecuación de predicción?
 - e) Defina la cantidad de variación no explicada.
 - f) Obtenga la cantidad de variación total.
4. En la tabla P-4 se presenta el tiempo requerido para hacer el cobro a los clientes en un supermercado y los valores correspondientes a las compras. Conteste los incisos a), b), e) y f) del problema 3 usando estos datos. Proporcione un estimado puntual y un intervalo estimado del 99% para Y si $X = 3.0$.
5. A Lori Franz, supervisora de mantenimiento de la Baltimore Transit Authority, le gustaría determinar si existe una relación positiva entre el costo anual de mantenimiento de un autobús y su antigüedad. Si existe una relación, Lori siente que puede hacer un mejor trabajo al pronosticar el presupuesto de mantenimiento anual del autobús. Ella recopiló los datos que se presentan en la tabla P-5.
 - a) Grafique un diagrama de dispersión.
 - b) ¿Qué clase de relación existe entre estas dos variables?
 - c) Calcule el coeficiente de correlación.
 - d) Determine la línea de mínimos cuadrados.
 - e) Pruebe la significancia del coeficiente de la pendiente para el nivel de significancia de .05. ¿Es significativa la correlación? Explique.
 - f) Pronostique el costo anual de mantenimiento para un autobús de cinco años de antigüedad.
6. Andrew Vazsonyi es el gerente de la cadena de supermercados Spendwise. A él le gustaría pronosticar las ventas de libros en edición rústica (libros por semana) con base en la canti-

TABLA P-4

<i>Tiempo requerido para el pago (minutos)</i>	<i>Valor de la compra (\$)</i>	<i>Tiempo requerido para el pago (minutos)</i>	<i>Valor de la compra (\$)</i>
3.6	30.6	1.8	6.2
4.1	30.5	4.3	40.1
.8	2.4	.2	2.0
5.7	42.2	2.6	15.5
3.4	21.8	1.3	6.5

TABLA P-5

<i>Autobús</i>	<i>Costo de mantenimiento (\$)</i> <i>Y</i>	<i>Antigüedad (años)</i> <i>X</i>
1	859	8
2	682	5
3	471	3
4	708	9
5	1,094	11
6	224	2
7	320	1
8	651	8
9	1,049	12

TABLA P-6

<i>Semana</i>	<i>Número de libros vendidos</i> <i>Y</i>	<i>Pies de espacio de anaqueles</i> <i>X</i>
1	275	6.8
2	142	3.3
3	168	4.1
4	197	4.2
5	215	4.8
6	188	3.9
7	241	4.9
8	295	7.7
9	125	3.1
10	266	5.9
11	200	5.0

dad de espacio de exhibición disponible (pies) en los anaqueles. Andrew recopila los datos de una muestra de 11 semanas, los cuales se presentan en la tabla P-6.

- Grafique un diagrama de dispersión.
 - ¿Qué clase de relación existe entre estas dos variables?
 - Calcule el coeficiente de correlación.
 - Determine la línea de mínimos cuadrados.
 - Pruebe la significancia del coeficiente de la pendiente en el nivel de significancia de .10. ¿Es significativa la correlación? Explique.
 - Grafique los residuos contra los valores ajustados. De acuerdo con esta gráfica, ¿el modelo de regresión lineal simple es adecuado para estos datos?
 - Pronostique las ventas de libros en edición rústica para una semana durante la cual existen cuatro pies de espacio en los anaqueles.
- En la tabla P-7 se presenta la información correspondiente a un negocio de ventas por correo que opera en 12 ciudades.
 - Determine la línea de regresión ajustada.
 - Calcule el error estándar de la estimación.
 - Determine la tabla ANOVA.
 - ¿Qué porcentaje de la variación de ventas por correo se explica por el número de catálogos distribuidos?

TABLA P-7

<i>Ciudad</i>	<i>Número de órdenes de ventas por correo (en miles)</i> <i>Y</i>	<i>Número de catálogos distribuidos (en miles)</i> <i>X</i>	<i>Ciudad</i>	<i>Número de órdenes de ventas por correo (en miles)</i> <i>Y</i>	<i>Número de catálogos distribuidos (en miles)</i> <i>X</i>
A	24	6	G	18	15
B	16	2	H	18	3
C	23	5	I	35	11
D	15	1	J	34	13
E	32	10	K	15	2
F	25	7	L	32	12

- e) Haga una prueba para determinar si el coeficiente de regresión de la pendiente es significativamente diferente de cero. (Use un nivel de significancia de .01).
- f) Pruebe la significancia de la regresión usando el estadístico F de la tabla ANOVA. (Use un nivel de significancia de .01). ¿Es congruente el resultado con el del inciso e)? ¿Debería serlo?
- g) Pronostique el número de ventas por correo recibidas cuando se distribuyen 10,000 catálogos; utilice un intervalo de predicción del 90%.
8. En un estudio de inversiones y tasas de interés se recabaron los datos de la tabla P-8 durante un periodo de 10 años.
- a) ¿Es significativa la relación entre estas variables?
- b) ¿Puede desarrollarse una ecuación efectiva de predicción?
- c) Si la tasa de interés promedio es del 4% dentro de cinco años, ¿puede pronosticarse la inversión anual?
- d) Calcule e interprete r^2 .
- e) Discuta la correlación y la causalidad en este ejemplo.
9. La ABC Investment Company está en el negocio de hacer licitaciones sobre inversiones ofrecidas por varias empresas que quieren financiamiento adicional. La ABC ha tabulado sus ofertas en las últimas 25 licitaciones en términos de su porcentaje de valor nominal. También se tabularon las ofertas del principal competidor de ABC, como un porcentaje del valor nominal. ABC ahora se pregunta si está usando el mismo razonamiento que su competidor en la preparación de las ofertas. En otras palabras, ¿es posible que ABC pronostique las ofertas de su competidor a partir de las propias? Si no es así, entonces el competidor debe estar evaluando las licitaciones de manera diferente. Los datos se presentan en la tabla P-9.

TABLA P-8

<i>Inversión anual (en miles de \$)</i>	<i>Tasa de interés promedio (%)</i>	<i>Inversión anual (en miles de \$)</i>	<i>Tasa de interés promedio (%)</i>
1,060	4.8	2,050	3.8
940	5.1	2,070	3.7
920	5.9	2,030	4.5
1,110	5.1	1,780	4.9
1,590	4.8	1,420	6.2

TABLA P-9

<i>Licitación</i>	<i>Oferta de ABC</i>	<i>Oferta del competidor</i>	<i>Licitación</i>	<i>Oferta de ABC</i>	<i>Oferta del competidor</i>
1	99.035	100.104	14	100.542	99.936
2	104.358	105.032	15	96.842	95.834
3	99.435	99.517	16	99.200	99.863
4	96.932	95.808	17	101.614	102.010
5	98.904	98.835	18	99.501	99.432
6	101.635	101.563	19	100.898	99.965
7	100.001	101.237	20	97.001	96.838
8	98.234	99.123	21	100.025	100.804
9	93.849	94.803	22	103.014	104.300
10	99.412	100.063	23	98.702	99.010
11	99.949	99.564	24	101.834	100.936
12	104.012	103.889	25	102.903	103.834
13	99.473	99.348			

- a) ¿Hasta qué grado están usando las dos firmas el mismo razonamiento en la preparación de sus ofertas?
- b) Pronostique la oferta del competidor si las ofertas de ABC tienen el 101% de valor nominal. Construya para ambos un estimado puntual y un intervalo de la predicción.
- c) En el inciso b), ¿cuál es la probabilidad de que ABC gane esta licitación particular? (La oferta más baja gana).
10. Evalúe los siguientes enunciados.
- a) Una r^2 alta se refiere a una regresión significativa.
- b) Un tamaño muestral muy grande en un problema de regresión siempre arrojará resultados útiles.
11. Suponga que usted fue contratado por Ed Bodganski, dueño de la American Precast Company, como analista de tiempo parcial. Ed estaba muy contento cuando usted determinó que existe una relación positiva entre los permisos de construcción expedidos y la cantidad de trabajo disponible para su compañía. Ahora él se pregunta si es posible usar el conocimiento de las tasas de interés sobre las hipotecas de primer grado para predecir el número de permisos de construcción que se expedirán cada mes. Usted recopila una muestra aleatoria de nueve meses de datos, como se presenta en la tabla P-11.

TABLA P-11

<i>Mes</i>	<i>Permisos de construcción Y</i>	<i>Tasa de interés (%) X</i>
1	786	10.2
2	494	12.6
3	289	13.5
4	892	9.7
5	343	10.8
6	888	9.5
7	509	10.9
8	987	9.2
9	187	14.2

- a) Grafique los datos en un diagrama de dispersión.
 - b) Determine la función de regresión ajustada.
 - c) Pruebe la significancia del coeficiente de la pendiente con un nivel de significancia de .05.
 - d) Cuando la tasa de interés se incrementa en 1%, ¿cuál es el decremento promedio en el número de permisos de construcción expedidos?
 - e) Calcule el coeficiente de determinación.
 - f) Redacte un enunciado que Ed pueda comprender y en el cual se interprete el número calculado en el inciso e).
 - g) Redacte un escrito para Ed explicándole los resultados de su análisis.
12. Considere la población de 140 observaciones que se presenta en la tabla P-12. La Marshall Printing Company desea estimar la relación entre el número de copias producidas por una técnica de impresión de offset (X) y el costo de la mano de obra directa asociada (Y). Seleccione una muestra aleatoria de 20 observaciones.
- a) Construya un diagrama de dispersión.
 - b) Calcule el coeficiente de correlación de la muestra.
 - c) Determine la línea de regresión ajustada.
 - d) Grafique la línea ajustada sobre el diagrama de dispersión.
 - e) Calcule el error estándar de la estimación.
 - f) Calcule el coeficiente de determinación e interprete su valor.
 - g) Pruebe la hipótesis de que la pendiente, β_1 , de la línea de regresión de la población es cero.
 - h) Calcule un pronóstico puntual y un intervalo de predicción del 90% para el costo de la mano de obra directa si el proyecto implica 250 copias.
 - i) Examine los residuos. ¿Parece que un modelo de regresión lineal simple es adecuado para estos datos? Explique.
13. Harry Daniels es un ingeniero de control de calidad de Specific Electric Corporation, una empresa dedicada a fabricar motores eléctricos. Uno de los pasos en el proceso de manufactura implica el uso de una fresadora automática para hacer las ranuras en el eje de los motores. Cada lote de ejes de motor se prueba y todos los ejes que no tengan las dimensiones requeridas se desechan. La fresadora debe reajustarse al comenzar a trabajar con cada nuevo lote porque su cabeza cortadora se desgasta ligeramente durante la producción. A Harry se le asigna el trabajo de pronosticar cómo afecta el tamaño de un lote al número de ejes defectuosos en el lote, de manera que pueda seleccionar el mejor tamaño de lote. Él recopila los datos del tamaño promedio del lote de los 13 lotes considerados en la tabla P-13 y le pide a usted analizarla.
- a) Grafique los datos en un diagrama de dispersión.
 - b) Ajuste un modelo de regresión lineal simple.
 - c) Haga una prueba de significancia del coeficiente de la pendiente.
 - d) Examine los residuos.
 - e) Desarrolle un modelo curvilíneo ajustando un modelo de regresión lineal simple para alguna transformación de la variable independiente.
 - f) Haga una prueba de la significancia del coeficiente de la pendiente de la variable transformada.
 - g) Examine los residuos.
 - h) Pronostique el número de defectos para un tamaño de lote de 300 ejes.
 - i) ¿Cuál modelo prefiere, el del inciso b) o el del inciso e)?
 - j) Redacte un escrito para Harry resumiendo sus resultados.
14. Los datos de la tabla P-14 fueron recopilados como parte de un estudio de evaluación de bienes inmuebles. Los números son observaciones de X = valor tasado (en miles de dólares) en los libros del valuador de la ciudad y Y = valor de mercado (precio de venta en miles de dólares) para $n = 30$ terrenos que se vendieron en un año particular en cierta área geográfica.

TABLA P-12

<i>Obs.</i>	<i>Y</i>	<i>X</i>	<i>Obs.</i>	<i>Y</i>	<i>X</i>	<i>Obs.</i>	<i>Y</i>	<i>X</i>
(1)	1.0	10	(48)	2.2	180	(95)	2.0	330
(2)	0.9	10	(49)	2.4	180	(96)	2.4	340
(3)	0.8	10	(50)	1.6	180	(97)	2.2	340
(4)	1.3	20	(51)	1.8	190	(98)	2.0	340
(5)	0.9	20	(52)	4.1	190	(99)	2.5	350
(6)	0.6	30	(53)	2.0	190	(100)	2.8	350
(7)	1.1	30	(54)	1.5	200	(101)	2.3	350
(8)	1.0	30	(55)	2.1	200	(102)	2.7	350
(9)	1.4	40	(56)	2.5	200	(103)	2.8	360
(10)	1.4	40	(57)	1.7	220	(104)	3.1	360
(11)	1.2	40	(58)	2.0	220	(105)	2.5	370
(12)	1.7	50	(59)	2.3	220	(106)	2.9	370
(13)	0.9	50	(60)	1.8	220	(107)	2.6	370
(14)	1.2	50	(61)	1.3	230	(108)	3.0	380
(15)	1.3	50	(62)	1.6	230	(109)	3.2	380
(16)	0.7	60	(63)	2.8	230	(110)	2.9	390
(17)	1.0	60	(64)	2.2	230	(111)	2.6	390
(18)	1.3	70	(65)	2.6	230	(112)	2.5	390
(19)	1.5	70	(66)	1.4	240	(113)	2.7	400
(20)	2.0	70	(67)	1.6	240	(114)	3.1	400
(21)	0.8	80	(68)	1.7	240	(115)	2.4	400
(22)	0.6	80	(69)	1.5	250	(116)	3.0	400
(23)	1.8	80	(70)	2.2	250	(117)	3.4	420
(24)	1.0	90	(71)	2.5	250	(118)	3.5	420
(25)	2.0	100	(72)	2.4	260	(119)	3.1	420
(26)	0.5	100	(73)	2.0	260	(120)	2.9	420
(27)	1.5	100	(74)	2.7	260	(121)	2.8	430
(28)	1.3	110	(75)	2.0	270	(122)	3.3	430
(29)	1.7	110	(76)	2.2	270	(123)	2.5	440
(30)	1.2	110	(77)	2.4	270	(124)	2.8	440
(31)	0.8	110	(78)	1.8	280	(125)	2.4	450
(32)	1.0	120	(79)	2.8	290	(126)	2.6	450
(33)	1.8	120	(80)	2.2	290	(127)	3.0	450
(34)	2.1	120	(81)	2.4	290	(128)	3.4	460
(35)	1.5	130	(82)	2.1	290	(129)	3.0	460
(36)	1.9	130	(83)	1.9	290	(130)	3.3	470
(37)	1.7	140	(84)	2.4	300	(131)	3.4	470
(38)	1.2	150	(85)	2.5	300	(132)	3.1	470
(39)	1.4	150	(86)	2.9	300	(133)	3.6	480
(40)	2.1	150	(87)	2.0	300	(134)	3.0	480
(41)	0.9	160	(88)	1.9	310	(135)	2.9	480
(42)	1.1	160	(89)	2.5	310	(136)	3.2	480
(43)	1.7	160	(90)	2.6	310	(137)	2.6	490
(44)	2.0	160	(91)	3.2	320	(138)	3.8	490
(45)	1.6	170	(92)	2.8	320	(139)	3.3	490
(46)	1.9	170	(93)	2.4	320	(140)	2.9	500
(47)	1.7	170	(94)	2.5	320			

TABLA P-13

<i>Lote</i>	<i>Número de defectos</i> <i>Y</i>	<i>Tamaño del lote</i> <i>X</i>
1	4	25
2	8	50
3	6	75
4	16	100
5	22	125
6	27	150
7	36	175
8	49	200
9	53	225
10	70	250
11	82	275
12	95	300
13	109	325

TABLA P-14

<i>Terreno</i>	<i>Valor tasado</i>	<i>Mercado</i>	<i>Terreno</i>	<i>Valor tasado</i>	<i>Mercado</i>
1	68.2	87.4	16	74.0	88.4
2	74.6	88.0	17	72.8	93.6
3	64.6	87.2	18	80.4	92.8
4	80.2	94.0	19	74.2	90.6
5	76.0	94.2	20	80.0	91.6
6	78.0	93.6	21	81.6	92.8
7	76.0	88.4	22	75.6	89.0
8	77.0	92.2	23	79.4	91.8
9	75.2	90.4	24	82.2	98.4
10	72.4	90.4	25	67.0	89.8
11	80.0	93.6	26	72.0	97.2
12	76.4	91.4	27	73.6	95.2
13	70.2	89.6	28	71.4	88.8
14	75.8	91.8	29	81.0	97.4
15	79.2	94.8	30	80.6	95.4

- Grafique el valor de mercado contra el valor tasado en los libros en un diagrama de dispersión.
 - Suponiendo un modelo de regresión lineal simple, determine la línea de mínimos cuadrados que relaciona el valor de mercado con el valor tasado en los libros.
 - Determine r^2 e interprete su valor.
 - ¿Es significativa la regresión? Explique.
 - Pronostique el valor de mercado de una propiedad a partir de un valor tasado en los libros de 90.5. ¿Hay algún peligro al hacer esta predicción?
 - Examine los residuos. ¿Puede usted identificar observaciones que tienen gran influencia en la localización de la línea de mínimos cuadrados?
15. En la tabla P-15 se presentan los costos de jugadores (X) y gastos operativos (Y) para $n = 26$ de los principales equipos de la liga mayor de béisbol durante la temporada 1990-1991.

TABLA P-15

<i>Equipo</i>	<i>Costos de jugadores (millones de \$)</i>	<i>Gastos operativos Y (millones de \$)</i>
1	29.8	59.6
2	36.0	72.0
3	35.2	70.4
4	29.7	62.4
5	35.4	70.8
6	15.8	39.5
7	18.0	60.0
8	23.2	46.4
9	29.0	58.0
10	20.7	47.6
11	30.4	60.8
12	21.7	43.4
13	39.2	66.6
14	34.3	61.7
15	33.3	53.3
16	27.1	48.8
17	24.4	48.8
18	12.1	31.5
19	24.9	49.8
20	31.1	54.4
21	20.4	40.8
22	24.1	48.2
23	17.4	41.8
24	26.4	50.2
25	19.5	46.8
26	21.8	43.6

- Suponiendo un modelo de regresión lineal simple, determine la ecuación para la línea recta ajustada.
 - Determine r^2 y haga comentarios acerca de la intensidad de la relación lineal.
 - Pruebe la significancia de la regresión para un nivel de significancia de .10.
 - ¿Se puede concluir que, como regla general, los gastos operativos son aproximadamente el doble de los costos de los jugadores? Analícelo.
 - Pronostique los gastos operativos, con un intervalo de predicción del 95% de una muestra grande, si los costos de los jugadores son de 30.5 millones de dólares.
 - Usando los residuos como guía, identifique cualquier observación atípica. Es decir, ¿algunos equipos tienen costos de jugadores inusualmente bajos o altos en comparación con los gastos operativos?
16. La tabla P-16 contiene datos de consumo de periódicos de 23 ciudades (Y) y el número de familias en la ciudad (X) durante un año particular.
- Grafique el consumo de periódicos contra el número de familias en un diagrama de dispersión.
 - ¿Es adecuado el modelo de regresión lineal simple para los datos de la tabla P-16? Asegúrese de que su respuesta incluya un análisis de los residuos.
 - Considere una transformación logarítmica del consumo de periódicos y un modelo de regresión lineal simple que relacione $Y = \log$ (consumo de periódicos) con $X =$ número de familias. Ajuste este modelo.

TABLA P-16

<i>Ciudad</i>	<i>Consumo de periódico Y (toneladas métricas)</i>	<i>Número de familias X</i>	<i>Ciudad</i>	<i>Consumo de periódico Y (toneladas métricas)</i>	<i>Número de familias X</i>
1	961	8,600	13	878	8,330
2	469	6,870	14	637	9,010
3	556	9,880	15	3,291	11,790
4	1,252	12,370	16	2,470	18,910
5	902	6,920	17	916	8,550
6	1,399	13,760	18	525	8,850
7	1,877	7,450	19	1,159	8,540
8	921	6,700	20	1,138	6,910
9	494	7,420	21	979	7,060
10	530	6,930	22	1,899	10,920
11	488	7,400	23	5,022	14,800
12	1,253	7,420			

- d) Examine los residuos de la regresión del inciso c). ¿Cuál modelo es mejor, el del inciso b) o el del inciso c)? Justifique su respuesta.
- e) Usando la función ajustada del inciso c), pronostique la cantidad de periódico consumida en un año si una ciudad tiene 100,000 familias.
- f) ¿Podría indicar otras variables que probablemente tengan influencia sobre la cantidad de periódico consumida durante un año?
17. La Outback Steakhouse creció explosivamente durante sus primeros años de operación. Los números de sucursales de Outback Steakhouse para el periodo de 1988 a 1993 se presentan abajo.

Año	1988	1989	1990	1991	1992	1993
Núm. de sucursales	2	9	23	49	87	137

Fuente: Outback Steakhouse.

- a) ¿Parece haber un crecimiento lineal o exponencial en el número de sucursales?
- b) Calcule la tasa de crecimiento anual de Outback Steakhouse durante el periodo de 1988 a 1993.
- c) Pronostique el número de sucursales de Outback para 2007. ¿Parece razonable este número? Explique.
18. On The Double, una cadena de centros de copiado instalados dentro de planteles universitarios, inició operaciones con una sola tienda en 1993. En la tabla P-18 está registrado el número de centros de copiado en operación, Y , durante 14 años consecutivos.
- a) Grafique el número de centros de copiado contra el año. ¿El crecimiento experimentado por On The Double es lineal o exponencial?
- b) Determine la tasa de crecimiento anual de On The Double.
- c) Pronostique el número de centros de copiado en operación para 2012. ¿Parece razonable este número? ¿Por qué?
19. En la tabla P-19 se presenta el número de empleados (X) y las utilidades por empleado (Y) para $n = 16$ empresas editoriales. Los empleados se registran en miles, y las utilidades por

TABLA P-18

<i>Año</i>	<i>Periodo</i>	<i>Centros de copiado</i>
1993	1	1
1994	2	2
1995	3	2
1996	4	6
1997	5	10
1998	6	16
1999	7	25
2000	8	41
2001	9	60
2002	10	97
2003	11	150
2004	12	211
2005	13	382
2006	14	537

TABLA P-19

<i>Empresa</i>	<i>Utilidades (en miles de \$)</i>	<i>Empleados (en miles)</i>
1	33.5	9.4
2	31.4	6.3
3	25.0	10.7
4	23.1	7.4
5	14.2	17.1
6	11.7	21.2
7	10.8	36.8
8	10.5	28.5
9	9.8	10.7
10	9.1	9.9
11	8.5	26.1
12*	8.3	70.5
13	4.8	14.8
14	3.2	21.3
15	2.7	14.6
16	-9.5	26.8

*Dun and Bradstreet.

empleado en miles de dólares. A continuación se presenta una parte del resultado de Minitab de un análisis de regresión lineal.

The regression equation is

Profits = 18.0 - 0.271 Employees

Predictor	Coef	SE Coef	T	P
Constant	17.954	4.457	4.03	0.001
Employees	-0.2715	0.1726	-1.57	0.138

s = 10.6112 R - Sq = 15.0% R - Sq(adj) = 9.0%

- a) Identifique la estimación de los mínimos cuadrados de los coeficientes de la pendiente y de la intersección.
- b) Pruebe la hipótesis $H_0: \beta_1 = 0$ con $\alpha = .10$. ¿Parece haber una relación entre las utilidades por empleado y el número de empleados? Explique.
- c) Identifique e interprete r^2 .
- d) ¿Esta función de regresión ajustada es una buena herramienta para pronosticar las utilidades por empleado para un número dado de empleados de una empresa editorial? Discútalos.
20. Con respecto al problema 19, la observación 12 corresponde a Dun y Bradstreet. Haga de nuevo el análisis de regresión lineal omitiendo esta observación. ¿Cambian sus conclusiones de los incisos b) y d) del problema 19? ¿Qué implica esto, si acaso, con respecto a la influencia de una observación individual sobre el análisis de regresión cuando el número de observaciones es bastante pequeño? ¿Cree usted razonable despedir a Dun y Bradstreet? Analícelo.
21. En el contexto del ejemplo 2-13 se presenta la tabla 2-28 con los datos sobre el costo real (Y) y el costo estimado (X), en millones de dólares, para $n = 26$ proyectos de construcción. La figura 2-17 muestra la gráfica de la línea ajustada para estos datos.
- a) Reanalice los datos de costos usando un modelo de regresión lineal simple. Elabore una gráfica de los residuos contra los valores ajustados.
- b) ¿Es significativa la regresión del costo real sobre el costo estimado? Justifique su respuesta.
- c) Identifique e interprete r^2 .
- d) ¿Cuáles son los valores apropiados de los coeficientes de la pendiente y de la intersección de la función de regresión de la población si el costo estimado es un factor de predicción perfecto del costo real esperado? ¿Son congruentes los coeficientes estimados en la ecuación de la línea recta ajustada con estos valores? Discútalos.
- e) Considere la gráfica de los residuos contra los valores ajustados. ¿Parece como si los costos estimados fueran, en general, factores de predicción más exactos de los costos reales de los proyectos relativamente baratos que de los proyectos de alto costo? ¿Por qué?
22. Con respecto al problema 21, los datos de costo pueden transformarse tomando los logaritmos naturales tanto de los costos estimados como de los costos reales. Considere un modelo de regresión lineal simple para los costos transformados. A continuación se presenta una porción del resultado de Minitab para este análisis.

The regression equation is

$$\text{LnActual} = 0.003 + 0.968 \text{ LnEstimate}$$

Predictor	Coef	SE Coef	T	P
Constant	0.0026	0.1625	0.02	0.987
LnEstimate	0.96811	0.06583	14.71	0.000

$$S = 0.412124 \quad R - \text{Sq} = 90.0\% \quad R - \text{Sq}(\text{adj}) = 89.6\%$$

- a) ¿Es significativa la regresión? Explique.
- b) Identifique e interprete r^2 .
- c) ¿Los datos muestrales son congruentes con los valores de la población, $\beta_0 = 0$ y $\beta_1 = 1$? Explique. ¿Cuál es la significancia de estas opciones particulares para β_0 y β_1 ?
- d) Elabore un pronóstico del costo real cuando el costo estimado es de \$24 millones.