

ANÁLISIS DE REGRESIÓN
MÚLTIPLE

En la regresión lineal simple se investiga la relación entre una variable independiente y una variable dependiente. A menudo la relación entre dos variables permite pronosticar con exactitud la variable dependiente a partir del conocimiento de la variable independiente. Por desgracia, muchos escenarios de elaboración de pronósticos en la vida real no son tan simples. Con frecuencia se necesita más de una variable independiente para pronosticar con exactitud una variable dependiente. Los modelos de regresión con más de una variable independiente se llaman modelos de *regresión múltiple*. La mayoría de los conceptos presentados en la regresión lineal simple se utilizan en la regresión múltiple. Sin embargo, surgen algunos conceptos nuevos, ya que se usa más de una variable independiente para predecir la variable dependiente.

La *regresión múltiple* implica el uso de más de una variable independiente para predecir una variable dependiente.

DIVERSAS VARIABLES EXPLICATIVAS

Para ejemplificar, regresemos al problema en el cual se pronostica el volumen de las ventas de galones de leche a partir del conocimiento del precio por galón. El señor Bump enfrenta el problema de hacer un pronóstico que no es totalmente exacto. Él puede explicar casi el 75% de las diferencias en los galones vendidos de leche usando una variable independiente. Sin embargo, el 25% ($1 - r^2$) de la variación total no encuentra explicación. En otras palabras, por la evidencia muestral, el señor Bump conoce el 75% de lo que debe saber para pronosticar perfectamente el volumen de ventas. Para hacer un trabajo con mayor exactitud, necesita obtener otra variable explicativa que le permita explicar más de la variación total. Si el señor Bump puede reducir la variación no explicada, su pronóstico tendrá menos incertidumbre y más exactitud.

Es necesario investigar para conocer otra variable independiente que esté relacionada con el volumen de galones vendidos de leche. Sin embargo, esta nueva variable independiente, o predictiva, no debe estar muy estrechamente relacionada con la variable independiente que ya se está usando (el precio por galón). Si las dos variables independientes están profundamente relacionadas una con otra, explicarán la misma variación, y el hecho de agregar una segunda variable no mejorará el pronóstico.¹ En campos como la econometría y la estadística aplicada, existe gran preocupación por este problema de intercorrelación entre variables independientes, conocido a

¹Las variables explicativas interrelacionadas contienen, en esencia, la misma información y, por lo tanto, no aportan “nueva” información acerca del comportamiento de la variable dependiente. De manera ideal, los efectos de cada una de las variables explicativas sobre la variable dependiente no deben estar relacionados unos con otros.

menudo como *multicolinealidad*. La solución más sencilla al problema de dos variables independientes profundamente relacionadas consiste en *no* usarlas juntas. Estudiaremos el problema de la multicolinealidad más adelante en este capítulo

MATRIZ DE CORRELACIÓN

El señor Bump determina que los gastos en publicidad podrían ayudar a mejorar su pronóstico del volumen semanal de ventas. Él investiga las relaciones entre el gasto en publicidad, el volumen de ventas y el precio por galón examinando una matriz de correlación. La *matriz de correlación* se elabora calculando los coeficientes de correlación simple de cada combinación de pares de variables.

En la tabla 7-1 se presenta un ejemplo de una matriz de correlación. El coeficiente de correlación que indica la relación entre las variables 1 y 2 se representa como r_{12} . Observe que el primer subíndice, 1, hace referencia a la fila y el segundo subíndice, 2, hace referencia a la columna de la tabla. Esta convención permite determinar, con una mirada, la relación entre cualquier par de variables. Por supuesto, la correlación entre, digamos, la variable 1 y la variable 2 es exactamente la misma que la correlación entre las variables 2 y 1; es decir, $r_{12} = r_{21}$. Por lo tanto, sólo se necesita la mitad de la matriz de correlación. Además, la correlación de una variable consigo misma siempre es 1, de manera que, por ejemplo, $r_{11} = r_{22} = r_{33} = 1$.

El señor Bump ingresa sus datos en la computadora, y los resultados de la matriz de correlación se muestran en la tabla 7-2. Un análisis de las relaciones entre el gasto en publicidad, el volumen de ventas y el precio por galón indica que la nueva variable independiente debe contribuir a mejorar el pronóstico. La matriz de correlación indica que el gasto en publicidad tiene una relación positiva alta ($r_{13} = .89$) con la variable dependiente, el volumen de ventas, y una relación negativa moderada ($r_{23} = -.65$) con la variable independiente, el precio por galón. Esta combinación de relaciones debería permitir que los gastos en publicidad expliquen algo de la variación total del volumen de ventas que todavía no se ha explicado mediante el precio por galón. Como veremos, cuando se usan tanto el precio por galón como el gasto en publicidad para estimar el volumen de ventas R^2 aumenta al 93.2%.

El análisis de la matriz de correlación es un paso inicial importante en la resolución de cualquier problema que implique múltiples variables independientes

TABLA 7-1 Matriz de correlación

Variables	Variables		
	1	2	3
1	r_{11}	r_{12}	r_{13}
2	r_{21}	r_{22}	r_{23}
3	r_{31}	r_{32}	r_{33}

TABLA 7-2 Matriz de correlación de los datos del señor Bump

Variables	Variables		
	Ventas 1	Precio 2	Publicidad 3
Ventas, 1	1.00	-.86	.89
Precio, 2		1.00	-.65
Publicidad, 3			1.00

MODELO DE REGRESIÓN MÚLTIPLE

En la regresión simple, la variable dependiente puede representarse mediante Y , y la variable independiente mediante X . En el análisis de regresión múltiple, las variables independientes se denotan mediante X con subíndices. Así, las variables dependientes se siguen representando por Y y las variables independientes por $X_1, X_2, \dots, X_k$. Una vez que se ha determinado el conjunto inicial de variables independientes, la relación entre Y y estas X se expresa como un *modelo de regresión múltiple*.

En el modelo de regresión múltiple, la respuesta promedio se toma como una función lineal de las variables explicativas:

$$\mu_Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k \quad (7.1)$$

Esta expresión es la *función de regresión múltiple de la población*. Al igual que en el caso de la regresión lineal simple, no podemos observar directamente la función de regresión de la población porque los valores observados de Y varían alrededor de sus medias. Cada combinación de valores para todas las X define la media de una subpoblación de respuestas Y . Suponemos que las Y de cada una de estas subpoblaciones están distribuidas de manera normal alrededor de sus medias con la misma desviación estándar, σ .

Los datos de la regresión lineal simple consisten en observaciones (X_i, Y_i) de las dos variables. En la regresión múltiple, los datos en cada caso consisten en una observación de la respuesta y una observación de cada una de las variables independientes. La i -ésima observación de la j -ésima variable explicativa se representa por X_{ij} . Con esta notación, los datos de la regresión múltiple tienen la forma que se ilustra en la tabla 7-3. Es conveniente referirse a los datos del i -ésimo caso simplemente como la i -ésima observación. Con esta convención, n es el número de observaciones y k es el número de variables explicativas.

Modelo estadístico para la regresión múltiple

La respuesta, Y , es una variable aleatoria que está relacionada con las variables independientes (predictivas), $X_1, X_2, \dots, X_k$, por

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \varepsilon$$

donde

1. Para la i -ésima observación, $Y = Y_i$ y $X_1, X_2, \dots, X_k$ se definen para los valores $X_{i1}, X_{i2}, \dots, X_{ik}$.

TABLA 7-3 Estructura de datos de la regresión múltiple

Caso	Variables explicativas				Respuesta
	X_1	X_2		X_k	Y
1	X_{11}	X_{12}		X_{1k}	Y_1
2	X_{21}	X_{22}		X_{2k}	Y_2
.	.	.		.	.
.	.	.		.	.
i	X_{i1}	X_{i2}		X_{ik}	Y_i
.	.	.		.	.
.	.	.		.	.
n	X_{n1}	X_{n2}		X_{nk}	Y_n

2. Las ε 's son componentes de error que representan las desviaciones de la respuesta de la relación verdadera. Son variables aleatorias no observables que explican los efectos de otros factores sobre la respuesta. Se supone que los errores son independientes y todos están distribuidos de manera normal con una media 0 y desviación estándar desconocida σ .
3. Los coeficientes de regresión, $\beta_0, \beta_1, \dots, \beta_k$, que en conjunto definen la función de regresión son desconocidos.

Teniendo los datos, es posible estimar los coeficientes de regresión usando el principio de mínimos cuadrados. Las estimaciones de los mínimos cuadrados se representan por $b_0, b_1, \dots, b_k$ y la función de regresión estimada por

$$\hat{Y} = b_0 + b_1X_1 + \dots + b_kX_k \quad (7.2)$$

Los residuos, $e = Y - \hat{Y}$, son estimaciones del componente de error y similares al escenario de la regresión lineal simple; la correspondencia entre la población y la muestra es

$$\text{Población: } Y = \beta_0 + \beta_1X_1 + \beta_2X_2 + \dots + \beta_kX_k + \varepsilon$$

$$\text{Muestra: } Y = b_0 + b_1X_1 + b_2X_2 + \dots + b_kX_k + e$$

Por lo general, los cálculos en el análisis de regresión múltiple se realizan usando paquetes de software como Minitab y Excel (véanse las secciones de aplicaciones de Minitab y Excel al final del capítulo).

Ejemplo 7.1

Para los datos presentados en la tabla 7-4, el señor Bump considera un modelo de regresión múltiple que relaciona el volumen de ventas (Y) con el precio (X_1) y la publicidad (X_2):

$$Y = \beta_0 + \beta_1X_1 + \beta_2X_2 + \varepsilon$$

El señor Bump determina la función de regresión ajustada:

$$\hat{Y} = 16.41 - 8.25X_1 + .59X_2$$

Los valores de los mínimos cuadrados — $b_0 = 16.41$, $b_1 = -8.25$, y $b_2 = .59$ — minimizan la suma de errores al cuadrado:

$$SSE = \sum_i (Y_i - b_0 - b_1X_{i1} - b_2X_{i2})^2 = \sum_i (Y_i - \hat{Y}_i)^2$$

para todas las opciones posibles de b_0, b_1 , y b_2 . Aquí, la función que mejor ajusta es un plano (véase la figura 7-1). Los puntos de datos se grafican en tres dimensiones a lo largo de los ejes Y, X_1 , y X_2 . Los puntos caen por encima y por debajo del plano de manera tal que $\sum (Y - \hat{Y})^2$ es un mínimo.

La función de regresión ajustada servirá para pronosticar las ventas de la siguiente semana. Si los planes requieren un precio por galón de \$1.50 y gastos de publicidad de \$1,000, el pronóstico es de 9.935 miles de galones; es decir,

$$\hat{Y} = 16.41 - 8.25X_1 + .59X_2$$

$$\hat{Y} = 16.41 - 8.25(1.5) + .59(10) = 9.935$$

TABLA 7-4 Datos del señor Bump para el ejemplo 7.1

<i>Semana</i>	<i>Ventas (en miles)</i> Y	<i>Precio por galón (\$)</i> X_1	<i>Publicidad (en cientos de \$)</i> X_2
1	10	1.30	9
2	6	2.00	7
3	5	1.70	5
4	12	1.50	14
5	10	1.60	15
6	15	1.20	12
7	5	1.60	6
8	12	1.40	10
9	17	1.00	15
10	20	1.10	21
Totales	112	14.40	114
Medias	11.2	1.44	11.4




FIGURA 7-1 Plano de regresión ajustado de los datos del señor Bump; ejemplo 7.1

INTERPRETACIÓN DE LOS COEFICIENTES DE REGRESIÓN

Considere la interpretación de b_0 , b_1 , y b_2 en la función de regresión ajustada del señor Bump. Otra vez el valor de b_0 es la intersección con Y . Sin embargo, ahora se interpreta como el valor de $\hat{Y}$ cuando tanto X_1 como X_2 son iguales a cero. Los coeficientes b_1 y b_2 se conocen como los *coeficientes de la regresión parcial* o *neta*. Cada uno mide el cambio promedio de Y por unidad de cambio en las variables independientes relevantes. Sin embargo, como la función de regre-

sión está midiendo la influencia simultánea de todas las variables independientes sobre Y , el efecto parcial o neto de X_1 (o de cualquier X) debe medirse por separado de la influencia de otras variables. Por lo tanto, se dice que b_1 mide el cambio promedio de Y por unidad de cambio de X_1 , cuando se mantienen constantes las demás variables independientes.

El *coeficiente de regresión parcial o neto* mide el cambio promedio de la variable dependiente por unidad de cambio en la variable independiente relevante, cuando se mantienen constantes las demás variables independientes.

En este ejemplo, el valor b_1 de -8.25 indica que por cada incremento de 1 centavo en el precio de un galón de leche cuando los gastos de publicidad se mantienen *constantes*, la cantidad comprada se reduce un promedio de 82.5 galones. De manera análoga, el valor b_2 de $.59$ significa que, si los gastos de publicidad se incrementan \$100 cuando el precio por galón se mantiene constante, el volumen de ventas aumentará en un promedio de 590 galones.

Ejemplo 7.2

Para ilustrar los efectos netos de las X individuales sobre la respuesta, considere la situación en la cual el precio es de \$1.00 por galón y se gastan \$1,000 en publicidad. Así

$$\begin{aligned}\hat{Y} &= 16.41 - 8.25X_1 + .59X_2 \\ &= 16.41 - 8.25(1.00) + .59(10) \\ &= 16.41 - 8.25 + 5.9 = 14.06\end{aligned}$$

El pronóstico de las ventas es de 14,060 galones de leche.

¿Cuál es el efecto sobre las ventas del incremento de un centavo en el precio si se gastan \$1,000 en publicidad?

$$\begin{aligned}\hat{Y} &= 16.41 - 8.25(1.01) + .59(10) \\ &= 16.41 - 8.3325 + 5.9 = 13.9775\end{aligned}$$

Advierta que las ventas disminuyen 82.5 galones ($14.06 - 13.9775 = .0825$).

¿Cuál es el efecto sobre las ventas de un aumento de \$100 en publicidad si el precio permanece constante en \$1.00

$$\begin{aligned}\hat{Y} &= 16.41 - 8.25(1.00) + .59(11) \\ &= 16.41 - 8.25 + 6.49 = 14.65\end{aligned}$$

Note que las ventas se incrementan 590 galones ($14.65 - 14.06 = .59$).

INFERENCIAS EN MODELOS DE REGRESIÓN MÚLTIPLE

La inferencia en los modelos de regresión múltiple es análoga a la de la regresión lineal simple. La estimación de mínimos cuadrados de los parámetros del modelo, la estimación de los errores estándar, las estadísticas t que se usan para examinar la significancia de los términos individuales del modelo de regresión, y el estadístico F que permite verificar la significancia de la regresión se obtienen empleando paquetes estándar de software estadístico. La determinación manual de estas cantidades en un análisis de regresión múltiple de cualquier tamaño es impráctica, y se debe usar una computadora para efectuar los cálculos.

Como en el capítulo 6, cualquier observación Y puede escribirse como

$$\text{Observación} = \text{Ajuste} + \text{Residuo}$$

o

$$Y = \hat{Y} + (Y - \hat{Y})$$

donde

$$\hat{Y} = b_0 + b_1X_1 + b_2X_2 + \cdots + b_kX_k$$

es la función de regresión ajustada. Recuerde que $\hat{Y}$ es una estimación de la función de regresión de la población. Representa la parte de Y que se explica por la relación de Y con las X . El residuo, $Y - \hat{Y}$, es una estimación del componente de error del modelo. Representa la parte de Y que no explican las variables explicativas.

La descomposición de la suma de cuadrados y los grados de libertad asociada son

$$\begin{aligned}\Sigma(Y - \bar{Y})^2 &= \Sigma(\hat{Y} - \bar{Y})^2 + \Sigma(Y - \hat{Y})^2 \\ SST &= SSR + SSE \\ df: n - 1 &= k + n - k - 1\end{aligned}\tag{7.3}$$

La variación total en la respuesta, SST , consiste en dos componentes: SSR , la variación explicada por las variables explicativas a través de la función de regresión estimada, y el SSE , la variación no explicada o el error. La información de la ecuación 7.3 puede obtenerse haciendo un análisis de la tabla de varianza (ANOVA), la cual se analizará en una sección posterior.

Error estándar de la estimación

El error estándar de la estimación es la desviación estándar de los residuos. Mide la dispersión típica de los valores de Y alrededor de la función de regresión ajustada.² El error estándar de la estimación es

$$s_{y \cdot x's} = \sqrt{\frac{\Sigma(Y - \hat{Y})^2}{n - k - 1}} = \sqrt{\frac{SSE}{n - k - 1}} = \sqrt{MSE}\tag{7.4}$$

donde

n = el número de observaciones

k = el número de variables independientes en la función de regresión

$SSE = \Sigma(Y - \hat{Y})^2$ = suma de los cuadrados de los residuos

$MSE = SSE/(n - k - 1)$ = el cuadrado medio de los residuos

El *error estándar de la estimación* es la desviación estándar de los residuos. Mide la cantidad en que los valores reales de (Y) difieren de los valores estimados ($\hat{Y}$). Para muestras relativamente grandes, esperaríamos que alrededor del 67% de las diferencias $Y - \hat{Y}$ estén dentro de $s_{y \cdot x's}$ de cero, y alrededor del 95% de estas diferencias estén dentro de $2 s_{y \cdot x's}$ de cero.

Ejemplo 7.3

Las cantidades requeridas para calcular el error estándar de la estimación para los datos del señor Bump se indican en la tabla 7-5.

²El error estándar de la estimación es una estimación de σ , la desviación estándar del término de error, ε , en el modelo de regresión múltiple.

TABLA 7-5 Residuos del modelo de los datos del señor Bump para el ejemplo 7.3

<i>Y</i>	<i>X</i> ₁	<i>X</i> ₂	<i>Y</i> pronosticada (<i>Ŷ</i>) usando $\hat{Y} = 16.406 - 8.248X_1 + .585X_2$	Residuo (<i>Y</i> - <i>Ŷ</i>)	(<i>Y</i> - <i>Ŷ</i>) ²
10	1.30	9	10.95	-.95	.90
6	2.00	7	4.01	1.99	3.96
5	1.70	5	5.31	-.31	.10
12	1.50	14	12.23	-.23	.05
10	1.60	15	11.99	-1.99	3.96
15	1.20	12	13.53	1.47	2.16
5	1.60	6	6.72	-1.72	2.96
12	1.40	10	10.71	1.29	1.66
17	1.00	15	16.94	.06	.00
20	1.10	21	19.62	.38	.14
Totales				.00	15.90

El error estándar de la estimación es

$$s_{y \cdot x'} = \sqrt{\frac{15.90}{10 - 2 - 1}} = \sqrt{2.27} = 1.51$$

Con una sola variable explicativa X_1 = precio, el error estándar de la estimación era $s_{y \cdot x} = 2.72$ (véase el capítulo 6). Con la variable explicativa adicional, X_2 = publicidad, el señor Bump redujo el error estándar de la estimación en casi un 50%. Las diferencias entre los volúmenes reales de leche vendida y los pronósticos obtenidos a partir de la ecuación de regresión ajustada son considerablemente más pequeñas con dos variables explicativas que con una sola. Es decir, la ecuación con dos variables explicativas está mucho muy cerca de reproducir el valor real de las Y que la ecuación con una sola variable explicativa.

Significancia de la regresión

La tabla ANOVA basada en la descomposición de la variación total de Y (SST) en sus partes explicadas (SSR) y no explicadas (SSE) (véase la ecuación 7.3) se presenta en la tabla 7-6.

Considere la hipótesis $H_0: \beta_1 = \beta_2 = \cdots = \beta_k = 0$. Esta hipótesis significa que Y no está relacionada con ninguna de las X (el coeficiente de cada X es cero). La prueba de H_0 se conoce como prueba de *significancia de la regresión*. Si los supuestos del modelo de regresión son apropiados y H_0 es verdadera, la razón

$$F = \frac{MSR}{MSE}$$

tiene una distribución F con $df = k, n - k - 1$. De este modo, la razón F se puede usar como prueba de la significancia de la regresión.

TABLA 7-6 Tabla ANOVA de regresión múltiple

<i>Fuente</i>	<i>Suma de cuadrados</i>	<i>df</i>	<i>Cuadrado medio</i>	<i>Razón F</i>
Regresión	SSR	k	$MSR = SSR/k$	$F = \frac{MSR}{MSE}$
Error	SSE	$n - k - 1$	$MSE = SSE/(n - k - 1)$	
Total	SST	$n - 1$		

En la regresión lineal simple, sólo existe una variable explicativa. En consecuencia, la prueba de significancia de la regresión usando la razón F de la tabla ANOVA es equivalente a la prueba t de dos colas para la hipótesis de que la pendiente de la línea de regresión es cero. Para la regresión múltiple, las pruebas t (que se presentarán dentro de poco) examinan la significancia de las X individuales en la función de regresión, y la prueba F examina la significancia de todas las X de manera colectiva.

Prueba F de la significancia de la regresión

En el modelo de regresión múltiple, las hipótesis

$$H_0: \beta_1 = \beta_2 = \cdots = \beta_k = 0$$

$$H_1: \text{por lo menos una } b_j \neq 0$$

se prueban mediante la razón F :

$$F = \frac{MSR}{MSE}$$

con $df = k, n - k - 1$. Con un nivel de significancia α , la región de rechazo es

$$F > F_\alpha$$

donde F_α es el punto que deja un área de α a la derecha de una distribución F con $\delta_1 = k, \delta_2 = n - k - 1$ grados de libertad del numerador y del denominador respectivamente.

El *coeficiente de determinación*, R^2 , está dado por

$$\begin{aligned} R^2 &= \frac{SSR}{SST} = \frac{\sum(\hat{Y} - \bar{Y})^2}{\sum(Y - \bar{Y})^2} \\ &= 1 - \frac{SSE}{SST} = 1 - \frac{\sum(Y - \hat{Y})^2}{\sum(Y - \bar{Y})^2} \end{aligned} \quad (7.5)$$

y tiene la misma forma e interpretación que la r^2 de la regresión lineal simple. Representa la proporción de variación en la respuesta, Y , explicada por la relación de Y con las X .

Un valor de $R^2 = 1$ indica que todas las Y observadas caen exactamente sobre la función de regresión ajustada. Toda la variación en la respuesta se explica mediante la regresión. Un valor de $R^2 = 0$ dice que $\hat{Y} = \bar{Y}$ —es decir, $SSR = 0$ —y nada de la variación en Y se explica mediante la regresión. En la práctica, $0 \leq R^2 \leq 1$, y el valor de R^2 debe interpretarse dentro de los extremos 0 y 1.

La cantidad

$$R = \sqrt{R^2} \quad (7.6)$$

se llama *coeficiente de correlación múltiple* y es la correlación entre las respuestas, Y , y los valores ajustados, $\hat{Y}$. Puesto que los valores ajustados predicen las respuestas, R siempre es positiva, de manera que $0 \leq R \leq 1$.

Para la regresión múltiple,

$$F = \frac{R^2}{1 - R^2} \left(\frac{n - k - 1}{k} \right) \quad (7.7)$$

de manera que, si todo lo demás permanece igual, las regresiones significativas (razones F grandes) están asociadas con valores relativamente grandes de R^2 .

El coeficiente de determinación (R^2) siempre se incrementa al agregar una variable independiente, X , a la función de regresión, incluso si esta variable adicional no es importante.³ Por esta razón, algunos analistas prefieren interpretar R^2 ajustada al número de términos en la función de regresión. El coeficiente ajustado de determinación, $\bar{R}^2$, está dado por

$$\bar{R}^2 = 1 - (1 - R^2) \left(\frac{n - 1}{n - k - 1} \right) \quad (7.8)$$

Al igual que R^2 , $\bar{R}^2$ es una medida de la proporción de la variabilidad en la respuesta, Y , explicada por la regresión. Es posible demostrar que $0 \leq \bar{R}^2 \leq R^2$. Cuando el número de observaciones (n) es grande en relación con el número de variables independientes (k), $\bar{R}^2 \approx R^2$. Si $k = 0$, $\hat{Y} = \bar{Y}$ y $\bar{R}^2 = R^2$. En muchas situaciones prácticas, no hay mucha diferencia entre las magnitudes de $\bar{R}^2$ y R^2 .

Ejemplo 7.4

Usando la suma total de cuadrados de la tabla 7-6 y la suma de cuadrados de los residuos del ejemplo 7.3, la descomposición de la suma de cuadrados para el problema del señor Bump es

$$\begin{aligned} SST &= SST + SSE \\ \sum (Y - \bar{Y})^2 &= \sum (\hat{Y} - \bar{Y})^2 + \sum (Y - \hat{Y})^2 \\ 233.6 &= 217.7 + 15.9 \end{aligned}$$

Por consiguiente, usando ambas formas de la ecuación 7.5 para ilustrar los cálculos,

$$R^2 = \frac{217.7}{233.6} = 1 - \frac{15.9}{233.6} = .932$$

y el coeficiente de correlación múltiple es $R = \sqrt{R^2} = \sqrt{.932} = .965$.

Aquí, alrededor del 93% de la variación en el volumen de ventas es explicado por la regresión, es decir, la relación entre las ventas y el precio y los gastos de publicidad. Además, la correlación entre las ventas y las ventas ajustadas es de alrededor de .965, lo que indica un acuerdo cercano entre los valores reales y los pronosticados. En la tabla 7-7 se presenta un resumen del análisis de los datos del señor Bump al respecto.

Variables explicativas individuales

El coeficiente de una X individual en la función de regresión mide el efecto parcial o neto de esa X sobre la respuesta, Y , manteniendo constantes las demás X de la ecuación. Si la regresión se considera como significativa, entonces es de interés examinar la significancia de las variables explicativas individuales. El asunto es éste: Dadas las otras X , ¿es importante el efecto de esta X particular, o es posible eliminar de la función de regresión este término X ? Esta pregunta puede contestarse examinando un valor apropiado de t .

³Aquí, “no es importante” significa “no significativo”. Es decir, el coeficiente de X no es significativamente diferente de cero (véase la sección que sigue sobre las variables individuales de explicativas).

TABLA 7-7 Resumen del análisis de los datos del señor Bump para el ejemplo 7.4

<i>Variables usadas para explicar la variabilidad de Y</i>	R^2	$\Sigma(Y - \hat{Y})^2$
Ninguna	.00	233.6
Precio	.75	59.4
Precio y gastos de publicidad	.93	15.9

Si $H_0: \beta_j = 0$ es verdadera, el *estadístico de prueba*, t , para $t = b_j/s_{b_j}$ tiene una distribución t con $df = n - k - 1$.⁴

Para evaluar la significancia del término j -ésimo, $j = 0, 1, \dots, k$, en la función de regresión, el estadístico de prueba t se compara con un punto porcentual de una distribución t con $n - k - 1$ grados de libertad. Para una prueba en el nivel de significancia α de

$$H_0: \beta_j = 0$$

$$H_1: \beta_j \neq 0$$

si $|t| > t_{\alpha/2}$ se rechaza H_0 . Aquí, $t_{\alpha/2}$ es el punto que deja un área $\alpha/2$ a la derecha de una distribución t con $df = n - k - 1$.

Se debe tener cuidado en la eliminación de la función de regresión de aquellas variables explicativas que se consideran insignificantes por la prueba t ($H_0: \beta_j = 0$ no puede rechazarse). Si las X están relacionadas (multicolinealidad), los coeficientes de los mínimos cuadrados y los valores correspondientes de t pueden cambiar, algunas veces de manera apreciable, si una X individual se elimina de la función de regresión. Por ejemplo, una X que previamente era insignificante puede convertirse en significativa. En consecuencia, si existen varios valores t pequeños (insignificantes), las variables explicativas deben eliminarse de una en una (comenzando con la variable que tiene el valor t más pequeño) en vez de hacerlo por grupos. El proceso se detiene cuando la regresión es significativa y todas las variables explicativas tienen estadísticos t grandes (significativos).

Pronóstico de una respuesta futura

Un pronóstico, $\hat{Y}^*$, de una respuesta futura, Y , para valores nuevos de las X —digamos, $X_1 = X_1^*$, $X_2 = X_2^*, \dots, X_k = X_k^*$ —está dado por la evaluación de la función de regresión ajustada para las X :

$$\hat{Y}^* = b_0 + b_1X_1^* + b_2X_2^* + \dots + b_kX_k^* \quad (7.9)$$

Con un nivel de confianza $1 - \alpha$, un intervalo de predicción para Y toma la forma

$$\hat{Y}^* \pm t_{\alpha/2} \times (\text{Error estándar del pronóstico})$$

El error estándar del pronóstico es una expresión complicada, pero el error estándar de la estimación, $s_{y \cdot x}$, es un componente importante. De hecho, si n es grande y todas las X son muy variables, un intervalo de predicción *aproximado* de $100(1 - \alpha)\%$ para una nueva respuesta Y es

$$(\hat{Y}^* - t_{\alpha/2}s_{y \cdot x}, \hat{Y}^* + t_{\alpha/2}s_{y \cdot x}) \quad (7.10)$$

⁴Aquí, b_j es el coeficiente de mínimos cuadrados para la j -ésima variable explicativa, X_j , y S_{b_j} es la estimación de la desviación estándar (error estándar). Estos dos estadísticos se obtienen normalmente a través de un software como Minitab.

RESULTADO DE LA COMPUTADORA

En la tabla 7-8 se presenta el resultado de computadora para el problema del señor Bump. La revisión de resultado trae consigo las siguientes observaciones (las explicaciones aparecen en la tabla 7-8).

1. Los coeficientes de regresión son -8.25 para el precio y $.585$ para gastos de publicidad. La ecuación de regresión ajustada es $\hat{Y} = 16.4 - 8.25X_1 + .585X_2$.
2. La ecuación de regresión explica el 93.2% de la variación en el volumen de ventas.
3. El error estándar de la estimación es 1.5072 galones. Este valor es una medida de la cantidad en que los valores reales difieren de los valores ajustados.
4. En el capítulo 6, el coeficiente de la pendiente de regresión se sometió a prueba para determinar si era diferente de cero. En la presente situación, el estadístico t grande de -3.76 para la variable de precio, X_1 , y su pequeño valor p (.007) indican que el coeficiente del precio es significativamente diferente de cero (se rechaza $H_0: \beta_1 = 0$). Dada la variable de publicidad, X_2 , en la función de regresión, el precio no puede eliminarse de la función de regresión. De manera análoga, el estadístico t grande de 4.38 para la variable de publicidad, X_2 , y su pequeño valor p (.003) indican que el coeficiente de publicidad es significativamente diferente de cero (se rechaza $H_0: \beta_2 = 0$). Dada la variable del precio, X_1 , en la función de regresión, la variable de publicidad no puede eliminarse de la función de regresión. (Como un punto de referencia para la magnitud de los valores t , con siete grados de libertad, la tabla B-3 indica $t_{.01} = 2.998$.) En resumen, los coeficientes de ambas variables explicativas son significativamente diferentes de cero.
5. El valor p .007 es la probabilidad de obtener un valor de t por lo menos tan grande como -3.76 si la hipótesis $H_0: \beta_1 = 0$ es verdadera. Puesto que esta probabilidad es extremadamente pequeña, es improbable que H_0 sea verdadera, y se rechaza. El coeficiente del precio es significativamente diferente de cero. El valor p .003 es la probabilidad de obtener un valor t por lo menos tan grande como 4.38 si $H_0: \beta_2 = 0$ es verdadera. Puesto que un valor t de esta magnitud es extremadamente improbable, se rechaza, H_0 . El coeficiente de publicidad es significativamente diferente de cero.

TABLA 7-8 Resultado de Minitab para los datos del señor Bump

Correlations: Y, X1, X2

	Y	X1
X1	-0.863	
X2	0.891	-0.654 (6)

Regression Analysis: Y versus X1, X2

The regression equation is

$$Y = 16.4 - 8.25 X1 + 0.585 X2 \quad (1)$$

Presictor	Coef	SE Coef	T	P
Constant	16.406 (1)	4.343	3.78	0.007
X1	-8.248 (1)	2.196	-3.76 (4)	0.007 (5)
X2	0.5851 (1)	0.1337	4.38 (4)	0.003 (5)

$$S = 1.50720 \quad (3) \quad R\text{-Sq} = 93.2\% \quad (2) \quad R\text{-Sq}(\text{adj}) = 91.2\% \quad (9)$$

Analysis of Variance

Source	DF	SS	MS	F	P
Regression	2	217.70 (7)	108.85	47.92 (8)	0.000
Residual Error	7	15.90 (7)	2.27		
Total	9	233.60 (7)			

6. La matriz de correlación se presentó en la tabla 7-2.
7. La descomposición de la suma de cuadrados, $SST = SSR + SSE$ (suma total de cuadrados = suma de cuadrados de la regresión + suma de cuadrados de los errores), se presentó en el ejemplo 7.4.
8. El valor F calculado (47.92) se utiliza para probar la significancia de la regresión. La razón grande F y su valor pequeño p (.000) indican que la regresión es significativa (se rechaza $H_0: \beta_1 = \beta_2 = 0$). La razón F se calcula mediante

$$F = \frac{MSR}{MSE} = \frac{108.85}{2.27} = 47.92$$

Como una referencia para la magnitud de la razón F , la tabla B-5 proporciona el punto superior de 1% de una distribución F con dos y siete grados de libertad como $F_{.01} = 9.55$. La función de regresión explica una cantidad significativa de la variabilidad en las ventas, Y .

9. El cálculo de la R^2 corregida o ajustada, $\bar{R}^2$, es

$$\begin{aligned}\bar{R}^2 &= 1 - (1 - R^2) \left(\frac{n - 1}{n - k - 1} \right) \\ &= 1 - (1 - .932) \left(\frac{10 - 1}{10 - 2 - 1} \right) = 1 - (.068)(1.286) = .912\end{aligned}$$

VARIABLES FICTICIAS

Considere el siguiente ejemplo.

Ejemplo 7.5

Suponga que un analista desea investigar qué tan bien predice el rendimiento en el trabajo una prueba de aptitud. Ocho mujeres y siete hombres realizaron la prueba, la cual mide la destreza para manipular objetos minúsculos. Cada sujeto pasó por un mes de entrenamiento intensivo como ensamblador de aparatos electrónicos, seguido de otro mes como ensamblador real, durante el cual su productividad fue evaluada por medio de un índice cuyos valores iban de 0 a 10 (cero significa improductivo).

Los datos se muestran en la tabla 7-9. Un diagrama de dispersión se presenta en la figura 7-2. Cada mujer trabajadora se representa por un cero y cada trabajador masculino se representa por un 1.

Al observar la figura 7-2 de inmediato se hace evidente que la relación de esta prueba de aptitud con el rendimiento en el trabajo sigue dos patrones distintos, uno aplicable a las mujeres y otro a los hombres.

Algunas veces es necesario determinar cómo se relaciona una variable dependiente con una variable independiente cuando un factor *cualitativo* influye en la situación. Esta relación se establece creando una *variable ficticia*. Existen muchas maneras de identificar cuantitativamente las clases de una variable cualitativa. En este texto se usan los valores 0 y 1.

Las *variables ficticias*, o indicadores ficticios, se utilizan para determinar las relaciones entre variables independientes cualitativas y una variable dependiente.

La técnica de la variable ficticia se ilustra en la figura 7-3. Los puntos de datos de las mujeres se presentan como 0; y los 1 representan a los hombres. Se construyen dos líneas paralelas en el diagrama de dispersión. La de arriba se ajusta los datos de las mujeres; la de abajo se ajusta los puntos de datos de los hombres.

Cada una de estas líneas se obtuvo a partir de una función de regresión ajustada de la forma

$$\hat{Y} = b_0 + b_1X_1 + b_2X_2$$

TABLA 7-9 Datos de la variable ficticia de ensambladores de aparatos electrónicos para el ejemplo 7.5

<i>Sujeto</i>	<i>Calificación del desempeño laboral Y</i>	<i>Calificación en la prueba de aptitud X_1</i>	<i>Género X_2</i>
1	5	60	0(F)
2	4	55	0(F)
3	3	35	0(F)
4	10	96	0(F)
5	2	35	0(F)
6	7	81	0(F)
7	6	65	0(F)
8	9	85	0(F)
9	9	99	1(M)
10	2	43	1(M)
11	8	98	1(M)
12	6	91	1(M)
13	7	95	1(M)
14	3	70	1(M)
15	6	85	1(M)
Totales	87	1,093	

$\bar{Y}_F$ = Media de la calificación del desempeño laboral de las mujeres = 5.75

$\bar{Y}_M$ = Media de la calificación del desempeño laboral de los hombres = 5.86

$\bar{X}_F$ = Media del resultado de la prueba de aptitud para las mujeres = 64

$\bar{X}_M$ = Media del resultado de la prueba de aptitud para los hombres = 83




FIGURA 7-2 Diagrama de dispersión de los datos para el ejemplo 7.5




FIGURA 7-3 Líneas de regresión correspondientes a las variables ficticias para el ejemplo 7.5

donde

X_1 = calificación de la prueba

$X_2 = \begin{cases} 0 & \text{para mujeres} \\ 1 & \text{para hombres} \end{cases}$ variable ficticia

La ecuación individual es equivalente a las siguientes dos ecuaciones:

$$\hat{Y} = b_0 + b_1X_1 \quad \text{para mujeres}$$

$$\hat{Y} = b_0 + b_1X_1 + b_2 = (b_0 + b_2) + b_1X_1 \quad \text{para hombres}$$

Observe que b_2 representa el efecto de un varón sobre el rendimiento en el trabajo, y b_1 representa el efecto de las diferencias en las calificaciones de las pruebas de aptitud (se supone que el valor de b_1 es el mismo tanto para hombres como para mujeres). El punto importante es que una ecuación de regresión múltiple producirá las dos líneas de estimación mostradas en la figura 7-3. La línea de arriba es la relación estimada para mujeres, y la línea de abajo es la relación estimada para hombres. Uno podría imaginarse a X_2 como una variable “apagador” que está “encendido” cuando se hace una observación para un hombre y “apagado” cuando se hace para una mujer.

Ejemplo 7.6

La ecuación de regresión múltiple estimada para los datos del ejemplo 7.5 se presenta en los resultados de Minitab de la tabla 7-10. Ésta es

$$\hat{Y} = -1.96 + .12X_1 - 2.18X_2$$

TABLA 7-10 Resultados de Minitab del ejemplo 7.6**Correlations: Ratings, Test, Gender**

	Rating	Test
Test	0.876	
Gender	0.021	0.428

Regression Analysis: Rating versus Test, Gender

The regression equation is

$$\text{Rating} = -1.96 + 0.120 \text{ Test} - 2.18 \text{ Gender}$$

Predictor	Coef	SE Coef	T	P
Constant	-1.9565	0.7068	-2.77	0.017
Test	0.12041	0.01015	11.86	0.000
Gender	-2.1807	0.4503	-4.84	0.000

$$S = 0.7863 \quad R\text{-sq} = 92.1\% \quad R\text{-sq}(\text{adj}) = 90.8\%$$

Analysis of Variance

Source	DF	SS	MS	F	P
Regression	2	86.981	43.491	70.35	0.000
Residual Error	12	7.419	0.618		
Total	14	94.400			

Para los dos valores (0 y 1) de X_2 , la ecuación ajustada se convierte en

$$\hat{Y} = -1.96 + .12X_1 - 2.18(0) = -1.96 + .12X_1 \quad \text{para mujeres}$$

y

$$\hat{Y} = -1.96 + .12X_1 - 2.18(1) = -4.14 + .12X_1 \quad \text{para hombres}$$

Estas ecuaciones se pueden interpretar de la siguiente manera: el valor del coeficiente de regresión $b_1 = .12$, el cual es la pendiente de cada una de las líneas, es el incremento promedio estimado de la calificación del desempeño laboral por cada unidad de incremento en la calificación de la prueba de aptitud. Este coeficiente se aplica tanto a los hombres como a las mujeres.

El otro coeficiente de regresión, $b_2 = -2.18$, se aplica sólo a los hombres. Para un hombre que realiza la prueba, la calificación del desempeño laboral estimada se reduce, en relación con las mujeres que hacen la prueba, en 2.18 unidades cuando la calificación de aptitud se mantiene constante.

Un examen de los promedios de las variables Y y X_1 clasificadas por género, nos ayuda a comprender este resultado. La tabla 7-9 indica que la media de las calificaciones del desempeño laboral fueron aproximadamente iguales para los hombres, 5.86, y las mujeres, 5.75. Sin embargo, los hombres obtuvieron una calificación significativamente más alta (83) en la prueba de aptitud que las mujeres (64). Por lo tanto, si dos candidatos, un hombre y una mujer, realizan la prueba de aptitud y ambos obtienen una calificación de 70, la calificación del desempeño laboral estimada de la mujer sería 2.18 más alta que la del hombre, puesto que

$$\text{Mujer: } \hat{Y} = -1.96 + .12X_1 = -1.96 + .12(70) = 6.44$$

$$\text{Hombre: } \hat{Y} = -4.14 + .12X_1 = -4.14 + .12(70) = 4.26$$

Una mirada a la matriz de correlación de la tabla 7-10 ofrece una visión interesante. Existe una relación lineal fuerte entre el rendimiento en el trabajo y la prueba de aptitud porque $r_{12} = .876$. Si solamente se usara la calificación de la prueba de aptitud para predecir el rendimiento, se explicaría alrededor del 77% ($.876^2 = .767$) de la variación en las calificaciones del rendimiento en el trabajo.

El coeficiente de correlación $r_{13} = .02$ indica que prácticamente no existe relación entre el género y el rendimiento en el trabajo. Esta conclusión también se hace evidente a partir del hecho de que los índices de rendimiento promedio para hombres y mujeres son aproximadamente iguales (5.86 contra 5.75). A primera vista, uno podría concluir que el conocimiento de que un candidato sea

hombre o mujer no es una información útil. Sin embargo, la relación moderada, $r_{23} = .428$, entre el género y la calificación en la prueba de aptitud indica que la prueba podría hacer una discriminación entre sexos. Los hombres parecen desempeñarse mejor en la prueba que las mujeres (83 contra 64). Quizás en la prueba se requiere algún elemento de fortaleza que no se requiere en el trabajo.

Cuando se usan tanto los resultados de la prueba como el género para pronosticar el rendimiento en el trabajo, se explica el 92% de la varianza. Este resultado sugiere que ambas variables hacen una contribución valiosa al rendimiento pronosticado. La calificación de la prueba de aptitud explica el 77% de la varianza, y el género considerado junto con la calificación de la prueba de aptitud agrega otro 15%. Los estadísticos t calculados, 11.86 (valor- $p = .000$) y -4.84 (valor- $p = .000$), para la calificación de la prueba de aptitud y el género, respectivamente, indican que ambas variables explicativas deben incluirse en la función final de regresión.

MULTICOLINEALIDAD

En muchos problemas de regresión, los datos se registran rutinariamente en vez de ser generados por posiciones previamente elegidas de las variables independientes. En estos casos, las variables independientes son a menudo linealmente dependientes o *multicolineales*. Por ejemplo, en el trabajo de avalúos, el precio de venta de una casa puede estar relacionado con variables explicativas como la edad, el espacio habitable en pies cuadrados, el número de baños, el número de habitaciones que no son baños, las dimensiones del terreno y un índice de la calidad de la construcción. El espacio habitable, el número de cuartos y el número de baños, desde luego, deben “moverse juntos”. Si una de estas variables aumenta, las otras generalmente se incrementarán.

Si esta dependencia lineal es menos perfecta, todavía se puede obtener la estimación de mínimos cuadrados de los coeficientes del modelo de regresión. Sin embargo, estas estimaciones tienden a ser inestables —sus valores pueden cambiar drásticamente con cambios ligeros en los datos— e inflarse (sus valores son más grandes de lo esperado). En particular, los coeficientes individuales pueden tener el signo equivocado, y los estadísticos t para juzgar la significancia de los términos individuales pueden ser insignificantes, aun cuando la prueba F indique que la relación es significativa. Finalmente, el cálculo de los estimados de mínimos cuadrados es sensible a errores de redondeo.

La *multicolinealidad* es la situación en la cual las variables independientes de una ecuación de regresión múltiple están sumamente intercorrelacionadas. Es decir, existe una relación lineal entre dos o más variables independientes.

La fortaleza de la multicolinealidad se mide por el factor de inflación de la varianza (VIF , por las siglas de variance inflation factor):⁵

$$VIF_j = \frac{1}{1 - R_j^2} \quad j = 1, 2, \dots, k \quad (7.11)$$

Aquí, R_j^2 es el coeficiente de determinación de la regresión de la j -ésima variable independiente con el resto $k - 1$ de las variables independientes. Para dos variables independientes $k = 2$, R_j^2 es el cuadrado de su correlación muestral, r .

Si la j -ésima variable explicativa, X_j , no está relacionada con el resto de las X , $R_j^2 = 0$ y el $VIF_j = 1$. Si existe una relación, entonces $VIF_j > 1$. Por ejemplo, cuando R_j^2 es igual a .90, $VIF_j = 1/(1 - .90) = 10$.

Un VIF próximo a 1 sugiere que la multicolinealidad no es un problema para esa variable independiente. Su coeficiente estimado y el valor t asociado no cambiarán mucho conforme las otras variables independientes se agregan o se eliminan de la ecuación de regresión. Un VIF

⁵El factor de inflación de la varianza (VIF) toma su nombre del hecho de que $s_{b_j} \propto VIF_j$. La desviación estándar estimada (error estándar) del coeficiente de mínimos cuadrados, b_j , se incrementa conforme VIF_j aumenta.

mucho más grande que 1 indica que el coeficiente estimado de esa variable independiente es inestable. Su valor y su estadístico t asociado pueden cambiar considerablemente conforme las otras variables independientes se agregan o se eliminan de la ecuación de regresión. Un VIF grande significa, en esencia, que existe información redundante entre las variables explicativas. La información expresada por una variable con un VIF grande se explica por las variables explicativas restantes. Por lo tanto, la multicolinealidad hace difícil la interpretación del efecto de una variable explicativa individual sobre la respuesta (variable dependiente).

Ejemplo 7.7

Un componente grande del costo de poseer una empresa periodística es el papel. Las editoriales de periódicos están interesadas en los factores que determinan el consumo anual de papel. En un estudio (véase Johnson y Wichern, 1997), los datos sobre el consumo anual de papel (Y), el número de periódicos en una ciudad (X_1), el logaritmo⁶ del número de familias en una ciudad (X_2), y el logaritmo de las ventas totales al menudeo en una ciudad (X_3) se recopilieron para 15 ciudades $n = 15$. El arreglo de correlación para las tres variables explicativas y el resultado de Minitab de un análisis de regresión que relaciona el consumo de papel con las variables explicativas se encuentran en la tabla 7-11.

El estadístico F (18.54) y su valor p (.000) indican claramente que la regresión es significativa. El estadístico t de cada una de las variables independientes es pequeño con un valor p relativamente grande. Debe concluirse, por ejemplo, que la variable LnFamily no es significativa, siempre que las otras variables explicativas permanezcan en la función de regresión. Esto sugiere que el término $\beta_2 X_2$ puede eliminarse de la función de regresión si los términos restantes, $\beta_1 X_1$ y $\beta_3 X_3$, se conservan. De manera análoga, parece que $\beta_3 X_3$ puede eliminarse si $\beta_1 X_1$ y $\beta_2 X_2$ permanecen en la función de regresión. El valor t (1.69) asociado con los periódicos es marginalmente significativo, pero el término $\beta_1 X_1$ también podría eliminarse si las otras variables explicativas permanecen en la ecuación. Aquí, la regresión es significativa, pero cada una de las variables explicativas no es significativa. ¿Por qué?

La columna VIF de la tabla 7-11 brinda la respuesta. Puesto que $VIF = 1.7$ para periódicos (Papers), esta variable explicativa está muy débilmente relacionada (VIF cerca de 1) con las variables explicativas restantes, LnFamily y LnRetSales. El $VIF = 7.4$ de LnFamily es relativamente grande, lo

TABLA 7-11 Resultado de Minitab para el ejemplo 7.7: tres variables explicativas

Correlations: Papers, LnFamily, LnRetSales

	Papers	LnFamily
LnFamily	0.600	
LnRetSales	0.643	0.930

Regression Analysis: Newsprint versus Papers, LnFamily, LnRetSales

The regression equation is

$$\text{Newsprint} = -56388 + 2385 \text{ Papers} + 1859 \text{ LnFamily} + 3455 \text{ LnRetSales}$$

Predictor	Coef	SE Coef	T	P	VIF
Constant	-56388	13206	-4.27	0.001	
Papers	2385	1410	1.69	0.119	1.7
LnFamily	1859	2346	0.79	0.445	7.4
LnRetSales	3455	2590	1.33	0.209	8.1

$$S = 1849 \quad R\text{-Sq} = 83.8\% \quad R\text{-Sq}(\text{adj}) = 79.0\%$$

Analysis of Variance

Source	DF	SS	MS	F	P
Regression	3	190239371	63413124	18.54	0.000
Residual Error	11	37621478	3420134		
Total	14	227860849			

⁶Los logaritmos del número de familias y de las ventas totales se emplean para hacer los números menos positivamente sesgados y más manejables.

TABLA 7-12 Resultado de Minitab para el ejemplo 7.7:
dos variables explicativas**Regression Analysis: Newsprint versus Papers, LnRetSales**

The regression equation is

$$\text{Newsprint} = -59766 + 2393 \text{ Papers} + 5279 \text{ LnRetSales}$$

Predictor	Coef	SE Coef	T	P	VIF
Constant	-59766	12304	-4.86	0.000	
Papers	2393	1388	1.72	0.110	1.7
LnRetSales	5279	1171	4.51	0.001	1.7

S = 1820 R-sq = 82.5% R-sq(adj) = 79.6%

Analysis of Variance

Source	DF	SS	MS	F	P
Regression	2	188090489	94045244	28.38	0.000
Residual Error	12	39770360	3314197		
Total	14	227860849			

que indica que esta variable se encuentra linealmente relacionada con las variables explicativas restantes. Además, el $VIF = 8.1$ de LnRetSales indica que LnRetSales está relacionada con el resto de las variables explicativas. Puesto que Papers está débilmente relacionada con LnFamily y LnRetSales, la relación entre las variables explicativas es esencialmente la relación entre LnFamily y LnRetSales. De hecho, la correlación muestral entre LnFamily y LnRetSales es $r = .93$, lo que indica una asociación lineal fuerte.

Las variables LnFamily y LnRetSales son muy similares en su capacidad para explicar el consumo de papel. Sólo necesitamos una, no ambas, en la función de regresión. El resultado de Minitab de un análisis de regresión eliminando LnFamily (estadístico t más pequeño) de la función de regresión se presenta en la tabla 7-12.

Advierta que el coeficiente de Papers es aproximadamente igual para las dos regresiones. Sin embargo, los coeficientes de LnRetSales son considerablemente diferentes (3,455 para las variables explicativas $k = 3$ y 5,279 para variables explicativas $k = 2$). Además, para la segunda regresión, la variable LnRetSales es claramente significativa ($t = 4.51$ con valor $p = .001$). Con Papers en el modelo, LnRetSales es una variable explicativa adicional importante del consumo de papel. Las R^2 para las dos regresiones son casi iguales, aproximadamente .83, como lo son los errores estándar de las estimaciones, $s_{y \cdot x's} = 1,849$ y $s_{y \cdot x's} = 1,820$, respectivamente. Por último, el VIF común = 1.7 para los dos factores explicativos en el segundo modelo indica que la multicolinealidad ya no es un problema. Como lo confirma un análisis residual, para las variables consideradas, la regresión de Newsprint sobre Papers y LnRetSales es completamente adecuada.

Si la estimación de los efectos por separado de las variables explicativas es importante y la multicolinealidad parece ser un problema, ¿qué se debe hacer? Existen varias maneras para manejar la multicolinealidad severa, como veremos en seguida. Ninguna de ellas es completamente satisfactoria o factible

- Cree nuevas variables X (llamándolas $\tilde{X}$) luego escale todas las variables independientes de acuerdo con la fórmula

$$\tilde{X} = \frac{X_{ij} - \bar{X}_j}{\sqrt{\frac{1}{n} \sum_i (X_{ij} - \bar{X}_j)^2}} \quad j = 1, 2, \dots, k; \quad i = 1, 2, \dots, n \quad (7.12)$$

Cada una de estas variables nuevas tiene una media muestral de 0 y la misma desviación estándar muestral. Los cálculos de la regresión con las nuevas X son menos sensibles al error de redondeo en presencia de la multicolinealidad severa.

- Identifique y elimine una o más de las variables independientes redundantes de la función de regresión. (Este método se usó en el ejemplo 7.7).

- Considere otros procedimientos de estimación que no sean los mínimos cuadrados.⁷
- Realice una regresión de la respuesta, Y , sobre las nuevas X que no están correlacionadas unas con otras. Es posible elaborar combinaciones lineales de las X originales que no están correlacionadas.⁸
- Seleccione cuidadosamente las variables independientes potenciales al principio del estudio. Trate de eliminar las variables que “dicen lo mismo”

SELECCIÓN DE LA “MEJOR” ECUACIÓN DE REGRESIÓN

¿Cómo se desarrolla la mejor ecuación de regresión múltiple para pronosticar una variable de interés? El *primer paso* implica la selección de un conjunto completo de variables explicativas potenciales. Se debe incluir cualquier variable que pudiera agregar exactitud al pronóstico. En la selección de la ecuación final, el analista generalmente se enfrenta al dilema de obtener el pronóstico más exacto al menor costo. En otras palabras, cuando elegimos las variables explicativas para incluirlas en la ecuación final, debemos evaluarlas usando los siguientes dos criterios antagónicos:

1. El analista desea que la ecuación incluya tantas variables explicativas como sea posible.⁹
2. Puesto que obtener y monitorear la información de un gran número de X es una labor costosa, la ecuación debe incluir menos variables explicativas como sea posible. Por lo general, la ecuación más simple es la mejor.

La selección de la mejor ecuación de regresión, por lo regular, implica un compromiso entre estos extremos, y el criterio personal será una parte obligatoria de cualquier solución.

Después de recopilar una lista aparentemente completa de variables explicativas potenciales, el *segundo paso* es eliminar las variables independientes que no parezcan adecuadas. Una variable independiente: **1.** quizá no sea fundamental para el problema (debe haber alguna relación posible entre la variable dependiente y la variable independiente), **2.** podría estar sujeta a errores de medición grandes, **3.** puede ser un duplicado de otra variable independiente (multicolinealidad), o **4.** tal vez sea difícil medirla con exactitud (los datos exactos no están disponibles o sería muy costoso obtenerlos).

El *tercer paso* es recortar la lista de variables explicativas de manera que se obtenga la “mejor” selección de variables independientes. En el material que sigue se analizan las técnicas actualmente en uso. No se puede decir que alguno de los procedimientos de búsqueda permita obtener el “mejor” conjunto de variables independientes. De hecho, no es frecuente que exista un solo conjunto “mejor”. Para agravar la confusión, las diferentes técnicas no necesariamente conducen a la misma ecuación final de predicción. El proceso completo de selección de la variable es muy subjetivo. La ventaja principal de los procedimientos automáticos de búsqueda es que los analistas pueden enfocar su atención en las áreas fundamentales del problema.

Para estudiar diferentes procedimientos de búsqueda, se presenta un ejemplo sencillo que incluye cinco variables independientes potenciales.

Ejemplo 7.8

Pam Weigand, la directora de personal de Zurenko Pharmaceutical Company, está interesada en pronosticar si un candidato particular se convertirá en un buen vendedor. Ella decide usar las primeras ventas mensuales como la variable dependiente (Y) y selecciona para el análisis las siguientes variables independientes

⁷Los procedimientos alternativos para la estimación de los parámetros de la regresión están más allá del alcance de este libro. Al lector interesado se le recomienda consultar el trabajo de Draper y Smith (1988).

⁸Otra vez, los procedimientos para la creación de combinaciones lineales de las X que no están correlacionadas se encuentran más allá del alcance de este libro. Draper y Smith (1988) analizan estas técnicas.

⁹Recuerde que siempre que se agrega una variable explicativa nueva a la ecuación de regresión múltiple, R^2 aumenta. Por ello, es importante que una nueva variable explicativa haga una contribución *significativa* a la ecuación de regresión.

X_1 = prueba de aptitud para ventas

X_2 = edad, en años

X_3 = prueba de ansiedad

X_4 = experiencia en años

X_5 = promedio de calificaciones (*grade point average*)

La directora de personal recopila los datos presentados en la tabla 7-13, y asigna a su analista la tarea de obtener el “mejor” conjunto de variables independientes para pronosticar la habilidad para trabajar en ventas.

El primer paso es obtener una matriz de correlación para todas las variables usando un programa de computadora. Esta matriz le dará el conocimiento esencial acerca de las relaciones básicas entre las variables.

El examen de la matriz de correlación en la tabla 7-14 revela que la calificación del examen de aptitud para ventas, la edad, la experiencia y el GPA están relacionados positivamente con la habilidad para trabajar en ventas y tienen potencial como buenas variables explicativas. La calificación en la prueba de ansiedad indica una correlación negativa baja con las ventas y probablemente no es una variable explicativa importante. El análisis posterior indica que la edad está correlacionada modera-

TABLA 7-13 Datos de la Zurenko Pharmaceutical para el ejemplo 7.8

<i>Ventas de un mes (unidades)</i>	<i>Calificación en la prueba de aptitud</i>	<i>Edad (años)</i>	<i>Calificación en la prueba de ansiedad</i>	<i>Experiencia (años)</i>	<i>GPA de la preparatoria</i>
44	10	22.1	4.9	0	2.4
47	19	22.5	3.0	1	2.6
60	27	23.1	1.5	0	2.8
71	31	24.0	.6	3	2.7
61	64	22.6	1.8	2	2.0
60	81	21.7	3.3	1	2.5
58	42	23.8	3.2	0	2.5
56	67	22.0	2.1	0	2.3
66	48	22.4	6.0	1	2.8
61	64	22.6	1.8	1	3.4
51	57	21.1	3.8	0	3.0
47	10	22.5	4.5	1	2.7
53	48	22.2	4.5	0	2.8
74	96	24.8	.1	3	3.8
65	75	22.6	.9	0	3.7
33	12	20.5	4.8	0	2.1
54	47	21.9	2.3	1	1.8
39	20	20.5	3.0	2	1.5
52	73	20.8	.3	2	1.9
30	4	20.0	2.7	0	2.2
58	9	23.3	4.4	1	2.8
59	98	21.3	3.9	1	2.9
52	27	22.9	1.4	2	3.2
56	59	22.3	2.7	1	2.7
49	23	22.6	2.7	1	2.4
63	90	22.4	2.2	2	2.6
61	34	23.8	.7	1	3.4
39	16	20.6	3.1	1	2.3
62	32	24.4	.6	3	4.0
78	94	25.0	4.6	5	3.6

TABLA 7-14 Correlaciones: Ventas, aptitud, edad, ansiedad, experiencia, GPA

Correlations: Sales, Aptitude, Age, Anxiety, Experience, GPA					
	Sales	Aptitude	Age	Anxiety	Experience
Aptitude	0.676				
Age	0.798	0.228			
Anxiety	-0.296	-0.222	-0.287		
Experience	0.550	0.350	0.540	-0.279	
GPA	0.622	0.318	0.695	-0.244	0.312

damente tanto con el GPA como con la experiencia. La presencia de estas interrelaciones debe considerarse en el intento por encontrar el mejor conjunto posible de variables explicativas.

Se presentan dos procedimientos: todas las regresiones posibles y la regresión por pasos.

Todas las regresiones posibles

El procedimiento requiere la investigación de todas las ecuaciones de regresión posibles que implican las variables independientes potenciales. El analista inicia con una ecuación que no contiene variables independientes y luego procede al análisis de todas las combinaciones posibles para seleccionar el mejor conjunto de variables explicativas.

Con el *enfoque de todas las regresiones posibles* se pueden usar diferentes criterios para comparar varias ecuaciones de regresión. Aquí se analizará sólo la técnica de la R^2 la cual contempla cuatro pasos

Este procedimiento requiere primero el ajuste de cada modelo de regresión posible que incluye la variable dependiente y cualquier número de variables independientes. Cada variable independiente puede estar o no en la ecuación (dos posibles resultados), y este hecho es verdad para todas las variables independientes. Por lo tanto, existen en total 2^k ecuaciones (donde k es el número de variables independientes). De esta forma, si existen ocho variables independientes a considerar ($k = 8$), habrá que examinar $2^8 = 256$ ecuaciones.

El segundo paso del procedimiento es dividir las ecuaciones en conjuntos de acuerdo con el número de parámetros que se estimarán.

Ejemplo 7.9

Los resultados de todas las regresiones posibles para la Zurenko Pharmaceutical Company se presentan en la tabla 7-15. Observe que la tabla 7-15 está dividida en seis conjuntos de resultados de las ecuaciones de regresión. Este agrupamiento coincide con el número de parámetros contenidos en cada ecuación.

El tercer paso consiste en la selección de la mejor variable (o variables) independiente(s) para cada agrupamiento de parámetros. La ecuación con la R^2 más alta se considera la mejor. Con base en los resultados del ejemplo 7.9, la mejor ecuación de cada grupo listado en la tabla 7-15 se presenta en la tabla 7-16

El cuarto paso supone tomar la decisión subjetiva: “¿Cuál ecuación es la mejor?”. Por un lado, el analista desea la R^2 más grande posible; por otro, quiere la ecuación más sencilla posible. El enfoque de todas las regresiones posibles supone que el número de puntos de datos, n , excede el número de parámetros, $k + 1$.

Ejemplo 7.10

El analista está intentando encontrar el punto en el cual agregar variables independientes para el problema de la Zurenko Pharmaceutical ya no vale la pena porque conduce a un incremento muy pequeño en R^2 . Los resultados en la tabla 7-16 indican claramente que no es necesario sumar varia-

TABLA 7-15 Valores de R^2 para todas las regresiones posibles de Zurenko Pharmaceutical; ejemplo 7.9

<i>Variables independientes empleadas</i>	<i>Número de parámetros</i>	<i>Grados de libertad de los errores</i>	R^2
Ninguno	1	29	.0000
X_1	2	28	.4570
X_2	2	28	.6370
X_3	2	28	.0880
X_4	2	28	.3020
X_5	2	28	.3870
X_1, X_2	3	27	.8948
X_1, X_3	3	27	.4790
X_1, X_4	3	27	.5690
X_1, X_5	3	27	.6410
X_2, X_3	3	27	.6420
X_2, X_4	3	27	.6570
X_2, X_5	3	27	.6460
X_3, X_4	3	27	.3240
X_3, X_5	3	27	.4090
X_4, X_5	3	27	.5270
X_1, X_2, X_3	4	26	.8951
X_1, X_2, X_4	4	26	.8948
X_1, X_2, X_5	4	26	.8953
X_1, X_3, X_4	4	26	.5750
X_1, X_3, X_5	4	26	.6460
X_1, X_4, X_5	4	26	.7010
X_2, X_3, X_4	4	26	.6590
X_2, X_3, X_5	4	26	.6500
X_2, X_4, X_5	4	26	.6690
X_3, X_4, X_5	4	26	.5310
X_1, X_2, X_3, X_4	5	25	.8951
X_1, X_2, X_3, X_5	5	25	.8955
X_1, X_2, X_4, X_5	5	25	.8953
X_1, X_3, X_4, X_5	5	25	.7010
X_2, X_3, X_4, X_5	5	25	.6710
X_1, X_2, X_3, X_4, X_5	6	24	.8955

TABLA 7-16 Mejores ecuaciones de regresión de la Zurenko Pharmaceutical; ejemplo 7.9

<i>Número de parámetros</i>	<i>Variables independientes</i>	<i>Grados de libertad de los errores</i>	R^2
1	Ninguno	29	.0000
2	X_2	28	.6370
3	X_1, X_2	27	.8948
4	X_1, X_2, X_5	26	.8953
5	X_1, X_2, X_3, X_5	25	.8955
6	X_1, X_2, X_3, X_4, X_5	24	.8955

bles después de la prueba de aptitud para ventas (X_1) y la edad (X_2). Por lo tanto, la ecuación final de regresión ajustada tiene la forma

$$\hat{Y} = b_0 + b_1X_1 + b_2X_2$$

y explica el 89.48% de la variación en Y .

Draper y Smith (1998) resumen así el procedimiento de todas las regresiones posibles:

En general, el análisis de todas las regresiones no está justificado. Aunque significa que el investigador ha “considerado todas las posibilidades”, también significa que ha examinado un gran número de ecuaciones de regresión que una persona inteligente a menudo rechazaría de inmediato. El tiempo de computadora utilizado es un despilfarro y tan sólo el trabajo físico de examinar todos los reportes de resultados de la computadora es enorme cuando se examinan más de unas cuantas variables. Es preferible alguna clase de selección de un procedimiento que acorte esta tarea. (p. 333)

Regresión por pasos

El procedimiento de regresión por pasos agrega al modelo una variable independiente a la vez. Cuando se utiliza este procedimiento se puede manejar un número grande de variables independientes en una sola corrida en la computadora.

La regresión por pasos puede describirse mejor listando los pasos básicos (el algoritmo) para realizar los cálculos.

1. Se consideran todas las regresiones *simples* posibles. La variable explicativa que explica la proporción significativa más grande de la variación de Y (es decir, tiene la correlación más grande con la respuesta) es la primera variable que se introduce en la ecuación de regresión.
2. La siguiente variable en introducirse a la ecuación es la que (fuera de aquellas no incluidas) hace la mayor contribución significativa a la suma de cuadrados de la regresión. La significancia de la contribución se determina mediante una prueba F . El valor del estadístico F que debe sobrepasarse antes de que la contribución de una variable se considere significativa a menudo se conoce como F de entrada (F to enter).
3. Una vez que una variable adicional se ha incluido en la ecuación, se hace una prueba de significancia de las contribuciones individuales a la suma de cuadrados de regresión de las otras variables *que ya están en la ecuación* usando pruebas F . Si el estadístico F es menor que un valor llamado F de salida (F to remove), la variable se elimina de la ecuación de regresión.
4. Los pasos 2 y 3 se repiten hasta que todas las adiciones posibles sean no significativas y todas las eliminaciones posibles sean significativas. En este punto, la selección se detiene.

La *regresión por pasos* permite a las variables explicativas entrar o salir de la función de regresión en diferentes etapas de su desarrollo. Una variable independiente se elimina del modelo si no tiene una contribución significativa cuando se agrega una nueva variable.

El usuario de un programa de regresión por pasos suministra los valores que deciden cuándo una variable puede entrar y cuándo una variable se elimina. Puesto que los estadísticos F usados en la regresión por pasos son tales que $F = t^2$ donde t es el estadístico t para probar la significancia de una variable explicativa, $F = 4$ (correspondiente a $|t| = 2$) es una opción común tanto para F de entrada y la F de salida. Una F de entrada de 4 es esencialmente equivalente a probar la significancia de una variable explicativa con un nivel de 5%. El programa por pasos de Minitab permite al usuario seleccionar un nivel α para introducir y eliminar variables, o

bien, el valor F para introducir y eliminar variables. Usar un valor α de .05 es aproximadamente equivalente a emplear $F = 4$. Los valores actuales predeterminados de Minitab son $\alpha = .15$ y $F = 4$.

El resultado del procedimiento por pasos es un modelo que contiene sólo variables independientes con valores t que son significativos en el nivel especificado. Sin embargo, el desarrollo del procedimiento por pasos no garantiza que la regresión por pasos permita seleccionar, por ejemplo, las tres mejores variables explicativas. Además, un método de selección automática no es capaz de indicar cuándo son útiles las transformaciones de las variables, ni necesariamente evita el problema de la multicolinealidad. Finalmente, la regresión por pasos no puede crear variables importantes que no sean suministradas por el usuario. Es necesario pensar cuidadosamente acerca de la colección de variables independientes que se suministra a un programa de regresión por pasos.

El procedimiento por pasos se ilustra en el ejemplo 7.11.

Ejemplo 7.11

Vamos a “resolver” el problema de Zurenko Pharmaceutical usando la regresión por pasos.

Pam examina la matriz de correlación presentada en la tabla 7-14 y decide que, cuando ella corra el análisis por pasos, la variable de la edad entrará primero al modelo porque tiene la correlación más grande con las ventas ($r_{1,3} = .798$) y explicará el 63.7% ($.798^2$) de la variación en las ventas.

Ella observa que la calificación en la prueba de aptitud probablemente será la segunda en entrar al modelo porque está fuertemente relacionada con las ventas ($r_{1,2} = .676$) pero no está fuertemente relacionada con la variable de la edad ($r_{2,3} = .228$) ya incluida en el modelo.

Pam también advierte que las otras variables probablemente no calificarán como buenas variables explicativas. La calificación en la prueba de ansiedad no será una buena variable explicativa porque no está bien relacionada con las ventas ($r_{1,4} = -.296$). Las variables de experiencia y GPA podrían tener potencial como buenas variables explicativas ($r_{1,5} = .550$ y $r_{1,6} = .622$, respectivamente). Sin embargo, ambas variables explicativas tienen un problema potencial de multicolinealidad con la variable de la edad ($r_{3,5} = .540$ y $r_{3,6} = .695$, respectivamente).

Los comandos de Minitab para correr un análisis de regresión por pasos para este ejemplo se describen en la sección de aplicaciones de Minitab al final del capítulo. La salida para esta regresión por pasos se presenta en la tabla 7-17. El análisis por pasos se aplica de acuerdo con los siguientes pasos.

TABLA 7-17 Regresión por pasos para el ejemplo 7.11: Ventas contra aptitud, edad, ansiedad, experiencia y GPA

Alpha-to-Enter: 0.05 Alpha-to-Remove: 0.05		
Response is Sales on 5 predictors, with N = 30		
Step	1	2
Constant	-100.85	-86.79
Age	6.97	5.93
T-Value	7.01	10.60
P-Value	0.000	0.000
Aptitude		0.200
T-Value		8.13
P-Value		0.000
S	6.85	3.75
R-Sq	63.70	89.48
R-Sq(adj)	62.41	88.70
Mallows Cp	57.4	0.2

Paso 1. El modelo después del paso 1 es

$$\text{Ventas} = -100.85 + 6.97 (\text{Edad})$$

Como Pam estableció, la variable de la edad se introduce primero al modelo y explica el 63.7% de la varianza en las ventas. Puesto que el valor p de .000 es menor que el valor α de .05, se agrega la edad al modelo. Recuerde que el valor p es la probabilidad de obtener un estadístico t tan grande como 7.01 por casualidad. La regla de decisión de Minitab que Pam seleccionó fue introducir la variable si el valor p era menor que $\alpha = .05$.

Observe que $t = 7.01 < 2.048$, el punto superior que deja a la derecha un área de 0.025 en una distribución t con 28 ($n - k - 1 = 30 - 1 - 1$) grados de libertad. De este modo, en el nivel de significancia .05, la hipótesis $H_0: \beta_1 = 0$ se rechaza en favor de $H_1: \beta_1 \neq 0$. Puesto que $t^2 = F$ o $2.048^2 = 4.19$, una F de entrada de 4 también es esencialmente equivalente a la prueba de significancia de una variable explicativa en el nivel del 5%. En este caso, puesto que el coeficiente de la variable de la edad es a todas luces significativamente diferente de cero, la edad entra a la ecuación de regresión y el procedimiento ahora continúa hacia el paso 2.

Paso 2. El modelo después del paso 2 es

$$\text{Ventas} = -86.79 + 5.93 (\text{Edad}) + 0.200 (\text{Aptitud})$$

Este modelo explica el 89.48% de la variación en las ventas.

La hipótesis nula y la hipótesis alternativa para determinar si el coeficiente de regresión de la calificación en la prueba de aptitud es significativamente diferente de cero son

$$\begin{aligned} H_0: \beta_2 &= 0 \\ H_1: \beta_2 &\neq 0 \end{aligned}$$

De nuevo, el valor p de .000 es menor que el valor α de .05, y la calificación en la prueba de aptitud se agrega al modelo. El coeficiente de regresión de la calificación de la prueba de aptitud es significativamente diferente de cero y la probabilidad de que esto ocurra tan sólo por error de muestreo es aproximadamente de cero. Este resultado significa que la calificación en la prueba de aptitud es una variable importante cuando se utiliza en conjunto con la edad.

El estadístico crítico t basado en 27 ($n - k - 1 = 30 - 2 - 1$) grados de libertad es 2.052.¹⁰ La razón t calculada que se encuentra en el resultado de Minitab es 8.13, una cifra mayor que 2.052. Usando la prueba t , la hipótesis nula también se rechaza.

Advierta que el valor p del estadístico t de la variable de la edad, .000, sigue siendo muy pequeño. La edad aún es una variable explicativa significativa de las ventas. El procedimiento ahora avanza hacia el paso 3.

Paso 3. La computadora ahora considera agregar una tercera variable explicativa, en vista de que X_1 (la edad) y X_2 (la calificación en la prueba de aptitud) están en la ecuación de regresión. Ninguna de las variables independientes restantes es significativa (con un valor p menor que .05) cuando corre en combinación con X_1 y X_2 , de manera que el procedimiento por pasos concluye.

El modelo final que seleccionó Pam mediante el procedimiento de los pasos es el modelo de dos variables explicativas descrito en el paso 2.

Notas finales sobre la regresión por pasos

La técnica de regresión por pasos es extremadamente fácil de usar. Por desgracia, también es extremadamente fácil hacer un uso inadecuado de esta técnica. Los analistas que desarrollan un modelo de regresión a menudo generan un conjunto grande de variables independientes potenciales y luego dejan que el procedimiento por pasos determine cuáles son significativas. El problema es que, cuando se analiza un grupo grande de variables independientes, se realizan muchas pruebas t y es probable que se presente el error tipo I (agregar una variable no significativa). Es decir, el modelo final podría contener una variable que no está linealmente relacionada con la variable dependiente y que se introdujo al modelo de manera fortuita.

¹⁰Otra vez, puesto que $2.052^2 = 4.21$, el uso de una F de entrada de 4 es aproximadamente equivalente que hacer una prueba de significancia de una variable explicativa con un nivel de .05.

Como se mencionó anteriormente, existe otro problema implicado en la selección inicial de las variables independientes potenciales. Cuando se seleccionan estas variables, a menudo se omiten términos de alto orden (curvilíneos, no lineales e interacción) para dejar manejable el número de variables. Así, es posible que muchas variables importantes se omitan del modelo desde el principio. Es obvio que la selección intuitiva de las variables independientes iniciales por parte del analista es crucial para tener éxito en el desarrollo de un modelo de regresión.

DIAGNÓSTICOS DE REGRESIÓN Y ANÁLISIS RESIDUAL

Un análisis de regresión no está completo sino hasta que uno está convencido de que el modelo es una representación adecuada de los datos. Es imperativo examinar la idoneidad del modelo antes de que se convierta en parte del mecanismo de toma de decisiones.

Un examen de los residuos es un componente crucial de la determinación de la idoneidad del modelo. Varias gráficas residuales diseñadas para verificar los supuestos del modelo se presentaron en el capítulo 6. Por otra parte, si se usan los modelos de regresión con datos de una serie de tiempo (lo que se analizará en el capítulo 8), es necesario calcular las autocorrelaciones residuales para verificar el supuesto de independencia. Las inferencias (y decisiones) con base en modelos que no satisfacen los supuestos de la regresión pueden ser sumamente desorientadoras. Por ejemplo, podría concluirse que la manipulación de una variable explicativa producirá un cambio específico en la respuesta cuando, de hecho, no sucede así. Se puede concluir también que es muy probable que un pronóstico (95% de confianza) esté dentro del 2% de la respuesta futura cuando, de hecho, la confianza real es mucho menor, y así podríamos seguir dando ejemplos.

En esta sección se analizarán algunas herramientas adicionales que permiten evaluar un modelo de regresión. Estas herramientas están diseñadas para identificar observaciones que son atípicas o extremas (observaciones que están muy alejadas del resto de los datos). Las observaciones atípicas a menudo se esconden tras el proceso de ajuste y es difícil detectarlas en un examen de las gráficas de residuos. Sin embargo, pueden tener un papel importante al determinar la función de regresión ajustada. Es fundamental estudiar las observaciones atípicas para decidir si deben conservarse o eliminarse y, en el primer caso, habrá que decidir si su influencia debe reducirse en el proceso de ajuste o si debe revisarse la función de regresión.

El apalancamiento h_{ii} ofrece una medida de la influencia del i -ésimo punto de datos sobre la ubicación de la función de regresión ajustada. El apalancamiento sólo depende de las variables explicativas; no depende de la respuesta Y . Para la regresión lineal simple con una variable explicativa X ,

$$h_{ii} = \frac{1}{n} + \frac{(X_i - \bar{X})^2}{\sum (X_i - \bar{X})^2} \quad (7.13)$$

Con k variables explicativas, la expresión para el i -ésimo apalancamiento es más complicada; sin embargo, uno puede demostrar que $0 < h_{ii} < 1$ y que el apalancamiento medio es $\bar{h} = (k + 1)/n$.

Si el i -ésimo punto de datos tiene un apalancamiento alto (h_{ii} está cercano a 1), la respuesta ajustada $\hat{Y}_i$, en estas X se encuentra casi completamente determinada por Y_i , con muy poca influencia de los datos restantes. El punto de datos con apalancamiento alto también es un valor atípico entre las X (lejos de otras combinaciones de valores X).¹¹ Una regla empírica sugiere que h_{ii} es lo suficientemente grande para verificar si $h_{ii} \geq 3(k + 1)/n$.

La detección de valores atípicos o extremos de Y está basada en el tamaño de los residuos, $e = Y - \hat{Y}$. Residuos grandes indican un valor de Y que está “lejos” de su valor pronosticado o

¹¹Lo contrario no necesariamente es cierto. Es decir, un valor atípico entre las X puede no tener un punto de apalancamiento alto.

ajustado, $\hat{Y}$. Un residuo grande se manifestará en un histograma de los residuos con un valor lejos de cero (en cualquier dirección). Un residuo grande se manifestará en una gráfica de residuos contra los valores ajustados como un punto muy arriba o muy abajo del eje horizontal.

Los paquetes de software, como Minitab, marcan los puntos de datos con valores extremos de Y calculando residuos “estandarizados” e identificando puntos con residuos estandarizados grandes.

Una estandarización se basa en el hecho de que los residuos tienen desviaciones estándar estimadas:

$$s_{e_i} = s_{y \cdot x's} \sqrt{1 - h_{ii}}$$

donde $s_{y \cdot x's} = \sqrt{MSE}$ es el error estándar de la estimación y h_{ii} es el apalancamiento asociado con el i -ésimo punto de datos. El *residuo estandarizado*¹² es entonces

$$\frac{e_i}{s_{e_i}} = \frac{e_i}{s_{y \cdot x's} \sqrt{1 - h_{ii}}} \quad (7.14)$$

Todos los residuos estandarizados tienen una varianza de 1. Un residuo estandarizado se considera grande (la respuesta extrema) si

$$\left| \frac{e_i}{s_{e_i}} \right| > 2$$

Los valores Y correspondientes a los puntos de datos con residuos estandarizados grandes pueden influir fuertemente en la ubicación de la función de regresión ajustada.

Ejemplo 7.12

Los salarios de los directores ejecutivos en Estados Unidos son de interés en virtud de su relación con los salarios de los directores ejecutivos de las empresas internacionales y de los profesionales mejor pagados fuera de Estados Unidos. Además, para una empresa particular, la remuneración directa o indirecta de un director ejecutivo influye en los salarios de los gerentes de menor nivel. El salario del director ejecutivo varía considerablemente de una empresa a otra, pero los datos sugieren que el salario se puede explicar en términos de las ventas de la empresa, de la experiencia y el nivel educativo del director ejecutivo, así como de su participación como accionista en la compañía. En un estudio que incluyó a 50 empresas, los investigadores se propusieron desarrollar un modelo de regresión múltiple para vincular el sueldo de los directores ejecutivos con diversas variables explicativas, como ventas, utilidades, edad, experiencia, antecedentes profesionales y participación accionaria.

Después de la eliminación de variables explicativas sin importancia, la función de regresión ajustada fue

$$\hat{Y} = 5.52 - .467X_1 + .263X_2$$

donde

Y = logaritmo de la remuneración del director general

X_1 = variable indicadora del nivel educativo

X_2 = logaritmo de las ventas de la compañía

Minitab identificó tres observaciones a partir de este análisis de regresión que tenían residuos estandarizados grandes o apalancamiento grande.

¹²Algunos paquetes de software llaman *Studentized* al residuo estandarizado de la ecuación 7.14.

Unusual Observations

Obs	Educate	LnComp	Fit	StDev Fit	Residual	St Resid
14	1.00	6.0568	7.0995	0.0949	1.0427	2.09R
25	0.00	8.1342	7.9937	0.2224	0.1405	0.31X
33	0.00	6.3969	7.3912	0.2032	0.9943	2.13R

R denotes an observation with a large standardized residual.

X denotes an observation whose X value gives it large influence.

Las observaciones 14 y 33 tienen residuos estandarizados grandes. La función de regresión ajustada está prediciendo una remuneración (en logaritmos) de estos dos directores ejecutivos muy elevada. Un examen del conjunto completo de datos indica que cada uno de estos directores ejecutivos posee porcentajes relativamente grandes de las acciones de su compañía. El caso 14 posee más del 10% de acciones de la empresa, y el caso 33 posee más del 17% de acciones. Estos individuos reciben la mayor parte de su remuneración en forma de pagos a largo plazo, como incentivos accionarios, y no en forma de salario y bonos anuales. Puesto que la cantidad de acciones poseídas (o valor de las acciones) no está incluida como variable en la función de regresión, no puede utilizarse para ajustar el pronóstico de la remuneración determinada por la educación del director ejecutivo y las ventas de la compañía. Si bien la educación y las ventas (en logaritmo) no pronostican la remuneración de estos dos directores ejecutivos tan bien como las otras, no parece haber una razón para eliminarlas del estudio.

La observación 25 se distingue porque el apalancamiento de este punto de datos es mayor que $3(k+1)/n = 3(3)/50 = .18$. Este director ejecutivo no tiene grados académicos (Educación = 0) pero se encuentra en una compañía con ventas relativamente grandes ($\text{LnSales} = 9.394$). La combinación (0, 9.394) está lejos del punto $(\bar{X}_1, \bar{X}_2)$; por lo tanto, es un valor atípico en los pares de X . La respuesta asociada con estas X tendrá una gran influencia en la determinación de la función de regresión ajustada. [Observe que el residuo estandarizado para este punto de datos es pequeño, lo cual indica que la remuneración (log) pronosticada o ajustada está cerca del valor real]. Este director ejecutivo particular tiene 30 años de experiencia en el cargo, más experiencia que todos los directores ejecutivos, a excepción de uno, en el conjunto de datos. Esta observación es influyente, por lo que no hay razón para eliminarla.

El apalancamiento nos indica si una observación tiene variables explicativas inusuales, y un residuo estandarizado nos dice si una observación tiene una respuesta inusual. Estas cantidades pueden combinarse en una medida integral de influencia conocida como distancia de Cook. Las *distancias de Cook* se obtienen en la mayoría de paquetes de software estadístico, pero una explicación adicional está más allá del alcance de este libro.¹³

ADVERTENCIAS DEL PRONÓSTICO

Terminaremos este estudio de la regresión múltiple con algunos comentarios generales, los cuales están orientados a la aplicación práctica del análisis de regresión.

Sobreajuste de la prueba

El *sobreajuste* se refiere al hecho de agregar variables independientes a la función de regresión que, en gran medida, dan cuenta de todas las excentricidades de los datos muestrales bajo análisis.

Cuando se aplica un modelo sobreajustado a nuevos conjuntos de datos seleccionados de la misma población, no pronostica tan bien como el ajuste inicial podría sugerir.

Es más probable que ocurra el sobreajuste cuando el tamaño de la muestra es pequeño, especialmente si se incluye un gran número de variables independientes en el modelo. Algunos especialistas

¹³Draper y Smith (1998) aportan una buena explicación de la distancia de Cook.

sugieren que deben existir por lo menos 10 observaciones por cada variable independiente. (Si existen cuatro variables independientes, se sugiere un tamaño n de la muestra de por lo menos 40).

Una manera de protegerse contra el sobreajuste es desarrollar la función de regresión de una parte de los datos y luego aplicarla a una porción de la muestra. Se usa la función de regresión ajustada para pronosticar las respuestas de otra porción de datos y calcular los errores de pronóstico. Si los errores de pronóstico son sustancialmente mayores que los errores de ajuste medidos, digamos, por los errores cuadráticos medios comparables, entonces ha ocurrido un sobreajuste.

Regresiones útiles, valores grandes calculados de F

Una regresión que es estadísticamente significativa no necesariamente es útil. Con un tamaño muestral relativamente grande (por ejemplo, cuando n es grande en relación con k , el número de variables explicativas), no es extraño obtener una razón F significativa y una R^2 pequeña. Es decir, la regresión es significativa, pero sólo explica una pequeña porción de la variación en la respuesta. Una regla general sugiere que con un nivel de significancia de .05, la razón F debe ser por lo menos cuatro veces el valor crítico correspondiente antes de que la regresión pueda usarse para fines de predicción.¹⁴

El criterio de “cuatro veces” surge del argumento de que el rango de las predicciones (sobre todas las X) debe ser alrededor de cuatro veces el error de predicción (promedio) antes de que la regresión pueda generar una interpretación que valga la pena.¹⁵

Como ejemplo, con $k = 3$ variables explicativas, $n = 25$ observaciones, y un nivel de significancia de .05, la F calculada a partir de una tabla ANOVA tendría que exceder el valor crítico $F = 3.07$ (véase la tabla B-5 con $\delta_1 = k = 3$, $\delta_2 = n - k - 1 = 21$ grados de libertad) para que la regresión sea significativa. (Con base en la ecuación 7.7, la F crítica = 3.07 corresponde a una R^2 de alrededor del 30%, una cifra que no es particularmente grande). Sin embargo, la regla de las “cuatro veces” sugiere que la F calculada debería exceder $4(3.07) = 12.28$ para que la regresión valga la pena desde un punto de vista práctico.

APLICACIÓN A LA ADMINISTRACIÓN

El análisis de regresión múltiple se usa ampliamente para ayudar a pronosticar la actividad de varios segmentos de la economía. Muchos de los reportes y pronósticos acerca del futuro de la economía que aparecen en el *Wall Street Journal*, *Fortune*, *Business Week* y otras fuentes similares se basan en modelos econométricos (de regresión). El gobierno de Estados Unidos usa con frecuencia el análisis de regresión para pronosticar ingresos, gastos, niveles de ingreso, tasas de interés, índices de natalidad, desempleo y requerimientos para obtener beneficios de seguridad social, así como una multitud de sucesos. De hecho, prácticamente todas las grandes oficinas del gobierno de Estados Unidos utilizan las herramientas descritas en este capítulo.

De manera similar, las entidades de negocios han adoptado y, cuando es necesario, modificado el análisis de regresión como ayuda para el pronóstico de acontecimientos futuros. Pocas empresas pueden sobrevivir en el ambiente actual sin un pronóstico bastante exacto de las ventas, los gastos, los requerimientos de capital y los flujos de efectivo para el futuro. Si bien las empresas pequeñas o menos complejas pueden funcionar con pronósticos intuitivos, las empresas más grandes y/o más complejas recurren al análisis de regresión para estudiar las relaciones entre diversas variables y determinar cómo tales variables podrían afectar su futuro.

Por desgracia, la gran notoriedad que adquiere el análisis de regresión por su utilidad como una herramienta de pronóstico del futuro tiende a opacar un activo igualmente importante: su capacidad para ayudar a evaluar y controlar el presente. Como la ecuación de regresión ajustada brinda al investigador información sobre la *fortaleza y dirección*, la administración puede evaluar y modificar las estrategias en curso.

¹⁴Algunos autores argumentan que la regla de “cuatro veces” no es suficiente y que debería sustituirse por un criterio de “diez veces”.

¹⁵Esto supone que no se detectan otros defectos en el ajuste.

Suponga, por ejemplo, que un fabricante de mermelada quiere saber hacia dónde dirigir sus esfuerzos de marketing cuando lanza al mercado un nuevo sabor. Se puede usar el análisis de regresión para ayudar a determinar el perfil de los grandes consumidores de mermelada. Por ejemplo, tal vez una compañía quiera predecir el número de sabores de mermelada que una ama de casa podría tener en la alacena en un momento dado sobre la base de un número de variables independientes, como las siguientes:

- Número de niños que hay en casa
- Edad de los niños
- Sexo de los niños
- Propietarios de casas contra arrendadores
- Tiempo invertido en compras
- Ingreso

Incluso una reflexión superficial sobre el ejemplo de la mermelada rápidamente lleva al investigador a reconocer que el análisis de regresión tiene muchas posibilidades de uso en estudios de segmentación de mercado. De hecho, muchas compañías usan la regresión para estudiar segmentos de mercado y determinar cuáles variables parecen tener efecto sobre la participación en el mercado, la frecuencia de compra, la propiedad del producto y la lealtad a la marca y al producto, así como sobre otras muchas áreas.

Los especialistas en ciencias agrícolas utilizan el análisis de regresión para explorar la relación entre el rendimiento de la tierra (por ejemplo, número de fanegas de maíz por acre) y el tipo y la cantidad de fertilizante, la precipitación, la temperatura, los días de sol y las plagas de insectos. Las granjas modernas están equipadas con mini y micro computadoras completas con paquetes de software para ayudar en este proceso.

Los investigadores médicos usan el análisis de regresión para buscar vínculos entre la presión sanguínea y variables independientes como la edad, la clase social, el peso, el tabaquismo y la raza. También estudian el efecto de las comunicaciones, el número de visitas y la edad del paciente en relación con la satisfacción del servicio médico.

Los directores de personal exploran la relación de los niveles de salario de los empleados con la ubicación geográfica, las tasas de desempleo, el crecimiento de la industria, la afiliación a sindicatos, el tipo de industria y salarios competitivos. Los analistas financieros buscan las causas de los altos precios de las acciones analizando el rendimiento de dividendos, las ganancias por acción, la partición accionaria, las expectativas del consumidor en cuanto a tasas de interés, los niveles de ahorro y las tasas de inflación.

Los gerentes de publicidad a menudo tratan de estudiar el efecto de los presupuestos en publicidad, la selección de medios, la redacción del mensaje, la frecuencia del anuncio y la selección del anunciador en relación con el cambio de actitud del consumidor. De manera análoga, los especialistas en marketing intentan determinar las ventas a partir de los gastos en publicidad, los niveles de precio, los gastos competitivos en marketing y los ingresos disponibles del consumidor, así como una gran diversidad de variables.

Citemos un ejemplo final adicional para ilustrar la versatilidad del análisis de regresión. Los analistas del mercado inmobiliario han encontrado que el análisis de regresión es muy útil en la localización exacta de áreas geográficas con abundancia o escasez de tipos específicos de tiendas minoristas. Por ejemplo, una cadena de ferreterías podría buscar una ciudad potencial en la cual ubicar una nueva sucursal desarrollando un modelo de regresión diseñado para predecir las ventas de herramientas en cualquier ciudad específica. Los investigadores concentrarían sus esfuerzos en aquellas ciudades donde el modelo predijo ventas más altas que las reales (como se puede determinar consultando muchas fuentes). La hipótesis es que las ventas de artículos de ferretería no alcanzan todo su potencial en esas ciudades.

En resumen, el análisis de regresión brinda a los gerentes una herramienta poderosa y versátil para estudiar las relaciones entre una variable dependiente y múltiples variables independientes. El objetivo es comprender mejor y quizás controlar acontecimientos del presente, así como predecir mejor hechos futuros.

Glosario

Variables ficticias. Las variables o indicadores ficticios sirven para determinar las relaciones entre variables independientes cualitativas y una variable dependiente.

Multicolinealidad. La multicolinealidad es la situación en la cual las variables independientes en una ecuación de regresión múltiple están estrechamente intercorrelacionadas. Es decir, existe una relación lineal entre dos o más variables independientes.

Regresión múltiple. La regresión múltiple implica el uso de más de una variable independiente para predecir una variable dependiente.

Sobreajuste. Se refiere al hecho de agregar variables independientes a la función de regresión que, en gran medida, explican todas las excentricidades de los datos muestrales bajo análisis.

Coefficiente de regresión parcial o neto. El coeficiente de regresión parcial, o neto, mide el cambio promedio de la variable dependiente por unidad de cambio en la variable independiente relevante, cuando se mantienen constantes las demás variables independientes.

Error estándar de la estimación. El error estándar de la estimación es la desviación estándar de los residuos. Mide la cantidad de valores reales (Y) que difieren de los valores estimados ($\hat{Y}$).

Regresión por pasos. La regresión por pasos permite a las variables explicativas entrar o salir de la función de regresión en diferentes etapas de su desarrollo. Una variable independiente se elimina del modelo si no continúa haciendo una contribución significativa cuando se agrega una nueva variable.

Fórmulas clave

Función de regresión múltiple de población

$$\mu_Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k \quad (7.1)$$

Función de regresión estimada (ajustada)

$$\hat{Y} = b_0 + b_1 X_1 + \cdots + b_k X_k \quad (7.2)$$

Descomposición de la suma de cuadrados y grados de libertad asociados

$$\begin{aligned} \Sigma(Y - \bar{Y})^2 &= \Sigma(\hat{Y} - \bar{Y})^2 + \Sigma(Y - \hat{Y})^2 \\ SST &= SSR + SSE \\ df: n - 1 &= k + n - k - 1 \end{aligned} \quad (7.3)$$

Error estándar de la estimación

$$s_{y \cdot x's} = \sqrt{\frac{\Sigma(Y - \hat{Y})^2}{n - k - 1}} = \sqrt{\frac{SSE}{n - k - 1}} = \sqrt{MSE} \quad (7.4)$$

Estadístico F para prueba de significancia de la regresión

$$F = \frac{MSR}{MSE} \quad (\text{véase el recuadro de la p. 289})$$

Coefficiente de determinación

$$\begin{aligned} R^2 &= \frac{SSR}{SST} = \frac{\Sigma(\hat{Y} - \bar{Y})^2}{\Sigma(Y - \bar{Y})^2} \\ &= 1 - \frac{SSE}{SST} = 1 - \frac{\Sigma(Y - \hat{Y})^2}{\Sigma(Y - \bar{Y})^2} \end{aligned} \quad (7.5)$$

Coefficiente de correlación múltiple

$$R = \sqrt{R^2} \quad (7.6)$$

Relación entre el estadístico F y R^2

$$F = \frac{R^2}{1 - R^2} \left(\frac{n - k - 1}{k} \right) \quad (7.7)$$

Coefficiente ajustado de determinación

$$\bar{R}^2 = 1 - (1 - R^2) \left(\frac{n - 1}{n - k - 1} \right) \quad (7.8)$$

Estadístico t para la prueba de $H_0: \beta_j = 0$

$$t = \frac{b_j}{s_{b_j}} \quad (\text{véase el recuadro de la p. 291})$$

Pronóstico de un valor futuro

$$\hat{Y}^* = b_0 + b_1 X_1^* + b_2 X_2^* + \cdots + b_k X_k^* \quad (7.9)$$

Intervalo de de confianza para la predicción al utilizar una muestra grande para una respuesta futura

$$(\hat{Y}^* - t_{\alpha/2} s_{y \cdot x' s}, \hat{Y}^* + t_{\alpha/2} s_{y \cdot x' s}) \quad (7.10)$$

Factor de inflación de la varianza

$$VIF_j = \frac{1}{1 - R_j^2} \quad j = 1, 2, \dots, k \quad (7.11)$$

Valores estandarizados de la variable independiente

$$\tilde{X} = \frac{X_{ij} - \bar{X}_j}{\sqrt{\sum_i (X_{ij} - \bar{X}_j)^2}} \quad j = 1, 2, \dots, k; \quad i = 1, 2, \dots, n \quad (7.12)$$

Apalancamiento (una variable explicativa)

$$h_{ii} = \frac{1}{n} + \frac{(X_i - \bar{X})^2}{\sum (X_i - \bar{X})^2} \quad (7.13)$$

Residuo estandarizado

$$\frac{e_i}{s_{e_i}} = \frac{e_i}{s_{y \cdot x' s} \sqrt{1 - h_{ii}}} \quad (7.14)$$

Problemas

1. ¿Cuáles son las características de una buena variable explicativa?
2. ¿Cuáles son los supuestos asociados con el modelo de regresión múltiple?
3. ¿Qué mide el coeficiente de regresión parcial, o neto, en la regresión múltiple?
4. ¿Qué mide el error estándar de la estimación en la regresión múltiple?
5. Su ecuación de la regresión múltiple estimada es $\hat{Y} = 7.52 + 3X_1 - 12.2X_2$. Pronostique el valor de Y si $X_1 = 20$ y $X_2 = 7$.

TABLA P-7

Número de variable	Número de variable					
	1	2	3	4	5	6
1	1.00	.55	.20	-.51	.79	.70
2		1.00	.27	.09	.39	.45
3			1.00	.04	.17	.21
4				1.00	-.44	-.14
5					1.00	.69
6						1.00

6. Explique cada uno de los siguientes conceptos:
 - a) Matriz de correlación
 - b) R^2
 - c) Multicolinealidad
 - d) Residuo
 - e) Variable ficticia
 - f) Regresión por pasos
7. La mayoría de las soluciones por computadora para la regresión múltiple inician con una matriz de correlación. El examen de esta matriz a menudo es el primer paso cuando se analiza un problema de regresión que implica más de una variable independiente. Conteste las siguientes preguntas relacionadas con la matriz de correlación de la tabla P-7.
 - a) ¿Por qué todas las entradas que se encuentran sobre la diagonal principal son iguales a 1.00?
 - b) ¿Por qué la mitad de la matriz debajo de la diagonal principal se encuentra en blanco?
 - c) Si la variable 1 es la variable dependiente, ¿cuáles variables independientes tienen el grado más alto de asociación lineal con la variable 1?
 - d) ¿Qué clase de asociación existe entre las variables 1 y 4?
 - e) ¿Esta matriz de correlación indica alguna evidencia de multicolinealidad?
 - f) En su opinión, ¿cuál variable o variables deberían incluirse en el mejor modelo de pronóstico? Explique.
 - g) Si los datos presentados en esta matriz de correlación se corren en un programa de regresión por pasos, ¿cuál variable independiente (2, 3, 4, 5 o 6) será la primera en entrar en la función de regresión?
8. A Jennifer Dahl, supervisora de la cadena de descuento Circle O, le gustaría pronosticar el tiempo que se tardan los empleados en cobrarle a un cliente. Ella decide usar las siguientes variables independientes: número de artículos comprados e importe total de compra. Recopila datos para una muestra de 18 clientes, los cuales se presentan en la tabla P-8.
 - a) Determine la mejor ecuación de regresión.
 - b) Cuando se compra un artículo adicional, ¿cuál es el incremento promedio en el tiempo de cobro?
 - c) Calcule el residuo para el cliente 18.
 - d) Calcule el error estándar de la estimación.
 - e) Interprete el inciso d) en términos de las variables usadas en el problema.
 - f) Elabore un pronóstico del tiempo de cobro si un cliente compra 14 artículos que suman un total de \$70.
 - g) Calcule un intervalo estimado de 95% para su pronóstico del inciso f).
 - h) ¿Qué debería concluir Jennifer?
9. La tabla P-9 contiene datos de gastos de alimentación, ingreso anual y tamaño de la familia para una muestra de 10 familias.

TABLA P-8

<i>Cliente</i>	<i>Tiempo de cobro (minutos) Y</i>	<i>Importe (\$) X₁</i>	<i>Número de artículos X₂</i>
1	3.0	36	9
2	1.3	13	5
3	.5	3	2
4	7.4	81	14
5	5.9	78	13
6	8.4	103	16
7	5.0	64	12
8	8.1	67	11
9	1.9	25	7
10	6.2	55	11
11	.7	13	3
12	1.4	21	8
13	9.1	121	21
14	.9	10	6
15	5.4	60	13
16	3.3	32	11
17	4.5	51	15
18	2.4	28	10

TABLA P-9

<i>Familia</i>	<i>Gastos anuales de comida (en cientos de \$) Y</i>	<i>Ingreso anual (en miles de \$) X₁</i>	<i>Tamaño de la familia X₂</i>
A	24	11	6
B	8	3	2
C	16	4	1
D	18	7	3
E	24	9	5
F	23	8	4
G	11	5	2
H	15	7	2
I	21	8	3
J	20	7	2

- Elabore la matriz de correlación para las tres variables de la tabla P-9. Interprete las correlaciones en la matriz.
 - Ajuste un modelo de regresión múltiple que relacione los gastos de comida con los ingresos y el tamaño de la familia. Interprete los coeficientes de regresión parcial de ingreso y tamaño de la familia. ¿Tienen sentido?
 - Calcule los factores de inflación de la varianza (*VIF*) para las variables independientes. ¿La multicolinealidad es un problema para estos datos? Si es así, ¿cómo podría usted modificar el modelo de regresión?
10. Las ventas de cerveza en la tienda Shapiro One-Stop se analizan considerando la temperatura y el número de personas en la calle (de 21 años de edad en adelante) como variables independientes. Se selecciona una muestra aleatoria de 20 días, y se miden las siguientes variables:

TABLA P-10 Resultado de Minitab					
Correlations					
		Y		X1	
X1	0.827				
X2	0.822	0.680			
Regression Analysis					
The regression equation is					
$Y = -26.7 + .782 X1 + .068 X2$					
Predictor	Coef	SE Coef	T	P	
Constant	-26.706				
X1	.78207	.22694			
X2	.06795	.02026			
S =	R-Sq =	R-Sq(adj) =			
Analysis of Variance					
Source	DF	SS	MS	F	
Regression	2	11589.035	5794.516	36.11	
Residual Error	17	2727.914	160.466		
Total	19	14316.949			

Y = el número de empaques de 6 cervezas que se venden diariamente

X_1 = la temperatura diaria más alta

X_2 = el tráfico diario de personas

Se analizan los datos usando regresión múltiple. El resultado parcial de la computadora es la tabla P-10.

- Analice la matriz de correlación.
 - Pruebe la hipótesis $H_0: \beta_j = 0, j = 1, 2$, con un nivel de significancia de .01.
 - Pronostique el volumen de cerveza vendida si la temperatura más alta es de 60 grados Fahrenheit y el tráfico es de 500 personas.
 - Calcule R^2 , e interprete su significado en términos de este problema.
 - Calcule el error estándar de la estimación.
 - Explique cómo se ven afectadas las ventas de cerveza por el incremento de un grado en la temperatura más alta.
 - Redacte sus conclusiones de este análisis en relación con la exactitud de la ecuación del pronóstico y también sobre las contribuciones de las variables independientes.
11. Una compañía de taxis está interesada en la relación entre el millaje, medido en millas por galón, y la antigüedad de los automóviles de su flota. Los 12 vehículos son de la misma marca y del mismo tamaño y están en buenas condiciones de operación gracias a un mantenimiento sistemático. La compañía emplea tanto a hombres como mujeres como conductores y se cree que algo de la variabilidad en el millaje puede deberse a las diferencias en las técnicas de manejo entre los grupos de conductores de uno y otro sexo. De hecho, si todo lo demás se mantiene igual, las mujeres tienden a obtener mejor millaje que los hombres. Se registran los datos generados por la asignación al azar de los 12 automóviles a cinco mujeres y siete hombres, y se calculan las millas por galón después de recorrer 300 millas. Los datos aparecen en la tabla P-11.
- Elabore un diagrama de dispersión con Y como el eje vertical y X_1 como el eje horizontal. Identifique los puntos correspondientes a los conductores hombres y mujeres, respectivamente.

TABLA P-11

<i>Millas por galón Y</i>	<i>Antigüedad del auto (años) X_1</i>	<i>Sexo (0 = hombre, 1 = mujer) X_2</i>
22.3	3	0
22.0	4	1
23.7	3	1
24.2	2	0
25.5	1	1
21.1	5	0
20.6	4	0
24.0	1	0
26.0	1	1
23.1	2	0
24.8	2	1
20.2	5	0

b) Ajuste el modelo de regresión

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$$

interprete el coeficiente de mínimos cuadrados, b_2 .

- c) Calcule los valores ajustados de cada uno de los pares (X_1, X_2) y grafique los valores ajustados en el diagrama de dispersión. Dibuje líneas rectas a través de los valores ajustados para los conductores hombres y las conductoras mujeres, respectivamente. Especifique las ecuaciones para estas dos líneas rectas.
- d) Suponga que se ignora el género. Ajuste el modelo de regresión lineal simple, $Y = \beta_0 + \beta_1 X_1 + \varepsilon$, y grafique la línea recta ajustada sobre el diagrama de dispersión. ¿Es importante incluir los efectos del género en este caso? Explique.
12. El gerente de ventas de un distribuidor grande de partes automotrices, Hartman Auto Supplies, quiere desarrollar un modelo para pronosticar desde mayo las ventas anuales totales de una región. Si es posible pronosticar las ventas regionales, entonces es factible pronosticar las ventas totales de la compañía. El número de minoristas en la región en cuyos inventarios hay refacciones de la compañía y el número de automóviles registrados para cada región al primero de mayo son las dos variables independientes investigadas. Los datos aparecen en la tabla P-12.
- a) Analice la matriz de correlación.
- b) ¿Qué tanto de error está implicado en el pronóstico de la región 1?
- c) Pronostique las ventas anuales para la región 12, dados 2,500 minoristas y 20.2 millones de automóviles registrados.
- d) Discuta la exactitud del pronóstico elaborado en el inciso c).
- e) Indique cómo encontró el error estándar de la estimación.
- f) Dé una interpretación de los coeficientes de regresión parciales. ¿Son razonables estos coeficientes de regresión?
- g) ¿Cómo se puede mejorar esta ecuación de regresión?
13. El director de ventas de Hartman Auto Supplies decide investigar una nueva variable independiente, el ingreso personal por región (véase el problema 12). Los datos para esta nueva variable se presentan en la tabla P-13.
- a) ¿El ingreso personal por región hace una contribución al pronóstico de las ventas?

TABLA P-12

<i>Región X_2</i>	<i>Ventas anuales (millones de \$) Y</i>	<i>Número de minoristas X_1</i>	<i>Número de automóviles registrados (\$ millones)</i>
1	52.3	2,011	24.6
2	26.0	2,850	22.1
3	20.2	650	7.9
4	16.0	480	12.5
5	30.0	1,694	9.0
6	46.2	2,302	11.5
7	35.0	2,214	20.5
8	3.5	125	4.1
9	33.1	1,840	8.9
10	25.2	1,233	6.1
11	38.2	1,699	9.5

TABLA P-13

<i>Región</i>	<i>Ingreso personal (miles de millones de \$)</i>	<i>Región</i>	<i>Ingreso personal (miles de millones de \$)</i>
1	98.5	7	67.6
2	31.1	8	19.7
3	34.8	9	67.9
4	32.7	10	61.4
5	68.8	11	85.6
6	94.7		

- b) Pronostique las ventas anuales para la región 12 para un ingreso personal de \$40 mil millones y las cifras correspondientes a los minoristas y los automóviles registrados de acuerdo con el inciso c) del problema 12
- c) Discuta la exactitud del pronóstico elaborado en el inciso b).
- d) ¿Cuáles variables independientes incluiría usted en su modelo final de pronóstico? ¿Por qué?
14. Nelson Corporation decide desarrollar una ecuación de regresión múltiple para pronosticar el desempeño del área de ventas. Se entrevista a 14 vendedores de una muestra aleatoria y se les aplica una prueba de aptitud. También se calcula un índice de esfuerzo realizado por cada vendedor sobre la base de una razón entre el millaje recorrido en el automóvil de su compañía y el total de millaje proyectado para una cobertura adecuada de territorio. El análisis de regresión produce los siguientes resultados:

$$\hat{Y} = 16.57 + \underset{(.05)}{.65} X_1 + \underset{(1.69)}{20.6} X_2$$

Las cantidades entre paréntesis son los errores estándar de los coeficientes de regresión parciales. El error estándar de la estimación es 3.56. La desviación estándar de la variable de ventas es $s_y = 16.57$. Las variables son

Y = el desempeño de las ventas, en miles
 X_1 = la calificación en la prueba de aptitud
 X_2 = el índice de esfuerzo

- a) ¿Los coeficientes de regresión parciales son significativamente diferentes de cero en el nivel de significancia de .01?
 - b) Interprete el coeficiente de regresión parcial para el índice de esfuerzo.
 - c) Pronostique el desempeño en las ventas de un vendedor que obtiene una calificación de 75 en la prueba de aptitud y un índice de esfuerzo de .5.
 - d) Calcule la suma de los cuadrados residuales, $\Sigma(Y - \hat{Y})^2$.
 - e) Calcule la suma total de cuadrados $\Sigma(Y - \bar{Y})^2$.
 - f) Calcule R^2 , e interprete este número en términos del problema.
 - g) Calcule el coeficiente ajustado de determinación, $\bar{R}^2$.
15. Cabe esperar que las compras con tarjeta de crédito sean diferentes de las compras en efectivo en la misma tienda. La tabla P-15 indica las ventas diarias brutas y los artículos vendidos que se pagan en efectivo, así como las ventas diarias brutas en efectivo y los artículos vendidos que se pagan con tarjetas de crédito en la misma tienda de consignación por 25 días consecutivos.
- a) Elabore un diagrama de dispersión de las ventas brutas diarias, Y , contra artículos vendidos que se pagan en efectivo, X_1 . Usando otros símbolos, o bien, colores diferentes, agregue las ventas brutas diarias y los artículos vendidos que se pagan con tarjeta de crédito, X_2 . Compare visualmente la relación entre las ventas y el número de artículos vendidos que se pagan en efectivo con los pagados con tarjeta de crédito.

TABLA P-15

<i>Día</i>	<i>Ventas brutas en efectivo (\$)</i>	<i>Número de artículos</i>	<i>Ventas brutas con tarjeta de crédito (\$)</i>	<i>Número de artículos</i>
1	348	55	148	4
2	42	8	111	6
3	61	9	62	7
4	94	16	0	0
5	60	11	39	5
6	165	26	7	1
7	126	27	143	26
8	111	19	27	5
9	26	5	14	2
10	109	18	71	12
11	180	27	116	21
12	212	36	50	9
13	58	10	13	2
14	115	20	105	16
15	15	8	19	3
16	97	15	44	14
17	61	10	0	0
18	85	15	24	3
19	157	24	144	10
20	88	15	63	11
21	96	19	0	0
22	202	33	14	3
23	108	23	0	0
24	158	21	24	4
25	176	43	253	28

b) Defina la variable ficticia

$$X_2 = \begin{cases} 1 & \text{si la compra es en efectivo} \\ 0 & \text{si la compra es con tarjeta de crédito} \end{cases}$$

y ajuste el modelo de regresión

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$$

- c) Analice el ajuste del inciso b). Asegúrese de incluir un análisis de los residuos. ¿Está usted satisfecho con su modelo?
- d) Con base en el modelo ajustado del inciso b), elabore un pronóstico de las ventas diarias para un individuo que compra 25 artículos y paga en efectivo. Para una muestra grande, construya un intervalo de predicción del 95% para las ventas diarias.
- e) Describa la naturaleza de la función ajustada del inciso b). ¿Cree usted que es mejor ajustar dos líneas rectas separadas, una para las ventas en efectivo y otra para las ventas con tarjeta de crédito, para los datos de la tabla P-15? Discútalos.
16. Cindy Lawson acaba de comprar un equipo de la liga mayor de béisbol. Ella ha estado recibiendo muchos consejos acerca de lo que debe hacer para convertir a su equipo en ganador. Cindy le pide a usted que estudie este problema y escriba un reporte. Usted decide usar el análisis de regresión múltiple para determinar cuáles datos estadísticos son importantes para desarrollar un equipo ganador (considerado como tal por el número de juegos ganados durante la temporada 1991). Usted reúne los datos de seis estadísticos del *Sporting News*

TABLA P-16

<i>Equipo</i>	<i>Victorias</i>	<i>ERA</i>	<i>SO</i>	<i>BA</i>	<i>Carreras</i>	<i>HR</i>	<i>SB</i>
Gigantes	75	4.03	905	.246	649	141	95
Mets	77	3.56	1,028	.244	640	117	153
Cachorros	77	4.03	927	.253	695	159	123
Rojos	74	3.83	997	.258	689	164	124
Piratas	98	3.44	919	.263	768	126	124
Cardenales	84	3.69	822	.255	651	68	202
Phillies	78	3.86	988	.241	629	111	92
Astros	65	4.00	1,033	.244	605	79	125
Dodgers	93	3.06	1,028	.253	665	108	126
Expos	71	3.64	909	.246	579	95	221
Bravos	94	3.49	969	.258	749	141	165
Padres	84	3.57	921	.244	636	121	101
Medias rojas	84	4.01	999	.269	731	126	59
Medias blancas	87	3.79	923	.262	758	139	134
Yankees	71	4.42	936	.256	674	147	109
Tigres	84	4.51	739	.247	817	209	109
Orioles	67	4.59	868	.254	686	170	50
Cerveceros	83	4.14	859	.271	799	116	106
Indios	57	4.23	862	.254	576	79	84
Azulejos	91	3.50	971	.257	684	133	148
Marineros	83	3.79	1,003	.255	702	126	97
Rangers	85	4.47	1,022	.270	829	177	102
Atléticos	84	4.57	892	.248	760	159	151
Reales	82	3.92	1,004	.264	727	117	119
Ángeles	81	3.69	990	.255	653	115	94
Gemelos	95	3.69	876	.280	776	140	107

NOTA: *ERA* significa promedio de carreras ganadas (*earned run average*); *SO* significa ponches (*strikeouts*); *BA* significa promedio de bateo (*batting average*); *HR* significa *homeruns*; y *SB* significa bases robadas (*stolen bases*).

1992 *Baseball Yearbook*, los cuales se muestran en la tabla P-16, y corre un programa de regresión por pasos, suponiendo un modelo de regresión múltiple con “Victorias” como la variable dependiente.

- a) Discuta la importancia de cada variable independiente.
 - b) ¿Cuál ecuación debe usar Cindy para pronosticar las victorias?
 - c) Escriba un reporte para Cindy.
 - d) Recopile datos de los números más recientes del *Sporting News Baseball Yearbook* u otra fuente de datos estadísticos de béisbol. Corra una regresión por pasos y compare sus resultados.
17. La señora Haight, una agente inmobiliaria, desea pronosticar la importancia de cuatro factores en la determinación de los precios de terrenos. Ella recopila datos sobre el precio, el área, la elevación y la inclinación, y, con base en ello, califica la vista de 50 lotes. Ingresa los datos en un programa de correlación y obtiene la matriz de correlación que se presenta en la tabla P-17. Luego, Haight ingresa los datos en un programa de regresión múltiple por pasos.
- a) Determine cuál variable entrará en primer lugar, segundo, tercero y último lugar al modelo.
 - b) ¿Qué variable o variables serán incluidas en la mejor ecuación de predicción?
18. En la tabla P-18 se listan: la calificación de dos exámenes parciales, X_1 y X_2 ; el promedio actual de calificaciones (GPA), X_3 ; y la calificación del examen final, Y , de 20 estudiantes en la clase de estadística para los negocios.
- a) Ajuste un modelo de regresión múltiple para predecir la puntuación del examen final a partir de las calificaciones de los exámenes parciales y el GPA. ¿Es significativa la regresión? Explique.
 - b) Pronostique la calificación del examen final de un estudiante con calificaciones parciales de 86 y 77 y un GPA de 3.4.
 - c) Calcule los *VIF* y examine los estadísticos t para probar la significancia de las variables explicativas individuales. ¿La multicolinealidad es un problema? Explique.

TABLA P-17

Variable	Variable				
	Precio	Área	Elevación	Pendiente	Vista
Precio	1.00	.59	.66	.68	.88
Área		1.00	.04	.64	.41
Elevación			1.00	.13	.76
Pendiente				1.00	.63
Vista					1.00

TABLA P-18

X_1	X_2	X_3	Y	X_1	X_2	X_3	Y
87	85	2.7	91	93	60	3.2	54
100	84	3.3	90	92	69	3.1	63
91	82	3.5	83	100	86	3.6	96
85	60	3.7	93	80	87	3.5	89
56	64	2.8	43	100	96	3.8	97
81	48	3.1	75	69	51	2.8	50
77	67	3.1	63	80	75	3.6	74
86	73	3.0	78	74	70	3.1	58
79	90	3.8	98	79	66	2.9	87
96	69	3.7	99	95	83	3.3	57

- d) Calcule el apalancamiento medio. ¿Algunas de las observaciones son puntos de apalancamiento alto?
- e) Calcule los residuos estandarizados. Identifique cualquier observación con residuo estandarizado grande. ¿El modelo ajustado predice una respuesta muy alta o muy baja de estas observaciones?
19. Con respecto a los datos de la tabla P-18, obtenga el “mejor” modelo de regresión usando el procedimiento de regresión por pasos y el procedimiento de todas las regresiones posibles. Compare los resultados. ¿Se siente usted confiado al usar un modelo de regresión para predecir la calificación del examen final con menos variables independientes que las tres originales?
20. Recuerde el ejemplo 7.12. El conjunto completo de datos relacionado con la remuneración del director general aparece en el apéndice C. (Consulte las páginas 533-545). Use la regresión por pasos para seleccionar el “mejor” modelo con $k = 3$ variables explicativas. Ajuste el modelo de pasos e interprete los coeficientes calculados. Examine los residuos. Identifique y explique cualquier observación con influencia. Si usted tuviera que elegir entre este modelo y el modelo de pronóstico con $k = 2$ analizado en el ejemplo 7-12, ¿cuál de ellos seleccionaría? ¿Por qué?
21. La tabla P-21 contiene el número de cuentas (en miles) y los activos (en miles de millones de dólares) de 10 corredurías de bolsa *online*. Grafique los activos contra el número de cuentas. Investigue la posibilidad de que la relación sea curva elaborando una regresión múltiple para pronosticar los activos; considere el número de cuentas y el número de cuentas elevado al cuadrado como variables independientes.
- a) Proporcione la función de regresión ajustada. ¿Es significativa la regresión? Explique.
- b) Pruebe la significancia del coeficiente del término elevado al cuadrado. Resuma su conclusión.
- c) Corra otra vez el análisis sin el término cuadrático (elevado al cuadrado). Explique por qué el coeficiente del número de cuentas no es el mismo que el que usted obtuvo en el inciso a).
22. Existen catadores de queso que determinan la calidad de estos productos; las puntuaciones que otorgan se suman para obtener una variable dependiente denominada simplemente “sabor”. Las variables independientes (explicativas) son tres sustancias químicas presentes en el queso: ácido acético, sulfuro de hidrógeno (H_2S), y ácido láctico. Los 15 casos del conjunto de datos se presentan en la tabla P-22. Analice estos datos usando métodos de regresión múltiple. Asegúrese de incluir solamente variables independientes significativas en su modelo final e interprete R^2 . Incluya un análisis de los residuos.
23. Remítase al problema 22. Usando su función final de regresión ajustada, pronostique Sabor (calidad) para Acético = 5.750, H_2S = 7.300, y Láctico = 1.85. (Es posible que no se

TABLA P-21

<i>Activos (miles de millones de) X</i>	<i>Número de cuentas (en miles) Y</i>
219.0	2,500
21.1	909
38.8	615
5.5	205
160.0	2,300
19.5	428
11.2	590
5.9	134
1.3	130
6.8	125

TABLA P-22

<i>Caso</i>	<i>Sabor Y</i>	<i>Acético X₁</i>	<i>H₂S X₂</i>	<i>Láctico X₃</i>
1	40.9	6.365	9.588	1.74
2	15.9	4.787	3.912	1.16
3	6.4	5.412	4.700	1.49
4	18.0	5.247	6.174	1.63
5	38.9	5.438	9.064	1.99
6	14.0	4.564	4.949	1.15
7	15.2	5.298	5.220	1.33
8	32.0	5.455	9.242	1.44
9	56.7	5.855	10.199	2.01
10	16.8	5.366	3.664	1.31
11	11.6	6.043	3.219	1.46
12	26.5	6.458	6.962	1.72
13	0.7	5.328	3.912	1.25
14	13.4	5.802	6.685	1.08
15	5.5	6.176	4.787	1.25

TABLA P-24 Categorías contables para la liga mayor de béisbol (en millones de \$)

<i>GtReceit</i>	<i>MediaRev</i>	<i>StadRev</i>	<i>TotRev</i>	<i>PlayerCt</i>	<i>OpExpens</i>	<i>OpIncome</i>	<i>FranValu</i>	<i>Franchise</i>
19.4	61.0	7.4	90.0	29.8	59.6	30.4	200	NyYank
26.6	32.5	18.0	79.3	36.0	72.0	7.3	180	LADodge
22.9	50.0	16.0	91.1	35.2	70.4	20.7	170	NYMets
44.5	30.0	12.0	88.7	29.7	62.4	26.3	160	TorBIJay
24.5	40.5	14.3	81.5	35.4	70.8	10.7	160	BosRdSox
19.0	24.4	5.0	50.6	15.8	39.5	11.1	140	BaltOrio
27.5	25.7	19.3	78.0	18.0	60.0	18.0	140	ChWhSox
19.9	25.0	12.0	59.1	23.2	46.4	12.7	132	StLCard
22.8	27.5	12.0	64.5	29.0	58.0	6.5	132	ChCubs
19.0	25.5	14.0	61.5	20.7	47.6	13.9	123	TxRanger
16.9	20.5	14.0	53.6	30.4	60.8	-7.2	117	KCRoyals
15.2	23.2	7.6	48.2	21.7	43.4	4.8	115	PhilPhil
25.7	27.0	10.0	64.9	39.2	66.6	-1.7	115	OakAthlt
19.0	27.9	5.0	54.1	34.3	61.7	-7.6	103	CalAngls
15.5	26.2	5.0	48.9	33.3	53.3	-4.4	99	SFGiants
17.1	24.4	5.3	49.0	27.1	48.8	0.2	98	CinnReds
15.6	23.1	7.5	48.4	24.4	48.8	-0.4	96	SDPadres
10.6	25.2	8.0	46.0	12.1	31.5	14.5	95	HousAstr
16.2	21.9	5.5	45.8	24.9	49.8	-4.0	87	PittPirt
15.6	28.8	5.0	51.6	31.1	54.4	-2.8	85	DetTiger
15.4	18.9	3.8	40.3	20.4	40.8	-0.5	83	AtBraves
18.2	20.5	3.2	44.1	24.1	48.2	-4.1	83	MinnTwin
15.5	22.0	5.0	44.7	17.4	41.8	2.9	79	SeatMar
14.2	19.4	3.0	38.8	26.4	50.2	-11.4	77	MilBrews
9.5	23.7	6.6	42.0	19.5	46.8	-4.8	77	ClevIndn
10.7	23.5	3.0	39.4	21.8	43.6	-4.2	75	MonExpos

Fuente: M. Ozanian and S. Taub, "Big Leagues, Bad Business," *Financial World*, July 7, 1992, pp. 34-51.

requieran las tres variables independientes). Si bien n es pequeña en este caso, elabore el intervalo de predicción del 95% para una muestra grande. ¿Siente usted que el análisis de regresión ha producido una herramienta útil para pronosticar la calidad del queso? Explique

24. Las cifras contables de 1991 de la liga mayor de béisbol aparecen en la tabla P-24. Todas las cifras están en millones de dólares. Las variables numéricas son GtReceit (entradas con boleto), MediaRev (ingreso promedio), StadRev (ingreso del estadio), TotRev (ingreso total), PlayerCt (costos de jugadores), OpExpens (gastos operativos), OpIncome (ingreso operativo = ingreso total – gastos operativos) y FranValu (valor de la franquicia).
 - a) Elabore una matriz de correlación para las variables GtReceit, MediaRev, ..., FranValu. A partir de la matriz de correlación, ¿puede usted determinar una variable que sea un buen factor para explicar FranValu? Discútalalo.
 - b) Use la regresión por pasos para elaborar un modelo que permita pronosticar el valor de la franquicia usando las variables restantes. ¿Está sorprendido con el resultado? Explique.
 - c) ¿Podría usted concluir que, como regla general, el valor de la franquicia es aproximadamente el doble del ingreso total? Explique
 - d) Los costos de los jugadores son una gran parte de los costos operativos. Desarrolle una ecuación para pronosticar los gastos operativos a partir de los costos de jugadores. Comente acerca de la fortaleza de la relación. Usando los residuos como guía, identifique los equipos que tienen costos de jugadores inusualmente bajos o inusualmente altos como un componente de los gastos operativos.
 - e) Considere las variables diferentes a FranValu. De acuerdo con sus definiciones, ¿existen grupos de variables que sean multicolineales? Si es así, identifique esos grupos.

CASOS

CASO 7-1 EL MERCADO DE BONOS¹⁶

Judy Johnson, vicepresidente financiera de una gran compañía privada que presta servicios públicos en el noroeste del país, se enfrentó con un problema de financiamiento. La compañía necesitaba dinero para pagar deudas de corto plazo por vencer y para continuar la construcción de una planta activada por carbón.

La principal preocupación de Judy era la estimación del mercado de bonos de 10 o 30 años; la compañía necesitaba decidir si usar financiamiento de capital o deuda a largo plazo. Para tomar esta decisión, la institución necesitaba un pronóstico confiable de la tasa de interés que pagaría en el momento de la emisión de los bonos.

Judy convocó a una junta al personal de finanzas para discutir el problema de los bonos. Un miembro de su equipo, Ron Peterson, con una maestría en administración, dijo que, en su opinión, se podía desarrollar un modelo de regresión múltiple para pronosticar las tasas de los bonos. Puesto que la vicepresidente no estaba familiarizada con la regresión múltiple, condujo la discusión en otra dirección. Después de una hora de interacción improductiva, Judy pidió a Ron un reporte al respecto para el siguiente lunes.

Ron sabía que la clave para el desarrollo de un buen modelo de pronóstico es la identificación de las variables independientes que se relacionan con la tasa

¹⁶Los datos de este caso fueron proporcionados por Dorothy Mercer, una estudiante de la maestría en administración de la Universidad del Este de Washington. El análisis fue realizado por los estudiantes de maestría Tak Fu, Ron Hand, Dorothy Mercer, Mary Lou Redmond y Harold Wilson.