

INTRODUCCIÓN A LOS PRONÓSTICOS EN LOS NEGOCIOS

Este libro examina los métodos usados para predecir la naturaleza incierta de las tendencias en los negocios, en un esfuerzo por ayudar a los administradores y gerentes a realizar mejores planes y a tomar mejores decisiones. Tales esfuerzos con frecuencia requieren el estudio de datos históricos y la manipulación de esos datos, en la búsqueda de patrones que se extrapolen efectivamente para realizar pronósticos.

En este libro, continuamente recordamos a los lectores que se debe hacer un buen juicio de los resultados numéricos, si queremos obtener pronósticos confiables. Los ejemplos en este capítulo, así como los casos de estudio al final de éste y del resto de los capítulos del texto, resaltan este punto. Hay más análisis acerca del papel del juicio en este capítulo y en el capítulo final.

LA HISTORIA DE LOS PRONÓSTICOS EN LOS NEGOCIOS

En un libro sobre la historia del riesgo, su autor, Peter Bernstein (1996), señaló que el desarrollo de los pronósticos en los negocios durante el siglo xvii fue una gran innovación. Él escribió:

—el pronóstico —largamente desacreditado como una pérdida de tiempo en el mejor de los casos, y como un pecado en el peor— se convirtió en una necesidad absoluta en el curso del siglo xvii, para algunos empresarios audaces que estaban dispuestos tomar el riesgo de dar forma al futuro, de acuerdo con su propio diseño. (p. 95)

Durante los siguientes 300 años, hubo avances significativos en los métodos para pronosticar basados en datos, muchos de los cuales ocurrieron en el siglo xx. Los métodos de análisis de regresión, descomposición, suavizamiento y promedios móviles autorregresivos son ejemplos de procedimientos para realizar pronósticos, basados en datos que se analizan en este libro. Tales procedimientos han demostrado ser altamente eficientes y aparecen rutinariamente en los menús del software comercial de pronósticos en los negocios.

Con el desarrollo de los métodos basados en datos, los enfoques del rol del buen juicio y la crítica para realizar pronósticos han crecido significativamente durante los últimos 25 años. Sin datos históricos, el juicio humano sería el único modo de hacer predicciones acerca del futuro. En los casos donde los datos están disponibles, el buen juicio debería utilizarse para revisar, y quizá modificar, el pronóstico elaborado mediante procedimientos cuantitativos. Si bien la mayor parte de este libro está dedicada a los métodos de elaboración de pronósticos basados en datos, se incluye un análisis sobre métodos críticos de pronósticos en el capítulo 10.

Con la difusión de poderosas computadoras personales y la disponibilidad de paquetes de software avanzado, se generan fácilmente los pronósticos de los valores futuros para variables de interés. Sin embargo, esta facilidad en el cálculo no sustituye el razonamiento claro. La falta de visión gerencial y el uso inadecuado de las técnicas para pronosticar quizá originen decisiones costosas.

Nuevos procedimientos de elaboración de pronósticos continúan desarrollándose conforme se acelera la necesidad de pronósticos más exactos.¹ Se pone especial atención al proceso de elaboración de pronósticos en organizaciones que tienen necesidad de coordinar objetivos, métodos, evaluación e interpretación.

¿ES NECESARIO EL PRONÓSTICO EN LOS NEGOCIOS?

A pesar de las imprecisiones inherentes al intentar predecir el futuro, los pronósticos necesariamente guían el establecimiento de políticas y la planeación. ¿Cómo puede la Reserva Federal ajustar en forma realista las tasas de interés, sin alguna noción del crecimiento económico futuro ni de las presiones inflacionarias? ¿Cómo un gerente de operaciones establecería realísticamente programas de producción sin algún estimado de las ventas futuras? ¿Cómo podría una compañía determinar la plantilla laboral de sus *call centers*, sin alguna suposición de la demanda futura de sus servicios? ¿Cómo un banco haría planes realistas sin algún pronóstico de futuros depósitos y saldos en préstamos? Todos requieren los pronósticos. La necesidad de pronósticos está en todas las líneas funcionales, así como en todos tipos de organizaciones. Los pronósticos son absolutamente necesarios para avanzar en el ambiente de negocios actual, siempre cambiante y altamente interactivo.

Este libro analiza varias formas de realizar pronósticos, que dependen de métodos lógicos de manipulación de datos que se han generado en eventos históricos. Pero creemos que el pronosticador eficaz debe ser capaz de establecer una hábil mezcla de pronóstico cuantitativo y buen juicio, evitando los extremos de confiar totalmente en uno o en otro. En un extremo, encontramos al ejecutivo que, por ignorancia y miedo a las computadoras y a las técnicas cuantitativas, confía solamente en su intuición y sensibilidad. En el otro extremo, está el pronosticador diestro en las más avanzadas técnicas actuales de manipulación de datos, pero que parece incapaz o está indispuerto para relacionar el proceso de elaboración del pronóstico, con las necesidades de la organización y de sus tomadores de decisiones. Nosotros vemos las técnicas cuantitativas para pronosticar, estudiadas en la mayor parte de este libro, como el único punto de arranque en el pronóstico efectivo de resultados importantes para la organización: análisis, juicio, sentido común y experiencia en el negocio deben aplicarse para brindar apoyo al proceso a través del cual estas importantes técnicas han generado sus resultados.

Otro pasaje de Bernstein (1996) resume efectivamente el rol del pronóstico en las organizaciones.

Usted no planearía enviar bienes a través del océano, ensamblar mercancía para vender ni solicitar dinero en préstamo, sin primero tratar de determinar qué depara el futuro a su empresa. Asegurarse de que los materiales que usted solicitó se entreguen a tiempo, saber que los artículos que usted planea vender se produzcan conforme a lo programado, y ver sus instalaciones reales de ventas deben planearse antes del momento en que los clientes aparecen y ponen su dinero en el mostrador. El ejecutivo de negocios exitoso es, en primer lugar, un pronosticador: la compra, la producción, el marketing, la fijación de precios y la organización vienen todos después. (pp. 21-22)

TIPOS DE PRONÓSTICOS

Cuando los gerentes se enfrentan con la necesidad de tomar decisiones en una atmósfera de incertidumbre, ¿qué tipos de pronósticos tienen disponibles? Los procedimientos para realizar pronósticos se clasifican, en primer lugar, como de largo plazo y de corto plazo. Los pronósticos a largo plazo necesariamente señalan el curso general de una organización para un tiempo de

¹Un repaso reciente acerca del estado actual de la elaboración de pronósticos está disponible en un número especial del *Internacional Journal of Forecasting*, editado por R. J. Hyndman y J. K. Ord (2006).

funcionamiento largo; de modo que se convierten en un tema de particular relevancia para la alta dirección. Los pronósticos a corto plazo se requieren para diseñar estrategias inmediatas, y las gerencias media y de primera línea los emplean para satisfacer las necesidades del futuro inmediato.

Los pronósticos también se clasifican en términos de su posición en un continuo micro-macro, es decir, en términos del grado en que implican pequeños detalles o grandes valores de resumen. Por ejemplo, un gerente de planta estaría interesado en pronosticar el número de trabajadores necesarios para los meses siguientes (un micro pronóstico); mientras que el gobierno federal pronostica el número total de gente con empleo en todo el país (un macro pronóstico). Otra vez, diferentes niveles de administración en una organización tienden a enfocarse en diferentes niveles del continuo micro-macro. La alta gerencia estaría interesada en el pronóstico de ventas de la toda compañía, por ejemplo; en tanto que los vendedores individuales estarían mucho más interesados en pronosticar sus propios volúmenes de ventas.

Los procedimientos para la elaboración de pronósticos también se clasifican de acuerdo con la tendencia a ser más cualitativos o más cuantitativos. En un extremo, una técnica puramente cualitativa es aquella que evidentemente no requiere manipulación de datos alguna, tan sólo se usa el “juicio” del pronosticador. Aun aquí, por supuesto, el “juicio” del pronosticador quizá sea realmente el resultado de la manipulación mental de ciertos datos históricos. En el otro extremo, las técnicas puramente cuantitativas no necesitan el juicio como insumo, pues se trata de procedimientos mecánicos para producir resultados cuantitativos. Por supuesto, algunos procedimientos cuantitativos requieren una manipulación de datos mucho más compleja que otros. Este libro se enfoca en las técnicas de pronóstico cuantitativas, porque la comprensión profunda de estos procedimientos tan útiles es necesaria en la administración eficiente de las organizaciones modernas. Sin embargo, destacamos una vez más que el buen juicio y el sentido común deberían utilizarse junto con los procedimientos mecánicos y de manipulación de datos. Sólo de este modo se obtendrá un pronóstico inteligente.

Finalmente, los pronósticos podrían clasificarse de acuerdo con la naturaleza del producto obtenido. Uno debe decidir si el pronóstico será un número individual (*pronóstico puntual*), un intervalo de números dentro del cual se espera que esté el valor futuro (un pronóstico por intervalo) o la distribución de probabilidad total del valor futuro (un *pronóstico de densidad*). Puesto que “shocks” imprevisibles pueden afectar los valores futuros (el futuro nunca es exactamente como el pasado), ocurrirán errores de pronóstico diferentes de cero, incluso en aquellos pronósticos muy buenos. De modo que hay cierta incertidumbre asociada con un pronóstico puntual específico. La incertidumbre que rodea los pronósticos puntuales sugiere la inutilidad de los pronósticos por intervalo. Sin embargo, si los pronósticos tan sólo son el resultado del juicio, los pronósticos puntuales normalmente son el único recurso. En situaciones de juicio, resulta extremadamente difícil describir con precisión la incertidumbre asociada con el pronóstico.

CONSIDERACIONES MACROECONÓMICAS DEL PRONÓSTICO

Usualmente concebimos los pronósticos en términos de la predicción de variables importantes para una compañía individual o quizá para un componente de la empresa. Ventas mensuales de la compañía, ventas unitarias de una de las tiendas de ésta, y horas de ausentismo por empleado por mes en una fábrica son buenos ejemplos.

En contraste, hay un interés creciente en la predicción de variables importantes para toda la economía de un país. Se ha desarrollado mucho trabajo en la evaluación de métodos para hacer esta clase de pronósticos económicos generales, llamados *pronósticos macroeconómicos*. Ejemplos de interés para el gobierno federal de Estados Unidos, y de muchos otros países, son la tasa de desempleo, el producto interno bruto y la tasa de interés de referencia. La política económica se basa, en parte, en las proyecciones de importantes indicadores económicos como éstos. Por tal motivo, existe un gran interés en mejorar los métodos para realizar pronósticos, que se enfoquen en mediciones generales del funcionamiento económico de un país.

Una de las principales dificultades en la elaboración de pronósticos precisos de la actividad económica general es el cambio relevante e inesperado de un factor económico clave. Cambios importantes en los precios del petróleo, inflación súbita, y cambios políticos significativos en el gobierno de un país son ejemplos de cambios de un factor clave que puede afectar la economía global.

La posibilidad de estos cambios relevantes en la escena económica motivó una pregunta fundamental en la elaboración de pronósticos macroeconómicos: ¿Los pronósticos generados por el modelo de elaboración de pronósticos deberían modificarse usando el buen juicio del pronosticador? Los trabajos actuales sobre la metodología en la realización de pronósticos a menudo implican dicha pregunta.

Se siguen efectuando trabajos teóricos y prácticos sobre la elaboración de pronósticos macroeconómicos. Considerando la importancia de la realización de pronósticos económicos precisos para la formulación de la política económica, para este y otros países, se esperaría una mayor atención futura para esta clase de pronósticos. Una buena referencia de introducción a los pronósticos macroeconómicos es Pindyck y Rubinfeld (1998).

SELECCIÓN DE UN MÉTODO DE PRONÓSTICOS

El análisis precedente sugiere que se consideren varios factores en la selección de un método para pronosticar. Se debe considerar el nivel de detalle. ¿Son necesarios los pronósticos de detalles específicos (un micro pronóstico)? ¿O es necesario el estatus futuro de algo general, o factor de resumen (un macro pronóstico)? ¿Es necesario el pronóstico para algún momento en el futuro cercano (un pronóstico a corto plazo) o de un momento en el futuro lejano (un pronóstico a largo plazo)? ¿Hasta dónde son adecuados los métodos cualitativos (juicio) y cuantitativos (manipulación de datos)? Y finalmente, ¿qué forma debería tomar el pronóstico (pronóstico puntual, por intervalo o de densidad)?

La consideración primordial en la selección de un método para pronosticar es que los resultados deben facilitar el proceso de toma de decisiones a los gerentes de la organización. Rara vez un método funciona para todos los casos. Diferentes productos (por ejemplo, nuevo contra existente), metas (por ejemplo, predicción sencilla contra la necesidad de controlar una importante directriz del negocio con valores futuros) y restricciones (por ejemplo, costo, habilidad requerida y lo prioritario) deben considerarse en la selección de un método de pronósticos. Con la disponibilidad del software actual para pronosticar, es mejor pensar en los métodos de pronósticos como herramientas genéricas que pueden aplicarse simultáneamente. En una situación dada es posible intentar varios métodos. La metodología que produce los pronósticos más exactos en un caso quizá no sea la mejor metodología en otra situación. Sin embargo, el(los) método(s) seleccionado(s) debería(n) producir un pronóstico que sea preciso, oportuno y comprensible para la gerencia, de manera que el pronóstico ayude a tomar mejores decisiones.

La selección de una técnica para pronosticar se analiza en el capítulo 3 y se resume en la tabla 3-6. Las metodologías para elaborar pronósticos que estudiamos en este libro se resumen en la tabla 11-1. Dichas tablas, junto con el análisis adicional disponible en Chase (1997), ayudan al pronosticador a seleccionar un conjunto inicial de procedimientos para pronosticar.

ETAPAS DEL PRONÓSTICO

Todos los procedimientos formales para pronosticar requieren extender las experiencias del pasado hacia el futuro. Así, implican la suposición de que las condiciones que generaron los datos y las relaciones pasados son iguales a las condiciones futuras.

Un departamento de recursos humanos contrata empleados, en parte, sobre la base de la puntuación en el examen de ingreso porque, en el pasado, esa puntuación parecía ser un predictor importante del nivel de desempeño en el trabajo. Siempre que se mantenga esta relación, el pronóstico del futuro desempeño en el trabajo —y, por lo tanto, las decisiones de contratación— puede mejorar usando las calificaciones del examen. Si, por alguna razón, la asociación

entre la puntuación del examen y el desempeño en el trabajo cambia, entonces el pronóstico del nivel de desempeño en el trabajo a partir de las puntuaciones del examen que usan el modelo histórico originará pronósticos imprecisos y, potencialmente, decisiones de contratación deficientes. Esto es lo que hace difícil pronosticar. El futuro no siempre es como el pasado. Cuando sí lo es, los métodos cuantitativos de elaboración de pronósticos funcionan bien. Cuando no lo es, llegan a producirse pronósticos imprecisos. Sin embargo, generalmente es mejor tener algún pronóstico construido razonablemente, que no pronosticar.

El reconocimiento de que las técnicas de pronósticos funcionan con datos generados por eventos históricos conduce a la identificación de los siguientes cinco pasos en el proceso de pronosticar:

1. Formulación del problema y recopilación de datos
2. Manipulación y limpieza de datos
3. Construcción y evaluación del modelo
4. Implementación del modelo (el pronóstico real)
5. Evaluación del pronóstico

En el paso 1, la formulación del problema y la recolección de datos se tratan como un solo paso porque están íntimamente relacionadas. El problema determina los datos apropiados. Si se está considerando una metodología cuantitativa para pronosticar, los datos pertinentes deben estar disponibles y ser correctos. Con frecuencia, el acceso y la recopilación de los datos adecuados constituyen una tarea desafiante y consumidora de tiempo. Si los datos apropiados no están disponibles, quizá tenga que volver a definirse el problema o tal vez se tenga que emplear una metodología no cuantitativa para pronosticar. Los problemas de recopilación y control de calidad de los datos surgen siempre que sea necesario obtener datos pertinentes para elaborar un pronóstico de negocios.

El paso 2, manipulación y limpieza de datos, a menudo es necesario. Es posible tener demasiados datos o muy pocos, en el proceso para realizar pronósticos. Algunos datos quizá no sean pertinentes. Tal vez a algunos datos les falten valores que deban estimarse. En ocasiones ciertos datos tienen que expresarse en unidades diferentes de las originales. Algunos datos deben volverse a procesar (por ejemplo, recolectarse de varias fuentes y sumarse). Otros datos pueden ser adecuados, pero sólo para ciertos periodos históricos (por ejemplo, en la elaboración del pronóstico de ventas de automóviles compactos, uno quizá disponga únicamente de los datos de venta de autos desde el embargo petrolero en la década de 1970, en vez de datos de venta durante los últimos 60 años). Normalmente se requiere algún esfuerzo para obtener datos en la forma requerida, para usar ciertos procedimientos para pronosticar.

El paso 3, construcción y evaluación del modelo, incluye ajustar los datos recolectados a un modelo de pronóstico que sea adecuado, en términos de minimizar errores en el pronóstico. Cuanto más sencillo sea el modelo, mejor será en términos de la aceptación del proceso de pronósticos por parte de los gerentes que deben tomar las decisiones de la empresa. Con frecuencia, se debe alcanzar un equilibrio entre un enfoque para pronosticar complejo que ofrezca un poco más de precisión, y un enfoque sencillo que se entienda fácilmente y gane el apoyo de quienes toman las decisiones de la compañía —y sea activamente usado por éstos. Evidentemente, el buen juicio interviene en este proceso de selección. Puesto que este libro analiza diversos modelos de pronósticos y su aplicación, la capacidad del lector para ejercitar el buen juicio, en la selección y el uso de modelos para pronosticar adecuados, se incrementará después de estudiar este material.

El paso 4, implementación del modelo, es la generación del modelo real una vez que se hayan recopilado y depurado los datos apropiados, y se haya seleccionado el modelo de pronóstico adecuado. Los datos de periodos históricos más recientes se mantienen como respaldo y más tarde se usan para verificar la exactitud del proceso.

El paso 5, evaluación del pronóstico, implica la comparación de los valores del pronóstico con valores históricos reales. Después de que se termina la implementación del modelo, se rea-

lizan los pronósticos para los periodos históricos más recientes, donde se conocen los valores de los datos, pero se mantienen como respaldo de los datos que se analizan. Estos pronósticos se comparan después con los valores históricos conocidos y se analizan cualesquiera errores en el pronóstico. Algunos procedimientos para pronosticar suman los valores absolutos de los errores y reportan esta suma; o dividen esta suma entre el número de intentos para producir el pronóstico, y conocer el error promedio del pronóstico. Otros procedimientos brindan la suma de los errores al cuadrado, lo cual se compara luego con cifras similares de métodos alternativos para pronosticar. Algunos procedimientos también rastrean y reportan la magnitud de los términos del error, durante el periodo del pronóstico. El examen de los patrones de error a menudo lleva al analista a modificar el modelo para pronosticar. Métodos específicos de medición de los errores en los pronósticos se examinan cerca del final del capítulo 3.

ADMINISTRACIÓN DEL PROCESO DE ELABORACIÓN DEL PRONÓSTICO

En este capítulo, el análisis sirve para resaltar nuestra creencia de que la capacidad gerencial y el sentido común deben intervenir en el proceso de elaboración del pronóstico. El pronosticador debería concebirse como un asesor del gerente, en vez de un monitor de un dispositivo automático para la toma de decisiones. Por desgracia, en la práctica se da el último caso, especialmente con la imagen que tiene la computadora. Otra vez, las técnicas cuantitativas de elaboración del pronóstico deben verse como realmente son; a saber, herramientas que el gerente va a utilizar para tomar mejores decisiones. De acuerdo con Makridakis (1986):

La utilidad del pronóstico mejoraría si la gerencia adoptara una actitud más realista. El pronóstico no debería verse como un sustituto del vaticinio, sino como el mejor camino para identificar y extrapolar patrones o relaciones establecidos para la elaboración de pronósticos. Si se acepta dicha actitud, los errores del pronóstico deben considerarse inevitables y se tienen que investigar las circunstancias que los causan. (p. 33)

Entonces, siempre deberían surgir algunas preguntas fundamentales, si el proceso de elaboración del pronóstico se administra adecuadamente:

- ¿Por qué es necesario el pronóstico?
- ¿Quién usará el pronóstico y cuáles son los requerimientos específicos?
- ¿Qué nivel de detalle o generalización se requiere, y cuál es el horizonte de tiempo adecuado?
- ¿Qué datos están disponibles y serán suficientes los datos para generar el pronóstico que se necesita?
- ¿Cuánto costará el pronóstico?
- ¿Qué tan exacto se espera que sea el pronóstico?
- ¿el pronóstico estará a tiempo para ayudar en el proceso de toma de decisiones?
- ¿El pronosticador entiende claramente cómo se usará el pronóstico en la organización?
- ¿Está disponible un proceso de retroalimentación para evaluar el pronóstico y ajustar el proceso como corresponde?

SOFTWARE DE PRONÓSTICOS

Actualmente, hay un gran número de paquetes de software diseñados específicamente para ofrecer al usuario diversos métodos para elaborar pronósticos. Dos tipos de paquetes computacionales son, en primera instancia, de interés para los pronosticadores: **1.** paquetes estadísticos generales que incluyen análisis de regresión, análisis de series de tiempo y otras técnicas usadas frecuentemente por quienes hacen pronósticos; y **2.** paquetes para elaboración de pronósticos diseñados específicamente para aplicaciones en pronósticos. Adicionalmente, algu-

nas herramientas de pronósticos están disponibles en los sistemas de planeación de recursos de la empresa (*enterprise resource planning*) (PRE).

Capacidades gráficas, interfaces con hoja de cálculo y fuentes de datos externas, métodos numéricos y estadísticos confiables, así como algoritmos automáticos sencillos para la selección y configuración de modelos para la elaboración de pronósticos, son ahora características comunes del software para pronóstico en los negocios. Sin embargo, aun cuando el desarrollo y conocimiento del software para pronósticos han crecido considerablemente durante los últimos años, la mayoría de las compañías usan simplemente hojas de cálculo (quizá con la función de complementos, *add-ins*) para generar pronósticos y desarrollar planes de negocios.

Ejemplos de paquetes de software específicos con *herramientas* para elaboración del pronóstico son Minitab, SAS y SPSS. Hay muchos programas complementarios que brindan herramientas para pronosticar en un ambiente de hoja de cálculo. Por ejemplo, *add-in* de Analysis ToolPak (Herramientas, análisis de datos) de Microsoft Excel ofrece algunas capacidades de análisis de regresión y de suavizamiento. Existen otros complementos más integrales que proporcionan un rango (casi) completo de capacidades para la elaboración de pronósticos.²

Algunas veces, particularmente en el ambiente de hojas de cálculo, están disponibles pronósticos “automáticos”. Es decir, el software selecciona el modelo o procedimiento que sea mejor para elaborar el pronóstico e, inmediatamente, genera los pronósticos. No obstante, debemos estar concientes de que esta ventaja tiene un precio. Los procedimientos automáticos producen números, pero raras veces brindan al pronosticador la comprensión real de la naturaleza y la calidad de los pronósticos. La generación de pronósticos significativos requiere de la intervención humana: un continuo intercambio entre el conocimiento del problema y los procedimientos (software) para la elaboración de pronósticos.

Muchas de las técnicas de este libro se ilustrarán con Minitab 15 y Microsoft Excel 2003 (con *add-in* de Análisis ToolPak). Se seleccionó Minitab 15 por su uso fácil y su amplia disponibilidad. Si bien Excel es limitado en su funcionalidad para la elaboración de pronósticos, a menudo es la herramienta seleccionada para proyecciones de cálculos.

INFORMACIÓN EN LÍNEA

Hay información disponible de interés para los pronosticadores en la Web. Quizás el mejor modo de aprender lo que está disponible en el ciberespacio sea pasar algún tiempo buscando todo lo que le interese a usted, usando un navegador como Netscape o Microsoft Internet Explorer.

Cualquier lista de sitios Web para los pronosticadores tal vez esté obsoleta para el tiempo en que aparezca esta edición; sin embargo, hay dos sitios Web que probablemente estén vigentes por algún tiempo. B&E DataLinks, disponible en www.econ-datalinks.org, es un sitio Web administrado por la Business and Economic Statistics Section of the American Statistical Association. Este sitio Web contiene muchos vínculos con fuentes de datos económicos y financieros que son de interés para los pronosticadores. El segundo sitio, Resources for Economists on the Internet, patrocinado por la American Economic Association, y disponible en rfe.org, contiene un extenso conjunto de vínculos con fuentes de datos, publicaciones, organizaciones profesionales, etcétera.

EJEMPLOS DE ELABORACIÓN DE PRONÓSTICOS

Los análisis en este capítulo enfatizan que la elaboración de pronósticos requiere un alto grado de juicio, junto con la manipulación matemática de los datos recopilados. Los siguientes ejemplos muestran la clase de pensamiento que precede a un esfuerzo de elaboración del pronóstico en una empresa real. Note que los valores de datos que producirán pronósticos útiles, incluso si

²Al momento de escribir esta edición, el Institute for Forecasting Education efectuó revisiones del software para pronósticos en su sitio Web. Se pueden consultar tales revisiones en www.forecastingeducation.com/forecastingsoftwareviews.asp.

existen, quizá no sean evidentes al inicio del proceso, y tal vez no se identifiquen conforme el proceso evoluciona. En otras palabras, los esfuerzos iniciales podrían terminar siendo inútiles y entonces se requeriría otro enfoque.

No se muestran los resultados de los esfuerzos en la elaboración de pronósticos para los dos ejemplos que se analizan aquí, ya que requieren temas que se estudian a lo largo del texto. Busque las técnicas descritas en capítulos posteriores y que se aplican a esos datos. Por el momento, esperamos que estos ejemplos ilustren el trabajo en la elaboración de pronósticos que los gerentes enfrentan en la realidad.

Ejemplo 1.1 Alomega Food Stores

Alomega Food Stores es un proveedor minorista de alimentos, con 27 tiendas en un estado del oeste medio. La compañía ha contratado varias clases de publicidad y, hasta hace poco, nunca había estudiado el efecto que su dinero en publicidad tienen sobre las ventas, aun cuando algunos datos se han recopilado y almacenado durante tres años.

Los ejecutivos de Alomega decidieron empezar a examinar sus campañas publicitarias, en relación con los volúmenes de ventas mensuales. Esperaban que después de algunos meses de recolectar datos, tuvieran la posibilidad de descubrir las relaciones que ayudarían en la determinación de los gastos futuros en publicidad.

El departamento de contabilidad empezó la generación de sus registros históricos, anotando los volúmenes de ventas mensuales junto con el dinero gastado en publicidad, tanto en anuncios de periódicos, como en spots televisivos. También registraron los valores de las ventas y la publicidad que se habían retrasado por uno y dos meses. Esto se hizo porque algunas personas del comité ejecutivo pensaron que quizá las ventas dependían de los gastos en publicidad en los meses previos, en vez del mes en que ocurrieron las ventas.

Asimismo, los ejecutivos creían que las ventas tenían un efecto estacional. Por tal razón, se usó una variable ficticia (*dummy*) o categórica para identificar cada mes. Adicionalmente, ellos querían conocer cualquier tendencia en el volumen de ventas.

Por último, los ejecutivos creían que el dinero que Alomega gastaba en publicidad podría tener un efecto en el presupuesto de publicidad de sus principales competidores, durante el mes siguiente. Para cada mes sucesivo, se decidió que la publicidad de los competidores se clasificaría como **1**, una cantidad pequeña, **2**, una cantidad moderada o **3**, una cantidad grande.

Después de pocos meses de recolección de datos y análisis de los registros pasados, el departamento de contabilidad terminó una muestra de 48 datos mensuales, usando las siguientes variables:

- Dinero en ventas
- Dinero en publicidad en periódicos
- Dinero en publicidad televisiva
- Código del mes, donde enero = 1, febrero = 2, hasta diciembre = 12
- Serie de 11 variables ficticias para indicar el mes
- Publicidad en el periódico atrasada un mes
- Publicidad en el periódico atrasada dos meses
- Publicidad televisiva atrasada un mes
- Publicidad televisiva atrasada dos meses
- Número de mes de 1 a 48
- Código 1, 2 o 3 para indicar las campañas publicitarias de los competidores el siguiente mes

Los gerentes de Alomega, especialmente Julie Ruth, la presidenta de la compañía, ahora quiere saber todo lo que pueda a partir de los datos que se han recolectado. Además del conocimiento acerca de los efectos de la publicidad sobre los volúmenes de ventas y la publicidad de los competidores, Julie se pregunta acerca de cualquier tendencia y efecto estacional en las ventas. Sin embargo, el gerente de producción de la compañía, Jackson Tilson, no comparte su entusiasmo. Al final de la junta de planeación del pronóstico, él hizo la siguiente declaración: “He estado tratando de mantener mi boca cerrada durante esta junta, pero es realmente demasiado. Creo que estamos perdiendo mucho tiempo de la gente con toda esta recolección de datos, y haciendo nimiedades con las computadoras. Todo lo que ustedes tienen que hacer es hablar con nuestra gente de piso y con los gerentes de la tienda de abarrotes, para entender qué está pasando. He visto que esto ya ha pasado antes y aquí vamos de nuevo. Alguien de ustedes necesita apagar sus computadoras, salir de sus confortables oficinas y hablar con algunas personas reales”.

Ejemplo 1.2 Minorista grande con operaciones en la Web

Uno de los objetivos de un minorista grande con operaciones en Internet es ser el centro de consumo más grande del mundo. La compañía reconoce que la capacidad para establecer y conservar relaciones de largo plazo con los clientes, y motivarlos a repetir visitas y compras, depende, en parte, de la fortaleza de las operaciones de servicio al cliente. En lo referente al servicio que no puede manejarse usando las características de sitios Web, los representantes de servicio al cliente están localizados en centros de contacto disponibles las 24 horas del día, para atender llamadas de voz y correos electrónicos.

Debido al crecimiento de sus ventas y a su estacionalidad (el volumen del servicio es relativamente bajo en verano y alto cerca del fin de año), es un reto para la compañía dotar del personal adecuado a sus centros de contacto. El problema de planeación implica tomar decisiones acerca de la contratación y la capacitación de los centros administrados internamente, así como de la distribución del trabajo para los proveedores externos, con base en el volumen de llamadas de voz y correos electrónicos. El manejo de cada tipo de contacto debe satisfacer un nivel de servicio determinado cada semana.

Para hacer el problema aún más difícil, el tiempo de duración de cada llamada de voz y correo electrónico se ve afectado por varios atributos del contacto, incluyendo el tipo de producto, de cliente y de compra. Dichos atributos se usan para clasificar los contactos en categorías: en este caso, una categoría “principal” y siete categorías “especiales”. Se necesita un conjunto de habilidades específicas para resolver las diferentes clases de asuntos que surgen en las diferentes categorías. Puesto que la contratación y la capacitación requieren seis semanas, se hacen necesarios pronósticos de contactos de servicio, para tener el número requerido de representantes de servicio disponibles las 24 horas del día, los 7 días a la semana durante todo el año.

Pat Niebuhr y su equipo son los responsables de desarrollar un plan global de dotación de personal para los centros de contacto. Su reto inicial es pronosticar los contactos para las categorías principal y especiales. Pat debe trabajar con pronósticos mensuales de los pedidos totales (los cuales, a la vez, se derivan de los pronósticos de ingresos mensuales) y los contactos por pedido (CPP), números proporcionados por el departamento de finanzas. Pat sabe que los contactos están dados por:

$$\text{Contactos} = \text{pedidos} \times \text{CPP}$$

Para efectos de la planeación de la dotación de personal, Pat debe tener pronósticos de contactos sobre una base semanal. Por fortuna, existe una historia de los pedidos reales, contactos reales, contactos reales por pedido y otra información relevante, en algunos casos, registrada por día de la semana. Esta historia está organizada en una hoja de cálculo. Pat considera usar esta información histórica para desarrollar los pronósticos necesarios.

Resumen

La finalidad de un pronóstico es reducir el nivel de incertidumbre con que deben realizarse los juicios de la gerencia. Tal propósito sugiere dos reglas fundamentales, las cuales debe seguir el proceso de elaboración de pronósticos:

1. El pronóstico debe ser técnicamente correcto y generar pronósticos lo suficientemente precisos para satisfacer las necesidades de la empresa.
2. El procedimiento de elaboración de pronósticos y sus resultados tienen que presentarse convincentemente a la gerencia, de modo que los pronósticos se utilicen en el proceso de toma de decisiones para beneficio de la compañía; los resultados también deben justificarse desde el punto de vista del costo-beneficio.

Los pronosticadores a menudo dan mucha atención a la primera regla y gastan menos esfuerzo en la segunda. Si los pronósticos bien preparados y de costo efectivo van a beneficiar a la empresa, deben usarlos quienes tienen la autoridad para tomar decisiones. Esto motiva la cuestión de lo que podría llamarse las “políticas” del pronóstico. Gastos sustanciales y frecuentemente mayores, así como la asignación de recursos dentro de una empresa, con frecuencia se basan en el punto de vista de la gerencia acerca del curso de eventos futuros. Puesto que el movimiento de recursos y poder dentro de una organización por lo general se basa en la percepción del futuro (pronósticos), no es sorprendente encontrar cierta cantidad de intriga política alrededor del proceso de la elaboración de pronósticos. La necesidad de vender efectivamente los pronósticos a la gerencia es, por lo menos, tan importante como la necesidad de desarrollar los pronósticos mismos.

El resto de este libro analiza varios modelos y procedimientos para realizar pronósticos. Primero revisaremos los conceptos estadísticos básicos, y daremos una introducción a la correlación y al análisis de regresión. Luego, dedicamos un capítulo a los métodos de recolección de datos y exploración de conjuntos de datos para establecer patrones. Muchos métodos específicos de elaboración de pronósticos se estudian con detalle en los siguientes capítulos; los dos capítulos finales se dedican a los aspectos de aplicación del juicio a los pronósticos y la administración del proceso de realizar pronósticos.

CASOS

CASO 1-1 MR. TUX

John Mosby es propietario de varias tiendas de alquiler Mr. Tux, la mayoría de ellas en el área de Spokane, Washington.³ Su tienda de Spokane también confecciona camisas para esmoquin, las cuales distribuye a tiendas de alquiler a lo largo del país. Debido a que la actividad de alquiler varía de una temporada a otra por los bailes colegiales, reuniones y otras actividades, John sabe que su negocio es estacional. A él le gustaría medir este efecto estacional, tanto para ayudarse en la administración de su negocio, como para su uso en la negociación de la deuda de un préstamo con su banquero.

Aun de mayor interés para John es encontrar la forma de pronosticar sus ventas mensuales. Su negocio continúa creciendo, lo cual, a la vez, requerirá de más capital y deudas a largo plazo. Él tiene fuentes de financia-

miento de dos tipos: inversionistas y banqueros; no obstante, ambos están interesados en contar con un modo concreto de pronosticar sus ventas futuras. Aún cuando confían en John, su dicho de que el futuro de su negocio “luce grandioso” los deja inquietos.

Como primer paso en la construcción de un modelo de pronóstico, John da instrucciones a uno de sus empleados, McKennah Lane, para recolectar mensualmente los datos de ventas durante varios años pasados. En los capítulos que siguen, se usarán varias técnicas para pronosticar tales datos de ventas para Mr. Tux. En el capítulo 11, se resumen dichas técnicas, así como los intentos de John Mosby para seleccionar la técnica de elaboración de pronósticos que mejor se adapte a sus necesidades.

CASO 1-2 CONSUMER CREDIT COUNSELING

Consumer Credit Counseling (CCC), una empresa privada sin fines de lucro, se fundó en 1982.⁴ El objetivo de CCC es proporcionar a los consumidores ayuda en la planeación y el seguimiento de presupuestos, así como asistencia en la negociación con acreedores para liquidar deudas con morosidad y en capacitación sobre la administración del dinero.

El asesoramiento financiero privado se ofrece sin costo a las familias y a los individuos que atraviesan por dificultades financieras, o que quieren mejorar sus

habilidades para administrar el dinero. Los programas educativos de administración del dinero se dan a escuelas, grupos comunitarios y negocios. Se cuenta con un programa de administración de la deuda como una alternativa a la bancarrota. A través de este programa, CCC negocia con los acreedores en representación del cliente para acuerdos de pagos especiales. El cliente hace un pago fijo a CCC que luego se desembolsa a los acreedores.

³Agradecemos a John Mosby, el propietario de las tiendas de alquiler Mr. Tux, por su ayuda en la elaboración de este caso.

⁴Agradecemos a Marv Harnishfeger, director ejecutivo de Consumer Credit Counseling de Spokane, y a Dorothy Mercer, presidenta de su consejo de administración, por su ayuda en la preparación de este caso. Dorothy es una ex alumna de MBA de JH, que se ha mantenido consistentemente en contacto con nosotros en el uso de métodos cuantitativos en el mundo de negocios real.

CCC tiene una mezcla de plantilla laboral remunerada y voluntaria; de hecho, los voluntarios superan en número al personal remunerado en proporción de tres a uno. Siete empleados pagados brindan administración, apoyo de oficina y cerca de la mitad de necesidades de asesoría de CCC. Veintiún consejeros voluntarios completan la otra mitad de las necesidades de asesoría del servicio. CCC depende de en primera instancia de fondos corporativos para financiar operaciones y servicios. The Fair Share Funding Program permite a los acreedores, que reciben pagos de un cliente endeudado, administrar programas para donar al servicio una porción de los fondos devueltos a ellos a través de dichos programas.

La mayoría del apoyo corporativo viene de una empresa local de servicio público, que proporciona financiamiento para una posición de asesor de tiempo completo, así como espacio de oficina para asesoramiento en todas las oficinas.

Adicionalmente, los cobros a los clientes son una fuente de recursos. Los clientes que participan en la administración de la deuda pagan una cuota mensual de \$15 para ayudar a cubrir los costos administrativos de este programa. (Las cuotas se reducen o se condonan a los clientes que no pueden solventarlos).

Este antecedente se usará en los capítulos que siguen cuando CCC enfrente problemas difíciles relacionados con el pronóstico de variables importantes.


Aplicaciones de Minitab

Minitab es un programa estadístico avanzado que se mejora en cada versión. Lo descrito aquí es la versión 15.

La figura 1-1 le muestra a usted cuatro aspectos importantes de Minitab. La barra del menú es donde el usuario selecciona los comandos. Por ejemplo, al hacer clic en Stat aparece un menú desplegable que contiene todas las técnicas estadísticas disponibles. La barra de herramientas despliega botones de las funciones usadas comúnmente. Note que estos botones cambian dependiendo de cuál ventana de Minitab esté abierta. Hay dos ventanas separadas en la pantalla de Minitab: la ventana de datos, donde usted introduce, edita y observa la columna de datos de cada hoja de cálculo; y la ventana de sesión, que despliega el texto de salida o producto, como tablas de estadísticas.

En los capítulos siguientes se darán instrucciones específicas para facilitarle la introducción de datos en la hoja de cálculo de Minitab y para activar los procedimientos de elaboración de pronósticos, para producir los pronósticos necesarios.

FIGURA 1-1 Pantalla básica de Minitab






FIGURA 1-2 Pantalla básica de Excel

Aplicaciones de Excel

Excel es un programa de hoja de cálculo de uso común, que se usa frecuentemente para la elaboración de pronósticos. La figura 1.2 muestra la pantalla abierta de la versión 2003. Los datos se introducen en las filas y columnas de la hoja de cálculo y, luego, se dan los comandos para ejecutar varias operaciones con los datos introducidos.

Por ejemplo, los salarios anuales de varios empleados se pueden introducir en la columna A y el promedio de esos valores es calculado por Excel. Como otro ejemplo, se colocan las edades de los empleados en la columna B y se examina la relación entre la edad y el salario. Los capítulos que siguen le mostrarán a usted cómo usar Excel para resolver estos y otros problemas en la elaboración de pronósticos.

Existen algunas funciones estadísticas disponibles en Excel, que quizá no estén en los menús desplegables en su pantalla. Para activar estas funciones, haga clic en lo siguiente:

Tools>Add-Ins o Herramientas>Complementos

Aparece la ventana de diálogo Add-Ins. Seleccione Analysis ToolPak y dé clic en OK. La función disponible bajo ToolPak se utilizará en capítulos posteriores.

Se recomienda ampliamente que un *add-in* o complemento de Excel se use para ayudar con los diversos cálculos estadísticos, requeridos por las técnicas de elaboración de pronósticos estudiadas en este libro de texto.

Referencias

- Bernstein, P. L. *Against the Gods: The Remarkable Store of Risk*. Nueva York: Wiley, 1996.
- Carlberg, C. "Use Excel's Forecasting to Get Terrific Projections". *Denver Business Journal* 47 (18)(1996): 2B.

- Chase, C. W., Jr. "Selecting the Appropriate Forecasting Method". *Journal of Business Forecasting* 15 (otoño de 1997): 2.
- Diebold, F. X. *Elements of Forecasting*, 3a. ed. Cincinnati, Ohio: South-Western, 2004.

- Georgoff, D. M. y R. G. Mardick. "Manager's Guide for Forecasting". *Harvard Business Review* 1 (1986): 110-120.
- Hogarth, R. M., and S. Makridakis. "Forecasting and Planning: An Evaluation." *Management Science* 27 (2) (1981): 115-138.
- Hyndman, R. J., and J. K. Ord, eds. "Special Issue: Twenty Five Years of Forecasting." *International Journal of Forecasting* 22 (2006): 413-636.
- Levenbach, H., and J. P. Cleary. *Forecasting Practice and Process for Demand Management*. Belmont, Calif.: Thomson Brooks/Cole, 2006.
- Makridakis, S. "The Art and Science of Forecasting." *International Journal of Forecasting* 2 (1986): 15-39.
- Newbold, P., and T. Bos. *Introductory Business and Economic Forecasting*, 2nd ed. Cincinnati, Ohio: South-Western, 1994.
- Ord, J. K., and S. Lowe. "Automatic Forecasting." *American Statistician* 50 (1996): 88-94.
- Perry, S. "Applied Business Forecasting." *Management Accounting* 72 (3) (1994): 40.
- Pindyck, R. S., and D. L. Rubinfeld. *Econometric Models and Economic Forecasts*, 4th ed. New York: McGraw-Hill, 1998.
- Wright, G., and P. Ayton, eds. *Judgemental Forecasting*. New York: Wiley, 1987.

CAPÍTULO

2

REPASO DE CONCEPTOS ESTADÍSTICOS BÁSICOS

La mayoría de las técnicas para la elaboración de pronósticos se basan en conceptos estadísticos fundamentales que se estudian en libros de texto de estadística en los negocios y en cursos introductorios de estadística. Este capítulo examina algunos de los conceptos básicos que servirán como base para la mayoría del material en el resto del libro.

La mayoría de los procedimientos estadísticos hacen deducciones sobre datos de interés, llamados *población*, después de la selección y la medición de un subgrupo de tales datos, llamado *muestra*. La selección cuidadosa de una muestra representativa y el uso de una muestra lo suficientemente grande son componentes importantes de un proceso estadístico deductivo, que tenga un grado de riesgo aceptablemente bajo.

En la elaboración de pronósticos, generalmente trabajamos con datos históricos en un intento por predecir el futuro incierto. Por tal motivo, nos concentraremos en examinar los datos de la muestra, en manipular estos datos de alguna forma y en usar los resultados para efectuar pronósticos.

DESCRIPCIÓN DE DATOS CON RESÚMENES NUMÉRICOS

El objetivo de los procedimientos estadísticos descriptivos es detallar brevemente un conjunto grande de mediciones, con unos cuantos valores clave resumidos. El resumen más común se obtiene promediando los valores. En estadística, el proceso de promediar generalmente se realiza calculando la *media*, la cual implica la suma de todos los valores y la división entre el número de éstos. Aunque en cierto sentido la media indica la “parte de en medio”, este cálculo es sensible a unas cuantas mediciones que sean mucho más grandes o mucho más pequeñas que el resto. Estas mediciones inusuales se denominan *valores atípicos*. El ejemplo 2.1 presenta una ilustración de este fenómeno.

La media de la muestra ($\bar{X}$ o X -testada) se calcula usando la ecuación 2.1.

$$\bar{X} = \frac{\sum X}{n} \quad (2.1)$$

donde

$\bar{X}$ = la media de la muestra

$\sum X$ = la suma de todos los valores de la muestra

n = el tamaño de la muestra

Para simplificar los cálculos en este texto, se usa un tipo de notación abreviada. En la notación simplificada para la suma de todos los valores de X (véase la ecuación 2.1), se entiende que la sumatoria va desde 1 hasta n . Un sistema de notación más formal para este procedimiento es

$$\sum_{i=1}^n X_i$$

donde el subíndice i varía de su valor inicial de 1 a n , en incrementos de 1. Puesto que casi todas las sumas van de 1 a n , omitiremos los índices inicial y final, y usaremos la notación más sencilla, excepto donde sea necesaria una notación más completa para fines de claridad.

Además de la tendencia central de un conjunto de valores, obtenidos al calcular la media, también es interesante conocer el rango (intervalo) a través del cual se dispersan los valores alrededor de la media. La *desviación estándar* es una unidad para medir la distancia desde la media. La fórmula para la desviación estándar está dada por

$$S = \sqrt{\frac{\sum (X - \bar{X})^2}{n - 1}} = \sqrt{\frac{\sum X^2 - \frac{(\sum X)^2}{n}}{n - 1}} \quad (2.2)$$

donde el numerador es la suma de las diferencias al cuadrado, entre los valores medidos y su media.

Muchos procedimientos estadísticos utilizan la *varianza* de la muestra. La varianza de un conjunto de medidas es la desviación estándar al cuadrado. Entonces, la varianza de la muestra (S^2) se calcula como

$$S^2 = \frac{\sum (X - \bar{X})^2}{n - 1} = \frac{\sum X^2 - \frac{(\sum X)^2}{n}}{n - 1} \quad (2.3)$$

Ejemplo 2.1 Cálculo de media, varianza y desviación estándar

Considere el siguiente conjunto de edades de personas:

23, 38, 42, 25, 60, 55, 50, 42, 32, 35

Para esta muestra, $n = 10$ y

$$\sum_{i=1}^n X_i = X_1 + X_2 + \cdots + X_{10} = 23 + 38 + \cdots + 35 = 402$$

$$\bar{X} = \frac{\sum X}{n} = \frac{402}{10} = 40.2$$

$$S^2 = \frac{\sum (X - \bar{X})^2}{n - 1} = \frac{(23 - 40.2)^2 + \cdots + (35 - 40.2)^2}{10 - 1} = \frac{1,339.6}{9} = 148.84$$

$$S = \sqrt{S^2} = \sqrt{148.84} = 12.2$$

Los cálculos se muestran en la tabla 2.1. La media de la muestra es 40.2 años, la varianza de la muestra es 148.84 y la desviación estándar de la muestra es 12.2 años.

TABLA 2-1 Cálculo de S^2 ($\bar{X} = 40.2$)		
X	$X - \bar{X}$	$(X - \bar{X})^2$
23	-17.2	295.84
38	-2.2	4.84
42	1.8	3.24
25	-15.2	231.04
60	19.8	392.04
55	14.8	219.04
50	9.8	96.04
42	1.8	3.24
32	-8.2	67.24
35	-5.2	27.04
		$\Sigma(X - \bar{X})^2 = 1,339.60$
		$S^2 = \frac{1,339.60}{10 - 1} = 148.84$

Para indicar la sensibilidad de la media a una medición atípica, suponga que sustituimos la edad 60 con una edad mucho mayor, digamos 90. Sustituyendo esta edad, la media sería

$$\bar{X} = \frac{\Sigma X}{n} = \frac{23 + \cdots + 25 + 90 + 55 + \cdots + 35}{10} = \frac{432}{10} = 43.2$$

Incrementar el tamaño de una sola de las diez edades originales da como resultado un incremento de 3 años en la media de la edad.

El término *grados de libertad* se usa para indicar el número de datos que son libres entre sí, en el sentido de que no pueden calcularse uno a partir del otro y, por lo tanto, llevan piezas de información únicas. Por ejemplo, suponga que se hacen los tres enunciados siguientes:

Estoy pensando en el número 5. Estoy pensando en el número 7. La suma de los dos números en que estoy pensando es 12.

A primera vista, se presentan tres piezas de información. Sin embargo, si se conocen cualesquiera dos de estos enunciados, el otro se podría inferir. Diríamos entonces que sólo hay dos piezas únicas de información en los tres enunciados o, usando el término estadístico, sólo hay dos grados de libertad porque únicamente dos de los valores tienen libertad para variar; no así el tercero.

Los *grados de libertad* se refieren al número de datos que son independientes uno de otro y que tienen piezas de información únicas

En el ejemplo que se presenta en la tabla 2-1, las edades de 10 personas constituyen una muestra con 10 grados de libertad. Cualquier edad pudo haberse incluido en la muestra y, por lo tanto, cada una de las edades tiene libertad para variar. Cuando se calcula la media, se usan las 10 edades para contar con una edad media igual a 40.2 años.

El cálculo de la desviación estándar de la muestra difiere. Cuando se calcula la desviación estándar de la muestra, se usa un estimado de la media de la población (la media de la muestra $\bar{X}$). Si en los cálculos se emplea la media de la muestra como un estimado de la media de la población, por lo general se obtendrá una desviación estándar más pequeña que la desviación estándar de la población. Sin embargo, este problema se corrige dividiendo el valor $\sum(X - \bar{X})^2$ entre los grados de libertad adecuados. Una vez que se calcula la media de la muestra, sólo se requieren nueve de las desviaciones $X - \bar{X}$, en este ejemplo, para calcular la desviación estándar de la muestra. Dadas nueve de las desviaciones, se determina la última desviación, puesto que $\sum(X - \bar{X})$ debe ser igual a cero. Por lo tanto, decimos que la desviación estándar de la muestra (o varianza de la muestra) tiene nueve grados de libertad. En general, siempre que se utilice un estadístico muestral para estimar un parámetro de la población, se pierde un grado de libertad.

Se pueden definir estadísticos de resumen para poblaciones. Para distinguir entre parámetros poblacionales de estadísticos muestrales, usamos notaciones diferentes. La tabla 2-2 presenta los símbolos usados tanto para parámetros de la población como para estadísticos muestrales.

La media y la desviación estándar son las medidas más comúnmente usadas para describir datos muestrales de forma breve y significativa. Sin embargo, están disponibles otras medidas de resumen descriptivas. Por ejemplo, la *mediana* se usa a menudo para indicar el valor de la parte media o central en un conjunto de datos. La mediana es el valor que divide por la mitad un conjunto de mediciones ordenadas. Es decir, la mitad de las mediciones son menores que la mediana y la mitad son mayores. Puesto que la mediana simplemente divide un conjunto de mediciones por la mitad, es invariable si, por ejemplo, se incrementa la medición más grande. Decimos que la mediana es *resistente* a los efectos de valores atípicos.

Algunas veces, el *rango* de datos se presenta como una medida de dispersión burda. El rango es la diferencia entre los valores mayor y menor. Por ejemplo, el rango de edades en la tabla 2-1 es 37 (60-23).

Después de que los valores numéricos se ordenan de menor a mayor, los *cuartiles* dividen el conjunto de datos en cuatro partes iguales. Como hemos visto, la mediana divide el conjunto ordenado en dos partes iguales y, algunas veces, se llama el *segundo cuartil* y se denota con Q_2 . El *primer cuartil* (Q_1) divide la mitad inferior del conjunto en dos partes iguales, en tanto que el *tercer cuartil* (Q_3) divide la mitad superior en dos partes iguales. El conjunto de edades en la tabla 2-1, por ejemplo, tiene un primer cuartil de $Q_1 = 30.25$, una mediana (o segundo cuartil) de $Q_2 = 40$ y un tercer cuartil de $Q_3 = 51.25$.

Finalmente, el *rango intercuartil* es otro indicador de la variabilidad de un conjunto de datos. Es simplemente la diferencia entre el tercer cuartil y el primer cuartil ($Q_3 - Q_1$), es decir, el rango para el 50% central de los valores de los datos. Para los datos de edades, el rango intercuartil es 21 ($51.25 - 30.25$).

Minitab y Excel sirven para calcular la mayoría de los estadísticos descriptivos presentados hasta aquí. La figura 2-1 muestra el resultado de Minitab para los datos de edades de la tabla 2-1. Las instrucciones para el cálculo de estadísticos descriptivos usando Minitab y Excel se presentan en las secciones de aplicaciones de Minitab y Excel, al final de este capítulo.

TABLA 2-2 Notación para parámetros de la población y de la muestra

Estadístico	Símbolo de población	Símbolo de muestra
Media	μ	$\bar{X}$
Varianza	σ^2	S^2
Desviación estándar	σ	S




FIGURA 2-1 Resultado de Minitab para estadísticos descriptivos

PRESENTACIÓN DE INFORMACIÓN NUMÉRICA

En la elaboración de pronósticos, trabajamos con dos tipos de datos: *datos transversales*, los cuales consisten en observaciones desde el mismo marco de referencia temporal; y datos de *series de tiempo*, que consisten en una secuencia de observaciones en el tiempo. La tabla 2-3 muestra un ejemplo de datos transversales: el ingreso neto como un porcentaje del capital invertido para una muestra de 209 compañías en una encuesta específica de Fortune 500. Otro ejemplo son los ingresos anuales de ejecutivos corporativos en 2006 y los precios de venta de casas en cierta ciudad en un día determinado. Algunos ejemplos de datos de series de tiempo son el número de visitantes mensuales al Grand Coulee Dam Visitor Center durante varios años, las ventas mensuales de Sears Corporation durante los últimos diez años, el precio diario de la acción de IBM para 2006 y la producción anual de trigo en Estados Unidos para el periodo 2000-2005.

Una de las cuestiones más importantes que se deben hacer primero cuando se explora una variable es visualizar los datos en tablas y gráficas. Las características básicas de los datos, incluyendo observaciones inusuales y patrones únicos, se perciben más fácil visualmente. A veces, incluso, las gráficas sugieren explicaciones posibles para alguna variación en los datos.

Un *diagrama de puntos* es una de las formas más simples de visualizar gráficamente los datos. En la figura 2-2 el eje horizontal presenta el rango de valores para el ingreso neto como un porcentaje del capital invertido de la tabla 2-3. Cada observación se representa usando un punto colocado encima del eje. Los diagramas de puntos muestran los detalles de los datos y también le permiten a un pronosticador comparar dos o más conjuntos de datos.

Un *diagrama de caja* es útil para mostrar las características de distribución de los datos. La figura 2-3 ilustra un diagrama de caja del ingreso neto como un porcentaje de los datos del capital invertido de la tabla 2-3. En la mediana se traza una línea a lo largo de la caja. Esta línea

TABLA 2-3 Ingreso neto como un porcentaje del capital invertido para una muestra de 209 compañías en una encuesta de Fortune 500

17	23	22	18	8	7	12	2	49	14
14	36	16	7	3	8	10	11	20	17
15	25	18	12	20	7	5	11	0	22
14	10	14	19	8	12	13	21	3	22
11	18	2	18	14	11	36	16	7	14
12	14	10	8	20	13	8	23	6	21
9	23	7	14	25	12	12	8	11	5
18	13	14	9	16	2	19	21	18	9
14	2	20	17	11	16	13	12	22	16
7	6	14	10	1	21	35	20	18	28
17	15	9	12	5	10	14	1	17	14
14	14	6	22	16	13	14	8	12	6
15	10	22	19	16	4	20	18	2	3
20	7	15	39	4	3	10	7	15	16
12	13	12	11	18	10	13	7	13	12
14	8	11	17	11	22	16	11	12	11
9	11	13	0	12	3	9	9	13	27
1	16	18	12	11	0	10	9	12	22
18	44	4	3	17	12	8	16	7	16
27	11	19	12	22	3	14	14	7	8
11	1	3	17	8	7	5	19	22	




FIGURA 2-2 Diagrama de puntos para el ingreso neto como un porcentaje del capital invertido para una muestra de 209 compañías en una encuesta de Fortune 500

divide los datos en dos secciones iguales. El borde inferior del cuadro es el primer cuartil (Q_1), y el borde superior es el tercer cuartil (Q_3). Se construyen límites adicionales usando el rango intercuartil ($Q_3 - Q_1$). El límite inferior se localiza en $Q_1 - 1.5(Q_3 - Q_1)$, y el límite superior se localiza en $Q_3 + 1.5(Q_3 - Q_1)$. Los valores atípicos están identificados como aquellos puntos fuera de los límites inferior y superior, y están representados por asteriscos. En la figura 2-3, el primer cuartil es 8, la mediana es 13, el tercer cuartil es 17, y el rango intercuartil es




FIGURA 2-3 Diagrama de caja para el ingreso neto como un porcentaje del capital invertido para una muestra de 209 compañías en una encuesta de Fortune 500

9 ($17 - 8$). El límite inferior es -5.5 ($8 - 1.5 \times 9$) y el límite superior es 30.5 ($17 + 1.5 \times 9$). Note que el valor más bajo dentro del límite inferior, -5.5 , es 0; en tanto el valor más alto dentro del límite superior, 30.5 , es 28. Seis valores (35, 36, 36, 39, 44 y 49) exceden el límite superior de 30.5 y son los valores atípicos.

El *histograma* condensa los datos, agrupando valores similares en clases. Se puede construir un histograma colocando la variable de interés en el eje horizontal, y la frecuencia, frecuencia relativa o frecuencia porcentual, en el eje vertical. Al observar un histograma como el de la figura 2-4, usted puede indicar la proporción del área total, arriba de un intervalo del eje




FIGURA 2-4 Histograma del ingreso neto como un porcentaje del capital invertido para una muestra de 209 compañías en una encuesta de Fortune 500




FIGURA 2-5 Ventas mensuales de las tiendas de alimentos Alomega (de la tabla 3-11)

horizontal. Un total de 23 de las 209 compañías, o el 11.0%, tienen ingreso neto como porcentaje del capital invertido en el rango entre 6.25% y 8.75%. Por lo tanto, el cuarto rectángulo de la figura 2-4 contiene .110 del área total representada por las barras verticales sombreadas.

Aunque los histogramas ofrecen buenas descripciones visuales de conjuntos de datos, especialmente de conjuntos de datos muy grandes, no nos permiten identificar observaciones individuales. En contraste, en un diagrama de puntos, está visible cada uno de los valores originales.

Se utilizan *diagramas de dispersión* para visualizar la relación entre dos variables. Tales diagramas se analizarán más adelante, en el capítulo de la sección sobre análisis de correlación.

Para datos cronológicos, la forma gráfica más frecuentemente empleada es un *diagrama de series de tiempo*, en el cual los datos se grafican a través del tiempo. La figura 2-5 ilustra el diagrama de una serie de tiempo con las ventas anuales en las tiendas de alimentos Alomega, que analizamos en el ejemplo 1.1. Un diagrama de series de tiempo revela la variabilidad de los datos y el momento en que ocurren picos y valles. También muestra el tamaño relativo de los picos y los valles, en comparación con el resto de la serie.

Un paso importante en la selección de una técnica de pronósticos adecuada consiste en identificar los patrones de datos que existen dentro de una serie de tiempo. Una vez que se identifican los patrones de datos, se pueden utilizar los métodos de pronóstico más adecuados para tales patrones. Se identifican cuatro tipos de patrones de datos para series de tiempo: horizontal, de tendencia, cíclico y estacional. Cada tipo se estudiará con profundidad en el capítulo 3.

Una herramienta utilizada con frecuencia para identificar patrones de datos en las series de tiempo es el *correlograma* o la *función de autocorrelación*, que es una herramienta gráfica para presentar las correlaciones entre diversos retrasos de una serie de tiempo. Los correlogramas también se examinarán en el capítulo 3.

DISTRIBUCIONES DE PROBABILIDAD

Variable aleatoria es el nombre que se le da a una cantidad que puede tomar valores diferentes de una prueba a otra en un experimento, donde el resultado exacto es un suceso fortuito. Si sólo son posibles ciertos valores específicos, la variable aleatoria se llama *variable discreta*. Ejemplos son el número de habitaciones en una casa, el número de gente que llega a pagar a las cajas de un supermercado en cierta hora, y el número de unidades defectuosas en un lote de partes elec-

trónicas. Si es posible cualquier valor de la variable aleatoria dentro de cierto rango, se llama *variable continua*. Ejemplos de este tipo de variable son el peso de un individuo, la longitud de una parte manufacturada, y el tiempo entre llegadas de automóviles a una caseta de peaje.

Una *variable aleatoria discreta* puede tener valores tan sólo de un conjunto predeterminado. A menudo tales resultados se presentan como números enteros. Una *variable aleatoria continua* puede tomar cualquier valor dentro de un rango específico. Tales resultados se representan numéricamente con intervalos de valores.

La *distribución de probabilidad* de una variable aleatoria discreta enlista todos los valores posibles que puede tomar la variable, junto con la probabilidad de que ocurra cada uno. El *valor esperado* de una variable aleatoria es el valor medio (promedio) que adquiere la variable en muchos intentos realizados. El valor esperado, $E(X)$, para una distribución de probabilidad discreta se obtiene al multiplicar cada valor posible de X por su probabilidad, $P(X)$, y después se suman los productos. La ecuación 2.4 presenta este cálculo:

$$E(X) = \sum [X \times P(X)] \quad (2.4)$$

El *valor esperado* de una variable aleatoria es el valor medio de la variable a lo largo de varios ensayos u observaciones.

Ejemplo 2.2 Una distribución de probabilidad discreta

El número de días sin ventas de un vendedor, durante un mes, se describe mediante la distribución de probabilidad mostrada en la tabla 2-4. Estos valores se basan en experiencias del vendedor y se usarán para pronosticar la actividad futura de ventas. La columna X lista todos los valores (días sin ventas) que son posibles, mientras que la columna $P(X)$ lista las probabilidades correspondientes. Observe que puesto que se listan todos los valores posibles de X , las probabilidades suman 1.00, o 100%. Esto es válido para todas las distribuciones de probabilidad, ignorando los errores por redondeo.

Para la distribución de probabilidad dada en la tabla 2-4, el valor esperado es

$$E(X) = 1(.1) + 2(.2) + 3(.25) + 4(.15) + 5(.30) = 3.35$$

De modo que si se observara a este vendedor durante un número de meses muy grande y se registrara el número de días sin venta, la media sería 3.35 días sin venta, si la actividad futura está pronosticada correctamente por los datos históricos, en los cuales se basa la distribución de probabilidad.

TABLA 2-4 Distribución de probabilidad discreta para el ejemplo 2.2

X	$P(X)$
1	.10
2	.20
3	.25
4	.15
5	.30

Advierta que la media cae cerca de la parte central de los valores X . Es atraída hacia el extremo superior de la distribución de probabilidad debido a la probabilidad relativamente alta asociada con $X = 5$.

Para una distribución continua, la probabilidad de obtener un valor específico se aproxima a cero. Por ejemplo, la probabilidad de que alguien pese 150 libras podría considerarse igual a cero, ya que esto significaría que tal peso sea exactamente 150.0000 —sin importar la precisión de la escala que se use. En el caso de la distribución continua, las probabilidades se asignan a intervalos o rangos de valores. Por ejemplo, podría calcularse la probabilidad de que el peso de un individuo caiga en el intervalo de 149 a 151 libras.

Algunas distribuciones teóricas ocurren una y otra vez en aplicaciones estadísticas prácticas, y por este motivo es importante examinar sus propiedades. Una de éstas es la *distribución binomial*, que a menudo se utiliza para representar una variable aleatoria discreta. Los requisitos para un experimento binomial son los siguientes:

1. Hay n ensayos idénticos, cada uno de los cuales da como resultado uno de dos resultados posibles —digamos, éxito y fracaso.
2. La probabilidad de éxito para cada resultado se mantiene igual de un ensayo a otro.
3. Los ensayos son independientes (no están relacionados).

Nos interesa encontrar la probabilidad X de éxitos que ocurren en n ensayos, donde arbitrariamente el éxito se define como uno de los dos resultados posibles. Los diversos valores de X , junto con sus probabilidades, forman la distribución binomial. Estas probabilidades se calculan con la siguiente fórmula binomial:

$$P(X) = \binom{n}{X} p^X (1 - p)^{n-X} \quad \text{para } X = 0, 1, \dots, n \quad (2.5)$$

donde

$\binom{n}{X}$ = el número de combinaciones de n elementos tomados X a la vez

p = la probabilidad de éxito en cada ensayo

X = el número específico de éxitos que nos interesa

n = el número de ensayos

La *distribución binomial* es una distribución de probabilidad discreta, que describe la probabilidad de X éxitos en n ensayos independientes de un experimento binomial.

Una forma más sencilla de encontrar probabilidades binomiales que usar la ecuación 2.5 es remitirse a una tabla de distribución binomial como la tabla B-1, que se encuentra en el Apéndice B. Los bloques que representan n agrupan las probabilidades. Cada bloque tiene una columna titulada con p y filas indicadas con X .¹

¹Minitab y Excel también calculan probabilidades binomiales.




FIGURA 2-6 Una distribución normal

Ejemplo 2.3 Una probabilidad binomial

Suponga que ocho artículos se extraen aleatoriamente de una línea de producción que, se sabe, produce partes defectuosas el 5% de las veces. ¿Cuál es la probabilidad de obtener exactamente cero defectuosos? La respuesta de la tabla B-1 es 0.6634. (Aquí, $n = 8$, $p = .05$ y $X = 0$).

La distribución continua importante, ya que muchas poblaciones de números se pueden aproximar mediante ella, es la *distribución normal*. Para identificar una población normal específica, es necesario conocer la media y la desviación estándar. Una curva normal es simétrica y tiene forma de campana, como se ilustra en la figura 2-6. Esta distribución representa muchas variables de la vida real que se miden en una escala continua.

Las probabilidades de valores extraídos de una distribución normal, que caen en varios intervalos, se obtienen convirtiendo primero todos los intervalos en unidades de desviación estándar, llamadas Z como número de varianzas.² El resultado Z , como el número de varianzas de cualquier valor de X , es el número de desviaciones estándar desde el valor central de la curva (μ) hasta ese valor. Entonces, la fórmula es

$$Z = \frac{X - \mu}{\sigma} \quad (2.6)$$

donde

X = el valor de interés

μ = la media

σ = desviación estándar

Después de que se haya calculado Z como número de varianzas, se puede consultar la tabla de la curva normal, para encontrar el área bajo la curva entre el centro de la curva original (μ) y el valor de interés (X).³

La *distribución normal* tiene forma de campana y está completamente determinada por su media y su desviación estándar.

²Se puede demostrar que, si la variable aleatoria X tiene una distribución normal con media μ y desviación estándar σ , entonces la variable aleatoria $Z = (X - \mu)/\sigma$ tiene una distribución normal, con media 0 y desviación estándar 1. Esta distribución normal específica se conoce como la *distribución normal estándar*.

³Se pueden calcular las probabilidades normales usando Minitab o Excel.




FIGURA 2-7 Áreas de la curva normal para el ejemplo 2.4

Ejemplo 2.4 Cálculo de una probabilidad normal

Los pesos de una población de partes fabricadas con cierta máquina, están distribuidos normalmente con una media de 10 libras y una desviación estándar de 2 libras. ¿Cuál es la probabilidad de que una pieza seleccionada al azar de la máquina pese entre 9 y 12 libras? La curva normal con el área sombreada adecuada se ilustra en la figura 2-7.

Puesto que a menudo las tablas de la curva normal se diseñan para dar áreas desde el centro de la curva hasta algún punto, deben obtenerse dos áreas separadas: una a cada lado de la media. Luego se suman estas áreas. Dicho proceso indicará la probabilidad de que un valor caiga en este intervalo. Los dos valores de Z son

$$Z_1 = \frac{X_1 - \mu}{\sigma} = \frac{9 - 10}{2} = -.50$$

$$Z_2 = \frac{X_2 - \mu}{\sigma} = \frac{12 - 10}{2} = 1.00$$


Por lo tanto, el área bajo la curva normal entre 9 y 12 de la figura 2-7 es la misma que el área bajo la curva normal de Z (véase la nota al pie de página 2) entre $-.5$ y 1 . Para la tabla normal de este libro, se ignora el signo negativo en el primer valor de Z , ya que el área de la curva normal para Z entre $-.5$ y 0 es la misma que el área bajo la curva entre 0 y $.5$. Estos dos valores de Z se localizan en la tabla B-2, una tabla de curva normal, darán como resultado las siguientes dos áreas, las cuales se suman después:

$$\begin{array}{rcl}
 Z_1 = -.50 & : & .1915 \\
 Z_2 = 1.00 & : & .3413 \\
 & & \hline
 & & .5328
 \end{array}$$

Se concluye que hay aproximadamente un 53% de probabilidad de que una parte de esta población, extraída al azar, pesará entre 9 y 12 libras.

DISTRIBUCIONES MUESTRALES

En la mayoría de aplicaciones estadísticas, se extrae una muestra al azar de la población en estudio, se calcula un estadístico a partir de los datos de la muestra y se infieren conclusiones acerca de la población sobre la base de dicha muestra. Una *distribución muestral* es la distribución de todos los valores posibles del estadístico muestral que se pueden obtener de la

FIGURA 2-8 Distribución muestral de $\bar{X}$

población, para un tamaño de muestra dado. Por ejemplo, de una población se toma una muestra aleatoria de 100 personas, se pesan y luego se calcula su media (promedio) de peso. Esta media de la muestra ($\bar{X}$) puede considerarse como si fuera extraída de la distribución de todas las medias muestrales posibles, con un tamaño de 100, que podrían tomarse de la población. Más generalmente, cada estadístico muestral que se calcule a partir de los datos de la muestra puede considerarse como si se hubiera tomado de una distribución muestral.

Una *distribución muestral* es el arreglo de todos los valores posibles de un estadístico muestral, que puede extraerse de una población, para un tamaño de muestra dado.

El *teorema central del límite* indica que, conforme aumenta el tamaño de la muestra, la distribución muestral de las medias de la muestra tiende hacia la distribución normal, y que la media de esta distribución normal es μ , la media de la población; y la desviación estándar es $\sigma/\sqrt{n}$, la desviación estándar de la población, dividida entre la raíz cuadrada del tamaño de la muestra. La cantidad $\sigma/\sqrt{n}$ se conoce como el *error estándar* de la media de la muestra. Así, la distribución muestral de la media de la muestra tenderá hacia la normalidad, sin importar la forma de la distribución de la población de la cual se extrajeron las muestras. La figura 2-8 demuestra cómo se observaría tal distribución muestral.

El teorema central del límite es de importancia fundamental en estadística, ya que permite a los analistas calcular la probabilidad de varios resultados de muestras, usando el conocimiento de las probabilidades de la curva normal.

Ejemplo 2.5 Cálculo de una probabilidad usando la distribución muestral de $\bar{X}$

¿Cuál es la probabilidad de que la media de una muestra aleatoria de 100 pesos —extraída de una población— estará dentro de 2 libras del peso medio de la población verdadera, si se estima que la desviación estándar de la población es de 15 libras? La figura 2-9 ilustra la distribución muestral adecuada.

El error estándar es $\sigma/\sqrt{n} = 15/\sqrt{100} = 1.5$, que da como resultado un valor Z de $Z = (\bar{X} - \mu)/(\sigma/\sqrt{n}) = 2/1.5 = 1.33$ y una área de la tabla de la curva normal de .4082. Al duplicar esta área para contabilizar ambos lados de la media, da como resultado una área total de .8164. Las probabilidades son del 82% de que la media de la muestra estará dentro de 2 libras de la media verdadera, dado el tamaño de la muestra de 100 y la variabilidad estimada de la población, $\sigma = 15$. Como se verá, esta destreza al calcular las probabilidades de los resultados de una muestra facilitará a un analista hacer inferencias acerca de la población de la muestra, con aplicabilidad directa a la realización de pronósticos.




FIGURA 2-9 Áreas de distribución muestral para el ejemplo 2.5

Para tamaños de muestra pequeños, quizá las medias muestrales no estén normalmente distribuidas. Sin embargo, si la población de la cual se selecciona la muestra es esencialmente normal y la desviación estándar de la población se estima con la desviación estándar de la muestra S , se conoce la distribución muestral de la relación

$$t = \frac{\bar{X} - \mu}{S/\sqrt{n}} \quad (2.7)$$

También llamada *distribución t de Student* (o simplemente *distribución t*) con $n - 1$ grados de libertad (que se abrevian gl). La distribución t está centrada en 0 y tiene una forma de campana, pero con colas más gruesas que en una distribución normal. Sin embargo, conforme se incrementa el número de grados de libertad (y de forma equivalente, el tamaño de la muestra n), la distribución t parece cada vez más una distribución normal con una media de 0 y una desviación estándar de 1.

La tabla B-3 (en el Apéndice B) presenta valores tomados de la distribución t . Observe que sólo se requiere especificar un valor antes de remitirse a la tabla; a saber, los grados de libertad. Una vez que se conocen los grados de libertad, se pueden obtener los valores t que excluyen porcentajes deseados del área bajo la curva. Por ejemplo, si la distribución t de interés tiene 12 grados de libertad, entonces un valor t de 2.179 en cada lado del 0 incluirá el 95% del área bajo la curva y excluirá el 5% de ella, es decir, 2.5% en cada cola.

Ejemplo 2.6 Uso de la distribución t

El gerente de una compañía de tarjetas de crédito afirma que el tiempo medio para resolver una queja de los clientes es de 30 días. Para probar tal aseveración, se recopilaron datos de una muestra de 15 quejas, las cuales tuvieron un tiempo medio para resolverse de 35.9 días y una desviación estándar de 10.2 días.

Si los datos se consideran como una muestra aleatoria de una población normal, ¿arrojan sospechas sobre la afirmación del gerente?

Si la afirmación del gerente es correcta, la media de la población es $\mu = 30$ y la variable aleatoria

$$t = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

tiene una distribución t de Student con $n - 1 = 15 - 1 = 14$ grados de libertad. La afirmación del gerente será sospechosa, si el valor de esta variable es demasiado grande o demasiado pequeño, porque esto ocurre cuando el valor de $\bar{X}$ está lejos de μ . Consultando la tabla B-3 para 14 grados de libertad, vemos que $t_{.025} = 2.145$. Antes de obtener la muestra, la probabilidad de que t excederá 2.145 es .025. Asimismo, la probabilidad de que t será menor que -2.145 es de .025. Sumando estas dos probabilidades iguales, la probabilidad es $.025 + .025 = .5$ de que t será más grande

que 2.145 o menor que -2.145 . Ahora estamos listos para determinar si el valor de $\bar{X}$, 35.9, está lejos de μ , 30. El valor observado de t es

$$t = \frac{35.9 - 30}{10.2/\sqrt{15}} = 2.240$$

el cual excede $t_{.025} = 2.145$. En vez de aceptar la explicación de que ocurrió un evento con escasa probabilidad, cuestionamos la afirmación de que la media sea de 30 días. Un valor más grande para la media sería más consistente con los datos.

INFERENCIA DE UNA MUESTRA

Estimación

Cuando no es viable o incluso es imposible medir la población total de interés, se selecciona una muestra de la población y se utiliza para aprender acerca de la población. Este aprendizaje (llamado *inferencia*) por lo común toma dos formas. La primera de estas se denomina *estimación*, donde los resultados de la muestra se usan para estimar una característica desconocida de la población. Si bien la estimación es el término estadístico común para dicha tarea, también podría llamarse pronóstico en muchas situaciones de negocios, porque la muestra consiste en observaciones históricas recopiladas y se requiere un valor (estimado o pronosticado) para una observación futura. La segunda forma de aprendizaje acerca de la población a partir de una muestra se llama *prueba de hipótesis* y se estudiará en la siguiente sección.

Una *estimación puntual* (un pronóstico) de una cantidad de la población, como la media poblacional, es un solo valor calculado a partir de los datos de la muestra, y estima el valor de la cantidad desconocida de una población. En estadística, una cantidad de la población se conoce como *parámetro* de ésta. Una estimación puntual es la “mejor suposición” de un parámetro de la población calculada a partir de la muestra. Con frecuencia, la mejor suposición de un parámetro de la población lo proporciona la cantidad correspondiente de la muestra. Por ejemplo, la mejor suposición del valor de la media de la población está dada por el valor de la media de la muestra. La tabla 2-2 contiene tres parámetros de la población y los estadísticos muestrales que dieron estimaciones puntuales de aquéllos.

Un *intervalo de estimación* es un intervalo dentro del cual es probable que esté el parámetro de la población de interés. Se obtiene construyendo un intervalo alrededor de la estimación puntual:

$$\text{Estimación puntual} = \pm \text{múltiplo} \times (\text{desviación estándar estimada de la estimación puntual}) \quad (2.8)$$

donde el “múltiplo” es a menudo un punto porcentual de la distribución normal o un punto porcentual de la distribución t . Se prefiere un intervalo de estimación por encima de la estimación puntual, ya que aquélla toma en cuenta la incertidumbre asociada con una estimación.

Idealmente, nos gustaría obtener una muestra y luego determinar un intervalo que, por ejemplo, contuviera en definitiva la media de la población, μ . Sin embargo, debido a la variabilidad de una muestra a otra, tal objetivo es inalcanzable. En vez de eso, especificamos una alta probabilidad —digamos, .95 o .99— de que un intervalo propuesto cubrirá el valor verdadero del parámetro de la población de interés. Como esta probabilidad pertenece al intervalo antes de que se observe la muestra, se denomina el *nivel de confianza*. Un intervalo obtenido mediante un procedimiento que satisfaga el requisito de probabilidad se llama *intervalo de confianza*. La cantidad a la derecha del signo $\pm$ en la ecuación 2.8 se conoce a menudo como el *error permitido*, y su magnitud dependerá directamente del nivel de confianza (a través de un múltiplo) y la información en la muestra (a través de la desviación estándar estimada de la estimación puntual).

Una *estimación puntual* es un solo valor estimado de un parámetro de la población. Un *intervalo de estimación* es un intervalo dentro del cual es probable que esté el parámetro de la población.

Ejemplo 2.7 Cálculo de estimaciones puntual y de intervalos de estimación

Se elige una muestra aleatoria de 500 compradores en el Centro Comercial Northgate, para determinar la distancia promedio que recorrieron para llegar al centro comercial. Un análisis de los resultados de la muestra revela que $\bar{X} = 23.5$ millas y $S = 10.4$ millas.

La estimación puntual para la distancia media desconocida de la población, para todos los compradores del centro comercial, es de 23.5 millas, la media de la muestra.

La desviación estándar estimada de $\bar{X}$ es $S/\sqrt{n}$ y para muestras aleatorias grandes (digamos, $n > 30$), el múltiplo en la construcción de un intervalo de confianza (véase la ecuación 2.8) para la media de la población, μ , es Z , un punto porcentual normal estándar. Por lo tanto, un intervalo de estimación para μ es

$$\bar{X} \pm Z \frac{S}{\sqrt{n}} \quad (2.9)$$

Si establecemos el nivel de confianza en 95%, entonces $Z = 1.96$, el punto más alto .025 (2.5%) de un distribución normal estándar (véase nota al pie 2). Usando la ecuación 2.9 con nuestros resultados de la muestra, se produce el intervalo

$$\begin{aligned} 23.5 \pm 1.96 \frac{10.4}{\sqrt{500}} \\ 23.5 \pm 1.96(.465) \\ 23.5 \pm .91 : (22.6, 24.4) \end{aligned}$$

Así, se dice, con 95% de confianza, que el número medio de millas recorridas para llegar al centro comercial, por la población de compradores, está en algún punto entre 22.6 millas y 24.4 millas. El 95% de confianza se refiere al hecho de que si, digamos, se seleccionaran 100 muestras de tamaño de 500, se calculara la media y la desviación estándar de cada muestra y se construyeran intervalos de estimación, 95 de 100 de los intervalos contendrían, en efecto, la media real de la población. Por lo tanto, es altamente probable que el intervalo específico construido arriba contenga la media de la población en millas viajadas al centro comercial.

Si el tamaño de la muestra hubiera sido pequeño, quizá $n = 20$, entonces, un intervalo de confianza de 95% para μ podría construirse con la ecuación 2.9, usando un punto porcentual t con 19 gl en vez de Z . Puesto que el punto más alto .025 (2.5%) de una distribución t con 19 gl es $t_{.025} = 2.093$ y $S/\sqrt{n} = 10.4/\sqrt{20} = 2.326$, el intervalo de confianza de 95% de la muestra pequeña será considerablemente más amplio, que el intervalo con la muestra grande calculado arriba. Esto es razonable porque hay más incertidumbre asociada con una muestra pequeña. Note que para muestras pequeñas, también hacemos la suposición adicional de que las millas viajadas están distribuidas aproximadamente normal.

Prueba de hipótesis

En muchas situaciones de inferencia, incluyendo la elaboración de pronósticos, el interés está en probar alguna clase de afirmación acerca de la población, en vez de la estimación o el pronóstico de uno de sus parámetros. Este procedimiento se llama *prueba de hipótesis* y es la segunda forma principal de examinar evidencia de la muestra. La prueba de hipótesis implica los siguientes pasos:

- Paso 1.** Formule la hipótesis que se va a probar (llamada hipótesis nula, representada con H_0) y la definición de la hipótesis alternativa (la que se acepta si H_0 se rechaza, representada con H_1).
- Paso 2.** Obtenga una muestra aleatoria de elementos de la población, mídalos y calcule el estadístico de prueba adecuado de la muestra.

TABLA 2-5 Resultados de una prueba de hipótesis

		Acción	
		No rechace H_0	Rechace H_0
Condición natural	H_0 verdadera	Decisión correcta	Error tipo I: probabilidad α
	H_0 falsa	Error tipo II: probabilidad β	Decisión correcta

Paso 3. Suponga que la hipótesis nula es verdadera, y determine la distribución de muestral, del estadístico de prueba.

Paso 4. Calcule la probabilidad de que un valor del estadístico de prueba, por lo menos tan grande como el observado, se hubiera extraído de esta distribución muestral.

Paso 5. Si esta probabilidad es alta, no rechace la hipótesis nula; si esta probabilidad es baja, se desacredita la hipótesis nula y puede rechazarse con poco margen de error.

Cuando se siguen estos pasos, es posible que haya dos tipos de error, como se indica en la tabla 2-5. Se espera que se tome la decisión correcta con respecto a la hipótesis nula, después de examinar la evidencia de la muestra; no obstante, siempre hay una posibilidad de rechazar una H_0 verdadera y fallar en rechazar una H_0 falsa. Las probabilidades de dichos eventos se conocen como alfa (β) y beta (σ), respectivamente. Alfa también se conoce como *nivel de significancia* de la prueba.

Ejemplo 2.8 Construcción de una prueba de hipótesis

El supervisor de un taller cree que disminuyó el peso medio de las piezas producidas por cierta máquina. Se desea probar la hipótesis de que el peso medio de las piezas producidas por la máquina es todavía de 50 libras, es decir, el peso medio de las piezas en años pasados. Se toma una muestra aleatoria de 100 piezas. Se supone que la desviación estándar de los pesos de las piezas es de 5 libras, sin importar el peso medio, ya que este valor ha permanecido constante en estudios anteriores de las piezas. Usaremos la media de la muestra, como nuestro estadístico de prueba y tomaremos como hipótesis nula el *statu quo*; es decir, el peso medio de la pieza, μ , es de 50 libras. Por lo tanto, si la hipótesis nula H_0 es verdadera, el teorema central del límite indica que la distribución muestral de $\bar{X}$ es, en este caso, normal con media $\mu = 50$ y desviación estándar $\sigma/\sqrt{n} = 5/\sqrt{100} = .5$. Un valor de la media de la muestra, $\bar{X}$, cercano o mayor que 50 apoya la H_0 ; un valor de $\bar{X}$ muy por debajo de 50 es evidencia contra la H_0 , puesto que tal evento es improbable si H_0 es verdadera. Entonces, una regla de decisión sensible es aquella que rechaza H_0 para un valor de $\bar{X}$ muy por debajo de 50. Sin embargo, con esta regla, es probable que cometamos un error tipo I, es decir, que rechacemos una H_0 verdadera. Podemos controlar la probabilidad de rechazar una H_0 verdadera cuando seleccionamos α , el nivel de significancia. Suponga que hacemos a α pequeña —digamos .05 (5%). Entonces, rechazaremos H_0 si el valor observado de nuestro estadístico de prueba, $\bar{X}$, cae más allá del punto más bajo 0.05 (5%) de su distribución muestral de la H_0 . La prueba se muestra en la figura 2-10.

La regla de decisión para esta prueba es como sigue:

$$\text{Si } \bar{X} < 49.18, \text{ rechace la hipótesis nula } H_0: \mu = 50$$

Suponga que la media de la muestra resulta ser de 49.6 libras. Entonces, podríamos no rechazar H_0 al nivel de 5%. Por otro lado, si el peso medio de la muestra resultara ser de 48.6 libras, rechazaríamos H_0 . Note que para $\bar{X} = 48.6$, la probabilidad de obtener un valor en este extremo (muy por debajo de 50), si H_0 es verdadera, es $P(\bar{X} < 48.6) = P(Z < \frac{48.6 - 50}{.5}) = P(Z < -28) = P(Z > 2.8) = (.5000 - .4974) = .0026$ lo cual es, desde luego, un evento improbable.

En la prueba de hipótesis, siempre existe alguna ambigüedad asociada con la selección de las hipótesis nula y alternativa. En general, la hipótesis nula es el *estatus quo* (condición actual) o hipótesis “sin cambio”. La hipótesis alternativa es la hipótesis de investigación o de cambio.

$H_0: \mu = 50$ libras, (la hipótesis nula)

$H_1: \mu < 50$ libras (la hipótesis alternativa)




FIGURA 2-10 Prueba de hipótesis para el ejemplo 2.8

Para descubrir si lo que hemos hecho marcó una diferencia o resultó en un cambio del *estatus quo* o de los procedimientos actuales, formulamos la diferencia o el cambio como la hipótesis alternativa. El objetivo es ver si podemos rechazar la hipótesis nula, con una probabilidad pequeña de un error tipo I, a favor de la alternativa.

La prueba de hipótesis que se describe en el ejemplo 2-8 se conoce como prueba *unilateral*. Se sigue esta terminología porque, en este ejemplo, la hipótesis alternativa especifica valores de los parámetros de la población, a un lado del valor especificado en la hipótesis nula. Las pruebas para las cuales la hipótesis alternativa especifica valores tanto más grandes como más pequeños, que el valor con la hipótesis nula, se llaman pruebas *bilaterales*. En este caso, valores del estadístico de prueba mucho más grandes o mucho más pequeños que el valor del parámetro de la población, con H_0 , conducen al rechazo.

Valor p

En el ejemplo 2-8, calculamos la probabilidad de obtener un valor de la media de la muestra tan extremo como $\bar{X} = 48.6$ si la hipótesis nula $H_0: \mu = 50$ es verdadera. La probabilidad encontrada fue de .0026. Esta probabilidad se llama *valor de prueba* o simplemente *valor p* de la prueba. En vez de seleccionar un nivel de significancia, ahora es práctica común calcular e informar el valor p para la prueba; de hecho, los paquetes de software estadístico en general reportan los valores p asociados con estadísticos de prueba. En efecto, los valores p y su uso en pruebas de hipótesis se analizan en los pasos 4 y 5 de nuestro procedimiento de prueba de hipótesis, al inicio de esta sección. Un valor p pequeño significa un fuerte rechazo de la hipótesis nula. El valor p puede considerarse como evidencia a favor (un valor p grande) o en contra (un valor p pequeño) de la hipótesis nula. Los puntos límite comunes para valores p pequeños son .05 y .01.

Usando la información del ejemplo 2.8, si se realiza una prueba bilateral, $H_0: \mu = 50$ contra $H_1: \mu \neq 50$, y $\bar{X} = 48.6$, el valor p sería $P(\bar{X} < 48.6 \text{ o } \bar{X} > 51.4) = 2P(Z > \frac{51.4 - 50}{.5})$, o dos veces el área bajo la curva normal estándar a la derecha de $Z = 2.8$. En este ejemplo, el valor p es igual a $2(0.0026) = 0.0052$.

El valor p o *probabilidad de significancia* es la probabilidad de obtener, al menos, un resultado de la muestra tan extremo como el realmente observado, si H_0 fuera verdadera. De forma equivalente, el valor p puede considerarse como la α más pequeña, para la cual el estadístico de prueba observado conduce al rechazo de H_0 .

Ejemplo 2.9 Cálculo de un valor p

Suponga que se desea probar la hipótesis de que la puntuación media de estudiantes en un examen nacional es de 500, contra la hipótesis alternativa de que es menor de 500. Se toma una muestra aleatoria de 15 estudiantes de la población que produce una puntuación media de la muestra de $\bar{X} = 475$. La desviación estándar de la población se estima con la desviación estándar de la muestra, $S = 35$. Suponga que la población de las puntuaciones de los exámenes se distribuye normalmente.

Queremos saber si los puntajes promedio de la prueba son menores que su valor histórico de 500. Tomaremos una decisión con base en la evidencia de la muestra y, en particular, del valor de la media de la muestra. Las hipótesis en competencia son

$$H_0: \mu = 500$$

$$H_1: \mu < 500$$

Si H_0 fuera verdadera, esperaríamos ver un valor del promedio de la muestra cercano a 500 o mayor. Si H_0 fuera falsa (H_1 es verdadera), esperaríamos ver un valor del promedio de la muestra bastante menor de 500. Puesto que el tamaño de la muestra es pequeño, la población es normal y la desviación estándar de la población se estima con la desviación estándar de la muestra, un estadístico de prueba adecuado es el estadístico t dado en la ecuación 2.7, con $n - 1 = 15 - 1 = 14$ gl. Un valor negativo grande del estadístico t es evidencia contra H_0 (que indica que el promedio de la muestra es mucho menor que el promedio hipotético de la población de 500). Primero, realicemos la prueba para un nivel de significancia de $\alpha = .05$. La prueba (regla de decisión) se ilustra en la figura 2-11.




FIGURA 2-11 Prueba de hipótesis para el ejemplo 2.9

Puesto que la regla de decisión es como sigue:

Si observó que $t < -1.76$, rechace H_0 ; $\mu = 500$

y el estadístico t observado es:

$$t = \frac{\bar{X} - \mu}{S/\sqrt{n}} = \frac{475 - 500}{35/\sqrt{15}} = -2.77$$

rechazaríamos la hipótesis nula y concluiríamos que la puntuación media de la prueba de estudiantes en el examen nacional es menor de 500. El *valor p* en este caso es $P(t < -2.77)$. Usando la tabla B-3 con 14 gl y la simetría de la distribución t , esto probablemente esté entre .010 y .005. Nuestro estadístico de prueba observado es muy improbable si H_0 es verdadera. El *valor p* nos indica que deberíamos rechazar la hipótesis nula.

ANÁLISIS DE CORRELACIÓN

En la construcción de modelos estadísticos para realizar pronósticos, a menudo es útil examinar la relación entre dos variables. Dos técnicas, el análisis de correlación y el análisis de regresión, se estudian aquí. Además, en capítulos posteriores se consideran casos especiales de correlación y de regresión. Este énfasis en la correlación y en la regresión se justifica en vista del uso generalizado de dichas técnicas, en todas las clases de aplicaciones para la elaboración de pronósticos.

Diagramas de dispersión

Un estudio de la relación entre variables inicia con el caso más sencillo: el de la relación existente entre dos variables. Suponga que se toman dos mediciones en cada uno de varios objetos. Un analista quiere determinar si una de estas variables medibles, llamada Y , tiende a aumentar o a disminuir cuando la otra variable, llamada X , cambia. Por ejemplo, suponga que se miden tanto la edad como el ingreso de varios individuos, como se indica en la tabla 2-6. ¿Qué se puede decir acerca de la relación entre X y Y ?

En la tabla 2-6, se observa que Y y X tienen una relación evidente. Conforme X aumenta, Y tiende a incrementarse. De esta muestra de cinco individuos, parece que cuanto más vieja se vuelve una persona, más dinero ganará esa persona. Por supuesto, es peligroso llegar a conclusiones sobre la base de una muestra pequeña, un tema que se estudiará más tarde. Incluso con estas observaciones, parece existir una relación evidente entre Y y X .

Estos cinco puntos de datos pueden graficarse sobre una escala bidimensional, con valores de X a lo largo del eje horizontal y valores de Y a lo largo del eje vertical. Una gráfica como ésta se llama *diagrama de dispersión* y se ilustra en la figura 2-12.

TABLA 2-6 Mediciones de ingreso y edad

<i>Persona</i>	<i>Ingreso (en miles) Y</i>	<i>Edad (años) X</i>
1	27.8	22
2	28.5	23
3	30.0	26
4	35.0	27
5	36.4	35




FIGURA 2-12 Diagrama de dispersión para edad e ingreso

Un *diagrama de dispersión* es una gráfica de puntos de datos X - Y en un sistema de coordenadas bidimensional.

El diagrama de dispersión ayuda a ilustrar lo que la intuición sugiere cuando se observan a primera vista los datos; a saber: la evidencia de una relación lineal entre Y y X . Esta relación se llama una relación lineal *positiva*, porque conforme X se incrementa, lo hace también Y .

En otras situaciones donde intervienen dos variables, quizá surjan diferentes patrones en el diagrama de dispersión. Considere los diagramas de la figura 2-13.

La figura 2-13(a) sugiere lo que se llama una *relación lineal positiva perfecta*. Conforme X se incrementa, Y aumenta también, y de una forma perfectamente predecible. Es decir, los puntos de datos X y Y parecen formar una línea recta. La figura 2-13(b) sugiere una *relación lineal negativa perfecta*. Conforme X se incrementa, Y disminuye de un modo perfectamente predecible.

Las figuras 2-13(c) y (d) ilustran una *relación lineal imperfecta, positiva y negativa*, respectivamente. Conforme X se incrementa en estos diagramas de dispersión, Y se incrementa (parte c) o disminuye (parte d), aunque no lo hace de un modo perfectamente predecible. Así, Y podría estar ligeramente más arriba o más abajo de “lo esperado”. Es decir, los puntos X - Y no forman una línea recta.

Los diagramas de dispersión en las figuras 2-13(a) a d) ilustran *relaciones lineales*. La relación X - Y , sea perfecta o imperfecta, puede resumirse con una línea recta. En cambio, en la figura 2-13(e) aparece una *relación curva*.

Finalmente, la figura 2-13(f) sugiere que no hay relación de ninguna clase entre las variables X y Y . Conforme X se incrementa, Y no parece aumentar ni disminuir de algún modo predecible. Sobre la base de la evidencia de la muestra que se indica en la figura 2-13(f), podría concluirse que en el mundo que contiene todos los puntos de datos X - Y , no existe relación alguna, ni lineales ni de otra clase, entre las variables X y Y .




FIGURA 2-13 Patrones para puntos de datos X - Y




FIGURA 2-14 Asociación lineal fuerte y débil para puntos de datos X - Y

Considere ahora los dos diagramas de dispersión en la figura 2-14. Ambos diagramas de dispersión sugieren relaciones lineales positivas imperfectas entre Y y X . La figura 2-14(a) ilustra una relación fuerte porque los puntos de datos están bastante cerca de la línea recta que pasa a través de ellos. En la figura 2-14(b), los puntos de datos están más lejos de la recta que pasa a través de ellos, sugiriendo así una relación lineal más débil. Más adelante en este capítulo, mostraremos cómo medir la fortaleza de la relación que existe entre dos variables.

Como sugieren los dos diagramas de dispersión de la figura 2-14, a menudo es deseable resumir la relación entre dos variables ajustando una recta a través de los puntos de datos. Usted aprenderá cómo se hace esto en breve; por el momento, piense que una línea recta puede ajustarse a los puntos de un diagrama de dispersión, de modo que resulte un “buen ajuste”. Una pregunta de interés para la elaboración del pronóstico es ¿qué tan rápido se sube o baja la línea recta?

La respuesta a esta cuestión requiere del cálculo de la pendiente de la línea. La pendiente de cualquier recta se define como el cambio de Y asociado con una unidad de incremento en X .

Para resumir, cuando se estudia una relación entre dos variables, uno debe saber primero si la relación es lineal (ilustrada con una línea recta) o no lineal. Si es lineal, uno necesita saber si la relación es positiva o negativa, y qué tan abruptamente sube o desciende la recta que ajusta los puntos de datos. Por último, uno necesita conocer la fortaleza de la relación, es decir, qué tan cerca están los puntos de datos de la línea que mejor se ajusta a ellos.

Coeficiente de correlación

La fortaleza de la relación lineal que existe entre dos variables se mide usando la *correlación* que existe entre ellas. El *coeficiente de correlación* mide la fortaleza de la siguiente manera. Dos variables con una relación negativa perfecta tienen un coeficiente de correlación igual a -1 . En el otro extremo, dos variables con una relación positiva perfecta tienen un coeficiente de correlación igual a 1 . De esta manera, el coeficiente de correlación varía de -1 a 1 inclusive, dependiendo de la cantidad de asociación entre las dos variables que se estén midiendo.

El *coeficiente de correlación* mide el grado en que dos variables están linealmente relacionadas entre sí.

El diagrama de dispersión en la figura 2-13(a) ilustra una situación que produce un coeficiente de correlación de 1 . El diagrama de dispersión en la figura 2-13(b) tiene un coeficiente de correlación de -1 . Las figuras 2-13(e) y (f) ilustran dos variables que no están linealmente relacionadas. Los coeficientes de correlación para estas relaciones son iguales a 0 ; es decir, se presenta una relación no lineal.

Los pronosticadores se interesan tanto en la población como en los datos muestreados. En la *población* que contiene todos los puntos de datos X - Y de interés, hay un coeficiente de correlación cuyo símbolo es ρ , la letra griega ρ . Si se extrae una muestra aleatoria de estos puntos de datos X - Y , el coeficiente de correlación para tales datos de muestra se denota con la letra r .

Frecuentemente, X - Y se miden en unidades diferentes, como libras y dólares, unidades vendidas y dólares en ventas, o tasa de desempleo y dólares del PIB. A pesar de tales unidades diferentes para X - Y , es todavía importante medir el grado en que X y Y están relacionadas. Estas mediciones se realizan convirtiendo primero las variables X y Y a unidades estándar o valores de Z .

Después de que las mediciones X - Y se han convertido en Z como número de varianza, se multiplican estos valores Z para cada medida X - Y , lo que da como resultado productos cruzados para cada caso. Estos productos cruzados son de interés porque la media de estos valores es el coeficiente de correlación. El cálculo del coeficiente de correlación (esencialmente) como el producto cruzado medio de Z producirá el valor correcto; pero en la mayoría de los casos, el coeficiente de correlación se calcula directamente a partir de los valores X - Y . La ecuación 2-10 muestra cómo se calcula el coeficiente de correlación de la muestra, r , a partir de Z como número de varianza y de las mediciones X - Y . Aquí $Z_x = (X - \bar{X})/S_x$ y $Z_y = (Y - \bar{Y})/S_y$.

$$\begin{aligned} r &= \frac{1}{n-1} \sum Z_x Z_y = \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\sqrt{\sum (X - \bar{X})^2} \sqrt{\sum (Y - \bar{Y})^2}} \\ &= \frac{n \sum XY - (\sum X)(\sum Y)}{\sqrt{n \sum X^2 - (\sum X)^2} \sqrt{n \sum Y^2 - (\sum Y)^2}} \end{aligned} \quad (2.10)$$

Una tabla como la 2-7 facilita el cálculo de r .

Ejemplo 2.10 Cálculo del coeficiente de correlación de una muestra

Si se estudia la relación entre la edad y el ingreso, sería de interés conocer el valor de r para estos datos. Los cálculos requeridos se presentan en la tabla 2-7. Los totales de la tabla 2-7 se sustituyen en la ecuación 2.10, con lo cual se obtiene:

$$\begin{aligned} r &= \frac{n \sum XY - \sum X \sum Y}{\sqrt{n \sum X^2 - (\sum X)^2} \sqrt{n \sum Y^2 - (\sum Y)^2}} \\ &= \frac{5(4,266.1) - (133)(157.7)}{\sqrt{5(3,643) - (133)^2} \sqrt{5(5,035.05) - (157.7)^2}} \\ &= \frac{21,330.5 - 20,974.1}{\sqrt{526} \sqrt{305.96}} = \frac{356.4}{(22.93)(17.49)} = .89 \end{aligned}$$

Se observa que el coeficiente de correlación de la muestra confirma lo que se ilustró en la figura 2-12. El valor de r es positivo, lo cual sugiere una relación lineal positiva entre la edad y el ingreso. También, en una escala de 0 a 1, el valor de r es bastante alto (0.89). Este resultado sugiere una relación lineal fuerte en vez de una débil. La pregunta restante es si la combinación del tamaño de la muestra y el coeficiente de correlación es lo suficientemente fuerte para hacer afirmaciones significativas acerca de la población, de la cual se extrajeron los valores de los datos.

Ahora deberían hacerse dos observaciones importantes acerca de la correlación. Primero, siempre debe tenerse en mente que se mide la *correlación*, no la *causalidad*. Puede ser perfectamente válido decir que dos variables están relacionadas sobre la base de un coeficiente de

TABLA 2-7 Cálculos para la correlación entre edad e ingreso del ejemplo 2.10

Persona	Y	X	Y ²	X ²	XY
1	27.8	22	772.84	484	611.6
2	28.5	23	812.25	529	655.5
3	30.0	26	900.00	676	780.0
4	35.0	27	1,225.00	729	945.0
5	36.4	35	1,324.96	1,225	1,274.0
Totales	157.7	133	5,035.05	3,643	4,266.1

correlación alto. Quizá sea válido o no decir que una variable es causante del cambio en la otra; esto es una cuestión para el juicio del analista. Por ejemplo, puede ser verdad que el volumen de ventas de una tienda local, en una área escasamente poblada, está altamente correlacionado con el precio de mercado promedio de las acciones en Nueva York. Después de examinar una muestra grande de estas dos variables, podría concluirse que existe esa correlación alta. Probablemente no sea verdad que una de tales variables esté causando el cambio en la otra. De hecho, los cambios de ambas variables quizá sean causados por un tercer factor, el estado general de la economía. Los políticos, los anunciantes y otros a menudo cometen el error de suponer una causa con base en la correlación.

Segundo, advierta que el coeficiente de correlación mide una relación *lineal* entre dos variables. En el caso en que el coeficiente de correlación es bajo, se concluiría que las dos variables no están estrechamente relacionadas de forma lineal. Tal vez estén estrechamente relacionadas de un modo no lineal o curvado. Así, un coeficiente de correlación bajo no significa que las dos variables no estén relacionadas, solo que parece que no existe una relación lineal o en línea recta.

AJUSTE DE UNA LÍNEA RECTA

Como se mencionó antes, con frecuencia es de interés ajustar una línea recta a través de un conjunto de puntos de datos X - Y , de manera tal que resulte un “buen ajuste”. Como se mostrará en los capítulos posteriores, esa línea bien ajustada puede usarse para pronosticar valores desconocidos de Y , la variable de interés.

En la práctica, se usa un procedimiento matemático bien definido para calcular tanto la intersección con el eje Y (ordenada al origen), como la pendiente de la línea recta mejor ajustada. El enfoque más común para determinar esa línea mejor ajustada se llama *método de los mínimos cuadrados*. Con este procedimiento, se construye una línea que minimiza la suma de los cuadrados de las distancias entre los puntos de datos y la recta, medidos en la dirección (Y) vertical.

El método de los mínimos cuadrados selecciona los valores de la pendiente y de la intersección con el eje Y que minimizan la suma de errores al cuadrado (distancias), SSE , entre los valores de Y y la recta.

$$SSE = \sum (Y - \hat{Y})^2 = \sum (Y - b_0 - b_1 X)^2 \quad (2.11)$$

donde $\hat{Y} = b_0 + b_1 X$ es el valor estimado de Y , sobre la recta ajustada.

Usando el cálculo, se pueden derivar expresiones algebraicas específicas para los valores de los mínimos cuadrados. Particularmente:

$$b_1 = \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\sum (X - \bar{X})^2} = \frac{n \sum XY - \sum X \sum Y}{n \sum X^2 - (\sum X)^2} \quad (2.12)$$


$$b_0 = \bar{Y} - b_1 \bar{X} = \frac{\sum Y}{n} - \frac{b_1 \sum X}{n} \quad (2.13)$$

donde

b_1 = la pendiente de la recta

b_0 = la intersección con el eje Y

El *método de los mínimos cuadrados* se utiliza para calcular la ecuación de una recta, que minimiza la suma de las distancias al cuadrado entre los puntos de datos X - Y y la recta, medidos en la dirección vertical (Y).

**FIGURA 2-15** Recta ajustada del ejemplo 2-11**Ejemplo 2.11 Cálculo de una recta ajustada usando el método de los mínimos cuadrados**

El ejemplo 2-10 sugiere una relación lineal positiva fuerte entre edad e ingreso. Sustituyendo los totales de la tabla 2-7 en las ecuaciones 2.12 y 2.13, la ecuación de una recta que mejor se ajuste a los puntos se calcula como:

$$b_1 = \frac{n\sum XY - \sum X\sum Y}{n\sum X^2 - (\sum X)^2} = \frac{5(4,266.1) - (133)(157.7)}{5(3,643) - (133)^2} = \frac{356.4}{526} = .678$$

$$b_0 = \frac{\sum Y}{n} - \frac{b_1\sum X}{n} = \frac{157.7}{5} - \frac{(.678)(133)}{5} = 31.540 - 18.035 = 13.505$$

La recta que mejor se ajusta a los datos, $\hat{Y} = 13.505 + .678 X$, se ilustra en la figura 2-15.

La ecuación calculada en el ejemplo 2-11, junto con otros valores que pueden calcularse a partir de los datos de la muestra, es de enorme utilidad para los gerentes en el pronóstico de valores futuros de una variable importante, y en la evaluación anticipada de qué tan precisos serían tales pronósticos. En un capítulo posterior, usted aprenderá cómo extraer gran parte de información a partir de los datos de la muestra, y cómo usarla para hacer pronósticos con el análisis de regresión.

El coeficiente de la pendiente de cuadrados mínimos está relacionado con el coeficiente de correlación de la muestra. Específicamente:

$$b_1 = \frac{\sqrt{\sum (Y - \bar{Y})^2}}{\sqrt{\sum (X - \bar{X})^2}} r \quad (2.14)$$

Como resultado, b_1 y r son proporcionales entre sí y tienen el mismo signo.

Ejemplo 2.12 Demostración de la relación entre el coeficiente de correlación y el coeficiente de la pendiente

Usando los resultados de la tabla 2-7 y los ejemplos 2-10 y 2-11, verificamos numéricamente la ecuación 2.14. Usando la ecuación 2.14, tenemos

$$b_1 = \frac{\sqrt{\Sigma(Y - \bar{Y})^2}}{\sqrt{\Sigma(X - \bar{X})^2}} r = \frac{\sqrt{61.192}}{\sqrt{105.2}} .89 = (.763)(.89) = .679$$

Este valor, considerando el error por redondeo, coincide con el valor del coeficiente de la pendiente calculado directamente en el ejemplo 2.11, usando la ecuación 2.12.

Ejemplo 2.13

Suponga que el director general de una empresa constructora grande sospecha que los gastos estimados de los proyectos de construcción de su compañía no están muy cercanos de los gastos reales al final del proyecto. Los datos que se presentan en la tabla 2-8 se recopilieron de unos cuantos proyectos anteriores, para analizar la relación entre los costos estimados y los costos reales. Puesto que tiene a su disposición Minitab, se analizan los datos usando este programa.

La figura 2-16 ilustra que la correlación entre los costos de construcción estimados y reales, con base en los datos de la muestra, es $r = .912$. El director general de la compañía está sorprendido por saber que éste sea alto.

La figura 2-17 presenta los datos graficados como un diagrama de dispersión y la recta que mejor se ajusta a estos datos: $\hat{Y} = .683 + .922X$. El director general puede ahora pronosticar el costo de construcción real (Y), después de que se preparó el estimado para el proyecto (X).

TABLA 2-8 Costos estimados y reales del proyecto de construcción del ejemplo 2.13

<i>Renglón</i>	<i>Actual</i>	<i>Estimado</i>
1	0.918	0.575
2	7.214	6.127
3	14.577	11.215
4	30.028	28.195
5	38.173	30.100
6	15.320	21.091
7	14.837	8.659
8	51.284	40.630
9	34.100	37.800
10	2.003	1.803
11	20.099	18.048
12	4.324	8.102
13	10.523	10.730
14	13.371	8.947
15	1.553	3.157
16	4.069	3.540
17	27.973	37.400
18	7.642	7.650
19	3.692	13.700
20	29.522	29.003
21	15.317	14.639
22	5.292	5.292
23	0.707	0.960
24	1.246	1.240
25	1.143	1.419
26	21.571	38.936

Correlations: ActualCost, EstimatedCost

Pearson correlation of ActualCost and EstimatedCost = 0.912

Regression Analysis: ActualCost versus EstimatedCost

The regression equation is

ActualCost = 0.683 + 0.9223 EstimatedCost

FIGURA 2-16 Resultado de Minitab para el ejemplo 2.13




FIGURA 2-17 Gráfica de la línea ajustada del ejemplo 2.13

EVALUACIÓN DE LA NORMALIDAD

Muchas técnicas estadísticas, incluyendo algunas de las que se usan en la elaboración de pronósticos, requieren la suposición de que un conjunto de datos sigue una distribución normal. Por tal motivo, se han desarrollado técnicas estadísticas que prueban la hipótesis de que un conjunto de datos muestrales fue extraído de una población normalmente distribuida.

Considere las tasas de rendimiento mensual del índice bursátil Standard & Poor's 500, mostradas en la tabla 2-9. ¿Se puede suponer que estos datos siguen una distribución normal? La respuesta, obtenida con Minitab, está contenida en la figura 2-18.

La recta trazada en la figura 2-18 muestra qué puntos de una curva normal perfecta se verían como si se hubieran graficado usando esta escala especial.⁴ Como se indica, los datos de la tabla 2-9 están muy cerca de esta línea, lo cual sugiere un buen ajuste entre los datos de S&P y una distribución normal.

⁴Están disponibles otras gráficas de probabilidad normal. Una de ellas, llamada *gráfica de puntuaciones normal*, se usa frecuentemente. En todas estas gráficas, normalmente se indica si los datos graficados están cerca de una recta.

TABLA 2-9 Tasas mensuales de rendimiento (%) del índice Standard & Poor's 500

	Año			
	1	2	3	4
Ene.	—	6.87	-7.13	4.07
Feb.	4.10	-2.94	0.85	6.51
Mar.	-3.39	2.06	2.40	2.20
Abr.	0.94	4.89	-2.73	0.03
Mayo	0.32	3.45	8.80	3.79
Jun.	4.23	-0.80	-0.89	-4.91
Jul.	-0.54	8.47	-0.52	4.39
Ago.	-3.94	1.54	-9.91	1.95
Sept.	3.90	-0.66	-5.25	-1.93
Oct.	2.56	-2.55	-0.67	1.18
Nov.	-1.91	1.64	5.82	-4.49
Dic.	1.46	2.12	2.45	10.58




FIGURA 2-18 Gráfica de probabilidad normal para tasas de rendimiento mensuales del índice Standard & Poor's 500

La prueba de normalidad preestablecida de Minitab es la prueba Anderson-Darling, cuyos resultados se ilustran en la figura 2-18. Los detalles de esta prueba no nos interesan por el momento; sin embargo, note el *valor p* (indicado como P-Value en la parte superior derecha de la figura) de .927. En este caso, el *valor p* grande sugiere que los datos de la muestra de S&P son consistentes con la hipótesis nula (en efecto, no es inusual si la hipótesis nula es verdadera). El rechazo de la hipótesis nula de la normalidad daría como resultado casi con seguridad un error. Por lo tanto, la hipótesis nula no debería rechazarse y la suposición de que los datos de S&P siguen una distribución normal puede hacerse con seguridad.

APLICACIÓN EN LA ADMINISTRACIÓN

Muchos de los conceptos en este capítulo de repaso pueden considerarse como los antecedentes necesarios para la comprensión de técnicas más avanzadas para elaborar pronósticos, que se encuentran a lo largo del resto del libro. Sin embargo, los conceptos en este capítulo también tienen valor por sí mismos en muchas aplicaciones estadísticas. Aunque algunas de dichas aplicaciones quizá no caigan lógicamente dentro del título de “pronósticos”, implican el uso de datos recopilados para contestar preguntas acerca de incertidumbres en la operación de negocios, en especial de los resultados futuros inciertos.

Los procedimientos estadísticos descriptivos mencionados al principio del capítulo son ampliamente usados siempre que grandes cantidades de datos deban describirse de forma convincente, de modo que puedan utilizarse en el proceso de toma de decisiones. Sería casi imposible pensar en una sola área que implique mediciones numéricas, en las cuales los conjuntos de datos no estén resumidos rutinariamente, usando estadísticos descriptivos. Este hecho se aplica específicamente a la media, que por lo general se conoce como el “promedio”, y —en menor medida— a la desviación estándar. Los promedios son cosa común y se han utilizado por muchos años para tener medidas centrales de conjuntos ordenados de datos. El énfasis reciente en la calidad requiere una comprensión de la variación y, por lo tanto, medidas de dispersión, tales como la desviación estándar, están apareciendo con cada vez mayor frecuencia en la práctica de negocios.

Las distribuciones binomial y normal son buenos ejemplos de distribuciones teóricas que sirven como modelos para muchas situaciones de la vida real. Como tales, se han utilizado abundantemente en aplicaciones, incluyendo la elaboración de pronósticos.

La estimación y la prueba de hipótesis son el principal fundamento de la inferencia estadística básica. La elaboración de pronósticos, o estimación, acerca de los valores de interés de población, a partir de una muestra aleatoria, se emplea comúnmente siempre que las restricciones de tiempo y de costos descartan un examen de todos los elementos en consideración. El muestreo está muy extendido en auditorías. La prueba de hipótesis está relacionada con dos enunciados en competencia, acerca de parámetros de la población, de modo que se emplea a menudo para contestar preguntas como éstas:

- ¿Cómo se compara la media de ventas de este periodo con la del periodo anterior?
- ¿Cómo se compara la razón activos/pasivos media de empresas exitosas con la de empresas malogradas?
- ¿La producción media por hora de este proceso de producción es menor de lo que había sido?

La correlación se utiliza ampliamente para examinar las relaciones entre pares de variables numéricas. Como veremos en capítulos posteriores, estas relaciones son de gran importancia en la elaboración de pronósticos, porque el pronóstico de una variable a menudo requiere los valores de las variables relevantes relacionadas. Tanto los análisis de regresión simple como múltiple son técnicas de pronósticos que caen dentro de esta categoría.

Glosario

Distribución binomial. La distribución binomial es una distribución de probabilidad discreta, que describe la probabilidad de X éxitos en n ensayos independientes de un experimento binomial.

Variable aleatoria continua. Una variable aleatoria continua puede tomar cualquier valor dentro de un rango específico. Estos resultados se representan numéricamente con intervalos de valores.

Coefficiente de correlación. Mide el grado en que dos variables están linealmente relacionadas entre sí.

Grados de libertad. Se refieren al número de datos que son independientes entre sí y llevan piezas únicas de información.

Variable aleatoria discreta. Tipo de variable que sólo puede tomar ciertos valores de un conjunto predeterminado. Estos resultados a menudo se representan numéricamente con enteros.

Valor esperado. El valor medio de la variable a lo largo de muchos ensayos u observaciones.

Intervalo de estimación. Intervalo numérico dentro del cual es probable que se encuentre el parámetro de la población.

Método de los mínimos cuadrados. Se usa para calcular la ecuación de una línea recta que minimiza la suma de los cuadrados de las distancias entre los puntos de datos X - Y y la línea, medidos en la dirección vertical (Y).

Distribución normal. Tiene forma de campana y está completamente determinada por su media y su desviación estándar.

Estimación puntual. Estimación de un parámetro poblacional mediante un valor único.

Valor p . También llamado probabilidad de significancia, es la probabilidad de obtener un resultado de muestra por lo menos tan extremo como el que se observa realmente si H_0 es verdadera.

Distribución muestral. Es el arreglo de todos los valores posibles de un estadístico muestral, que puede obtenerse a partir de una población para un tamaño de muestra determinado.

Diagrama de dispersión. Un diagrama de dispersión es una gráfica de puntos de datos X - Y sobre una gráfica bidimensional.

Fórmulas clave

Media de la muestra

$$\bar{X} = \frac{\Sigma X}{n} \quad (2.1)$$

Desviación estándar de la muestra

$$S = \sqrt{\frac{\Sigma (X - \bar{X})^2}{n - 1}} = \sqrt{\frac{\Sigma X^2 - \frac{(\Sigma X)^2}{n}}{n - 1}} \quad (2.2)$$

Varianza de la muestra

$$S^2 = \frac{(X - \bar{X})^2}{n - 1} = \frac{\Sigma X^2 - \frac{(\Sigma X)^2}{n}}{n - 1} \quad (2.3)$$

Valor esperado

$$E(X) = \Sigma [X \times P(X)] \quad (2.4)$$

Distribución de probabilidad binomial

$$P(X) = \binom{n}{X} p^X (1 - p)^{n-X} \quad \text{para } X = 0, 1, \dots, n \quad (2.5)$$

Z como número de varianzas

$$Z = \frac{X - \mu}{\sigma} \quad (2.6)$$

Estadístico de prueba t (distribución t de Student)

$$t = \frac{\bar{X} - \mu}{S/\sqrt{n}} \quad (2.7)$$

Intervalo de confianza para la media de la población (muestra grande)

$$\bar{X} \pm Z \frac{S}{\sqrt{n}} \quad (2.9)$$

Intervalo para la media de la población (muestra pequeña, población normal)

$$\bar{X} \pm t \frac{S}{\sqrt{n}}$$

Coefficiente de correlación

$$\begin{aligned} r &= \frac{1}{n-1} \Sigma Z_X Z_Y = \frac{\Sigma(X - \bar{X})(Y - \bar{Y})}{\sqrt{\Sigma(X - \bar{X})^2} \sqrt{\Sigma(Y - \bar{Y})^2}} \\ &= \frac{n \Sigma XY - (\Sigma X)(\Sigma Y)}{\sqrt{n \Sigma X^2 - (\Sigma X)^2} \sqrt{n \Sigma Y^2 - (\Sigma Y)^2}} \end{aligned} \quad (2.10)$$

Método de mínimos cuadrados

$$SSE = \Sigma(Y - \hat{Y})^2 = \Sigma(Y - b_0 - b_1 X)^2 \quad (2.11)$$

Ecuación de la pendiente de regresión ajustada

$$b_1 = \frac{\Sigma(X - \bar{X})(Y - \bar{Y})}{\Sigma(X - \bar{X})^2} = \frac{n \Sigma XY - \Sigma X \Sigma Y}{n \Sigma X^2 - (\Sigma X)^2} \quad (2.12)$$

Ecuación de la intersección con el eje Y de la recta de regresión ajustada

$$b_0 = \bar{Y} - b_1 \bar{X} = \frac{\Sigma Y}{n} - \frac{b_1 \Sigma X}{n} \quad (2.13)$$

Ecuación alternativa de la pendiente de la ecuación de regresión ajustada

$$b_1 = \left(\frac{\sqrt{\Sigma(Y - \bar{Y})^2}}{\sqrt{\Sigma(X - \bar{X})^2}} \right) r \quad (2.14)$$

Problemas

1. Dick Hoover, propietario de Modern Office Equipment, está preocupado por los costos de fletes (de envío) y por los costos de oficina en que incurren pedidos pequeños. En un esfuerzo por reducir gastos en esta área, decide aplicar una

política de descuentos en pedidos de más de \$40, con la esperanza de que esto motive a los clientes a consolidar varios pedidos pequeños en pedidos más grandes. Los siguientes datos presentan las cantidades por transacción para una muestra de 28 clientes.

10, 15, 20, 25, 15, 17, 41, 50, 5, 9,
12, 14, 35, 18, 19, 17, 28, 29, 11, 11,
43, 54, 7, 8, 16, 13, 37, 18

- Calcule la media de la muestra.
 - Calcule la desviación estándar de la muestra.
 - Calcule la varianza de la muestra
 - Si la política tiene éxito, ¿la media de la distribución aumentará, disminuirá o no se verá afectada?
 - Si la política tiene éxito, ¿la desviación estándar de la distribución aumentará, disminuirá o no se verá afectada?
 - Dados los datos anteriores, pronostique la cantidad del siguiente pedido de parte de los clientes.
2. Sandy James cree que los precios de las viviendas se han estabilizado en los recientes meses. Para convencer a su jefe, ella tiene pensado comparar los precios actuales con los precios del año pasado. Ella reúne 12 precios de viviendas de anuncios clasificados:
- 125,900 253,000 207,500 146,950 121,450 135,450
175,000 200,000 210,950 166,700 185,000 191,950
- Luego, calcula la media y la desviación estándar de los precios que encontró. ¿Cuáles son estos dos valores?
3. Una compañía constructora grande planea idear una manera útil de visualizar las ganancias típicas de trabajos obtenidos por licitación. Debido a que los trabajos varían significativamente en tamaño y en la cantidad final de subasta exitosa, la compañía ha decidido expresar las utilidades como ganancias porcentuales:

$$\text{Ganancias porcentuales} = 100 \times \frac{\text{Ganancias}}{\text{Costos reales de construcción}}$$

Cuando se pierde dinero en un proyecto, las ganancias son negativas y también la utilidad neta resultante. Una muestra de 30 trabajos arrojó las ganancias porcentuales:

15.9 21.3 -1.8 6.6 .4 53.6 19.7 -5 6.7 -2.3
11.9 -.3 19.0 12.8 -9.6 26.8 21.0 32.0 -4 10.9
6.9 -8.5 3.5 3.5 -1.9 4.0 13.0 15.1 9.7 33.9

- Calcule un estimado de las ganancias porcentuales medias para la población de trabajos al incluir todos los trabajos potenciales.
- Construya un intervalo de confianza de 95% para las ganancias porcentuales medias de la población de trabajos, usando un argumento de muestra grande.
- Construya un intervalo de confianza de 95%, para las ganancias porcentuales medias para la población de trabajos, suponiendo que 30 es un tamaño de muestra pequeño. ¿Cuál es la suposición adicional que usted necesita hacer en este caso?
- Compare los dos intervalos en los incisos b) y c). Explique por qué un tamaño de muestra de 30 a menudo se toma como límite entre una muestra grande y una pequeña.

4. De los datos en una muestra grande de transacciones de ventas, el propietario de un negocio pequeño informa que un intervalo de confianza de 95% para la utilidad media por transacción, μ , es (23.41, 102.59). Use estos datos para determinar
 - a) Una estimación puntual (mejor conjetura) de la media, μ , y su margen de error de 95%.
 - b) Un intervalo de confianza de 90% para la media, μ .
5. Queremos predecir si el número medio de días de ausencia por año se ha incrementado para una muestra grande de trabajadores. Se sabía que hace un año la media era de 12.1. Una muestra reciente de 100 empleados revela una media muestral de 13.5, con una desviación estándar de la muestra de 1.7 días. Pruebe con nivel de significancia de .05, para determinar si la media de la población se ha incrementado, o si la diferencia entre 13.5 y 12.1 simplemente representa un error de muestreo.
6. New Horizons Airlines quiere predecir el número medio de asientos vacíos por vuelo a Alemania para el siguiente año. Para realizar tal pronóstico, se seleccionan al azar los registros de 49 vuelos de los archivos del año pasado, y se anota el número de asientos desocupados para cada vuelo. La media y la desviación estándar de la muestra son de 8.1 asientos y 5.7 asientos, respectivamente. Desarrolle una estimación puntual y por intervalo de 95% del número medio de asientos desocupados por vuelo, durante el año pasado. Pronostique la media de asientos vacíos por vuelo a Alemania para el siguiente año. Analice la exactitud de su pronóstico.
7. Por un periodo de varios años, un dentífrico ha recibido una puntuación media de 5.9, en una escala de 7 puntos, en cuanto a la satisfacción general del cliente con el producto. Debido a un cambio no anunciado en el producto, existe la preocupación de que quizás haya cambiado la satisfacción del cliente. Suponga que las puntuaciones de satisfacción para una muestra de 60 clientes tienen una media de 5.60 y una desviación estándar de .87. ¿Indican estos datos que la puntuación media de satisfacción es diferente de 5.9? Pruebe con $\alpha = .05$. ¿Cuál es el valor p de la prueba?
8. La gerente de una tienda de yogurt congelado afirma que una porción de tamaño mediano contiene un promedio de más de 4 onzas de producto. A partir de una muestra aleatoria de 14 raciones, se obtiene una media de 4.31 onzas y una desviación estándar de .52 onzas. Pruebe, con $\alpha = .05$, la afirmación de la gerente. Calcule el valor p para la prueba. Suponga que la distribución de peso por ración es normal.
9. Con base en experiencias pasadas, la California Power Company predice que la media del uso residencial de electricidad por hogar será de 700 kwh para el próximo enero. En enero, la compañía selecciona una muestra aleatoria simple de 50 hogares, y calcula una media y una desviación estándar de 715 y 50, respectivamente. Utilice un nivel de significancia de 0.05, para determinar si el pronóstico de California Power es razonable. Calcule e interprete el valor p de esta prueba.
10. Expertos demógrafos indican que el tamaño de la familia ha disminuido en los años recientes. Hace 10 años, el tamaño promedio de la familia era de 2.9. Considere la población de 200 tamaños de familia mostrados en la tabla P-10. Seleccione al azar una muestra de 30 tamaños de familia y pruebe la hipótesis de que el tamaño promedio de la familia no ha cambiado en los últimos 10 años.
11. A James Dobbins, supervisor de mantenimiento en Atlanta Transit Authority, le gustaría determinar si hay una relación positiva entre el costo de mantenimiento anual de un autobús y su antigüedad. Si existe tal relación, James cree que puede predecir mejor el presupuesto anual de mantenimiento de los autobuses. Él reúne los datos que se presentan en la tabla P-11.
 - a) Grafique un diagrama de dispersión.
 - b) ¿Qué tipo de relación hay entre estas dos variables?
 - c) Calcule el coeficiente de correlación.

TABLA P-10

(1) 3	(35) 1	(69) 2	(102) 1	(135) 5	(168) 6
(2) 2	(36) 2	(70) 4	(103) 2	(136) 2	(169) 3
(3) 7	(37) 4	(71) 3	(104) 5	(137) 1	(170) 2
(4) 3	(38) 1	(72) 7	(105) 3	(138) 4	(171) 3
(5) 4	(39) 4	(73) 2	(106) 2	(139) 2	(172) 4
(6) 2	(40) 2	(74) 6	(107) 1	(140) 4	(173) 2
(7) 3	(41) 1	(75) 2	(108) 2	(141) 1	(174) 2
(8) 1	(42) 3	(76) 7	(109) 2	(142) 2	(175) 1
(9) 5	(43) 5	(77) 3	(110) 1	(143) 4	(176) 5
(10) 3	(44) 2	(78) 6	(111) 4	(144) 1	(177) 3
(11) 2	(45) 1	(79) 4	(112) 1	(145) 2	(178) 2
(12) 3	(46) 4	(80) 2	(113) 1	(146) 2	(179) 4
(13) 4	(47) 3	(81) 3	(114) 2	(147) 5	(180) 3
(14) 1	(48) 5	(82) 5	(115) 2	(148) 3	(181) 5
(15) 2	(49) 2	(83) 2	(116) 1	(149) 1	(182) 3
(16) 2	(50) 4	(84) 1	(117) 4	(150) 2	(183) 1
(17) 4	(51) 1	(85) 3	(118) 2	(151) 6	(184) 2
(18) 4	(52) 6	(86) 3	(119) 1	(152) 2	(185) 4
(19) 3	(53) 2	(87) 2	(120) 3	(153) 5	(186) 3
(20) 2	(54) 5	(88) 4	(121) 5	(154) 1	(187) 2
(21) 1	(55) 4	(89) 1	(122) 1	(155) 2	(188) 5
(22) 5	(56) 1	(90) 2	(123) 2	(156) 1	(189) 3
(23) 2	(57) 2	(91) 3	(124) 3	(157) 4	(190) 4
(24) 1	(58) 1	(92) 3	(125) 4	(158) 2	(191) 3
(25) 4	(59) 5	(93) 2	(126) 3	(159) 2	(192) 2
(26) 3	(60) 2	(94) 4	(127) 2	(160) 7	(193) 3
(27) 2	(61) 7	(95) 1	(128) 1	(161) 4	(194) 2
(28) 3	(62) 1	(96) 2	(129) 6	(162) 2	(195) 5
(29) 6	(63) 2	(97) 4	(130) 1	(163) 1	(196) 3
(30) 1	(64) 6	(98) 3	(131) 2	(164) 7	(197) 3
(31) 2	(65) 4	(99) 2	(132) 5	(165) 2	(198) 2
(32) 4	(66) 1	(100) 6	(133) 2	(166) 7	(199) 5
(33) 3	(67) 2	(101) 4	(134) 1	(167) 4	(200) 1
(34) 2	(68) 1				

TABLA P-11

<i>Autobús</i>	<i>Costo de mantenimiento (\$)</i>	<i>Antigüedad</i>
	<i>Y</i>	<i>(años) X</i>
1	859	8
2	682	5
3	471	3
4	708	9
5	1,094	11
6	224	2
7	320	1
8	651	8
9	1,049	12

TABLA P-12

<i>Semana</i>	<i>Libros vendidos Y</i>	<i>Espacio en estantes X</i>
1	275	6.8
2	142	3.3
3	168	4.1
4	197	4.2
5	215	4.8
6	188	3.9
7	241	4.9
8	295	7.7
9	125	3.1
10	266	5.9
11	200	5.0

12. Ana Sheehan es la gerente de la cadena de supermercados Spendwise. A ella le gustaría predecir las ventas (ejemplares por semana) de libros de pasta blanda (rústica), con base en la cantidad de espacio de exhibición en los anaqueles (en pies). Anna reúne datos para una muestra de 11 semanas, como se presenta en la tabla P-12.
- Grafique un diagrama de dispersión.
 - ¿Qué tipo de relación hay entre estas dos variables?
 - Calcule el coeficiente de correlación. Utilice el método de mínimos cuadrados para determinar la pendiente y la intersección con el eje Y de la ecuación de la recta. Use esta ecuación para predecir el número de libros vendidos, si se usan 5.2 pies de espacio en estantes (es decir, $X = 5.2$).
13. Considere la población de 200 observaciones semanales presentadas en la tabla P-13. La variable independiente X es la temperatura semanal promedio en Spokane, Washington. La variable dependiente Y es el número de acciones de Sunshine Mining Stock, con las que se hicieron operaciones en la bolsa de valores de Spokane en una semana. Elija datos al azar para 16 semanas y calcule el coeficiente de correlación. (*Sugerencia:* Asegúrese de que su muestra se obtiene aleatoriamente de la población). Luego determine la recta de los mínimos cuadrados y pronostique Y para una temperatura promedio semanal de 63.
14. Un inversionista inmobiliario recolecta los siguientes datos de una muestra aleatoria de apartamentos en el lado oeste de College Station, Texas.
- Grafique los datos como un diagrama de dispersión donde Y = renta y X = tamaño.
 - Determine la ecuación de la recta ajustada que relacione la renta con el tamaño.
 - ¿Cuál es el incremento estimado en renta, para un pie adicional de espacio?
 - Pronostique la renta mensual para un departamento de 750 pies cuadrados.

Renta (\$ mensuales)	Tamaño (pies ²)	Renta (\$ mensuales)	Tamaño (pies ²)
720	1,000	650	800
595	900	748	960
915	1,200	685	650
760	810	755	970
1,000	1,210	815	1,000
790	860	745	1,000
880	1,135	715	1,000
845	960	885	1,180

TABLA P-13

<i>OBS.</i>	<i>Y</i>	<i>X</i>	<i>OBS.</i>	<i>Y</i>	<i>X</i>	<i>OBS.</i>	<i>Y</i>	<i>X</i>	<i>OBS.</i>	<i>Y</i>	<i>X</i>
(1)	50	37	(51)	54	86	(101)	22	43	(151)	79	85
(2)	90	77	(52)	76	48	(102)	32	5	(152)	79	27
(3)	46	55	(53)	55	48	(103)	24	13	(153)	48	61
(4)	47	27	(54)	12	15	(104)	63	3	(154)	5	7
(5)	12	49	(55)	5	70	(105)	16	58	(155)	24	79
(6)	23	23	(56)	2	9	(106)	4	13	(156)	47	49
(7)	65	18	(57)	77	52	(107)	79	18	(157)	65	71
(8)	37	1	(58)	6	71	(108)	5	5	(158)	56	27
(9)	87	41	(59)	67	38	(109)	59	26	(159)	52	15
(10)	83	73	(60)	30	69	(110)	99	9	(160)	17	88
(11)	87	61	(61)	3	13	(111)	76	96	(161)	45	38
(12)	39	85	(62)	6	63	(112)	15	94	(162)	45	31
(13)	28	16	(63)	70	65	(113)	10	30	(163)	90	35
(14)	97	46	(64)	33	87	(114)	20	41	(164)	69	78
(15)	69	88	(65)	13	18	(115)	37	1	(165)	62	93
(16)	87	87	(66)	10	4	(116)	56	27	(166)	0	51
(17)	52	82	(67)	21	29	(117)	6	73	(167)	8	68
(18)	52	56	(68)	56	21	(118)	86	19	(168)	47	30
(19)	15	22	(69)	74	9	(119)	27	94	(169)	7	81
(20)	85	49	(70)	47	8	(120)	67	5	(170)	48	30
(21)	41	44	(71)	34	18	(121)	22	31	(171)	59	46
(22)	82	33	(72)	38	84	(122)	32	13	(172)	76	99
(23)	98	77	(73)	75	64	(123)	90	11	(173)	54	98
(24)	99	87	(74)	0	81	(124)	88	50	(174)	95	11
(25)	23	54	(75)	51	98	(125)	35	40	(175)	7	6
(26)	77	8	(76)	47	55	(126)	57	80	(176)	24	83
(27)	42	64	(77)	63	40	(127)	73	44	(177)	55	49
(28)	60	24	(78)	7	14	(128)	13	63	(178)	41	39
(29)	22	29	(79)	6	11	(129)	18	74	(179)	14	16
(30)	91	40	(80)	68	42	(130)	70	40	(180)	24	13
(31)	68	35	(81)	72	43	(131)	9	53	(181)	36	31
(32)	36	37	(82)	95	73	(132)	93	79	(182)	62	44
(33)	22	28	(83)	82	45	(133)	41	9	(183)	77	11
(34)	92	56	(84)	91	16	(134)	17	52	(184)	32	60
(35)	34	33	(85)	83	21	(135)	10	82	(185)	12	82
(36)	34	82	(86)	27	85	(136)	69	37	(186)	85	7
(37)	63	89	(87)	13	37	(137)	5	57	(187)	90	68
(38)	30	78	(88)	6	89	(138)	18	62	(188)	78	10
(39)	31	24	(89)	76	76	(139)	88	21	(189)	60	27
(40)	84	53	(90)	55	71	(140)	99	94	(190)	96	90
(41)	56	61	(91)	13	53	(141)	86	99	(191)	51	6
(42)	48	18	(92)	50	13	(142)	95	45	(192)	9	62
(43)	0	45	(93)	60	12	(143)	78	19	(193)	93	78
(44)	58	4	(94)	61	30	(144)	3	76	(194)	61	22
(45)	27	23	(95)	73	57	(145)	38	81	(195)	5	99
(46)	78	68	(96)	20	66	(146)	57	95	(196)	88	51
(47)	78	79	(97)	36	27	(147)	77	30	(197)	45	44
(48)	72	66	(98)	85	41	(148)	25	59	(198)	34	86
(49)	21	80	(99)	49	20	(149)	99	93	(199)	28	47
(50)	73	99	(100)	83	66	(150)	9	28	(200)	44	49

15. Abbot & Sons necesita pronosticar la edad media μ de sus trabajadores contratados por hora. Se obtiene una muestra aleatoria de los archivos personales, con los resultados de abajo. Prepare una estimación puntual y un intervalo de confianza de 98%, para la edad media de los trabajadores. Pruebe la hipótesis $H_0: \mu = 44$ contra $H_1: \mu \neq 44$ al nivel de 2%. ¿Los resultados de la prueba de hipótesis son consistentes con el intervalo de confianza para μ ? ¿Usted esperaría que fueran?

$$\bar{X} = 45.2 \quad S = 10.3 \quad n = 175$$

16. En cada una de las siguientes situaciones, establezca una hipótesis nula adecuada, H_0 , y una hipótesis alternativa, H_1 . Identifique el parámetro que utilizará para establecer la hipótesis.
- Datos de Census Bureau indican que el ingreso familiar medio, en el área que atiende un centro comercial, es de \$63,700 anuales. Una empresa de investigación de mercados encuesta a los compradores del centro comercial, para averiguar si el ingreso familiar medio de los clientes es mayor que el de la población general.
 - El año pasado, al departamento de bomberos local le tomó un promedio de 4.3 minutos dar respuesta a las llamadas. ¿Los datos de este año indican un promedio diferente en el tiempo de respuesta?
 - Se anuncia que el área media de varios miles de apartamentos en un nuevo desarrollo es de 1,300 pies cuadrados. Un grupo de arrendatarios cree que los apartamentos son más pequeños que lo que dice la publicidad. Ellos contrataron a un ingeniero para medir una muestra de apartamentos para probar sus sospechas.
17. Un inversionista con un portafolio de inversiones sustancial demandó a su agente bursátil y a su empresa de corretaje, a causa de que la falta de diversificación en su portafolio le ocasionó un desempeño deficiente. Las tasas de rendimiento para los 39 meses que la cuenta fue administrada por tal agente produjeron estos estadísticos de resumen: $\bar{r} = -1.10\%$, $S = 5.99\%$. Considere los 39 rendimientos mensuales como una muestra aleatoria de la población de rendimientos que la correduría generaría, si administrara la cuenta para siempre. Usando los resultados de la muestra, construya un intervalo de confianza de 95%, para la media de rendimientos mensuales del mercado. Permita que S&P 500 represente al mercado y suponga que el rendimiento medio de S&P 500 para el mismo periodo es de 0.94%. ¿Éste un valor realista para la media de la población de cuentas del cliente? Explique.
18. La tabla P-18 proporciona sueldos mensuales en dólares (SUELDOS) y tiempo de servicio (TDS) en meses, en un momento específico, para 16 mujeres que tienen trabajos de servicio al cliente en bancos de Texas.

TABLA P-18

<i>Empleado</i>	<i>SUELDOS</i>	<i>TDS</i>
1	389	94
2	377	60
3	315	45
4	316	39
5	324	20
6	403	76
7	390	106
8	441	62
9	418	68
10	413	55
11	396	27
12	353	58
13	483	139
14	437	98
15	341	70
16	476	60

- Grafique los datos de la tabla P-18 como un diagrama de dispersión, con SUELDOS a lo largo del eje vertical (Y) y TDS en el eje horizontal (X).
- Calcule el coeficiente de correlación de la muestra, r . Usando el signo y la magnitud de r , describa la naturaleza de la asociación lineal entre SUELDOS y TDS. ¿Puede pensar en otras variables que afectarían los sueldos semanalmente, además del tiempo de servicio?
- Calcule la recta ajustada que pueda usarse para predecir SUELDOS a partir de TDS. Si el TDS es de 80 meses, ¿cuál será el SUELDO pronosticado?

CASOS

CASO 2-1 ALCAM ELECTRONICS

Jarrick Tilby se tituló recientemente en administración de negocios en una pequeña universidad y comenzó a trabajar a Alcam Electronics, un fabricante de varios componentes electrónicos para la industria. Después de unas semanas en el trabajo, la gerente y propietaria de Alcam, McKennah Labrum, lo llamó a su oficina y le pidió investigar una cuestión respecto a cierto transistor fabricado por Alcam, porque una compañía de TV grande estaba interesada en una compra significativa.

McKennah quería pronosticar el tiempo de vida promedio de este tipo de transistor, un asunto de gran preocupación para la compañía de TV. Las unidades que actualmente están en existencia podrían ser representativas de aquellas que se producirían durante la vigencia del nuevo contrato si es que éste fuera aceptado.

Jarrick decidió tomar una muestra aleatoria de los transistores en cuestión y formuló un plan para llevar a cabo esa tarea. Numeró los contenedores de almacenamiento de los transistores, les puso números aleatorios y muestreó todos los transistores en cada contenedor seleccionado para la muestra. Puesto que cada contenedor incluía aproximadamente de 20 transistores, seleccionó 10 números al azar, lo cual le dio un tamaño de muestra final de 205 transistores. Debido a que había seleccionado 10 de 55 contenedores, creía que tenía una buena muestra representativa y podría usar los resultados de esta muestra para generalizar a la población completa de transistores en el inventario, así como a las unidades aún habrían de ser fabricadas con el mismo proceso.

Entonces, Jerrick consideró la cuestión del tiempo de vida promedio de las unidades. Debido a que el tiempo de vida de la unidad puede extenderse varios años, se dio cuenta de que ninguna de las unidades muestreadas podría probarse, si se deseaba una res-

puesta oportuna. Por lo tanto, decidió contactar a varios usuarios de dichos componentes para determinar si había registros acerca de la vida de los componentes. Por fortuna, encontró tres compañías que han usado el transistor en el pasado y que tenían registros limitados acerca del tiempo de vida del componente. En total, recibió datos sobre 38 transistores cuyos tiempos de falla eran conocidos. Puesto que estos transistores se fabricaron usando el proceso actual, Jarrick pensó que los resultados de esta muestra podrían utilizarse para hacer inferencias acerca de las unidades en el inventario y aquellas que se fabricarían.

Los resultados de los cálculos que Jarrick ejecutó con su muestra de datos del tiempo de vida son:

$$n = 38$$

$$\text{Tiempo de vida promedio } \bar{X} = 4,805 \text{ horas}$$

$$\text{Desviación estándar de tiempos de vida } S = 675 \text{ horas}$$

Después de encontrar que el tiempo de vida promedio de la muestra era tan sólo de 4,805 horas, Jarrick estaba preocupado porque sabía que otro proveedor de componentes estaba garantizando un tiempo de vida promedio de 5,000 horas. Aunque su promedio de la muestra estaba un poco por debajo de 5,000 horas, se dio cuenta de que el tamaño de la muestra era únicamente de 38 y que esto no constituía una prueba contundente de que la calidad de Alcam fuera inferior a la del otro proveedor. Decidió probar la hipótesis de que el tiempo de vida promedio de todos los transistores era de 5,000 horas contra la alternativa de que fuera menor. En seguida se presentan los cálculos que realizó usando $\alpha = .01$:

$$H_0: \mu = 5,000$$

$$H_1: \mu < 5,000$$

Si $S = 675$, entonces el punto de la regla de decisión es

$$5,000 - 2.33 \frac{675}{\sqrt{38}} = 4,744.9$$

y la regla de decisión es como sigue:

$$\text{Si } \bar{X} < 4,744.9, \text{ rechace } H_0$$

Puesto que la media de la muestra (4,805) no estaba por debajo del punto de la regla de decisión para el rechazo (4,744.9), Jarrick no rechazó la hipótesis de que el tiempo de vida medio de todos los componentes era igual a 5,000 horas. Pensó que esto serían

buenas noticias para McKennah Labrum e incluyó un resumen de sus hallazgos en su informe final. Pocos días después, le entregó a McKennah su informe verbal y escrito. Ella lo llamó a su oficina para felicitarlo por su buen trabajo y compartir con él una inquietud que tenía en relación con sus hallazgos. Ella dijo: “Estoy preocupada por el nivel de significancia tan bajo de tu prueba de hipótesis. Tan sólo tomaste una probabilidad de 1% de rechazar la hipótesis nula si fuera verdadera. Esto me suena muy conservador. Estoy alarmada de firmar el contrato y luego entrarme de que nuestro nivel de calidad no satisface la especificación deseada de 5,000 horas”.

PREGUNTA

1. ¿Cómo respondería ante el comentario de McKennah Labrum?

CASO 2-2 MR. TUX

John Mosby, propietario de varias tiendas de alquiler Mr. Tux, está interesado en predecir su volumen de ventas mensual (véase caso 1-1). Como primer paso, John recolecta datos de ventas mensuales de los años 1998 a 2005, como se expone en la tabla 2-10.

Después, John calcula el valor promedio de ventas mensuales para cada año (es decir, suma los 12 valores

para 1998 y los divide entre 12). John también calcula la desviación estándar para los 12 valores mensuales de cada año. Los resultados se presentan en la tabla 2-11. John también decide construir una gráfica de series de tiempo, que se ilustra en la figura 2-19. Grafica los valores medios de ventas mensuales sobre el eje Y y el tiempo sobre el eje X .

TABLA 2-10		Datos de ventas mensuales de Mr. Tux						
	1998	1999	2000	2001	2002	2003	2004	2005
Ene.	6,028	16,850	15,395	27,773	31,416	51,604	58,843	71,043
Feb.	5,927	12,753	30,826	36,653	48,341	80,366	82,386	152,930
Mar.	10,515	26,901	25,589	51,157	85,651	208,938	224,803	250,559
Abr.	32,276	61,494	103,184	217,509	242,673	263,830	354,301	409,567
Mayo	51,920	147,862	197,608	206,229	289,554	252,216	328,263	394,747
Jun.	31,294	57,990	68,600	110,081	164,373	219,566	313,647	272,874
Jul.	23,573	51,318	39,909	102,893	160,608	149,082	214,561	230,303
Ago.	36,465	53,599	91,368	128,857	176,096	213,888	337,192	375,402
Sept.	18,959	23,038	58,781	104,776	142,363	178,947	183,482	195,409
Oct.	13,918	41,396	59,679	111,036	114,907	133,650	144,618	173,518
Nov.	17,987	19,330	33,443	63,701	113,552	116,946	139,750	181,702
Dic.	15,294	22,707	53,719	82,657	127,042	164,154	184,546	258,713

TABLA 2-11 Valores mensuales promedio de ventas de Mr. Tux		
Año	Promedio (media) (\$)	Desviación estándar (\$)
1998	22,013	13,165
1999	44,603	35,290
2000	64,841	47,217
2001	103,610	57,197
2002	141,381	70,625
2003	169,432	63,376
2004	213,866	96,387
2005	247,231	99,153




FIGURA 2-19 Ventas mensuales medias de Mr. Tux

PREGUNTAS

1. ¿Qué ideas de pronósticos le vienen a la mente cuando estudia los valores medios de ventas mensuales para los años de esos datos?

2. Suponga que John traza una recta a mano a través de su diagrama de dispersión, de modo que “se ajuste bien” y, luego, extiende esta línea hacia el futuro, usando puntos a lo largo de la línea como sus pronósticos mensuales. ¿Qué tan exactos piensa usted que serían tales pronósticos? Use los valores de la desviación estándar que calculó John,
- al contestar esta pregunta. Con base en su análisis, ¿animaría a John para continuar buscando un método de pronóstico más exacto? John tiene la última versión de Minitab en su computadora. ¿Cree usted que él debería utilizar la función de análisis de regresión de Minitab, para calcular una línea de mínimos cuadrados? Si lo hizo, ¿qué variable *X* debería utilizar para pronosticar las ventas mensuales (*Y*)?

CASO 2-3 ALOMEGA FOOD STORES

En el ejemplo 1.1, la presidenta de Alomega, Julie Ruth, recolectó datos de las operaciones de su compañía. Obtuvo datos de varios meses de ventas, junto con posibles variables explicativas (repase esta situación en el ejemplo 1.1). Mientras su equipo de análisis estaba trabajando con los datos, en un intento por pronosticar las ventas mensuales, se impacientó y se preguntó cuál de las variables de predicción era mejor para este propósito.

Debido a que ella tenía un programa estadístico en su computadora de escritorio, decidió echar una mirada a los datos por sí misma. Primero, encontró los coeficientes de correlación entre la variable de ventas mensuales y varias de las variables explicativas potenciales. Específicamente, estaba interesada en las correlaciones entre las ventas mensuales y el importe de la publicidad en periódicos, el importe mensual de la publicidad en TV, el de la publicidad de uno o dos meses antes, la publicidad en televisión uno o dos meses antes y las calificaciones de la publicidad de sus competidores. Los valores r (coeficientes de correlación) fueron los siguientes:

Coeficiente de correlación r entre
la variable ventas y

Importe mensual de publicidad en periódico	.45
Importe mensual de publicidad en TV	.60
Importe de publicidad en periódico un mes antes	-.32
Importe de publicidad en periódico dos meses antes	.21
Importe de publicidad en TV un mes antes	-.06
Importe de publicidad en TV dos meses antes	.03
Calificación de la publicidad de los competidores	-.18

Julie no estaba sorprendida de encontrar que la correlación más alta era entre las ventas mensuales y los importes de publicidad en TV ($r = .60$); pero esperaba una correlación más fuerte. Decidió usar una función de regresión para calcular la ecuación de la recta

de mínimos cuadrados, usando las ventas como la variable dependiente, y el importe de publicidad en TV como la variable explicativa. Los resultados de esta corrida fueron

$$\begin{aligned}\text{Ventas} &= 341,663 + .336 (\text{publicidad mensual en TV}) \\ r\text{-cuadrada} &= .36(36\%) \quad \text{valor } p = .000\end{aligned}$$

Julie buscó en su libro de texto de estadística universitaria, para interpretar los resultados para r -cuadrada y $\text{valor } p$ que imprimió. Después de la lectura, ella recordó que r -cuadrada (que es el cuadrado del coeficiente de correlación r) mide el porcentaje de la variabilidad en ventas, que puede explicarse con la variabilidad en los dólares mensuales de publicidad en TV (esto se estudiará en el capítulo 6). El $\text{valor } p$ también indica que el coeficiente de la pendiente (.336) es significativo; es decir, puede rechazarse la hipótesis de que es cero en la población de la cual se extrajo la muestra sin que exista posibilidad de error.

Julie concluyó que la ecuación de regresión que encontró era importante y podría utilizarse para el pronóstico de ventas mensuales, si se conoce el presupuesto asignado a publicidad en TV. Puesto que los gastos de publicidad en TV están bajo el control de la compañía, ella sintió que tenía una buena forma de pronosticar las ventas futuras. En una breve conversación con el gerente de su departamento de administración de datos, Roger Jackson, ella mencionó sus hallazgos. Él contestó: “Sí, nosotros encontramos eso también. Pero nos dimos cuenta de que la publicidad en TV explica sólo aproximadamente un tercio de la variabilidad en las ventas. Muy bien, 36%. Realmente no creemos que sea suficiente, y estamos tratando de usar otras variables juntas para intentar obtener ese valor r -cuadrado más elevado. Además, creemos que estamos en un método que consistentemente hará un mejor trabajo que el análisis de regresión”.

PREGUNTAS

1. ¿Qué piensa del análisis de Julie Ruth?
2. Defina los residuos (errores) como diferencias entre los valores de ventas reales y los valores

predichos por la línea recta. ¿Cómo podría examinar usted los residuos para decidir si la representación de la línea recta de Julie es adecuada?

Aplicaciones de Minitab

El problema. En el ejemplo 2.1, se analizó un conjunto de edades usando estadística descriptiva.

Soluciones de Minitab

1. Introduzca el nombre de la variable Ages (Edades) debajo de C1.
2. Introduzca los datos en la columna C1.
3. Haga clic en los menús mostrados abajo.

Stat>Basic Statistics>Graphical Summary

4. Aparece la ventana de diálogo Graphical Summary:
 - a) Haga clic en Variables y seleccione Ages (C1), como se ilustra en la figura 2-20.
 - b) Haga clic en OK en la ventana de diálogo Graphical Summary y aparecerá el resumen mostrado en la figura 2-21.
 - c) Para imprimir esta gráfica, haga clic en los siguientes menús.


File>Print Graph


5. Haga clic en los menús mostrados a continuación:

Stat>Basic Statistics>Display Descriptive Statistics

6. Aparece la ventana de diálogo Display Descriptive Statistics.
 - a) Haga clic en Variables y seleccione Ages (C1).
 - b) Haga clic en OK y aparece el resumen mostrado en la figura 2-1 en la ventana Session. (Para obtener estadísticas descriptivas adicionales, dé clic en Statistics y seleccione medidas descriptivas adicionales, antes del clic en OK).

FIGURA 2-20 Pantalla de Minitab de la ventana de diálogo Graphical Summary





- c) Para imprimir la ventana de la sesión que contiene un resumen de los estadísticos descriptivos, haga clic en:

File>Print Session Window

El resultado se ilustra en la figura 2-1.

7. Los siguientes comandos le permitirán a usted desarrollar un histograma, un diagrama de puntos y un diagrama de caja:

Graph>Histogram

Graph>Dotplot

Graph>Boxplot

Las instrucciones de cómo usar Minitab para correr los análisis de correlación y regresión se presentan al final del capítulo 6.

Aplicaciones de Excel

El problema. En el problema 1, Dick Hoover, propietario de Modern Office Equipment, está preocupado acerca de los costos de flete y de administración en que se incurre cuando los pedidos son pequeños.

Soluciones de Excel

1. Abra el programa Excel y aparecerá la pantalla de hoja de cálculo de la figura 1-2. Mueva el cursor a la celda A1 resaltada en la esquina superior izquierda de la hoja de cálculo.




FIGURA 2-22 Hoja de cálculo de Excel para el problema 1

2. Introduzca el primer valor, 10, seguido por la tecla return (enter), luego introduzca el siguiente valor de los datos, y así sucesivamente.
3. Después de que se hayan tecleado los 28 valores de datos en la columna A, se coloca el cursor en la celda donde se desean colocar los resultados del primer cálculo, A30.
4. El promedio de los datos de las celdas A1 a A28 se calcula tecleando la fórmula en A30. Para introducir una fórmula, el signo = (igual) debe ir antes de ella. La fórmula es `=Average(A1:A28)`. *Nota:* Se muestra A30 a la izquierda de la barra de la fórmula e `=Average(A1:A28)` arriba a la derecha de la hoja de cálculo.
5. El mismo enfoque se utiliza para calcular la desviación estándar. La fórmula `=Stdev(A1:A28)` se introduce en la celda A31. Los resultados se muestran en la figura 2-22.

También se pueden calcular el promedio y la desviación estándar usando la función Insert o la herramienta Data Analysis. Estos enfoques se estudiarán en capítulos posteriores.

Las instrucciones de cómo usar Excel para correr los análisis de correlación y de regresión se presentan al final del capítulo 6.

Si usted usa Minitab o Excel, se le sugiere que intente diferentes conjuntos de datos y rutinas estadísticas, para familiarizarse con estos poderosos programas. La habilidad que obtenga será muy útil cuando aprenda acerca de los procedimientos para elaboración de pronósticos en este texto.

Referencias

Anderson, D. R., D. J. Sweeney y T. A. Williams.
Essentials of Modern Business Statistics, 3a. ed.
Belmont, Calif.: Thomson/South-Western, 2007.

Keller, G. *Statistics for Management and Economics*, 7a
ed. Belmont, Calif.: Thomson/South-Western, 2005.

Moore, D. S., G. P. McCabe, W. M. Duckworth y S. L.
Sclove, *The Practice of Business Statistics*. Nueva
York: Freeman, 2003.

EXPLORACIÓN DE PATRONES DE DATOS E INTRODUCCIÓN A LAS TÉCNICAS DE PRONÓSTICOS

Una de las partes más difícil y que más tiempo consume en la elaboración de pronósticos es la recopilación de datos válidos y confiables. El personal de procesamiento de datos usa comúnmente la expresión “basura entra, basura sale”. Esta expresión también se aplica a la elaboración de pronósticos. Un pronóstico no puede ser tan preciso como los datos en que se basa. El modelo de pronóstico más elaborado fallará si se aplica a datos poco confiables.

El poder y la capacidad de las computadoras modernas han traído consigo la acumulación de una cantidad increíble de datos en casi todas las disciplinas. La difícil tarea a la que se enfrenta la mayoría de los pronosticadores es cómo obtener los datos adecuados que les ayuden a resolver sus problemas propios de toma de decisiones.

Para determinar qué datos serán útiles, se aplican cuatro criterios:

1. Los datos deben ser fidedignos y precisos. Se debe tener mucho cuidado en que los datos se obtengan de una fuente confiable, poniendo especial atención en la exactitud.
2. Los datos deberían ser relevantes. Los datos tienen que ser representativos de las circunstancias para las cuales se están usando.
3. Los datos tienen que ser consistentes. Cuando cambian las definiciones relacionadas con la recopilación de datos, se tienen que hacer los ajustes necesarios para conservar la consistencia en los patrones históricos. Esto quizá sea un problema, por ejemplo, cuando las dependencias gubernamentales cambian la miscelánea o la “canasta básica”, que se emplea al determinar el índice del costo de la vida. Hace varios años, las computadoras personales no formaban parte de la combinación de productos que compraban los consumidores; ahora sí lo son.
4. Los datos deberían ser oportunos. Los datos recopilados, resumidos y publicados oportunamente tendrán el mayor valor para el pronosticador. Puede haber muy pocos datos (una historia insuficiente sobre la cual apoyar resultados futuros) o demasiados datos (datos de periodos históricos irrelevantes lejanos en el pasado).

Generalmente, son dos los tipos de datos de interés para el pronosticador. El primer tipo son los datos recopilados en un periodo único, ya sea una hora, un día, una semana, un mes, o un trimestre. El segundo tipo son las observaciones de datos realizadas a través del tiempo. Cuando todas las observaciones se hacen durante el mismo periodo, las llamamos datos de corte *transversal*. El propósito es examinar esos datos y luego extrapolar o extender las relaciones identificadas a una población en general. Por ejemplo, la extracción de una muestra aleatoria de archivos del personal, para conocer la situación de los empleados de una compañía. La recopilación de datos sobre la antigüedad y el costo del mantenimiento de nueve autobuses de Spokane Transit Authority es otro. Un diagrama de dispersión, como el de la figura 3-1, nos ayuda a visualizar las relaciones y sugiere que la antigüedad podría ayudar en la elaboración del pronóstico del presupuesto anual de mantenimiento.




FIGURA 3-1 Diagrama de dispersión de la antigüedad y el costo de mantenimiento para nueve autobuses de Spokane Transit Authority

Los datos *de corte transversal* son observaciones recopiladas en un solo punto del tiempo.

Cualquier variable integrada con datos recopilados, registrados u observados durante incrementos de tiempo sucesivos se llama *serie de tiempo*. La producción mensual de cerveza en Estados Unidos es un ejemplo de una serie de tiempo.

Una *serie de tiempo* consiste en datos que se recopilan, registran u observan durante incrementos sucesivos de tiempo.

ESTUDIO DE PATRONES DE DATOS EN LAS SERIES DE TIEMPO

Uno de los pasos más importantes en la selección de un método para pronosticar adecuado con datos de una serie de tiempo es considerar los diferentes tipos de patrones de datos. Existen cuatro tipos generales: horizontal, tendencias, estacionales y cíclicos.

Cuando los datos recopilados en el transcurso del tiempo fluctúan alrededor de un nivel o una media constantes, hay un patrón *horizontal*. Se dice que este tipo de series es *estacionario* en su media. Se considera que las ventas mensuales de un producto alimenticio que no se incrementan, ni disminuyen, consistentemente durante un largo periodo tienen un patrón horizontal.

Cuando los datos crecen o descienden en varios periodos, existe un patrón *de tendencia*. La figura 3-2 muestra el crecimiento (tendencia) a largo plazo de una serie de tiempo (costos de viviendas) con datos anuales. Para ilustrar el crecimiento se dibuja una recta de tendencia lineal. Si bien la variable costo de la vivienda no se ha incrementado cada año, el cambio de la variable ha sido generalmente hacia arriba entre los periodos 1 a 20. Algunos ejemplos de las fuerzas básicas que afectan y ayudan a explicar la tendencia de una serie son el crecimiento de la población, la inflación de los precios, el avance tecnológico, las preferencias del consumidor y los incrementos en la productividad.




FIGURA 3-2 Tendencia y componentes cíclicos de una serie de tiempo anual, como el costo de la vivienda

Muchas variables macroeconómicas, como el producto interno bruto (PIB), el empleo y la producción industrial de un país presentan un comportamiento con tendencia. La figura 3-10 (véase p. 74) contiene otro ejemplo de una serie de tiempo con una tendencia preponderante. Esta figura muestra el crecimiento de ingresos operativos para Sears, de 1995 a 2004.

La *tendencia* es el componente de largo plazo que representa el crecimiento o el descenso en la serie de tiempo, durante un periodo extenso.

Cuando las observaciones indican aumentos y caídas que no tienen un periodo fijo, existe un patrón cíclico. El *componente cíclico* es la fluctuación con forma de onda alrededor de la tendencia y, por lo común, se ve afectada por las condiciones económicas generales. Un componente cíclico, si existe, típicamente presenta un ciclo durante varios años. Las fluctuaciones cíclicas a menudo están influidas por cambios en las expansiones y contracciones económicas, mejor conocidas como el ciclo de negocios. La figura 3-2 también muestra una serie de tiempo con un componente cíclico. El pico cíclico en el periodo 9 ilustra una expansión económica; y el valle cíclico en el periodo 12, una contracción económica.

El *componente cíclico* es la oscilación alrededor de la tendencia.

Cuando las observaciones se ven influidas por factores temporales, existe un patrón estacional. El *componente estacional* se refiere a un patrón de cambio que se repite año tras año. Para las series mensuales, el componente estacional mide la variabilidad de la serie cada enero, cada febrero, y así sucesivamente. Para una serie trimestral, hay cuatro elementos estacionales, uno por cada trimestre. La figura 3-3 indica que el consumo de electricidad de clientes residenciales de la compañía Washington Water Power es mayor en el primer trimestre (los




FIGURA 3-3 Consumo eléctrico para la compañía Washington Water Power, 1980-1991

meses de invierno) de cada año. La figura 3-14 (véase p. 77) indica que las ventas trimestrales de Coastal Marine son usualmente bajas en el primer trimestre de cada año. La variación estacional puede representar condiciones climáticas, horarios de escuela, días feriados o duración de los meses calendario.

El componente estacional es un patrón de cambio que se repite año tras año.

EXPLORACIÓN DE PATRONES DE DATOS CON ANÁLISIS DE AUTOCORRELACIÓN

Cuando se mide una variable a lo largo del tiempo, las observaciones en diferentes periodos a menudo están relacionadas o correlacionadas. Esta correlación se mide usando el coeficiente de autocorrelación.

Autocorrelación es la correlación que existe entre una variable retrasada uno o más periodos consigo misma.

Los patrones de datos que incluyen componentes como tendencia y estacionalidad pueden estudiarse usando autocorrelaciones. Los patrones se identifican examinando los coeficientes de autocorrelación de una variable en diferentes retrasos de tiempo.

El concepto de autocorrelación se ilustra con los datos presentados en la tabla 3-1. Observe que los valores de las variables Y_{t-1} y Y_{t-2} son valores reales de Y , que se han retrasado uno y dos periodos, respectivamente. Los valores para marzo, los cuales se muestran en el renglón para el periodo 3, son ventas de marzo, $Y_t = 125$; ventas de febrero, $Y_{t-1} = 130$; y ventas de enero, $Y_{t-2} = 123$.

TABLA 3-1 Datos de la VCR para el ejemplo 3.1

Tiempo <i>t</i>	Mes	Datos originales Y_t	Y atrasada un periodo Y_{t-1}	Y atrasada dos periodos Y_{t-2}
1	Enero	123		
2	Febrero	130	123	
3	Marzo	125	130	123
4	Abril	138	125	130
5	Mayo	145	138	125
6	Junio	142	145	138
7	Julio	141	142	145
8	Agosto	146	141	142
9	Septiembre	147	146	141
10	Octubree	157	147	146
11	Noviembre	150	157	147
12	Diciembre	160	150	157

La ecuación 3.1 es la fórmula para calcular k el coeficiente de autocorrelación (r_k) entre las observaciones Y_t y Y_{t-k} , que se encuentran a k periodos de distancia.

$$r_k = \frac{\sum_{t=k+1}^n (Y_t - \bar{Y})(Y_{t-k} - \bar{Y})}{\sum_{t=1}^n (Y_t - \bar{Y})^2} \quad k = 0, 1, 2, \dots \quad (3.1)$$

donde

r_k = coeficiente de autocorrelación para un retraso de k periodos

$\bar{Y}$ = media de los valores de la serie

Y_t = observación en el periodo t

Y_{t-k} = observación k periodos anteriores o durante un periodo $t - k$

Ejemplo 3.1

Harry Vernon, ha recopilado datos del número de VCR vendidos el año pasado por Vernon's Music Store. Los datos se presentan en la tabla 3-1. La tabla 3-2 muestra las operaciones que llevan al cálculo del coeficiente de autocorrelación para un retraso de 1. La figura 3-4 contiene un diagrama de dispersión de los pares de observaciones (Y_t , Y_{t-1}). Al revisar el diagrama de dispersión, queda claro que la correlación de retraso 1 será positiva.

El coeficiente de autocorrelación de retraso 1 (r_1), es decir, la autocorrelación entre Y_t y Y_{t-1} , se calcula usando los totales de la tabla 3.2 y la ecuación 3.1. De modo que:

$$r_1 = \frac{\sum_{t=1+1}^n (Y_{t-1} - \bar{Y})(Y_t - \bar{Y})}{\sum_{t=1}^n (Y_t - \bar{Y})^2} = \frac{843}{1,474} = .572$$

Como se sugiere en el diagrama de la figura 3-4, en esta serie de tiempo hay una autocorrelación positiva para el retraso 1. La correlación entre Y_t y Y_{t-1} o la autocorrelación para el retraso de 1 es .572. Esto significa que las ventas mensuales sucesivas de VCR están correlacionadas de algún modo unas con otras. Esta información daría a Harry perspectivas valiosas sobre su serie de tiempo, que le ayudaría a prepararse para usar un método avanzado para la elaboración del pronóstico y quizás advertirle acerca del uso de un análisis de regresión con tales datos. Todas estas ideas se analizarán en capítulos posteriores.

TABLA 3-2 Cálculo del coeficiente de autocorrelación del retraso 1, para los datos de la tabla 3-1

Tiempo t	Y_t	Y_{t-1}	$(Y_t - \bar{Y})$	$(Y_{t-1} - \bar{Y})$	$(Y_t - \bar{Y})^2$	$(Y_t - \bar{Y})(Y_{t-1} - \bar{Y})$
1	123	—	-19	—	361	—
2	130	123	-12	-19	144	228
3	125	130	-17	-12	289	204
4	138	125	-4	-17	16	68
5	145	138	3	-4	9	-12
6	142	145	0	3	0	0
7	141	142	-1	0	1	0
8	146	141	4	-1	16	-4
9	147	146	5	4	25	20
10	157	147	15	5	225	75
11	150	157	8	15	64	120
12	160	150	18	8	324	144
Total	1,704		0		1,474	843

$$\bar{Y} = \frac{1,704}{12} = 142$$

$$r_1 = \frac{843}{1,474} = .572$$

El coeficiente de autocorrelación de segundo orden (r_2), o la correlación entre Y_t y Y_{t-2} , para los datos de Harry, también se calcula con la ecuación 3.1.

$$r_2 = \frac{\sum_{t=2+1}^n (Y_t - \bar{Y})(Y_{t-2} - \bar{Y})}{\sum_{t=1}^n (Y_t - \bar{Y})^2} = \frac{682}{1,474} = .463$$




FIGURA 3-4 Diagrama de dispersión de los datos de Vernon's Music Store para el ejemplo 3-1

Parece que existe una autocorrelación moderada en esta serie de tiempo, para dos periodos de retraso. La correlación entre Y_t y Y_{t-2} , o la autocorrelación para un retraso 2, es de .463. Observe que el coeficiente de autocorrelación para el retraso de 2 (.463) es menor que el coeficiente de autocorrelación para el retraso de 1 (.572). Generalmente, conforme aumenta el número de retrasos (k), disminuyen las magnitudes de los coeficientes de autocorrelación.

La figura 3-5 ilustra una gráfica de autocorrelaciones con retrasos de tiempo, para los datos de Harry Vernon usados en el ejemplo 3-1. La escala horizontal en la parte inferior de la gráfica presenta cada retraso de tiempo de interés: 1, 2, 3, etc. La escala vertical de la izquierda indica el posible rango del coeficiente de autocorrelación, de -1 a 1 . La línea horizontal a la mitad de la gráfica representa autocorrelaciones de cero. La línea vertical que se extiende por arriba de un retraso de tiempo 1 muestra un coeficiente de autocorrelación de .57, o $r_1 = .57$. La línea vertical que se extiende hacia arriba de un retraso de tiempo 2 muestra un coeficiente de autocorrelación .46, o $r_2 = .46$. Los estadísticos de las líneas punteadas, los estadísticos T y LBQ (Ljung-Box Q) desplegados en la ventana de sesión de Minitab se examinarán en los ejemplos 3.2 y 3.3. Los patrones en un correlograma se usan para analizar las características clave de los datos, un concepto que se estudia en la siguiente sección. El software Minitab (para instrucciones específicas, véase la sección de aplicaciones de Minitab al final del capítulo) puede usarse para calcular autocorrelaciones y desarrollar correlogramas.

Un *correlograma* o *función de autocorrelación* es una gráfica de las autocorrelaciones para varios retrasos de una serie de tiempo.




FIGURA 3-5 Correlograma o función de autocorrelación de los datos usados para el ejemplo 3.1

Con una pantalla como la de la figura 3-5, se estudian los patrones de datos incluyendo la tendencia y la estacionalidad. Los coeficientes de autocorrelación para diferentes retrasos de tiempo de una variable pueden usarse para contestar las siguientes preguntas acerca de una serie de tiempo:

1. ¿Los datos son aleatorios?
2. ¿Los datos muestran una tendencia (son no estacionarios)?
3. ¿Los datos son estacionarios?
4. ¿Los datos son estacionales?

Si una serie es aleatoria, las autocorrelaciones entre Y_t y Y_{t-k} para cualquier retraso de tiempo k son cercanas a cero. Los valores sucesivos de una serie de tiempo no están relacionados entre sí.

Si una serie muestra una tendencia, las observaciones sucesivas están altamente correlacionadas y es típico que los coeficientes de correlación sean significativamente diferentes de cero, para los primeros retrasos de tiempo, y de forma gradual tienden a cero conforme se incrementa el número de retrasos. El coeficiente de autocorrelación para un retraso de tiempo 1 a menudo será muy grande (cercano a 1). También el coeficiente de autocorrelación para el retraso de tiempo 2 será grande. Sin embargo, no será tan grande como para el retraso de tiempo 1.

Si una serie tiene un patrón estacional, se presentará un coeficiente de autocorrelación significativo en el retraso de tiempo estacional o en los múltiplos del retraso estacional. El retraso estacional se considera de 4 para datos trimestrales y 12 para datos mensuales.

¿Cómo determina un analista si un coeficiente de autocorrelación es significativamente diferente de cero para los datos de la tabla 3-1? Quenouille (1949) y otros han demostrado que los coeficientes de autocorrelación de datos aleatorios tienen una distribución muestral que puede aproximarse mediante una curva normal, con una media de cero y una desviación estándar aproximada de $1/\sqrt{n}$. Sabiendo esto, el analista compara los coeficientes de autocorrelación de la muestra, con esta distribución teórica de la muestra y determinar si, para retrasos de tiempo dados, provienen de una población cuya media sea cero.

En realidad, algunos paquetes de software usan una fórmula ligeramente diferente, como se indica en la ecuación 3.2, para calcular las desviaciones estándar (o errores estándar) de los coeficientes de autocorrelación. Esta fórmula supone que cualquier autocorrelación antes del retraso de tiempo k es diferente de cero, y que cualquier autocorrelación anterior al retraso k es cero. Para una autocorrelación en el retraso 1, se utiliza el error estándar $1/\sqrt{n}$.

$$SE(r_k) = \sqrt{\frac{1 + 2 \sum_{i=1}^{k-1} r_i^2}{n}} \quad (3.2)$$

donde

$SE(r_k)$ = error estándar (desviación estándar estimada) de la autocorrelación en retraso k

r_i = la autocorrelación en el retraso i

k = retraso de tiempo

n = el número de observaciones en la serie de tiempo

Este cálculo se demostrará en el ejemplo 3.2. Si la serie es verdaderamente aleatoria, casi todos los coeficientes de autocorrelación de la muestra deberían estar dentro de un rango especificado por cero, más o menos cierto número de errores estándar. En un nivel de confianza específico, una serie puede considerarse aleatoria, si cada uno de los coeficientes de autocorrelación calculados se encuentra dentro del intervalo alrededor de 0, definido por $0 \pm t \times SE(r_k)$, donde el multiplicador t es un punto porcentual adecuado de una distribución t .

Si bien es útil cada prueba de r_k para saber si, en lo individual, es significativamente diferente de 0, también es recomendable examinar un conjunto de r_k consecutivos, como un grupo. Podemos usar una prueba de conjunto para ver si, por ejemplo, de los primeros 10 valores de r_k son significativamente diferentes de un conjunto donde los 10 valores son cero.

Una prueba de baúl común es el estadístico modificado Q de Ljung-Box (ecuación 3.3). Esta prueba se aplica usualmente a los residuos de un modelo de pronóstico. Si las autocorrelaciones se calculan mediante un proceso aleatorio (o de ruido blanco), el estadístico Q tiene una distribución chi cuadrada con m grados de libertad (el número de retrasos de tiempo por probar). Sin embargo, para los residuos de un modelo de pronóstico, el estadístico Q tiene una distribución chi cuadrada, con m grados de libertad menos el número de parámetros estimados en el modelo. El valor del estadístico Q puede compararse con la tabla de chi cuadrada (tabla B-4), para determinar si es mayor de lo que esperaríamos que fuera, con la hipótesis nula de que todas las autocorrelaciones en el conjunto son cero. Alternativamente, el valor p generado por el estadístico de prueba Q puede ser calculado e interpretado. El estadístico Q está dado por la ecuación 3.3 y se demuestra en el ejemplo 3.3.

$$Q = n(n + 2) \sum_{k=1}^m \frac{r_k^2}{n - k} \quad (3.3)$$

donde

n = número de observaciones en la serie de tiempo

k = retraso de tiempo

m = número de retrasos de tiempo que se van a probar

r_k = la función de autocorrelación muestral de los residuos atrasados k periodos

¿Los datos son aleatorios?

Un modelo aleatorio simple, a menudo llamado *modelo de ruido blanco*, está representado por la ecuación 3.4. La observación Y_t se compone de dos partes: c , el nivel general; y ε_t , el componente de error aleatorio. Es importante advertir que se supone que el componente ε_t no está correlacionado de un periodo a otro.

$$Y_t = c + \varepsilon_t \quad (3.4)$$

¿Los datos de la tabla 3-1 son consistentes con este modelo? Este punto se explorará en los ejemplos 3.2 y 3.3.

Ejemplo 3.2

Se desarrolla una prueba de hipótesis para determinar si un coeficiente de autocorrelación específico es significativamente diferente de cero, para el correlograma de la figura 3-5. Las hipótesis nula y alternativa para la prueba de significancia del coeficiente de autocorrelación de la población del retraso 1 son:

$$H_0: \rho_1 = 0$$

$$H_1: \rho_1 \neq 0$$

Si la hipótesis nula es verdadera, el estadístico de prueba

$$t = \frac{r_1 - \rho_1}{SE(r_1)} = \frac{r_1 - 0}{SE(r_1)} = \frac{r_1}{SE(r_1)} \quad (3.5)$$

tiene una distribución t con $df = n - 1$. Donde, $n - 1 = 12 - 1 = 11$, entonces, para un nivel de significancia de 5%, la regla de decisión es como sigue:

Si $t < -2.2$, o bien, $t > 2.2$ rechace H_0 y concluya que la autocorrelación del retraso 1 es significativamente diferente de 0.

Los valores críticos ± 2.2 son los puntos .025 superior e inferior, de una distribución t con 11 grados de libertad. El error estándar de r_1 es $SE(r_1) = \sqrt{1/12} = \sqrt{.083} = .289$, y el valor del estadístico de prueba se convierte en

$$t = \frac{r_1}{SE(r_1)} = \frac{.572}{.289} = 1.98$$

Con la anterior regla de decisión, no puede rechazarse $H_0: \rho_1 = 0$ ya que $-2.2 < 1.98 < 2.2$. Observe que el valor de nuestro estadístico de prueba, $t = 1.98$, es el mismo que la cantidad del renglón de retraso 1, debajo de la T en el resultado de Minitab en la figura 3-5. Los valores T en la figura de Minitab son simplemente los valores del estadístico de prueba al realizar la prueba para la autocorrelación igual a 0 en los diferentes retrasos.

Para la prueba de autocorrelación cero en el retraso de tiempo 2, consideramos

$$\begin{aligned} H_0: \rho_2 &= 0 \\ H_1: \rho_2 &\neq 0 \end{aligned}$$

Y el estadístico de prueba

$$t = \frac{r_2 - \rho_2}{SE(r_2)} = \frac{r_2 - 0}{SE(r_2)} = \frac{r_2}{SE(r_2)}$$

Usando la ecuación 3.2,

$$SE(r_2) = \sqrt{\frac{1 + 2 \sum_{i=1}^{k-1} r_i^2}{n}} = \sqrt{\frac{1 + 2 \sum_{i=1}^{2-1} r_i^2}{n}} = \sqrt{\frac{1 + 2(.572)^2}{12}} = \sqrt{\frac{1.6544}{12}} = \sqrt{.138} = .371$$

y

$$t = \frac{.463}{.371} = 1.25$$

Este resultado coincide con el valor T para el retraso 2 en el resultado de Minitab de la figura 3-5.

Usando la anterior regla de decisión, $H_0: \rho_1 = 0$ no puede rechazarse con un nivel de 0.05, ya que $-2.2 < 1.25 < 2.2$. Una forma alternativa para verificar la autocorrelación significativa es construir, digamos, límites de confianza de 95% centrados en cero. Estos límites para los retrasos de tiempo 1 y 2 son como sigue:

$$\begin{aligned} \text{retraso 1: } 0 \pm t_{.025} \times SE(r_1) & \quad \text{o bien} \quad 0 \pm 2.2(.289) \rightarrow (-.636, .636) \\ \text{retraso 2: } 0 \pm t_{.025} \times SE(r_2) & \quad \text{o bien} \quad 0 \pm 2.2(.371) \rightarrow (-.816, .816) \end{aligned}$$

Está indicada una autocorrelación significativamente diferente de 0, siempre que un valor de r_k caiga fuera de los límites de confianza correspondientes. En la figura 3-5 se presentan los límites de confianza de 95%, representados con líneas punteadas, en la gráfica de la función de autocorrelación.

Ejemplo 3.3

Se usó Minitab para generar la serie de tiempo de 40 números de tres dígitos pseudoaleatorios presentados en la tabla 3-3. La figura 3-6 muestra una gráfica de la serie de tiempo con estos datos. Puesto que tales datos son aleatorios (independientes entre sí y todos de la misma población), las autocorrelaciones para todos los retrasos de tiempo, teóricamente, deberían ser iguales a cero. Por supuesto, los

TABLA 3-3 Serie de tiempo de 40 números aleatorios para el ejemplo 3.3

t	Y_t	t	Y_t	t	Y_t	t	Y_t
1	343	11	946	21	704	31	555
2	574	12	142	22	291	32	476
3	879	13	477	23	43	33	612
4	728	14	452	24	118	34	574
5	37	15	727	25	682	35	518
6	227	16	147	26	577	36	296
7	613	17	199	27	834	37	970
8	157	18	744	28	981	38	204
9	571	19	627	29	263	39	616
10	72	20	122	30	424	40	97

40 valores de la tabla 3-3 son sólo un conjunto, de 40 elementos, de un gran número de muestras posibles de tamaño 40. Cada muestra producirá autocorrelaciones diferentes. La mayoría de estas muestras producirán coeficientes de autocorrelación muestrales que estén cercanos a cero. No obstante, es posible que una muestra produzca un coeficiente de autocorrelación que sea significativamente diferente de cero, tan sólo por casualidad.

En seguida, usando Minitab, se construye la función de autocorrelación representada en la figura 3-7. Observe que las dos líneas punteadas indican los límites de confianza de 95%. Se examinan diez retrasos de tiempo y todos los coeficientes de autocorrelación individuales están dentro de estos límites. No hay razón para dudar de que cada una de las autocorrelaciones para los primeros 10 retrasos sea cero. Sin embargo, aun cuando las autocorrelaciones muestrales individuales no sean significativamente diferentes de cero, ¿las magnitudes de los primeros $10r_k$, consideradas como grupo, son mayores de lo que uno esperaría con la hipótesis de que no hay autocorrelación en ningún retraso? Esta pregunta la contesta el estadístico Q de Ljung-Box (LBQ en Minitab).

Si no hay autocorrelación en cualquiera de los retrasos, el estadístico Q tiene una distribución chi cuadrada con, en este caso, con $df = 10$. Como resultado, un valor grande para Q (un extremo de la distribución chi cuadrada) es evidencia contra la hipótesis nula. A partir la figura 3-7 vemos que el valor de Q (LBQ) para 10 retrasos de tiempo es 7.75. En la tabla B-4 observamos que el punto .05 más alto de una distribución chi cuadrada con 10 grados de libertad es 18.31. Puesto que $7.75 < 18.31$, no se puede rechazar la hipótesis nula con el nivel de significancia de 5%. Estos datos no están correlacionados en ningún retraso de tiempo, lo cual es consistente con el modelo de la ecuación 3.4.





FIGURA 3-6 Gráfica de serie de tiempo de 40 números aleatorios usados para el ejemplo 3.3

Función de autocorrelación: Yt

Retraso	ACF	T	LBQ
1	-0.191171	-1.21	1.57
2	-0.006293	-0.04	1.58
3	-0.145224	-0.89	2.53
4	0.104475	0.63	3.04
5	-0.253756	-1.50	6.13
6	0.028640	0.16	6.17
7	0.169071	0.95	7.63
8	-0.027390	-0.15	7.67
9	-0.032551	-0.18	7.73
10	0.021546	0.12	7.75

**FIGURA 3-7** Función de autocorrelación para los datos usados en el ejemplo 3.3

¿Los datos muestran una tendencia?

Si una serie muestra una tendencia, hay una relación significativa entre los valores sucesivos de la serie de tiempo. Los coeficientes de autocorrelación son usualmente grandes para varios de los primeros retrasos de tiempo y luego, conforme se incrementa el número de retrasos, caen gradualmente hacia cero.

Una serie de tiempo *estacionaria* es aquella cuyas propiedades estadísticas básicas, como la media y la varianza, permanecen constantes en el tiempo. Por lo tanto, se dice que una serie que varía alrededor de un nivel fijo (sin crecimiento ni decrecimiento) con el paso del tiempo es estacionaria. Se dice también que una serie que contiene una tendencia es *no estacionaria*. Los coeficientes de autocorrelación de una serie estacionaria decrecen hacia cero bastante rápidamente, por lo común después del segundo o tercer retraso de tiempo. Por otro lado, las autocorrelaciones muestrales de serie no estacionaria se permanecen muy grandes durante varios periodos. A menudo, para analizar la serie no estacionaria, se elimina la tendencia antes de aplicar cualquier modelo. Los procedimientos que se estudian en el capítulo 9 utilizan dicho enfoque.

Con frecuencia se utiliza un método llamado *diferencias* para eliminar la tendencia de una serie no estacionaria. Los datos de las VCR incluidos originalmente en la tabla 3-1 se presentan otra vez en la columna A de la figura 3-8. Los valores de Y_t , retrasados un periodo Y_{t-1} , se presentan en la columna B. Las diferencias de $Y_t - Y_{t-1}$ (columna A - columna B) se presentan en la columna C. Por ejemplo, el primer valor de las diferencias es $Y_2 - Y_1 = 130 - 123 = 7$. Observe el crecimiento o la tendencia de los datos de las VCR presentados en la gráfica A de la figura 3-9. Ahora observe el patrón estacionario de los datos diferenciados en la gráfica B de la figura 3-9. La diferencia de los datos elimina la tendencia.

Ejemplo 3.4

A Maggie Trymane, una analista de Sears, se le asignó la tarea de pronosticar los ingresos operativos para 2005. Ella reúne los datos de los años 1955 a 2004, que se muestran en la tabla 3-4. Los datos se grafican como una serie de tiempo en la figura 3-10. Observe que, si bien los ingresos operativos de Sears estuvieron decreciendo durante el periodo 2000 a 2004, la tendencia general durante el periodo completo 1955 a 2004 fue hacia arriba. Primero, Maggie calcula un intervalo de confianza de 95% para los coeficientes de autocorrelación para un retraso de tiempo 1, usando $0 \pm Z_{.025}(1/\sqrt{n})$ donde, para muestras grandes, la distribución normal estándar correspondiente a .025 se ha sustituido a la distribución t correspondiente:

$$0 \pm 1.96(\sqrt{1/50})$$

$$0 \pm .277$$

Después, Maggie corre los datos en Minitab y obtiene la función de autocorrelación que se presenta en la figura 3-11. Durante la revisión, se observa que las autocorrelaciones para los primeros cua-

Microsoft Excel - Book1

File Edit View Insert Format Tools Data Window Help

Arial 10 B I U

C3 =A3-B3

	A	B	C	D	E	F	G	H	I	J
1	Yt	Yt-1	Differences							
2	123									
3	130	123	7							
4	125	130	-5							
5	138	125	13							
6	145	138	7							
7	142	145	-3							
8	141	142	-1							
9	146	141	5							
10	147	146	1							
11	157	147	10							
12	150	157	-7							
13	160	150	10							
14										
15										
16										
17										
18										
19										
20										

FIGURA 3-8 Resultados de Excel de la diferenciación de los datos de las VCR para el ejemplo 3.1




FIGURA 3-9 Gráficas de series de tiempo de los datos de las VCR y los datos diferenciados de las VCR para el ejemplo 3.1

TABLA 3-4 Ingresos operativos anuales de Sears, 1955 a 2004, para el ejemplo 3.4

Año	Y_t	Año	Y_t	Año	Y_t	Año	Y_t	Año	Y_t
1955	3,307	1967	7,296	1979	17,514	1991	57,242	2003	23,253
1956	3,556	1968	8,178	1980	25,195	1992	52,345	2004	19,701
1957	3,601	1969	8,844	1981	27,357	1993	50,838		
1958	3,721	1970	9,251	1982	30,020	1994	54,559		
1959	4,036	1971	10,006	1983	35,883	1995	34,925		
1960	4,134	1972	10,991	1984	38,828	1996	38,236		
1961	4,268	1973	12,306	1985	40,715	1997	41,296		
1962	4,578	1974	13,101	1986	44,282	1998	41,322		
1963	5,093	1975	13,639	1987	48,440	1999	41,071		
1964	5,716	1976	14,950	1988	50,251	2000	40,937		
1965	6,357	1977	17,224	1989	53,794	2001	36,151		
1966	6,769	1978	17,946	1990	55,972	2002	30,762		

Fuente: Industry Surveys, varios años.

**FIGURA 3-10 Gráficas de series de tiempo de los ingresos operativos de Sears para el ejemplo 3.4**

tro retrasos de tiempo son significativamente diferentes de cero (.96, .92, .87 y .81) y que luego los valores tienden gradualmente hacia cero. Finalmente, Maggie mira el estadístico Q para 10 retrasos de tiempo. El LBQ es 300.56, el cual es mayor que el valor 18.3 de chi cuadrada (el punto .05 superior de una distribución chi cuadrada con 10 grados de libertad). Este resultado indica que las autocorrelaciones para los primeros 10 retrasos como grupo son significativamente diferentes de cero. Ella decide que los datos están altamente autocorrelacionados y que muestran una tendencia en su comportamiento.

Maggie sospecha que las series pueden diferenciarse para eliminar la tendencia y crear una serie estacionaria. Luego diferencia los datos (véase la sección de aplicaciones de Minitab al final del capítulo), y los resultados se presentan en la figura 3-12. Las series diferenciadas no presentan evidencia de alguna tendencia, en tanto que la función de autocorrelación de la figura 3-13 parece apoyar esta conclusión. Examinando la figura 3-13, Maggie observa que el coeficiente de autocorrelación en el retraso de tiempo 3, .32, es significativamente diferente de cero (probado al nivel de significancia .05). Las autocorrelaciones de los retrasos diferentes del retraso 3 son pequeñas, mientras que la del estadístico LBQ para un retraso 10 también es relativamente pequeña, de manera que hay una pequeña evidencia que sugiere que los datos diferenciados están autocorrelacionados. Todavía Maggie se pregunta si existe algún patrón en estos datos, que pueda modelarse con una de las técnicas más avanzadas como las que se estudian en el capítulo 9.




FIGURA 3-11 Función de autocorrelación de ingresos operativos de Sears para el ejemplo 3.4




FIGURA 3-12 Gráfica de serie de tiempo de las primeras diferencias de los ingresos operativos de Sears para el ejemplo 3.4




FIGURA 3-13 Función de autocorrelación para las primeras diferencias de los ingresos operativos de Sears para el ejemplo 3.4

TABLA 3-5 Ventas trimestrales de Coastal Marine, 1994-2006, para el ejemplo 3-5

<i>Año fiscal</i>	<i>Diciembre 31</i>	<i>Marzo 31</i>	<i>Junio 30</i>	<i>Septiembre 30</i>
1994	147.6	251.8	273.1	249.1
1995	139.3	221.2	260.2	259.5
1996	140.5	245.5	298.8	287.0
1997	168.8	322.6	393.5	404.3
1998	259.7	401.1	464.6	479.7
1999	264.4	402.6	411.3	385.9
2000	232.7	309.2	310.7	293.0
2001	205.1	234.4	285.4	258.7
2002	193.2	263.7	292.5	315.2
2003	178.3	274.5	295.4	286.4
2004	190.8	263.5	318.8	305.5
2005	242.6	318.8	329.6	338.2
2006	232.1	285.6	291.0	281.4

¿Los datos son estacionales?

Si una serie es estacional, un patrón relacionado con el calendario se repite a sí mismo durante un intervalo de tiempo específico (generalmente un año). Las observaciones de la misma posición, en diferentes periodos estacionales, tienden a estar relacionadas. Si se analizan datos trimestrales que tienen un patrón estacional, los primeros trimestres tienden a parecerse, los segundos trimestres tienden a parecerse, y así sucesivamente, y habrá un coeficiente de autocorrelación significativo en el retraso de tiempo 4. Si se analizan datos mensuales, aparecerá un coeficiente de autocorrelación significativo en el retraso de tiempo 12. Es decir, enero se correlacionará con otros enero, febrero se correlacionará con otros febreros y así sucesivamente. En el ejemplo 3.5 se analiza una serie que es estacional.

Ejemplo 3.5

Perkin Kendell es un analista de Coastal Marine Corporation. Él siempre ha creído que las ventas son estacionales. Perkin reúne los datos presentados en la tabla 3-5 de las ventas trimestrales de Coastal Marine Corporation, de 1994 a 2006, y los grafica como una serie de tiempo como la presentada en la figura 3-14. Después, calcula un intervalo de confianza de 95% para una muestra grande con el coeficiente de autocorrelación en el retraso de tiempo 1:

$$0 \pm 1.96\sqrt{1/52}$$

$$0 \pm .272$$

Luego, Perkin calcula los coeficientes de autocorrelación presentados en la figura 3-15. Él nota que los coeficientes de autocorrelación en los retrasos de tiempo 1 y 4 son significativamente diferentes de cero ($r_1 = .39 > .272$ y $r_4 = .74 > .333$). Concluye que las ventas de Coastal Marine son estacionales, sobre una base trimestral.

SELECCIÓN DE UNA TÉCNICA DE PRONÓSTICOS

En su mayor parte, este libro está dedicado a la explicación de varias técnicas de elaboración de pronósticos y a la demostración de su utilidad. Primero se examina el valioso trabajo de seleccionar, entre varias, una técnica de elaboración de pronósticos.

Veamos algunas de las preguntas que deben considerarse, antes de decidir sobre la técnica más adecuada para la elaboración del pronóstico de un problema específico:

- ¿Por qué es necesario un pronóstico?
- ¿Quién usará el pronóstico?




FIGURA 3-14 Gráfica de serie de tiempo de las ventas trimestrales de Coastal Marine para el ejemplo 3.5

Función de autocorrelación: Ventas

Retraso	ACF	T	LBQ
1	0.392861	2.83	8.50
2	0.153945	0.97	9.83
3	0.293782	1.82	14.77
4	0.743520	4.34	47.11
5	0.150655	0.67	48.47
6	-0.153008	-0.67	49.90
7	-0.046978	-0.21	50.04
8	0.346975	1.51	57.72
9	-0.182601	-0.76	59.90
10	-0.434729	-1.80	72.53
11	-0.315031	-1.23	79.33
12	0.091203	0.35	79.91
13	-0.353274	-1.34	88.90




FIGURA 3-15 Función de autocorrelación de las ventas trimestrales de Coastal Marine para el ejemplo 3.5

- ¿Cuáles son las características de los datos disponibles?
- ¿Qué periodo se va pronosticar?
- ¿Cuáles son los requerimientos mínimos de datos?
- ¿Qué precisión se desea?
- ¿Cuánto costará el pronóstico?

Para elegir acertadamente la técnica de pronóstico, el pronosticador debe hacer lo siguiente:

- Definir la naturaleza del problema que se va a pronosticar.
- Explicar la naturaleza de los datos en investigación.
- Describir las capacidades y limitaciones de las técnicas de elaboración de pronósticos potencialmente útiles.
- Desarrollar algún criterio predeterminado, con el cual se pueda tomar la decisión.

Un factor importante que influye en la selección de la técnica de elaboración del pronóstico es la identificación y comprensión de patrones históricos en los datos. Si se pueden recono-

cer patrones de tendencia, cíclicos o estacionales, entonces se deben seleccionar las técnicas que sean capaces de extrapolar efectivamente tales patrones.

Técnicas de pronósticos para datos estacionarios

Se definió antes una serie *estacionaria* como aquella cuyo valor medio no cambia con el paso del tiempo. Tales situaciones surgen cuando los patrones de demanda que influyen en las series son relativamente estables. Es importante reconocer que los datos estacionarios no necesariamente varían de manera aleatoria alrededor de un nivel medio. Las series estacionarias pueden estar autocorrelacionadas; sin embargo, la naturaleza de la asociación es tal que los datos no se alejan de la media para cualquier periodo ampliado. En su forma más simple, el pronóstico de una serie estacionaria implica el uso de la historia disponible de la serie para estimar su valor medio, el cual se convierte así en el pronóstico de futuros periodos. Las técnicas más avanzadas implican actualizar la historia disponible de la serie para estimar su valor medio, lo que a su vez se convierte en el pronóstico de periodos futuros. Los pronósticos pueden actualizarse conforme se dispone de nueva información. La actualización es útil cuando las estimaciones iniciales no son confiables, o cuando se cuestiona la estabilidad del promedio. En este último caso, la actualización brinda algún grado de sensibilidad a los cambios potenciales en la estructura subyacente de la serie.

Las técnicas de pronósticos estacionarias se usan en las siguientes circunstancias:

- *Los factores que generan una serie se han estabilizado, y el ambiente en el cual existe la serie permanece relativamente sin cambios.* Algunos ejemplos son el número de interrupciones semanales de una línea de ensamble que tiene una tasa de producción uniforme, las unidades vendidas de un producto o servicio en la etapa de maduración de su ciclo de vida y el número de ventas resultantes de un nivel de esfuerzo constante.
- *Se necesita un modelo muy simple debido a la falta de datos para la explicación o implementación.* Un ejemplo se presenta cuando un negocio u organización es nuevo, y hay muy poca información histórica disponible.
- *La estabilidad puede obtenerse haciendo correcciones sencillas de factores tales como crecimiento demográfico o la inflación.* Algunos ejemplos son el cambio del ingreso por el ingreso per capita, y el cambio de ventas en dólares por cantidades constantes en dólares.
- *La serie puede convertirse en una serie estable.* Algunos ejemplos son la transformación de una serie mediante el uso de logaritmos, raíces cuadradas o diferencias.
- *La serie es un grupo de errores de pronóstico de una técnica de elaboración del pronóstico que se considera adecuada.* (Véase el ejemplo 3.7 de la p. 85).

Las técnicas que deben considerarse en la elaboración de pronósticos de serie estacionaria incluyen métodos informales, métodos de promedio simple, promedio móvil y modelos autorregresivos de promedio móvil (ARMA) así como los modelos de Box-Jenkins.

Técnicas de pronósticos para datos con una tendencia

En palabras sencillas, en una serie de tiempo una *tendencia* es un crecimiento o decrecimiento persistente de larga duración. Para una serie de tiempo con tendencia, el nivel de la serie no es constante. Es común que las series de tiempo de economía muestren una tendencia.

Las técnicas de pronóstico para datos con tendencia se usan en las siguientes circunstancias:

- *Un incremento en la productividad y nueva tecnología traen consigo cambios en el estilo de vida.* Algunos ejemplos son las demandas de componentes electrónicos, las cuales aumentaron con la llegada de las computadoras, y el uso del ferrocarril, el cual disminuyó con la aparición del avión.
- *Un incremento de la población causa aumentos en la demanda de bienes y servicios.* Ejemplos de esto son los ingresos por ventas de bienes de consumo, demanda de consumo de energía y uso de materias primas.
- *El poder de compra de la moneda afecta las variables económicas debido a la inflación.* Son ejemplos los salarios, los costos de producción y los precios.
- *Incremento de aceptación en el mercado.* Un ejemplo es el periodo de crecimiento en el ciclo de vida de un producto nuevo.

Las técnicas que deberían considerarse en el pronóstico de series con tendencia incluyen modelos de promedios móviles, de suavizamiento exponencial lineal de Holt, de regresión simple, de curvas de crecimiento, los modelos exponenciales y los modelos autorregresivos integrados de promedio móvil (ARIMA)(métodos de Box-Jenkins).

Técnicas de pronósticos para datos estacionales

Con anterioridad se definió una serie *estacional* como una serie de tiempo con un patrón de cambio que se repite a sí mismo año tras año. Una forma de desarrollar pronósticos estacionales es estimar índices estacionales de la historia de la serie. Por ejemplo, en datos mensuales, hay un índice para enero, un índice para febrero, y así sucesivamente. Estos índices se utilizan después para incluir la estacionalidad en los pronósticos o para eliminar tales efectos de los valores observados. El proceso que sigue se conoce como un ajuste de la estacionalidad de los datos y se analiza junto con los métodos de descomposición de la serie de tiempo en el capítulo 5.

Las técnicas para la elaboración de pronósticos con datos estacionales se usan en las siguientes circunstancias:

- *El clima influye en la variable de interés.* Ejemplos son el consumo eléctrico, las actividades de verano e invierno (por ejemplo, deportes como el esquí), el vestido y buenas temporadas en la agricultura.
- *El calendario anual influye en la variable de interés.* Son ejemplos las ventas al menudeo influidas por las vacaciones, fines de semana de tres días y calendarios académicos.

Las técnicas que deberían considerarse cuando se elaboren pronósticos con series estacionales incluyen modelos de descomposición clásica, Census *X*-12, suavizamiento exponencial de Winter, regresión múltiple y ARIMA (métodos de Box-Jenkins).

Técnicas de pronósticos para series cíclicas

El efecto cíclico se definió antes como la fluctuación con forma de onda alrededor de una tendencia. Los patrones cíclicos son difíciles de modelar porque sus patrones generalmente son inestables. Las fluctuaciones ondulatorias hacia arriba y hacia abajo de la tendencia rara vez se repiten en intervalos de tiempo fijos, en tanto que la magnitud de las variaciones también tiende a cambiar. Los métodos de descomposición (capítulo 5) pueden ampliarse para analizar los datos cíclicos. Sin embargo, debido al comportamiento irregular de los ciclos, el análisis del componente cíclico de una serie, si existe, a menudo requiere de la obtención de indicadores de coincidencia o indicadores económicos importantes.

Las técnicas para la elaboración de pronósticos con datos cíclicos se usan en las siguientes circunstancias:

- *El ciclo de negocios influye en la variable de interés.* Son ejemplos los factores económicos, de mercado y competitivos.
- *Ocurren cambios en el gusto popular.* Son ejemplos la moda, la música y la comida.
- *Sucedan cambios en la población.* Son ejemplos las guerras, las hambrunas, las epidemias y los desastres naturales.
- *Ocurren cambios en el ciclo de vida del producto.* Son ejemplos el lanzamiento, el crecimiento, la maduración, la saturación del mercado, y su declive.

Las técnicas que deberían considerarse cuando se elaboren pronósticos con series cíclicas incluyen la descomposición clásica, los indicadores de la economía, los modelos econométricos, la regresión múltiple y modelos ARIMA (métodos de Box-Jenkins).

Otros factores a considerar en la selección de una técnica de pronóstico

El horizonte de tiempo de un pronóstico tiene una relación directa con la selección de la técnica para pronosticar. En pronósticos de corto y mediano plazos, se puede aplicar una gama de técnicas cuantitativas. Sin embargo, conforme aumenta el horizonte del pronóstico, varias de estas técnicas se vuelven menos adecuadas. Por ejemplo, los modelos de promedios móviles, suavizamiento exponencial y ARIMA son pronosticadores deficientes de los cambios económicos drásticos;

mientras que los modelos econométricos resultan más útiles. Los modelos de regresión son apropiados para el corto, el mediano y el largo plazos. Las medias, los promedios móviles, la descomposición clásica y las proyecciones de la tendencia son técnicas cuantitativas adecuadas para horizontes de tiempo de corto y mediano plazos. Las técnicas más complejas de Box-Jenkins y econométricas también son recomendables para pronósticos de corto y mediano plazos. Los métodos cualitativos se usan a menudo para los horizontes de tiempo más largos (véase el capítulo 10).

La aplicabilidad de las técnicas de elaboración del pronóstico es algo que generalmente el pronosticador determina con base en la experiencia. Los gerentes frecuentemente necesitan pronósticos para un tiempo relativamente corto. Los métodos de suavizamiento exponencial, proyección de tendencia, modelos de regresión y descomposición clásica tienen una ventaja en esta situación (véase la tabla 3-6).

Los costos asociados con el uso de la computadora ya no son parte importante en la selección de una técnica. Las computadoras de escritorio (microprocesadores) y los paquetes de software para elaboración de pronósticos se han convertido en un lugar común en muchas organizaciones. Gracias a estos desarrollos, probablemente otros criterios minimizarán las consideraciones del costo informático.

A final de cuentas, el pronóstico se presentará a la gerencia para su aprobación y uso en el proceso de planeación. Por lo tanto, una fácil comprensión e interpretación de los resultados es una consideración importante. Los modelos de regresión, la proyección de tendencias, la descomposición clásica y las técnicas de suavizamiento exponencial, todas obtienen una calificación alta en dicho criterio.

Es importante señalar que la información presentada en la tabla 3-6 debería usarse como una guía para la selección de una técnica de elaboración de pronósticos. Es buena práctica

TABLA 3-6 Selección de una técnica de pronósticos

<i>Método</i>	<i>Patrón de datos</i>	<i>Horizonte de tiempo</i>	<i>Tipo del modelo</i>	<i>Datos mínimos requeridos</i>	
				<i>No estacionales</i>	<i>Estacionales</i>
Simple	ST, T, S	S	TS	1	
Promedios simples	ST	S	TS	30	
Promedios móviles	ST	S	TS	4–20	
Suavizamiento exponencial	ST	S	TS	2	
Suavizamiento exponencial lineal	T	S	TS	3	
Suavizamiento exponencial cuadrático	T	S	TS	4	
Suavizamiento exponencial estacional	S	S	TS		2 × s
Filtración adaptativa	S	S	TS		
Regresión simple	T	I	C	10	
Regresión múltiple	C, S	I	C	10 × V	
Descomposición clásica	S	S	TS		5 × s
Modelos de tendencia exponencial	T	I, L	TS	10	
Ajuste de la curva <i>S</i>	T	I, L	TS	10	
Modelos de Gompertz	T	I, L	TS	10	
Curvas de crecimiento	T	I, L	TS	10	
Census <i>X</i> -12	S	S	TS		6 × s
Box-Jenkins	ST, T, C, S	S	TS	24	3 × s
Indicadores principales	C	S	C	24	
Modelos econométricos	C	S	C	30	
Regresión múltiple de series de tiempo	T, S	I, L	C		6 × s

Patrón de datos: ST, estacionario; T, de tendencia; S, estacional; C, cíclico

Horizonte de tiempo: S, corto plazo (menos de tres meses); I, mediano plazo; L, largo plazo

Tipo de modelo: TS, serie de tiempo; C, causal

Estacional: S, longitud de la estacionalidad

Variable: V, número de variables

intentar más de un método para la elaboración del pronóstico de un problema específico, dejando fuera algunos datos recientes y luego calcular los pronósticos de estas observaciones excluidas, usando métodos diferentes. La efectividad de los métodos para estos casos de prueba excluidos puede determinarse usando una o más de las medidas de precisión definidas en las ecuaciones 3-7 a 3-11, que se estudian más adelante. Suponiendo un ajuste de los datos adecuado, el método más exacto (aquel con el menor error de pronóstico) es una selección razonable para “mejor” método. Aunque quizá no sea el mejor método en la siguiente situación.

Evaluación empírica de métodos para pronosticar

La investigación empírica ha encontrado que la exactitud en el pronóstico de los métodos sencillos a menudo es tan buena como la de las técnicas avanzadas o estadísticamente complejas (véase Fildes y otros, 1997; Makridakis y otros, 1993; y Makridakis y Hibon, 2000). Los resultados de M3-IJF Competition, donde diferentes expertos usaron su metodología favorita para pronosticar y obtuvieron cada uno pronósticos para 3,003 series de tiempo diferentes, tendieron a apoyar este hallazgo (Makridakis y Hibon, 2000). Parecería que cuanto más compleja es una técnica estadística, mejor debería predecir patrones de series de tiempo. Por desgracia, los patrones establecidos en las series de tiempo pueden cambiar en el futuro. De modo que tener el modelo que mejor represente los datos históricos (algo que los métodos complejos hacen bien) no necesariamente garantiza mayor exactitud en las predicciones del futuro. Por supuesto, la habilidad del pronosticador también desempeña un papel importante en el desarrollo de un buen pronóstico.

La M3-IJF Competition se realizó en 1997. Los pronósticos obtenidos con diferentes técnicas se compararon en toda la muestra de 3,003 series de tiempo, evaluando la exactitud con diversas medidas de error. La finalidad del estudio de 1997 fue verificar las cuatro conclusiones principales de la M-Competition original, sobre un conjunto de datos más grande (véase Makridakis y otros, 1982). Makridakis y Hibon (2000) resumieron la última competencia como sigue:

1. Al igual que en un estudio previo, los métodos avanzados o estadísticamente complejos no necesariamente dan como resultado pronósticos más precisos, que los métodos más simples.
2. Diferentes medidas de precisión producen resultados consistentes cuando se usan para evaluar diferentes métodos de elaboración de pronósticos.
3. La combinación de tres métodos de suavizamiento exponencial supera, en promedio, los métodos individuales que se combinan y funcionan bien en comparación con otros métodos.
4. La efectividad de los diferentes métodos de elaboración de pronósticos depende de la longitud del horizonte del pronóstico y la clase de datos (anuales, trimestrales, mensuales) que se analizan. Algunos métodos funcionan con más exactitud para horizontes cortos, en tanto que otros son más adecuados para los horizontes más grandes. Algunos métodos funcionan mejor con datos anuales y otros son más apropiados para datos trimestrales y mensuales.

Como parte de la selección final, cada técnica debe evaluarse en términos de su confiabilidad y aplicabilidad al problema que tenemos, de su eficiencia de costos y exactitud comparadas con técnicas similares, así como de su aceptación por parte de la gerencia. La tabla 3-6 resume las técnicas de elaboración de pronósticos adecuadas para patrones de datos específicos. Como señalamos, esta tabla representa un punto de inicio, es decir, métodos a tomar en cuenta —para datos con ciertas características. Finalmente, cualquier método seleccionado debería supervisarse continuamente para asegurarse de que hace adecuadamente el trabajo para el cual se aplica.

MEDICIÓN DEL ERROR DE PRONÓSTICO

Debido a que las técnicas cuantitativas de elaboración de pronósticos a menudo incluyen datos de series de tiempo, se desarrolló una notación matemática para referirse a cada periodo específico. La letra Y se usa para representar una variable de serie de tiempo, a menos que haya

más de una variable. El periodo asociado con una observación se identifica como un subíndice. De modo que Y_t se refiere al valor de la serie de tiempo en el periodo t . Los datos trimestrales para Coastal Marine Corporation presentados en el ejemplo 3.5 (véase la p. 76) se escribirían como $Y_1 = 147.6$, $Y_2 = 251.8$, $Y_3 = 273.1$, ..., $Y_{52} = 281.4$.

También debe desarrollarse notación matemática para distinguir entre un valor real de la serie de tiempo y el valor del pronóstico. Un símbolo $\hat{}$ (sombrero) se coloca arriba de un valor para indicar que se trata del pronóstico. El valor del pronóstico para Y_t es $\hat{Y}_t$. La exactitud de una técnica para la elaboración de un pronóstico a menudo se juzga por la comparación entre las series originales $Y_1, Y_2, \dots$, y los valores pronosticados de las series, $\hat{Y}_1, \hat{Y}_2, \dots$.

La notación básica para pronósticos se resume de la siguiente manera:

Y_t = valor de una serie de tiempo en el periodo t

$\hat{Y}_t$ = valor pronosticado de Y_t

$e_t = Y_t - \hat{Y}_t$ = residuo o error de pronóstico

Hay varios métodos cuya finalidad es resumir los errores generados por una técnica específica de pronósticos. La mayoría de estas medidas son el promedio de alguna función de la diferencia entre su valor real y su valor pronosticado. Estas diferencias se conocen como residuos.

Un *residuo* es la diferencia entre un valor real observado y su valor de pronóstico.

La ecuación 3.6 se usa para calcular el error o residuo de cada periodo pronosticado.

$$e_t = Y_t - \hat{Y}_t \quad (3.6)$$

donde

e_t = error de pronóstico en el periodo t

Y_t = valor real en el periodo t

$\hat{Y}_t$ = valor del pronóstico en el periodo t

Un método para evaluar una técnica de pronósticos usa la suma de los errores absolutos. La desviación media absoluta (*MAD*) mide la exactitud del pronóstico, promediando las magnitudes de los errores del pronóstico (los valores absolutos de los errores). *MAD* está en las mismas unidades que la serie original, y proporciona un tamaño promedio de los “errores” sin importar la dirección. La ecuación 3.7 muestra cómo se calcula la *MAD*.

$$MAD = \frac{1}{n} \sum_{t=1}^n |Y_t - \hat{Y}_t| \quad (3.7)$$

El error cuadrático medio (*MSE*) es otro método para evaluar una técnica de elaboración de pronósticos. Cada error o residuo se eleva al cuadrado; luego éstos se suman y se dividen entre el número de observaciones. Este enfoque sanciona errores grandes en la elaboración de pronósticos, ya que los errores están elevados al cuadrado, lo cual es importante porque una técnica que produce errores moderados quizá sea preferible a una que usualmente tenga pequeños errores, pero ocasionalmente produce errores extremadamente grandes. El *MSE* está dado por la ecuación 3.8.

$$MSE = \frac{1}{n} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2 \quad (3.8)$$

La raíz cuadrada del *MSE*, o la raíz cuadrada del error cuadrado medio (*RMSE*), también se usa para evaluar los métodos de elaboración de pronósticos. Tanto la *RMSE* como la *MSE* sancio-

nan los errores grandes pero tienen las mismas unidades de la serie que se está pronosticando, de modo que su magnitud se interpreta con mayor facilidad. La *RMSE* se presenta a continuación.

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2} \quad (3.9)$$

A veces es más útil calcular los errores del pronóstico en términos de porcentajes en vez de cantidades. El error porcentual absoluto medio (*MAPE*) se calcula obteniendo el error absoluto de cada periodo, dividiendo éste entre el valor real observado en ese periodo y promediando estos errores porcentuales absolutos. El resultado final se multiplica después por 100 y se expresa como porcentaje. Este enfoque es útil cuando el error relativo al tamaño respectivo del valor de la serie de tiempo es importante, para la evaluación de la exactitud del pronóstico. El *MAPE* es especialmente útil cuando los valores Y_t son grandes. El *MAPE* no tiene unidades de medición (es un porcentaje) y sirve para comparar la exactitud de la misma técnica o de otras técnicas en dos series completamente diferentes. La ecuación 3.10 muestra cómo se calcula el *MAPE*.

$$MAPE = \frac{1}{n} \sum_{t=1}^n \frac{|Y_t - \hat{Y}_t|}{|Y_t|} \quad (3.10)$$

Note que el *MAPE* no puede calcularse si cualquiera de las Y_t es cero.

Algunas veces es necesario determinar si el método para pronosticar está sesgado (con pronósticos consistentemente altos o bajos). En estos casos, se usa el error porcentual medio (*MPE*), el cual se calcula obteniendo el error en cada periodo, dividiendo éste entre el valor real de ese periodo y luego promediando estos errores porcentuales. El resultado usualmente se multiplica por 100 y se expresa como un porcentaje. Si el enfoque del pronóstico no tiene sesgo, el *MPE* producirá un resultado que esté cercano a cero. Si el resultado es un porcentaje negativo grande, el método de elaboración del pronóstico está sobreestimando consistentemente. Si el resultado es un porcentaje positivo grande, el método de elaboración del pronóstico está subestimando consistentemente. El *MPE* está dado por:

$$MPE = \frac{1}{n} \sum_{t=1}^n \frac{(Y_t - \hat{Y}_t)}{Y_t} \quad (3.11)$$

La decisión para usar una técnica de elaboración de pronósticos específica se basa, en parte, en la determinación de si la técnica producirá errores en el pronóstico que se consideren lo suficientemente pequeños. En efecto, es realista esperar que una buena técnica de elaboración de pronósticos produzca errores relativamente pequeños de manera consistente.

Las cinco medidas de precisión de un pronóstico recientemente descritas son usadas para:

- Comparar la exactitud de dos (o más) técnicas diferentes.
- Medir la utilidad o confiabilidad de una técnica en particular.
- Ayudar en la búsqueda de una técnica óptima.

El ejemplo 3.6 ilustrará cómo se calcula cada una de estas mediciones del error.

Ejemplo 3.6

La tabla 3.7 presenta los datos del número diario de clientes que solicitan reparaciones, Y_t , y un pronóstico de tales datos, $\hat{Y}_t$, para la estación de servicio Chevron de Gary. La técnica de elaboración del pronóstico utilizó el número de clientes atendidos en el periodo anterior como el pronóstico para el periodo actual. Esta sencilla técnica se estudiará en el capítulo 4. Se emplearon los siguientes cálculos para evaluar este modelo usando *MAD*, *MSE*, *RMSE*, *MAPE* y *MPE*.

$$MAD = \frac{1}{n} \sum_{t=1}^n |Y_t - \hat{Y}_t| = \frac{34}{8} = 4.3$$

$$MSE = \frac{1}{n} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2 = \frac{188}{8} = 23.5$$

$$RMSE = \sqrt{MSE} = \sqrt{23.5} = 4.8$$

$$MAPE = \frac{1}{n} \sum_{t=1}^n \frac{|Y_t - \hat{Y}_t|}{Y_t} = \frac{.556}{8} = .0695 \text{ (6.95\%)}$$

$$MPE = \frac{1}{n} \sum_{t=1}^n \frac{(Y_t - \hat{Y}_t)}{Y_t} = \frac{.162}{8} = .0203 \text{ (2.03\%)}$$

TABLA 3-7 Datos usados en los cálculos para medir el error en el pronóstico del ejemplo 3.6

Tiempo t	Clientes Y_t	Pronóstico					
		$\hat{Y}_t$	Error e_t	$ e_t $	e_t^2	$ e_t /Y_t$	e_t/Y_t
1	58	—	—	—	—	—	—
2	54	58	-4	4	16	.074	-.074
3	60	54	6	6	36	.100	.100
4	55	60	-5	5	25	.091	-.091
5	62	55	7	7	49	.113	.113
6	62	62	0	0	0	.000	.000
7	65	62	3	3	9	.046	.046
8	63	65	-2	2	4	.032	-.032
9	70	63	7	7	49	.100	.100
Totales			12	34	188	.556	.162

La *MAD* indica que cada pronóstico está desviado un promedio de 4.3 clientes. El *MSE* de 23.5 (o la *RMSE* de 4.8) y el *MAPE* de 6.95% se compararían con el *MSE* (*RMSE*) y el *MAPE* de cualquier otro método usado para pronosticar esos datos. Finalmente, el pequeño *MPE* de 2.03% indica que la técnica no tiene sesgo: Puesto que el valor está cercano a cero, la técnica no sobreestima ni subestima consistentemente el número de clientes atendidos diariamente.

DETERMINACIÓN DE UNA TÉCNICA ADECUADA DE PRONÓSTICO

Antes de elaborar el pronóstico con una técnica particular, se debería evaluar lo adecuado de la elección. El pronosticador debe contestar las siguientes preguntas:

- ¿Los coeficientes de autocorrelación de los residuos son indicadores de una serie aleatoria? Esta pregunta puede contestarse examinando la función de autocorrelación para los residuos, tal como se presentó en el ejemplo 3.7.
- ¿La distribución de los residuos es aproximadamente normal? Esta pregunta puede contestarse analizando un histograma de los residuos o una gráfica de probabilidad normal.
- ¿Son significativas las estadísticas t para los valores estimados de los parámetros? La distribución t se revisó en el capítulo 2, y se presentan aplicaciones de las estadísticas t en el ejemplo 3.2 y en los capítulos 6 a 9.
- ¿Quiénes toman decisiones entienden la técnica y la emplean con facilidad?

El requisito básico de que el patrón residual sea aleatorio se verifica examinando los coeficientes de autocorrelación de los residuos. No debería haber coeficientes de autocorrelación significativos. El ejemplo 3.2 ilustra cómo los coeficientes de autocorrelación pueden usarse para determinar si una serie es aleatoria. El estadístico Q de Ljung-Box también se usa para

probar que las autocorrelaciones para todos los retrasos hasta el retraso K dado sean iguales a cero. El ejemplo 3.7 ilustra este procedimiento con los residuos de dos modelos ajustados.

Ejemplo 3.7

A Maggie Trimane, la analista de Sears, se le ha pedido el pronóstico de ventas para 2005. Los datos de 1995 a 2004 se presentan en la tabla 3-4. Primero, Maggie trata de pronosticar los datos usando un promedio móvil de cinco meses (véase el capítulo 4 para la descripción de esta técnica). Los residuos, las diferencias entre los valores reales y los valores pronosticados, se calculan y se guardan. Los coeficientes de autocorrelación para tales residuos se muestran en la figura 3-16. Un examen de estos coeficientes de autocorrelación indica que dos son significativamente diferentes de cero, $r_1 = .77$ y $r_2 = .58$. Los coeficientes de autocorrelación significativos indican alguna asociación o patrón en los residuos. Además, la función de autocorrelación misma tiene un patrón de coeficientes que declinan suavemente. Examinando las primeras 10 autocorrelaciones como un grupo, vemos que el estadístico Q para 10 retrasos es 73.90, mucho mayor que el valor 0.05 superior de una variable chi cuadrada, con 10 grados de libertad, 18.3. La hipótesis de que las primeras 10 autocorrelaciones son consistentes con aquéllas de una serie aleatoria se rechaza claramente para el nivel de 5%. Puesto que uno de los requisitos básicos de una buena técnica de pronósticos es que brinde un residuo o una serie de error que sea esencialmente aleatorio, Maggie juzga que la técnica del promedio móvil de cinco meses es inadecuada.

Ahora Maggie prueba con el suavizamiento exponencial lineal de Holt (véase el capítulo 4 para su descripción). La función de autocorrelación para la serie de residuos generada con esta técnica se presenta en la figura 3-17. Un examen de estos coeficientes de autocorrelación indica que ninguno es

Función de autocorrelación: Residuos MA

Retraso	ACF	T	LBQ
1	0.767355	5.15	28.30
2	0.577829	2.63	44.73
3	0.452556	1.80	55.04
4	0.302645	1.13	59.77
5	0.242298	0.88	62.87
6	0.260305	0.93	66.54
7	0.263140	0.92	70.40
8	0.213366	0.73	73.00
9	0.092468	0.31	73.50
10	-0.080688	-0.27	73.90




FIGURA 3-16 Función de autocorrelación para residuos con un patrón del ejemplo 3.7

Función de autocorrelación: Residuos Holt

Retraso	ACF	T	LBQ
1	-0.010799	-0.08	0.01
2	-0.045018	-0.32	0.12
3	0.180281	1.27	1.91
4	-0.104552	-0.71	2.53
5	-0.214739	-1.45	5.20
6	-0.031463	-0.20	5.25
7	0.113653	0.74	6.04
8	0.091499	0.59	6.55
9	0.003889	0.02	6.55
10	0.114144	0.73	7.40




FIGURA 3-17 Función de autocorrelación para residuos que son esencialmente aleatorios del ejemplo 3.7

significativamente diferente de cero (al nivel de 5%). También se examina el estadístico Q para 10 retrasos de tiempo. El valor LBQ de 7.40 en el resultado Minitab es menor que el valor .05 superior de una variable chi cuadrada, con ocho grados de libertad, 15.5. (En este caso, los grados de libertad son iguales al número de retrasos que se prueban, menos el número de parámetros en el modelo de suavización exponencial lineal que se ha ajustado a los datos). Como grupo, las primeras 10 autocorrelaciones residuales no son diferentes de aquellas de una serie completamente aleatoria. Maggie decide considerar la técnica de suavizamiento exponencial lineal de Holt, como un posible modelo para elaborar el pronóstico de los ingresos operativos para Sears en 2005.

APLICACIÓN EN LA ADMINISTRACIÓN

Los conceptos en este capítulo brindan una base para la selección de una técnica de elaboración de pronósticos adecuada en una situación dada. Muchas de las técnicas más importantes para pronosticar se analizan y aplican en las situaciones de pronósticos en los siguientes capítulos. Es importante observar que en muchas situaciones prácticas, más de un método o modelo para pronosticar puede dar como pronósticos aceptables y casi sin diferencias. De hecho, se recomienda intentar varias técnicas razonables para pronosticar. A menudo se debe usar un criterio con base en la facilidad de uso, el costo, las condiciones ambientales externas, etcétera, para elegir un conjunto de pronósticos específico de entre, digamos, dos conjuntos de valores casi sin diferencias.

Los siguientes son unos cuantos ejemplos de situaciones que se presentan constantemente en el mundo de los negocios, donde una buena técnica para elaboración de pronósticos ayudaría en el proceso de toma de decisiones:

- Una compañía de bebidas gaseosas quiere proyectar la demanda mensual de su principal producto durante los próximos dos años.
- Una compañía de telecomunicaciones líder quiere pronosticar los pagos de dividendos trimestrales de su principal competidor por los próximos tres años.
- Una universidad necesita pronosticar las horas-crédito trimestrales de los estudiantes por los siguientes cuatro años, para desarrollar proyecciones del presupuesto para la legislatura estatal.
- Una empresa de contabilidad pública necesita pronósticos mensuales de ingresos por facturación, de modo que pueda planear las vacantes contables e iniciar el reclutamiento.
- El gerente de control de calidad de una fábrica que produce perfiles de aluminio necesita un pronóstico semanal de los defectos de producción para la alta gerencia de la compañía.
- Un banquero quiere ver las proyecciones mensuales de ingresos de un pequeño fabricante de bicicletas, quien está solicitando un crédito grande para triplicar su capacidad de producción.
- Una institución del gobierno federal necesita proyecciones anuales del promedio de millas por galón de los automóviles hechos en Estados Unidos durante los próximos 10 años, para efectuar recomendaciones regulatorias.
- Un gerente de recursos humanos necesita un pronóstico mensual de días de ausentismo en la fuerza laboral de la compañía para planear los gastos por horas extras.
- Un negocio de préstamos y ahorro requiere un pronóstico de préstamos incobrables por los siguientes dos años, en un intento por evitar la bancarrota.
- Una compañía que fabrica chips para computadora necesita un pronóstico de la industria sobre el número de computadoras personales vendidas para los próximos 5 años, con la finalidad de planear su presupuesto de investigación y desarrollo.
- Una compañía de Internet necesita pronosticar las solicitudes de servicio por los siguientes seis meses, para elaborar planes de reclutamiento de personal para sus *call centers*.

Glosario

Autocorrelación. Es la correlación entre una variable atrasada uno o más periodos consigo misma.

Correlograma o función de autocorrelación. Es una gráfica de las autocorrelaciones para varios retrasos en una serie de tiempo.

Corte transversal. Son observaciones recopiladas en un único periodo de tiempo.

Componente cíclico. Es la fluctuación ondulatoria alrededor de la tendencia.

Residuo. Es la diferencia entre un valor real y su valor pronosticado.

Componente estacional. Es un patrón de cambio que se repite año tras año.

Serie estacionaria. Es aquella cuyas propiedades estadísticas básicas, como la media y la varianza, permanecen constantes a través del tiempo.

Serie de tiempo. Una serie de tiempo consiste en datos que se recolectan, se registran o se observan durante incrementos de tiempo sucesivos.

Tendencia. Es el componente de largo plazo que representa el crecimiento o el decrecimiento en la serie de tiempo durante un periodo largo.

Fórmulas clave

Coefficiente de autocorrelación de k -ésimo orden

$$r_k = \frac{\sum_{t=k+1}^n (Y_t - \bar{Y})(Y_{t-k} - \bar{Y})}{\sum_{t=1}^n (Y_t - \bar{Y})^2} \quad (3.1)$$

Error estándar del coeficiente de autocorrelación

$$SE(r_k) = \sqrt{\frac{1 + 2 \sum_{i=1}^{k-1} r_i^2}{n}} \quad (3.2)$$

Estadístico Q de Ljung-Box

$$Q = n(n+2) \sum_{k=1}^m \frac{r_k^2}{n-k} \quad (3.3)$$

Modelo aleatorio

$$Y_t = c + \varepsilon_t \quad (3.4)$$

Estadístico t para probar la significancia de la autocorrelación del retraso 1

$$t = \frac{r_1}{SE(r_1)} \quad (3.5)$$

Error de pronóstico o residuo

$$e_t = Y_t - \hat{Y}_t \quad (3.6)$$

Desviación media absoluta

$$MAD = \frac{1}{n} \sum_{t=1}^n |Y_t - \hat{Y}_t| \quad (3.7)$$

Error cuadrático medio

$$MSE = \frac{1}{n} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2 \quad (3.8)$$

Raíz cuadrada del error cuadrático medio

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2} \quad (3.9)$$

Error porcentual absoluto medio

$$MAPE = \frac{1}{n} \sum_{t=1}^n \frac{|Y_t - \hat{Y}_t|}{|Y_t|} \quad (3.10)$$

Error porcentual medio

$$MPE = \frac{1}{n} \sum_{t=1}^n \frac{(Y_t - \hat{Y}_t)}{Y_t} \quad (3.11)$$

Problemas

1. Explique las diferencias entre las técnicas de pronósticos cualitativas y cuantitativas.
2. ¿Qué es una serie de tiempo?
3. Describa cada uno de los componentes de una serie de tiempo.
4. ¿Qué es la autocorrelación?
5. ¿Qué mide un coeficiente de autocorrelación?
6. Explique cómo se usan los correlogramas para analizar las autocorrelaciones de varios retrasos de una serie de tiempo.
7. Indique si cada uno de los siguientes enunciados describe una serie estacionaria o una serie no estacionaria.
 - a) Una serie que muestra una tendencia
 - b) Una serie cuya media y varianza permanecen constantes en el tiempo
 - c) Una serie cuyo valor de la media cambia con el tiempo
 - d) Una serie que no tiene crecimiento ni decrecimiento
8. En seguida se presentan descripciones de varios tipos de series: aleatoria, estacionaria, de tendencia y estacional. Identifique el tipo de serie que describe cada inciso.
 - a) La serie tiene propiedades estadísticas básicas, como media y varianza, que permanecen constantes en el tiempo.
 - b) Los valores sucesivos de una serie de tiempo no están relacionados entre sí.
 - c) Existe una relación significativa entre cada valor sucesivo de una serie.

- d) Un coeficiente de autocorrelación significativo aparece en el retraso de tiempo 4 para datos trimestrales.
 - e) La serie no tiene crecimiento ni decrecimiento
 - f) En general, los coeficientes de autocorrelación son significativamente diferentes de cero, para varios de los primeros retrasos de tiempo y luego disminuyen gradualmente hacia cero, conforme se incrementa el número de retrasos.
9. Liste algunas de las técnicas de pronósticos que deban considerarse cuando se está pronosticando una serie estacionaria. Dé ejemplos de situaciones en que dichas técnicas serían aplicables.
 10. Liste algunas de las técnicas de pronósticos que deban considerarse cuando se está pronosticando una serie de tendencia. Mencione ejemplos de situaciones en que dichas técnicas serían aplicables.
 11. Liste algunas de las técnicas de pronósticos que deban considerarse cuando se está pronosticando una serie estacional. Mencione ejemplos de situaciones en que dichas técnicas serían aplicables.
 12. Liste algunas de las técnicas de pronósticos que deban considerarse cuando se está pronosticando una serie cíclica. Mencione ejemplos de situaciones en que dichas técnicas serían aplicables.
 13. En la tabla P-13, se presenta el número de matrimonios en Estados Unidos. Calcule las primeras diferencias para tales datos. Grafique los datos originales y los datos de diferencia como una serie de tiempo. ¿Hay tendencia en cualquiera de estas series? Explique su respuesta.
 14. Calcule un intervalo de confianza de 95% para el coeficiente de autocorrelación para el retraso de tiempo 1 para una serie que contiene 80 elementos.
 15. ¿Qué medida de precisión del pronóstico debería usarse en cada una de las siguientes situaciones?
 - a) El analista necesita determinar si el método de elaboración del pronóstico tiene un sesgo.
 - b) El analista cree que el tamaño o la magnitud de la variable del pronóstico es importante en la evaluación de la exactitud de éste.
 - c) El analista necesita sancionar errores grandes del pronóstico.

TABLA P-13

<i>Año</i>	<i>Matrimonios (miles)</i>	<i>Año</i>	<i>Matrimonios (miles)</i>
1985	2,413	1995	2,336
1986	2,407	1996	2,344
1987	2,403	1997	2,384
1988	2,396	1998	2,244
1989	2,403	1999	2,358
1990	2,443	2000	2,329
1991	2,371	2001	2,345
1992	2,362	2002	2,254
1993	2,334	2003	2,245
1994	2,362	2004	2,279

Fuente: Basada en *Statistical Abstract of the United States*, varios años.

16. ¿Cuál de los siguientes enunciados es verdadero en relación con las medidas de precisión usadas para evaluar pronósticos?
- El *MAPE* toma en consideración la magnitud de los valores que se pronostican.
 - El *MSE* y la *RMSE* sancionan errores grandes.
 - El *MPE* se usa para determinar si, sistemáticamente, un modelo está prediciendo muy alto o muy bajo.
 - La ventaja del método de la *MAD* es que relaciona el tamaño del error con la observación real.
17. A Allie White, la jefa de la oficina de préstamos del Dominion Bank, le gustaría analizar el portafolios de préstamos del banco para los años 2001 a 2006. Los datos se presentan en la tabla P-17.
- Calcule las autocorrelaciones para los retrasos de tiempo 1 y 2. Haga una prueba para determinar si estos coeficientes de autocorrelación son significativamente diferentes de cero, para el nivel de significancia de .05.
 - Use un programa de computadora para graficar los datos y calcule las autocorrelaciones para los primeros seis retrasos de tiempo. ¿Esta serie de tiempo es estacionaria?

TABLA P-17 Préstamos por trimestre (\$ millones) del Dominion Bank, 2001 a 2006				
Calendario	Mar. 31	Jun. 30	Sep. 30	Dic. 31
2001	2,313	2,495	2,609	2,792
2002	2,860	3,099	3,202	3,161
2003	3,399	3,471	3,545	3,851
2004	4,458	4,850	5,093	5,318
2005	5,756	6,013	6,158	6,289
2006	6,369	6,568	6,646	6,861

Fuente: Basado en los registros del Dominion Bank.

18. Para el problema anterior. Calcule las primeras diferencias de los datos de préstamos trimestrales del Dominion Bank.
- Calcule el coeficiente de autocorrelación para el retraso de tiempo 1, usando los datos diferenciados.
 - Use un programa de cómputo para graficar los datos diferenciados y para calcular sus autocorrelaciones de los primeros seis retrasos de tiempo. ¿Esta serie es estacionaria?
19. Analice los coeficientes de autocorrelación para las series presentadas en las figuras 3-18 a 3-21. Describa brevemente cada serie.
20. A un analista le gustaría determinar si existe un patrón de ganancias por acción para la Price Company, la cual opera un negocio de autoservicio de venta al mayoreo/menudeo en varios estados con el nombre de Price Club. Los datos se presentan en la tabla P-20. Describa cualquiera de los patrones que existan en estos datos.
- Encuentre el pronóstico de las ganancias trimestrales por acción de Price Club para cada trimestre, usando el enfoque sencillo (p. ej., el pronóstico del primer trimestre de 1987 es el valor del cuarto trimestre de 1986, es decir, .32).
 - Evalúe el pronóstico sencillo usando la *MAD*.

- c) Evalúe el pronóstico sencillo usando el MSE y la $RMSE$.
- d) Evalúe el pronóstico sencillo usando el $MAPE$.
- e) Evalúe el pronóstico sencillo usando el MPE .
- f) Escriba un reporte que resuma sus hallazgos.




FIGURA 3-18 Función de autocorrelación para el problema 19




FIGURA 3-19 Función de autocorrelación para el problema 19




FIGURA 3-20 Función de autocorrelación para el problema 19




FIGURA 3-21 Función de autocorrelación para el problema 19

TABLA P-20 Ganancias trimestrales por acción de Price Club: trimestres de 1986 a 1993				
Año	1o	2o	3o	4o
1986	.40	.29	.24	.32
1987	.47	.34	.30	.39
1988	.63	.43	.38	.49
1989	.76	.51	.42	.61
1990	.86	.51	.47	.63
1991	.94	.56	.50	.65
1992	.95	.42	.57	.60
1993	.93	.38	.37	.57

Fuente: *The Value Line Investment Survey* (Nueva York: Value Line, 1994), p. 1646.

TABLA P-21 Ventas semanales de un artículo alimenticio							
(Lea transversalmente)							
2649.9	2898.7	2897.8	3054.3	3888.1	3963.6	3258.9	3199.6
3504.3	2445.9	1833.9	2185.4	3367.4	1374.1	497.5	1699.0
1425.4	1946.2	1809.9	2339.9	1717.9	2420.3	1396.5	1612.1
1367.9	2176.8	2725.0	3723.7	2016.0	862.2	1234.6	1166.5
1759.5	1039.4	2404.8	2047.8	4072.6	4600.5	2370.1	3542.3
2273.0	3596.6	2615.8	2253.3	1779.4	3917.9	3329.3	1864.4
3318.9	3342.6	2131.9	3003.2				

21. La tabla p-21 contiene las ventas semanales de un artículo alimenticio para 52 semanas consecutivas.
- a) Grafique los datos de ventas como una serie de tiempo.
 - b) ¿Cree que esta serie sea estacionaria o no estacionaria?
 - c) Usando Minitab o un programa similar, calcule las autocorrelaciones de la serie de ventas para los 10 primeros retrasos de tiempo. ¿El comportamiento de las autocorrelaciones es consistente con su respuesta al inciso b)? Explique por qué.

22. Esta pregunta se refiere al problema 21.
- Ajuste el modelo aleatorio dado por la ecuación 3.4 a los datos de la tabla P-21, estimando c con la media muestral $\bar{Y}$ de modo que $\hat{Y}_t = \bar{Y}$. Calcule los residuos usando $e_t = Y_t - \hat{Y}_t = Y_t - \bar{Y}$.
 - Usando Minitab o un programa similar, calcule las autocorrelaciones de los residuos de la parte c para los primeros 10 retrasos de tiempo. ¿El modelo aleatorio es adecuado para los datos de ventas? Explique su respuesta.
23. La tabla P-23 presenta los ingresos trimestrales de Southwest Airlines, antes de partidas extraordinarias (millones de \$) para los años de 1988 a 1999.
- Grafique los datos de ingresos como una serie de tiempo y describa cualquier patrón existente.
 - ¿La serie es estacionaria o no estacionaria? Explique su respuesta.
 - Usando Minitab o un programa similar, calcule las autocorrelaciones de la serie de ingresos para los primeros 10 retrasos de tiempo. ¿El comportamiento de las autocorrelaciones es congruente con su elección realizada en el inciso b)? Explique su respuesta.
24. Esta pregunta se refiere al problema 23.
- Use Minitab o Excel para calcular las diferencias *cuartas* de los datos de ingresos en la tabla P-23. Las diferencias cuartas se calculan diferenciando las observaciones separadas por cuatro periodos. Con datos trimestrales, este procedimiento algunas veces es útil en la creación de una serie estacionaria, a partir de una serie no estacionaria (véase el capítulo 9). Por lo tanto, los datos diferenciados cuartos serán $Y_5 - Y_1 = 19.64 - 0.17 = 19.47$, $Y_6 - Y_2 = 19.24 - 15.13 = 4.11$, ..., y así sucesivamente.
 - Grafique las series de tiempo de las diferencias cuartas. ¿Estas series de tiempo parecen ser estacionarias o no estacionarias? Explique su respuesta.
25. Este problema se remite al problema 23.
- Considere un método de pronósticos sencillo, donde los ingresos del primer trimestre se usen para pronosticar los ingresos del primer trimestre del siguiente año, los ingresos del segundo trimestre se usen para pronosticar los ingresos del segundo trimestre del siguiente año, etcétera. Por ejemplo, un pronóstico de los ingresos del primer trimestre de 1998 lo proporcionan los ingresos del primer trimestre de 1997: 50.87 (véase la tabla P-23). Use este

TABLA P-23 Ingresos trimestrales de Southwest Airlines (millones de \$)				
Año	1o	2o	3o	4o
1988	0.17	15.13	26.59	16.07
1989	19.64	19.24	24.57	8.11
1990	5.09	23.53	23.04	-4.58
1991	-8.21	10.57	15.72	8.84
1992	13.48	23.48	26.89	27.17
1993	24.93	42.15	48.83	38.37
1994	41.85	58.52	58.62	20.34
1995	11.83	59.72	67.72	43.36
1996	33.00	85.32	60.86	28.16
1997	50.87	93.83	92.51	80.55
1998	70.01	133.39	129.64	100.38
1999	95.85	157.76	126.98	93.80

Fuente: Basada en *Compustat Industrial Quarterly Data Base*.

método sencillo para calcular los pronósticos de los ingresos trimestrales para los años 1998 a 1999.

b) Usando los pronósticos del inciso a), calcule *MAD*, *RMSE* y *MAPE*.

c) Dados los resultados en el inciso b) y la naturaleza de los patrones en la serie de ingresos, ¿cree usted que sea viable el método del pronóstico sencillo?
¿Pensaría en otro método sencillo que fuera mejor?

CASOS

CASO 3-1A MURPHY BROTHERS FURNITURE

En 1958 los hermanos Murphy abrieron una tienda de muebles en el centro de Dallas. Tuvieron mucho éxito durante varios años y ampliaron su cobertura de menudeo al oeste y al medio oeste. Para 1996 la cadena de sus mueblerías tenía presencia en 36 estados.

Julie Murphy, la hija de uno de los fundadores, se incorporó recientemente a la empresa. Su papá y su tío tenían buenos conocimientos en muchas áreas, aunque no en el área de las habilidades cuantitativas. En particular, ambos creían que no serían capaces de pronosticar con exactitud las futuras ventas de Murphy Brothers usando las técnicas computacionales modernas. Por tal razón, pidieron a Julie que los ayudara como parte de su nuevo empleo.

Julie pensó primero en usar las ventas en dólares de Murphy como su variable; pero se encontró con que faltaban varios años de información. Consultó a su padre, Glen, acerca de esto y él le dijo que por ese entonces él “creía que no era importante”. Julie explicó a Glen la importancia de los datos históricos y le pidió que guardara los datos en el futuro.

Julie pensó que las ventas de Murphy probablemente estaban muy relacionadas con las cifras de ventas nacionales y decidió buscar una variable adecuada en una de las diversas publicaciones federales. Después

de buscar en un número reciente de *Survey and Current Business*, encontró la historia de ventas mensuales de todas las tiendas minoristas en Estados Unidos, y decidió usar esta variable como sustituto de la variable que le interesaba: las ventas en dólares de Murphy Brothers. Ella creía que si era capaz de obtener pronósticos exactos de las ventas nacionales, podría relacionar tales pronósticos con las ventas propias de Murphy y conseguir los pronósticos que requería.

La tabla 3-8 presenta los datos que recopiló Julie, y la figura 3-22 ilustra una gráfica con los datos obtenidos con el programa de cómputo de Julie. Ella inició su análisis usando la computadora para desarrollar una gráfica de los coeficientes de autocorrelación.

Después de revisar la función de autocorrelación de la figura 3-23, era evidente para Julie que sus datos mostraban una tendencia. Los primeros coeficientes de autocorrelación eran muy grandes, y tendían hacia cero muy lentamente en el tiempo. Para hacer estacionaria la serie, de modo que pudiera considerar varios métodos de elaboración de pronósticos, Julie decidió diferenciar primero sus datos, para saber si la tendencia se podría eliminar. La función de autocorrelación para estos datos diferenciados se presenta en la figura 3-24.

PREGUNTAS

1. ¿Qué debería concluir Julie acerca de la serie de ventas al menudeo?
2. ¿Ha avanzado mucho Julie para encontrar una técnica de elaboración de pronósticos?
3. ¿Ha avanzado mucho Julie para encontrar una técnica de elaboración de pronósticos?
4. ¿Cómo sabrá Julie cuál técnica funcionará mejor?

TABLA 3-8 Ventas mensuales (miles de millones de \$) para todas las tiendas al menudeo, 1983 a 1995

	1983	1984	1985	1986	1987	1988	1989	1990	1991	1992	1993	1994	1995
Ene.	81.3	93.1	98.8	105.6	106.4	113.6	122.5	132.6	130.9	142.1	148.4	154.6	167.0
Feb.	78.9	93.7	95.6	99.7	105.8	115.0	118.9	127.3	128.6	143.1	145.0	155.8	164.0
Mar.	93.8	103.3	110.2	114.2	120.4	131.6	141.3	148.3	149.3	154.7	164.6	184.2	192.1
Abr.	93.8	103.9	113.1	115.7	125.4	130.9	139.8	145.0	148.5	159.1	170.3	181.8	187.5
Mayo	97.8	111.8	120.3	125.4	129.1	136.0	150.3	154.1	159.8	165.8	176.1	187.2	201.4
Jun.	100.6	112.3	115.0	120.4	129.0	137.5	149.0	153.5	153.9	164.6	175.7	190.1	202.6
Jul.	99.4	106.9	115.5	120.7	129.3	134.1	144.6	148.9	154.6	166.0	177.7	185.8	194.9
Ago.	100.1	111.2	121.1	124.1	131.5	138.7	153.0	157.4	159.9	166.3	177.1	193.8	204.2
Sept.	97.9	104.0	113.8	124.4	124.5	131.9	144.1	145.6	146.7	160.6	171.1	185.9	192.8
Oct.	100.7	109.6	115.8	123.8	128.3	133.8	142.3	151.5	152.1	168.7	176.4	189.7	194.0
Nov.	103.9	113.5	118.1	121.4	126.9	140.2	148.8	156.1	155.6	167.2	180.9	194.7	202.4
Dic.	125.8	132.3	138.6	152.1	157.2	171.0	176.5	179.7	181.0	204.1	218.3	233.3	238.0

Fuente: Basada en Survey of Current Business, varios años.




FIGURA 3-22 Gráfica de la serie de tiempo de ventas mensuales de todas las tiendas minoristas en Estados Unidos




FIGURA 3-23 Función de autocorrelación para ventas mensuales de todas las tiendas minoristas en Estados Unidos




FIGURA 3-24 Función de autocorrelación de la primera diferencia para ventas mensuales en todas las tiendas minoristas de Estados Unidos

TABLA 3-9 Ventas mensuales de la mueblería Murphy Brothers, 1992 a 1995

	<i>Ene.</i>	<i>Feb.</i>	<i>Mar.</i>	<i>Abr.</i>	<i>Mayo</i>	<i>Jun.</i>	<i>Jul.</i>	<i>Ago.</i>	<i>Sept.</i>	<i>Oct.</i>	<i>Nov.</i>	<i>Dic.</i>
1992	4,906	5,068	4,710	4,792	4,638	4,670	4,574	4,477	4,571	4,370	4,293	3,911
1993	5,389	5,507	4,727	5,030	4,926	4,847	4,814	4,744	4,844	4,769	4,483	4,120
1994	5,270	5,835	5,147	5,354	5,290	5,271	5,328	5,164	5,372	5,313	4,924	4,552
1995	6,283	6,051	5,298	5,659	5,343	5,461	5,568	5,287	5,555	5,501	5,201	4,826

Fuente: Registros de ventas de las tiendas Murphy Brothers.

CASO 3-1B MURPHY BROTHERS FURNITURE

Glen Murphy no quedó satisfecho con el regaño de su hija. Él decidió hacer una búsqueda intensiva en los registros de Murphy Brothers. Durante la investigación, él se emocionó al descubrir los datos de ventas de los pasados cuatro años, 1992 a 1995, como se presenta en

la tabla 3-9. Estaba sorprendido de averiguar que Julie no compartía su entusiasmo. Ella sabía que la obtención de datos reales de los últimos 4 años era un suceso positivo. El problema de Julie era que no estaba muy segura de qué hacer con los datos recién adquiridos.

PREGUNTAS

1. ¿Qué conclusiones debe obtener Julie acerca de los datos de ventas de Murphy Brothers?
2. ¿Cómo se compara el patrón de las ventas reales con el patrón de los datos de ventas al menudeo presentado en el caso 3-1A?
3. ¿Qué datos debería usar Julie para desarrollar un modelo de pronóstico?

CASO 3-2 MR. TUX

John Mosby, propietario de varias tiendas de alquiler Mr. Tux, está iniciando el pronóstico de la variable más importante de su negocio: las ventas mensuales en dólares (véase los casos de Mr. Tux al final de los capítulos 1 y 2). Una de sus empleadas, Virginia Perot, ha reunido los datos de ventas que se presentan en el caso 2-2. John decidió utilizar los 96 meses de datos que había recopilado. Él corrió los datos en Minitab y obtuvo la función de correlación mostrada en la figura 3-25. Puesto que todos los coeficientes de correlación son positivos y disminuyen muy lentamente, John concluyó que sus datos muestran una tendencia.

Luego, John le pidió al programa que calculara las primeras diferencias de los datos. La figura 3-26 presenta la función de autocorrelación para los datos diferenciados. Los coeficientes de autocorrelación para

los retrasos de tiempo 12 y 24, $r_{12} = .68$ y $r_{24} = .42$, respectivamente, son significativamente diferentes de cero.

Finalmente, John usa otro programa de cómputo para calcular el porcentaje de la varianza con los datos originales, explicado por los componentes de tendencia, estacionales y aleatorios.

El programa calcula el porcentaje de la varianza en los datos originales, explicado por los factores en el análisis:

FACTOR	EXPLICADO
Data	100
De tendencia	6
Estacional	45
Aleatorio	49

PREGUNTAS

1. Resuma los resultados del análisis de John en un párrafo que un gerente, no un pronosticador, pueda entender.
2. Describa los efectos de tendencia y estacionales que parecen estar presentes en los datos de ventas de Mr. Tux.
3. ¿Cómo explicaría usted la línea “Aleatoriedad, 49%”?
4. Considere las autocorrelaciones significativas, r_{12} y r_{24} , de los datos diferenciados. ¿Concluiría usted que las primeras ventas diferenciadas tienen un componente estacional? Si es así, ¿cuáles son las implicaciones para el pronóstico, digamos, de los cambios mensuales en ventas?




FIGURA 3-25 Función de autocorrelación para los datos de Mr. Tux

PREGUNTAS

1. Explique cómo usó Dorothy el análisis de autocorrelación para investigar el patrón de datos del número de clientes nuevos atendido por CCC.
2. ¿Qué concluyó ella después de terminar este análisis?
3. ¿Qué tipo de técnica de pronóstico recomendó Dorothy para este conjunto de datos?

CASO 3-4 ALOMEGA FOOD STORES

En el ejemplo 1.1, la presidenta de Alomega, Julie Ruth, había recopilado datos de las operaciones de su compañía. Ella encontró varios meses de datos de ventas junto con diversas variables explicativas potenciales (repase esta situación en el ejemplo 1.1). Mientras su equipo de análisis estaba trabajando con los datos en un intento por pronosticar las ventas mensuales, se

impacientó y se preguntó cuáles de las variables explicativas eran las mejores para este propósito.

En el caso 2-3, Julie investigó las relaciones entre las ventas y las posibles variables explicativas. Se da cuenta ahora de que este paso fue prematuro porque ella incluso no conocía el patrón de las ventas (véase la tabla 3-11).

PREGUNTA

1. ¿Qué concluyó Julie acerca del patrón de datos de las ventas de Alomega?

TABLA 3-11 Ventas mensuales de las 27 tiendas Alomega, 2003 a 2006

<i>Mes</i>	<i>2003</i>	<i>2004</i>	<i>2005</i>	<i>2006</i>
Ene.	425,075	629,404	655,748	455,136
Feb.	315,305	263,467	270,483	247,570
Mar.	432,101	468,612	429,480	732,005
Abr.	357,191	313,221	260,458	357,107
Mayo	347,874	444,404	528,210	453,156
Jun.	435,529	386,986	379,856	320,103
Jul.	299,403	414,314	472,058	451,779
Ago.	296,505	253,493	254,516	249,482
Sept.	426,701	484,365	551,354	744,583
Oct.	329,722	305,989	335,826	421,186
Nov.	281,783	315,407	320,408	397,367
Dic.	166,391	182,784	276,901	269,096

CASO 3-5 SURTIDO COOKIES

La compañía GAMESA es el productor más grande de galletas, botanas y pastelillos en México y América Latina.

Jaime Luna, un analista de SINTEC, una importante firma de consultoría en cadena de suministros establecida en México, está trabajando con GAMESA en un sistema de optimización de las rutas de reparto y del estacionamiento de vehículos, para todos los centros de distribución en México. Los pronósticos de la demanda de productos de GAMESA le ayudarán a elaborar un plan para la flotilla de camiones y requerimientos de almacenamiento, asociados con el sistema de optimización de las rutas de reparto y del estacionamiento de vehículos.

Como punto de partida, Jaime decidió enfocarse en uno de los productos principales de la División de Galletas de GAMESA. Él recopiló datos de la demanda agregada mensual (en kilogramos) de las galletas Surtido, de enero de 2000 a mayo del 2003. Los resultados se presentan en la tabla 3-12.

Surtido es una mezcla de diferentes galletas en una sola presentación. Jaime sabe que este producto se consume comúnmente en juntas de trabajo, fiestas y reuniones. También es popular durante las festividades navideñas. De modo que Jaime está bastante seguro de que habrá un componente estacional en la serie de tiempo de las ventas mensuales, pero no está seguro de si existirá una tendencia en las ventas. Él decidió graficar la serie de ventas y usar el análisis de autocorrelación para que le ayude a determinar si estos datos muestran una tendencia y un componente estacional.

Karen, uno de los miembros del equipo de Jaime, sugiere que los pronósticos de las ventas mensuales futuras podrían generarse usando simplemente el promedio de ventas de cada mes. Jaime decidió probar esta sugerencia “considerando” las ventas mensuales de 2003 para casos de prueba. Entonces, el promedio de ventas de enero de 2000 a 2002 se utilizará para pronosticar las ventas de enero de 2003, y así sucesivamente.

PREGUNTAS

1. ¿Qué debería concluir Jaime acerca del patrón de datos de las ventas de galletas Surtido?
2. ¿Qué aprendió Jaime acerca de la exactitud del pronóstico sugerencia de Karen?

TABLA 3-12 Ventas mensuales (en kg) de las galletas Surtido, de enero de 2000 a mayo de 2003				
Mes	2000	2001	2002	2003
Ene.	666,922	802,365	574,064	1,072,617
Feb.	559,962	567,637	521,469	510,005
Mar.	441,071	527,987	522,118	579,541
Abr.	556,265	684,457	716,624	771,350
Mayo	529,673	747,335	632,066	590,556
Jun.	564,722	658,036	633,984	
Jul.	638,531	874,679	543,636	
Ago.	478,899	793,355	596,131	
Sept.	917,045	1,819,748	1,606,798	
Oct.	1,515,695	1,600,287	1,774,832	
Nov.	1,834,695	2,177,214	2,102,863	
Dic.	1,874,515	1,759,703	1,819,749	

Aplicaciones de Minitab

El problema. En el ejemplo 3.4, Maggie Trymane, una analista de Sears, quiere pronosticar las ventas para 2005. Ella necesita determinar el patrón de los datos de ventas para los años 1955 a 2004.

Solución con Minitab

1. Introduzca los datos de Sears presentados en la tabla 3-4, en la columna C1. Puesto que los datos ya están almacenados en un archivo llamado Tab3-4.MTW, haga clic en

File>Open Worksheet

y doble clic en el archivo Ch3 de Minitab. Haga clic en Tab3-4.MTW y en Open para abrir el archivo. Los datos de Sears aparecerán en la columna C1.

2. Para construir una función de autocorrelación, haga clic en los siguientes menús, como se indica en la figura 3-27:

Stat>Time Series>Autocorrelation

3. Aparece la ventana de diálogo de la función de autocorrelación ilustrada en la figura 3-28.
 - a) Haga doble clic en la variable Revenue y ésta aparecerá a la derecha de Series.
 - b) Introduzca un encabezado en Title en el espacio adecuado y haga clic en OK. La función de autocorrelación resultante se presenta en la figura 3-11.
4. Para diferenciar los datos, haga clic en los siguientes menús:

Stat>Time Series>Differences




FIGURA 3-27 Menú de autocorrelación en Minitab




FIGURA 3-28 Ventana de diálogo de la función de autocorrelación en Minitab




FIGURA 3-29 Ventana de diálogo de diferencias en Minitab

- La opción Differences está arriba de la opción Autocorrelation mostrada en la figura 3-27.
5. Aparece la ventana de diálogo Differences, ilustrada en la figura 3-29.
 - a) Haga doble clic en la variable Revenue y ésta aparecerá a la derecha de Series.
 - b) Utilice el tabulador para introducir las diferencias en el campo Store differences in: C2. Los datos diferenciados aparecerán ahora en la columna C2 de la hoja de cálculo.

Aplicaciones de Excel

El problema. Harry Vernon quiere usar Excel para calcular los coeficientes de autocorrelación y un correlograma para los datos presentados en la tabla 3-1. (Véase la p. 65).

Solución de Excel

1. Cree un archivo haciendo clic en los siguientes menús:

File>New

2. Posicione el cursor en A1. Observe que, siempre que el cursor esté en una celda, ésta queda resaltada. Escriba el encabezado VERNON'S MUSIC STORE. Posicione el cursor en A2 y teclee NUMBER OF VCRS SOLD.
3. Posicione el cursor en A4 y teclee Month. Presione <enter> y la celda resaltará A5. Ahora introduzca cada mes, empezando con January (enero) en A5 y terminando con december (diciembre) en A16.
4. Posicione el cursor en B4 y teclee Y. Introduzca los datos de la tabla 3-1, empezando con la celda B5. Posicione el cursor en C4 y teclee Z.
5. Resalte las celdas B4:C16 y haga clic en los siguientes menús:

Insert>Name>Create

En la ventana de diálogo Create Names, haga clic en la ventana de diálogo Top row y luego dé clic en OK. Este paso crea el nombre Y para el rango B5:B16 y el nombre Z para el rango C5:C16.

6. Resalte C5 e introduzca la fórmula

$$=(B5-AVERAGE(Y))/STDEV(Y)$$

Copie C5 al resto de la columna resaltándola y haciendo luego clic en el “llenado a mano”, en la esquina inferior derecha y arrástrelo hacia abajo a la celda C16. Con las celdas C5:C16 aún resaltadas, haga clic en el botón Decrease Decimal (indicado en la figura 3-30 en la mitad superior) hasta que se desplieguen tres posiciones decimales. El botón Decrease Decimal está en la barra de tareas Formatting. Esta barra de tareas puede desplegarse haciendo clic con el botón derecho del mouse en File y, luego, en Formatting con el botón izquierdo del mouse.

7. Introduzca las etiquetas LAG y ACF en las celdas E4 y F4. Para examinar los primeros seis retrasos de tiempo, introduzca los dígitos 1 a 6 en las celdas E5:E10.
8. Resalte F5 e introduzca la fórmula

$$=SUMPRODUCT(OFFSET(Z,E5,0,12-E5),OFFSET(Z,0,0,12-E5))/11$$

Resalte F5, haga clic en llenado a mano, en la esquina inferior derecha y arrástrelo a la celda F10. Con las celdas F5:F10 resaltadas, haga clic en el botón Decrease Decimal hasta que se desplieguen tres posiciones decimales. Se presentan los resultados en la figura 3-30.

9. Para desarrollar la función de autocorrelación, resalte las celdas F5:F10. Haga clic en la herramienta ChartWizard (presentada en la figura 3-31 en la mitad superior).
10. Aparece la ventana de diálogo ChartWizard pasos 1 a 4. En el paso 1, seleccione un tipo de gráfica haciendo clic en Column y luego en Next. En la ventana de diálogo del paso 2, haga clic en la ventana de diálogo Series. En el espacio siguiente a Name, teclee Corr. Dé clic en Next y aparecerá la ventana de diálogo 3. Con el título de Chart, borre Corr. Abajo del eje (X) Category, teclee Time Lags. Ahora haga clic en la ventana de diálogo Data Table y en la siguiente ventana a Show data table. Haga clic en Next para obtener la ventana de diálogo del paso 4 y luego en Finish para producir la función de autocorrelación presentada en la figura




FIGURA 3-30 Hoja de cálculo Excel para los datos de las VCR




FIGURA 3-31 Resultado de Excel para la función de autocorrelación

3-31. Haga clic en una de las esquinas de la gráfica y muévela hacia el exterior para agrandar la función de autocorrelación.

11. Para salvar los datos y usarlos en el capítulo 9, haga clic en

File>Save As

En la ventana de diálogo Save As, teclee Tab3-1 en el espacio a la derecha de File name. Haga clic en Save y el archivo se guardará como Tab3-1.xls.

Referencias

- Armstrong, J. S., ed. *Principles of Forecasting: A Handbook for Researchers and Practitioners*. Norwell, Mass.: Kluwer, 2001.
- Diebold, F. X. *Elements of Forecasting*, 3rd ed. Cincinnati, Ohio: South-Western, 2004.
- Ermer, C. M. "Cost of Error Affects the Forecasting Model Selection." *Journal of Business Forecasting* 9 (Primavera de 1991): 10–12.
- Fildes, R., M. Hibon, S. Makridakis, and N. Meade. "The Accuracy of Extrapolative Forecasting Methods: Additional Empirical Evidence." *International Journal of Forecasting* 13 (1997): 13.
- Makridakis, S., A. Andersen, R. Carbone, R. Fildes, M. Hibon, R. Lewandowski, J. Newton, E. Parzen, and R. Winkler. "The Accuracy of Extrapolation (Time Series) Methods: Results of a Forecasting Competition." *Journal of Forecasting* 1 (1982): 111–153.
- Makridakis, S., C. Chatfield, M. Hibon, M. Lawrence, T. Mills, J. K. Ord, and L. F. Simmons. "The M2-Competition: A Real Time Judgmentally Based Forecasting Study." *International Journal of Forecasting* 9 (1993): 5–30.
- Makridakis, S., and M. Hibon. "The M3-Competition: Results, Conclusions and Implications." *International Journal of Forecasting* 16 (2000): 451–476.
- Newbold, P., and T. Bos. *Introductory Business and Economic Forecasting*, 2nd ed. Cincinnati, Ohio: South-Western, 1994.
- Quenouille, M. H. "The Joint Distribution of Serial Correlation Coefficients." *Annals of Mathematical Statistics* 20 (1949): 561–571.
- Wilkinson, G. F. "How a Forecasting Model Is Chosen." *Journal of Business Forecasting* 7 (Verano de 1989): 7–8.

MÉTODOS DE PROMEDIOS
MÓVILES Y DE SUAVIZACIÓN

Este capítulo describe tres enfoques sencillos para pronosticar una serie de tiempo: el método informal, el método de promedios y el método de suavización. Los métodos *informales* se usan para desarrollar modelos simples que suponen que los datos más recientes ofrecen las mejores predicciones del futuro. Los métodos *de promedio* generan pronósticos con base en un promedio de observaciones pasadas. Los métodos *de suavización* generan pronósticos con base en el promedio de valores pasados de una serie con una serie decreciente (exponencial) de ponderación o pesos.

La figura 4-1 presenta los métodos de pronósticos que se exponen en este capítulo. Visualícese usted mismo en una escala de tiempo. Suponga que se encuentra en el punto t de la figura 4-1 y puede mirar hacia atrás o hacia delante y observar la información pasada o futura de la variable de interés (Y_t). Después de que usted selecciona una técnica para la elaboración del pronóstico, la ajusta a los datos conocidos y obtiene los valores del pronóstico ($\hat{Y}_t$). Una vez que estos valores pronosticados están disponibles, los compara con las observaciones conocidas y calcula el error de pronóstico (e_t).

Una buena estrategia para evaluar los métodos de pronósticos implica los siguientes pasos:

- 1. La selección de un método de pronósticos se realiza con base en el análisis y la intuición del pronosticador acerca de la naturaleza de los datos.
- 2. El conjunto de datos se divide en dos secciones: una sección de inicio o de ajuste y una sección de prueba o de pronóstico.
- 3. La técnica seleccionada de pronóstico se usa para desarrollar valores de ajuste con la primera parte de los datos.
- 4. La técnica se usa para pronosticar la segunda sección, los pronósticos obtenidos se comparan con los datos y se evalúa el error de pronóstico (consulte el capítulo 3 para revisar las medidas de la precisión del pronóstico).
- 5. Se toma una decisión. La decisión puede ser usar la técnica en su forma actual, modificarla o desarrollar un pronóstico usando otra técnica y comparar los resultados.

FIGURA 4-1 Esquema de elaboración del pronóstico

	Datos pasados	Usted está aquí t	Periodos por pronosticar
	$\dots Y_{t-3}, Y_{t-2}, Y_{t-1},$	$Y_t,$	$\hat{Y}_{t+1}, \hat{Y}_{t+2}, \hat{Y}_{t+3}, \dots$
donde	Y_t es la observación más reciente de una variable		
	$\hat{Y}_{t+1}$ es el pronóstico para el siguiente periodo en el futuro		

MODELOS INFORMALES

A menudo los negocios nuevos enfrentan el problema de tratar de elaborar un pronóstico con grupos muy reducidos de datos. Esta situación genera un problema real, puesto que muchas técnicas para la elaboración de un pronóstico requieren grandes cantidades de datos. Los pronósticos informales son una posible solución, puesto que se basan solamente en la información más reciente que está disponible.

Los pronósticos informales suponen que los periodos recientes son los mejores para predecir el futuro. El modelo más sencillo es:

$$\hat{Y}_{t+1} = Y_t \quad (4.1)$$

donde $\hat{Y}_{t+1}$ es el pronóstico realizado en el momento t (el origen del pronóstico) para el tiempo $t + 1$.

El pronóstico informal de cada periodo es la observación inmediata anterior. Se da el 100% del peso al valor actual de la serie. El pronóstico informal se conoce algunas veces como pronóstico “sin cambio”. En el pronóstico meteorológico de corto plazo a menudo se aplica el pronóstico “sin cambio”. Se supone que el clima de mañana se parecerá mucho al clima de hoy.

Puesto que el pronóstico informal (ecuación 4.1) descarta cualquier otra observación, este esquema detecta cambios muy rápidamente. El problema con este enfoque es que las fluctuaciones aleatorias se producen con la misma fidelidad que los cambios en los datos fundamentales.

Ejemplo 4.1

La figura 4-2 muestra las ventas trimestrales de serruchos del 2000 al 2006 de Acme Tool Company. Se usa la técnica informal para pronosticar que las ventas del siguiente trimestre serán iguales que las del trimestre anterior. La tabla 4-1 presenta los datos del 2000 al 2006. Si se usan los datos del 2000 al 2005 como parte inicial (de ajustes) y los datos del 2006 como la parte de prueba, el pronóstico para el primer trimestre del 2006 es:

$$\begin{aligned}\hat{Y}_{24+1} &= Y_{24} \\ \hat{Y}_{25} &= 650\end{aligned}$$

FIGURA 4-2 Gráfica de las series de tiempo de las ventas de serruchos de Acme Tool Company, 2000 a 2006, para el ejemplo 4.1




TABLA 4-1 Ventas de serruchos de Acme Tool Company, 2000 a 2006, para el ejemplo 4.1

<i>Año</i>	<i>Trimestre</i>	<i>t</i>	<i>Ventas</i>
2000	1	1	500
	2	2	350
	3	3	250
	4	4	400
2001	1	5	450
	2	6	350
	3	7	200
	4	8	300
2002	1	9	350
	2	10	200
	3	11	150
	4	12	400
2003	1	13	550
	2	14	350
	3	15	250
	4	16	550
2004	1	17	550
	2	18	400
	3	19	350
	4	20	600
2005	1	21	750
	2	22	500
	3	23	400
	4	24	650
2006	1	25	850
	2	26	600
	3	27	450
	4	28	700

El error de pronóstico se determina usando la ecuación 3.6. El error del periodo 25 es:

$$e_{25} = Y_{25} - \hat{Y}_{25} = 850 - 650 = 200$$

De modo similar, el pronóstico del periodo 26 es 850, con un error de -250 . La figura 4-2 indica que estos datos tienen una tendencia ascendente y que parece haber un patrón estacional (el primer trimestre y el cuarto son relativamente altos), de manera que se toma una decisión para modificar el modelo informal.

Un examen de los datos del ejemplo 4.1 nos lleva a concluir que los valores se incrementan con el tiempo. Cuando los valores de los datos aumentan con el tiempo, se dice que son de nivel *no estacionario* o que tienen una *tendencia*. Si se usa la ecuación 4.1, las proyecciones serán bajas de forma sistemática. Sin embargo, la técnica puede ajustarse para tomar en cuenta la tendencia sumando la diferencia entre este periodo y el último. La ecuación del pronóstico es:

$$\hat{Y}_{t+1} = Y_t + (Y_t - Y_{t-1}) \quad (4.2)$$

La ecuación 4.2 toma en cuenta la magnitud del cambio que ocurre entre trimestres.

Ejemplo 4.1 (cont.)

Usando la ecuación 4.2, el pronóstico del primer trimestre del 2006 es:

$$\begin{aligned}\hat{Y}_{24+1} &= Y_{24} + (Y_{24} - Y_{24-1}) \\ \hat{Y}_{25} &= Y_{24} + (Y_{24} - Y_{23}) \\ \hat{Y}_{25} &= 650 + (650 - 400) \\ \hat{Y}_{25} &= 650 + 250 = 900\end{aligned}$$

El error de pronóstico con este modelo es:

$$e_{25} = Y_{25} - \hat{Y} = 850 - 900 = -50$$

En algunos casos, la tasa de cambio podría ser más apropiada que el valor absoluto del cambio. Si éste es el caso, es razonable elaborar el pronóstico de acuerdo con:

$$\hat{Y}_{t+1} = Y_t \frac{Y_t}{Y_{t-1}} \quad (4.3)$$

Una revisión visual de los datos en la tabla 4-1 indica que puede existir una variación estacional. Las ventas en el primer trimestre y en el cuarto generalmente son mayores que las del segundo y tercer trimestres. Si el patrón estacional es fuerte, entonces una ecuación adecuada para el pronóstico de datos trimestrales sería

$$\hat{Y}_{t+1} = Y_{t-3} \quad (4.4)$$

La ecuación 4.4 indica que en el siguiente trimestre la variable tendrá el mismo valor que tenía en el trimestre correspondiente del año anterior.

La mayor debilidad de este enfoque es que ignora todo lo que ha ocurrido desde el año anterior y también cualquier tendencia. Existen varias maneras de introducir esta información más reciente. Por ejemplo, el analista puede combinar las estimaciones estacionales y de tendencia, y pronosticar el siguiente trimestre mediante:

$$\hat{Y}_{t+1} = Y_{t-3} + \frac{(Y_t - Y_{t-1}) + \cdots + (Y_{t-3} - Y_{t-4})}{4} = Y_{t-3} + \frac{Y_t - Y_{t-4}}{4} \quad (4.5)$$

donde el término Y_{t-3} pronostica el patrón estacional, y el término restante promedia la magnitud del cambio de los cuatro trimestres anteriores y ofrece un estimado de la tendencia.

Los modelos de pronóstico informales de las ecuaciones 4.4 y 4.5 se aplican para datos trimestrales. Es posible hacer ajustes para los datos recolectados durante diferentes periodos de tiempo. Para datos mensuales, por ejemplo, el periodo estacional es 12, no 4, y el pronóstico para el siguiente periodo (mes) dado por la ecuación 4.4 es $\hat{Y}_{t+1} = Y_{t-11}$.

Es evidente que el número y la complejidad de los modelos informales posibles están limitados sólo por el ingenio del analista, pero el uso de estas técnicas debe guiarse por el uso de un buen juicio.

Los métodos informales también se usan como base para hacer comparaciones con las cuales se evalúa el desempeño de métodos más complejos.

Ejemplo 4.1 (cont.)

Los pronósticos del primer trimestre de 2006, usando las ecuaciones 4.3, 4.4 y 4.5, son:

$$\begin{aligned}\hat{Y}_{24+1} &= Y_{24} \frac{Y_{24}}{Y_{24-1}} = Y_{24} \frac{Y_{24}}{Y_{23}} \\ \hat{Y}_{25} &= 650 \frac{650}{400} = 1,056\end{aligned} \quad (\text{Ecuación 4.3})$$

$$\begin{aligned}\hat{Y}_{24+1} &= Y_{24-3} = Y_{21} \\ \hat{Y}_{25} &= Y_{21} = 750\end{aligned} \quad (\text{Ecuación 4.4})$$

$$\begin{aligned}\hat{Y}_{24+1} &= Y_{24-3} + \frac{(Y_{24} - Y_{24-1}) + \dots + (Y_{24-3} - Y_{24-4})}{4} = Y_{24-3} + \frac{Y_{24} - Y_{2-4}}{4} \\ \hat{Y}_{25} &= Y_{21} + \frac{(Y_{24} - Y_{20})}{4} = 750 + \frac{650 - 600}{4} \\ \hat{Y}_{25} &= 750 + 12.5 = 762.5\end{aligned}\quad (\text{Ecuación 4.5})$$

MÉTODOS DE PRONÓSTICOS BASADOS EN PROMEDIOS

Con frecuencia, los administradores enfrentan el problema de actualizar de forma diaria, semanal o mensual los pronósticos de inventarios que contienen cientos o miles de artículos. Muchas veces no es posible desarrollar técnicas complejas para elaborar pronósticos de cada artículo. En vez de ello, se necesitan herramientas para pronosticar de manera sencilla, rápida, poco costosa y para el corto plazo.

Un administrador que enfrenta una situación como ésta probablemente use una técnica de promedios o una técnica de suavización. Estos tipos de técnicas usan alguna clase de promedio ponderado de observaciones pasadas para suavizar fluctuaciones de corto plazo. La suposición implícita de estas técnicas es que las fluctuaciones de los valores pasados representan puntos de partida aleatorios de alguna estructura subyacente. Una vez que se identifica esta estructura, es posible proyectarla hacia el futuro para generar un pronóstico.

Promedios simples

Los datos históricos pueden suavizarse de muchas maneras. El objetivo es usar los datos pasados para desarrollar un modelo de pronóstico para periodos futuros. En esta sección se presenta el método de promedios simples. Al igual que sucede con los métodos informales, se toma una decisión para usar los primeros puntos de datos t como la parte de inicialización y la parte restante de puntos como la parte de prueba. Luego, se usa la ecuación 4.6 para promediar (calcular la media de) la parte de inicialización de los datos y pronosticar el siguiente periodo.

$$\hat{Y}_{t+1} = \frac{1}{t} \sum_{i=1}^t Y_i \quad (4.6)$$

Cuando una nueva observación está disponible, el pronóstico del siguiente periodo, $\hat{Y}_{t+2}$, es el promedio o la media calculada empleando la ecuación 4.6 incluyendo esta nueva observación.

Cuando se pronostica un gran número de series simultáneamente (por ejemplo, en la administración de inventarios), el almacenamiento de datos suele ser un problema. La ecuación 4.7 resuelve este problema potencial. Sólo se requiere contar con el pronóstico más reciente y la observación más reciente conforme el tiempo transcurre.

$$\hat{Y}_{t+2} = \frac{t\hat{Y}_{t+1} + Y_{t+1}}{t + 1} \quad (4.7)$$

El método de *promedios simples* es una técnica adecuada cuando los factores que producen la serie que se va a pronosticar se han estabilizado y el ambiente en el cual se encuentra la serie generalmente permanece sin cambios. Ejemplos de este tipo de series son: las ventas efectuadas como resultado de un nivel de esfuerzo constante de los vendedores; las ventas de un producto en la etapa de madurez de su ciclo de vida; y el número de citas semanales de un dentista, doctor o abogado cuyo número de clientes o pacientes es estable.

Un *promedio simple* usa la media de todas las observaciones históricas relevantes como el pronóstico para el siguiente periodo.

Ejemplo 4.2

La Spokane Transit Authority opera una flota de camionetas para transportar tanto personas mayores como discapacitadas. El registro de la gasolina comprada para esta flota de camionetas se presenta en la tabla 4-2. La cantidad real de gasolina consumida por una camioneta en un día cualquiera se caracteriza por la naturaleza aleatoria de las visitas y los destinos. La revisión de las compras de gasolina graficadas en la figura 4-3 indica que los datos son muy estables. Puesto que los datos parecen estacionarios, se usa el método de los promedios simples de las semanas 1 a 28 para pronosticar las compras de gasolina de las semanas 29 y 30. El pronóstico para la semana 29 es:

TABLA 4-2 Compras de gasolina de la Spokane Transit Authority para el ejemplo 4.2

Semana t	Galones Y_t	Semana t	Galones Y_t	Semana t	Galones Y_t
1	275	11	302	21	310
2	291	12	287	22	299
3	307	13	290	23	285
4	281	14	311	24	250
5	295	15	277	25	260
6	268	16	245	26	245
7	252	17	282	27	271
8	279	18	277	28	282
9	264	19	298	29	302
10	288	20	303	30	285




FIGURA 4-3 Gráfica de las series de tiempo de las compras semanales de gasolina de la Spokane Transit Authority para el ejemplo 4.2

$$\hat{Y}_{28+1} = \frac{1}{28} \sum_{i=1}^{28} Y_i$$

$$\hat{Y}_{29} = \frac{7,874}{28} = 281.2$$

El error de pronóstico es

$$e_{29} = Y_{29} - \hat{Y}_{29} = 302 - 281.2 = 20.8$$

El pronóstico para la semana 30 incluye un punto más de datos (302) que se añadió al periodo de inicialización. El pronóstico calculado con la ecuación 4.7 es:

$$\hat{Y}_{28+2} = \frac{28\hat{Y}_{28+1} + Y_{28+1}}{28 + 1} = \frac{28\hat{Y}_{29} + Y_{29}}{29}$$

$$\hat{Y}_{20} = \frac{28(281.2) + 302}{29} = 281.9$$

El error de pronóstico es:

$$e_{30} = Y_{30} - \hat{Y}_{30} = 285 - 281.9 = 3.1$$

Usando el método de promedios simples, el pronóstico de galones de gasolina comprados para la semana 31 es:

$$\hat{Y}_{30+1} = \frac{1}{30} \sum_{i=1}^{30} Y_i = \frac{8,461}{30} = 282$$

Promedios móviles

El método de promedios simples utiliza la media de todos los datos para hacer el pronóstico. ¿Qué sucede si en el analista está más interesado en las observaciones recientes? Se puede especificar un número constante de puntos de datos al inicio y se puede calcular una media con las observaciones más recientes. El término *promedios móviles* se utiliza para describir este enfoque. Conforme está disponible cada nueva observación, se calcula una nueva media sumando el valor más reciente y eliminando el valor más antiguo. Entonces se usa este promedio móvil para pronosticar el siguiente periodo. La ecuación 4.8 nos da el pronóstico de un promedio móvil simple. Un promedio móvil de orden k , $MA(k)$, se calcula mediante

$$\hat{Y}_{t+1} = \frac{Y_t + Y_{t-1} + \cdots + Y_{t-k+1}}{k} \quad (4.8)$$

donde

$\hat{Y}_{t+1}$ = valor pronosticado para el siguiente periodo

Y_t = valor real en el periodo t

k = número de términos en el promedio móvil

El promedio móvil para el periodo de tiempo t es la media aritmética de las k observaciones más recientes. En un promedio móvil, se asignan pesos iguales a cada observación. Conforme está disponible, cada nuevo punto de datos se incluye en el promedio y el punto de datos más antiguo se descarta. El porcentaje de respuesta a los cambios en el patrón subyacente de datos depende del número de periodos, k , incluidos en el promedio móvil.

Observe que la técnica de promedio móvil maneja sólo los últimos k periodos de los datos conocidos; el número de puntos de datos en cada promedio no cambia conforme el tiempo avanza. El modelo de promedio móvil no maneja muy bien la tendencia o la estacionalidad, si bien es cierto que lo hace mejor que el método de promedio simple.

En un *promedio móvil*, el analista debe seleccionar el número de periodos, k . Un promedio móvil de orden 1, MA(1), tomaría la observación actual, Y_t , y la usaría para pronosticar Y para el siguiente periodo. Esto simplemente es el enfoque del pronóstico informal de la ecuación 4.1.

Un *promedio móvil* de orden k es el valor de la media de k observaciones consecutivas. El valor del promedio móvil más reciente indicará el pronóstico del siguiente periodo.

Ejemplo 4.3

La tabla 4-3 presenta la técnica del pronóstico del promedio móvil para los datos de la Spokane Transit Authority, usando un promedio móvil de cinco semanas. El pronóstico de promedio móvil para la semana 29 es:

$$\hat{Y}_{28+1} = \frac{Y_{28} + Y_{28-1} + \cdots + Y_{28-5+1}}{5}$$

$$\hat{Y}_{29} = \frac{Y_{28} + Y_{27} + Y_{26} + Y_{25} + Y_{24}}{5}$$

TABLA 4-3 Compras de gasolina de la Spokane Transit Authority para el ejemplo 4.3

t	Galones	$\hat{Y}_t$	e_t
1	275	—	—
2	291	—	—
3	307	—	—
4	281	—	—
5	295	—	—
6	268	289.8	-21.8
7	252	288.4	-36.4
8	279	280.6	-1.6
9	264	275.0	-11.0
10	288	271.6	16.4
11	302	270.2	31.8
12	287	277.0	10.0
13	290	284.0	6.0
14	311	286.2	24.8
15	277	295.6	-18.6
16	245	293.4	-48.4
17	282	282.0	0.0
18	277	281.0	-4.0
19	298	278.4	19.6
20	303	275.8	27.2
21	310	281.0	29.0
22	299	294.0	5.0
23	285	297.4	-12.4
24	250	299.0	-49.0
25	260	289.4	-29.4
26	245	280.8	-35.8
27	271	267.8	3.2
28	282	262.2	19.8
29	302	261.6	40.4
30	285	272.0	13.0

$$\hat{Y}_{29} = \frac{282 + 271 + 245 + 260 + 250}{5} = \frac{1,308}{5} = 261.6$$

Cuando se conoce el valor real de la semana 29, se calcula el error de pronóstico:

$$e_{29} = Y_{29} - \hat{Y}_{29} = 302 - 261.6 = 40.4$$

El pronóstico para la semana 31 es:


$$\begin{aligned}\hat{Y}_{30+1} &= \frac{Y_{30} + Y_{30-1} + \cdots + Y_{30-5+1}}{5} \\ \hat{Y}_{31} &= \frac{Y_{30} + Y_{29} + Y_{28} + Y_{27} + Y_{26}}{5} \\ \hat{Y}_{31} &= \frac{285 + 302 + 282 + 271 + 245}{5} = \frac{1,385}{5} = 277\end{aligned}$$

Se puede usar Minitab para calcular un promedio móvil de cinco semanas (para instrucciones específicas, véase la sección de aplicaciones de Minitab al final del capítulo). La figura 4-4 presenta el promedio móvil de cinco semanas graficado contra los datos reales, *MAPE*, *MAD* y *MSD* y las instrucciones básicas de Minitab. Observe que Minitab llama *MSD* (desviación cuadrática media) al error cuadrático medio.

La figura 4-5 presenta la función de autocorrelación de los residuos del método de promedio móvil para las cinco semanas. Los límites de error para las autocorrelaciones individuales centradas en cero y el estadístico *Q* de Ljung-Box (con seis grados de libertad, puesto que no se estiman los parámetros del modelo) indican que existen autocorrelaciones residuales significativas. Es decir, los residuos no son aleatorios. La asociación contenida en los residuos en ciertos retrasos de tiempo puede usarse para mejorar el modelo de pronóstico.

El analista debe usar su criterio en la determinación de los días, semanas, meses o trimestres en los cuales basar el promedio móvil. Cuanto menor es el número, mayor es el peso que se asigna a los periodos más recientes. Y a la inversa, cuanto mayor es el número, menor es el peso que se asigna a los periodos más recientes. Es más deseable un número pequeño cuando existen cambios repentinos en el nivel de la serie. Un número pequeño pone mayor peso a la

FIGURA 4-4 Promedio móvil de cinco semanas aplicado a las compras semanales de gasolina de la Spokane Transit Authority para el ejemplo 4.3



Función de autocorrelación: Residuos MA(5)

Retraso	ACF	T	LBQ
1	0.506290	2.53	7.21
2	0.078551	0.32	7.39
3	-0.298611	-1.21	10.13
4	-0.602830	-2.31	21.81
5	-0.642632	-2.06	35.74
6	-0.219452	-0.61	37.46




FIGURA 4-5 Función de autocorrelación para los residuos cuando se usa el método de promedio móvil de cinco semanas con datos de la Spokane Transit Authority para el ejemplo 4.3

historia reciente, lo cual facilita que los pronósticos alcancen más rápidamente el nivel real. Es deseable un número grande cuando hay fluctuaciones amplias y poco frecuentes en las series.

Los promedios móviles se usan a menudo con datos mensuales o trimestrales como ayuda para suavizar los componentes de una serie de tiempo, como se verá en el capítulo 5. Para datos trimestrales, un promedio móvil de cuatro trimestres, MA(4), genera un promedio de los cuatro trimestres, y para datos mensuales, un promedio móvil de 12 meses, MA(12), elimina o promedia los efectos estacionales. Cuanto más grande es el orden del promedio móvil, mayor es el efecto de suavización.

En el ejemplo 4.3 se usó la técnica del promedio móvil con datos estacionarios. En el ejemplo 4.4 vimos qué pasa cuando se usa el método del promedio móvil en datos con tendencia. La técnica del promedio móvil doble, la cual está diseñada para manejar datos con tendencia, se presenta a continuación.

Promedios móviles dobles

Una manera de pronosticar los datos de las series de tiempo que tienen una tendencia lineal es usar promedios móviles dobles. Este método hace lo que indica su nombre: se calcula un conjunto de promedios móviles y luego se calcula un segundo conjunto como un promedio móvil del primer conjunto.

La tabla 4-4 presenta los datos de rentas semanales de Movie Video Store, junto con los resultados de la aplicación de un promedio móvil de tres semanas para pronosticar las ventas futuras. El examen de la columna de error en la tabla 4-4 indica que todas las entradas son positivas, lo cual significa que los pronósticos no alcanzaron la tendencia. El promedio móvil de tres semanas y el promedio móvil doble para estos datos se presentan en la figura 4-6. Observe cómo los promedios móviles de tres semanas se quedan retrasados con respecto a los valores reales de periodos similares. Esto ilustra lo que pasa cuando se emplea la técnica de promedios móviles con datos que muestran una tendencia. Advierta también que los pronósticos realizados mediante promedios móviles dobles se retrasan con respecto al primer conjunto de pronósticos casi tanto como éste se atrasa con respecto a los valores reales. La diferencia entre los dos conjuntos de promedios móviles se suma al promedio móvil de tres semanas para pronosticar los valores reales.


La construcción de un promedio móvil doble se resume en las ecuaciones 4.9 a 4.12. Primero, se usa la ecuación 4.8 para calcular el promedio móvil de orden k .

$$M_t = \hat{Y}_{t+1} = \frac{Y_t + Y_{t-1} + Y_{t-2} + \cdots + Y_{t-k+1}}{k}$$

TABLA 4-4 Rentas semanales de la Movie Video Store para el ejemplo 4.4

t	Unidades semanales rentadas Y_t	Variación total en tres semanas	Promedio móvil del pronóstico $\hat{Y}_{t+1}$	e
1	654	—	—	—
2	658	—	—	—
3	665	1,977	—	—
4	672	1,995	659	13
5	673	2,010	665	8
6	671	2,016	670	1
7	693	2,037	672	21
8	694	2,058	679	15
9	701	2,088	686	15
10	703	2,098	696	7
11	702	2,106	699	3
12	710	2,115	702	8
13	712	2,124	705	7
14	711	2,133	708	3
15	728	2,151	711	17
16	—	—	717	—

MSE = 133

**FIGURA 4-6** Promedios móviles simple y doble de tres semanas de los datos de la Movie Video Store para el ejemplo 4.4

Entonces se usa la ecuación 4.9 para calcular el segundo promedio móvil:

$$M'_t = \frac{M_t + M_{t-1} + M_{t-2} + \cdots + M_{t-k+1}}{k} \quad (4.9)$$

Se emplea la ecuación 4.10 para desarrollar un pronóstico sumando al promedio móvil simple la diferencia entre el promedio móvil simple y el segundo promedio móvil.

$$a_t = M_t + (M_t - M'_t) = 2M_t - M'_t \quad (4.10)$$

La ecuación 4.11 es un factor de ajuste adicional, que es similar a la medida de cambio a lo largo de la serie:

$$b_t = \frac{2}{k-1}(M_t - M_t') \quad (4.11)$$

Finalmente, se usa la ecuación 4.12 para realizar el pronóstico de p periodos en el futuro.

$$\hat{Y}_{t+p} = a_t + b_t p \quad (4.12)$$

donde

k = número de periodos en el promedio móvil

p = número de periodos futuros por pronosticar

Ejemplo 4.4

La Movie Video Store opera varias tiendas de renta de películas en Denver, Colorado. La compañía está creciendo y necesita expandir su inventario para adaptar sus servicios a la creciente demanda. El presidente de la compañía asignó a Jill Ottenbreit la tarea de realizar un pronóstico de las rentas para el siguiente mes. Están disponibles los datos de las rentas de las últimas 15 semanas y se presentan en la tabla 4-5. En primer lugar, Jill intenta desarrollar un pronóstico usando un promedio móvil de tres semanas. El MSE para este modelo es 133 (véase la tabla 4-4). Puesto que los datos tienen una tendencia obvia, Jill descubre que sus pronósticos están subestimando de manera sistemática las rentas reales. Por esta razón decide intentar con un promedio móvil doble. Los resultados se presentan en la tabla 4-5. Para entender el pronóstico de la semana 16, se presentan los cálculos a continuación. Se emplea la ecuación 4.8 para calcular el promedio móvil de tres semanas (columna 3).

$$M_{15} = \hat{Y}_{15+1} = \frac{Y_{15} + Y_{15-1} + Y_{15-3+1}}{3}$$

$$M_{15} = \hat{Y}_{16} = \frac{728 + 711 + 712}{3} = 717$$

TABLA 4-5 Pronóstico de promedio móvil doble para Movie Video Store del ejemplo 4.4

(1) Tiempo t	(2) Ventas semanales Y_t	(3) Promedio móvil de tres semanas M_t	(4) Promedio móvil doble M_t'	(5) Valor de a	(6) Valor de b	(7) Pronóstico $a + bp$ ($p = 1$)	(8) e_t
1	654	—	—	—	—	—	—
2	658	—	—	—	—	—	—
3	665	659	—	—	—	—	—
4	672	665	—	—	—	—	—
5	673	670	665	675	5	—	—
6	671	672	669	675	3	680	-9
7	693	679	674	684	5	678	15
8	694	686	679	693	7	689	5
9	701	696	687	705	9	700	1
10	703	699	694	704	5	714	-11
11	702	702	699	705	3	709	-7
12	710	705	702	708	3	708	2
13	712	708	705	711	3	711	1
14	711	711	708	714	3	714	-3
15	728	717	712	722	5	717	11
16	—	—	—	—	—	727	—

$MSE = 63.7$

Luego se usa la ecuación 4.9 para calcular el promedio móvil doble (columna 4).

$$M'_{15} = \frac{M_{15} + M_{15-1} + M_{15-3+1}}{3}$$

$$M'_{15} = \frac{717 + 711 + 708}{3} = 712$$

Se emplea la ecuación 4.10 para calcular la diferencia entre los dos promedios móviles (columna 5).

$$a_{15} = 2M_{15} - M'_{15} = 2(717) - 712 = 722$$

Se utiliza la ecuación 4.11 para ajustar la pendiente (columna 6).

$$b_{15} = \frac{2}{3-1}(M_{15} - M'_{15}) = \frac{2}{2}(717 - 712) = 5$$

Se usa la expresión 4.12 para hacer el pronóstico de un periodo futuro (columna 7).

$$\hat{Y}_{15+1} = a_{15} + b_{15}p = 722 + 5(1) = 727$$

El pronóstico de 4 semanas en el futuro es:

$$\hat{Y}_{15+4} = a_{15} + b_{15}p = 722 + 5(4) = 742$$

Note que el *MSE* se ha reducido de 133 a 63.7.

Parece razonable que las observaciones más recientes son las que probablemente contienen la información más importante. En la siguiente sección se presenta un procedimiento que hace más énfasis en las observaciones más recientes.

MÉTODOS DE SUAVIZACIÓN EXPONENCIAL

Mientras que el método de promedios móviles toma en cuenta sólo las observaciones más recientes, la suavización exponencial simple ofrece un promedio móvil con peso exponencial para todos los valores previos observados. A menudo el modelo es adecuado para datos que no tienen una tendencia predecible ascendente o descendente. El objetivo es estimar el nivel real. Esta estimación de nivel se emplea luego como el pronóstico de valores futuros.

La suavización exponencial revisa continuamente un estimado a la luz de las experiencias más recientes. Este método se basa en promediar (suavizar) valores pasados de una serie de manera exponencialmente decreciente. La observación más reciente recibe el peso más grande, α (donde $0 < \alpha < 1$); la siguiente observación más reciente recibe menos peso, $\alpha(1 - \alpha)$; la observación de dos periodos en el pasado recibe incluso menos peso, $\alpha(1 - \alpha)^2$; y así sucesivamente.

En una representación de suavización exponencial, el nuevo pronóstico (para el tiempo $t + 1$) puede considerarse como la suma ponderada de la nueva observación (en el tiempo t) y el antiguo pronóstico (para el tiempo t). Se asigna el peso α ($0 < \alpha < 1$) al nuevo valor observado, y el peso $(1 - \alpha)$ al último pronóstico. Así,

$$\text{Nuevo pronóstico} = [\alpha \times (\text{nueva observación})] + [(1 - \alpha) \times (\text{último pronóstico})]$$

Más formalmente, la ecuación de suavización exponencial es

$$\hat{Y}_{t+1} = \alpha Y_t + (1 - \alpha) \hat{Y}_t \quad (4.13)$$

donde

$\hat{Y}_{t+1}$ = nuevo valor suavizado o el valor del pronóstico para el siguiente periodo

α = constante de suavización ($0 < \alpha < 1$)

Y_t = nueva observación o el valor real de la serie en el periodo t

$\hat{Y}_t$ = último valor suavizado o el pronóstico del periodo t

La ecuación 4.13 se puede escribir como:

$$\begin{aligned}\hat{Y}_{t+1} &= \alpha Y_t + (1-\alpha)\hat{Y}_t = \alpha Y_t + \hat{Y}_t - \alpha \hat{Y}_t \\ \hat{Y}_{t+1} &= \hat{Y}_t + \alpha(Y_t - \hat{Y}_t)\end{aligned}$$

De esta forma, el nuevo pronóstico ($\hat{Y}_{t+1}$) es el viejo ($\hat{Y}_t$) ajustado en α veces el error $Y_t - \hat{Y}_t$ en el pronóstico antiguo.

En la ecuación 4.13 la constante de suavización, α , sirve como el factor de ponderación. El valor de α determina el grado con el cual la observación actual influye en el pronóstico de la siguiente observación. Cuando α es cercano a 1, el nuevo pronóstico será, en esencia, la observación actual. (Asimismo, el nuevo pronóstico será el pronóstico anterior más un ajuste sustancial por cualquier error que haya ocurrido en el pronóstico precedente). A la inversa, cuando α es cercano a cero, el nuevo pronóstico será muy similar al pronóstico anterior, y la observación actual tendrá muy poco efecto.

La *suavización exponencial* es un procedimiento para revisar de forma continua un pronóstico a la luz de la experiencia más reciente.

Finalmente, la ecuación 4.13 supone que, para el tiempo t , $\hat{Y}_t = \alpha \hat{Y}_{t-1} + (1 - \alpha)Y_{t-1}$, y al sustituir en la ecuación 4.13 se obtiene:

$$\begin{aligned}\hat{Y}_{t+1} &= \alpha Y_t + (1 - \alpha)\hat{Y}_t = \alpha Y_t + (1 - \alpha)[\alpha Y_{t-1} + (1 - \alpha)\hat{Y}_{t-1}] \\ \hat{Y}_{t+1} &= \alpha Y_t + \alpha(1 - \alpha)Y_{t-1} + (1 - \alpha)^2\hat{Y}_{t-1}\end{aligned}$$

La sustitución continua (de $\hat{Y}_{t-1}$ y así sucesivamente) indica que $\hat{Y}_{t+1}$ puede escribirse como la suma de la Y actual y las anteriores con pesos que descienden exponencialmente

$$\hat{Y}_{t+1} = \alpha Y_t + \alpha(1 - \alpha)Y_{t-1} + \alpha(1 - \alpha)^2Y_{t-2} + \alpha(1 - \alpha)^3Y_{t-3} + \cdots \quad (4.14)$$

Es decir, $\hat{Y}_{t+1}$ es un valor suavizado exponencialmente. La rapidez con la cual las observaciones pasadas pierden su efecto depende del valor de α , como se demuestra en la tabla 4-6.

Las ecuaciones 4.13 y 4.14 son equivalentes, pero la ecuación 4.13 se emplea generalmente para calcular el pronóstico de $\hat{Y}_{t+1}$ porque requiere menos almacenamiento de datos y se aplica fácilmente.

El valor asignado a α es la clave del análisis. Si se desea que las predicciones sean estables y las variaciones aleatorias se suavicen, se requiere un valor pequeño de α . Si se desea una respuesta rápida a un cambio real en el patrón de observaciones, un valor más grande de α es el apropiado. Un método para estimar α es un procedimiento iterativo que minimiza el error cuadrático medio (*MSE*) dado por la ecuación 3.8. Los pronósticos se calculan para, digamos, $\alpha = .1, .2, \dots, .9$, y se calcula la suma de los errores cuadráticos del pronóstico de cada uno de ellos.

TABLA 4-6 Comparación de constantes de suavización

Periodo	$\alpha = .1$		$\alpha = .6$	
	Cálculos	Peso	Cálculos	Peso
t		.100		.600
$t-1$	$.9 \times .1$	.090	$.4 \times .6$	.240
$t-2$	$.9 \times .9 \times .1$	.081	$.4 \times .4 \times .6$	.096
$t-3$	$.9 \times .9 \times .9 \times .1$	.073	$.4 \times .4 \times .4 \times .6$	.038
$t-4$	$.9 \times .9 \times .9 \times .9 \times .1$	.066	$.4 \times .4 \times .4 \times .4 \times .6$	.015
Todos los demás		.590		.011
	Totales	1.000		1.000

Se selecciona el valor de α que produzca el error más pequeño para usarlo en la generación de futuros pronósticos.

Para aplicar el algoritmo de la ecuación 4.13, se debe fijar un pronóstico. Una manera de fijar el primer pronóstico es tomarlo como la primera observación. El ejemplo 4.5 ilustrará este enfoque. Otro método es usar el promedio de las primeras cinco o seis observaciones del valor inicial suavizado.

Ejemplo 4.5

La técnica de suavización exponencial se presenta en la tabla 4-7 y en la figura 4-7 con datos de Acme Tool Company para los años 2000 a 2006, usando constantes de suavización de .1 y .6. Los datos del primer trimestre de 2006 se usarán como datos de prueba para ayudar a determinar el valor más adecuado de α (entre los dos considerados). La serie suavizada exponencialmente se calcula igualando la $\hat{Y}_1$ inicial a 500. Si existen datos anteriores, será posible usarlos para desarrollar una serie suavizada hasta el 2000 y luego usar esta experiencia como el valor inicial de la serie suavizada. Los cálculos que conducen al pronóstico de los periodos 3 y 4 se presentan a continuación:

1. Usando la ecuación 4-13, para el periodo de tiempo 2, el pronóstico para el periodo 3, con $\alpha = .1$ es

$$\begin{aligned}\hat{Y}_{2+1} &= \alpha Y_2 + (1 - \alpha) \hat{Y}_2 \\ \hat{Y}_3 &= .1(350) + .9(500) = 485\end{aligned}$$

2. El error en este pronóstico es

$$e_3 = Y_3 - \hat{Y}_3 = 250 - 485 = -235$$

3. El pronóstico para el periodo 4 es:

$$\begin{aligned}\hat{Y}_{3+1} &= \alpha Y_3 + (1 - \alpha) \hat{Y}_3 \\ \hat{Y}_4 &= .1(250) + .9(485) = 461.5\end{aligned}$$

En la tabla 4-7, cuando la constante de suavización es .1, el pronóstico para el primer trimestre de 2006 es 469, con un error cuadrático de 145,161. Cuando la constante de suavización es .6, el pronóstico para el primer trimestre de 2006 es 576, con un error cuadrático de 75,076. Con base en esta limitada evidencia, la suavización exponencial con $\alpha = .6$ funciona mejor que la suavización exponencial con $\alpha = .1$.

En la figura 4-7, advierta cómo son estables los valores suavizados para la constante de suavización .1. Con base en la minimización del error cuadrático medio *MSE* (el *MSE* se llama *MSD* en el resultado de Minitab), durante los primeros 24 trimestres, es mejor la constante de

TABLA 4-7 Valores de Acme Tool Company suavizados exponencialmente para el ejemplo 4.5

<i>Tiempo</i>		<i>Valor real</i>	<i>Valor suavizado</i>	<i>Error de pronóstico</i>	<i>Valor suavizado</i>	<i>Error de pronóstico</i>
<i>Año</i>	<i>Trimestres</i>	Y_t	$\hat{Y}_t(\alpha = .1)$	e_t	$\hat{Y}_t(\alpha = .6)$	e_t
2000	1	500	500.0	0.0	500.0	0.0
	2	350	500.0	-150.0	500.0	-150.0
	3	250	485.0 (1)	-235.0 (2)	410.0	-160.0
	4	400	461.5 (3)	-61.5	314.0	86.0
2001	5	450	455.4	-5.4	365.6	84.4
	6	350	454.8	-104.8	416.2	-66.2
	7	200	444.3	-244.3	376.5	-176.5
	8	300	419.9	-119.9	270.6	29.4
2002	9	350	407.9	-57.9	288.2	61.8
	10	200	402.1	-202.1	325.3	-125.3
	11	150	381.9	-231.9	250.1	-100.1
	12	400	358.7	41.3	190.0	210.0
2003	13	550	362.8	187.2	316.0	234.0
	14	350	381.6	-31.5	456.4	-106.4
	15	250	378.4	-128.4	392.6	-142.6
	16	550	365.6	184.4	307.0	243.0
2004	17	550	384.0	166.0	452.8	97.2
	18	400	400.6	-0.6	511.1	-111.1
	19	350	400.5	-50.5	444.5	-94.5
	20	600	395.5	204.5	387.8	212.2
2005	21	750	415.9	334.1	515.1	234.9
	22	500	449.3	-50.7	656.0	-156.0
	23	400	454.4	-54.4	562.4	-162.4
	24	650	449.0	201.0	465.0	185.0
2006	25	850	469.0	381.0	576.0	274.0

Nota: Los números entre paréntesis se refieren a las explicaciones que se dan en el texto del ejemplo 4.5.

suavización .6. Si se comparan los errores porcentuales absolutos medios (*MAPE*), la constante de suavización de .6 también es mejor. Resumiendo:

$$\alpha = .1 \quad MSE = 24,262 \quad MAPE = 38.9\%$$

$$\alpha = .6 \quad MSE = 22,248 \quad MAPE = 36.5\%$$

Sin embargo, tanto el *MSE* como el *MAPE* son grandes y, con base en estos estadísticos de resumen, es evidente que la suavización exponencial no representa bien estos datos. Como veremos, un método de suavización que permite la estacionalidad hace un mejor trabajo para predecir las ventas de serruchos de Acme Tool Company.

Un factor, diferente de la selección de α , que afecta los valores de pronósticos subsiguientes es la selección del valor inicial, $\hat{Y}_1$ de la serie suavizada. En la tabla 4-7 (véase el ejemplo 4.5), se utilizó $\hat{Y}_1 = Y_1$ como el valor inicial suavizado. Esta selección tiende a otorgar demasiado peso a Y_1 en los pronósticos posteriores. Por fortuna, la influencia del pronóstico inicial disminuye considerablemente conforme se incrementa t .





FIGURA 4-7 Suavización exponencial de los datos de Acme Tool Company del ejemplo 4.5: (arriba) $\alpha = .1$ y (abajo) $\alpha = .6$

Otro enfoque de inicialización del procedimiento de suavización es promediar las primeras k observaciones. Entonces, la suavización inicia con:

$$\hat{Y}_1 = \frac{1}{k} \sum_{t=1}^k Y_t$$

A menudo se selecciona un número relativamente pequeño para k . Por ejemplo, Minitab predetermina que $k = 6$.

Ejemplo 4.6

El cálculo del valor inicial como un promedio para los datos de Acme Tool Company presentados en el ejemplo 4.5 se muestra a continuación. Si se iguala k a 6, entonces el valor inicial es:

$$\hat{Y}_1 = \frac{1}{6} \sum_{t=1}^6 Y_t = \frac{1}{6}(500 + 350 + 250 + 400 + 450 + 350) = 383.3$$

A continuación se presentan el MSE y el $MAPE$ para cada α cuando se usa un valor inicial suavizado de 383.3:

$$\alpha = .1 \quad MSE = 21,091 \quad MAPE = 32.1\%$$

$$\alpha = .6 \quad MSE = 22,152 \quad MAPE = 36.7\%$$

El valor inicial $\hat{Y}_1 = 383.3$, trae consigo una disminución del MSE y el $MAPE$ para $\alpha = .1$, pero no tiene mucho efecto cuando $\alpha = .6$. Ahora el mejor modelo, basado en las medidas de resumen del MSE y el $MAPE$, parece ser uno que use $\alpha = .1$ en vez de $.6$.

La figura 4-8 presenta los resultados del ejemplo 4.5 cuando los datos se corren en Minitab (para instrucciones específicas, véase la sección de aplicaciones de Minitab al final del capítulo). La constante de suavización $\alpha = .266$ fue seleccionada automáticamente al minimizar el MSE . El MSE se redujo a 19,447, el $MAPE$ es igual al 32.2% y, aunque no se indica, el MPE es igual a -6.4% . El pronóstico para el primer trimestre de 2006 es 534.

La figura 4-9 presenta la función de autocorrelación para los residuos del método de suavización exponencial usando una alfa de .266. Cuando la prueba de Ljung-Box se realiza para seis retrasos de tiempo, el gran valor de LBQ (33.86) indica que el conjunto de las primeras seis autocorrelaciones residuales son más grandes de lo que se esperaría si los residuos fueran aleatorios. En particular, las autocorrelaciones de los residuos tan significativamente grandes en los retrasos 2 y 4 indican que la variación estacional en los datos que no se explica mediante un suavizamiento exponencial simple.

La suavización exponencial a menudo es un buen procedimiento para pronosticar cuando una serie de tiempo que no es aleatoria exhibe una tendencia en su comportamiento. Es útil desarrollar una medida que se pueda utilizar para determinar cuándo ha cambiado el patrón básico de una serie de tiempo. Una *señal de control* es un modo de supervisar un cambio. Una señal de control implica el cálculo de una medida de los errores de pronóstico en el tiempo y el establecimiento de límites, de manera que, cuando los errores caen fuera de esos límites, el encargado de efectuar el pronóstico recibe una señal de alerta.




FIGURA 4-8 Suavización exponencial con $\alpha = .266$ para los datos de Acme Tool Company para el ejemplo 4.6

Función de autocorrelación: Residuos

Retraso	ACF	T	LBQ
1	0.121421	0.59	0.40
2	-0.588941	-2.84	10.24
3	0.109122	0.41	10.59
4	0.646967	2.40	23.65
5	-0.006908	-0.02	23.65
6	-0.542625	-1.65	33.86




FIGURA 4-9 Función de autocorrelación para los residuos cuando se usa suavización exponencial con $\alpha = .266$ con datos de Acme Tool Company para el Ejemplo 4.6

Una *señal de control* implica el cálculo de una medida de errores de pronóstico en el tiempo y el establecimiento de límites, de manera que, cuando los errores acumulados caen fuera de esos límites, el encargado de efectuar el pronóstico recibe una señal de alerta.

Por ejemplo, podría utilizarse una señal de control para determinar cuándo debe modificarse el valor de la constante de suavización α . Como generalmente se pronostica un número grande de artículos, la práctica común es continuar con el mismo valor de α para varios periodos antes de intentar determinar si es necesaria una revisión. Desafortunadamente, la simplicidad de usar un modelo de suavización exponencial establecido es un fuerte motivador para no hacer un cambio. Pero en algún punto, puede ser necesario actualizar α o abandonar totalmente la suavización exponencial. Cuando el modelo genera pronósticos que contienen muchos errores, es adecuado hacer un cambio.

Un sistema de control es un método para supervisar la necesidad de cambio. Un sistema tal contiene un rango de desviaciones permitidas del pronóstico con respecto a los valores reales. Siempre que los pronósticos generados por la suavización exponencial caigan dentro de este rango, no se necesita ningún cambio de α . Sin embargo, si un pronóstico cae fuera del rango, el sistema señala la necesidad de actualizar α .

Por ejemplo, si las cosas van bien, la técnica de elaboración del pronóstico debería sobreestimar y subestimar con la misma frecuencia. Se puede desarrollar una señal de control con base en esta lógica.

Sea U igual al número de subestimaciones de los últimos n pronósticos fuera de los límites. En otras palabras, U es el número de errores entre los últimos k positivos. Si el proceso está bajo control, el valor esperado de U es $k/2$; aunque está implicada la variabilidad de la muestra, así que los valores cercanos a $k/2$ no son raros. Por otro lado, los valores que no están cercanos a $k/2$ indicarían que la técnica está generando pronósticos con sesgos.

Ejemplo 4.7

Suponga que Acme Tool Company decidió usar la técnica de suavización exponencial con α igual a .1, como se indica en el ejemplo 4.5 (véase la p. 121). Si el proceso está controlado, y el analista decide hacer un seguimiento de los últimos 10 valores de error, U tiene un valor esperado de 5. En realidad,

un valor de U igual a 2, 3, 4, 6, 7 u 8, no sería demasiado alarmante. Sin embargo, un valor de 0, 1, 9 o 10 sería motivo de preocupación, puesto que la probabilidad de obtener un valor tal, sólo por casualidad, sería de .022 (con base en la distribución binomial). Con esta información, se puede desarrollar un sistema de control con base en las siguientes reglas:

Si $2 \leq U \leq 8$, entonces el proceso está bajo control.

Si $U < 2$ o $U > 8$, entonces el proceso está fuera de control.

Suponga que, de los siguientes 10 pronósticos que usan esta técnica, sólo uno tiene un error positivo. Puesto que la probabilidad de obtener un solo error positivo de 10 posibles es muy baja (.011), se considera que el proceso está fuera de control (sobreestimando), y el valor de α debe cambiarse.

Otra manera de dar seguimiento a una técnica de pronósticos es determinar el rango en el que deben estar los errores de pronóstico. Esto puede realizarse usando el MSE que se estableció al determinar el tamaño óptimo de α . Si la técnica de suavización exponencial es razonablemente exacta, el error de pronóstico debe tener una distribución aproximadamente normal alrededor de una media igual a cero. Con esta condición, hay un 95% de probabilidad de que la observación real caiga dentro de aproximadamente dos desviaciones estándar del pronóstico. Usando la $RMSE$ como un estimado de la desviación estándar del error de pronóstico, se pueden determinar los límites de error aproximados a 95%. Los errores de pronóstico que caigan dentro de estos límites indican que no hay motivo de alarma. Los errores (particularmente una secuencia de errores) fuera de los límites sugieren un cambio. El ejemplo 4.8 ilustra este enfoque.

Ejemplo 4.8

En el ejemplo 4.6, sobre Acme Tool Company, se determinó que la α óptima era .266, con $MSE = 19,447$. Un estimado de la desviación estándar de los errores de pronóstico es $RMSE = \sqrt{19,447} = 139.5$. Si los errores de pronóstico tienen distribución aproximadamente normal alrededor de una media de cero, existe un 95% de probabilidad de que la observación real caiga dentro de dos desviaciones estándar del pronóstico, o dentro de:

$$\pm 2RMSE = \pm 2\sqrt{19,447} = \pm 2(139.5) = \pm 279$$

Para este ejemplo, el error permisible absoluto es 279. Si para cualquier pronóstico futuro la magnitud del error es mayor que 279, existen razones para creer que la constante α óptima de suavización debe actualizarse o que debe considerarse un método diferente para la elaboración del pronóstico.

La explicación anterior sobre las señales de control también se aplica a los métodos de suavización que serán discutidos en el resto del capítulo.

La suavización exponencial simple funciona bien cuando los datos tienen un nivel de cambio infrecuente. Siempre que existe una tendencia sostenida, la suavización exponencial permanecerá retrasada en el tiempo con respecto a los valores reales. La técnica de suavización exponencial lineal de Holt, la cual se diseñó para manejar datos con una tendencia bien definida, enfrenta este problema y se presenta a continuación.

Suavización exponencial ajustada a la tendencia: Método de Holt

En la suavización exponencial simple, se supone que el nivel de las series de tiempo varía ocasionalmente, y se requiere un estimado del nivel actual. En algunas situaciones, los datos observados tienen una tendencia clara y contienen información que permite anticipar movimientos futuros ascendentes. Cuando éste es el caso, se necesita una función de tendencia lineal del pronóstico. Puesto que las series de negocios y económicas rara vez exhiben una tendencia lineal fija, consideramos la posibilidad de modelar tendencias lineales locales en evolución con el tiempo. Holt (2004) desarrolló un método de suavización exponencial, conocida como la *suavización exponencial lineal de Holt*,¹ la cual toma en cuenta la evolución local lineal de las tendencias en una serie de tiempo y puede usarse para generar pronósticos.

¹La suavización exponencial lineal de Holt algunas veces se conoce como *suavización exponencial doble*.

Cuando se anticipa una tendencia en una serie de tiempo, se requiere un estimado de la pendiente actual, así como del nivel actual. La técnica de Holt suaviza directamente el nivel y la pendiente usando diferentes constantes de suavización para cada uno. Estas constantes de suavización proporcionan estimados del nivel y la pendiente que se adaptan en el tiempo conforme se dispone de nuevas observaciones. Una de las ventajas de la técnica de Holt es que ofrece un alto grado de flexibilidad en la selección de coeficientes con los cuales se controla el nivel y la tendencia.

Las tres ecuaciones usadas en el método de Holt son

1. La serie suavizada exponencialmente o nivel actual estimado

$$L_t = \alpha Y_t + (1 - \alpha)(L_{t-1} + T_{t-1}) \quad (4.15)$$

2. El estimado de la tendencia

$$T_t = \beta(L_t - L_{t-1}) + (1 - \beta)T_{t-1} \quad (4.16)$$

3. El pronóstico para los p periodos del futuro

$$\hat{Y}_{t+p} = L_t + pT_t \quad (4.17)$$

donde

L_t = nuevo valor suavizado (estimado del nivel actual)

$\alpha = 1$, constante de suavización para el nivel ($0 < \alpha < 1$)

Y_t = nueva observación o valor real de la serie en el periodo t

β = constante de suavización para el estimado de la tendencia ($0 < \beta < 1$)

T_t = estimado de tendencia

p = periodos a pronosticar en el futuro

$\hat{Y}_{t+p}$ = pronóstico para el periodo p en el futuro

La ecuación 4.15 es muy similar a la ecuación de la suavización exponencial simple, la ecuación 4.13, excepto que se ha incorporado el término (T_{t-1}) para actualizar adecuadamente el nivel cuando existe una tendencia. Es decir, el nivel actual (L_t) se calcula tomando un promedio ponderado de dos estimaciones de nivel: una estimación está dada por la observación actual (Y_t), y la otra estimación está dada por la suma de la tendencia previa (T_{t-1}) y el nivel previamente suavizado (L_{t-1}). Si no existe una tendencia en los datos, no hay necesidad del término T_{t-1} en la ecuación 4.15, reduciéndola efectivamente a la ecuación 4.13. Tampoco es necesaria la ecuación 4.16.

Para efectuar la estimación de la tendencia, se usa una nueva constante de suavización, β . La ecuación 4.16 indica que la tendencia actual (T_t) es un promedio ponderado (con pesos β y $1 - \beta$) de dos tendencias estimadas: una estimación está dada por el cambio en el nivel de tiempo $t - 1$ a t ($L_t - L_{t-1}$), y la otra estimación es la tendencia previamente suavizada (T_{t-1}). La ecuación 4.16 es similar a la ecuación 4.15, excepto que la suavización se hace para la tendencia y no para los datos reales.

La ecuación 4.17 muestra el pronóstico para p periodos en el futuro. Para un pronóstico hecho en el tiempo t , la tendencia actual estimada (T_t) se multiplica por el número de periodos (p) que serán pronosticados, y luego el producto se suma al nivel actual (L_t). Note que los pronósticos para periodos futuros permanecen a lo largo de una línea recta con pendiente T_t e intersección en L_t .

Al igual que en la suavización exponencial simple, las constantes de suavización α y β pueden seleccionarse subjetivamente o generarse minimizando una medida de error de pronóstico tal como el *MSE*. Pesos grandes tienen como resultado cambios más rápidos en el componente; pesos pequeños tienen como resultado cambios menos rápidos. Por lo tanto, cuanto mayores son los pesos, los valores de suavizamiento seguirán más a los datos; cuanto menores son los pesos, los valores de suavizamiento seguirán más a los valores de suavizamiento previos.

Podríamos desarrollar una tabla de valores de α y β (por ejemplo, cada combinación de $\alpha = 0.1, 0.2, \dots, 0.9$ y $\beta = 0.1, 0.2, \dots, 0.9$) y luego seleccionar la combinación que dé el menor MSE . La mayoría de los paquetes de software para elaboración de pronósticos usan un algoritmo de optimización para minimizar el MSE . Podríamos insistir en que $\alpha = \beta$, proporcionando así cantidades iguales de suavización para el nivel y la tendencia. En el caso especial en que $\alpha = \beta$, el método de Holt es igual que la suavización exponencial doble de Brown.

Para iniciar, se deben determinar los valores iniciales de L y T en las ecuaciones 4.15 y 4.16. Un enfoque consiste en fijar la primera estimación del nivel suavizado igual a la primera observación. Luego se considera la tendencia igual a cero. Un segundo enfoque es usar el promedio de las primeras cinco o seis observaciones como el valor suavizado inicial de L . Luego, se estima la tendencia usando la pendiente de una línea ajustada a estas cinco o seis observaciones. Minitab desarrolla una ecuación de regresión usando la variable de interés como Y y el tiempo como la variable independiente X . La constante de esta ecuación es la estimación inicial del componente de nivel, y la pendiente o el coeficiente de regresión es la estimación inicial del componente de tendencia.

Ejemplo 4.9

En el ejemplo 4.6 la suavización exponencial simple no produjo pronósticos exitosos de las ventas de serruchos de Acme Tool Company. Como la figura 4-8 sugiere que podría haber una tendencia en estos datos, se usa la suavización exponencial lineal de Holt para desarrollar los pronósticos. Para iniciar los cálculos mostrados en la tabla 4-8, se necesita estimar dos valores iniciales, a saber, el valor del nivel inicial y el valor de la tendencia inicial. El estimado del nivel se iguala a la primera observación. La tendencia se iguala a cero. La técnica se presenta en la tabla 4-8 para $\alpha = .3$ y $\beta = .1$.

El valor de α que se usa aquí es cercano al valor óptimo de α ($\alpha = .266$) para la suavización exponencial simple del ejemplo 4.6. Se usa α en la suavización de los datos para eliminar la aleatoriedad y estimar el nivel. La constante de suavización β es como α , excepto que se usa para suavizar la tendencia en los datos. Ambas constantes de suavización se utilizan para promediar valores pasados y así eliminar la aleatoriedad. A continuación se presentan los cálculos para obtener el pronóstico del periodo 3.

1. Actualización de la serie o nivel suavizado exponencialmente:

$$\begin{aligned}L_t &= \alpha Y_t + (1 - \alpha)(L_{t-1} + T_{t-1}) \\L_2 &= .3Y_2 + (1 - .3)(L_{2-1} + T_{2-1}) \\L_2 &= .3(350) + .7(500 + 0) = 455\end{aligned}$$

2. Actualización de la estimación de la tendencia:

$$\begin{aligned}T_t &= \beta(L_t - L_{t-1}) + (1 - \beta)T_{t-1} \\T_2 &= .1(L_2 - L_{2-1}) + (1 - .1)T_{2-1} \\T_2 &= .1(455 - 500) + .9(0) = -4.5\end{aligned}$$

3. Pronóstico de un periodo futuro:

$$\begin{aligned}\hat{Y}_{t+p} &= L_t + pT_t \\\hat{Y}_{2+1} &= L_2 + 1T_2 = 455 + 1(-4.5) = 450.5\end{aligned}$$

4. Determinación del error de pronóstico:

$$e_3 = Y_3 - \hat{Y}_3 = 250 - 450.5 = -200.5$$

El pronóstico para el periodo 25 se calcula como sigue:

1. Actualización de la serie o nivel suavizado exponencialmente:

$$\begin{aligned}L_{24} &= .3Y_{24} + (1 - .3)(L_{24-1} + T_{24-1}) \\L_{24} &= .3(650) + .7(517.6 + 9.8) = 564.2\end{aligned}$$

TABLA 4-8 Valores de las ventas suavizadas exponencialmente de Acme Tool Company, por el método de Holt, para el ejemplo 4.9

Año	t	Y_t	L_t	T_t	$\hat{Y}_{t+p}$	e_t
2000	1	500	500.0	0.0	500.0	0.0
	2	350	455.0	-4.5	500.0	-150.0
	3	250	390.4	-10.5	450.5	-200.5
	4	400	385.9	-9.9	379.8	20.2
2001	5	450	398.2	-7.7	376.0	74.0
	6	350	378.3	-8.9	390.5	-40.5
	7	200	318.6	-14.0	369.4	-169.4
	8	300	303.2	-14.1	304.6	-4.6
2002	9	350	307.4	-12.3	289.1	60.9
	10	200	266.6	-15.2	295.1	-95.1
	11	150	221.0	-18.2	251.4	-101.4
	12	400	262.0	-12.3	202.8	197.2
2003	13	550	339.8	-3.3	249.7	300.3
	14	350	340.6	-2.9	336.5	13.5
	15	250	311.4	-5.5	337.7	-87.7
	16	550	379.1	1.8	305.9	244.1
2004	17	550	431.7	6.9	381.0	169.0
	18	400	427.0	5.7	438.6	-38.6
	19	350	407.9	3.3	432.7	-82.7
	20	600	467.8	8.9	411.2	188.8
2005	21	750	558.7	17.1	476.8	273.2
	22	500	553.1	14.8	575.9	-75.9
	23	400	517.6	9.8	567.9	-167.9
	24	650	564.2	13.5	527.4	122.6
2006	25	850	—	—	577.7	272.3

$MSE = 20,515.5$

2. Actualización del cálculo de la tendencia:

$$T_{24} = .1(L_{24} - L_{24-1}) + (1 - .1)T_{24-1}$$

$$T_{24} = .1(564.2 - 517.6) + .9(9.8) = 13.5$$

3. Pronóstico de un periodo futuro:

$$\hat{Y}_{24+1} = L_{24} + 1T_{24}$$

$$\hat{Y}_{25} = 564.2 + 1(13.5) = 577.7$$

Con base en la minimización del MSE durante el periodo 2000 a 2006, la suavización lineal de Holt (con $\alpha = .3$ y $\beta = .1$) no reproduce los datos mejor que la suavización exponencial simple que usó una constante de suavización de .266. Una comparación de los $MAPE$ indica que son iguales. Cuando se comparan los pronósticos de las ventas actuales del primer trimestre de




FIGURA 4-10 Suavización exponencial lineal de Holt de los datos de Acme Tool Company para el ejemplo 4.9

2006, una vez más la suavización de Holt y la suavización exponencial simple son comparables. Resumiendo:

$$\begin{aligned} \alpha &= .266 & MSE &= 19,447 & MAPE &= 32.2\% \\ \alpha &= .3, \beta &= .1 & MSE &= 20,516 & MAPE &= 35.4\% \end{aligned}$$

La figura 4-10 presenta los resultados cuando el método de Holt con $\alpha = .3$ y $\beta = .1$ se corre en Minitab.² La función de autocorrelación para los residuos de la suavización exponencial lineal de Holt se presenta en la figura 4-11. Los coeficientes de autocorrelación en los retrasos 2 y 4 parecen significantes. También, cuando se calcula el estadístico Q de Ljung-Box para seis retrasos de tiempo, el valor grande del estadístico LBQ (36.33) indica que los residuos contienen autocorrelaciones grandes; no son aleatorios. Las grandes autocorrelaciones residuales en los retrasos 2 y 4 sugieren que puede estar presente un componente estacional en los datos de Acme Tool Company.

Los resultados en los ejemplos 4.6 y 4.9 (véanse las figuras 4-8 y 4-10) no son muy diferentes porque la constante α de suavización es aproximadamente la misma en ambos casos y la constante de suavización β en el ejemplo 4.9 es pequeña. (Para $\beta = 0$, la suavización lineal de Holt se convierte en una suavización exponencial simple).

Suavización exponencial ajustada a la tendencia y a la variación estacional: Método de Winters

La revisión de los datos de Acme Tool Company en la tabla 4-8 indica que las ventas son más altas durante el primero y el cuarto trimestres y más bajas durante el tercer trimestre de manera sistemática. Parece que existe un patrón estacional. El método de suavización exponencial lineal y estacional de tres parámetros de Winters, una extensión del método de Holt, podría representar mejor los datos y reducir el error de pronóstico. En el método de Winters, se emplea una ecuación adicional para estimar la estacionalidad. En la versión multiplicativa del método de Winters, la estimación de la estacionalidad está dada por un índice estacional y se calcula mediante la ecuación 4.20. Esta última indica que para calcular el componente esta-

²En el programa de Minitab, el parámetro de tendencia gama (γ) es idéntico a nuestra beta (β).

Función de autocorrelación: Residuos

Retraso	ACF	T	LBQ
1	0.092547	0.45	0.23
2	-0.629408	-3.06	11.47
3	0.074355	0.27	11.63
4	0.601371	2.18	22.92
5	-0.070132	-0.22	23.08
6	-0.618267	-1.90	36.33




FIGURA 4-11 Función de autocorrelación de los residuos de la suavización exponencial lineal de Holt de los catos de Acme Tool Company para el Ejemplo 4.9

cional actual, S_t , el producto de γ y un estimado del índice estacional dado por Y_t/L_t se suma $(1 - \gamma)$ veces al componente estacional previo S_{t-s} . Este procedimiento es equivalente a suavizar los valores previos y actuales de Y_t/L_t . Y_t se divide entre el nivel actual estimado L_t , para crear un índice (razón) que pueda usarse de forma multiplicativa para ajustar un pronóstico que tome en cuenta los picos y valles estacionales.

Las cuatro ecuaciones usadas en la suavización (multiplicativa) de Winters son

1. Series suavizadas exponencialmente o nivel estimado:

$$L_t = \alpha \frac{Y_t}{S_{t-s}} + (1 - \alpha)(L_{t-1} + T_{t-1}) \quad (4.18)$$

2. Estimación de la tendencia:

$$T_t = \beta(L_t - L_{t-1}) + (1 - \beta)T_{t-1} \quad (4.19)$$

3. Estimado de estacionalidad:

$$S_t = \gamma \frac{Y_t}{L_t} + (1 - \gamma)S_{t-s} \quad (4.20)$$

4. Pronóstico de p periodos futuros:

$$\hat{Y}_{t+p} = (L_t + pT_t)S_{t-s+p} \quad (4.21)$$

donde

L_t = nuevo valor suavizado (estimado de nivel actual)

α = constante de suavización del nivel

Y_t = nueva observación o valor real en el periodo t

β = constante de suavización para el estimado de tendencia

T_t = estimado de tendencia

γ = constante de suavización para el estimado de estacionalidad

S_t = estimado de estacionalidad

p = periodos futuros a pronosticarse

s = longitud de la estacionalidad

$\hat{Y}_{t+p}$ = el pronóstico para el periodo p en el futuro

La ecuación 4.18 actualiza las series suavizadas. Una ligera diferencia en esta ecuación la distingue de la correspondiente en el procedimiento de Holt, la ecuación 4.15. En la ecuación 4.18, Y_t se divide entre S_{t-s} , lo cual ajusta Y_t para la estacionalidad, eliminando así los efectos estacionales que pudieran existir en los datos originales Y_t .

Después de que la estimación de la tendencia y la estimación de la estacionalidad se han suavizado en las ecuaciones 4.19 y 4.20, se obtiene un pronóstico con la ecuación 4.21. Casi es igual que la fórmula correspondiente, la ecuación 4.17, usada para obtener un pronóstico con la suavización de Holt. La diferencia es que esta estimación para futuros periodos, $t + p$, se multiplica por S_{t-s+p} . Este índice estacional es el último disponible y, por consiguiente, se utiliza para ajustar el pronóstico con la estacionalidad.

Al igual que en la suavización exponencial lineal de Holt, los pesos α , β y γ pueden seleccionarse subjetivamente o generarse al minimizar una medida de error de pronóstico, como el *MSE*. El enfoque más común para determinar estos valores es usar un algoritmo de optimización para obtener las constantes óptimas de suavización.

Para iniciar el algoritmo de la ecuación 4.18, se deben establecer los valores iniciales para las series suavizadas, L_t , la tendencia T_t y los índices estacionales S_t . Un método consiste en igualar la primera estimación de la serie suavizada (nivel) a la primera observación. Luego, la tendencia se iguala a cero y cada índice estacional se fija en 1.0. Existen otros métodos para la inicialización de la estimación del nivel, tendencia y estacionalidad. Minitab, por ejemplo, desarrolla una ecuación de regresión usando la variable de interés como Y y el tiempo como la variable independiente X . La constante de esta ecuación es la estimación inicial de la serie suavizada o componente de nivel, y la pendiente o el coeficiente de regresión es la estimación inicial del componente de tendencia. Los valores iniciales de los componentes estacionales se obtienen a partir de una regresión de variable ficticia que usa datos sin tendencia (véase el capítulo 8).

Ejemplo 4.10

En la tabla 4-9 se presenta la técnica de Winters, para $\alpha = .4$, $\beta = .1$ y $\gamma = .3$ para los datos de Acme Tool Company. El valor de α es similar al utilizado en la suavización exponencial simple del ejemplo 4.6 y sirve para suavizar los datos y crear un nivel estimado. La constante de suavización β , se utiliza para crear una estimación suavizada de la tendencia. La constante de suavización γ se emplea para crear una estimación suavizada del componente estacional en los datos.

Es factible usar Minitab para resolver este ejemplo (para instrucciones específicas, véase la sección de aplicaciones de Minitab al final del capítulo).³ Los resultados se muestran en la tabla 4-9 y en la figura 4-12. El pronóstico para el primer trimestre de 2006 es 778.2. Los cálculos para obtener el valor del pronóstico para el primer trimestre de 2006, o periodo 25, se presentan a continuación.

1. La serie suavizada exponencialmente o nivel estimado:

$$L_t = \alpha \frac{Y_t}{S_{t-s}} + (1 - \alpha)(L_{t-1} + T_{t-1})$$

$$L_{24} = .4 \frac{Y_{24}}{S_{24-4}} + (1 - .4)(L_{24-1} + T_{24-1})$$

$$L_{24} = .4 \frac{650}{1.39628} + (1 - .4)(501.286 + 9.148)$$

$$L_{24} = .4(465.52) + .6(510.434) = 492.469$$

³En el programa de Minitab, el parámetro de tendencia gama (γ) es idéntico a nuestra beta (β) y el parámetro estacional delta (δ) es idéntico a nuestra gama (γ) de las ecuaciones 4.19 y 4.20, respectivamente.

TABLA 4-9 Valores suavizados exponencialmente de las ventas de Acme Tool Company, por el método de Winters, para el ejemplo 4.10

Año	t	Y_t	L_t	T_t	S_t	$\hat{Y}_{t+p}$	e_t
2000	1	500	415.459	-41.9541	1.26744	563.257	-63.257
	2	350	383.109	-40.9937	0.89040	328.859	21.141
	3	250	358.984	-39.3068	0.66431	222.565	27.435
	4	400	328.077	-38.4668	1.18766	375.344	24.656
2001	5	450	315.785	-35.8494	1.31471	367.063	82.937
	6	350	325.194	-31.3235	0.94617	249.255	100.745
	7	200	296.748	-31.0358	0.66721	195.221	4.779
	8	300	260.466	-31.5604	1.17690	315.576	-15.576
2002	9	350	243.831	-30.0679	1.35093	300.945	49.055
	10	200	212.809	-30.1632	0.94426	202.255	-2.255
	11	150	199.515	-28.4764	0.69259	121.863	28.137
	12	400	238.574	-21.7228	1.32682	201.294	198.706
2003	13	550	292.962	-14.1117	1.50886	292.949	257.051
	14	350	315.575	-10.4393	0.99371	263.306	86.694
	15	250	327.466	-8.2062	0.71385	211.335	38.665
	16	550	357.366	-4.3956	1.39048	423.599	126.401
2004	17	550	357.588	-3.9339	1.51763	532.584	17.416
	18	400	373.206	-1.9787	1.01713	351.428	48.572
	19	350	418.856	2.7843	0.75038	264.999	85.001
	20	600	425.586	3.1788	1.39628	586.284	13.716
2005	21	750	454.936	5.7959	1.55691	650.706	99.294
	22	500	473.070	7.0297	1.02907	468.626	31.374
	23	400	501.286	9.1484	0.76465	360.255	39.745
	24	650	492.469	7.3518	1.37336	712.712	-62.712
2006	25	850	—	—	—	778.179	—
	26	600	—	—	—	521.917	—
	27	450	—	—	—	393.430	—
	28	700	—	—	—	716.726	—


$MSE = 7,636.86$

2. El estimado de la tendencia:

$$\begin{aligned}
 T_t &= \beta(L_t - L_{t-1}) + (1 - \beta)T_{t-1} \\
 T_{24} &= .1(L_{24} - L_{24-1}) + (1 - .1)T_{24-1} \\
 T_{24} &= .1(492.469 - 501.286) + .9(9.148) \\
 T_{24} &= .1(-8.817) + .9(9.148) = 7.352
 \end{aligned}$$

3. El estimado de la estacionalidad:

$$\begin{aligned}
 S_t &= \gamma \frac{Y_t}{L_t} + (1 - \gamma)S_{t-s} \\
 S_{24} &= .3 \frac{Y_{24}}{L_{24}} + (1 - .3)S_{24-4} \\
 S_{24} &= .3 \frac{650}{492.469} + .7(1.39628) \\
 S_{24} &= .3(1.3199) + .9774 = 1.3734
 \end{aligned}$$



4. El pronóstico para el primer periodo, $p = 1$ en el futuro:

$$\hat{Y}_{24+1} = (L_{24} + 1T_{24})S_{24-4+1}$$

$$\hat{Y}_{25} = (492.469 + 1(7.352))1.5569 = 778.17$$

Para los valores de los parámetros considerados, la técnica de Winters es mejor que los dos procedimientos de suavización anteriores en términos de la minimización del MSE . Cuando se comparan los pronósticos de las ventas reales para el primer trimestre de 2006, la técnica de Winters también parece hacer un mejor trabajo. La figura 4-13 muestra la función de autocorrelación para los residuos de suavización exponencial, con la técnica de Winters. Ninguno de los coeficientes de autocorrelación residual parece ser significativamente mayor que cero. Cuando se calcula el estadístico Q de Ljung-Box para seis retrasos de tiempo, el pequeño valor de LBQ (5.01) indica que la serie residual es aleatoria. El método de suavización exponencial de Winters parece arrojar pronósticos adecuados para los datos de Acme Tool Company.

El método de Winters ofrece una manera fácil de tomar en cuenta la estacionalidad cuando los datos muestran un patrón estacional. Un método alternativo consiste en eliminar la estacionalidad (desestacionalizar) primero o ajustar la estacionalidad de los datos. La desestacionalización es un proceso que elimina los efectos de la estacionalidad en los datos y se estudiará en el capítulo 5. El modelo de elaboración del pronóstico se aplica a los datos desestacionalizados y, si se requiere, se reinserta el componente de estacionalidad para obtener pronósticos exactos.

La suavización exponencial es una técnica habitual para pronósticos de corto plazo. Sus mayores ventajas son su bajo costo y su sencillez. Cuando se necesitan pronósticos para sistemas de inventario que contienen miles de artículos, los métodos de suavización son a menudo el único enfoque aceptable.

Los promedios móviles simples y la suavización exponencial basan los pronósticos en promedios ponderados de mediciones pasadas. El fundamento es que los valores pasados contienen información acerca de lo que ocurrirá en el futuro. Puesto que los valores pasados incluyen fluctuaciones aleatorias, así como información relacionada con el patrón subyacente

Función de autocorrelación para residuos de Winters

Retraso	ACF	T	LBQ
1	0.297749	1.46	2.41
2	-0.031543	-0.14	2.43
3	0.017610	0.08	2.44
4	-0.107084	-0.48	2.80
5	-0.257066	-1.15	4.97
6	0.033280	0.14	5.01




FIGURA 4-13 Función de autocorrelación del método de suavización exponencial multiplicativa de Winters de los residuos para los datos de Acme Tool Company para el ejemplo 4.10

de la variable, se hace un intento para suavizar los valores. La suavización supone que las fluctuaciones extremas representan la aleatoriedad en una serie de observaciones históricas.

Los promedios móviles son las medias de un cierto número, k , de valores de una variable. El promedio más reciente es entonces el pronóstico para el siguiente periodo. Este enfoque asigna un peso igual a cada valor pasado implicado en el promedio. No obstante, es una buena idea usar todos los datos pero haciendo énfasis en los valores más recientes. Los métodos de suavización exponencial son atractivos porque generan pronósticos usando todas las observaciones y asignando pesos que disminuyen exponencialmente conforme las observaciones se vuelven más antiguas.

APLICACIÓN A LA ADMINISTRACIÓN

Los pronósticos son uno de los elementos más importantes con los que cuentan los gerentes para apoyar el proceso de toma de decisiones. Prácticamente todas las decisiones operativas dependen hasta cierto punto de un pronóstico. El departamento de producción tiene que programar, para uno o dos meses, las necesidades de personal y los pedidos de materia prima; el departamento de finanzas debe determinar las mejores oportunidades de inversión; el mercadeo debe pronosticar la demanda de un nuevo producto. La lista de las aplicaciones de los pronósticos es muy extensa.

Los ejecutivos están profundamente conscientes de la importancia del pronóstico. De hecho, se dedica una gran cantidad de tiempo al estudio de las tendencias en asuntos económicos y políticos y en la manera como los acontecimientos pueden afectar la demanda de los productos o servicios. Un tema de interés es la importancia que dan los ejecutivos a los métodos de pronósticos cuantitativos en comparación con sus propias opiniones. Este tema es especialmente sensible cuando se trata de acontecimientos que tienen un efecto significativo en la demanda. Un problema con los métodos de pronóstico cuantitativos es que dependen de datos históricos. Por esta razón, probablemente son menos efectivos en la identificación de un cambio drástico que a menudo tiene como resultado demandas notoriamente más altas o más bajas.

Los métodos de suavización y promedio para la elaboración de pronósticos discutidos en este capítulo son útiles por su relativa sencillez. Estos métodos simples tienden a ser menos costosos, más fáciles de aplicar y más fáciles de comprender que los métodos complejos. A menudo, el costo y las dificultades potenciales asociadas con la construcción de modelos más complejos exceden por mucho cualquier aumento en la exactitud. Por esta razón, los negocios

pequeños encuentran prácticos los métodos simples. Los negocios que no tienen personal capaz de manejar modelos estadísticos también se inclinan por los métodos simples. Los directores de negocios a menudo enfrentan la necesidad de elaborar pronósticos de corto plazo para un buen número de diferentes artículos. Un ejemplo común es el gerente que debe programar la producción con base en algún pronóstico de la demanda de varios cientos de productos diferentes en una línea de producción. También los nuevos negocios sin grandes bases de datos históricos encuentran útiles estos enfoques simples.

Con una selección sensata del orden k , el método de promedio móvil puede hacer un buen trabajo de ajuste de los cambios en los niveles. Su actualización es de bajo costo y no requiere de un gran almacén de datos. El método de promedio móvil se usa más a menudo cuando son necesarios pronósticos repetitivos.

La suavización exponencial es una técnica difundida cuya fortaleza reside en la exactitud a corto plazo combinada con una actualización rápida y de bajo costo. La técnica es ampliamente usada cuando se necesitan pronósticos mensuales o semanales de un gran número, quizá miles, de artículos. El control de inventario es un ejemplo donde los métodos de suavización exponencial se usan de forma rutinaria.

Glosario

Suavización exponencial. Es un procedimiento de revisión continua de un pronóstico a la luz de la experiencia más reciente.

Promedio móvil. El valor medio de k observaciones consecutivas es un promedio móvil de orden k . Los valores más recientes del promedio móvil brindan un pronóstico para el siguiente periodo.

Promedio simple. Usa la media de todas las observaciones históricas relevantes como pronóstico para el siguiente periodo.

Señal de control. Implica el cálculo de una medida de errores de pronóstico a lo largo del tiempo y el establecimiento de límites de manera que, cuando el error acumulativo salga fuera de esos límites, se alerte al pronosticador.

Fórmulas clave

Modelo informal

$$\hat{Y}_{t+1} = Y_t \quad (4.1)$$

Modelo informal con tendencia

$$\hat{Y}_{t+1} = Y_t + (Y_t - Y_{t-1}) \quad (4.2)$$

Modelo informal de tasa de cambio

$$\hat{Y}_{t+1} = Y_t \frac{Y_t}{Y_{t-1}} \quad (4.3)$$

Modelo informal estacional para datos trimestrales

$$\hat{Y}_{t+1} = Y_{t-3} \quad (4.4)$$

Modelo informal estacional y con tendencia para datos trimestrales

$$\hat{Y}_{t+1} = Y_{t-3} + \frac{Y_t - Y_{t-4}}{4} \quad (4.5)$$

Modelo de promedio simple

$$\hat{Y}_{t+1} = \frac{1}{t} \sum_{i=1}^t Y_i \quad (4.6)$$

Promedio simple actualizado, nuevo periodo

$$\hat{Y}_{t+2} = \frac{t\hat{Y}_{t+1} + Y_{t+1}}{t+1} \quad (4.7)$$

Promedio móvil para k periodos de tiempo

$$\hat{Y}_{t+1} = \frac{Y_t + Y_{t-1} + \cdots + Y_{t-k+1}}{k} \quad (4.8)$$

Promedio móvil doble

$$M'_t = \frac{M_t + M_{t-1} + M_{t-2} + \cdots + M_{t-k+1}}{k} \quad (4.9)$$

$$a_t = 2M_t - M'_t \quad (4.10)$$

$$b_t = \frac{2}{k-1}(M_t - M'_t) \quad (4.11)$$

$$\hat{Y}_{t+p} = a_t + b_t p \quad (4.12)$$

Suavización exponencial simple

$$\hat{Y}_{t+1} = \alpha Y_t + (1 - \alpha)\hat{Y}_t \quad (4.13)$$

Expresión alternativa equivalente:

$$\hat{Y}_{t+1} = \alpha Y_t + \alpha(1 - \alpha)Y_{t-1} + \alpha(1 - \alpha)^2 Y_{t-2} + \alpha(1 - \alpha)^3 Y_{t-3} + \cdots \quad (4.14)$$

Suavización lineal de Holt

Estimado del nivel actual de la serie suavizada exponencialmente:

$$L_t = \alpha Y_t + (1 - \alpha)(L_{t-1} + T_{t-1}) \quad (4.15)$$

Estimado de tendencia:

$$T_t = \beta(L_t - L_{t-1}) + (1 - \beta)T_{t-1} \quad (4.16)$$

Pronóstico del periodo p futuro:

$$\hat{Y}_{t+p} = L_t + pT_t \quad (4.17)$$

Suavización multiplicativa de Winters

Nivel estimado de serie suavizada exponencialmente:

$$L_t = \alpha \frac{Y_t}{S_{t-s}} + (1 - \alpha)(L_{t-1} + T_{t-1}) \quad (4.18)$$

Estimado de tendencia:

$$T_t = \beta(L_t - L_{t-1}) + (1 - \beta)T_{t-1} \quad (4.19)$$

Estimado de estacionalidad:

$$S_t = \gamma \frac{Y_t}{L_t} + (1 - \gamma)S_{t-s} \quad (4.20)$$

El pronóstico para p periodos futuros:

$$\hat{Y}_{t+p} = (L_t + pT_t)S_{t-s+p} \quad (4.21)$$

Problemas

1. ¿Qué técnica de pronósticos revisa continuamente el estimado a la luz de las experiencias más recientes?
2. ¿Cuál técnica de pronósticos usa el valor del periodo actual como base del pronóstico para el siguiente periodo?
3. ¿Cuál técnica de pronósticos concede el mismo peso a cada observación?
4. ¿Cuál(es) técnica(s) de pronósticos debe(n) utilizarse si los datos muestran una tendencia?
5. ¿Cuál(es) técnica(s) de pronósticos debe(n) utilizarse si los datos son estacionales?
6. La Apex Mutual Fund invierte principalmente en acciones de tecnología. El precio del fondo al final de cada mes para los 12 meses de 2006 se presenta en la tabla P-6.
 - a) Obtenga el pronóstico del fondo común por cada mes usando un modelo informal (véase la ecuación 4.1). El valor para diciembre de 2005 fue de 19.00.
 - b) Evalúe este método de pronóstico usando la *MAD*.
 - c) Evalúe este método de pronóstico usando el *MSE*.
 - d) Evalúe este método de pronóstico usando el *MAPE*.
 - e) Evalúe este método de pronóstico usando el *MPE*.
 - f) Utilizando un modelo informal, pronostique el precio del fondo común para enero del 2007.
 - g) Redacte un escrito resumiendo sus hallazgos.
7. Refiérase al problema 6. Use un promedio móvil de tres meses para pronosticar el precio del fondo común para enero de 2007. ¿Es mejor este pronóstico que el pronóstico realizado usando el modelo informal? Explique.
8. A partir de la serie Y_t en la tabla P-8, responda lo siguiente:
 - a) ¿Cuál es el pronóstico para el periodo 9 usando un promedio móvil de cinco meses?
 - b) Si se usa la suavización exponencial simple con una constante de suavización de .4, ¿cuál es el pronóstico para el periodo 4?
 - c) En el inciso b), ¿cuál es el error de pronóstico para el periodo 3?
9. El rendimiento de un bono de obligación general de la ciudad de Davenport fluctúa con el mercado. Las cotizaciones mensuales para 2006 se indican en la tabla P-9.

TABLA P-6

<i>Mes</i>	<i>Precio del fondo común</i>
Enero	19.39
Febrero	18.96
Marzo	18.20
Abril	17.89
Mayo	18.43
Junio	19.98
Julio	19.51
Agosto	20.63
Septiembre	19.78
Octubre	21.25
Noviembre	21.18
Diciembre	22.14

TABLA P-8

<i>Periodo</i>	Y_t	$\hat{Y}_t$	e_t
1	200	200	—
2	210	—	—
3	215	—	—
4	216	—	—
5	219	—	—
6	220	—	—
7	225	—	—
8	226	—	—

TABLA P-9

<i>Mes</i>	<i>Rendimiento</i>
Enero	9.29
Febrero	9.99
Marzo	10.16
Abril	10.25
Mayo	10.61
Junio	11.07
Julio	11.52
Agosto	11.09
Septiembre	10.80
Octubre	10.50
Noviembre	10.86
Diciembre	9.97

- Usando un promedio móvil de tres meses, obtenga el pronóstico del rendimiento mensual de los bonos de obligación a partir de abril.
 - Usando un promedio móvil de cinco meses, obtenga el pronóstico del rendimiento mensual de los bonos de obligación a partir de junio.
 - Evalúe estos métodos de pronósticos usando la *MAD*.
 - Evalúe estos métodos de pronósticos usando el *MSE*.
 - Evalúe estos métodos de pronósticos usando el *MAPE*.
 - Evalúe estos métodos de pronósticos usando el *MPE*.
 - Empleando la mejor técnica, pronostique el rendimiento para enero del 2007.
 - Redacte un escrito resumiendo sus hallazgos.
- Esta pregunta se refiere al problema 9. Use suavización exponencial con una constante de suavización de .2 y un valor inicial de 9.29 para pronosticar el rendimiento de enero de 2007. ¿Es mejor este pronóstico que el pronóstico realizado usando el mejor modelo de promedio móvil? Explique.
 - La Hughes Supply Company utiliza un método de administración del inventario para determinar las demandas mensuales de varios productos. Se tienen registrados los valores de la demanda de los últimos 12 meses de cada producto y están disponibles para futuros pronósticos. Los valores de la demanda de los 12 meses de 2006 de una pieza eléctrica se presentan en la tabla P-11.

TABLA P-11

<i>Mes</i>	<i>Demanda</i>
Enero	205
Febrero	251
Marzo	304
Abril	284
Mayo	352
Junio	300
Julio	241
Agosto	284
Septiembre	312
Octubre	289
Noviembre	385
Diciembre	256

Fuente: Con base en los registros de Hughes Supply Company.

Use una suavización exponencial con una constante de suavización de .5 y un valor inicial de 205 para pronosticar la demanda para enero de 2007.

12. La General American Investors Company, una compañía de administración de inversiones, invierte principalmente en acciones de mediana y alta calidad. Jim Campbell está estudiando el valor de sus activos por acción para esta compañía y le gustaría pronosticar esta variable para los trimestres restantes de 1996. Los datos se presentan en la tabla P-12.

Evalúe la capacidad para pronosticar el valor de los activos por acción de los siguientes métodos de pronósticos: informal, promedio móvil y suavización exponencial. Cuando compare las técnicas, tome en consideración que el valor real de los activos por acción para el segundo trimestre de 1996 fue de 26.47. Escriba un reporte para Jim indicando cuál método debe usar y por qué.

TABLA P-12 Activos por acción de la General American Investors Company, 1985 a 1996

<i>Año</i>	<i>Trimestre</i>			
	<i>1</i>	<i>2</i>	<i>3</i>	<i>4</i>
1985	16.98	18.47	17.63	20.65
1986	21.95	23.85	20.44	19.29
1987	22.75	23.94	24.84	16.70
1988	18.04	19.19	18.97	17.03
1989	18.23	19.80	22.89	21.41
1990	21.50	25.05	20.33	20.60
1991	25.33	26.06	28.89	30.60
1992	27.44	26.69	28.71	28.56
1993	25.87	24.96	27.61	24.75
1994	23.32	22.61	24.08	22.31
1995	22.67	23.52	25.41	23.94
1996	25.68	—	—	—

Fuente: The Value Line Investment Survey (Nueva York: Value Line, 1990, 1993, 1996).

TABLA P-13 Ingresos de Southdown, 1986 a 1999

Año	Trimestre			
	1	2	3	4
1986	77.4	88.8	92.1	79.8
1987	77.5	89.1	92.4	80.1
1988	74.7	185.2	162.4	178.1
1989	129.1	158.4	160.6	138.7
1990	127.2	149.8	151.7	132.9
1991	103.0	136.8	141.3	123.5
1992	107.3	136.1	138.6	123.7
1993	106.1	144.4	156.1	138.2
1994	111.8	149.8	158.5	141.8
1995	119.1	158.0	170.4	151.8
1996	127.4	178.2	189.3	169.5
1997	151.4	187.2	199.2	181.4
1998	224.9	317.7	341.4	300.7
1999	244.9	333.4	370.0	326.7

Fuente: *The Value Line Investment Survey* (Nueva York: Value Line, 1990, 1993, 1996, 1999).

13. Southdown, Inc., el tercer productor de cemento más grande de Estados Unidos, está impulsando un programa de quema de residuos de combustible. El costo para Southdown totalizará cerca de los \$37 millones. Por esta razón, es extremadamente importante para la compañía tener un pronóstico exacto de los ingresos para el primer trimestre de 2000. Los datos se presentan en la tabla P-13.
 - a) Use suavización exponencial con una constante de suavización de .4 y un valor inicial de 77.4 para pronosticar los ingresos trimestrales del primer trimestre de 2000.
 - b) Use ahora una constante de suavización de .6 y un valor inicial de 77.4 para pronosticar los ingresos trimestrales del primer trimestre de 2000.
 - c) ¿Qué constante de suavización ofrece el mejor pronóstico?
 - d) Revise el inciso c). Examine las autocorrelaciones residuales. ¿Está usted satisfecho con la suavización exponencial simple para este ejemplo? Explique.
14. La Triton Energy Corporation explora para extraer petróleo y gas. El presidente de la compañía, Gail Freeman, quiere que el analista de la compañía pronostique las ventas por acción de la compañía para el año 2000. Éste será un pronóstico importante, puesto que los planes de reestructuración de Triton han encontrado inconvenientes. Los datos se presentan en la tabla P-14.

Determine cuál es el mejor método para la elaboración del pronóstico y pronostique las ventas por acción para el año 2000.
15. La Consolidated Edison Company vende energía eléctrica (82% de sus ingresos), gas (13%) y vapor (5%) en la ciudad de Nueva York y el condado de Westchester. A Bart Thomas, el encargado de elaborar pronósticos en la empresa, se le asigna la tarea de pronosticar los ingresos trimestrales de la compañía por el resto de 2002 y todo 2003. Él recopila los datos que se presentan en la tabla P-15.

Determine cuál es la mejor técnica para la elaboración del pronóstico y pronostique los ingresos trimestrales para el resto de 2002 y todo 2003.
16. Un fabricante que se especializa en refacciones no tiene sistema de pronósticos y fabrica sus productos con base en las últimas ventas mensuales. Están disponibles los datos de 24 meses de ventas y se presentan en la tabla P-16.

TABLA P-14 Ventas de Triton por acción, 1974 a 1999

<i>Año</i>	<i>Ventas por acción</i>	<i>Año</i>	<i>Ventas por acción</i>
1974	.93	1987	5.33
1975	1.35	1988	8.12
1976	1.48	1989	10.65
1977	2.36	1990	12.06
1978	2.45	1991	11.63
1979	2.52	1992	6.58
1980	2.81	1993	2.96
1981	3.82	1994	1.58
1982	5.54	1995	2.99
1983	7.16	1996	3.69
1984	1.93	1997	3.98
1985	5.17	1998	4.39
1986	7.72	1999	6.85

Fuente: *The Value Line Investment Survey* (Nueva York: Value Line, 1990, 1993, 1996, 1999).

TABLA P-15 Ingresos trimestrales para Consolidated Edison (millones de \$), 1985 a junio de 2002

<i>Año</i>	<i>Mar. 31</i>	<i>Jun. 30</i>	<i>Sept. 30</i>	<i>Dic. 31</i>
1985	1,441	1,209	1,526	1,321
1986	1,414	1,187	1,411	1,185
1987	1,284	1,125	1,493	1,192
1988	1,327	1,102	1,469	1,213
1989	1,387	1,218	1,575	1,371
1990	1,494	1,263	1,613	1,369
1991	1,479	1,330	1,720	1,344
1992	1,456	1,280	1,717	1,480
1993	1,586	1,396	1,800	1,483
1994	1,697	1,392	1,822	1,461
1995	1,669	1,460	1,880	1,528
1996	1,867	1,540	1,920	1,632
1997	1,886	1,504	2,011	1,720
1998	1,853	1,561	2,062	1,617
1999	1,777	1,479	2,346	1,889
2000	2,318	2,042	2,821	2,250
2001	2,886	2,112	2,693	1,943
2002	2,099	1,900	—	—

Fuente: *The Value Line Investment Survey* (Nueva York: Value Line, 1990, 1993, 1996, 1999, 2001).

a) Grafique los datos de ventas como una serie de tiempo. ¿Los datos son estacionales?

Pista: Para los datos mensuales el periodo estacional es $s = 12$. ¿Existe un patrón que tienda a repetirse cada 12 meses? (por ejemplo, ventas de verano relativamente bajas o ventas de otoño relativamente altas).

TABLA P-16

<i>Mes</i>	<i>Ventas</i>	<i>Mes</i>	<i>Ventas</i>
Enero de 2005	430	Enero 2006	442
Febrero	420	Febrero	449
Marzo	436	Marzo	458
Abril	452	Abril	472
Mayo	477	Mayo	463
Junio	420	Junio	431
Julio	398	Julio	400
Agosto	501	Agosto	487
Septiembre	514	Septiembre	503
Octubre	532	Octubre	503
Noviembre	512	Noviembre	548
Diciembre	410	Diciembre	432

- b) Use un modelo informal para generar pronósticos de ventas mensuales (por ejemplo, el pronóstico de febrero de 2005 está dado por el valor de enero de 2005, y así sucesivamente). Calcule el *MAPE*.
- c) Use suavización exponencial simple con una constante de suavización de .5 y un valor inicial suavizado de 430 para producir pronósticos de ventas mensuales. Calcule el *MAPE*.
- d) ¿Piensa que alguno de los modelos de los incisos b) y c) probablemente generará pronósticos de ventas exactos para las ventas mensuales futuras? Explique.
- e) Use Minitab y el método de suavización multiplicativa de Winters con constantes de suavización $\alpha = \beta = \gamma = .5$ para generar el pronóstico de enero de 2007. Guarde los residuos.
- f) Remítase al inciso e). Compare el *MAPE* del método de Winters que salió de la computadora con el *MAPE* de los incisos b) y c). ¿Cuál de los tres métodos para pronosticar prefiere y por qué?
- g) Revise el inciso e). Calcule la autocorrelación de los residuos (para seis retrasos de tiempo) con el procedimiento multiplicativo de Winters. ¿Las autocorrelaciones residuales sugieren que el procedimiento de Winters funciona bien para estos datos? Explique.
17. Considere las compras de gasolina de la Spokane Transit Authority de la tabla 4.2. En el ejemplo 4.3 se utilizó un promedio móvil de cinco semanas para suavizar los datos y generar los pronósticos.
- a) Utilice Minitab para suavizar los datos de la Spokane Transit Authority, usando un promedio móvil de cuatro semanas. ¿Cuál longitud de promedio móvil (cuatro o cinco semanas) parece representar mejor los datos? Explique.
- b) Utilice Minitab para suavizar los datos de Spokane Transit Authority usando la suavización exponencial simple. Compare sus resultados con los del inciso a). ¿Qué procedimiento, entre el promedio móvil de cuatro semanas o la suavización exponencial simple, prefiere para estos datos? Explique.
18. La tabla P-18 indica el número de terremotos severos anuales (aquellos con una magnitud en la escala de Richter de 7 grados o más) de 1900 a 1999.
- a) Utilice Minitab para suavizar los datos de terremotos con promedios móviles de órdenes de $k = 5, 10$ y 15 . Describa la naturaleza de la suavización conforme el orden del promedio móvil se incrementa. ¿Cree usted que podría haber un ciclo en estos datos? Si es así, dé un estimado de la duración (en años) del ciclo.

TABLA P-18 Número de terremotos severos, 1900 a 1999

Año	Número	Año	Número	Año	Número	Año	Número
1900	13	1927	20	1954	17	1981	14
1901	14	1928	22	1955	19	1982	10
1902	8	1929	19	1956	15	1983	15
1903	10	1930	13	1957	34	1984	8
1904	16	1931	26	1958	10	1985	15
1905	26	1932	13	1959	15	1986	6
1906	32	1933	14	1960	22	1987	11
1907	27	1934	22	1961	18	1988	8
1908	18	1935	24	1962	15	1989	7
1909	32	1936	21	1963	20	1990	12
1910	36	1937	22	1964	15	1991	11
1911	24	1938	26	1965	22	1992	23
1912	22	1939	21	1966	19	1993	16
1913	23	1940	23	1967	16	1994	15
1914	22	1941	24	1968	30	1995	25
1915	18	1942	27	1969	27	1996	22
1916	25	1943	41	1970	29	1997	20
1917	21	1944	31	1971	23	1998	16
1918	21	1945	27	1972	20	1999	23
1919	14	1946	35	1973	16		
1920	8	1947	26	1974	21		
1921	11	1948	28	1975	21		
1922	14	1949	36	1976	25		
1923	23	1950	39	1977	16		
1924	18	1951	21	1978	18		
1925	17	1952	17	1979	15		
1926	19	1953	22	1980	18		

Fuente: U.S. Geological Survey Earthquake Hazard Program.

- b) Use Minitab para suavizar los datos de los terremotos usando la suavización exponencial simple. Almacene los residuos y genere un pronóstico para el número de terremotos severos en el año 2000. Calcule las autocorrelaciones residuales. ¿La suavización exponencial simple ofrece un ajuste razonable de estos datos? Explique.
- c) ¿Existe un componente estacional en los datos del terremoto? ¿Por qué?
19. La tabla P-23 del capítulo 3 contiene los ingresos trimestrales antes de ingresos extraordinarios de la Southwest Airlines de 1988 a 1999.
- a) Con Minitab, suavice los datos de ingresos de la Southwest Airlines utilizando la suavización lineal de Holt y guarde los residuos. Calcule las autocorrelaciones de los residuos. ¿Parece que el procedimiento de suavización de Holt representa bien estos datos? Si no es así, ¿qué componente de la serie de tiempo (tendencia, ciclo, componente estacional) no toma en cuenta el método de Holt?
- b) Emplee Minitab para suavizar los datos de ingresos de Southwest Airlines con la suavización exponencial multiplicativa de Winters. Guarde los residuos y genere pronósticos de ingresos para los cuatro trimestres de 2000. Calcule las autocorrelaciones residuales. ¿La técnica de suavización de Winters se ajusta bien a los datos de ingresos? ¿El pronóstico parece razonable? Discútalos.

TABLA P-20 Ventas trimestrales para The Gap en los años fiscales 1980 a 2004

<i>Año</i>	<i>T1</i>	<i>T2</i>	<i>T3</i>	<i>T4</i>
1980	65.3	72.1	107.1	125.3
1981	76.0	76.9	125.4	139.1
1982	84.4	86.0	125.4	139.1
1983	87.3	90.9	133.3	169.0
1984	98.0	105.3	141.4	189.4
1985	105.7	120.1	181.7	239.8
1986	160.0	164.8	224.8	298.4
1987	211.1	217.7	273.6	359.6
1988	241.3	264.3	322.8	423.7
1989	309.9	325.9	405.6	545.2
1990	402.4	405.0	501.7	624.7
1991	490.3	523.1	702.0	803.5
1992	588.9	614.1	827.2	930.2
1993	643.6	693.2	898.7	1,060.2
1994	751.7	773.1	988.3	1,209.8
1995	848.7	868.5	1,155.9	1,522.1
1996	1,113.2	1,120.3	1,383.0	1,667.9
1997	1,231.2	1,345.2	1,765.9	2,165.5
1998	1,719.7	1,905.0	2,399.9	3,029.8
1999	2,277.7	2,453.3	3,045.4	3,858.9
2000	2,732.0	2,947.7	3,414.7	4,579.1
2001	3,179.7	3,245.2	3,333.4	4,089.6
2002	2,890.8	3,268.3	3,645.0	4,650.6
2003	3,353.0	3,685.0	3,929.0	4,887.0
2004	3,668.0	3,721.0	3,980.0	4,898.0

Fuente: De acuerdo con *The Value Line Investment Survey* (Nueva York: Value Line, varios años) y archivos 10K de la Security and Exchange Comisión.

20. La tabla P-20 contiene las ventas trimestrales (en millones de \$) para The Gap de los años fiscales 1980 a 2004.

Grafique las ventas de The Gap como una serie de tiempo y examine sus características. El objetivo es generar pronósticos de ventas para los cuatro trimestres de 2005. Seleccione un método de suavización adecuado para la elaboración del pronóstico y justifique su selección.

CASOS

CASO 4-1 THE SOLAR ALTERNATIVE COMPANY⁴

The Solar Alternative Company está por entrar a su tercer año de operación. Bob y Mary Johnson, quienes dan clases de ciencias en la preparatoria local, fun-

daron la compañía. Los Johnson abrieron la compañía para complementar sus ingresos. Con base en sus investigaciones sobre sistemas de energía solar, lograron

⁴Este caso es contribución de William P. Darrow de Towson State University, Towson, Maryland.

integrar un sistema de energía solar que permitiera calentar el agua para uso doméstico. El sistema consiste en un tanque de almacenamiento de fibra de vidrio de 100 galones, dos paneles solares de 36 pies, controles electrónicos, tubería PVC y accesorios adicionales.

El periodo de recuperación del sistema es de 10 años. Si bien esta situación no es una oportunidad de inversión atractiva desde el punto de vista financiero, existe suficiente interés en lo novedoso del concepto como para generar un nivel de ventas moderado. Los Johnson ganan cerca de \$75 sobre un precio de \$2000 de un sistema instalado, después de gastos y costos. Los costos de material y equipo representan el 75% del costo total del sistema instalado. Una ventaja que ayuda a compensar el escaso margen de ganancias es que, por lo mismo, no genera competencia significativa entre los contratistas del ramo. Los Johnson operan el negocio fuera de su casa. Tienen una oficina en el sótano y su cochera la usan exclusivamente para almacenar los componentes y materiales del sistema. Como resultado, los gastos indirectos son mínimos. Los Johnson disfrutan de un modesto ingreso adicional por la operación de su compañía. El negocio también proporciona varias ventajas fiscales.

Bob y Mary están contentos con el crecimiento del negocio. Si bien las ventas son variables de un mes a otro, los resultados totales del segundo año fueron mucho mejores que los del primero. Muchos de los

clientes del segundo año eran vecinos de las personas que compraron el sistema durante el primer año. Aparentemente, después de ver que el sistema operó con éxito durante un año, varias personas estuvieron dispuestas a probar el concepto de energía solar. Las ventas se presentaron a lo largo del año. La demanda del sistema es mayor al final del verano y al principio del otoño, cuando la gente por lo general prepara sus casas para el invierno que se acerca.

Ante el probable crecimiento del negocio, los Johnson sienten que necesitan un pronóstico de las ventas para administrar efectivamente el año entrante. Por lo general, reciben los tanques de almacenamiento de 60 a 90 días después de hacer el pedido. Los paneles solares están disponibles en los anaqueles la mayor parte el año. Sin embargo, al final del verano y durante el otoño, el tiempo de entrega se puede prolongar de 90 a 100 días. Aunque la competencia es limitada, la pérdida de las ventas es una posibilidad real si al cliente potencial se le pide esperar algunos meses para hacer la instalación. Quizás lo más importante es hacer proyecciones exactas de las ventas para tener la ventaja de un descuento por una compra voluminosa. Cuando se combinan estos factores, con los altos costos de los componentes del sistema y el espacio limitado de almacenamiento en la cochera, se hace necesario desarrollar un pronóstico confiable. Las ventas históricas de la compañía para los primeros dos años se presentan en la tabla 4-10.

TABLA 4-10

<i>Mes</i>	<i>2005</i>	<i>2006</i>	<i>Mes</i>	<i>2005</i>	<i>2006</i>
Enero	5	17	Julio	23	44
Febrero	6	14	Agosto	26	41
Marzo	10	20	Septiembre	21	33
Abril	13	23	Octubre	15	23
Mayo	18	30	Noviembre	12	26
Junio	15	38	Diciembre	14	17

TAREA

1. Identifique el modelo que Bob y Mary deberían utilizar como base para la planeación de su negocio en 2007 y explique por qué seleccionó este modelo.
2. Pronostique las ventas de 2007.

CASO 4-2 MR. TUX

John Mosby, propietario de varias tiendas de alquiler Mr. Tux, está empezando a pronosticar la variable más importante de su negocio: las ventas mensuales en dólares (véase los casos de Mr. Tux en capítulos anteriores). Uno de sus empleados, Virginia Perot, reunió los datos de ventas que se presentaron en el caso 2-2. Ahora, John quiere elaborar un pronóstico con base en estos datos de ventas empleando técnicas de promedio móvil y suavización exponencial.

John usó Minitab en el caso de estudio 3-2 para determinar que estos datos tienen una tendencia y un efecto estacional. Le han dicho que las técnicas de los promedios móviles simples y de la suavización exponencial no funcionarán con estos datos, pero él decidió averiguarlo por sí mismo.

Comenzó con un promedio móvil de tres meses. El programa calculó varias mediciones de resumen de errores de pronóstico. Estos valores resumen los errores encontrados en la predicción de valores de datos históricos reales usando un promedio móvil de tres meses. John decidió registrar dos de estas mediciones de error:

$$MAD = 54,373$$

$$MAPE = 47.0\%$$

La *MAD* (la desviación media absoluta) es el error absoluto promedio obtenido en la elaboración de pronósticos de valores pasados. Todo pronóstico que use el método de promedios móviles de tres meses es infructuoso con un promedio de error de 54,373. El *MAPE* (el error porcentual absoluto medio) indica el error como un porcentaje del valor real que se va a pronosticar. El error promedio al usar la técnica de promedio móvil de tres meses es del 47%, o casi tan grande como la mitad del valor que se va a pronosticar.

A continuación, John intenta la suavización exponencial simple. El programa le solicita que introduzca la constante de suavización α que habrá de utilizarse o que pida calcular el valor óptimo de α . John opta por

esto último y el programa encuentra que el valor óptimo de α es .867. De nuevo, él registra las mediciones apropiadas de error:

$$MAD = 46,562$$

$$MAPE = 44.0\%$$

John le pide al programa usar la suavización exponencial lineal de Holt para sus datos. Este programa usa el método de suavización exponencial, pero también puede tomar en cuenta la tendencia en los datos. John hace que el programa use una constante de suavización de .4 tanto para α como para β . Los dos resúmenes de mediciones de error para el método de Holt son:

$$MAD = 63,579$$

$$MAPE = 59.0\%$$

John está sorprendido de encontrar mediciones de error más grandes con esta técnica. Concluye que el problema es el aspecto estacional de los datos. La suavización exponencial multiplicativa de Winters es el siguiente método que John emplea. Este método puede tomar en cuenta tanto factores estacionales como tendencias. John usa constantes de suavización de $\alpha = .2$, $\beta = .2$ y $\gamma = .2$. Las mediciones de error son:

$$MAD = 25,825$$

$$MAPE = 22.0\%$$

Cuando John se sienta y empieza a estudiar los resultados de su análisis, se siente desilusionado. El método de Winters es una gran mejora; sin embargo, el *MAPE* es del 22%. Tenía la esperanza de que uno de los métodos que usó daría pronósticos exactos de los periodos pasados; luego, podría usar este método para pronosticar los niveles de ventas de los meses venideros del próximo año. Pero el promedio de errores absolutos (*MAD*) y los errores porcentuales (*MAPE*) de estos métodos lo inducen a buscar otra manera de realizar el pronóstico.

PREGUNTAS

1. Resuma el nivel de error de pronóstico del mejor método de pronósticos que John encontró usando Minitab.
2. John usó los valores que Minitab predeterminó para α , β , y γ . John cree que existen otras opciones para estos parámetros que implicarían mediciones del error más pequeñas. ¿Está usted de acuerdo?
3. Aun cuando se desilusionó con los resultados iniciales, esto es lo mejor que puede hacer con métodos de suavización. ¿Qué puede hacer John, por ejemplo, para determinar qué tan adecuada es la técnica de pronósticos de Winters?
4. Si bien no se calculó directamente en Minitab, el *MPE* (error porcentual medio) mide el sesgo del pronóstico. ¿Cuál es el valor ideal del *MPE*? ¿Cuál es la implicación de un signo negativo en el *MPE*?

CASO 4-3 CONSUMER CREDIT COUNSELING

La operación del Consumer Credit Counseling (CCC) se describió en el caso 1-2. El director ejecutivo, Marv Harnishfeger, concluyó que la variable más importante que necesitaba pronosticar CCC era el número de clientes nuevos que serían atendidos por el resto de 1993. Marv proporcionó a Dorothy Mercer datos mensuales

del número de clientes nuevos atendidos por CCC durante el periodo de enero de 1985 a marzo de 1993 (véase el caso 3-3). Entonces Dorothy utilizó el análisis de autocorrelación para explorar el patrón de datos. Use los resultados de esta investigación para realizar las siguientes tareas.

TAREA

1. Desarrolle un modelo informal para pronosticar el número de clientes nuevos que atenderá CCC por el resto de 1993.
2. Desarrolle un modelo de promedio móvil para pronosticar el número de clientes nuevos que atenderá CCC por el resto de 1993.
3. Desarrolle un procedimiento de suavización exponencial para pronosticar el número de clientes nuevos que atenderá CCC por el resto de 1993.
4. Evalúe estos métodos de pronósticos usando las medidas de resumen de errores de pronósticos presentadas en el capítulo 3.
5. Seleccione el mejor modelo y pronostique los nuevos clientes para el resto de 1993.
6. Determine la idoneidad del modelo de pronóstico que usted seleccionó.

CASO 4-4 MURPHY BROTHERS FURNITURE

Julie Murphy sabe que las decisiones operativas más importantes dependen, en algún grado, de los pronósticos. En Murphy Brothers Furniture, los pronósticos de ventas tienen efecto en la incorporación de nuevas líneas de muebles o la eliminación de algunas existentes, en la planeación de compras, en el establecimiento de cuotas de ventas, y también en la toma de decisiones relacionadas con el personal, la publicidad y las finanzas. Específicamente, Julie está consciente de varias necesidades actuales de pronósticos. Sabe que el departamento de producción tiene que programar su plantilla de personal y definir los pedidos de materia prima para el siguiente mes o los siguientes dos. Ella también sabe que su papá, Glen Murphy, necesita iden-

tificar las mejores oportunidades de inversión y debe pronosticar la demanda de una nueva línea de muebles.

En el caso 3-1A, Julie Murphy usó las ventas mensuales de todas las tiendas minoristas de 1983 a 1995 (véase la tabla 3-8) para desarrollar un patrón de ventas en Murphy Brothers Furniture. En el caso de estudio 3-1B, Glen Murphy descubrió datos de ventas reales de los pasados cuatro años, de 1992 a 1995 (véase la tabla 3-9). Julie no estaba emocionada por el descubrimiento de su padre porque no estaba segura cuál conjunto de datos usar para desarrollar un pronóstico para 1996. Ella determinó que las ventas de todas las tiendas minoristas tenían algo del patrón de los datos de ventas reales de Murphy Brothers.

PREGUNTAS

1. ¿Alguno de los modelos de pronósticos estudiados en este capítulo funcionará con los datos de ventas nacionales?
2. ¿Alguno de los modelos de pronósticos estudiados en este capítulo funcionará con los datos de ventas reales de Murphy Brothers?
3. ¿Qué conjunto de datos y qué modelo de pronóstico debe usar Julie para pronosticar las ventas de 1996?

CASO 4-5 PROYECCIÓN DE CINCO AÑOS DE INGRESOS PARA DOWNTOWN RADIOLOGY

Hace algunos años, Downtown Radiology desarrolló un centro de imagenología médica que era el más completo y técnicamente más avanzado que cualquiera de los localizados en el área del oriente de Washington y el norte de Idaho, llamado el Inland Empire. El equipo planeado para el centro igualaba o superaba las capacidades de imagenología de todos los centros médicos en la región. El centro inicialmente contaba con un escáner de tomografía computarizada (TC) de la serie 9800 y equipo para obtener imágenes de resonancia magnética nuclear (MRI). El centro también tenía equipos de ultrasonido, medicina nuclear, angiografías por sustracción digital (DSA), mamografía, así como de radiología y fluoroscopia convencionales. Se hizo posible la participación accionaria mediante una oferta pública, y Downtown Radiology hizo una evaluación independiente del mercado. La Professional Marketing Associates, Inc., evaluó el mercado y elaboró una proyección de ingresos para cinco años.

DEFINICIÓN DEL PROBLEMA

El propósito de este estudio es elaborar un pronóstico de los ingresos para los próximos cinco años del centro de imagenología médica propuesto, suponiendo que usted es empleado de Professional Marketing Associates, Inc., en el año de 1984.

OBJETIVOS

Los objetivos de este estudio son:

- Identificar áreas de mercado para cada tipo de procedimiento médico que se ofrecerá en las nuevas instalaciones.
- Reunir y analizar los datos de ingresos existentes en el área del mercado para cada tipo de procedimiento médico ofrecido en las nuevas instalaciones.
- Identificar tendencias en la industria de cuidados de la salud que afectarán positiva o negativamente los ingresos de los procedimientos médicos que se ofrecerán en las nuevas instalaciones.
- Identificar los factores de negocio, marketing o planeación de la nueva empresa que afectarán positiva o negativamente las proyecciones de ingresos.
- Analizar los procedimientos médicos anteriores de Downtown Radiology cuando se compile una base de datos para el modelo del pronóstico que será desarrollado.
- Utilizar el modelo apropiado de pronóstico cuantitativo para obtener las proyecciones de ingresos del centro propuesto para cinco años.

METODOLOGÍA

Procedimientos médicos

Se realizaron los siguientes pasos con la finalidad de obtener la proyección de ingresos para los próximos cinco años. Se realizó un análisis de los procedimientos médicos anteriores. Se desarrolló el modelo de pronóstico adecuado y se usó para determinar un punto de inicio de la proyección de cada procedimiento médico.

1. Se determinó el área de mercado para cada tipo de procedimiento médico y el pronóstico de la población para 1986 y 1990.
2. Se estudiaron los patrones de recomendaciones médicas para determinar el porcentaje de doctores que sugerían los servicios de Downtown Radiology y el número promedio de recomendaciones por médico.
3. Las tarifas nacionales se obtuvieron del Centro Nacional de Estadísticas para la Salud. Estas tarifas se compararon con los números reales obtenidos por la Comisión Hospitalaria.
4. La participación en el mercado de Downtown Radiology se calculó con base en las tomografías computarizadas reales en el área de mercado. (La participación en el mercado de otros procedimientos médicos se determinó con base en la comparación de la participación de Downtown Radiology con las tarifas proporcionadas por el Centro Nacional de Estadísticas para la Salud).

Suposiciones

Se hicieron las siguientes suposiciones, las cuales fueron necesarias para desarrollar el pronóstico cuantitativo:

- El nuevo centro de imagenología estará en condiciones de operar con todo el equipo, a excepción del MRI, el 1 de enero de 1985.
- El equipo de resonancia magnética nuclear comenzará a funcionar en abril de 1985.
- La oferta de participación limitada será comercializada con éxito entre por lo menos 50 médicos en el área de servicio.
- Los médicos que tengan un interés financiero en el nuevo centro de imagenología aumentarán sus remisiones para el centro.
- No habrá otros equipos de MRI en el área de mercado antes de 1987.
- El nuevo centro de imagenología ofrecerá servicios a precios más bajos que la competencia.

- Tendrá lugar un esfuerzo efectivo de marketing, concentrado especialmente en grandes empleadores, compañías de seguros y sindicatos.
- El MRI reemplazará aproximadamente al 60% de las tomografías craneales que actualmente se practican con el escáner de TC durante los primeros seis meses de operación y al 70% durante los siguientes 12 meses.
- El público en general seguirá presionando a la industria del cuidado de la salud para mantener costos bajos.
- Los costos de los desembolsos en la industria del cuidado de la salud se elevaron 13.2% anualmente de 1971 a 1981. La Health Care Financing Administration estima que la tasa promedio anual de incremento se reducirá aproximadamente al 11% o 12% entre 1981 y 1990 (*Industry Surveys*, abril de 1984).
- Las compañías de seguros reembolsarán a los pacientes del 0% (en el peor de los casos) hasta el 100% (en el mejor de los casos) del costo de la imagenología por resonancia magnética (*Imaging News*, febrero de 1984).

Modelos

Se desarrolló un pronóstico para cada procedimiento médico, con base en la experiencia pasada, las cifras de la industria y supuestos razonables. Los modelos se desarrollaron con base en los supuestos anteriores; sin embargo, si los supuestos no son válidos, los modelos serán inexactos.

ANÁLISIS DE DATOS ANTERIORES

Oficina de rayos X


Se analizó el número de procedimientos médicos de rayos X practicados de julio de 1981 a mayo de 1984. Los datos incluyeron diagnóstico de rayos X, rayos X gastrointestinales, imagenología de tórax, inyecciones y procedimientos médicos especiales. La revisión de estos datos indicó que no existía un patrón de tendencia, ni tampoco estacional ni cíclico. Por esta razón, se optó por la suavización exponencial simple como el método adecuado de pronóstico. Se examinaron varias constantes de suavización y se encontró que una constante de .3 proporcionaba el mejor modelo. Los resultados se presentan en la figura 4-14. El pronóstico para el periodo 36, de junio de 1984, es de 855 procedimientos médicos de rayos X.

Oficina de ultrasonido

Se analizó el número de procedimientos médicos de ultrasonido realizados de julio de 1981 a mayo de 1984. La figura 4-15 muestra el patrón de datos. Nuevamente, no están presentes patrones de tendencia, ni tampoco estacionales ni cíclicos. Se determinó que la suavización exponencial con una constante de suavización $\alpha = .5$ ofrecía el mejor modelo. El pronóstico para junio de 1984 graficado en la figura 4-15 es de 127 procedimientos médicos de ultrasonido.

Se revisaron varios procedimientos médicos de ultrasonido ejecutados por las dos unidades móviles pertenecientes al Downtown Radiology de julio de 1981 a mayo de 1984. La figura 4-16 muestra el patrón de los datos.

FIGURA 4-14 Suavización exponencial simple: Downtown Radiology, rayos X






FIGURA 4-15 Suavización exponencial simple: Ultrasonido de Downtown Radiology




FIGURA 4-16 Suavización exponencial lineal de Holt: Ultrasonidos en unidades móviles de Downtown Radiology

Como es evidente, existe una tendencia ascendente y puede modelarse usando la suavización exponencial lineal de Holt con dos parámetros. Se usaron las constantes de suavización $\alpha = .5$ y $\beta = .1$ y el pronóstico del periodo 36, correspondiente a junio de 1984, es de 227.

Procedimientos de medicina nuclear

Se analizaron los procedimientos de medicina nuclear practicados en dos unidades móviles pertenecientes al Downtown Radiology de agosto de 1982 a mayo de

1984. La figura 4-17 muestra el patrón de datos. Los datos no fueron estacionales y no mostraron una tendencia, ni tampoco un patrón cíclico. Por esta razón, se eligió la suavización exponencial simple como el método apropiado de elaboración del pronóstico. Se encontró que un factor de suavización $\alpha = .5$ ofrecía el mejor modelo. El pronóstico del periodo 23, correspondiente a junio de 1984, es de 48 procedimientos médicos de medicina nuclear.




FIGURA 4-17 Suavización exponencial simple: Medicina nuclear en unidades móviles de Downtown Radiology

Oficina de tomografías computarizadas (TC)

También se analizó el número de tomografías computarizadas (TC) practicadas de julio de 1981 a mayo de 1984. No se encontró estacionalidad y el número de tomografías realizadas no parecía seguir una tendencia. Sin embargo, parecía estar presente un patrón cíclico. El hecho de saber cuántas tomografías se practicaron el mes pasado sería importante para pronosticar qué va a pasar este mes. Se examinó un modelo auto-

regresivo (véase los capítulos 8 y 9) y se comparó con un modelo de suavización exponencial con una constante de suavización $\alpha = 0.461$. La constante de suavización más grande asignó más peso en el pronóstico a la observación más reciente. Se determinó que el modelo de suavización exponencial era mejor que el modelo autorregresivo, y la figura 4-18 indica que la proyección del número de tomografías computarizadas para el periodo 36, junio de 1984, es de 221.




FIGURA 4-18 Suavización exponencial simple: Tomografías computarizadas de Downtown Radiology

ANÁLISIS DEL ÁREA DE MERCADO

Se determinaron las áreas de mercado de procedimientos médicos que actualmente realiza Downtown Radiology revisando los registros de los pacientes y los patrones de recomendaciones de los médicos. Se determinaron las áreas de mercado para procedimientos médicos *no* realizados actualmente en Downtown Radiology investigando la competencia y analizando las áreas geográficas que atienden.

Áreas de mercado de tomografías computarizadas (TC)

El área de mercado de las tomografías computarizadas para el centro de imagenología médico propuesto incluye los condados de Spokane, Whitman, Adams, Lincoln, Stevens y Pend Oreille, en Washington, y los condados de Bonner, Boundary, Kootenai, Benewah y Shoshone en Idaho. Con base en las proyecciones porcentuales pertinentes, el área del mercado de las tomografías computarizadas tendrá una población de 630,655 en 1985 y 696,018 en 1990.

Estimaciones cuantitativas

Para proyectar los ingresos, es necesario determinar ciertas estimaciones cuantitativas. La estimación más importante implica el número de médicos que participarán en la asociación limitada. La estimación utilizada en cálculos futuros es que participará, al menos, el 8% de la población de médicos del condado de Spokane.

La siguiente incertidumbre que debe ser cuantificada implica la determinación de cómo se verá afectado el patrón de recomendaciones con la participación de 50 médicos en la asociación limitada. Se supone que 30 de los doctores que actualmente recomiendan al Downtown Radiology se unirán a la asociación limitada. De esos 30, se supone que 10 no incrementarán sus recomendaciones y 20 duplicarán sus recomendaciones. También se supone que 20 doctores que nunca habían recomendado al Downtown Radiology se unirán a la asociación limitada y empezarán a recomendar Downtown Radiology a por lo menos la mitad de sus pacientes.

La cuantificación de las recomendaciones adicionales de los médicos debe clarificarse con algunas observaciones cualitativas. La estimación de que 50 doctores se unirán a la propuesta de asociación limitada es conservadora. Existe una gran posibilidad de que médicos de las áreas fuera del condado de Spokane se puedan unir. Tradicionalmente, el patrón de recomendaciones de los doctores cambia muy lentamente. Sin embargo, la súbita naturaleza competitiva del mercado local probablemente tendrá repercusión en las recomendaciones de los doctores. Si la asociación limitada se ofrece entre médicos especialistas con alto potencial para hacer recomendaciones radiológicas, el número de recomendaciones debe incrementarse más de lo proyectado. La variabilidad en el número de recomenda-

ciones por procedimiento médico es extremadamente grande. Unos cuantos médicos recomiendan un porcentaje extremadamente alto de procedimientos médicos hechos por Downtown Radiology. Si se reclutan unos cuantos médicos nuevos que hagan muchas recomendaciones, ellos pueden tener un mayor efecto sobre el número total de procedimientos médicos realizados por Downtown Radiology.

Finalmente, se debe estimar el efecto que tendrá un nuevo centro de imagenología en la participación de mercado de Downtown Radiology. El nuevo centro de imagenología tendrá el mejor equipamiento y estará preparado para cubrir el espectro total de procedimientos médicos al costo más bajo. El número de nuevos doctores que recomienden el centro debe crecer con base en la recomendación de boca a boca de los nuevos médicos inversionistas. Si las compañías de seguros, los grandes empleadores y/o los sindicatos entran en los acuerdos con el nuevo centro, Downtown Radiology debe estar en condiciones de incrementar su participación en el mercado por lo menos en un 4% en 1985, 2% en 1986 y 1% en 1987 y conservar su participación en el mercado durante 1988 y 1989. Este incremento en la participación de mercado será mencionado como el *efecto total de imagenología* en el resto de este reporte.

Proyecciones de ingresos

Se realizaron proyecciones de ingresos para cada procedimiento médico. En este caso de estudio se presentan sólo las proyecciones de las tomografías computarizadas.

Proyecciones de tomografías computarizadas (TC)

Con base en el modelo de suavización exponencial y lo que ha tenido lugar en los primeros cinco meses de 1984, el pronóstico de tomografías computarizadas para 1984 (de enero de 1984 a enero de 1985) es de 2,600.

El Centro Nacional de Estadísticas para la Salud reporta una tasa de 261 TC mensuales por cada 100,000 habitantes. Utilizando la cifra proyectada de la población de 630,655 para el área de mercado de TC, el mercado debe realizar 19,752 procedimientos durante todo 1985. El número real de TC realizadas en el área de mercado durante 1983 se estimó en 21,600. Esta estimación se basó en los procedimientos reales conocidos de Downtown Radiology (2,260), del Sacred Heart (4,970), del Deaconess (3,850), del Valley (2,300) y del Kootenai (1,820), así como en las estimaciones de Radiation Therapy (2,400) y Northwest Imaging (4,000). Si las estimaciones son exactas, Downtown Radiology tenía una participación en el mercado de aproximadamente el 10.5% en 1983. También se analizaron los valores reales de 1982, y se proyectó que Downtown Radiology tendría aproximadamente el 15.5% del mercado de TC durante ese año. Por lo tanto, se pronostica que Downtown Radiology tendrá un promedio del 13% del mercado.

Con base en las recomendaciones crecientes de los médicos que pertenecen a la sociedad limitada y en un análisis del promedio de recomendaciones de TC, se proyectó un incremento de 320 TC para 1985. Si se usan los valores reales de 1983, la tasa para el área de mercado de TC de Inland Empire es de 3,568 (21,600/6.054) por cada 100,000 habitantes. Si este patrón continúa, el número de TC en el área de mercado aumentará a 22,514 ($3,568 \times 6.31$) en 1985. Por consiguiente, la proyección de la participación en el mercado de Downtown Radiology será del 13% ($2,920/22,514$). Cuando se suma el 4% de incremento en la participación en el mercado basado en el total de imagenología, la participación en el mercado de Downtown Radiology se incrementa al 17% y el número proyectado de TC es de 3,827 ($22,514 \times .17$).

Sin embargo, la investigación parece indicar que las imágenes por resonancia magnética (MRI), con el tiempo, reemplazarán a un gran número de tomografías craneales (*Applied Radiology*, mayo/junio de 1983, y *Diagnostic Imaging*, febrero de 1984). El Centro Nacional de Estadísticas para la Salud indicaba que el 60% de todas las TC eran craneales. Los registros de Downtown Radiology mostraban que el 59% de sus TC en 1982 fueron de la cabeza y el 54% en 1983. Si el 60% de las TC de Downtown Radiology son craneales y considerando que el método de MRI sustituirá aproximadamente al 60% de éstas, se necesitan nuevas proyecciones de TC para 1985. Puesto que el MRI operará sólo la mitad del año, se pronostica una disminución de 689 ($3,827/2 \times .60 \times .60$) tomografías computarizadas.

El número proyectado de TC para 1985 es de 3,138. El costo promedio de una TC es de \$360, y el

TABLA 4-11 Ingresos proyectados de cinco años para TC

<i>Año</i>	<i>Procedimientos</i>	<i>Ingresos (\$)</i>
1985	3,138	1,129,680
1986	2,531	1,012,400
1987	2,716	1,205,904
1988	2,482	1,223,626
1989	2,529	1,383,363

ingreso proyectado de TC es de \$1,129,680. La tabla 4-11 indica el ingreso proyectado de TC para los siguientes cinco años. Se estima que el costo de estos procedimientos médicos se incrementa en aproximadamente un 11% por año.

Sin el efecto de MRI, la proyección para las TC para 1986 se estima en 4,363 ($6.31 \times 1.02 \times 3,568 \times .19$). Sin embargo, si el 60% corresponde a TC craneales y la tecnología de MRI sustituye al 70% de las TC craneales, el número proyectado de TC disminuirá a 2,531 [$4,363 - (4,363 \times .60 \times .70)$].

La proyección de TC sin el efecto MRI para 1987 es de 4,683 ($6.31 \times 1.04 \times 3,568 \times .20$). El pronóstico con el efecto MRI es de 2,716 [$4,683 - (4,683 \times .60 \times .70)$].

La proyección de TC sin el efecto MRI para 1988 es de 4,773 ($6.31 \times 1.06 \times 3,568 \times .20$). El pronóstico con el efecto MRI es de 2,482 [$4,733 - (4,733 \times .60 \times .80)$].

La proyección de TC sin el efecto MRI para 1989 es de 4,863 ($6.31 \times 1.08 \times 3,568 \times .20$). El pronóstico con el efecto MRI es de 2,529 [$4,863 - (4,863 \times .60 \times .80)$].

PREGUNTA

1. El contador de Downtown Radiology proyectó unos ingresos considerablemente mayores en comparación con los que reportó Professional Marketing Associates. Puesto que la participación accionaria será posible mediante una oferta pública, la

administración de Downtown Radiology debe tomar una decisión en lo referente a la exactitud de las proyecciones de Professional Marketing Associates. A usted se le pide analizar el reporte. ¿Qué recomendaciones haría?

CASO 4-6 MINORISTA EN LA WEB

En el ejemplo 1.2 se presentó a Pat Niebuhr y su equipo, quienes son responsables del desarrollo de un plan global de dotación de personal para los centros de contacto de un minorista grande en la Web. Pat nece-

sita obtener un pronóstico mensual del total de los pedidos y los contactos totales por pedido (CPP) de los cuales le informará el departamento de finanzas, para así pronosticar el número de contactos semanales

con el cliente (por teléfono, correo electrónico, etcétera) que se establecen en los centros de contacto. Los centros de contacto están abiertos 24 horas al día, siete días a la semana y deben contar con el personal suficiente para mantener un alto nivel de servicio. El minorista reconoce que un excelente servicio al cliente probablemente ayudará a que éste regrese y compre de nuevo.

La ecuación clave para Pat y su equipo es:

$$\text{Contactos} = \text{Pedidos} \times \text{CPP}$$

Los datos históricos indican el porcentaje de contactos por cada día de la semana. Por ejemplo, históricamente el 9.10% de los contactos semanales ocurren los domingos, el 17.25% de los contactos semanales ocurren los lunes, y así sucesivamente. Teniendo en mente el número de domingos, lunes, etcétera, en un mes determinado, los pronósticos mensuales de contactos pueden convertirse a pronósticos semanales de contactos. Los pronósticos semanales son los que se utilizan para efectos de planeación de la plantilla.

Pat piensa que podría ser una buena idea usar los datos históricos para generar directamente pronósticos de pedidos y contactos por pedido. Él está interesado en determinar si éstos pronósticos son más exactos que los pronósticos que el departamento de finanzas derivó de las proyecciones de ingresos. En principio, Pat y su equipo están interesados en los patrones de datos de los pedidos históricos mensuales y de los contactos por pedido, así que decidieron graficar estas series de tiempo y analizar las autocorrelaciones. Los datos se presentan en la tabla 4-12 y están graficados en las figuras 4-19 y 4-20. Las autocorrelaciones se presentan en las figuras 4-21 y 4-22.

Pat está intrigado con las gráficas de las series de tiempo y las funciones de autocorrelación, y siente que un procedimiento de suavización podría ser la herramienta correcta para ajustar las series de tiempo a los pedidos y contactos por pedido, así como para la generación de pronósticos.

TABLA 4-12 Pedidos y contactos por pedido (CPP) del minorista en la Web, junio de 2001 a junio de 2003

<i>Mes</i>	<i>Pedidos</i>	<i>CPP</i>
01 jun.	3,155,413	0.178
01 jul.	3,074,723	0.184
01 ago.	3,283,838	0.146
01 sept.	2,772,971	0.144
01 oct.	3,354,889	0.144
01 nov.	4,475,792	0.152
01 dic.	5,944,348	0.152
02 ene.	3,742,334	0.174
02 feb.	3,681,370	0.123
02 mar.	3,546,647	0.121
02 abr.	3,324,321	0.117
02 mayo	3,318,181	0.116
02 jun.	3,181,115	0.129
02 jul.	3,022,091	0.131
02 ago.	3,408,870	0.137
02 sept.	3,501,779	0.140
02 oct.	3,712,424	0.144
02 nov.	4,852,090	0.129
02 dic.	7,584,065	0.124
03 ene.	4,622,233	0.136
03 feb.	3,965,540	0.116
03 mar.	3,899,108	0.111
03 abr.	3,670,589	0.108
03 mayo	3,809,110	0.101
03 jun.	4,159,358	0.105




FIGURA 4-19 Gráfica de series de tiempo de pedidos, junio de 2001 a junio de 2003




FIGURA 4-20 Gráfica de series de tiempo de contactos por pedido (CPP), junio de 2001 a junio de 2003

PREGUNTAS

1. ¿Qué aprendieron Pat y su equipo acerca de los patrones de datos de los pedidos y de los contactos por pedido en las gráficas de las series de tiempo y de las funciones de autocorrelación?
2. Ajuste un procedimiento de suavización apropiado para las series de tiempo de pedidos y genere pronósticos para los siguientes cuatro meses. Justifique su selección.

Función de autocorrelación para pedidos

Retraso	ACF	T	LBQ
1	0.449007	2.25	5.67
2	0.052358	0.22	5.75
3	-0.101155	-0.43	6.06
4	-0.196536	-0.82	7.31
5	-0.271190	-1.10	9.79
6	-0.187990	-0.73	11.04




FIGURA 4-21 Función de autocorrelación para pedidos

Función de autocorrelación para CPP

Retraso	ACF	T	LBQ
1	0.637679	3.19	11.44
2	0.346901	1.29	14.97
3	0.195365	0.68	16.14
4	0.098064	0.34	16.45
5	0.084642	0.29	16.69
6	0.147248	0.50	17.46




FIGURA 4-22 Función de autocorrelación para contactos por pedido (CPP)

- Ajuste un procedimiento de suavización apropiado para las series de tiempo de contactos por pedido y genere los pronósticos para los siguientes cuatro meses. Justifique su selección.
- Utilice los resultados de las preguntas 2 y 3 para generar pronósticos de contactos para los siguientes cuatro meses.
- Pat tiene acceso a una hoja de cálculo con la historia de contactos reales. Él está considerando elaborar el pronóstico de contactos directamente en vez de multiplicar los pronósticos de pedidos y contactos por pedido. ¿Esto parece razonable? ¿Por qué?
- Muchos pedidos contienen más de un artículo (unidad). ¿Sería mejor enfocarse en el número de unidades y contactos por unidad para obtener un pronóstico de contactos? Discútalos.

CASO 4-7 SOUTHWEST MEDICAL CENTER

Mary Beasley es responsable de dar seguimiento al número de visitas facturadas al grupo Medical Oncology de Southwest Medical Center. Su información personal sugiere que el número de visitas ha ido en aumento y que algunas épocas del año parecen estar más saturadas que otras. Algunos médicos están empezando a quejarse por la carga de trabajo y afirman que no siempre tienen tiempo suficiente para interactuar de forma individual con los pacientes. ¿Será necesario un aumento en la plantilla de médicos para manejar el aparente incremento en la demanda? Si es

así, ¿cuántos nuevos doctores habrá que contratar y/o reasignar a esta área?

Para comprender mejor la naturaleza de la demanda del servicio, Mary abre su hoja de cálculo de Excel y revisa el número total mensual de visitas facturadas de varios años fiscales anteriores. Los datos están listados en la tabla 4-13.

Una gráfica de series de tiempo con los datos de Mary se presenta en la figura 4-23. Como se esperaba, la serie de tiempo muestra una tendencia ascendente, pero Mary no está segura de si existe un componente

TABLA 4-13 Total de visitas facturadas por el Medical Oncology, año fiscal 1995 al año fiscal 2004

Año	Sept.	Oct.	Nov.	Dic.	Ene.	Feb.	Mar.	Abr.	Mayo	Jun.	Jul.	Ago.
FY1994-95	725	789	893	823	917	811	1,048	970	1,082	1,028	1,098	1,062
FY1995-96	899	1,022	895	828	1,011	868	991	970	934	784	1,028	956
FY1996-97	916	988	921	865	998	963	992	1,118	1,041	1,057	1,200	1,062
FY1997-98	1,061	1,049	829	1,029	1,120	1,084	1,307	1,458	1,295	1,412	1,553	1,480
FY1998-99	1,554	1,472	1,326	1,231	1,251	1,092	1,429	1,399	1,341	1,409	1,367	1,483
FY1999-00	1,492	1,650	1,454	1,373	1,466	1,477	1,466	1,182	1,208	1,132	1,094	1,061
FY2000-01	1,018	1,233	1,112	1,107	1,305	1,181	1,391	1,324	1,259	1,236	1,227	1,294
FY2001-02	1,083	1,404	1,329	1,107	1,313	1,156	1,184	1,404	1,310	1,200	1,396	1,373
FY2002-03	1,259	1,295	1,100	1,097	1,357	1,256	1,350	1,318	1,271	1,439	1,441	1,352
FY2003-04	1,339	1,351	1,197	1,333	1,339	1,307	—	—	—	—	—	—




FIGURA 4-23 Gráfica de la serie de tiempo del total de visitas al Medical Oncology, año fiscal 1995 al año fiscal 2004

estacional en la serie de visitas totales. Ella decide investigar este asunto construyendo la función de autocorrelación. Si existe un componente estacional en los datos mensuales, Mary espera ver justamente grandes autocorrelaciones en los retrasos estacionales: 12, 24,

etcétera. Por un curso que tomó en su maestría en administración, Mary sabe que el procedimiento de suavización de Winters podría ser un buen camino para generar pronósticos de visitas futuras si existen componentes de tendencia y estacionales.

PREGUNTAS

1. ¿Qué revela el análisis de autocorrelación de Mary?
2. Ajuste un procedimiento de suavización apropiado para los datos de Mary, examine las autocorrelaciones residuales y genere pronósticos para el resto del año fiscal 2003-2004. ¿Estos pronósticos parecen razonables?
3. Considerando los resultados de la pregunta 2, ¿cree que es probable que otro método de elaboración del pronóstico genere “mejores” pronósticos? Discútalos.
4. ¿Usted cree que sería necesario el aumento de la plantilla médica para manejar la demanda futura? Escriba un breve reporte resumiendo el análisis de los datos de Mary y las implicaciones de la plantilla adicional.

CASO 4-8 SURTIDO COOKIES

En el caso 3-5, Jaime Luna investigó el patrón de datos de las ventas mensuales de Galletas Surtido (véase la tabla 3-12). En ese caso, Karin, uno de los miembros del equipo de Jaime, sugirió que los pronósticos de las ventas futuras para un mes determinado se podría generar usando sencillamente el promedio de ventas históricas de ese mes. Sin embargo, después de aprender algo acerca de los métodos de suavización, Jaime piensa que un procedimiento de suavización podría ser un mejor modo para elaborar pronósticos de las ventas

futuras. Jaime reconoce que los primeros pasos importantes para seleccionar un método de pronóstico son graficar las series de tiempo de las ventas y la realización de un análisis de autocorrelación. Él sabe que a menudo uno puede aprender mucho con tan sólo revisar una gráfica de series de tiempo. Más aún, las autocorrelaciones tienden a reforzar el patrón observado en la gráfica. Jaime está listo para iniciar con el objetivo de la generación de pronósticos de ventas mensuales de galletas para los meses restantes de 2003.

PREGUNTAS

1. ¿Qué patrón(es) observó Jaime en la gráfica de series de tiempo de las ventas de Surtido Cookies?
2. ¿Las autocorrelaciones son congruentes con el patrón (o los patrones) que Jaime observó en la gráfica de series de tiempo?
3. Seleccione y justifique un procedimiento de suavización apropiado para pronosticar las ventas futuras de galletas y elabore pronósticos para los meses restantes de 2003.
4. Use la sugerencia del promedio mensual histórico de Karin para elaborar pronósticos para los meses restantes de 2003. ¿Cuáles pronósticos prefiere, los de usted o los de Karin? ¿Por qué?

Aplicaciones de Minitab

El problema. En el ejemplo 4-3 se necesita pronosticar los datos de la Spokane Transit Authority usando un promedio móvil de cinco semanas.

Solución Minitab

1. Introduzca los datos de la Spokane Transit Authority mostrados en la tabla 4-2 (véase la p. 112), en la columna C1. Haga clic en los siguientes menús:

Stat>Time Series>Moving Average

2. Aparece la ventana de diálogo de Moving Average.
 - a) Haga doble clic en la variable Gallons y aparecerá a la derecha de Variable.
 - b) Puesto que queremos un promedio móvil de cinco meses, ponemos 5 para la longitud MA.
 - c) No haga clic en la ventana Center moving average. Usaremos un promedio móvil centrado para suavizar los datos en el capítulo 5.
 - d) Haga clic en Generate y ponga 1 a la derecha en número de pronósticos (Number of forecasts).
 - e) Haga clic en OK y aparecerá la figura 4-4.

El problema. En el ejemplo 4-6 se necesita pronosticar los datos de Acme Tool Company usando suavización exponencial simple.

Solución Minitab


1. Introduzca los datos de Acme Tool Company presentados en la tabla 4-1 (véase la p. 109) de los años 2000 a 2006 en la columna C1. Haga clic en los siguientes menús:
Stat>Time Series>Single Exponential Smoothing
2. Aparece la ventana de diálogo de la suavización exponencial simple
 - a) Haga doble clic en la variable Saws y aparecerá a la derecha de Variable.
 - b) Debajo de Weight to Use in Smoothing, seleccione Optimal ARIMA y haga clic en OK. El resultado se presenta en la figura 4-8 (véase la p. 129).

El problema. En el ejemplo 4.10 se requiere pronosticar los datos de Acme Tool Company usando suavización exponencial ajustada para la tendencia y la estacionalidad.

Solución Minitab

1. Introduzca los datos de Acme Tool Company presentados en la tabla 4-1 (véase la p. 109) de los años 2000 a 2006 en la columna C1. Haga clic en los siguientes menús:
Stat>Time Series>Winters' Method

FIGURA 4-24 Ventana de diálogo de Minitab para el método de Winters



2. Aparece la ventana de diálogo del Winters Method como se presenta en la figura 4-24.
 - a) La variable de interés es Saws (serruchos).
 - b) Puesto que los datos son trimestrales, seleccione 4 para Seasonal (la estacionalidad).
 - c) Los Weights in Use in Smoothing son Level: 0.4; Trend: 0.1; y Seasonal: 0.3.
 - d) Haga clic en Generate y en Number of forecasts, seleccione 4.
 - e) Haga clic en Storage.
3. Aparece la ventana de diálogo Winter's Method Storage.
 - a) Haga clic en estimaciones Level, Trend y Seasonal, Fits (un periodo delante de los pronósticos) y Residuals.
 - b) Haga clic en OK tanto en la ventana de diálogo del Winter's Method Storage como en la ventana de diálogo Winters' Method. Los resultados se presentan en la tabla 4-9 y en la figura 4-12. El pronóstico para el primer trimestre de 2007 es 778.2.
4. Si desea guardar los datos para uso posterior, haga clic en los siguientes menús:
File>Save Worksheet As
5. Aparece la ventana de diálogo Save Worksheet As.
 - a) Teclee un nombre tal como Saws en el espacio de File Name.
 - b) El espacio Save as Type le permite seleccionar cómo quiere guardar su archivo. La mayoría de las veces usted seleccionará Minitab. Sin embargo, usted puede guardar su archivo de manera que puedan usarlo varios programas de software. Por ejemplo, usted podría guardarlo como un archivo de Excel. El archivo se guarda como Saws.xls y se utilizará en la sección de las aplicaciones de Excel.

Aplicaciones de Excel

El problema. En el ejemplo 4.5 los datos de Acme Tool Company se pronosticaron usando suavización exponencial simple con una constante de suavización igual a .6.

Solución de Excel

1. Abra el archivo que contiene los datos presentados en la tabla 4-1 (véase la p. 109) haciendo clic en los siguientes menús:

File>Open

Busque el archivo llamado Saws.xls.

2. Haga clic en los siguientes menús:

Tools>Data Analysis

Aparece la ventana de diálogo Data Analysis. Bajo Analysis Tools, seleccione Exponential Smoothing y haga clic en OK. Aparecerá la ventana de diálogo Exponential Smoothing presentada en la figura 4-25.

- a) Introduzca A2:A25 en la ventana de edición Input Range.
 - b) Revise la ventana Labels.
 - c) Introduzca .4 en el cuadro de edición del factor Damping, $(1 - \alpha)$ se definió como el complemento de la constante de suavización.
 - d) Introduzca B3 en la ventana de edición Output Range. (Esto pondrá al pronóstico $\hat{Y}_t$ opuesto al valor correspondiente en la columna A).
 - e) Revise la ventana Chart Output.
 - f) Ahora haga clic en OK.
4. Los resultados (columna B) y la gráfica se presentan en la figura 4-26. Advierta que la herramienta de análisis Exponential Smoothing pone fórmulas en la hoja de cálculo. La celda B5 aparece resaltada y la fórmula $= 0.6 \times A4 + 0.4 \times B4$ se presenta en la barra de herramientas de fórmula.




FIGURA 4-25 Ventana de diálogo de la Suavización exponencial de Excel




FIGURA 4-26 Suavización exponencial de Excel: Resultados del ejemplo 4.5

- Note que si bien Excel inicia la suavización exponencial de manera diferente al modo de inicio de la suavización en la tabla 4-7 (observe los primeros valores en la columna correspondiente a $\alpha = .6$), después de seis o siete iteraciones los números de la columna B

en la figura 4-26 y los números en la columna correspondientes a $\alpha = .6$ en la tabla 4-7 son exactamente los mismos. Las fluctuaciones debidas a las diferentes opciones de valores iniciales desaparecen rápidamente.

Referencias

- Aaker, D. A. y R. Jacobson. "The Sophistication of 'Naive' Modeling". *International Journal of Forecasting* 3(314)(1987): 449-452.
- Bowerman, B. L., R. T. O'Connell y A. B. Koheler. *Forecasting, Time Series and Regression*, 4a. ed. Belmont, CA: Thomson Brooks/Cole, 2005.
- Dalrymple, D. J. y B. E. King. "Selecting Parameters for Short-Term Forecasting Techniques". *Decision Sciences* 12(1981): 661-669.
- Gardner, E. S. Jr. "Exponential Smoothing: The State of the Art", *Journal of Forecasting* 4((1985): 1-28.
- Gardner, E. S. Jr. y D. G. Dannenbring. "Forecasting with Exponential Smoothing: Some Guidelines for Model Selection". *Decision Sciences* 11(1980): 370-383.
- Holt, C. C. "Forecasting Seasonals and Trends by Exponentially Weighted Moving Averages". *International Journal of Forecasting* 20(2004): 5-10.
- Holt, C. C., F. Modigliani, J. F. Muth y H. A. Simon. *Planning Production Inventories and Work Force*. Englewood Cliffs, N.J.: Prentice Hall, 1960.
- Koehler, A. B., R. D. Snyder y D. K. Ord. "Forecasting Models and Prediction Intervals for the Multiplicative Holt-Winters Method". *International Journal of Forecasting* 17(2001): 269-286.
- Ledolter, J. y B. Abraham. "Some Comments on the Initialization of Exponential Smoothing", *Journal of Forecasting* 3(1)(1984): 79-84.
- Makridakis, S., S. C. Wheelwright y R. Hyndman. *Forecasting Method and Applications*. Nueva York: Wiley, 1998.
- McKenzie, E. "An Analysis of General Exponential Smoothing", *Operations Research* 24(1976): 131-140.
- Newbold, P. y T. Bos. *Introductory Business and Economic Forecasting*, 2a. ed. Cincinnati, Ohio: South-Western, 1994.
- Winters, P. R. "Forecasting Sales by Exponentially Weighted Moving Averages". *Management Science* 6(1960): 324-342.

SERIES DE TIEMPO Y SUS COMPONENTES

Como hemos apuntado en capítulos anteriores, las observaciones de una variable Y que se recaban en el transcurso del tiempo se conocen como *datos de una serie de tiempo* o simplemente una *serie de tiempo*. Estas observaciones se registran a menudo en intervalos fijos de tiempo. Por ejemplo, Y podría representar ventas, y la serie de tiempo asociada podría ser una secuencia de cifras de ventas anuales. Otros ejemplos de series de tiempo incluyen ingresos trimestrales, niveles de inventario mensuales y tasas de tipo de cambio semanales. En general, las series de tiempo no se comportan como muestras aleatorias y requieren de métodos especiales para su análisis. Las observaciones de una serie de tiempo generalmente están relacionadas unas con otras (autocorrelacionadas). Esta dependencia genera patrones de variabilidad que pueden utilizarse para pronosticar valores futuros y ayudar en la administración de las operaciones de los negocios. Considere estas situaciones.

American Airlines (AA) compara las reservaciones actuales con pronósticos basados en proyecciones de patrones históricos. Si las reservaciones actuales están retrasadas o exceden las proyecciones, AA ajusta la proporción correspondiente a los asientos con descuento. Los ajustes se hacen para cada segmento de vuelo en el sistema de AA.

Un importador canadiense de flores compra sus productos a floricultores de Estados Unidos, México, Centroamérica y Sudamérica. Sin embargo, como estos proveedores adquieren parte de sus insumos y agroquímicos en Estados Unidos, todos los precios de venta se cotizan en dólares estadounidenses en el momento de la venta. Una factura no se paga inmediatamente, y puesto que la tasa de cambio entre el dólar canadiense y el estadounidense fluctúa, el costo para el importador en dólares canadienses se desconoce en el momento de la compra. Si la tasa de cambio no varía antes del pago de la factura, no existe riesgo monetario para el importador. Si la tasa se eleva, el importador pierde dinero por cada dólar de la compra. Si la tasa de cambio disminuye, el importador gana. El importador usa pronósticos semanales de la tasa de cambio entre el dólar canadiense y el dólar estadounidense para administrar el inventario de flores.

Si bien las series de tiempo a menudo se elaboran internamente y son únicas para cada organización, muchas series de interés en los negocios se pueden obtener de fuentes externas. Publicaciones como *Statistical Abstract of the United States*, *Survey of Current Business*, *Monthly Labor Review* y el *Federal Reserve Bulletin* contienen series de tiempo de todos tipos. Éstas y otras publicaciones dan a conocer datos de series de tiempo mensuales, trimestrales o anuales sobre precios, producción, ventas, empleo, desempleo, horas laboradas, combustible consumido, energía producida, ingresos, etcétera. En la actualidad están disponibles una gran cantidad de series de tiempo en la World Wide Web, en sitios correspondientes a oficinas gubernamentales, organizaciones de estadística, universidades e individuos.

Es importante que los administradores comprendan el pasado y usen datos históricos y su buen juicio para hacer planes inteligentes que satisfagan las demandas del futuro. Los pronósticos de series de tiempo elaborados adecuadamente ayudan a eliminar parte de la incertidumbre asociada con el futuro y puede ayudar a la dirección de una empresa en la definición de estrategias alternativas.

La alternativa, por supuesto, no es planear anticipadamente. Sin embargo, en un ambiente de negocios dinámico, la falta de planeación podría ser desastrosa. Un fabricante de grandes computadoras que hace algunos años hubiera ignorado la tendencia hacia las computadoras personales y estaciones de trabajo habría perdido una gran parte de su participación en el mercado bastante rápido.

Si bien centraremos nuestra atención en un enfoque basado en un modelo de análisis de series de tiempo que depende fundamentalmente de los datos, es muy importante una revisión subjetiva de las actividades de la elaboración de pronósticos. El pasado es relevante en la búsqueda de claves acerca del futuro sólo en la medida en que las condiciones causales previas continúen su efecto en el periodo siguiente. En las actividades económicas y de negocios, las condiciones causales pocas veces permanecen constantes. La multitud de factores causales en el trabajo tienden a cambiar constantemente, de manera que las relaciones entre el pasado, el presente y el futuro deben reevaluarse continuamente.

Las técnicas de las series de tiempo ofrecen un enfoque conceptual para la elaboración de pronósticos que ha probado ser muy útil. Los pronósticos se elaboran con la ayuda de un conjunto de procedimientos formales específicos y los juicios que se derivan de ello se exponen de manera explícita.

DESCOMPOSICIÓN

Un enfoque para el análisis de los datos de las series de tiempo incluye un intento por identificar los componentes que influyen en cada uno de los valores de una serie. Este procedimiento de identificación se llama *descomposición*. Cada componente se identifica por separado. Las proyecciones de cada uno de los componentes se pueden usar luego de manera combinada para elaborar pronósticos de valores futuros de la serie de tiempo. Los métodos de descomposición se usan para pronósticos tanto de corto como de largo plazos. También se emplean para exhibir de manera simple el crecimiento o la declinación subyacente de una serie, así como para ajustar la serie al eliminar uno o más de los componentes.

El análisis de una serie de tiempo a través de la descomposición de sus componentes tiene una larga historia. Sin embargo, recientemente, los métodos de descomposición para pronosticar han perdido algo de su prestigio. Con frecuencia, las proyecciones de los componentes individuales en el futuro y la recombinación de esas proyecciones para elaborar un pronóstico de la serie subyacente no funcionan muy bien en la práctica. La dificultad radica en la obtención de pronósticos exactos de los componentes. El desarrollo de procedimientos para la elaboración de pronósticos basados en un modelo más flexible (algunos de los cuales examinaremos en capítulos posteriores) ha hecho de la descomposición una herramienta fundamental para la comprensión de las series de tiempo y no un método de pronóstico en sí mismo.

Para comprender la descomposición, iniciaremos con los cuatro componentes de las series de tiempo que se presentaron en el capítulo 3. Éstos son el componente de la tendencia, el componente cíclico, el componente estacional y el componente irregular o aleatorio.

1. *Tendencia*. La tendencia es el componente que representa el crecimiento (o la declinación) subyacente en una serie de tiempo. La tendencia se produce, por ejemplo, como resultado de la inflación, de cambios demográficos persistentes o de cambios tecnológicos e incrementos en la productividad. El componente de la tendencia se denota como T .
2. *Componente cíclico*. Es una serie de fluctuaciones en forma de onda o ciclos de más de un año de duración. Las condiciones cambiantes de la economía generalmente producen ciclos. La letra C representa el componente cíclico.

En la práctica, los ciclos son difíciles de identificar, de manera que con frecuencia se les considera como parte de la tendencia. En este caso, el crecimiento (o la declinación) general subyacente del componente se llama *tendencia-ciclo* y se denota como T . Usamos la notación de la tendencia porque con frecuencia es difícil separar el componente cíclico de la tendencia.

3. *Componente estacional*. Los componentes estacionales se encuentran comúnmente en datos trimestrales, mensuales o semanales. La variación estacional se refiere a un patrón de cambio más o menos estable que aparece anualmente y se repite un año tras otro. Los

patrones estacionales ocurren por la influencia del tiempo climatológico o por acontecimientos relacionados con el calendario, como las vacaciones escolares y los días feriados nacionales. S representa al componente estacional.

4. *Componente irregular.* El componente irregular consiste en fluctuaciones impredecibles o aleatorias. Estas fluctuaciones son el resultado de incontables hechos que de forma individual tal vez no sean particularmente importantes, pero cuyos efectos combinados suelen ser considerables. I representa al componente irregular.

Para estudiar los componentes de una serie de tiempo, el analista debe considerar cómo se relacionan los componentes con la serie original. Esta tarea se lleva a cabo especificando un *modelo* (relación matemática) que exprese la variable Y de la serie de tiempo en términos de los componentes T , C , S e I . Un modelo que trata los valores de la serie de tiempo como una suma de los componentes se llama *modelo aditivo de los componentes*. Un modelo que trata los valores de las series de tiempo como el producto de los componentes se llama *modelo multiplicativo de los componentes*. Ambos modelos se denominan algunas veces *modelos de componentes no observados*, puesto que, en la práctica, si bien observamos los valores de la serie de tiempo, no sucede lo mismo con los valores de los componentes. El método de análisis de las series de tiempo descrito en este capítulo implica un intento por estimar los valores de los componentes, dada la serie observada. Estas estimaciones pueden utilizarse para pronosticar o desplegar la serie sin el inconveniente de las fluctuaciones estacionales. Este último proceso se llama *ajuste estacional*.

Es difícil tratar con el componente cíclico de una serie de tiempo. En la medida en que los ciclos puedan determinarse a partir de los datos históricos, tanto su duración (medida en años) como su magnitud (diferencias entre altas y bajas) están lejos de ser constantes. Esta falta de un patrón consistente de la onda hace que se dificulte la distinción entre los ciclos y las tendencias que evolucionan con suavidad. En consecuencia, para simplificar, supondremos que cualquier ciclo en los datos es parte de la tendencia. De manera que inicialmente consideraremos sólo tres componentes: T , S e I . Una explicación breve de un modo de manejar las fluctuaciones cíclicas en el método de descomposición para el análisis de las series de tiempo se incluye en la sección de variaciones cíclicas e irregulares de este capítulo (véase la p. 180).

Los dos modelos más sencillos que relacionan los valores observados (Y_t) de una serie de tiempo con los componentes de la tendencia (T_t), estacionales (S_t) e irregulares (I_t) son el modelo de componentes aditivo:

$$Y_t = T_t + S_t + I_t \quad (5.1)$$

y el modelo de componentes multiplicativo:

$$Y_t = T_t \times S_t \times I_t \quad (5.2)$$

El modelo de componentes aditivo funciona mejor cuando la serie de tiempo sometida a análisis tiene aproximadamente la misma variabilidad a lo largo de toda la serie. Es decir, en esencia, todos los valores de la serie caen dentro de una banda de anchura constante centrada en la tendencia.

El modelo de componentes multiplicativo funciona mejor cuando la variabilidad de la serie de tiempo aumenta con el nivel.¹ Es decir, los valores de la serie se dispersan conforme la tendencia aumenta, y el conjunto de observaciones tiene la apariencia de un megáfono o embudo. En la figura 5-1 se representan una serie de tiempo con variabilidad constante y una serie de

¹Es posible convertir una descomposición multiplicativa en una descomposición aditiva trabajando con los logaritmos de los datos. A partir de la ecuación 5.2 y de las propiedades de los logaritmos, tenemos que $\log Y = \log (T \times S \times I) = \log T + \log S + \log I$. La descomposición de datos logarítmicos se analiza en el problema 5.15.




FIGURA 5-1 Serie de tiempo con variabilidad constante (arriba) y una serie de tiempo con variabilidad creciente con el nivel (abajo)

tiempo cuya variabilidad aumenta con el nivel. Estas dos series mensuales tienen una tendencia creciente y un patrón estacional claramente definido.²

Tendencia

Las tendencias son movimientos a largo plazo en una serie de tiempo que en ocasiones pueden describirse mediante una línea recta o una curva suave. Ejemplos de los factores básicos que producen o influyen en la tendencia de una serie de tiempo son un cambio en la población, un cambio de precio, un cambio tecnológico, un incremento en la productividad y los ciclos de vida de un producto.

²Existen variantes de los modelos de descomposición (véanse las ecuaciones 5.1 y 5.2) que contienen términos tanto multiplicativos como aditivos. Por ejemplo, algunos paquetes de software realizan la descomposición “multiplicativa” usando el modelo $Y = T \times S + I$.

Un incremento en la población podría causar que las ventas al menudeo de una comunidad aumenten anualmente durante varios años. Más aún, es posible que las ventas en dólares actuales se eleven durante el mismo periodo como resultado de incrementos generales en los precios de bienes al menudeo, aun cuando el volumen físico de los bienes vendidos no cambie.

En ocasiones los cambios tecnológicos provocan que una serie de tiempo se desplace hacia arriba o hacia abajo. El desarrollo de chips de alta velocidad para computadoras, el perfeccionamiento de los dispositivos de memoria y la mejora en las pantallas, acompañados de avances en la tecnología de telecomunicaciones, han dado como resultado incrementos drásticos en el uso de computadoras personales y teléfonos celulares. Por supuesto, los mismos desarrollos tecnológicos han traído consigo una tendencia descendente en la producción de calculadoras mecánicas y teléfonos convencionales.

Los incrementos en la productividad que podrían deberse a cambios tecnológicos le dan una pendiente ascendente a muchas series de tiempo. Cualquier medida de la producción total, como las ventas de los fabricantes, se ve afectada por cambios en la productividad.

Para las series de tiempo de negocios y económicas, lo mejor es ver la tendencia (o tendencia-ciclo) como un cambio uniforme en el tiempo. En raras ocasiones podemos suponer que la tendencia realmente queda representada mediante alguna función tan simple como una línea recta durante el todo el periodo en el cual observamos la serie de tiempo. Sin embargo, a menudo es conveniente ajustar una curva de tendencia a una serie de tiempo por dos razones: **1.** proporciona cierto indicio de la dirección general de la serie observada, y **2.** puede eliminarse de la serie original para obtener una imagen más clara de la estacionalidad.

Si la tendencia parece ser aproximadamente lineal —es decir, si aumenta o disminuye como una línea recta—, entonces se representa por la ecuación:

$$\hat{T}_t = b_0 + b_1t \quad (5.3)$$

en donde $\hat{T}_t$ es el valor pronosticado de la tendencia para el tiempo t . El símbolo t representa el tiempo, la variable independiente, y ordinariamente toma los valores 1, 2, 3, ... correspondientes a periodos consecutivos. El coeficiente de la pendiente, b_1 , es el incremento o decremento promedio de T para cada incremento de un periodo en el tiempo.

Las ecuaciones de tendencia en el tiempo, incluyendo la tendencia en línea recta, se pueden ajustar a los datos usando el *método de mínimos cuadrados*. Recuerde del capítulo 2 que el método de mínimos cuadrados selecciona los valores de los coeficientes en la ecuación de tendencia (b_0 y b_1 en el caso de la línea recta), de manera que los valores estimados de la tendencia ($\hat{T}_t$) estén cerca de los valores reales (Y_t) conforme se miden con el criterio de la suma del cuadrado de los residuos.

$$SSE = \sum (Y_t - \hat{T}_t)^2 \quad (5.4)$$

Ejemplo 5.1

Los datos anuales de los registros de vehículos nuevos de pasajeros en Estados Unidos de 1960 a 1992 se presentan en la tabla 5-1 y están graficados en la figura 5-2. Los valores de 1960 a 1992 se emplean para desarrollar la ecuación de la tendencia. Los registros de vehículos son la variable dependiente, y la variable independiente es el tiempo t , codificado como 1960 = 1, 1961 = 2 y así sucesivamente.

La línea de tendencia ajustada tiene la ecuación:

$$\hat{T}_t = 7.988 + .0687t$$

La pendiente de la ecuación de tendencia indica que se estima que los registros se incrementan en un promedio de 68,700 cada año. La figura 5-3 presenta la línea recta de la tendencia ajustada de los datos reales. La figura 5-3 también muestra los pronósticos de registros de automóviles nuevos para los años 1993 y 1994 ($t = 34$ y $t = 35$), los cuales se obtuvieron extrapolarando la línea de la tendencia. Más adelante, diremos algo más acerca del pronóstico de la tendencia.

Los valores estimados de la tendencia para los registros de vehículos de pasajeros de 1960 a 1992 se presentan en la tabla 5-1, en la columna $\hat{T}$. Por ejemplo, la ecuación de la tendencia estima que los registros en 1992 ($t = 33$) fueron:



$$\hat{T}_{33} = 7.988 + .0687(33) = 10.255$$

TABLA 5-1 Registro de vehículos nuevos de pasajeros en Estados Unidos, 1960 a 1992, para el ejemplo 5.1

<i>Año</i>	<i>Registros (millones) Y</i>	<i>Tiempo t</i>	<i>Tendencia estimada (millones) $\hat{T}$</i>	<i>Error (millones) $Y - \hat{T}$</i>
1960	6.577	1	8.0568	-1.4798
1961	5.855	2	8.1255	-2.2705
1962	6.939	3	8.1942	-1.2552
1963	7.557	4	8.2629	-0.7059
1964	8.065	5	8.3316	-0.2666
1965	9.314	6	8.4003	0.9138
1966	9.009	7	8.4690	0.5401
1967	8.357	8	8.5376	-0.1807
1968	9.404	9	8.6063	0.7977
1969	9.447	10	8.6750	0.7720
1970	8.388	11	8.7437	-0.3557
1971	9.831	12	8.8124	1.0186
1972	10.409	13	8.8811	1.5279
1973	11.351	14	8.9498	2.4012
1974	8.701	15	9.0185	-0.3175
1975	8.168	16	9.0872	-0.9192
1976	9.752	17	9.1559	0.5961
1977	10.826	18	9.2246	1.6014
1978	10.946	19	9.2933	1.6527
1979	10.357	20	9.3620	0.9950
1980	8.761	21	9.4307	-0.6697
1981	8.444	22	9.4994	-1.0554
1982	7.754	23	9.5681	-1.8141
1983	8.924	24	9.6368	-0.7128
1984	10.118	25	9.7055	0.4125
1985	10.889	26	9.7742	1.1148
1986	11.140	27	9.8429	1.2971
1987	10.183	28	9.9116	0.2714
1988	10.398	29	9.9803	0.4177
1989	9.833	30	10.0490	-0.2160
1990	9.160	31	10.1177	-0.9577
1991	9.234	32	10.1863	-0.9524
1992	8.054	33	10.2550	-2.2010

Fuente: Datos del Departamento de Comercio de Estados Unidos, *Survey of Current Business* (varios años).

es decir, 10,255,000 registros. Sin embargo, los registros de automóviles nuevos de pasajeros fueron en realidad 8,054,000 en 1992. De manera que, para 1992, la ecuación de la tendencia sobreestima los registros por aproximadamente 2.2 millones. Éste y los demás errores de estimación definidos como $Y - \hat{T}$ se listan en la tabla 5-1. Estos errores de estimación se usaron para calcular las medidas de ajuste, *MAD*, *MSD* y *MAPE*, presentadas en la figura 5-3. Éstas son las mismas medidas de precisión del pronóstico dadas por las ecuaciones 3.7, 3.8 y 3.10, respectivamente, en el capítulo 3. (Los comandos de Minitab que se usaron para generar los resultados en el ejemplo 5.1 se especifican en la sección de Aplicaciones de Minitab al final de este capítulo).

**FIGURA 5-2** Serie de tiempo de registros de automóviles para el ejemplo 5.1**FIGURA 5-3** Tendencia lineal de las series de tiempo de registros de automóviles para el ejemplo 5.1

Curvas de tendencia no lineal

El ciclo de vida de un producto nuevo tiene tres etapas: Introducción, crecimiento, y madurez y saturación. En la figura 5-4 se observa una curva que representa las ventas (en dólares o unidades) durante el ciclo de vida de un producto nuevo. El tiempo, representado sobre el eje horizontal, puede variar de días a años, dependiendo de la naturaleza del mercado. Con estos datos no funcionaría una línea recta para modelar la tendencia. Los modelos lineales suponen que una variable aumenta (o disminuye) por una cantidad constante en cada periodo de




FIGURA 5-4 Ciclo de vida típico de un producto nuevo

tiempo. Los incrementos por periodo en la curva del ciclo de vida del producto son muy diferentes dependiendo de la etapa del ciclo. Se necesita una curva diferente de una línea recta para modelar la tendencia del ciclo de vida de un producto nuevo.

Una función simple que toma en cuenta la curvatura es la ecuación de la tendencia cuadrática:

$$\hat{T}_t = b_0 + b_1t + b_2t^2 \quad (5.5)$$

Como ilustración de lo anterior, la figura 5-5 presenta una curva de tendencia cuadrática ajustada a los datos de los registros de automóviles de pasajeros del ejemplo 5.1 usando el criterio *SSE*. Es posible proyectar la tendencia cuadrática más allá de los datos para, digamos, dos años adicionales, 1993 y 1994. Consideraremos las implicaciones de esta proyección en la siguiente sección, dedicada al pronóstico de la tendencia.




FIGURA 5-5 Curva de tendencia cuadrática para la serie de tiempo de los registros de automóviles para el ejemplo 5.1

Con base en las medidas de precisión *MAPE*, *MAD* y *MSD*, una tendencia cuadrática parece ser una mejor representación de la dirección general de las series de registros de vehículos que la tendencia lineal de la figura 5-3. ¿Cuál es el modelo de tendencia adecuado? Antes de considerar este asunto, presentaremos unas cuantas curvas adicionales de tendencia que han probado su utilidad.

Cuando una serie de tiempo inicia lentamente y luego parece que se incrementa a un ritmo creciente de manera (véase la figura 5-4) que la diferencia porcentual entre una observación y otra es constante, es posible ajustar una tendencia exponencial. La tendencia exponencial está dada por:

$$\hat{T}_t = b_0 b_1^t \quad (5.6)$$

El coeficiente b_1 está relacionado con la tasa de crecimiento. Si la tendencia exponencial se ajusta a los datos anuales, se estima que la tasa de crecimiento anual es $100(b_1 - 1)\%$.

La figura 5-6 indica el número de vendedores empleados por el fondo común de inversión de una compañía particular durante varios años consecutivos. El incremento en el número de vendedores no es constante. Parece como si los mayores incrementos en el número de vendedores se presentaron en los últimos años.

Una curva de tendencia exponencial que se ajusta a los datos de los vendedores tiene la ecuación

$$\hat{T}_t = 10.016(1.313)^t$$

lo que implica una tasa de crecimiento anual de alrededor del 31%. En consecuencia, si el modelo estima 51 vendedores en 2005, el aumento en 2006 sería $16(51 \times .31)$, para un estimado total de 67. Esto se puede comparar con el valor real de 68 vendedores.

Una tendencia lineal ajustada a los datos de los vendedores indicaría un incremento promedio constante de alrededor de nueve vendedores por año. Esta tendencia sobreestima el incremento real en los primeros años y subestima el crecimiento en el último año. No modela la tendencia aparente de los datos tan bien como lo hace la curva exponencial.

Es claro que la extrapolación de una tendencia exponencial con una tasa de crecimiento del 31% rápidamente producirá algunas cifras muy grandes. Éste es un problema potencial del modelo de tendencia exponencial. ¿Qué pasa cuando la economía entra en calma y los precios de las acciones comienzan a retraerse? La demanda de vendedores del fondo de inversión disminuirá, y el número de vendedores podría incluso declinar. El pronóstico de la tendencia mediante la curva exponencial será demasiado alto.




FIGURA 5-6 Gráfica de vendedores del fondo común de inversión

Las curvas de crecimiento del tipo logístico o de Gompertz representan la tendencia de muchas industrias y líneas de productos cuyo crecimiento registra una tasa de declinación conforme maduran. Si los datos graficados reflejan una situación en la cual las ventas inician bajas, luego se incrementan conforme el producto gana popularidad y finalmente disminuyen conforme se alcanza la saturación, la curva de Gompertz o el modelo logístico de Pearl-Reed podrían ser adecuados. La figura 5-7 muestra una comparación de las formas generales de a) la curva de Gompertz y b) el modelo logístico de Pearl Reed. Observe que la curva de logística es muy similar a la curva de Gompertz, aunque tiene una pendiente ligeramente más suave. La figura 5-7 indica cómo las intersecciones en Y y los valores máximos para estas curvas están relacionados con algunos de los coeficientes en sus formas funcionales. Las fórmulas para estas líneas de tendencia son complejas y no están dentro del alcance de este libro. Muchos paquetes estadísticos de software, incluyendo Minitab, permiten ajustar varios de los modelos de tendencias presentados en esta sección.

Si bien existen algunos criterios objetivos para seleccionar una tendencia apropiada, en general, la elección correcta es un asunto de buen juicio y, por lo tanto, requiere de experiencia y sentido común por parte del analista. Como veremos en la siguiente sección, la línea o curva que mejor se ajusta a un conjunto de puntos de datos podría carecer de sentido cuando se proyecta como una tendencia hacia el futuro.

Pronóstico de la tendencia

Ahora suponga que estamos en el momento $t = n$ (fin de la serie) y queremos usar un modelo de tendencia para pronosticar el valor de Y , p pasos adelante. El periodo en el cual hacemos el pronóstico, n en este caso, se llama el *origen del pronóstico*. El valor p se conoce como *tiempo principal*. Para el modelo de tendencia lineal, podemos generar un pronóstico evaluando $\hat{T}_{n+p} = b_0 + b_1(n + p)$.

Al emplear la línea de tendencia ajustada para los datos del registro de vehículos del ejemplo 5.1, un pronóstico de la tendencia para 1993 ($t = 34$) realizado en 1992 ($t = n = 33$) sería el pronóstico un paso adelante $p = 1$

$$\hat{T}_{33+1} = 7.988 + .0687(33 + 1) = 7.988 + .0687(34) = 10.324$$

De manera análoga, el pronóstico para dos pasos adelante $p = 2$ (1994) está dado por

$$\hat{T}_{33+2} = 7.988 + .0687(33 + 2) = 7.988 + .0687(35) = 10.393$$

Estos dos pronósticos se muestran en la figura 5-3 como extrapolaciones de la línea de tendencia ajustada.




FIGURA 5-7 Curvas de crecimiento en forma de S

La figura 5-5 ilustra la curva de tendencia cuadrática ajustada a los datos del registro de automóviles. Al emplear la ecuación presentada en la figura, podemos calcular pronósticos de la tendencia para 1993 y 1994 estableciendo que $t = 33 + 1 = 34$ y $t = 33 + 2 = 35$. El lector podrá verificar que $\hat{T}_{33+1} = 8.688$ y $\hat{T}_{33+2} = 8.468$. Estos números se graficaron en la figura 5-5 como extrapolaciones de la curva de tendencia cuadrática.

Como los registros de vehículos se miden en millones, los dos pronósticos de tendencia obtenidos a partir de la curva cuadrática son muy diferentes de los pronósticos obtenidos a partir de la ecuación de tendencia lineal. Más aún, se mueven en dirección opuesta. Si tuviéramos que extrapolar las tendencias lineal y cuadrática para periodos de tiempo adicionales, sus diferencias serían más evidentes.

El ejemplo del registro de vehículos ilustra por qué debemos tener mucho cuidado al usar curvas de tendencia ajustadas para pronosticar tendencias futuras. Dos ecuaciones que representan razonablemente bien la serie de tiempo observada, tal vez den resultados muy diferentes cuando se proyectan hacia periodos futuros. Estas diferencias podrían ser sustanciales para tiempos principales largos (pronósticos a largo plazo).

Los modelos de la curva de tendencia se basan en las siguientes suposiciones:

1. Se ha seleccionado la curva de tendencia correcta.
2. La curva que se ajusta al pasado es indicativa del futuro.

Estas suposiciones sugieren que el buen juicio y la experiencia desempeñan un papel esencial en la selección y el uso de una curva de tendencia. Al usar una curva de tendencia para pronosticar, debemos estar en condiciones de argumentar que se ha seleccionado la tendencia correcta y que, con toda probabilidad, el futuro será como el pasado.

Existen criterios objetivos para seleccionar una curva de tendencia. En el capítulo 9 analizaremos dos de estos criterios: el criterio de información Akaike (AIC, por las siglas de *Akaike information criterion*) y el criterio de información Bayesiano (BIC, por las siglas de *Bayesian information criterion*). Sin embargo, aun cuando éstos y otros criterios ayudan a identificar un modelo adecuado, no reemplazan el buen juicio.

Estacionalidad

Un patrón estacional es aquel que se repite un año tras otro. Para datos anuales, la estacionalidad no tiene sentido porque no hay oportunidad de modelar un patrón con datos que se recaban una vez por año. Sin embargo, las series de tiempo que consisten en observaciones semanales, mensuales o trimestrales a menudo presentan estacionalidad.

El análisis del componente estacional de una serie de tiempo tiene implicaciones inmediatas en el corto plazo y es de gran importancia para la administración de los niveles medios y bajos. Los planes de marketing, por ejemplo, deben tomar en cuenta los patrones estacionales esperados en las compras de los consumidores.

Se han desarrollado varios métodos para medir la variación estacional. La idea básica en todos estos métodos es, primero, estimar y eliminar la tendencia de la serie original y, después, suavizar el componente irregular. Teniendo en mente nuestros modelos de descomposición, esto deja datos que contienen sólo variación estacional. Luego, se recolectan y se resumen los valores estacionales para obtener un número (generalmente un *número índice*) para cada intervalo del año observado (semana, mes, trimestre, etcétera).

Así, la identificación del componente estacional en una serie de tiempo difiere del análisis de tendencia por lo menos en dos formas:

1. La tendencia se determina directamente a partir de los datos originales, pero el componente estacional se determina indirectamente después de eliminar los otros componentes de los datos, de manera que sólo quede la estacionalidad.
2. La tendencia se representa mediante la curva, o ecuación, mejor ajustada, mientras que debe calcularse un valor estacional por separado para cada intervalo observado del año (semana, mes, trimestre) y a menudo tiene la forma de un número índice.

Si se emplea una descomposición aditiva, las estimaciones de la tendencia y los componentes estacionales e irregulares se suman para generar la serie original. Si se usa una descomposición multiplicativa se deben multiplicar los componentes individuales para reconstruir la serie original, y en esta formulación, el componente estacional se representa por una colección de números índices. Estos números indican qué periodos del año son relativamente bajos y qué periodos son relativamente altos. Los índices estacionales definen el patrón estacional.

Los *números índices* son porcentajes que indican los cambios en el tiempo.

Con los datos mensuales, por ejemplo, un índice estacional de 1.0 para un mes particular significa que el valor esperado para ese mes es de 1/12 del total del año. Un índice de 1.25 para un mes diferente implica que se espera que la observación para ese mes sea un 25% mayor que 1/12 del total anual. Un índice mensual de 0.80 indica que el nivel esperado de actividad para ese mes es 20% menor que 1/12 del total del año, y así sucesivamente. Los números índices indican las altas y bajas esperadas en los niveles de actividad durante el curso del año después de haber eliminado los efectos que se deben a la tendencia (o tendencia-ciclo) y los componentes irregulares.

Para resaltar la estacionalidad, primero debemos estimar y eliminar la tendencia. Esta última puede estimarse con una de las curvas de tendencia que explicamos antes, o bien, usando un promedio móvil, como vimos en el capítulo 4.

Al suponer un modelo de descomposición multiplicativo, la *proporción del promedio móvil* es un método que se emplea comúnmente para medir la variación estacional. En este método, la tendencia se estima usando un promedio móvil centrado. Ilustramos el método de la proporción del promedio móvil con las ventas mensuales de la Cavanaugh Company, que se muestran en la figura 5.1 (abajo) en el siguiente ejemplo.

Ejemplo 5.2

Para ilustrar el método de proporción del promedio móvil, utilizamos los datos de dos años de ventas mensuales de la Cavanaugh Company.³ La tabla 5-2 indica las ventas mensuales de enero de 2004 a diciembre de 2005 para ilustrar los cálculos desde el principio. Cuando tenemos datos mensuales, el primer paso es calcular un promedio móvil de 12 meses (para datos trimestrales se calcularía un promedio móvil de cuatro meses). Como todos los meses del año están incluidos en los cálculos de este promedio móvil, se eliminan los efectos que se deben al componente estacional, de manera que el promedio móvil sólo contenga la tendencia y los componentes irregulares.

Los pasos (identificados en la tabla 5-2) para calcular los índices estacionales por el método de la proporción del promedio móvil son los siguientes:

- Paso 1.** Partiendo del principio de la serie, calcule el total móvil de 12 meses y coloque este total para enero de 2004 hasta diciembre de 2004 entre junio y julio de 2004.
- Paso 2.** Calcule el total móvil de dos años, de manera que los promedios subsecuentes estén centrados en julio, en lugar de que esto ocurra entre un mes y otro.
- Paso 3.** Puesto que el total de dos años contiene los datos de 24 meses (enero de 2004 una vez, febrero de 2004 a diciembre de 2004 dos veces, y enero de 2005 una vez), este total se centra en julio de 2004.
- Paso 4.** Divida el total móvil de dos años entre 24 para obtener el promedio móvil centrado de 12 meses.
- Paso 5.** El índice estacional para julio se calcula dividiendo el valor real de julio entre el promedio móvil centrado de 12 meses.⁴

³Se omitieron las unidades, y las fechas y nombres se alteraron para proteger la identidad de la compañía.

⁴Ésta es la operación de proporción del promedio móvil que da su nombre al procedimiento.

TABLA 5-2 Ventas de la Cavanaugh Company, 2004 a 2005, para el ejemplo 5.2

<i>Periodo</i>	<i>Ventas</i>	<i>Total móvil de 12 meses</i>	<i>Total móvil de dos años</i>	<i>Promedio móvil centrado de 12 meses</i>	<i>Índice estacional</i>
2004					
Enero	518	1 4,869 } ²	9,833 } ³	409.7 } ⁴	0.60 } ⁵
Febrero	404				
Marzo	300				
Abril	210				
Mayo	196				
Junio	186				
Julio	247				
Agosto	343				
Septiembre	464				
Octubre	680				
Noviembre	711				
Diciembre	610				
2005					
Enero	613	5,101	10,279	428.3	1.43
Febrero	392	5,178	10,417	434.0	0.90
Marzo	273	5,239	10,691	445.5	0.61
Abril	322	5,452	11,082	461.8	0.70
Mayo	189	5,630	11,444	476.8	0.40
Junio	257	5,814	11,682	486.8	0.53
Julio	324	5,868			
Agosto	404				
Septiembre	677				
Octubre	858				
Noviembre	895				
Diciembre	664				

Repita los pasos 1 a 5 iniciando con el segundo mes de la serie, agosto de 2004, y así sucesivamente. El proceso termina cuando ya no sea posible calcular un total móvil completo de 12 meses.

Puesto que existen varias estimaciones (correspondientes a diferentes años) del índice estacional para cada mes, deben sumarse para obtener un solo número. Se usa la mediana, y no la media, como la medida de resumen. Al emplear la mediana se elimina la influencia de los datos que son inusualmente grandes o pequeños para un mes de un año en particular. Un resumen de las proporciones estacionales, junto con el valor de la mediana para cada mes, se presenta en la tabla 5-3.

Los índices estacionales mensuales para cada año deben sumar 12, de manera que la mediana de cada mes debe ajustarse para obtener el conjunto final de índices estacionales.⁵ Puesto que este multiplicador debe ser mayor que 1 si el total de razones de medianas antes del ajuste es menor que 12, y menor que 1 si el total es mayor que 12, el multiplicador se define como

$$\text{Multiplicador} = \frac{12}{\text{Total real}}$$

⁵Los índices mensuales deben sumar 12 de manera que el total anual esperado iguale al total real del año.

TABLA 5-3 Resumen de índices estacionales mensuales de Cavanaugh Company para el ejemplo 5-2

<i>Mes</i>	<i>2000</i>	<i>2001</i>	<i>2002</i>	<i>2003</i>	<i>2004</i>	<i>2005</i>	<i>2006</i>	<i>Mediana</i>	<i>Índice estacional ajustado (Mediana × 1.0044)</i>
Enero	—	1.208	1.202	1.272	1.411	1.431	—	1.272	1.278
Febrero	—	0.700	0.559	0.938	1.089	0.903	—	0.903	0.907
Marzo	—	0.524	0.564	0.785	0.800	0.613	—	0.613	0.616
Abril	—	0.444	0.433	0.480	0.552	0.697	—	0.480	0.482
Mayo	—	0.424	0.365	0.488	0.503	0.396	—	0.424	0.426
Junio	—	0.490	0.459	0.461	0.465	0.528	—	0.465	0.467
Julio	0.639	0.904	0.598	0.681	0.603	0.662	—	0.651	0.654
Agosto	1.115	0.913	0.889	0.799	0.830	0.830	—	0.860	0.864
Septiembre	1.371	1.560	1.346	1.272	1.128	1.395	—	1.359	1.365
Octubre	1.792	1.863	1.796	1.574	1.638	1.771	—	1.782	1.790
Noviembre	1.884	2.012	1.867	1.697	1.695	1.846	—	1.857	1.865
Diciembre	1.519	1.088	1.224	1.282	1.445	—	—	1.282	1.288
								11.948	12.002

Usando la información de la tabla 5-3,

$$\text{Multiplicador} = \frac{12}{11.948} = 1.0044$$

La columna final de la tabla 5-3 contiene el índice estacional final de cada mes, calculado haciendo el ajuste (al multiplicar por 1.0044) para cada una de las proporciones de las medianas.⁶ Los índices estacionales finales presentados en la figura 5-8 representan el componente estacional en una descomposición multiplicativa de las ventas de la serie de tiempo de la Cavanaugh Company. La esta-




FIGURA 5-8 Índices estacionales de la Cavanaugh Company para el ejemplo 5.2

⁶En ocasiones los índices estacionales se multiplican por 100 y se expresan como porcentajes.

cionalidad en las ventas es evidente en la figura 5-8. Las ventas de esta compañía son periódicas, con ventas relativamente bajas al final de la primavera y relativamente altas al final del otoño.

Nuestro análisis de la serie de ventas del ejemplo 5.2 supuso que el patrón estacional permanecía constante de un año a otro. Si el patrón estacional parece modificarse con el tiempo, entonces la estimación del componente estacional con el conjunto completo de datos puede conducir a resultados engañosos. En este caso, es mejor: **1.** usar sólo datos recientes (de los últimos años) para estimar el componente estacional, o bien, **2.** usar un modelo de series de tiempo que permita analizar la evolución de la estacionalidad. En un capítulo posterior estudiaremos los modelos que permiten conocer la evolución de la estacionalidad.

El análisis estacional ilustrado en el ejemplo 5.2 es adecuado para un modelo de descomposición multiplicativo. Sin embargo, el enfoque general esquematizado en los pasos 1 a 5 funciona para una descomposición aditiva si, en el paso 5, la estacionalidad se calcula restando la tendencia de la serie original en vez de dividirla entre la tendencia (promedio móvil) para obtener un índice. En la descomposición aditiva, el componente estacional se expresa en las mismas unidades que la serie original.

Además, es evidente en nuestro ejemplo de ventas que el hecho de utilizar un promedio móvil centrado para determinar la tendencia da como resultado algunos valores faltantes en los extremos de la serie. Esto es particularmente problemático si el objetivo es la elaboración de un pronóstico. Para pronosticar valores futuros usando un método de descomposición, se deben usar métodos alternativos para la estimación de la tendencia.

Los resultados de un análisis estacional sirven para: **1.** eliminar la estacionalidad en los datos; **2.** pronosticar valores futuros; **3.** evaluar las posiciones actuales en ventas, inventarios y embarques, por ejemplo; y **4.** programar la producción.

Datos ajustados a la estacionalidad

Una vez que se ha aislado el componente estacional, se puede usar para calcular *datos ajustados a la estacionalidad*. Para una descomposición aditiva, los datos ajustados a la estacionalidad se calculan restando el componente estacional:

$$Y_t - S_t = T_t + I_t \quad (5.7a)$$

Para una descomposición multiplicativa, los datos ajustados a la estacionalidad se calculan dividiendo las observaciones originales entre el componente estacional:

$$\frac{Y_t}{S_t} = T_t \times I_t \quad (5.7b)$$

La mayoría de las series económicas que publican las oficinas gubernamentales están ajustadas estacionalmente porque la variación estacional no es de interés primordial. Más bien, lo que resulta de interés es el patrón de la actividad económica, independientemente de las fluctuaciones estacionales normales. Por ejemplo, los registros de vehículos nuevos podrían aumentar un 10% de mayo a junio, pero, ¿este aumento es un indicador de que las ventas de vehículos nuevos están completando un trimestre representativo? La respuesta es “no” si el 10% de aumento es común en ese momento del año fundamentalmente a causa de factores estacionales.

En una investigación relacionada con la obtención de datos ajustados estacionalmente, Bell y Hillmer (1984) encontraron que una amplia variedad de usuarios valoran los ajustes estacionales. Ellos identificaron tres motivos para hacer ajustes estacionales:

1. Los ajustes estacionales permiten la comparación confiable de valores en diferentes momentos.
2. Es más fácil comprender las relaciones entre las variables económicas o de negocios una vez que se ha eliminado de los datos el complicado factor de la estacionalidad.
3. El ajuste estacional es un elemento útil para elaborar pronósticos de corto plazo de los valores futuros de una serie de tiempo.

Bell y Hillmer concluyeron que “el ajuste estacional permite simplificar los datos de manera que los usuarios que no son expertos en estadística puedan interpretarlos más fácilmente, sin que esto implique una pérdida significativa de información” (p. 301).

Variaciones cíclicas e irregulares

Los ciclos son fluctuaciones de largo plazo en forma de onda, que se manifiestan sobre todo en los indicadores macroeconómicos de un país. Como hemos visto, hasta el grado en que se pueden medir, los ciclos no muestran un patrón consistente. Sin embargo, es posible lograr cierta comprensión del comportamiento cíclico de una serie de tiempo si se eliminan los componentes de tendencia y estacionalidad mediante la descomposición multiplicativa.⁷

$$\frac{Y_t}{T_t \times S_t} = \frac{T_t \times C_t \times S_t \times I_t}{T_t \times S_t} = C_t \times I_t \quad (5.8)$$

Se puede usar un promedio móvil para suavizar las irregularidades, I_t , dejando el componente cíclico C_t . Para eliminar el problema del centrado que se presenta cuando se usa un promedio móvil con un número par de periodos, las irregularidades se suavizan usando un promedio móvil con un número impar de periodos. Para datos mensuales, funcionará un promedio móvil de 5, 7, 9 o incluso 11 periodos. Para datos trimestrales, se puede calcular una estimación de C utilizando un promedio móvil de tres periodos de los valores.⁸

Finalmente, el componente irregular se calcula mediante

$$I_t = \frac{C_t \times I_t}{C_t} \quad (5.9)$$

El componente irregular representa la variabilidad en la serie de tiempo después de que se eliminaron los demás componentes. Algunas veces se le conoce como *residuo* o *error*. En una descomposición multiplicativa, tanto los componentes cíclicos como los irregulares se expresan en forma de índices.

Ejemplo de resumen

Una razón para la descomposición de una serie de tiempo es aislar y examinar los componentes de la serie. Después de que el analista está listo para revisar uno por uno los componentes de tendencia, estacionales, cíclicos e irregulares, podrá comprender los patrones en los valores de los datos originales. Además, una vez que se han aislado los componentes, es posible recombinarlos o sintetizarlos para elaborar pronósticos de valores futuros de las series de tiempo.

Ejemplo 5.3

En el ejemplo 3.5, Perkin Kendell, el analista de Coastal Marine Corporation, empleó el análisis de autocorrelación para determinar que las ventas eran estacionales sobre una base trimestral. Ahora utilizará la descomposición para entender la variable de las ventas trimestrales. Perkin emplea Minitab (véase la sección de aplicaciones de Minitab al final del capítulo) para elaborar la tabla 5-4 y la figura 5-9. Para conservar el patrón estacional actual, sólo se analizaron los datos de venta (Y) de los últimos siete años (2000 a 2006).

Los datos originales se presentan en la gráfica superior izquierda de la figura 5-10. La tendencia se calculó usando el modelo lineal: $\hat{T}_t = 261.24 + .759t$. Puesto que 1 representaba el primer trimestre de 2000, la tabla 5-4 muestra un valor de la tendencia igual a 262.000 para ese periodo, en tanto que las ventas estimadas (columna T) registraron un incremento de .759 cada trimestre.

⁷Advierta que hemos agregado el componente cíclico C a la descomposición multiplicativa de la ecuación 5.2.

⁸Para datos anuales, no existe componente estacional, y el componente cíclico $\times$ el componente irregular se obtiene eliminando simplemente la tendencia de la serie original.

TABLA 5-4 La descomposición multiplicativa de las ventas de Coastal Marine para el ejemplo 5.3

<i>t</i>	Año	Trimestre	Ventas	<i>T</i>	<i>SCI</i>	<i>S</i>	<i>TCI</i>	<i>CI</i>	<i>C</i>	<i>I</i>
1	2000	1	232.7	262.000	0.888	0.780	298.458	1.139	—	—
2		2	309.2	262.759	1.177	1.016	304.434	1.159	1.118	1.036
3		3	310.7	263.518	1.179	1.117	278.239	1.056	1.078	0.980
4		4	293.0	264.276	1.109	1.088	269.300	1.019	1.022	0.997
5	2001	1	205.1	265.035	0.774	0.780	263.059	0.993	0.960	1.034
6		2	234.4	265.794	0.882	1.016	230.787	0.868	0.940	0.924
7		3	285.4	266.553	1.071	1.117	255.582	0.959	0.906	1.059
8		4	258.7	267.312	0.968	1.088	237.775	0.890	0.924	0.962
9	2002	1	193.2	268.071	0.721	0.780	247.796	0.924	0.927	0.998
10		2	263.7	268.830	0.981	1.016	259.635	0.966	0.954	1.012
11		3	292.5	269.589	1.085	1.117	261.940	0.972	1.003	0.969
12		4	315.2	270.348	1.166	1.088	289.705	1.072	0.962	1.114
13	2003	1	178.3	271.107	0.658	0.780	228.686	0.844	0.970	0.870
14		2	274.5	271.866	1.010	1.016	270.269	0.994	0.936	1.062
15		3	295.4	272.625	1.084	1.117	264.537	0.970	0.976	0.994
16		4	286.4	273.383	1.048	1.088	263.234	0.963	0.942	1.022
17	2004	1	190.8	274.142	0.696	0.780	244.718	0.893	0.933	0.957
18		2	263.5	274.901	0.959	1.016	259.438	0.944	0.957	0.986
19		3	318.8	275.660	1.157	1.117	285.492	1.036	0.998	1.038
20		4	305.3	276.419	1.104	1.088	280.605	1.015	1.058	0.960
21	2005	1	242.6	277.178	0.875	0.780	311.156	1.123	1.089	1.031
22		2	318.8	277.937	1.147	1.016	313.886	1.129	1.104	1.023
23		3	329.6	278.696	1.183	1.117	295.164	1.059	1.100	0.963
24		4	338.2	279.455	1.210	1.088	310.844	1.112	1.078	1.032
25	2006	1	232.1	280.214	0.828	0.780	297.689	1.062	1.059	1.004
26		2	285.6	280.973	1.016	1.016	281.198	1.001	0.996	1.005
27		3	291.0	281.732	1.033	1.117	260.597	0.925	0.947	0.977
28		4	281.4	282.491	0.996	1.088	258.639	0.916	—	—

La gráfica superior derecha en la figura 5-10 presenta los datos sin la tendencia. Estos datos también se muestran en la columna *SCI* de la tabla 5-4. El valor sin la tendencia para el primer trimestre de 2000 fue⁹

$$SCI = \frac{Y}{T} = \frac{232.7}{262.000} = .888$$

Los datos ajustados a la estacionalidad se presentan en la columna *TCI* de la tabla 5-4 y en la figura 5-10. El valor ajustado a la estacionalidad del primer trimestre de 2000 fue

$$TCI = \frac{232.7}{.77967} = 298.458$$

Las ventas en el primer trimestre de 2005 fueron 242.6. Sin embargo, la revisión de la columna ajustada a la estacionalidad indica que las ventas para ese trimestre en realidad fueron altas cuando los datos se ajustaron al hecho de que el primer trimestre, comúnmente, es muy débil.

⁹Para simplificar la notación en este ejemplo, omitimos el subíndice *t* en los datos originales *Y*, así como en cada uno de sus componentes *T*, *S*, *C* e *I*. También omitimos el signo de multiplicación $\times$ entre los componentes, puesto que resulta claro que estamos considerando una descomposición multiplicativa.




FIGURA 5-9 Resultado de Minitab para la descomposición de las ventas trimestrales de Coastal Marine para el ejemplo 5.3




FIGURA 5-10 Análisis de componentes de las ventas de Coastal Marine para el ejemplo 5.3

Los índices estacionales en la figura 5-9 fueron

Primer trimestre = .77967 → 78.0 %
 Segundo trimestre = 1.01566 → 101.6%
 Tercer trimestre = 1.11667 → 111.7%
 Cuarto trimestre = 1.08800 → 108.8%

La gráfica de la izquierda en la figura 5-11 muestra los componentes estacionales en relación con 1.0. Vemos que las ventas del primer trimestre están un 22% por debajo del promedio, las ventas del segundo trimestre están cerca de lo esperado, las ventas del tercer trimestre están casi un 12% por arriba del promedio, mientras que las ventas del cuarto trimestre están casi un 9% por arriba de lo normal.

El valor cíclico-irregular del primer trimestre de 2000 fue¹⁰

$$CI = \frac{Y}{TS} = \frac{232.7}{(262.000)(.77967)} = 1.139$$

Para calcular la columna cíclica, se calculó un promedio móvil de tres periodos. El valor para el segundo trimestre de 2000 fue

$$\begin{array}{r} 1.139 \\ 1.159 \\ 1.056 \\ \hline 3.354 \end{array} \quad 3.354/3 = 1.118$$

Observe que la suavización de la columna *C* es comparada con la columna *CI*. La razón es que al usar el promedio móvil se han suavizado las irregularidades.

Finalmente, se calculó la columna *I*. Por ejemplo, para el segundo trimestre de 2000,

$$I = \frac{CI}{C} = \frac{1.159}{1.118} = 1.036$$

Al examinar la columna *I* se observa que existieron algunos cambios importantes en el componente irregular. El índice irregular cayó del 111.4% en el cuarto trimestre de 2002 al 87% en el primer




FIGURA 5-11 Análisis estacional de las ventas de Coastal Marine para el ejemplo 5.3

¹⁰Minitab calcula el componente cíclico × el componente irregular (o simplemente el componente irregular si no se considera el componente cíclico) restando de los datos originales el componente tendencia × el componente estacional. En símbolos, Minitab establece que $CI = Y - TS$. El componente *CI* de Minitab se muestra en la gráfica inferior derecha de la figura 5-10. Más aún, Minitab ajusta la línea de tendencia a los datos ajustados estacionalmente. Es decir, se realiza el ajuste estacional antes de determinar la tendencia.

trimestre de 2003, y luego aumentó al 106.2% en el segundo trimestre de 2003. Este comportamiento es resultado de las ventas inusualmente bajas del primer trimestre de 2003.

Indicadores de negocios

Los índices cíclicos nos ayudan a responder las siguientes preguntas:

1. ¿La serie es cíclica?
2. Si es así, ¿qué tan extremo es el ciclo?
3. ¿La serie sigue el estado general de la economía (ciclo de negocios)?

Una manera de investigar los patrones cíclicos es a través del estudio de los indicadores de negocios. Un *indicador de negocios* es una serie de tiempo relacionada con los negocios que se emplea como ayuda para evaluar el estado general de la economía, particularmente en lo que se refiere al ciclo de negocios. Muchos empresarios y economistas siguen sistemáticamente los movimientos de estas series estadísticas para obtener información económica y de negocios en forma de una imagen desplegada que se considera actualizada, detallada, relativamente objetiva, y la cual puede leerse y comprenderse en poco tiempo.

Los *indicadores de negocios* son series de tiempo relacionadas con los negocios, las cuales ayudan a evaluar el estado general de la economía.

La lista más importante de indicadores estadísticos se originó durante la fuerte recesión que sufrieron los negocios entre 1937 y 1938. En esa época, el Secretario del Tesoro, Henry Morgenthau, pidió a la Oficina Nacional de Investigación Económica (National Bureau of Economic Research, NBER) diseñar un sistema que indicara cuándo terminaría la recesión. Bajo el liderazgo de Wesley Michael y Arthur F. Burns, los economistas del NBER seleccionaron 21 series que, según su comportamiento en el pasado, prometían ser indicadores confiables de la reactivación económica. Desde entonces, la lista de indicadores de negocios se ha revisado varias veces. La lista actual contiene 21 indicadores: 10 clasificados como adelantados, 4 como coincidentes y 7 como retrasados.

1. *Indicadores adelantados.* En la práctica, los componentes de la serie adelantada se estudian para anticipar los momentos de cambio en la economía. El *Survey of Current Business* publica esta lista cada mes, junto con los valores reales de cada serie en varios meses pasados y el año más reciente. Además, se calcula un índice compuesto de indicadores adelantados para cada mes y año; el valor mensual más reciente se reporta a menudo en la prensa no especializada para indicar la dirección general del futuro de la economía. Ejemplos de indicadores adelantados son los permisos de construcción y los índices bursátiles.
2. *Indicadores coincidentes.* Los cuatro indicadores coincidentes proporcionan una medida de cómo está funcionando actualmente la economía de Estados Unidos. Un índice de estas cuatro series se calcula cada mes. Ejemplos de indicadores coincidentes son la producción industrial y las ventas de la industria y el comercio.
3. *Indicadores retrasados.* El nombre de estos indicadores se debe a que tienden a retrasarse con respecto a la situación general de la economía, tanto en tiempos de bonanza como de crisis. También se calcula un índice compuesto para esta lista. Ejemplos de indicadores retrasados son las tasas de interés preferencial y el índice de desempleo.

Los ciclos implican momentos de inflexión. Es decir, estos momentos indican el inicio de una caída o un crecimiento en el ciclo de negocios. Los indicadores adelantados cambian de dirección antes de que se presente un viraje en la actividad general de negocios, los indicadores coincidentes cambian al mismo tiempo que la economía general, y los indicadores retrasados experimentan un cambio después de que se manifiestan modificaciones en la

economía general. Sin embargo, es difícil identificar los puntos de inflexión cíclicos en el momento en que ocurren, puesto que no todas las áreas de la economía crecen al mismo tiempo durante periodos de expansión, ni tampoco se contraen de manera simultánea durante periodos de contracción. Por eso, tal vez pasen varios meses antes de que se identifique con certeza un verdadero ascenso o descenso cíclico.

Los indicadores adelantados son la herramienta más útil de predicción, puesto que intentan señalar cambios económicos de forma anticipada. En cambio, los indicadores coincidentes y los de comportamiento retrasado son de mínimo interés desde el punto de vista de los pronósticos, pero sirven para evaluar la efectividad de la política económica actual y pasada y así contribuir a formular futuras políticas.

En su artículo titulado “Early Warning Signals for the Economy”, Geoffrey H. Moore y Julius Shiskin (1976) dicen lo siguiente acerca de la utilidad de los indicadores del ciclo de negocios:

A partir de los registros, parece claro que los indicadores del ciclo empresarial son útiles en la interpretación de la tónica actual de los negocios y de las perspectivas a corto plazo. Pero a causa de sus limitaciones, los indicadores deben usarse junto con otros datos y con plena conciencia de los antecedentes de los negocios, de las expectativas y la confianza del consumidor, de las políticas gubernamentales, así como de los sucesos internacionales. También debemos advertir que los indicadores son a menudo difíciles de interpretar, que los analistas difieren en sus interpretaciones y que las señales que envían los indicadores tal vez no se interpreten correctamente. Los indicadores ofrecen una imagen sensible y reveladora del flujo y reflujo de las mareas económicas, la cual servirá a un analista hábil del escenario económico, político e internacional para mejorar sus probabilidades de hacer un pronóstico válido de las tendencias económicas a corto plazo. Si el analista está consciente de las limitaciones de los indicadores y está al tanto del mundo que lo rodea, encontrará en estos datos referencias útiles para hacer un balance de la economía y sus necesidades. (p. 81)

Por lo general, los componentes cíclicos de las series de tiempo individuales no se ajustan con mucho rigor —y en ocasiones no se ajustan en absoluto— al ciclo de negocios tal como se identifica con los indicadores NBER. Sin embargo, si se calcula un componente cíclico para una serie de tiempo determinada, siempre debe graficarse contra el tiempo para obtener alguna información de la magnitud y duración de cualquier ciclo que pudiera existir. Además, la gráfica debe examinarse para saber si existe alguna relación con las altas y bajas de la actividad económica en general.

La discusión hasta ahora indica cómo se pueden separar los factores que crean la variación en una serie de tiempo para estudiarlos individualmente. *Análisis* es el proceso de separar las partes de una serie de tiempo; *síntesis* es el proceso de reunir de nuevo las partes. A continuación pondremos juntos otra vez los componentes de la serie de tiempo para hacer pronósticos.

PRONÓSTICO DE UNA SERIE DE TIEMPO ESTACIONAL

En la elaboración del pronóstico de una serie estacional, se invierte el proceso de descomposición. En vez de separar la serie en sus componentes individuales para su examen, recombina los componentes para elaborar los pronósticos de periodos futuros. Usaremos el modelo multiplicativo y los resultados del ejemplo 5.3 para desarrollar los pronósticos de las ventas de Coastal Marine Corporation.

Ejemplo 5.4

Es posible desarrollar pronósticos para los cuatro trimestres de 2007 de las ventas de Coastal Marine Corporation usando la tabla 5-4.

1. *Tendencia*. La ecuación de la tendencia trimestral es $\hat{T}_t = 261.24 + .759t$. El pronóstico de origen es el cuarto trimestre de 2006, o periodo $t = n = 28$.

Las ventas del primer trimestre de 2007 ocurren en el periodo $t = 28 + 1 = 29$. Esta notación indica que estamos pronosticando el periodo $p = 1$ a partir del final de la serie de tiempo. Al establecer $t = 29$, la proyección de la tendencia es

$$\hat{T}_{29} = 261.24 + .759(29) = 283.251$$

2. *Estacionalidad*. El índice estacional para el primer trimestre, .77967, se presenta en la figura 5-9.
3. *Componente cíclico*. La proyección cíclica debe determinarse a partir del patrón cíclico estimado (si existe) y de cualquier otra información generada por los indicadores de la economía general para 2007. La proyección del patrón cíclico para periodos futuros está llena de incertidumbre y, como indicamos antes, para efectos del pronóstico se supone generalmente que está incluida en la tendencia. En el desarrollo de este ejemplo, daremos al índice cíclico un valor de 1.0.
4. *Componente irregular*. Las fluctuaciones irregulares representan una variación aleatoria que no es explicable a través de otros componentes. Para efectos del pronóstico, el componente irregular se fija en el valor promedio de 1.0.¹¹

El pronóstico del primer trimestre de 2007 es

$$\hat{Y}_{29} = T_{29} \times S_{29} \times C_{29} \times I_{29} = (283.251)(.77967)(1.0)(1.0) = 220.842$$

Los pronósticos para el resto de 2007 son

Segundo trimestre = 288.455

Tercer trimestre = 317.990

Cuarto trimestre = 310.654

Los pronósticos ajustados por descomposición multiplicativa para las ventas de Coastal Marine Corporation —junto con los pronósticos de 2007— se presenta en la figura 5-12. En la figura podemos ver que el ajuste, construido a partir de los componentes de tendencia y estacional, representa los datos reales razonablemente bien. Sin embargo, el ajuste no es bueno para los dos últimos trimestres de 2006, los periodos 27 y 28. Los pronósticos de 2007 imitan el patrón del ajuste.




FIGURA 5-12 Ajuste de descomposición y pronósticos de ventas de Coastal Marine para el ejemplo 5.4

¹¹Para los pronósticos generados a partir de un modelo aditivo, el índice de irregularidad se fija en un valor promedio de 0.

Los pronósticos que se elaboran a partir un modelo aditivo o un modelo de descomposición multiplicativo reflejan la importancia de los componentes individuales. Si una variable es altamente estacional, entonces los pronósticos tendrán un fuerte patrón estacional. Si, además, existe una tendencia, los pronósticos seguirán un patrón estacional superpuesto a la tendencia extrapolada. Si un componente domina el análisis, por sí solo daría un pronóstico exacto y práctico de corto plazo.

MÉTODO DE DESCOMPOSICIÓN DE CENSO II

Los métodos de descomposición de las series de tiempo tienen una larga historia. En las décadas de 1920 y 1930, el Federal Reserve Board y la National Bureau of Economic Research estuvieron fuertemente implicados en el ajuste estacional y la suavización de las series de tiempo económicas. Sin embargo, antes del desarrollo de las computadoras, los cálculos de descomposición eran laboriosos y la aplicación práctica de los métodos era limitada. A principios de la década de 1950, Julius Shiskin, jefe de estadística económica de la Oficina de Censos de Estados Unidos (U.S. Bureau of the Census), desarrolló un programa de cómputo de gran escala para descomponer series de tiempo. El primer programa de cómputo era similar, en esencia, a los métodos manuales que se usaban hasta entonces; un año después, se sustituyó por un programa mejorado conocido como el Método II. Con el paso de los años, continuaron las mejoras al Método II. La versión actual del programa de descomposición de series de tiempo del Census Bureau se conoce como X-12-ARIMA. Este programa está disponible sin cargo alguno en el Census Bureau y se utiliza ampliamente en oficinas gubernamentales y compañías privadas.¹²

La descomposición del Censo II por lo general es multiplicativa, puesto que la mayoría de las series de tiempo de naturaleza económica tienen una variación estacional que se incrementa con el nivel de las series. La descomposición también supone tres componentes: tendencia-ciclo, estacional e irregular.

El método del Censo II repite una serie de pasos hasta que los componentes logran aislarse con éxito. Muchos de los pasos implican la aplicación de promedios móviles ponderados a los datos. Esto da como resultado una pérdida inevitable de datos al principio y al final de la serie a causa del promedio. La parte ARIMA del X-12-ARIMA tiene la capacidad de ampliar la serie original en ambas direcciones con pronósticos, de manera que la mayoría de las observaciones se ajusten usando promedios móviles totalmente ponderados. Estos pronósticos se generan mediante un modelo ARIMA de series de tiempo (véase el capítulo 9).

Los pasos de cada iteración del método Censo II, tal como se implementaron en el X-12-ARIMA, se describen a continuación. Quizá parezca que el método es complicado, ya que son muchos los pasos que deben realizarse. Sin embargo, la idea básica es muy simple: aislar uno por uno los componentes de tendencia-ciclo, estacional e irregular. Las numerosas iteraciones están diseñadas para mejorar la estimación de cada componente. Para un estudio más detallado, consulte las siguientes referencias: *Forecasting: Methods and Applications* (Makridakis, Wheelwright y Hyndman, 1998), *Forecasting: Practice and Process for Demand Management* (Levenbach y Cleary, 2006), y “New Capabilities and Methods of the X-12-ARIMA Seasonal-Adjustment Program” (Findley *et al.*, 1998).

- Paso 1.** Se aplica un promedio móvil de s periodos a los datos originales para obtener un estimado aproximado del componente tendencia-ciclo. (Para datos mensuales, $s = 12$; para datos trimestrales, $s = 4$; etcétera).
- Paso 2.** Se calculan las razones entre los datos originales y estos valores de promedios móviles como una descomposición multiplicativa clásica, como se ilustra en el ejemplo 5.2.

¹²La versión para PC del programa X-12-ARIMA puede descargarse del sitio Web del U.S. Census Bureau. En el momento en que se escribió este libro, la dirección del sitio de la página para efectuar la descarga era www.census.gov/srd/www/x12a/x12down_pc.html.

- Paso 3.** Las razones del paso 2 contienen tanto el componente estacional como el irregular. También incluyen los valores extremos resultantes de eventos inusuales como huelgas o guerras. Las razones se dividen entre una estimación aproximada del componente estacional para obtener una estimación del componente irregular. Un valor demasiado grande del término irregular indica un valor extremo en los datos originales. Se identifican estos valores extremos y se ajustan las razones del paso 2 como corresponda. Esto elimina efectivamente valores que no se ajustan al patrón de los datos restantes. Los valores faltantes al principio y al final de las series también se reemplazan con las estimaciones de esta etapa.
- Paso 4.** Las razones obtenidas a partir de los datos modificados (con los valores extremos reemplazados y las estimaciones de los valores faltantes) se suavizan usando un promedio móvil para eliminar la variación irregular. Esto permite obtener una estimación preliminar del componente estacional.
- Paso 5.** Los datos originales se dividen entre el componente estacional preliminar del paso 4 para obtener la serie preliminar ajustada estacionalmente, la cual contiene el componente tendencia-ciclo y el componente irregular. En símbolos,

$$\frac{Y_t}{S_t} = \frac{T_t \times S_t \times I_t}{S_t} = T_t \times I_t$$

- Paso 6.** El componente tendencia-ciclo se estima aplicando un promedio móvil ponderado a la serie preliminar ajustada estacionalmente. Este promedio móvil elimina la variación irregular y genera una curva suave que indica el componente preliminar de tendencia-ciclo en los datos.
- Paso 7.** Se repite el paso 2 con esta nueva estimación de la tendencia-ciclo. Es decir, las nuevas razones que contienen sólo los componentes estacionales e irregulares se obtienen dividiendo las observaciones originales entre la tendencia-ciclo del paso 6. Éstas son las razones finales estacionales-irregulares. Matemáticamente,

$$\frac{Y_t}{T_t} = \frac{T_t \times S_t \times I_t}{T_t} = S_t \times I_t$$

- Paso 8.** Se repite el paso 3 usando las nuevas razones calculadas en el paso 7.
- Paso 9.** Se repite el paso 4 para obtener una nueva estimación del componente estacional.
- Paso 10.** Se repite el paso 5 con el componente estacional del paso 9.
- Paso 11.** Se dividen los datos ajustados estacionalmente del paso 10 entre la tendencia-ciclo obtenida en el paso 6 para obtener el componente irregular estimado.
- Paso 12.** Los valores extremos del componente irregular se sustituyen como en el paso 3. Se obtiene una serie de datos modificados al multiplicar la tendencia-ciclo, el componente estacional y el componente irregular ajustado. Estos datos reproducen los datos originales, a excepción de los valores extremos.

Se repiten los 12 pasos anteriores, iniciando con los datos modificados del paso 12 en vez de los datos originales. La longitud de los promedios móviles usados en los diferentes pasos cambiará dependiendo de la variabilidad en los datos.

La serie final ajustada estacionalmente se determina dividiendo el componente estacional final entre los datos originales. El resultado contiene sólo el producto del componente tendencia-ciclo y el componente irregular.

Los valores de cada uno de los componentes finales se imprimen y se grafican. Existe un conjunto de pruebas de diagnóstico que permiten determinar si la descomposición fue correcta.

El programa X-12-ARIMA posee características adicionales que no hemos descrito. Por ejemplo, es posible hacer ajustes para considerar diferentes números de días de operación o los efectos de días no laborables; también es posible estimar y reemplazar los valores faltantes dentro de la serie, eliminar los efectos de los valores atípicos antes de la descomposición, o bien, modelar otros cambios en la tendencia, como modificaciones en un nivel o efectos de rampa temporales.

APLICACIÓN A LA ADMINISTRACIÓN

El análisis de las series de tiempo es una herramienta estadística ampliamente utilizada en el pronóstico de acontecimientos futuros entrelazados de alguna manera con la economía. Las compañías manufactureras están sumamente interesadas en los ciclos de prosperidad y declinación tanto de la economía nacional como de economías extranjeras, de manera que puedan predecir mejor la demanda de sus productos, la cual, a la vez, tendrá efectos sobre sus niveles de inventario, necesidades de personal, flujos de efectivo y casi todas las demás actividades dentro de la empresa.

La complejidad de estos problemas es enorme. Tomemos, por ejemplo, el problema de la predicción de la demanda de petróleo y sus derivados. A finales de la década de 1960, el precio del petróleo por barril era muy bajo y parecía haber una demanda mundial insaciable de gas y petróleo. Luego vino la sacudida de los precios del petróleo al principio y mediados de la década de 1970. ¿Cuál sería la demanda futura del petróleo? ¿Qué sucedería con los precios? Desde luego, empresas como Exxon y General Motors estaban muy interesadas en las respuestas a estas preguntas. Si los precios continuaban la escalada, ¿disminuiría la demanda de automóviles grandes? ¿Cuál sería la demanda de energía eléctrica? En general, los analistas predijeron que la demanda de energía y, por consiguiente, de petróleo sería muy inelástica, de manera que los precios continuarían superando a la inflación. Sin embargo, estas predicciones no tomaron en cuenta un profundo descenso en el ciclo de negocios a principios de la década de 1980 y una mayor elasticidad que la anunciada en la demanda de energía por parte de los consumidores. Alrededor de 1980, el mundo empezó a ver un exceso de petróleo en el mercado y los precios cayeron de forma drástica. Por ese tiempo, parecía difícil creer que los consumidores estuvieran beneficiándose realmente, una vez más, de la guerra de precios de la gasolina. Para cuando esta edición se escribía, disturbios importantes en el Medio Oriente generaron de nuevo una escasez de petróleo. El precio de un barril de petróleo y el costo de un galón de gasolina en Estados Unidos alcanzaron cifras muy altas y sin precedentes.

La demanda de petróleo no sólo se ve influida por acontecimientos cíclicos de largo plazo, sino además por sucesos estacionales y aleatorios; esto se refleja también en la mayoría de los pronósticos de demanda de cualquier tipo de producto o servicio. Por ejemplo, considere los sectores de servicios y de ventas al menudeo. Hemos sido testigos de un desplazamiento continuo del empleo del sector manufacturero hacia los sectores de servicios y de ventas al menudeo. Sin embargo, las ventas al menudeo (ya sea en tiendas, por catálogo o por Internet) son negocios extremadamente estacionales y cíclicos, por lo que las proyecciones de demanda y de inventario son esenciales para los minoristas, quienes cada vez utilizarán más el análisis de las series de tiempo.

Las compañías manufactureras tienen una necesidad continua de proyecciones estadísticas de acontecimientos futuros. Fuimos testigos del crecimiento explosivo en los campos de la tecnología y las telecomunicaciones durante la década de 1990 y de la contracción sustancial de estas industrias al principio del siglo XXI. Tal crecimiento y contracción fueron el resultado, en gran medida, de proyecciones de demanda que nunca se materializaron por completo. Las preguntas que todas las empresas manufactureras deben plantearse son: ¿Cuál será la tasa de inflación en el futuro? ¿Cómo se verán afectados los ajustes del costo de la vida que se incluyen en los contratos laborales de la compañía? ¿Qué repercusión tendrán estos ajustes en los precios y en la demanda? ¿Cuáles serán las habilidades gerenciales requeridas en 2025? ¿Cuál será el efecto del gasto gubernamental y las estrategias fiscales?

¿Cómo será la población de gente joven en el futuro? ¿Cuál será la mezcla étnica? Estos asuntos afectan a casi todos los segmentos de la economía. Los demógrafos están siguiendo muy de cerca las tasas de fertilidad actual y emplean casi todas las técnicas de pronósticos

disponibles de series de tiempo para tratar de hacer proyecciones de las variables demográficas. Errores de cálculo muy pequeños tendrán fuertes repercusiones en todos los ámbitos, desde la producción de juguetes para niños hasta la solidez financiera del sistema de seguridad social. Es interesante ver cómo los demógrafos están mirando los ciclos de negocios de largo plazo (ciclos de 20 años o más) al tratar de predecir qué hará esa generación de mujeres en edad fértil en lo que se refiere a la maternidad. ¿Tendrán uno o dos hijos como las familias de las décadas de 1960 y 1970, o regresarán a la concepción de dos o tres hijos, como lo hicieron las generaciones anteriores? Estas decisiones determinarán la composición de edad de la población para los próximos 50 o 75 años.

Los especialistas en ciencias políticas están interesados en usar el análisis de las series de tiempo para estudiar los patrones variables de los gastos gubernamentales en los programas de defensa y de asistencia social. Como es evidente, estas tendencias tienen gran repercusión en el futuro de todas las industrias.

Finalmente, un microcosmos interesante para la aplicación del análisis de las series de tiempo es el ámbito legal. Los abogados están usando cada vez más testigos expertos para testificar acerca del valor presente de los ingresos futuros de una persona o una empresa, el costo en que se incurre por la pérdida de un trabajo a causa de la discriminación, y el efecto sobre el mercado de una huelga ilegal. Estas preguntas a menudo se contestan mejor a través del uso acertado del análisis de las series de tiempo.

La tecnología satelital y la World Wide Web han hecho posible la acumulación y transmisión de información de manera casi instantánea. La proliferación de computadoras personales, la disponibilidad de programas estadísticos de cómputo fáciles de usar y el acceso creciente a las bases de datos han traído al escritorio el procesamiento de la información. La supervivencia de los negocios durante periodos de mayor cambio competitivo requiere la toma rápida de decisiones con base en el manejo de datos. El análisis de las series de tiempo y la elaboración de pronósticos desempeñan un papel importante en estos procesos de toma de decisiones.

APÉNDICE: ÍNDICE DE PRECIOS

Varias de las series de tiempo referentes a producción, ventas y otras situaciones económicas contienen datos disponibles sólo en dólares. Estos datos se ven afectados tanto por las cantidades físicas de bienes vendidos como por sus precios. La inflación y una gran variación de precios en el tiempo pueden causar problemas de análisis. Por ejemplo, un aumento en la cantidad en dólares puede esconder una disminución en las ventas de unidades cuando los precios están inflados. Así, a menudo es necesario saber cuánto del cambio del valor en dólares representa un cambio real en la cantidad física y cuánto se debe al cambio en el precio causado por la inflación. En estos casos es deseable expresar los valores en dólares constantes.

El concepto de *poder de compra* es importante. El poder actual de compra de \$1 se define como sigue:

$$\text{Actual poder de compra de \$1} = \frac{100}{\text{Índice de precios al consumidor}} \quad (5.10)$$

De esta forma, si en noviembre de 2006 el índice de precios al consumidor (considerando 2002 como 100) alcanza 150, el poder de compra actual del dólar del consumidor en noviembre de 2006 es

$$\text{Actual poder de compra de \$1} = \frac{100}{150} = .67$$

El dólar de 2006 compraba sólo dos tercios de los bienes y servicios que pudieron comprarse con un dólar del periodo base (2002).

Para expresar los valores de dólares en términos de *dólares constantes*, se usa la ecuación 5.11.

$$\text{Valor deflactado del dólar} = (\text{Valor del dólar}) = (\text{Poder de compra de \$1}) \quad (5.11)$$

Suponga que las ventas de automóviles se elevaron de \$300,000 en 2005 a \$350,000 en 2006, mientras que el índice de precios de automóviles nuevos (considerando 2002 como base) se elevó de 135 a 155. Las ventas deflactadas de 2005 y 2006 serían

$$\text{Ventas deflactadas de 2005} = (\$300,000) \left(\frac{100}{135} \right) = \$222,222$$

$$\text{Ventas deflactadas de 2006} = (\$350,000) \left(\frac{100}{155} \right) = \$225,806$$

Observe que las ventas en dólares reales tuvieron un aumento considerable de \$350,000 – \$300,000 = \$50,000. Sin embargo, las ventas deflactadas se incrementaron sólo en \$225,806 – \$222,222 = \$3,584.

El propósito de la deflación en los valores en dólares es eliminar el efecto de los cambios en el precio. Este ajuste se llama *deflación del precio* y se utiliza para expresar una serie en dólares constantes.

La *deflación del precio* es el proceso que permite expresar los valores de una serie en dólares constantes.

El proceso de deflación es relativamente simple. Para ajustar los precios a dólares constantes, se usa un número índice calculado a partir de los precios de mercancías cuyos valores van a ser deflactados. Por ejemplo, las ventas de una zapatería deberían deflactarse mediante un índice de precios del calzado, no mediante un índice general de precios. Para valores monetarios deflactados que representan más de un tipo de mercancía, el analista debe desarrollar un índice de precios combinando los índices de precios pertinentes en una mezcla correcta.

Ejemplo 5.5

El señor Burnham desea estudiar el crecimiento a largo plazo de la Burnham Furniture Store. La tendencia a largo plazo se debe evaluar usando el volumen físico de las ventas. Si no es posible hacer esta evaluación, los cambios de precio reflejados en las ventas en dólares seguirán patrones inconsistentes y solamente ocultarán el patrón de crecimiento real. Si se usan las ventas en dólares, es necesario dividir las ventas en dólares reales entre un índice de precios adecuado para obtener las ventas medidas en dólares constantes.

El índice de precios al consumidor (IPC) no es conveniente para Burnham porque contiene elementos como renta, alimentos y servicios personales que la tienda no vende, pero algunos componentes de este índice sí son apropiados. Burnham está consciente de que el 70% de las ventas son de muebles y el 30% de electrodomésticos. Por lo tanto, puede multiplicar el componente de muebles al menudeo del IPC por .70, multiplicar el componente de electrodomésticos por .30 y luego sumar los resultados para obtener un índice de precios combinados. La tabla 5-5 ilustra este enfoque, en el cual los cálculos para 1999 son

$$90.1(.70) + 94.6(.30) = 91.45$$

Las ventas de 1999 se deflactaron en términos del poder de compra de 2002, de manera que

$$\text{Ventas deflactadas en 1999} = (42.1) \left(\frac{100}{91.45} \right) = 46.0$$

La tabla 5-5 indica que, si bien las ventas reales crecieron regularmente de 1999 a 2006, los volúmenes físicos permanecieron estables de 2004 a 2006. Como es evidente, los incrementos en las ventas se debieron a los aumentos de precios generados, a la vez, por la tendencia inflacionaria de la economía.

TABLA 5-5 Datos de las ventas de la Burnham Furniture Store, 1999 a 2006, para el ejemplo 5-5

<i>Año</i>	<i>Ventas de Burnham (en miles de \$)</i>	<i>Índice de precios de muebles al menudeo (2002=100)</i>	<i>Índice de precios de electrodomésticos al menudeo (2002=100)</i>	<i>Índice de precios^a (2002=100)</i>	<i>Ventas deflactadas^b (en miles de 2002)</i>
1999	42.1	90.1	94.6	91.45	46.0
2000	47.2	95.4	97.2	95.94	49.2
2001	48.4	97.2	98.4	97.56	49.6
2002	50.6	100.0	100.0	100.00	50.6
2003	55.2	104.5	101.1	103.48	53.3
2004	57.9	108.6	103.2	106.98	54.1
2005	59.8	112.4	104.3	109.97	54.4
2006	60.7	114.0	105.6	111.48	54.4

^aIntegrado al combinar precios de muebles (70%) y precios de electrodomésticos (30%).

^bVentas divididas entre el índice de precios por 100.

Glosario

Indicadores de negocios. Series de tiempo relacionadas con los negocios, las cuales ayudan a evaluar el estado general de la economía.

Números índice. Porcentajes que muestran cambios a través del tiempo.

Deflación de precios. Proceso que permite expresar los valores de una serie en dólares constantes.

Fórmulas clave

Descomposición aditiva de series de tiempo

$$Y_t = T_t + S_t + I_t \quad (5.1)$$

Descomposición multiplicativa de series de tiempo

$$Y_t = T_t \times S_t \times I_t \quad (5.2)$$

Tendencia lineal

$$\hat{T}_t = b_0 + b_1t \quad (5.3)$$

Criterio del cuadrado de los errores (con tendencia $\hat{T}$)

$$SSE = \sum (Y_t - \hat{T}_t)^2 \quad (5.4)$$

Tendencia cuadrática

$$\hat{T}_t = b_0 + b_1t + b_2t^2 \quad (5.5)$$

Tendencia exponencial

$$\hat{T}_t = b_0b_1^t \quad (5.6)$$

Datos ajustados estacionalmente (descomposición aditiva)

$$Y_t - S_t = T_t + I_t \quad (5.7a)$$

Datos ajustados estacionalmente (descomposición multiplicativa)

$$\frac{Y_t}{S_t} = T_t \times I_t \quad (5.7b)$$

Componente cíclico-irregular (descomposición multiplicativa)

$$C_t \times I_t = \frac{Y_t}{T_t \times S_t} \quad (5.8)$$

Componente irregular (descomposición multiplicativa)

$$I_t = \frac{C_t \times I_t}{C_t} \quad (5.9)$$

Poder de compra actual de \$1

$$\frac{100}{\text{Índice de precios al consumidor}} \quad (5.10)$$

Valor del dólar deflactado

$$(\text{valor del dólar}) \times (\text{poder de compra de \$1}) \quad (5.11)$$

Problemas

1. Explique el concepto de descomposición de una serie de tiempo.
2. Explique cuándo es más adecuada una descomposición multiplicativa que una descomposición aditiva.
3. ¿Cuáles son algunos factores básicos que influyen en el ciclo de tendencia de la mayoría de las variables?
4. ¿Qué clase de modelo de tendencia debería emplearse en cada uno de los siguientes casos?
 - a) La variable aumenta a una tasa constante.
 - b) La variable aumenta a una tasa constante hasta que alcanza la saturación y se nivela.
 - c) La variable aumenta en una cantidad constante.
5. ¿Cuáles son algunos factores básicos que influyen en el componente estacional de la mayoría de las variables?
6. Las estimaciones de crecimiento de ventas e ingresos de Value Line para compañías individuales se derivan de las correlaciones de ventas, ingresos y dividendos de los componentes apropiados de National Income Accounts, como inversiones en bienes de capital. Jason Black, un analista de Value Line, está revisando la tendencia de la variable de las inversiones en bienes de capital de 1977 a 1993. Los datos se presentan en la tabla P-6.
 - a) Grafique los datos y determine el modelo de tendencia adecuado para los años de 1977 a 1993.
 - b) Si el modelo adecuado es lineal, calcule el modelo de tendencia lineal para los años de 1977 a 1993.

TABLA P-6 Inversiones en bienes de capital (miles de millones de \$), 1977 a 1993

<i>Año</i>	<i>Miles de millones de \$</i>	<i>Año</i>	<i>Miles de millones de \$</i>	<i>Año</i>	<i>Miles de millones de \$</i>
1977	214	1983	357	1989	571
1978	259	1984	416	1990	578
1979	303	1985	443	1991	556
1980	323	1986	437	1992	566
1981	369	1987	443	1993	623
1982	367	1988	545	1994	680 ^a

^aEstimado de Value Line

Fuente: *The Value Line Investment Survey* (Nueva York: Value Line, 1988, 1990, 1994).

- c) ¿Cuál es el incremento promedio anual en inversiones en bienes de capital desde 1977?
- d) Estime el valor de la tendencia para inversiones en bienes de capital en 1994.
- e) Compare su estimación de la tendencia con la de Value Line.
- f) ¿Qué factor(es) influye(n) en la tendencia de la inversión en bienes de capital?
7. Una compañía estadounidense grande está considerando hacer recortes en su publicidad en TV y, en vez de ello, entregar a sus clientes videos del negocio. Esta acción se está revisando después de que el presidente de la compañía leyó recientemente un artículo en el periódico que se refería a los videos para atraer clientes como “el arma para lograr ventas” en la actualidad. Algo que al presidente le gustaría investigar antes de emprender esta acción es la historia de la publicidad en TV en Estados Unidos, especialmente en relación con el ciclo de tendencia.
- La tabla P-7 indica el gasto total en dólares en publicidad televisiva en Estados Unidos (en millones de dólares).
- a) Grafique la serie de tiempo de los gastos en publicidad televisiva en Estados Unidos.
- b) Ajuste una tendencia lineal a los datos de publicidad y grafique la línea ajustada sobre la gráfica de la serie de tiempo.
- c) Pronostique los gastos en publicidad televisiva en dólares para 1998.
- d) De acuerdo con los resultados del inciso b), ¿cree que podría haber un componente cíclico en los gastos en publicidad televisiva en dólares? Explique.
8. Suponga que los siguientes índices estacionales específicos para marzo están dados como porcentajes y se obtuvieron por el método de la proporción del promedio móvil:

102.2 105.9 114.3 122.4 109.8 98.9

¿Cuál es el índice estacional para marzo usando la mediana?

TABLA P-7

<i>Año</i>	<i>Y</i>	<i>Año</i>	<i>Y</i>
1980	11,424	1989	26,891
1981	12,811	1990	29,073
1982	14,566	1991	28,189
1983	16,542	1992	30,450
1984	19,670	1993	31,698
1985	20,770	1994	35,435
1986	22,585	1995	37,828
1987	23,904	1996	42,484
1988	25,686	1997	44,580

Fuente: *Statistical Abstract of the United States*, varios años.

9. El valor esperado de la tendencia para octubre es de \$850. Suponiendo un índice estacional para octubre de 1.12 (112%) y el modelo multiplicativo dado por la ecuación 5.2, ¿cuál sería el pronóstico para octubre?
10. Los siguientes porcentajes específicos para los índices estacionales corresponden al mes de diciembre:

75.4 86.8 96.9 72.6 80.0 85.4

Suponga un modelo de descomposición multiplicativa. Si la tendencia esperada para diciembre es de \$900 y se usa el ajuste estacional de la mediana, ¿cuál es el pronóstico para diciembre?

11. Un gran centro vacacional cerca de Portland, Maine, ha llevado registro de sus ventas mensuales durante varios años, pero nunca ha analizado estos datos. El centro vacacional calcula los índices estacionales para sus ventas mensuales. ¿Cuáles de los siguientes enunciados acerca del índice son correctos?
- La suma de los 12 números índices mensuales, expresados como porcentajes, debería ser 1,200.
 - Un índice de 85 para mayo indica que las ventas son 15% más bajas que las ventas mensuales promedio.
 - Un índice de 130 para enero indica que las ventas están un 30% por arriba de las ventas mensuales promedio.
 - El índice para cualquier mes debe estar entre 0 y 200.
 - El índice porcentual promedio para cada uno de los 12 meses debe ser 100.
12. En la preparación de un reporte para June Bancock, gerente de Kula Department Store, usted incluye las cifras de ventas del último año (en miles de dólares) presentadas en la tabla P-12. Al verlas, el señor Bancock dice: “Este reporte confirma lo que le he estado diciendo: el negocio cada vez va mejor”. ¿Es correcta esta afirmación? ¿Por qué?
13. Los niveles de ventas trimestrales (medidos en millones de dólares) de Goodyear Tire se presentan en la tabla P-13. ¿Parece haber un efecto estacional significativo en estos niveles de ventas? Analice esta serie de tiempo para obtener los cuatro índices estacionales y determine la magnitud del componente estacional en las ventas de Goodyear.

TABLA P-12

<i>Mes</i>	<i>Ventas (en miles de \$)</i>	<i>Índice estacional ajustado (%)</i>
Enero	125	51
Febrero	113	50
Marzo	189	87
Abril	201	93
Mayo	206	95
Junio	241	99
Julio	230	96
Agosto	245	89
Septiembre	271	103
Octubre	291	120
Noviembre	320	131
Diciembre	419	189

Fuente: Con base en los registros de Kula Department Store.

TABLA P-13

Año	Trimestre			
	1	2	3	4
1985	2,292	2,450	2,363	2,477
1986	2,063	2,358	2,316	2,366
1987	2,268	2,533	2,479	2,625
1988	2,616	2,793	2,656	2,746
1989	2,643	2,811	2,679	2,736
1990	2,692	2,871	2,900	2,811
1991	2,497	2,792	2,838	2,780
1992	2,778	3,066	3,213	2,928
1993	2,874	3,000	2,913	2,916
1994	2,910	3,052	3,116	3,210
1995	3,243	3,351	3,305	3,267
1996	3,246	3,330	3,340 ^a	3,300 ^a

^aEstimados de Value LineFuente: *The Value Line Investment Survey* (Nueva York: Value Line, 1988, 1989, 1993, 1994, 1996).

- a) Para pronosticar, ¿usaría el componente de la tendencia, el componente de la estacionalidad o ambos?
- b) Elabore un pronóstico para el tercero y el cuarto trimestres de 1996.
- c) Compare sus pronósticos con los de Value Line.
14. Las ventas mensuales de Cavanaugh Company, representadas en la figura 5.1 (abajo), se especifican en la tabla P-14.
- a) Realice una descomposición multiplicativa de la serie de tiempo de las ventas de Cavanaugh Company, suponiendo los componentes de tendencia, estacional e irregular.
- b) Para pronosticar, ¿usaría el componente de tendencia, el componente estacional o ambos?
- c) Obtenga pronósticos para el resto de 2006.
15. Construya una tabla similar a la tabla P-14 con los logaritmos naturales de las ventas mensuales. Por ejemplo, el valor para enero de 2000 es $\ln(154) = 5.037$.
- a) Haga una descomposición aditiva de $\ln(\text{ventas})$, considerando el modelo

$$Y = T + S + I.$$

TABLA P-14

Mes	2000	2001	2002	2003	2004	2005	2006
Enero	154	200	223	346	518	613	628
Febrero	96	118	104	261	404	392	308
Marzo	73	90	107	224	300	273	324
Abril	49	79	85	141	210	322	248
Mayo	36	78	75	148	196	189	272
Junio	59	91	99	145	186	257	
Julio	95	167	135	223	247	324	
Agosto	169	169	211	272	343	404	
Septiembre	210	289	335	445	464	677	
Octubre	278	347	460	560	680	858	
Noviembre	298	375	488	612	711	895	
Diciembre	245	203	326	467	610	664	

- b) Para pronosticar, ¿usaría el componente de la tendencia, el componente estacional o ambos?
- c) Elabore pronósticos para $\ln(\text{ventas})$ para los meses restantes de 2006.
- d) Tome los antilogaritmos de los pronósticos calculados en el inciso c) para obtener pronósticos de las ventas reales para el resto de 2006.
- e) Compare los pronósticos del inciso d) con los del inciso c) del problema 14. ¿Cuál conjunto de pronósticos prefiere usted? ¿Por qué?
16. La tabla P-16 indica las ventas trimestrales (en millones de dólares) de Disney Company del primer trimestre de 1980 al tercer trimestre de 1995.
- a) Haga una descomposición multiplicativa de la serie de tiempo que integran las ventas trimestrales de Disney.
- b) ¿Parece haber una tendencia significativa? Discuta la naturaleza del componente estacional.
- c) ¿Usaría usted ambos componentes, el de tendencia y el estacional, para pronosticar?
- d) Pronostique las ventas para el cuarto trimestre de 1995 y los cuatro trimestres de 1996.
17. La demanda mensual de gasolina (en miles de barriles/día) de la Yukong Oil Company de Corea del Sur para el periodo que va de enero de 1986 a septiembre de 1996 se indica en la tabla P-17.
- a) Grafique la serie de tiempo de la demanda de gasolina. ¿Piensa usted que sería adecuada una descomposición aditiva o una multiplicativa para esta serie de tiempo? Explique.
- b) Realice un análisis de descomposición de la demanda de gasolina.
- c) Interprete los índices estacionales.
- d) Pronostique la demanda de gasolina para los últimos tres meses de 1996.
18. La tabla P-18 contiene datos que representan las ventas mensuales (en miles de millones de dólares) de todas las tiendas minoristas en Estados Unidos. Con base en los datos de 1994, ejecute un análisis de descomposición de esta serie. Haga comentarios acerca de los tres componentes de la serie. Pronostique las ventas al menudeo para 1995 y compare sus resultados con los valores reales que aparecen en la tabla.

TABLA P-16

Año	Trimestre			
	1	2	3	4
1980	218.1	245.4	265.5	203.5
1981	235.1	258.0	308.4	211.8
1982	247.7	275.8	295.0	270.1
1983	315.7	358.5	363.0	302.2
1984	407.3	483.3	463.2	426.5
1985	451.5	546.9	590.4	504.2
1986	592.4	647.9	726.4	755.5
1987	766.4	819.4	630.1	734.6
1988	774.5	915.7	1,013.4	1,043.6
1989	1,037.9	1,167.6	1,345.1	1,288.2
1990	1,303.8	1,539.5	1,712.2	1,492.4
1991	1,439.0	1,511.6	1,739.4	1,936.6
1992	1,655.1	1,853.5	2,079.1	2,391.4
1993	2,026.5	1,936.8	2,174.5	2,727.3
1994	2,275.8	2,353.6	2,698.4	3,301.7
1995	2,922.8	2,764.0	3,123.6	

TABLA P-17

<i>Mes</i>	<i>1986</i>	<i>1987</i>	<i>1988</i>	<i>1989</i>	<i>1990</i>	<i>1991</i>	<i>1992</i>	<i>1993</i>	<i>1994</i>	<i>1995</i>	<i>1996</i>
Enero	15.5	20.4	26.9	36.0	52.1	64.4	82.3	102.7	122.2	145.8	170.0
Febrero	17.8	20.8	29.4	39.0	53.1	68.1	83.6	102.2	121.4	144.4	176.3
Marzo	18.1	22.2	29.9	42.2	56.5	68.5	85.5	104.7	125.6	145.2	174.2
Abril	20.5	24.1	32.4	44.3	58.4	72.3	91.0	108.9	129.7	148.6	176.1
Mayo	21.3	25.5	33.3	46.6	61.7	74.1	92.1	112.2	133.6	153.7	185.3
Junio	19.8	25.9	34.5	46.1	61.0	77.6	95.8	109.7	137.5	157.9	182.7
Julio	20.5	26.1	34.8	48.5	65.5	79.9	98.3	113.5	143.0	169.7	197.0
Agosto	22.3	27.5	39.1	52.6	71.0	86.7	102.2	120.4	149.0	184.2	216.1
Septiembre	22.9	25.8	39.0	52.2	68.1	84.4	101.5	124.6	149.9	163.2	192.2
Octubre	21.1	29.8	36.5	50.8	67.5	81.4	98.5	116.7	139.5	155.4	
Noviembre	22.0	27.4	37.5	51.9	68.8	85.1	101.1	120.6	147.7	168.9	
Diciembre	22.8	29.7	39.7	55.1	68.1	81.7	102.5	124.9	154.7	178.3	

TABLA P-18

<i>Mes</i>	<i>1988</i>	<i>1989</i>	<i>1990</i>	<i>1991</i>	<i>1992</i>	<i>1993</i>	<i>1994</i>	<i>1995</i>
Enero	113.6	122.5	132.6	130.9	142.1	148.4	154.6	167.0
Febrero	115.0	118.9	127.3	128.6	143.1	145.0	155.8	164.0
Marzo	131.6	141.3	148.3	149.3	154.7	164.6	184.2	192.1
Abril	130.9	139.8	145.0	148.5	159.1	170.3	181.8	187.5
Mayo	136.0	150.3	154.1	159.8	165.8	176.1	187.2	201.4
Junio	137.5	149.0	153.5	153.9	164.6	175.7	190.1	202.6
Julio	134.1	144.6	148.9	154.6	166.0	177.7	185.8	194.9
Agosto	138.7	153.0	157.4	159.9	166.3	177.1	193.8	204.2
Septiembre	131.9	144.1	145.6	146.7	160.6	171.1	185.9	192.8
Octubre	133.8	142.3	151.5	152.1	168.7	176.4	189.7	194.0
Noviembre	140.2	148.8	156.1	155.6	167.2	180.9	194.7	202.4
Diciembrer	171.0	176.5	179.7	181.0	204.1	218.3	233.3	238.0

Fuente: Con base en *Survey of Current Business*, 1989, 1993, 1996.

TABLA P-19

<i>Mes</i>	<i>Índice estacional ajustado</i>	<i>Mes</i>	<i>Índice estacional ajustado</i>
Enero	120	Julio	153
Febrero	137	Agosto	151
Marzo	100	Septiembre	95
Abril	33	Octubre	60
Mayo	47	Noviembre	82
Junio	125	Diciembre	97

Fuente: Con base en los registros del Mount Spokane Resort Hotel.

19. Los índices estacionales ajustados que aparecen en la tabla P-19 reflejan el volumen cambiante de los negocios del Mount Spokane Resort Hotel, el cual ofrece servicios a familias en el verano y a esquiadores entusiastas durante los meses de invierno. No se esperan variaciones cíclicas bruscas durante 2007.

TABLA P-24

		<i>Volumen de ventas</i>	<i>Índice de precios de productos primarios (2001 = 100)</i>
2005	Enero	358,235	118.0
	Febrero	297,485	118.4
	Marzo	360,321	118.7
	Abril	378,904	119.2
	Mayo	394,472	119.7
	Junio	312,589	119.6
	Julio	401,345	119.3

- a) Si 600 turistas se alojaron en el hotel en enero de 2007, ¿cuál sería una estimación razonable para febrero?
- b) La ecuación de la tendencia mensual es $\hat{T} = 140 + 5t$ donde $t = 0$ representa el 15 de enero de 2001. ¿Cuál es el pronóstico para cada mes de 2007?
- c) ¿Cuál es el número promedio de nuevos turistas por mes?
20. Analice el desempeño del índice compuesto de los indicadores con comportamiento adelantado como un barómetro de la actividad empresarial en años recientes.
21. ¿Cuál es la posición actual del ciclo de negocios? ¿Se está expandiendo o contrayendo? ¿Cuándo se presentará el siguiente punto de inflexión?
22. ¿Cuál es el propósito de la deflación de una serie de tiempo que se mide en dólares?
23. En el periodo base de junio, el precio de una cantidad seleccionada de bienes era de \$1,289.73. En los meses más recientes, el índice de precios para estos bienes era de 284.7. ¿Cuánto sería el costo de los bienes seleccionados si se compraron en el mes más reciente?
24. Desarrolle una deflación de los volúmenes de ventas en dólares de la tabla P-24 usando el índice de precios de los productos primarios. Estos índices se aplican a todos los productos primarios, considerando que 2001 = 100.
25. La tabla P-25 contiene el número (en miles) de varones de 16 años de edad en adelante que fueron empleados en Estados Unidos para los meses de enero de 1993 a octubre de 2003.

TABLA P-25

<i>Año</i>	<i>Ene.</i>	<i>Feb.</i>	<i>Mar.</i>	<i>Abr.</i>	<i>Mayo</i>	<i>Jun.</i>	<i>Jul.</i>	<i>Ago.</i>	<i>Sept.</i>	<i>Oct.</i>	<i>Nov.</i>	<i>Dic.</i>
1993	63,344	63,621	64,023	64,482	65,350	66,412	67,001	66,861	65,808	65,961	65,779	65,545
1994	64,434	64,564	64,936	65,492	66,340	67,230	67,649	67,717	66,997	67,424	67,313	67,292
1995	65,966	66,333	66,758	67,018	67,227	68,384	68,750	68,326	67,646	67,850	67,219	67,049
1996	66,006	66,481	66,961	67,415	68,258	69,298	69,819	69,533	68,614	69,099	68,565	68,434
1997	67,640	67,981	68,573	69,105	69,968	70,619	71,157	70,890	69,890	70,215	70,328	69,849
1998	68,932	69,197	69,506	70,348	70,856	71,618	72,049	71,537	70,866	71,219	71,256	70,930
1999	69,992	70,084	70,544	70,877	71,470	72,312	72,803	72,348	71,603	71,825	71,797	71,699
2000	71,862	72,177	72,501	73,006	73,236	74,267	74,420	74,352	73,391	73,616	73,497	73,338
2001	72,408	72,505	72,725	73,155	73,313	74,007	74,579	73,714	73,483	73,228	72,690	72,547
2002	71,285	71,792	71,956	72,483	73,230	73,747	74,210	73,870	73,596	73,513	72,718	72,437
2003	71,716	72,237	72,304	72,905	73,131	73,894	74,269	74,032	73,715	73,979		

Fuente: Con base en estadísticas de la fuerza laboral del Current Population Survey.

Use Minitab para hacer una descomposición multiplicativa de estos datos y genere los pronósticos para los siguientes 12 meses. ¿Parece adecuada una descomposición multiplicativa para este caso? Explique. ¿Existe un fuerte componente estacional en estos datos? ¿Le sorprende? ¿Los pronósticos parecen razonables?

26. Remítase al problema 25. La descomposición multiplicativa en Minitab supone de forma predeterminada una tendencia lineal. Grafique los datos de los varones empleados de la tabla P-25 y examine los años de 1993 a 2000 y de 2001 a 2003. ¿Se trata de una tendencia lineal adecuada? Si no es así, ¿puede usted sugerir una curva de tendencia que podría ser adecuada? Ajuste su curva de tendencia sugerida y guarde los residuos. Calcule la función de autocorrelación de los residuos. ¿Las autocorrelaciones residuales sugieren un componente estacional? Explique.
27. La tabla P-27 indica las ventas trimestrales (en millones de dólares) de las tiendas Wal-Mart de 1990 a 2004. Use Minitab para hacer una descomposición multiplicativa de la serie de tiempo de las ventas de Wal-Mart de los años 1990 a 2003 y genere pronósticos de los cuatro trimestres de 2004. ¿Es adecuada una descomposición multiplicativa para los datos de Wal-Mart? Explique. ¿Existe un fuerte componente estacional? ¿Le sorprende? Compare los pronósticos trimestrales de 2004 con las ventas reales. ¿Los resultados refuerzan la selección de una descomposición multiplicativa?
28. Remítase al problema 27. La descomposición multiplicativa en Minitab supone de manera predeterminada una tendencia lineal. Ajuste y grafique una línea de tendencia lineal para las ventas de Wal-Mart. ¿Es adecuada la tendencia lineal para estos datos? Si no es así, ¿podría sugerir una curva de tendencia que resulte adecuada? Ajuste su curva de tendencia sugerida y guarde los residuos. Calcule las autocorrelaciones de los residuos. ¿Las autocorrelaciones residuales sugieren un componente estacional? Explique.

TABLA P-27

Año	Trimestre			
	1	2	3	4
1990	6,768	7,544	7,931	10,359
1991	9,281	10,340	10,628	13,639
1992	11,649	13,028	13,684	17,122
1993	13,920	16,237	16,827	20,361
1994	17,686	19,942	20,418	24,448
1995	20,440	22,723	22,914	27,550
1996	22,772	25,587	25,644	30,856
1997	25,409	28,386	28,777	35,386
1998	29,819	33,521	33,509	40,785
1999	35,129	28,913	40,899	51,868
2000	43,447	46,588	46,181	57,079
2001	48,565	53,187	53,185	64,735
2002	52,126	56,781	55,765	66,905
2003	57,224	63,231	63,036	75,190
2004	65,443	70,466	69,261	82,819

Fuente: Base de datos de S&P Compustat North American Industrial Quarterly.

CASOS

CASO 5-1 THE SMALL ENGINE DOCTOR¹³

The Small Engine Doctor es el nombre de un negocio fundado por Thomas Brown, quien es un cartero del servicio postal de Estados Unidos. Él ha sido un reparador de todo desde su niñez, ya que, desde entonces, tiene la costumbre de examinar los aparatos domésticos inservibles para entender por qué se descompusieron. Conforme Tom creció y se convirtió en un habitante típico de los suburbios, adquirió numerosos artículos de equipo de jardinería. Cuando Tom averiguó acerca de un curso de reparación de máquinas pequeñas que se impartiría en una universidad local, no dejó pasar la oportunidad. Tom inició la reparación de pequeñas máquinas desarmando su propio equipo de jardinería para revisarlo y luego volverlo a ensamblar. Tan pronto como terminó su curso de reparación de máquinas, empezó a reparar podadoras de pasto, arados giratorios, sopladores de nieve y otros equipos de jardinería de amigos y vecinos. En este proceso adquirió varios manuales de equipo y herramientas especiales..

No pasó mucho tiempo para que Tom decidiera convertir su pasatiempo en un negocio de tiempo parcial. Publicó un anuncio en un boletín comercial suburbano bajo el nombre de Small Engine Doctor (Doctor de máquinas pequeñas). Durante los últimos dos años, el negocio ha crecido lo suficiente para complementar su sueldo regular. Si bien el crecimiento fue bienvenido, conforme el negocio está por entrar a su tercer año de operación, existen varias preocupaciones. Tom opera su negocio fuera de su casa. El sótano está dividido en una sala familiar, un taller y una oficina. Originalmente, el área de oficina era utilizada para manejar la publicidad, procesar pedidos y llevar la contabilidad. Todas las reparaciones de las máquinas se hacían en el taller. La política de Tom ha sido tener en inventario un limitado número de refacciones y solicitar el resto de éstas conforme se necesita. Éste parecía ser el único modo práctico de manejar la gran variedad de refacciones necesarias en la reparación de las máquinas fabricadas por una docena o más de empresas fabricantes de equipo para jardinería.

Las piezas de repuesto han sido el problema más grave durante el funcionamiento del negocio. Tom inició su negocio comprando piezas de repuesto a vendedores de equipo. Esta práctica tuvo varias desventajas. Primero, él tenía que comprar las piezas a precios de menudeo. Segundo, la mayoría de las veces el vendedor

tenía que reservar el pedido de una o más partes para cualquier trabajo de reparación. Las partes ordenadas al fabricante tenían tiempos de entrega de 30 a 120 días. Como consecuencia, Tom cambió su política y comenzó a ordenar las piezas de repuesto directamente a la fábrica. Se dio cuenta de que los gastos de embarque y manejo se comían sus utilidades, aun cuando el precio de la pieza era sólo del 60% de su precio al menudeo. Sin embargo, los dos problemas más importantes que implicó la sustitución de piezas fueron las pérdidas de ventas y el espacio de almacenamiento. Tom atrajo clientes por la calidad de su servicio y los precios razonables de reparación, los cuales eran posibles gracias a que sus gastos indirectos eran bajos. Por desgracia, muchos clientes potenciales acudían con los vendedores de equipo en vez de esperar varios meses por la reparación. El problema más apremiante era el espacio de almacenamiento. Mientras que un equipo estaba en espera de las piezas de repuesto, tenía que almacenarse en el local. No pasó mucho tiempo para que tanto su taller como su estacionamiento para un solo coche estuvieran saturados de equipos mientras él esperaba las piezas de repuesto. En el segundo año de operación, Tom realmente tuvo que suspender la publicidad como una táctica para limitar el número de clientes ante la falta de espacio de almacenamiento.

Tom ha considerado tener existencias en inventario para su tercer año de operación. Esta práctica reducirá costos de compras haciendo posible obtener descuentos y plazos de envío más favorables. También espera ofrecer mucho mejor tiempo de respuesta a los clientes, mejorando tanto el flujo de efectivo como las ventas. Los riesgos de esta estrategia son los costos que acarrea el manejo de inventarios sin control y la obsolescencia de las piezas.

Antes de aventurarse a surtir un inventario de piezas de repuesto, Tom quiere tener un pronóstico confiable de la actividad del negocio para el próximo año. Él confía lo suficiente en su conocimiento de la mezcla del producto para usar un pronóstico agregado de órdenes de reparación de los clientes como base para el encargo selectivo de las piezas de repuesto. El pronóstico se complica por los patrones estacionales de la demanda y una tendencia hacia arriba de las ventas.

Tom planea desarrollar un pronóstico de ventas para el tercer año de operación. Los datos de las ventas de los primeros dos años se presentan en la tabla 5-6.

¹³Este caso es contribución de William P. Darrow de la Universidad Estatal de Towson, en Towson, Maryland.

TABLA 5-6 Historia de ventas de Small Engine Doctor

<i>Mes</i>	<i>2005 (unidades)</i>	<i>2006 (unidades)</i>	<i>Mes</i>	<i>2005 (unidades)</i>	<i>2006 (unidades)</i>
Enero	5	21	Julio	28	46
Febrero	8	20	Agosto	20	32
Marzo	10	29	Septiembre	14	27
Abril	18	32	Octubre	8	13
Mayo	26	44	Noviembre	6	11
Junio	35	58	Diciembre	26	52

Tarea

1. Grafique los datos en un horizonte de tiempo de dos años de 2005 a 2006. Una los puntos de datos para trazar una gráfica de serie de tiempo.
2. Desarrolle una ecuación de tendencia lineal usando la regresión lineal y grafique los resultados.
3. Estime los factores de ajuste estacional para cada mes dividiendo la demanda promedio para los meses correspondientes entre el promedio de los pronósticos correspondientes de la línea de tendencia. Grafique los valores ajustados y los pronósticos de 2007 que se obtienen a partir del producto de la tendencia por el componente estacional.
4. Suavice las series de tiempo usando la suavización exponencial lineal de Holt con tres grupos de constantes de suavización: $(\alpha = .1, \beta = .1)$, $(\alpha = .25, \beta = .25)$ y $(\alpha = .5, \beta = .5)$. Grafique los tres conjuntos de valores suavizados en la gráfica de la serie de tiempo. Genere pronósticos para el final del tercer año de cada una de las posibilidades consideradas de suavización exponencial ajustada a la tendencia.
5. Calcule los valores de la *MAD* para los dos modelos que visualmente parecen tener los mejores ajustes (los pronósticos más exactos del siguiente periodo).
6. Si tuviera que restringir su selección a uno de los modelos de las preguntas 2 y 4, identifique el modelo que usaría para la planeación de su negocio en 2007 y discuta por qué seleccionó ese modelo por encima de los demás.

CASO 5-2 MR. TUX

John Mosby ha estado mirando hacia delante de la descomposición de su serie de tiempo, las ventas mensuales en dólares. Él sabe que la serie tiene un fuerte efecto estacional y le gustaría medirlo por dos razones. Primero, el ejecutivo bancario está renuente a autorizarle pagos mensuales variables de su préstamo. John le explicó que, a causa de la estacionalidad de las ventas y el flujo de efectivo mensual, le gustaría hacer pagos extras en algunos meses y pagos reducidos —o inclusive no pagar— en otros. Su banquero quiere ver una prueba de lo que John asegura acerca de que sus ventas tienen un fuerte efecto estacional.

Segundo, John quiere pronosticar sus ventas mensuales. Necesita estos pronósticos para efectos de planeación, especialmente desde que su negocio está creciendo. Tanto banqueros como empresas quieren

algún pronóstico sólido sobre el cual basar sus decisiones de inversión. John sabe que su negocio está mejorando y que las perspectivas son alentadoras, pero los inversionistas quieren documentación.

Los volúmenes de ventas mensuales de Mr. Tux de 1999 a 2005 se introducen en Minitab. Puesto que 1998 fue el primer año del negocio, los volúmenes de ventas fueron extremadamente bajos comparados con el resto de los años. Por esta razón, John decide eliminar estos valores del análisis. Los índices estacionales se presentan en la tabla 5-7. El resto del reporte de resultados de la computadora se presenta en la tabla 5-8.

John no está sorprendido de ver los índices estacionales que aparecen en la tabla 5-7 y está contento de tener cifras contundentes para mostrar a su banquero. Después de revisar estas cifras, el banquero está de

TABLA 5-7 Resumen de índices estacionales mensuales para Mr. Tux

<i>Descomposición de la serie de tiempo</i>	
<i>Ecuación de la línea de tendencia</i>	
$\hat{T}_t = 12,133 + 3,033t$	
<i>Índice estacional</i>	
<i>Periodo</i>	<i>Índice</i>
1	0.3144
2	0.4724
3	0.8877
4	1.7787
5	1.9180
6	1.1858
7	1.0292
8	1.2870
9	0.9377
10	0.8147
11	0.6038
12	0.7706
<i>Exactitud del modelo</i>	
<i>MAPE:</i>	20
<i>MAD:</i>	21,548
<i>MSD:</i>	9.12E + 08

TABLA 5-8 Cálculo de los componentes de corto plazo para Mr. Tux

<i>t</i>	<i>Año</i>	<i>Mes</i>	<i>Ventas</i>	<i>T</i>	<i>SCI</i>	<i>TCI</i>	<i>CI</i>	<i>C</i>	<i>I</i>
1	1999	Enero	16,850	15,166	1.1111	53,589	3.5336	—	—
2		Febrero	12,753	18,198	0.7708	26,997	1.4835	—	—
3		Marzo	26,901	21,231	1.2671	30,306	1.4274	2.1387	0.6674
4		Abril	61,494	24,264	2.5344	34,572	1.4249	1.7545	0.8121
5		Mayo	147,862	27,297	5.4169	77,092	2.8242	1.7567	1.6077
6		Junio	57,990	30,329	1.9120	48,902	1.6124	1.7001	0.9484
7		Julio	51,318	33,362	1.5382	49,862	1.4946	1.5397	0.9707
8		Agosto	53,599	36,395	1.4727	41,647	1.1443	1.2142	0.9424
9		Septiembre	23,038	39,428	0.5843	24,568	0.6231	1.0325	0.6035
10		Octubre	41,396	42,460	0.9749	50,815	1.1968	0.8550	1.3997
11		Noviembre	19,330	45,493	0.4249	32,014	0.7037	0.8161	0.8623
12		Diciembre	22,707	48,526	0.4679	29,466	0.6072	0.9305	0.6526
13	2000	Enero	15,395	51,559	0.2986	48,961	0.9496	0.7912	1.2002
14		Febrero	30,826	54,592	0.5647	65,257	1.1954	0.8418	1.4201
15		Marzo	25,589	57,624	0.4441	28,828	0.5003	1.0439	0.4793
16		Abril	103,184	60,657	1.7011	58,011	0.9564	1.0273	0.9309
17		Mayo	197,608	63,690	3.1027	103,029	1.6177	0.8994	1.7985
18		Junio	68,600	66,723	1.0281	57,850	0.8670	0.9945	0.8719
19		Julio	39,909	69,755	0.5721	38,777	0.5559	0.9685	0.5740
20		Agosto	91,368	72,788	1.2553	70,994	0.9754	0.8308	1.1740

TABLA 5-8 (Continuación)

<i>t</i>	<i>Año</i>	<i>Mes</i>	<i>Ventas</i>	<i>T</i>	<i>SCI</i>	<i>TCI</i>	<i>CI</i>	<i>C</i>	<i>I</i>
21	2001	Septiembre	58,781	75,821	0.7753	62,684	0.8267	0.7927	1.0430
22		Octubre	59,679	78,854	0.7568	73,257	0.9290	0.8457	1.0986
23		Noviembre	33,443	81,887	0.4084	55,387	0.6764	0.8515	0.7944
24		Diciembre	53,719	84,919	0.6326	69,709	0.8209	0.8567	0.9582
25		Enero	27,773	87,952	0.3158	88,327	1.0043	0.7935	1.2657
26		Febrero	36,653	90,985	0.4029	77,592	0.8528	0.9102	0.9370
27		Marzo	51,157	94,018	0.5441	57,632	0.6130	0.9609	0.6380
28		Abril	217,509	97,050	2.2412	122,285	1.2600	0.9401	1.3403
29		Mayo	206,229	100,083	2.0606	107,523	1.0743	0.9579	1.1216
30		Junio	110,081	103,116	1.0676	92,830	0.9003	1.0187	0.8837
31		Julio	102,893	106,149	0.9693	99,973	0.9418	0.9658	0.9751
32		Agosto	128,857	109,182	1.1802	100,124	0.9170	0.9875	0.9287
33	2002	Septiembre	104,776	112,214	0.9337	111,732	0.9957	0.9858	1.0100
34		Octubre	111,036	115,247	0.9635	136,299	1.1827	0.9743	1.2139
35		Noviembre	63,701	118,280	0.5386	105,499	0.8920	0.9516	0.9373
36		Diciembre	82,657	121,313	0.6814	107,260	0.8842	0.9131	0.9683
37		Enero	31,416	124,345	0.2527	99,913	0.8035	0.8246	0.9745
38		Febrero	48,341	127,378	0.3795	102,335	0.8034	0.8507	0.9444
39		Marzo	85,651	130,411	0.6568	96,492	0.7399	0.8951	0.8266
40		Abril	242,673	133,444	1.8185	136,432	1.0224	0.9331	1.0957
41		Mayo	289,554	136,477	2.1216	150,967	1.1062	0.9914	1.1158
42		Junio	164,373	139,509	1.1782	138,614	0.9936	1.0314	0.9634
43		Julio	160,608	142,542	1.1267	156,051	1.0948	1.0312	1.0616
44		Agosto	176,096	145,575	1.2097	136,829	0.9399	0.9960	0.9437
45	2003	Septiembre	142,363	148,608	0.9580	151,815	1.0216	1.0405	0.9819
46		Octubre	114,907	151,640	0.7578	141,051	0.9302	1.0306	0.9026
47		Noviembre	113,552	154,673	0.7341	188,061	1.2159	1.0468	1.1615
48		Diciembre	127,042	157,706	0.8056	164,856	1.0453	1.0502	0.9953
49		Enero	51,604	160,739	0.3210	164,118	1.0210	1.1464	0.8906
50		Febrero	80,366	163,771	0.4907	170,129	1.0388	1.0779	0.9637
51		Marzo	208,938	166,804	1.2526	235,383	1.4111	1.0210	1.3821
52		Abril	263,830	169,837	1.5534	148,327	0.8734	1.0273	0.8501
53		Mayo	252,216	172,870	1.4590	131,500	0.7607	0.9815	0.7751
54		Junio	219,566	175,903	1.2482	185,157	1.0526	0.8819	1.1936
55		Julio	149,082	178,935	0.8332	144,852	0.8095	0.9135	0.8862
56		Agosto	213,888	181,968	1.1754	166,194	0.9133	0.9359	0.9759
57	2004	Septiembre	178,947	185,001	0.9673	190,828	1.0315	0.9281	1.1114
58		Octubre	133,650	188,034	0.7108	164,059	0.8725	0.9857	0.8852
59		Noviembre	116,946	191,066	0.6121	193,682	1.0137	0.9929	1.0210
60		Diciembre	164,154	194,099	0.8457	213,015	1.0975	0.9609	1.1422
61		Enero	58,843	197,132	0.2985	187,140	0.9493	1.0356	0.9167
62		Febrero	82,386	200,165	0.4116	174,405	0.8713	1.0261	0.8492
63		Marzo	224,803	203,198	1.1063	253,256	1.2464	0.9701	1.2847
64		Abril	354,301	206,230	1.7180	199,190	0.9659	1.0295	0.9382
65		Mayo	328,263	209,263	1.5687	171,149	0.8179	1.0488	0.7798
66		Junio	313,647	212,296	1.4774	264,495	1.2459	1.0395	1.1985

TABLA 5-8 (Continuación)

<i>t</i>	Año	Mes	Ventas	<i>T</i>	<i>SCI</i>	<i>TCI</i>	<i>CI</i>	<i>C</i>	<i>I</i>
67		Julio	214,561	215,329	0.9964	208,473	0.9682	1.0231	0.9463
68		Agosto	337,192	218,361	1.5442	262,003	1.1999	1.0177	1.1790
69		Septiembre	183,482	221,394	0.8288	195,664	0.8838	0.9721	0.9092
70		Octubre	144,618	224,427	0.6644	177,522	0.7910	0.9862	0.8020
71		Noviembre	139,750	227,460	0.6144	231,449	1.0175	0.9398	1.0828
72		Diciembre	184,546	230,493	0.8007	239,476	1.0390	1.0367	1.0022
73	2005	Enero	71,043	233,525	0.3042	225,940	0.9675	1.1142	0.8684
74		Febrero	152,930	236,558	0.6465	323,742	1.3686	1.1005	1.2436
75		Marzo	250,559	239,591	1.0458	282,272	1.1781	1.0602	1.1112
76		Abril	409,567	242,624	1.6881	230,261	0.9490	1.0518	0.9023
77		Mayo	394,747	245,656	1.6069	205,813	0.8378	0.9559	0.8765
78		Junio	272,874	248,689	1.0973	230,111	0.9253	0.9492	0.9748
79		Julio	230,303	251,722	0.9149	223,768	0.8890	0.9211	0.9651
80		Agosto	375,402	254,755	1.4736	291,693	1.1450	0.9169	1.2488
81		Septiembre	195,409	257,787	0.7580	208,383	0.8084	0.9599	0.8421
82		Octubre	173,518	260,820	0.6653	212,998	0.8166	1.0337	0.7900
83		Noviembre	181,702	263,853	0.6887	300,928	1.1405	—	—
84		Diciembre	258,713	266,886	0.9694	335,719	1.2579	—	—

acuerdo en que John haga pagos dobles sobre su préstamo en abril, mayo, junio y agosto, y que no haga pagos en enero, febrero, noviembre y diciembre. El ejecutivo bancario le pide una copia de los índices estacionales para mostrárselos a su jefe e incluye la copia en el expediente del préstamo de John.

Para el pronóstico de los primeros seis meses de 2006, John empieza por proyectar valores de la tendencia usando la ecuación de la tendencia $\hat{T}_t = 12,133 + 3,033t$. La tendencia estimada para enero de 2006 es

$$\hat{T}_{85} = 12,133 + 3,033(85) = 269,938$$

A continuación, John obtiene el índice estacional de la tabla 5-7. El índice para enero es 31.44%. John ha estado leyendo *The Wall Street Journal* y viendo los programas de análisis de negocios con regularidad, de manera que ya tiene una idea de la naturaleza general de la economía y su curso en el futuro. También pertenece a un club de servicio de negocios que organiza con regularidad pláticas con expertos en la economía local. Cuando estudia la columna *C* del resultado de su computadora, la cual contiene la historia cíclica de su serie, piensa en cómo pronosticar este valor para los primeros seis meses de 2006. Como los pronósticos de los expertos nacionales y locales anuncian una mejora en los negocios para 2006 y puesto que el último valor de *C* para octubre del 2005 se ha elevado (103.4%), decide usar los siguientes valores de *C* para sus pronósticos:

2005	Noviembre	104
	Diciembre	105
2006	Enero	105
	Febrero	106
	Marzo	107
	Abril	109
	Mayo	110
	Junio	111

Para el valor irregular (*I*) de estos meses, John no prevé ningún acontecimiento inusual, excepto en marzo de 2006. En ese mes, él planea mantener una exhibición abierta al público y reducir las tarifas en una de sus tiendas que está terminando de remodelar. Como resultado de esta promoción, que estará acompañada de publicidad en radio y TV, espera que las ventas en esa tienda sean 50% más altas de lo normal. Por lo que se refiere a sus ventas mensuales totales, cree que este efecto tendrá como resultado un incremento del 15% en sus ventas totales.

Usando todos los cálculos que realizó, junto con los resultados de su computadora, John hace los pronósticos de las ventas de Mr. Tux para los primeros seis meses de 2006, los cuales se muestran en la tabla 5-9.

Después de estudiar los pronósticos de 2006, John se inquieta al ver el rango tan amplio de las proyecciones de las ventas mensuales, que van de \$89,112 a \$595,111. Si bien sabía que su volumen mensual tenía una considerable variabilidad, le preocupa la amplitud

TABLA 5-9 Pronósticos de Mr. Tux

<i>Ventas</i>	<i>Pronóstico</i>	=	<i>T</i>	×	<i>S</i>	×	<i>C</i>	×	<i>I</i>
Enero	89,112	=	269,938		.3144		1.05		1.00
Febrero	136,689	=	272,971		.4724		1.06		1.00
Marzo	301,483	=	276,004		.8877		1.07		1.15
Abril	540,992	=	279,037		1.7787		1.09		1.00
Mayo	595,111	=	282,070		1.9180		1.10		1.00
Junio	375,263	=	285,103		1.1858		1.11		1.00

de las fluctuaciones. John ha estado pensando acerca de la expansión de su ubicación actual en Spokane hacia el área de Seattle. Él descubrió recientemente que existen varios grandes acontecimientos en Seattle que lo hacen diferente de su mercado actual de Spokane. En particular, la celebración de bailes formales de regreso a casa será fastuosa en Seattle, no en Spokane. Puesto que esto tendrá lugar en el otoño, cuando su negocio de Spokane tiene menor actividad (véase los índices estacionales de octubre y noviembre), John ve la ventaja de nivelar su negocio entrando al mercado de Seattle.

Su preocupación real, sin embargo, se enfoca en los peores meses, enero y febrero. Él ha considerado recientemente comprar una máquina de fabricación de camisas para esmoquin que vio en una feria de productos, pensando en que podría dedicarse a esa actividad durante los meses de invierno. Si la reacción de los compradores potenciales de las camisas para ese periodo es positiva, él estaría dispuesto a intentarlo. Por así decirlo, los índices estacionales calculados por su computadora han enfocado su atención en los cambios extremos de los niveles de ventas mensuales.

Preguntas

- Suponga que el ejecutivo bancario de John le pide dos enunciados, para mostrarlos a su jefe, que justifiquen la petición de John de realizar pagos extras del préstamo en algunos meses y dejar de pagar en otros. Escriba estos dos enunciados.
- Suponga que John hará el doble de negocios en Seattle que en Spokane el próximo año. Determine los índices estacionales de Seattle que serían ideales para equilibrar los ingresos mensuales de Mr. Tux.
- Ignorando Seattle, ¿qué volumen de camisas tendría que confeccionar John en su máquina para que tanto enero como febrero resulten con un nivel “promedio”?

CASO 5-3 CONSUMER CREDIT COUNSELING

El Consumer Credit Counseling (CCC) se describió en el caso 1-2.

El director ejecutivo, Marv Harnishfeger, concluyó que la variable más importante que CCC necesitaba pronosticar era el número de clientes nuevos que serían atendidos durante el resto de 1993. Marv entregó a Dorothy Mercer datos mensuales del número de clientes nuevos atendidos por CCC durante el periodo de enero de 1985 a marzo de 1993 (véase el caso 3-3).

Dorothy le dio a usted estos datos y le pidió que realizara un análisis de descomposición de la serie de tiempo. Ella enfatizó que quería comprender plenamente los componentes de tendencia y estacionalidad. Dorothy quiere conocer la importancia de cada componente. También quiere saber si en los datos aparecen algunas irregularidades inusuales. Por último, le solicitó elaborar el pronóstico para el resto de 1993.

Tarea

Escriba un reporte para Dorothy con la información que le solicitó.

CASO 5-4 MURPHY BROTHERS FURNITURE

En el caso 4-4, Julie Murphy desarrolló un modelo informal que combinaba estimaciones estacionales y de tendencia (similar a la ecuación 4.5). Una de las razones principales para seleccionar este modelo informal fue su sencillez. Julie sabía que su padre, Glen, necesitaba comprender el modelo de pronóstico que utilizaba la compañía.

Suponga que ahora estamos en octubre de 2002, y hay muchos cambios. Glen Murphy se retiró. Julie ha tomado algunos cursos de negocios en la universidad local, incluyendo uno de pronósticos de negocios. Murphy Brothers Furniture construyó una fábrica en Dallas y empezó a fabricar su propia línea de muebles en octubre de 1995.

En la tabla 5-10 se presentan los datos mensuales de ventas de Murphy Brothers Furniture de 1996 a octubre de 2002. Como indica el patrón de estos datos en la figura 5-13, las ventas han aumentado notoriamente desde 1996. Por desgracia, la figura 5-13 también indica que uno de los problemas de la demanda es que es un tanto estacional. La política general de la compañía es contratar dos turnos durante el verano y los primeros meses del otoño, y luego trabajar un solo turno durante el resto del año. De este modo, se conformarán inventarios sustanciales al final del verano y los meses del otoño hasta que la demanda comience a

mejorar en noviembre y diciembre. Ante estos requerimientos de producción, Julie está muy ansiosa por elaborar pronósticos de corto plazo para la compañía que se apoye en la mejor información disponible referente a la demanda.

Para efectos del pronóstico, Julie decidió usar sólo los datos reunidos desde 1996, el primer año completo en que Murphy Brothers fabricó su propia línea de muebles (tabla 5-10). Julie puede ver (tabla 5-13) que sus datos tienen tanto tendencia como estacionalidad. Por esta razón, decide usar un método de descomposición de series de tiempo para analizar su variable de ventas.

Como la figura 5-13 indica que la serie de tiempo que Julie está analizando tiene aproximadamente la misma variabilidad a lo largo de la serie, ella decide usar un modelo de componentes aditivos para elaborar el pronóstico. Así, corre el modelo $Y_t = T_t + S_t + I_t$. En la tabla 5-11 se presenta un resumen de los resultados. Julie observa el patrón de autocorrelación de los residuos (véase la figura 5-14) para verificar la aleatoriedad. Los residuos no son aleatorios y el modelo no parece ser el adecuado.

Julie está atorada. Ella intentó un modelo informal que combinaba estimaciones estacionales y de tendencia, la suavización exponencial de Winters y la descomposición clásica. Finalmente, Julie decide hacer un ajuste para dejar la estacionalidad fuera de los datos,

TABLA 5-10 Ventas mensuales de Murphy Brothers Furniture, 1996 a 2002

	<i>Ene.</i>	<i>Feb.</i>	<i>Mar.</i>	<i>Abr.</i>	<i>Mayo</i>	<i>Jun.</i>	<i>Jul.</i>	<i>Ago.</i>	<i>Sept.</i>	<i>Oct.</i>	<i>Nov.</i>	<i>Dic.</i>
1996	4,964	4,968	5,601	5,454	5,721	5,690	5,804	6,040	5,843	6,087	6,469	7,002
1997	5,416	5,393	5,907	5,768	6,107	6,016	6,131	6,499	6,249	6,472	6,946	7,615
1998	5,876	5,818	6,342	6,143	6,442	6,407	6,545	6,758	6,485	6,805	7,361	8,079
1999	6,061	6,187	6,792	6,587	6,918	6,920	7,030	7,491	7,305	7,571	8,013	8,727
2000	6,776	6,847	7,531	7,333	7,685	7,518	7,672	7,992	7,645	7,923	8,297	8,537
2001	7,005	6,855	7,420	7,183	7,554	7,475	7,687	7,922	7,426	7,736	8,483	9,329
2002	7,120	7,124	7,817	7,538	7,921	7,757	7,816	8,208	7,828			

Fuente: Registros de ventas de Murphy Brothers Furniture.




FIGURA 5-13 Ventas mensuales de Murphy Brothers Furniture, 1996 a 2002

TABLA 5-11 Resumen del modelo de descomposición para Murphy Brothers Furniture

Descomposición de las series de tiempo

Ecuación de la línea de tendencia

$$\hat{T}_t = 5,672 + 31.4t$$

Índice estacional

<i>Periodo</i>	<i>Índice</i>
1	-674.60
2	-702.56
3	-143.72
4	-366.64
5	-53.52
6	-173.27
7	-42.74
8	222.32
9	-57.95
10	145.76
11	612.30
12	1234.63
<i>Exactitud</i>	<i>Medidas</i>
MAPE:	1.9
MAD:	135.1
MSD:	30,965.3




FIGURA 5-14 Función de autocorrelación para los residuos usando un modelo de descomposición de series de tiempo para Murphy Brothers Furniture

TABLA 5-12 Ventas mensuales ajustadas estacionalmente de Murphy Brothers Furniture, 1996 a 2002

	<i>Ene.</i>	<i>Feb.</i>	<i>Mar.</i>	<i>Abr.</i>	<i>Mayo</i>	<i>Jun.</i>	<i>Jul.</i>	<i>Ago.</i>	<i>Sept.</i>	<i>Oct.</i>	<i>Nov.</i>	<i>Dic.</i>
1996	5,621	5,671	5,745	5,821	5,775	5,863	5,847	5,818	5,901	5,941	5,857	5,767
1997	6,091	6,096	6,051	6,135	6,161	6,189	6,174	6,277	6,307	6,326	6,334	6,380
1998	6,551	6,521	6,486	6,510	6,496	6,580	6,588	6,536	6,543	6,659	6,749	6,844
1999	6,736	6,890	6,936	6,954	6,972	7,093	7,073	7,269	7,363	7,425	7,401	7,492
2000	7,451	7,550	7,675	7,700	7,739	7,691	7,715	7,770	7,703	7,777	7,685	7,302
2001	7,680	7,558	7,564	7,550	7,608	7,648	7,730	7,700	7,484	7,590	7,871	8,094
2002	7,795	7,827	7,961	7,905	7,975	7,930	7,859	7,986	7,886			

de manera que pueda aplicar las técnicas de pronóstico que no manejan datos estacionales. Julie desestacionaliza los datos sumando o restando el índice estacional para el mes apropiado. Por ejemplo, suma 674.60 a los

datos de cada enero y resta 1,234.63 de los datos de cada diciembre. La tabla 5-12 presenta los datos ajustados estacionalmente.

Tarea

1. Con base en los datos de 2001 en la tabla 5-12, desarrolle un modelo para pronosticar los datos de ventas ajustados a la estacionalidad y generar pronósticos para los primeros nueve meses de 2002.
2. De acuerdo con los pronósticos del inciso 1, pronostique las ventas para los primeros nueve meses de 2002 sumando o restando el índice estacional apropiado de la tabla 5-11. ¿Son exactos estos pronósticos cuando se comparan con los valores reales?
3. Pronostique las ventas de octubre de 2002 usando el mismo procedimiento del inciso 2.
4. Compare el patrón de los datos de ventas al menudeo presentados en el caso 3-1A con el patrón de los datos de ventas reales de 1992 a 1995 presentados en el caso 4-4 y con el patrón de los datos de ventas reales de 1996 a 2001 presentados en este caso.

CASO 5-5 AAA WASHINGTON¹⁴

En 1993 AAA Washington era uno de los dos clubes regionales de conductores de automóviles afiliado a la Asociación Americana de Automovilistas (AAA o triple A) que operaban en el estado de Washington. En esa época, el 69% de las personas que pertenecían a algún club de automovilistas eran socios de la Asociación Americana del Automóvil, lo que hizo de ésta el club de conductores de automóviles más grande de Norteamérica. AAA era una asociación nacional que atendía a sus socios individuales a través de una federación de aproximadamente 150 clubes regionales que optaban por afiliarse a la asociación nacional. La asociación estableció un número mínimo de normas que los clubes afiliados tenían que cumplir para mantener su afiliación. Cada club regional era dirigido localmente por su propio consejo y equipo de administración. Los miembros del consejo de administración local y los gerentes eran responsables del reclutamiento y la retención de socios dentro de sus territorios y de garantizar la salud financiera del club regional. Más allá del cumplimiento de las normas mínimas establecidas por AAA, cada club regional era libre para definir qué productos y servicios adicionales ofrecería y cómo los cobraría.

AAA Washington fue fundada en 1904. Su territorio estaba integrado por los 26 condados de Washington al oeste del río Columbia. El club ofrecía a sus socios una variedad de servicios relacionados con la conducción de automóviles y con los viajes en este medio de transporte. Los beneficios a los socios brindados en cooperación con la asociación nacional incluían servicios de emergencia en el camino; servicio clasificado de alojamiento, restaurantes y talleres de reparación de automóviles; viajes guiados a los alojamientos aprobados por AAA, restaurantes, campamentos y puntos de interés; y asistencia legal a los miembros. Además de estos servicios, AAA Washington ofrecía a sus socios planes de protección ampliada para servicios de emergencia en el camino; servicios financieros, incluyendo tarjetas de crédito afines, líneas de crédito personal, cuentas de cheques y ahorro, depósitos a plazo, y cheques de viajero de American Express sin cargo; acceso a una flota de camionetas para diagnóstico de automóviles para determinar el estado del vehículo de un socio; una agencia de viajes; y

una agencia de seguros. El club brindaba estos servicios a través de una red de oficinas localizadas en Bellevue, Bellingham, Bremerton, Everett, Lynnwood, Olympia, Renton, Seattle, Tacoma, las tres ciudades (Pasco, Richland y Kennewick), Vancouver, Wenatchee y Yakima, en Washington.

La investigación del club ha demostrado de forma constante que el servicio de emergencia en el camino era la razón principal por la que la gente se unía a AAA. La importancia del servicio de emergencia en el camino para la seguridad de los socios se reflejaba en los tres tipos de membresías ofrecidas por AAA Washington: Básica, AAA Plus y AAA Plus RV. La membresía básica proporcionaba a los socios cinco millas de arrastre con grúa desde el punto en el que su vehículo se había descompuesto. AAA Plus ofrecía a los socios 100 millas de arrastre con grúa desde el punto en el que su vehículo se había descompuesto. AAA Plus RV brindaba a los socios 100 millas de servicio de arrastre a los socios que tenían vehículos recreativos (campers), automóviles de pasajeros y camiones ligeros. El servicio de emergencia en el camino era el gasto operativo individual más grande del club. Se había proyectado que para el siguiente año fiscal, el otorgamiento del servicio de emergencia en el camino costaría \$9.5 millones, el 37% del presupuesto operativo anual del club.

Michael DeCoria, un graduado de la carrera de contaduría (CPA) con una maestría en administración (MBA) de la Universidad del Este de Washington, se unió recientemente al equipo de administración del club como vicepresidente de operaciones. Una de las responsabilidades que Michael asumió era la administración del servicio de emergencia en el camino. Al principio de la evaluación de la operación de este servicio, DeCoria descubrió que los costos se habían incrementado a un ritmo más rápido de lo que podía justificarse con la tasa de inflación o el incremento en las afiliaciones al club. Michael empezó por analizar la manera en que el club prestaba el servicio de emergencia en el camino para determinar si los costos podrían controlarse más de cerca en esta área.

El servicio de emergencia en el camino se otorgaba en una de cuatro modalidades: a través de la flota de servicio de AAA Washington, compañías contratistas, reembolso recíproco y reembolso directo. Los

¹⁴Este caso fue proporcionado por Steve Branton, ex alumno y graduado de MBA, de la Universidad del Este de Washington.

vehículos de la flota de servicio de AAA Washington respondían a las llamadas de solicitud de servicio de los socios que tenían problemas en el área del centro de Seattle. Dentro del área de servicio de AAA Washington, pero fuera del centro de Seattle, el servicio era proporcionado por las compañías comerciales de grúas que había contratado AAA Washington. Los socios tramitaban ambos tipos de servicio llamando al centro de atención del club. Si un socio tenía problemas fuera del área de AAA Washington, podía llamar al club AAA local afiliado para recibir el servicio. El club afiliado pagaba por este servicio y luego lo facturaba a AAA Washington para un reembolso recíproco a través de un servicio de compensación proporcionado por la aso-

ciación nacional. Finalmente, los socios podían hacer contacto directamente con una compañía de grúas de su elección, pagando por el servicio de la grúa y luego enviando un requerimiento de reembolso por parte del club. AAA Washington reembolsaba directamente al socio el costo real del arrastre o \$50, lo que fuera menor. Después de un examen cuidadoso de los cuatro métodos de prestación del servicio del club, Michael concluyó que el club estaba controlando el costo de la entrega del servicio tan estrechamente como era posible.

Otra fuente posible de incremento de costos era un aumento en el uso del servicio. El número de afiliados había aumentado constantemente por varios años, pero el aumento en el costo era más de lo que podría

TABLA 5-13 Volumen de llamadas mensuales de emergencias en el camino de AAA Washington

<i>Año</i>	<i>Mes</i>	<i>Llamadas</i>	<i>Año</i>	<i>Mes</i>	<i>Llamadas</i>
1988	Mayo	20,002	1991	Enero	23,441
	Junio	21,591		Febrero	19,205
	Julio	22,696		Marzo	20,386
	Agosto	21,509		Abril	19,988
	Septiembre	22,123		Mayo	19,077
	Octubre	21,449		Junio	19,141
	Noviembre	23,475		Julio	20,883
	Diciembre	23,529		Agosto	20,709
1989	Enero	23,327	1992	Septiembre	19,647
	Febrero	24,050		Octubre	22,013
	Marzo	24,010		November	22,375
	Abril	19,735		Diciembre	22,727
	Mayo	20,153		Enero	22,367
	Junio	19,512		Febrero	21,155
	Julio	19,892		Marzo	21,209
	Agosto	20,326		Abril	19,286
1990	Septiembre	19,378		Mayo	19,725
	Octubre	21,263		Junio	20,276
	Noviembre	21,443		Julio	20,795
	Diciembre	23,366		Agosto	21,126
	Enero	23,836		Septiembre	20,251
	Febrero	23,336		Octubre	22,069
	Marzo	22,003		Noviembre	23,268
	Abril	20,155		Diciembre	26,039
	Mayo	20,070	1993	Enero	26,127
	Junio	19,588		Febrero	20,067
	Julio	20,804		Marzo	19,673
	Agosto	19,644		Abril	19,142
	Septiembre	17,424			
	Octubre	20,833			
	Noviembre	22,490			
	Diciembre	24,861			

atribuirse tan sólo al aumento de afiliados. Entonces Michael revisó para ver si existía un aumento en el uso del servicio sobre una base per cápita. Descubrió que entre el año fiscal 1990 y el año fiscal 1991, el número promedio de llamadas de emergencia por socio para solicitar el servicio creció en 3.28%, de un promedio de

0.61 llamadas por socio a 0.63 llamadas. A DeCoria le preocupaba el hecho de que si esta tendencia continuaba, podría haber un efecto negativo en las finanzas del club; así que reunió los datos sobre el volumen de las llamadas del servicio de emergencia en el camino, los cuales se presentan en la tabla 5-13.

Tarea

1. Realice la descomposición de una serie de tiempo con los datos de llamadas de emergencia para solicitar el servicio de asistencia en el camino de AAA.
2. Escriba un memorando a DeCoria en el que resuma los hechos importantes de los cambios en

las llamadas de los servicios de emergencia en el camino que usted descubrió con el análisis de la descomposición de la serie de tiempo.

CASO 5-6 ALOMEGA FOOD STORES

En el ejemplo 1.1, Julie Ruth, presidenta de Alomega Food Stores, recolectó datos sobre las ventas mensuales de su compañía junto con otras variables que podrían estar relacionadas con las ventas (revise el ejemplo 1.1). En el caso 2-3 se explicó cómo Julie usó su programa de Minitab para calcular la ecuación de regresión múltiple usando la mejor predicción de las ventas mensuales.

Después de revisar los resultados de este análisis de regresión, incluyendo el bajo valor de r^2 (36%), Julie decidió intentar la descomposición de series de tiempo de una variable individual: las ventas mensuales. La figura 5-15 presenta la gráfica de los datos de ventas que obtuvo (véase el caso 3-4). Parece que las ventas estuvieran ampliamente distribuidas alrededor de la línea de tendencia para los pronósticos exactos. Confirmó




FIGURA 5-15 Análisis de tendencia de las ventas de Alomega Food Stores




FIGURA 5-16 Ajuste de descomposición de las ventas de Alomega Food Stores

esta impresión cuando observó el valor de 28 del *MAPE*. Ella interpretó que esto significaba que el porcentaje de error promedio entre los valores reales y la línea de tendencia era 28%, un valor que consideró muy alto. Luego intentó una descomposición multiplicativa de los datos. Los resultados se presentan en la figura 5-16.

Además de la ecuación de la tendencia presentada en el reporte, Julie estaba interesada en los índices (mensuales) estacionales que calculó el programa. Ella notó que el mes con las ventas más bajas era diciembre (mes 12, índice = 0.49) y el más alto era enero (mes 1, índice 1.74). Ella estaba consciente de la gran diferencia entre diciembre y enero, pero no se dio cuenta qué tan extrema era.

También notó que el *MAPE* había caído al 12%, una mejora definitiva sobre el valor obtenido cuando sólo se usó la ecuación de la tendencia.

Finalmente, Julie hizo que el programa elaborara pronósticos de los siguientes 12 meses, usando las proyecciones de la ecuación de la tendencia modificada por los índices estacionales. Pensó que podría usarlos como pronósticos para efectos de planeación, pero se preguntaba si otro método podría arrojar mejores pronósticos. También estaba preocupada por lo que su gerente de producción, Jackson Tilson, podría decir acerca de sus pronósticos, especialmente porque había expresado su preocupación por el uso de la computadora para hacer predicciones (véase este comentario al final del ejemplo 1.1).

Pregunta

1. ¿Qué podría decir Jackson Tilson acerca de los pronósticos de Julie?

CASO 5-7 SURTIDO COOKIES

Las ventas mensuales (en kilogramos) de las galletas Surtido se reportaron en el caso 3-5. En el caso 4-8, Jaime Luna examinó las autocorrelaciones de las ventas de galletas para determinar si podría existir un

componente estacional. También consideró un método de suavización para generar pronósticos de las ventas futuras. Un miembro del equipo de Jaime tiene alguna experiencia con el análisis de descomposición y sugiere

que se intente una descomposición multiplicativa de los datos de ventas de las galletas. No sólo se obtendría una indicación de la tendencia en las ventas, sino que también se podrían ver los índices estacionales. Estos últimos son piezas importantes de información para determinar los requerimientos de la flotilla de camiones y de almacenamiento (inventario) durante el año. Jaime

no tiene mucha fe en un procedimiento que intente estimar componentes que no pueden observarse directamente. Sin embargo, puesto que Minitab está disponible, está de acuerdo en hacer un intento de descomposición y utilizarla con la finalidad de generar pronósticos de ventas para los meses restantes de 2003.

Preguntas

1. Realice una descomposición multiplicativa de los datos de ventas de Surtido Cookies, guarde los residuos y genere pronósticos de ventas para los meses restantes de 2003.
2. ¿De qué se enteró Jaime en relación con la tendencia en ventas? ¿Qué le dicen los índices estacionales?
3. Calcule las autocorrelaciones residuales. Revisando las autocorrelaciones residuales y los pronósticos de ventas por el resto de 2003, ¿debe Jaime modificar sus creencias acerca del valor del análisis de descomposición? Explique.

CASO 5-8 SOUTHWEST MEDICAL CENTER

Mary Beasley y su objetivo de pronosticar el número de visitas futuras facturables al Medical Oncology de Southwest Medical Center fueron presentados en el caso 4-7. En ese caso, Mary se enteró de que había un componente estacional en sus datos y consideró el uso del método de suavización de Winters para generar los pronósticos de las visitas futuras. Mary no estaba totalmente satisfecha con este análisis, puesto que parecía haber algunas autocorrelaciones residuales significativas. Más aún, Mary estaba interesada en aislar los índices estacionales porque quería tener total eviden-

cia de que algunos periodos del año estaban más saturados que otros. (La programación de los médicos nunca es una tarea fácil). Un colega de Mary le sugirió que considerara el análisis de descomposición, una técnica con la cual Mary no estaba familiarizada. Sin embargo, como tenía disponible un paquete de software estadístico que incluía la descomposición, Mary estaba dispuesta a intentarlo. También se dio cuenta de que tenía que entender la descomposición lo suficientemente bien para vender los resultados a la administración central si era necesario.

Preguntas

1. Redacte un breve escrito para explicar a Mary la descomposición de una serie de tiempo..
2. Ejecute una descomposición multiplicativa del total de visitas facturables, guarde los residuos y genere los pronósticos de las visitas para los siguientes 12 meses, usando febrero del año fiscal 2003-2004 como el pronóstico de origen.
3. Interprete el componente de la tendencia para Mary. ¿Qué aprendió ella de los índices estacionales?
4. Calcule las autocorrelaciones residuales. Dadas las autocorrelaciones residuales y los pronósticos, ¿debe Mary estar contenta con el análisis de descomposición del total de visitas facturables? Explique.

Aplicaciones de Minitab

El problema. En el ejemplo 5.1 se desarrolló una ecuación de la tendencia para el registro anual de automóviles nuevos de pasajeros en Estados Unidos de 1960 a 1992.

Solución de Minitab

1. Después de introducir los datos de registro de automóviles nuevos de pasajeros en la columna C1 de la hoja de trabajo, haga clic en los siguientes menús para correr el análisis de la tendencia:

Stat>Time Series>Trend Analysis

2. Aparece la ventana de diálogo Trend Analysis.
 - a) La variable es Cars.
 - b) Haga clic en Linear para Model Type.
 - c) Haga clic en Generate forecasts, y coloque un 1 en Number of forecasts para el pronóstico de 1993.
 - d) Haga clic en Options. En el espacio provisto para TITLE, escriba Linear Trend for Annual Car Registrations.
 - e) Haga clic en OK en la ventana de diálogo de Options. Haga clic en OK otra vez y aparecerá la gráfica que se presenta en la figura 5-3.

El problema. La tabla 5-1 se construyó con la finalidad de mostrar la tendencia estimada y los errores calculados para los datos del registro de automóviles nuevos de pasajeros (véase la p. 170).

Solución de Minitab

1. La columna C1 está titulada como Year, la C2 como Y, la C3 como t, la C4 como Estimates, y la C5 está titulada Error. Haga clic en los siguientes menús para crear los años:

Calc>Make Patterned Data>Simple Set of Numbers

2. Aparece la ventana de diálogo Simple Set of Numbers.
 - a) Se deben dar las siguientes respuestas:
Almacenar datos con patrón en: C1
Desde el primer valor: 1960
Hasta el último valor: 1992
En pasos de: 1
 - b) Haga clic en OK y aparecerán los años en C1.
 - c) Introduzca los datos de automóviles nuevos de pasajeros registrados en C2.
3. Los datos codificados de tiempo t se introducen en C3, usando la ventana de diálogo Simple Set of Numbers.
4. En C4 se introducen las estimaciones de la tendencia haciendo clic en los mismos menús de análisis de la tendencia usados para resolver el ejemplo 5.1, con un paso adicional.
5. Haga clic en el menú Storage y obtendrá la ventana de diálogo Trend Analysis Storage.
 - a) Abajo de Storage, haga clic en Fits (línea de tendencia) y Residuals (datos sin tendencia).
 - b) Haga clic en OK en esta ventana de diálogo y luego en la ventana Trend Analysis. Las estimaciones de la tendencia aparecerán en C4 y los errores (residuos) aparecerán en C5.

El problema. En los ejemplos 5.3 y 5.4, Perkin Kendell, el analista de Coastal Marine Corporation, quería pronosticar las ventas trimestrales de 2007.

Solución de Minitab

1. Introduzca los años correspondientes en la columna C1, los trimestres en C2 y los datos en C3. Para correr un modelo de descomposición, haga clic en los siguientes menús:

Stat>Time Series>Decomposition




FIGURA 5-17 Ventana de diálogo de Descomposición en Minitab

2. Aparece la ventana de diálogo Decomposition mostrada en la figura 5-17.
 - a) La variable es C3 o Sales.
 - b) Como los datos son trimestrales, la duración estacional (Seasonal length) es 4.
 - c) El tipo de modelo es multiplicativo y los componentes del modelo son el de tendencia y el estacional (Trend plus seasonal).
 - d) Haga clic en Options. El periodo estacional inicial es 1. Haga clic en OK.
 - e) Haga clic en Generate forecasts y escriba el número 4 en Number of forecasts.
3. Haga clic en el menú Storage y obtendrá la ventana de diálogo Decomposition-Storage mostrada en la figura 5-18.
 - a) Debajo del menú Storage, seleccione Trend line, Detrended data, Seasonals y Seasonally adjusted data.
 - b) Haga clic en OK tanto para esta ventana de diálogo como en la ventana de diálogo Decomposition. La tabla 5-4 presenta las estimaciones de la tendencia en la columna C4 (titulada como *T*), los datos sin tendencia en la columna C5 (titulada como *SCI*), las estacionalidades en la columna C6 (titulada como *S*), y los datos ajustados estacionalmente en la columna C7 (titulada como *TCI*).
4. Las figuras 5-10, 5-11 y 5-12 aparecen en la pantalla y pueden imprimirse una por una usando los siguientes menús:

File>Print Graph
5. Después de imprimir las gráficas, haga clic en

File>Print Session Window

y se imprimirán los pronósticos presentados en la figura 5-9.

Las columnas *CI*, *C* e *I* se pueden calcular usando Minitab, como se demuestra en los siguientes pasos.




FIGURA 5-18 Ventana de diálogo Descomposición-almacenamiento en Minitab

6. Etiquete la columna C8 CI. Usando el menú Calc>Calculator de Minitab, genere la columna C8 dividiendo la columna C7 entre la columna C4, así que $CI = TCI/T$.
7. Etiquete la columna C9 C. Genere la columna C9 seleccionando un promedio móvil centrado de orden 3 de los valores en la columna C8. Use el menú

Stat>Time Series>Moving Average

Asegúrese de verificar la ventana Center the moving averages.

8. Etiquete la columna C10I. Usando el menú Calc>Calculador de Minitab, genere la columna C10 dividiendo la columna C8 entre la columna C9, así que $I = CI/C$. Se completan ahora las columnas restantes de la tabla 5-4.

Aplicaciones de Excel

El problema. La figura 5-6 presenta los datos y la gráfica correspondientes a los vendedores del fondo común (véase la p. 173). Se necesita un modelo de tendencia exponencial para ajustar estos datos.

Solución de Excel

1. Introduzca Y en A1 y los datos de los vendedores en A2:A8.
2. Introduzca X en B1 y la variable codificada X (1, 2, 3, 4, 5, 6, 7) en B2:B8.
3. Introduzca Log Y en C1, y produzca los logaritmos (de base 10) de la variable Y introduciendo la fórmula = LOG10(A2) en la celda C2. Copie esta fórmula para el resto de la columna.
4. Haga clic en los siguientes menús para calcular la tendencia exponencial:

Tools>Data Analysis

5. Aparece la ventana de diálogo Data Analysis. Debajo de Analysis Tools, seleccione Regression y haga clic en OK. Aparecerá la ventana de diálogo de Regresión mostrada en la figura 5-19.




FIGURA 5-19 Ventana de diálogo para la regresión de Excel

Microsoft Excel - Book1

File Edit View Insert Format Tools Data Window Help

Type a question for help

Snagit Window

Arial 10 B I U

A22 fx

1	SUMMARY OUTPUT							
2								
3	Regression Statistics							
4	Multiple R	0.9984						
5	R Square	0.9969						
6	Adjusted R Square	0.9963						
7	Standard Error	0.0157						
8	Observations	7						
9								
10	ANOVA							
11		df	SS	MS	F	Significance F		
12	Regression	1	0.392106065	0.392106	1600.788	1.8389E-07		
13	Residual	5	0.001224728	0.000245				
14	Total	6	0.393330793					
15								
16		Coefficients	Standard Error	t Stat	P-value	Lower 95%	Upper 95%	Lower 95.0%
17	Intercept	1.00069	0.01323	75.65363	7.64E-09	0.96669	1.03469	0.96669
18	X	0.11834	0.00296	40.00985	1.84E-07	0.11073	0.12594	0.11073
19								
20								
21								
22								
23								
24								
25								

Figure 5-20 Sheet1 Sheet2 Sheet3

Ready NUM

FIGURA 5-20 Resultado de Excel de la regresión para el ejemplo de los vendedores del fondo común

- a) Introduzca C1:C8 como el rango de Y (Input Y Range).
- b) Introduzca B1:B8 como el rango de X (Input X Range).
- c) Seleccione la casilla de verificación Labels.
- d) Introduzca la figura 5-20 como el nombre de New Worksheet Ply. Haga clic en OK.

La figura 5-20 representa el resultado de Excel de un modelo exponencial de los vendedores del fondo común. La ecuación es

$$\log \hat{T} = 1.00069 + 0.11834t$$

Los antilogaritmos de los coeficientes de regresión en esta ecuación son

$$b_0 = \text{antilog } 1.00069 = 10.016$$

$$b_1 = \text{antilog } 0.11834 = 1.313$$

Por lo tanto, la ecuación de la tendencia exponencial ajustada es

$$\hat{Y} = (10.016)(1.313)^t$$

Referencias

- Bell, W. R. y S. C. Hillmer. "Issues Involved with the Seasonal Adjustment of Economic Time Series", *Journal of Business and Economic Statistics* 2 (1984):291-320.
- Bowerman, B. L., R. T. O'Connell y A. B. Koehler. *Forecasting, Time Series and Regresión*, 4a. ed. Belmont, Calif.: Thomson Brooks/Cole, 2005.
- Diebold, F. X. *Elements of Forecasting*, 3a. ed. Cincinnati, Ohio: South-Western, 2004.
- Findley, D. F., B. C. Monsell, W. R. Bell, M. C. Otto y B. Chen. "New Capabilities and Methods of the X-12 ARIMA Seasonal Adjustment Program", *Journal of Business and Economic Statistics* 16 (1998): 127-152.
- Levenbach, H. y J. P. Cleary. *Forecasting: Practice and Process for Demand Management*. Belmont, Calif.: Thomson Brooks/Cole, 2006.
- Makridakis, S., S. C. Wheelwright y R. J. Hyndman. *Forecasting Methods and Applications*, 3a. ed. Nueva York: Wiley, 1998.
- Moore, G. H. y J. Shiskin. "Early Warning Signals for the Economy". En *Statistics: A Guide to Business and Economics*, J. M. Tanur *et al.*, eds. San Francisco: Holden-Day, 1976.

REGRESIÓN LINEAL
SIMPLE

En el capítulo 2 se analizó la asociación lineal (correlación) entre dos variables numéricas. La asociación lineal implica una relación en línea recta, y vimos cómo ajustar una línea recta a pares de observaciones de las dos variables usando el método de los mínimos cuadrados. En este capítulo se estudian con detalle los modelos de regresión lineal simple (línea recta). Una vez que se establece una relación lineal, el conocimiento de la variable independiente servirá para pronosticar la variable dependiente.

Con la finalidad de revisar el análisis de la relación entre dos variables, presentado en el capítulo 2, considere el siguiente ejemplo.

Ejemplo 6.1

Suponga que el señor Bump observa el precio y volumen de los galones de leche vendidos durante 10 semanas seleccionadas al azar. Los datos que recolectó se presentan en la tabla 6-1.

Primero, elabora un diagrama de dispersión de los datos, que se muestra en la figura 6-1. En este diagrama parece que existe una relación lineal negativa entre Y , el número de galones de leche vendidos, y X , el precio por galón. Al parecer, conforme el precio sube, el volumen baja.

Ahora, Bump desea medir el grado de esta relación aparente calculando el coeficiente de correlación de la muestra, r . Con base en la ecuación 2.10 y los cálculos de la tabla 6-2, él obtiene

$$\begin{aligned}
 r &= \frac{n\sum XY - (\sum X)(\sum Y)}{\sqrt{n\sum X^2 - (\sum X)^2}\sqrt{n\sum Y^2 - (\sum Y)^2}} \\
 &= \frac{10(149.3) - (14.4)(112)}{\sqrt{10(21.56) - (14.4)^2}\sqrt{10(1,488) - (112)^2}} \\
 &= \frac{-119.8}{138.7} = -.86
 \end{aligned}$$

TABLA 6-1 Datos de los galones de leche para el ejemplo 6.1

<i>Semana</i>	<i>Nivel de ventas semanal, Y (miles de galones)</i>	<i>Precio de venta X (\$)</i>
1	10	1.30
2	6	2.00
3	5	1.70
4	12	1.50
5	10	1.60
6	15	1.20
7	5	1.60
8	12	1.40
9	17	1.00
10	20	1.10




FIGURA 6-1 Diagrama de dispersión para el ejemplo 6.1

TABLA 6-2 Cálculos necesarios para el ejemplo 6.1

	<i>Y</i>	<i>X</i>	<i>XY</i>	<i>X</i> ²	<i>Y</i> ²
<i>n</i> = 10	10	1.30	13.0	1.69	100
	6	2.00	12.0	4.00	36
	5	1.70	8.5	2.89	25
	12	1.50	18.0	2.25	144
	10	1.60	16.0	2.56	100
	15	1.20	18.0	1.44	225
	5	1.60	8.0	2.56	25
	12	1.40	16.8	1.96	144
	17	1.00	17.0	1.00	289
	20	1.10	22.0	1.21	400
Totales	112	14.40	149.3	21.56	1,488

El coeficiente de correlación de la muestra de $-.86$ indica una relación negativa bastante fuerte entre *Y* y *X*: conforme el precio del galón de leche aumenta, el número de galones vendidos disminuye.

La pregunta que se puede hacer ahora es: ¿En qué medida descende el volumen conforme el precio se eleva? Esta pregunta sugiere la graficación de una línea recta por los puntos de datos representados en el diagrama de dispersión. Después de que se ha dibujado la línea, la pendiente de ésta indicará la disminución promedio del volumen *Y* por cada dólar de incremento en el precio *X*.

LÍNEA DE REGRESIÓN

El señor Bump podría dibujar una línea recta por los puntos de datos, intentando ajustar la línea a los puntos tanto como sea posible. Sin embargo, alguien más podría dibujar una línea diferente. Un procedimiento más adecuado es obtener la mejor línea recta usando un criterio que, para un conjunto determinado de datos, produzca siempre la misma línea recta sin impor-

tar quién esté haciendo el ajuste. Como apuntamos en el capítulo 2, un procedimiento muy conocido para determinar la mejor línea recta ajustada es el criterio de los mínimos cuadrados.

La línea que mejor se ajusta a una colección de puntos de datos X - Y es la línea que minimiza la suma de los cuadrados de las distancias entre los puntos y la línea, medidas verticalmente, es decir, en la dirección Y . Esta línea se conoce como la *línea de los mínimos cuadrados* o *línea de regresión ajustada* y su ecuación se llama *ecuación de regresión ajustada*.

La línea recta ajustada es de la forma $\hat{Y} = b_0 + b_1X$. El primer término del segundo miembro, b_0 , es la *intersección con Y* , y el segundo término, b_1 , es la *pendiente*. Recuerde que la pendiente representa la cantidad de cambio de Y cuando se incrementa X en una unidad. El objetivo inmediato es determinar los valores de b_0 y b_1 .

Recuerde del capítulo 2 (véase la ecuación 2.11) que el *método de los mínimos cuadrados* selecciona los valores de b_0 y b_1 que minimizan los errores de la suma de los cuadrados (distancias).

$$SSE = \sum (Y - \hat{Y})^2 = \sum (Y - b_0 - b_1X)^2 \quad (6.1)$$

Usando un poco de cálculo, es posible obtener expresiones algebraicas específicas para los valores de los mínimos cuadrados. En particular,

$$b_1 = \frac{n \sum XY - \sum X \sum Y}{n \sum X^2 - (\sum X)^2} = \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\sum (X - \bar{X})^2} \quad (6.2)$$

$$b_0 = \frac{\sum Y}{n} - \frac{b_1 \sum X}{n} = \bar{Y} - b_1 \bar{X} \quad (6.3)$$

Como usted podrá adivinar, el coeficiente de la pendiente de los mínimos cuadrados está relacionado con el coeficiente de correlación de la muestra. Específicamente,

$$b_1 = \frac{\sqrt{\sum (Y - \bar{Y})^2}}{\sqrt{\sum (X - \bar{X})^2}} r \quad (6.4)$$

De manera que b_1 y r son proporcionales entre sí y tienen el mismo signo.

Las diferencias entre los valores Y realmente observados y los correspondientes valores Y ajustados, las $\hat{Y}$'s, se llaman *residuos*. Los residuos son las distancias verticales (positivas o negativas) entre los puntos de datos y la línea de mínimos cuadrados.

Tenemos la identidad

$$\text{Observación} = \text{Ajuste} + \text{Residuo}$$

o, en símbolos,

$$Y = \hat{Y} + (Y - \hat{Y}) \quad (6.5)$$

En este contexto, el ajuste representa el patrón general en los datos, y los residuos representan las desviaciones de ese patrón. La separación en ajustes más residuos se aplica también a otros patrones diferentes a los de una línea recta y los utilizaremos repetidamente en capítulos posteriores.

Ejemplo 6.2

Los coeficientes de mínimos cuadrados para ajustar una línea recta a los datos del señor Bump (véase la figura 6-1) se calculan fácilmente mediante las ecuaciones 6.2 y 6.3 y la información de la tabla 6-2. Así, tenemos

$$b_1 = \frac{10(149.3) - (14.4)(112)}{10(21.56) - (14.4)^2} = \frac{-119.8}{8.24} = -14.54$$

$$b_0 = \frac{112}{10} - (-14.54)\frac{14.4}{10} = 11.2 + 14.54(1.44) = 32.14$$

La línea de mínimos cuadrados ajustada tiene la ecuación

$$\hat{Y} = b_0 + b_1X$$

$$\hat{Y} = 32.14 - 14.54X \quad (6.6)$$

Esta ecuación se llama la *ecuación de regresión ajustada*.

Ahora, el señor Bump desea interpretar los valores en esta ecuación. La intersección con Y , b_0 , es el valor de Y cuando X es igual a cero. Una interpretación estricta sugeriría que el número promedio de galones vendidos cuando $X = 0$ (es decir, cuando el precio del galón de leche es cero) es de 32,140 galones. Esta interpretación no concuerda con el sentido común, puesto que uno esperaría que se “vendiera” más leche si ésta fuera gratis. El problema ilustrado aquí implica la predicción de un valor de Y con base en un valor de X acerca del cual no se ha recolectado evidencia muestral. Es decir, ninguno de los puntos de la muestra tiene un valor X en cero o cerca de cero. En este caso, como en muchos casos de análisis de regresión, no es posible tener una interpretación útil de la intersección con Y .

En términos más generales, con frecuencia no conviene predecir valores de Y para cualquier X más allá del rango de las X recopiladas en los datos muestrales. Una función de regresión debería interpretarse como una aproximación útil al comportamiento en el mundo real *de la región en la cual existen datos*. La extrapolación más allá de los datos requiere una desmedida suposición de que la naturaleza de la relación entre X y Y no cambia.¹

El coeficiente de la pendiente, b_1 , se puede interpretar como el cambio promedio de Y que ocurre cuando X se incrementa en una unidad. En este ejemplo, Y disminuye un promedio de 14.54 (esto es, se venden 14,540 galones menos) cuando X se incrementa en 1 (es decir, cuando el costo de un galón de leche se incrementa en \$1). Cada dólar de incremento en el precio de un galón de leche reduce la cantidad comprada en un promedio de 14,540 galones. Para expresar este enunciado en unidades más significativas, la evidencia muestral indica que cada incremento de 1 centavo en el precio de un galón de leche reduce la cantidad comprada en un promedio de 145.4 galones.

La relación X - Y se puede ilustrar dibujando la línea recta que mejor se ajusta a los puntos de datos en un diagrama de dispersión. El resultado se presenta en la figura 6-2.

Observe que las distancias verticales de los puntos a la línea se representan como líneas punteadas. Si estas distancias se elevan al cuadrado y se suman, el resultado sería menor que el calculado para cualquier otra línea que pudiera dibujarse a través de los puntos.² Así, de acuerdo con el procedimiento de los mínimos cuadrados, esta línea representa el mejor ajuste posible para los puntos de los 10 datos muestrales.

Cuando los puntos en el diagrama de dispersión no se ubican exactamente sobre la línea, como en la figura 6-2, es necesario recurrir a ideas estadísticas para el estudio de la relación entre dos variables. Pensamos en los datos de un diagrama de dispersión como una muestra de observaciones sobre una relación subyacente que se mantiene en la población de valores X - Y . El modelo estadístico de la regresión lineal simple supone que para todos los valores de X , los valores observados de la variable dependiente, Y , están normalmente distribuidos

¹En el capítulo 5 encontramos una situación similar cuando analizamos la utilidad de la extrapolación de curvas de tendencia para pronosticar valores futuros de una serie de tiempo.

²Para los datos de Bump, la suma más pequeña de las distancias elevadas al cuadrado es $SSE = 59.14$.




FIGURA 6-2 Línea de regresión ajustada de los datos del señor Bump para el ejemplo 6.2




FIGURA 6-3 Modelo estadístico de la regresión lineal simple

alrededor de la media, $\mu_Y = \beta_0 + \beta_1 X$, la cual depende linealmente de X . Es decir, conforme X cambia, las medias de la distribución de los valores posibles de Y permanecen a lo largo de la línea recta. Esta línea se conoce como la *línea de regresión de población*. Las Y observadas variarán alrededor de estas medias por la influencia de factores no medidos. El modelo supone que esta variación, medida por la desviación estándar, σ , es la misma para todos los valores de X . Finalmente, la desviación (distancia) entre un valor de Y y su media se conoce como *error* y se representa mediante la letra griega épsilon.

En el modelo de regresión lineal simple, la variable de respuesta o dependiente Y es la suma de esta media y la desviación aleatoria (ϵ) en relación con la media. Las desviaciones (ϵ) representan la variación de Y que se debe a otros factores no observados, los cuales impiden a los valores X - Y ubicarse exactamente sobre una línea recta en el diagrama de dispersión.

El modelo estadístico de regresión lineal simple se ilustra en la figura 6-3.

Modelo estadístico de regresión lineal

La variable de respuesta o dependiente, Y , está relacionada con la variable controlada o independiente, X , mediante

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Aquí, $\beta_0 + \beta_1 X$ es la respuesta promedio para una X dada. Se supone que las desviaciones (ε) son independientes y están normalmente distribuidas, con una media igual a 0 y una desviación estándar ε . Las constantes desconocidas son β_0 , β_1 y σ .

La línea de regresión ajustada (de la muestra), $\hat{Y} = b_0 + b_1 X$, puede considerarse como una estimación de la línea de regresión de la población, $m_y = \beta_0 + \beta_1 X$, en tanto que los residuos $e = Y - \hat{Y}$, pueden considerarse como estimaciones de los componentes del error, ε . Esto implica la siguiente correspondencia:

$$\text{Población: } Y = \beta_0 + \beta_1 X + \varepsilon$$

$$\text{Muestra: } Y = b_0 + b_1 X + e$$

La mayoría de los paquetes de software de computadora ejecutan los análisis de correlación y regresión. Las instrucciones para usar Excel en los ejemplos 6.1 y 6.2 se presentan en la sección de aplicaciones de Excel al final de este capítulo.

ERROR ESTÁNDAR DE LA ESTIMACIÓN

Una vez que se ha calculado la línea recta ajustada, el señor Bump podría estar interesado en medir el grado en el que los puntos de datos muestrales se dispersan alrededor de la función de regresión ajustada. Es posible desarrollar una medida de dispersión análoga a la desviación estándar de la muestra. Esta medida, llamada *error estándar de la estimación*, mide la dispersión de los puntos de datos en la dirección Y alrededor de la línea ajustada. El error estándar de la estimación se denota por $s_{y \cdot x}$ y está dado por

$$s_{y \cdot x} = \sqrt{\frac{\sum (Y - \hat{Y})^2}{n - 2}} \quad (6.7)$$

El *error estándar de la estimación* mide la cantidad por la cual los valores reales de Y difieren de los valores estimados o $\hat{Y}$. Para muestras relativamente grandes, esperaríamos que alrededor del 67% de las diferencias $Y - \hat{Y}$ estuvieran a una distancia inferior de $s_{y \cdot x}$ del 0, y que alrededor del 95% de estas diferencias estuvieran dentro de $2s_{y \cdot x}$ del 0.

El error estándar de la estimación es similar a la desviación estándar de la muestra presentada en el capítulo 2. Puede utilizarse para calcular la desviación estándar de la población. De hecho, $s_{y \cdot x}$ estima la desviación estándar, σ , del término de error, ε , en el modelo estadístico de regresión lineal simple. De manera equivalente, $s_{y \cdot x}$ estima la desviación estándar común, σ , de la distribución normal de los valores Y alrededor de la línea de regresión de la población, $\mu_y = \beta_0 + \beta_1 X$, para cada X (véase la figura 6-3).

Un análisis de regresión con un error estándar pequeño de la estimación significa que todos los puntos de datos se ubican muy cerca de la línea de regresión ajustada.³ Si el error estándar de la estimación es grande, los puntos de datos están considerablemente dispersos alrededor de la línea ajustada.

Para efectos de cálculo, la ecuación 6.7 se convierte en

$$s_{y \cdot x} = \sqrt{\frac{\sum Y^2 - b_0 \sum Y - b_1 \sum XY}{n - 2}} \quad (6.8)$$

Para el ejemplo de Bump, el error estándar de la estimación es

$$\begin{aligned} s_{y \cdot x} &= \sqrt{\frac{1,488 - (32.14)(112) - (-14.54)(149.3)}{10 - 2}} \\ &= \sqrt{\frac{59.14}{8}} = \sqrt{7.39} = 2.72 \end{aligned}$$

Con los valores de $\hat{Y}$ en el rango 3-18 (véase la figura 6-2), $s_{y \cdot x}$ es moderadamente grande e indica que una cantidad apreciable de la variación en Y (galones vendidos) no se explica por X (precio). Investigaremos más adelante esta afirmación, en la sección sobre el coeficiente de determinación.

PRONÓSTICO DE Y

Luego, la línea de regresión ajustada puede usarse para estimar el valor de Y para un valor dado de X . Si queremos obtener un *pronóstico puntual* o un pronóstico para un valor dado de X , simplemente evaluamos la función de regresión estimada para X .

Ejemplo 6.3

Suponga que el señor Bump desea pronosticar la cantidad de leche vendida si el precio se fijara en \$1.63. De acuerdo con la ecuación 6.6, el pronóstico es

$$\begin{aligned} \hat{Y} &= 32.14 - 14.54X \\ \hat{Y} &= 32.14 - 14.54(1.63) = 8.440 \end{aligned}$$

o 8,440 galones. Observe que este pronóstico es un valor de $\hat{Y}$; es decir, el pronóstico es la coordenada Y del punto sobre la línea de regresión ajustada donde $X = 1.63$.

Por supuesto, el señor Bump se da cuenta de que es improbable que los valores reales de Y correspondientes a las posiciones de las X se ubiquen exactamente sobre la línea de regresión. De hecho, estarán distribuidos a uno y otro lado de la línea conforme a la medición $s_{y \cdot x}$. Más aún, la línea de regresión (ajustada) de la muestra es una estimación de la línea de regresión de la población basada en una muestra de 10 puntos de datos. Otras muestras aleatorias de 10 producirían diferentes líneas de regresión ajustada, en forma similar al caso en el que muchas muestras extraídas de la misma población tienen diferentes medias muestrales.

Entonces, existen dos fuentes de incertidumbre asociadas con un pronóstico puntual generado por una ecuación de regresión ajustada:

1. La incertidumbre que se debe a la dispersión de los puntos de datos alrededor de la línea de regresión de la muestra.
2. La incertidumbre que se debe a la dispersión de la línea de la regresión de la muestra alrededor de la línea de regresión de la población.

³Si todos los puntos de datos se localizan exactamente sobre la línea ajustada, $Y = \hat{Y}$ para toda X y $s_{y \cdot x} = 0$.

Es posible construir un *intervalo de predicción* de Y que tome en cuenta estas dos fuentes de incertidumbre.

El *error estándar del pronóstico*, s_f , mide la variabilidad de la Y pronosticada en relación con el valor real de Y para un valor dado de X .

El error estándar del pronóstico es

$$s_f = \sqrt{s_{y \cdot x}^2 + s_{y \cdot x}^2 \left(\frac{1}{n} + \frac{(X - \bar{X})^2}{\sum (X - \bar{X})^2} \right)}$$

$$s_f = s_{y \cdot x} \sqrt{1 + \frac{1}{n} + \frac{(X - \bar{X})^2}{\sum (X - \bar{X})^2}} \quad (6.9)$$

El primer término debajo del primer radical en la ecuación 6.9, $s_{y \cdot x}^2$, mide la dispersión de los puntos de datos alrededor de la línea de regresión de la muestra (primera fuente de incertidumbre). El segundo término debajo del radical mide la dispersión de la línea de regresión de la muestra alrededor de la línea de regresión de la población (segunda fuente de incertidumbre). Advierta que el error estándar del pronóstico depende de X , el valor de X para el cual se desea un pronóstico de Y . También, observe que s_f es el más pequeño cuando $X = \bar{X}$, puesto que el numerador del tercer término debajo del radical en la ecuación 6.9 (abajo) será $(\bar{X} - \bar{X})^2 = 0$.⁴ Si todo permanece igual, cuanto más lejos está X de $\bar{X}$, más grande es el error estándar del pronóstico.

Si el modelo estadístico de regresión lineal simple es el adecuado, un intervalo de predicción de Y está dado por

$$\hat{Y} \pm ts_f \quad (6.10)$$

donde t es un punto porcentual de la distribución t de Student con $df = n - 2$. Si el tamaño de la muestra es grande ($n \geq 30$), el punto porcentual t puede sustituirse por el correspondiente punto porcentual Z de la distribución normal estándar. Por ejemplo, en esencia, un intervalo de predicción del 95% para una muestra grande para Y es

$$\hat{Y} \pm 2s_f \quad (6.11)$$

Ejemplo 6.4

Gráficamente, en el caso que analiza el señor Bump, el intervalo de predicción del 95% para Y con varios valores de X se vería como el de la figura 6-4.

Al usar los resultados de la tabla 6-3 y la ecuación 6.9 con $\bar{X} = 1.44$, el error estándar del pronóstico para $X = 1.63$ es

$$s_f = 2.72 \sqrt{1 + \frac{1}{10} + \frac{(1.63 - 1.44)^2}{.824}} = 2.72(1.069) = 2.91$$

A partir del ejemplo 6.3, $\hat{Y} = 8.440$ cuando $X = 1.63$, y usando la ecuación 6.10, un intervalo de predicción del 95% para Y es

$$\hat{Y} \pm ts_f = 8.44 \pm 2.306(2.91) = 8.44 \pm 6.71$$

⁴Para la opción $X = \bar{X}$, el pronóstico de Y es $\hat{Y} = \bar{Y}$.




FIGURA 6-4 Intervalo de predicción de los datos del señor Bump para el ejemplo 6.4

TABLA 6-3 Cálculo de $\Sigma(X - \bar{X})^2$ para el ejemplo 6.4

X	$(X - \bar{X})^2$
1.30	.0196
2.00	.3136
1.70	.0676
1.50	.0036
1.60	.0256
1.20	.0576
1.60	.0256
1.40	.0016
1.00	.1936
1.10	.1156
$\Sigma(X - \bar{X})^2 = .8240$	

o (1.73, 15.15); es decir, de 1,730 a 15,150 galones. Aquí, $2.306 = t_{0.025}$ es el punto que deja un área de 2.5% a la derecha de la distribución t con 8 grados de libertad $df = 8$.

El intervalo de predicción es muy extenso —tanto, que prácticamente carece de valor para pronosticar Y — a causa del reducido tamaño de la muestra y del valor relativamente grande de s_f . La cantidad de incertidumbre reflejada por el intervalo de predicción tan grande no es evidente en el pronóstico puntual calculado a partir de la función de regresión ajustada. La ventaja principal de la estimación del intervalo es que da cuenta explícitamente de la incertidumbre asociada con el pronóstico.

En general, es peligroso utilizar la función de regresión ajustada para predecir los valores de Y más allá del rango de los datos disponibles. El señor Bump tiene justificación al tratar de pronosticar Y cuando $X = 1.63$ porque algunos de los valores originales de X están cercanos a 1.63. Por otro lado, tal vez no sería conveniente pronosticar Y cuando $X = 3.00$. No se han recopilado valores de X tan grandes y, por esa razón, cualquier pronóstico que implique valores de X como éstos sería muy sospechoso.⁵ Para calcular la cantidad de leche vendida cuando el precio por galón es de \$3.00, el señor Bump tiene que suponer que el modelo lineal sigue siendo válido. Tal vez tenga una buena razón para hacer esta suposición, pero no tiene evidencia directa para apoyarla.

⁵Más aún, el error estándar del pronóstico sería grande, puesto que la cifra $(X - \bar{X})^2$ sería relativamente grande.

Resulta útil terminar esta sección revisando los supuestos subyacentes del modelo estadístico de regresión lineal.

1. *Para un valor dado de X , la población de los valores de Y está normalmente distribuida alrededor de la línea de regresión de la población.* Esta condición se evidencia en la figura 6-3. En la práctica, se obtienen resultados razonablemente exactos siempre que los valores de Y estén distribuidos aproximadamente de manera normal.
2. *La dispersión de los puntos de datos de la población alrededor de la línea de regresión de la población permanece constante a lo largo de la línea.* Es decir, la varianza de la población no se hace más grande o más pequeña conforme los valores de los puntos de datos de X se incrementan. Una violación de este supuesto se llama *heteroscedasticidad*; un ejemplo de esta condición y su solución se encuentra en el capítulo 8.
3. *Los términos de error (ϵ) son independientes uno del otro.* Esta suposición implica una muestra aleatoria de datos X - Y . Cuando los puntos de datos X - Y se registran en el tiempo, este supuesto se viola a menudo. En vez de ser independientes, las observaciones consecutivas están *serialmente correlacionadas*. Los métodos para manejar el problema de la correlación serial se estudiarán en el capítulo 8.
4. *Existe una relación lineal entre X y Y en la población.* Existen extensiones de regresiones lineales simples para manejar las relaciones X - Y que no son lineales; algunas de ellas se estudiarán más adelante en este capítulo.


DESCOMPOSICIÓN DE LA VARIANZA

De acuerdo con la ecuación 6.5

$$Y = \hat{Y} + (Y - \hat{Y})$$

o

$$Y = b_0 + b_1X + (Y - b_0 - b_1X)$$



En una situación ideal, en la cual todos los puntos se ubican exactamente sobre la línea ajustada, todos los residuos son cero y los valores de Y están totalmente explicados por la relación lineal con X .

Al restar $\bar{Y}$ de ambos lados de la expresión anterior,

$$(Y - \bar{Y}) = (\hat{Y} - \bar{Y}) + (Y - \hat{Y})$$

Con un poco de álgebra es posible demostrar que la suma de los cuadrados da por resultado:

$$\Sigma(Y - \bar{Y})^2 = \Sigma(\hat{Y} - \bar{Y})^2 + \Sigma(Y - \hat{Y})^2 \quad (6.12)$$

o

$$SST = SSR + SSE$$

donde

$$SST = \Sigma(Y - \bar{Y})^2$$

$$SSR = \Sigma(\hat{Y} - \bar{Y})^2$$

$$SSE = \Sigma(Y - \hat{Y})^2$$

Aquí, SS significa *suma de cuadrados* (del inglés, *sum of squares*) y T , R y E significan *total*, *regresión* y *error*, respectivamente. Estas sumas de cuadrados tienen grados de libertad asociados:

$$df(SST) = n - 1$$

$$df(SSR) = 1$$

$$df(SSE) = n - 2$$

En correspondencia con las sumas de los cuadrados, los grados de libertad están relacionados por

$$n - 1 = 1 + (n - 2) \quad (6.13)$$

Si no existe una relación lineal, Y no depende de X , y la variación de Y queda descrita por la varianza de la muestra:

$$s_y^2 = \frac{1}{n - 1} \sum (Y - \bar{Y})^2$$

Si, por otro lado, Y está relacionada con X , algunas de las diferencias en los valores de Y se deben a esta relación.

La regresión de la suma de los cuadrados, SSR , mide la parte de la variación de Y que se explica por la relación lineal. La suma de los errores al cuadrado, SSE , es la variación restante de Y , o la variación de Y que no se explica por la relación lineal.

Descomposición de la variabilidad

$$\begin{array}{ccccc} SST & = & SSR & + & SSE \\ \text{Variabilidad} & & \text{Variabilidad} & & \text{Residuo o} \\ \text{total de } Y & & \text{explicada por} & & \text{variabilidad} \\ & & \text{la relación lineal} & & \text{no explicada} \end{array}$$

La sumas de los cuadrados asociadas con la descomposición de la variabilidad de Y y sus correspondientes grados de libertad se pueden arreglar como se muestra en la tabla 6-4, que constituye un ejemplo de una *tabla ANOVA* (*analysis of variance*, análisis de varianza).

La columna final de la tabla ANOVA es la columna del cuadrado medio. El *cuadrado medio* de la regresión, MSR , es la suma de los cuadrados de la regresión dividida entre su número de grados de libertad. De forma similar, el error cuadrático medio, MSE , es la suma de los cuadrados de los errores dividida entre su número de grados de libertad.

TABLA 6-4 Tabla ANOVA para la regresión de línea recta

<i>Fuente</i>	<i>Suma de cuadrados</i>	<i>df</i>	<i>Cuadrado medio</i>
Regresión	SSR	1	$MSR = SSR/1$
Error	SSE	$n-2$	$MSE = SSE/(n-2)$
Total	SST	$n-1$	

TABLA 6-5 Residuos de los datos del señor Bump con el factor de predicción $\bar{Y}$ para el ejemplo 6.5

<i>Y real</i>	<i>Y pronosticada ($\bar{Y}$)</i>	<i>Residuo ($Y - \bar{Y}$)</i>	$(Y - \bar{Y})^2$
10	11.2	-1.2	1.44
6	11.2	-5.2	27.04
5	11.2	-6.2	38.44
12	11.2	.8	.64
10	11.2	-1.2	1.44
15	11.2	3.8	14.44
5	11.2	-6.2	38.44
12	11.2	.8	.64
17	11.2	5.8	33.64
20	11.2	8.8	77.44
		Totales	233.60
			0.0

Observe que en la ecuación 6.7 el error cuadrático medio es

$$MSE = \frac{SSE}{n - 2} = \frac{\sum (Y - \hat{Y})^2}{n - 2} = s_{y \cdot x}^2$$

el cuadrado del error estándar de la estimación. Las razones de los cuadrados medios se utilizarán más adelante con otra finalidad en este capítulo.

Ejemplo 6.5

El análisis del señor Bump se inició con el conocimiento tan sólo de 10 cantidades del volumen de ventas semanales (la variable Y). Si no hubiera más información disponible, el señor Bump podría utilizar el promedio muestral, $\bar{Y} = 11.2$, como un factor de predicción de los galones de leche vendidos cada semana. Los errores, o residuos, asociados con este pronóstico son $Y - \bar{Y}$, y la suma de los errores cuadráticos es $\sum (Y - \bar{Y})^2$. Observe que esta última cantidad, $\sum (Y - \bar{Y})^2$, es exactamente SST , la suma total de cuadrados que se introdujo en la ecuación 6.12. Por lo tanto, SST mide la variabilidad de Y alrededor de un factor de predicción que usa sólo los valores Y en sus cálculos.⁶ Los pronósticos ($\bar{Y}$), los residuos ($Y - \bar{Y}$), y la suma total de cuadrados ($SST = \sum (Y - \bar{Y})^2$) se muestran en la tabla 6-5.⁷

El señor Bump también tiene información acerca de una variable X , el precio por galón de leche, que está relacionada con Y , el volumen semanal de leche vendida. (Recuerde el ejemplo 6.1, donde $r = -.86$). Con esta variable adicional, él espera explicar parte de la variación (diferencias) de los valores de Y más allá de lo que explica el factor de predicción, $\bar{Y}$.

En el ejemplo 6.2, la línea ajustada a la gráfica de dispersión de las observaciones X - Y tiene la ecuación $\hat{Y} = 32.14 - 14.54X$. Se puede construir una tabla similar a la tabla 6-5, si se usa $\hat{Y}$ para predecir Y . El resultado es la tabla 6-6.⁸

Una comparación de las tablas 6-5 y 6-6 indica que el uso de $\hat{Y}$ como factor de predicción de Y tiene como resultado residuos generalmente más pequeños (en valor absoluto) y una suma de cuadrados residual (error) considerablemente menor que cuando se usa $\bar{Y}$ como factor de predicción. El uso de la variable relacionada X reduce los errores de predicción o pronóstico. Es decir, el conocimiento de X ayuda a explicar aún más las diferencias en las Y . ¿Qué tanto ayuda X ? La descomposición de la variabilidad ofrece una respuesta a esta pregunta.

⁶Si el análisis se detuviera en este punto, la variabilidad de Y se mediría por la varianza muestral, $s_y^2 = \sum (Y - \bar{Y})^2 / (n - 1)$, en vez de $SST = \sum (Y - \bar{Y})^2$. La varianza muestral es la medida habitual de variabilidad para mediciones de una variable individual.

⁷Los residuos, $Y - \bar{Y}$, siempre suman cero porque el promedio $\bar{Y}$ es el centro matemático de los valores de Y .

⁸Si se incluye un término de intersección en la ecuación de regresión, la suma de los residuos $\sum (Y - \hat{Y})$ siempre es cero.

TABLA 6-6 Residuos de los datos del señor Bump con el factor de predicción $\hat{Y}$ para el ejemplo 6.5

X	Y	$Y(\hat{Y})$ pronosticada usando $\hat{Y} = 32.14 - 14.54X$	Residual ($Y - \hat{Y}$)	($Y - \hat{Y}$) ²
1.30	10	13.238	-3.238	10.48
2.00	6	3.060	2.940	8.64
1.70	5	7.422	-2.422	5.87
1.50	12	10.330	1.670	2.79
1.60	10	8.876	1.124	1.26
1.20	15	14.692	.308	.09
1.60	5	8.876	-3.876	15.02
1.40	12	11.784	.216	.05
1.00	17	17.600	-.600	.36
1.10	20	16.146	3.854	14.85
			Totales 0.000	59.41

De acuerdo con las tablas 6-5 y 6-6 y la ecuación 6-12,

$$SST = \Sigma(Y - \bar{Y})^2 = 233.60$$

$$SSE = \Sigma(Y - \hat{Y})^2 = 59.41$$

y, en consecuencia,

$$SSR = \Sigma(\hat{Y} - \bar{Y})^2 = 233.60 - 59.41 = 174.19$$

La descomposición de la variabilidad es

SST	=	SSR	+	SSE
233.60	=	174.19	+	59.41
Variación total		Variación explicada		Variación no explicada

De la variabilidad restante después del pronóstico de Y con $\bar{Y}$, el señor Bump ve que una proporción

$$\frac{SSR}{SST} = \frac{174.19}{233.60} = .75$$

de ella ha sido explicada por la relación de Y con X . Una proporción, $1 - .75 = .25$, de la variación de Y con respecto a $\bar{Y}$ permanece sin explicación. Desde esta perspectiva, el conocimiento de la variable relacionada X da como resultado mejores predicciones de Y de las que pueden obtenerse a partir de $\bar{Y}$, una cantidad que no depende de X .

La descomposición de la variabilidad de los datos del señor Bump puede obtenerse a partir del análisis de una tabla de varianza, como se demuestra en el siguiente ejemplo.

Ejemplo 6.6

El señor Bump construye una tabla ANOVA para sus datos usando el formato de la tabla 6-4 y los cálculos de las sumas de los cuadrados del ejemplo 6.5, como se indica en la tabla 6-7.

La descomposición de la variabilidad se presenta claramente en la columna de la suma de cuadrados. Observe que, dentro del redondeo del error, $MSE = 7.43 = (2.72)^2 = s_{y \cdot x}^2$.

TABLA 6-7 Tabla ANOVA de los datos del señor Bump para el ejemplo 6.6

<i>Fuente</i>	<i>Suma de cuadrados</i>	<i>df</i>	<i>Cuadrado medio</i>
Regresión	174.19	1	174.19
Error	59.41	8	7.43
Total	233.60	9	

COEFICIENTE DE DETERMINACIÓN

La identidad

$$(Y - \bar{Y}) = (\hat{Y} - \bar{Y}) + (Y - \hat{Y})$$

conduce a la descomposición de la varianza dada por la ecuación 6.12 y se muestra gráficamente para la línea de regresión ajustada del señor Bump y un punto de datos hipotético en la figura 6-5.

Si Y no dependiera de X , el señor Bump esperaría que Y estuviera cerca de $\bar{Y}$ y que la desviación $Y - \bar{Y}$ sencillamente reflejara la variación aleatoria. Sin embargo, Y depende de X de una manera sugerida por la función de regresión ajustada. En la figura, el valor observado X es mayor que $\bar{X}$, y se sabe que X y Y tienen una correlación negativa bastante fuerte ($r = -.86$). De la distancia vertical total $Y - \bar{Y}$, la cantidad $\hat{Y} - \bar{Y}$ es “explicada”, por lo tanto, por la variación de X , mientras que la distancia vertical restante, $Y - \hat{Y}$, “no se explica” por el movimiento de X .

Como se indicó en la sección anterior, SST mide la variación total alrededor de $\bar{Y}$, y la parte del total que se explica por la variación de X es SSR . La variación restante o no explicada es el SSE . La razón entre la variación explicada y la variación total se llama *coeficiente de determinación* de la muestra y se representa por r^2 .




FIGURA 6-5 Variación explicada y variación no explicada en los datos del señor Bump

$$\begin{aligned}
 r^2 &= \frac{\text{Variación explicada}}{\text{Variación total}} = \frac{SSR}{SST} = \frac{\sum(\hat{Y} - \bar{Y})^2}{\sum(Y - \bar{Y})^2} \\
 &= 1 - \frac{\text{Variación no explicada}}{\text{Variación total}} = 1 - \frac{SSE}{SST} = 1 - \frac{\sum(Y - \hat{Y})^2}{\sum(Y - \bar{Y})^2} \quad (6.14)
 \end{aligned}$$

El *coeficiente de determinación* mide el porcentaje de variabilidad de Y que se puede explicar a través del conocimiento de la variabilidad (diferencias) de la variable independiente X .

Ejemplo 6.7

El coeficiente de determinación, r^2 , para los datos del señor Bump se calculó en el ejemplo 6.5, aunque no se le llamó así. El coeficiente de determinación también se encuentra fácilmente disponible en la tabla ANOVA, es decir, la tabla 6-7, del ejemplo 6.6. Recuerde que

$$SST = \sum(Y - \bar{Y})^2 = 233.60$$

$$SSR = \sum(\hat{Y} - \bar{Y})^2 = 174.19$$

$$SSE = \sum(Y - \hat{Y})^2 = 59.41$$

y

$$r^2 = \frac{174.19}{233.60} = .746$$

De forma alternativa, r^2 puede calcularse como

$$r^2 = 1 - \frac{59.41}{233.60} = 1 - .254 = .746$$

Alrededor del 75% de la variabilidad en galones de leche vendida (Y) puede explicarse por las diferencias en el precio por galón (X). Alrededor del 25% de la variabilidad en la cantidad de leche vendida *no puede* explicarse por el precio. Esta porción de la variabilidad debe explicarse por factores que no se consideraron en este análisis de regresión (por ejemplo, la cantidad de publicidad, la disponibilidad de productos sustitutos o la calidad de la leche).

Para la regresión lineal, r^2 es el cuadrado de r , el coeficiente de correlación.

$$\text{Coeficiente de determinación} = (\text{Coeficiente de correlación})^2$$

$$r^2 = (r)^2$$


De manera que, para los datos del señor Bump e ignorando el redondeo del error,

$$.746 = (-.863)^2$$

¿Por qué es necesario identificar específicamente tanto r como r^2 en un análisis de regresión? La respuesta es que expresan información diferente.

El coeficiente de correlación revela la fortaleza y dirección de la relación lineal. En el caso de los datos que recopiló el señor Bump, existe una relación negativa ($r = -.86$). En otros casos, el valor de r podría estar indicando una relación positiva. Como veremos en el siguiente capítulo, es útil identificar la naturaleza de las relaciones que existen entre ciertos pares de variables cuando se está manejando un gran conjunto de variables. Observe que, cuando el coeficiente de correlación está elevado al cuadrado, el valor siempre es positivo, de manera que la naturaleza de la relación se pierde.

El coeficiente de determinación, r^2 , mide la fuerza de la relación entre Y y X de un modo diferente a como lo hace r . El valor de r^2 mide el *porcentaje* de variabilidad de Y que se explica

FIGURA 6-6 Valores extremos de r^2

por las diferencias de X . Esta útil interpretación se puede generalizar a las relaciones entre Y y más de una X .

La figura 6-6 ilustra los dos casos extremos para r^2 , $r^2 = 0$ y $r^2 = 1$. En el primer caso, *nada* de variabilidad de Y se explica por X : el diagrama de dispersión sugiere que no existe una relación lineal entre X y Y . Cuando $r^2 = 1$, *toda* la variabilidad de Y se explica cuando se conoce X : todos los puntos de datos muestrales se ubican sobre la línea de regresión ajustada.

PRUEBA DE HIPÓTESIS

La línea de regresión ajustada se genera por los valores X - Y de la *muestra*. El modelo estadístico de regresión lineal simple sugiere que la relación lineal entre Y y X se mantiene para *todas* las opciones de pares X - Y . Es decir, existe una relación verdadera entre X y Y de la forma $\mu_y = \beta_0 + \beta_1 X$. Dada la evidencia muestral, ¿podemos concluir que la relación verdadera se mantiene para todas las X y Y ?

Considere la hipótesis

$$H_0: \beta_1 = 0$$

donde β_1 es la pendiente de la línea de regresión de la población. Advierta que, si esta hipótesis es verdadera, no existe relación entre Y y X en la población. Por otro lado, si no se rechaza H_0 , significa que a pesar del hecho de que la muestra ha producido una línea ajustada con un valor diferente de cero para b_1 , debemos concluir que no hay suficiente evidencia para indicar que Y esté relacionada con X . Es decir, no podemos excluir la posibilidad de que la línea de regresión de la población sea plana (horizontal).⁹

¿Cómo es posible que β_1 sea cero mientras b_1 es diferente de cero? Considere la figura 6-7 donde se presenta una población de puntos de datos de los cuales se selecciona una muestra de cinco datos (los puntos de datos muestrales se indican mediante $\times$). Como lo sugiere el diagrama de dispersión, si se seleccionan suficientes puntos de datos muestrales, se hará obvio que la población de puntos de datos tiene una línea de regresión con pendiente cero. Sin embargo, los cinco puntos de datos seleccionados de manera aleatoria se ubican bastante cerca de una línea de regresión con tendencia ascendente. A partir de esta evidencia se podría concluir erróneamente que X y Y están relacionadas linealmente de manera positiva. Sin embargo, si se prueba la hipótesis $\beta_1 = 0$ con los datos muestrales, quizás no pueda rechazarla el encargado de efectuar el pronóstico.

⁹Una línea de regresión plana de la población (esto es, $\beta_1 = 0$) también es equivalente al enunciado $H_0: \rho = 0$, donde ρ es el coeficiente de correlación de la población.




FIGURA 6-7 Población y puntos de datos muestrales

Si $H_0: \beta_1 = 0$ es verdadera, el estadístico de prueba t con valor de $t = \frac{b_1}{s_{b_1}}$ tiene una distribución t con $df = n - 2$, donde S_{b_1} es la desviación estándar estimada (o error estándar) de b_1 , dado por $s_{b_1} = s_{y \cdot x} / \sqrt{\sum (X - \bar{X})^2}$.

Este resultado ofrece un modo de probar $H_0: \beta_1 = 0$, como se ilustra en el siguiente ejemplo.

Ejemplo 6.8

Al señor Bump le gustaría probar

$$H_0: \beta_1 = 0 \text{ (no hay relación lineal)}$$

contra

$$H_1: \beta_1 \neq 0 \text{ (una relación lineal con pendiente diferente de cero)}$$

Él calcula¹⁰

$$s_{b_1} = s_{y \cdot x} / \sqrt{\sum (X - \bar{X})^2} = 2.72 / \sqrt{.824} = 3.00$$

y formula la razón (estadístico de prueba)

$$t = \frac{b_1}{s_{b_1}} = \frac{-14.54}{3.00} = -4.8$$

¿El valor $t = -4.8$ es un resultado inusual si H_0 es verdadera? El señor Bump verifica t en la tabla para $n - 2 = 8$ grados de libertad y obtiene

$$t_{.005} = 3.355$$

$$t_{.025} = 2.306$$

Puesto que $|t| = 4.8 > 3.355$, el señor Bump rechaza H_0 para el nivel de significancia del 1%. Concluye que su regresión es significativa, puesto que $t = -4.8$ es sumamente improbable si H_0 es verdadera. Un valor t de esta magnitud se presentará menos de una vez en 100 si no existiera una relación lineal entre Y y X .

¹⁰Los valores usados en los siguientes cálculos se obtuvieron con anterioridad en este capítulo.

Para tamaños muestrales muy grandes, es posible rechazar H_0 y concluir que existe una relación lineal entre X y Y aun cuando r^2 sea pequeña, digamos, del 10%. De forma similar, para muestras pequeñas y una r^2 muy grande —digamos, del 95%— es posible concluir que la regresión es significativa. Una r^2 pequeña significa que es improbable que la ecuación de regresión ajustada tenga mucho poder de predicción. Por otro lado, una r^2 grande con un tamaño muestral muy pequeño podría dejar incómodo al analista y requerir mayor evidencia muestral antes de que la función ajustada se use para pronosticar. Puede haber una diferencia entre la significancia estadística y la significancia práctica. A veces, es necesario un buen juicio aparejado con conocimiento del tema para determinar si una función de regresión ajustada es una herramienta útil para pronosticar.

Una prueba alternativa de $H_0: \beta_1 = 0$ está disponible en la tabla ANOVA.

Si los supuestos del modelo estadístico de la regresión lineal son adecuados y si la hipótesis nula $H_0: \beta_1 = 0$ es verdadera, la razón

$$F = \frac{\text{Cuadrado medio de la regresión}}{\text{Error cuadrático medio}} = \frac{MSR}{MSE} \quad (6.15)$$

tiene una distribución F con $df = 1, n - 2$. Cuando H_0 es verdadera, tanto el MSR como el MSE son estimadores de σ^2 , la varianza del término de error (ε) en el modelo estadístico de regresión de línea recta. Por otro lado, si $H_0: \beta_1 \neq 0$ es verdadera, el numerador F en la razón tiende a ser mayor que el denominador. De esta forma, razones grandes de F son congruentes con la hipótesis alternativa.

En el modelo de regresión de línea recta, la prueba de la hipótesis $H_0: \beta_1 = 0$ contra $H_0: \beta_1 \neq 0$ puede apoyarse en la razón $F = \frac{MSR}{MSE}$ con $df = 1, n - 2$. En el nivel α , la región de rechazo es $F > F_\alpha$.

Como se discutirá en el próximo capítulo, la prueba F se puede extender para verificar la significancia de los modelos de regresión con más de una variable independiente.

Ejemplo 6.9

La tabla 6-7 es la tabla ANOVA para los datos del señor Bump. En esta tabla,

$$F = \frac{MSR}{MSE} = \frac{174.19}{7.43} = 23.4$$

y con $\delta_1 = 1$ y $\delta_2 = 8$ grados de libertad

$$F_{.05} = 5.32$$

$$F_{.01} = 11.26$$

Puesto que $F = 23.4 > 11.26$, $H_0: \beta_1 = 0$ se rechaza con un nivel del 1%. La regresión es significativa.

No es accidental que los resultados de la prueba F sean congruentes con los resultados de la prueba t del ejemplo 6.8. De hecho, dentro del error de redondeo,

$$F = 23.4 = (-4.8)^2 = t^2$$

Más aún,

$$F_{.01} = 11.26 = (3.355)^2 = (t_{.005})^2$$

Así, para un nivel de significancia dado, la prueba t rechaza $H_0: \beta_1 = 0$ siempre que la prueba F la rechace y viceversa. Esta relación entre las pruebas t y F se cumple sólo para el modelo de regresión de línea recta.

El estadístico F también puede expresarse en términos del coeficiente de determinación, r^2 .

$$F = \frac{r^2(n - 2)}{1 - r^2} \quad (6.16)$$

Si todo lo demás permanece igual, el valor de F se incrementa conforme r^2 aumenta. Cuanta mayor sea la cantidad de variación de Y que tenga explicación mediante la función de regresión ajustada, más probabilidad hay de que la prueba F considere a la regresión como significativa.

ANÁLISIS DE RESIDUOS

El ajuste de un modelo por los mínimos cuadrados, la construcción de intervalos de predicción y la prueba de hipótesis no completan un estudio de regresión. Estos pasos son sólo la mitad de la historia: las inferencias que pueden hacerse *cuando el modelo supuesto es adecuado*. En la mayoría de los estudios no resulta obvio cuál es el modelo correcto.

Las inferencias suelen ser muy engañosas si los supuestos realizados en la formulación del modelo son extremadamente incompatibles con los datos. Es esencial verificar con cuidado los datos para obtener indicios de cualquier violación de los supuestos. Recuerde que los supuestos del modelo de regresión de línea recta son los siguientes:

1. La relación entre las variables es lineal.
2. Los errores son independientes.
3. Los errores tienen una varianza constante.
4. Los errores están distribuidos normalmente.

La información sobre la variación que no puede explicarse mediante la función de regresión ajustada está contenida en los residuos, $e = Y - \hat{Y}$. Para calificar los méritos de un modelo tentativo, podemos examinar los residuos graficándolos de varias maneras.

1. Grafique un histograma de los residuos.
2. Grafique los residuos contra los valores ajustados.
3. Grafique los residuos contra la variable explicativa.
4. Grafique los residuos en el tiempo si los datos son cronológicos.

Un histograma de los residuos permite verificar el supuesto de normalidad. Comúnmente, las desviaciones moderadas de una curva en forma de campana no afectan las conclusiones de las pruebas o los intervalos de predicción basados en la distribución t , particularmente si el conjunto de datos es grande. Por lo regular, una violación del supuesto de normalidad no es tan seria como una violación de cualquier otro de los supuestos.

Si una gráfica de los residuos contra los valores ajustados indica que la naturaleza general de la relación entre Y y X forma una curva en vez de una línea recta, una transformación conveniente de los datos puede reducir una relación no lineal a una que sea aproximadamente lineal. Examinaremos las transformaciones de las variables en una sección posterior de este capítulo.

Una transformación también ayuda a estabilizar la varianza. La figura 6-8 presenta una gráfica residual que indica que la dispersión de los residuos se incrementa conforme la magnitud de los valores ajustados aumenta. Es decir, la variabilidad de los puntos de datos alrededor de la línea de los mínimos cuadrados es más grande para valores ajustados de Y grandes que para valores pequeños. Esto implica que tal vez no se cumpla el supuesto de la varianza constante. En esta situación, relacionar el logaritmo de Y con X puede generar una relación residual que sea más congruente con una varianza constante.

El supuesto de independencia es el más importante. La falta de independencia podría distorsionar en forma drástica las conclusiones obtenidas de las pruebas t . El supuesto de independencia es particularmente riesgoso en los datos de las series de tiempo, que son frecuentes en problemas de pronósticos económicos y de negocios.




FIGURA 6-8 Una gráfica residual con dispersión creciente

Para los residuos de las series de tiempo —es decir, para los residuos que se producen al usar métodos de regresión con datos ordenados en el tiempo— la independencia puede verificarse con una gráfica de los residuos en el tiempo. No debe haber patrones sistemáticos, tales como una sucesión de valores altos seguida de una sucesión de valores bajos. Además, las autocorrelaciones muestrales de los residuos

$$r_k(e) = \frac{\sum_{t=k+1}^n e_t e_{t-k}}{\sum_{t=1}^n e_t^2} \quad k = 1, 2, \dots, K \quad (6.17)$$

donde n es el número de residuos y K comúnmente es $n/4$, deberían ser todas pequeñas. En particular, la independencia existe si los coeficientes de autocorrelación residual se encuentran todos en el intervalo $0 \pm 2/\sqrt{n}$ para todos los retrasos de tiempo k .

Ejemplo 6.10

Usando los valores ajustados y los residuos presentados en la tabla 6-6, el señor Bump construyó un histograma de los residuos y una gráfica de los residuos contra los valores ajustados. Éstos y otros resultados se presentan en la figura 6-9.

El histograma está centrado en cero y, si bien es simétrico, no parece tener forma de campana. Sin embargo, con sólo 10 observaciones, un histograma como el ilustrado en la figura 6-9 no es raro para datos con distribución normal. El supuesto de normalidad parece razonable.

Los puntos en la gráfica de probabilidad normal de la figura 6-9 se ubican muy cerca de la línea recta. Como señalamos en el capítulo 2, este comportamiento como línea recta sugiere un buen ajuste entre los datos (en este caso, los residuos) y una distribución normal. La gráfica de probabilidad normal sugiere que no hay razón para dudar del supuesto de normalidad.

La segunda gráfica de la primera fila en la figura 6-9 también se ve bien. Cuando se grafican los residuos contra los valores ajustados, la dispersión alrededor del cero en la dirección vertical debe ser aproximadamente igual para todos los valores a lo largo del eje horizontal. Es decir, las magnitudes de los residuos para valores ajustados pequeños deben ser aproximadamente iguales que las magnitudes de los residuos para valores ajustados intermedios y aproximadamente iguales que las magnitudes de los residuos para valores ajustados grandes. Este comportamiento ideal sugiere dos cosas: **1.** La relación subyacente entre Y y X es lineal, y **2.** la variabilidad del error es constante (las Y para diferentes valores de X tienen la misma dispersión alrededor de la línea de regresión).

El señor Bump está contento de que la gráfica de los residuos contra los valores ajustados no esté “arqueada” —por ejemplo, con una sucesión de residuos positivos seguida de una sucesión de residuos negativos, seguida, a la vez, de una sucesión de residuos positivos. Este comportamiento




FIGURA 6-9 Gráficas residuales de los datos del señor Bump para el ejemplo 6.10

sugeriría una relación no lineal entre Y y X . Él también está complacido porque su gráfica no tiene la forma cónica como la de la gráfica de la figura 6-8, lo cual indica variabilidad inconstante (creciente).

Si bien las Y representan ventas semanales de leche, las semanas fueron seleccionadas al azar y no estaban ordenadas en el tiempo. Por consiguiente, la graficación de los residuos en el tiempo o el cálculo de las autocorrelaciones residuales no eran apropiados.

El señor Bump está satisfecho con su análisis residual. Considera que su modelo de regresión de línea recta describe adecuadamente la relación entre el volumen de las ventas semanales y el precio.

RESULTADO DE COMPUTADORA

El problema del análisis de regresión del señor Bump (con los datos de la tabla 6-1) se corre en Minitab (para instrucciones específicas, véase la sección de aplicaciones de Minitab al final del capítulo), y la salida se presenta en la tabla 6-8.

Para explicar la terminología usada en el resultado de la computadora, se presentan las definiciones y los cálculos en la siguiente lista. Estas definiciones y cálculos se teclearon para obtener la tabla 6-8.

1. Correlación = $-.86$. El coeficiente de correlación (r) de la muestra indica la relación entre X y Y , es decir, precio y ventas, respectivamente.
2. El coeficiente de regresión (Coef) = -14.54 . Este valor (b_1) es el cambio de Y (las ventas) cuando X (el precio) se incrementa en una unidad. Cuando el precio aumenta \$1, las ventas estimadas disminuyen en 14,539 unidades.

TABLA 6-8 Resultado de Minitab para los datos del señor Bump

Correlations: Sales, Price

Pearson correlation of Sales (Y) and Price (X) = -0.863 (1)

Regression Analysis: Sales versus Price

The regression equation is

Sales (Y) = 32.1 - 14.5 Price (X) (5) and (2)

Predictor	Coef	SE Coef	T	P
Constant	32.136 (5)	4.409	7.29	0.000
Price (X)	-14.539 (2)	3.002 (3)	-4.84 (4)	0.001 (7)

S = 2.72545 (6) R-Sq = 74.6% (8) R-Sq(adj) = 71.4% (9)

Analysis of Variance

Source	DF	SS	MS	F	P
Regression	1	174.18	174.18	23.45 (12)	0.001
Residual Error	8	59.42 (10)	7.43 (6)		
Total	9	233.60 (11)			

3. El error estándar del coeficiente de regresión (SE Coef) = 3.0. Este valor es la estimación de la desviación estándar del valor del coeficiente de regresión (b_1).

$$s_{b_1} = s_{y \cdot x} / \sqrt{\sum (X - \bar{X})^2} = 2.725 / \sqrt{.824} = 2.725 / .908 = 3.002$$

4. Se calcula el valor de $t = -4.84$. El valor de t calculado se utiliza para probar si el coeficiente de regresión de la población (β_1) es significativamente diferente de cero.

$$t = \frac{b_1}{s_{b_1}} = \frac{-14.54}{3.002} = -4.84$$

5. La constante = 32.14. Este valor es la intersección con Y (b_0). Por lo tanto, la ecuación completa de regresión es

$$\hat{Y} = 32.14 - 14.54X$$

6. El error estándar de la estimación = 2.725. El error estándar de la estimación indica que los valores de Y caen generalmente a una distancia de unas 2.725 unidades de la línea de regresión.

$$s_{y \cdot x} = \sqrt{\frac{\sum (Y - \hat{Y})^2}{n - 2}} = \sqrt{\frac{SSE}{n - 2}} = \sqrt{MSE} = \sqrt{7.43} = 2.725$$

7. El valor p , .001, es la probabilidad de obtener un valor t tan grande como $|t| = |-4.84| = 4.84$ por azar si $H_0: \beta_1 = 0$ es verdadera. Puesto que el valor p es extremadamente pequeño, se concluye que el coeficiente de la pendiente de la regresión es significativamente diferente de 0.

8. $r^2 = (R - Sq) = .746$. La línea de regresión ajustada explica el 74.6% de la varianza en el volumen de las ventas.

$$r^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} = 1 - \frac{59.42}{233.60} = 1 - .254 = .746$$

9. La r^2 ajustada ($R-Sq(adj)$) = .714. Se ajusta la r^2 para los grados de libertad adecuados.

$$\begin{aligned}\bar{r}^2 &= 1 - \frac{\Sigma(Y - \hat{Y})^2/(n - 2)}{\Sigma(Y - \bar{Y})^2/(n - 1)} = 1 - \frac{SSE/(n - 2)}{SST/(n - 1)} = 1 - \frac{59.42/8}{233.60/9} \\ &= 1 - \frac{7.428}{25.956} = 1 - .286 = .714\end{aligned}$$

10. La suma residual de cuadrados (Error residual) = 59.42. La suma de residuos al cuadrado es la suma de las diferencias al cuadrado entre las Y reales y las Y pronosticadas ($\hat{Y}$'s).

$$SSE = \Sigma(Y - \hat{Y})^2 = 59.42$$

11. Suma total de cuadrados = 233.60. Este valor es la suma de las desviaciones al cuadrado de las Y con respecto a su media.

$$SST = \Sigma(Y - \bar{Y})^2 = 233.60$$

12. El análisis de la varianza y la razón F : La razón F ($23.45 = 174.18/7.43$) en esta tabla ANOVA prueba la hipótesis nula de que la regresión no es significativa; es decir, $H_0: \beta_1 = 0$. Un valor F grande permitirá el rechazo de esta hipótesis, sugiriendo una regresión *significativa*. El valor F (23.45) aumenta conforme una porción más grande de la suma total de las desviaciones al cuadrado (SST) se explica por la regresión. En este caso, el valor tabulado de F ($df = 1, 8; \alpha = .01$) es 11.26. La hipótesis de regresión no significativa con un nivel de significancia del 1% se rechaza, puesto que $F = 23.45 > 11.26$. (Véase el ejemplo 6.9).

TRANSFORMACIONES DE VARIABLES

Si bien el modelo de regresión lineal simple supone una relación lineal entre X y Y , en general, un modelo de regresión lineal se refiere a un modelo que es lineal en la incógnita β . Siempre que la función de regresión sea lineal en las β (por ejemplo, no está presente), las variables de predicción (las X) pueden adoptar varias formas y entonces la metodología de regresión estándar sigue siendo adecuada. Es posible utilizar los modelos de regresión para modelar relaciones complejas entre Y y X (o varias X), o bien, para modelar una relación lineal entre Y y alguna función (transformación) de X .

Cuando un diagrama de dispersión indica que existe una relación no lineal entre Y y X , existen dos métodos básicos para tratar este caso. El primero consiste en ajustar los datos a una función de regresión que se grafique como una curva y utilizar la función ajustada para elaborar el pronóstico. El segundo método implica la transformación de la variable X a otra forma, de manera que la relación resultante con Y sea lineal.

Cuatro de las transformaciones más comunes (funciones) que se emplean para generar nuevas variables de predicción son el recíproco, el logaritmo, la raíz cuadrada y el cuadrado.

$$\frac{1}{X}, \log X, \sqrt{X}, X^2$$

Cuando cada una de estas variables se grafica contra Y , se espera que la relación no lineal entre Y y X se convierta en una relación lineal entre Y y una de las X transformadas. Si es así, Y y esta nueva variable pueden tratarse con el modelo lineal explicado en este capítulo, incluyendo el cálculo del coeficiente de correlación y la ecuación de regresión ajustada.

En el siguiente ejemplo se usa Minitab (véase la sección de aplicaciones de Minitab al final del capítulo) para graficar una relación simple entre X y Y que parece ser no lineal. Entonces se dan instrucciones al programa para que calcule las cuatro transformaciones descritas anteriormente. Luego, estas variables se grafican contra Y para generar los puntos de datos que se indican.

Ejemplo 6.11



Gilbert García posee una cadena de ferreterías en Chicago, Illinois. Él está interesado en predecir sus ventas mensuales usando el conocimiento que tiene acerca de los gastos de publicidad mensual correspondientes. Gil sospecha que las ventas se incrementarán conforme la cantidad gastada en publicidad se incrementa. Sin embargo, también cree que después de cierto punto, las ventas empezarán a incrementarse a un ritmo más lento. Gil siente que, después de gastar cierta cantidad en publicidad, alcanzará un punto donde se obtendrán pocas ventas a partir de gastos posteriores en publicidad.

A partir de los registros de la compañía, Gil seleccionó una muestra aleatoria de datos de 14 meses. Los datos aparecen en la figura 6-10, mientras que el diagrama de dispersión de los datos se presenta en la figura 6-11. Gil advierte que las ventas parecen nivelarse después de que se gasta cierta cantidad en publicidad. Ajusta la ecuación de regresión lineal presentada en la figura 6-12 y se percata de que la ecuación explica el 77.7% de la variabilidad en las ventas.

En la figura 6-13 se observa una gráfica de los residuos contra los valores ajustados de la línea recta ajustada. Esta gráfica indica que una línea recta no describe adecuadamente la relación entre las ventas y los gastos de publicidad. Todos los residuos son negativos para pequeños valores pronosticados, todos son positivos para los valores pronosticados de nivel medio, y todos son negativos otra

	C1	C2	C3	C4	C5	C6	C7	C8	C9	C10
	Sales	Expenditures	LOGX	SQRTX	X*X	1/X				
1	1.1	3.9	1.36098	1.97484	15.21	0.256410				
2	1.7	4.9	1.58924	2.21359	24.01	0.204082				
3	2.6	7.6	2.02815	2.75681	57.76	0.131579				
4	2.4	6.8	1.91692	2.60768	46.24	0.147059				
5	2.3	5.9	1.77495	2.42899	34.81	0.169492				
6	2.9	9.1	2.20827	3.01662	82.81	0.109890				
7	0.4	3.4	1.22378	1.84391	11.56	0.294118				
8	3.2	11.6	2.45101	3.40588	134.56	0.086207				
9	3.3	14.1	2.64617	3.75500	198.81	0.070922				
10	3.1	14.9	2.70136	3.86005	222.01	0.067114				
11	3.2	10.5	2.35138	3.24037	110.25	0.095238				
12	3.0	9.9	2.29253	3.14643	98.01	0.101010				
13	3.7	17.1	2.83908	4.13521	292.41	0.058480				
14	3.3	12.4	2.51770	3.52136	153.76	0.080645				
15										

FIGURA 6-10 Datos para el ejemplo 6.11

**FIGURA 6-11** Diagrama de dispersión para el ejemplo 6.11**FIGURA 6-12** Línea de regresión ajustada para el ejemplo 6.11

vez para valores pronosticados grandes. Los residuos no están distribuidos de manera uniforme alrededor de la línea de regresión estimada. Se ve claramente que una línea recta no refleja la curvatura de los datos.

Luego, Gil considera varias transformaciones de X (véase la figura 6-10). Construye un diagrama de dispersión múltiple con gráficas de las ventas (Y) contra los logaritmos de los gastos en publicidad ($\log X$), ventas (Y) contra las raíces cuadradas de los gastos en publicidad ($\sqrt{X}$), ventas




FIGURA 6-13 Gráfica de residuos contra valores ajustados para la línea recta ajustada del ejemplo 6.11

(Y) contra los gastos en publicidad elevados al cuadrado (X^2) y, finalmente, ventas (Y) contra los recíprocos de los gastos en publicidad ($1/X$). El resultado se presenta en la figura 6-14.

Después de examinar el diagrama de dispersión múltiple, Gil concluye que las relaciones entre las ventas y los logaritmos de gastos en publicidad, las ventas y las raíces cuadradas de gastos en publicidad, y las ventas y los gastos en publicidad elevados al cuadrado muestran todos algún grado de curvatura. Estas relaciones no son lineales. Sin embargo, la relación entre las ventas y los recíprocos de los gastos en publicidad parece ser lineal con una pendiente negativa. Usando Minitab, Gil ajusta un modelo de regresión lineal simple a los datos de las ventas y los recíprocos de los gastos en publicidad. Así, determina la ecuación ajustada $\hat{Y} = 4.29 - 12.7(1/X)$, como se presenta en la tabla 6-9, y ve que r^2 es igual al 98.1%. Un análisis residual indica que este modelo lineal es apropiado.

CURVAS DE CRECIMIENTO

Las curvas de crecimiento se presentaron en el capítulo 5 (véase la figura 5-7) en nuestro estudio para modelar la tendencia en la descomposición de una serie de tiempo. A menudo, la tendencia (cambio a largo plazo) es de interés por sí misma. Un analista, por ejemplo, tal vez esté interesado en la proyección de los costos del uso de la computadora hasta bien entrado el futuro sin considerar la tecnología que podría traer cambios en el costo. Como otro ejemplo, un analista de seguros de vida quizás esté interesado en proyecciones a largo plazo de la expectativa de vida de la población de Estados Unidos sin considerar las condiciones económicas y ambientales que podrían ser responsables de cambios en la expectativa de vida.

Las curvas de crecimiento son relaciones curvilíneas entre la variable de interés y el tiempo. Las curvas de crecimiento se ajustan comúnmente a los datos anuales, puesto que en estos casos se requieren pronósticos a largo plazo.

Aun cuando los pronósticos son probablemente imprecisos cuando los ajustes de las curvas de crecimiento a los datos históricos son extrapolados para predecir el futuro, este método de pronóstico puede ser de gran ayuda para los administradores, puesto que concentra su atención en aspectos a largo plazo de los negocios. Más aún, las curvas de crecimiento indican la tasa anual de crecimiento que debe mantenerse con la finalidad de alcanzar los niveles proyectados




FIGURA 6-14 Diagrama de dispersión de ventas (Y) contra *a)* $\log X$, *b)* raíz cuadrada de X , *c)* X al cuadrado y *d)* recíproco de X

TABLA 6-9 Resultado de Minitab para el ejemplo 6-11

Regression Analysis: Sales versus 1/X

The regression equation is

$$\text{Sales} = 4.29 - 12.7 \, 1/X$$

Predictor	Coef	SE Coef	T	P
Constant	4.28587	0.07695	55.69	0.000
1/X	-12.7132	0.5092	-24.97	0.000

S = 0.134159 R-Sq = 98.1% R-Sq(adj) = 98.0%

Analysis of Variance

Source	DF	SS	MS	F	P
Regression	1	11.221	11.221	623.44	0.000
Residual Error	12	0.216	0.018		
Total	13	11.437			

para el futuro. Esta tasa de crecimiento anual puede o no ser razonable y tal vez sea motivo de debate en una reunión de ejecutivos o en un “comité de expertos”.

Si una variable medida en el tiempo se incrementa en el mismo *porcentaje* cada periodo, se dice que presenta un *crecimiento exponencial*. Si una variable se incrementa en la misma *cantidad* cada periodo, se dice que registra un *crecimiento lineal*. Algunas veces una transformación simple convierte una variable con crecimiento exponencial en una variable con crecimiento lineal. Si éste es el caso, los métodos de regresión presentados en este capítulo servirán para modelar el crecimiento exponencial.

Por ejemplo, suponga que una variable Y , medida anualmente, sigue la curva de tendencia exponencial (véase la ecuación 5.6).

$$Y = b_0 b_1^t$$

Aquí, $100(b_1 - 1)\%$ es el incremento porcentual anual de Y . Tomando los logaritmos de ambos lados de la ecuación de la tendencia exponencial, tenemos

$$\log Y = \log(b_0 b_1^t) = \log b_0 + t \log b_1 = \tilde{b}_0 + \tilde{b}_1 t$$

Así, $\log Y$ contra el tiempo (t) grafica una línea recta con pendiente $\tilde{b}_1 = \log b_1$ e intersección $\tilde{b}_0 = \log b_0$. $\log Y$ se incrementa una cantidad constante, $\tilde{b}_1$, de un año a otro. Como se ilustra en el siguiente ejemplo, es posible obtener los pronósticos de Y y una estimación de la tasa de crecimiento, b_1 , a partir de la ecuación de la línea recta que relaciona $\log Y$ con t .

Ejemplo 6.12

Jill Johnson, la asistente administrativa de una universidad importante, está contenta con la aprobación de un sistema de inscripciones por Internet para los cursos. Ella recolectó los datos de la tabla 6-10 y ve que el uso del sistema ha crecido de forma increíble. Si la tasa actual de crecimiento continúa, todo el campus estará registrándose por Internet para los cursos dentro de un año y el sistema anterior de inscripciones por teléfono se eliminará por completo.

Los datos de la tabla 6-10 indican los números de estudiantes que usan el sistema de inscripciones por Internet para el periodo de 2002 a 2006. La última columna de la tabla contiene los logaritmos de base 10 de los números de usuarios.


Jill ha tenido alguna experiencia con la regresión lineal simple y se pregunta si este método servirá para pronosticar el número de usuarios en 2007 y para hacer una estimación de la tasa de crecimiento anual. Una gráfica del número de usuarios contra el año (véase la figura 6-15a) rápidamente le sugiere a Jill que un modelo de regresión lineal simple no es adecuado para sus datos. El crecimiento del uso parece ser exponencial, con un incremento porcentual anual de alrededor del 70%. Sin embargo, el aumento en el número de usuarios cada año es completamente diferente. Los incrementos varían en magnitud desde una modesta cifra de 2,500 durante el periodo de 2002 a 2003 a una cifra considerable de 10,000 durante el periodo de 2005 a 2006.

Jill siempre ha sido buena manejando logaritmos y recuerda que un cambio porcentual constante en una variable durante cierto periodo es equivalente a un incremento constante en la magnitud del logaritmo de la variable durante el mismo periodo de tiempo. Con esto en mente, Jill transforma los números de las inscripciones por Internet de los usuarios a los cursos tomando sus logaritmos; luego, grafica los logaritmos (usuarios) contra el año (véase la figura 6-15b).


Como ella sospechaba, cuando los números de los usuarios se transforman usando sus logaritmos, el crecimiento exponencial se convierte en un crecimiento lineal. La curva que representa el crecimiento exponencial en la figura 6-15a se convierte en una línea en la figura 6-15b) gracias a la transformación logarítmica. En la figura 6-15b), el incremento en la magnitud de los logaritmos (usuarios) cada año es aproximadamente el mismo, alrededor de .23 por año. Jill ajusta una línea recta a los datos de la figura 6-15b) con los logaritmos (usuarios) como la variable dependiente Y y el tiempo (t) como la variable independiente. Los resultados se presentan en la figura 6-16.

TABLA 6-10 Datos para el ejemplo 6.12

<i>Año</i>	<i>Tiempo</i>	<i>Usuarios</i>	<i>Log (Usuarios)</i>
2002	1	3,000	3.477
2003	2	5,500	3.740
2004	3	9,000	3.954
2005	4	16,500	4.217
2006	5	26,500	4.423



a)



b)

FIGURA 6-15 Diagramas de dispersión de los datos de Jill Johnson para el ejemplo 6.12

Jill calcula el pronóstico para el año de 2007 usando la ecuación ajustada $\log \hat{Y} = 3.252 + .2369t$ con $t = 6$:

$$\log \hat{Y}_{2007} = 3.252 + .2369(6) = 4.673$$

$$\hat{Y}_{2007} = 10^{4.673} = 47,100$$

Jill pronostica que 47,100 estudiantes usarán el sistema de inscripción por Internet en 2007. Puesto que la universidad espera una matrícula total de 45,000 estudiantes, Jill concluye que probablemente todos los estudiantes van a usar el nuevo sistema de inscripciones a los cursos y que el sistema telefónico anterior puede descontinuarse.

Finalmente, Jill calcula que la tasa de crecimiento anual de los usuarios del sistema de inscripciones por Internet es

$$100(\text{antilog}(.2369) - 1)\% = 100(10^{.2369} - 1)\% = 100(1.725 - 1)\% = 72.5\%$$

Jill admite que con la capacidad de inscripción de la universidad, no tiene sentido extrapolar el aumento del número de usuarios del sistema de inscripción por Internet más allá de 2007.

En algunas situaciones, una curva de crecimiento lineal puede ajustarse directamente a los datos originales.




FIGURA 6-16 Línea ajustada de regresión para el ejemplo 6.12

Ejemplo 6.13

Suponga que en 1999 una compañía relacionada con la prestación de servicios de salud para personas mayores está interesada en una proyección a largo plazo de la expectativa de vida en el momento del nacimiento en Estados Unidos, de manera que pueda formular una estrategia corporativa de largo plazo. La compañía obtiene proyecciones de esta variable desde 1970 a 1997 del *Statistical Abstract of the United States*. Estos datos se presentan en la tabla 6-11. Después de codificar los años como 1 = 1970, 2 = 1971, ..., 28 = 1997 y teclear los datos en Minitab, la rutina Regresión-Gráfica de línea ajustada produce la gráfica de la figura 6-17.

La compañía no está interesada en examinar las razones de un incremento obvio en la longevidad durante varios años pasados, sino en una proyección lejana en el futuro de la línea de regresión ajustada. Tampoco está interesada en especular acerca de si la tendencia ascendente continuará, o por qué medios se podría alcanzar un incremento como éste. Sólo quiere completar el siguiente enunciado: “Si las tendencias actuales continúan, la expectativa de vida en el momento del nacimiento será de Y en un futuro de X años”. Se selecciona el año de 2050 ($X = 53$ años más allá de 1997) como el año objetivo en el futuro. Al usar $28 + 53 = 81$ como el valor para el tiempo en la ecuación de regresión que se presenta en la figura 6-17 y al despejar Y, la compañía obtiene una expectativa de vida de 86.6 años. Esta edad obviamente representa un aumento sustancial en la longevidad para las próximas décadas y la compañía empieza a trabajar sobre planes estratégicos para tomar ventaja de este incremento esperado en el tiempo de vida.

APLICACIÓN A LA ADMINISTRACIÓN

El análisis de regresión es la herramienta estadística que se utiliza más ampliamente en la dirección de una empresa cuando existe la necesidad de evaluar el efecto de una sola variable independiente sobre una variable dependiente. El análisis de regresión —junto con el análisis de correlación— ayuda al responsable de hacer el pronóstico a conocer las relaciones entre variables. El analista puede determinar tanto la importancia como la dirección de la relación entre variables.

La mayoría de los problemas que requieren el análisis de regresión implican la versión más compleja, llamada *análisis de regresión múltiple* (que estudiaremos en el siguiente capítulo), porque la mayoría de las relaciones ameritan el estudio de la relación entre una variable

TABLA 6-11 Expectativa de vida al nacer de la población total de Estados Unidos, ejemplo 6.13			
1970	70.8	1984	74.7
1971	71.2*	1985	74.7
1972	71.5*	1986	74.7
1973	71.9*	1987	74.9
1974	72.4*	1988	74.9
1975	72.6	1989	75.1
1976	72.8*	1990	75.4
1977	73.0*	1991	75.5
1978	73.3*	1992	75.8
1979	73.5*	1993	75.5
1980	73.7	1994	75.7
1981	74.1*	1995	75.8
1982	74.5	1996	76.1
1983	74.6	1997	76.5

Fuente: Statiscal Abstract of the United States, 119a. ed., 1999.

*Interpoladas.




FIGURA 6-17 Línea de regresión ajustada para el ejemplo 6.13

dependiente y más de una variable independiente. Sin embargo, la regresión simple y el análisis de correlación simple se utilizan con frecuencia. Los siguientes son unos cuantos ejemplos de situaciones que implican la regresión múltiple:

- *Consumo de productos.* Un fabricante desea pronosticar cuánta cerveza bebe una persona a la semana considerando variables como ingreso, edad, educación y clase demográfica.
- *Ventas.* Un minorista quiere pronosticar las ventas de un producto de una tienda contra las ventas de otra sobre la base de diferencias de precio, el ingreso relativo de la comunidad circundante, la simpatía relativa del personal de la tienda, y el número y fortaleza de los competidores en cada mercado.
- *Precios de las acciones.* Un analista bursátil de una firma regional de corretaje desea pronosticar el precio de una nueva emisión de acciones de una empresa local sobre la base de la economía regional, el ingreso, la población y el prestigio de la compañía.
- *Deudas incobrables.* Un contador necesita pronosticar las deudas incobrables que una empresa podría enfrentar el siguiente año fiscal sobre la base del número de personas desempleadas, créditos pendientes, tasas de interés y ventas esperadas.
- *Necesidades de empleo.* El director de personal de una gran empresa manufacturera desea pronosticar los requerimientos de personal para el año venidero tomando como base la edad promedio de sus empleados, su escala de salarios comparada con los de la localidad, la expectativa de nuevos contratos de ventas y la disponibilidad de puestos de trabajo competitivos.
- *Demanda en centros comerciales.* El gerente de un nuevo centro comercial quiere anticipar la demanda analizando el ingreso de la localidad, el tamaño de la población, así como la proximidad y el tamaño de centros comerciales competidores.

Una vez que se determina la relación entre las variables independiente y dependiente, la administración puede, en algunos casos, tratar de controlar la variable dependiente con base en este conocimiento. Por ejemplo, suponga que un gerente de marketing determina que existe una relación positiva significativa entre los gastos de publicidad y las ventas. La ecuación de regresión podría ser

$$\text{Ventas} = \$43,000 + .3(\text{Gastos de publicidad})$$

A partir de esta ecuación, el gerente de marketing puede tratar de controlar las ventas aumentando o disminuyendo los gastos de publicidad en una cantidad que maximice las utilidades. Siempre que el gerente tenga control sobre la variable independiente y exista la relación causa-efecto implicada por la ecuación de regresión, es posible controlar parcialmente la variable dependiente. La ecuación de regresión y el coeficiente de determinación ayudan a la administración de una compañía a determinar si tal control vale la pena.

Glosario

Coefficiente de determinación. Mide el porcentaje de variabilidad de Y que puede explicarse a través del conocimiento de la variabilidad (diferencias) de la variable independiente X .

Línea de regresión ajustada. Es la línea que mejor se ajusta a la colección de puntos de datos $X-Y$. Minimiza la suma de las distancias elevadas al cuadrado desde los puntos hasta la línea medidas verticalmente, es decir, en la dirección Y .

Error estándar de la estimación. Mide la cantidad por la que los valores reales de Y difieren de los valores estimados. Es una estimación de la desviación estándar del término de error, ε , en el modelo de regresión lineal simple.

Error estándar del pronóstico (s_f). Mide la variabilidad de la Y pronosticada en relación con la Y real para un valor dado de X .

Fórmulas clave

Suma de errores al cuadrado

$$SSE = \sum (Y - \hat{Y})^2 = \sum (Y - b_0 - b_1X)^2 \quad (6.1)$$

Método de los mínimos cuadrados: fórmula de la pendiente

$$b_1 = \frac{n \sum XY - \sum X \sum Y}{n \sum X^2 - (\sum X)^2} = \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\sum (X - \bar{X})^2} \quad (6.2)$$

Método de los mínimos cuadrados: fórmula de la intersección con Y

$$b_0 = \frac{\sum Y}{n} - \frac{b_1 \sum X}{n} = \bar{Y} - b_1 \bar{X} \quad (6.3)$$

Relación entre el coeficiente de la pendiente y el coeficiente de correlación

$$b_1 = \frac{\sqrt{\sum (Y - \bar{Y})^2}}{\sqrt{\sum (X - \bar{X})^2}} r \quad (6.4)$$

Observación = Ajuste + residuo

$$Y = \hat{Y} + (Y - \hat{Y}) \quad (6.5)$$

Ecuación de regresión ajustada

$$\hat{Y} = b_0 + b_1X \quad (6.6)$$

Error estándar de la estimación: fórmula de definición

$$s_{y \cdot x} = \sqrt{\frac{\sum (Y - \hat{Y})^2}{n - 2}} \quad (6.7)$$

Error estándar de la estimación: fórmula de cálculo

$$s_{y \cdot x} = \sqrt{\frac{\sum Y^2 - b_0 \sum Y - b_1 \sum XY}{n - 2}} \quad (6.8)$$

Error estándar del pronóstico

$$s_f = s_{y \cdot x} \sqrt{1 + \frac{1}{n} + \frac{(X - \bar{X})^2}{\sum (X - \bar{X})^2}} \quad (6.9)$$

Intervalo de predicción

$$\hat{Y} \pm t s_f \quad (6.10)$$

Intervalo de predicción del 95% para una muestra grande

$$\hat{Y} \pm 2s_f \quad (6.11)$$

Descomposición de la suma de los cuadrados y grados de libertad

$$\begin{aligned} SST &= SSR + SSE \\ \sum (Y - \bar{Y})^2 &= \sum (\hat{Y} - \bar{Y})^2 + \sum (Y - \hat{Y})^2 \end{aligned} \quad (6.12)$$

$$df: n - 1 = 1 + (n - 2) \quad (6.13)$$

Coefficiente de determinación

$$r^2 = \frac{\sum(\hat{Y} - \bar{Y})^2}{\sum(Y - \bar{Y})^2} = 1 - \frac{\sum(Y - \hat{Y})^2}{\sum(Y - \bar{Y})^2} \quad (6.14)$$

Estadístico t para probar $H_0: \beta_1 = 0$

$$t = \frac{b_1}{s_{b_1}} \quad (\text{véase el recuadro sombreado en la p. 237})$$

Error estándar del coeficiente de regresión

$$s_{b_1} = s_{y \cdot x} / \sqrt{\sum(X - \bar{X})^2} \quad (\text{véase el recuadro sombreado en la p. 237})$$

Estadístico F

$$F = \frac{\text{Cuadrado medio de regresión}}{\text{Error cuadrático medio}} = \frac{MSR}{MSE} \quad (6.15)$$

Relación del estadístico F con el coeficiente de determinación

$$F = \frac{r^2(n-2)}{1-r^2} \quad (6.16)$$

Coefficiente de autocorrelación residual

$$r_k(e) = \frac{\sum_{t=k+1}^n e_t e_{t-k}}{\sum_{t=1}^n e_t^2} \quad k = 1, 2, \dots, K \quad (6.17)$$

Problemas

Nota: La mayoría de los problemas siguientes contienen datos que van a ser manipulados usando procedimientos de análisis de regresión. Si bien es posible, incluso útil, trabajar uno o dos de estos análisis a mano, es importante que usted aprenda cómo usar el software de computadora para resolver problemas como éstos. En el siguiente capítulo usted aprenderá cómo se efectúa un análisis de regresión múltiple, en el cual no es posible resolver los problemas a mano. Por eso, usted debe familiarizarse con el software de análisis de regresión cuando resuelva los siguientes problemas. Si usted tiene acceso a Minitab o Excel, vea las instrucciones de uso en la sección final de este capítulo.

- ¿Cuál de las siguientes situaciones es incongruente?
 - $\hat{Y} = 499 + .21X$ y $r = .75$
 - $\hat{Y} = 100 + .9X$ y $r = -.70$
 - $\hat{Y} = -20 + 1X$ y $r = .40$
 - $\hat{Y} = -7 - 4X$ y $r = -.90$
- Las ganancias en miles de millones de dólares de American Telegraph and Telephone (AT&T) se estiman usando el producto interno bruto (PIB). La ecuación de regresión es $\hat{Y} = .078 + .06X$, donde el PIB se mide en miles de millones de dólares.
 - Interprete la pendiente.
 - Interprete la intersección con Y .

TABLA P-3

<i>Y</i> (\$)	<i>X</i> (\$)	<i>Y</i> (\$)	<i>X</i> (\$)
1,250	41	1,300	46
1,380	54	1,400	62
1,425	63	1,510	61
1,425	54	1,575	64
1,450	48	1,650	71

3. Considere los datos de la tabla P-3 donde X = gastos semanales de publicidad y Y = ventas semanales.
 - a) ¿Existe una relación significativa entre los gastos de publicidad y las ventas?
 - b) Defina la ecuación de predicción.
 - c) Pronostique las ventas para un gasto de publicidad de \$50.
 - d) ¿Qué porcentaje de variación de las ventas puede explicarse con la ecuación de predicción?
 - e) Defina la cantidad de variación no explicada.
 - f) Obtenga la cantidad de variación total.
4. En la tabla P-4 se presenta el tiempo requerido para hacer el cobro a los clientes en un supermercado y los valores correspondientes a las compras. Conteste los incisos a), b), e) y f) del problema 3 usando estos datos. Proporcione un estimado puntual y un intervalo estimado del 99% para Y si $X = 3.0$.
5. A Lori Franz, supervisora de mantenimiento de la Baltimore Transit Authority, le gustaría determinar si existe una relación positiva entre el costo anual de mantenimiento de un autobús y su antigüedad. Si existe una relación, Lori siente que puede hacer un mejor trabajo al pronosticar el presupuesto de mantenimiento anual del autobús. Ella recopiló los datos que se presentan en la tabla P-5.
 - a) Grafique un diagrama de dispersión.
 - b) ¿Qué clase de relación existe entre estas dos variables?
 - c) Calcule el coeficiente de correlación.
 - d) Determine la línea de mínimos cuadrados.
 - e) Pruebe la significancia del coeficiente de la pendiente para el nivel de significancia de .05. ¿Es significativa la correlación? Explique.
 - f) Pronostique el costo anual de mantenimiento para un autobús de cinco años de antigüedad.
6. Andrew Vazsonyi es el gerente de la cadena de supermercados Spendwise. A él le gustaría pronosticar las ventas de libros en edición rústica (libros por semana) con base en la canti-

TABLA P-4

<i>Tiempo requerido para el pago (minutos)</i>	<i>Valor de la compra (\$)</i>	<i>Tiempo requerido para el pago (minutos)</i>	<i>Valor de la compra (\$)</i>
3.6	30.6	1.8	6.2
4.1	30.5	4.3	40.1
.8	2.4	.2	2.0
5.7	42.2	2.6	15.5
3.4	21.8	1.3	6.5

TABLA P-5

<i>Autobús</i>	<i>Costo de mantenimiento (\$)</i> <i>Y</i>	<i>Antigüedad (años)</i> <i>X</i>
1	859	8
2	682	5
3	471	3
4	708	9
5	1,094	11
6	224	2
7	320	1
8	651	8
9	1,049	12

TABLA P-6

<i>Semana</i>	<i>Número de libros vendidos</i> <i>Y</i>	<i>Pies de espacio de anaqueles</i> <i>X</i>
1	275	6.8
2	142	3.3
3	168	4.1
4	197	4.2
5	215	4.8
6	188	3.9
7	241	4.9
8	295	7.7
9	125	3.1
10	266	5.9
11	200	5.0

dad de espacio de exhibición disponible (pies) en los anaqueles. Andrew recopila los datos de una muestra de 11 semanas, los cuales se presentan en la tabla P-6.

- Grafique un diagrama de dispersión.
 - ¿Qué clase de relación existe entre estas dos variables?
 - Calcule el coeficiente de correlación.
 - Determine la línea de mínimos cuadrados.
 - Pruebe la significancia del coeficiente de la pendiente en el nivel de significancia de .10. ¿Es significativa la correlación? Explique.
 - Grafique los residuos contra los valores ajustados. De acuerdo con esta gráfica, ¿el modelo de regresión lineal simple es adecuado para estos datos?
 - Pronostique las ventas de libros en edición rústica para una semana durante la cual existen cuatro pies de espacio en los anaqueles.
- En la tabla P-7 se presenta la información correspondiente a un negocio de ventas por correo que opera en 12 ciudades.
 - Determine la línea de regresión ajustada.
 - Calcule el error estándar de la estimación.
 - Determine la tabla ANOVA.
 - ¿Qué porcentaje de la variación de ventas por correo se explica por el número de catálogos distribuidos?

TABLA P-7

<i>Ciudad</i>	<i>Número de órdenes de ventas por correo (en miles)</i> <i>Y</i>	<i>Número de catálogos distribuidos (en miles)</i> <i>X</i>	<i>Ciudad</i>	<i>Número de órdenes de ventas por correo (en miles)</i> <i>Y</i>	<i>Número de catálogos distribuidos (en miles)</i> <i>X</i>
A	24	6	G	18	15
B	16	2	H	18	3
C	23	5	I	35	11
D	15	1	J	34	13
E	32	10	K	15	2
F	25	7	L	32	12

- e) Haga una prueba para determinar si el coeficiente de regresión de la pendiente es significativamente diferente de cero. (Use un nivel de significancia de .01).
- f) Pruebe la significancia de la regresión usando el estadístico F de la tabla ANOVA. (Use un nivel de significancia de .01). ¿Es congruente el resultado con el del inciso e)? ¿Debería serlo?
- g) Pronostique el número de ventas por correo recibidas cuando se distribuyen 10,000 catálogos; utilice un intervalo de predicción del 90%.
8. En un estudio de inversiones y tasas de interés se recabaron los datos de la tabla P-8 durante un periodo de 10 años.
- a) ¿Es significativa la relación entre estas variables?
- b) ¿Puede desarrollarse una ecuación efectiva de predicción?
- c) Si la tasa de interés promedio es del 4% dentro de cinco años, ¿puede pronosticarse la inversión anual?
- d) Calcule e interprete r^2 .
- e) Discuta la correlación y la causalidad en este ejemplo.
9. La ABC Investment Company está en el negocio de hacer licitaciones sobre inversiones ofrecidas por varias empresas que quieren financiamiento adicional. La ABC ha tabulado sus ofertas en las últimas 25 licitaciones en términos de su porcentaje de valor nominal. También se tabularon las ofertas del principal competidor de ABC, como un porcentaje del valor nominal. ABC ahora se pregunta si está usando el mismo razonamiento que su competidor en la preparación de las ofertas. En otras palabras, ¿es posible que ABC pronostique las ofertas de su competidor a partir de las propias? Si no es así, entonces el competidor debe estar evaluando las licitaciones de manera diferente. Los datos se presentan en la tabla P-9.

TABLA P-8

<i>Inversión anual (en miles de \$)</i>	<i>Tasa de interés promedio (%)</i>	<i>Inversión anual (en miles de \$)</i>	<i>Tasa de interés promedio (%)</i>
1,060	4.8	2,050	3.8
940	5.1	2,070	3.7
920	5.9	2,030	4.5
1,110	5.1	1,780	4.9
1,590	4.8	1,420	6.2

TABLA P-9

<i>Licitación</i>	<i>Oferta de ABC</i>	<i>Oferta del competidor</i>	<i>Licitación</i>	<i>Oferta de ABC</i>	<i>Oferta del competidor</i>
1	99.035	100.104	14	100.542	99.936
2	104.358	105.032	15	96.842	95.834
3	99.435	99.517	16	99.200	99.863
4	96.932	95.808	17	101.614	102.010
5	98.904	98.835	18	99.501	99.432
6	101.635	101.563	19	100.898	99.965
7	100.001	101.237	20	97.001	96.838
8	98.234	99.123	21	100.025	100.804
9	93.849	94.803	22	103.014	104.300
10	99.412	100.063	23	98.702	99.010
11	99.949	99.564	24	101.834	100.936
12	104.012	103.889	25	102.903	103.834
13	99.473	99.348			

- a) ¿Hasta qué grado están usando las dos firmas el mismo razonamiento en la preparación de sus ofertas?
- b) Pronostique la oferta del competidor si las ofertas de ABC tienen el 101% de valor nominal. Construya para ambos un estimado puntual y un intervalo de la predicción.
- c) En el inciso b), ¿cuál es la probabilidad de que ABC gane esta licitación particular? (La oferta más baja gana).
10. Evalúe los siguientes enunciados.
- a) Una r^2 alta se refiere a una regresión significativa.
- b) Un tamaño muestral muy grande en un problema de regresión siempre arrojará resultados útiles.
11. Suponga que usted fue contratado por Ed Bodganski, dueño de la American Precast Company, como analista de tiempo parcial. Ed estaba muy contento cuando usted determinó que existe una relación positiva entre los permisos de construcción expedidos y la cantidad de trabajo disponible para su compañía. Ahora él se pregunta si es posible usar el conocimiento de las tasas de interés sobre las hipotecas de primer grado para predecir el número de permisos de construcción que se expedirán cada mes. Usted recopila una muestra aleatoria de nueve meses de datos, como se presenta en la tabla P-11.

TABLA P-11

<i>Mes</i>	<i>Permisos de construcción Y</i>	<i>Tasa de interés (%) X</i>
1	786	10.2
2	494	12.6
3	289	13.5
4	892	9.7
5	343	10.8
6	888	9.5
7	509	10.9
8	987	9.2
9	187	14.2

- a) Grafique los datos en un diagrama de dispersión.
 - b) Determine la función de regresión ajustada.
 - c) Pruebe la significancia del coeficiente de la pendiente con un nivel de significancia de .05.
 - d) Cuando la tasa de interés se incrementa en 1%, ¿cuál es el decremento promedio en el número de permisos de construcción expedidos?
 - e) Calcule el coeficiente de determinación.
 - f) Redacte un enunciado que Ed pueda comprender y en el cual se interprete el número calculado en el inciso e).
 - g) Redacte un escrito para Ed explicándole los resultados de su análisis.
12. Considere la población de 140 observaciones que se presenta en la tabla P-12. La Marshall Printing Company desea estimar la relación entre el número de copias producidas por una técnica de impresión de offset (X) y el costo de la mano de obra directa asociada (Y). Seleccione una muestra aleatoria de 20 observaciones.
- a) Construya un diagrama de dispersión.
 - b) Calcule el coeficiente de correlación de la muestra.
 - c) Determine la línea de regresión ajustada.
 - d) Grafique la línea ajustada sobre el diagrama de dispersión.
 - e) Calcule el error estándar de la estimación.
 - f) Calcule el coeficiente de determinación e interprete su valor.
 - g) Pruebe la hipótesis de que la pendiente, β_1 , de la línea de regresión de la población es cero.
 - h) Calcule un pronóstico puntual y un intervalo de predicción del 90% para el costo de la mano de obra directa si el proyecto implica 250 copias.
 - i) Examine los residuos. ¿Parece que un modelo de regresión lineal simple es adecuado para estos datos? Explique.
13. Harry Daniels es un ingeniero de control de calidad de Specific Electric Corporation, una empresa dedicada a fabricar motores eléctricos. Uno de los pasos en el proceso de manufactura implica el uso de una fresadora automática para hacer las ranuras en el eje de los motores. Cada lote de ejes de motor se prueba y todos los ejes que no tengan las dimensiones requeridas se desechan. La fresadora debe reajustarse al comenzar a trabajar con cada nuevo lote porque su cabeza cortadora se desgasta ligeramente durante la producción. A Harry se le asigna el trabajo de pronosticar cómo afecta el tamaño de un lote al número de ejes defectuosos en el lote, de manera que pueda seleccionar el mejor tamaño de lote. Él recopila los datos del tamaño promedio del lote de los 13 lotes considerados en la tabla P-13 y le pide a usted analizarla.
- a) Grafique los datos en un diagrama de dispersión.
 - b) Ajuste un modelo de regresión lineal simple.
 - c) Haga una prueba de significancia del coeficiente de la pendiente.
 - d) Examine los residuos.
 - e) Desarrolle un modelo curvilíneo ajustando un modelo de regresión lineal simple para alguna transformación de la variable independiente.
 - f) Haga una prueba de la significancia del coeficiente de la pendiente de la variable transformada.
 - g) Examine los residuos.
 - h) Pronostique el número de defectos para un tamaño de lote de 300 ejes.
 - i) ¿Cuál modelo prefiere, el del inciso b) o el del inciso e)?
 - j) Redacte un escrito para Harry resumiendo sus resultados.
14. Los datos de la tabla P-14 fueron recopilados como parte de un estudio de evaluación de bienes inmuebles. Los números son observaciones de X = valor tasado (en miles de dólares) en los libros del valuador de la ciudad y Y = valor de mercado (precio de venta en miles de dólares) para $n = 30$ terrenos que se vendieron en un año particular en cierta área geográfica.

TABLA P-12

<i>Obs.</i>	<i>Y</i>	<i>X</i>	<i>Obs.</i>	<i>Y</i>	<i>X</i>	<i>Obs.</i>	<i>Y</i>	<i>X</i>
(1)	1.0	10	(48)	2.2	180	(95)	2.0	330
(2)	0.9	10	(49)	2.4	180	(96)	2.4	340
(3)	0.8	10	(50)	1.6	180	(97)	2.2	340
(4)	1.3	20	(51)	1.8	190	(98)	2.0	340
(5)	0.9	20	(52)	4.1	190	(99)	2.5	350
(6)	0.6	30	(53)	2.0	190	(100)	2.8	350
(7)	1.1	30	(54)	1.5	200	(101)	2.3	350
(8)	1.0	30	(55)	2.1	200	(102)	2.7	350
(9)	1.4	40	(56)	2.5	200	(103)	2.8	360
(10)	1.4	40	(57)	1.7	220	(104)	3.1	360
(11)	1.2	40	(58)	2.0	220	(105)	2.5	370
(12)	1.7	50	(59)	2.3	220	(106)	2.9	370
(13)	0.9	50	(60)	1.8	220	(107)	2.6	370
(14)	1.2	50	(61)	1.3	230	(108)	3.0	380
(15)	1.3	50	(62)	1.6	230	(109)	3.2	380
(16)	0.7	60	(63)	2.8	230	(110)	2.9	390
(17)	1.0	60	(64)	2.2	230	(111)	2.6	390
(18)	1.3	70	(65)	2.6	230	(112)	2.5	390
(19)	1.5	70	(66)	1.4	240	(113)	2.7	400
(20)	2.0	70	(67)	1.6	240	(114)	3.1	400
(21)	0.8	80	(68)	1.7	240	(115)	2.4	400
(22)	0.6	80	(69)	1.5	250	(116)	3.0	400
(23)	1.8	80	(70)	2.2	250	(117)	3.4	420
(24)	1.0	90	(71)	2.5	250	(118)	3.5	420
(25)	2.0	100	(72)	2.4	260	(119)	3.1	420
(26)	0.5	100	(73)	2.0	260	(120)	2.9	420
(27)	1.5	100	(74)	2.7	260	(121)	2.8	430
(28)	1.3	110	(75)	2.0	270	(122)	3.3	430
(29)	1.7	110	(76)	2.2	270	(123)	2.5	440
(30)	1.2	110	(77)	2.4	270	(124)	2.8	440
(31)	0.8	110	(78)	1.8	280	(125)	2.4	450
(32)	1.0	120	(79)	2.8	290	(126)	2.6	450
(33)	1.8	120	(80)	2.2	290	(127)	3.0	450
(34)	2.1	120	(81)	2.4	290	(128)	3.4	460
(35)	1.5	130	(82)	2.1	290	(129)	3.0	460
(36)	1.9	130	(83)	1.9	290	(130)	3.3	470
(37)	1.7	140	(84)	2.4	300	(131)	3.4	470
(38)	1.2	150	(85)	2.5	300	(132)	3.1	470
(39)	1.4	150	(86)	2.9	300	(133)	3.6	480
(40)	2.1	150	(87)	2.0	300	(134)	3.0	480
(41)	0.9	160	(88)	1.9	310	(135)	2.9	480
(42)	1.1	160	(89)	2.5	310	(136)	3.2	480
(43)	1.7	160	(90)	2.6	310	(137)	2.6	490
(44)	2.0	160	(91)	3.2	320	(138)	3.8	490
(45)	1.6	170	(92)	2.8	320	(139)	3.3	490
(46)	1.9	170	(93)	2.4	320	(140)	2.9	500
(47)	1.7	170	(94)	2.5	320			

TABLA P-13

<i>Lote</i>	<i>Número de defectos</i> <i>Y</i>	<i>Tamaño del lote</i> <i>X</i>
1	4	25
2	8	50
3	6	75
4	16	100
5	22	125
6	27	150
7	36	175
8	49	200
9	53	225
10	70	250
11	82	275
12	95	300
13	109	325

TABLA P-14

<i>Terreno</i>	<i>Valor tasado</i>	<i>Mercado</i>	<i>Terreno</i>	<i>Valor tasado</i>	<i>Mercado</i>
1	68.2	87.4	16	74.0	88.4
2	74.6	88.0	17	72.8	93.6
3	64.6	87.2	18	80.4	92.8
4	80.2	94.0	19	74.2	90.6
5	76.0	94.2	20	80.0	91.6
6	78.0	93.6	21	81.6	92.8
7	76.0	88.4	22	75.6	89.0
8	77.0	92.2	23	79.4	91.8
9	75.2	90.4	24	82.2	98.4
10	72.4	90.4	25	67.0	89.8
11	80.0	93.6	26	72.0	97.2
12	76.4	91.4	27	73.6	95.2
13	70.2	89.6	28	71.4	88.8
14	75.8	91.8	29	81.0	97.4
15	79.2	94.8	30	80.6	95.4

- Grafique el valor de mercado contra el valor tasado en los libros en un diagrama de dispersión.
 - Suponiendo un modelo de regresión lineal simple, determine la línea de mínimos cuadrados que relaciona el valor de mercado con el valor tasado en los libros.
 - Determine r^2 e interprete su valor.
 - ¿Es significativa la regresión? Explique.
 - Pronostique el valor de mercado de una propiedad a partir de un valor tasado en los libros de 90.5. ¿Hay algún peligro al hacer esta predicción?
 - Examine los residuos. ¿Puede usted identificar observaciones que tienen gran influencia en la localización de la línea de mínimos cuadrados?
15. En la tabla P-15 se presentan los costos de jugadores (X) y gastos operativos (Y) para $n = 26$ de los principales equipos de la liga mayor de béisbol durante la temporada 1990-1991.

TABLA P-15

<i>Equipo</i>	<i>Costos de jugadores (millones de \$)</i>	<i>Gastos operativos Y (millones de \$)</i>
1	29.8	59.6
2	36.0	72.0
3	35.2	70.4
4	29.7	62.4
5	35.4	70.8
6	15.8	39.5
7	18.0	60.0
8	23.2	46.4
9	29.0	58.0
10	20.7	47.6
11	30.4	60.8
12	21.7	43.4
13	39.2	66.6
14	34.3	61.7
15	33.3	53.3
16	27.1	48.8
17	24.4	48.8
18	12.1	31.5
19	24.9	49.8
20	31.1	54.4
21	20.4	40.8
22	24.1	48.2
23	17.4	41.8
24	26.4	50.2
25	19.5	46.8
26	21.8	43.6

- Suponiendo un modelo de regresión lineal simple, determine la ecuación para la línea recta ajustada.
 - Determine r^2 y haga comentarios acerca de la intensidad de la relación lineal.
 - Pruebe la significancia de la regresión para un nivel de significancia de .10.
 - ¿Se puede concluir que, como regla general, los gastos operativos son aproximadamente el doble de los costos de los jugadores? Analícelo.
 - Pronostique los gastos operativos, con un intervalo de predicción del 95% de una muestra grande, si los costos de los jugadores son de 30.5 millones de dólares.
 - Usando los residuos como guía, identifique cualquier observación atípica. Es decir, ¿algunos equipos tienen costos de jugadores inusualmente bajos o altos en comparación con los gastos operativos?
16. La tabla P-16 contiene datos de consumo de periódicos de 23 ciudades (Y) y el número de familias en la ciudad (X) durante un año particular.
- Grafique el consumo de periódicos contra el número de familias en un diagrama de dispersión.
 - ¿Es adecuado el modelo de regresión lineal simple para los datos de la tabla P-16? Asegúrese de que su respuesta incluya un análisis de los residuos.
 - Considere una transformación logarítmica del consumo de periódicos y un modelo de regresión lineal simple que relacione $Y = \log$ (consumo de periódicos) con $X =$ número de familias. Ajuste este modelo.

TABLA P-16

<i>Ciudad</i>	<i>Consumo de periódico Y (toneladas métricas)</i>	<i>Número de familias X</i>	<i>Ciudad</i>	<i>Consumo de periódico Y (toneladas métricas)</i>	<i>Número de familias X</i>
1	961	8,600	13	878	8,330
2	469	6,870	14	637	9,010
3	556	9,880	15	3,291	11,790
4	1,252	12,370	16	2,470	18,910
5	902	6,920	17	916	8,550
6	1,399	13,760	18	525	8,850
7	1,877	7,450	19	1,159	8,540
8	921	6,700	20	1,138	6,910
9	494	7,420	21	979	7,060
10	530	6,930	22	1,899	10,920
11	488	7,400	23	5,022	14,800
12	1,253	7,420			

- d) Examine los residuos de la regresión del inciso c). ¿Cuál modelo es mejor, el del inciso b) o el del inciso c)? Justifique su respuesta.
- e) Usando la función ajustada del inciso c), pronostique la cantidad de periódico consumida en un año si una ciudad tiene 100,000 familias.
- f) ¿Podría indicar otras variables que probablemente tengan influencia sobre la cantidad de periódico consumida durante un año?
17. La Outback Steakhouse creció explosivamente durante sus primeros años de operación. Los números de sucursales de Outback Steakhouse para el periodo de 1988 a 1993 se presentan abajo.

Año	1988	1989	1990	1991	1992	1993
Núm. de sucursales	2	9	23	49	87	137

Fuente: Outback Steakhouse.

- a) ¿Parece haber un crecimiento lineal o exponencial en el número de sucursales?
- b) Calcule la tasa de crecimiento anual de Outback Steakhouse durante el periodo de 1988 a 1993.
- c) Pronostique el número de sucursales de Outback para 2007. ¿Parece razonable este número? Explique.
18. On The Double, una cadena de centros de copiado instalados dentro de planteles universitarios, inició operaciones con una sola tienda en 1993. En la tabla P-18 está registrado el número de centros de copiado en operación, Y , durante 14 años consecutivos.
- a) Grafique el número de centros de copiado contra el año. ¿El crecimiento experimentado por On The Double es lineal o exponencial?
- b) Determine la tasa de crecimiento anual de On The Double.
- c) Pronostique el número de centros de copiado en operación para 2012. ¿Parece razonable este número? ¿Por qué?
19. En la tabla P-19 se presenta el número de empleados (X) y las utilidades por empleado (Y) para $n = 16$ empresas editoriales. Los empleados se registran en miles, y las utilidades por

TABLA P-18

<i>Año</i>	<i>Periodo</i>	<i>Centros de copiado</i>
1993	1	1
1994	2	2
1995	3	2
1996	4	6
1997	5	10
1998	6	16
1999	7	25
2000	8	41
2001	9	60
2002	10	97
2003	11	150
2004	12	211
2005	13	382
2006	14	537

TABLA P-19

<i>Empresa</i>	<i>Utilidades (en miles de \$)</i>	<i>Empleados (en miles)</i>
1	33.5	9.4
2	31.4	6.3
3	25.0	10.7
4	23.1	7.4
5	14.2	17.1
6	11.7	21.2
7	10.8	36.8
8	10.5	28.5
9	9.8	10.7
10	9.1	9.9
11	8.5	26.1
12*	8.3	70.5
13	4.8	14.8
14	3.2	21.3
15	2.7	14.6
16	-9.5	26.8

*Dun and Bradstreet.

empleado en miles de dólares. A continuación se presenta una parte del resultado de Minitab de un análisis de regresión lineal.

The regression equation is

Profits = 18.0 - 0.271 Employees

Predictor	Coef	SE Coef	T	P
Constant	17.954	4.457	4.03	0.001
Employees	-0.2715	0.1726	-1.57	0.138

s = 10.6112 R - Sq = 15.0% R - Sq(adj) = 9.0%

- a) Identifique la estimación de los mínimos cuadrados de los coeficientes de la pendiente y de la intersección.
- b) Pruebe la hipótesis $H_0: \beta_1 = 0$ con $\alpha = .10$. ¿Parece haber una relación entre las utilidades por empleado y el número de empleados? Explique.
- c) Identifique e interprete r^2 .
- d) ¿Esta función de regresión ajustada es una buena herramienta para pronosticar las utilidades por empleado para un número dado de empleados de una empresa editorial? Discútalos.
20. Con respecto al problema 19, la observación 12 corresponde a Dun y Bradstreet. Haga de nuevo el análisis de regresión lineal omitiendo esta observación. ¿Cambian sus conclusiones de los incisos b) y d) del problema 19? ¿Qué implica esto, si acaso, con respecto a la influencia de una observación individual sobre el análisis de regresión cuando el número de observaciones es bastante pequeño? ¿Cree usted razonable despedir a Dun y Bradstreet? Analícelo.
21. En el contexto del ejemplo 2-13 se presenta la tabla 2-28 con los datos sobre el costo real (Y) y el costo estimado (X), en millones de dólares, para $n = 26$ proyectos de construcción. La figura 2-17 muestra la gráfica de la línea ajustada para estos datos.
- a) Reanalice los datos de costos usando un modelo de regresión lineal simple. Elabore una gráfica de los residuos contra los valores ajustados.
- b) ¿Es significativa la regresión del costo real sobre el costo estimado? Justifique su respuesta.
- c) Identifique e interprete r^2 .
- d) ¿Cuáles son los valores apropiados de los coeficientes de la pendiente y de la intersección de la función de regresión de la población si el costo estimado es un factor de predicción perfecto del costo real esperado? ¿Son congruentes los coeficientes estimados en la ecuación de la línea recta ajustada con estos valores? Discútalos.
- e) Considere la gráfica de los residuos contra los valores ajustados. ¿Parece como si los costos estimados fueran, en general, factores de predicción más exactos de los costos reales de los proyectos relativamente baratos que de los proyectos de alto costo? ¿Por qué?
22. Con respecto al problema 21, los datos de costo pueden transformarse tomando los logaritmos naturales tanto de los costos estimados como de los costos reales. Considere un modelo de regresión lineal simple para los costos transformados. A continuación se presenta una porción del resultado de Minitab para este análisis.

The regression equation is

$$\text{LnActual} = 0.003 + 0.968 \text{ LnEstimate}$$

Predictor	Coef	SE Coef	T	P
Constant	0.0026	0.1625	0.02	0.987
LnEstimate	0.96811	0.06583	14.71	0.000

$$S = 0.412124 \quad R - \text{Sq} = 90.0\% \quad R - \text{Sq}(\text{adj}) = 89.6\%$$

- a) ¿Es significativa la regresión? Explique.
- b) Identifique e interprete r^2 .
- c) ¿Los datos muestrales son congruentes con los valores de la población, $\beta_0 = 0$ y $\beta_1 = 1$? Explique. ¿Cuál es la significancia de estas opciones particulares para β_0 y β_1 ?
- d) Elabore un pronóstico del costo real cuando el costo estimado es de \$24 millones.

CASOS

CASO 6-1 TIGER TRANSPORT

Tiger Transport Company es una empresa de transporte que traslada enseres domésticos tanto localmente como a nivel nacional. Actualmente está interesada en el precio cobrado por transportar cargas pequeñas a largas distancias. La empresa está satisfecha con sus tarifas para cargas completas; estos precios están basados en los costos variables de los conductores, el combustible y el servicio de mantenimiento, más los costos indirectos y las utilidades. Sin embargo, hay dudas sobre la tarifa apropiada que debe cobrar por las mercancías adicionales necesarias para llenar el camión. Para realizar el pronóstico de las necesidades futuras de combustible y elaborar presupuestos de largo plazo, la compañía desea determinar el costo de agregar carga a un camión parcialmente lleno.

La compañía considera que el único costo adicional en que se incurre si se agrega carga al camión es el costo del combustible extra, pues se reducirían las millas que recorre el camión por galón. Como uno de los factores que se usarían para determinar las tarifas de cargas pequeñas, a la compañía le gustaría conocer el monto de los costos asociados al consumo adicional de combustible.

Usted está recién graduado de la escuela de negocios y trabaja en el departamento de contabilidad de costos; se le asigna la tarea de investigar este problema y comunicar a la alta dirección las consideraciones

necesarias para tomar una decisión sensata sobre las tarifas. Usted inicia suponiendo que todos los camiones son iguales; de hecho, son casi idénticos en términos de tamaño, capacidad de peso bruto y tamaño del motor. Usted también supone que todos los conductores recorrerán el mismo millaje en un trayecto largo. El jefe del departamento de contabilidad de Tiger considera que estas suposiciones son razonables.

Entonces usted tiene sólo una variable que podría afectar el millaje por galón para camiones en grandes distancias: el peso de la carga. Usted encuentra que el departamento de contabilidad tiene registros de cada viaje realizado por un camión de Tiger durante varios años. Estos registros incluyen el peso total de la carga, la distancia recorrida y el número de galones de diesel consumidos. Estas dos últimas cifras conforman una razón: las millas por galón para el viaje.

Usted se lecciona como su población los viajes realizados durante los últimos cuatro años; hay un total de 5,428 viajes. Entonces usted selecciona 40 números de una tabla de números aleatorios y puesto que los viajes están registrados uno tras otro, usted asigna el 1 al primer viaje, 2 al segundo y así sucesivamente. De esta forma, sus 40 números aleatorios producen una selección aleatoria de 40 viajes que se van a examinar. El peso de la carga y las millas por galón aparecen registrados en la tabla 6-12.

TABLA 6-12 Datos del peso de la carga y millas por galón de Tiger Transport

<i>Peso</i> (miles de libras)	<i>Millas</i> por galón	<i>Peso</i> (miles de libras)	<i>Millas</i> por galón	<i>Peso</i> (miles de libras)	<i>Millas</i> por galón	<i>Peso</i> (miles de libras)	<i>Millas</i> por galón
60	5.3	58	4.9	63	5.0	63	5.0
55	5.0	60	5.1	65	4.9	62	4.9
80	4.0	74	4.5	72	4.6	77	4.6
72	4.2	80	4.3	81	4.0	76	4.5
75	4.5	53	5.9	64	5.3	51	5.7
63	5.1	61	5.5	78	4.4	74	4.2
48	7.2	80	3.5	62	4.9	78	4.3
79	3.9	68	4.1	83	3.8	50	6.1
82	3.8	76	4.5	79	4.1	79	4.3
72	4.4	75	4.4	61	4.8	55	4.7

TABLA 6-13 Resultados de computadora del análisis de regresión de Tiger Transport**Regression Analysis: MPG versus Weight**

The regression equation is

$$\text{MPG} = 8.85 - 0.0604 \text{ Weight}$$

Predictor	Coef	SE Coef	T	P
Constant	8.8484	0.3840	23.04	0.000
Weight	-0.060399	0.005538	-10.91	0.000

$$S = 0.3534 \quad R\text{-Sq} = 75.8\% \quad R\text{-Sq}(\text{adj}) = 75.1\%$$

Analysis of Variance

Source	DF	SS	MS	F	P
Regression	1	14.853	14.853	118.93	0.000
Residual Error	38	4.746	0.125		
Total	39	19.599			

Puesto que su computadora de escritorio tiene el software de un paquete de análisis de regresión, usted ajusta un modelo de regresión lineal simple a los datos de la tabla 6-12. El reporte resultante se presenta en la tabla 6-13.

Después de estudiar el reporte en la tabla 6-13, usted concluye que los datos muestrales han generado una ecuación de regresión útil. Esta conclusión está basada en una r^2 relativamente alta (76%), un valor grande negativo de t (-10.9) y un valor alto de F (119). Del reporte de resultados usted obtiene la ecuación de la línea ajustada

$$\hat{Y} = 8.8484 - .0604X$$

donde Y se mide en millas por galón y X en miles de libras. La pendiente de la ecuación de regresión ($-.0604$) se interpreta como sigue: *Cada 1,000 libras adicionales de carga reducen el millaje de un camión un promedio de .0604 millas por galón.*

La compañía paga aproximadamente \$2.55 por galón de combustible diesel. Por lo tanto, usted puede calcular el costo de transportar una carga de 1,000 libras adicionales una distancia de 100 millas de la siguiente manera:

Promedio de millas por galón = 4.7 (de la tabla 6-12)

$$\text{Costo de 100 millas} = \frac{100(2.55)}{4.7} = \$54.26$$

Costo del mismo viaje con carga adicional de

$$1,000 \text{ libras es } \frac{100(2.55)}{(4.7 - .0604)} = \$54.96$$

Por lo tanto,

$$\begin{aligned} \text{Aumento de costo de 1,000 libras transportadas} \\ 100 \text{ millas} &= \$.70 \end{aligned}$$

Ahora usted cree que ha completado parte de su tarea, a saber, la determinación de los costos en efectivo de combustible asociados con el peso de la carga adicional de un camión que está parcialmente lleno. Desde luego, usted se da cuenta de que hay otros factores relacionados con una decisión de tarifa para cargas pequeñas.

TAREA

1. Redacte un escrito para la alta dirección de la compañía que resuma el análisis. Incluya comentarios sobre la forma en la cual su trabajo mejorará

los pronósticos de necesidades de combustible e ingresos por camión.

CASO 6-2 BUTCHER PRODUCTS, INC.

Gene Butcher es dueño y presidente de Butcher Products, Inc., una compañía pequeña que fabrica tubos de fibra de vidrio para cables de instalaciones eléctricas. Gene ha estudiado el número de unidades manufacturadas diariamente durante los dos años y medio anteriores y está preocupado por la amplia variabilidad de estas cifras. Para pronosticar adecuadamente el rendimiento de producción, los costos e ingresos, Gene necesita establecer una relación entre la producción y alguna otra variable.

Con base en su experiencia en la compañía, Gene no puede identificar una razón para la variabilidad en la producción sino hasta que piensa en las condiciones del estado del tiempo. Su razonamiento es que la temperatura exterior puede tener algo que ver con la productividad de su fuerza de trabajo y la producción diaria obtenida.

Él selecciona de manera aleatoria varios días de sus archivos y registra los números de unidades de conductos producidos para cada uno de esos días. Luego, va a la estación meteorológica local y, para cada uno de los días seleccionados, registra la temperatura más alta del día. Ahora está listo para efectuar un estudio de correlación entre estas dos variables al darse cuenta de que la producción probablemente está relacionada con la desviación con respecto a una temperatura ideal y no con la temperatura misma. Es decir, él piensa que un día que es muy caluroso o muy frío tendría un efecto negativo sobre la producción cuando se le compara con un día que tiene una temperatura ideal. Él decide convertir sus lecturas de la temperatura en desviaciones con respecto a los 65 grados Fahrenheit, una temperatura que considera ideal para la obtención de un alto rendimiento. Sus datos aparecen a continuación; Y representa el número de unidades producidas,

mientras que X representa la diferencia absoluta (se eliminaron los signos negativos) entre la temperatura más alta del día y los 65 grados ideales:

Y	X	Y	X
485	12	327	15
512	10	308	25
625	3	603	8
585	4	321	35
318	27	426	5
405	10	410	12
379	18	515	2
497	12	498	7
316	27	357	17
351	20	429	8
525	4	401	12
395	11		

Gene ejecuta un análisis de regresión lineal simple usando la computadora de su compañía y el programa de Minitab.

Gene está complacido de ver los resultados de su análisis de regresión, tal como se presentan en la tabla 6-14. Los valores t correspondientes a los coeficientes de la intersección estimada y la pendiente son grandes (en valor absoluto) y sus valores p son muy pequeños. Ambos coeficientes (552 y -8.9) en la ecuación de regresión de la muestra son claramente significativos.

Al considerar r^2 , Gene se siente algo decepcionado por encontrar que este valor, si bien es satisfactorio, no es tan alto como esperaba (64.2%). Sin embargo, determina que es lo suficientemente alto para empezar a pensar en formas de incrementar los niveles de la producción diaria.

TABLA 6-14 Pantalla de resultado del análisis de regresión de Butcher Products, Inc.

Regression Analysis: Y versus X

The regression equation is

$$Y = 552 - 8.91 X$$

Predictor	Coef	SE Coef	T	P
Constant	552.04	22.85	24.16	0.000
X	-8.911	1.453	-6.13	0.000

S = 59.41 R-Sq = 64.2% R-Sq(adj) = 62.5%

Analysis of Variance

Source	DF	SS	MS	F	P
Regression	1	132,758	132,758	37.62	0.000
Residual Error	21	74,109	3,529		
Total	22	206,866			

PREGUNTAS

1. ¿Cuántas unidades pronosticaría usted para un día en el cual la temperatura más alta es de 89 grados Fahrenheit?

2. ¿Cuántas unidades pronosticaría usted para un día en el cual la temperatura más alta es de 41 grados Fahrenheit?
3. Con base en los resultados del análisis de regresión que se presentó antes, ¿qué acción aconsejaría usted a Gene para incrementar la producción diaria?

4. ¿Cree usted que Gene ha desarrollado una herramienta de pronóstico efectiva?

CASO 6-3 ACE MANUFACTURING

Ace Manufacturing Company da empleo a varios miles de personas en la fabricación de teclados, estuches para equipo y cables para la industria de las computadoras pequeñas. Recientemente, el presidente de Ace ha estado preocupado por la tasa de ausentismo entre los empleados de la compañía y pidió al departamento de personal que investigue este asunto. El departamento de personal se da cuenta de que un método efectivo para pronosticar el ausentismo fortalecería mucho su capacidad para planear adecuadamente.

Bill McGone, el director de personal, decide echar un vistazo a unos cuantos expedientes del personal en un intento por evaluar el problema. Decide seleccionar 15 expedientes de manera aleatoria y registra el número de faltas durante el año fiscal pasado, junto con la edad del empleado. Después de leer un artículo en una revista especializada sobre personal, McGone cree que la edad podría tener un efecto significativo en el ausentismo. Si descubre que la edad y las faltas mani-

fiestan una buena correlación en su pequeña muestra, tomará una muestra de 200 o 300 expedientes y formulará una buena ecuación de predicción.

La siguiente tabla contiene los valores de los datos recopilados en la muestra inicial. El número de faltas durante el pasado año fiscal está representado por *Y*, mientras que *X* representa la edad del empleado.

<i>Y</i>	<i>X</i>	<i>Y</i>	<i>X</i>
3	25	9	56
4	36	12	60
7	41	8	51
4	27	5	33
3	35	6	37
3	31	2	31
5	35	2	29
7	41		

PREGUNTAS

1. ¿Qué tan bien están correlacionados las faltas al trabajo y la edad? ¿Podría generalizarse esta correlación para la fuerza laboral completa?

2. ¿Cuál es la ecuación para pronosticar los días de ausentismo usando la edad como variable de predicción?

3. ¿Qué porcentaje de la variabilidad en días de ausencia se puede explicar al conocer la edad del empleado?

4. ¿Existe una relación significativa entre las faltas al trabajo y la edad? Al responder esta pregunta use
- los procedimientos estadísticos pertinentes para fundamentar su respuesta.

5. Suponga que una persona recién contratada tiene 24 años. ¿Cuántas faltas pronosticaría usted en el caso de esta persona durante el año fiscal?

6. ¿Debe proceder Bill McGone a tomar una muestra más grande de los empleados de la compañía con base en los resultados preliminares de su muestra?

7. ¿Se ha desarrollado un método efectivo de pronóstico?

CASO 6-4 MR. TUX

John Mosby ha escuchado que el análisis de regresión a menudo se usa para pronosticar las variables de las series de tiempo y, como tiene una computadora personal con un paquete de software de regresión, decide intentarlo. Los volúmenes de ventas mensuales de Mr. Tux de 1998 a 2005 son la variable dependiente. Como primer intento, decide usar el número del periodo como el factor de predicción, o variable X . Su primer valor de ventas Y , \$6,028, tendrá un valor X de 1, el segundo tendrá un valor de X de 2, etcétera. Su razonamiento es que la tendencia ascendente que él sabe que existe en sus datos será tomada en cuenta usando un valor siempre creciente de X para explicar sus datos de ventas.

Después de realizar el análisis de regresión en su computadora, John registra los siguientes valores:

$$t = 11.01 \quad r^2 = .563$$

$$F = 121.14 \quad \hat{Y} = -6,495 + 2,729.2X$$

El valor alto de t le indica a John que la pendiente de su línea de regresión ajustada (2,729.2) es significativa; es decir, rechaza la hipótesis nula porque la pendiente de la línea de regresión de la población es cero. El valor alto de F es congruente con este resultado

(John recuerda que $F = t^2$ para la regresión de línea recta), y la hipótesis nula de que la regresión no es significativa debe rechazarse.

John está decepcionado con el valor relativamente bajo de r^2 (56.3%). Él esperaba un valor más alto de manera que su ecuación de regresión simple pudiera utilizarse para pronosticar con exactitud sus ventas. Se da cuenta de que este valor bajo puede ser resultado de la estacionalidad de sus ventas mensuales, un hecho que conocía antes de iniciar sus actividades de pronóstico. Una variación estacional considerable tendría como resultado que los puntos de datos mensuales no se aglomerasen alrededor de la línea de regresión lineal, arrojando un valor insatisfactorio de r^2 .

Hay algo más que preocupa a John acerca de los resultados de su regresión. En el reporte de resultados de la computadora se encuentra este enunciado: Durbin-Watson = .99. John no entiende este resultado y llama a su profesor de estadística de la universidad. Después de que le describe los valores de su reporte de resultados de la regresión, el profesor le dice: “Tengo una clase en este momento, pero el bajo valor del estadístico de Durbin-Watson significa que uno de los supuestos de tu análisis de regresión no se cumple”.

PREGUNTAS

1. Comente acerca de la creencia de John de que sus ventas mensuales son altamente estacionales y, por lo tanto, traen consigo un valor “bajo” de r^2 .
2. ¿Cuál es su opinión con respecto a la idoneidad del método de pronóstico de John?
3. ¿De qué manera violan los datos de John uno de los supuestos del análisis de regresión?

CASO 6-5 CONSUMER CREDIT COUNSELING

La operación de Consumer Credit Counseling (CCC) se describió en el caso 1-2.

El director ejecutivo, Marv Harnishfeger, concluyó que la variable más importante que CCC necesitaba pronosticar era el número de nuevos clientes que serían atendidos durante el resto de 1993. Marv proporcionó a Dorothy Mercer los datos mensuales del

número de clientes nuevos atendidos por CCC en el periodo de enero de 1985 a marzo de 1993 (véase el caso 3-3). En el caso 3-3, Dorothy utilizó el análisis de autocorrelación para explorar el patrón de datos. En el caso 4-3 utilizó los métodos de promedios móviles y de suavización exponencial para pronosticar los meses restantes de 1993.

<i>Año</i>	<i>Ene.</i>	<i>Feb.</i>	<i>Mar.</i>	<i>Abr.</i>	<i>Mayo</i>	<i>Jun.</i>	<i>Jul.</i>	<i>Ago.</i>	<i>Sept.</i>	<i>Oct.</i>	<i>Nov.</i>	<i>Dic.</i>
1985	110	108	105	104	104	102	103	101	102	102	99	99
1986	102	105	106	107	105	106	105	105	103	105	103	101
1987	108	105	105	108	104	108	105	105	103	105	104	104
1988	104	109	109	103	103	104	99	102	101	101	102	102
1989	107	106	109	105	104	103	103	106	105	106	107	99
1990	103	106	110	108	110	105	105	106	107	107	111	112
1991	114	116	118	119	118	120	120	121	119	121	119	120
1992	122	118	123	118	118	120	122	120	122	123	124	122
1993	125	125	130									

Dorothy se pregunta si podría utilizar el análisis de regresión para desarrollar un buen modelo de pronóstico. Le pidió a Marv que pensara en algunas variables posibles de predicción. Marv sentía que el número de personas con cupones canjeables por alimentos podría estar relacionado con el número de clientes nuevos atendidos.

Dorothy sólo pudo obtener los datos del número de personas con cupones canjeables por alimentos a partir de enero de 1989 y hasta diciembre de 1992. A continuación se presentan esos datos.

Marv también estaba familiarizado con un índice de actividad de negocios calculado para el condado por el Consejo de Desarrollo Económico local. El índice de

1989	24,450 25,163	24,761 25,184	25,397 25,417	25,617 25,411	25,283 25,565	25,242 26,543
1990	26,784 28,161	27,044 27,936	27,567 28,423	28,080 28,366	28,142 29,029	28,412 29,035
1991	29,254 30,863	29,962 31,288	30,499 31,492	30,879 31,577	30,995 31,912	31,356 32,050
1992	32,383 33,556	32,625 33,751	33,499 33,777	34,076 33,769	34,191 34,077	33,788 34,232

actividad económica era un indicador de los cambios relativos en las condiciones generales de los negocios para la región. Los datos de este índice se encuentran en la parte superior de la página.

PREGUNTAS

1. Determine si existe una relación significativa entre el número de clientes nuevos atendidos y el número de personas con cupones canjeables por alimentos y/o el índice de actividad de negocios. No olvide la posibilidad de transformar los datos.

2. Desarrolle una ecuación de regresión y utilícela para pronosticar el número de clientes nuevos para los primeros tres meses de 1993.

3. Compare los resultados de su pronóstico con las observaciones reales para los primeros tres meses de 1993.
4. ¿El índice de actividad de negocios sería un buen factor de predicción del número de clientes nuevos?

5. Los datos consisten en una serie de tiempo. ¿Significa esto que se ha violado el supuesto de la independencia?

6. Suponga que usted desarrolló una buena ecuación de regresión. ¿Usaría usted esta ecuación para hacer un pronóstico del resto de 1993? Explique su respuesta.

CASO 6-6 AAA WASHINGTON

En el caso 5-5 se dio una visión general de AAA Washington cuando se pidió a los estudiantes que prepararan la descomposición de una serie de tiempo de las llamadas de servicio de emergencia en el camino recibidas por el club durante cinco años. La descomposición de la serie de tiempo realizada en el caso 5-5

demonstró que el patrón que Michael DeCoria había observado en el volumen de llamadas de emergencia en el camino probablemente era de naturaleza cíclica. A Michael le gustaría pronosticar el volumen de llamadas de emergencia en el camino para años futuros.

Otra investigación hecha por el club identificó varios factores que tenían efecto en el volumen de llamadas al servicio de emergencia en el camino. Entre estos factores se encuentran el promedio de temperatura diaria y la cantidad de lluvia registrada en un día. Esta investigación indica que las llamadas al servicio de emergencia en el camino se incrementan conforme aumentan las precipitaciones y conforme declina la temperatura del día. El club también cree que el número total de llamadas de emergencia que recibe es

dependiente del número de miembros en el club. Finalmente, Michael cree que el número de llamadas recibidas está relacionado con el ciclo general de la economía. La tasa de desempleo para el estado de Washington se utiliza como una buena medición sustituta de la economía general del estado de Washington. En la tabla 6-15 se incluyen los datos correspondientes a la tasa de desempleo, la temperatura mensual promedio, la precipitación mensual y el número de miembros del club.

TABLA 6-15 Datos para AAA Washington

<i>Año</i>	<i>Mes</i>	<i>Llamadas</i>	<i>Tasa de desempleo (%)</i>	<i>Temp. (° F)</i>	<i>Lluvia (pulgadas)</i>	<i>Miembros</i>
1988	Mayo	20,002	5.7867	55.1	3.75	
	Junio	21,591	5.7592	59	1.95	
	Julio	22,696	5.5718	63.8	0.89	
	Agosto	21,509	5.2939	63.8	0.51	384,746
	Septiembre	22,123	5.4709	59.1	2.31	388,652
	Octubre	21,449	5.5049	54.6	3.12	392,241
	Noviembre	23,475	5.863	45.4	8.42	393,115
	Diciembre	23,529	6.1349	41	4.44	392,631
1989	Enero	23,327	7.5474	40.3	4.3	396,975
	Febrero	24,050	7.8157	34.3	3.18	395,186
	Marzo	24,010	7.139	43.2	6.57	397,791
	Abril	19,735	6.2637	52.5	2.39	397,764
	Mayo	20,153	5.8332	55.3	2.83	399,348
	Junio	19,512	5.8077	62.4	1.3	401,949
	Julio	19,892	5.6713	62.9	0.83	404,866
	Agosto	20,326	5.4977	63.5	1.53	405,341
	Septiembre	19,378	5.2989	60.9	0.32	407,479
	Octubre	21,263	5.6028	51.9	3.44	405,430
	Noviembre	21,443	5.9143	46.2	7.24	412,134
	Diciembre	23,366	5	41.8	4.72	415,342
1990	Enero	23,836	6.1917	41.8	9.55	416,255
	Febrero	23,336	6.3775	38.9	5.73	423,001
	Marzo	22,003	5.7234	46.3	3.4	428,559
	Abril	20,155	4.7792	51.7	2.91	431,429
	Mayo	20,070	4.5715	54.9	2.15	434,675
	Junio	19,588	4.3899	59.8	3.55	435,864
	Julio	20,804	4.2559	66.7	0.59	437,969
	Aosto	19,644	3.9359	66.4	1.33	440,565
	Septiembre	17,424	3.9048	61.9	0.24	441,936
	Octubre	20,833	4.4294	50.4	1.17	448,595
	Noviembre	22,490	5.1523	45.8	10.66	446,291

TABLA 6-15 (continuación)

<i>Año</i>	<i>Mes</i>	<i>Llamadas</i>	<i>Tasa de desempleo (%)</i>	<i>Temp. (° F)</i>	<i>Lluvia (pulgadas)</i>	<i>Miembros</i>
1991	Diciembre	24,861	5.5102	33.9	7.93	446,455
	Enero	23,441	6.8901	37.9	4.4	445,392
	Febrero	19,205	7.0308	46.9	5.42	445,787
	Marzo	20,386	6.7186	43.4	4.35	445,746
	Abril	19,988	6.128	49.1	5.69	446,430
	Mayo	19,077	5.8146	54.3	2.12	450,001
	Junio	19,141	5.948	58.2	1.61	452,303
	Julio	20,883	5.9026	65.4	0.51	456,551
	Agosto	20,709	5.7227	66	2.8	455,747
	Septiembre	19,647	5.6877	60.9	0.2	456,764
	Octubre	22,013	6.2922	51	1.7	462,340
	Noviembre	22,375	7.0615	46.2	6.5	460,492
1992	Diciembre	22,727	7.437	42.4	3.45	465,361
	Enero	22,367	8.4513	43	7.26	465,492
	Febrero	21,155	8.7699	46	3.59	466,775
	Marzo	21,209	8.0728	48.9	1.47	467,168
	Abril	19,286	7.2392	52.7	4.35	464,575
	Mayo	19,725	7.0461	58.3	0.6	459,019
	Junio	20,276	7.0478	63.6	1.84	463,665
	Julio	20,795	7.108	64.9	1.41	463,775
	Agosto	21,126	6.7824	65	1.01	466,230
	Septiembre	20,251	6.7691	58.4	2.16	
	Octubre	22,069	7.5896	53.2	2.55	
	Noviembre	23,268	7.9908	44.8	6.23	
1993	Diciembre	26,039	8.246	37.8	4.38	
	Enero	26,127	9.5301	34.9	4.08	
	Febrero	20,067	9.279			
	Marzo	19,673	8.6802			
	Abril	19,142	7.7815			

Una conversación con el director del centro de llamadas del servicio de emergencia en el camino condujo a dos observaciones importantes: **1.** Los fabricantes de automóviles parecen diseñar vehículos que funcionan mejor a 65 grados Fahrenheit y **2.** el volumen de llamadas parece incrementarse notoriamente cuando la temperatura promedio disminuye unos

cuantos grados a partir de una temperatura promedio en el rango de los 30 grados en la escala que cuando se registra una disminución similar a partir de una temperatura promedio en el rango de los 60 grados en la escala. Esta información sugiere que el efecto de la temperatura sobre el servicio de emergencia en el camino no es lineal.

PREGUNTAS

1. Corra cuatro modelos de regresión lineal simple usando el número total de llamadas al servicio de emergencia en el camino como la variable dependiente, y la tasa de desempleo, la temperatura, la lluvia y el número de miembros como las cuatro variables independientes. ¿Cualquiera de estas cuatro variables independientes sería útil para la predicción del número total de llamadas al servicio?
2. Establezca una nueva variable de temperatura y relaciónela con el servicio de emergencia. Recuerde que la temperatura es una escala relativa y que la selección del punto cero es arbitraria. Si los vehículos están diseñados para funcionar mejor a los 65 grados Fahrenheit, entonces cada grado por arriba o por debajo de los 65 grados haría que los vehículos operaran menos confiablemente. Para llevar a cabo una transformación de los datos de temperatura que simule este efecto, comience por restar los 65 grados de los valores promedio mensuales de la temperatura. Esto reposiciona el “cero” en los 65 grados Fahrenheit. ¿Se deben usar los valores absolutos de esta nueva variable de temperatura?
3. Desarrolle un diagrama de dispersión. ¿Existe una relación lineal entre las llamadas y la nueva variable de la temperatura?
4. Si existe una relación no lineal entre las llamadas y la nueva variable de la temperatura, desarrolle el mejor modelo.

Aplicaciones de Minitab

El problema. En el ejemplo 6.2, el señor Bump quería correr un análisis de regresión con los datos presentados en la tabla 6-1.

Solución de Minitab

1. Introduzca los datos de la tabla 6-1 en la hoja de cálculo: los galones de las ventas de leche van en la columna C1 y los precios de venta en la columna C2.
2. Para correr un modelo de regresión, haga clic en los siguientes menús:
Stat>Regression>Regression
3. Aparecerá la ventana de diálogo de Regression que se presenta en la figura 6-18.
 - a) Se selecciona Sales como respuesta (Response) o variable dependiente.
 - b) Se selecciona Price como factor de predicción (Predictor) o variable independiente.
4. Para almacenar los residuos y las estimaciones Y, haga clic en Storage.
Aparece la ventana de diálogo Regression-Storage presentada en la figura 6-19..
 - a) Haga clic en Residuals debajo de Diagnostic Measures para almacenar los residuos en C3.
 - b) Haga clic en Fits debajo de Characteristics of Estimated Equation para almacenar los valores pronosticados de Y en C4.
 - c) Haga clic en OK para cerrar la ventana de diálogo Regression-Storage.
5. Para correr gráficas de residuos, haga clic en Graphs en la ventana de diálogo de Regression.
Aparecerá la ventana de diálogo Regression Graphs presentada en la figura 6-20.
 - a) Haga clic en Four in one para incluir las cuatro gráficas.
 - b) Haga clic en OK para cerrar la ventana de diálogo de Regression-Graphs.
 - c) Haga clic en OK en la ventana de diálogo Regression y se presentará el análisis de regresión desplegado en la tabla 6-8 en la ventana de sesión y sobre la pantalla aparecerá la gráfica de la figura 6-9.

El problema. En el ejemplo 6.11 Gilbert García quería pronosticar las ventas usando los gastos de publicidad.

Solución de Minitab

1. Introduzca los datos de la figura 6-10 en la hoja de cálculo: las ventas van en la columna C1 y los gastos de publicidad en la columna C2.




FIGURA 6-18 Ventana de diálogo Regression de Minitab




FIGURA 6-19 Ventana de diálogo Regression-Storage de Minitab

2. Para desarrollar el diagrama de dispersión que se observa en la figura 6-11, haga clic en Graph>Scatterplot
3. Aparecerán unas opciones de Scatterplots. Seleccione Simple y haga clic en OK.
4. Aparecerá la ventana de diálogo Scatterplot-Simple.




FIGURA 6-20 Ventana de diálogo Regression-Graphs de Minitab

- a) Seleccione C1, Sales, como la variable Y y C2, gastos de publicidad, como la variable X .
- b) Haga clic en OK y aparecerá el diagrama de dispersión que se aprecia en la figura 6-11.
5. Para correr un modelo ajustado como el de la figura 6-12, haga clic en
`Stat>Regression>Fitted Line Plot`
6. Aparecerá la ventana de diálogo Fitted Line Plot.
 - a) La variable dependiente Response (Y) es Sales.
 - b) La variable independiente o Predictor (X) es Advertising Expenditures.
 - c) El tipo de modelo de regresión es lineal (Linear).
 - d) Haga clic en OK. Los resultados se muestran en la figura 6-12.
7. Luego, convierta la variable X al logaritmo natural de X haciendo clic en los siguientes menús:
`Calc>Calculator`
8. Aparecerá la ventana de diálogo Calculator que se observa en la figura 6-21.
 - a) Introduzca C3 en el espacio junto a Store result in variable.
 - b) Para ejecutar la transformación, resalte Natural log (log base e) en la pantalla de Functions
 - c) Haga clic en Select y aparecerá LN (number) debajo de Select en el espacio de Expression.
 - d) Puesto que los gastos de publicidad constituyen la variable que se va a transformar, C2 sustituye a "number" en esta expresión.
 - e) Haga clic en OK y aparecerá el logaritmo natural de X en la celda C3 de la hoja de cálculo de los datos.




FIGURA 6-21 Ventana de diálogo Calculator de Minitab

9. Las transformaciones para la raíz cuadrada de X , el cuadrado de X y el recíproco de X también se llevan a cabo usando la ventana de diálogo Calculator.
10. La hoja de cálculo completa de Minitab se presenta en la figura 6-10.

Aplicaciones de Excel

El problema. En la situación del señor Bump, del ejemplo 6.1, se usa el análisis de regresión para determinar si el precio de venta sirve para pronosticar las ventas semanales de galones de leche.

Solución de Excel

1. Introduzca las ventas semanales (véase la tabla 6-1) de A1 a A10 y el precio de venta de B1 a B10 en la hoja de cálculo.
2. Haga clic en los siguientes menús para ejecutar el análisis de regresión:
Tools>Data Analysis
3. Aparecerá la ventana de diálogo Data Analysis. Debajo de Analysis Tools, seleccione Regression y haga clic en OK. Aparecerá la ventana de diálogo Regression de la figura 6-22.
 - a) Introduzca A1:A10 en Input Y Range.
 - b) Introduzca B1:B10 en Input X Range.
 - c) Haga clic en Output Range e introduzca C1 en el siguiente espacio.
 - d) Haga clic en OK, y aparecerá la salida presentada en la figura 6-23.




FIGURA 6-22 Ventana de diálogo Regression en Excel

Microsoft Excel - ExcelAppCh6

	A	B	C	D	E	F	G	H	I
1	10	1.3	SUMMARY OUTPUT						
2	6	2							
3	6	1.7	Regression Statistics						
4	12	1.5	Multiple R	0.863					
5	10	1.6	R Square	0.746					
6	16	1.2	Adjusted R Square	0.714					
7	5	1.6	Standard Error	2.725					
8	12	1.4	Observations	10					
9	17	1							
10	20	1.1	ANOVA						
11				df	SS	MS	F	Significance F	
12			Regression	1	174.175	174.175	23.448	0.0013	
13			Residual	8	59.425	7.428			
14			Total	9	233.6				
15									
16				Coefficients	Standard Error	t Stat	P-value	Lower 95%	Upper 95%
17			Intercept	32.136	4.409	7.289	0.0001	21.970	42.902
18			X Variable 1	14.539	3.002	-4.842	0.0013	21.462	7.615
19									
20									
21									
22									
23									
24									
25									

Ready NUM

FIGURA 6-23 Salida de Regresion de Excel para el ejemplo 6.1

Referencias

- Abraham, B. y J. Ledolter. *Introduction to regression Modeling*. Belmont, Calif.: Thomson Brooks/Cole, 2006.
- Draper, N. y H. Smith. *Applied Regression Analysis*, 3a. ed. Nueva York: Wiley, 1998.
- Flaherty, W. P. "Using Regression Analysis to Pick the Best Targets," *M&A* (marzo-abril de 1991): 47-49.
- Kutner, M. H., C. J. Nachtsheim y J. Neter. *Applied Linear Regression Models*, 4a. ed. Nueva York: McGraw-Hill, 2004.
- Moore, D. S., G. P. McCabe, W. M. Duckworth y S. L. Sclove. *The Practice of Business Statistics*. Nueva York: Freeman, 2003.

ANÁLISIS DE REGRESIÓN
MÚLTIPLE

En la regresión lineal simple se investiga la relación entre una variable independiente y una variable dependiente. A menudo la relación entre dos variables permite pronosticar con exactitud la variable dependiente a partir del conocimiento de la variable independiente. Por desgracia, muchos escenarios de elaboración de pronósticos en la vida real no son tan simples. Con frecuencia se necesita más de una variable independiente para pronosticar con exactitud una variable dependiente. Los modelos de regresión con más de una variable independiente se llaman modelos de *regresión múltiple*. La mayoría de los conceptos presentados en la regresión lineal simple se utilizan en la regresión múltiple. Sin embargo, surgen algunos conceptos nuevos, ya que se usa más de una variable independiente para predecir la variable dependiente.

La *regresión múltiple* implica el uso de más de una variable independiente para predecir una variable dependiente.

DIVERSAS VARIABLES EXPLICATIVAS

Para ejemplificar, regresemos al problema en el cual se pronostica el volumen de las ventas de galones de leche a partir del conocimiento del precio por galón. El señor Bump enfrenta el problema de hacer un pronóstico que no es totalmente exacto. Él puede explicar casi el 75% de las diferencias en los galones vendidos de leche usando una variable independiente. Sin embargo, el 25% ($1 - r^2$) de la variación total no encuentra explicación. En otras palabras, por la evidencia muestral, el señor Bump conoce el 75% de lo que debe saber para pronosticar perfectamente el volumen de ventas. Para hacer un trabajo con mayor exactitud, necesita obtener otra variable explicativa que le permita explicar más de la variación total. Si el señor Bump puede reducir la variación no explicada, su pronóstico tendrá menos incertidumbre y más exactitud.

Es necesario investigar para conocer otra variable independiente que esté relacionada con el volumen de galones vendidos de leche. Sin embargo, esta nueva variable independiente, o predictiva, no debe estar muy estrechamente relacionada con la variable independiente que ya se está usando (el precio por galón). Si las dos variables independientes están profundamente relacionadas una con otra, explicarán la misma variación, y el hecho de agregar una segunda variable no mejorará el pronóstico.¹ En campos como la econometría y la estadística aplicada, existe gran preocupación por este problema de intercorrelación entre variables independientes, conocido a

¹Las variables explicativas interrelacionadas contienen, en esencia, la misma información y, por lo tanto, no aportan “nueva” información acerca del comportamiento de la variable dependiente. De manera ideal, los efectos de cada una de las variables explicativas sobre la variable dependiente no deben estar relacionados unos con otros.

menudo como *multicolinealidad*. La solución más sencilla al problema de dos variables independientes profundamente relacionadas consiste en *no* usarlas juntas. Estudiaremos el problema de la multicolinealidad más adelante en este capítulo

MATRIZ DE CORRELACIÓN

El señor Bump determina que los gastos en publicidad podrían ayudar a mejorar su pronóstico del volumen semanal de ventas. Él investiga las relaciones entre el gasto en publicidad, el volumen de ventas y el precio por galón examinando una matriz de correlación. La *matriz de correlación* se elabora calculando los coeficientes de correlación simple de cada combinación de pares de variables.

En la tabla 7-1 se presenta un ejemplo de una matriz de correlación. El coeficiente de correlación que indica la relación entre las variables 1 y 2 se representa como r_{12} . Observe que el primer subíndice, 1, hace referencia a la fila y el segundo subíndice, 2, hace referencia a la columna de la tabla. Esta convención permite determinar, con una mirada, la relación entre cualquier par de variables. Por supuesto, la correlación entre, digamos, la variable 1 y la variable 2 es exactamente la misma que la correlación entre las variables 2 y 1; es decir, $r_{12} = r_{21}$. Por lo tanto, sólo se necesita la mitad de la matriz de correlación. Además, la correlación de una variable consigo misma siempre es 1, de manera que, por ejemplo, $r_{11} = r_{22} = r_{33} = 1$.

El señor Bump ingresa sus datos en la computadora, y los resultados de la matriz de correlación se muestran en la tabla 7-2. Un análisis de las relaciones entre el gasto en publicidad, el volumen de ventas y el precio por galón indica que la nueva variable independiente debe contribuir a mejorar el pronóstico. La matriz de correlación indica que el gasto en publicidad tiene una relación positiva alta ($r_{13} = .89$) con la variable dependiente, el volumen de ventas, y una relación negativa moderada ($r_{23} = -.65$) con la variable independiente, el precio por galón. Esta combinación de relaciones debería permitir que los gastos en publicidad expliquen algo de la variación total del volumen de ventas que todavía no se ha explicado mediante el precio por galón. Como veremos, cuando se usan tanto el precio por galón como el gasto en publicidad para estimar el volumen de ventas R^2 aumenta al 93.2%.

El análisis de la matriz de correlación es un paso inicial importante en la resolución de cualquier problema que implique múltiples variables independientes

TABLA 7-1 Matriz de correlación

Variables	Variables		
	1	2	3
1	r_{11}	r_{12}	r_{13}
2	r_{21}	r_{22}	r_{23}
3	r_{31}	r_{32}	r_{33}

TABLA 7-2 Matriz de correlación de los datos del señor Bump

Variables	Variables		
	Ventas 1	Precio 2	Publicidad 3
Ventas, 1	1.00	-.86	.89
Precio, 2		1.00	-.65
Publicidad, 3			1.00

MODELO DE REGRESIÓN MÚLTIPLE

En la regresión simple, la variable dependiente puede representarse mediante Y , y la variable independiente mediante X . En el análisis de regresión múltiple, las variables independientes se denotan mediante X con subíndices. Así, las variables dependientes se siguen representando por Y y las variables independientes por $X_1, X_2, \dots, X_k$. Una vez que se ha determinado el conjunto inicial de variables independientes, la relación entre Y y estas X se expresa como un *modelo de regresión múltiple*.

En el modelo de regresión múltiple, la respuesta promedio se toma como una función lineal de las variables explicativas:

$$\mu_Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k \quad (7.1)$$

Esta expresión es la *función de regresión múltiple de la población*. Al igual que en el caso de la regresión lineal simple, no podemos observar directamente la función de regresión de la población porque los valores observados de Y varían alrededor de sus medias. Cada combinación de valores para todas las X define la media de una subpoblación de respuestas Y . Suponemos que las Y de cada una de estas subpoblaciones están distribuidas de manera normal alrededor de sus medias con la misma desviación estándar, σ .

Los datos de la regresión lineal simple consisten en observaciones (X_i, Y_i) de las dos variables. En la regresión múltiple, los datos en cada caso consisten en una observación de la respuesta y una observación de cada una de las variables independientes. La i -ésima observación de la j -ésima variable explicativa se representa por X_{ij} . Con esta notación, los datos de la regresión múltiple tienen la forma que se ilustra en la tabla 7-3. Es conveniente referirse a los datos del i -ésimo caso simplemente como la i -ésima observación. Con esta convención, n es el número de observaciones y k es el número de variables explicativas.

Modelo estadístico para la regresión múltiple

La respuesta, Y , es una variable aleatoria que está relacionada con las variables independientes (predictivas), $X_1, X_2, \dots, X_k$, por

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \varepsilon$$

donde

1. Para la i -ésima observación, $Y = Y_i$ y $X_1, X_2, \dots, X_k$ se definen para los valores $X_{i1}, X_{i2}, \dots, X_{ik}$.

TABLA 7-3 Estructura de datos de la regresión múltiple

Caso	Variables explicativas				Respuesta
	X_1	X_2		X_k	Y
1	X_{11}	X_{12}		X_{1k}	Y_1
2	X_{21}	X_{22}		X_{2k}	Y_2
.	.	.		.	.
.	.	.		.	.
i	X_{i1}	X_{i2}		X_{ik}	Y_i
.	.	.		.	.
.	.	.		.	.
n	X_{n1}	X_{n2}		X_{nk}	Y_n

2. Las ε 's son componentes de error que representan las desviaciones de la respuesta de la relación verdadera. Son variables aleatorias no observables que explican los efectos de otros factores sobre la respuesta. Se supone que los errores son independientes y todos están distribuidos de manera normal con una media 0 y desviación estándar desconocida σ .
3. Los coeficientes de regresión, $\beta_0, \beta_1, \dots, \beta_k$, que en conjunto definen la función de regresión son desconocidos.

Teniendo los datos, es posible estimar los coeficientes de regresión usando el principio de mínimos cuadrados. Las estimaciones de los mínimos cuadrados se representan por $b_0, b_1, \dots, b_k$ y la función de regresión estimada por

$$\hat{Y} = b_0 + b_1X_1 + \dots + b_kX_k \quad (7.2)$$

Los residuos, $e = Y - \hat{Y}$, son estimaciones del componente de error y similares al escenario de la regresión lineal simple; la correspondencia entre la población y la muestra es

$$\text{Población: } Y = \beta_0 + \beta_1X_1 + \beta_2X_2 + \dots + \beta_kX_k + \varepsilon$$

$$\text{Muestra: } Y = b_0 + b_1X_1 + b_2X_2 + \dots + b_kX_k + e$$

Por lo general, los cálculos en el análisis de regresión múltiple se realizan usando paquetes de software como Minitab y Excel (véanse las secciones de aplicaciones de Minitab y Excel al final del capítulo).

Ejemplo 7.1

Para los datos presentados en la tabla 7-4, el señor Bump considera un modelo de regresión múltiple que relaciona el volumen de ventas (Y) con el precio (X_1) y la publicidad (X_2):

$$Y = \beta_0 + \beta_1X_1 + \beta_2X_2 + \varepsilon$$

El señor Bump determina la función de regresión ajustada:

$$\hat{Y} = 16.41 - 8.25X_1 + .59X_2$$

Los valores de los mínimos cuadrados — $b_0 = 16.41$, $b_1 = -8.25$, y $b_2 = .59$ — minimizan la suma de errores al cuadrado:

$$SSE = \sum_i (Y_i - b_0 - b_1X_{i1} - b_2X_{i2})^2 = \sum_i (Y_i - \hat{Y}_i)^2$$

para todas las opciones posibles de b_0, b_1 , y b_2 . Aquí, la función que mejor ajusta es un plano (véase la figura 7-1). Los puntos de datos se grafican en tres dimensiones a lo largo de los ejes Y, X_1 , y X_2 . Los puntos caen por encima y por debajo del plano de manera tal que $\sum (Y - \hat{Y})^2$ es un mínimo.


La función de regresión ajustada servirá para pronosticar las ventas de la siguiente semana. Si los planes requieren un precio por galón de \$1.50 y gastos de publicidad de \$1,000, el pronóstico es de 9.935 miles de galones; es decir,

$$\hat{Y} = 16.41 - 8.25X_1 + .59X_2$$

$$\hat{Y} = 16.41 - 8.25(1.5) + .59(10) = 9.935$$

TABLA 7-4 Datos del señor Bump para el ejemplo 7.1

<i>Semana</i>	<i>Ventas (en miles)</i> Y	<i>Precio por galón (\$)</i> X_1	<i>Publicidad (en cientos de \$)</i> X_2
1	10	1.30	9
2	6	2.00	7
3	5	1.70	5
4	12	1.50	14
5	10	1.60	15
6	15	1.20	12
7	5	1.60	6
8	12	1.40	10
9	17	1.00	15
10	20	1.10	21
Totales	112	14.40	114
Medias	11.2	1.44	11.4

**FIGURA 7-1** Plano de regresión ajustado de los datos del señor Bump; ejemplo 7.1

INTERPRETACIÓN DE LOS COEFICIENTES DE REGRESIÓN

Considere la interpretación de b_0 , b_1 , y b_2 en la función de regresión ajustada del señor Bump. Otra vez el valor de b_0 es la intersección con Y . Sin embargo, ahora se interpreta como el valor de $\hat{Y}$ cuando tanto X_1 como X_2 son iguales a cero. Los coeficientes b_1 y b_2 se conocen como los *coeficientes de la regresión parcial* o *neta*. Cada uno mide el cambio promedio de Y por unidad de cambio en las variables independientes relevantes. Sin embargo, como la función de regre-

sión está midiendo la influencia simultánea de todas las variables independientes sobre Y , el efecto parcial o neto de X_1 (o de cualquier X) debe medirse por separado de la influencia de otras variables. Por lo tanto, se dice que b_1 mide el cambio promedio de Y por unidad de cambio de X_1 , cuando se mantienen constantes las demás variables independientes.

El *coeficiente de regresión parcial o neto* mide el cambio promedio de la variable dependiente por unidad de cambio en la variable independiente relevante, cuando se mantienen constantes las demás variables independientes.

En este ejemplo, el valor b_1 de -8.25 indica que por cada incremento de 1 centavo en el precio de un galón de leche cuando los gastos de publicidad se mantienen *constantes*, la cantidad comprada se reduce un promedio de 82.5 galones. De manera análoga, el valor b_2 de $.59$ significa que, si los gastos de publicidad se incrementan \$100 cuando el precio por galón se mantiene constante, el volumen de ventas aumentará en un promedio de 590 galones.

Ejemplo 7.2

Para ilustrar los efectos netos de las X individuales sobre la respuesta, considere la situación en la cual el precio es de \$1.00 por galón y se gastan \$1,000 en publicidad. Así

$$\begin{aligned}\hat{Y} &= 16.41 - 8.25X_1 + .59X_2 \\ &= 16.41 - 8.25(1.00) + .59(10) \\ &= 16.41 - 8.25 + 5.9 = 14.06\end{aligned}$$

El pronóstico de las ventas es de 14,060 galones de leche.

¿Cuál es el efecto sobre las ventas del incremento de un centavo en el precio si se gastan \$1,000 en publicidad?

$$\begin{aligned}\hat{Y} &= 16.41 - 8.25(1.01) + .59(10) \\ &= 16.41 - 8.3325 + 5.9 = 13.9775\end{aligned}$$

Advierta que las ventas disminuyen 82.5 galones ($14.06 - 13.9775 = .0825$).

¿Cuál es el efecto sobre las ventas de un aumento de \$100 en publicidad si el precio permanece constante en \$1.00

$$\begin{aligned}\hat{Y} &= 16.41 - 8.25(1.00) + .59(11) \\ &= 16.41 - 8.25 + 6.49 = 14.65\end{aligned}$$

Note que las ventas se incrementan 590 galones ($14.65 - 14.06 = .59$).

INFERENCIAS EN MODELOS DE REGRESIÓN MÚLTIPLE

La inferencia en los modelos de regresión múltiple es análoga a la de la regresión lineal simple. La estimación de mínimos cuadrados de los parámetros del modelo, la estimación de los errores estándar, las estadísticas t que se usan para examinar la significancia de los términos individuales del modelo de regresión, y el estadístico F que permite verificar la significancia de la regresión se obtienen empleando paquetes estándar de software estadístico. La determinación manual de estas cantidades en un análisis de regresión múltiple de cualquier tamaño es impráctica, y se debe usar una computadora para efectuar los cálculos.

Como en el capítulo 6, cualquier observación Y puede escribirse como

$$\text{Observación} = \text{Ajuste} + \text{Residuo}$$

o

$$Y = \hat{Y} + (Y - \hat{Y})$$

donde

$$\hat{Y} = b_0 + b_1X_1 + b_2X_2 + \cdots + b_kX_k$$

es la función de regresión ajustada. Recuerde que $\hat{Y}$ es una estimación de la función de regresión de la población. Representa la parte de Y que se explica por la relación de Y con las X . El residuo, $Y - \hat{Y}$, es una estimación del componente de error del modelo. Representa la parte de Y que no explican las variables explicativas.

La descomposición de la suma de cuadrados y los grados de libertad asociada son

$$\begin{aligned}\Sigma(Y - \bar{Y})^2 &= \Sigma(\hat{Y} - \bar{Y})^2 + \Sigma(Y - \hat{Y})^2 \\ SST &= SSR + SSE \\ df: n - 1 &= k + n - k - 1\end{aligned}\tag{7.3}$$

La variación total en la respuesta, SST , consiste en dos componentes: SSR , la variación explicada por las variables explicativas a través de la función de regresión estimada, y el SSE , la variación no explicada o el error. La información de la ecuación 7.3 puede obtenerse haciendo un análisis de la tabla de varianza (ANOVA), la cual se analizará en una sección posterior.

Error estándar de la estimación

El error estándar de la estimación es la desviación estándar de los residuos. Mide la dispersión típica de los valores de Y alrededor de la función de regresión ajustada.² El error estándar de la estimación es

$$s_{y \cdot x's} = \sqrt{\frac{\Sigma(Y - \hat{Y})^2}{n - k - 1}} = \sqrt{\frac{SSE}{n - k - 1}} = \sqrt{MSE}\tag{7.4}$$

donde

n = el número de observaciones

k = el número de variables independientes en la función de regresión

$SSE = \Sigma(Y - \hat{Y})^2$ = suma de los cuadrados de los residuos

$MSE = SSE/(n - k - 1)$ = el cuadrado medio de los residuos

El *error estándar de la estimación* es la desviación estándar de los residuos. Mide la cantidad en que los valores reales de (Y) difieren de los valores estimados ($\hat{Y}$). Para muestras relativamente grandes, esperaríamos que alrededor del 67% de las diferencias $Y - \hat{Y}$ estén dentro de $s_{y \cdot x's}$ de cero, y alrededor del 95% de estas diferencias estén dentro de $2 s_{y \cdot x's}$ de cero.

Ejemplo 7.3

Las cantidades requeridas para calcular el error estándar de la estimación para los datos del señor Bump se indican en la tabla 7-5.

²El error estándar de la estimación es una estimación de σ , la desviación estándar del término de error, ε , en el modelo de regresión múltiple.

TABLA 7-5 Residuos del modelo de los datos del señor Bump para el ejemplo 7.3

<i>Y</i>	<i>X</i> ₁	<i>X</i> ₂	<i>Y</i> pronosticada (<i>Ŷ</i>) usando $\hat{Y} = 16.406 - 8.248X_1 + .585X_2$	Residuo (<i>Y</i> - <i>Ŷ</i>)	(<i>Y</i> - <i>Ŷ</i>) ²
10	1.30	9	10.95	-.95	.90
6	2.00	7	4.01	1.99	3.96
5	1.70	5	5.31	-.31	.10
12	1.50	14	12.23	-.23	.05
10	1.60	15	11.99	-1.99	3.96
15	1.20	12	13.53	1.47	2.16
5	1.60	6	6.72	-1.72	2.96
12	1.40	10	10.71	1.29	1.66
17	1.00	15	16.94	.06	.00
20	1.10	21	19.62	.38	.14
Totales				.00	15.90

El error estándar de la estimación es

$$s_{y \cdot x'} = \sqrt{\frac{15.90}{10 - 2 - 1}} = \sqrt{2.27} = 1.51$$

Con una sola variable explicativa X_1 = precio, el error estándar de la estimación era $s_{y \cdot x} = 2.72$ (véase el capítulo 6). Con la variable explicativa adicional, X_2 = publicidad, el señor Bump redujo el error estándar de la estimación en casi un 50%. Las diferencias entre los volúmenes reales de leche vendida y los pronósticos obtenidos a partir de la ecuación de regresión ajustada son considerablemente más pequeñas con dos variables explicativas que con una sola. Es decir, la ecuación con dos variables explicativas está mucho muy cerca de reproducir el valor real de las Y que la ecuación con una sola variable explicativa.

Significancia de la regresión

La tabla ANOVA basada en la descomposición de la variación total de Y (SST) en sus partes explicadas (SSR) y no explicadas (SSE) (véase la ecuación 7.3) se presenta en la tabla 7-6.

Considere la hipótesis $H_0: \beta_1 = \beta_2 = \cdots = \beta_k = 0$. Esta hipótesis significa que Y no está relacionada con ninguna de las X (el coeficiente de cada X es cero). La prueba de H_0 se conoce como prueba de *significancia de la regresión*. Si los supuestos del modelo de regresión son apropiados y H_0 es verdadera, la razón

$$F = \frac{MSR}{MSE}$$

tiene una distribución F con $df = k, n - k - 1$. De este modo, la razón F se puede usar como prueba de la significancia de la regresión.

TABLA 7-6 Tabla ANOVA de regresión múltiple

<i>Fuente</i>	<i>Suma de cuadrados</i>	<i>df</i>	<i>Cuadrado medio</i>	<i>Razón F</i>
Regresión	SSR	k	$MSR = SSR/k$	$F = \frac{MSR}{MSE}$
Error	SSE	$n - k - 1$	$MSE = SSE/(n - k - 1)$	
Total	SST	$n - 1$		

En la regresión lineal simple, sólo existe una variable explicativa. En consecuencia, la prueba de significancia de la regresión usando la razón F de la tabla ANOVA es equivalente a la prueba t de dos colas para la hipótesis de que la pendiente de la línea de regresión es cero. Para la regresión múltiple, las pruebas t (que se presentarán dentro de poco) examinan la significancia de las X individuales en la función de regresión, y la prueba F examina la significancia de todas las X de manera colectiva.

Prueba F de la significancia de la regresión

En el modelo de regresión múltiple, las hipótesis

$$H_0: \beta_1 = \beta_2 = \cdots = \beta_k = 0$$

$$H_1: \text{por lo menos una } b_j \neq 0$$

se prueban mediante la razón F :

$$F = \frac{MSR}{MSE}$$

con $df = k, n - k - 1$. Con un nivel de significancia α , la región de rechazo es

$$F > F_\alpha$$

donde F_α es el punto que deja un área de α a la derecha de una distribución F con $\delta_1 = k, \delta_2 = n - k - 1$ grados de libertad del numerador y del denominador respectivamente.

El *coeficiente de determinación*, R^2 , está dado por

$$\begin{aligned} R^2 &= \frac{SSR}{SST} = \frac{\sum(\hat{Y} - \bar{Y})^2}{\sum(Y - \bar{Y})^2} \\ &= 1 - \frac{SSE}{SST} = 1 - \frac{\sum(Y - \hat{Y})^2}{\sum(Y - \bar{Y})^2} \end{aligned} \quad (7.5)$$

y tiene la misma forma e interpretación que la r^2 de la regresión lineal simple. Representa la proporción de variación en la respuesta, Y , explicada por la relación de Y con las X .

Un valor de $R^2 = 1$ indica que todas las Y observadas caen exactamente sobre la función de regresión ajustada. Toda la variación en la respuesta se explica mediante la regresión. Un valor de $R^2 = 0$ dice que $\hat{Y} = \bar{Y}$ —es decir, $SSR = 0$ —y nada de la variación en Y se explica mediante la regresión. En la práctica, $0 \leq R^2 \leq 1$, y el valor de R^2 debe interpretarse dentro de los extremos 0 y 1.

La cantidad

$$R = \sqrt{R^2} \quad (7.6)$$

se llama *coeficiente de correlación múltiple* y es la correlación entre las respuestas, Y , y los valores ajustados, $\hat{Y}$. Puesto que los valores ajustados predicen las respuestas, R siempre es positiva, de manera que $0 \leq R \leq 1$.

Para la regresión múltiple,

$$F = \frac{R^2}{1 - R^2} \left(\frac{n - k - 1}{k} \right) \quad (7.7)$$

de manera que, si todo lo demás permanece igual, las regresiones significativas (razones F grandes) están asociadas con valores relativamente grandes de R^2 .

El coeficiente de determinación (R^2) siempre se incrementa al agregar una variable independiente, X , a la función de regresión, incluso si esta variable adicional no es importante.³ Por esta razón, algunos analistas prefieren interpretar R^2 ajustada al número de términos en la función de regresión. El coeficiente ajustado de determinación, $\bar{R}^2$, está dado por

$$\bar{R}^2 = 1 - (1 - R^2) \left(\frac{n - 1}{n - k - 1} \right) \quad (7.8)$$

Al igual que R^2 , $\bar{R}^2$ es una medida de la proporción de la variabilidad en la respuesta, Y , explicada por la regresión. Es posible demostrar que $0 \leq \bar{R}^2 \leq R^2$. Cuando el número de observaciones (n) es grande en relación con el número de variables independientes (k), $\bar{R}^2 \approx R^2$. Si $k = 0$, $\hat{Y} = \bar{Y}$ y $\bar{R}^2 = R^2$. En muchas situaciones prácticas, no hay mucha diferencia entre las magnitudes de $\bar{R}^2$ y R^2 .

Ejemplo 7.4

Usando la suma total de cuadrados de la tabla 7-6 y la suma de cuadrados de los residuos del ejemplo 7.3, la descomposición de la suma de cuadrados para el problema del señor Bump es

$$\begin{aligned} SST &= SST + SSE \\ \sum (Y - \bar{Y})^2 &= \sum (\hat{Y} - \bar{Y})^2 + \sum (Y - \hat{Y})^2 \\ 233.6 &= 217.7 + 15.9 \end{aligned}$$

Por consiguiente, usando ambas formas de la ecuación 7.5 para ilustrar los cálculos,

$$R^2 = \frac{217.7}{233.6} = 1 - \frac{15.9}{233.6} = .932$$

y el coeficiente de correlación múltiple es $R = \sqrt{R^2} = \sqrt{.932} = .965$.

Aquí, alrededor del 93% de la variación en el volumen de ventas es explicado por la regresión, es decir, la relación entre las ventas y el precio y los gastos de publicidad. Además, la correlación entre las ventas y las ventas ajustadas es de alrededor de .965, lo que indica un acuerdo cercano entre los valores reales y los pronosticados. En la tabla 7-7 se presenta un resumen del análisis de los datos del señor Bump al respecto.

Variables explicativas individuales

El coeficiente de una X individual en la función de regresión mide el efecto parcial o neto de esa X sobre la respuesta, Y , manteniendo constantes las demás X de la ecuación. Si la regresión se considera como significativa, entonces es de interés examinar la significancia de las variables explicativas individuales. El asunto es éste: Dadas las otras X , ¿es importante el efecto de esta X particular, o es posible eliminar de la función de regresión este término X ? Esta pregunta puede contestarse examinando un valor apropiado de t .

³Aquí, “no es importante” significa “no significativo”. Es decir, el coeficiente de X no es significativamente diferente de cero (véase la sección que sigue sobre las variables individuales de explicativas).

TABLA 7-7 Resumen del análisis de los datos del señor Bump para el ejemplo 7.4

<i>Variables usadas para explicar la variabilidad de Y</i>	R^2	$\Sigma(Y - \hat{Y})^2$
Ninguna	.00	233.6
Precio	.75	59.4
Precio y gastos de publicidad	.93	15.9

Si $H_0: \beta_j = 0$ es verdadera, el *estadístico de prueba*, t , para $t = b_j/s_{b_j}$ tiene una distribución t con $df = n - k - 1$.⁴

Para evaluar la significancia del término j -ésimo, $j = 0, 1, \dots, k$, en la función de regresión, el estadístico de prueba t se compara con un punto porcentual de una distribución t con $n - k - 1$ grados de libertad. Para una prueba en el nivel de significancia α de

$$H_0: \beta_j = 0$$

$$H_1: \beta_j \neq 0$$

si $|t| > t_{\alpha/2}$ se rechaza H_0 . Aquí, $t_{\alpha/2}$ es el punto que deja un área $\alpha/2$ a la derecha de una distribución t con $df = n - k - 1$.

Se debe tener cuidado en la eliminación de la función de regresión de aquellas variables explicativas que se consideran insignificantes por la prueba t ($H_0: \beta_j = 0$ no puede rechazarse). Si las X están relacionadas (multicolinealidad), los coeficientes de los mínimos cuadrados y los valores correspondientes de t pueden cambiar, algunas veces de manera apreciable, si una X individual se elimina de la función de regresión. Por ejemplo, una X que previamente era insignificante puede convertirse en significativa. En consecuencia, si existen varios valores t pequeños (insignificantes), las variables explicativas deben eliminarse de una en una (comenzando con la variable que tiene el valor t más pequeño) en vez de hacerlo por grupos. El proceso se detiene cuando la regresión es significativa y todas las variables explicativas tienen estadísticos t grandes (significativos).

Pronóstico de una respuesta futura

Un pronóstico, $\hat{Y}^*$, de una respuesta futura, Y , para valores nuevos de las X —digamos, $X_1 = X_1^*$, $X_2 = X_2^*, \dots, X_k = X_k^*$ —está dado por la evaluación de la función de regresión ajustada para las X :

$$\hat{Y}^* = b_0 + b_1X_1^* + b_2X_2^* + \dots + b_kX_k^* \quad (7.9)$$

Con un nivel de confianza $1 - \alpha$, un intervalo de predicción para Y toma la forma

$$\hat{Y}^* \pm t_{\alpha/2} \times (\text{Error estándar del pronóstico})$$

El error estándar del pronóstico es una expresión complicada, pero el error estándar de la estimación, $s_{y \cdot x}$, es un componente importante. De hecho, si n es grande y todas las X son muy variables, un intervalo de predicción *aproximado* de $100(1 - \alpha)\%$ para una nueva respuesta Y es

$$(\hat{Y}^* - t_{\alpha/2}s_{y \cdot x}, \hat{Y}^* + t_{\alpha/2}s_{y \cdot x}) \quad (7.10)$$

⁴Aquí, b_j es el coeficiente de mínimos cuadrados para la j -ésima variable explicativa, X_j , y S_{b_j} es la estimación de la desviación estándar (error estándar). Estos dos estadísticos se obtienen normalmente a través de un software como Minitab.

RESULTADO DE LA COMPUTADORA

En la tabla 7-8 se presenta el resultado de computadora para el problema del señor Bump. La revisión de resultado trae consigo las siguientes observaciones (las explicaciones aparecen en la tabla 7-8).

1. Los coeficientes de regresión son -8.25 para el precio y $.585$ para gastos de publicidad. La ecuación de regresión ajustada es $\hat{Y} = 16.4 - 8.25X_1 + .585X_2$.
2. La ecuación de regresión explica el 93.2% de la variación en el volumen de ventas.
3. El error estándar de la estimación es 1.5072 galones. Este valor es una medida de la cantidad en que los valores reales difieren de los valores ajustados.
4. En el capítulo 6, el coeficiente de la pendiente de regresión se sometió a prueba para determinar si era diferente de cero. En la presente situación, el estadístico t grande de -3.76 para la variable de precio, X_1 , y su pequeño valor p (.007) indican que el coeficiente del precio es significativamente diferente de cero (se rechaza $H_0: \beta_1 = 0$). Dada la variable de publicidad, X_2 , en la función de regresión, el precio no puede eliminarse de la función de regresión. De manera análoga, el estadístico t grande de 4.38 para la variable de publicidad, X_2 , y su pequeño valor p (.003) indican que el coeficiente de publicidad es significativamente diferente de cero (se rechaza $H_0: \beta_2 = 0$). Dada la variable del precio, X_1 , en la función de regresión, la variable de publicidad no puede eliminarse de la función de regresión. (Como un punto de referencia para la magnitud de los valores t , con siete grados de libertad, la tabla B-3 indica $t_{.01} = 2.998$.) En resumen, los coeficientes de ambas variables explicativas son significativamente diferentes de cero.
5. El valor p .007 es la probabilidad de obtener un valor de t por lo menos tan grande como -3.76 si la hipótesis $H_0: \beta_1 = 0$ es verdadera. Puesto que esta probabilidad es extremadamente pequeña, es improbable que H_0 sea verdadera, y se rechaza. El coeficiente del precio es significativamente diferente de cero. El valor p .003 es la probabilidad de obtener un valor t por lo menos tan grande como 4.38 si $H_0: \beta_2 = 0$ es verdadera. Puesto que un valor t de esta magnitud es extremadamente improbable, se rechaza, H_0 . El coeficiente de publicidad es significativamente diferente de cero.

TABLA 7-8 Resultado de Minitab para los datos del señor Bump

Correlations: Y, X1, X2

	Y	X1
X1	-0.863	
X2	0.891	-0.654 (6)

Regression Analysis: Y versus X1, X2

The regression equation is

$$Y = 16.4 - 8.25 X1 + 0.585 X2 \quad (1)$$

Presictor	Coef	SE Coef	T	P
Constant	16.406 (1)	4.343	3.78	0.007
X1	-8.248 (1)	2.196	-3.76 (4)	0.007 (5)
X2	0.5851 (1)	0.1337	4.38 (4)	0.003 (5)

$$S = 1.50720 \quad (3) \quad R\text{-Sq} = 93.2\% \quad (2) \quad R\text{-Sq}(\text{adj}) = 91.2\% \quad (9)$$

Analysis of Variance

Source	DF	SS	MS	F	P
Regression	2	217.70 (7)	108.85	47.92 (8)	0.000
Residual Error	7	15.90 (7)	2.27		
Total	9	233.60 (7)			

6. La matriz de correlación se presentó en la tabla 7-2.
7. La descomposición de la suma de cuadrados, $SST = SSR + SSE$ (suma total de cuadrados = suma de cuadrados de la regresión + suma de cuadrados de los errores), se presentó en el ejemplo 7.4.
8. El valor F calculado (47.92) se utiliza para probar la significancia de la regresión. La razón grande F y su valor pequeño p (.000) indican que la regresión es significativa (se rechaza $H_0: \beta_1 = \beta_2 = 0$). La razón F se calcula mediante

$$F = \frac{MSR}{MSE} = \frac{108.85}{2.27} = 47.92$$

Como una referencia para la magnitud de la razón F , la tabla B-5 proporciona el punto superior de 1% de una distribución F con dos y siete grados de libertad como $F_{.01} = 9.55$. La función de regresión explica una cantidad significativa de la variabilidad en las ventas, Y .

9. El cálculo de la R^2 corregida o ajustada, $\bar{R}^2$, es

$$\begin{aligned}\bar{R}^2 &= 1 - (1 - R^2) \left(\frac{n - 1}{n - k - 1} \right) \\ &= 1 - (1 - .932) \left(\frac{10 - 1}{10 - 2 - 1} \right) = 1 - (.068)(1.286) = .912\end{aligned}$$

VARIABLES FICTICIAS

Considere el siguiente ejemplo.

Ejemplo 7.5

Suponga que un analista desea investigar qué tan bien predice el rendimiento en el trabajo una prueba de aptitud. Ocho mujeres y siete hombres realizaron la prueba, la cual mide la destreza para manipular objetos minúsculos. Cada sujeto pasó por un mes de entrenamiento intensivo como ensamblador de aparatos electrónicos, seguido de otro mes como ensamblador real, durante el cual su productividad fue evaluada por medio de un índice cuyos valores iban de 0 a 10 (cero significa improductivo).

Los datos se muestran en la tabla 7-9. Un diagrama de dispersión se presenta en la figura 7-2. Cada mujer trabajadora se representa por un cero y cada trabajador masculino se representa por un 1.

Al observar la figura 7-2 de inmediato se hace evidente que la relación de esta prueba de aptitud con el rendimiento en el trabajo sigue dos patrones distintos, uno aplicable a las mujeres y otro a los hombres.

Algunas veces es necesario determinar cómo se relaciona una variable dependiente con una variable independiente cuando un factor *cualitativo* influye en la situación. Esta relación se establece creando una *variable ficticia*. Existen muchas maneras de identificar cuantitativamente las clases de una variable cualitativa. En este texto se usan los valores 0 y 1.

Las *variables ficticias*, o indicadores ficticios, se utilizan para determinar las relaciones entre variables independientes cualitativas y una variable dependiente.

La técnica de la variable ficticia se ilustra en la figura 7-3. Los puntos de datos de las mujeres se presentan como 0; y los 1 representan a los hombres. Se construyen dos líneas paralelas en el diagrama de dispersión. La de arriba se ajusta los datos de las mujeres; la de abajo se ajusta los puntos de datos de los hombres.

Cada una de estas líneas se obtuvo a partir de una función de regresión ajustada de la forma

$$\hat{Y} = b_0 + b_1X_1 + b_2X_2$$

TABLA 7-9 Datos de la variable ficticia de ensambladores de aparatos electrónicos para el ejemplo 7.5

<i>Sujeto</i>	<i>Calificación del desempeño laboral Y</i>	<i>Calificación en la prueba de aptitud X_1</i>	<i>Género X_2</i>
1	5	60	0(F)
2	4	55	0(F)
3	3	35	0(F)
4	10	96	0(F)
5	2	35	0(F)
6	7	81	0(F)
7	6	65	0(F)
8	9	85	0(F)
9	9	99	1(M)
10	2	43	1(M)
11	8	98	1(M)
12	6	91	1(M)
13	7	95	1(M)
14	3	70	1(M)
15	6	85	1(M)
Totales	87	1,093	

$\bar{Y}_F$ = Media de la calificación del desempeño laboral de las mujeres = 5.75

$\bar{Y}_M$ = Media de la calificación del desempeño laboral de los hombres = 5.86

$\bar{X}_F$ = Media del resultado de la prueba de aptitud para las mujeres = 64

$\bar{X}_M$ = Media del resultado de la prueba de aptitud para los hombres = 83




FIGURA 7-2 Diagrama de dispersión de los datos para el ejemplo 7.5




FIGURA 7-3 Líneas de regresión correspondientes a las variables ficticias para el ejemplo 7.5

donde

X_1 = calificación de la prueba

$X_2 = \begin{cases} 0 & \text{para mujeres} \\ 1 & \text{para hombres} \end{cases}$ variable ficticia

La ecuación individual es equivalente a las siguientes dos ecuaciones:

$$\hat{Y} = b_0 + b_1X_1 \quad \text{para mujeres}$$

$$\hat{Y} = b_0 + b_1X_1 + b_2 = (b_0 + b_2) + b_1X_1 \quad \text{para hombres}$$

Observe que b_2 representa el efecto de un varón sobre el rendimiento en el trabajo, y b_1 representa el efecto de las diferencias en las calificaciones de las pruebas de aptitud (se supone que el valor de b_1 es el mismo tanto para hombres como para mujeres). El punto importante es que una ecuación de regresión múltiple producirá las dos líneas de estimación mostradas en la figura 7-3. La línea de arriba es la relación estimada para mujeres, y la línea de abajo es la relación estimada para hombres. Uno podría imaginarse a X_2 como una variable “apagador” que está “encendido” cuando se hace una observación para un hombre y “apagado” cuando se hace para una mujer.

Ejemplo 7.6

La ecuación de regresión múltiple estimada para los datos del ejemplo 7.5 se presenta en los resultados de Minitab de la tabla 7-10. Ésta es

$$\hat{Y} = -1.96 + .12X_1 - 2.18X_2$$

TABLA 7-10 Resultados de Minitab del ejemplo 7.6**Correlations: Ratings, Test, Gender**

	Rating	Test
Test	0.876	
Gender	0.021	0.428

Regression Analysis: Rating versus Test, Gender

The regression equation is

$$\text{Rating} = -1.96 + 0.120 \text{ Test} - 2.18 \text{ Gender}$$

Predictor	Coef	SE Coef	T	P
Constant	-1.9565	0.7068	-2.77	0.017
Test	0.12041	0.01015	11.86	0.000
Gender	-2.1807	0.4503	-4.84	0.000

$$S = 0.7863 \quad R\text{-sq} = 92.1\% \quad R\text{-sq}(\text{adj}) = 90.8\%$$

Analysis of Variance

Source	DF	SS	MS	F	P
Regression	2	86.981	43.491	70.35	0.000
Residual Error	12	7.419	0.618		
Total	14	94.400			

Para los dos valores (0 y 1) de X_2 , la ecuación ajustada se convierte en

$$\hat{Y} = -1.96 + .12X_1 - 2.18(0) = -1.96 + .12X_1 \quad \text{para mujeres}$$

y

$$\hat{Y} = -1.96 + .12X_1 - 2.18(1) = -4.14 + .12X_1 \quad \text{para hombres}$$

Estas ecuaciones se pueden interpretar de la siguiente manera: el valor del coeficiente de regresión $b_1 = .12$, el cual es la pendiente de cada una de las líneas, es el incremento promedio estimado de la calificación del desempeño laboral por cada unidad de incremento en la calificación de la prueba de aptitud. Este coeficiente se aplica tanto a los hombres como a las mujeres.

El otro coeficiente de regresión, $b_2 = -2.18$, se aplica sólo a los hombres. Para un hombre que realiza la prueba, la calificación del desempeño laboral estimada se reduce, en relación con las mujeres que hacen la prueba, en 2.18 unidades cuando la calificación de aptitud se mantiene constante.

Un examen de los promedios de las variables Y y X_1 clasificadas por género, nos ayuda a comprender este resultado. La tabla 7-9 indica que la media de las calificaciones del desempeño laboral fueron aproximadamente iguales para los hombres, 5.86, y las mujeres, 5.75. Sin embargo, los hombres obtuvieron una calificación significativamente más alta (83) en la prueba de aptitud que las mujeres (64). Por lo tanto, si dos candidatos, un hombre y una mujer, realizan la prueba de aptitud y ambos obtienen una calificación de 70, la calificación del desempeño laboral estimada de la mujer sería 2.18 más alta que la del hombre, puesto que

$$\text{Mujer: } \hat{Y} = -1.96 + .12X_1 = -1.96 + .12(70) = 6.44$$

$$\text{Hombre: } \hat{Y} = -4.14 + .12X_1 = -4.14 + .12(70) = 4.26$$

Una mirada a la matriz de correlación de la tabla 7-10 ofrece una visión interesante. Existe una relación lineal fuerte entre el rendimiento en el trabajo y la prueba de aptitud porque $r_{12} = .876$. Si solamente se usara la calificación de la prueba de aptitud para predecir el rendimiento, se explicaría alrededor del 77% ($.876^2 = .767$) de la variación en las calificaciones del rendimiento en el trabajo.

El coeficiente de correlación $r_{13} = .02$ indica que prácticamente no existe relación entre el género y el rendimiento en el trabajo. Esta conclusión también se hace evidente a partir del hecho de que los índices de rendimiento promedio para hombres y mujeres son aproximadamente iguales (5.86 contra 5.75). A primera vista, uno podría concluir que el conocimiento de que un candidato sea

hombre o mujer no es una información útil. Sin embargo, la relación moderada, $r_{23} = .428$, entre el género y la calificación en la prueba de aptitud indica que la prueba podría hacer una discriminación entre sexos. Los hombres parecen desempeñarse mejor en la prueba que las mujeres (83 contra 64). Quizás en la prueba se requiere algún elemento de fortaleza que no se requiere en el trabajo.

Cuando se usan tanto los resultados de la prueba como el género para pronosticar el rendimiento en el trabajo, se explica el 92% de la varianza. Este resultado sugiere que ambas variables hacen una contribución valiosa al rendimiento pronosticado. La calificación de la prueba de aptitud explica el 77% de la varianza, y el género considerado junto con la calificación de la prueba de aptitud agrega otro 15%. Los estadísticos t calculados, 11.86 (valor- $p = .000$) y -4.84 (valor- $p = .000$), para la calificación de la prueba de aptitud y el género, respectivamente, indican que ambas variables explicativas deben incluirse en la función final de regresión.

MULTICOLINEALIDAD

En muchos problemas de regresión, los datos se registran rutinariamente en vez de ser generados por posiciones previamente elegidas de las variables independientes. En estos casos, las variables independientes son a menudo linealmente dependientes o *multicolineales*. Por ejemplo, en el trabajo de avalúos, el precio de venta de una casa puede estar relacionado con variables explicativas como la edad, el espacio habitable en pies cuadrados, el número de baños, el número de habitaciones que no son baños, las dimensiones del terreno y un índice de la calidad de la construcción. El espacio habitable, el número de cuartos y el número de baños, desde luego, deben “moverse juntos”. Si una de estas variables aumenta, las otras generalmente se incrementarán.

Si esta dependencia lineal es menos perfecta, todavía se puede obtener la estimación de mínimos cuadrados de los coeficientes del modelo de regresión. Sin embargo, estas estimaciones tienden a ser inestables —sus valores pueden cambiar drásticamente con cambios ligeros en los datos— e inflarse (sus valores son más grandes de lo esperado). En particular, los coeficientes individuales pueden tener el signo equivocado, y los estadísticos t para juzgar la significancia de los términos individuales pueden ser insignificantes, aun cuando la prueba F indique que la relación es significativa. Finalmente, el cálculo de los estimados de mínimos cuadrados es sensible a errores de redondeo.

La *multicolinealidad* es la situación en la cual las variables independientes de una ecuación de regresión múltiple están sumamente intercorrelacionadas. Es decir, existe una relación lineal entre dos o más variables independientes.

La fortaleza de la multicolinealidad se mide por el factor de inflación de la varianza (VIF , por las siglas de variance inflation factor):⁵

$$VIF_j = \frac{1}{1 - R_j^2} \quad j = 1, 2, \dots, k \quad (7.11)$$

Aquí, R_j^2 es el coeficiente de determinación de la regresión de la j -ésima variable independiente con el resto $k - 1$ de las variables independientes. Para dos variables independientes $k = 2$, R_j^2 es el cuadrado de su correlación muestral, r .

Si la j -ésima variable explicativa, X_j , no está relacionada con el resto de las X , $R_j^2 = 0$ y el $VIF_j = 1$. Si existe una relación, entonces $VIF_j > 1$. Por ejemplo, cuando R_j^2 es igual a .90, $VIF_j = 1/(1 - .90) = 10$.

Un VIF próximo a 1 sugiere que la multicolinealidad no es un problema para esa variable independiente. Su coeficiente estimado y el valor t asociado no cambiarán mucho conforme las otras variables independientes se agregan o se eliminan de la ecuación de regresión. Un VIF

⁵El factor de inflación de la varianza (VIF) toma su nombre del hecho de que $s_{b_j} \propto VIF_j$. La desviación estándar estimada (error estándar) del coeficiente de mínimos cuadrados, b_j , se incrementa conforme VIF_j aumenta.

mucho más grande que 1 indica que el coeficiente estimado de esa variable independiente es inestable. Su valor y su estadístico t asociado pueden cambiar considerablemente conforme las otras variables independientes se agregan o se eliminan de la ecuación de regresión. Un VIF grande significa, en esencia, que existe información redundante entre las variables explicativas. La información expresada por una variable con un VIF grande se explica por las variables explicativas restantes. Por lo tanto, la multicolinealidad hace difícil la interpretación del efecto de una variable explicativa individual sobre la respuesta (variable dependiente).

Ejemplo 7.7

Un componente grande del costo de poseer una empresa periodística es el papel. Las editoriales de periódicos están interesadas en los factores que determinan el consumo anual de papel. En un estudio (véase Johnson y Wichern, 1997), los datos sobre el consumo anual de papel (Y), el número de periódicos en una ciudad (X_1), el logaritmo⁶ del número de familias en una ciudad (X_2), y el logaritmo de las ventas totales al menudeo en una ciudad (X_3) se recopilaron para 15 ciudades $n = 15$. El arreglo de correlación para las tres variables explicativas y el resultado de Minitab de un análisis de regresión que relaciona el consumo de papel con las variables explicativas se encuentran en la tabla 7-11.

El estadístico F (18.54) y su valor p (.000) indican claramente que la regresión es significativa. El estadístico t de cada una de las variables independientes es pequeño con un valor p relativamente grande. Debe concluirse, por ejemplo, que la variable LnFamily no es significativa, siempre que las otras variables explicativas permanezcan en la función de regresión. Esto sugiere que el término $\beta_2 X_2$ puede eliminarse de la función de regresión si los términos restantes, $\beta_1 X_1$ y $\beta_3 X_3$, se conservan. De manera análoga, parece que $\beta_3 X_3$ puede eliminarse si $\beta_1 X_1$ y $\beta_2 X_2$ permanecen en la función de regresión. El valor t (1.69) asociado con los periódicos es marginalmente significativo, pero el término $\beta_1 X_1$ también podría eliminarse si las otras variables explicativas permanecen en la ecuación. Aquí, la regresión es significativa, pero cada una de las variables explicativas no es significativa. ¿Por qué?

La columna VIF de la tabla 7-11 brinda la respuesta. Puesto que $VIF = 1.7$ para periódicos (Papers), esta variable explicativa está muy débilmente relacionada (VIF cerca de 1) con las variables explicativas restantes, LnFamily y LnRetSales. El $VIF = 7.4$ de LnFamily es relativamente grande, lo

TABLA 7-11 Resultado de Minitab para el ejemplo 7.7: tres variables explicativas

Correlations: Papers, LnFamily, LnRetSales

	Papers	LnFamily
LnFamily	0.600	
LnRetSales	0.643	0.930

Regression Analysis: Newsprint versus Papers, LnFamily, LnRetSales

The regression equation is

$$\text{Newsprint} = -56388 + 2385 \text{ Papers} + 1859 \text{ LnFamily} + 3455 \text{ LnRetSales}$$

Predictor	Coef	SE Coef	T	P	VIF
Constant	-56388	13206	-4.27	0.001	
Papers	2385	1410	1.69	0.119	1.7
LnFamily	1859	2346	0.79	0.445	7.4
LnRetSales	3455	2590	1.33	0.209	8.1

$$S = 1849 \quad R\text{-Sq} = 83.8\% \quad R\text{-Sq}(\text{adj}) = 79.0\%$$

Analysis of Variance

Source	DF	SS	MS	F	P
Regression	3	190239371	63413124	18.54	0.000
Residual Error	11	37621478	3420134		
Total	14	227860849			

⁶Los logaritmos del número de familias y de las ventas totales se emplean para hacer los números menos positivamente sesgados y más manejables.

TABLA 7-12 Resultado de Minitab para el ejemplo 7.7:
dos variables explicativas**Regression Analysis: Newsprint versus Papers, LnRetSales**

The regression equation is

$$\text{Newsprint} = -59766 + 2393 \text{ Papers} + 5279 \text{ LnRetSales}$$

Predictor	Coef	SE Coef	T	P	VIF
Constant	-59766	12304	-4.86	0.000	
Papers	2393	1388	1.72	0.110	1.7
LnRetSales	5279	1171	4.51	0.001	1.7

S = 1820 R-sq = 82.5% R-sq(adj) = 79.6%

Analysis of Variance

Source	DF	SS	MS	F	P
Regression	2	188090489	94045244	28.38	0.000
Residual Error	12	39770360	3314197		
Total	14	227860849			

que indica que esta variable se encuentra linealmente relacionada con las variables explicativas restantes. Además, el $VIF = 8.1$ de LnRetSales indica que LnRetSales está relacionada con el resto de las variables explicativas. Puesto que Papers está débilmente relacionada con LnFamily y LnRetSales, la relación entre las variables explicativas es esencialmente la relación entre LnFamily y LnRetSales. De hecho, la correlación muestral entre LnFamily y LnRetSales es $r = .93$, lo que indica una asociación lineal fuerte.

Las variables LnFamily y LnRetSales son muy similares en su capacidad para explicar el consumo de papel. Sólo necesitamos una, no ambas, en la función de regresión. El resultado de Minitab de un análisis de regresión eliminando LnFamily (estadístico t más pequeño) de la función de regresión se presenta en la tabla 7-12.

Advierta que el coeficiente de Papers es aproximadamente igual para las dos regresiones. Sin embargo, los coeficientes de LnRetSales son considerablemente diferentes (3,455 para las variables explicativas $k = 3$ y 5,279 para variables explicativas $k = 2$). Además, para la segunda regresión, la variable LnRetSales es claramente significativa ($t = 4.51$ con valor $p = .001$). Con Papers en el modelo, LnRetSales es una variable explicativa adicional importante del consumo de papel. Las R^2 para las dos regresiones son casi iguales, aproximadamente .83, como lo son los errores estándar de las estimaciones, $s_{y \cdot x's} = 1,849$ y $s_{y \cdot x's} = 1,820$, respectivamente. Por último, el VIF común = 1.7 para los dos factores explicativos en el segundo modelo indica que la multicolinealidad ya no es un problema. Como lo confirma un análisis residual, para las variables consideradas, la regresión de Newsprint sobre Papers y LnRetSales es completamente adecuada.

Si la estimación de los efectos por separado de las variables explicativas es importante y la multicolinealidad parece ser un problema, ¿qué se debe hacer? Existen varias maneras para manejar la multicolinealidad severa, como veremos en seguida. Ninguna de ellas es completamente satisfactoria o factible

- Cree nuevas variables X (llamándolas $\tilde{X}$) luego escale todas las variables independientes de acuerdo con la fórmula

$$\tilde{X} = \frac{X_{ij} - \bar{X}_j}{\sqrt{\frac{1}{n} \sum_i (X_{ij} - \bar{X}_j)^2}} \quad j = 1, 2, \dots, k; \quad i = 1, 2, \dots, n \quad (7.12)$$

Cada una de estas variables nuevas tiene una media muestral de 0 y la misma desviación estándar muestral. Los cálculos de la regresión con las nuevas X son menos sensibles al error de redondeo en presencia de la multicolinealidad severa.

- Identifique y elimine una o más de las variables independientes redundantes de la función de regresión. (Este método se usó en el ejemplo 7.7).

- Considere otros procedimientos de estimación que no sean los mínimos cuadrados.⁷
- Realice una regresión de la respuesta, Y , sobre las nuevas X que no están correlacionadas unas con otras. Es posible elaborar combinaciones lineales de las X originales que no están correlacionadas.⁸
- Seleccione cuidadosamente las variables independientes potenciales al principio del estudio. Trate de eliminar las variables que “dicen lo mismo”

SELECCIÓN DE LA “MEJOR” ECUACIÓN DE REGRESIÓN

¿Cómo se desarrolla la mejor ecuación de regresión múltiple para pronosticar una variable de interés? El *primer paso* implica la selección de un conjunto completo de variables explicativas potenciales. Se debe incluir cualquier variable que pudiera agregar exactitud al pronóstico. En la selección de la ecuación final, el analista generalmente se enfrenta al dilema de obtener el pronóstico más exacto al menor costo. En otras palabras, cuando elegimos las variables explicativas para incluirlas en la ecuación final, debemos evaluarlas usando los siguientes dos criterios antagónicos:

1. El analista desea que la ecuación incluya tantas variables explicativas como sea posible.⁹
2. Puesto que obtener y monitorear la información de un gran número de X es una labor costosa, la ecuación debe incluir menos variables explicativas como sea posible. Por lo general, la ecuación más simple es la mejor.

La selección de la mejor ecuación de regresión, por lo regular, implica un compromiso entre estos extremos, y el criterio personal será una parte obligatoria de cualquier solución.

Después de recopilar una lista aparentemente completa de variables explicativas potenciales, el *segundo paso* es eliminar las variables independientes que no parezcan adecuadas. Una variable independiente: **1.** quizá no sea fundamental para el problema (debe haber alguna relación posible entre la variable dependiente y la variable independiente), **2.** podría estar sujeta a errores de medición grandes, **3.** puede ser un duplicado de otra variable independiente (multicolinealidad), o **4.** tal vez sea difícil medirla con exactitud (los datos exactos no están disponibles o sería muy costoso obtenerlos).

El *tercer paso* es recortar la lista de variables explicativas de manera que se obtenga la “mejor” selección de variables independientes. En el material que sigue se analizan las técnicas actualmente en uso. No se puede decir que alguno de los procedimientos de búsqueda permita obtener el “mejor” conjunto de variables independientes. De hecho, no es frecuente que exista un solo conjunto “mejor”. Para agravar la confusión, las diferentes técnicas no necesariamente conducen a la misma ecuación final de predicción. El proceso completo de selección de la variable es muy subjetivo. La ventaja principal de los procedimientos automáticos de búsqueda es que los analistas pueden enfocar su atención en las áreas fundamentales del problema.

Para estudiar diferentes procedimientos de búsqueda, se presenta un ejemplo sencillo que incluye cinco variables independientes potenciales.

Ejemplo 7.8

Pam Weigand, la directora de personal de Zurenko Pharmaceutical Company, está interesada en pronosticar si un candidato particular se convertirá en un buen vendedor. Ella decide usar las primeras ventas mensuales como la variable dependiente (Y) y selecciona para el análisis las siguientes variables independientes

⁷Los procedimientos alternativos para la estimación de los parámetros de la regresión están más allá del alcance de este libro. Al lector interesado se le recomienda consultar el trabajo de Draper y Smith (1988).

⁸Otra vez, los procedimientos para la creación de combinaciones lineales de las X que no están correlacionadas se encuentran más allá del alcance de este libro. Draper y Smith (1988) analizan estas técnicas.

⁹Recuerde que siempre que se agrega una variable explicativa nueva a la ecuación de regresión múltiple, R^2 aumenta. Por ello, es importante que una nueva variable explicativa haga una contribución *significativa* a la ecuación de regresión.

- X_1 = prueba de aptitud para ventas
 X_2 = edad, en años
 X_3 = prueba de ansiedad
 X_4 = experiencia en años
 X_5 = promedio de calificaciones (*grade point average*)

La directora de personal recopila los datos presentados en la tabla 7-13, y asigna a su analista la tarea de obtener el “mejor” conjunto de variables independientes para pronosticar la habilidad para trabajar en ventas.

El primer paso es obtener una matriz de correlación para todas las variables usando un programa de computadora. Esta matriz le dará el conocimiento esencial acerca de las relaciones básicas entre las variables.

El examen de la matriz de correlación en la tabla 7-14 revela que la calificación del examen de aptitud para ventas, la edad, la experiencia y el GPA están relacionados positivamente con la habilidad para trabajar en ventas y tienen potencial como buenas variables explicativas. La calificación en la prueba de ansiedad indica una correlación negativa baja con las ventas y probablemente no es una variable explicativa importante. El análisis posterior indica que la edad está correlacionada modera-

TABLA 7-13 Datos de la Zurenko Pharmaceutical para el ejemplo 7.8

<i>Ventas de un mes (unidades)</i>	<i>Calificación en la prueba de aptitud</i>	<i>Edad (años)</i>	<i>Calificación en la prueba de ansiedad</i>	<i>Experiencia (años)</i>	<i>GPA de la preparatoria</i>
44	10	22.1	4.9	0	2.4
47	19	22.5	3.0	1	2.6
60	27	23.1	1.5	0	2.8
71	31	24.0	.6	3	2.7
61	64	22.6	1.8	2	2.0
60	81	21.7	3.3	1	2.5
58	42	23.8	3.2	0	2.5
56	67	22.0	2.1	0	2.3
66	48	22.4	6.0	1	2.8
61	64	22.6	1.8	1	3.4
51	57	21.1	3.8	0	3.0
47	10	22.5	4.5	1	2.7
53	48	22.2	4.5	0	2.8
74	96	24.8	.1	3	3.8
65	75	22.6	.9	0	3.7
33	12	20.5	4.8	0	2.1
54	47	21.9	2.3	1	1.8
39	20	20.5	3.0	2	1.5
52	73	20.8	.3	2	1.9
30	4	20.0	2.7	0	2.2
58	9	23.3	4.4	1	2.8
59	98	21.3	3.9	1	2.9
52	27	22.9	1.4	2	3.2
56	59	22.3	2.7	1	2.7
49	23	22.6	2.7	1	2.4
63	90	22.4	2.2	2	2.6
61	34	23.8	.7	1	3.4
39	16	20.6	3.1	1	2.3
62	32	24.4	.6	3	4.0
78	94	25.0	4.6	5	3.6

TABLA 7-14 Correlaciones: Ventas, aptitud, edad, ansiedad, experiencia, GPA

Correlations: Sales, Aptitude, Age, Anxiety, Experience, GPA					
	Sales	Aptitude	Age	Anxiety	Experience
Aptitude	0.676				
Age	0.798	0.228			
Anxiety	-0.296	-0.222	-0.287		
Experience	0.550	0.350	0.540	-0.279	
GPA	0.622	0.318	0.695	-0.244	0.312

damente tanto con el GPA como con la experiencia. La presencia de estas interrelaciones debe considerarse en el intento por encontrar el mejor conjunto posible de variables explicativas.

Se presentan dos procedimientos: todas las regresiones posibles y la regresión por pasos.

Todas las regresiones posibles

El procedimiento requiere la investigación de todas las ecuaciones de regresión posibles que implican las variables independientes potenciales. El analista inicia con una ecuación que no contiene variables independientes y luego procede al análisis de todas las combinaciones posibles para seleccionar el mejor conjunto de variables explicativas.

Con el *enfoque de todas las regresiones posibles* se pueden usar diferentes criterios para comparar varias ecuaciones de regresión. Aquí se analizará sólo la técnica de la R^2 la cual contempla cuatro pasos

Este procedimiento requiere primero el ajuste de cada modelo de regresión posible que incluye la variable dependiente y cualquier número de variables independientes. Cada variable independiente puede estar o no en la ecuación (dos posibles resultados), y este hecho es verdad para todas las variables independientes. Por lo tanto, existen en total 2^k ecuaciones (donde k es el número de variables independientes). De esta forma, si existen ocho variables independientes a considerar ($k = 8$), habrá que examinar $2^8 = 256$ ecuaciones.

El segundo paso del procedimiento es dividir las ecuaciones en conjuntos de acuerdo con el número de parámetros que se estimarán.

Ejemplo 7.9

Los resultados de todas las regresiones posibles para la Zurenko Pharmaceutical Company se presentan en la tabla 7-15. Observe que la tabla 7-15 está dividida en seis conjuntos de resultados de las ecuaciones de regresión. Este agrupamiento coincide con el número de parámetros contenidos en cada ecuación.

El tercer paso consiste en la selección de la mejor variable (o variables) independiente(s) para cada agrupamiento de parámetros. La ecuación con la R^2 más alta se considera la mejor. Con base en los resultados del ejemplo 7.9, la mejor ecuación de cada grupo listado en la tabla 7-15 se presenta en la tabla 7-16

El cuarto paso supone tomar la decisión subjetiva: “¿Cuál ecuación es la mejor?”. Por un lado, el analista desea la R^2 más grande posible; por otro, quiere la ecuación más sencilla posible. El enfoque de todas las regresiones posibles supone que el número de puntos de datos, n , excede el número de parámetros, $k + 1$.

Ejemplo 7.10

El analista está intentando encontrar el punto en el cual agregar variables independientes para el problema de la Zurenko Pharmaceutical ya no vale la pena porque conduce a un incremento muy pequeño en R^2 . Los resultados en la tabla 7-16 indican claramente que no es necesario sumar varia-

TABLA 7-15 Valores de R^2 para todas las regresiones posibles de Zurenko Pharmaceutical; ejemplo 7.9

<i>Variables independientes empleadas</i>	<i>Número de parámetros</i>	<i>Grados de libertad de los errores</i>	R^2
Ninguno	1	29	.0000
X_1	2	28	.4570
X_2	2	28	.6370
X_3	2	28	.0880
X_4	2	28	.3020
X_5	2	28	.3870
X_1, X_2	3	27	.8948
X_1, X_3	3	27	.4790
X_1, X_4	3	27	.5690
X_1, X_5	3	27	.6410
X_2, X_3	3	27	.6420
X_2, X_4	3	27	.6570
X_2, X_5	3	27	.6460
X_3, X_4	3	27	.3240
X_3, X_5	3	27	.4090
X_4, X_5	3	27	.5270
X_1, X_2, X_3	4	26	.8951
X_1, X_2, X_4	4	26	.8948
X_1, X_2, X_5	4	26	.8953
X_1, X_3, X_4	4	26	.5750
X_1, X_3, X_5	4	26	.6460
X_1, X_4, X_5	4	26	.7010
X_2, X_3, X_4	4	26	.6590
X_2, X_3, X_5	4	26	.6500
X_2, X_4, X_5	4	26	.6690
X_3, X_4, X_5	4	26	.5310
X_1, X_2, X_3, X_4	5	25	.8951
X_1, X_2, X_3, X_5	5	25	.8955
X_1, X_2, X_4, X_5	5	25	.8953
X_1, X_3, X_4, X_5	5	25	.7010
X_2, X_3, X_4, X_5	5	25	.6710
X_1, X_2, X_3, X_4, X_5	6	24	.8955

TABLA 7-16 Mejores ecuaciones de regresión de la Zurenko Pharmaceutical; ejemplo 7.9

<i>Número de parámetros</i>	<i>Variables independientes</i>	<i>Grados de libertad de los errores</i>	R^2
1	Ninguno	29	.0000
2	X_2	28	.6370
3	X_1, X_2	27	.8948
4	X_1, X_2, X_5	26	.8953
5	X_1, X_2, X_3, X_5	25	.8955
6	X_1, X_2, X_3, X_4, X_5	24	.8955

bles después de la prueba de aptitud para ventas (X_1) y la edad (X_2). Por lo tanto, la ecuación final de regresión ajustada tiene la forma

$$\hat{Y} = b_0 + b_1X_1 + b_2X_2$$

y explica el 89.48% de la variación en Y .

Draper y Smith (1998) resumen así el procedimiento de todas las regresiones posibles:

En general, el análisis de todas las regresiones no está justificado. Aunque significa que el investigador ha “considerado todas las posibilidades”, también significa que ha examinado un gran número de ecuaciones de regresión que una persona inteligente a menudo rechazaría de inmediato. El tiempo de computadora utilizado es un despilfarro y tan sólo el trabajo físico de examinar todos los reportes de resultados de la computadora es enorme cuando se examinan más de unas cuantas variables. Es preferible alguna clase de selección de un procedimiento que acorte esta tarea. (p. 333)

Regresión por pasos

El procedimiento de regresión por pasos agrega al modelo una variable independiente a la vez. Cuando se utiliza este procedimiento se puede manejar un número grande de variables independientes en una sola corrida en la computadora.

La regresión por pasos puede describirse mejor listando los pasos básicos (el algoritmo) para realizar los cálculos.

1. Se consideran todas las regresiones *simples* posibles. La variable explicativa que explica la proporción significativa más grande de la variación de Y (es decir, tiene la correlación más grande con la respuesta) es la primera variable que se introduce en la ecuación de regresión.
2. La siguiente variable en introducirse a la ecuación es la que (fuera de aquellas no incluidas) hace la mayor contribución significativa a la suma de cuadrados de la regresión. La significancia de la contribución se determina mediante una prueba F . El valor del estadístico F que debe sobrepasarse antes de que la contribución de una variable se considere significativa a menudo se conoce como F de entrada (F to enter).
3. Una vez que una variable adicional se ha incluido en la ecuación, se hace una prueba de significancia de las contribuciones individuales a la suma de cuadrados de regresión de las otras variables *que ya están en la ecuación* usando pruebas F . Si el estadístico F es menor que un valor llamado F de salida (F to remove), la variable se elimina de la ecuación de regresión.
4. Los pasos 2 y 3 se repiten hasta que todas las adiciones posibles sean no significativas y todas las eliminaciones posibles sean significativas. En este punto, la selección se detiene.

La *regresión por pasos* permite a las variables explicativas entrar o salir de la función de regresión en diferentes etapas de su desarrollo. Una variable independiente se elimina del modelo si no tiene una contribución significativa cuando se agrega una nueva variable.

El usuario de un programa de regresión por pasos suministra los valores que deciden cuándo una variable puede entrar y cuándo una variable se elimina. Puesto que los estadísticos F usados en la regresión por pasos son tales que $F = t^2$ donde t es el estadístico t para probar la significancia de una variable explicativa, $F = 4$ (correspondiente a $|t| = 2$) es una opción común tanto para F de entrada y la F de salida. Una F de entrada de 4 es esencialmente equivalente a probar la significancia de una variable explicativa con un nivel de 5%. El programa por pasos de Minitab permite al usuario seleccionar un nivel α para introducir y eliminar variables, o

bien, el valor F para introducir y eliminar variables. Usar un valor α de .05 es aproximadamente equivalente a emplear $F = 4$. Los valores actuales predeterminados de Minitab son $\alpha = .15$ y $F = 4$.

El resultado del procedimiento por pasos es un modelo que contiene sólo variables independientes con valores t que son significativos en el nivel especificado. Sin embargo, el desarrollo del procedimiento por pasos no garantiza que la regresión por pasos permita seleccionar, por ejemplo, las tres mejores variables explicativas. Además, un método de selección automática no es capaz de indicar cuándo son útiles las transformaciones de las variables, ni necesariamente evita el problema de la multicolinealidad. Finalmente, la regresión por pasos no puede crear variables importantes que no sean suministradas por el usuario. Es necesario pensar cuidadosamente acerca de la colección de variables independientes que se suministra a un programa de regresión por pasos.

El procedimiento por pasos se ilustra en el ejemplo 7.11.

Ejemplo 7.11

Vamos a “resolver” el problema de Zurenko Pharmaceutical usando la regresión por pasos.

Pam examina la matriz de correlación presentada en la tabla 7-14 y decide que, cuando ella corra el análisis por pasos, la variable de la edad entrará primero al modelo porque tiene la correlación más grande con las ventas ($r_{1,3} = .798$) y explicará el 63.7% ($.798^2$) de la variación en las ventas.

Ella observa que la calificación en la prueba de aptitud probablemente será la segunda en entrar al modelo porque está fuertemente relacionada con las ventas ($r_{1,2} = .676$) pero no está fuertemente relacionada con la variable de la edad ($r_{2,3} = .228$) ya incluida en el modelo.

Pam también advierte que las otras variables probablemente no calificarán como buenas variables explicativas. La calificación en la prueba de ansiedad no será una buena variable explicativa porque no está bien relacionada con las ventas ($r_{1,4} = -.296$). Las variables de experiencia y GPA podrían tener potencial como buenas variables explicativas ($r_{1,5} = .550$ y $r_{1,6} = .622$, respectivamente). Sin embargo, ambas variables explicativas tienen un problema potencial de multicolinealidad con la variable de la edad ($r_{3,5} = .540$ y $r_{3,6} = .695$, respectivamente).

Los comandos de Minitab para correr un análisis de regresión por pasos para este ejemplo se describen en la sección de aplicaciones de Minitab al final del capítulo. La salida para esta regresión por pasos se presenta en la tabla 7-17. El análisis por pasos se aplica de acuerdo con los siguientes pasos.

TABLA 7-17 Regresión por pasos para el ejemplo 7.11: Ventas contra aptitud, edad, ansiedad, experiencia y GPA

Alpha-to-Enter: 0.05 Alpha-to-Remove: 0.05		
Response is Sales on 5 predictors, with N = 30		
Step	1	2
Constant	-100.85	-86.79
Age	6.97	5.93
T-Value	7.01	10.60
P-Value	0.000	0.000
Aptitude		0.200
T-Value		8.13
P-Value		0.000
S	6.85	3.75
R-Sq	63.70	89.48
R-Sq(adj)	62.41	88.70
Mallows Cp	57.4	0.2

Paso 1. El modelo después del paso 1 es

$$\text{Ventas} = -100.85 + 6.97 (\text{Edad})$$

Como Pam estableció, la variable de la edad se introduce primero al modelo y explica el 63.7% de la varianza en las ventas. Puesto que el valor p de .000 es menor que el valor α de .05, se agrega la edad al modelo. Recuerde que el valor p es la probabilidad de obtener un estadístico t tan grande como 7.01 por casualidad. La regla de decisión de Minitab que Pam seleccionó fue introducir la variable si el valor p era menor que $\alpha = .05$.

Observe que $t = 7.01 < 2.048$, el punto superior que deja a la derecha un área de 0.025 en una distribución t con 28 ($n - k - 1 = 30 - 1 - 1$) grados de libertad. De este modo, en el nivel de significancia .05, la hipótesis $H_0: \beta_1 = 0$ se rechaza en favor de $H_1: \beta_1 \neq 0$. Puesto que $t^2 = F$ o $2.048^2 = 4.19$, una F de entrada de 4 también es esencialmente equivalente a la prueba de significancia de una variable explicativa en el nivel del 5%. En este caso, puesto que el coeficiente de la variable de la edad es a todas luces significativamente diferente de cero, la edad entra a la ecuación de regresión y el procedimiento ahora continúa hacia el paso 2.

Paso 2. El modelo después del paso 2 es

$$\text{Ventas} = -86.79 + 5.93 (\text{Edad}) + 0.200 (\text{Aptitud})$$

Este modelo explica el 89.48% de la variación en las ventas.

La hipótesis nula y la hipótesis alternativa para determinar si el coeficiente de regresión de la calificación en la prueba de aptitud es significativamente diferente de cero son

$$\begin{aligned} H_0: \beta_2 &= 0 \\ H_1: \beta_2 &\neq 0 \end{aligned}$$

De nuevo, el valor p de .000 es menor que el valor α de .05, y la calificación en la prueba de aptitud se agrega al modelo. El coeficiente de regresión de la calificación de la prueba de aptitud es significativamente diferente de cero y la probabilidad de que esto ocurra tan sólo por error de muestreo es aproximadamente de cero. Este resultado significa que la calificación en la prueba de aptitud es una variable importante cuando se utiliza en conjunto con la edad.

El estadístico crítico t basado en 27 ($n - k - 1 = 30 - 2 - 1$) grados de libertad es 2.052.¹⁰ La razón t calculada que se encuentra en el resultado de Minitab es 8.13, una cifra mayor que 2.052. Usando la prueba t , la hipótesis nula también se rechaza.

Advierta que el valor p del estadístico t de la variable de la edad, .000, sigue siendo muy pequeño. La edad aún es una variable explicativa significativa de las ventas. El procedimiento ahora avanza hacia el paso 3.

Paso 3. La computadora ahora considera agregar una tercera variable explicativa, en vista de que X_1 (la edad) y X_2 (la calificación en la prueba de aptitud) están en la ecuación de regresión. Ninguna de las variables independientes restantes es significativa (con un valor p menor que .05) cuando corre en combinación con X_1 y X_2 , de manera que el procedimiento por pasos concluye.

El modelo final que seleccionó Pam mediante el procedimiento de los pasos es el modelo de dos variables explicativas descrito en el paso 2.

Notas finales sobre la regresión por pasos

La técnica de regresión por pasos es extremadamente fácil de usar. Por desgracia, también es extremadamente fácil hacer un uso inadecuado de esta técnica. Los analistas que desarrollan un modelo de regresión a menudo generan un conjunto grande de variables independientes potenciales y luego dejan que el procedimiento por pasos determine cuáles son significativas. El problema es que, cuando se analiza un grupo grande de variables independientes, se realizan muchas pruebas t y es probable que se presente el error tipo I (agregar una variable no significativa). Es decir, el modelo final podría contener una variable que no está linealmente relacionada con la variable dependiente y que se introdujo al modelo de manera fortuita.

¹⁰Otra vez, puesto que $2.052^2 = 4.21$, el uso de una F de entrada de 4 es aproximadamente equivalente que hacer una prueba de significancia de una variable explicativa con un nivel de .05.

Como se mencionó anteriormente, existe otro problema implicado en la selección inicial de las variables independientes potenciales. Cuando se seleccionan estas variables, a menudo se omiten términos de alto orden (curvilíneos, no lineales e interacción) para dejar manejable el número de variables. Así, es posible que muchas variables importantes se omitan del modelo desde el principio. Es obvio que la selección intuitiva de las variables independientes iniciales por parte del analista es crucial para tener éxito en el desarrollo de un modelo de regresión.

DIAGNÓSTICOS DE REGRESIÓN Y ANÁLISIS RESIDUAL

Un análisis de regresión no está completo sino hasta que uno está convencido de que el modelo es una representación adecuada de los datos. Es imperativo examinar la idoneidad del modelo antes de que se convierta en parte del mecanismo de toma de decisiones.

Un examen de los residuos es un componente crucial de la determinación de la idoneidad del modelo. Varias gráficas residuales diseñadas para verificar los supuestos del modelo se presentaron en el capítulo 6. Por otra parte, si se usan los modelos de regresión con datos de una serie de tiempo (lo que se analizará en el capítulo 8), es necesario calcular las autocorrelaciones residuales para verificar el supuesto de independencia. Las inferencias (y decisiones) con base en modelos que no satisfacen los supuestos de la regresión pueden ser sumamente desorientadoras. Por ejemplo, podría concluirse que la manipulación de una variable explicativa producirá un cambio específico en la respuesta cuando, de hecho, no sucede así. Se puede concluir también que es muy probable que un pronóstico (95% de confianza) esté dentro del 2% de la respuesta futura cuando, de hecho, la confianza real es mucho menor, y así podríamos seguir dando ejemplos.

En esta sección se analizarán algunas herramientas adicionales que permiten evaluar un modelo de regresión. Estas herramientas están diseñadas para identificar observaciones que son atípicas o extremas (observaciones que están muy alejadas del resto de los datos). Las observaciones atípicas a menudo se esconden tras el proceso de ajuste y es difícil detectarlas en un examen de las gráficas de residuos. Sin embargo, pueden tener un papel importante al determinar la función de regresión ajustada. Es fundamental estudiar las observaciones atípicas para decidir si deben conservarse o eliminarse y, en el primer caso, habrá que decidir si su influencia debe reducirse en el proceso de ajuste o si debe revisarse la función de regresión.

El apalancamiento h_{ii} ofrece una medida de la influencia del i -ésimo punto de datos sobre la ubicación de la función de regresión ajustada. El apalancamiento sólo depende de las variables explicativas; no depende de la respuesta Y . Para la regresión lineal simple con una variable explicativa X ,

$$h_{ii} = \frac{1}{n} + \frac{(X_i - \bar{X})^2}{\sum (X_i - \bar{X})^2} \quad (7.13)$$

Con k variables explicativas, la expresión para el i -ésimo apalancamiento es más complicada; sin embargo, uno puede demostrar que $0 < h_{ii} < 1$ y que el apalancamiento medio es $\bar{h} = (k + 1)/n$.

Si el i -ésimo punto de datos tiene un apalancamiento alto (h_{ii} está cercano a 1), la respuesta ajustada $\hat{Y}_i$, en estas X se encuentra casi completamente determinada por Y_i , con muy poca influencia de los datos restantes. El punto de datos con apalancamiento alto también es un valor atípico entre las X (lejos de otras combinaciones de valores X).¹¹ Una regla empírica sugiere que h_{ii} es lo suficientemente grande para verificar si $h_{ii} \geq 3(k + 1)/n$.

La detección de valores atípicos o extremos de Y está basada en el tamaño de los residuos, $e = Y - \hat{Y}$. Residuos grandes indican un valor de Y que está “lejos” de su valor pronosticado o

¹¹Lo contrario no necesariamente es cierto. Es decir, un valor atípico entre las X puede no tener un punto de apalancamiento alto.

ajustado, $\hat{Y}$. Un residuo grande se manifestará en un histograma de los residuos con un valor lejos de cero (en cualquier dirección). Un residuo grande se manifestará en una gráfica de residuos contra los valores ajustados como un punto muy arriba o muy abajo del eje horizontal.

Los paquetes de software, como Minitab, marcan los puntos de datos con valores extremos de Y calculando residuos “estandarizados” e identificando puntos con residuos estandarizados grandes.

Una estandarización se basa en el hecho de que los residuos tienen desviaciones estándar estimadas:

$$s_{e_i} = s_{y \cdot x's} \sqrt{1 - h_{ii}}$$

donde $s_{y \cdot x's} = \sqrt{MSE}$ es el error estándar de la estimación y h_{ii} es el apalancamiento asociado con el i -ésimo punto de datos. El *residuo estandarizado*¹² es entonces

$$\frac{e_i}{s_{e_i}} = \frac{e_i}{s_{y \cdot x's} \sqrt{1 - h_{ii}}} \quad (7.14)$$

Todos los residuos estandarizados tienen una varianza de 1. Un residuo estandarizado se considera grande (la respuesta extrema) si

$$\left| \frac{e_i}{s_{e_i}} \right| > 2$$

Los valores Y correspondientes a los puntos de datos con residuos estandarizados grandes pueden influir fuertemente en la ubicación de la función de regresión ajustada.

Ejemplo 7.12

Los salarios de los directores ejecutivos en Estados Unidos son de interés en virtud de su relación con los salarios de los directores ejecutivos de las empresas internacionales y de los profesionales mejor pagados fuera de Estados Unidos. Además, para una empresa particular, la remuneración directa o indirecta de un director ejecutivo influye en los salarios de los gerentes de menor nivel. El salario del director ejecutivo varía considerablemente de una empresa a otra, pero los datos sugieren que el salario se puede explicar en términos de las ventas de la empresa, de la experiencia y el nivel educativo del director ejecutivo, así como de su participación como accionista en la compañía. En un estudio que incluyó a 50 empresas, los investigadores se propusieron desarrollar un modelo de regresión múltiple para vincular el sueldo de los directores ejecutivos con diversas variables explicativas, como ventas, utilidades, edad, experiencia, antecedentes profesionales y participación accionaria.

Después de la eliminación de variables explicativas sin importancia, la función de regresión ajustada fue

$$\hat{Y} = 5.52 - .467X_1 + .263X_2$$

donde

Y = logaritmo de la remuneración del director general

X_1 = variable indicadora del nivel educativo

X_2 = logaritmo de las ventas de la compañía

Minitab identificó tres observaciones a partir de este análisis de regresión que tenían residuos estandarizados grandes o apalancamiento grande.

¹²Algunos paquetes de software llaman *Studentized* al residuo estandarizado de la ecuación 7.14.

Unusual Observations

Obs	Educate	LnComp	Fit	StDev Fit	Residual	St Resid
14	1.00	6.0568	7.0995	0.0949	1.0427	2.09R
25	0.00	8.1342	7.9937	0.2224	0.1405	0.31X
33	0.00	6.3969	7.3912	0.2032	0.9943	2.13R

R denotes an observation with a large standardized residual.

X denotes an observation whose X value gives it large influence.

Las observaciones 14 y 33 tienen residuos estandarizados grandes. La función de regresión ajustada está prediciendo una remuneración (en logaritmos) de estos dos directores ejecutivos muy elevada. Un examen del conjunto completo de datos indica que cada uno de estos directores ejecutivos posee porcentajes relativamente grandes de las acciones de su compañía. El caso 14 posee más del 10% de acciones de la empresa, y el caso 33 posee más del 17% de acciones. Estos individuos reciben la mayor parte de su remuneración en forma de pagos a largo plazo, como incentivos accionarios, y no en forma de salario y bonos anuales. Puesto que la cantidad de acciones poseídas (o valor de las acciones) no está incluida como variable en la función de regresión, no puede utilizarse para ajustar el pronóstico de la remuneración determinada por la educación del director ejecutivo y las ventas de la compañía. Si bien la educación y las ventas (en logaritmo) no pronostican la remuneración de estos dos directores ejecutivos tan bien como las otras, no parece haber una razón para eliminarlas del estudio.

La observación 25 se distingue porque el apalancamiento de este punto de datos es mayor que $3(k+1)/n = 3(3)/50 = .18$. Este director ejecutivo no tiene grados académicos (Educación = 0) pero se encuentra en una compañía con ventas relativamente grandes (LnSales = 9.394). La combinación (0, 9.394) está lejos del punto $(\bar{X}_1, \bar{X}_2)$; por lo tanto, es un valor atípico en los pares de X . La respuesta asociada con estas X tendrá una gran influencia en la determinación de la función de regresión ajustada. [Observe que el residuo estandarizado para este punto de datos es pequeño, lo cual indica que la remuneración (log) pronosticada o ajustada está cerca del valor real]. Este director ejecutivo particular tiene 30 años de experiencia en el cargo, más experiencia que todos los directores ejecutivos, a excepción de uno, en el conjunto de datos. Esta observación es influyente, por lo que no hay razón para eliminarla.

El apalancamiento nos indica si una observación tiene variables explicativas inusuales, y un residuo estandarizado nos dice si una observación tiene una respuesta inusual. Estas cantidades pueden combinarse en una medida integral de influencia conocida como distancia de Cook. Las *distancias de Cook* se obtienen en la mayoría de paquetes de software estadístico, pero una explicación adicional está más allá del alcance de este libro.¹³

ADVERTENCIAS DEL PRONÓSTICO

Terminaremos este estudio de la regresión múltiple con algunos comentarios generales, los cuales están orientados a la aplicación práctica del análisis de regresión.

Sobreajuste de la prueba

El *sobreajuste* se refiere al hecho de agregar variables independientes a la función de regresión que, en gran medida, dan cuenta de todas las excentricidades de los datos muestrales bajo análisis.

Cuando se aplica un modelo sobreajustado a nuevos conjuntos de datos seleccionados de la misma población, no pronostica tan bien como el ajuste inicial podría sugerir.

Es más probable que ocurra el sobreajuste cuando el tamaño de la muestra es pequeño, especialmente si se incluye un gran número de variables independientes en el modelo. Algunos especialistas

¹³Draper y Smith (1998) aportan una buena explicación de la distancia de Cook.

sugieren que deben existir por lo menos 10 observaciones por cada variable independiente. (Si existen cuatro variables independientes, se sugiere un tamaño n de la muestra de por lo menos 40).

Una manera de protegerse contra el sobreajuste es desarrollar la función de regresión de una parte de los datos y luego aplicarla a una porción de la muestra. Se usa la función de regresión ajustada para pronosticar las respuestas de otra porción de datos y calcular los errores de pronóstico. Si los errores de pronóstico son sustancialmente mayores que los errores de ajuste medidos, digamos, por los errores cuadráticos medios comparables, entonces ha ocurrido un sobreajuste.

Regresiones útiles, valores grandes calculados de F

Una regresión que es estadísticamente significativa no necesariamente es útil. Con un tamaño muestral relativamente grande (por ejemplo, cuando n es grande en relación con k , el número de variables explicativas), no es extraño obtener una razón F significativa y una R^2 pequeña. Es decir, la regresión es significativa, pero sólo explica una pequeña porción de la variación en la respuesta. Una regla general sugiere que con un nivel de significancia de .05, la razón F debe ser por lo menos cuatro veces el valor crítico correspondiente antes de que la regresión pueda usarse para fines de predicción.¹⁴

El criterio de “cuatro veces” surge del argumento de que el rango de las predicciones (sobre todas las X) debe ser alrededor de cuatro veces el error de predicción (promedio) antes de que la regresión pueda generar una interpretación que valga la pena.¹⁵

Como ejemplo, con $k = 3$ variables explicativas, $n = 25$ observaciones, y un nivel de significancia de .05, la F calculada a partir de una tabla ANOVA tendría que exceder el valor crítico $F = 3.07$ (véase la tabla B-5 con $\delta_1 = k = 3$, $\delta_2 = n - k - 1 = 21$ grados de libertad) para que la regresión sea significativa. (Con base en la ecuación 7.7, la F crítica = 3.07 corresponde a una R^2 de alrededor del 30%, una cifra que no es particularmente grande). Sin embargo, la regla de las “cuatro veces” sugiere que la F calculada debería exceder $4(3.07) = 12.28$ para que la regresión valga la pena desde un punto de vista práctico.

APLICACIÓN A LA ADMINISTRACIÓN

El análisis de regresión múltiple se usa ampliamente para ayudar a pronosticar la actividad de varios segmentos de la economía. Muchos de los reportes y pronósticos acerca del futuro de la economía que aparecen en el *Wall Street Journal*, *Fortune*, *Business Week* y otras fuentes similares se basan en modelos econométricos (de regresión). El gobierno de Estados Unidos usa con frecuencia el análisis de regresión para pronosticar ingresos, gastos, niveles de ingreso, tasas de interés, índices de natalidad, desempleo y requerimientos para obtener beneficios de seguridad social, así como una multitud de sucesos. De hecho, prácticamente todas las grandes oficinas del gobierno de Estados Unidos utilizan las herramientas descritas en este capítulo.

De manera similar, las entidades de negocios han adoptado y, cuando es necesario, modificado el análisis de regresión como ayuda para el pronóstico de acontecimientos futuros. Pocas empresas pueden sobrevivir en el ambiente actual sin un pronóstico bastante exacto de las ventas, los gastos, los requerimientos de capital y los flujos de efectivo para el futuro. Si bien las empresas pequeñas o menos complejas pueden funcionar con pronósticos intuitivos, las empresas más grandes y/o más complejas recurren al análisis de regresión para estudiar las relaciones entre diversas variables y determinar cómo tales variables podrían afectar su futuro.

Por desgracia, la gran notoriedad que adquiere el análisis de regresión por su utilidad como una herramienta de pronóstico del futuro tiende a opacar un activo igualmente importante: su capacidad para ayudar a evaluar y controlar el presente. Como la ecuación de regresión ajustada brinda al investigador información sobre la *fortaleza y dirección*, la administración puede evaluar y modificar las estrategias en curso.

¹⁴Algunos autores argumentan que la regla de “cuatro veces” no es suficiente y que debería sustituirse por un criterio de “diez veces”.

¹⁵Esto supone que no se detectan otros defectos en el ajuste.

Suponga, por ejemplo, que un fabricante de mermelada quiere saber hacia dónde dirigir sus esfuerzos de marketing cuando lanza al mercado un nuevo sabor. Se puede usar el análisis de regresión para ayudar a determinar el perfil de los grandes consumidores de mermelada. Por ejemplo, tal vez una compañía quiera predecir el número de sabores de mermelada que una ama de casa podría tener en la alacena en un momento dado sobre la base de un número de variables independientes, como las siguientes:

- Número de niños que hay en casa
- Edad de los niños
- Sexo de los niños
- Propietarios de casas contra arrendadores
- Tiempo invertido en compras
- Ingreso

Incluso una reflexión superficial sobre el ejemplo de la mermelada rápidamente lleva al investigador a reconocer que el análisis de regresión tiene muchas posibilidades de uso en estudios de segmentación de mercado. De hecho, muchas compañías usan la regresión para estudiar segmentos de mercado y determinar cuáles variables parecen tener efecto sobre la participación en el mercado, la frecuencia de compra, la propiedad del producto y la lealtad a la marca y al producto, así como sobre otras muchas áreas.

Los especialistas en ciencias agrícolas utilizan el análisis de regresión para explorar la relación entre el rendimiento de la tierra (por ejemplo, número de fanegas de maíz por acre) y el tipo y la cantidad de fertilizante, la precipitación, la temperatura, los días de sol y las plagas de insectos. Las granjas modernas están equipadas con mini y micro computadoras completas con paquetes de software para ayudar en este proceso.

Los investigadores médicos usan el análisis de regresión para buscar vínculos entre la presión sanguínea y variables independientes como la edad, la clase social, el peso, el tabaquismo y la raza. También estudian el efecto de las comunicaciones, el número de visitas y la edad del paciente en relación con la satisfacción del servicio médico.

Los directores de personal exploran la relación de los niveles de salario de los empleados con la ubicación geográfica, las tasas de desempleo, el crecimiento de la industria, la afiliación a sindicatos, el tipo de industria y salarios competitivos. Los analistas financieros buscan las causas de los altos precios de las acciones analizando el rendimiento de dividendos, las ganancias por acción, la partición accionaria, las expectativas del consumidor en cuanto a tasas de interés, los niveles de ahorro y las tasas de inflación.

Los gerentes de publicidad a menudo tratan de estudiar el efecto de los presupuestos en publicidad, la selección de medios, la redacción del mensaje, la frecuencia del anuncio y la selección del anunciador en relación con el cambio de actitud del consumidor. De manera análoga, los especialistas en marketing intentan determinar las ventas a partir de los gastos en publicidad, los niveles de precio, los gastos competitivos en marketing y los ingresos disponibles del consumidor, así como una gran diversidad de variables.

Citemos un ejemplo final adicional para ilustrar la versatilidad del análisis de regresión. Los analistas del mercado inmobiliario han encontrado que el análisis de regresión es muy útil en la localización exacta de áreas geográficas con abundancia o escasez de tipos específicos de tiendas minoristas. Por ejemplo, una cadena de ferreterías podría buscar una ciudad potencial en la cual ubicar una nueva sucursal desarrollando un modelo de regresión diseñado para predecir las ventas de herramientas en cualquier ciudad específica. Los investigadores concentrarían sus esfuerzos en aquellas ciudades donde el modelo predijo ventas más altas que las reales (como se puede determinar consultando muchas fuentes). La hipótesis es que las ventas de artículos de ferretería no alcanzan todo su potencial en esas ciudades.

En resumen, el análisis de regresión brinda a los gerentes una herramienta poderosa y versátil para estudiar las relaciones entre una variable dependiente y múltiples variables independientes. El objetivo es comprender mejor y quizás controlar acontecimientos del presente, así como predecir mejor hechos futuros.

Glosario

Variables ficticias. Las variables o indicadores ficticios sirven para determinar las relaciones entre variables independientes cualitativas y una variable dependiente.

Multicolinealidad. La multicolinealidad es la situación en la cual las variables independientes en una ecuación de regresión múltiple están estrechamente intercorrelacionadas. Es decir, existe una relación lineal entre dos o más variables independientes.

Regresión múltiple. La regresión múltiple implica el uso de más de una variable independiente para predecir una variable dependiente.

Sobreajuste. Se refiere al hecho de agregar variables independientes a la función de regresión que, en gran medida, explican todas las excentricidades de los datos muestrales bajo análisis.

Coefficiente de regresión parcial o neto. El coeficiente de regresión parcial, o neto, mide el cambio promedio de la variable dependiente por unidad de cambio en la variable independiente relevante, cuando se mantienen constantes las demás variables independientes.

Error estándar de la estimación. El error estándar de la estimación es la desviación estándar de los residuos. Mide la cantidad de valores reales (Y) que difieren de los valores estimados ($\hat{Y}$).

Regresión por pasos. La regresión por pasos permite a las variables explicativas entrar o salir de la función de regresión en diferentes etapas de su desarrollo. Una variable independiente se elimina del modelo si no continúa haciendo una contribución significativa cuando se agrega una nueva variable.

Fórmulas clave

Función de regresión múltiple de población

$$\mu_Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k \quad (7.1)$$

Función de regresión estimada (ajustada)

$$\hat{Y} = b_0 + b_1 X_1 + \cdots + b_k X_k \quad (7.2)$$

Descomposición de la suma de cuadrados y grados de libertad asociados

$$\begin{aligned} \Sigma(Y - \bar{Y})^2 &= \Sigma(\hat{Y} - \bar{Y})^2 + \Sigma(Y - \hat{Y})^2 \\ SST &= SSR + SSE \\ df: n - 1 &= k + n - k - 1 \end{aligned} \quad (7.3)$$

Error estándar de la estimación

$$s_{y \cdot x's} = \sqrt{\frac{\Sigma(Y - \hat{Y})^2}{n - k - 1}} = \sqrt{\frac{SSE}{n - k - 1}} = \sqrt{MSE} \quad (7.4)$$

Estadístico F para prueba de significancia de la regresión

$$F = \frac{MSR}{MSE} \quad (\text{véase el recuadro de la p. 289})$$

Coefficiente de determinación

$$\begin{aligned} R^2 &= \frac{SSR}{SST} = \frac{\Sigma(\hat{Y} - \bar{Y})^2}{\Sigma(Y - \bar{Y})^2} \\ &= 1 - \frac{SSE}{SST} = 1 - \frac{\Sigma(Y - \hat{Y})^2}{\Sigma(Y - \bar{Y})^2} \end{aligned} \quad (7.5)$$

Coefficiente de correlación múltiple

$$R = \sqrt{R^2} \quad (7.6)$$

Relación entre el estadístico F y R^2

$$F = \frac{R^2}{1 - R^2} \left(\frac{n - k - 1}{k} \right) \quad (7.7)$$

Coefficiente ajustado de determinación

$$\bar{R}^2 = 1 - (1 - R^2) \left(\frac{n - 1}{n - k - 1} \right) \quad (7.8)$$

Estadístico t para la prueba de $H_0: \beta_j = 0$

$$t = \frac{b_j}{s_{b_j}} \quad (\text{véase el recuadro de la p. 291})$$

Pronóstico de un valor futuro

$$\hat{Y}^* = b_0 + b_1 X_1^* + b_2 X_2^* + \cdots + b_k X_k^* \quad (7.9)$$

Intervalo de de confianza para la predicción al utilizar una muestra grande para una respuesta futura

$$(\hat{Y}^* - t_{\alpha/2} s_{y \cdot x' s}, \hat{Y}^* + t_{\alpha/2} s_{y \cdot x' s}) \quad (7.10)$$

Factor de inflación de la varianza

$$VIF_j = \frac{1}{1 - R_j^2} \quad j = 1, 2, \dots, k \quad (7.11)$$

Valores estandarizados de la variable independiente

$$\tilde{X} = \frac{X_{ij} - \bar{X}_j}{\sqrt{\sum_i (X_{ij} - \bar{X}_j)^2}} \quad j = 1, 2, \dots, k; \quad i = 1, 2, \dots, n \quad (7.12)$$

Apalancamiento (una variable explicativa)

$$h_{ii} = \frac{1}{n} + \frac{(X_i - \bar{X})^2}{\sum (X_i - \bar{X})^2} \quad (7.13)$$

Residuo estandarizado

$$\frac{e_i}{s_{e_i}} = \frac{e_i}{s_{y \cdot x' s} \sqrt{1 - h_{ii}}} \quad (7.14)$$

Problemas

1. ¿Cuáles son las características de una buena variable explicativa?
2. ¿Cuáles son los supuestos asociados con el modelo de regresión múltiple?
3. ¿Qué mide el coeficiente de regresión parcial, o neto, en la regresión múltiple?
4. ¿Qué mide el error estándar de la estimación en la regresión múltiple?
5. Su ecuación de la regresión múltiple estimada es $\hat{Y} = 7.52 + 3X_1 - 12.2X_2$. Pronostique el valor de Y si $X_1 = 20$ y $X_2 = 7$.

TABLA P-7

Número de variable	Número de variable					
	1	2	3	4	5	6
1	1.00	.55	.20	-.51	.79	.70
2		1.00	.27	.09	.39	.45
3			1.00	.04	.17	.21
4				1.00	-.44	-.14
5					1.00	.69
6						1.00

6. Explique cada uno de los siguientes conceptos:
 - a) Matriz de correlación
 - b) R^2
 - c) Multicolinealidad
 - d) Residuo
 - e) Variable ficticia
 - f) Regresión por pasos
7. La mayoría de las soluciones por computadora para la regresión múltiple inician con una matriz de correlación. El examen de esta matriz a menudo es el primer paso cuando se analiza un problema de regresión que implica más de una variable independiente. Conteste las siguientes preguntas relacionadas con la matriz de correlación de la tabla P-7.
 - a) ¿Por qué todas las entradas que se encuentran sobre la diagonal principal son iguales a 1.00?
 - b) ¿Por qué la mitad de la matriz debajo de la diagonal principal se encuentra en blanco?
 - c) Si la variable 1 es la variable dependiente, ¿cuáles variables independientes tienen el grado más alto de asociación lineal con la variable 1?
 - d) ¿Qué clase de asociación existe entre las variables 1 y 4?
 - e) ¿Esta matriz de correlación indica alguna evidencia de multicolinealidad?
 - f) En su opinión, ¿cuál variable o variables deberían incluirse en el mejor modelo de pronóstico? Explique.
 - g) Si los datos presentados en esta matriz de correlación se corren en un programa de regresión por pasos, ¿cuál variable independiente (2, 3, 4, 5 o 6) será la primera en entrar en la función de regresión?
8. A Jennifer Dahl, supervisora de la cadena de descuento Circle O, le gustaría pronosticar el tiempo que se tardan los empleados en cobrarle a un cliente. Ella decide usar las siguientes variables independientes: número de artículos comprados e importe total de compra. Recopila datos para una muestra de 18 clientes, los cuales se presentan en la tabla P-8.
 - a) Determine la mejor ecuación de regresión.
 - b) Cuando se compra un artículo adicional, ¿cuál es el incremento promedio en el tiempo de cobro?
 - c) Calcule el residuo para el cliente 18.
 - d) Calcule el error estándar de la estimación.
 - e) Interprete el inciso d) en términos de las variables usadas en el problema.
 - f) Elabore un pronóstico del tiempo de cobro si un cliente compra 14 artículos que suman un total de \$70.
 - g) Calcule un intervalo estimado de 95% para su pronóstico del inciso f).
 - h) ¿Qué debería concluir Jennifer?
9. La tabla P-9 contiene datos de gastos de alimentación, ingreso anual y tamaño de la familia para una muestra de 10 familias.

TABLA P-8

<i>Cliente</i>	<i>Tiempo de cobro (minutos) Y</i>	<i>Importe (\$) X₁</i>	<i>Número de artículos X₂</i>
1	3.0	36	9
2	1.3	13	5
3	.5	3	2
4	7.4	81	14
5	5.9	78	13
6	8.4	103	16
7	5.0	64	12
8	8.1	67	11
9	1.9	25	7
10	6.2	55	11
11	.7	13	3
12	1.4	21	8
13	9.1	121	21
14	.9	10	6
15	5.4	60	13
16	3.3	32	11
17	4.5	51	15
18	2.4	28	10

TABLA P-9

<i>Familia</i>	<i>Gastos anuales de comida (en cientos de \$) Y</i>	<i>Ingreso anual (en miles de \$) X₁</i>	<i>Tamaño de la familia X₂</i>
A	24	11	6
B	8	3	2
C	16	4	1
D	18	7	3
E	24	9	5
F	23	8	4
G	11	5	2
H	15	7	2
I	21	8	3
J	20	7	2

- Elabore la matriz de correlación para las tres variables de la tabla P-9. Interprete las correlaciones en la matriz.
 - Ajuste un modelo de regresión múltiple que relacione los gastos de comida con los ingresos y el tamaño de la familia. Interprete los coeficientes de regresión parcial de ingreso y tamaño de la familia. ¿Tienen sentido?
 - Calcule los factores de inflación de la varianza (*VIF*) para las variables independientes. ¿La multicolinealidad es un problema para estos datos? Si es así, ¿cómo podría usted modificar el modelo de regresión?
10. Las ventas de cerveza en la tienda Shapiro One-Stop se analizan considerando la temperatura y el número de personas en la calle (de 21 años de edad en adelante) como variables independientes. Se selecciona una muestra aleatoria de 20 días, y se miden las siguientes variables:

TABLA P-10 Resultado de Minitab					
Correlations					
		Y		X1	
X1	0.827				
X2	0.822	0.680			
Regression Analysis					
The regression equation is					
$Y = -26.7 + .782 X1 + .068 X2$					
Predictor	Coef	SE Coef	T	P	
Constant	-26.706				
X1	.78207	.22694			
X2	.06795	.02026			
S =	R-Sq =	R-Sq(adj) =			
Analysis of Variance					
Source	DF	SS	MS	F	
Regression	2	11589.035	5794.516	36.11	
Residual Error	17	2727.914	160.466		
Total	19	14316.949			

Y = el número de empaques de 6 cervezas que se venden diariamente

X_1 = la temperatura diaria más alta

X_2 = el tráfico diario de personas

Se analizan los datos usando regresión múltiple. El resultado parcial de la computadora es la tabla P-10.

- Analice la matriz de correlación.
 - Pruebe la hipótesis $H_0: \beta_j = 0, j = 1, 2$, con un nivel de significancia de .01.
 - Pronostique el volumen de cerveza vendida si la temperatura más alta es de 60 grados Fahrenheit y el tráfico es de 500 personas.
 - Calcule R^2 , e interprete su significado en términos de este problema.
 - Calcule el error estándar de la estimación.
 - Explique cómo se ven afectadas las ventas de cerveza por el incremento de un grado en la temperatura más alta.
 - Redacte sus conclusiones de este análisis en relación con la exactitud de la ecuación del pronóstico y también sobre las contribuciones de las variables independientes.
11. Una compañía de taxis está interesada en la relación entre el millaje, medido en millas por galón, y la antigüedad de los automóviles de su flota. Los 12 vehículos son de la misma marca y del mismo tamaño y están en buenas condiciones de operación gracias a un mantenimiento sistemático. La compañía emplea tanto a hombres como mujeres como conductores y se cree que algo de la variabilidad en el millaje puede deberse a las diferencias en las técnicas de manejo entre los grupos de conductores de uno y otro sexo. De hecho, si todo lo demás se mantiene igual, las mujeres tienden a obtener mejor millaje que los hombres. Se registran los datos generados por la asignación al azar de los 12 automóviles a cinco mujeres y siete hombres, y se calculan las millas por galón después de recorrer 300 millas. Los datos aparecen en la tabla P-11.
- Elabore un diagrama de dispersión con Y como el eje vertical y X_1 como el eje horizontal. Identifique los puntos correspondientes a los conductores hombres y mujeres, respectivamente.

TABLA P-11

<i>Millas por galón Y</i>	<i>Antigüedad del auto (años) X_1</i>	<i>Sexo (0 = hombre, 1 = mujer) X_2</i>
22.3	3	0
22.0	4	1
23.7	3	1
24.2	2	0
25.5	1	1
21.1	5	0
20.6	4	0
24.0	1	0
26.0	1	1
23.1	2	0
24.8	2	1
20.2	5	0

b) Ajuste el modelo de regresión

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$$

interprete el coeficiente de mínimos cuadrados, b_2 .

- c) Calcule los valores ajustados de cada uno de los pares (X_1, X_2) y grafique los valores ajustados en el diagrama de dispersión. Dibuje líneas rectas a través de los valores ajustados para los conductores hombres y las conductoras mujeres, respectivamente. Especifique las ecuaciones para estas dos líneas rectas.
- d) Suponga que se ignora el género. Ajuste el modelo de regresión lineal simple, $Y = \beta_0 + \beta_1 X_1 + \varepsilon$, y grafique la línea recta ajustada sobre el diagrama de dispersión. ¿Es importante incluir los efectos del género en este caso? Explique.
12. El gerente de ventas de un distribuidor grande de partes automotrices, Hartman Auto Supplies, quiere desarrollar un modelo para pronosticar desde mayo las ventas anuales totales de una región. Si es posible pronosticar las ventas regionales, entonces es factible pronosticar las ventas totales de la compañía. El número de minoristas en la región en cuyos inventarios hay refacciones de la compañía y el número de automóviles registrados para cada región al primero de mayo son las dos variables independientes investigadas. Los datos aparecen en la tabla P-12.
- a) Analice la matriz de correlación.
- b) ¿Qué tanto de error está implicado en el pronóstico de la región 1?
- c) Pronostique las ventas anuales para la región 12, dados 2,500 minoristas y 20.2 millones de automóviles registrados.
- d) Discuta la exactitud del pronóstico elaborado en el inciso c).
- e) Indique cómo encontró el error estándar de la estimación.
- f) Dé una interpretación de los coeficientes de regresión parciales. ¿Son razonables estos coeficientes de regresión?
- g) ¿Cómo se puede mejorar esta ecuación de regresión?
13. El director de ventas de Hartman Auto Supplies decide investigar una nueva variable independiente, el ingreso personal por región (véase el problema 12). Los datos para esta nueva variable se presentan en la tabla P-13.
- a) ¿El ingreso personal por región hace una contribución al pronóstico de las ventas?

TABLA P-12

<i>Región X_2</i>	<i>Ventas anuales (millones de \$) Y</i>	<i>Número de minoristas X_1</i>	<i>Número de automóviles registrados (\$ millones)</i>
1	52.3	2,011	24.6
2	26.0	2,850	22.1
3	20.2	650	7.9
4	16.0	480	12.5
5	30.0	1,694	9.0
6	46.2	2,302	11.5
7	35.0	2,214	20.5
8	3.5	125	4.1
9	33.1	1,840	8.9
10	25.2	1,233	6.1
11	38.2	1,699	9.5

TABLA P-13

<i>Región</i>	<i>Ingreso personal (miles de millones de \$)</i>	<i>Región</i>	<i>Ingreso personal (miles de millones de \$)</i>
1	98.5	7	67.6
2	31.1	8	19.7
3	34.8	9	67.9
4	32.7	10	61.4
5	68.8	11	85.6
6	94.7		

- b) Pronostique las ventas anuales para la región 12 para un ingreso personal de \$40 mil millones y las cifras correspondientes a los minoristas y los automóviles registrados de acuerdo con el inciso c) del problema 12
- c) Discuta la exactitud del pronóstico elaborado en el inciso b).
- d) ¿Cuáles variables independientes incluiría usted en su modelo final de pronóstico? ¿Por qué?
14. Nelson Corporation decide desarrollar una ecuación de regresión múltiple para pronosticar el desempeño del área de ventas. Se entrevista a 14 vendedores de una muestra aleatoria y se les aplica una prueba de aptitud. También se calcula un índice de esfuerzo realizado por cada vendedor sobre la base de una razón entre el millaje recorrido en el automóvil de su compañía y el total de millaje proyectado para una cobertura adecuada de territorio. El análisis de regresión produce los siguientes resultados:

$$\hat{Y} = 16.57 + \underset{(.05)}{.65} X_1 + \underset{(1.69)}{20.6} X_2$$

Las cantidades entre paréntesis son los errores estándar de los coeficientes de regresión parciales. El error estándar de la estimación es 3.56. La desviación estándar de la variable de ventas es $s_y = 16.57$. Las variables son

Y = el desempeño de las ventas, en miles
 X_1 = la calificación en la prueba de aptitud
 X_2 = el índice de esfuerzo

- a) ¿Los coeficientes de regresión parciales son significativamente diferentes de cero en el nivel de significancia de .01?
 - b) Interprete el coeficiente de regresión parcial para el índice de esfuerzo.
 - c) Pronostique el desempeño en las ventas de un vendedor que obtiene una calificación de 75 en la prueba de aptitud y un índice de esfuerzo de .5.
 - d) Calcule la suma de los cuadrados residuales, $\Sigma(Y - \hat{Y})^2$.
 - e) Calcule la suma total de cuadrados $\Sigma(Y - \bar{Y})^2$.
 - f) Calcule R^2 , e interprete este número en términos del problema.
 - g) Calcule el coeficiente ajustado de determinación, $\bar{R}^2$.
15. Cabe esperar que las compras con tarjeta de crédito sean diferentes de las compras en efectivo en la misma tienda. La tabla P-15 indica las ventas diarias brutas y los artículos vendidos que se pagan en efectivo, así como las ventas diarias brutas en efectivo y los artículos vendidos que se pagan con tarjetas de crédito en la misma tienda de consignación por 25 días consecutivos.
- a) Elabore un diagrama de dispersión de las ventas brutas diarias, Y , contra artículos vendidos que se pagan en efectivo, X_1 . Usando otros símbolos, o bien, colores diferentes, agregue las ventas brutas diarias y los artículos vendidos que se pagan con tarjeta de crédito, X_2 . Compare visualmente la relación entre las ventas y el número de artículos vendidos que se pagan en efectivo con los pagados con tarjeta de crédito.

TABLA P-15

<i>Día</i>	<i>Ventas brutas en efectivo (\$)</i>	<i>Número de artículos</i>	<i>Ventas brutas con tarjeta de crédito (\$)</i>	<i>Número de artículos</i>
1	348	55	148	4
2	42	8	111	6
3	61	9	62	7
4	94	16	0	0
5	60	11	39	5
6	165	26	7	1
7	126	27	143	26
8	111	19	27	5
9	26	5	14	2
10	109	18	71	12
11	180	27	116	21
12	212	36	50	9
13	58	10	13	2
14	115	20	105	16
15	15	8	19	3
16	97	15	44	14
17	61	10	0	0
18	85	15	24	3
19	157	24	144	10
20	88	15	63	11
21	96	19	0	0
22	202	33	14	3
23	108	23	0	0
24	158	21	24	4
25	176	43	253	28

b) Defina la variable ficticia

$$X_2 = \begin{cases} 1 & \text{si la compra es en efectivo} \\ 0 & \text{si la compra es con tarjeta de crédito} \end{cases}$$

y ajuste el modelo de regresión

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$$

- c) Analice el ajuste del inciso b). Asegúrese de incluir un análisis de los residuos. ¿Está usted satisfecho con su modelo?
- d) Con base en el modelo ajustado del inciso b), elabore un pronóstico de las ventas diarias para un individuo que compra 25 artículos y paga en efectivo. Para una muestra grande, construya un intervalo de predicción del 95% para las ventas diarias.
- e) Describa la naturaleza de la función ajustada del inciso b). ¿Cree usted que es mejor ajustar dos líneas rectas separadas, una para las ventas en efectivo y otra para las ventas con tarjeta de crédito, para los datos de la tabla P-15? Discútalas.
16. Cindy Lawson acaba de comprar un equipo de la liga mayor de béisbol. Ella ha estado recibiendo muchos consejos acerca de lo que debe hacer para convertir a su equipo en ganador. Cindy le pide a usted que estudie este problema y escriba un reporte. Usted decide usar el análisis de regresión múltiple para determinar cuáles datos estadísticos son importantes para desarrollar un equipo ganador (considerado como tal por el número de juegos ganados durante la temporada 1991). Usted reúne los datos de seis estadísticos del *Sporting News*

TABLA P-16

<i>Equipo</i>	<i>Victorias</i>	<i>ERA</i>	<i>SO</i>	<i>BA</i>	<i>Carreras</i>	<i>HR</i>	<i>SB</i>
Gigantes	75	4.03	905	.246	649	141	95
Mets	77	3.56	1,028	.244	640	117	153
Cachorros	77	4.03	927	.253	695	159	123
Rojos	74	3.83	997	.258	689	164	124
Piratas	98	3.44	919	.263	768	126	124
Cardenales	84	3.69	822	.255	651	68	202
Phillies	78	3.86	988	.241	629	111	92
Astros	65	4.00	1,033	.244	605	79	125
Dodgers	93	3.06	1,028	.253	665	108	126
Expos	71	3.64	909	.246	579	95	221
Bravos	94	3.49	969	.258	749	141	165
Padres	84	3.57	921	.244	636	121	101
Medias rojas	84	4.01	999	.269	731	126	59
Medias blancas	87	3.79	923	.262	758	139	134
Yankees	71	4.42	936	.256	674	147	109
Tigres	84	4.51	739	.247	817	209	109
Orioles	67	4.59	868	.254	686	170	50
Cerveceros	83	4.14	859	.271	799	116	106
Indios	57	4.23	862	.254	576	79	84
Azulejos	91	3.50	971	.257	684	133	148
Marineros	83	3.79	1,003	.255	702	126	97
Rangers	85	4.47	1,022	.270	829	177	102
Atléticos	84	4.57	892	.248	760	159	151
Reales	82	3.92	1,004	.264	727	117	119
Ángeles	81	3.69	990	.255	653	115	94
Gemelos	95	3.69	876	.280	776	140	107

NOTA: *ERA* significa promedio de carreras ganadas (*earned run average*); *SO* significa ponches (*strikeouts*); *BA* significa promedio de bateo (*batting average*); *HR* significa *homeruns*; y *SB* significa bases robadas (*stolen bases*).

1992 *Baseball Yearbook*, los cuales se muestran en la tabla P-16, y corre un programa de regresión por pasos, suponiendo un modelo de regresión múltiple con “Victorias” como la variable dependiente.

- a) Discuta la importancia de cada variable independiente.
 - b) ¿Cuál ecuación debe usar Cindy para pronosticar las victorias?
 - c) Escriba un reporte para Cindy.
 - d) Recopile datos de los números más recientes del *Sporting News Baseball Yearbook* u otra fuente de datos estadísticos de béisbol. Corra una regresión por pasos y compare sus resultados.
17. La señora Haight, una agente inmobiliaria, desea pronosticar la importancia de cuatro factores en la determinación de los precios de terrenos. Ella recopila datos sobre el precio, el área, la elevación y la inclinación, y, con base en ello, califica la vista de 50 lotes. Ingresa los datos en un programa de correlación y obtiene la matriz de correlación que se presenta en la tabla P-17. Luego, Haight ingresa los datos en un programa de regresión múltiple por pasos.
- a) Determine cuál variable entrará en primer lugar, segundo, tercero y último lugar al modelo.
 - b) ¿Qué variable o variables serán incluidas en la mejor ecuación de predicción?
18. En la tabla P-18 se listan: la calificación de dos exámenes parciales, X_1 y X_2 ; el promedio actual de calificaciones (GPA), X_3 ; y la calificación del examen final, Y , de 20 estudiantes en la clase de estadística para los negocios.
- a) Ajuste un modelo de regresión múltiple para predecir la puntuación del examen final a partir de las calificaciones de los exámenes parciales y el GPA. ¿Es significativa la regresión? Explique.
 - b) Pronostique la calificación del examen final de un estudiante con calificaciones parciales de 86 y 77 y un GPA de 3.4.
 - c) Calcule los *VIF* y examine los estadísticos t para probar la significancia de las variables explicativas individuales. ¿La multicolinealidad es un problema? Explique.

TABLA P-17

Variable	Variable				
	Precio	Área	Elevación	Pendiente	Vista
Precio	1.00	.59	.66	.68	.88
Área		1.00	.04	.64	.41
Elevación			1.00	.13	.76
Pendiente				1.00	.63
Vista					1.00

TABLA P-18

X_1	X_2	X_3	Y	X_1	X_2	X_3	Y
87	85	2.7	91	93	60	3.2	54
100	84	3.3	90	92	69	3.1	63
91	82	3.5	83	100	86	3.6	96
85	60	3.7	93	80	87	3.5	89
56	64	2.8	43	100	96	3.8	97
81	48	3.1	75	69	51	2.8	50
77	67	3.1	63	80	75	3.6	74
86	73	3.0	78	74	70	3.1	58
79	90	3.8	98	79	66	2.9	87
96	69	3.7	99	95	83	3.3	57

- d) Calcule el apalancamiento medio. ¿Algunas de las observaciones son puntos de apalancamiento alto?
- e) Calcule los residuos estandarizados. Identifique cualquier observación con residuo estandarizado grande. ¿El modelo ajustado predice una respuesta muy alta o muy baja de estas observaciones?
19. Con respecto a los datos de la tabla P-18, obtenga el “mejor” modelo de regresión usando el procedimiento de regresión por pasos y el procedimiento de todas las regresiones posibles. Compare los resultados. ¿Se siente usted confiado al usar un modelo de regresión para predecir la calificación del examen final con menos variables independientes que las tres originales?
20. Recuerde el ejemplo 7.12. El conjunto completo de datos relacionado con la remuneración del director general aparece en el apéndice C. (Consulte las páginas 533-545). Use la regresión por pasos para seleccionar el “mejor” modelo con $k = 3$ variables explicativas. Ajuste el modelo de pasos e interprete los coeficientes calculados. Examine los residuos. Identifique y explique cualquier observación con influencia. Si usted tuviera que elegir entre este modelo y el modelo de pronóstico con $k = 2$ analizado en el ejemplo 7-12, ¿cuál de ellos seleccionaría? ¿Por qué?
21. La tabla P-21 contiene el número de cuentas (en miles) y los activos (en miles de millones de dólares) de 10 corredurías de bolsa *online*. Grafique los activos contra el número de cuentas. Investigue la posibilidad de que la relación sea curva elaborando una regresión múltiple para pronosticar los activos; considere el número de cuentas y el número de cuentas elevado al cuadrado como variables independientes.
- a) Proporcione la función de regresión ajustada. ¿Es significativa la regresión? Explique.
- b) Pruebe la significancia del coeficiente del término elevado al cuadrado. Resuma su conclusión.
- c) Corra otra vez el análisis sin el término cuadrático (elevado al cuadrado). Explique por qué el coeficiente del número de cuentas no es el mismo que el que usted obtuvo en el inciso a).
22. Existen catadores de queso que determinan la calidad de estos productos; las puntuaciones que otorgan se suman para obtener una variable dependiente denominada simplemente “sabor”. Las variables independientes (explicativas) son tres sustancias químicas presentes en el queso: ácido acético, sulfuro de hidrógeno (H_2S), y ácido láctico. Los 15 casos del conjunto de datos se presentan en la tabla P-22. Analice estos datos usando métodos de regresión múltiple. Asegúrese de incluir solamente variables independientes significativas en su modelo final e interprete R^2 . Incluya un análisis de los residuos.
23. Remítase al problema 22. Usando su función final de regresión ajustada, pronostique Sabor (calidad) para Acético = 5.750, H_2S = 7.300, y Láctico = 1.85. (Es posible que no se

TABLA P-21

<i>Activos (miles de millones de) X</i>	<i>Número de cuentas (en miles) Y</i>
219.0	2,500
21.1	909
38.8	615
5.5	205
160.0	2,300
19.5	428
11.2	590
5.9	134
1.3	130
6.8	125

TABLA P-22

<i>Caso</i>	<i>Sabor Y</i>	<i>Acético X₁</i>	<i>H₂S X₂</i>	<i>Láctico X₃</i>
1	40.9	6.365	9.588	1.74
2	15.9	4.787	3.912	1.16
3	6.4	5.412	4.700	1.49
4	18.0	5.247	6.174	1.63
5	38.9	5.438	9.064	1.99
6	14.0	4.564	4.949	1.15
7	15.2	5.298	5.220	1.33
8	32.0	5.455	9.242	1.44
9	56.7	5.855	10.199	2.01
10	16.8	5.366	3.664	1.31
11	11.6	6.043	3.219	1.46
12	26.5	6.458	6.962	1.72
13	0.7	5.328	3.912	1.25
14	13.4	5.802	6.685	1.08
15	5.5	6.176	4.787	1.25

TABLA P-24 Categorías contables para la liga mayor de béisbol (en millones de \$)

<i>GtReceit</i>	<i>MediaRev</i>	<i>StadRev</i>	<i>TotRev</i>	<i>PlayerCt</i>	<i>OpExpens</i>	<i>OpIncome</i>	<i>FranValu</i>	<i>Franchise</i>
19.4	61.0	7.4	90.0	29.8	59.6	30.4	200	NyYank
26.6	32.5	18.0	79.3	36.0	72.0	7.3	180	LADodge
22.9	50.0	16.0	91.1	35.2	70.4	20.7	170	NYMets
44.5	30.0	12.0	88.7	29.7	62.4	26.3	160	TorBIJay
24.5	40.5	14.3	81.5	35.4	70.8	10.7	160	BosRdSox
19.0	24.4	5.0	50.6	15.8	39.5	11.1	140	BaltOrio
27.5	25.7	19.3	78.0	18.0	60.0	18.0	140	ChWhSox
19.9	25.0	12.0	59.1	23.2	46.4	12.7	132	StLCard
22.8	27.5	12.0	64.5	29.0	58.0	6.5	132	ChCubs
19.0	25.5	14.0	61.5	20.7	47.6	13.9	123	TxRanger
16.9	20.5	14.0	53.6	30.4	60.8	-7.2	117	KCRoyals
15.2	23.2	7.6	48.2	21.7	43.4	4.8	115	PhilPhil
25.7	27.0	10.0	64.9	39.2	66.6	-1.7	115	OakAthlt
19.0	27.9	5.0	54.1	34.3	61.7	-7.6	103	CalAngls
15.5	26.2	5.0	48.9	33.3	53.3	-4.4	99	SFGiants
17.1	24.4	5.3	49.0	27.1	48.8	0.2	98	CinnReds
15.6	23.1	7.5	48.4	24.4	48.8	-0.4	96	SDPadres
10.6	25.2	8.0	46.0	12.1	31.5	14.5	95	HousAstr
16.2	21.9	5.5	45.8	24.9	49.8	-4.0	87	PittPirt
15.6	28.8	5.0	51.6	31.1	54.4	-2.8	85	DetTiger
15.4	18.9	3.8	40.3	20.4	40.8	-0.5	83	AtBraves
18.2	20.5	3.2	44.1	24.1	48.2	-4.1	83	MinnTwin
15.5	22.0	5.0	44.7	17.4	41.8	2.9	79	SeatMar
14.2	19.4	3.0	38.8	26.4	50.2	-11.4	77	MilBrews
9.5	23.7	6.6	42.0	19.5	46.8	-4.8	77	ClevIndn
10.7	23.5	3.0	39.4	21.8	43.6	-4.2	75	MonExpos

Fuente: M. Ozanian and S. Taub, "Big Leagues, Bad Business," *Financial World*, July 7, 1992, pp. 34-51.

requieran las tres variables independientes). Si bien n es pequeña en este caso, elabore el intervalo de predicción del 95% para una muestra grande. ¿Siente usted que el análisis de regresión ha producido una herramienta útil para pronosticar la calidad del queso? Explique

24. Las cifras contables de 1991 de la liga mayor de béisbol aparecen en la tabla P-24. Todas las cifras están en millones de dólares. Las variables numéricas son GtReceit (entradas con boleto), MediaRev (ingreso promedio), StadRev (ingreso del estadio), TotRev (ingreso total), PlayerCt (costos de jugadores), OpExpens (gastos operativos), OpIncome (ingreso operativo = ingreso total – gastos operativos) y FranValu (valor de la franquicia).
 - a) Elabore una matriz de correlación para las variables GtReceit, MediaRev, ..., FranValu. A partir de la matriz de correlación, ¿puede usted determinar una variable que sea un buen factor para explicar FranValu? Discútalos.
 - b) Use la regresión por pasos para elaborar un modelo que permita pronosticar el valor de la franquicia usando las variables restantes. ¿Está sorprendido con el resultado? Explique.
 - c) ¿Podría usted concluir que, como regla general, el valor de la franquicia es aproximadamente el doble del ingreso total? Explique
 - d) Los costos de los jugadores son una gran parte de los costos operativos. Desarrolle una ecuación para pronosticar los gastos operativos a partir de los costos de jugadores. Comente acerca de la fortaleza de la relación. Usando los residuos como guía, identifique los equipos que tienen costos de jugadores inusualmente bajos o inusualmente altos como un componente de los gastos operativos.
 - e) Considere las variables diferentes a FranValu. De acuerdo con sus definiciones, ¿existen grupos de variables que sean multicolineales? Si es así, identifique esos grupos.

CASOS

CASO 7-1 EL MERCADO DE BONOS¹⁶

Judy Johnson, vicepresidente financiera de una gran compañía privada que presta servicios públicos en el noroeste del país, se enfrentó con un problema de financiamiento. La compañía necesitaba dinero para pagar deudas de corto plazo por vencer y para continuar la construcción de una planta activada por carbón.

La principal preocupación de Judy era la estimación del mercado de bonos de 10 o 30 años; la compañía necesitaba decidir si usar financiamiento de capital o deuda a largo plazo. Para tomar esta decisión, la institución necesitaba un pronóstico confiable de la tasa de interés que pagaría en el momento de la emisión de los bonos.

Judy convocó a una junta al personal de finanzas para discutir el problema de los bonos. Un miembro de su equipo, Ron Peterson, con una maestría en administración, dijo que, en su opinión, se podía desarrollar un modelo de regresión múltiple para pronosticar las tasas de los bonos. Puesto que la vicepresidente no estaba familiarizada con la regresión múltiple, condujo la discusión en otra dirección. Después de una hora de interacción improductiva, Judy pidió a Ron un reporte al respecto para el siguiente lunes.

Ron sabía que la clave para el desarrollo de un buen modelo de pronóstico es la identificación de las variables independientes que se relacionan con la tasa

¹⁶Los datos de este caso fueron proporcionados por Dorothy Mercer, una estudiante de la maestría en administración de la Universidad del Este de Washington. El análisis fue realizado por los estudiantes de maestría Tak Fu, Ron Hand, Dorothy Mercer, Mary Lou Redmond y Harold Wilson.

de interés pagada por las empresas en el momento de la emisión de los bonos. Después de discutir el problema con varias personas de la institución, Ron decidió investigar las siguientes variables: un índice (Moody's) para la calidad de bonos de una empresa de servicios públicos, la tasa de ganancias de renta fija de una empresa de servicios públicos, las tasas de interés de los bonos del Tesoro de Estados Unidos, el vencimiento de los bonos (a 10 o 30 años) y la prima de interés preferencial al momento de la emisión.

Ron recopiló los datos que podrían correlacionarse con las tasas de interés de bonos para la emisión de bonos de la empresa durante los dos años anteriores. Al principio, no estaba seguro de cómo manejar las tasas de los bonos. Finalmente, decidió considerar sólo empresas cuyas tasas fueran iguales o ligeramente superiores a las de su compañía. Esta decisión le proporcionó una muestra de 93 emisiones para analizar. Pero él estaba preocupado acerca de la validez de utilizar la calidad de los bonos como datos de tipo intervalo. Ron llamó a su ex profesor de estadística y entendió que las variables ficticias resolverían el problema. Así, codificó las clasificaciones de los bonos de la siguiente manera:

$X_1 = 1$ si la clasificación de los bonos es A; 0 de lo contrario

$X_2 = 1$ si la clasificación de los bonos es AA; 0 de lo contrario

Si la clasificación del bono es BAA, tanto X_1 como X_2 son 0. El siguiente paso para Ron fue seleccionar un programa de regresión múltiple de la computadora e introducir los datos. Se incluyeron las siguientes variables en la ecuación completa del modelo:

Variable 1: Y = la tasa de interés pagada por la empresa en el momento de la emisión de bonos

Variable 2: $X_1 = 1$ si la clasificación de los bonos de la empresa es A

Variable 3: $X_2 = 1$ si la clasificación de los bonos de la empresa es AA

Variable 4: X_3 = la tasa de ganancia de la empresa contra los cargos fijos

Variable 5: X_4 = las tasas de bonos del tesoro de los Estados Unidos (para 10 y 30 años) en el momento de la emisión de los bonos

Variable 6: X_5 = vencimiento del bono (10 o 30 años)

Variable 7: X_6 = prima de interés preferencial en el momento de la emisión

Los datos reales se presentan en el apéndice A.

Ron decidió analizar la matriz de correlación mostrada en la tabla 7-18. No se sorprendió de encontrar una relación positiva alta entre la tasa de interés pagada por la empresa en el momento de la emisión de los bonos y la tasa $r = .883$ de los bonos del tesoro de Estados Unidos. También esperaba una relación positiva bastante alta entre la variable dependiente y la tasa preferencial ($r = .596$). No estaba muy sorprendido de descubrir que estas dos variables explicativas estuvieran también relacionadas una con otra (multicolinealidad potencial $r = .713$). La relación negativa entre la variable dependiente y la duración del plazo de los bonos (10 o 30 años), $r = -.221$, también era un resultado que tenía sentido para Ron.

En seguida, Ron corrió un modelo completo que contenía todas las variables explicativas. El examen de los valores t y/o los valores p calculados, los cuales se presentan en la tabla 7-19, indicaron que quizá la variable de la tasa de ingresos a cargos fijos y seguramente la variable de tasa de interés preferencial no estaban haciendo una contribución al pronóstico de la tasa de interés pagada por la institución en el momento de la emisión de los bonos.

Para verificar esta interpretación de los resultados de la regresión completa, Ron decidió hacer una regresión por pasos. La salida se presenta en la tabla 7-20.

Si bien el valor p , .035, asociado con el valor t para la razón entre ingresos y cargos fijos era menor que .05, Ron decidió eliminar la variable razón (Ratio) de su ecuación de regresión. Un argumento adicional para apoyar esta decisión lo dio la pequeña correlación ($r = .097$) de la razón con la variable dependiente Rate. Los resultados de Minitab del modelo final de Ron se presentan en la tabla 7-21.

El reporte de Ron para Judy incluía los siguientes comentarios:

1. El mejor modelo, Interés = $-1.28 - .929 \text{ AA} - 1.18 \text{ AA} + 1.23 \text{ tasas de bonos} + 0.0615 \text{ Plazo}$, explica el 90.6% de la variación de la tasa de interés.
2. El error estándar de la estimación es .53 con base en $n = 93$ observaciones. Por lo tanto, para un pronóstico determinado, $\hat{Y}$, el intervalo de predicción del 95% de los valores reales de la variable es $\hat{Y} \pm 2(.53)$ o $\hat{Y} \pm 1.06$.
3. Todos los coeficientes de las variables independientes son significativos (valores muy pequeños de p) y parecen ser confiables. La multicolinealidad no es un problema.

Ron estaba muy satisfecho con su trabajo y pensaba que Judy también lo estaría.

TABLA 7-18 Matriz de correlación para el estudio del mercado de bonos

	<i>Correlaciones</i>					
	<i>Tasa de interés</i>	<i>A</i>	<i>AA</i>	<i>Razón</i>	<i>Tasas de bonos</i>	<i>Plazo</i>
A	−0.347					−0.314
AA	0.173	−0.399				
Razón	0.097	0.037	0.577			
Tasas de bonos	0.883	−0.256	0.291	0.253		
Plazo	−0.221	0.278	0.010	0.094	−0.477	
Tasa preferencial	0.596	−0.152	0.342	0.255	0.713	

TABLA 7-19 Corrida del modelo completo para el estudio del mercado de bonos**Regression Analysis**

The regression equation is

$$\text{Interest Rates} = -1.03 - 0.829 A - 0.889 AA - 0.242 \text{ Ratio} + \text{Bond Rates} \\ + 0.0628 \text{ Maturity} - 0.0031 \text{ Prime}$$

Predictor	Coef	SE Coef	T	P
Constant	−1.0263	0.6572	−1.56	0.122
A	−0.8285	0.1342	−6.17	0.000
AA	−0.8894	0.2248	−3.96	0.000
Ratio	−0.2417	0.1135	−2.13	0.036
Rates	1.25753	0.05964	21.08	0.000
Maturity	0.062839	0.006589	9.54	0.000
Prime	−0.00313	0.02720	−0.12	0.909

$$S = 0.5235 \quad R\text{-Sq} = 91.1\% \quad R\text{-sq(adj)} = 90.5\%$$

Analysis of Variance

Source	DF	SS	MS	F	P
Regression	6	240.907	40.151	146.52	0.000
Residual Error	86	23.567	0.274		
Total	92	264.474			

Unusual Observations

Obs	A	Rate	Fit St	Dev	Fit Residual	St Resid
64	1.00	15.5000	13.7645	0.1627	1.7355	3.49R
66	1.00	11.3000	13.4780	0.1357	−2.1780	−4.31R
67	1.00	12.3800	13.7897	0.1297	−1.4097	−2.78R
68	1.00	12.1500	13.7097	0.0947	−1.5597	−3.03R

R denotes an observation with a large standardized residual.

PREGUNTA

1. ¿Qué preguntas cree usted que le hará Judy a Ron?

TABLA 7-20 Regresión por pasos para el estudio del mercado de bonos

Stepwise Regression: Int rate versus A, AA, . . .

Alpha-to-Enter: 0.05 Alpha-to-Remove: 0.05

Response is Int rate on 6 predictors, with N = 93

Step	1	2	3	4	5
Constant	1.9818	-0.7641	-0.7372		-1.0244
Bondrate	1.029	1.173	1.267	1.231	1.253
T-Value	17.95	20.44	23.43	24.78	27.21
P-Value	0.000	0.000	0.000	0.000	0.000
Maturity		0.0439	0.0537	0.058	0.0629
T-Value		5.25	7.02	8.37	9.60
P-Value		0.000	0.000	0.000	0.000
Ratio			-0.547		-0.241
T-Value			-5.08	-5.29	-2.14
P-Value			0.000	0.000	0.035
A				-0.56	-0.83
T-Value				-4.49	-6.28
P-Value				0.000	0.000
AA					-0.89
T-Value					-4.10
P-Value					0.000
S	0.800	0.704	0.623	0.565	0.521
R-Sq	77.97	83.14	86.93	89.37	91.09
R-Sq(adj)	77.73	82.76	86.49	88.88	90.58
Mallows Cp	123.6	75.7	41.2	19.6	5.0

TABLA 7-21 Modelo final para el estudio del mercado de bonos

Regression Analysis

The regression equation is

Interest Rates = -1.28 - 0.929 A - 1.18 AA + 1.23 Bond Rates + 0.0615 Maturity

Predictor	Coef	SE Coef	T	P
Constant	-1.2765	0.6554	-1.95	0.055
A	-0.9293	0.1264	-7.35	0.000
AA	-1.1751	0.1781	-6.60	0.000
Rates	1.23308	0.05964	26.81	0.000
Maturity	0.061474	0.006649	9.25	0.000

S = 0.5310 R-sq = 90.6% R-sq(adj) = 90.2%

Analysis of Variance

Source	DF	SS	MS	F	P
Regression	4	239.665	59.916	212.53	0.000
Residual Error	88	24.809	0.282		
Total	92	264.474			

Unusual Observations

Obs	A	Rate	Fit	St Dev Fit	Residual	St Resid
64	1.00	15.5000	13.6956	0.0894	1.8044	3.45R
66	1.00	11.3000	13.6462	0.0898	-2.3462	-4.48R
67	1.00	12.3800	13.6462	0.0898	-1.2662	-4.42R
68	1.00	12.1500	13.6462	0.0898	-1.4962	-2.86R

R denotes an observation with a large standardized residual.

CASO 7-2 AAA WASHINGTON

En el caso 5-5 se echó un vistazo a AAA Washington cuando se pidió a los estudiantes preparar una descomposición de la serie de tiempo de las llamadas al servicio de emergencia en el camino recibidas en el club durante cinco años. El análisis realizado en el caso 5-5 mostró que el patrón del volumen de llamadas del servicio de emergencia en el camino tenía algo de cíclico en su naturaleza. En el caso 6-6 se investigaron cuatro variables: tasa de desempleo, temperatura promedio diaria, precipitación y número de miembros en el club.

La temperatura promedio diaria, la precipitación y, quizás, la tasa de desempleo se identificaron como variables significativas. El número de miembros en el club no era una variable significativa.

Una conversación con el director del centro de llamadas del servicio de emergencia en el camino trajo consigo dos observaciones importantes: **1.** Las fábricas de automóviles parecen diseñar vehículos que operan mejor a 65 grados Fahrenheit y **2.** el volumen de llamadas

parece incrementarse más marcadamente cuando la temperatura promedio baja unos cuantos grados a partir de una temperatura promedio en el rango de los 30 grados de lo que se incrementa cuando una caída similar ocurre con una temperatura promedio en el rango de los 60 grados. Esta información sugería que el efecto de la temperatura sobre el servicio de emergencia en el camino no era lineal.

Michael DeCoria estableció en el caso 6-6 que creía que el número de llamadas recibidas en el servicio estaba relacionado con el ciclo general de la economía y que la tasa de desempleo en el estado de Washington es una buena medida sustituta del estado general de la economía en el estado de Washington. Ahora ha observado que la tendencia cíclica de la serie de tiempo parece quedarse rezagada con respecto al ciclo general de la economía. Los datos sobre la temperatura promedio mensual y la tasa de desempleo en el estado de Washington se presentan en la tabla 7-22.

TABLA 7-22 Datos de AAA Washington

<i>Año</i>	<i>Mes</i>	<i>Llamadas</i>	<i>Tasa de desempleo</i>	<i>Temp.</i>
1987	Junio		6.9940	
	Julio		6.8137	
	Agosto		6.3648	
	Septiembre		6.5435	
	Octubre		6.7826	
	Noviembre		6.9225	
	Diciembre		7.1560	
1988	Enero		7.9143	
	Febrero		7.7576	
	Marzo		7.0641	
	Abril		6.0977	
	Mayo	20,002	5.7867	55.1
	Junio	21,591	5.7592	59
	Julio	22,696	5.5718	63.8
	Agosto	21,509	5.2939	63.8
	Septiembre	22,123	5.4709	59.1
	Octubre	21,449	5.5049	54.6
	Noviembre	23,475	5.8630	45.4
	Diciembre	23,529	6.1349	41
1989	Enero	23,327	7.5474	40.3
	Febrero	24,050	7.8157	34.3
	Marzo	24,010	7.1390	43.2
	Abril	19,735	6.2637	52.5
	Mayo	20,153	5.8332	55.3
	Junio	19,512	5.8077	62.4
	Julio	19,892	5.6713	62.9

TABLA 7-22 (Continuación)				
<i>Año</i>	<i>Mes</i>	<i>Llamadas</i>	<i>Tasa de desempleo</i>	<i>Temp.</i>
1990	Agosto	20,326	5.4977	63.5
	Septiembre	19,378	5.2989	60.9
	Octubre	21,263	5.6028	51.9
	Noviembre	21,443	5.9143	46.2
	Diciembre	23,366	5	41.8
	Enero	23,836	6.1917	41.8
	Febrero	23,336	6.3775	38.9
	Marzo	22,003	5.7234	46.3
	Abril	20,155	4.7792	51.7
	Mayo	20,070	4.5715	54.9
	Junio	19,588	4.3899	59.8
	Julio	20,804	4.2559	66.7
1991	Agosto	19,644	3.9359	66.4
	Septiembre	17,424	3.9048	61.9
	Octubre	20,833	4.4294	50.4
	Noviembre	22,490	5.1523	45.8
	Diciembre	24,861	5.5102	33.9
	Enero	23,441	6.8901	37.9
	Febrero	19,205	7.0308	46.9
	Marzo	20,386	6.7186	43.4
	Abril	19,988	6.1280	49.1
	Mayo	19,077	5.8146	54.3
	Junio	19,141	5.9480	58.2
	Julio	20,883	5.9026	65.4
1992	Agosto	20,709	5.7227	66
	Septiembre	19,647	5.6877	60.9
	Octubre	22,013	6.2922	51
	Noviembre	22,375	7.0615	46.2
	Diciembre	22,727	7.4370	42.4
	Enero	22,367	8.4513	43
	Febrero	21,155	8.7699	46
	Marzo	21,209	8.0728	48.9
	Abril	19,286	7.2392	52.7
	Mayo	19,725	7.0461	58.3
	Junio	20,276	7.0478	63.6
	Julio	20,795	7.1080	64.9
1993	Agosto	21,126	6.7824	65
	Septiembre	20,251	6.7691	58.4
	Octubre	22,069	7.5896	53.2
	Noviembre	23,268	7.9908	44.8
	Diciembre	26,039	8.2460	37.8
	Enero	26,127	9.5301	34.9

PREGUNTAS

1. Desarrolle una ecuación de regresión múltiple usando la tasa de desempleo y la temperatura promedio mensual para pronosticar las llamadas al servicio de emergencias en el camino.
2. Defina una nueva variable de temperatura y relaciónela con el servicio de emergencia en el camino. Recuerde que la temperatura es una escala relativa y que la selección del punto cero es arbitraria.

Si los vehículos están diseñados para operar mejor a 65 grados Fahrenheit, entonces cada grado por arriba o por debajo de 65 grados debe hacer que los vehículos operen menos confiablemente. Para llevar a cabo una transformación de los datos de temperatura que simule este efecto, empiece por sustraer 65 de los valores de temperatura promedio mensual. Esto reposiciona el “cero” a 65 grados Fahrenheit. ¿Deben usarse los valores absolutos de esta nueva variable de temperatura?

3. Defina una nueva variable de tasa de desempleo y relaciónela con el servicio de emergencia en el camino. Dé al desempleo un efecto retrasado en el servicio de emergencia en el camino usando la tasa de desempleo para el mes: **1.** tres meses antes del mes

actual y **2.** 11 meses antes del mes actual de acuerdo con los datos de la variable independiente de desempleo. ¿Qué modelo es mejor para pronosticar? ¿Los signos de los coeficientes de las variables independientes son los que usted esperaría que fueran? ¿Los coeficientes de las variables independientes son significativamente diferentes de cero?

4. Desarrolle una ecuación de regresión múltiple usando la variable de temperatura promedio transformada creada en el paso 2 y la variable de desempleo retrasada creada en el paso 3. ¿Es éste un buen modelo? ¿Se ha violado cualquiera de los supuestos subyacentes?

CASO 7-3 BÉISBOL DE FANTASÍA (A)

Era febrero y John Hanke, un profesor retirado de estadística, se estaba preparando para otra temporada de béisbol de fantasía. En años pasados, sus amigos beisbolistas siempre le decían que seguramente utilizaba sus conocimientos de estadística para obtener alguna ventaja. Por desgracia, eso nunca fue verdad. La enseñanza, la investigación, las publicaciones y los comités de trabajo lo habían mantenido ocupadísimo. Ahora que Hanke está retirado, finalmente tiene el tiempo para aplicar sus conocimientos de estadística en el proceso anual de reclutamiento de jugadores. Cada director técnico tiene \$260 con los cuales hacer ofertas y comprar 23 jugadores (14 bateadores y 9 lanzadores). Cada equipo es clasificado (con base en datos estadísticos reales del jugador de la temporada pasada) en ocho categorías estadísticas. El doctor Hanke estaba muy ocupado en la selección de jugadores que rendirían bien en tres de las cuatro categorías de lanzamiento. En años pasados, su equipo de lanzadores, especialmente sus lanzadores abridores, habían sido el hazmerreír de la liga. La temporada 2007 iba a ser diferente. Él

intentó desarrollar modelos para pronosticar con exactitud los rendimientos de lanzadores abridores.

Las tres categorías que Hanke deseaba investigar eran victorias (VICTORIAS), promedio de carreras ganadas (ERA), y bases por bolas y hits otorgados por entrada (WHIP). Destinó una considerable cantidad de tiempo descargando datos estadísticos de béisbol para lanzadores abridores de la temporada 2006.¹⁷ Intentó desarrollar un modelo de regresión múltiple para pronosticar cada una de las tres categorías de interés. A menudo había predicado a sus estudiantes que la selección de la variable inicial era el aspecto más importante en el desarrollo de un modelo de regresión. Él sabía que, si no tenía buenas variables explicativas, no obtendría ecuaciones útiles de predicción. Después de una cantidad considerable de trabajo, el doctor Hanke seleccionó las cinco variables explicativas potenciales que siguen. También decidió incluir solamente lanzadores abridores que habían lanzado por lo menos 100 entradas durante la temporada. Una parte de los datos de los 138 lanzadores abridores seleccionados se presentan en la tabla 7-23.

TABLA 7-23 Estadísticas de lanzamiento de 138 lanzadores abridores

<i>Lanzador</i>	<i>EQUIPO</i>	<i>ERA</i>	<i>WHIP</i>	<i>CMD</i>	<i>K/9</i>	<i>HR/9</i>	<i>OBA</i>	<i>LANZAMIENTOS</i>
1 Armas, Jr., T	WAS	5.03	1.50	5.7	1.5	1.1	339	1
2 Arroyo, B	CIN	3.29	1.19	6.9	2.9	1.2	289	1
3 Batista, M	ARI	4.58	1.53	4.8	1.3	0.8	343	1
4 Beckett, J	BOS	5.01	1.29	6.9	2.1	1.6	307	1
5 Bedard, E	BAL	3.76	1.35	7.8	2.5	0.7	316	0

¹⁷Los datos estadísticos de lanzamientos de béisbol se descargaron del sitio Web BaseballHQ de Ron Shandler, en www.BaseballHQ.com.

TABLA 7-23 (Continuación)

<i>Lanzador</i>		<i>EQUIPO</i>	<i>ERA</i>	<i>WHIP</i>	<i>CMD</i>	<i>K/9</i>	<i>HR/9</i>	<i>OBA</i>	<i>LANZAMIENTOS</i>
6	Benson, K	BAL	4.82	1.40	4.3	1.5	1.6	325	1
7	Blanton, J	OAK	4.82	1.54	5.0	1.8	0.8	345	1
8	Bonderman, J	DET	4.08	1.30	8.5	3.2	0.8	308	1
9	Bonser, B	MIN	4.22	1.28	7.5	3.5	1.6	304	1
10	Buchholz, T	HOU	5.89	1.25	6.1	2.3	1.7	299	1
11	Buehrle, M	CHW	4.99	1.45	4.3	2.0	1.6	331	0
12	Burnett, A	TOR	3.98	1.30	7.8	3.0	0.9	309	1
13	Bush, D	MIL	4.41	1.14	7.1	4.4	1.1	280	1
14	Byrd, P	CLE	4.88	1.51	4.4	2.3	1.3	341	1
15	Cabrera, D	BAL	4.74	1.58	9.5	1.5	0.7	351	1
16	Cain, M	SF	4.15	1.28	8.4	2.1	0.8	305	1
17	Capuano, C	MIL	4.03	1.25	7.1	3.7	1.2	299	0
18	Carpenter, C	STL	3.09	1.07	7.5	4.3	0.9	268	1
19	Carrasco, H	LAA	3.41	1.20	6.5	2.7	0.9	291	1
20	Chacon, S	PIT	6.36	1.72	5.1	1.0	1.9	370	1
	:	:	:	:	:	:	:	:	:
	:	:	:	:	:	:	:	:	:
119	Tomko, B	LAD	4.73	1.35	6.1	2.6	1.4	317	1
120	Trachsel, S	NYM	4.97	1.60	4.3	1.0	1.3	354	1
121	Vargas, C	ARI	4.83	1.41	6.6	2.4	1.4	326	1
122	Vazquez, J	CHW	4.84	1.29	8.2	3.3	1.0	307	1
123	Verlander, J	DET	3.63	1.33	6.0	2.1	1.0	313	1
124	Wakefield, T	BOS	4.63	1.33	5.8	1.8	1.2	313	1
125	Wang, C	NYN	3.63	1.31	3.1	1.5	0.5	309	1
126	Washburn, J	SEA	4.67	1.35	5.0	1.9	1.2	317	0
127	Weaver, J	STL	5.76	1.51	5.6	2.3	1.8	341	1
128	Weaver, J	LAA	2.56	1.03	7.7	3.2	1.1	261	1
129	Webb, B	ARI	3.10	1.13	6.8	3.6	0.6	279	1
130	Westbrook, J	CLE	4.17	1.43	4.6	2.0	0.6	329	1
131	Williams, W	SD	3.65	1.29	4.5	2.1	1.3	306	1
132	Willis, D	FLA	3.87	1.42	6.4	1.9	0.8	327	0
133	Woods, J	SEA	4.20	1.60	5.7	1.2	1.0	354	0
134	Wright, J	SF	5.19	1.48	4.6	1.2	0.9	336	1
135	Wright, J	NYN	4.49	1.52	5.4	1.5	0.6	343	1
136	Young, C	SD	3.46	1.13	8.2	2.4	1.4	279	1
137	Zambrano, C	CHC	3.41	1.29	8.8	1.8	0.8	307	1
138	Zito, B	OAK	3.83	1.40	6.1	1.5	1.1	324	0

*El conjunto completo de datos está disponible en el sitio Web: www.prenhall.com/hanke under Chapter 7 Case 7-3.

Las variables se definen de la siguiente forma:

ERA: Promedio de carreras ganadas o número de carreras permitidas por partido (en nueve entradas)

WHIP: Número de bases por bolas más hits cedidos por entrada lanzada

CMD: Dominio de lanzamientos, la razón de ponches/bases por bolas

K/9: Bateadores que un lanzador poncha por partido (en nueve entradas lanzadas)

HR/9: *Homeruns* de la oposición por partido (en nueve entradas lanzadas)

OBA: Promedio de bateo de la oposición

THROWS: Lanzador diestro (1) o lanzador zurdo (0)

El siguiente paso en el análisis fue la creación de la matriz de correlación presentada en la tabla 7-24. Hanke encontró que las correlaciones entre ERA y WHIP, y entre ERA y OBA eran iguales, .825. Más aún,

TABLA 7-24 Correlaciones: ERA, THROWS, WHIP, K/9, CMD, HR/9, OBA

	ERA	THROWS	WHIP	K/9	CMD	HR/9
THROWS	0.036					
WHIP	0.825	-0.039				
K/9	-0.445	-0.061	-0.503			
CMD	-0.462	0.121	-0.664	0.570		
HR/9	0.562	0.023	0.341	-0.238	-0.184	
OBA	0.825	-0.039	0.998	-0.510	-0.673	0.341

la correlación entre WHIP y OBA, .998, indicaba que estas variables tenían una relación lineal fuerte. En consecuencia, los lanzadores que estaban bien en una de estas variables debían estar bien en las otras dos. Hanke determinó que el ERA es el mejor indicador del rendimiento y decidió correr una regresión para saber qué tan bien pronosticaban el ERA las variables en este conjunto. Sin embargo, sabía que la alta correlación entre WHIP y OBA crearían un problema de multicolinealidad, de manera que sólo una de estas variables sería requerida en la función de regresión. Hanke seleccionó el OBA lanzando una moneda al aire y corrió una regresión con el ERA como variable dependiente y el resto de variables, con excepción de WHIP, como variables independientes. Los resultados se presentan en la tabla 7-25.

De la tabla 7-25 se desprende que las variables independientes THROWS y K/9 no son significativas, dadas las otras variables en la función de regresión. Más aún, los pequeños *VIF* sugieren que THROWS y K/9 se pueden eliminar juntas y los coeficientes de las variables restantes no cambiarán mucho. La tabla 7-26 presenta el resultado de cuando tanto THROWS como K/9 se dejan fuera del modelo. La R^2 es 78.1%, y la ecuación se ve bien. El estadístico *t* de cada una de las variables explicativas es grande con un valor *p* muy pequeño. Los *VIF* son pequeños para las tres variables explicativas, lo que indica que la multicolinealidad ya no es problema.

Hanke determinó que tiene un buen modelo y desarrolló las gráficas residuales que se presentan en la figura 7-4.

TABLA 7-25 Resultado de la regresión de Minitab usando todas las variables explicativas a excepción de WHIP**Regression Analysis: ERA versus THROWS, K/9, CMD, HR/9, OBA**

The regression equation is

$$\text{ERA} = -5.54 + 0.0779 \text{ THROWS} - 0.0303 \text{ K/9} + 0.125 \text{ CMD} + 0.840 \text{ HR/9} + 0.0280 \text{ OBA}$$

Predictor	Coef	SE Coef	T	P	VIF
Constant	-5.5439	0.7395	-7.50	0.000	
THROWS	0.07792	0.08507	0.92	0.361	1.042
K/9	-0.03028	0.02977	-1.02	0.311	1.602
CMD	0.12517	0.04671	2.68	0.008	2.181
HR/9	0.8404	0.1198	7.02	0.000	1.151
OBA	0.027991	0.002025	13.82	0.000	2.068

S = 0.437305 R-Sq = 78.4% R-Sq(adj) = 77.6%

Analysis of Variance

Source	DF	SS	MS	F	P
Regression	5	91.783	18.357	95.99	0.000
Residual Error	132	25.243	0.191		
Total	137	117.026			

TABLA 7-26 Resultado de la regresión final de Minitab para pronosticar el ERA**Regression Analysis: ERA versus CMD, HR/9, OBA**

The regression equation is





$$\text{ERA} = -5.81 + 0.113 \text{ CMD} + 0.857 \text{ HR/9} + 0.0284 \text{ OBA}$$

Predictor	Coef	SE Coef	T	P	VIF
Constant	-5.8088	0.6862	-8.46	0.000	
CMD	0.11298	0.04290	2.63	0.009	1.837
HR/9	0.8573	0.1191	7.20	0.000	1.137
OBA	0.028425	0.001997	14.23	0.000	2.009

S = 0.437628 R-Sq = 78.1% R-Sq(adj) = 77.6%

Analysis of Variance

Source	DF	SS	MS	F	P
Regression	3	91.363	30.454	159.01	0.000
Residual Error	134	25.663	0.192		
Total	137	117.026			

Gráficas residuales para ERA (variables explicativas: CMD, HR/9, OBA)**Gráfica de probabilidad normal****Contra ajustes****Histograma****Contra orden****FIGURA 7-4 Gráficas residuales del pronóstico del ERA**

PREGUNTAS

1. Haga comentarios sobre el modelo que desarrolló Hanke para pronosticar el ERA. Examine las gráficas residuales de la figura 7-4 y determine si este modelo es válido.
2. ¿Existen algunas relaciones no lineales entre las variables explicativas y el promedio de carreras ganadas? Si es así, desarrolle un modelo nuevo incluyendo la transformación apropiada de la variable.
3. Desarrolle un modelo para pronosticar el ERA usando la variable explicativa WHIP en vez de OBA. ¿Qué modelo prefiere usted, el de OBA como variable explicativa o el de WHIP como variable explicativa? ¿Por qué

CASO 7-4 BÉISBOL DE FANTASÍA (B)¹⁸

Ahora que el doctor Hanke siente que ha desarrollado con éxito un modelo para pronosticar el ERA, está listo para ocuparse de las victorias (WINS).¹⁹ Sin embargo, el consenso de los expertos indicaba que el proyecto estaba destinado al fracaso. Los comentarios en el sitio Web BaseballHQ de Ron Shandler decían: “No hay manera de proyectar con exactitud a los lanzadores año tras año” (Bill James); “Tu activo más valioso es un lanzador abridor con el que puedas contar. El único problema es que no puedes contar con ninguno de ellos” (Peter Golenbock); “¿En qué otro sitio del reino de los deportes fantásticos puede usted tener peores augurios sobre el éxito que en el mundo maravilloso de los lanzadores?” (Rod Beaton); “Los lanzadores abridores son el grupo de personas menos confiables, más impredecibles y más desagradables del mundo; desde el punto de vista estadístico, así es” (John Benson)

Hanke investigó y encontró un modelo estadístico que podía utilizarse. De acuerdo con BaseballHQ de Ron Shandler, cuatro variables tienen un efecto importante sobre las victorias totales de lanzamiento:

1. Ofensiva del equipo
2. Efectividad del lanzamiento

3. Apoyo de lanzadores de reserva
4. Defensa del equipo

Hanke estaba listo para desarrollar una base de datos predictivos.

Para proyectar una ofensiva del equipo, seleccionó carreras anotadas por un equipo (RUNS)²⁰ como la variable más importante. Para indicar qué tan bueno era un equipo en todo, Hanke seleccionó las victorias del equipo (TMWINS). Seis de estas siete variables usadas en el caso 7-3 se utilizaron para indicar la efectividad de un lanzador: ERA, CMD, K/9, HR/9, OBA y THROWS. Para la defensa del equipo, utilizó el número total de errores del equipo (ERRORS). Para el apoyo de lanzadores de reserva, intentó con salvamentos (SAVES).

Un conjunto parcial de datos para las variables de efectividad en el lanzamiento están dadas en la tabla 7-23. Algunos de los datos de las variables restantes se presentan en la tabla 7-27. Los datos restantes tanto para la efectividad en el lanzamiento como datos estadísticos del equipo están disponibles en el sitio Web: www.prenhall.com/hanke en el capítulo 7, caso 7-4.

¹⁸El caso 7-4 está basado en un modelo desarrollado por BaseballHQ de Ron Shandler.

¹⁹Los datos estadísticos de lanzamiento de béisbol fueron descargados del sitio Web de BaseballHQ de Ron Shandler en www.BaseballHQ.com.

²⁰Los datos estadísticos para RUNS, TMWINS y SAVES son de SportsTicket® y aparecen en www.sports.espn.go.com/mlb/stats.

TABLA 7-27 Datos estadísticos del equipo para lanzadores abridores

<i>Lanzador</i>		<i>WINS</i>	<i>TM WINS</i>	<i>RUNS</i>	<i>ERRORS</i>	<i>SAVES</i>
1	Armas Jr., T	9	71	746	131	32
2	Arroyo, B	14	80	749	128	36
3	Batista, M	11	76	773	104	34
4	Beckett, J	16	86	820	66	46
5	Bedard, E	15	70	768	102	35
6	Benson, K	11	70	768	102	35
7	Blanton, J	16	93	771	84	54
8	Bonderman, J	14	95	822	106	46
9	Bonser, B	7	96	801	84	40
10	Buchholz, T	6	82	735	80	42
11	Buehrle, M	12	90	868	80	46
12	Burnett, A.	10	87	809	99	42
13	Bush, D	12	75	730	117	43
14	Byrd, P	10	78	870	118	24
15	Cabrera, D	9	70	768	102	35
16	Cain, M	13	76	746	91	37
17	Capuano, C	11	75	730	117	43
18	Carpenter, C	15	83	781	98	38
19	Carrasco, H	7	89	766	124	50
20	Chacon, S	7	67	691	104	39
:	:	:	:	:	:	:
:	:	:	:	:	:	:
119	Tomko, B	8	88	820	115	40
120	Trachsel, S	15	97	834	104	43
121	Vargas, C	12	76	773	104	34
122	Vazquez, J	11	90	868	80	46
123	Verlander, J	17	95	822	106	46
124	Wakefield, T	7	86	820	66	46
125	Wang, C	19	97	930	104	43
126	Washburn, J	8	78	756	88	47
127	Weaver, J	8	83	781	98	38
128	Weaver, J	11	89	766	124	50
129	Webb, B	16	76	773	104	34
130	Westbrook, J	15	78	870	118	24
131	Williams, W	12	88	731	92	50
132	Willis, D	12	78	758	126	41
133	Woods, J	7	78	756	88	47
134	Wright, J	6	76	746	91	37
135	Wright, J	11	97	930	104	43
136	Young, C	11	88	731	92	50
137	Zambrano, C	16	66	716	106	29
138	Zito, B	16	93	771	84	54

*El conjunto completo de datos está disponible en el sitio Web: www.prenhall.com/hanke en el capítulo 7, caso 7-4.

PREGUNTA

1. El consenso de los expertos indicaba que el proyecto estaba destinado al fracaso.
¿Estaban en lo correcto?

Aplicaciones de Minitab

El problema. En el ejemplo 7.11, Pam Weigand quería correr una regresión por pasos con los datos de Zurenko Pharmaceutical Company para pronosticar cuál candidato se convertiría en un buen vendedor.

Solución de Minitab

1. Si los datos están en un archivo, abra el archivo (Tab 7-13) usando los siguientes menús:

File>Open Worksheet

Si los datos no están en un archivo, introdúzcalos en una hoja de cálculo. Para correr la regresión por pasos, haga clic en los siguientes menús:

Stat>Regression>Stepwise

2. Aparece la ventana de diálogo Stepwise Regression presentada en la figura 7-5.
 - a) La variable dependiente o respuesta (Response) es C1 o Sales.
 - b) Las variables explicativas son C2 a C6 o Aptitude-GPA.
 - c) Haga clic en Methods para indicar el nivel α .




FIGURA 7-5 Ventana de diálogo de la regresión por pasos de Minitab




FIGURA 7-6 Ventana de diálogo de Métodos por pasos de Minitab

3. Aparece la ventana de diálogo Stepwise-Methods de la figura 7-6.
 - a) Haga clic en Use alpha values.
 - b) Haga clic en Stepwise (forward and backward).
 - c) Cambie el Alpha to enter y el Alpha to remove de .15 a .05.
 - d) Haga clic en OK y luego en OK de la ventana de diálogo Stepwise Regression. Los resultados se presentan en la tabla 7-17.

Aplicaciones de Excel

El problema. En el ejemplo 7.1 se usó el análisis de la regresión múltiple para determinar si el precio de venta y los gastos de publicidad podían usarse para pronosticar las ventas mensuales de galones de leche (véase la tabla 7-4).

Solución de Excel

1. Introduzca el título Sales en A1, Price en B1, y Adv. En C1. Introduzca las ventas semanales de A2 a A11, precios de venta de B2 a B11, y gastos de publicidad de C2 a C11 de la hoja de cálculo. Las dos variables explicativas deben estar en columnas adyacentes.
2. Haga clic en los siguientes menús:

Tools>Data Analysis

3. Aparecerá la ventana de diálogo Data Analysis. Debajo de Analysis Tools, seleccione Regression. Aparecerá la ventana de diálogo Regression de la figura 6-22.
 - a) Introduzca de A1 a A2 en Input Y Range (rango Y de entrada).
 - b) Introduzca de B1 a C11 en Input X Range para las dos variables explicativas: precio de venta y gastos de publicidad.
 - c) Haga clic en Labels.
 - d) Haga clic en Output Range e introduzca D1.
 - e) Haga clic en OK y aparecerá el resultado en la hoja de cálculo.

Referencias

- Abraham, B. y J. Ledolter. *Introduction to Regression Modeling*. Belmont, Calif.: Thomson Brooks/Cole, 2006.
- Belsley, D. A. *Conditioning, Diagnostics, Collinearity y Weak Data in Regression*. New York: Wiley, 1991.
- Bowerman, B. L., R. T. O'Connell y A. B. Koehler. *Forecasting, TimeSeries and Regression*, 4a. ed. Belmont, Calif: Thomson Brooks/Cole, 2005.
- Draper, N. R. y H. Smith. *Applied Regression Analysis*, 3a. ed. New York: Wiley, 1998.
- Johnson, R. A. y D. W. Wichern. *Business Statistics: Decision Making with Data*. New York: Wiley, 1997.
- Kutner, M. H., C. J. Nachtsheim, y J. Neter. *Applied Linear Regression Models*, 4a. ed. New York: McGraw-Hill, 2004.