

Resumen 1er Parcial - Sistemas de Gestión

Capítulo 1 - Introducción a los Pronósticos en los Negocios

¿Es Necesario el Pronóstico en los Negocios?

Los pronósticos necesariamente guían el establecimiento de políticas y la planeación.

Los pronósticos son absolutamente necesarios para avanzar en el ambiente de negocios actual, siempre cambiante y altamente interactivo.

El pronosticador eficaz debe ser capaz de establecer una hábil mezcla de pronóstico cuantitativo y buen juicio, evitando los extremos de confiar totalmente en uno o en otro.

Tipos de Pronósticos

Los procedimientos para realizar pronósticos se clasifican, en primer lugar, como de largo plazo y de corto plazo.

- Largo plazo: señalan el curso general de una organización para un tiempo de funcionamiento largo; de modo que se convierten en un tema de particular relevancia para la alta dirección.
- Corto plazo: se requieren para diseñar estrategias inmediatas, y las gerencias media y de primera línea los emplean para satisfacer las necesidades del futuro inmediato.

Los pronósticos también se clasifican en términos de su posición en un continuo micro-macro, es decir, en términos del grado en que implican pequeños detalles o grandes valores de resumen.

Los procedimientos para la elaboración de pronósticos también se clasifican de acuerdo con la tendencia a ser más cualitativos o más cuantitativos.

- Técnica cualitativa: no requiere manipulación de datos alguna, tan sólo se usa el “juicio” del pronosticador.
- Técnica cuantitativa: no necesitan el juicio como insumo, pues se trata de procedimientos mecánicos para producir resultados cuantitativos.

Los pronósticos podrían clasificarse de acuerdo con la naturaleza del producto obtenido. El pronóstico será:

- Pronóstico puntual: un número individual.

- Pronóstico por intervalo :un intervalo de números dentro del cual se espera que esté el valor futuro.
- Pronóstico de densidad: la distribución de probabilidad total del valor futuro.

Consideraciones Macroeconómicas del Pronóstico

Hay un interés creciente en la predicción de variables importantes para toda la economía de un país. Estos se llaman pronósticos macroeconómicos.

Una de las principales dificultades en la elaboración de estos pronósticos es el cambio relevante e inesperado de un factor económico clave (precios del petróleo, inflación súbita, etc.).

Selección de un Método de Pronósticos

Se deben considerar varios factores en la selección de un método para pronosticar:

- Se debe considerar el nivel de detalle.
- La consideración primordial en la selección de un método para pronosticar es que los resultados deben facilitar el proceso de toma de decisiones a los gerentes de la organización. El(los) método(s) seleccionado(s) debería(n) producir un pronóstico que sea preciso, oportuno y comprensible para la gerencia.

Etapas del Pronóstico

El reconocimiento de que las técnicas de pronósticos funcionan con datos generados por eventos históricos conduce a la identificación de los siguientes cinco pasos en el proceso de pronosticar:

1. Formulación del problema y recopilación de datos: el problema determina los datos apropiados. Si los datos apropiados no están disponibles, quizá tenga que volver a definirse el problema o tal vez se tenga que emplear una metodología no cuantitativa para pronosticar.
2. Manipulación y limpieza de datos.
3. Construcción y evaluación del modelo: incluye ajustar los datos recolectados a un modelo de pronóstico que sea adecuado, en términos de minimizar errores en el pronóstico.
4. Implementación del modelo (el pronóstico real): es la generación del modelo real una vez que se hayan recopilado y depurado los datos apropiados, y se haya seleccionado el modelo de pronóstico adecuado. Los datos de periodos históricos más recientes se mantienen como respaldo y más tarde se usan para verificar la exactitud del proceso.

5. Evaluación del pronóstico: implica la comparación de los valores del pronóstico con valores históricos reales. El examen de los patrones de error a menudo lleva al analista a modificar el modelo para pronosticar.

Administración del Proceso de Elaboración del Pronóstico

Siempre deberían surgir algunas preguntas fundamentales, si el proceso de elaboración del pronóstico se administra adecuadamente:

- ¿Por qué es necesario el pronóstico?
- ¿Quién usará el pronóstico y cuáles son los requerimientos específicos?
- ¿Qué nivel de detalle o generalización se requiere, y cuál es el horizonte de tiempo adecuado?
- ¿Qué datos están disponibles y serán suficientes los datos para generar el pronóstico que se necesita?
- ¿Cuánto costará el pronóstico?
- ¿Qué tan exacto se espera que sea el pronóstico?
- ¿el pronóstico estará a tiempo para ayudar en el proceso de toma de decisiones?
- ¿El pronosticador entiende claramente cómo se usará el pronóstico en la organización?
- ¿Está disponible un proceso de retroalimentación para evaluar el pronóstico y ajustar el proceso como corresponde?

Software de Pronósticos

Dos tipos de paquetes computacionales son, en primera instancia, de interés para los pronosticadores:

1. paquetes estadísticos generales que incluyen análisis de regresión, análisis de series de tiempo y otras técnicas usadas frecuentemente por quienes hacen pronósticos;
2. paquetes para elaboración de pronósticos diseñados específicamente para aplicaciones en pronósticos.

Sin embargo, la mayoría de las compañías usan simplemente hojas de cálculo para generar pronósticos y desarrollar planes de negocios.

Resumen

La finalidad de un pronóstico es reducir el nivel de incertidumbre con que deben realizarse los juicios de la gerencia. Tal propósito sugiere dos reglas fundamentales, las cuales debe seguir el proceso de elaboración de pronósticos:

1. El pronóstico debe ser técnicamente correcto y generar pronósticos lo suficientemente precisos para satisfacer las necesidades de la empresa.

2. El procedimiento de elaboración de pronósticos y sus resultados tienen que presentarse convincentemente a la gerencia, de modo que los pronósticos se utilicen en el proceso de toma de decisiones para beneficio de la compañía; los resultados también deben justificarse desde el punto de vista del costo-beneficio.

Los pronosticadores a menudo dan mucha atención a la primera regla y gastan menos esfuerzo en la segunda. Si los pronósticos bien preparados y de costo efectivo van a beneficiar a la empresa, deben usarlos quienes tienen la autoridad para tomar decisiones.

Capítulo 2 - Repaso de Conceptos Estadísticos Básicos

La mayoría de las técnicas para la elaboración de pronósticos se basan en conceptos estadísticos fundamentales.

La mayoría de los procedimientos estadísticos hacen deducciones sobre datos de interés, llamados población, después de la selección y la medición de un subgrupo de tales datos, llamado muestra.

Descripción de Datos con Resúmenes Numéricos

El objetivo de los procedimientos estadísticos descriptivos es detallar brevemente un conjunto grande de mediciones, con unos cuantos valores clave resumidos.

El proceso de promediar generalmente se realiza calculando la **media**, la cual es sensible a unas cuantas mediciones que sean mucho más grandes o mucho más pequeñas que el resto.

$$\bar{X} = \frac{\sum X}{n}$$

La **desviación estándar** es una unidad para medir la distancia desde la media. La fórmula para la desviación estándar está dada por

$$S = \sqrt{\frac{\sum (X - \bar{X})^2}{n - 1}} = \sqrt{\frac{\sum X^2 - \frac{(\sum X)^2}{n}}{n - 1}}$$

Muchos procedimientos estadísticos utilizan la **varianza** de la muestra.

$$s^2 = \frac{\sum (X - \bar{X})^2}{n - 1} = \frac{\sum X^2 - \frac{(\sum X)^2}{n}}{n - 1}$$

Los **grados de libertad** se refieren al número de datos que son independientes uno del otro y que tienen piezas de información únicas.

La **mediana** se usa a menudo para indicar el valor de la parte media o central en un conjunto de datos. La mediana es el valor que divide por la mitad un conjunto de mediciones ordenadas. Es resistente a valores atípicos.

El **rango de datos** se presenta como una medida de dispersión burda. El rango es la diferencia entre los valores mayor y menor.

Después de que los valores numéricos se ordenan de menor a mayor, los **cuartiles** dividen el conjunto de datos en cuatro partes iguales. El segundo cuartil (Q2) es la mediana. El primer cuartil (Q1) divide la mitad inferior del conjunto en dos partes iguales, en tanto que el tercer cuartil (Q3) divide la mitad superior en dos partes iguales.

El **rango intercuartil** es otro indicador de la variabilidad de un conjunto de datos. Es simplemente la diferencia entre el tercer cuartil y el primer cuartil (Q3-Q1).

Presentación de Información Numérica

En la elaboración de pronósticos, trabajamos con dos tipos de datos: **datos transversales**, los cuales consisten en observaciones desde el mismo marco de referencia temporal; y **datos de series de tiempo**, que consisten en una secuencia de observaciones en el tiempo.

Una de las cuestiones más importantes que se deben hacer primero cuando se explora una variable es visualizar los datos en tablas y gráficas.

Un **diagrama de puntos** es una de las formas más simples de visualizar gráficamente los datos.

Un **diagrama de caja** es útil para mostrar las características de distribución de los datos.

El **histograma** condensa los datos, agrupando valores similares en clases.

Se utilizan **diagramas de dispersión** para visualizar la relación entre dos variables.

Para datos cronológicos, la forma gráfica más frecuentemente empleada es un **diagrama de series de tiempo**.

Un paso importante en la selección de una técnica de pronósticos adecuada consiste en identificar los patrones de datos que existen dentro de una serie de tiempo. Se identifican cuatro tipos de patrones de datos para series de tiempo:

- horizontal,
- de tendencia
- cíclico
- estacional

Una herramienta utilizada con frecuencia para identificar patrones de datos en las series de tiempo es el **correlograma** o la **función de autocorrelación**, que es una herramienta gráfica para presentar las correlaciones entre diversos retrasos de una serie de tiempo.

Distribuciones de Probabilidad

Variable aleatoria es el nombre que se le da a una cantidad que puede tomar valores diferentes de una prueba a otra en un experimento. Si sólo son posibles ciertos valores específicos, la variable aleatoria se llama **variable discreta**. Si es posible cualquier valor de la variable aleatoria dentro de cierto rango, se llama **variable continua**.

La **distribución de probabilidad** de una variable aleatoria discreta enlista todos los valores posibles que puede tomar la variable, junto con la probabilidad de que ocurra cada uno. El **valor esperado** ($E(X)$) de una variable aleatoria es el valor medio (promedio) que adquiere la variable en muchos intentos realizados. El valor esperado para una distribución de probabilidad discreta se obtiene al multiplicar cada valor posible de X por su probabilidad, $P(X)$, y después se suman los productos.

En el caso de la distribución continua, las probabilidades se asignan a intervalos o rangos de valores.

La **distribución binomial** a menudo se utiliza para representar una variable aleatoria discreta. Los requisitos para un experimento binomial son los siguientes:

1. Hay n ensayos idénticos, cada uno de los cuales da como resultado uno de dos resultados posibles digamos, éxito y fracaso.
2. La probabilidad de éxito para cada resultado se mantiene igual de un ensayo a otro.
3. Los ensayos son independientes (no están relacionados).

Nos interesa encontrar la probabilidad X de éxitos que ocurren en n ensayos.

$$P(X) = \binom{n}{X} p^X (1 - p)^{n-X}$$

Donde:

p = la probabilidad de éxito en cada ensayo

La distribución continua importante, ya que muchas poblaciones de números se pueden aproximar mediante ella, es la **distribución normal**. La distribución normal tiene forma de campana y está completamente determinada por su media y su desviación estándar.

Distribuciones Muestrales

Una **distribución muestral** es la distribución de todos los valores posibles del estadístico muestral que se pueden obtener de la población, para un tamaño de muestra dado.

El teorema central del límite indica que, conforme aumenta el tamaño de la muestra, la distribución muestral de las medias de la muestra tiende hacia la distribución normal. La media de esta distribución normal es μ , la media de la población; y la desviación estándar es $\sigma/\sqrt{n}$. La cantidad $\sigma/\sqrt{n}$ se conoce como el **error estándar** de la media de la muestra.

Para tamaños de muestra pequeños, quizá las medias muestrales no estén normalmente distribuidas. Sin embargo, si la población de la cual se selecciona la muestra es esencialmente normal y la desviación estándar de la población se estima con la desviación estándar de la muestra S, se conoce la distribución muestral de la relación

$$t = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

También llamada **distribución t de Student** con n — 1 grados de libertad. Sin embargo, conforme se incrementa el número de grados de libertad, la distribución t parece cada vez más una distribución normal con una media de 0 y una desviación estándar de 1.

Inferencia de una Muestra

Estimación

Cuando no es viable o incluso es imposible medir la población total de interés, se selecciona una muestra de la población y se utiliza para aprender acerca de la población. Este aprendizaje (llamado **inferencia**) por lo común toma dos formas. La primera de estas se denomina **estimación**, donde los resultados de la muestra se usan para estimar una característica desconocida de la población. La segunda forma de aprendizaje acerca de la población a partir de una muestra se llama **prueba de hipótesis**.

Un **intervalo de estimación** es un intervalo dentro del cual es probable que esté el parámetro de la población de interés.

Prueba de hipótesis

En muchas situaciones de inferencia, incluyendo la elaboración de pronósticos, el interés está en probar alguna clase de afirmación acerca de la población, en vez de la estimación o el pronóstico de uno de sus parámetros. Este procedimiento se llama prueba de hipótesis e implica los siguientes pasos:

- Paso 1.** Formule la hipótesis que se va a probar (llamada hipótesis nula, representada con H_0) y la definición de la hipótesis alternativa (la que se acepta si H_0 se rechaza, representada con H_1).
- Paso 2.** Obtenga una muestra aleatoria de elementos de la población, mídalos y calcule el estadístico de prueba adecuado de la muestra.
- Paso 3.** Suponga que la hipótesis nula es verdadera, y determine la distribución de muestral, del estadístico de prueba.
- Paso 4.** Calcule la probabilidad de que un valor del estadístico de prueba, por lo menos tan grande como el observado, se hubiera extraído de esta distribución muestral.
- Paso 5.** Si esta probabilidad es alta, no rechace la hipótesis nula; si esta probabilidad es baja, se desacredita la hipótesis nula y puede rechazarse con poco margen de error.

Cuando se siguen estos pasos, es posible que haya dos tipos de error


		<i>Acción</i>	
		<i>No rechace H_0</i>	<i>Rechace H_0</i>
Condición natural	H_0 verdadera	Decisión correcta	Error tipo I: probabilidad α
	H_0 Falsa	Error tipo II: probabilidad β	Decisión correcta

Análisis de Correlación


En la construcción de modelos estadísticos para realizar pronósticos, a menudo es útil examinar la relación entre dos variables. Dos técnicas, el análisis de correlación y el análisis de regresión, se estudian aquí.

Diagramas de dispersión

El diagrama de dispersión ayuda a ilustrar lo que la intuición sugiere cuando se observan a primera vista los datos; a saber: la evidencia de una relación lineal entre Y y X. Esta relación se llama una relación lineal positiva, porque conforme X se incrementa, lo hace también Y.



La relación lineal puede ser fuerte o débil:



A menudo es deseable resumir la relación entre dos variables ajustando una recta a través de los puntos de datos.

Coeficiente de correlación

La fortaleza de la relación lineal que existe entre dos variables se mide usando la **correlación** que existe entre ellas. El **coeficiente de correlación** mide la fortaleza de la siguiente manera. Dos variables con una relación negativa perfecta tienen un coeficiente de correlación igual a -1. En el otro extremo, dos variables con una relación positiva perfecta tienen un coeficiente de correlación igual a 1.

Ajuste de una Línea Recta

Con frecuencia es de interés ajustar una línea recta a través de un conjunto de puntos de datos X-Y, de manera tal que resulte un “buen ajuste”

El enfoque más común para determinar esa línea mejor ajustada se llama **método de los mínimos cuadrados**. Con este procedimiento, se construye una línea que minimiza la suma de los cuadrados de las distancias entre los puntos de datos y la recta, medidos en la dirección (Y) vertical.

El método de los mínimos cuadrados selecciona los valores de la pendiente y de la intersección con el eje Y que minimizan la suma de errores al cuadrado (distancias), SSE, entre los valores de Y y la recta.

$$SSE = \sum (Y - \hat{Y})^2 = \sum (Y - b_0 - b_1 X)^2$$

donde $\hat{Y} = b_0 + b_1 X$ es el valor estimado de Y, sobre la recta ajustada.

Usando el cálculo, se pueden derivar expresiones algebraicas específicas para los valores de los mínimos cuadrados.

$$b_1 = \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\sum (X - \bar{X})^2} = \frac{n \sum XY - \sum X \sum Y}{n \sum X^2 - (\sum X)^2}$$

$$b_0 = \bar{Y} - b_1 \bar{X} = \frac{\sum Y}{n} - \frac{b_1 \sum X}{n}$$

Donde:

b1 = la pendiente de la recta

b0 = la intersección con el eje Y

El coeficiente de la pendiente de cuadrados mínimos está relacionado con el coeficiente de correlación de la muestra. Específicamente:

$$b_1 = \frac{\sqrt{\Sigma(Y - \bar{Y})^2}}{\sqrt{\Sigma(X - \bar{X})^2}} r$$

Evaluación de la Normalidad

Muchas técnicas estadísticas, incluyendo algunas de las que se usan en la elaboración de pronósticos, requieren la suposición de que un conjunto de datos sigue una distribución normal. Por tal motivo, se han desarrollado técnicas estadísticas que prueban la hipótesis de que un conjunto de datos muestrales fue extraído de una población normalmente distribuida.

Un valor p (p-value) grande sugiere que los datos de la muestra son consistentes con la hipótesis nula.

Aplicación en la Administración

Los procedimientos estadísticos descriptivos mencionados al principio del capítulo son ampliamente usados siempre que grandes cantidades de datos deban describirse de forma convincente, de modo que puedan utilizarse en el proceso de toma de decisiones.

Las distribuciones binomial y normal son buenos ejemplos de distribuciones teóricas que sirven como modelos para muchas situaciones de la vida real.

La estimación y la prueba de hipótesis son el principal fundamento de la inferencia estadística básica.

La correlación se utiliza ampliamente para examinar las relaciones entre pares de variables numéricas.

Capítulo 3 - Exploración de Patrones de Datos e Introducción a las Técnicas de Pronósticos

Una de las partes más difícil y que más tiempo consume en la elaboración de pronósticos es la recopilación de datos válidos y confiables.

La difícil tarea a la que se enfrenta la mayoría de los pronosticadores es cómo obtener los datos adecuados que les ayuden a resolver sus problemas propios de toma de decisiones.

Para determinar qué datos serán útiles, se aplican cuatro criterios:

1. Los datos deben ser fidedignos y precisos. Se debe tener mucho cuidado en que los datos se obtengan de una fuente confiable, poniendo especial atención en la exactitud.
2. Los datos deberían ser relevantes. Los datos tienen que ser representativos de las circunstancias para las cuales se están usando.
3. Los datos tienen que ser consistentes. Cuando cambian las definiciones relacionadas con la recopilación de datos, se tienen que hacer los ajustes necesarios para conservar la consistencia en los patrones históricos.
4. Los datos deberían ser oportunos. Los datos recopilados, resumidos y publicados oportunamente tendrán el mayor valor para el pronosticador.

Generalmente, son dos los tipos de datos de interés para el pronosticador.


- Datos de **corte transversal**: observaciones recopiladas en un solo punto del tiempo.
- **Serie de tiempo**: cualquier variable integrada con datos recopilados, registrados u observados durante incrementos de tiempo sucesivos

Estudio de Patrones de Datos en las Series de Tiempo

Existen cuatro tipos generales: horizontal, tendencias, estacionales y cíclicos.


Cuando los datos recopilados en el transcurso del tiempo fluctúan alrededor de un nivel o una media constantes, hay un patrón **horizontal**. Se dice que este tipo de series es **estacionario** en su media.

Cuando los datos crecen o descienden en varios periodos, existe un patrón de **tendencia**. La **tendencia** es el componente de largo plazo que representa el crecimiento o el descenso en la serie de tiempo, durante un periodo extenso.



Cuando las observaciones indican aumentos y caídas que no tienen un periodo fijo, existe un patrón **cíclico**. El **componente cíclico** es la fluctuación con forma de onda alrededor de la tendencia y, por lo común, se ve afectada por las condiciones económicas generales. Un componente cíclico, si existe, típicamente presenta un ciclo durante varios años. El **componente cíclico** es la oscilación alrededor de la tendencia.

Cuando las observaciones se ven influidas por factores temporales, existe un patrón **estacional**. El **componente estacional** se refiere a un patrón de cambio que se repite año tras año.



Exploración de Patrones de Datos con Análisis de Autocorrelación

Cuando se mide una variable a lo largo del tiempo, las observaciones en diferentes periodos a menudo están relacionadas o correlacionadas. Esta correlación se mide usando el coeficiente de autocorrelación.

Autocorrelación es la correlación que existe entre una variable retrasada uno o más periodos consigo misma.

Los patrones de datos que incluyen componentes como tendencia y estacionalidad pueden estudiarse usando autocorrelaciones. Los patrones se identifican examinando los coeficientes de autocorrelación de una variable en diferentes retrasos de tiempo.

La fórmula para calcular el coeficiente de autocorrelación (r_k) entre las observaciones Y_t y Y_{t-k} , que se encuentran a k periodos de distancia es:

$$r_k = \frac{\sum_{t=k+1}^n (Y_t - \bar{Y})(Y_{t-k} - \bar{Y})}{\sum_{t=1}^n (Y_t - \bar{Y})^2} \quad k = 0, 1, 2, \dots$$

Donde

r_k = coeficiente de autocorrelación para un retraso de k periodos

$\bar{Y}$ = media de los valores de la serie

Y_t = observación en el periodo t

Y_{t-k} = observación k periodos anteriores o durante un periodo $t - k$

Generalmente, conforme aumenta el número de retrasos (k), disminuyen las magnitudes de los coeficientes de autocorrelación.

Un **correlograma** o **función de autocorrelación** es una gráfica de las autocorrelaciones para varios retrasos de una serie de tiempo.

Los coeficientes de autocorrelación para diferentes retrasos de tiempo de una variable pueden usarse para contestar las siguientes preguntas acerca de una serie de tiempo:

1. ¿Los datos son aleatorios?
2. ¿Los datos muestran una tendencia (son no estacionarios)?
3. ¿Los datos son estacionarios?
4. ¿Los datos son estacionales?

Si una serie es aleatoria, las autocorrelaciones entre Y_t y Y_{t-k} para cualquier retraso de tiempo k son cercanas a cero. Los valores sucesivos de una serie de tiempo no están relacionados entre sí.

Si una serie muestra una tendencia, las observaciones sucesivas están altamente correlacionadas y es típico que los coeficientes de correlación sean

significativamente diferentes de cero, para los primeros retrasos de tiempo, y de forma gradual tienden a cero conforme se incrementa el número de retrasos.

Si una serie tiene un patrón estacional, se presentará un coeficiente de autocorrelación significativo en el retraso de tiempo estacional o en los múltiplos del retraso estacional. El retraso estacional se considera de 4 para datos trimestrales y 12 para datos mensuales.

¿Los datos son aleatorios?

Un modelo aleatorio simple, a menudo llamado **modelo de ruido blanco**, está representado por

$$Y_t = c + \varepsilon_t$$

La observación Y_t se compone de dos partes: c , el nivel general; y ε_t , el componente de error aleatorio. Es importante advertir que se supone que el componente ε_t no está correlacionado de un periodo a otro.

¿Los datos muestran una tendencia?

Si una serie muestra una tendencia, hay una relación significativa entre los valores sucesivos de la serie de tiempo. Los coeficientes de autocorrelación son usualmente grandes para varios de los primeros retrasos de tiempo y luego, conforme se incrementa el número de retrasos, caen gradualmente hacia cero.

Una serie de tiempo **estacionaria** es aquella cuyas propiedades estadísticas básicas, como la media y la varianza, permanecen constantes en el tiempo. Por lo tanto, se dice que una serie que varía alrededor de un nivel fijo (sin crecimiento ni decrecimiento) con el paso del tiempo es estacionaria. Se dice también que una serie que contiene una tendencia es **no estacionaria**. Los coeficientes de autocorrelación de una serie estacionaria decrecen hacia cero bastante rápidamente, por lo común después del segundo o tercer retraso de tiempo.

A menudo, para analizar la serie no estacionaria, se elimina la tendencia utilizando un método llamado **diferencias** antes de aplicar cualquier modelo.

¿Los datos son estacionales?

Si una serie es estacional, un patrón relacionado con el calendario se repite a sí mismo durante un intervalo de tiempo específico (generalmente un año). Las observaciones de la misma posición, en diferentes periodos estacionales, tienden a estar relacionadas.

Selección de una Técnica de Pronósticos

Antes de decidir sobre la técnica más adecuada para la elaboración del pronóstico de un problema específico deben considerarse las siguientes preguntas:

- ¿Por qué es necesario un pronóstico?
- ¿Quién usará el pronóstico?
- ¿Cuáles son las características de los datos disponibles?
- ¿Qué periodo se va a pronosticar?
- ¿Cuáles son los requerimientos mínimos de datos?
- ¿Qué precisión se desea?
- ¿Cuánto costará el pronóstico?

Para elegir acertadamente la técnica de pronóstico, el pronosticador debe hacer lo siguiente:

- Definir la naturaleza del problema que se va a pronosticar.
- Explicar la naturaleza de los datos en investigación.
- Describir las capacidades y limitaciones de las técnicas de elaboración de pronósticos potencialmente útiles.
- Desarrollar algún criterio predeterminado, con el cual se pueda tomar la decisión.

Un factor importante que influye en la selección de la técnica de elaboración del pronóstico es la identificación y comprensión de patrones históricos en los datos. Si se pueden reconocer patrones de tendencia, cíclicos o estacionales, entonces se deben seleccionar las técnicas que sean capaces de extrapolar efectivamente tales patrones.

Técnicas de pronósticos para datos estacionarios

Es importante reconocer que los datos estacionarios no necesariamente varían de manera aleatoria alrededor de un nivel medio. En su forma más simple, el pronóstico de una serie estacionaria implica el uso de la historia disponible de la serie para estimar su valor medio, el cual se convierte así en el pronóstico de futuros periodos. Las técnicas más avanzadas implican actualizar la historia disponible de la serie para estimar su valor medio, lo que a su vez se convierte en el pronóstico de periodos futuros.

Las técnicas de pronósticos estacionarias se usan en las siguientes circunstancias:

- Los **factores que generan una serie se han estabilizado, y el ambiente en el cual existe la serie permanece relativamente sin cambios.**
- **Se necesita un modelo muy simple debido a la falta de datos para la explicación o implementación.**

- La **estabilidad puede obtenerse haciendo correcciones sencillas de factores tales como crecimiento demográfico o la inflación.**
- La **serie puede convertirse en una serie estable.**
- La **serie es un grupo de errores de pronóstico de una técnica de elaboración del pronóstico que se considera adecuada.**

Técnicas de pronósticos para datos con una tendencia

Las técnicas de pronóstico para datos con tendencia se usan en las siguientes circunstancias:

- Un **incremento en la productividad y nueva tecnología traen consigo cambios en el estilo de vida.**
- Un **incremento de la población causa aumentos en la demanda de bienes y servicios.**
- El **poder de compra de la moneda afecta las variables económicas debido a la inflación.**
- **Incremento de aceptación en el mercado.**

Técnicas de pronósticos para datos estacionales

Una forma de desarrollar pronósticos estacionales es estimar índices estacionales de la historia de la serie. Estos índices se utilizan después para incluir la estacionalidad en los pronósticos o para eliminar tales efectos de los valores observados.

Las técnicas para la elaboración de pronósticos con datos estacionales se usan en las siguientes circunstancias:

- El **clima influye en la variable de interés.**
- El **calendario anual influye en la variable de interés.**

Técnicas de pronósticos para series cíclicas

Los patrones cíclicos son difíciles de modelar porque sus patrones generalmente son inestables. Las fluctuaciones ondulatorias hacia arriba y hacia abajo de la tendencia rara vez se repiten en intervalos de tiempo fijos, en tanto que la magnitud de las variaciones también tiende a cambiar.

Las técnicas para la elaboración de pronósticos con datos cíclicos se usan en las siguientes circunstancias:

- El **ciclo de negocios influye en la variable de interés.**
- **Ocurren cambios en el gusto popular.**
- **Sucedan cambios en la población.**
- **Ocurren cambios en el ciclo de vida del producto.**

Otros factores a considerar en la selección de una técnica de pronóstico

El horizonte de tiempo de un pronóstico tiene una relación directa con la selección de la técnica para pronosticar. En pronósticos de corto y mediano plazos, se puede aplicar una gama de técnicas cuantitativas. Sin embargo, conforme aumenta el horizonte del pronóstico, varias de estas técnicas se vuelven menos adecuadas. Los métodos cualitativos se usan a menudo para los horizontes de tiempo más largos.

La aplicabilidad de las técnicas de elaboración del pronóstico es algo que generalmente el pronosticador determina con base en la experiencia.

Los costos asociados con el uso de la computadora ya no son parte importante en la selección de una técnica.

Evaluación empírica de métodos para pronosticar

La investigación empírica ha encontrado que la exactitud en el pronóstico de los métodos sencillos a menudo es tan buena como la de las técnicas avanzadas o estadísticamente complejas. Por desgracia, los patrones establecidos en las series de tiempo pueden cambiar en el futuro. De modo que tener el modelo que mejor represente los datos históricos (algo que los métodos complejos hacen bien) no necesariamente garantiza mayor exactitud en las predicciones del futuro.

1. Los métodos avanzados o estadísticamente complejos no necesariamente dan como resultado pronósticos más precisos, que los métodos más simples.
2. Diferentes medidas de precisión producen resultados consistentes cuando se usan para evaluar diferentes métodos de elaboración de pronósticos.
3. La combinación de tres métodos de suavizamiento exponencial supera, en promedio, los métodos individuales que se combinan y funcionan bien en comparación con otros métodos.
4. La efectividad de los diferentes métodos de elaboración de pronósticos depende de la longitud del horizonte del pronóstico y la clase de datos que se analizan.

Medición del Error de Pronóstico

Debido a que las técnicas cuantitativas de elaboración de pronósticos a menudo incluyen datos de series de tiempo, se desarrolló una notación matemática para referirse a cada periodo específico. La letra Y se usa para representar una variable de serie de tiempo, a menos que haya más de una variable. El periodo asociado con una observación se identifica como un subíndice. De modo que Y_t se refiere al valor de la serie de tiempo en el periodo t.

Un símbolo $\hat{}$ (sombrero) se coloca arriba de un valor para indicar que se trata del pronóstico.

La notación básica para pronósticos se resume de la siguiente manera:

Y_t = valor de una serie de tiempo en el periodo t

$\hat{Y}_t$ = valor pronosticado de Y_t

$e_t = Y_t - \hat{Y}_t$ = residuo o error de pronóstico

Un **residuo** es la diferencia entre un valor real observado y su valor de pronóstico.

Un método para evaluar una técnica de pronósticos usa la suma de los errores absolutos. La desviación media absoluta (MAD) mide la exactitud del pronóstico, promediando las magnitudes de los errores del pronóstico. MAD está en las mismas unidades que la serie original, y proporciona un tamaño promedio de los “errores” sin importar la dirección.

$$MAD = \frac{1}{n} \sum_{t=1}^n |Y_t - \hat{Y}_t|$$

El error cuadrático medio (MSE) es otro método para evaluar una técnica de elaboración de pronósticos. Cada error o residuo se eleva al cuadrado; luego éstos se suman y se dividen entre el número de observaciones. Este enfoque sanciona errores grandes en la elaboración de pronósticos, ya que los errores están elevados al cuadrado.

$$MSE = \frac{1}{n} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2$$

La raíz cuadrada del MSE, o la raíz cuadrada del error cuadrado medio (RMSE), también se usa para evaluar los métodos de elaboración de pronósticos.

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2}$$

A veces es más útil calcular los errores del pronóstico en términos de porcentajes en vez de cantidades. El error porcentual absoluto medio (MAPE) se calcula obteniendo el error absoluto de cada periodo, dividiendo éste entre el valor real observado en ese periodo y promediando estos errores porcentuales absolutos. El resultado final se multiplica después por 100 y se expresa como porcentaje. El

MAPE es especialmente útil cuando los valores Y_t son grandes.

$$MAPE = \frac{1}{n} \sum_{t=1}^n \frac{|Y_t - \hat{Y}_t|}{|Y_t|}$$

Algunas veces es necesario determinar si el método para pronosticar está sesgado (con pronósticos consistentemente altos o bajos). En estos casos, se usa el error porcentual medio (MPE), el cual se calcula obteniendo el error en cada periodo, dividiendo éste entre el valor real de ese periodo y luego promediando estos errores porcentuales. El resultado usualmente se multiplica por 100 y se expresa como un porcentaje. Si el enfoque del pronóstico no tiene sesgo, el MPE producirá un resultado que esté cercano a cero. Si el resultado es un porcentaje negativo grande, el método de elaboración del pronóstico está sobreestimando consistentemente. Si el resultado es un porcentaje positivo grande, el método de elaboración del pronóstico está subestimando consistentemente.

$$MPE = \frac{1}{n} \sum_{t=1}^n \frac{(Y_t - \hat{Y}_t)}{Y_t}$$

Las cinco medidas de precisión de un pronóstico recientemente descritas son usadas para:

- Comparar la exactitud de dos (o más) técnicas diferentes.
- Medir la utilidad o confiabilidad de una técnica en particular.
- Ayudar en la búsqueda de una técnica óptima.

Determinación de una Técnica Adecuada de Pronóstico

Antes de elaborar el pronóstico con una técnica particular, se debería evaluar lo adecuado de la elección. El pronosticador debe contestar las siguientes preguntas:

- ¿Los coeficientes de autocorrelación de los residuos son indicadores de una serie aleatoria?
- ¿La distribución de los residuos es aproximadamente normal?
- ¿Son significativas las estadísticas t para los valores estimados de los parámetros?
- ¿Quiénes toman decisiones entienden la técnica y la emplean con facilidad?

Aplicación en la Administración

Es importante observar que en muchas situaciones prácticas, más de un método o modelo para pronosticar puede dar como pronósticos aceptables y casi sin diferencias. De hecho, se recomienda intentar varias técnicas razonables para pronosticar.

Capítulo 4 - Métodos de Promedios Móviles y de Suavización

Los métodos **informales** se usan para desarrollar modelos simples que suponen que los datos más recientes ofrecen las mejores predicciones del futuro. Los métodos de **promedio** generan pronósticos con base en un promedio de observaciones pasadas. Los métodos de **suavización** generan pronósticos con base en el promedio de valores pasados de una serie con una serie decreciente (exponencial) de ponderación o pesos.

Una buena estrategia para evaluar los métodos de pronósticos implica los siguientes pasos:

1. La selección de un método de pronósticos se realiza con base en el análisis y la intuición del pronosticador acerca de la naturaleza de los datos.
2. El conjunto de datos se divide en dos secciones: una sección de inicio o de ajuste y una sección de prueba o de pronóstico.
3. La técnica seleccionada de pronóstico se usa para desarrollar valores de ajuste con la primera parte de los datos.
4. La técnica se usa para pronosticar la segunda sección, los pronósticos obtenidos se comparan con los datos y se evalúa el error de pronóstico.
5. Se toma una decisión. La decisión puede ser usar la técnica en su forma actual, modificarla o desarrollar un pronóstico usando otra técnica y comparar los resultados

Modelos Informales

A menudo los negocios nuevos enfrentan el problema de tratar de elaborar un pronóstico con grupos muy reducidos de datos. Los pronósticos informales son una posible solución, puesto que se basan solamente en la información más reciente que está disponible.

Los pronósticos informales suponen que los periodos recientes son los mejores para predecir el futuro. El modelo más sencillo es:

$$\hat{Y}_{t+1} = Y_t$$

El pronóstico informal de cada periodo es la observación inmediata anterior. El pronóstico informal se conoce algunas veces como pronóstico “sin cambio”.

Puesto que el pronóstico informal descarta cualquier otra observación, este esquema detecta cambios muy rápidamente. El problema con este enfoque es que las fluctuaciones aleatorias se producen con la misma fidelidad que los cambios en los datos fundamentales.

La técnica puede ajustarse para tomar en cuenta la tendencia sumando la diferencia entre este periodo y el último:

$$\hat{Y}_{t+1} = Y_t + (Y_t - Y_{t-1})$$

En algunos casos, la tasa de cambio podría ser más apropiada que el valor absoluto del cambio. Si éste es el caso, es razonable elaborar el pronóstico de acuerdo con:

$$\hat{Y}_{t+1} = Y_t \frac{Y_t}{Y_{t-1}}$$

En el caso de datos trimestrales, si el patrón estacional es fuerte, entonces una ecuación adecuada para el pronóstico de datos trimestrales sería:

$$\hat{Y}_{t+1} = Y_{t-3}$$

La mayor debilidad de este enfoque es que ignora todo lo que ha ocurrido desde el año anterior y también cualquier tendencia. El analista puede combinar las estimaciones estacionales y de tendencia, y pronosticar el siguiente trimestre mediante:

$$\hat{Y}_{t+1} = Y_{t-3} + \frac{(Y_t - Y_{t-1}) + \dots + (Y_{t-3} - Y_{t-4})}{4} = Y_{t-3} + \frac{Y_t - Y_{t-4}}{4}$$

Métodos de Pronósticos Basados en Promedios

Estos tipos de técnicas usan alguna clase de promedio ponderado de observaciones pasadas para suavizar fluctuaciones de corto plazo. La suposición implícita de estas técnicas es que las fluctuaciones de los valores pasados representan puntos de partida aleatorios de alguna estructura subyacente.

Promedios simples

Al igual que sucede con los métodos informales, se toma una decisión para usar los primeros puntos de datos t como la parte de inicialización y la parte restante de puntos como la parte de prueba. Luego, se usa la ecuación:

$$\hat{Y}_{t+1} = \frac{1}{t} \sum_{i=1}^t Y_i$$

Cuando se pronostica un gran número de series simultáneamente, el almacenamiento de datos suele ser un problema. Sólo se requiere contar con el pronóstico más reciente y la observación más reciente conforme el tiempo transcurre:

$$\hat{Y}_{t+2} = \frac{t\hat{Y}_{t+1} + Y_{t+1}}{t + 1}$$

El método de promedios simples es una técnica adecuada cuando los factores que producen la serie que se va a pronosticar se han estabilizado y el ambiente en el cual se encuentra la serie generalmente permanece sin cambios.

Un **promedio simple** usa la media de todas las observaciones históricas relevantes como el pronóstico para el siguiente periodo.

Promedios móviles

Se puede especificar un número constante de puntos de datos al inicio y se puede calcular una media con las observaciones más recientes. Conforme está disponible cada nueva observación, se calcula una nueva media sumando el valor más reciente y eliminando el valor más antiguo. Un promedio móvil de orden k, MA(k), se calcula mediante:

$$\hat{Y}_{t+1} = \frac{Y_t + Y_{t-1} + \dots + Y_{t-k+1}}{k}$$

El promedio móvil para el periodo de tiempo t es la media aritmética de las k observaciones más recientes. El porcentaje de respuesta a los cambios en el patrón subyacente de datos depende del número de periodos, k, incluidos en el promedio móvil.

El modelo de promedio móvil no maneja muy bien la tendencia o la estacionalidad, si bien es cierto que lo hace mejor que el método de promedio simple.

Un **promedio móvil** de orden k es el valor de la media de k observaciones consecutivas. El valor del promedio móvil más reciente indicará el pronóstico del siguiente periodo.

Cuanto menor es el número k, mayor es el peso que se asigna a los periodos más recientes. Y a la inversa, cuanto mayor es el número k, menor es el peso que se asigna a los periodos más recientes.

Cuanto más grande es el orden del promedio móvil, mayor es el efecto de suavización.

Promedios móviles dobles

Este método hace lo que indica su nombre: se calcula un conjunto de promedios móviles y luego se calcula un segundo conjunto como un promedio móvil del primer conjunto.

La construcción de un promedio móvil doble se resume en las siguientes ecuaciones. Primero, se usa la ecuación para calcular el promedio móvil de orden k:

$$M_t = \hat{Y}_{t+1} = \frac{Y_t + Y_{t-1} + Y_{t-2} + \cdots + Y_{t-k+1}}{k}$$

Entonces se usa esta otra ecuación para calcular el segundo promedio móvil:

$$M'_t = \frac{M_t + M_{t-1} + M_{t-2} + \cdots + M_{t-k+1}}{k}$$

Se emplea la siguiente ecuación para desarrollar un pronóstico sumando al promedio móvil simple la diferencia entre el promedio móvil simple y el segundo promedio móvil:

$$a_t = M_t + (M_t - M'_t) = 2M_t - M'_t$$

Esta ecuación es un factor de ajuste adicional, que es similar a la medida de cambio a lo largo de la serie:

$$b_t = \frac{2}{k-1}(M_t - M'_t)$$

Finalmente, se usa esta ecuación para realizar el pronóstico de p periodos en el futuro:

$$\hat{Y}_{t+p} = a_t + b_t p$$

Métodos de Suavización Exponencial

La suavización exponencial simple ofrece un promedio móvil con peso exponencial para todos los valores previos observados. A menudo el modelo es adecuado para datos que no tienen una tendencia predecible ascendente o descendente. El objetivo es estimar el nivel real. Esta estimación de nivel se emplea luego como el pronóstico de valores futuros.

La suavización exponencial revisa continuamente un estimado a la luz de las experiencias más recientes. Este método se basa en promediar (suavizar) valores pasados de una serie de manera exponencialmente decreciente. La observación más reciente recibe el peso más grande, α (donde $0 < \alpha < 1$); la siguiente observación más reciente recibe menos peso, $\alpha(1 - \alpha)$; la observación de dos periodos en el pasado recibe incluso menos peso, $\alpha(1 - \alpha)^2$; y así sucesivamente.

En una representación de suavización exponencial, el nuevo pronóstico puede considerarse como la suma ponderada de la nueva observación y el antiguo pronóstico:

$$\text{Nuevo pronóstico} = [\alpha \times (\text{nueva observación})] + [(1 - \alpha) \times (\text{último pronóstico})]$$

Más formalmente, la ecuación de suavización exponencial es

$$\hat{Y}_{t+1} = \alpha Y_t + (1 - \alpha) \hat{Y}_t$$

donde

α = constante de suavización

Esa ecuación se puede escribir como:

$$\begin{aligned}\hat{Y}_{t+1} &= \alpha Y_t + (1 - \alpha) \hat{Y}_t = \alpha Y_t + \hat{Y}_t - \alpha \hat{Y}_t \\ \hat{Y}_{t+1} &= \hat{Y}_t + \alpha(Y_t - \hat{Y}_t)\end{aligned}$$

El valor de α determina el grado con el cual la observación actual influye en el pronóstico de la siguiente observación. Cuando α es cercano a 1, el nuevo pronóstico será, en esencia, la observación actual. A la inversa, cuando α es cercano a cero, el nuevo pronóstico será muy similar al pronóstico anterior, y la observación actual tendrá muy poco efecto.

La **suavización exponencial** es un procedimiento para revisar de forma continua un pronóstico a la luz de la experiencia más reciente.

La sustitución continua (de $\hat{Y}_{t-1}$ y así sucesivamente) indica que $\hat{Y}_{t+1}$ puede escribirse como la suma de la Y actual y las anteriores con pesos que descienden exponencialmente:

$$\hat{Y}_{t+1} = \alpha Y_t + \alpha(1 - \alpha)Y_{t-1} + \alpha(1 - \alpha)^2 Y_{t-2} + \alpha(1 - \alpha)^3 Y_{t-3} + \dots$$

El valor asignado a α es la clave del análisis. Si se desea que las predicciones sean estables y las variaciones aleatorias se suavicen, se requiere un valor pequeño de α . Si se desea una respuesta rápida a un cambio real en el patrón de observaciones, un valor más grande de α es el apropiado.

La suavización exponencial a menudo es un buen procedimiento para pronosticar cuando una serie de tiempo que no es aleatoria exhibe una tendencia en su comportamiento. Es útil desarrollar una medida que se pueda utilizar para determinar cuándo ha cambiado el patrón básico de una serie de tiempo. Una señal de control es un modo de supervisar un cambio. Una **señal de control** implica el cálculo de una medida de los errores de pronóstico en el tiempo y el establecimiento de límites, de manera que, cuando los errores caen fuera de esos límites, el encargado de efectuar el pronóstico recibe una señal de alerta.

Suavización exponencial ajustada a la tendencia: Método de Holt

En la suavización exponencial simple, se supone que el nivel de las series de tiempo varía ocasionalmente, y se requiere un estimado del nivel actual. En algunas situaciones, los datos observados tienen una tendencia clara y contienen información que permite anticipar movimientos futuros ascendentes. La **suavización exponencial lineal de Holt** toma en cuenta la evolución local lineal de las tendencias en una serie de tiempo y puede usarse para generar pronósticos

Cuando se anticipa una tendencia en una serie de tiempo, se requiere un estimado de la pendiente actual, así como del nivel actual. La técnica de Holt suaviza directamente el nivel y la pendiente usando diferentes constantes de suavización para cada uno.

Las tres ecuaciones usadas en el método de Holt son:

1. La serie suavizada exponencialmente o nivel actual estimado

$$L_t = \alpha Y_t + (1 - \alpha)(L_{t-1} + T_{t-1})$$

2. El estimado de la tendencia

$$T_t = \beta(L_t - L_{t-1}) + (1 - \beta)T_{t-1}$$

3. El pronóstico para los p periodos del futuro

$$\hat{Y}_{t+p} = L_t + pT_t$$

donde

L_t = nuevo valor suavizado (estimado del nivel actual)

$\alpha = 1$, constante de suavización para el nivel ($0 < \alpha < 1$)

Y_t = nueva observación o valor real de la serie en el periodo t

β = constante de suavización para el estimado de la tendencia ($0 < , \beta < 1$)

T_t = estimado de tendencia

p = periodos a pronosticar en el futuro

$\hat{Y}_{t+p}$ = pronóstico para el periodo p en el futuro

Suavización exponencial ajustada a la tendencia y a la variación estacional: Método de Winters

En el método de Winters, se emplea una ecuación adicional para estimar la estacionalidad.

Las cuatro ecuaciones usadas en la suavización (multiplicativa) de Winters son:

1. Series suavizadas exponencialmente o nivel estimado:

$$L_t = \alpha \frac{Y_t}{S_{t-s}} + (1 - \alpha)(L_{t-1} + T_{t-1})$$

2. Estimación de la tendencia:

$$T_t = \beta(L_t - L_{t-1}) + (1 - \beta)T_{t-1}$$

3. Estimado de estacionalidad:

$$S_t = \gamma \frac{Y_t}{L_t} + (1 - \gamma)S_{t-s}$$

4. Pronóstico de p periodos futuros:

$$\hat{Y}_{t+p} = (L_t + pT_t)S_{t-s+p}$$

donde

L_t = nuevo valor suavizado (estimado de nivel actual)

α = constante de suavización del nivel

Y_t = nueva observación o valor real en el periodo t

β = constante de suavización para el estimado de tendencia

T_t = estimado de tendencia

γ = constante de suavización para el estimado de estacionalidad

S_t = estimado de estacionalidad

p = periodos futuros a pronosticarse

s = longitud de la estacionalidad

$\hat{Y}_{t+p}$ = el pronóstico para el periodo p en el futuro

La suavización exponencial es una técnica habitual para pronósticos de corto plazo. Sus mayores ventajas son su bajo costo y su sencillez

Capítulo 5 - Series de Tiempo y sus Componentes

Descomposición

Un enfoque para el análisis de los datos de las series de tiempo incluye un intento por identificar los componentes que influyen en cada uno de los valores de una serie. Este procedimiento de identificación se llama **descomposición**.

Para comprender la descomposición, iniciaremos con los cuatro componentes de las series de tiempo. Éstos son el componente de la tendencia, el componente cíclico, el componente estacional y el componente irregular o aleatorio.

1. **Tendencia.** La tendencia es el componente que representa el crecimiento (o la declinación) subyacente en una serie de tiempo. El componente de la tendencia se denota como T.
2. **Componente cíclico.** Es una serie de fluctuaciones en forma de onda o ciclos de más de un año de duración. La letra C representa el componente cíclico.
En la práctica, los ciclos son difíciles de identificar, de manera que con frecuencia se les considera como parte de la tendencia.
3. **Componente estacional.** Los componentes estacionales se encuentran comúnmente en datos trimestrales, mensuales o semanales. La variación estacional se refiere a un patrón de cambio más o menos estable que aparece anualmente y se repite un año tras otro. S representa al componente estacional.
4. **Componente irregular.** El componente irregular consiste en fluctuaciones impredecibles o aleatorias. Estas fluctuaciones son el resultado de incontables hechos que de forma individual tal vez no sean particularmente importantes, pero cuyos efectos combinados suelen ser considerables. I representa al componente irregular

Para estudiar los componentes de una serie de tiempo, el analista debe considerar cómo se relacionan los componentes con la serie original. Esta tarea se lleva a cabo especificando un **modelo** (relación matemática) que exprese la variable Y de la serie de tiempo en términos de los componentes T, C, S e I.

- Un modelo que trata los valores de la serie de tiempo como una suma de los componentes se llama **modelo aditivo de los componentes**.
- Un modelo que trata los valores de las series de tiempo como el producto de los componentes se llama **modelo multiplicativo de los componentes**.

Ambos modelos se denominan algunas veces **modelos de componentes no observados**. El método de análisis de las series de tiempo descrito en este capítulo implica un intento por estimar los valores de los componentes, dada la serie observada. Estas estimaciones pueden utilizarse para pronosticar o desplegar la

serie sin el inconveniente de las fluctuaciones estacionales. Este último proceso se llama **ajuste estacional**.

Para simplificar, supondremos que cualquier ciclo en los datos es parte de la tendencia. De manera que inicialmente consideraremos sólo tres componentes: T, S e I.

Los dos modelos más sencillos que relacionan los valores observados (Y_t) de una serie de tiempo con los componentes de la tendencia (T_t), estacionales (S_t) e irregulares (I_t) son:

- el modelo de componentes aditivo:

$$Y_t = T_t + S_t + I_t$$

Funciona mejor cuando la serie de tiempo sometida a análisis tiene aproximadamente la misma variabilidad a lo largo de toda la serie. Es decir, en esencia, todos los valores de la serie caen dentro de una banda de anchura constante centrada en la tendencia.

- el modelo de componentes multiplicativo:

$$Y_t = T_t \times S_t \times I_t$$

Funciona mejor cuando la variabilidad de la serie de tiempo aumenta con el nivel.¹ Es decir, los valores de la serie se dispersan conforme la tendencia aumenta, y el conjunto de observaciones tiene la apariencia de un megáfono o embudo.

Tendencia

Las tendencias son movimientos a largo plazo en una serie de tiempo que en ocasiones pueden describirse mediante una línea recta o una curva suave.

Para las series de tiempo de negocios y económicas, lo mejor es ver la tendencia como un cambio uniforme en el tiempo. En raras ocasiones podemos suponer que la tendencia realmente queda representada mediante alguna función tan simple como una línea recta durante el todo el periodo en el cual observamos la serie de tiempo. Sin embargo, a menudo es conveniente ajustar una curva de tendencia a una serie de tiempo por dos razones:

1. Proporciona cierto indicio de la dirección general de la serie observada.
2. Puede eliminarse de la serie original para obtener una imagen más clara de la estacionalidad.

Si la tendencia parece ser aproximadamente lineal, se representa:

$$\hat{T}_t = b_0 + b_1t$$


Las ecuaciones de tendencia en el tiempo, incluyendo la tendencia en línea recta, se pueden ajustar a los datos usando el **método de mínimos cuadrados**:

$$SSE = \sum (Y_t - \hat{T}_t)^2$$

Curvas de tendencia no lineal

El ciclo de vida de un producto nuevo tiene tres etapas: Introducción, crecimiento, y madurez y saturación.

Los incrementos por periodo en la curva del ciclo de vida del producto son muy diferentes dependiendo de la etapa del ciclo. Se necesita una curva diferente de una línea recta para modelar la tendencia del ciclo de vida de un producto nuevo.



Una función simple que toma en cuenta la curvatura es la ecuación de la tendencia cuadrática:

$$\hat{T}_t = b_0 + b_1t + b_2t^2$$

Cuando una serie de tiempo inicia lentamente y luego parece que se incrementa a un ritmo creciente de manera que la diferencia porcentual entre una observación y otra es constante, es posible ajustar una tendencia exponencial. La tendencia exponencial está dada por:

$$\hat{T}_t = b_0b_1^t$$

El coeficiente b_1 está relacionado con la tasa de crecimiento. Si la tendencia exponencial se ajusta a los datos anuales, se estima que la tasa de crecimiento anual es $100(b_1 - 1)\%$.

Pronóstico de la tendencia

Ahora suponga que estamos en el momento $t = n$ (fin de la serie) y queremos usar un modelo de tendencia para pronosticar el valor de Y , p pasos adelante. El periodo en el cual hacemos el pronóstico, n en este caso, se llama el **origen del**

pronóstico. El valor p se conoce como **tiempo principal**. Para el modelo de tendencia lineal, podemos generar un pronóstico evaluando

$$\hat{T}_{n+p} = b_0 + b_1(n + p)$$

Los modelos de la curva de tendencia se basan en las siguientes suposiciones:

1. Se ha seleccionado la curva de tendencia correcta.
2. La curva que se ajusta al pasado es indicativa del futuro.

Estas suposiciones sugieren que el buen juicio y la experiencia desempeñan un papel esencial en la selección y el uso de una curva de tendencia.

Estacionalidad

Las series de tiempo que consisten en observaciones semanales, mensuales o trimestrales a menudo presentan estacionalidad.

El análisis del componente estacional de una serie de tiempo tiene implicaciones inmediatas en el corto plazo.

Se han desarrollado varios métodos para medir la variación estacional. La idea básica en todos estos métodos es, primero, estimar y eliminar la tendencia de la serie original y, después, suavizar el componente irregular. Teniendo en mente nuestros modelos de descomposición, esto deja datos que contienen sólo variación estacional. Luego, se recolectan y se resumen los valores estacionales para obtener un número (generalmente un número índice) para cada intervalo del año observado.

La identificación del componente estacional en una serie de tiempo difiere del análisis de tendencia por lo menos en dos formas:

1. La tendencia se determina directamente a partir de los datos originales, pero el componente estacional se determina indirectamente después de eliminar los otros componentes de los datos, de manera que sólo quede la estacionalidad.
2. La tendencia se representa mediante la curva, o ecuación, mejor ajustada, mientras que debe calcularse un valor estacional por separado para cada intervalo observado del año (semana, mes, trimestre) y a menudo tiene la forma de un número índice.

Los **números índices** son porcentajes que indican los cambios en el tiempo.

Para resaltar la estacionalidad, primero debemos estimar y eliminar la tendencia. Esta última puede estimarse con una de las curvas de tendencia que explicamos antes, o bien, usando un promedio móvil.

Al suponer un modelo de descomposición multiplicativo, la **proporción del promedio móvil** es un método que se emplea comúnmente para medir la variación estacional.

Si el patrón estacional parece modificarse con el tiempo, entonces la estimación del componente estacional con el conjunto completo de datos puede conducir a resultados engañosos. En este caso, es mejor:

1. Usar sólo datos recientes (de los últimos años) para estimar el componente estacional
2. Usar un modelo de series de tiempo que permita analizar la evolución de la estacionalidad

Los resultados de un análisis estacional sirven para:

1. Eliminar la estacionalidad en los datos;
2. Pronosticar valores futuros;
3. Evaluar las posiciones actuales en ventas, inventarios y embarques, por ejemplo;
4. Programar la producción.

Datos ajustados a la estacionalidad

Una vez que se ha aislado el componente estacional, se puede usar para calcular **datos ajustados a la estacionalidad**. Para una descomposición aditiva, los datos ajustados a la estacionalidad se calculan restando el componente estacional:

$$Y_t - S_t = T_t + I_t$$

Para una descomposición multiplicativa, los datos ajustados a la estacionalidad se calculan dividiendo las observaciones originales entre el componente estacional:

$$\frac{Y_t}{S_t} = T_t \times I_t$$

Hay tres motivos para hacer ajustes estacionales:

1. Los ajustes estacionales permiten la comparación confiable de valores en diferentes momentos.
2. Es más fácil comprender las relaciones entre las variables económicas o de negocios una vez que se ha eliminado de los datos el complicado factor de la estacionalidad.
3. El ajuste estacional es un elemento útil para elaborar pronósticos de corto plazo de los valores futuros de una serie de tiempo.

Variaciones cíclicas e irregulares

Como hemos visto, hasta el grado en que se pueden medir, los ciclos no muestran un patrón consistente. Sin embargo, es posible lograr cierta comprensión del comportamiento cíclico de una serie de tiempo si se eliminan los componentes de tendencia y estacionalidad mediante la descomposición multiplicativa

$$\frac{Y_t}{T_t \times S_t} = \frac{T_t \times C_t \times S_t \times I_t}{T_t \times S_t} = C_t \times I_t$$

Se puede usar un promedio móvil para suavizar las irregularidades, I_t , dejando el componente cíclico C_t . Las irregularidades se suavizan usando un promedio móvil con un número impar de periodos.

Finalmente, el componente irregular se calcula mediante:

$$I_t = \frac{C_t \times I_t}{C_t}$$

El componente irregular representa la variabilidad en la serie de tiempo después de que se eliminaron los demás componentes. Algunas veces se le conoce como **residuo** o **error**. En una descomposición multiplicativa, tanto los componentes cíclicos como los irregulares se expresan en forma de índices.

Indicadores de negocios

Una manera de investigar los patrones cíclicos es a través del estudio de los indicadores de negocios. Los **indicadores de negocios** son series de tiempo relacionadas con los negocios, las cuales ayudan a evaluar el estado general de la economía.

La lista actual contiene 21 indicadores: 10 clasificados como adelantados, 4 como coincidentes y 7 como retrasados.

1. **Indicadores adelantados.** En la práctica, los componentes de la serie adelantada se estudian para anticipar los momentos de cambio en la economía. (Ej. permisos de construcción)
2. **Indicadores coincidentes.** Proporcionan una medida de cómo está funcionando actualmente la economía. (Ej. producción industrial)
3. **Indicadores retrasados.** El nombre de estos indicadores se debe a que tienden a retrasarse con respecto a la situación general de la economía, tanto en tiempos de bonanza como de crisis. (Ej. índice de desempleo)

Los ciclos implican momentos de inflexión. Es decir, estos momentos indican el inicio de una caída o un crecimiento en el ciclo de negocios.

La discusión hasta ahora indica cómo se pueden separar los factores que crean la variación en una serie de tiempo para estudiarlos individualmente. **Análisis** es el proceso de separar las partes de una serie de tiempo; **síntesis** es el proceso de reunir de nuevo las partes.

Pronóstico de una Serie de Tiempo Estacional

En la elaboración del pronóstico de una serie estacional, se invierte el proceso de descomposición. En vez de separar la serie en sus componentes individuales para su examen, re combinamos los componentes para elaborar los pronósticos de periodos futuros.

Los pronósticos que se elaboran a partir de un modelo aditivo o un modelo de descomposición multiplicativo reflejan la importancia de los componentes individuales. Si una variable es altamente estacional, entonces los pronósticos tendrán un fuerte patrón estacional. Si, además, existe una tendencia, los pronósticos seguirán un patrón estacional superpuesto a la tendencia extrapolada. Si un componente domina el análisis, por sí solo daría un pronóstico exacto y práctico de corto plazo.

Método de Descomposición de Censo II

La descomposición del Censo II por lo general es multiplicativa. La descomposición también supone tres componentes: tendencia-ciclo, estacional e irregular.

El método del Censo II repite una serie de pasos hasta que los componentes logran aislarse con éxito. Muchos de los pasos implican la aplicación de promedios móviles ponderados a los datos. Esto da como resultado una pérdida inevitable de datos al principio y al final de la serie a causa del promedio.

La idea básica es muy simple: aislar uno por uno los componentes de tendencia-ciclo, estacional e irregular.

Pasos:

1. Se aplica un promedio móvil de s periodos a los datos originales para obtener un estimado aproximado del componente tendencia-ciclo. (Para datos mensuales, s 12; para datos trimestrales, s 4; etcétera).
2. Se calculan las razones entre los datos originales y estos valores de promedios móviles como una descomposición multiplicativa clásica.
3. Las razones del paso 2 contienen tanto el componente estacional como el irregular. También incluyen los valores extremos resultantes de eventos inusuales como huelgas o guerras. Las razones se dividen entre una estimación aproximada del componente estacional para obtener una

estimación del componente irregular. Un valor demasiado grande del término irregular indica un valor extremo en los datos originales. Se identifican estos valores extremos y se ajustan las razones del paso 2 como corresponda. Esto elimina efectivamente valores que no se ajustan al patrón de los datos restantes. Los valores faltantes al principio y al final de las series también se reemplazan con las estimaciones de esta etapa.

4. Las razones obtenidas a partir de los datos modificados (con los valores extremos reemplazados y las estimaciones de los valores faltantes) se suavizan usando un promedio móvil para eliminar la variación irregular. Esto permite obtener una estimación preliminar del componente estacional.
5. Los datos originales se dividen entre el componente estacional preliminar del paso 4 para obtener la serie preliminar ajustada estacionalmente, la cual contiene el componente tendencia-ciclo y el componente irregular. En símbolos.

$$\frac{Y_t}{S_t} = \frac{T_t \times S_t \times I_t}{S_t} = T_t \times I_t$$

6. El componente tendencia-ciclo se estima aplicando un promedio móvil ponderado a la serie preliminar ajustada estacionalmente. Este promedio móvil elimina la variación irregular y genera una curva suave que indica el componente preliminar de tendencia-ciclo en los datos.
7. Se repite el paso 2 con esta nueva estimación de la tendencia-ciclo. Es decir, las nuevas razones que contienen sólo los componentes estacionales e irregulares se obtienen dividiendo las observaciones originales entre la tendencia-ciclo del paso 6. Éstas son las razones finales estacionales-irregulares. Matemáticamente,

$$\frac{Y_t}{T_t} = \frac{T_t \times S_t \times I_t}{T_t} = S_t \times I_t$$

8. Se repite el paso 3 usando las nuevas razones calculadas en el paso 7.
9. Se repite el paso 4 para obtener una nueva estimación del componente estacional.
10. Se repite el paso 5 con el componente estacional del paso 9.
11. Se dividen los datos ajustados estacionalmente del paso 10 entre la tendencia-ciclo obtenida en el paso 6 para obtener el componente irregular estimado.
12. Los valores extremos del componente irregular se sustituyen como en el paso 3. Se obtiene una serie de datos modificados al multiplicar la tendencia-ciclo, el componente estacional y el componente irregular ajustado. Estos datos reproducen los datos originales, a excepción de los valores extremos.

Se repiten los 12 pasos anteriores, iniciando con los datos modificados del paso 12 en vez de los datos originales. La longitud de los promedios móviles usados en los diferentes pasos cambiará dependiendo de la variabilidad en los datos.

La serie final ajustada estacionalmente se determina dividiendo el componente estacional final entre los datos originales. El resultado contiene sólo el producto del componente tendencia-ciclo y el componente irregular.

Aplicación en la Administración

El análisis de las series de tiempo es una herramienta estadística ampliamente utilizada en el pronóstico de acontecimientos futuros entrelazados de alguna manera con la economía.

Apéndice: Índice de Precios

Varias de las series de tiempo referentes a producción, ventas y otras situaciones económicas contienen datos disponibles sólo en dólares. La inflación y una gran variación de precios en el tiempo pueden causar problemas de análisis. Así, a menudo es necesario saber cuánto del cambio del valor en dólares representa un cambio real en la cantidad física y cuánto se debe al cambio en el precio causado por la inflación. En estos casos es deseable expresar los valores en dólares constantes.

El concepto de **poder de compra** es importante. El poder actual de compra de \$1 se define como sigue:

$$\text{Actual poder de compra de \$1} = \frac{100}{\text{Índice de precios al consumidor}}$$

Para expresar los valores de dólares en términos de **dólares constantes**:

$$\text{Valor deflactado del dólar} = (\text{Valor del dólar}) \times (\text{Poder de compra de \$1})$$

El propósito de la deflación en los valores en dólares es eliminar el efecto de los cambios en el precio. Este ajuste se llama **deflación del precio** y se utiliza para expresar una serie en dólares constantes.

Capítulo 6 - Regresión Lineal Simple

Línea de Regresión

La línea que mejor se ajusta a una colección de puntos de datos X–Y es la línea que minimiza la suma de los cuadrados de las distancias entre los puntos y la línea, medidas verticalmente, es decir, en la dirección Y. Esta línea se conoce como la **línea de los mínimos cuadrados** o **línea de regresión ajustada** y su ecuación se llama **ecuación de regresión ajustada**.

La línea recta ajustada es de la forma $\hat{Y} = b_0 + b_1X$. El objetivo inmediato es determinar los valores de b_0 y b_1 .

El método de los mínimos cuadrados selecciona los valores de b_0 y b_1 que minimizan los errores de la suma de los cuadrados (distancias).

$$SSE = \sum (Y - \hat{Y})^2 = \sum (Y - b_0 - b_1X)^2$$

$$b_1 = \frac{n\sum XY - \sum X \sum Y}{n\sum X^2 - (\sum X)^2} = \frac{\sum (X - \bar{X})(Y - \bar{Y})}{\sum (X - \bar{X})^2}$$

$$b_0 = \frac{\sum Y}{n} - \frac{b_1 \sum X}{n} = \bar{Y} - b_1 \bar{X}$$

Como usted podrá adivinar, el coeficiente de la pendiente de los mínimos cuadrados está relacionado con el coeficiente de correlación de la muestra. Específicamente,

$$b_1 = \frac{\sqrt{\sum (Y - \bar{Y})^2}}{\sqrt{\sum (X - \bar{X})^2}} r$$

Las diferencias entre los valores Y realmente observados y los correspondientes valores Y ajustados se llaman **residuos**.

Tenemos la identidad:

$$\text{Observación} = \text{Ajuste} + \text{Residuo}$$

$$Y = \hat{Y} + (Y - \hat{Y})$$

Con frecuencia no conviene predecir valores de Y para cualquier X más allá del rango de las X recopiladas en los datos muestrales. Una función de regresión

debería interpretarse como una aproximación útil al comportamiento en el mundo real de la región en la cual existen datos.

El modelo estadístico de la regresión lineal simple supone que para todos los valores de X , los valores observados de la variable dependiente, Y , están normalmente distribuidos alrededor de la media, $\mu_y = \beta_0 + \beta_1 X$, la cual depende linealmente de X . Es decir, conforme X cambia, las medias de la distribución de los valores posibles de Y permanecen a lo largo de la línea recta. Esta línea se conoce como la **línea de regresión de población**. Las Y observadas variarán alrededor de estas medias por la influencia de factores no medidos. El modelo supone que esta variación, medida por la desviación estándar, es la misma para todos los valores de X . La desviación (distancia) entre un valor de Y y su media se conoce como **error** y se representa mediante la letra griega épsilon.

Modelo estadístico de regresión lineal

La variable de respuesta o dependiente, Y , está relacionada con la variable controlada o independiente, X , mediante

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Aquí, $\beta_0 + \beta_1 X$ es la respuesta promedio para una X dada. Se supone que las desviaciones (ε) son independientes y están normalmente distribuidas, con una media igual a 0 y una desviación estándar σ . Las constantes desconocidas son β_0 , β_1 y σ .

La línea de regresión ajustada (de la muestra) puede considerarse como una estimación de la línea de regresión de la población, en tanto que los residuos, pueden considerarse como estimaciones de los componentes del error.

$$\text{Población: } Y = \beta_0 + \beta_1 X + \varepsilon$$

$$\text{Muestra: } Y = b_0 + b_1 X + e$$

Error Estándar de la Estimación

Es posible desarrollar una medida de dispersión análoga a la desviación estándar de la muestra. Esta medida, llamada **error estándar de la estimación**, mide la dispersión de los puntos de datos en la dirección Y alrededor de la línea ajustada

$$s_{y \cdot x} = \sqrt{\frac{\sum (Y - \hat{Y})^2}{n - 2}}$$

El *error estándar de la estimación* mide la cantidad por la cual los valores reales de Y difieren de los valores estimados o $\hat{Y}$. Para muestras relativamente grandes, esperaríamos que alrededor del 67% de las diferencias $Y - \hat{Y}$ estuvieran a una distancia inferior de $s_{y \cdot x}$ del 0, y que alrededor del 95% de estas diferencias estuvieran dentro de $2s_{y \cdot x}$ del 0.

Un análisis de regresión con un error estándar pequeño de la estimación significa que todos los puntos de datos se ubican muy cerca de la línea de regresión ajustada. Si el error estándar de la estimación es grande, los puntos de datos están considerablemente dispersos alrededor de la línea ajustada.

La ecuación se puede convertir en:

$$s_{y \cdot x} = \sqrt{\frac{\sum Y^2 - b_0 \sum Y - b_1 \sum XY}{n - 2}}$$

Pronóstico de Y

Si queremos obtener un **pronóstico puntual** o un pronóstico para un valor dado de X , simplemente evaluamos la función de regresión estimada para X .

Existen dos fuentes de incertidumbre asociadas con un pronóstico puntual generado por una ecuación de regresión ajustada:

1. La incertidumbre que se debe a la dispersión de los puntos de datos alrededor de la línea de regresión de la muestra.
2. La incertidumbre que se debe a la dispersión de la línea de la regresión de la muestra alrededor de la línea de regresión de la población.

Es posible construir un **intervalo de predicción** de Y que tome en cuenta estas dos fuentes de incertidumbre.

El **error estándar del pronóstico**, s_f , mide la variabilidad de la Y pronosticada en relación con el valor real de Y para un valor dado de X .

$$s_f = \sqrt{s_{y \cdot x}^2 + s_{y \cdot x}^2 \left(\frac{1}{n} + \frac{(X - \bar{X})^2}{\sum (X - \bar{X})^2} \right)}$$

$$s_f = s_{y \cdot x} \sqrt{1 + \frac{1}{n} + \frac{(X - \bar{X})^2}{\sum (X - \bar{X})^2}}$$


Si el modelo estadístico de regresión lineal simple es el adecuado, un intervalo de predicción de Y está dado por

$$\hat{Y} \pm ts_f$$

donde t es un punto porcentual de la distribución t de Student con $df = n - 2$.

Un intervalo de predicción del 95% para una muestra grande para Y es

$$\hat{Y} \pm 2s_f$$



Resulta útil terminar esta sección revisando los supuestos subyacentes del modelo estadístico de regresión lineal.


1. **Para un valor dado de X, la población de los valores de Y está normalmente distribuida alrededor de la línea de regresión de la población.**
2. **La dispersión de los puntos de datos de la población alrededor de la línea de regresión de la población permanece constante a lo largo de la línea.**
3. **Los términos de error (ϵ) son independientes uno del otro.**
4. **Existe una relación lineal entre X y Y en la población.**

Descomposición de la Varianza

Usando la ecuación

$$Y = \hat{Y} + (Y - \hat{Y})$$

$$Y = b_0 + b_1X + (Y - b_0 - b_1X)$$



Al restar $\bar{Y}$ de ambos lados de la expresión anterior:

$$(Y - \bar{Y}) = (\hat{Y} - \bar{Y}) + (Y - \hat{Y})$$

Con un poco de álgebra:

$$\Sigma(Y - \bar{Y})^2 = \Sigma(\hat{Y} - \bar{Y})^2 + \Sigma(Y - \hat{Y})^2$$

$$SST = SSR + SSE$$

donde

$$SST = \Sigma(Y - \bar{Y})^2$$

$$SSR = \Sigma(\hat{Y} - \bar{Y})^2$$

$$SSE = \Sigma(Y - \hat{Y})^2$$

Aquí, SS significa **suma de cuadrados** y T, R y E significan **total**, **regresión** y **error**, respectivamente

Si no existe una relación lineal, Y no depende de X, y la variación de Y queda descrita por la varianza de la muestra:

$$s_y^2 = \frac{1}{n-1} \Sigma(Y - \bar{Y})^2$$


Si, por otro lado, Y está relacionada con X, algunas de las diferencias en los valores de Y se deben a esta relación

La regresión de la suma de los cuadrados, SSR, mide la parte de la variación de Y que se explica por la relación lineal. La suma de los errores al cuadrado, SSE, es la variación restante de Y, o la variación de Y que no se explica por la relación lineal.

Descomposición de la variabilidad

SST	=	SSR	+	SSE
Variabilidad total de Y		Variabilidad explicada por la relación lineal		Residuo o variabilidad no explicada

Coefficientes de Determinación



A 6-5 Variación explicada y variación no explicada en los datos del señor Bump

$$r^2 = \frac{\text{Variación explicada}}{\text{Variación total}} = \frac{SSR}{SST} = \frac{\sum(\hat{Y} - \bar{Y})^2}{\sum(Y - \bar{Y})^2}$$

$$= 1 - \frac{\text{Variación no explicada}}{\text{Variación total}} = 1 - \frac{SSE}{SST} = 1 - \frac{\sum(Y - \hat{Y})^2}{\sum(Y - \bar{Y})^2}$$

El **coeficiente de determinación** (r^2) mide el porcentaje de variabilidad de Y que se puede explicar a través del conocimiento de la variabilidad (diferencias) de la variable independiente X.

Para la regresión lineal, r^2 es el cuadrado de r, el coeficiente de correlación

Coeficiente de determinación = (Coeficiente de correlación)

El coeficiente de correlación revela la fortaleza y dirección de la relación lineal.

El coeficiente de determinación, r^2 , mide la fuerza de la relación entre Y y X de un modo diferente a como lo hace r. El valor de r^2 mide el porcentaje de variabilidad de Y que se explica por las diferencias de X.


Prueba de Hipótesis

Considere la hipótesis:

$$H_0: \beta_1 = 0$$

donde β_1 es la pendiente de la línea de regresión de la población. Advierta que, si esta hipótesis es verdadera, no existe relación entre Y y X en la población. Por otro lado, si no se rechaza H_0 , significa que a pesar del hecho de que la muestra ha producido una línea ajustada con un valor diferente de cero para b_1 , debemos concluir que no hay suficiente evidencia para indicar que Y esté relacionada con X

¿Cómo es posible que β_1 sea cero mientras b_1 es diferente de cero?



Si $H_0: \beta_1 = 0$ es verdadera, el *estadístico de prueba t* con valor de $t = \frac{b_1}{s_{b_1}}$ tiene una distribución *t* con $df = n - 2$, donde S_{b_1} es la desviación estándar estimada (o error estándar) de b_1 , dado por $s_{b_1} = s_{y,x} / \sqrt{\sum (X - \bar{X})^2}$.

Para tamaños muestrales muy grandes, es posible rechazar H_0 y concluir que existe una relación lineal entre X y Y aun cuando r^2 sea pequeña, digamos, del 10%. De forma similar, para muestras pequeñas y una r^2 muy grande —digamos, del 95%— es posible concluir que la regresión es significativa

Una prueba alternativa de H_0 está disponible en la tabla ANOVA.

TABLA 6-4 Tabla ANOVA para la regresión de línea recta			
Fuente	Suma de cuadrados	df	Cuadrado medio
Regresión	SSR	1	$MSR = SSR/1$
Error	SSE	$n-2$	$MSE = SSE/(n-2)$
Total	SST	$n-1$	

Si los supuestos del modelo estadístico de la regresión lineal son adecuados y si la hipótesis es verdadera, la razón

$$F = \frac{\text{Cuadrado medio de la regresión}}{\text{Error cuadrático medio}} = \frac{MSR}{MSE}$$

Tiene distribución F con $df = 1, n-2$.

El estadístico F también puede expresarse en términos del coeficiente de determinación, r^2 .

$$F = \frac{r^2(n - 2)}{1 - r^2}$$

Cuanta mayor sea la cantidad de variación de Y que tenga explicación mediante la función de regresión ajustada, más probabilidad hay de que la prueba F considere a la regresión como significativa.

Análisis de Residuos

Los supuestos del modelo de regresión de línea recta son los siguientes:

1. La relación entre las variables es lineal.
2. Los errores son independientes.
3. Los errores tienen una varianza constante.
4. Los errores están distribuidos normalmente

Para calificar los méritos de un modelo tentativo, podemos examinar los residuos graficándolos de varias maneras.

1. Grafique un histograma de los residuos: permite verificar el supuesto de normalidad. Por lo regular, una violación del supuesto de normalidad no es tan seria como una violación de cualquier otro de los supuestos.
2. Grafique los residuos contra los valores ajustados : si una gráfica de los residuos contra los valores ajustados indica que la naturaleza general de la relación entre Y y X forma una curva en vez de una línea recta, una transformación conveniente de los datos puede reducir una relación no lineal a una que sea aproximadamente lineal.
3. Grafique los residuos contra la variable explicativa
4. Grafique los residuos en el tiempo si los datos son cronológicos.

El supuesto de independencia es el más importante. Para los residuos de las series de tiempo, la independencia puede verificarse con una gráfica de los residuos en el tiempo. No debe haber patrones sistemáticos, tales como una sucesión de valores altos seguidos de una sucesión de valores bajos. Además, las autocorrelaciones muestrales de los residuos

$$r_k(e) = \frac{\sum_{t=k+1}^n e_t e_{t-k}}{\sum_{t=1}^n e_t^2} \quad k = 1, 2, \dots, K$$

donde n es el número de residuos y K comúnmente es n/4, deberían ser todas pequeñas.

Transformaciones de Variables

Cuando un diagrama de dispersión indica que existe una relación no lineal entre Y y X, existen dos métodos básicos para tratar este caso. El primero consiste en ajustar los datos a una función de regresión que se grafique como una curva y utilizar la función ajustada para elaborar el pronóstico. El segundo método implica la transformación de la variable X a otra forma, de manera que la relación resultante con Y sea lineal.

Cuatro de las transformaciones más comunes (funciones) que se emplean para generar nuevas variables de predicción son el recíproco, el logaritmo, la raíz cuadrada y el cuadrado.

$$\frac{1}{X}, \quad \log X, \quad \sqrt{X}, \quad X^2$$

Cuando cada una de estas variables se grafica contra Y, se espera que la relación no lineal entre Y y X se convierta en una relación lineal entre Y y una de las X transformadas. Si es así, Y y esta nueva variable pueden tratarse con el modelo lineal explicado en este capítulo, incluyendo el cálculo del coeficiente de correlación y la ecuación de regresión ajustada.

Curvas de Crecimiento

Las curvas de crecimiento se presentaron para modelar la tendencia en la descomposición de una serie de tiempo.

Las curvas de crecimiento son relaciones curvilíneas entre la variable de interés y el tiempo. Las curvas de crecimiento se ajustan comúnmente a los datos anuales, puesto que en estos casos se requieren pronósticos a largo plazo.

Si una variable medida en el tiempo se incrementa en el mismo porcentaje cada periodo, se dice que presenta un **crecimiento exponencial**. Si una variable se incrementa en la misma cantidad cada periodo, se dice que registra un **crecimiento lineal**. Algunas veces una transformación simple convierte una variable con

crecimiento exponencial en una variable con crecimiento lineal. Si éste es el caso, los métodos de regresión presentados en este capítulo servirán para modelar el crecimiento exponencial.

Aplicación a la Administración

El análisis de regresión es la herramienta estadística que se utiliza más ampliamente en la dirección de una empresa cuando existe la necesidad de evaluar el efecto de una sola variable independiente sobre una variable dependiente.

La mayoría de los problemas que requieren el análisis de regresión implican la versión más compleja, llamada **análisis de regresión múltiple** (que estudiaremos en el siguiente capítulo), porque la mayoría de las relaciones ameritan el estudio de la relación entre una variable dependiente y más de una variable independiente. Sin embargo, la regresión simple y el análisis de correlación simple se utilizan con frecuencia.

Una vez que se determina la relación entre las variables independiente y dependiente, la administración puede, en algunos casos, tratar de controlar la variable dependiente con base en este conocimiento.

Capítulo 7 - Análisis de Regresión Múltiple

Con frecuencia se necesita más de una variable independiente para pronosticar con exactitud una variable dependiente. Los modelos de regresión con más de una variable independiente se llaman **modelos de regresión múltiple**. La mayoría de los conceptos presentados en la regresión lineal simple se utilizan en la regresión múltiple.

Diversas Variables Explicativas

Es necesario investigar para conocer otra variable independiente. Esta nueva variable independiente, o predictiva, no debe estar muy estrechamente relacionada con la variable independiente que ya se está usando. Si las dos variables independientes están profundamente relacionadas una con otra, explicarán la misma variación, y el hecho de agregar una segunda variable no mejorará el pronóstico.

Este problema de intercorrelación entre variables independientes es conocido como **multicolinealidad**.

Matriz de Correlación

La **matriz de correlación** se elabora calculando los coeficientes de correlación simple de cada combinación de pares de variables.

<i>Variables</i>	<i>Variables</i>		
	<i>1</i>	<i>2</i>	<i>3</i>
1	r_{11}	r_{12}	r_{13}
2	r_{21}	r_{22}	r_{23}
3	r_{31}	r_{32}	r_{33}

El análisis de la matriz de correlación es un paso inicial importante en la resolución de cualquier problema que implique múltiples variables independientes.

Modelo de Regresión Múltiple

En el análisis de regresión múltiple, las variables independientes se denotan mediante X con subíndices.

La respuesta promedio se toma como una función lineal de las variables explicativas:

$$\mu_Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k$$

Esta expresión es la **función de regresión múltiple de la población**.

Modelo estadístico para la regresión múltiple

La respuesta, Y, es una variable aleatoria que está relacionada con las variables independientes (predictivas) por

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k + \varepsilon$$

donde

1.

Para la i -ésima observación, $Y = Y_i$ y $X_1, X_2, \dots, X_k$ se definen para los valores $X_{i1}, X_{i2}, \dots, X_{ik}$.

TABLA 7-3 Estructura de datos de la regresión múltiple					
<i>Caso</i>	<i>Variables explicativas</i>				<i>Respuesta</i>
	X_1	X_2		X_k	Y
1	X_{11}	X_{12}		X_{1k}	Y_1
2	X_{21}	X_{22}		X_{2k}	Y_2
.	.	.		.	.
.	.	.		.	.
i	X_{i1}	X_{i2}		X_{ik}	Y_i
.	.	.		.	.
.	.	.		.	.
n	X_{n1}	X_{n2}		X_{nk}	Y_n

2. Las ε 's son componentes de error que representan las desviaciones de la respuesta de la relación verdadera. Son variables aleatorias no observables que explican los efectos de otros factores sobre la respuesta. Se supone que los errores son independientes y todos están distribuidos de manera normal con una media 0 y desviación estándar desconocida σ .
3. Los coeficientes de regresión, $\beta_0, \beta_1, \dots, \beta_k$, que en conjunto definen la función de regresión son desconocidos.

Teniendo los datos, es posible estimar los coeficientes de regresión usando el principio de mínimos cuadrados. Las estimaciones de los mínimos cuadrados se representan por $b_0, b_1, \dots, b_k$ y la función de regresión estimada por

$$\hat{Y} = b_0 + b_1X_1 + \dots + b_kX_k$$

Los residuos, $e = Y - \hat{Y}$, son estimaciones del componente de error y similares al escenario de la regresión lineal simple

$$\text{Población: } Y = \beta_0 + \beta_1X_1 + \beta_2X_2 + \dots + \beta_kX_k + \varepsilon$$

$$\text{Muestra: } Y = b_0 + b_1X_1 + b_2X_2 + \dots + b_kX_k + e$$

Los valores de los mínimos cuadrados ($b_0, b_1, b_2, \dots$) minimizan la suma de errores al cuadrado:

$$SSE = \sum_i (Y_i - b_0 - b_1X_{i1} - b_2X_{i2})^2 = \sum_i (Y_i - \hat{Y}_i)^2$$

(llega hasta X_{i2} ya que en el ejemplo había dos variables independientes que explicaban la dependiente, en el caso general llegaría hasta X_{ik}).

Interpretación de los Coeficientes de Regresión

Otra vez el valor de b_0 es la intersección con Y. Los coeficientes b_1 y b_2 se conocen como los coeficientes de la **regresión parcial o neta**.

El **coeficiente de regresión parcial o neto** mide el cambio promedio de la variable dependiente por unidad de cambio en la variable independiente relevante, cuando se mantienen constantes las demás variables independientes.

Inferencias en Modelos de Regresión Múltiple

La inferencia en los modelos de regresión múltiple es análoga a la de la regresión lineal simple. La estimación de mínimos cuadrados de los parámetros del modelo, la estimación de los errores estándar, las estadísticas t que se usan para examinar la significancia de los términos individuales del modelo de regresión, y el estadístico F

que permite verificar la significancia de la regresión se obtienen empleando paquetes estándar de software estadístico.

Cualquier observación Y puede escribirse como

$$\text{Observación} = \text{Ajuste} + \text{Residuo}$$

$$Y = \hat{Y} + (Y - \hat{Y})$$

La descomposición de la suma de cuadrados y los grados de libertad asociada son

$$\Sigma(Y - \bar{Y})^2 = \Sigma(\hat{Y} - \bar{Y})^2 + \Sigma(Y - \hat{Y})^2$$

$$SST = SSR + SSE$$

$$df: n - 1 = k + n - k - 1$$

Error estándar de la estimación

El error estándar de la estimación es la desviación estándar de los residuos. Mide la dispersión típica de los valores de Y alrededor de la función de regresión ajustada.

$$s_{y \cdot x's} = \sqrt{\frac{\Sigma(Y - \hat{Y})^2}{n - k - 1}} = \sqrt{\frac{SSE}{n - k - 1}} = \sqrt{MSE}$$

Donde

n = el número de observaciones

k = el número de variables independientes en la función de regresión

$SSE = \Sigma(Y - \hat{Y})^2$ = suma de los cuadrados de los residuos

$MSE = SSE/(n - k - 1)$ = el cuadrado medio de los residuos

El *error estándar de la estimación* es la desviación estándar de los residuos. Mide la cantidad en que los valores reales de (Y) difieren de los valores estimados ($\hat{Y}$). Para muestras relativamente grandes, esperaríamos que alrededor del 67% de las diferencias $Y - \hat{Y}$ estén dentro de $s_{y \cdot x's}$ de cero, y alrededor del 95% de estas diferencias estén dentro de $2 s_{y \cdot x's}$ de cero.

Significancia de la regresión

TABLA 7-6 Tabla ANOVA de regresión múltiple				
Fuente	Suma de cuadrados	df	Cuadrado medio	Razón F
Regresión	SSR	k	$MSR = SSR/k$	$F = \frac{MSR}{MSE}$
Error	SSE	$n - k - 1$	$MSE = SSE/(n - k - 1)$	
Total	SST	$n - 1$		

Considere la hipótesis $H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0$. Esta hipótesis significa que Y no está relacionada con ninguna de las X (el coeficiente de cada X es cero). La prueba de se conoce como prueba de **significancia de la regresión**. Si los supuestos del modelo de regresión son apropiados y es verdadera, la razón

$$F = \frac{MSR}{MSE}$$

tiene una distribución F con . De este modo, la razón F se puede usar como prueba de la significancia de la regresión. $df = k, n - k - 1$

Prueba F de la significancia de la regresión

En el modelo de regresión múltiple, las hipótesis

$$H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0$$

$$H_1: \text{por lo menos una } \beta_j \neq 0$$

se prueban mediante la razón F:

$$F = \frac{MSR}{MSE}$$

con $df = k, n - k - 1$. Con un nivel de significancia α , la región de rechazo es

$$F > F_\alpha$$

donde F_α es el punto que deja un área de α a la derecha de una distribución F con $\delta_1 = k, \delta_2 = n - k - 1$ grados de libertad del numerador y del denominador respectivamente.

El **coeficiente de determinación**, R^2 , está dado por

$$\begin{aligned}
 R^2 &= \frac{SSR}{SST} = \frac{\sum(\hat{Y} - \bar{Y})^2}{\sum(Y - \bar{Y})^2} \\
 &= 1 - \frac{SSE}{SST} = 1 - \frac{\sum(Y - \hat{Y})^2}{\sum(Y - \bar{Y})^2}
 \end{aligned}$$

y tiene la misma forma e interpretación que la r^2 de la regresión lineal simple. Representa la proporción de variación en la respuesta, Y, explicada por la relación de Y con las X.

La cantidad

$$R = \sqrt{R^2}$$

se llama **coeficiente de correlación múltiple** y es la correlación entre las respuestas, Y, y los valores ajustados, $\hat{Y}$.

Para la regresión múltiple,

$$F = \frac{R^2}{1 - R^2} \left(\frac{n - k - 1}{k} \right)$$

El coeficiente de determinación (R^2) siempre se incrementa al agregar una variable independiente, X, a la función de regresión, incluso si esta variable adicional no es importante. Por esta razón, algunos analistas prefieren interpretar R^2 ajustada al número de términos en la función de regresión. El coeficiente ajustado de determinación está dado por

$$\bar{R}^2 = 1 - (1 - R^2) \left(\frac{n - 1}{n - k - 1} \right)$$

Variables explicativas individuales

El coeficiente de una X individual en la función de regresión mide el efecto parcial o neto de esa X sobre la respuesta, Y, manteniendo constantes las demás X de la ecuación. Si la regresión se considera como significativa, entonces es de interés examinar la significancia de las variables explicativas individuales.

Para evaluar la significancia del término j-ésimo, $j = 0, 1, \dots, k$, en la función de regresión, el estadístico de prueba t se compara con un punto porcentual de una distribución t con grados de libertad. Para una prueba en el nivel de significancia α de

$$H_0: \beta_j = 0$$

$$H_1: \beta_j \neq 0$$

si $|t| > t_{\alpha/2}$ se rechaza H_0 . Aquí, $t_{\alpha/2}$ es el punto que deja un área $\alpha/2$ a la derecha de una distribución t con $df = n - k - 1$.

Se debe tener cuidado en la eliminación de la función de regresión de aquellas variables explicativas que se consideran insignificantes por la prueba t.

El proceso se detiene cuando la regresión es significativa y todas las variables explicativas tienen estadísticos t grandes (significativos).

Pronóstico de una respuesta futura

Un pronóstico, $\hat{Y}^*$, de una respuesta futura, Y, para valores nuevos de las X está dado por la evaluación de la función de regresión ajustada para las X:

$$\hat{Y}^* = b_0 + b_1X_1^* + b_2X_2^* + \cdots + b_kX_k^*$$

Con un nivel de confianza α , un intervalo de predicción para Y toma la forma

$$\hat{Y}^* \pm t_{\alpha/2} \times (\text{Error estándar del pronóstico})$$


Si n es grande y todas las X son muy variables, un intervalo de predicción aproximado de $100(1 - \alpha)\%$ para una nueva respuesta Y es

$$(\hat{Y}^* - t_{\alpha/2}s_{y \cdot x's}, \hat{Y}^* + t_{\alpha/2}s_{y \cdot x's})$$

Variables Ficticias

Algunas veces es necesario determinar cómo se relaciona una variable dependiente con una variable independiente cuando un factor **cualitativo** influye en la situación. Esta relación se establece creando una **variable ficticia**. Existen muchas maneras de identificar cuantitativamente las clases de una variable cualitativa. En este texto se usan los valores 0 y 1.

Ejemplo



$$\hat{Y} = b_0 + b_1X_1 + b_2X_2$$

donde

X_1 = calificación de la prueba

$$X_2 = \begin{cases} 0 & \text{para mujeres} \\ 1 & \text{para hombres} \end{cases} \quad \text{variable ficticia}$$

La ecuación individual es equivalente a las siguientes dos ecuaciones:

$$\hat{Y} = b_0 + b_1X_1 \quad \text{para mujeres}$$

$$\hat{Y} = b_0 + b_1X_1 + b_2 = (b_0 + b_2) + b_1X_1 \quad \text{para hombres}$$

Observe que b_2 representa el efecto de un varón sobre el rendimiento en el trabajo, y b_1 representa el efecto de las diferencias en las calificaciones de las pruebas de aptitud (se supone que el valor de b_1 es el mismo tanto para hombres como para mujeres).

Multicolinealidad

En muchos problemas de regresión, los datos se registran rutinariamente en vez de ser generados por posiciones previamente elegidas de las variables independientes. En estos casos, las variables independientes son a menudo linealmente dependientes o **multicolineales**.

La **multicolinealidad** es la situación en la cual las variables independientes de una ecuación de regresión múltiple están sumamente intercorrelacionadas. Es decir, existe una relación lineal entre dos o más variables independientes.

La fortaleza de la multicolinealidad se mide por el factor de inflación de la varianza

$$VIF_j = \frac{1}{1 - R_j^2} \quad j = 1, 2, \dots, k$$

Un VIF próximo a 1 sugiere que la multicolinealidad no es un problema para esa variable independiente. Un VIF mucho más grande que 1 indica que el coeficiente estimado de esa variable independiente es inestable. Un VIF grande significa, en esencia, que existe información redundante entre las variables explicativas.

Existen varias maneras para manejar la multicolinealidad severa. Ninguna de ellas es completamente satisfactoria o factible

- Cree nuevas variables X (llamándolas $\tilde{X}$) luego escale todas las variables independientes de acuerdo con la fórmula

$$\tilde{X} = \frac{X_{ij} - \bar{X}_j}{\sqrt{a_i (X_{ij} - \bar{X}_j)^2}} \quad j = 1, 2, \dots, k; \quad i = 1, 2, \dots, n$$

- Identifique y elimine una o más de las variables independientes redundantes de la función de regresión.
- Considere otros procedimientos de estimación que no sean los mínimos cuadrados.
- Realice una regresión de la respuesta, Y, sobre las nuevas X que no están correlacionadas unas con otras.
- Seleccione cuidadosamente las variables independientes potenciales al principio del estudio. Trate de eliminar las variables que “dicen lo mismo

Selección de la “Mejor” Ecuación de Regresión

¿Cómo se desarrolla la mejor ecuación de regresión múltiple para pronosticar una variable de interés?

El **primer paso** implica la selección de un conjunto completo de variables explicativas potenciales. Se debe incluir cualquier variable que pudiera agregar exactitud al pronóstico. Cuando elegimos las variables explicativas para incluirlas en la ecuación final, debemos evaluarlas usando los siguientes dos criterios antagónicos:

1. El analista desea que la ecuación incluya tantas variables explicativas como sea posible
2. Puesto que obtener y monitorear la información de un gran número de X es una labor costosa, la ecuación debe incluir menos variables explicativas como sea posible

La selección de la mejor ecuación de regresión, por lo regular, implica un compromiso entre estos extremos, y el criterio personal será una parte obligatoria de cualquier solución.

El **segundo paso** es eliminar las variables independientes que no parezcan adecuadas. Una variable independiente:

1. quizá no sea fundamental para el problema
2. podría estar sujeta a errores de medición grandes
3. puede ser un duplicado de otra variable independiente (multicolinealidad)
4. tal vez sea difícil medirla con exactitud

El **tercer paso** es recortar la lista de variables explicativas de manera que se obtenga la “mejor” selección de variables independientes. El proceso completo de selección de la variable es muy subjetivo.

Se presentan dos procedimientos: todas las regresiones posibles y la regresión por pasos.

Todas las regresiones posibles

El procedimiento requiere la investigación de todas las ecuaciones de regresión posibles que implican las variables independientes potenciales. El analista inicia con una ecuación que no contiene variables independientes y luego procede al análisis de todas las combinaciones posibles para seleccionar el mejor conjunto de variables explicativas

Con el enfoque de todas las regresiones posibles se pueden usar diferentes criterios para comparar varias ecuaciones de regresión. Aquí se analizará sólo la técnica de la la cual contempla cuatro pasos.

Este procedimiento requiere primero el ajuste de cada modelo de regresión posible que incluye la variable dependiente y cualquier número de variables independientes. Por lo tanto, existen en total 2^k ecuaciones (donde k es el número de variables independientes).

El segundo paso del procedimiento es dividir las ecuaciones en conjuntos de acuerdo con el número de parámetros que se estimarán.

El tercer paso consiste en la selección de la mejor variable (o variables) independiente(s) para cada agrupamiento de parámetros. La ecuación R^2 con la más alta se considera la mejor.

El cuarto paso supone tomar la decisión subjetiva: “¿Cuál ecuación es la mejor?”. Por un lado, el analista desea la más grande posible; por otro, quiere la ecuación más sencilla posible. El enfoque de todas las regresiones posibles supone que el número de puntos de datos, n , excede el número de parámetros, $k + 1$.

En general, el análisis de todas las regresiones no está justificado. Aunque significa que el investigador ha “considerado todas las posibilidades”, también significa que ha examinado un gran número de ecuaciones de regresión que una persona inteligente a menudo rechazaría de inmediato.

Regresión por pasos

El procedimiento de regresión por pasos agrega al modelo una variable independiente a la vez.

La regresión por pasos puede describirse mejor listando los pasos básicos:

1. Se consideran todas las regresiones simples posibles. La variable explicativa que explica la proporción significativa más grande de la variación de Y (es decir, tiene la correlación más grande con la respuesta) es la primera variable que se introduce en la ecuación de regresión.
2. La siguiente variable en introducirse a la ecuación es la que hace la mayor contribución significativa a la suma de cuadrados de la regresión. La significancia de la contribución se determina mediante una prueba F. El valor del estadístico F que debe sobrepasarse antes de que la contribución de una variable se considere significativa a menudo se conoce como **F de entrada (F to enter)**.
3. Una vez que una variable adicional se ha incluido en la ecuación, se hace una prueba de significancia de las contribuciones individuales a la suma de cuadrados de regresión de las otras variables que ya están en la ecuación usando pruebas F. Si el estadístico F es menor que un valor llamado **F de salida (F to remove)**, la variable se elimina de la ecuación de regresión.
4. Los pasos 2 y 3 se repiten hasta que todas las adiciones posibles sean no significativas y todas las eliminaciones posibles sean significativas. En este punto, la selección se detiene.

La **regresión por pasos** permite a las variables explicativas entrar o salir de la función de regresión en diferentes etapas de su desarrollo. Una variable independiente se elimina del modelo si no tiene una contribución significativa cuando se agrega una nueva variable

Diagnósticos de Regresión y Análisis Residual

Un **análisis de regresión** no está completo sino hasta que uno está convencido de que el modelo es una representación adecuada de los datos.

Un examen de los residuos es un componente crucial de la determinación de la idoneidad del modelo.

En esta sección se analizarán algunas herramientas adicionales que permiten evaluar un modelo de regresión. Estas herramientas están diseñadas para identificar observaciones que son atípicas o extremas. Es fundamental estudiar las observaciones atípicas para decidir si deben conservarse o eliminarse y, en el primer caso, habrá que decidir si su influencia debe reducirse en el proceso de ajuste o si debe revisarse la función de regresión.

El apalancamiento h_{ii} ofrece una medida de la influencia del i -ésimo punto de datos sobre la ubicación de la función de regresión ajustada. El apalancamiento sólo depende de las variables explicativas; no depende de la respuesta Y. Para la regresión lineal simple con una variable explicativa X,

$$h_{ii} = \frac{1}{n} + \frac{(X_i - \bar{X})^2}{\sum (X_i - \bar{X})^2}$$

Si el i-ésimo punto de datos tiene un apalancamiento alto es un valor atípico entre las X.

La detección de valores atípicos o extremos de Y está basada en el tamaño de los residuos, e.

Una estandarización se basa en el hecho de que los residuos tienen desviaciones estándar estimadas

$$s_{e_i} = s_{y \cdot x's} \sqrt{1 - h_{ii}}$$

donde $s_{y \cdot x's} = \sqrt{MSE}$ es el error estándar de la estimación y h_{ii} es el apalancamiento asociado con el i-ésimo punto de datos. El residuo estandarizado es entonces

$$\frac{e_i}{s_{e_i}} = \frac{e_i}{s_{y \cdot x's} \sqrt{1 - h_{ii}}}$$

Todos los residuos estandarizados tienen una varianza de 1. Un residuo estandarizado se considera grande (la respuesta extrema) si

$$\left| \frac{e_i}{s_{e_i}} \right| > 2$$

Los valores Y correspondientes a los puntos de datos con residuos estandarizados grandes pueden influir fuertemente en la ubicación de la función de regresión ajustada.

El apalancamiento nos indica si una observación tiene variables explicativas inusuales, y un residuo estandarizado nos dice si una observación tiene una respuesta inusual. Estas cantidades pueden combinarse en una medida integral de influencia conocida como **distancia de Cook**.

Advertencias del Pronóstico

Sobreajuste de la prueba

El **sobreajuste** se refiere al hecho de agregar variables independientes a la función de regresión que, en gran medida, dan cuenta de todas las excentricidades de los datos muestrales bajo análisis.

Es más probable que ocurra el sobreajuste cuando el tamaño de la muestra es pequeño, especialmente si se incluye un gran número de variables independientes en el modelo. Algunos especialistas sugieren que deben existir por lo menos 10 observaciones por cada variable independiente.

Regresiones útiles, valores grandes calculados de F

Una regresión que es estadísticamente significativa no necesariamente es útil. Con un tamaño muestral relativamente grande, no es extraño obtener una razón F significativa y una R^2 pequeña. Es decir, la regresión es significativa, pero sólo explica una pequeña porción de la variación en la respuesta.