Sistemas de Soporte a la Toma de Decisiones

Resumen teórico — Temas 5 a 9

Este desarrollo continúa el apunte anterior y reúne los conceptos relacionados para facilitar el estudio del parcial. Se priorizan las definiciones, diferencias, funcionamiento y aplicaciones más importantes, evitando repetir los fundamentos ya explicados en los temas 1 a 4.

5. Procesamiento Analítico en Línea (OLAP)

5.1. Fundamentos de OLAP

5.1.1. Definición y características

El Procesamiento Analítico en Línea (OLAP) es una tecnología que permite analizar grandes volúmenes de datos de forma interactiva, utilizando una perspectiva multidimensional. Su objetivo es facilitar la exploración de información y la identificación de tendencias para apoyar la toma de decisiones.

OLAP se caracteriza por permitir consultas complejas, agrupaciones, cálculos y navegación entre distintos niveles de detalle. A diferencia de los sistemas OLTP, está orientado principalmente a la lectura y al análisis de datos históricos o consolidados.

5.1.2. Análisis multidimensional interactivo

El análisis multidimensional consiste en estudiar una medida desde diferentes perspectivas denominadas dimensiones. Por ejemplo, las ventas pueden analizarse simultáneamente por producto, región y período.

Su carácter interactivo permite modificar las dimensiones, aplicar filtros o cambiar el nivel de detalle durante el análisis, sin necesidad de diseñar una consulta completamente nueva para cada pregunta.

5.1.3. Consultas analíticas y agregaciones

Las consultas OLAP permiten realizar cálculos sobre conjuntos de registros para obtener información resumida. Las operaciones más habituales incluyen sumas, promedios, conteos, valores máximos y mínimos.

Estas operaciones se denominan agregaciones y permiten obtener resultados a distintos niveles. Por ejemplo, las ventas individuales pueden agruparse por mes, trimestre o año. Muchos sistemas OLAP precalculan determinadas agregaciones para responder rápidamente a las consultas.

5.1.4. Herramientas de consulta, reporting y visualización

Las herramientas OLAP permiten consultar información y presentar los resultados mediante tablas, gráficos y reportes. Su principal ventaja es ofrecer interfaces que facilitan el análisis sin exigir que el usuario conozca la estructura física de los datos.

También permiten elaborar indicadores, comparar períodos, representar tendencias y modificar dinámicamente las perspectivas de análisis.

5.2. Cubos OLAP

5.2.1. Definición y estructura

Un cubo OLAP es una representación lógica multidimensional de los datos que permite analizar medidas según distintas dimensiones y sus jerarquías.

Por ejemplo, un cubo de ventas puede contener las dimensiones Tiempo, Producto y Región, y almacenar medidas como importe vendido o unidades vendidas.

El cubo no necesariamente tiene tres dimensiones: puede tener tantas como requiera el análisis empresarial.

5.2.2. Representación multidimensional de los datos

Cada dimensión constituye un eje lógico de análisis. La combinación de valores de las dimensiones permite identificar una medida específica.

Por ejemplo, la intersección de Marzo, Computadoras y Rosario puede representar el importe total de computadoras vendidas en Rosario durante marzo.

La representación mediante cubos es conceptual: físicamente, los datos pueden almacenarse en tablas relacionales, estructuras multidimensionales u otros formatos optimizados.

5.2.3. Celdas y subcubos

Una celda representa una combinación particular de valores de las dimensiones y contiene la medida correspondiente. Por ejemplo, `(Marzo, Rosario, Computadoras)`.

Un subcubo es una porción del cubo original obtenida mediante restricciones sobre una o varias dimensiones. Permite concentrar el análisis en determinados productos, períodos o regiones.

5.2.4. Cuboides (Cuboids)

Un cuboide representa los datos agrupados según una combinación específica de dimensiones. Cada cuboide equivale conceptualmente a un resultado de agrupación o `GROUP BY`.

Por ejemplo, para un cubo con las dimensiones Tiempo, Producto y Región pueden existir cuboides que agrupen las ventas por Tiempo y Producto, únicamente por Región, o por las tres dimensiones simultáneamente.

5.2.5. Cuboide base y cuboide ápice

El cuboide base (Base Cuboid) contiene la información al nivel de detalle más fino considerado en el cubo, utilizando todas sus dimensiones.

El cuboide ápice (Apex Cuboid) representa el mayor nivel de agregación, donde todas las dimensiones se resumen en un único resultado general.

Por ejemplo, el cuboide base puede contener las ventas por producto, ciudad y mes, mientras que el ápice contiene las ventas totales de toda la empresa.

5.2.6. Retícula de cuboides (Lattice of Cuboids)

La retícula de cuboides representa todas las combinaciones posibles de agrupaciones de un cubo multidimensional y las relaciones existentes entre ellas.

Para tres dimensiones independientes A, B y C, sin considerar jerarquías internas, existen $2^3 = 8$ combinaciones posibles de agrupación.

Retícula de ocho cuboides: desde la agregación total (ALL) hasta el cuboide base (ABC).

Esta estructura permite identificar qué agregaciones pueden obtenerse a partir de otras y resulta fundamental para optimizar la computación de los cubos.

5.3. Operaciones OLAP

Las operaciones OLAP permiten navegar y modificar la representación de los datos multidimensionales para responder distintas preguntas analíticas.

5.3.1. Drill Down — Aumentar el detalle

Permite descender por una jerarquía, pasando de información resumida a información más detallada. Por ejemplo, analizar ventas anuales y después desglosarlas por trimestre o mes. También puede incorporar dimensiones adicionales.

5.3.2. Roll Up — Resumir la información

Es la operación inversa al Drill Down. Permite ascender por una jerarquía para obtener valores más agregados, como pasar de ventas por ciudad a ventas por provincia o país. También puede eliminar dimensiones para obtener totales generales.

5.3.3. Slice — Seleccionar una sección

Consiste en seleccionar un valor particular de una dimensión para obtener una porción del cubo. Por ejemplo, consultar únicamente las ventas correspondientes a marzo, conservando todas las regiones y productos.

5.3.4. Dice — Aplicar múltiples filtros

Permite seleccionar un subconjunto del cubo mediante condiciones sobre varias dimensiones. Por ejemplo, analizar las ventas de computadoras y celulares, durante marzo y abril, en Rosario y Córdoba.

5.3.5. Pivot o Rotate — Cambiar la perspectiva

Consiste en rotar o intercambiar los ejes de visualización del cubo. No modifica las medidas almacenadas, sino la forma de presentar los datos, permitiendo observarlos desde otra perspectiva.

5.3.6. Drill Across

La operación Drill Across permite realizar consultas que involucran más de una tabla de hechos, generalmente utilizando dimensiones compartidas.

Por ejemplo, puede utilizarse para comparar ventas y envíos de determinados productos durante un mismo período. Esto permite analizar conjuntamente distintos procesos de negocio.

5.3.7. Drill Through

La operación Drill Through permite acceder desde los valores resumidos de un cubo hasta los registros detallados almacenados en las tablas relacionales subyacentes.

Por ejemplo, después de consultar las ventas totales de marzo, el usuario podría acceder a las transacciones específicas que originaron ese resultado, siempre que ese detalle se encuentre disponible.

5.4. Arquitecturas de servidores OLAP

5.4.1. ROLAP (Relational OLAP)

ROLAP implementa el análisis multidimensional sobre bases de datos relacionales. Las dimensiones y medidas se almacenan en tablas, y las consultas OLAP se traducen a operaciones SQL.

Su principal ventaja es que aprovecha la infraestructura de bases de datos relacionales y puede manejar grandes volúmenes de información. Sin embargo, las consultas complejas pueden requerir numerosas uniones y agregaciones.

5.4.2. MOLAP (Multidimensional OLAP)

MOLAP utiliza estructuras de almacenamiento multidimensional diseñadas específicamente para el análisis. Las agregaciones suelen estar precalculadas, lo que permite obtener tiempos de respuesta rápidos.

Su ventaja principal es el rendimiento de las consultas. Como contrapartida, la construcción y actualización de estas estructuras puede requerir procesamiento y almacenamiento adicionales.

5.4.3. HOLAP (Hybrid OLAP)

HOLAP combina las características de ROLAP y MOLAP. Generalmente conserva los datos detallados en estructuras relacionales y utiliza estructuras multidimensionales para almacenar agregaciones.

Busca aprovechar la capacidad de almacenamiento de ROLAP y la velocidad de consulta de MOLAP.

5.4.4. Servidores SQL especializados

Son sistemas que utilizan motores relacionales optimizados para operaciones analíticas. Incorporan mecanismos específicos para procesar consultas complejas, grandes agrupaciones y accesos masivos a datos, sin depender necesariamente de un servidor multidimensional separado.

5.4.5. Comparación entre arquitecturas

Arquitectura	Almacenamiento	Principal ventaja	Principal limitación
ROLAP	Relacional	Escalabilidad y flexibilidad	Consultas complejas potencialmente costosas
MOLAP	Multidimensional	Rapidez de análisis	Costo de procesamiento y almacenamiento
HOLAP	Híbrido	Equilibrio entre ambos	Mayor complejidad de implementación
SQL especializado	Relacional optimizado	Aprovecha optimizaciones analíticas	Rendimiento dependiente del motor y diseño

5.5. Optimización de consultas OLAP

5.5.1. Índices Bitmap

Los índices Bitmap representan los valores de un atributo mediante vectores de bits. Permiten identificar rápidamente qué registros cumplen determinadas condiciones utilizando operaciones binarias.

Son especialmente útiles para atributos con pocos valores diferentes, como género, estado o categoría, y pueden acelerar filtrados y agregaciones.

5.5.2. Índices Bit-Sliced

Los índices Bit-Sliced extienden el uso de vectores de bits a atributos numéricos, representando sus valores mediante diferentes posiciones binarias.

Esta técnica facilita operaciones como sumas y otras agregaciones sobre conjuntos seleccionados de registros, aprovechando operaciones eficientes a nivel de bits.

5.5.3. Índices Join

Los índices Join almacenan asociaciones que permiten localizar rápidamente registros relacionados de distintas tablas, evitando repetir determinadas operaciones de unión.

En un modelo dimensional pueden utilizarse para identificar qué registros de una tabla de hechos corresponden a los valores seleccionados de una dimensión.

5.5.4. Almacenamiento orientado a columnas (Column-Based Databases)

Las bases de datos orientadas a columnas almacenan consecutivamente los valores de un mismo atributo, en lugar de almacenar todos los campos de cada registro juntos.

Este enfoque resulta especialmente eficiente para consultas OLAP, porque muchas operaciones analíticas necesitan leer pocas columnas de una gran cantidad de registros.

También puede facilitar la compresión, ya que los valores de una misma columna suelen compartir características y tipos de datos.

5.5.5. Comparación entre almacenamiento por filas y columnas

El almacenamiento por filas resulta adecuado para operaciones transaccionales que necesitan acceder o modificar registros completos.

El almacenamiento por columnas suele ser más eficiente cuando se deben recorrer millones de registros para calcular agregaciones sobre un número reducido de atributos.

Por esta razón, el almacenamiento por filas se asocia tradicionalmente con OLTP, mientras que el almacenamiento por columnas se utiliza ampliamente en sistemas analíticos.

6. Computación y Materialización de Cubos de Datos

6.1. Fundamentos de computación de cubos

6.1.1. Celdas base y celdas agregadas

La computación de cubos consiste en calcular las medidas correspondientes a diferentes combinaciones de dimensiones y niveles de agregación.

Las celdas base contienen valores correspondientes al mayor nivel de detalle del cubo. Las celdas agregadas representan resultados obtenidos al resumir una o varias dimensiones.

Por ejemplo, `(Marzo, Rosario, Computadoras)` puede representar una celda base, mientras que `(Marzo, Todas las ciudades, Computadoras)` representa una celda agregada.

6.1.2. Relaciones entre celdas: padres, hijos, ancestros y descendientes

Las celdas se relacionan mediante diferentes niveles de generalización.

Una celda padre contiene información más agregada que una celda hija. Una celda hija representa información más específica. Los conceptos de ancestro y descendiente extienden estas relaciones a varios niveles.

Por ejemplo, las ventas de Argentina constituyen una agregación de las ventas de sus provincias, que a su vez pueden agrupar las ventas de sus ciudades.

6.1.3. Combinaciones de dimensiones y niveles de agregación

Un cubo puede generar múltiples agrupaciones dependiendo de las dimensiones disponibles y sus jerarquías. Cada combinación constituye una perspectiva analítica distinta.

Para un cubo de n dimensiones independientes, sin considerar jerarquías internas, existen 2^n cuboides posibles. Por lo tanto, al aumentar la cantidad de dimensiones, crece rápidamente el número de agregaciones que pueden calcularse.

6.1.4. Complejidad y costo computacional

Calcular todas las agregaciones posibles puede requerir grandes cantidades de memoria, almacenamiento y tiempo de procesamiento.

El problema se vuelve especialmente importante cuando el cubo contiene muchas dimensiones o grandes volúmenes de registros. Por este motivo, los sistemas OLAP utilizan técnicas de optimización y materialización para evitar cálculos innecesarios.

6.2. Materialización de cubos

La materialización consiste en calcular anticipadamente las agregaciones de un cubo y almacenar sus resultados para acelerar futuras consultas.

6.2.1. Sin materialización

No se precalculan cuboides agregados. Los resultados deben obtenerse durante la ejecución de cada consulta.

Esta alternativa reduce el almacenamiento adicional, pero puede provocar tiempos de respuesta elevados.

6.2.2. Materialización completa

Se calculan y almacenan todos los cuboides posibles del cubo de datos.

Permite responder rápidamente numerosas consultas, pero requiere un volumen importante de almacenamiento y procesamiento previo.

6.2.3. Materialización parcial

Se calculan únicamente determinados cuboides, seleccionados según su utilidad, frecuencia de consulta o costo de procesamiento.

Es una alternativa equilibrada porque reduce el almacenamiento respecto de la materialización completa y permite acelerar las consultas más importantes.

6.2.4. Cubos Iceberg

Un Iceberg Cube almacena únicamente las celdas agregadas que cumplen una condición mínima, como alcanzar determinado número de registros o volumen de ventas.

Por ejemplo, pueden almacenarse solamente las combinaciones de dimensiones que representan al menos 1.000 transacciones.

El objetivo es evitar el procesamiento y almacenamiento de agregaciones que no cumplen el umbral establecido.

6.2.5. Cubos cerrados (Closed Cubes)

Los cubos cerrados buscan reducir el almacenamiento eliminando agregaciones redundantes.

Se conservan las celdas cerradas, es decir, aquellas para las que no existe un descendiente más específico con exactamente el mismo conjunto de celdas base cubiertas. Esto permite representar la información de manera más compacta sin conservar todas las combinaciones equivalentes.

6.2.6. Estrategias de precomputación de agregados

La precomputación consiste en anticipar los resultados analíticos que probablemente serán necesarios.

La selección de agregaciones depende de factores como la frecuencia de uso, el tamaño de los cuboides, el costo de calcularlos y los recursos disponibles. El objetivo es reducir los tiempos de consulta sin materializar información innecesaria.

6.3. Estrategias de optimización de la computación

6.3.1. Ordenamiento, hashing y agrupamiento

Estas técnicas permiten organizar los registros que comparten valores de dimensiones para facilitar las agregaciones.

El ordenamiento agrupa registros según determinados atributos, mientras que el hashing permite distribuirlos en conjuntos utilizando funciones de dispersión. Ambas estrategias reducen el trabajo necesario para localizar y procesar datos relacionados.

6.3.2. Agregación simultánea y reutilización de resultados intermedios

En lugar de calcular cada cuboide desde cero, es posible aprovechar operaciones realizadas previamente.

Por ejemplo, una misma lectura de datos puede utilizarse para calcular ventas por producto, por región y por combinación de ambas dimensiones.

La reutilización de resultados intermedios disminuye las lecturas de disco y el costo computacional.

6.3.3. Agregación desde el cuboide hijo más pequeño

Cuando un cuboide puede obtenerse a partir de varios cuboides previamente calculados, conviene seleccionar aquel que contenga menos registros, siempre que tenga el detalle necesario.

Esto reduce la cantidad de información que debe procesarse para construir una agregación más general.

6.3.4. Poda mediante antimonotonicidad

La antimonotonicidad permite descartar combinaciones que no pueden satisfacer determinadas condiciones.

Por ejemplo, si una combinación contiene solamente 800 registros y el mínimo requerido para un cubo Iceberg es 1.000, ninguna combinación más específica derivada de ella podrá alcanzar ese mínimo.

Esta propiedad permite evitar el cálculo de numerosas celdas innecesarias. Se aplica a condiciones de agregación apropiadas, como un conteo mínimo.

6.4. Métodos de computación de cubos

6.4.1. MultiWay Array Aggregation

MultiWay es un algoritmo de computación de cubos completos que utiliza arreglos multidimensionales.

Divide los datos en bloques pequeños (chunks) que pueden procesarse en memoria y calcula varias agregaciones simultáneamente. Su objetivo es reducir los accesos repetidos a los datos y aprovechar eficientemente los recursos disponibles.

Se asocia especialmente con implementaciones MOLAP.

6.4.2. BUC (Bottom-Up Computation)

BUC es un algoritmo que calcula cubos utilizando un enfoque de especialización progresiva de dimensiones. Parte de agrupaciones generales y profundiza en combinaciones más específicas.

Es especialmente útil para construir cubos Iceberg porque puede aplicar técnicas de poda y descartar tempranamente combinaciones que no cumplen los umbrales mínimos establecidos.

6.4.3. Precomputación de Shell Fragments

La técnica de Shell Fragments está orientada a cubos con muchas dimensiones, donde calcular todas las combinaciones sería demasiado costoso.

Consiste en dividir las dimensiones en grupos pequeños y calcular cubos locales para cada grupo. Posteriormente, los resultados pueden combinarse mediante índices invertidos para responder consultas que involucran dimensiones de distintos fragmentos.

Esto reduce considerablemente la cantidad de agregaciones que deben precalcularse.

6.4.4. Procesamiento eficiente de consultas mediante cuboides

Cuando se ejecuta una consulta OLAP, el sistema debe determinar si puede responderla utilizando alguno de los cuboides materializados.

Para ello, identifica los cuboides compatibles con las dimensiones y el nivel de detalle solicitado, descarta los que no pueden proporcionar la información necesaria y estima el costo de utilizar los restantes.

Finalmente, selecciona una alternativa eficiente para obtener el resultado. Es importante recordar que un cuboide más agregado no permite recuperar información más detallada que la que conserva.

7. Data Mining (Minería de Datos)

7.1. Fundamentos de Data Mining

7.1.1. Definición y objetivos

La Minería de Datos (Data Mining) es el proceso de identificar patrones válidos, novedosos, potencialmente útiles y comprensibles a partir de grandes conjuntos de datos.

Su objetivo es descubrir conocimiento que no resulta evidente mediante consultas tradicionales, proporcionando información que permita comprender comportamientos y apoyar decisiones.

7.1.2. Descubrimiento de patrones y relaciones ocultas

Data Mining permite identificar relaciones, regularidades y comportamientos que pueden encontrarse ocultos dentro de grandes volúmenes de información.

Por ejemplo, una empresa puede descubrir que determinados productos suelen comprarse conjuntamente o que ciertos grupos de clientes presentan comportamientos de consumo similares.

Estas relaciones pueden utilizarse para mejorar estrategias comerciales, identificar oportunidades o anticipar situaciones futuras.

7.1.3. Análisis descriptivo y predictivo

El análisis descriptivo busca identificar y comprender patrones existentes en los datos, como agrupaciones de clientes o asociaciones entre productos.

El análisis predictivo utiliza información histórica para construir modelos capaces de estimar valores, comportamientos o acontecimientos futuros.

La principal diferencia es que el descriptivo busca comprender la estructura y las relaciones de los datos, mientras que el predictivo intenta anticipar resultados.

7.1.4. Relación entre Data Mining, Data Warehouse y OLAP

El Data Warehouse proporciona datos históricos, integrados y depurados. OLAP permite explorarlos interactivamente mediante consultas y agregaciones. Data Mining aplica técnicas de análisis para descubrir patrones y construir modelos.

Estas tecnologías son complementarias. El Data Warehouse proporciona la infraestructura de información, OLAP facilita su exploración y Data Mining permite profundizar en el descubrimiento de conocimiento.

7.2. Aplicaciones analíticas

7.2.1. Identificación de patrones y tendencias

Consiste en descubrir comportamientos recurrentes o cambios significativos en los datos. Puede utilizarse para analizar hábitos de compra, variaciones de demanda o evolución de indicadores empresariales.

7.2.2. Clasificación y agrupamiento (Clustering)

La clasificación consiste en asignar registros a categorías previamente definidas, generalmente utilizando modelos entrenados con ejemplos etiquetados.

El clustering agrupa registros según sus similitudes, sin requerir categorías conocidas previamente. Por ejemplo, permite identificar segmentos de clientes con comportamientos semejantes.

7.2.3. Asociaciones entre datos

El análisis de asociaciones busca identificar elementos o acontecimientos que aparecen relacionados frecuentemente.

Un ejemplo clásico es descubrir productos que suelen comprarse juntos. Este conocimiento puede utilizarse para recomendaciones, promociones o distribución de productos.

7.2.4. Predicción de comportamientos futuros

Las técnicas predictivas utilizan datos históricos para estimar comportamientos que todavía no ocurrieron.

Pueden aplicarse para pronosticar ventas, detectar riesgos, estimar demanda o predecir abandono de clientes. Sus resultados son estimaciones sujetas a incertidumbre, no garantías sobre acontecimientos futuros.

7.2.5. Integración con Inteligencia Artificial y Machine Learning

Data Mining puede utilizar algoritmos de Machine Learning para descubrir patrones y realizar predicciones. A su vez, los modelos de IA pueden aprovechar los datos preparados en un Data Warehouse para entrenarse y generar resultados analíticos.

También pueden aplicarse técnicas de aprendizaje automático para mejorar procesos de limpieza, integración y gestión de los propios repositorios.

8. Data Lakes y Data Lakehouses

8.1. Fundamentos de Data Lake

8.1.1. Definición y objetivos

Un Data Lake es un repositorio centralizado diseñado para almacenar grandes cantidades de datos provenientes de diferentes fuentes, conservándolos inicialmente en su formato original.

Su objetivo es proporcionar una infraestructura flexible que permita almacenar información sin necesidad de definir previamente todos los análisis que se realizarán sobre ella.

A diferencia de un Data Warehouse, que organiza y transforma los datos según determinados requerimientos analíticos, un Data Lake permite conservar información potencialmente útil para necesidades presentes y futuras.

8.1.2. Datos estructurados, semiestructurados y no estructurados

Un Data Lake puede almacenar información de distintos tipos.

Los datos estructurados poseen una organización definida, como las tablas de una base relacional. Los semiestructurados contienen cierta organización, como archivos JSON o XML. Los no estructurados incluyen documentos, imágenes, audio y video.

Esta capacidad permite integrar información que no encaja fácilmente en los modelos tradicionales de almacenamiento analítico.

8.1.3. Almacenamiento de datos en formato original

Una característica fundamental del Data Lake es que los datos pueden almacenarse sin transformaciones previas.

Esto permite conservar su contenido original y decidir posteriormente cómo procesarlos según las necesidades del análisis.

Este enfoque suele asociarse con Schema-on-Read, donde la estructura se interpreta al consultar los datos, a diferencia del enfoque Schema-on-Write característico de muchos Data Warehouses tradicionales.

8.1.4. Escalabilidad y flexibilidad

Los Data Lakes están diseñados para manejar grandes volúmenes de información y adaptarse a la incorporación de nuevas fuentes y formatos.

Suelen utilizar sistemas de almacenamiento distribuidos o servicios en la nube, que permiten ampliar la capacidad según las necesidades.

Además, pueden separar los recursos de almacenamiento de los recursos de procesamiento, permitiendo que diferentes herramientas analíticas utilicen los mismos datos.

8.1.5. Aplicaciones en Big Data, análisis en tiempo real y Machine Learning

Los Data Lakes permiten conservar los datos necesarios para diferentes tipos de análisis, desde reportes tradicionales hasta procesamiento de Big Data.

Son especialmente útiles para proyectos de Machine Learning, donde pueden necesitarse grandes conjuntos de datos históricos, textos, imágenes o registros de sensores.

También pueden utilizarse en aplicaciones de análisis en tiempo real, siempre que la arquitectura incluya mecanismos de ingesta y procesamiento adecuados.

8.2. Arquitectura de Data Lake

8.2.1. Fuentes de datos y conectores

Un Data Lake puede recibir información desde bases operacionales, documentos, aplicaciones web, redes sociales, imágenes y fuentes externas.

Los conectores permiten capturar e incorporar datos provenientes de estas fuentes, facilitando su integración dentro del repositorio centralizado.

8.2.2. Capa de datos crudos (Raw Data Layer)

Es la capa inicial, también denominada Landing Area o capa de ingesta.

Almacena los datos en su formato original, sin aplicar procesos de limpieza o transformación. Su función es conservar una copia de la información recibida y permitir que posteriormente pueda procesarse según diferentes necesidades.

8.2.3. Capa de estandarización (Standardized Data Layer)

Es una capa opcional donde los datos se convierten a formatos más apropiados para su procesamiento.

Su objetivo es facilitar y optimizar las tareas posteriores de transformación, limpieza y acceso.

8.2.4. Capa de datos depurados (Cleansed/Curated Data Layer)

Contiene información que ya fue limpiada, validada y transformada.

Los datos se organizan en conjuntos utilizables por analistas y otras aplicaciones, ofreciendo una base más confiable para el análisis.

8.2.5. Capa de aplicación (Application Data Layer)

Es la capa donde los datos se organizan de acuerdo con reglas y necesidades específicas del negocio.

Permite construir aplicaciones analíticas, reportes y soluciones de Machine Learning sobre información preparada para su utilización.

8.2.6. Capa Sandbox

Es un entorno opcional destinado a la experimentación de analistas y científicos de datos.

Permite realizar pruebas, explorar información, desarrollar modelos y generar nuevos conjuntos de datos sin alterar directamente las capas principales.

8.2.7. Descubrimiento de datos, motores de búsqueda y APIs

Los Data Lakes pueden incorporar herramientas de búsqueda que permiten localizar conjuntos de datos según su contenido, origen o significado empresarial.

Los catálogos, diccionarios y metadatos facilitan el descubrimiento de información disponible. Por su parte, las APIs permiten que diferentes aplicaciones accedan a los servicios y datos del repositorio.

8.3. Administración y gobierno de Data Lakes

8.3.1. Seguridad y control de acceso

La seguridad consiste en establecer quién puede acceder a los datos y qué operaciones tiene permitido realizar.

Incluye mecanismos de autenticación, autorización y protección de la información, especialmente cuando el repositorio contiene datos sensibles o provenientes de múltiples departamentos.

8.3.2. Calidad e integridad de datos

Aunque un Data Lake pueda conservar datos sin transformar, es necesario aplicar mecanismos que permitan evaluar su calidad y garantizar su integridad.

Esto implica controlar errores, inconsistencias y alteraciones indebidas, especialmente cuando los datos se preparan para su utilización analítica.

8.3.3. Catálogos, diccionarios y metadatos

Estos componentes permiten documentar los conjuntos de datos disponibles, su significado, procedencia y características.

Son fundamentales para que los usuarios puedan encontrar e interpretar correctamente la información almacenada.

8.3.4. Monitoreo, auditoría y trazabilidad

El gobierno de datos comprende las actividades destinadas a controlar el funcionamiento y uso del repositorio.

Incluye monitorear accesos, registrar operaciones, auditar modificaciones y mantener la trazabilidad de los datos desde su origen hasta su utilización.

Sin estos mecanismos, un Data Lake puede convertirse en un repositorio difícil de administrar y utilizar confiablemente.

8.4. Data Lakehouse

8.4.1. Definición y características

Un Data Lakehouse es una arquitectura que combina características de los Data Lakes y los Data Warehouses.

Busca aprovechar la flexibilidad del almacenamiento de grandes volúmenes de datos con las capacidades de organización, consistencia y análisis eficiente de los repositorios tradicionales.

8.4.2. Integración de capacidades de Data Lake y Data Warehouse

Un Lakehouse permite almacenar diferentes tipos de datos y, al mismo tiempo, incorporar mecanismos de gestión de tablas, esquemas, metadatos y optimización de consultas.

De esta forma, puede utilizarse tanto para análisis empresariales como para procesamiento avanzado y Machine Learning.

8.4.3. Arquitectura híbrida de almacenamiento y análisis

La arquitectura Lakehouse suele utilizar almacenamiento de objetos combinado con formatos de tabla y motores de procesamiento que permiten consultar y administrar los datos.

Su objetivo es reducir la necesidad de mantener repositorios completamente separados para distintas actividades analíticas.

8.5. Comparación de soluciones analíticas

8.5.1–8.5.6. Diferencias y criterios de selección

La elección entre Data Warehouse, Data Lake, Data Lakehouse y Data Mart depende del tipo de datos, los usuarios, las necesidades de análisis y los recursos disponibles.

Característica	Data Warehouse	Data Lake	Data Lakehouse	Data Mart
Objetivo	Análisis empresarial	Almacenamiento flexible y exploración	Unificar almacenamiento y análisis	Análisis departamental
Tipos de datos	Principalmente estructurados	Todos los tipos	Todos los tipos	Principalmente estructurados
Organización	Esquemas definidos	Datos crudos y procesados	Datos flexibles con gestión estructurada	Modelo específico de un área
Usuarios	Analistas y directivos	Científicos e ingenieros de datos, entre otros	Analistas, ingenieros y científicos de datos	Usuarios de un departamento
Ventaja	Consultas consistentes y eficientes	Flexibilidad y escalabilidad	Versatilidad analítica	Simplicidad y foco
Limitación	Menor flexibilidad ante nuevos formatos	Mayor necesidad de gobierno	Complejidad de implementación	Alcance limitado

En términos generales, un Data Warehouse resulta apropiado para reportes empresariales y decisiones basadas en información estructurada y consistente. Un Data Lake es conveniente para almacenar grandes volúmenes de datos heterogéneos y realizar análisis exploratorios.

Un Data Lakehouse es adecuado cuando se busca combinar ambas capacidades, mientras que un Data Mart permite satisfacer necesidades analíticas específicas de un área con un alcance más reducido.

8.6. Tecnologías y plataformas en la nube

8.6.1. Google Cloud

Google Cloud proporciona servicios para almacenar, procesar y analizar grandes volúmenes de datos. Puede utilizarse para implementar arquitecturas analíticas, Data Lakes y soluciones relacionadas con Big Data e inteligencia artificial.

8.6.2. Amazon S3

Amazon Simple Storage Service (S3) es un servicio de almacenamiento de objetos en la nube de AWS.

Es frecuentemente utilizado como base de almacenamiento para Data Lakes porque permite conservar grandes volúmenes de archivos y datos de diferentes formatos.

8.6.3. Amazon Redshift

Amazon Redshift es un servicio de Data Warehouse administrado en la nube de AWS.

Está diseñado para ejecutar consultas analíticas SQL sobre grandes volúmenes de información, utilizando mecanismos de almacenamiento y procesamiento optimizados para análisis.

8.6.4. Soluciones de almacenamiento y análisis en la nube

Las plataformas en la nube permiten implementar repositorios y herramientas analíticas sin necesidad de administrar directamente toda la infraestructura física.

Ofrecen capacidad de almacenamiento, procesamiento y escalabilidad según las necesidades de la organización. La elección depende de los costos, volúmenes de datos, tipos de consultas y servicios requeridos.

9. Ciclo de Vida de un Proyecto de Data Warehouse

El ciclo de vida de un Data Warehouse comprende las actividades necesarias para planificar, diseñar, construir, implementar y mantener una solución analítica.

Las fuentes presentan un enfoque basado en la metodología de Kimball, donde el desarrollo se organiza en etapas y tres pistas principales: Tecnología, Datos y Aplicaciones Analíticas. Estas pistas pueden avanzar en paralelo y se coordinan mediante la gestión del proyecto.

Etapa / Pista	Actividades
Planificación del proyecto	Definición de requerimientos de negocio
Pista de Tecnología	Arquitectura y productos
Pista de Datos	Modelado, diseño físico y ETL
Pista de Aplicaciones	Especificación y desarrollo analítico
Cierre	Implementación, mantenimiento y crecimiento

La gestión del proyecto acompaña todo el ciclo.

9.1. Planificación del proyecto

9.1.1–9.1.4. Evaluación, alcance, justificación y recursos

La planificación comienza evaluando si la organización se encuentra preparada para desarrollar un Data Warehouse. Esto implica analizar sus necesidades, la disponibilidad de datos, el apoyo de la dirección y los recursos técnicos y humanos.

Posteriormente, se definen los objetivos, el alcance inicial y los beneficios esperados. La justificación del proyecto requiere comparar los costos de implementación con las mejoras que se espera obtener en los procesos de análisis y toma de decisiones.

También se establece el equipo de trabajo, el presupuesto y el calendario de actividades.

9.1.5–9.1.6. Estrategia de implementación y ámbito inicial

La implementación puede seguir un enfoque Top-Down, comenzando por una visión corporativa general, o un enfoque Bottom-Up, desarrollando inicialmente soluciones analíticas más específicas.

El ámbito inicial debe ser suficientemente reducido para permitir obtener resultados en un tiempo razonable, pero también debe responder a necesidades empresariales relevantes.

Entre los criterios utilizados para delimitarlo se encuentran el presupuesto, la cantidad de fuentes de datos, los departamentos involucrados y el tiempo disponible.

9.1.7–9.1.8. Arquitectura, metodología y plan del proyecto

En esta etapa se selecciona la arquitectura general de la solución y la metodología de desarrollo.

El apunte menciona el desarrollo en espiral como una alternativa que permite construir versiones sucesivas del sistema, incorporando nuevos requerimientos y realizando ajustes durante su evolución.

El plan del proyecto establece las actividades, los responsables, los recursos y los plazos necesarios para coordinar su ejecución.

9.2. Definición de requerimientos de negocio

9.2.1–9.2.2. Necesidades de información y áreas tema

Esta etapa busca comprender qué información necesitan los usuarios para tomar decisiones y qué problemas empresariales debe resolver el Data Warehouse.

Se identifican las áreas tema que serán analizadas, como ventas, clientes, pedidos o promociones. Estas delimitan los procesos del negocio que formarán parte de la solución.

También deben considerarse los requerimientos de los responsables del proyecto, relacionados con costos, alcance, riesgos y objetivos empresariales.

9.2.3–9.2.4. Indicadores, dimensiones y granularidad

A partir de los requerimientos se determinan las medidas que permitirán evaluar los procesos y las dimensiones que proporcionarán contexto a esos resultados.

También se define la granularidad, que establece exactamente qué representa cada registro de la tabla de hechos.

Estas decisiones son fundamentales porque condicionan las consultas que podrán ejecutarse posteriormente.

9.2.5. Consultas y requerimientos analíticos

Los requerimientos pueden expresarse mediante preguntas concretas del negocio, como: «¿Cuáles fueron los diez productos más vendidos durante el último año por región?».

A partir de estas preguntas pueden construirse moldes de consulta que identifican las medidas, dimensiones y jerarquías necesarias.

La consolidación de estos moldes permite elaborar un modelo Starnet (red estrella), utilizado para representar los requerimientos analíticos de un área tema.

9.3. Pista de Tecnología

9.3.1. Diseño de la arquitectura técnica

Consiste en definir la infraestructura necesaria para implementar el Data Warehouse, incluyendo servidores, almacenamiento, conexiones, mecanismos de procesamiento y herramientas analíticas.

El objetivo es establecer una arquitectura que satisfaga los requerimientos actuales y permita acompañar el crecimiento de la organización.

9.3.2. Selección e instalación de productos

Una vez definida la arquitectura, se seleccionan las tecnologías que se utilizarán para implementarla.

Esta actividad incluye evaluar productos, verificar su compatibilidad, instalarlos y configurarlos de acuerdo con los requerimientos de rendimiento, seguridad y escalabilidad.

9.4. Pista de Datos

9.4.1. Modelado dimensional

En esta etapa, los requerimientos de negocio se transforman en un modelo dimensional.

Se identifican las áreas tema, las medidas, las dimensiones y la granularidad necesaria. El objetivo es construir una estructura que permita representar correctamente los procesos y responder las consultas planteadas por los usuarios.

9.4.2. Diseño físico

El diseño físico convierte el modelo lógico en estructuras concretas de almacenamiento.

Incluye la definición de tablas, columnas, tipos de datos, claves, restricciones e índices. También contempla mecanismos destinados a mejorar el rendimiento de las consultas.

9.4.3. Diseño de los procesos ETL

Consiste en definir cómo se extraerán los datos de las fuentes, qué transformaciones se aplicarán y cómo se incorporarán al Data Warehouse.

También deben establecerse los controles de calidad, el tratamiento de registros erróneos y los mecanismos de actualización necesarios para mantener la información disponible.

9.5. Pista de Aplicación Analítica

9.5.1. Especificación de aplicaciones analíticas

Consiste en definir qué herramientas utilizarán los usuarios y cómo deberán presentar la información.

Se especifican los reportes, consultas, indicadores, visualizaciones y funcionalidades necesarias para satisfacer los requerimientos del negocio.

9.5.2. Desarrollo de aplicaciones analíticas

En esta etapa se implementan las herramientas definidas anteriormente, conectándolas con los datos del DW.

El objetivo es proporcionar interfaces que permitan consultar, analizar e interpretar la información de manera sencilla y eficiente.

9.6. Implementación

9.6.1–9.6.3. Integración, puesta en funcionamiento y disponibilidad

La implementación consiste en integrar los componentes desarrollados en las distintas pistas: infraestructura tecnológica, estructuras de datos, procesos ETL y aplicaciones analíticas.

Se realizan las configuraciones, pruebas y verificaciones necesarias para poner la solución en funcionamiento.

Finalmente, el sistema se habilita para los usuarios, procurando que puedan acceder a información confiable y utilizar las herramientas de análisis disponibles.

9.7. Mantenimiento y crecimiento

9.7.1–9.7.3. Mantenimiento, evolución y escalabilidad

Una vez implementado, el Data Warehouse requiere actividades de mantenimiento para corregir errores, controlar el funcionamiento de los procesos y asegurar la disponibilidad de los datos.

También debe adaptarse a nuevos requerimientos, como incorporar fuentes de información, dimensiones, indicadores o áreas de negocio.

El crecimiento de la solución debe planificarse para evitar problemas de rendimiento y permitir que la infraestructura continúe respondiendo a las necesidades de la organización.

9.8. Gestión del proyecto

9.8.1–9.8.3. Coordinación, dependencias y control

La gestión del proyecto es una actividad transversal que acompaña todas las etapas del ciclo de vida.

Su función consiste en coordinar los equipos de trabajo, controlar los recursos y supervisar el cumplimiento de los objetivos establecidos.

Las pistas de Tecnología, Datos y Aplicaciones Analíticas poseen dependencias entre sí, por lo que deben planificarse de manera coordinada, aunque algunas actividades puedan ejecutarse en paralelo.

El seguimiento permite identificar retrasos, riesgos y problemas de integración, realizando los ajustes necesarios para completar el proyecto.

Qué conviene priorizar para el parcial

Según el desarrollo y el énfasis de los materiales, concentraría el repaso en este orden:

1. **Operaciones OLAP:** Drill Down, Roll Up, Slice, Dice, Pivot, Drill Across y Drill Through. Saber distinguirlas y reconocerlas en ejemplos.
2. **Cubos OLAP:** dimensiones, medidas, celdas, cuboides, cuboide base, ápice y retícula.
3. **Arquitecturas ROLAP, MOLAP y HOLAP:** funcionamiento, ventajas y diferencias.
4. **Materialización de cubos:** completa, parcial, sin materialización, Iceberg y técnicas básicas de optimización.
5. **Data Lake vs. Data Warehouse vs. Lakehouse:** características, diferencias y situaciones de uso.
6. **Ciclo de vida de un DW:** etapas, requerimientos de negocio y las tres pistas de desarrollo.
7. **Data Mining:** definición, clasificación, clustering, asociaciones y predicción.

Las técnicas específicas de índices y los algoritmos MultiWay, BUC y Shell Fragments también forman parte de las fuentes, pero tienen un carácter más especializado. Para un primer repaso, priorizaría comprender qué problema resuelve cada técnica antes que memorizar su procedimiento detallado, salvo que el docente haya indicado que se evaluarán algoritmos.

Con esto quedan desarrollados los temas 5 a 9 y completado el temario de las tres fuentes.