



Sistemas de Gestión

PRACTICA: REGRESION LINEAL SIMPLE Y MULTIPLE

1. Al gerente de una cadena de supermercados le gustaría determinar el efecto del espacio en estantes sobre la venta de comidas para mascotas. Se selecciona una muestra aleatoria de 12 supermercados de igual tamaño, los resultados se muestran a continuación.

Tienda	Espacio (pies)	Ventas semanales Cientos de \$
1	5	1.6
2	5	2.2
3	5	1.4
4	10	1.9
5	10	2.4
6	10	2.6
7	15	2.3
.	.	.
.	.	.

- Construya un diagrama de dispersión.
- Suponiendo que existe una relación lineal, utilice el método de mínimos cuadrados para calcular los coeficientes de regresión.
- Interprete el significado de la pendiente de la recta de regresión.
- Calcule el desvío estándar del error.
- Calcule el coeficiente de determinación, r^2 , e interprételo.
- Calcule el coeficiente de correlación. Interprete.
- Analice los residuos. Determine si el modelo es adecuado.
- Prediga las ventas semanales promedio de alimento para mascotas si se destinan 8 pies de espacio en el estante para alimentos.
- Establezca una estimación de intervalo de confianza del 95% de las ventas semanales promedio de las tiendas que tienen 8 pies de espacio en la góndola para exhibir alimentos para mascotas.
- Estime con un intervalo de predicción del 95% las ventas semanales de una tienda individual que destine 8 pies de espacio para alimentos para mascotas.
- Explique la diferencia entre los dos intervalos anteriores.

2. Al gerente de una compañía que se encarga de hacer investigaciones de mercado le gustaría desarrollar un modelo para predecir el número de entrevistas llevadas a cabo por sus encuestadores en un día dado. Tiene la creencia de que la experiencia del encuestador (medida en semanas de trabajo) es el principal determinante del número de entrevistas que puede llevar a cabo. Se seleccionó una muestra de 10 encuestadores y se registró el número de entrevistas llevadas a cabo junto con el número de semanas de experiencia. Se obtuvieron los siguientes resultados.

Semanas de experiencia	Cantidad de entrevistas
15	4
41	9
58	12
18	6
.	.
.	.



- a) ¿Qué diferencias observa entre los datos relevados en esta experiencia y los del ejercicio anterior?
- b) Interprete el significado de la pendiente de la recta de regresión.
- c) Calcule el desvío estándar del error.
- d) Calcule el coeficiente de determinación, r^2 , e interprételo.
- e) Calcule el coeficiente de correlación. Interprete.
- f) Analice los residuos. Determine si el modelo es adecuado.
- g) Prediga la cantidad de encuestas semanales promedio de un encuestador con 30 semanas de experiencia.
- h) Establezca una estimación de intervalo de confianza del 95% de la cantidad de encuestas semanales promedio de un encuestador con 30 semanas de experiencia.
- i) Estime con un intervalo de predicción del 95% la cantidad de encuestas semanales que hará un encuestador con 30 semanas de experiencia.
- j) Explique la diferencia entre los dos intervalos anteriores.

3. Una agrónoma quiere investigar los factores que determinan el rendimiento de la cosecha. Para ello, llevó a cabo un experimento en una granja previamente dividida en 30 porciones de un acre cada una. La cantidad de fertilizante utilizada en cada sección fue variable. Luego se plantó maíz, y se registró la cantidad cosechada al final de la temporada.

Cant de fert	Rendimiento
210	43,50
220	150,20
230	39,50
240	104,00
250	80,00
260	70,50
.	.
.	.

- a) Encuentre la recta de regresión muestral e interprete los coeficientes.
- b) ¿Puede concluir la agrónoma en un nivel de significación del 5% que hay una relación lineal entre la cantidad de fertilizante y el rendimiento de la cosecha?
- c) Encuentre el coeficiente de determinación e interprete su valor.
- d) ¿Es el modelo lineal simple una herramienta útil en la predicción del rendimiento de la cosecha con respecto a la cantidad de fertilizante utilizado?. Si es así, construya un intervalo de predicción del 95% del rendimiento de la cosecha cuando se aplican 300 libras de fertilizante. Si no, explique por qué no.

5. APLICACIÓN A LAS FINANZAS. Una importante aplicación de la regresión lineal simple es el conocido *modelo de mercado*. Este modelo supone que la tasa de retorno de una acción está relacionada linealmente con la tasa de retorno de todo el mercado. La expresión matemática es:

$$R = \beta_0 + \beta_1 R_m + e$$

Donde R es el retorno de una acción determinada, R_m es el retorno de un conjunto de acciones medido con un índice como el "New York Stock Exchange Composite Index", por ejemplo.

Al coeficiente β_1 se lo llama **coeficiente beta** de la acción y mide la sensibilidad de la tasa de retorno de la acción estudiada ante cambios en el nivel de retorno de todo el mercado. Por ejemplo si β_1 es mayor que uno, la tasa de retorno de la acción es más sensible a cambios del mercado que el promedio de las acciones. Supongamos que $\beta_1=2$: un incremento del 1% en el índice del mercado ocasiona un aumento promedio del 2% en el retorno de la acción. Una acción con un coeficiente beta mayor que uno tiende a ser más volátil que el mercado. Una acción con un coeficiente beta menor que uno será menos volátil.

Usando la regresión lineal simple se obtiene una estimación del coeficiente beta de una acción dada. El coeficiente de determinación es también una parte importante del análisis estadístico-financiero.

Las tasas de retorno mensuales de las acciones de Nortel y de todo el mercado para un período de 5 años aparecen en la tabla adjunta (de arriba abajo y de izquierda a derecha). Estime el modelo del mercado y analice los resultados.

- Analice los datos y el modelo propuesto, realice recomendaciones. Justifique
- ¿Qué puede decir de la volatilidad de Nortel? Justifique.
- ¿Usaría el rendimiento promedio del mercado para pronosticar el retorno de Nortel? Justifique la respuesta
- En caso de que haya contestado que no a la pregunta anterior: Si fuera posible hacerlo con el modelo planteado, ¿cómo lo llevaría a cabo?

Nortel	TSE
0.240688	0.093389
0.016166	0.046380
-0.038511	0.072486
.	.
.	.

6. Se desea explicar la variabilidad a través de los años de los márgenes de beneficio de las entidades de ahorro y crédito. Se supone que los márgenes de beneficio están relacionados con los ingresos netos por dólar depositado y con el aumento de la competencia medido a través del número de entidades de ahorro y crédito del mercado.

- Calcule la regresión múltiple considerando que el margen neto de beneficio es una variable dependiente de las otras dos. Los datos están en la próxima página.
- Escriba un informe con los resultados.

Año	Ingreso neto por dólar depositado	Nº de entidades de ahorro	Margen de beneficio (%)
1	3.92	7298	0.75
2	3.61	6855	0.71
3	3.32	6636	0.66
4	3.07	6506	0.61
5	3.06	6450	0.70
6	3.11	6402	0.72
7	3.21	6368	0.77
8	3.26	6340	0.74
9	3.42	6349	0.90
.	.	.	.
.	.	.	.

Fuente: "Entry and profitability in a rate-free saving market" *Quarterly Review of Economics and Business*, 18, n°2, (1978).

7. Al final del curso, los alumnos califican a su profesor en una escala del 1 (malo) al 5 (excelente). También se les pregunta qué nota esperan sacar en el curso. Estas se codifican como A=4, B=3 y así sucesivamente. En la tabla se muestran las calificaciones medias de los profesores, las notas medias esperadas y el número de alumnos en la clase de una muestra de 20 clases.

Calificación	Nota esperada	Cant. de estudiantes
4.1	3.4	45
3.4	3.1	52
3.3	3.0	47
3.0	2.8	63
4.7	3.7	20
4.6	3.5	32
3.0	2.9	51
.	.	.
.	.	.

- Calcule la regresión múltiple considerando que la calificación del profesor es una variable dependiente de las otras dos.
- Escriba un informe con los resultados.

8. Un agente inmobiliario de una ciudad de EEUU quiere desarrollar un modelo para predecir el precio de venta de las viviendas.

Cree que las variables más importantes para determinar el precio son: superficie de la vivienda, cantidad de dormitorios y superficie del lote. Tomó una muestra aleatoria de 100 viviendas vendidas recientemente y registró: precio de venta (en U\$S), número de dormitorios, superficie cubierta (en pie²) y superficie del lote (en pie²).

Precio	Dorm	Sup cubierta	Sup lote
124100	3	1290	3900
218300	4	2080	6600
117800	3	1250	3750
.	.	.	.
.	.	.	.

- Ajuste con un modelo lineal con las tres variables explicativas. Resuelva y estudie si las variables son significativas.
- Realice tres análisis simples (uno con cada variable independiente). Observe los resultados.
- Extraiga conclusiones.


9. Para estudiar si el kilometraje recorrido influye en el precio de los autos usados, un vendedor seleccionó al azar 100 Ford Corsa de dos años de antigüedad que se vendieron en su negocio durante los últimos tres meses. Todos ellos estaban en óptimas condiciones de mantenimiento y equipados con reproductor de CD y aire acondicionado.

El vendedor cree que el color de la unidad también influye en el precio. Piensa que el blanco y el plateado son los más buscados.

Analice si los datos apoyan su teoría.

N°	Precio	Kilometraje	Color
1	24636	56082	blanco
2	24122	67137	blanco
3	24016	68749	otros
4	25590	46293	otros
5	25568	47557	plata

Diagrama de dispersión



10. Un profesor de Estadística quiere saber si el límite de tiempo afecta los resultados de los exámenes escritos. Toma una muestra aleatoria de 100 estudiantes de los cursos de Estadística I y los divide en 5 grupos de 20 estudiantes cada uno. A todos los alumnos se les toma el mismo cuestionario que requiere de cálculos manuales simples. A cada grupo se le toma el examen con distinto límite de tiempo.

GRUPO	Tiempo Máximo
1	40 minutos
2	45 minutos
3	50 minutos
4	55 minutos
5	60 minutos

Realice un análisis de regresión completo, incluyendo diagnóstico. Los datos son los siguientes:

Tiempo	Nota	Tiempo	Nota	Tiempo	Nota	Tiempo	Nota	Tiempo	Nota
40	20	45	23	50	26	55	30	60	32
40	23	45	24	50	25	55	32	60	31
40	19	45	26	50	22	55	26	60	28
40	19	45	24	50	23	55	26	60	30
40	18	45	22	50	25	55	30	60	33
.	.	.	.	.	.	.	.	.	.
.	.	.	.	.	.	.	.	.	.

11. Una empresa eléctrica se interesa en desarrollar un modelo que relacione la demanda horaria pico (y) al uso total de energía durante el mes (x). Es un problema importante de planeación porque la mayor parte de los clientes pagan en forma directa por el uso de la energía (en kilowatt horas), el sistema de generación debe ser lo bastante grande como para cumplir con la demanda máxima impuesta. En la siguiente tabla se ven datos de 53 clientes residenciales para el mes de diciembre de 2006.

Cliente	X(kwh)	Y(kw)
1	679	0,79
2	292	0,44
.	.	.
.	.	.

12. Un ingeniero investiga el uso de un molino de viento para generar electricidad. Ha reunido datos sobre la corriente directa (CD) producida con su molino y la velocidad correspondiente del viento. Desarrollar un modelo que relacione ambas variables, corriente producida (y) con velocidad del viento (x).

Observación	Velocidad del viento (mph)	CD producida
1	5000	1,582
2	6000	1,822
.	.	.
.	.	.

EJERCICIOS PROPUESTOS

1. Se quiere explicar el precio de venta de las viviendas. Para ello se dispone de una muestra de 815 datos. Se ajusta el siguiente modelo:

$$y = -1264 + 48.18 x_1 + 338 x_2 - 1859 x_3 + 3219 x_4 + 2005 x_5 \quad R^2 = 0.8$$

(0.91) (515) (488) (947) (768)

y: precio de venta de la vivienda

x₁: superficie de la vivienda (m²)

x₂: tamaño del garaje (número de autos)

x₃: antigüedad de la vivienda (años)

x₄: variable artificial que vale 1 si la casa tiene chimenea

x₅: variable artificial que vale 1 si la casa tiene cerco de ladrillo

Los valores entre paréntesis son el desvío estándar del estimador

- a) Interprete la estimación del coeficiente que acompaña a x₄.
- b) Interprete la estimación del coeficiente que acompaña a x₅.
- c) Encuentre un intervalo de confianza del 95% para el impacto que tiene sobre el precio de venta el hecho de que la vivienda tenga chimenea (cuando las demás variables se mantienen constantes).
- d) Contraste la hipótesis nula de que el tipo de cerco no tiene impacto en el precio de venta, frente a la alternativa de que, a igualdad de condiciones, las casas con cerco de ladrillo son más caras.

2. El decano de la Facultad de Derecho de Sevilla quería conocer qué importancia podrían tener ciertos factores a la hora de predecir el éxito de los alumnos en sus estudios. Para conseguir su objetivo, tomó los datos necesarios de una muestra de 50 estudiantes recién graduados, y ajustó el siguiente modelo:

$$Y_i = \alpha + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \varepsilon_i$$

Y_i: nota promedio de la carrera

x_{1i}: nota promedio del secundario

x_{2i}: nota del examen de ingreso

x_{3i}: variable artificial que toma el valor 1 si el estudiante había presentado una carta de recomendación firmada por una persona prestigiosa

A partir de la salida de la computadora, saque todas las conclusiones posibles acerca del estudio.

Fuente	Grados de lib	Suma Cuadr	Cuadr Medio	F	R ²
Regresión	3	641.04	213068	8.48	0.356
Error	46	1159.66	25021		
Total	49	1800.70			

Parámetro	Estimación	t	Desvío estándar del estimador
Intercepción	6.512		
X1	3.502	1.45	2.419
X2	0.491	4.59	0.107
X3	10.327	2.45	4.213

3. En un estudio sobre marcas de computadoras en uso, se preguntó en el cuestionario qué computadora tenía la compañía. Se crearon las siguientes variables artificiales

$$\begin{aligned} I_1 &= 1 \text{ (si es IBM)} & I_2 &= 1 \text{ (si es Macintosh)} \\ I_1 &= 0 \text{ (si no es IBM)} & I_2 &= 0 \text{ (si no es Macintosh)} \end{aligned}$$

Identifique a qué marca corresponden los siguientes pares de valores:

$$\text{a) } I_1 = 0 ; I_2 = 1 \quad \text{b) } I_1 = 1 ; I_2 = 0 \quad \text{c) } I_1 = 0 ; I_2 = 0$$

4. En un estudio acerca de los factores determinantes del gasto de las familias en las vacaciones, se observaron datos de una muestra de 2246 familias.

El modelo estimado fue:

$$\log y = -4.054 + 1.1556 \log x_1 - 0.4408 \log x_2 \quad R^2 = 0.168$$

$$\quad \quad \quad (0.0546) \quad \quad \quad (0.0490)$$

y: gasto en vacaciones

x₁: gasto anual en consumo total

x₂: número de miembros de la familia

Los valores entre paréntesis son el desvío estándar del estimador

- Interprete las estimaciones de los coeficientes.
- Interprete el valor el coeficiente de determinación.
- Si todo lo demás permanece igual, encontrar un intervalo de confianza del 95% para el incremento porcentual en el gasto por vacaciones resultante a partir del incremento de un 1% en los gastos totales anuales.
- Suponiendo que el modelo está correctamente especificado, contrastar la hipótesis nula de que, permaneciendo todo lo demás igual, el número de miembros de la familia no afecta el gasto en vacaciones, frente a la alternativa de que a mayor número de miembros en la familia, el gasto en vacaciones es menor.

TRANSFORMACIONES

El método más usado para remediar la falta de normalidad o la heterocedasticidad es transformar la variable *dependiente*.

Primero, el tipo de transformación a usar depende de cuál es el supuesto que no se cumple y de la naturaleza de la desviación. Como hay muchas formas de violar los supuestos de la técnica estadística, la lista que aparece a continuación es irremediablemente incompleta.

Segundo, la transformación puede ser útil para mejorar el modelo. Es decir si el modelo lineal parece ser demasiado pobre, a menudo se puede mejorar el ajuste transformando y .

Tercero, muchos paquetes de computadoras permiten hacer transformaciones con mucha facilidad. Se debe experimentar para ver el efecto que tienen esas transformaciones en los resultados.

Aquí damos una lista breve de las transformaciones más usadas.

Logarítmica: $y' = \log y$ (dado que $y > 0$). Se usa cuando:

- a) la varianza del error crece cuando crece y
- b) la distribución del error es asimétrica a derecha.

Cuadrática: $y' = y^2$. Utilice esta transformación cuando:

- a) la varianza del error es proporcional al valor esperado de y
- b) la distribución del error es asimétrica a izquierda.

Raíz cuadrada: $y' = \sqrt{y}$ (dado que $y > 0$). Es valiosa cuando:

la varianza del error es proporcional al valor esperado de y .

Recíproca: $y' = 1/y$. Se recomienda cuando:

la varianza parece aumentar significativamente después que y supera un valor crítico.

BIBLIOGRAFÍA

MONTGOMERY

PROBABILIDAD Y ESTADISTICA aplicadas a la Ingeniería
Montgomery D., Runger, G. - Mc Graw Hill - México, 1996.

ESTADISTICA para los Negocios y la Economía.
Newbold P. - Prentice Hall - España, 1997

STATISTICS for Management and Economics. Fifth Edition.
Keller G, Warrack B - Duxbury - USA, 2000.

ESTADISTICA BASICA EN ADMINISTRACION, conceptos y aplicaciones. 6ª Edición
Berenson M., Levine D. - Prentice Hall Hispanoamericana - México 1998.

