

REGRESION LINEAL MULTIPLE

Ing. Cristian Bigatti

Modelo de Regresión Lineal Múltiple

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \epsilon$$

- Respuesta relacionada con k regresores.

- Lineal indica que el modelo es lineal en los parámetros, **NO** que $E(Y)$ es una función lineal de las x_i

- $Y = \beta_0 + \beta_1 x + \beta_2 x^2 + \epsilon$ puede trabajarse como una regresión lineal múltiple.


UTN - FRRO - ISI - SG - 2012

2

Regresión Lineal Múltiple

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \epsilon$$

- β_1 y β_2 coeficientes de regresión parciales
- β_1 es el cambio esperado en Y ante un cambio unitario de x_1 cuando x_2 se mantiene constante



UTN - FRRO - ISI - SG - 2012


3

Regresión Lineal Múltiple

- Modelo cuadrático $Y = \beta_0 + \beta_1 x + \beta_2 x^2 + \epsilon$ se transforma en $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \epsilon$

$$\begin{matrix} x = x_1 \\ x^2 = x_2 \end{matrix}$$

- Modelo con interacción $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{12} x_1 x_2 + \epsilon$
 $Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \epsilon$



UTN - FRRO - ISI - SG - 2012

4

Interacción. Ejemplo

Supongamos que consideramos la incidencia de **dos factores** sobre nuestro organismo.

- El primero es la **ingesta de una cantidad moderada de alcohol** que produce una sensación de euforia.
- El segundo un **medicamento para contrarrestar los efectos de la gripe** que produce una sensación de bienestar.

¿Qué ocurre cuando ingerimos las dos cosas simultáneamente? ¿Sentimos euforia y bienestar? No, tenemos una sensación de somnolencia y mareo.

Este es un caso de **interacción**, los **efectos** de las dos variables **no son aditivos**.


UTN - FRRO - ISI - SG - 2012

5

Regresión Lineal Múltiple

- Modelo de segundo grado con interacción

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \underbrace{\beta_{11} x_1^2}_{\beta_3 x_3} + \underbrace{\beta_{22} x_2^2}_{\beta_4 x_4} + \underbrace{\beta_{12} x_1 x_2}_{\beta_5 x_5} + \epsilon$$



Cualquier modelo de regresión lineal en los parámetros (β 's), es un modelo de regresión lineal, sin importar la forma de la superficie que genera

UTN - FRRO - ISI - SG - 2012

6

Modelo no lineal

- Modelo no lineal en los parámetros, ejemplo:

$$y = \theta_1 e^{\theta_2 x} + \varepsilon$$

$$E(y) = \theta_1 e^{\theta_2 x}$$

UTN - FRRO - ISI - SG - 2012

7

Hipótesis básicas

Modelo poblacional

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \varepsilon$$

- ε tiene
 - promedio 0
 - varianza constante σ_ε^2
 - $\varepsilon_i, \varepsilon_j$ independientes
 - distribución normal
- X no es aleatorio
Las x_i son linealmente independientes

ε_i es NID $(0; \sigma_\varepsilon^2)$

UTN - FRRO - ISI - SG - 2012

8

Regresión Lineal Múltiple

Ejemplo

Un distribuidor de bebidas gaseosas analiza las rutas diseñadas para prestar servicio a las máquinas expendedoras de su sistema. Le interesa predecir el tiempo que necesita un repositor para atender una máquina expendedora de un negocio. El servicio consiste en reabastecer la máquina con productos embotellados y hacer algo de mantenimiento y limpieza. El responsable del estudio ha sugerido que las dos variables más importantes que afectan el tiempo de entrega son la cantidad de cajas de producto abastecida y la distancia recorrida por el repositor. Se han reunido 25 observaciones.

UTN - FRRO - ISI - SG - 2012

9

Regresión Lineal Múltiple

Ejemplo:

- Y: tiempo que emplea un repositor para reabastecer una expendedora de gaseosas, en minutos
- x_1 : cantidad de cajas abastecida
- x_2 : distancia recorrida por el repositor, en metros

Este modelo se utilizó para diseñar la ruta, los horarios y la salida del vehículo

obs	tiempo	cajas	distancia
1	9.95	2	50
2	24.45	8	110
3	31.75	11	120
4	35.00	10	550
5	25.02	8	295
6	16.86	4	200
7	14.38	2	375
8	9.60	2	52
9	24.35	9	100
10	27.50	8	300
11	17.08	4	412
12	37.00	11	400
13	41.95	12	500
14	11.66	2	360
15	21.65	4	205
16	17.89	4	400
17	69.00	20	600
18	10.30	1	585
19	34.93	10	540
20	46.59	15	250
21	44.88	15	290
22	54.12	16	510
23	56.23	17	590
24	22.13	6	100
25	21.15	5	400


UTN - FRRO - ISI - SG - 2012

10

Regresión Lineal Múltiple

Ejemplo (cont.)

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$$



UTN - FRRO - ISI - SG - 2012

11

Resultados con R

```
> RegModel.gaseosas <- lm(tiempo~cajas+distancia, data=gaseosas)
```

```
> summary(RegModel.gaseosas)
```

```
Call:
lm(formula = tiempo ~ cajas + distancia, data = gaseosas)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-3.8665 -1.5003 -0.3565  1.1632  5.8292
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.309200   1.059482   2.180  0.040277 *
cajas        2.740369   0.093472  29.317 < 2e-16 ***
distancia    0.012440   0.002797   4.448  0.000202 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```


```
Residual standard error: 2.287 on 22 degrees of freedom
Multiple R-Squared: 0.9811,    Adjusted R-squared: 0.9794
F-statistic: 570.7 on 2 and 22 DF,  p-value: < 2.2e-16
```

UTN - FRRO - ISI - SG - 2012

12

Resultados con R

gaseosas



UTN - FRRO - ISI - SG - 2012


13

Resultados con R

■ Autocorrelación

Durbin-Watson test

data: tiempo ~ cajas + distancia
DW = 2.1312, p-value = 0.5928
alternative hypothesis: true autocorrelation is greater than 0



No hay evidencia de autocorrelación

UTN - FRRO - ISI - SG - 2012

14

Enfoque matricial

- Ventajoso para el ajuste de modelo.
- Dadas k variables y n observaciones:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + \varepsilon_i, \quad i = 1, 2, \dots, n$$

$$y = X\beta + \varepsilon$$

$$y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \quad X = \begin{bmatrix} 1 & x_{11} & \dots & x_{1k} \\ 1 & x_{21} & \dots & x_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \dots & x_{nk} \end{bmatrix} \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{bmatrix} \quad \varepsilon = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

UTN - FRRO - ISI - SG - 2012

15

Enfoque matricial

■ Ejemplo

> ygaseosas			> Xgaseosas			obs		
V1	V2	V3	V1	V2	V3	tiempo	cajas	distancia
1 9.95	1 1 2 50		1 9.95	2 24.45	8 110	1 9.95	2 24.45	8 110
2 24.45	2 1 8 110		2 24.45	3 31.75	11 120	2 24.45	3 31.75	11 120
3 31.75	3 1 11 120		3 31.75	4 35.00	10 550	3 31.75	4 35.00	10 550
4 35.00	4 1 10 550		4 35.00	5 25.02	8 295	4 35.00	5 25.02	8 295
5 25.02	5 1 8 295		5 25.02	6 16.86	4 200	5 25.02	6 16.86	4 200
6 16.86	6 1 4 200		6 16.86	7 14.38	2 375	6 16.86	7 14.38	2 375
7 14.38	7 1 2 375		7 14.38	8 9.60	2 52	7 14.38	8 9.60	2 52
8 9.60	8 2 52		8 9.60	9 24.35	9 100	8 9.60	9 24.35	9 100
9 24.35	9 1 9 100		9 24.35	10 27.50	8 300	9 24.35	10 27.50	8 300
10 27.50	10 1 8 300		10 27.50	11 17.08	4 412	10 27.50	11 17.08	4 412
11 17.08	11 1 4 412		11 17.08	12 37.00	11 400	11 17.08	12 37.00	11 400
12 37.00	12 1 11 400		12 37.00	13 41.95	12 500	12 37.00	13 41.95	12 500
13 41.95	13 1 12 500		13 41.95	14 11.66	2 360	13 41.95	14 11.66	2 360
14 11.66	14 1 2 360		14 11.66	15 21.65	4 205	14 11.66	15 21.65	4 205
15 21.65	15 1 4 205		15 21.65	16 17.89	4 400	15 21.65	16 17.89	4 400
16 17.89	16 1 4 400		16 17.89	17 120.600	600	16 17.89	17 120.600	600
17 120.600	17 1 120.600		17 120.600	18 10.30	1 585	17 120.600	18 10.30	1 585
18 10.30	18 1 1 585		18 10.30	19 34.93	10 540	18 10.30	19 34.93	10 540
19 34.93	19 1 10 540		19 34.93	20 46.59	15 250	19 34.93	20 46.59	15 250
20 46.59	20 1 15 250		20 46.59	21 44.88	15 290	20 46.59	21 44.88	15 290
21 44.88	21 1 15 290		21 44.88	22 54.12	16 510	21 44.88	22 54.12	16 510
22 54.12	22 1 16 510		22 54.12	23 56.23	17 590	22 54.12	23 56.23	17 590
23 56.23	23 1 17 590		23 56.23	24 22.13	6 100	23 56.23	24 22.13	6 100
24 22.13	24 1 6 100		24 22.13	25 21.15	5 400	24 22.13	25 21.15	5 400
25 21.15	25 1 5 400		25 21.15			25 21.15		

UTN - FRRO - ISI - SG - 2012

16

Estimación de los parámetros Mínimos cuadrados

- Min $\sum \varepsilon_i^2 = \varepsilon' \varepsilon = (y - X\beta)'(y - X\beta)$

$$\frac{\partial \sum \varepsilon_i^2}{\partial \beta} \bigg|_{\hat{\beta}} = -2X'y + 2X'X\hat{\beta} = 0 \Rightarrow X'X\hat{\beta} = X'y$$

$$\hat{\beta} = (X'X)^{-1} X'y$$

- El modelo ajustado es:

$$\hat{y} = X\hat{\beta} \longrightarrow e = y - \hat{y}$$

$$\hat{y} = X\hat{\beta} = X(X'X)^{-1} X'y \longrightarrow \hat{y} = Hy$$

UTN - FRRO - ISI - SG - 2012

17

Enfoque matricial

- Estimación de parámetros $\hat{\beta} = (X'X)^{-1} X'y$

> Xgas<-as.matrix(Xgaseosas)

> ygas<-as.matrix(ygaseosas)

> inv(t(Xgas)%*%Xgas)%*%(t(Xgas)%*%ygas)

V1

V1 2.30920043

V2 2.74036942

V3 0.01243958

$$\begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{bmatrix} = \begin{bmatrix} 2,309 \\ 2,740 \\ 0,012 \end{bmatrix}$$

$$\hat{y} = 2,309 + 2,740x_1 + 0,012x_2$$

UTN - FRRO - ISI - SG - 2012

18

Valores ajustados y residuales

valores ajustados

```
> RegModel.gaseosas$fitted
      1      2      3      4      5      6      7      8
8.411918 25.600510 33.946014 36.554664 27.901832 15.758594 12.454782 8.436798
      9     10     11     12     13     14     15     16
28.216483 27.964030 18.395786 37.429097 41.413424 12.268189 15.820792 18.246511
     17     18     19     20     21     22     23     24
64.580338 12.326725 36.430269 46.524637 47.022220 52.499298 56.234834 19.995375
     25
20.986880
```

residuales

$$e = y - \hat{y}$$

```
> RegModel.gaseosas$res
      1      2      3      4      5      6
1.538081654 -1.150509771 -2.196013856 -1.554664427 -2.881832327 1.101405600
      7      8      9     10     11     12
1.925217705 1.163202492 -3.886483381 -0.464030234 -1.315785653 -0.429096643
     13     14     15     16     17     18
0.536575795 -0.608188574 5.829207693 -0.356510677 4.419662267 -2.026724961
     19     20     21     22     23     24
-1.500268613 0.06362869 -2.142220386 1.620702286 -0.004833648 2.134624890
     25
0.163119899
```

UTN - FRRO - ISI - SG - 2012

19

Propiedades de los estimadores de β

- Se demuestra que $E(\hat{\beta}) = \beta$

$$\text{cov}(\hat{\beta}) = \sigma^2 (X'X)^{-1}$$

$$C = (X'X)^{-1} \rightarrow \text{cov}(\hat{\beta}) = \sigma^2 C$$

```
> inv(t(Xgas)%*%Xgas)
      V1      V2      V3
V1 0.2146526166 -7.490914e-03 -3.403891e-04
V2 -0.0074909142 1.670763e-03 -1.891781e-05
V3 -0.0003403891 -1.891781e-05 1.495876e-06
```

$$V(\hat{\beta}_j) = \sigma^2 C_{jj}, \quad j = 0, 1, 2$$

$$\text{cov}(\hat{\beta}_i, \hat{\beta}_j) = \sigma^2 C_{ij}, \quad i \neq j$$

$$S_{XX} = \sum_{i=1}^n (X_i - \bar{X})^2$$

UTN - FRRO - ISI - SG - 2012

20

Varianza y desvío estándar del residual

$$\hat{\sigma}_e^2 = S_e^2 = \frac{SC_e}{n - k - 1}$$

$S_e = 2.287 \text{ min}$

$$SC_e = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n e_i^2$$

$$SC_e = e'e = (y - X\hat{\beta})'(y - X\hat{\beta})$$

$$SC_e = y'y - \hat{\beta}'X'y - y'X\hat{\beta} + \hat{\beta}'X'X\hat{\beta}$$

$$SC_e = y'y - 2\hat{\beta}'X'y + \hat{\beta}'X'X\hat{\beta}$$

$$S_e^2 = \frac{y'y - \hat{\beta}'X'y}{n - k - 1}$$

UTN - FRRO - ISI - SG - 2012

21

Pruebas de hipótesis para β_i

- $H_0: \forall i: \beta_i = 0$
- $H_1: \exists \beta_i \neq 0$

```
> RegModel.gaseosas <- lm(tiempo~cajas+distancia, data=gaseosas)
> summary(RegModel.gaseosas)
```

```
Call:
lm(formula = tiempo ~ cajas + distancia, data = gaseosas)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-3.8665 -1.5003 -0.3565  1.1632  5.8292
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2.309200	1.059482	2.180	0.040277 *
cajas	2.740369	0.093472	29.317	< 2e-16 ***
distancia	0.012440	0.002797	4.448	0.000202 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.287 on 22 degrees of freedom
Multiple R-Squared: 0.9811, Adjusted R-Squared: 0.9794
F-statistic: 570.7 on 2 and 22 DF, p-value: < 2.2e-16

$$F_0 = \frac{SC_R / k}{SC_e / (n - k - 1)}$$

- Si se rechaza que $\forall i: \beta_i = 0$
- $H_0: \beta_i = 0$
- $H_1: \beta_i \neq 0$

$$\hat{\sigma}_{b1} = s_e \sqrt{C_{11}}$$

UTN - FRRO - ISI - SG - 2012

22

Multicolinealidad

- Es la violación del supuesto **Las xi son linealmente independientes**
- Existe multicolinealidad si hay fuerte dependencia **lineal** entre las variables x_j
- Tiene efecto serio sobre las estimaciones de los coeficientes de regresión, las vuelve muy imprecisas (varianzas grandes)
- Aún así la estimación (por interpolación) del modelo ajustado puede ser útil.

UTN - FRRO - ISI - SG - 2012

23

Multicolinealidad

$$\text{cov}(\hat{\beta}) = \sigma^2 C \quad V(\hat{\beta}_j) = \sigma^2 C_{jj}, \quad j = 0, 1, 2$$

$$C = (X'X)^{-1}$$

VIF: factor de inflación de varianza para β_j

$$C_{jj}^* = \frac{1}{(1 - R_j^2)}$$

Coefficiente de correlación múltiple de x_j sobre las $k-1$ variables restantes

$$\text{nuevo } X_{ij} = \frac{\text{viejo } X_{ij} - \text{viejo } \bar{X}_j}{\sum_{i=1}^n (x_{ij} - \bar{x}_j)^2}$$

Se trabaja con variables centradas y escaladas con factor unidad

UTN - FRRO - ISI - SG - 2012

24

Multicolinealidad

$$\text{nuevo } X_{ij} = \frac{\text{viejo } X_{ij} - \text{viejo } \bar{X}_j}{\sqrt{\sum_{i=1}^n (x_{ij} - \bar{x}_j)^2}}$$

Se detecta con:

- Factores de inflación de varianza (diagonal principal de $(X'X)^{-1}$): si alguno supera 5 ó 10
- Determinante de $X'X$: valor próximo a 0
- Valores propios (λ) de $X'X$: próximos a 0. Un valor propio 0 indica presencia de una variable combinación lineal de otras. $\lambda_{\max}/\lambda_{\min} > 100$
- Incongruencia entre la F y las t's, al probar la significación de la regresión

UTN - FRRO - ISI - SG - 2012

25

Resultados con R

- Factores de inflación de varianza (*variance inflation factors*)

```
> vif(RegModel.gaseosas)
cajas      distancia
1.167128    1.167128
```

$$\text{nuevo } X_{ij} = \frac{\text{viejo } X_{ij} - \text{viejo } \bar{X}_j}{\sqrt{\sum_{i=1}^n (x_{ij} - \bar{x}_j)^2}}$$

UTN - FRRO - ISI - SG - 2012

26

Muticolinealidad

- Hay varios métodos para eliminarla
- Solo estudiaremos el **más rudimentario**: buscar las variables con posible relación lineal y eliminar alguna de ellas.
 - Gráfico de dispersión múltiple
 - Matriz de correlación entre las variables explicativas

UTN - FRRO - ISI - SG - 2012

27

Intervalos de confianza para los parámetros

- Resultados con R

```
> Confint(RegModel.gaseosas, level=0.95)
                2.5 %      97.5 %
(Intercept)  0.111969586  4.50643127
cajas        2.546519768  2.93421908
distancia    0.006639215  0.01823995
```

UTN - FRRO - ISI - SG - 2012

28

Coefficiente de determinación ajustado

$$R^2 = \frac{SC_R}{SC_T}$$

$$R^2 = 1 - \frac{SC_e}{SC_T}$$

$$R^2_{ajustado} = 1 - \frac{SC_e / (n - k - 1)}{SC_T / (n - 1)}$$

$$R^2_{ajustado} = 1 - \frac{SC_e}{SC_T} \frac{n-1}{n-k-1}$$

$R^2_{ajustado}$ tiende al R^2 cuando es necesario estimar pocos parámetros respecto de la cantidad de observaciones

UTN - FRRO - ISI - SG - 2012

29

Resultados con R

```
> RegModel.gaseosas <- lm(tiempo-cajas+distancia, data=gaseosas)
```

```
> summary(RegModel.gaseosas)
```

```
Call:
lm(formula = tiempo ~ cajas + distancia, data = gaseosas)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-3.8665 -1.5003 -0.3565  1.1632  5.8292
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.309200   1.059482   2.180  0.040277 *
cajas        2.740369   0.093472  29.317 < 2e-16 ***
distancia    0.012440   0.002797   4.448  0.000202 ***
```

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 2.287 on 22 degrees of freedom
Multiple R-Squared: 0.9811, Adjusted R-squared: 0.9794
F-statistic: 570.7 on 2 and 22 DF, p-value: < 2.2e-16
```

UTN - FRRO - ISI - SG - 2012

30

Intervalo de confianza para

$$E(Y) = \mu_{Y/x_1 \dots x_k}$$


- una variable explicativa

$$IC_{\alpha+1;1-\alpha} = \left[a + bx_i \pm t_{n-2;1-\alpha} S_e \sqrt{\frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{xx}}} \right]$$

- k variables explicativas

$$IC_{\mu_{Y/x_0};1-\alpha} = \left[\hat{\mu}_{Y/x_0} \pm t_{n-k-1;1-\alpha} S_e \sqrt{x_0' (X'X)^{-1} x_0} \right]$$

$$x_0' = [1; x_{01}; x_{02}; \dots; x_{0k}] \quad \hat{\mu}_{Y/x_0} = x_0' \hat{\beta}$$



Resultados con R

- Construir un intervalo de confianza para el tiempo promedio de suministro a una máquina que requiere 8 cajas y está a 275 metros

```
> x0      > beta      > esperanza<-t(x0)%*%beta
var1      v1      > esperanza
1 1      V1 2.30920043      v1      > t(x0)%*%inv(t(Xgas)%*%Xgas)%*%x0
2 8      V2 2.74036942      var1 27.65304      var1
3 275     V3 0.01243958      var1 0.04440008
```

$$IC_{\mu_{Y/x_0};0.95} = [27.65304 \pm t_{22;0.95} 2.287 \sqrt{0.04440008}]$$


$$IC_{\mu_{Y/x_0};0.95} = [26.65; 28.65]$$

Intervalo de predicción

$$IP_{y_0;1-\alpha} = \left[\hat{y}_0 \pm t_{n-k-1;1-\alpha} S_e \sqrt{1 + x_0' (X'X)^{-1} x_0} \right]$$

```
> x0
var1
1 1
2 8
3 275
```

$$IP_{y_0;0.95} = [22.81; 32.50]$$



Residuales y Diagnóstico: Resultados con R

gaseosas									
	tiempo	cajas	distancia	tiempo	residuals	student	hatvalue	cooks	distancia
1	9.95	2	50	8.411910	1.530081654	0.724731806	0.15728923	3.339853e-02	
2	24.45	8	110	25.600510	-1.150509771	-0.524929428	0.11164598	1.193657e-02	
3	31.75	11	120	33.946014	-2.196013856	-1.038530899	0.14191905	5.924916e-02	
4	35.00	10	550	36.554664	-1.554664427	-0.709225737	0.10188923	1.946110e-02	
5	25.02	8	295	27.901852	-2.881832327	-1.308030223	0.04178381	2.409053e-02	
6	16.86	4	200	15.758594	1.101405600	0.492048154	0.07466842	6.764164e-03	
7	14.38	2	375	12.454782	1.925217705	0.892307076	0.11806106	3.586057e-02	
8	9.60	2	52	8.436798	1.163202492	0.544789313	0.15608149	1.890119e-02	
9	24.35	9	100	28.216483	-3.866483381	-1.917627027	0.12797685	1.603746e-01	
10	27.50	8	300	27.964030	-0.464030234	-0.202677685	0.04131672	6.170154e-04	
11	17.08	4	412	18.395786	-1.315785653	-0.595080108	0.09253979	1.240142e-02	
12	37.00	11	400	37.429097	-0.429096443	-0.188504130	0.05256700	6.873125e-04	
13	41.95	12	500	41.413424	0.536575795	0.239597205	0.08202675	1.786480e-03	
14	11.66	2	360	12.268189	-0.608188574	-0.276386721	0.11291577	3.383213e-03	
15	21.65	4	205	15.820792	5.829207693	3.135448482	0.07373697	1.861502e-01	
16	17.89	4	400	18.246511	-0.356510677	-0.159587604	0.08794942	8.565804e-04	
17	69.00	20	600	64.580338	4.419662267	2.499154552	0.25934228	5.886326e-01	
18	10.30	1	585	12.326725	-2.026724961	-1.056747956	0.29287870	1.533619e-01	
19	34.93	10	540	36.430269	-1.500268613	-0.681634995	0.09617553	1.689127e-02	
20	46.59	15	250	46.524637	0.065362869	0.030241643	0.14726101	5.515002e-05	
21	44.88	15	290	47.022220	-2.142220386	-1.004325956	0.12463943	5.006047e-02	
22	54.12	16	510	52.499298	1.620702286	0.754889040	0.13580052	3.044443e-02	
23	56.23	17	590	56.234834	-0.004833648	-0.002283869	0.18237610	4.062924e-07	
24	22.13	6	100	19.995375	2.134624850	0.988443804	0.10908869	3.991920e-02	
25	21.15	5	400	20.986880	0.165115889	0.072878527	0.07287021	1.437841e-04	

$$\hat{y} = X\hat{\beta} \quad e = y - \hat{y} \quad h_{ii} = x_i' (X'X)^{-1} x_i \quad \frac{(h_{ii} - \beta) X'X (\hat{\beta}_0 - \beta)}{p\hat{\sigma}^2}$$

Residuales y Diagnóstico: Resultados con R

- Residuos estudentizados internos

```
> rstandard(RegModel.gaseosas)
1      2      3      4      5      6
0.732680611 -0.533791746 -1.036681920 -0.717375084 -1.287394160 0.500749018
7      8      9      10     11     12
0.896468774 0.553706531 -1.810617526 -0.207244627 -0.604012506 -0.192777099
13     14     15     16     17     18
0.244901048 -0.282377706 2.648603461 -0.163244162 2.245716263 -1.053955887
19     20     21     22     23     24
-0.690083358 0.030952635 -1.004128102 0.762378820 -0.002337614 0.988960420
25
0.074081754
```

$$r_i = \frac{e_i}{\sqrt{\hat{\sigma}^2(1-h_{ii})}} \quad h_{ii} = x_i' (X'X)^{-1} x_i$$

Matriz
sombbrero

$$H = X(X'X)^{-1} X'$$


$$\hat{y} = X\hat{\beta} = X(X'X)^{-1} X'y = Hy$$

Variables Indicadoras

Problema:

- Un ingeniero mecánico desea relacionar la vida útil (y) de una herramienta en un torno, con la velocidad del torno, en revoluciones por minuto (rpm). Supone que influye también la clase de herramienta que se usa (A o B).


Variables Indicadoras



UTN - FRRO - ISI - SG - 2012

37


Variables Indicadoras



UTN - FRRO - ISI - SG - 2012

38


Variables Indicadoras



UTN - FRRO - ISI - SG - 2012

39


Variables Indicadoras



UTN - FRRO - ISI - SG - 2012

40

Variables Indicadoras




UTN - FRRO - ISI - SG - 2012

41

Variables indicadoras


- Kilometraje vs precio para autos de distinto color
- n=100



UTN - FRRO - ISI - SG - 2012

42

Variables indicadoras



UTN - FRRo - ISI - SG - 2012

43

Variables indicadoras

```
> summary(RegModel.artificial, cor=FALSE)
```

Call:

```
lm(formula = Precio ~ blanco + Kilometraje + plata, data = autos)
```

Residuals:

Min	1Q	Median	3Q	Max
-664.567	-193.410	-5.791	197.370	639.467

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2.670e+04	1.843e+02	144.852	< 2e-16 ***
blanco	9.048e+01	6.817e+01	1.327	0.187546 ← no significativo
Kilometraje	-3.703e-02	3.158e-03	-11.724	< 2e-16 ***
plata	2.955e+02	7.637e+01	3.869	0.000199 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 284.5 on 96 degrees of freedom
Multiple R-Squared: 0.698, Adjusted R-squared: 0.6886
F-statistic: 73.97 on 3 and 96 DF, p-value: < 2.2e-16

UTN - FRRo - ISI - SG - 2012

44

Variables indicadoras

```
> summary(RegModel.artificial1, cor=FALSE)
```

Call:

```
lm(formula = Precio ~ Kilometraje + plata, data = autos)
```

Residuals:

Min	1Q	Median	3Q	Max
-713.7948	-199.4519	0.9354	183.3033	683.1844

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2.674e+04	1.826e+02	146.452	< 2e-16 ***
Kilometraje	-3.689e-02	3.169e-03	-11.641	< 2e-16 ***
plata	2.489e+02	6.809e+01	3.655	0.000417 ***


Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 285.7 on 97 degrees of freedom
Multiple R-Squared: 0.6925, Adjusted R-squared: 0.6862
F-statistic: 109.2 on 2 and 97 DF, p-value: < 2.2e-16

UTN - FRRo - ISI - SG - 2012

45

Variables indicadoras



UTN - FRRo - ISI - SG - 2012

46

Bibliografía

- Montgomery D ; Peck E ; Vining G (2004): *Introducción al análisis de regresión lineal*, 3ª edición. CECSA. ISBN: 970-24-0327-8 (biblioteca.fcecon.unr.edu.ar/bib1/ 109263, 519.27 M787in)
- Montgomery D, Runger (1996): *Probabilidad y Estadística aplicadas a la ingeniería*. Ed Mc Graw Hill
- <http://pbil.univ-lyon1.fr/library/MPV/html/00Index.html>
Data sets de Montgomery, Peck, Vining
- www.engr.sjsu.edu/ahambaba/course2/chapter11.ppt

UTN - FRRo - ISI - SG - 2012

47