


PRONOSTICOS

Ing. Cristian G. Bigatti
UTN – FRRo - 2014

Tipos de pronósticos



UTN - FRRo - ISI - Sistemas de Gestión - 2014

2

Ejemplo de aplicación

■ Venta de alimentos para mascotas

Tienda	Espacio (pies)	Ventas semanales (\$00)
1	5	1,6
2	5	2,6
3	5	1,4
4	10	1,9
5	10	2,4
6	10	2,6
7	15	2,3
.	.	.
.	.	.


UTN - FRRo - ISI - Sistemas de Gestión - 2014

3

Regresión Lineal Simple

Y: ventas semanales de alimento para mascotas, en \$00
x: espacio destinado a la exhibición del producto, en dm
Unidad de observación: supermercado de una cadena

n=12



UTN - FRRo - ISI - Sistemas de Gestión - 2014

4

Regresión Lineal Simple


■ Modelo poblacional

Suponemos que:

- ϵ tiene
 - promedio 0 y
 - varianza constante σ_ϵ^2
 - ϵ_i, ϵ_j independientes
- x no es aleatorio

Entonces:

- Promedio de Y:
 $E(Y/x) = \mu_{Y/x} = \alpha + \beta x$
- Varianza de Y:
 $V(Y/x) = V(\epsilon) = \sigma_\epsilon^2$



UTN - FRRo - ISI - Sistemas de Gestión - 2014

5

Regresión Lineal Simple

■ Modelo poblacional $Y = \alpha + \beta x + \epsilon$

Y: variable dependiente o respuesta

x: variable independiente, explicativa, regresor o predictor

α, β : coeficientes desconocidos de la regresión

β : cambio promedio en la respuesta ante cambios unitarios en el regresor

ϵ : error aleatorio

UTN - FRRo - ISI - Sistemas de Gestión - 2014

6

Modelo de Regresión Lineal Múltiple

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \varepsilon$$

- Respuesta relacionada con k regresores.
- Lineal indica que el modelo es lineal en los parámetros, **NO** que E(Y) es una función lineal de las x_i
- $Y = \beta_0 + \beta_1 x + \beta_2 x^2 + \varepsilon$ puede trabajarse como una regresión lineal múltiple.

UTN - FRRO - ISI - Sistemas de Gestión - 2014

7

Fases del Análisis de Regresión

- **Estimar los parámetros desconocidos** del modelo. Ajuste del modelo a los datos.
- **Comprobación de la adecuación del modelo.**

UTN - FRRO - ISI - Sistemas de Gestión - 2014

8

Recolección de Datos

- El Análisis de Regresión es **tan bueno como los datos** con los que se calcula.
- Tres modos básicos:
 - Estudio retrospectivo: datos históricos
 - Estudio observacional
 - Experimento diseñado


UTN - FRRO - ISI - Sistemas de Gestión - 2014

9

REGRESION LINEAL SIMPLE

Regresión Lineal Simple

Y: ventas semanales de alimento para mascotas, en \$00
 x: espacio destinado a la exhibición del producto, en dm
 Unidad de observación: supermercado de una cadena
 n=12



	Espacio	Ventas
1	5	1.6
2	5	2.2
3	5	1.4
4	10	1.9
5	10	2.4
6	10	2.6
7	15	2.3
8	15	2.7
9	15	2.8
10	20	2.6
11	20	2.9
12	20	3.1

UTN - FRRO - ISI - Sistemas de Gestión - 2014


11

Regresión Lineal Simple

- **Modelo muestral teórico** para n observaciones:

$$y_i = \alpha + \beta x_i + \varepsilon_i \quad i=1,2,\dots,n$$

Próximo paso: estimar los parámetros a partir de los datos



UTN - FRRO - ISI - Sistemas de Gestión - 2014

12

Fase 1: Estimación de α y β
Mínimos cuadrados

Estimadores insesgados de varianza mínima

$y_i = \alpha + \beta x_i + \varepsilon_i$ $i=1,2,\dots,n$

$\min \sum (y_i - \alpha - \beta x_i)^2$

$$\begin{cases} a = \bar{y} - b\bar{x} \\ b = \frac{S_{XY}}{S_{XX}} \end{cases}$$

$$S_{XY} = \sum_{i=1}^n y_i(x_i - \bar{x})$$

$$S_{XX} = \sum_{i=1}^n (x_i - \bar{x})^2$$

$e_i = y_i - a - bx_i$

e_i : residual

UTN - FRRO - ISI - Sistemas de Gestión - 2014 13

Estimación de α y β

$\min \sum \varepsilon_i^2$
 $\min [(1.6 - \alpha - 5\beta)^2 + (2.2 - \alpha - 5\beta)^2 + \dots + (3.1 - \alpha - 20\beta)^2]$

$\hat{\beta} = b = 0.074$
 $\hat{\alpha} = a = 1.45$

$\hat{y}_i = 1.45 + 0.074 \cdot x_i$

Recta de regresión ajustada

UTN - FRRO - ISI - Sistemas de Gestión - 2014 14

Modelo de uso

■ **Residual o residuo:** es la diferencia entre el valor observado y el estimado

$y_i - \hat{y}_i = e_i$
 $y_i = \hat{y}_i + e_i$

■ Modelo muestral **estimado**

$y_i = a + bx_i + e_i$ en el intervalo de estudio

■ Ej.: $y_i = 1.45 + 0.074 x_i + e_i$ para $5 \leq x \leq 20$

Dedicar 1 dm más de espacio a exhibir alimento de mascotas produce un aumento promedio de las ventas de \$7.40 aproximadamente.

UTN - FRRO - ISI - Sistemas de Gestión - 2014 15

Error y Residuo

■ $Y = \alpha + \beta X + \varepsilon \longrightarrow \varepsilon = Y - \alpha - \beta X$

Modelo teórico

Error aleatorio desconocido

■ Estimación: $\hat{y}_i = a + bx_i$

■ Residuo $\longrightarrow e_i = y_i - \hat{y}_i$

UTN - FRRO - ISI - Sistemas de Gestión - 2014 16

Modelo poblacional/Modelo estimado

$\hat{y}_i = \hat{E}(Y / x_i)$

Venta de alimentos para mascotas

media muestral: $\hat{y}_i = a + bx_i = 1.82$

estima a $E(Y|x=5)$

Estimación puntual (interpolación)

$x = 8 \Rightarrow \hat{y} = 1.45 + 0.074 \cdot 8 = 2.042 = \204.20

UTN - FRRO - ISI - Sistemas de Gestión - 2014 17

Estimación de σ_ε^2

■ Si el ajuste lineal es bueno:

$$\hat{\sigma}_\varepsilon^2 = S^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - a - bx_i)^2$$

S es el desvío estándar de los residuos
Es una estimación de σ_ε **dependiente del modelo** porque se calcula con los residuales

UTN - FRRO - ISI - Sistemas de Gestión - 2014 18



Modelos

Poblacional

$$Y = \alpha + \beta x + \varepsilon \quad \sigma_{\varepsilon}^2$$

$$y_i = a + bx_i + e_i \quad S_e^2$$

Muestral



Análisis de supuestos

Antes de adoptar el modelo, investigar:

- ¿Qué tan bien ajusta la ecuación a los datos?
- El modelo ¿será útil para pronosticar?
- ¿Se viola alguna de las hipótesis básicas?
- Si se violan, ¿es grave?

Pruebas de hipótesis. Intervalos de Confianza

- Para realizar inferencias es necesario que los errores ε tengan **distribución normal**. Esta exigencia se suma a las anteriores:

- promedio 0
- varianza constante σ_{ε}^2
- $\varepsilon_i, \varepsilon_j$ independientes

- Ahora pedimos

ε_i se distribuyen NID ($0; \sigma_{\varepsilon}^2$)

NID: normally and independently distributed

Pruebas de hipótesis. Intervalos de Confianza Distribuciones

- Si ε_i son NID ($0; \sigma_{\varepsilon}^2$)

$$b \cdot es \cdot N\left(\beta; \frac{\sigma_{\varepsilon}^2}{S_{XX}}\right) \longrightarrow \frac{b - \beta}{\frac{S_e}{\sqrt{S_{XX}}}} \cdot es \cdot t_{n-2}$$

Si bien la estimación de α *no siempre es de interés*:

$$a \cdot es \cdot N\left(\alpha; \sigma_{\varepsilon}^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{S_{XX}}\right)\right) \longrightarrow \frac{a - \alpha}{S_e \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{S_{XX}}}} \cdot es \cdot t_{n-2}$$

$$S_{XX} = \sum_{i=1}^n (x_i - \bar{x})^2$$

Significancia de la regresión

$$\text{Modelo: } Y = \alpha + \beta x + \varepsilon$$


H_0) x e Y no están linealmente relacionadas $\Rightarrow \beta = 0$

H_1) x e Y están relacionadas $\Rightarrow \beta \neq 0$


Prueba t de Student

$$t_0 = \frac{b}{\frac{S_e}{\sqrt{S_{XX}}}}$$


Rechazar si: $|t_0| > t_{crítico}$
valor - p asociado(t_0) < α



Significancia de la regresión



Resultados



UTN - FRRO - ISI - Sistemas de Gestión - 2014

25

Intervalo de confianza para β

- Si se rechaza $H_0: \beta=0$, puede ser interesante estimar el valor del parámetro, tanto en forma puntual como con intervalo de confianza.

$$\hat{\beta} = b$$

$$IC_{\beta; 1-\alpha} = \left[b \pm t_{n-2; 1-\alpha} \frac{S_e}{\sqrt{S_{xx}}} \right]$$

$$\frac{b - \beta}{\frac{S_e}{\sqrt{S_{xx}}}} \cdot es \cdot t_{n-2}$$

UTN - FRRO - ISI - Sistemas de Gestión - 2014

26

Resultados

Coeficientes ^a								
Modelo	Coeficientes no estandarizados		Coeficientes tipificados		t	Sig.	Intervalo de confianza de 95,0% para B	
	B	Error tip.	Beta				Límite inferior	Límite superior
1 (Constante)	1,450	,218			6,657	,000	,966	1,935
Espacio	,074	,016	,827	4,652	,001		,039	,109

a. Variable dependiente: Ventas semanales

El intervalo [\$3.90;\$10.90] cubre el valor del aumento promedio de las ventas de alimento para mascotas que se obtiene al dedicar 1 dm más de espacio a exhibirlo. La confianza en este resultado es del 95%.

UTN - FRRO - ISI - Sistemas de Gestión - 2014

27

Predicción

- Intervalo de confianza para $\alpha+\beta x$
 - ¿Cuál sería la **venta semanal promedio** de un súper que dedique x dm a exhibir el producto?
¿cuál es el error de estimación?
- Intervalo de predicción
 - Con una probabilidad determinada ¿dentro de qué intervalo se encontrará la **venta semanal** de un súper que dedique x dm a exhibir el producto?

UTN - FRRO - ISI - Sistemas de Gestión - 2014

28

Diferencia entre ambos intervalos

- Intervalo de confianza:** estima un parámetro poblacional con medida de error y confianza
- Intervalo de predicción:** asociado a una probabilidad de ocurrencia de un evento futuro

UTN - FRRO - ISI - Sistemas de Gestión - 2014

29


Intervalo de confianza para $\mu_{Y/x}$

- El promedio poblacional de Y es:
 $\mu_{Y/x} = \alpha + \beta x$ lo estimamos con $\hat{y} = a + bx$

$$V(a + bx) = S^2 \left[\frac{1}{n} + \frac{(x - \bar{x})^2}{S_{xx}} \right]$$

$$S^2 = \frac{1}{n-2} \sum e_i^2$$

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2$$




UTN - FRRO - ISI - Sistemas de Gestión - 2014

30

Intervalo de confianza para $\mu_{Y/x}$

- $IC_{\alpha+\beta x; 1-\alpha} = [(a+bx) + \text{error de estimación}]$


$$IC_{\alpha+\beta x; 1-\alpha} = \left[a + bx_i \pm t_{n-2; 1-\alpha} S_e \sqrt{\frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{XX}}} \right]$$



Intervalo de predicción para una observación futura con probabilidad $1-\alpha$


$$IP_{y_0; 1-\alpha} = \left[a + bx_i \pm t_{n-2; 1-\alpha} S_e \sqrt{1 + \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{XX}}} \right]$$

Resultados



Coefficiente de Determinación

- medida de la capacidad explicativa del modelo de Regresión



Coefficiente de Determinación

- Variabilidad en el modelo a una variable:

$$S_y^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2$$

SC_T


- Descomposición:

$$y_i - \bar{y} = y_i - a - bx_i + a + bx_i - \bar{y}$$

$$y_i - \bar{y} = e_i + \hat{y}_i - \bar{y}$$

$$\sum (y_i - \bar{y})^2 = \sum e_i^2 + \sum (\hat{y}_i - \bar{y})^2 + 2 \sum e_i (\hat{y}_i - \bar{y})$$

$$SC_T = SC_e + SC_R$$



se anula

No tienen en cuenta los grados de libertad

Coefficiente de Determinación

Se define:

$$R^2 = \frac{SC_R}{SC_T}$$

Proporción de la variabilidad de la variable dependiente que se explica por la regresión

$$0 \leq R^2 \leq 1$$

Resultados

Resumen del modelo

Modelo	R	R cuadrado	R cuadrado corregida	Error típ. de la estimación
1	,827	,684	,652	,3081

a. Variables predictoras: (Constante), Espacio

El 68% de la variabilidad de las ventas semanales se explica por el espacio dedicado a exhibir el alimento para mascotas

Análisis de supuestos y Diagnóstico

Hipótesis básicas

Modelo poblacional

$$Y = \alpha + \beta x + \epsilon$$

□ ϵ tiene

- promedio 0
- varianza constante σ_ϵ^2
- ϵ_i, ϵ_j independientes
- distribución normal


□ x no es aleatorio

ϵ_i es NID $(0; \sigma_\epsilon^2)$

¿ x es aleatoria?

- Depende de cómo se hayan tomado los datos.
 - Si x es aleatoria: el regresor x debe ser independiente del residuo e
 - Para verificar graficar residual contra x . En nuestro caso de regresión simple es lo mismo que graficar contra el ajustado.

¿Distribución Normal?



Histograma de Residuos

¿Distribución Normal?




Gráfico de probabilidad normal

¿Distribución Normal?




Gráfico de probabilidad normal

¿Distribución Normal?

H_0 : Normalidad

H_A : No normalidad

Pruebas de normalidad						
	Kolmogorov-Smirnov ^a			Shapiro-Wilk		
	Estadístico	gl	Sig.	Estadístico	gl	Sig.
Unstandardized Residual	,190	12	,200	,913	12	,231

^a. Este es un límite inferior de la significación verdadera.

a. Corrección de la significación de Lilliefors

Residuo vs Ajustado


■ Para verificar:

1. ajuste


2. $E(\epsilon)=0$

3. $V(\epsilon)=\sigma_\epsilon^2$

homocedasticidad




Resultados



¿Centrado errores?

$H_0: \epsilon = 0$

$H_A: \epsilon \neq 0$



¿Centrado errores?

$H_0: \epsilon = 0$

$H_A: \epsilon \neq 0$

Prueba para una muestra						
	Valor de prueba = 0					
	t	gl	Sig. (bilateral)	Diferencia de medias	95% Intervalo de confianza para la diferencia	
					Inferior	Superior
Unstandardized Residual	,000	11	1,000	0E-8	-,1866222	,1866222

¿Varianza constante?

H_0 : Errores homocedásticos

H_A : Heterocedasticidad

Prueba de homogeneidad de varianzas

Unstandardized Residual

Estadístico de Levene	gl1	gl2	Sig.
.214	2	9	.811

¿Independencia de los errores?

- La falta de independencia de los errores se conoce como **autocorrelación**.
- Es un fenómeno que se presenta cuando las observaciones se toman espaciadas en el tiempo.
- Para evitarlo se recomienda, de ser posible, realizar las observaciones simultáneamente.

Coeficiente de Correlación Lineal

$$r = \frac{\text{cov}(XY)}{S_X S_Y} = \frac{S_{XY}}{\sqrt{S_{XX} S_{YY}}}$$

$$r = 0.97$$




Autocorrelación

- El gerente de una tienda desea predecir las ventas semanales de acuerdo al número de clientes. Cuenta con datos recopilados durante 15 semanas consecutivas en la misma tienda.

semana	clientes	ventas
1	794	9,33
2	799	8,26
3	837	7,48
4	855	9,08
5	845	9,83
6	844	10,09
7	863	11,01
8	875	11,49
9	880	12,07
10	905	12,55
11	886	11,92
12	843	10,27
13	904	11,8
14	950	12,15
15	841	9,64

Autocorrelación

- Ventas semanales



Autocorrelación

- Estadístico Durbin Watson (valor aproximado)

Dataset.7			
	Semanas	Clientes	Ventas
1	1	794	9.33
2	2	799	8.26
3	3	837	7.48
4	4	855	9.08
5	5	845	9.83
6	6	844	10.09
7	7	863	11.01
8	8	875	11.49
9	9	880	12.07
10	10	905	12.55
11	11	886	11.92
12	12	843	10.27
13	13	904	11.80
14	14	950	12.15
15	15	841	9.64

calcular $r = \hat{\rho}_{e_i e_{i-1}}$

Resultados

Resumen del modelo^b

Modelo	R	R cuadrado	R cuadrado corregido	Error tip. de la estimación	Durbin-Watson
1	.827 ^a	.684	.652	.3081	2.509

a. Variables predictoras: (Constante), Espacio

b. Variable dependiente: Ventas semanales

Autocorrelaciones

Serie: Unstandardized Residual

Retardo	Autocorrelación	Tip. Error ^a	Estadístico de Box-Ljung
1	.518	.234	4,890

a. El proceso subyacente asumido es la independencia (ruido blanco).

b. Basado en la aproximación chi cuadrado asintótica.

Rechaza Ho

Transformaciones


El método más usado para remediar la falta de normalidad o la heterocedasticidad es transformar la variable *dependiente*.

1. El tipo de transformación a usar depende de cuál es el supuesto que no se cumple y de la naturaleza de la desviación. Como hay muchas formas de violar los supuestos de la técnica estadística, la lista que aparece a continuación es irremediablemente incompleta.
2. La transformación puede ser útil para mejorar el modelo. Es decir si el modelo lineal parece ser demasiado pobre, a menudo se puede mejorar el ajuste transformando la *y*.
3. Muchos paquetes de computadoras permiten hacer transformaciones con mucha facilidad. Se debe experimentar para ver el efecto que tienen esas transformaciones en los resultados.

Transformaciones más usadas

- **Logarítmica:** $y' = \log y$ (dado que $y > 0$). Se usa cuando:
 - la varianza del error crece con y
 - la distribución del error es asimétrica a derecha.
- **Cuadrática:** $y' = y^2$. Utilice esta transformación cuando:
 - la varianza del error es proporcional al valor esperado de y
 - la distribución del error es asimétrica a izquierda.
- **Raíz cuadrada:** $y' = \sqrt{y}$ (dado que $y > 0$). Es valiosa cuando:
 - la varianza del error es proporcional al valor esperado de y .
- **Recíproca:** $y' = 1/y$. Se recomienda cuando:
 - la varianza parece aumentar significativamente después que y supera un valor crítico.

Leverage: puntos de balanceo e influyentes



Leverage

- El "leverage" de un punto i se define:

$$p_i = \frac{(x_i - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$


$$\sum_i p_i = 1$$

Leverage

$$b = \frac{S_{xy}}{S_{xx}} = \frac{\sum (y_i - \bar{y})(x_i - \bar{x})}{\sum (x_i - \bar{x})^2} = \sum \frac{(y_i - \bar{y})(x_i - \bar{x})^2}{(x_i - \bar{x}) \sum (x_i - \bar{x})^2}$$


$$b = \sum p_i \frac{(y_i - \bar{y})}{(x_i - \bar{x})}$$

Pendiente de la recta que pasa por $(x_i; y_i)$ y por $(\bar{x}; \bar{y})$



Leverage

$$b = \sum p_i \frac{(y_i - \bar{y})}{(x_i - \bar{x})}$$



- La pendiente de la recta de regresión es un promedio ponderado de las pendientes de las rectas que pasan por cada punto y el punto de los promedios de x e y
- La ponderación es el "leverage" de cada punto
- Cuanto mayor es el "leverage" de un punto, la pendiente de la recta de regresión ajustada se acerca más a la pendiente de la recta que pasa por ese punto y el punto de los promedios de x e y

Distancia de Cook

- Es una medida de la influencia de un punto
- La distancia de Cook para un punto $(x_i; y_i)$ es:

$$D_i = \frac{(\hat{y}_i - \hat{y}_{(i)})^2}{2S_e^2 h_i} \quad h_i = \frac{1}{n} + p_i$$

$\hat{y}_{(i)}$ es el valor predicho de la variable respuesta si se elimina la observación $(x_i; y_i)$

- Los puntos con grandes valores de D_i tienen influencia sobre la estimación de β . Se suelen considerar **puntos influyentes** si $D_i > 1$

Bibliografía

- Montgomery D ; Peck E ; Vining G (2004): *Introducción al análisis de regresión lineal*, 3ª edición. CECSA. ISBN: 970-24-0327-8 (biblioteca.fcecon.unr.edu.ar/bib1/ 109263, 519.27 M787in)
- Montgomery D, Runger: Probabilidad y Estadística aplicada a la Ingeniería.
- <http://pbil.univ-lyon1.fr/library/MPV/html/00Index.html>
Data sets de Montgomery, Peck, Vining
- <http://www.stats.uwo.ca/faculty/braun/Rlinks.htm> R
- Regresión con R
- www.engr.sjsu.edu/ahambaba/course2/chapter11.ppt